

Robot-use Benchmark：逐篇来源审阅与集成设计

版本v0.10；2026-10-02。

250篇现有书目全部初筛；143个原登记来源加40个补入来源，共183篇已读数据 / benchmark / 评测相关章节。其余67篇保留方法、原作实验、survey或统计方法索引。不宣称穷尽全球文献。

『已审阅』指核对原作身份并阅读所列PDF页的任务、数据与评测段落；不表示全文逐字精读、原始标注逐题人工复核或程序已重现。

本轮数字与目标

项目	目前确认	下一阶段规划口径
领域	18 来源用途类别。183篇按用途编码；22篇标记跨域 / 用途未指定。这是来源分布，尚非逐任务的可运行覆盖。	以全部已核用途为起点，逐任务对应；新来源可扩充分类。
环境	284 已取得命名场景条目。64个已读来源有某种环境量；284条仅是已取ID子集，未完成跨库几何去重。	整理各来源scene/layout/location及重用关系后，计全库联集；不再先配1,000。
任务	2,096 已取得robot任务条目。另有7信息题型、263人类活动。原作task/skill/instruction的差异已逐篇记录，尚未全部范式去重。	先取原作任务联集，再加有差异证据的新目标 / 规则；不再先配5,000。
题数	114,288 已取得题目定义元数据。111,652 PARTNR train+1,000 val+1,636 OpenEQA；含训练数据，素材未全齐，不是114,288道已集成测试题。	依task、split、合法输入及判分创建case manifest后定量；原作量、已取得量、可评量分列。
评估方式	4 共同判分大类。183份来源均有判分方式与原文依据；具体metrics及评分器仍各自保留，尚未全数挂接。	答案、误差、状态 / 过程、人工 / 模型评审各报；不以4类代表4个完成的通用评分器。

v0.9的12领域 / 1,000场景 / 5,000任务 / 100万题配额已撤回。4种判分方式仍作分类，不作完成量。实际清单仍保留，未知的全库联集不填0。

阅读后的主要发现

大量题目不一定是大量不同任务

Meta-World的50种task与参数instances、RoboRecover的400test recovery scenarios、EGOSTREAM的2,250问题→8,528recall测例，分别增加不同层级。每个数字保留它自己的单位。

依据：P063、P178、P203，详见逐篇纪录。

视频与通用数据集成前作已经很大

HowTo100M的23,611人类活动标签、OXE的527skills与160,266作者报告tasks、OpenEgo的290来源task labels都要比较。它们不是同一种范式机器人任务。

依据：P002、P125、P199，详见逐篇纪录。

环境数最容易混入配置与视频标签

RoboCasa365的layoutxstyle配置、DROID的564workspaces、S-EMBER的2,090scenario labels层级不同。DreamDojo自己的table与正文scene量也不一致，已明列待核。

依据：P071、P126、P204、P150，详见逐篇纪录。

主张范围通常大于实际实验子集

BEHAVIOR-1K的活动定义与原始baseline子集、AutoBio的16定义/9实测、Labimus的完整流程设计与v0已验证部分均应分栏。

依据：P100、P176、P174，详见逐篇纪录。

同源的数据与资产需要保留关系

Ego4D衍生多个QA/预测集合；EgoDex又出现在OpenEgo与EMPIRE；HSSD支持HomeRobot、Habitat3和PARTNR。来源联集不能直接相加这些原作数字。

依据：P013、P119、P199、P224、P099、P142、P143，详见逐篇纪录。

答案、代理量和物理完成有不同证据

摘果waypoint接近、衣物外形IoU、world-model视频品质、人工偏好和实际robot success不能等同。不同predicate、失败排除、oracle信息和best-of-K预算均留在逐篇纪录。

依据：P213、P089、P191、P150、P250，详见逐篇纪录。

现在的难度只能在共同协定下校准

EMPIRE按baseline error分级、LIBERO-Plus按扰动设置分级、RoboRecover按referencepolicy可恢复率筛选，都依赖各自模型和协定。不能取一篇的easy/hard直接替另一篇定级。

依据：P224、P105、P178，详见逐篇纪录。

Survey分布

研究类型沿用书目的12类并按本轮阅读修正所列来源。每篇一个主类，用于survey分布；细部角色和多种判分方式另保留。研究类型不是生活用途，两者不能用篇数配额互相换算。

研究类型	已详细审阅来源	全部书目
人类视频与动作数据	32	32
理解、推理与规划	21	25
未来动作 / 交互预测	18	48
一般操作 benchmark	31	32
布料 / 柔性物操作	21	26
导航与家务运行	11	11
稳健性、失败与评测品质	19	19
人类观测到机器人转移	7	11
机器人数据与通用策略	6	16
辅助与协作	11	11
世界模型与预测表示	5	9
Survey / 评测方法	1	10

用途分类是本次阅读后的来源层级survey编码，可多选。18类不是原作者共同采用的ontology，不等于已建成18域的可运行任务，也不限制之后添加用途。

生活 / 工作用途	来源数 (可重复标记)	来源支持
-----------	-------------	------

居家整理	94	P001、P003、P007、P009、P010、P011、P012、P013、P016、P017、P018、P024、P026、P027、P028、P029、P030、P031、P032、P033、P038、P039、P040、P042、P062、P064、P066、P067、P068、P069、P070、P071、
------	----	--

生活 / 工 作 用 途	来 源 数 (可 重复 标记)	来 源 支 持
与清 洁		P072、P074、P075、P076、P080、P081、P082、P083、P084、P087、P093、P094、P095、P096、P097、P098、P099、P100、P101、P104、P107、P108、P109、P111、P114、P116、P119、P123、P124、P129、P142、P143、P144、P145、P164、P165、P166、P169、P178、P180、P181、P199、P201、P202、P203、P204、P205、P206、P207、P034、P037、P051、P054、P110、P125、P126、P127、P120、P132、P150、P247、P250
餐饮 与烹 饪	60	P003、P004、P005、P006、P008、P009、P010、P011、P012、P013、P014、P018、P021、P022、P023、P024、P026、P027、P028、P029、P030、P031、P032、P033、P039、P070、P071、P072、P096、P097、P098、P100、P101、P108、P109、P116、P141、P143、P145、P152、P164、P166、P202、P204、P207、P002、P053、P057、P060、P125、P126、P127、P132、P217、P229、P233、P241、P246、P247、P250
衣物 与洗 护	25	P045、P082、P083、P085、P086、P087、P092、P093、P100、P119、P151、P152、P167、P181、P185、P196、P088、P089、P090、P091、P127、P186、P188、P191、P120
办公 与教 育	18	P018、P038、P039、P042、P072、P094、P095、P100、P101、P141、P144、P145、P202、P002、P054、P126、P120、P150
工艺 与修 缮	14	P003、P004、P013、P023、P028、P029、P031、P041、P112、P141、P002、P034、P054、P150
装配 与生 产作 业	27	P015、P016、P023、P067、P068、P069、P076、P079、P082、P083、P112、P119、P129、P141、P170、P171、P177、P179、P183、P184、P207、P208、P210、P211、P120、P150、P225
包 装、 仓储 与物 流	7	P076、P084、P086、P164、P170、P200、P077
零售 与购 物	9	P013、P031、P100、P164、P200、P202、P204、P120、P150
实验 室操 作	12	P021、P031、P072、P112、P164、P172、P173、P174、P175、P176、P192、P120
医疗 与手	5	P041、P113、P164、P060、P247

生活 / 工 作用 途	来源 数 (可 重复 标记)	来源支持
术支 持		
个人 照护	7	P003、P014、P031、P087、P148、P167、P002
交通 移动 与车 辆维 修	12	P003、P004、P013、P014、P031、P202、P002、P060、P150、P226、P247、P250
农业 与园 艺	7	P013、P023、P028、P031、P100、P002、P213
休闲 与运 动	14	P003、P013、P014、P019、P020、P031、P033、P041、P072、P202、P002、P054、P229、P247
公共 场馆 与服 务	2	P102、P209
宠物 照护 与动 物活 动	4	P025、P041、P205、P002
音乐 与表 演	3	P014、P229、P247
社交 与沟 通	7	P013、P019、P020、P032、P033、P061、P168

跨域 / 用途未指定：22来源。桌面操作、工具使用、导航、柔性物、触觉、协作、人体感知等是技术或能力描述，单凭这些字不推定生活用途。无用途标记的来源明列『跨域 / 用途未指定』。医疗视频标记只表示数据用途，非临床或机器人安全性能认证。

如何把大而广变成可发表的benchmark

先完成来源联集，再扩充任务和规则。集合的上限不能由论文数推定，异质数字不相加。要证明比前作更广、更大，须在相同任务粒度下报去重后任务数，并列各前作未覆盖而本库真正可评的用途、任务与规则。RoboVerse、OXE、OpenEgo等集成型前作必须直接比较。

环境、示范和评分器可以重用；添加目标、过程约束和介入条件要留下父任务与差异。每个case需要明确输入、答案或goal predicate、split、版本及预算。不同机体或传感条件下使用分组榜单；问答、预测、规划和物理控制的证据分开。

本轮是来源审阅与设计依据的完成，尚非通用benchmark全库的实验完成。接下来的论文证据应来自共同任务清单、有效case、可重现判分器与baseline结果。

难度量化

1. 先记可观测条件：步骤/依赖数、对象干扰、容许误差、材料、遮挡、历史长度、恢复和信息预算。这些是条件，不预先加成一个任意难度分数。
2. 同一case固定split、observation/action与budget，选涵盖不同能力的baseline，记逐case成功/误差和重跑。用task/source/scene群聚bootstrap估计不确定性。
3. 在同输出/判分协定内，以baseline成功率或相对误差校准难度，报分布与模型依赖。QA和物理控制不共用一条未验证的分数尺。
4. 有足够模型×题目矩阵后才试IRT或辨识度，检查拟合、单调性和source依赖；用新模型验证分级是否稳定。

Milestones

M1 来源阅读与共同比较

本版250篇筛查、183份逐篇审阅、原文页码/单位/重用纪录和五栏比较表。

验收：所有原143来源有记录，补入40来源；可重算分类分布，未知与冲突公开。

状态：本轮已完成，限现有书目范围

M2 逐ID整理环境与任务联集

取得各来源任务清单，保留source ID、version、split、资产引用；标示equivalent/derived/unresolved。

验收：来源覆盖率按183来源计；每笔任务有父来源和判分定义，不能仅比名称。

状态：已有部分清单；全库去重尚未完成

M3 扩充任务与规则

针对已核来源添加必要过程、精度、安全、恢复、记忆与协作规则；逐条记录相对父任务添加了什么。

验收：添加语义目标与添加测例条件分开计数；每个合法变体有可解性与evaluator验证。

状态：设计可据来源展开；未承诺固定题数

M4 创建可运行评测与论文证据

分问答、预测、规划、控制输出报分；固定观测/动作/时间/抽样预算，做来源与任务群聚切分。

验收：公开case manifest与判分器，报subset实测及不确定性；以去重后覆盖和添加任务证明规模优势。

状态：全库尚未完成；既有小型实验为工程附录

逐篇来源纪录

P100 BEHAVIOR-1K (2024)

原作：<https://arxiv.org/abs/2403.09227>

本次PDF：<https://arxiv.org/pdf/2403.09227v1>

PDF SHA256：ab4033f3e8a8187ad2cfd11f1979d33996ecce1e81fa3d62af33a92bbb17a2b

阅读页：1、2、3、4、6、7、20、24。人类需求survey、1K activity来源、scene/object表、BDDL与Transition Machine、baseline范围。

- 研究类型：导航与家务运行；室内长流程操作
- 领域：居家整理与清洁、餐饮与烹饪、衣物与洗护、办公与教育、零售与购物、农业与园艺
- 环境：50scenes / 373rooms / 8scene types；包含house、garden、restaurant、office等；不能把rooms和scenes相加。
- 任务：1,000 BDDL activities = 人类需求排序选909 + 沿用BEHAVIOR100的91项；2,090是survey候选池，不是已实作任务。
- 题数 / 数据：程序生成满足initial predicates的配置；原文baseline只实测CollectTrash、StoreDecoration、CleanTable三活动，非1,000活动全模型成绩。
- 评估方式：success、goal score Q、时间、导航距离、扰动对象量。；低级RL与assistive grasp/teleport primitive分开；高分primitive不能代称低级policy已解题。
- Split / 信息条件：原文3活动实验；初态生成规格与实验seed / rollout需另外记录。
- 来源关系：BEHAVIOR100的延伸；ATUS等time-use survey及WikiHow为活动来源。OmniGibson混用物理与temperature/烘焙等heuristic transition，非所有现象都是精密物理。
- 可复用：全库广度与生活活动规格的核心比较基准；新库要提出超过其已有activity和规则的具体联集。
- 待核 / 限制：全1K activities的去重semantic goal、可用资产及可解性应逐规格核，不用1K宣称1K模型可评结果。

P082 RoboVerse (2025)

原作：<https://arxiv.org/abs/2504.18904>

本次PDF：<https://arxiv.org/pdf/2504.18904v1>

PDF SHA256：8c0cb543ef3f0c9a033f06cbbd73a86f2f1177029751e72e86a54d366c355008

阅读页：1、2、3、5、6、7、8、9、10、34。MetaSim架构、来源迁移全表、操作/导航/人形数据、4级泛化与实验子集。

- 研究类型：一般操作 benchmark；跨数据集集成与评测方法
- 领域：居家整理与清洁、衣物与洗护、装配与生产作业
- 环境：操作多底座迁移；导航重用90个Matterport3D scenes；59camera候选不是59环境。
- 任务：表迁移276 manipulation task categories，另导航 / 人形。RLBench取80、CALVIN7、LIBERO10等为其迁移子集，不是全源benchmark相加。

- 题数 / 数据：510.5K manipulation trajectories、约5.5K assets；navigation另R2R10K、RxR20K episodes。主要IL表只评6个代表task。
- 评估方式：统一success checker / success rate；L0 task-space、L1场景、L2camera、L3光照反射。；不同simulator的migration成功不保证完全等价物理；需固定backend。
- Split / 信息条件：原作90/10；主IL取10train设置+10validation设置，3seeds；OpenVLA另限制20test scenarios。
- 来源关系：直接集成ManiSkill、RLBench、CALVIN、MetaWorld、Robosuite/MimicGen、GAPartNet、Open6DOR、ARNOLD、LIBERO、SIMPLER、RLAfford、GraspNet、GarmentLab、UniDoorManip、GAPartManip；导航R2R/RxR、人形HumanoidBench等。
- 可复用：本研究最重要的集成型比较对象之一；『把前作放一起』已有实作，添加贡献要在coverage、规则、来源联集与评估完整度。
- 待核 / 限制：276类是否存在跨源语义等价未在本文提供完整去重证据；需追MetaConfig IDs。

P071 RoboCasa365 (2026)

原作：<https://arxiv.org/abs/2603.04356>

本次PDF：<https://arxiv.org/pdf/2603.04356v1>

PDF SHA256: f3e6877b8de3dd471afb6951c1e067729e2a57c53fcb3d6daaa0f4af5080206b

阅读页：1、2、3、4、5、6、7、22。新旧资产、pretrain/target场景、365task组成、数据与eval。

- 研究类型：一般操作 benchmark；模拟操作benchmark
- 领域：居家整理与清洁、餐饮与烹饪
- 环境：50新layouts×50styles=2,500 pretrain scenes；另10 target layouts各配一style=10 target scenes。2,500不是2,500 floor plans。
- 任务：365=65 atomic+300 composite；60活动归6家族；220任务需mobile、145不需。主要target评测50任务=18 atomic+16 seen composite+16 unseen composite。
- 题数 / 数据：30K human pretrain+25K human target；60atomic各生成10K（600K synthetic）。target eval每task30trials；demo量不算test题。
- 评估方式：task-specific binary success，per-task horizon；跨task平均。
- Split / 信息条件：pretrain300task；target50含16个pretraining未见composite；场景 / style也分离。
- 来源关系：直接扩充RoboCasa；本文引述旧composite83是另一版本，不能覆盖2024原文75。
- 可复用：是大规模厨房benchmark必要主比较；跨生活用途更广与域内更大是两项不同主张。
- 待核 / 限制：365全任务与本文pretrain/target数据实际涵盖联集需manifest核对；不能从『cover all』概述推论每task都有同量demo。

P125 Open X-Embodiment (2023)

原作：<https://arxiv.org/abs/2310.08864>

本次PDF：<https://arxiv.org/pdf/2310.08864v9>

PDF SHA256: 13f16aff5afdee583dc25b3c570e9bb0cf6baefb59b539928d919588cd8d9246

阅读页：1、2、3、4、6。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：机器人数据与通用策略；跨数据集集成与评测方法
- 领域：居家整理与清洁、餐饮与烹饪
- 环境：60来源datasets、22embodiments；场所数由各dataset metadata而来，非60新环境。
- 任务：结论报527skills / 160,266tasks；方法用语言抽取skills，不能直接当160,266范式goal definitions。
- 题数 / 数据：1M+robottrajectories；主RT-X混合只选9manipulators，非全22都等量实测。
- 评估方式：跨robot实机tasksuccess、OOD / emergent skills与移除Bridge对照。
- Split / 信息条件：不同experiment的hosttask/robot子集不同；dataset-wide规模与policy实测范围分开。
- 来源关系：集成既有datasets到RLDS；不统一所有action坐标，absolute/relative/velocity仍可能不同。
- 可复用：all-in-one最重要对照之一：我们不能以合并文件夹或粗7Dactionformat宣称首次通用benchmark。
- 待核 / 限制：160,266的逐task IDs与同义/粒度规则未在已读段完备；21institutions / 34labs的口径也需保留。

P126 DROID (2024)

原作：<https://arxiv.org/abs/2403.12945>

本次PDF：<https://arxiv.org/pdf/2403.12945v2>

PDF SHA256：9e40a9c934ce78ea315d2c05593d60f9e18edf6dcd3785cd66439518965c3b07

阅读页：1、2、3、7。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：机器人数据与通用策略；真实操作benchmark
- 领域：居家整理与清洁、餐饮与烹饪、办公与教育
- 环境：564workspace scenes分52buildings；换对象摆位不增加scene。
- 任务：86是unique verb/task口径；下游主实验6tasks/4locations，不是全86实测。
- 题数 / 数据：76Kdemonstrations/350h；6task各50–150in-domain demos，混合DROID训练。
- 评估方式：ID/OOD task success；nativepolicyrollouts分母需appendix/manifest另核。
- Split / 信息条件：主task各有distractor/novelobject/cameravariation；不是564场所全部held-out验证。
- 来源关系：新distributedcapture；DROID表I与RH20T用unique multi-view trajectory重算，不能代替RH20T原作报告数。
- 可复用：提供workspaces与objectrandomization的清楚环境定义；大数据与小评测子集须并列。
- 待核 / 限制：18researchlabs/13institutions/18robots是不同口径；主规模不能称86完整独立工作流程。

P132 RT-1 (2022)

原作：<https://arxiv.org/abs/2212.06817>

本次PDF：<https://arxiv.org/pdf/2212.06817v2>

PDF SHA256：81efe669c8fa50ffc7097886dc78a442fa7a8f7f2451684b93069cb9fbeda767

阅读页：1、4、5、7、8、9。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：机器人数据与通用策略；通用策略的原作任务评测

- 领域：居家整理与清洁、餐饮与烹饪
- 环境：Three environments: robotclassroom与两个realofficekitchens；13robots不是13独立场景。
- 任务：Table1有744language instructions，依verb分skill；不同744工作家族。
- 题数 / 数据：约130Kdemonstrations；主seen>200instructions、unseen21、robustness30/22、long15；全研究>3,000trials。
- 评估方式：task SR与SayCan长流程成功；architectures在相同RT1数据重训。
- Split / 信息条件：novelinstructions保持object/skill可在别的training组合看过；OOD场景另列。
- 来源关系：自收Google/EverydayRobot数据，后被OXE/其他策略重用。
- 可复用：说明前作也能有数百instructiontasks；比较规模必须对齐语义粒度。
- 待核 / 限制：>3,000是跨method/condition运行次数；不能当3,000独立test cases。

P063 Meta-World (2019)

原作：<https://arxiv.org/abs/1910.10897>

本次PDF：<https://arxiv.org/pdf/1910.10897v2>

PDF SHA256: 8ea4fd9e7a2f7a2cfc475ae7e7021e7a6c03b99ae3932b455def9197ff1197e8

阅读页：1、4、5、6、7、12。50任务定义、观测 / 动作 / reward及MT / ML协定。

- 研究类型：一般操作 benchmark；模拟操作benchmark
- 领域：跨域 / 用途未指定
- 环境：50个task environment配置，共用Sawyer桌面；不能解读为50种生活场域。
- 任务：50个非参数性操作类型；原文又把位置 / goal参数化实例称task，需保留两种含义。
- 题数 / 数据：MT10含10环境×50参数配置=500；MT50为50×50=2,500训练task instances。这不是500 / 2,500个新语义任务，也不是正式test QA。
- 评估方式：各task成功predicate / 目标距离门槛，success与dense reward分开。
- Split / 信息条件：MT同已见任务学习；ML10 / ML45各有5保留task适应；ML1只在同一task变换50train / 50test goal。
- 来源关系：MuJoCo、Multiworld及Gym界面；后续MetaWorld+等为其扩充，不可把上游再次全加。
- 可复用：提供桌面操作任务底座；位置扩样容易，生活用途拓宽有限。
- 待核 / 限制：不同v1 / v2 / 后续release成功predicate细节与本地历史pilot须以commit分开。

P062 RLBench (2019)

原作：<https://arxiv.org/abs/1909.12271>

本次PDF：<https://arxiv.org/pdf/1909.12271v1>

PDF SHA256: fbb04509bea7bf6aa9b97b07c46d95e5c1a900987599693b3fae3fd84377db76

阅读页：1、3、4、5、6、7。原生task / variation / episode定义、scene、成功条件与few-shot协定。

- 研究类型：一般操作 benchmark；模拟操作benchmark

- 领域：居家整理与清洁
- 环境：共用1个Panda桌面scene，加载各task资产；API的TaskEnvironment不等于独立房间。
- 任务：原文100手写task，每task多variation（如目标色彩 / 对象），每variation再抽初态episode。
- 题数 / 数据：episode / demo可随机生成，原文没有固定全库题数；few-shot原版10%任务meta-test，1 / 5 / 20 demonstrations是每任务支持样本预算。
- 评估方式：task-specific success conditions，完成才给+1 sparse reward；few-shot在新episode报success；demo生成器通过验证不代表学习策略已成功。
- Split / 信息条件：原版90% tasks train、10% unseen tasks test；每次测试不能先知未见task规则。
- 来源关系：V-REP / PyRep / OMPL；大量后续benchmark重用其task、资产和成功predicate。
- 可复用：可直接作任务来源与扩充规则底座；task、variation、episode原作已有清楚先例。
- 待核 / 限制：后续版本的task总量与常用18-task子集要另附commit，不能用来改写2019原文。

P064 LIBERO (2023)

原作：<https://arxiv.org/abs/2306.03310>

本次PDF：<https://arxiv.org/pdf/2306.03310v2>

PDF SHA256：ff7d943e2eb37760df684f3ae2931a5a35ef8ea465bd387e62afe49507b8e414

阅读页：1、2、3、4、5、6、9、10。任务生成、PDDL goals、4 suites、lifelong指针及pretraining切分。

- 研究类型：一般操作 benchmark；模拟操作benchmark
- 领域：居家整理与清洁
- 环境：Robosuite场景配置；layout / objects由PDDL定义，本文已读段落未报去重layout总数。
- 任务：130 = Spatial10 + Object10 + Goal10 + LIBERO100；LIBERO100内90短程预训练 + 10长程。LIBERO-Long不是再额外增加10。
- 题数 / 数据：各task有human demos与随机初态评估；可生成不代表固定无限题库已发布。
- 评估方式：全部goal predicates为真才成功；以success计forward transfer、negative backward transfer、AUC。
- Split / 信息条件：lifelong顺序学task，过往数据限制；90→Long10预训练与Spatial/Object/Goal控制变因是不同协定。
- 来源关系：明确由Ego4D语言behavior templates生成task instructions，实作建于Robosuite；已是人类程序到robot benchmark的先例。
- 可复用：与本研究来源联集主线高度相关；新贡献需超过同类模板生成与桌面范围。
- 待核 / 限制：各发布demo / init-state精确ID数需对照版本，不从别篇约5K反推。

P068 ManiSkill3 (2024)

原作：<https://arxiv.org/abs/2410.00425>

本次PDF：<https://arxiv.org/pdf/2410.00425v2>

PDF SHA256：0482cef460af5ca0dd09d2b1d0f499b996287d9dadec31b13ca60377a49ee80c

阅读页：1、3、4、6、7、8、21、22、28。12种类型、平台与task生成、性能和learning评测段落。

- 研究类型：一般操作 benchmark；模拟平台与任务套件
- 领域：居家整理与清洁、装配与生产作业
- 环境：GPU异质并行模拟；1024平行instances / cameras是运行规模，非1024不同生活场景。
- 任务：原作12 task categories包含tabletop/mobile、room-scale、locomotion、bimanual、multi-agent、drawing/cleaning、dexterous、tactile、classic control、digital twins、soft-body；这12类不是12生活domain。
- 题数 / 数据：扩展中的环境注册表与demo来源，无单一固定全库test题数；例如SIMPLER转接4种环境。
- 评估方式：task success / return、sample efficiency与wall-clock分开；渲染FPS / VRAM是系统性能，非任务成功率。；本文GPU rasterization与IsaacLab ray tracing比较非完全同画质，原作有明示。
- Split / 信息条件：不同RL / IL / VLA / sim2real设置各有来源；应固定demo数、生成方式与控制器。
- 来源关系：ManiSkill2平台与任务延伸，另接SIMPLER等；不能把platform release当完全独立benchmark family。
- 可复用：可作运行底座；广泛技术支持不等同每种生活用途已有完整任务与cases。
- 待核 / 限制：目前API注册task总量随版本变动，需固定commit再盘点；本文不提供永续固定总数。

P074 RoboTwin 2.0 (2025)

原作：<https://arxiv.org/abs/2506.18088>

本次PDF：<https://arxiv.org/pdf/2506.18088v2>

PDF SHA256: 316ae82a97968e1a2d88540665401645a190d2699d7d8652e8fc0053ba609bda

阅读页：1、2、3、6、10、11、19。MLLM产生器、对象库、50task benchmark、Easy/Hard及real验证。

- 研究类型：一般操作 benchmark；模拟与真实操作benchmark
- 领域：居家整理与清洁
- 环境：双臂桌面程序配置；Easy/Hard为clutter / 光照 / texture / 高度分布，不是两个生活domain。
- 任务：50 benchmark tasks；另外真实实验4task×4conditions；RoboTwin-OD 147类731对象。
- 题数 / 数据：每task50 clean train demos，测试100rollouts于Easy/Hard条件；真实测试training另10real+1,000synthetic。
- 评估方式：simulation / real task success；Easy和Hard分开。；MLLM observer的failure detection / localization是产生器辅助诊断，不能替代所有物理success checker。
- Split / 信息条件：single-task training，Easy到Hard分布外；DP3在模拟可得完美point clouds / clean segmentation，跨方法需标明。
- 来源关系：RoboTwin延伸，Rodin资产、skill API和sim-in-loop expert生成。
- 可复用：可借双臂流程与有物理回馈的产题；50task不因两种难度变成100语义task。
- 待核 / 限制：100rollouts的公开seed列表与两条件是否完全对应需eval script核。

P143 PARTNR (2024)

原作：<https://arxiv.org/abs/2411.00081>

本次PDF：<https://arxiv.org/pdf/2411.00081v1>

PDF SHA256: 7da62f6f2b031d78908d6f063d44b6eae491bb31d03536218f6ee61dd300efd

阅读页：1、2、3、4、5、6、7、8、24、40。生成与评分完整章、原生100K口径、types、split、generation audit及agent信息条件。

- 研究类型：辅助与协作；对话协作与任务完成
- 领域：居家整理与清洁、餐饮与烹饪
- 环境：60HSSD houses（37train/13val/10test），5,819OVMM objects；与其他HSSD来源重用。
- 任务：4非互斥特性：constraint-free/spatial/temporal/heterogeneous；原作task以unique scene-goal pair计，100K不是100K语义family。
- 题数 / 数据：本文100,000train+1,000val+1,000test；全val/test及2Ktrain人工审核。固定公开HF文件本库实数111,652train+1,000val是另一版本，不能覆盖本文或补造test。
- 评估方式：完整state sequence检查propositions、dependencies、temporal/same-argument/terminal constraints；PC、success、failure explanation。；中央/分散、partial/full、oracle/learned skills、privileged/perceived graph分开评。
- Split / 信息条件：source houses互斥；支持human-only技能差异；生成时会排除不能做的折衣。
- 来源关系：Habitat3/HSSD/OVMM底座；1K人工seed衍生100K。原文generation audit约90%instruction、92%evaluator、83%joint，与本库旧92.5%小试作无关。
- 可复用：为十万级rule-conditioned episodes及共同协作评测的关键前作；数量比较须用scene-goal案例粒度。
- 待核 / 限制：本文某处称全tasks HITL，统计处实际描述val/test+2Ktrain审核，应按具体audit范围理解。；HF公开版本无test素材；111,652只是该快照metadata实数。

P199 OpenEgo (2025)

原作：<https://arxiv.org/abs/2509.05513>

本次PDF：<https://arxiv.org/pdf/2509.05513v1>

PDF SHA256：84068f8b5d7e8add70826aacda59a02d425f56125bcf3f1c450fe966db7f7e65

阅读页：1、2、3、4。六来源表、hand/primitive统一、实际0.1%子集实验和held-out metric。

- 研究类型：人类视频与动作数据；集成型人类视频数据与预测benchmark
- 领域：居家整理与清洁
- 环境：作者列10kitchens与610indoor rooms / 600+environments；是多来源合并，未证明全库去重。
- 任务：290 source task labels = 六来源原生task数相加；不等于290范式机器人目标。
- 题数 / 数据：1,107h、344.5Krecordings、119.6Mframes；实验只train在0.1%子集，10%demonstrations held-out，精确eval IDs/分母需核。
- 评估方式：AED/FED/DTW只算可见hand joints；8/16/32/64frames horizons。未测robot physical task success。
- Split / 信息条件：作者称demonstration-level holdout10%，但0.1%子集与holdout母集合关系需ID核。
- 来源关系：CaptainCook4D、HOI4D、HoloAssist、EgoDex、HOT3D、HO-Cap；语言多自动生成且部分人工核，添加的是统一label/format。
- 可复用：最直接的集成数据前作之一；我们必须清楚提出超出统一格式的task联集与评测规则。
- 待核 / 限制：跨来源环境/task去重未完成；data aggregation不可与父来源再次加总。

P002 HowTo100M (2019)

原作: <https://arxiv.org/abs/1906.03327>

本次PDF: <https://arxiv.org/pdf/1906.03327v2>

PDF SHA256: f55dbcb6598acecdedd0178243457eed6daf14626744e9bc50b0622cdbf58894

阅读页: 1、2、3、4、5、6。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 人类视频与动作数据; 人类程序视频与步骤定位
- 领域: 餐饮与烹饪、办公与教育、工艺与修缮、个人照护、交通移动与车辆维修、农业与园艺、休闲与运动、宠物照护与动物活动
- 环境: YouTube instructional/vlog等视频; 12 WikiHow用途类别, 不是12个物理场景。
- 任务: 23,611 visual tasks是WikiHow搜索活动标签, 未范式成robot goals。
- 题数 / 数据: 1.22M视频 / 136.6M弱配对clip-caption; 本库主要供pretraining, 下游评CrossTask等既有benchmark。
- 评估方式: 下游step recall、retrieval R@K/median rank; 非136.6M人工验证评测题。
- Split / 信息条件: 移除CrossTask test与YouCook2 val重复video IDs; 仍可能有重上传内容。
- 来源关系: WikiHow活动×YouTube搜索; 片段共享长视频, 后续world-model/ego conversion又会重用。
- 可复用: 是扩大生活/工作用途的重要来源; 活动标签、可观测步骤及robot可运行目标需逐层转换。
- 待核 / 限制: 原作抽400pairs仅51%至少一项提及与画面吻合; 不能直接将全部字幕当程序ground truth。

P119 EgoDex (2025)

原作: <https://arxiv.org/abs/2505.11709>

本次PDF: <https://arxiv.org/pdf/2505.11709v3>

PDF SHA256: 7ea269e5885392e65a7e206c2d6b5792022ec499367a070c2c269cbcf187e2b8

阅读页: 1、2、3、4、5、6、7、8。194tasks数据、reset类别、48D action表示、两benchmark、1%split与best-of-K。

- 研究类型: 人类观测到机器人转移; 人类示范与技能转移
- 领域: 居家整理与清洁、衣物与洗护、装配与生产作业
- 环境: tabletop录制; 原文明示场景多样性不是重点, 没有独立layout总数。
- 任务: 194human manipulation tasks; 3种reset类型; 正式两端点为未来手轨迹及给future goal图的inverse dynamics。
- 题数 / 数据: 338,000episodes、829小时、约90Mframes; 每task抽1%为held-out, 不把90Mframes等同90Mtest题。
- 评估方式: 12个wrist/fingertip keypoints的平均 / 终点Euclidean error, best-of-K (1/5/10), 分H=1/2/3秒。; 人手预测误差不是robot任务完成率; 给future image的inverse dynamics信息更强。
- Split / 信息条件: 主test为每task1%同分布; 未见task另附录, 不可把主结果称OOD。
- 来源关系: 新Apple headset录制; 部分task来自FurnitureBench等类型, 但非同robot轨迹。
- 可复用: 大量灵巧行为、工具与衣物候选; 转成robot benchmark需具体goal/初态与evaluator对应。
- 待核 / 限制: 精确split episodes及同session相依关系需manifest; ARKit confidence为追踪品质非真物理成功。

P150 DreamDojo (2026)

原作: <https://arxiv.org/abs/2602.06949>

本次PDF: <https://arxiv.org/pdf/2602.06949v1>

PDF SHA256: c8f02e22c8fbe98e0b50215e10e1f6baf2f589b1987e5c6dc07175bfe6fe8587

阅读页: 1、2、4、5、8、9、10。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 世界模型与预测表示; 世界模型与视频生成评测
- 领域: 居家整理与清洁、办公与教育、工艺与修缮、装配与生产作业、零售与购物、交通移动与车辆维修
- 环境: Table1的1.135M scenes与正文9,869unique scenes不一致; 暂不取其中任一为去重环境总量。
- 任务: 6,015skills/tasks由GPT对globalcaptions估计; 6个generation evalsets非6生活domains。
- 题数 / 数据: DreamDojo-HV43,827h, 加入in-lab55h/EgoDex829h后44,711h; 多数eval100samples, 两个image-edited sets各25。
- 评估方式: PSNR/SSIM/LPIPS; editedsets无配对futureGT, 12volunteers做physics/action-following偏好比较。
- Split / 信息条件: humanpretrain后robotposttrain, GR1是主要验证平台; counterfactual与backgroundedit分项。
- 来源关系: EgoDex + in-house; 和EgoScale的scene/task/object统计一致是待核同源线索, 非已证实完全相同。
- 可复用: 规模非常大的world-model数据源; 不能把44K人类视频小时或生成视觉评分当作可运行task库。
- 待核 / 限制: 1.135M scene与9,869scene粒度矛盾; 表中其他前作hours也不可代替原始论文校核。

P120 EgoScale (2026)

原作: <https://arxiv.org/abs/2602.16710>

本次PDF: <https://arxiv.org/pdf/2602.16710v1>

PDF SHA256: 39c691baf374a154e26ffc0098b97037875909495013d4017d97761716ff2735

阅读页: 1、3、4、6、7。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 人类观测到机器人转移; 人类示范与技能转移
- 领域: 居家整理与清洁、衣物与洗护、办公与教育、装配与生产作业、零售与购物、实验室操作
- 环境: 作者报9,869scenes的人类视频; 语义场所/视频scene定义及与其他corpora交集待核。
- 任务: 人类6,015task labels、对齐midtraining344tabletop tasks; 主实机只5dexterous goals。
- 题数 / 数据: 报告20,854hpretraining, 并使用EgoDex829h (不另外相加); midtrain50hhuman/4hrobot; 下游每task100robotdemos, shirt20。
- 评估方式: whole-task SR、fine-grained completion; 两trainingseeds、通常每checkpoint/task10trials。
- Split / 信息条件: 分大规模人类pretrain、配对midtrain、下游posttrain; 非zero-robot-data。
- 来源关系: EgoDex与in-house数据; 场景/task/object统计与DreamDojo相同数字, 不能假定是独立添加corpus。
- 可复用: 人类数据规模的必要对照; 要分6,015训练标签、344对齐任务与5实测目标。
- 待核 / 限制: protocol称TaskIII每bottle16trials, 但tasklist瓶盖是TaskIV, 需manifest厘清。

P181 RoboFolDeX (2026)

原作: <https://arxiv.org/abs/2609.10243>

本次PDF: <https://arxiv.org/pdf/2609.10243v2>

PDF SHA256: b7760baa843b43e164d224d5132fc13f534cb5e4bd834d7276340ee3f7d65553

阅读页: 1、3、4、5、6、7。数据源、四track、完整折叠流程、30实机回合及FoldScore。

- 研究类型: 布料 / 柔性物操作; 柔性物操作benchmark
- 领域: 居家整理与清洁、衣物与洗护
- 环境: 多个真实robot平台/场景, 10+embodiments; 精确独立工作站数未报。
- 任务: 数据20+tasks; 主折叠评测4类衣物Shirt/Skirt/Pants/Towel, 涵盖取出、翻整、摊平、折叠和堆栈。
- 题数 / 数据: 2,000+hours实机数据; 主评测每衣物类别30trials, 完整workflow须无人工介入。
- 评估方式: SR、成功回合时间、0-5neatness由至少2评者一致评分。FoldScore组合品质35%、可靠性35%、速度30%。
- Split / 信息条件: recovery、cross-task、cross-scene、cross-embodiment四tracks; 场景泛化不能只用主4类成绩代表。
- 来源关系: 多robot原始收集与统一格式; 长workflow可切subtasks, 切片不能再视为独立长示范。
- 可复用: 提供完整衣物处理流程、人工外观品质与自动成功率并列的设计。
- 待核 / 限制: 2,000+hours对应的unique episode IDs及工作站去重需要数据manifest; 复合分数权重不是通用难度尺。

P213 Vision to Harvest (2026)

原作: <https://arxiv.org/abs/2609.13606>

本次PDF: <https://arxiv.org/pdf/2609.13606v1>

PDF SHA256: b3ee03d5d25e728c85d714de947fb09d06f56e94067923961d75c365281c22eb

阅读页: 1、2、3、4、5、6。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 一般操作 benchmark; 专业场域规划benchmark
- 领域: 农业与园艺
- 环境: Fuji apple及citrus orchard RGB-D数据; citrus父库432images, 实际held-outscene数未报。
- 任务: multi-armCartesian fruit harvesting的offlineallocation/waypointplanning; apple/citrus两作物设置。
- 题数 / 数据: 每crop共用同一held-outimage集合; 未报可核固定题数, 不能将父库432全填成eval cases。
- 评估方式: detection/harvested ratio、arm-order violation、pathdistance/token成本; harvested其实是waypoint距离门槛0.25/0.5/1m。
- Split / 信息条件: zeroshot同prompt; 没有在线replanning或真的摘果控制。
- 来源关系: 既有果园数据+新plan/verifier; collision指order违反, 非完整动力学碰撞检查。
- 可复用: 补农业用途与多臂分配, 但转成运行benchmark仍需assets、接触和摘取验收。
- 待核 / 限制: exactevalsceneIDs未报; 高harvestedratio不可当物理摘取成功。

P001 VLOG (2017)

原作: <https://arxiv.org/abs/1712.02310>

本次PDF: <https://arxiv.org/pdf/1712.02310v1>

PDF SHA256: 914ea812883827c588beaafa23c52688332eff8824bb54128a2a9ec92331d3ac

阅读页: 1、3、4、5、6、7、8。正文数据搜集、标注、benchmark 与探索实验章节; 未逐行审阅模型训练附录。

- 研究类型: 人类视频与动作数据; 视频数据与感知评测
- 领域: 居家整理与清洁
- 环境: 网络生活视频中的自然场景; 没有可直接计数的模拟 layout 清单。365 是外部场景分类器类别, 不能当环境数。
- 任务: 30 个对象接触二元分类; 8 类手部 / 人物状态分类及未来状态预测。这些是感知标签与评测问题, 不是30个机器人操作任务。
- 题数 / 数据: 114K 视频、219K 抽样影格的手部状态标注; 原作分 uploader 做50/25/25切分。156K 影格另用于未来手位置探索实验。
- 评估方式: 对象接触: 逐类 AP / mAP。; 手状态: 分类 accuracy, 现在及未来6 / 12 / 30 / 60影格分开。; 未来手位置的156K影格探索实验不等于正式的独立机器人 benchmark。
- Split / 信息条件: 依 YouTube uploader 分50% train / 25% validation / 25% test, 避免同一上传者跨 split。
- 来源关系: 视频自行搜集自 YouTube; 与 COCO、Charades 的类别交集不表示共用全部数据。
- 可复用: 可提供生活操作与接触 / 预测题型; 转成机器人控制题仍需资产、状态及成功条件。
- 待核 / 限制: 视频可下载现况、精确公开split文件数尚未逐档核对。

P003 COIN (2019)

原作: <https://arxiv.org/abs/1903.02874>

本次PDF: <https://arxiv.org/pdf/1903.02874v1>

PDF SHA256: 4625e83e6d9eaecd1acdfb5c39fa7132bbe4c4c6a58e541473c24c9f738f6762

阅读页: 1、3、4、5、7。数据定义、阶层分类、标注规模、切分与评测章节。

- 研究类型: 人类视频与动作数据; 人类程序视频与步骤定位
- 领域: 居家整理与清洁、餐饮与烹饪、工艺与修缮、个人照护、交通移动与车辆维修、休闲与运动
- 环境: YouTube 教学视频; 原作12 domains是活动分类, 未提供12个物理环境。
- 任务: 原作阶层为12 domains、180人类程序任务、778步骤定义。180个活动可作任务候选, 不能直接当已实作的robot task。
- 题数 / 数据: 11,827视频、46,354步骤片段、476小时; 视频split为9,030 train及2,797 test。
- 评估方式: 步骤时段定位, 以 temporal IoU 0.1-0.5 的 mAP / mAR 衡量。
- Split / 信息条件: 9,030 train / 2,797 test; 不可把46,354步骤片段全称为test题。
- 来源关系: YouTube 视频与人类程序阶层; 与其他网络教学数据可能视频重叠, 尚无逐video ID跨库去重。
- 可复用: 可引入来源有据的180项程序及778步骤; 需另审机器人可行性与每一步的判分。
- 待核 / 限制: 完整12个原作domain到共同领域的逐条映射需保留原生label清单。; 跨数据集YouTube ID重叠未核。

P004 CrossTask (2019)

原作：<https://arxiv.org/abs/1903.08225>

本次PDF：<https://arxiv.org/pdf/1903.08225v2>

PDF SHA256：1613d28f8d75e86ceedd8b6f2a9c2a4bbf29e5ee8485026bfc7be29826ae7632

阅读页：1、2、5、6、14。数据创建、主要 / 相关任务定义、原作主评测，追读附录评分。

- 研究类型：人类视频与动作数据；人类程序视频与步骤定位
- 领域：餐饮与烹饪、工艺与修缮、交通移动与车辆维修
- 环境：wikiHow程序及YouTube视频；没有原生物理场景ID总数。
- 任务：83个程序=18个主要评测任务+65个相关支持任务；主实验不能写成83个同地位测试任务。
- 题数 / 数据：约4.7K视频；正文列主要任务212小时、相关任务161小时。每轮主要任务test为1,850视频。
- 评估方式：主指针step recall：每步只预测一个位置，落在GT时间段才正确。；20次随机切分的平均；附录另报mAP，不能把附录指针冒充唯一主指针。
- Split / 信息条件：每个主要任务每轮30训练视频；固定每任务20验证视频不进train/test；其余1,850视频测试；重复20次。
- 来源关系：wikiHow中筛选程序，YouTube搜集视频；相关任务筛除以视频重叠判定的近重复。
- 可复用：18个评测程序与65个支持程序分开引入；程序步骤可以映射机器人规格，但视频切分不能直接沿用作实体控制题。
- 待核 / 限制：前文376小时与正文212+161小时口径不完全一致，暂保留原文各自约数。；4.7K总量尚未以发布清单精确重算。

P005 YouCook2 (2017)

原作：<https://arxiv.org/abs/1703.09788>

本次PDF：<https://arxiv.org/pdf/1703.09788v3>

PDF SHA256：4ef636404bea37184e1fa056fa2a71a92705a1b3bc4ee58917a11806de17fbe3

阅读页：1、2、3、4、7、8。YouCook2数据、标注、split、程序分段与proposal评测。

- 研究类型：人类视频与动作数据；人类程序视频与步骤定位
- 领域：餐饮与烹饪
- 环境：自然料理视频；非4个物理场景。Africa / Americas / Asia / Europe是料理来源分类。
- 任务：89道食谱；benchmark要求定位程序步骤及描述。食谱、步骤、视频为不同层次。
- 题数 / 数据：2,000视频、176小时；每道食谱按67 / 23 / 10%分train / val / test。
- 评估方式：程序分段：Jaccard及mean IoU。；proposal：IoU 0.5下precision / recall / F1，与整体程序分段分开。
- Split / 信息条件：每食谱67 / 23 / 10%；本文百分比不自行换算成精确发布ID数。
- 来源关系：YouTube教学视频；与其他料理视频库的原始video重叠需逐ID核对。
- 可复用：可提供料理程序与步骤语言；不能直接把2,000视频列为2,000robot任务。
- 待核 / 限制：发布版本精确split ID数及素材可得性尚未逐档核。

P006 Breakfast (2014)

原作：https://openaccess.thecvf.com/content_cvpr_2014/html/Kuehne_The_Language_of_2014_CVPR_paper.html

本次PDF：https://openaccess.thecvf.com/content_cvpr_2014/papers/Kuehne_The_Language_of_2014_CVPR_paper.pdf

PDF SHA256：79ea90c0870d5e1e29b880a953555fe8d9dbd2b825f0f46e13d28d51c33e138f

阅读页：1、3、5、6。Breakfast数据、动作阶层、数据切分及语法式识别实验。

- 研究类型：人类视频与动作数据；人类程序视频与步骤定位
- 领域：餐饮与烹饪
- 环境：18个真实厨房；每处3–5台相机，视角不增加厨房数。
- 任务：10个料理活动、48个coarse action units；活动与动作单元分开。
- 题数 / 数据：52参与者、约77小时、超过400万影格；11,267个action-unit samples包含约3,600个silence samples。
- 评估方式：动作串行unit accuracy及逐frame recognition accuracy；grammar解析与flat grammar比较。
- Split / 信息条件：4组参与者轮替训练与测试；不能把多视角同次活动当独立受试者。
- 来源关系：自行录制；文中ADL等外部对照数字不是Breakfast规模。
- 可复用：可引入早餐程序及分层步骤；18厨房是视频录制环境，非可下载交互layout。
- 待核 / 限制：后续常用发布版本的视频 / 片段数与本文单位可能不同，不能直接混写。

P007 Charades-Ego (2018)

原作：<https://arxiv.org/abs/1804.09626>

本次PDF：<https://arxiv.org/pdf/1804.09626v2>

PDF SHA256：138cfb582bdf3ab17fb6aa3ad7f3dd09505f4410e6c31fd486f2aaf1c35beaf1

阅读页：1、2、3。短文3页全文，聚焦配对搜集、来源重叠及评测。

- 研究类型：人类视频与动作数据；视频数据与感知评测
- 领域：居家整理与清洁
- 环境：112个家、112位演员；第一 / 第三人称依相同脚本重演，异步录制的精确配准视角。
- 任务：157个activity classes；监督及zero-shot第一人称动作识别。
- 题数 / 数据：6,167 train视频+1,693 test视频=7,860视角视频；两种视角各34.4小时；68,536动作标注。
- 评估方式：video-level mAP；监督与zero-shot设置分别报告。
- Split / 信息条件：参与者不跨train/test；视角视频数不直接改称独立活动episode。
- 来源关系：78.7%脚本取自Charades train，另增1,000脚本；与Charades有明确脚本来源关系。
- 可复用：适合跨视角语义转移；不能把配对当作同步3D重建或robot轨迹监督。
- 待核 / 限制：逐配对ID与上游Charades脚本ID尚未在本库去重。

P008 EGTEA Gaze+ (2018)

原作：https://openaccess.thecvf.com/content_ECCV_2018/html/Yin_Li_In_the_Eye_ECCV_2018_paper.html

本次PDF：https://openaccess.thecvf.com/content_ECCV_2018/papers/Yin_Li_In_the_Eye_ECCV_2018_paper.pdf

PDF SHA256：aa3d3ec1981ea4b1b430c3712e3f56d851ac8173cfc5a9db797478cf4d4e3454

阅读页：1、9、10、11。数据与benchmark章、凝视与动作识别评测。

- 研究类型：人类视频与动作数据；视频数据与感知评测
- 领域：餐饮与烹饪
- 环境：自然厨房料理录制；本文未在已读段落提供独立厨房总ID数。
- 任务：7个meal preparation tasks、106个action classes；凝视估计和动作识别为两个端点。
- 题数 / 数据：本文报29小时、86 sessions、32人、10,321动作样本；首split为8,299 train / 2,022 test。
- 评估方式：凝视估计：precision / recall / F1，忽略无追踪与saccade影格。；动作识别：mean class accuracy，clip与video层次分开。
- Split / 信息条件：首split 8,299 / 2,022；评分时fixation采8影格聚合，保留原协定。
- 来源关系：EGTEA相关后续版本常报28小时或10,325片段；本笔不以别篇的数字覆盖所读PDF。
- 可复用：适合视线、动作与料理先后关系题；sessions不是交互环境数。
- 待核 / 限制：公开资产版本与后续10,325片段口径需另核对。

P009 EPIC-KITCHENS (2018)

原作：<https://arxiv.org/abs/1804.02748>

本次PDF：<https://arxiv.org/pdf/1804.02748v2>

PDF SHA256：2b7fe522827a041638ef2d3b27c9508ace434bd504e22c3e3d43894ea144b7a7

阅读页：1、3、10、11、12、13、14、15。数据搜集与词汇、split、对象侦测、动作识别及anticipation完整评测章节。

- 研究类型：人类视频与动作数据；视频数据与感知评测
- 领域：居家整理与清洁、餐饮与烹饪
- 环境：32位参与者 / 32个厨房；S2保留4位参与者的未见厨房。
- 任务：3个端点：active-object detection、action recognition、action anticipation；§3.4词汇125 verbs / 331 nouns，词汇数不是机器人任务数。
- 题数 / 数据：55小时、39,596动作片段、454,255对象框；同一片段可支持不同端点，不能把三种端点直接乘成独立题。
- 评估方式：侦测：mAP，IoU 0.05 / 0.5 / 0.75。；识别与anticipation：verb / noun / action各报top-1、top-5及per-class precision / recall。；anticipation观测1秒，截止于动作开始前1秒；与看到整段动作的recognition分开。
- Split / 信息条件：S1已见厨房按完整sequence约80/20切分；S2保留4位参与者 / 厨房。各端点可评类别又有最少训练样本门槛。
- 来源关系：为EPIC-KITCHENS-100、VISOR、EPIC Fields等后续来源的上游家族；不得把共用视频 / 厨房重复相加。
- 可复用：可引入对象、操作与短期预测题型；原生语言动作类别需另对齐正式robot goal与判分。
- 待核 / 限制：各原生split精确可下载ID数未以本版manifest重算。；表中与正文不同聚合词汇口径应保留版本，不能混加。

P010 EPIC-KITCHENS-100 (2020)

原作: <https://arxiv.org/abs/2006.13256>

本次PDF: <https://arxiv.org/pdf/2006.13256v4>

PDF SHA256: 2ad975f70d5b074a2b2616960bb53410a6d66ce973346284574e7b49684ab629

阅读页: 1、2、4、5、6、7、9、10、11、12、13。数据延伸与表1、六个challenge的定义及评测段落。

- 研究类型: 人类视频与动作数据; 视频数据与感知评测
- 领域: 居家整理与清洁、餐饮与烹饪
- 环境: 45个录制环境; 包含2018视频与新录像片, 不能和EPIC 2018厨房量直接相加。
- 任务: 6个challenge: 全监督 / 弱监督动作识别、检测、anticipation、跨年无监督适应、跨模态检索。97 verbs、300 nouns、4,053 action classes不是4,053个实体操作goal。
- 题数 / 数据: 700视频、89,977动作段; train / val / test动作段67,217 / 9,668 / 13,092; 检索采公开val, 另有专用UDA切分。
- 评估方式: 识别top-1 / top-5 accuracy; 检测mAP于temporal IoU 0.1-0.5; anticipation以动作开始前1秒为截止, class-mean top-5 recall; 检索用mAP及nDCG; UDA保留2018→2020的来源 / 目标域设置。
- Split / 信息条件: 主视频495 / 138 / 67; test皆新录像片。主split、UDA、retrieval评测集合不可混为一个test量。
- 来源关系: 2018上游视频重新标注, 89,977为新版本总量; 其约66M masks及手 / 物框多为自动产生, 非同量人工评测题。
- 可复用: 可复用同一生活视频家族的多端点评测; 必须以共用视频与split lineage控制泄漏。
- 待核 / 限制: 公开manifest与此PDF版本的精确ID差异尚未逐档重算。

P011 EPIC-KITCHENS VISOR (2022)

原作: <https://arxiv.org/abs/2209.13064>

本次PDF: <https://arxiv.org/pdf/2209.13064v1>

PDF SHA256: 912638891fd5608d681de38f6e902f5caa0b4a1925c4b22ffb564b92d69701c9

阅读页: 1、3、4、6、7、8、9、10、25。数据 / split表与3个benchmark定义、主要metric; 附录标注品质段落。

- 研究类型: 人类视频与动作数据; 视频数据与感知评测
- 领域: 居家整理与清洁、餐饮与烹饪
- 环境: 42个EPIC厨房; 为上游环境子集, 不是添加42个交互场景。
- 任务: 3个challenge: VOS、手物关系分割、Where Did This Come From。最后一项有15种来源容器, 非15个生活domain。
- 题数 / 数据: 179 untrimmed视频、50,729人工标注影格、271,584人工mask; 9.9M为筛过的插值mask。WDTCF另有222测试query, 取自92视频。
- 评估方式: VOS用Jaccard J及boundary F; 只追第一影格已指定对象; HOS用COCO mask AP, 手侧别、接触与active object分开; WDTCF用来源分类accuracy、证据影格及mask IoU; 错误证据影格使IoU为0。
- Split / 信息条件: train / val / test视频115 / 43 / 21, 影格32,857 / 7,747 / 10,125; 保留未见厨房子集。WDTCF为222题test-only taster。
- 来源关系: 直接标注EPIC-KITCHENS-100视频; 自动插值从14.5M过滤为9.9M, 不能当9.9M独立人工标签。

- 可复用：补充对象变形、接触及来源追溯题；同一视频不能重算为添加环境。
- 待核 / 限制：各VOS subsequence发布ID与视频父ID的完整映射尚未导入。

P012 HD-EPIC (2025)

原作：<https://arxiv.org/abs/2502.04144>

本次PDF：<https://arxiv.org/pdf/2502.04144v2>

PDF SHA256：d3648a8692d038cad2027290facf25c9f5d8ff12b65f912f4dc6d99b99118092

阅读页：1、5、6、7、28。数据与数字厨房、VQA创建 / 评测、recognition、长期VOS附录。

- 研究类型：人类视频与动作数据；视频问答与推理
- 领域：居家整理与清洁、餐饮与烹饪
- 环境：9个新录厨房，413个fixture数字模型；fixture不是413个环境。
- 任务：69食谱；VQA以7类笔记创建30种问题prototype，另有动作 / 声音识别和长期VOS。
- 题数 / 数据：正式VQA为26,650道五选一题；100,000是作者估计可生成上限，不是发布题数。VOS另为1,000串行 / 20,548标注影格；41.3小时为原始视频长度。
- 评估方式：VQA报各prototype accuracy后分群平均，5选1；包含blind language基线。；VOS用J / F / J&F；recognition沿用EPIC100训练权重，在新视频评估。
- Split / 信息条件：定位为新数据上的validation / zero-shot benchmark；没有依一般80/10/10重新分配。人类基线只抽600题。
- 来源关系：与EPIC系列研究相承但此批视频新录；使用EPIC100模型训练来源。数字副本不自动具备机器人物理 / 判分界面。
- 可复用：提供比粗动作标签更细的食谱、营养、3D、对象动态、视线问答；是可借鉴的多端点设计。
- 待核 / 限制：原生数字副本的交互物理完整性、本库素材取得与逐题manifest尚未核对。

P013 Ego4D (2021)

原作：<https://arxiv.org/abs/2110.07058>

本次PDF：<https://arxiv.org/pdf/2110.07058v3>

PDF SHA256：d33d9e7a1d4a93ab8e9137e62966b3e2b7d631f4c5b98e481f6fc2220739c2fc

阅读页：1、6、7、8、9、24、29、30、48、49、70、71、72、73、75、77、79。正文五大benchmark全段；附录数据split、episodic memory规模、short / long anticipation协定与统计。

- 研究类型：人类视频与动作数据；综合第一人称数据与评测
- 领域：居家整理与清洁、餐饮与烹饪、工艺与修缮、零售与购物、交通移动与车辆维修、农业与园艺、休闲与运动、社交与沟通
- 环境：74个全球location / 9国；location不是去重后可加载场景ID。VQ3D专用子集另只使用4个扫描。
- 任务：5大benchmark：episodic memory、手物状态变化、影音说话者、社交互动、forecasting。MQ有110活动类别，NLQ有13模板；都不是整个Ego4D的domain / 任务总量。
- 题数 / 数据：3,670小时、931佩戴者为数据规模。NLQ约19.2K query (test约4K)；VQ 22,602 query；MQ 22.2K活动实例；short anticipation 64,798样本 (test 19,780)。各端点母视频重叠，不能相加为独立episode。

- 评估方式：NLQ用recall@k / tIoU；MQ用mAP与recall；VQ用时空AP及搜索效率。；PNR用秒级绝对时间误差、状态分类accuracy、对象检测AP。；说话者追踪 / diarization / 转录用MOT、speaker error、DER、WER；社交LAM / TTM用mAP、accuracy。；forecasting：轨迹 / 手部位置误差；short anticipation top-5 mAP；long anticipation以20步串行edit distance等设置报告。
- Split / 信息条件：同family内一致（forecasting与hands共用；memory内共用），不同family不保证同一切分。NLQ约60/20/20；forecasting原协定40/30/30，另有locomotion切分。test标注及相交narrations不公开。
- 来源关系：上游多机构录制数据；EgoSchema / EgoPlan等后续题库常重用它。主表与附录部分过滤前后数字不同，保留端点与版本。
- 可复用：是跨日常场域及过去 / 现在 / 未来题型的重要上游；覆盖广度和正式robot控制任务量需分开。
- 待核 / 限制：不同端点的跨family视频泄漏需逐ID审核。；本文内MQ表3与过滤后表8、forecasting110.5 / 120小时等口径不能静默合并。

P014 Ego-Exo4D (2023)

原作：<https://arxiv.org/abs/2311.18259>

本次PDF：<https://arxiv.org/pdf/2311.18259v4>

PDF SHA256: 15e31586e111eb32fe54131840b7733b095fb3b20bebb14be9610d11967e26a8

阅读页：2、4、6、10、19、24、25、28、30、36、38、39、41、42、44、69、73、74。数据、8场域、benchmark总表、关系 / keystep / procedure / 熟练度 / pose评分及切分附录。

- 研究类型：人类视频与动作数据；综合第一人称数据与评测
- 领域：餐饮与烹饪、个人照护、交通移动与车辆维修、休闲与运动、音乐与表演
- 环境：123个自然scene、13城市；多台ego / exo相机同步录同take，视角不增加场景或活动次数。
- 任务：8原生domains、43活动、689 keysteps为整体概述；keystep标注子集17活动 / 664标签，正式识别过滤后278叶节点。4大benchmark family内含跨视角关系、程序、熟练度、3D姿态等端点。
- 题数 / 数据：整体1,286小时、5,035 takes（概述）；附录切分列5,045 takes，须查版本差异。keystep识别130,979视角片段，test 33,001，其中ego 6,373。不能用全部14M自动 / 人工姿态影格替代题数。
- 评估方式：跨视角mask用visibility accuracy / IoU / 位置误差；生成视角另有生成metric。；keystep recognition top-1 accuracy；程序前置 / 可选 / 错误 / 缺步 / 后续步用calibrated AP。；熟练程度用top-1；指导 / 正确运行时刻用L1时间门槛mAP。；人体用MPJPE、MPJVE；手部用MPJPE及PA-MPJPE；人工GT与自动GT分开。
- Split / 信息条件：以take及participant保持互斥，衍生片段继承父take；附录列3,082 train / 842 val / 1,121 test。procedure测试graph及标签不公开。
- 来源关系：独立同步多视角搜集；同take的多视角和多端点共用来源。本文提醒v1过时，不能混用v1 / v2数字。
- 可复用：可扩展维修、照护、运动、音乐与熟练度；多数为人类技能观测，转成robot运行规格须另定机体与成功条件。
- 待核 / 限制：概述5,035与附录5,045 takes相差10，待manifest核对。；整体689与keystep子集664不能视为同口径。

P015 Assembly101 (2022)

原作：<https://arxiv.org/abs/2203.14712>

本次PDF：<https://arxiv.org/pdf/2203.14712>

PDF SHA256: f115520e2f1cb8ec65ecf3e197be18dd91e8f34b1ee58fcb36d18e1346d24c1e

阅读页：1、3、4、5、6、7、8、15。搜集、粗细动作统计、split及四端点实验。

- 研究类型：人类视频与动作数据；人类程序视频与步骤定位
- 领域：装配与生产作业
- 环境：固定多视角录制配置；8外部+4ego相机不是12个环境。
- 任务：101种take-apart玩具，15玩具类别；202粗动作、1,380细动作标签；4端点为识别、预测、分段、错误侦测。
- 题数 / 数据：362次拆装sequence，产生4,321视角视频、513视角小时；1,013,523细片段及104,759粗片段含多视角重复。
- 评估方式：识别top-1；提前1秒预测用class-mean top-5 recall。；分段MoF / edit / F1@10,25,50；错误 / corrective分类precision与recall，early模式只看半段。
- Split / 信息条件：60/15/25%；有seen / unseen玩具，25玩具跨split；视角与片段应继承原sequence。
- 来源关系：自行搜集；多视角是同次拆装，不能用4,321宣称同量独立任务。其细标签与3D手pose专用表又有不同子集。
- 可复用：可引入装配依赖、顺序变化、犯错与纠正；应保留玩具、步骤、观测端点三层单位。
- 待核 / 限制：数据表中姿态专用1,456标签与一般1,380标签的完整映射待manifest核对。

P016 IKEA ASM (2020)

原作：<https://arxiv.org/abs/2007.00394>

本次PDF：<https://arxiv.org/pdf/2007.00394v2>

PDF SHA256：5869f1542aa7372df85b6b4006127599aba58b0364d546d963dff8a3876080af

阅读页：1、3、4、5、6、8。数据与split、动作 / 分割 / 追踪 / 姿态评分段落。

- 研究类型：人类视频与动作数据；人类程序视频与步骤定位
- 领域：居家整理与清洁、装配与生产作业
- 环境：5个真实环境，桌上 / 地上共10相机配置；3台同步RGB相机。
- 任务：4种家具（side table、coffee table、TV bench、drawer）与原子装配动作；不是1,113个任务。
- 题数 / 数据：371次assembly，1,113 RGB视角视频及371 depth视频；本文16,764动作标注；254 train / 117 test assembly scans。
- 评估方式：动作frame accuracy、macro-recall、mAP。；零件分割与MOT分开；追踪MOTA、IDF1、IDs等。；3D姿态用MPJPE / PA-MPJPE、PCK@150mm。
- Split / 信息条件：按环境保留family room与office测试；作者明示此主split不保证subject同时互斥，另提供其他切分脚本。
- 来源关系：自行录制；空间标注仅1%影格人工，余下有pseudo-GT；不可把全部影格称人工标注。
- 可复用：家具装配与部件追踪来源；环境泛化与受试者泛化要分开报。
- 待核 / 限制：原子动作label完整清单与不同年份发布版本尚未逐ID对齐。

P017 HOI4D (2022)

原作：<https://arxiv.org/abs/2203.01577>

本次PDF：<https://arxiv.org/pdf/2203.01577v4>

PDF SHA256：82c5f0bf505f59eed426c1efa03f12a4155a5e18416ff03477d9e25c301be74f

阅读页：1、2、7、8。数据概述与三个benchmark完整定义 / 主要评分。

- 研究类型：人类视频与动作数据；视频数据与感知评测
- 领域：居家整理与清洁
- 环境：610个室内rooms（录制环境）；4个参与者，不是610个已接入交互模拟器。
- 任务：16对象类别、800实例；3端点：category-level pose tracking、4D segmentation、action segmentation。pose实验只取4刚体+1关节类别。
- 题数 / 数据：4,000 sequences、2.4M RGB-D影格；4D分割专用376视频 / 14语义类别，不能把全数据量当每个端点实测量。
- 评估方式：pose：5°5cm accuracy、旋转 / 平移误差；以扰动GT pose初始化。；4D分割mIoU；动作分段Acc、edit、F1@10/25/50。
- Split / 信息条件：4D sequence随机7:3 train/test；不等同未见房间或受试者切分。
- 来源关系：自行搜集RGB-D及模型；NOCS / H2O / GTEA是外部对照，不属本库量。
- 可复用：补充对象 / 材质 / 房间变化和3D感知；原文明示未覆盖双手操作。
- 待核 / 限制：610 rooms的逐ID清单与可用重建品质未导入。

P018 HOT3D (2024)

原作：<https://arxiv.org/abs/2411.19167>

本次PDF：<https://arxiv.org/pdf/2411.19167v2>

PDF SHA256：cbe0c55d8c952c673dbff8633b5f23eb87963f7cf09429416eb2f1ac58236232

阅读页：1、3、4、5、6、7。数据、有效标注与subject切分、手 / 物追踪、分割与3D lifting。

- 研究类型：人类视频与动作数据；视频数据与感知评测
- 领域：居家整理与清洁、餐饮与烹饪、办公与教育
- 环境：同一mocap lab中的4种情境布置：inspection、kitchen、office、living room；不是4处独立真实住宅。
- 任务：33刚体对象；手pose、对象6DoF pose、in-hand分割、3D位置lifting。
- 题数 / 数据：833分钟、1.5M多视角timestamps / 3.7M images；其中1.16M timestamps有效完整。HOT3D-Clips为3,832 clips = 2,804 train + 1,028 test。
- 评估方式：手部MKPE毫米误差；对象pose以对称性处理后平移 / 旋转门槛recall。；in-hand mask mIoU；lifting用位置门槛recall。对象pose实验提供GT mask，并非端到端自由侦测。
- Split / 信息条件：13名受试者train、6名test，test GT走服务器；部分评测每30影格取一。
- 来源关系：新录Aria / Quest3数据。EgoHOS与UmeTrack为跨数据对照；部分baseline的400K Aria训练图是私有数据，不可算HOT3D公开题。
- 可复用：提供可靠3D接触 / 姿态参考；可控场景多样性与传感视角多样性应分开。
- 待核 / 限制：正文425 recordings与198 Aria + 226 Quest3相差1，需manifest厘清。

P019 EgoBody (2021)

原作：<https://arxiv.org/abs/2112.07642>

本次PDF：<https://arxiv.org/pdf/2112.07642v3>

PDF SHA256: 2e3713a6294f2f6db2fb815fc25f0ce080ce1fec87b663ccac54ff669c7de501

阅读页: 1、2、4、6、7、8、9、10、11、12。交互分类、capture、数据与split、3DHPS metric。

- 研究类型: 人类视频与动作数据; 人体与交互感知评测
- 领域: 休闲与运动、社交与沟通
- 环境: 15个室内scene, 有扫描mesh; 每次两人交互, 一人佩戴HoloLens2。
- 任务: 5种社会交互分类用于搜集; 主benchmark为interactee的3D人体形状 / 姿态估计, 不是5个机器人任务。
- 题数 / 数据: 125 sequences / 36人; 219,731多视角timestamps、199,111 ego影格; 可见interactee子集175,611影格, 其中62,155 test。
- 评估方式: MPJPE、vertex-to-vertex error; pelvis translation alignment与Procrustes alignment分开。
- Split / 信息条件: subject不重叠; interactee train / val / test = 90,124 / 23,332 / 62,155。
- 来源关系: 自行搜集; 同时有MVSet、EgoSet、可见interactee三个相依子集, 不能相加。
- 可复用: 补社交互动、遮挡与人体观测; 不提供完成生活工作的robot action evaluator。
- 待核 / 限制: 扫描资产是否可直接用于交互模拟未验证。

P020 EgoHumans (2023)

原作: <https://arxiv.org/abs/2305.16487>

本次PDF: <https://arxiv.org/pdf/2305.16487v2>

PDF SHA256: 7d7f42b85231561ddb1a646fefbdec9fe97bc1e02455d7603006aa7ceac3de30

阅读页: 1、2、6。数据统计、test切分、tracking评测与主端点定义。

- 研究类型: 人类视频与动作数据; 人体与交互感知评测
- 领域: 休闲与运动、社交与沟通
- 环境: 6个地点 = 3室内 + 3室外; 7个活动sequence, 20人, 多人同时戴Aria。
- 任务: 篮球、击剑、羽毛球、网球、排球、追逐、搭城堡; 主要3D多人追踪, 并提供2D/3D姿态与mesh。
- 题数 / 数据: 125K ego RGB、250K灰阶、446K外部图像; 正式ego train77,260 / test47,740 images。
- 评估方式: CLEAR追踪指针 (MOTA、FP、FN、IDs)、IDF1、HOTA; 因主要使用off-the-shelf detector, 以IDF1作主要tracking指针。
- Split / 信息条件: train/test地点不重叠; 同步多人的多视角不能视为独立活动。
- 来源关系: 新搜集多视角; COCO用于模型训练对照, 不算本benchmark题数。
- 可复用: 拓展户外多人交互感知; 不能直接宣称涵盖同量可运行robot工作任务。
- 待核 / 限制: 各附加pose / mesh端点是否有独立正式leaderboard与有效ID需另查。

P021 Ego-ExoLearn (2024)

原作: <https://arxiv.org/abs/2403.16182>

本次PDF: <https://arxiv.org/pdf/2403.16182v3>

PDF SHA256: bca30af05c678a221e17c8ff0fa92006870fc0b46f569e824b52c98aefc8a15b

阅读页: 1、2、3、4、5、6、7、8、11、12、14、16。数据 / 来源、四大benchmark、association、anticipation / planning、skill, 及专用split附录。

- 研究类型: 人类视频与动作数据; 跨视角程序学习
- 领域: 餐饮与烹饪、实验室操作
- 环境: 4个厨房 + 3个lab; ego示范跟做与exo教程异步、非同一环境。
- 任务: 8程序 = 5日常 + 3实验室; 4大benchmark含association、action understanding、skill ranking、captioning; 39粗步骤, planning取27类; anticipation取19 verbs / 31 nouns。
- 题数 / 数据: 432 ego视频96.5小时 + 315 exo视频23.5小时; 34,239有效skill比较对, 从40,191候选对筛选。ego anticipation test约17.3K片段。
- 评估方式: association: 20候选top-1; anticipation: 1秒前class-mean top-5 recall; planning: 8步ED@K、5条预测串行; skill: pairwise ranking accuracy; supervised recognition: macro mAP。
- Split / 信息条件: 端点采专用过滤集; 保留ego→exo、exo→ego、UDA、distillation、co-training不同信息条件。
- 来源关系: 日常exo取网络视频, lab exo由资深人员录制; 动词 / 名词taxonomy借Ego4D再扩充, 不表示视频皆来自Ego4D。
- 可复用: 对示范到robot的跨视角程序转移很相关; 实验室程序补生活操作库缺域。
- 待核 / 限制: captioning及segmentation专用metric / 完整case ID仍需数据端核对。; 附录planning两组split重复写egocentric, 保留原文歧义, 未擅改。

P022 CaptainCook4D (2023)

原作: <https://arxiv.org/abs/2312.14556>

本次PDF: <https://arxiv.org/pdf/2312.14556v4>

PDF SHA256: 03be2a06a5c5cc778808214ae9232f3156dfd3ba60c07140d93d1a20222cc0ae

阅读页: 1、2、3、4、5、6、7、8、9、38。采集、错误taxonomy、三大benchmark定义及评测。

- 研究类型: 人类视频与动作数据; 错误辨识与程序恢复
- 领域: 餐饮与烹饪
- 环境: 10个真实厨房, 8名参与者; Hololens2与GoPro同步。
- 任务: 24个WikiHow食谱、7种错误: 准备、测量、技术、时间、温度、缺步、顺序; 错误类别不另算7生活domain。
- 题数 / 数据: 384 recordings、94.5小时、5.3K步骤标注及10K细动作标注; 细动作只在约20%数据标注。错误有刻意诱发及自然发生。
- 评估方式: 错误辨识accuracy / precision / recall / F1 / AUC; step与recording split分开。; multi-step localization及RobustMSL用mAP、R@K、temporal IoU; 只正常数据训练、正常 / 错误数据测试分列。; procedure learning沿EgoProceL采步骤precision / recall / IoU。
- Split / 信息条件: error recognition有step / recording split; MSL有不同泛化split, 不能把step split成绩当跨录像泛化。
- 来源关系: 新录像片, 程序取WikiHow; procedure基线与评分沿EgoProceL, 不是重用其全部素材。
- 可复用: 可具体借用规则违反与near-failure定义; 观测到错误不等于机器人已能运行恢复。
- 待核 / 限制: 各原生split精确ID数尚未导入; 错误组合空间只被部分采样。

P023 EgoProceL (2022)

原作: <https://arxiv.org/abs/2207.10883>

本次PDF: <https://arxiv.org/pdf/2207.10883v1>

PDF SHA256: 533531617781659b6d42cbb81529f76f79277cb3cf1d05dad3504547b4ecdf9a

阅读页: 1、3、4、5、6、8、9、10。数据选取与联集、procedure问题、key-step排序、评测协定。

- 研究类型: 人类视频与动作数据; 人类程序视频与步骤定位
- 领域: 餐饮与烹饪、工艺与修缮、装配与生产作业、农业与园艺
- 环境: 来源数据场景混合; 没有共同去重的独立环境总数。
- 任务: 16个程序, 平均8.7 key-steps; 含料理、玩具机车、搭帐篷、PC组装 / 拆解。
- 题数 / 数据: 62小时、130人; 原作本文未在已读统计表给单一可评test题总数。
- 评估方式: Hungarian matching后按每个key-step计frame precision / recall / F1 / IoU再平均, 避免背景与长步骤垄断分数。
- Split / 信息条件: 采task-specific self-supervised procedure learning设置; K是模型key-step数超参数, 不是数据集总任务量。
- 来源关系: 明确重用CMU-MMAC、EGTEA Gaze+、MECCANO、EPIC-Tents, 再增自录PC装拆; 不是全新独立62小时。
- 可复用: 是从既有程序数据联集再补缺域的直接先例; 我们须说明添加任务 / 规则, 不能把联集本身当全部新贡献。
- 待核 / 限制: 所有视频ID、跨上游重复量和各task可评片段数需manifest核对。

P024 EPIC Fields (2023)

原作: <https://arxiv.org/abs/2306.08731>

本次PDF: <https://arxiv.org/pdf/2306.08731v2>

PDF SHA256: c7c08e1c9614782d2dcddaeec95b253c5d9f756ff2c4d30b712bcac6a90eebd

阅读页: 1、2、3、5、6、7、8、22。重建覆盖、三个benchmark、难度与frame切分。

- 研究类型: 人类视频与动作数据; 3D场景与世界建模
- 领域: 居家整理与清洁、餐饮与烹饪
- 环境: EPIC100的45个厨房; 671视频成功重建, 没有添加671个独立layout。
- 任务: D-NVS新视角合成、UDOS动态 / 半静态对象分割、VOS; 不是671个操作任务。
- 题数 / 数据: 18,790,333已注册camera-pose影格; D-NVS只取50视频 (14.7小时、2.86M注册影格)。
- 评估方式: D-NVS: PSNR, 前景 / 背景分列; UDOS: segmentation mAP; VOS沿VISOR。; 难度依in-action/out-of-action及与train frame的时间距离; hard、medium排除附近1秒train frame。
- Split / 信息条件: 每视频val/test交替抽样; UDOS无监督可看全视频, 不是D-NVS同一可见输入。
- 来源关系: EPIC100 + VISOR的相机与几何扩充, 来源视频 / mask共用。
- 可复用: 提供3D / 视角 / 动态对象评测; 重建相机轨迹不是robot action轨迹。
- 待核 / 限制: 50个benchmark video-scenes与原厨房一对多关系待逐ID导入。

P025 EgoPet (2024)

原作：<https://arxiv.org/abs/2404.09991>

本次PDF：<https://arxiv.org/pdf/2404.09991v1>

PDF SHA256：8be645841806230228c292995eb6538540f9be6d228b916b37e53fefeeca59ca

阅读页：1、2、4、5、6、7、8、9、10。数据、3种预测端点、各自标注与指针。

- 研究类型：人类视频与动作数据；动作与轨迹预测
- 领域：宠物照护与动物活动
- 环境：动物网络视频无去重场景总量；VPP额外robot测试有office、park、beach三处。
- 任务：VIP交互辨识 / 17种交互对象；LP预测未来4秒40个位置；VPP预测terrain latent的过去 / 未来。
- 题数 / 数据：6,646片段、84小时；VIP 1,449标注片段=754train+695test；LP 6,126train / 249val；VPP另20分钟robot测试。
- 评估方式：VIP：accuracy / AUROC及object top-1/top-3；LP：ATE / RPE的RMSE；VPP：latent MSE。
- Split / 信息条件：三端点分开train/test或val；LP为SLAM pseudo-GT且有人工筛选，非mocap真值。
- 来源关系：TikTok / YouTube新整理；VPP训练另用既有robot数据，不能把动物视频数算为robot控制题。
- 可复用：补充低视角移动与人以外的具身感知；与操作benchmark应分层比较。
- 待核 / 限制：正文819原视频与482+338的平台分量不一致，待manifest厘清。

P026 EgoHOS (2022)

原作：<https://arxiv.org/abs/2208.03826>

本次PDF：<https://arxiv.org/pdf/2208.03826v1>

PDF SHA256：94b61333b3477ef582a94281cc28852c750d6fbe096ddfe90c9434ca39101f07

阅读页：1、2、4、5、6、9、10、12。来源、手物标签定义、OOD测试与主要分割评估。

- 研究类型：人类视频与动作数据；视频数据与感知评测
- 领域：居家整理与清洁、餐饮与烹饪
- 环境：Ego4D、EPIC、THU-READ及自录GoPro多来源；无共同scene ID总数。
- 任务：左 / 右手、左 / 右 / 双手接触物分割；直接 / 间接接触有标注，但本文主要评估直接接触。
- 题数 / 数据：原作总量11,243图像；OOD另500影格来自30个YouTube视频，主分割实验预设在此测试。
- 评估方式：mIoU；binary hand、left/right hand、hand+arm、held-object等标签定义分开比较。
- Split / 信息条件：以原作validation选checkpoint，500-image OOD为另列测试；不能把源视频数当测试题数。
- 来源关系：直接重用Ego4D、EPIC影格；跨库去重需frame时间戳。
- 可复用：可作接触判定与视觉状态监督；11,243不是11,243项可运行操作。
- 待核 / 限制：正文来源分量7,458+2,121+806+350未加总为11,243；subjects/activity的表格与叙述亦互换，暂不采这两项总数。

P027 EgoPCA (2023)

原作：<https://arxiv.org/abs/2309.02423>

本次PDF：<https://arxiv.org/pdf/2309.02423v1>

PDF SHA256：b1562d6e36e0c788642711c6bcd038ed83e381ad8f9ae62cc5e341ee516c0a39

阅读页：1、2、4、5、6、8、14。One4All来源统一、采样、表2与原生识别评测；附录类别合并。

- 研究类型：人类视频与动作数据；跨数据集集成与评测方法
- 领域：居家整理与清洁、餐饮与烹饪
- 环境：来源视频混合，不提供新的可计数交互环境。
- 任务：EPIC100、EGTEA、Ego4D-AR、Something-Else合并语义；pretrain394类、test204类，联集401类含zero-shot。
- 题数 / 数据：表2列pretrain20K / 30K / 50K；test3K / 5K / 10K为嵌套子集，不能相加成18K独立题。
- 评估方式：top-1 verb/action accuracy；另用语义、手 / 物位置、手姿、camera motion、模糊程度分析分布。
- Split / 信息条件：上游train与val/test分开抽；不同规模套件彼此包含。
- 来源关系：本身就是多来源语义合并与平衡采样先例；没有将所有源任务转成robot控制。
- 可复用：对任务联集、分布分析、平衡采样直接相关；须辨识此类前作，不能只与单域benchmark比规模。
- 待核 / 限制：§3.4提5K / 10K / 20K但表2及附录为3K / 5K / 10K；采表2口径并保留冲突。

P028 EgoSchema (2023)

原作：<https://arxiv.org/abs/2308.09126>

本次PDF：<https://arxiv.org/pdf/2308.09126v1>

PDF SHA256：4ae865287c1d40b806c5f51e4b5101fe90f7d246a201668f14bbb9cab00b442f

阅读页：1、2、3、5、6、7、9、14。数据生成与人工过滤、temporal certificate定义、评测与datasheet精确量。

- 研究类型：理解、推理与规划；视频问答与推理
- 领域：居家整理与清洁、餐饮与烹饪、工艺与修缮、农业与园艺
- 环境：Ego4D视频子集，未另外提供去重后环境数。
- 任务：长视频五选一QA；temporal certificate量必要证据时长，不能把3分钟输入长度直接当难度。
- 题数 / 数据：5,063题，每题一段3分钟视频；约250小时为衍生片段量。
- 评估方式：选项accuracy；人类时间 / 影格受限条件另列。；QA人工过滤要求至少30秒certificate，与完整3分钟视频长度区分。
- Split / 信息条件：本文定位zero-shot诊断评测；公开标签子集与完整隐藏评测需依发布版本另外核对。
- 来源关系：Ego4D非重叠3分钟片段产题，与其他Ego4D衍生QA仍可能共用上游视频。
- 可复用：可借certificate、人类验证和blind基线衡量时间推理难度；不评机器人实际完成。
- 待核 / 限制：本库未逐ID对齐所有Ego4D衍生benchmark。

P029 EgoThink (2023)

原作: <https://arxiv.org/abs/2311.15596>

本次PDF: <https://arxiv.org/pdf/2311.15596v2>

PDF SHA256: f52b14647c715c4187f0f53bb90bde9e7d6f2f5d10eefc5da2a39b714076e040

阅读页: 1、2、3、4、5、6、13、14。人工QA搜集、700题统计、六能力十二维度、judge协定。

- 研究类型: 理解、推理与规划; 视频问答与推理
- 领域: 居家整理与清洁、餐饮与烹饪、工艺与修缮
- 环境: 595个Ego4D母视频; scene统计是语义场景如kitchen, 不能当相同数量的独立物理房间。
- 任务: 6能力 / 12细分维度: 对象、活动、定位、推理、forecasting、planning; 输入为单张图像。
- 题数 / 数据: 700图像QA, 无重复选图; 每维度至少50题, activity与forecasting各100。
- 评估方式: GPT-4依问题、答案、reference打0 / 0.5 / 1分; 是模型评审分数, 不是精确答案匹配accuracy。
- Split / 信息条件: zero-shot评测; 无一般train/val/test训练配额。人工审核QA与后续模型judge分开。
- 来源关系: 抽Ego4D影格, 最多同video两张; 能力分类不等同生活domain分类。
- 可复用: 可借主观 / 开放答案rubric; planning问答不能当作控制成功证据。
- 待核 / 限制: 跨库母视频重叠及judge版本稳定性需实作端固定。

P030 EgoPlan-Bench (2023)

原作: <https://arxiv.org/abs/2312.06722>

本次PDF: <https://arxiv.org/pdf/2312.06722v3>

PDF SHA256: c15ca6dd2823dc0af2a6f55ce15cae49463268b814075cc9260e0d79ba751373

阅读页: 1、2、3、5、6、7、14。数据源、goal到QA、统计、选项评分、instruction-tuning数据区别。

- 研究类型: 理解、推理与规划; 视频问答与推理
- 领域: 居家整理与清洁、餐饮与烹饪
- 环境: 原作报419 scenes (视频观测场景), 非419个已建模robot layouts。
- 任务: 下一步planning QA; 表2合计3,269 task goals与3,185候选action plans, 两者不等问题数。
- 题数 / 数据: 4,939评测QA=3,355 val+1,584 test; 50K EgoPlan-IT是另外训练集, 非50K测试题。
- 评估方式: MC accuracy; 部分开放模型以候选答案条件likelihood排序, 需保留不同推论界面。; 观测只可到下一动作开始前; 历史状态不能泄漏GT下一步。
- Split / 信息条件: EgoPlan-Val / EgoPlan-Test; EgoPlan-IT仅用EPIC来源, 以Ego4D子集查跨数据泛化。
- 来源关系: EPIC-KITCHENS与Ego4D的衍生QA; 不可与上游视频或EgoPlan2直接加成独立新活动。
- 可复用: 提供goal / 历史 / 当前观测→下一步的可用题型; 不同goal文字仍须做语义等价审核。
- 待核 / 限制: 正文3,296 goals与表2的3,269相差27; 采表2数字且保留差异。; 419 scenes的跨视频物理等价关系未核。

P031 EgoPlan-Bench2 (2024)

原作：<https://arxiv.org/abs/2412.04447>

本次PDF：<https://arxiv.org/pdf/2412.04447v2>

PDF SHA256：86d13b4d204df0eee1eec14c5a5dde9f3cdc465b7e5b96009d4d8b7f4c48f353

阅读页：1、2、3、4、5、6、7。4 domains / 24 scenarios清单、goal过滤、观测选取、MC评分。

- 研究类型：理解、推理与规划；视频问答与推理
- 领域：居家整理与清洁、餐饮与烹饪、工艺与修缮、零售与购物、实验室操作、个人照护、交通移动与车辆维修、农业与园艺、休闲与运动
- 环境：24个语义scenario类别，非24个物理scene；来源1,113个Ego4D视频。
- 任务：4原生domains（Work / Daily life / Hobbies / Recreation）；保留4–20步的goal；284 goal verbs不是284个正式任务。
- 题数 / 数据：1,321道四选一QA；比第一版题少但原作场域更广，两种尺度要分开。
- 评估方式：直接匹配A/B/C/D计accuracy；原作不引入第三方LLM judge。
- Split / 信息条件：评测用QA；原作观测筛选以排除单张即可答与已泄漏动作的影格。
- 来源关系：Ego4D更新版衍生；与第一版方法相承，但不是在同一题集上直接扩成更大数量。
- 可复用：其24 scenario清单是广度候选的重要依据；不能拿少量QA即宣称域内所有任务已覆盖。
- 待核 / 限制：task-goal语义去重与跨EgoPlan版本同源query重叠未逐ID核。

P032 EgoTaskQA (2022)

原作：<https://arxiv.org/abs/2210.03929>

本次PDF：<https://arxiv.org/pdf/2210.03929v1>

PDF SHA256：9a06fc9a9cfb5e7102f62ff34137fd261251eb9bd7c19ec19b07d4b8f36b5e87

阅读页：1、2、4、5、6、7、8、10。LEMMA状态 / 因果标注、QA生成、两种split与metric。

- 研究类型：理解、推理与规划；视频问答与推理
- 领域：居家整理与清洁、餐饮与烹饪、社交与沟通
- 环境：LEMMA多代理家务视频；没有新的独立场景全集。
- 任务：3个scope（world / intent / multi-agent）×4问法（描述 / 预测 / 解释 / 反事实）；属QA taxonomy，不是12个生活工作。
- 题数 / 数据：从368K程序生成候选挑出40K balanced QA，基于约2K ego clips及30K状态 / 人物注记blocks。
- 评估方式：在answer vocabulary上分类，报accuracy；按scope / type / semantic与open/binary分列。
- Split / 信息条件：normal以QA按3:1:1分train/val/test；indirect以多步间接指涉作泛化测试，不可当场景互斥split。
- 来源关系：直接扩充LEMMA标注；因果trace由前 / 后置条件规则生成，belief标注由多数人工票决。
- 可复用：提供规则、前置条件、因果与多代理信念的具体扩充；反事实QA不等于模拟器已验证反事实轨迹。
- 待核 / 限制：40K题的video父ID与上游LEMMA环境重用未导入。

P033 EgoLife (2025)

原作：<https://arxiv.org/abs/2503.03803>

本次PDF：<https://arxiv.org/pdf/2503.03803v3>

PDF SHA256：62089719b6879f1f7f10401989959c9a7e0531aa411284d10c9a713f0634c49a

阅读页：1、3、4、5、6、7。搜集、QA流程、正式题库与当版跑分范围。

- 研究类型：理解、推理与规划；长期记忆与生活助理
- 领域：居家整理与清洁、餐饮与烹饪、休闲与运动、社交与沟通
- 环境：1个自建EgoHouse、6人共同生活7天；15台外部相机不是15个环境。
- 任务：5题型：EntityLog、EventRecall、HabitInsight、RelationMap、TaskMaster。
- 题数 / 数据：约300小时原始 / 266小时保留视频；正式EgoLifeQA 3,000题（每人500）。本版§5快速实验只用Jake的500题；EgoIT-99K为训练数据。
- 评估方式：multiple-choice accuracy；依certificate长度、题型、audio / identity设置分析。；比较captioner时，最终QA由共同GPT-4o回答；这与将GPT当评分judge不同。
- Split / 信息条件：来源为连续一周个人经历；99K / D1模型训练与QA证据时间应另外追踪。
- 来源关系：新录EgoHouse；EgoIT-99K含其他ego来源，不能把训练集99K称本benchmark添加test量。
- 可复用：补多日记忆、习惯与人际关系；需要保留个人 / 共同事件重叠而非把6人同步视频全当独立时长。
- 待核 / 限制：完整3,000题是否有同设置的发布成绩，须另查后续版本。

P034 EgoVLP (2022)

原作：<https://arxiv.org/abs/2206.01670>

本次PDF：<https://arxiv.org/pdf/2206.01670v2>

PDF SHA256：cd7cf25aa25da8a2a88d0875ec2f0a5cf56f99a045eb7c11957a6e27784f584f

阅读页：1、3、4、5、6、7。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：人类视频与动作数据；视频数据与感知评测
- 领域：居家整理与清洁、工艺与修缮
- 环境：Ego4D的129scenario labels；来源环境重用。
- 任务：EgoMCQ包含inter-video/intra-video两种五选一video-text配对；EgoClip是训练库。
- 题数 / 数据：EgoClip约3.85M narrations/2,927h；EgoMCQ约39K题 = 24K inter+15K intra。
- 评估方式：EgoMCQ accuracy；下游retrieval、NLQ、recognition分开。
- Split / 信息条件：EgoClip排除Ego4D val/test；EgoMCQ再人工移除和pretraining共用multi-view的视频。
- 来源关系：Ego4D→EgoClip/EgoMCQ；两位narrators不代表两份独立行为。
- 可复用：原先只列成方法会漏掉真正添加的EgoMCQ；应把论文与其多个资源分开登记。
- 待核 / 限制：39K是概述约数；最终题ID与选项去重需原始manifest。

P037 EgoEnv (2022)

原作: <https://arxiv.org/abs/2207.11365>

本次PDF: <https://arxiv.org/pdf/2207.11365v3>

PDF SHA256: 30fca03c8d8d57b800a30c4d921db35c49f8d6339b1679c30268654e7783ba47

阅读页: 1、6、7、8。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 理解、推理与规划; 空间理解与affordance
- 领域: 居家整理与清洁
- 环境: pretraining 900 HM3D scenes; HouseTours选886houses, MP3D90scenes; 各自保留source单位。
- 任务: room prediction与NLQ两端点; 21real room classes, MP3D9classes不是新的生活domain。
- 题数 / 数据: 约15K合成walkthroughs×512steps; HouseTours约32h、MP3D146walkthroughs; QA精确总量未核。
- 评估方式: room分类、NLQ temporal localization; local-state AP另测。
- Split / 信息条件: HouseTours按house切, Ego4D/MP3D用原split; video memory可读query附近全片, 非严格在线。
- 来源关系: 添加HouseTours labels、Ego4D NLQ沿用, HM3D/MP3D资产重用。
- 可复用: 补house-tour与室内环境理解; source录像场所与sim资产必须分开。
- 待核 / 限制: Ego4D段落称1,259scenes, 需核是video/session或实体place; 不纳跨来源环境总和。

P038 OpenEQA (2024)

原作:

https://openaccess.thecvf.com/content/CVPR2024/html/Majumdar_OpenEQA_Embodied_Question_Answering_in_the_Era_of_Foundation_Models_CVPR_2024_paper.html

本次PDF:

https://openaccess.thecvf.com/content/CVPR2024/papers/Majumdar_OpenEQA_Embodied_Question_Answering_in_the_Era_of_Foundation_Models_CVPR_2024_paper.pdf

PDF SHA256: d2c714b7cfdcee8fe6cde607296c15689ecff298b752611c913458fd3964ca48

阅读页: 1、2、3、4、7。EM / Active定义、数据源与生成、题数及LLM-Match协定。

- 研究类型: 理解、推理与规划; 具身问答与探索
- 领域: 居家整理与清洁、办公与教育
- 环境: 搜集阶段100个ScanNet scenes + 87个HM3D scans; 这是生成候选history范围, 非已验证题目引用的152个history IDs。
- 任务: 7问答类别; 两种设置EM-EQA / A-EQA。Active只允许导航探索, 未包括开柜等操作。
- 题数 / 数据: 正式1,636题=1,079 ScanNet + 557 HM3D; A-EQA重用这557题, 不能加成2,193独立QA。
- 评估方式: LLM-Match给1-5分再范式; 不是字符串match或MC accuracy; Active另按路径长度折算效率; object localization有多个合理reference答案。
- Split / 信息条件: 来源ScanNet val/test、HM3D val场景; 相同QA跨EM与Active, 只改可用信息 / 探索权限。
- 来源关系: ScanNet / HM3D + Habitat。与本库固定manifest的152 history IDs口径不同, 187候选不等于187已取得交互环境。

- 可复用：是同一问题在记忆与可探索环境两种设置的明确先例；应以共享query而非双倍题数表示。
- 待核 / 限制：Active公开资产 / 运行入口和本文可评557题的可重现范围需另核；已取得QA metadata不代表所有素材到位。

P039 RoboVQA (2023)

原作：<https://arxiv.org/abs/2311.00899>

本次PDF：<https://arxiv.org/pdf/2311.00899v1>

PDF SHA256：0d6f31eb8631105b7abfd15b617c7477404b7e7694955c0a3108fcff05d658bf

阅读页：1、2、3、4、5、6、10。数据搜集、10种QA扩充、VQA人工判分与三种planning介入评测。

- 研究类型：理解、推理与规划；具身问答与探索
- 领域：居家整理与清洁、餐饮与烹饪、办公与教育
- 环境：3栋办公楼，robot / 人手 / 人持夹具3种embodiment。
- 任务：2,722 unique长指令、26,798 unique中程指令；字符串去重不是共同语义任务去重。10种QA包含规划、完成检测、affordance、过去描述 / 未来预测。
- 题数 / 数据：5,246长程episodes、92,948中程episodes、238小时；VQA val/test各约1,000笔，来自各50 episodes。另100个脱机planning episodes / 854步、10个live teleop任务及1个自主5步任务。
- 评估方式：VQA先查已人工判定的答案缓存，未见答案交人工判correct/incorrect；planning分cognitive / physical intervention rate；人类救援使所有任务完成，不能把完成率当自主成功率。
- Split / 信息条件：episodes互斥但scenes可重叠；robot-only与human+robot测试分开。
- 来源关系：自身多机体搜集；SayCan固定60任务是外部baseline范围，不是RoboVQA任务总量。
- 可复用：是大广度robot / human数据与高低级分离评测的直接比较对象；数万指令已大于先前任意5,000配额。
- 待核 / 限制：完整release QA精确行数与文字语义去重量尚未重算。

P040 RoboBench (2025)

原作：<https://arxiv.org/abs/2510.17801>

本次PDF：<https://arxiv.org/pdf/2510.17801v2>

PDF SHA256：b34e12bf6f096b03930eb63d6e6580345d4fc1330c8c54c7f9660c501b7ff204

阅读页：1、2、4、5、6、7、8、9、10、18、22。5维度 / 25端点、数据表、人机标注、Q1-Q3评分及下游控制验证。

- 研究类型：理解、推理与规划；综合具身认知评测
- 领域：居家整理与清洁
- 环境：多来源robot视频与自录配置；未报可相加的去重物理layout总量。
- 任务：5维度、14能力群、25评测端点；不同于25个生活工作任务。
- 题数 / 数据：6,092 questions / 4,336 unique items；含1,895 MC与Q1/Q2/Q3各1,973 / 842 / 1,192，加190navigation。相同item衍生多种问题。

- 评估方式：感知 / affordance / failure用MC accuracy；Q3 binary accuracy°；Q1用MLLM评node correctness与milestone completion；Q2用MLLM评skill/object/parameter。所称world-simulator是模型判断，不是刚体物理模拟运行。；另以CALVIN / LIBERO控制结果查关联，属下游验证子集。
- Split / 信息条件：QA与下游CALVIN ABC→D、LIBERO-Long10任务 / 各50trials分开；模型全对题会被筛掉，难度带有选模依赖。
- 来源关系：多robot来源及RoboMIND失败轨迹；planning failure有人工注入，execution failure来自真rollouts，证据不能混。
- 可复用：最直接的全in-one具身认知比较对象之一；我们需清楚提出场域 / 任务联集与可验证规则的添加部分。
- 待核 / 限制：来源unique item跨上游重用尚未逐ID去重；v1 unique items为4,333，不套用到v2°。

P041 EgoCross (2025)

原作：<https://arxiv.org/abs/2508.10729>

本次PDF：<https://arxiv.org/pdf/2508.10729v2>

PDF SHA256：f4c3606509844a990b9b1c2fc3df05bdab0cff9a08af8fa5446cc9080f49e743

阅读页：1、3、4、7、10。domain选择、五个上游数据、QA数、Close/Open评分与finetuning split°。

- 研究类型：理解、推理与规划；视频问答与推理
- 领域：工艺与修缮、医疗与手术支持、休闲与运动、宠物照护与动物活动
- 环境：4个domain来自5数据集，不是4个环境；含内视镜工具视角，不全是人类头戴相机。
- 任务：identification / localization / prediction / counting四类，15细分题型。
- 题数 / 数据：957 QA、798 clips；OpenQA与CloseQA为同一问题两种格式，不是1,914个独立题。
- 评估方式：CloseQA：4选1 accuracy；OpenQA：Qwen-Max检查语义正确与reference°。
- Split / 信息条件：主zero-shot全题；SFT / RL pilot将原QA再70:30分train/test，其分数不能与全题zero-shot当相同测集。
- 来源关系：EgoSurgery、CholecTrack20、ENIGMA-51、ExtremeSportFPV、EgoPet的衍生QA°。
- 可复用：直接提示家务之外的缺域；跨domain来源联集已有前例，要把多样性贡献做得可量化。
- 待核 / 限制：上述五个上游是否全部在现有书目中独立登记需补查。

P042 RoboSpatial (2024)

原作：<https://arxiv.org/abs/2411.16537>

本次PDF：<https://arxiv.org/pdf/2411.16537v5>

PDF SHA256：58a5b655a8d69265586b817547ebe08770c6d88ea05ea17d50c2fb56ead76c22

阅读页：1、2、3、4、5、6。关系与frame定义、生成规则、表2、Val/Home评测。

- 研究类型：理解、推理与规划；空间理解与affordance
- 领域：居家整理与清洁、办公与教育
- 环境：训练4,916 indoor scans + 190 tabletop scenes；validation40 scans + 77 scenes；来源重用而非新扫描5K个robot场景。
- 任务：context / compatibility / configuration三类空间关系，ego / world / object三种reference frame°。
- 题数 / 数据：约3M是生成训练QA/relations；正式Val 6,000题，每关系2,000；新录Home另350人工题。

- 评估方式：yes/no accuracy；座标预测以3D点是否落在reference convex hull判正确。；compatibility以bbox放置无重叠且各轴10cm余量的几何规则构造，不等于真实可操作性。
- Split / 信息条件：Val scans完全未在training中；另有indoor↔tabletop泛化与OOD Home。
- 来源关系：ScanNet、Matterport3D、3RScan经EmbodiedScan取几何；桌面用HOPE、GraspNet-1B；BLINK / SpatialBench是外部eval。
- 可复用：是规则自动扩题与多reference-frame评测的直接先例；可扩大题量，但需保留train与eval区别。
- 待核 / 限制：源scan之跨库重建重复量及bbox规则边界误差需原生ID / 几何审核。

P045 ManipBench (2025)

原作：<https://arxiv.org/abs/2505.09698>

本次PDF：<https://arxiv.org/pdf/2505.09698v2>

PDF SHA256: 7cd33f53355500d085efdd4c1c80dd05509e3d3b24c6ec7232519a9481e53d53

阅读页：1、3、4、5、6、27。三种数据源、五种操作类别、MCQ创建及实体验证。

- 研究类型：理解、推理与规划；空间理解与affordance
- 领域：衣物与洗护
- 环境：DROID / Bridge原始场景、自录布料工作站、SIMPLER / RLBench / SoftGym与添加IsaacSim ball场景。
- 任务：pick-place、articulated、deformable、tool、dynamic五种操作类别；布料10理解维度；另外7个真实机器人验证任务。
- 题数 / 数据：12,617 MCQ=9,180公共robot数据题+2,662布料题+其余simulation题；公共数据Q1 6,120、Q2 3,060，来自同episode的augmentation不算新任务。
- 评估方式：MC accuracy；Q2要pick与place两子题都对才算joint correct，第二题提供GT pick。；MCQ所称pick-place success不等于实际robot rollout success；另列UR5物理验证。
- Split / 信息条件：MCQ benchmark与7真机任务分开；新组合未在MCQ中共现，并非保证所有对象个别都未见。
- 来源关系：多既有数据 / simulation衍生+自录布料；有question augmentation共享母episode。
- 可复用：直接对应多来源robot操作→多模态题库；需比它更广的工作用途与更完整规则，而非只加QA格式。
- 待核 / 限制：各simulation来源精确母episode数与跨题同源关系需manifest导入。

P051 USST / EgoPAT3D trajectories (2023)

原作：<https://arxiv.org/abs/2307.08243>

本次PDF：<https://arxiv.org/pdf/2307.08243v2>

PDF SHA256: 592b977dc3d758aa321266c4f5e7588d29c8fd207b4630fa191021a49d73b634

阅读页：1、5、6。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：未来动作 / 交互预测；动作与轨迹预测
- 领域：居家整理与清洁
- 环境：EgoPAT3D-DT 14scenes=11seen+3unseen；H2O重用原capture。

- 任务：3D hand-centroid trajectory forecasting；2D projection另报，不是完整手指控制。
- 题数 / 数据：H2O 8,203/1,735/3,715 train/val/test windows；EgoPAT3D-DT 6,356/846/1,605 seen test+2,334 unseen test。
- 评估方式：ADE/FDE，3D以米、2D以frame size范式；3D模型投影和2D直接模型分开。
- Split / 信息条件：H2O64frame windows步长15，窗口重叠；EgoPAT3D有held-out scenes。
- 来源关系：H2O→PT/DT、EgoPAT3D→DT是添加标注；不把父原片重复计。
- 可复用：可添加trajectory模块；相近窗口须依原视频群聚切分与估计。
- 待核 / 限制：后续Diff-IP2D提及原repo的FDE erratum；比较成绩需固定修正版本。

P053 HandsOnVLM (2024)

原作：<https://arxiv.org/abs/2412.13187>

本次PDF：<https://arxiv.org/pdf/2412.13187v2>

PDF SHA256：9ad31595678bd06e9139e118c6a693354034f7c08a91f74988de80f3e5836948

阅读页：1、5、6、7。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：未来动作 / 交互预测；动作与轨迹预测
- 领域：餐饮与烹饪
- 环境：EPIC/H2O/FPHA/Ego4D原视频环境，无添加可运行robot scenes。
- 任务：VHP显式动作指令与RBHP隐式意图两预测任务；10observed→4future frames，4fps。
- 题数 / 数据：RBHP生成7.5K EPIC与8K Ego4D QA-prediction pairs；24K/epoch是抽样预算而非独立题库。
- 评估方式：ADE/FDE/WDE，不是语言答对率或robot完成率。
- Split / 信息条件：EPIC validation及H2O/FPHA zero-shot；+版本混合五个额外QA训练来源。
- 来源关系：OCT-style手轨迹标注+GPT生成implicit instructions；父视频和explicit/implicit变体共享。
- 可复用：是扩充任务规则的来源：同轨迹在明示/隐式需求下重测，保留对照关系。
- 待核 / 限制：生成指令的精确train/test manifest与ground-truth歧义需核；不是每次生成都新语义task。

P054 EgoVid-5M/EgoDreamer (2024)

原作：<https://arxiv.org/abs/2411.08380>

本次PDF：<https://arxiv.org/pdf/2411.08380v1>

PDF SHA256：c878ace0c6d18cf230b26b97a809cdaeda44659ed1cdf693245c44b6681b7f9d

阅读页：1、4、5、6、7、8。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：世界模型与预测表示；世界模型与视频生成评测
- 领域：居家整理与清洁、办公与教育、工艺与修缮、休闲与运动
- 环境：重用Ego4D来源，场景总数未报。
- 任务：文字与camera kinematics条件下video generation；kinematic label不是robot action。

- 题数 / 数据：名义5Mclips；正文4.9Mtrain、1.2Kval，只有65K具可用IMU的kinematic subset。
- 评估方式：CD-FVD、semantic/action alignment、clarity、motion smoothness/strength及pose errors。
- Split / 信息条件：val按品质/多样性选，已读段未明示source-video-disjoint；三个1Mcleaning subsets不是添加数据。
- 来源关系：Ego4D→EgoVid，VIO/MLLM重标；generation评测沿用AIGCBench/VBench部分metrics。
- 可复用：补ego世界模型，但评测视觉品质和实际可控物理成功需另验证。
- 待核 / 限制：5M不能全部叫action-conditioned examples；4.9M与5M概述差异保留。

P057 Motor attention and action forecasting (2019)

原作：<https://arxiv.org/abs/1911.10967>

本次PDF：<https://arxiv.org/pdf/1911.10967v2>

PDF SHA256: 91f5c905b44c16ebb6de7ac8c6523846a0254a218889c9afb2fc8305e061fc33

阅读页：1、7、8、9、11。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：未来动作 / 交互预测；动作与轨迹预测
- 领域：餐饮与烹饪
- 环境：EGTEA与EPIC-Kitchens原capture。
- 任务：action anticipation、motor attention、interaction hotspot三端点。
- 题数 / 数据：EGTEA10,321action instances；EPIC39,596是父数据，全量hotspot仅EGTEA，EPIC只many-shot noun subset。
- 评估方式：Top1/5、mean-class accuracy、hotspot F1/KLD、trajectory ADE/FDE。
- Split / 信息条件：EGTEA split1/0.5秒anticipation，EPIC既有train/val及1秒anticipation。
- 来源关系：增加manualhotspots；EPIC motor attention用fingertip→hotspot线性插值近似，非完整真实追踪。
- 可复用：补早期joint HOI预测及标签品质差异，保留真实/推估label来源。
- 待核 / 限制：添加hotspot/trajectory标注精确ID数未报，不能把39,596全当添加标注题。

P058 EgoPAT3Dv2 (2024)

原作：<https://arxiv.org/abs/2403.05046>

本次PDF：<https://arxiv.org/pdf/2403.05046v1>

PDF SHA256: 7496f4c315189a824e5c490ba688d26788d161a66d4cbc6f93caf2d64665979c

阅读页：1、2、4、5、6。原版 / 添加数据、seen/unseen切分、10段进度评分及HRI定位。

- 研究类型：未来动作 / 交互预测；动作与轨迹预测
- 领域：跨域 / 用途未指定
- 环境：原版5 seen + 6 unseen scenes；添加9 seen + 2 unseen，合计22场景（由原文分量推算）。
- 任务：从RGB预测人手3D action target；cobot接近 / 避让是应用展示，非22个操作goal。
- 题数 / 数据：本轮已读原作未取得精确clip总量；各test clip按进度10等份评测，不能乘10当独立轨迹。

- 评估方式：厘米级target prediction error，early / late分列；3个训练seed取平均。
- Split / 信息条件：保留T1/T2训练与D1/D2测试来源、seen/unseen；train clips最多25frames，test不限制。
- 来源关系：EgoPAT3D扩充并修正部分GT；原baseline也因此改进，需固定版本后比较。
- 可复用：可加入人类手部目标提前量 / 距离误差轴，不能拿10个观测比例冒充10种任务。
- 待核 / 限制：添加与原版各split精确clip ID总量仍须发布数据核对。

P060 Continuous 4D interaction forecasting (2026)

原作：<https://arxiv.org/abs/2609.08636>

本次PDF：<https://arxiv.org/pdf/2609.08636v1>

PDF SHA256：831ddd738803ba93751f328695856f63519cd1327b28140774d76cb95ae0ba35

阅读页：1、2、4、5、6。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：未来动作 / 交互预测；动作与轨迹预测
- 领域：餐饮与烹饪、医疗与手术支持、交通移动与车辆维修
- 环境：Ego-Exo4D的787takes，不等于787独立场地。
- 任务：3D interaction location + full-body pose联合预测；Cooking/Health/BikeRepair三用途。
- 题数 / 数据：233,828windows = 193,598train + 20,484val + 19,746test；1,594,186是有效future targets。
- 评估方式：continuous location errors与MPJPE/PA-MPJPE；两种target和validity mask分开。
- Split / 信息条件：take-level split；三域horizon为10/5/4interaction steps，不是固定秒数。
- 来源关系：Ego-Exo4D + Flction式事件 + WHAM重建；exoviews仅供offline labels。
- 可复用：扩展where-to-how预测；source-domain与camera/pose时间对应都可入共同规格。
- 待核 / 限制：take-level不自动证明不同take没有共用实体环境；作者scene-disjoint说法需place IDs核。

P061 Interact with me (2024)

原作：<https://arxiv.org/abs/2412.16698>

本次PDF：<https://arxiv.org/pdf/2412.16698v3>

PDF SHA256：35eabf84ae2cfa183887ab3924f91d9f15fa53aac29576e56407b4eee8da3642

阅读页：1、2、3、4、5。JPL扩充、3组标签、训练augmentation、主要实验。

- 研究类型：未来动作 / 交互预测；人体与交互感知评测
- 领域：社交与沟通
- 环境：沿用JPL人机交互视频；未报添加scene总数。
- 任务：intent 3类、attitude 2类、action 10类；attitude是依action规则产生的标签，不是独立量测心理状态。
- 题数 / 数据：200母视频→290 person-level tracks；crop/flip/keypoint noise扩增只增加训练样本，不增加290个来源个案。
- 评估方式：三任务各报accuracy及F1；主表观测首1秒30frames，另变更窗口；模型latency另列。

- Split / 信息条件：本轮已读段落未取得正式train/test track ID分配；不得把290直接称test题。
- 来源关系：JPL video-level标注扩成人物track；同视频多个人共享情境。
- 可复用：补交互意图与社交预测；需注明人设标签规则及与动作标签的依赖。
- 待核 / 限制：同母视频track是否跨split及split数须源code核对。

P065 CALVIN (2021)

原作：<https://arxiv.org/abs/2112.03227>

本次PDF：<https://arxiv.org/pdf/2112.03227v4>

PDF SHA256：c8ad4741782fa8fb773377fbf61b8772b86574f255599a229d3f6ad4d878c60e

阅读页：1、2、3、4、5、7。4环境、34task与全部success criteria、play数据及MTLC / 长链评测。

- 研究类型：一般操作 benchmark；模拟操作benchmark
- 领域：跨域 / 用途未指定
- 环境：A/B/C/D四个配置；共用桌面、robot及camera位置，但滑门 / 抽屉 / 开关位置与材质不同。
- 任务：34原子任务，包括方块转动 / 推移 / 抬起、收纳、堆栈、开关门与灯。
- 题数 / 数据：24小时play、约2.4M steps / 40M可重标窗口是数据潜量；正式long-horizon 1,000条5步链；单步每task10个rollouts。
- 评估方式：task completion依起终状态变化，不只终点距离；长链只成功才转下一subgoal，报链长 / 成功情况。
- Split / 信息条件：single / multi / zero-shot multi环境；ABC→D为未见配置但语义任务已在train出现，语句另保留未见表达。
- 来源关系：PyBullet自建play环境；多后续VLA评测重用同1,000 chains，不能算各自添加题库。
- 可复用：可借串行可行性、过程状态与长链测试；34原子任务和5,000子步次数不能混算。
- 待核 / 限制：模型成绩比较必须固定语言 / 初态链版本及可用sensor。

P066 ManiSkill (2021)

原作：<https://arxiv.org/abs/2107.14483>

本次PDF：<https://arxiv.org/pdf/2107.14483v5>

PDF SHA256：90472755c9779e6088c8a94faaed0a4de3b9743d2d994c421973b0e7c402b374

阅读页：1、3、4、5、6、7。原生task / environment定义、4 skills、对象split、demo及评分。

- 研究类型：一般操作 benchmark；模拟操作benchmark
- 领域：居家整理与清洁
- 环境：原作environment以一个对象资产为单位；表1为52门柜、35抽屉柜、36椅、39桶，柜体可能含多door/drawer，不能当162独立房间。
- 任务：4 skills：OpenCabinetDoor、OpenCabinetDrawer、PushChair、MoveBucket；涵盖单 / 双臂mobile manipulation。
- 题数 / 数据：约36K成功demonstrations、1.5M frames；测试对象每skill10个，cabinet target有多门 / 多抽屉。
- 评估方式：预定test environment instances的mean success；task-specific终态 / 稳定性判定；training restrictions分track。

- Split / 信息条件：同对象category下train/test object互斥；单个scene参数变化另为environment instance。
- 来源关系：SAPIEN + PartNet-Mobility类资产；ManiSkill2继承这4项，不可视作全部新任务。
- 可复用：资产拓扑泛化与对象级environment是重要细节；需转译成共同字段但不抹平原生定义。
- 待核 / 限制：门柜 / 抽屉柜底层asset ID是否重叠需manifest核。

P067 ManiSkill2 (2023)

原作：<https://arxiv.org/abs/2302.04659>

本次PDF：<https://arxiv.org/pdf/2302.04659v1>

PDF SHA256：89fb794345d860ee696ca2f4d7a75059b15352b615794eeadb0e6075426136f0

阅读页：1、2、3、4、5、6、7、8、19、22。20families内容、精密装配规则、rigid-soft平台、评测与部分task-specific附录。

- 研究类型：一般操作 benchmark；模拟操作benchmark
- 领域：居家整理与清洁、装配与生产作业
- 环境：SAPIEN / MPM配置及2,000+ object models；object assets非同量房屋。
- 任务：20 families：6 soft、3精密插入、5 pick-place、5关节 / mobile、1 AvoidObstacles；继承ManiSkill1的4项。
- 题数 / 数据：4M+ demonstration frames为训练数据。test依task不同：如PickSingleYCB每对象5/10 episodes、cabinet两阶段各250等，不能指定所有task同一题数。
- 评估方式：task-specific真物理成功；插入必须实际进孔，非靠近goal pose。；原文同AssemblingKits基线在pose accuracy可99%、真插入成功只18%，说明难度高度依赖规则。
- Split / 信息条件：按对象train/test及challenge stage，控制器可转换但要保留其action约定。
- 来源关系：继承ManiSkill1；任务灵感来自MetaWorld / RL Bench / Ravens，但更改孔洞几何与成功判准，属有实质规则差异的衍生。
- 可复用：直接支持『同名任务可扩充规则』主张；更严格成功条件必须以独立规则版本记录。
- 待核 / 限制：全20家族不同阶段test episodes总量要从eval manifest按版本重算。

P069 robosuite (2020)

原作：<https://arxiv.org/abs/2009.12293>

本次PDF：<https://arxiv.org/pdf/2009.12293v3>

PDF SHA256：3da1cc7ba84ee487a90d7013325dd6045eea7c2920bc50cdb8ff37db67426fd4

阅读页：1、7、10、11、12、13、14、15、16、17。平台、robots/controllers、全部9 benchmark descriptions与标准评测。

- 研究类型：一般操作 benchmark；模拟平台与任务套件
- 领域：居家整理与清洁、装配与生产作业
- 环境：9标准task环境，共用可配置arena / robot；10robot模型不是10场域。
- 任务：Lift、Stack、PickPlace、NutAssembly、Door、Wipe、TwoArmLift、TwoArmPegInHole、TwoArmHandover。
- 题数 / 数据：程序随机初始化，未固定全库题量；基线9环境xrobot/controller组合，5 seeds是训练重复，不增加task。

- 评估方式：标准SAC实验报normalized episode return, 500step horizon; task success条件依具体任务, 不能把return当百分比成功率。
- Split / 信息条件：原作比较Panda/Sawyer与OSC/joint velocity, 建议固定Panda OSC; 未提出全域held-out task split。
- 来源关系：MuJoCo模块平台; LIBERO、RoboCasa、MimicGen等重用, 平台与下游bench不可当完全独立环境源。
- 可复用：提供共通模拟 / 控制器 / task界面; 平台功能与benchmark实绩分开。
- 待核 / 限制：repo v1.5可用的其余task是否超过本文9个标准评测需分清, 不以注册class数覆盖论文结果。

P070 RoboCasa (2024)

原作：<https://arxiv.org/abs/2406.02523>

本次PDF：<https://arxiv.org/pdf/2406.02523v1>

PDF SHA256: 7aca93ca3f157e32a46e02d675b3b2c24e3073a7807c038f7f566b73db87bde3

阅读页：1、2、3、4、5、6、8。场景、资产、100tasks组成、MimicGen数据与正式eval子集。

- 研究类型：一般操作 benchmark; 模拟操作benchmark
- 领域：居家整理与清洁、餐饮与烹饪
- 环境：10 floor plans×12 styles=120 scenes; 只能把10称平面layout数。额外AI textures不添加layout。
- 任务：100=25 atomic (8skills) + 75 composite (20料理活动标签下生成并实作)。
- 题数 / 数据：atomic有1,250 human demos; 生成实验72K (24tasks, 排除navigation) 另28K组成100K发布集。主要eval每task50 trials, 分5个固定场景。
- 评估方式：物理task success; 按skill、数据规模、未见对象 / style分列。
- Split / 信息条件：eval只用未见对象实例; 5场景中2种style未见。MimicGen有成功rejection sampling, 训练数据成功不代表policy成功。
- 来源关系：Robosuite底座、Objaverse / Luma资产、MimicGen扩样; 后续RoboCasa365是同家族延伸。
- 可复用：支持生活工作组合扩充; 域仍主要在厨房, 须报真实layout与style层次。
- 待核 / 限制：本库先前收集的60个来源场景条目来自不同repo版本, 不能与此PDF120 scenes混写, 更不能叫60独立layouts。

P072 VLABench (2024)

原作：<https://arxiv.org/abs/2412.18194>

本次PDF：<https://arxiv.org/pdf/2412.18194v1>

PDF SHA256: 9dc4aa5cfa6dcb86a30099eda2482bf45814285a8d6662df624ed79f2382788b

阅读页：1、2、4、5、6、7、8、19。100任务、10skills、资产、VLA/流程/VLM三种评测与PS。

- 研究类型：一般操作 benchmark; 模拟操作benchmark
- 领域：居家整理与清洁、餐饮与烹饪、办公与教育、实验室操作、休闲与运动
- 环境：MuJoCo/dm_control程序配置; 未提供可直接与住宅数比较的独立scene总量。
- 任务：100=60 primitive+40 composite, 10操作skills; 包含整理桌面、料理、化学示范、纸牌规则等。

- 题数 / 数据：2,164资产 / 163类；VLA主微调只取16类各100trajs = 1,600训练轨迹，非全100task的test量。
- 评估方式：Success与Progress Score分开：PS预设0.2正确对象选取 + 0.8已完成子步比例。；VLM非交互模式输出DSL，转DAG比skill/parameter recall与exact matching；不能把此分数当物理成功率。
- Split / 信息条件：seen/unseen object是整个category的差异；与ManiSkill同category新instance不相同。VLA / workflow / VLM信息条件各异。
- 来源关系：部分RoboCasa assets + Objaverse、生成资产；技能API和标注先验要列清。
- 可复用：已涵盖多种日常语义和物理 / 知识规则；是本研究扩规则与multimodal tool use的近邻。
- 待核 / 限制：各task eval episode数、无交互VLM题库精确量需源manifest核。

P073 RoboTwin (2024)

原作：<https://arxiv.org/abs/2409.02920>

本次PDF：<https://arxiv.org/pdf/2409.02920v3>

PDF SHA256：2c289e8ac5352f42de2908b166176fe6d01f045fbb4fb7214134a63e7c432c4f

阅读页：1、2、4、5、7、8、9。digital twin数据流程、17真实数据任务与6个DP3 benchmark子集。

- 研究类型：一般操作 benchmark；模拟与真实操作benchmark
- 领域：跨域 / 用途未指定
- 环境：COBOT Magic工作站与其合成digital twins；未报多房屋总数。
- 任务：数据设计17任务（9tool、5人际、6双臂，标签可重叠）；本文DP3跑6任务。
- 题数 / 数据：真实数据每task30trajs（17×30 = 510）；6任务实验比较10/20/50 expert demos。test rollouts精确数本段未报。
- 评估方式：各task completion success rate；示范数是训练条件，不是评测题数。
- Split / 信息条件：real收集范围与synthetic expert评测6task分开；9+5+6不能加为20个不重叠task。
- 来源关系：AIGC由图到3D，MLLM写expert code；RoboTwin2为后续扩充。
- 可复用：双臂、工具、人机交互与digital twin产题可借；版本应明确分层。
- 待核 / 限制：原文引用A.3而此PDF附录信息有限，完整17task manifest与test rollout数仍待code核。

P075 VIMA (2022)

原作：<https://arxiv.org/abs/2210.03094>

本次PDF：<https://arxiv.org/pdf/2210.03094v2>

PDF SHA256：cf849f80368749b0310b43117519ce0abff3e8ae49744e78c4a29b9d17f0695f

阅读页：1、2、3、5、6、8、34、37。VIMA-Bench多模态prompt、17templates、4级泛化、训练与eval。

- 研究类型：一般操作 benchmark；多模态指令操作
- 领域：居家整理与清洁
- 环境：Ravens桌面平台，对象 / 材质 / 位置程序变化；未报多房屋环境数。
- 任务：17task templates归6非互斥类：对象操作、视觉goal、新概念、示范模仿、视觉约束、推理 / 记忆。

- 题数 / 数据：600K+ expert训练trajectories；程序产生的instances与17templates分开，不能把训练轨迹称600K测试题。
- 评估方式：模拟交互task success；L1位置、L2新组合、L3新对象、L4新task分开。
- Split / 信息条件：offline BC；held-out validation选模型、simulator evaluation。原生动作为参数化pick-place / wipe primitive，非相同低级控制难度。
- 来源关系：Ravens延伸；多模态prompt内图片、语言、示范本来就在单一界面，不能把这点当本研究首次贡献。
- 可复用：多模态指令统一入口的重要前作；可扩大生活用途与规则，但需承认其既有统一界面。
- 待核 / 限制：各泛化级的确切公开eval seeds / case数需发布设置核对。

P076 Ravens / Transporter Networks (2020)

原作：<https://arxiv.org/abs/2010.14406>

本次PDF：<https://arxiv.org/pdf/2010.14406v3>

PDF SHA256：3a5e78b5c8881863845c46bda0bf8c9071aa79a59a6f9a9f4d8732690482b228

阅读页：1、5、6、7、8。全部10simulation task清单、动作 / 观测、训练量、test与真机验证。

- 研究类型：一般操作 benchmark；模拟操作benchmark
- 领域：居家整理与清洁、装配与生产作业、包装、仓储与物流
- 环境：UR5e+0.5×1m桌面，3 RGB-D视角；real kit assembly / sweeping为额外实验。
- 任务：10task：block insertion、red-in-green、Hanoi、align corner、pyramid、palletizing、kits、packing、rope、sweeping。
- 题数 / 数据：每task训练1/10/100/1,000 demonstrations；每task100 unseen test runs＝一方法设置1,000runs。
- 评估方式：0–100 performance，多步task给partial credit；非所有表中的分数都是binary success percentage。
- Split / 信息条件：对象 / goal位置朝向train/test随机，3task含未见objects；two-pose动作primitive及suction降低控制负担。
- 来源关系：PyBullet桌面，自带script oracle；VIMA、DeformableRavens等衍生共享task与界面。
- 可复用：包装、堆栈、绳索、清扫可作source tasks；需标记primitive与成功判准。
- 待核 / 限制：task各自partial credit及物理predicate严格程度需具体code映射，不以同名插入直接对比ManiSkill2。

P077 CLIPort (2021)

原作：<https://arxiv.org/abs/2109.12098>

本次PDF：<https://arxiv.org/pdf/2109.12098v1>

PDF SHA256：3cc19664beabda203cb1a1ad86659f75f60a099189820d92d59d20067c9ab003

阅读页：1、2、4、5、6。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：一般操作 benchmark；模拟与真实操作benchmark
- 领域：包装、仓储与物流
- 环境：PyBullet Ravens UR5e桌面；3noiseless cameras融合RGB-D。
- 任务：10language-conditioned tasks；8有seen/unseen semantic variants。

- 题数 / 数据：每模型/设置100evaluation runs, train 1/10/100/1000demos是规模对照。
- 评估方式：Ravens 0–100partial-credit task score, 不能全叫binary success rate。
- Split / 信息条件：held-out colors/object categories; 56GoogleScannedObjects分37seen/19unseen。
- 来源关系：Ravens task复用并加语言; nominal SE(2) pick-place和通用6DoF policy难度不同。
- 可复用：补语言语义的操作规格; count10tasks, 不把每demo和attribute组合当新task。
- 待核 / 限制：真实补充任务及完整source-task对应另需原生code; 本列定量限已读sim protocol。

P079 FMB (2024)

原作: <https://arxiv.org/abs/2401.08553>

本次PDF: <https://arxiv.org/pdf/2401.08553v3>

PDF SHA256: c0d7c39378cfc46b87289276d517c5e9ef6aa5932fece6c5d2b0b4a4f120f9e8

阅读页: 1、3、4、5、7、8、10、12。资产、三大skill / 六种primitive、长流程、表1及evaluation。

- 研究类型：一般操作 benchmark; 真实操作benchmark
- 领域：装配与生产作业
- 环境：可重制Franka工作站, 对象与board初态依规定区域和姿态; 不是66个环境。
- 任务：functional grasp / reposition / insert三大能力; single-object与multi-object两类流程, 3套multi-object互锁装配。表1有6个primitive。
- 题数 / 数据：66训练对象+5新测试对象; 表1精确22,550 primitive trajectories由完整流程分割, 不能都叫独立22,550长程任务。
- 评估方式：依skill / 长流程success; grasp实验5 seen+5unseen对象各5次=50trials; 完整流程另有10次设置。
- Split / 信息条件：对象shape/size/color与初态泛化; board插入间隙1–2mm; 可模块评估也可end-to-end, 两者分开。
- 来源关系：自制3D printable objects与human demos; 长流程和primitive数据共享母轨迹。
- 可复用：精密contact、功能性抓取、重抓与顺序依赖; 只有模拟仍可收录规格, 不能称已重现其real实验。
- 待核 / 限制：摘要22,500与表1精确22,550为约数差异; 未取得完整真机eval。

P080 DexArt (2023)

原作: <https://arxiv.org/abs/2305.05706>

本次PDF: <https://arxiv.org/pdf/2305.05706v1>

PDF SHA256: 44354c0496a14f9ef90e19cd93f1521075adb6daff5f0a882cc045a649fbff7e

阅读页: 1、2、3、4、5、6。4task、seen/unseen表、22DoF界面、success与视角泛化。

- 研究类型：一般操作 benchmark; 灵巧手操作benchmark
- 领域：居家整理与清洁
- 环境：SAPIEN中XArm6+16DoF Allegro; 对象资产不同, 非多house layout。
- 任务：Faucet、Bucket、Laptop、Toilet四task; 资产18 / 19 / 17 / 28, 共82。

- 题数 / 数据: seen对象 $11+11+11+17=50$, unseen $7+8+6+11=32$; 3训练seeds; 6K point clouds/object为视觉预训练数据。
- 评估方式: success依关节角 / 抬升高度; episodic return另列; 测seen/unseen对象和新camera pose。
- Split / 信息条件: 同category未见instance; 4接触 / 进度reward不等于4独立benchmark。
- 来源关系: PartNet-Mobility资产; 额外PMM46类是pretraining, 不是DexArt46个任务。
- 可复用: 补灵巧手与拓扑泛化; DoF增加代表控制要求, 不能直接给跨benchmark单一难度等级。
- 待核 / 限制: 完整test episodes per object与seed ID需eval code核。

P081 ARNOLD (2023)

原作: <https://arxiv.org/abs/2304.04321>

本次PDF: <https://arxiv.org/pdf/2304.04321v2>

PDF SHA256: 5a2b6c0126bde99772c888036524fd071cf3890034be184e26c437bd42f50fdb

阅读页: 1、3、4、5、6、8。scene/objects、8tasks各continuous goal、表2/3、泛化切分与2秒success。

- 研究类型: 一般操作 benchmark; 模拟操作benchmark
- 领域: 居家整理与清洁
- 环境: 20个scene、40对象; Isaac Sim / PhysX5、固定Panda base。
- 任务: 8task×各4个数量goal (保留1个novel state); 抬物、重定向、开关drawer/cabinet、pour / transfer water。
- 题数 / 数据: 表3共10,080 demonstrations/configurations: train3571、val771、IIDtest773、novel object1078、scene1114、state2000、any-state773。
- 评估方式: 完成最终stage后在goal tolerance内保持2秒; transfer水另限 $\leq 10\%$ spill; 报success rate。
- Split / 信息条件: Normal约70/15/15; novel object / scene / state每次只变一因素; Any State是连续range抽样, 非同样extrapolation难度。
- 来源关系: 既有室内synthetic scenes + 外部object assets; 可接Roboverse但需保留新success规则。
- 可复用: 量化精度、稳定维持与spill限制是规则扩充的好依据; 同task多目标与新语义task分开。
- 待核 / 限制: 本库尚未逐ID导入全部scene/state/test组合。

P083 RoboDojo (2026)

原作: <https://arxiv.org/abs/2607.04434>

本次PDF: <https://arxiv.org/pdf/2607.04434v3>

PDF SHA256: e07c215f30169dde6a792c34b046b1f54818d09331763988732dcf9ead89a9d4

阅读页: 1、2、3、4、5、6、7、8、9、16、28、45。42sim/18real、五能力清单、train/eval数量、评分与hidden-layout验证。

- 研究类型: 一般操作 benchmark; 模拟与真实操作benchmark
- 领域: 居家整理与清洁、衣物与洗护、装配与生产作业
- 环境: Isaac Sim双臂工作站和3类真机平台; 各task有公共reset layouts和hidden验证布局。

- 任务：42simulation tasks（12 generalization、6 memory、8 long、8 precision、8 open）+ 18real tasks；同名/同goal的sim/real不能先假定60语义去重任务。
- 题数 / 数据：simulation每task50episodes = 2,100；real每task10trials = 180。sim train34tasks + DLC共35目录3,500trajs, real1,800trajs。
- 评估方式：sim binary success + partial-progress score，五能力宏平均；real三人双盲评分后平均。
- Split / 信息条件：Open8task不在train；generalization每task25标准 + 25随机；正式榜另3seeds及hidden layouts，不加作新task。
- 来源关系：参考RoboTwin、RMBench等，使用新规则及共同sim-real界面；公开表与hidden验证不同地位。
- 可复用：综合能力与可复现实测的近邻；我们simulation-only版本需以同等成功 / partial score证据比较。
- 待核 / 限制：sim/real相同任务之去重关系与hidden验证量未完整公开。

P084 KinDER (2026)

原作：<https://arxiv.org/abs/2604.25788>

本次PDF：<https://arxiv.org/pdf/2604.25788v2>

PDF SHA256：39d1283a971b7b903edb7885cabdc9dea9c412bd3cfcc8431f0c39154ba44900

阅读页：1、3、4、5、6、7、14。五大physical-reasoning要求、25环境、4种物理抽象、8实验环境及metrics。

- 研究类型：一般操作 benchmark；物理推理与规划benchmark
- 领域：居家整理与清洁、包装、仓储与物流
- 环境：25 procedural task-environments：6 Kinematic2D + 4 Dynamic2D + 5 Kinematic3D + 10 Dynamic3D；不是25生活场域。
- 任务：工具、nonprehensile、多物体、几何、动力约束；KinDERBench主实验只取8代表环境，13baselines。
- 题数 / 数据：10环境各≥100precollected demos；eval每seed50episodes×5seeds，8环境合计2,000runs / baseline（含重复seed运行）。
- 评估方式：success rate；只在成功episodes比较累积步数cost（每步-1），另报inference time。
- Split / 信息条件：不同物体数量OOD；state / RGB与提供skills/PDDL的信息差异需明示。Kinematic版本碰撞回退、rigid attachment，不等同dynamic真抓取。
- 来源关系：PyMunk / PyBullet / MuJoCo不同backend；借RoboCasa/MimicLabs资产及BDDL设计。
- 可复用：支持明确规则 / 物理抽象的比较；不得将kinematic、dynamic的成功直接合成无条件难度分数。
- 待核 / 限制：程序分布无固定题库上限；仅8环境有主baseline结果，不能声称全25已同程度验证。

P085 SoftGym (2020)

原作：<https://arxiv.org/abs/2011.07215>

本次PDF：<https://arxiv.org/pdf/2011.07215v2>

PDF SHA256：0e0bd8b74b7d8b3aa1a203694debf47d425adbfe2eab8bf4555b198525e89903

阅读页：1、3、4、5、6、7、8、14。6 Medium / 4 Hard任务、action抽象、oracle信息及eval切分。

- 研究类型：布料 / 柔性物操作；柔性物操作benchmark

- 领域：衣物与洗护
- 环境：Flex程序物理环境；主Medium/Hard直接控制picker或杯子，非完整手臂；SoftGym-Robot另列。
- 任务：10任务=6 Medium (transport/pour water、straighten rope、spread/fold/drop cloth) + 4 Hard (pour amount、fold crumpled、drop-fold、rope configuration)。
- 题数 / 数据：主实验每task预抽1,000 variations=800train+200eval；CEM只抽10个eval variations，不能称所有方法测同量。
- 评估方式：按task用覆盖面积、粒子距离、水量 / spill等；以do-nothing与upper bound范式，可能小于0。；5 seeds报median / 四分位，不是binary success rate。
- Split / 信息条件：初态variations800/200；DynamicsOracle / StateOracle / RGB信息权限不同，不能混为同难度。
- 来源关系：Flex与抽象pickers；后续布料task和数据生成器大量重用。
- 可复用：柔性物task与连续指针来源；加上机体、抓持及稳定性规则才适合与robot控制任务比较。
- 待核 / 限制：SoftGym-Robot在本文注明待NVIDIA许可发布；目前取得状态须另核，不能由API假定可用。

P086 DeformableRavens (2020)

原作：<https://arxiv.org/abs/2012.03385>

本次PDF：<https://arxiv.org/pdf/2012.03385v4>

PDF SHA256：7227984ec317cff8190a29c2f53794d0e399fbbb7ed78c8ee21c7b27f78d65f8

阅读页：1、3、4、5、6、7、13、14。12任务全表、deformable primitive、数据与checkpoint选择、真机cable实验。

- 研究类型：布料 / 柔性物操作；柔性物操作benchmark
- 领域：衣物与洗护、包装、仓储与物流
- 环境：共用UR5桌面，PyBullet绳索 / 布料 / 袋子；理想nearest-vertex抓持。
- 任务：12=5 cable、3 fabric、4 bag；有goal image和无goal图两种设置，bag含打开→装物→搬运。
- 题数 / 数据：每task1,000成功demo；每checkpoint20eval episodes、通常3训练runs，bag-color仅1run。表格选10checkpoints最大值。
- 评估方式：cable位置 / 凸包面积、cloth coverage、bag containment/transport依task分开。；真机cable另10episodes、最多10actions、mask IoU>0.25判成功。
- Split / 信息条件：held-out random seeds；依eval最大checkpoint报分有选择效应，不能当独立test后只评一次。
- 来源关系：Ravens延伸；成功demo经过滤，script成功率与policy测试不是同一分母。
- 可复用：拓展袋子、绳索与布料多阶段规则；要额外防止袋插件物等达标漏洞。
- 待核 / 限制：各task指针中连续coverage与binary success混合，跨任务总分需保留原生定义。

P087 GarmentLab (2024)

原作：<https://arxiv.org/abs/2411.01200>

本次PDF：<https://arxiv.org/pdf/2411.01200v3>

PDF SHA256：8b0cea58cae1f425754a11a328f6082eafc8066dd93300c8255ba4ae17ffa999

阅读页：1、2、3、4、5、6、7、8、9、16、17、20。资产与5种物理交互、20task、实验子集、split及5秒success。

- 研究类型：布料 / 柔性物操作；柔性物操作benchmark
- 领域：居家整理与清洁、衣物与洗护、个人照护
- 环境：20scene与9,000+object models资产库；PhysX多物理方法，scene/asset数不等于实评数。
- 任务：20tasks归5interaction groups：garment-garment/fluid/FEM/rigid/avatar；含折、展、挂、吹干、洗、收纳、穿衣。
- 题数 / 数据：不同task初态 / garment采样；正文baseline以大件fold/unfold/hang、小件place/hang及若干RL子集为主，没有统一全20task题数。
- 评估方式：达task-specific判准后维持至少5秒；fold用IoU、unfold用coverage，其他物理交互有专用容差。
- Split / 信息条件：objects70/15/15；另novel state / scene；主实验并非全部20task同程度跑分。
- 来源关系：ClothesNet、ShapeNet、PartNet/YCB、PartNet-Mobility、Omniverse/actorcore等资产；RoboVerse迁移其子集。
- 可复用：柔性物与日常服务广度的重要来源；应保留materials与state/evaluator可用程度。
- 待核 / 限制：折衣轮廓IoU无法单独检查层次 / 拓扑正确；需更细规则。；完整20task有效case数待manifest。

P088 FlingBot (2021)

原作：<https://arxiv.org/abs/2105.03655>

本次PDF：<https://arxiv.org/pdf/2105.03655v3>

PDF SHA256：ad6e502825c044a1ce13911164ae7817e00628ba7ac3e46358cc277c9d25dc8e

阅读页：1、6、7。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：布料 / 柔性物操作；柔性物操作benchmark
- 领域：衣物与洗护
- 环境：simulation cloths与dualUR5真实工作站；NormalRect/LargeRect/Shirt三object regimes。
- 任务：主要1个unfolding目标；三clothtypes是材料/形状泛化设置。
- 题数 / 数据：2,000trainingcloth settings，600sim test cases各类200；real各类10cases，150realadapt episodes不算test。
- 评估方式：normalized final/delta coverage及actions，允许coverage>1的范式情形不裁成success。
- Split / 信息条件：CLOTH3D test shirts；mesh/material/init分离，10step budget或预测抓地板终止。
- 来源关系：CLOTH3D与既有clothphysics，dataset task实为具体cloth+material+initialization。
- 可复用：示范同一目标可以有大量物理cases，而未增加语义task数。
- 待核 / 限制：coverage并不保证可直接折衣；real细节与sim material参数只能作相应范围推论。

P089 SpeedFolding (2022)

原作：<https://arxiv.org/abs/2208.10552>

本次PDF：<https://arxiv.org/pdf/2208.10552v2>

PDF SHA256：2421f14228d394a1a2f683d8156f4ff953dee3dd1deefef64ce0037854b86be1

阅读页：1、5、6、7。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：布料 / 柔性物操作；柔性物操作benchmark
- 领域：衣物与洗护
- 环境：ABB YuMi工作站；known shirt、unseen shirt、towel。
- 任务：smoothing→folding, instruction/2-second/Fling-to-fold三策略并非三个生活domain。
- 题数 / 数据：4,300action records包含1,500拷贝重标；每experiment15trials。
- 评估方式：fold由3reviewers多数决；horizon10；time成功回合平均，FPH/cycle包括失败。
- Split / 信息条件：train单shirt；towel泛化前加20smoothimages再训练，不是完全zero-shot。
- 来源关系：前作FlingBot比较有不同hardware；1500重标非独立physical actions。
- 可复用：补折衣全流程与吞吐量，不能只报93%而略过任务、排除规则和15次分母。
- 待核 / 限制：排除motion-planning early failures会影响整体systemsucccess解读；须在共同protocol保留此差异。

P090 Cloth Funnels (2022)

原作：<https://arxiv.org/abs/2210.09347>

本次PDF：<https://arxiv.org/pdf/2210.09347v1>

PDF SHA256：06417ac85cf98e06ede6fd96b746e6e1ce3ad99ca09fcd9f61789122d0ecfdb

阅读页：1、2、4、5、6。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：布料 / 柔性物操作；柔性物操作benchmark
- 领域：衣物与洗护
- 环境：CLOTH3D simulation与真实衣物工作站，5garment categories。
- 任务：canonicalized alignment, 另支持folding/ironing；highcoverage不保证对齐。
- 题数 / 数据：每garment category2,000train/400test settings；hard/easy train75/25、test50/50。
- 评估方式：IoU/coverage及分离rigid-alignment和deformable errors；fold success为qualitatively选的error门槛。
- Split / 信息条件：mesh-disjoint, easy/hard是不同初态生成；eachgarmentcategory独立policy。
- 来源关系：CLOTH3D / FlingBot数据生成构想；downstreamfoldheuristic非新end-to-end模型。
- 可复用：把摊平、对齐和指定折法拆成可验收目标，适合作为扩充规则依据。
- 待核 / 限制：real全部trajectory分母未在已读段报出；不可套用sim400为realcase数。

P091 UniFolding (2023)

原作：<https://arxiv.org/abs/2311.01267>

本次PDF：<https://arxiv.org/pdf/2311.01267v1>

PDF SHA256：b51de4cbad0c9715a18e88ce74af68a21192ad10e130a1b956715c87706d8049

阅读页：1、2、5、6。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：布料 / 柔性物操作；柔性物操作benchmark

- 领域：衣物与洗护
- 环境：RFUniverse/ClothDynamics及双Flexiv工作站；2garment categories。
- 任务：两类衣物的unfold+fold流程；60realgarments的train/test40/20。
- 题数 / 数据：VR1,218+1,575=2,793videos，real2,432samples；20heldoutgarments各10trial=200realtrials。
- 评估方式：IoU、normalizedcoverage，wholeflow10steps内按rules折好。
- Split / 信息条件：realgarments2:1，simCLOTH3D9:1；onlinehumanpreference作训练，不当test免介入证据。
- 来源关系：CLOTH3D、ClothFunnels目的函数及VR-human demonstrations。
- 可复用：可取shirt具体fold规则和材料差异，human annotations与robotepisodes分开。
- 待核 / 限制：机器人reach/grasp自动recovery和policyactionbudget的共同计数需要adapter明定。

P092 ICRA cloth competition (2025)

原作：<https://arxiv.org/abs/2508.16749>

本次PDF：<https://arxiv.org/pdf/2508.16749v2>

PDF SHA256: c44a1dff77f6fe471123e7e70b03b6735ed494e18190396a44c5c4232962b274

阅读页：1、2、5、6、7、8、11。固定unfold primitive、硬件 / grasp execution、coverage metric、数据及比赛规模。

- 研究类型：布料 / 柔性物操作；真实操作benchmark
- 领域：衣物与洗护
- 环境：双UR5e+单stereo camera标准工作站；训练在lab、比赛在会场，cloth初态无法精确拷贝。
- 任务：1个核心任务：悬挂布料选grasp后stretch展开；34garment items不是34task。
- 题数 / 数据：679episodes=503训练尝试+176竞赛trial；11队各16次（8衣物×2），同题型由不同方法运行。
- 评估方式：主metric projected coverage / 最大面积；另grasp success及成功抓取条件下coverage。；30秒grasp计算上限为建议，非由679样本推导的固定速度门槛。
- Split / 信息条件：503与176来源 / 用途分开；训练也含失败抓取；176是实验运行，不是176独立任务。
- 来源关系：部分毛巾来自Household Cloth Object Set，与其它cloth benchmarks资产可能重用。
- 可复用：可借真实garment多样性与grasp/coverage分离；不宜把单次展开当完整折衣 / 收纳任务。
- 待核 / 限制：场地与初态差异无法完全消除；本库无法只靠既有视频重跑physical grasp。

P093 MoDeSuite (2025)

原作：<https://arxiv.org/abs/2507.21796>

本次PDF：<https://arxiv.org/pdf/2507.21796v1>

PDF SHA256: 7487d599b51f5e6b76f91382e89b71c431f6314db66766625b35dda08d345dca

阅读页：1、3、4、5、6。两种mobile robot、8task逐项定义、source继承及learning评测。

- 研究类型：布料 / 柔性物操作；柔性物操作benchmark

- 领域：居家整理与清洁、衣物与洗护
- 环境：IsaacSim / PhysX；Ridgeback-Franka与Spot arm，走廊 / 桌面配置。
- 任务：8 = 新5elastic（Place/Bend/Transport/Drag/Lift） + 3既有cloth-like（Cover/Uncover/Curtain）；需base与arm协同。
- 题数 / 数据：RL5独立runs，success在20eval trials计算；非每task20个语义新任务。
- 评估方式：依task几何位置、跨越 / 覆盖与无碰撞条件报success；episode return和stability penalty另列。
- Split / 信息条件：不同机体 / state/RGB输入分开；本文无单一全库train/test IDs总量。
- 来源关系：3cloth tasks从前作扩充mobile base control；FEM与PBD为不同材料物理，不是新生活domain。
- 可复用：可补『移动时携带 / 拖拉柔性物』而非纯桌面折布；规则包含通过障碍与稳定。
- 待核 / 限制：原3task来源与精确scene/config IDs需从引用30及code进一步对齐。

P094 R2R/VLN (2017)

原作：<https://arxiv.org/abs/1711.07280>

本次PDF：<https://arxiv.org/pdf/1711.07280v3>

PDF SHA256: b7589865ee573d4753ee9e25bdc494cbbb199e6ec17d0a349091aed0fd86c420

阅读页：1、2、4、5、6、7。navigation graph、路径 / 指令搜集、scene split与stop成功定义。

- 研究类型：导航与家务运行；导航benchmark
- 领域：居家整理与清洁、办公与教育
- 环境：90个Matterport3D建筑scene；panorama graph离散移动，非真轮式动力学。
- 任务：1个指令导航task family；7,189 route goals、21,567语言指令（通常每path3条）。
- 题数 / 数据：train14,025 / val-seen1,020 / val-unseen2,349 / test4,173 instructions。
- 评估方式：navigation error；主success要求stop后距goal<3m；oracle stop另列。原文不要求全程遵循原path。
- Split / 信息条件：61train scenes / 11val-unseen / 18test；不能把全部21,567叫test。
- 来源关系：Matterport3D上游；RxR、RoboVerse、VLN-CE等重用同scene，场景数不可加总。
- 可复用：可引入route-following与语言多样性；路径数和导航task family是不同粒度。
- 待核 / 限制：下游continuous变体的可导航几何 / case过滤需要另版本。

P095 RxR (2020)

原作：<https://arxiv.org/abs/2010.07954>

本次PDF：<https://arxiv.org/pdf/2010.07954v1>

PDF SHA256: 8a964d95106ff267f934acf705a6b0be304a193f84745fe0ad55f51133d61bd8

阅读页：1、2、3、4、5、6、9。path采样、90scene重用、多语注记、split与path-adherence metrics。

- 研究类型：导航与家务运行；导航benchmark
- 领域：居家整理与清洁、办公与教育

- 环境：同Matterport3D90个室内场景；不是比R2R又添加90。
- 任务：16,522 paths；English/Hindi/Telugu三语，同一path有多语 / 多描述与guide/follower traces。
- 题数 / 数据：126,069 instructions；path split 11,089 train / 1,232 val-seen / 1,517 val-unseen / 2,684 test。这些是path数，不能当同数instruction。
- 评估方式：PL、NE、SR、SPL、NDTW、SDTW；原作主重NDTW/SDTW以奖励遵循指定路径，与R2R只到终点不同。
- Split / 信息条件：沿R2R / Matterport场景split；test-standard/test-challenge隐藏；3语每语约14K paths有交集。
- 来源关系：原始scene共用R2R，path另采样；与R2R多任务训练的追加数据不能再算新test。
- 可复用：证明同导航family可以扩语言与过程规则；规则差异应明确保留。
- 待核 / 限制：各language及test子split指令ID量需manifest核。

P096 ALFRED (2019)

原作：<https://arxiv.org/abs/1912.01734>

本次PDF：<https://arxiv.org/pdf/1912.01734v2>

PDF SHA256：84b314c06de82f5a1ff853676d391e05394a2e517986b03faadcbca325c9ee0b

阅读页：1、2、3、4、7、8。7task types、参数 / demo / directive层级、scene及split表、success与partial goal评测。

- 研究类型：导航与家务运行；室内长流程操作
- 领域：居家整理与清洁、餐饮与烹饪
- 环境：AI2-THOR 120 rooms = kitchen/bathroom/bedroom/living各30；不是120房屋。
- 任务：7types：pick-place、stack-place、pick-two、clean-place、heat-place、cool-place、examine-in-light；2,685 task parameter combinations。
- 题数 / 数据：8,055 expert episodes、概述25,743 directives；表2split为21,023 / 820 / 821 / 1,533 / 1,529（合25,726），原文存在17差异。
- 评估方式：全部goal condition成功 / 部分goal-condition比例；另以action length折算效率。；subgoal评测可先强制走expert历史，不能与end-to-end成功混同。
- Split / 信息条件：108train rooms，4val-unseen，8test-unseen；seen folds是train场景子集。
- 来源关系：AI2-THOR 2.0 + PDDL planner；TEACH沿同floorplans/splits，两者场景不可重加。
- 可复用：提供家务状态变更 / 工具切割 / 热冷清洁程序；符号动作语义不等于低级接触摸制。
- 待核 / 限制：25,743概述与表2合计25,726需release IDs厘清，不静默选方便的数字。

P097 TEACH (2021)

原作：<https://arxiv.org/abs/2110.00534>

本次PDF：<https://arxiv.org/pdf/2110.00534v3>

PDF SHA256：512d9ea49367fc5ec3559ab9b866c1aaafb015585dd2363bc7e918b20e42e40a

阅读页：1、2、3、4、5、6、7、9、21。TDL与12task、session→EDH、三种benchmark、全部split与success。

- 研究类型：导航与家务运行；对话协作与任务完成
- 领域：居家整理与清洁、餐饮与烹饪
- 环境：AI2-THOR；表2成功收集池覆盖109 rooms，重用ALFRED场景与unseen split。
- 任务：12task types、438参数variants（收集池）；3端点EDH / TfD / TATC，最后一种要同时建模Commander/Follower。
- 题数 / 数据：正文3,047可replay sessions；表3分量合3,045。EDH表3总11,176 = 5475train+608val-seen+2157val-unseen+666test-seen+2270test-unseen。
- 评估方式：EDH完成全部expected state changes为success，GC给部分分；trajectory length weighting另列。；TATC与TfD重用session数据，不是三倍独立任务量。
- Split / 信息条件：seen/unseen场景；train/val/test按session；旧版EDH因只保留推进任务的state changes而缩减。
- 来源关系：同AI2-THOR与ALFRED场景，语言 / session新human-human收集；TDL支持量词、阶层与共享object约束。
- 可复用：对话工具、澄清、任务阶层与量词规则有可复用形式；收集成功与可重播数需分开。
- 待核 / 限制：本文3,047与split3,045差2；表1还留早期3,215，必须以版本manifest查明。

P098 Habitat 2.0 (2021)

原作：<https://arxiv.org/abs/2106.14405>

本次PDF：<https://arxiv.org/pdf/2106.14405v2>

PDF SHA256: 92f9c30479fe4203f656c218fa228c7e5fd71f23a9821b3afa47e06dbe5ab317

阅读页：1、2、4、5、6、7、9、10、11、29。ReplicaCAD构造、Pick基本任务、3种HAB任务与评估假设。

- 研究类型：导航与家务运行；室内长流程操作
- 领域：居家整理与清洁、餐饮与烹饪
- 环境：ReplicaCAD111 layouts创建於单一apartment backdrop；正文105新layout variations与原始配置分量需分清，非111独立住宅。
- 任务：HAB3families：TidyHouse、PrepareGroceries、SetTable；另Pick基础实验。任务goal为object起终3D位置，不是自然语言理解。
- 题数 / 数据：程序clutter/goal episodes；Pick有500 unseen-layout eval样本；技能附录另100eval episodes，不能混作HAB全库题数。
- 评估方式：goal成功与分阶段成功；操作次数用作难度proxy；模拟速度SPS另列。
- Split / 信息条件：未见layout/object配置；抽象抓持与kinematic base控制，并非完整wheel/contact dynamics。
- 来源关系：Replica FRL apartment→ReplicaCAD、YCB clutter；Habitat3/后续rearrangement套件会重用。
- 可复用：可借home-scale长流程与open/close前后置条件；环境分量与传感先验需精确报。
- 待核 / 限制：HAB每family全套eval episode IDs与111layout正式manifest仍待导入。

P099 HomeRobot (2023)

原作：<https://arxiv.org/abs/2306.11565>

本次PDF：<https://arxiv.org/pdf/2306.11565v2>

PDF SHA256: 518b6ba6f64a2c51a1bda3b92902e6ad0d2cbf5567d6d07e93207a28155d61e3

阅读页: 1、2、4、5、6、7、17、18、19、20、24、27。HSSD实际子集、OVMM四stage、scene/objects切分、sim/real成功定义。

- 研究类型: 导航与家务运行; 室内长流程操作
- 领域: 居家整理与清洁
- 环境: HSSD原库200+, 本文实验只用60scenes = 38train/12val/10test; real为1个3-room apartment。
- 任务: 1个OVMM family: find object→pick→find receptacle→place; 129对象类别与21receptacle类, 不是129/21个新任务。
- 题数 / 数据: 2,535对象模型; sim程序产生object/start/goal cases, 已读段未给单一全库题量。real两baseline各20experiments。
- 评估方式: 四stage全过为success、partial success作tie-break; sim Place需静稳50steps; sim Pick是0.8m内magic snap, real Pick要实抓; 两者判准不同。
- Split / 信息条件: 未见scene及未见object instances, 另seen/unseen categories; sim1250step、real300step budget。
- 来源关系: HSSD + AI2-THOR/ABO/GSO objects, 与PARTNR HSSD衍生共享环境家族。
- 可复用: 可提供open-vocabulary寻物与搬运; 需在共同库标记抓持抽象层级。
- 待核 / 限制: HSSD不同项目的branch/scene ID对照需查; 不能把HomeRobot60与PARTNR60直接算120houses。

P101 Embodied Agent Interface (2024)

原作: <https://arxiv.org/abs/2410.07166>

本次PDF: <https://arxiv.org/pdf/2410.07166v3>

PDF SHA256: d10c7fee3594c88ff9f6a061a68b64a380a82d36c6652f3b08c42179044e2a9f

阅读页: 1、4、5、6、7、21、89、90、102、103。4 modules完整I/O与metric、表2、BEHAVIOR100 / VirtualHome标注与符号实作。

- 研究类型: 导航与家务运行; 符号规划与评测界面
- 领域: 居家整理与清洁、餐饮与烹饪、办公与教育
- 环境: VirtualHome与EvalGibson两后端; EvalGibson为BEHAVIOR100创建的符号transition simulator, 不是BEHAVIOR1K全物理运行。
- 任务: 4 modules: goal interpretation、subgoal decomposition、action sequencing、transition modeling。VirtualHome表2为26task names / 338instructions; BEHAVIOR100为100。
- 题数 / 数据: 338 + 100 = 438 instruction instances; 801/673 goals是组成标签, 平均4,164.4 goal options不是4,164题。
- 评估方式: goal / transition以logic F1; trajectory feasibility、goal satisfaction、partial goal success; PDDL planner成功另列; 模块评测其余部分用GT / BFS / planner补齐, 非端到端全系统分数; 只实作LTL部分语法, globally/until尚未实作。
- Split / 信息条件: zero-shot界面评估; 固定单module与pipeline分析分开。
- 来源关系: BEHAVIOR100 VR demos、RobotHow/VirtualHome; 重新标注抽象 / 具体goal以避免无关终态污染。
- 可复用: 是统一任务语言、规则及模块评测的直接前作; 应避免重造G/T轴而不交代与此界面差异。
- 待核 / 限制: 附录称VirtualHome30categories而表2为26names, 待label清单对齐。

P102 NavVerse (2026)

原作: <https://arxiv.org/abs/2607.19695>

本次PDF: <https://arxiv.org/pdf/2607.19695v1>

PDF SHA256: 9e578a0112fb1c6b3969bc02b262c7f35fa90e3321692f5dfa0ad033fef1fc68

阅读页: 1、2、3、4、5、6、8、12、13。200scene构造、3task、10K episodes、物理导航与metric / 难度。

- 研究类型: 导航与家务运行; 导航benchmark
- 领域: 公共场馆与服务
- 环境: 100 indoor GRScenes + 50 outdoor城市 + 50 indoor-outdoor组合; 混合scene重用前两组几何, 不是200独立底层环境。
- 任务: ObjNav / PlaceNav / VLN三类; PlaceNav没有纯室内split, 不能机械做3×3完整coverage。
- 题数 / 数据: 4,027 ObjNav + 2,973 PlaceNav + 3,000VLN = 10,000episodes (全生成benchmark); 与evaluation subset量分开。
- 评估方式: SR、SPL、coverage efficiency、collision rate、obstacle distance、navigable surface ratio; Spot goal tolerance 1.6m; 难度按各task自身path length的1/3、2/3分位, 不是跨benchmark通用难度。
- Split / 信息条件: indoor90/10、outdoor40/10, mixed沿outdoor split; 共享PID waypoint follower。
- 来源关系: GRUtopia/GRScenes + Virtual Community城市、Google tiles、Objaverse; mixed环境需追父scene。
- 可复用: 补室内到户外的连续导航与工作用途; 可用组合环境扩题, 但须报重用关系。
- 待核 / 限制: 各task evaluation split的精确case ID量与mixed scene父ID需要manifest导入。

P103 Follow-Bench (2025)

原作: <https://arxiv.org/abs/2509.10796>

本次PDF: <https://arxiv.org/pdf/2509.10796v4>

PDF SHA256: d0c3862a5ceea33af287b35df24c711ee5e923e829b298b2688ed9c280e18ace

阅读页: 1、6、7、8、9、10、20。16scenario、配置表、8planners、100trials与安全/舒适metric。

- 研究类型: 导航与家务运行; 社交导航benchmark
- 领域: 跨域 / 用途未指定
- 环境: CPU 2D simulator; 16scenario types分target trajectories、4crowd模式、4layouts; 非16个真实场所。
- 任务: 1内核family = 跟随指定人, 变更跟随角 / 距离、密度、狭窄通道及遮挡。
- 题数 / 数据: 各configuration 100个随机trial; 表V包含多种人数 / 宽度 / 距离, 不能简化为16×100而漏掉配置。
- 评估方式: 无碰撞且重新找到target才成功; TVR、目标personal-zone时间、侵入他人空间、jerk、路径等; 10Hz同步sim clock计jerk, wall-clock planner耗时另外量。
- Split / 信息条件: motion-planning测试假设可见人位置完美; 真人主观偏好另经real interviews, 不冒充sim几何metric。
- 来源关系: 既有2D人群simulator / ORCA/SFM扩充; 不是端到端camera跟人辨识benchmark。
- 可复用: 补持续陪伴与社交距离规则; 任务完成、安全与舒适分开比。
- 待核 / 限制: 全部配置去重后的trial总量需按发布config枚举。

P104 SIMPLER (2024)

原作: <https://arxiv.org/abs/2405.05941>

本次PDF: <https://arxiv.org/pdf/2405.05941v1>

PDF SHA256: 6a9481f3c0fc43fa6736e5f5fc8ddb72ebf05aad7dbd0ff31721e4d6bfffec9e5

阅读页: 1、3、4、5、6、7、8、18、20。real-to-sim目标、MMRV/Pearson、两机体场景、visual matching与主比较。

- 研究类型: 稳健性、失败与评测品质; 转移与评测有效性
- 领域: 居家整理与清洁
- 环境: 2个real robot setups: Google Robot与WidowX/Bridge; 4 robot texture版本是视觉补偿, 不是4个新环境。
- 任务: Google图6四组 (pick、move-near、open/close drawer、open+place); WidowX图7四组放置 / 堆栈, 含grasp子项。原作按group而非唯一语义task计。
- 题数 / 数据: 各task有专用real/sim trial安排; Octo多3policy seeds、Google4texture variants, 用来降低评估方差, 不作新题总量。
- 评估方式: task success; 比较sim/real policy排名用Mean Maximum Rank Violation与Pearson r ; validated subset的相关性不保证所有新domain也有相同sim-real关系。
- Split / 信息条件: train on real、evaluate in sim; visual matching与variant aggregation是不同评测策略。
- 来源关系: Google/Bridge真实数据+SAPIEN, 另IsaacSim验证; ManiSkill3等重用SIMPLER子集。
- 可复用: 为模拟benchmark有效性提供比较方法; 没有真机资源时只能先做sim范围, 不能宣称完成sim-real验证。
- 待核 / 限制: 每task原生trial manifest未完全导入, 不虚构统一全库题量。

P105 LIBERO-Plus (2025)

原作: <https://arxiv.org/abs/2510.13626>

本次PDF: <https://arxiv.org/pdf/2510.13626v3>

PDF SHA256: 661de08e0ed1bb4bb4774177cac9fafa94f06b5385fa2f4107a1927b9a4aada7

阅读页: 1、2、3、4、8、9、10、16。7扰动因素、10,030生成设置、难度分级、额外train数据与评分。

- 研究类型: 稳健性、失败与评测品质; 稳健性与分布外评测
- 领域: 跨域 / 用途未指定
- 环境: LIBERO场景扰动: layout、camera、robot初态、语言、light、texture、noise; 不是10K新生活场景。
- 任务: 7factors / 21components; 原作称10,030tasks, 多为原LIBERO语义任务的扰动配置。
- 题数 / 数据: 10,030benchmark settings; 额外>20K成功训练trajectories分开。
- 评估方式: 物理success / success drop, 依factor平均; 5级难度由4个参考模型实测accuracy分层。
- Split / 信息条件: 原LIBERO训练到扰动测试, 另外有泛化数据post-training; 难度依赖校准模型, 不能当永久内在难度。
- 来源关系: 直接衍生LIBERO; 10,030不等于10,030互异goal family。
- 可复用: 已有万级评测设置的规模先例; 我们若比task数必须先使用共同语义粒度。
- 待核 / 限制: 10,030各父task、扰动config和split的逐条去重仍待manifest。

P106 MetaWorld+ (2025)

原作: <https://arxiv.org/abs/2505.11289>

本次PDF: <https://arxiv.org/pdf/2505.11289v2>

PDF SHA256: 60d7c336669aaab9834d2e8a6156b410b5cfa28c0c7fe3da0b1da6881af9fc33

阅读页: 1、3、4、5、7、16。50task原库、reward版本修正、MT25/ML25、eval统计协定。

- 研究类型: 稳健性、失败与评测品质; 稳健性与分布外评测
- 领域: 跨域 / 用途未指定
- 环境: 沿用Meta-World Sawyer task environments, 非添加50不同环境。
- 任务: 50原生task types; 添加MT25/ML25中等规模suite及custom task sets。
- 题数 / 数据: multi-task每task50goal episodes; meta每goal适应10episodes后测3episodes; 10训练seed不当新task。
- 评估方式: mean success的IQM、95%CI, 10seeds; v1/v2 dense reward尺度与设计不同, 原文指出历史成绩不可直接混比。
- Split / 信息条件: 保留MT/ML角色区别; MT25/ML25自原50选, 非另外增加25语义任务。
- 来源关系: Meta-World版本整理与标准化; 最应避免把同benchmark历史版本当独立数据源。
- 可复用: 提供版本治理与可比较统计方法; 对避免旧网页数字混淆尤其重要。
- 待核 / 限制: 本库历史pilot的Meta-World commit及reward版本须维持标记, 不套用新版baseline成绩。

P107 COLOSSEUM (2024)

原作: <https://arxiv.org/abs/2402.08191>

本次PDF: <https://arxiv.org/pdf/2402.08191v2>

PDF SHA256: ae71956329278bc299039eaa133876b4b132772081418a26c733c4810169edf2

阅读页: 1、4、5、6、7、9、18。20task选取、14扰动、适用性、235test sets及real镜像。

- 研究类型: 稳健性、失败与评测品质; 稳健性与分布外评测
- 领域: 居家整理与清洁
- 环境: RLBench/PyRep场景, 外观、camera、质量与friction扰动; 不是20,371独立房屋。
- 任务: 20基本操作tasks、14perturbation factors; 原文20,371 unique task instances为生成配置规模。
- 题数 / 数据: 正式235test sets×25episodes = 5,875episodes / model; train20tasks×100demos = 2,000。real另4task镜像。
- 评估方式: task-averaged success与相对无扰动success drop; 不适用某factor的task不进该factor分母。
- Split / 信息条件: train不加扰动但保留RLBench原variation; eval固定variation再随机pose; 主结果1train seed+1eval seed。
- 来源关系: RLBench子集扩充, YCB distractors; 20×14全笛卡儿积不合法 (无receiver / compound shape等限制)。
- 可复用: 强调只有适用且可运行的扰动才计为case; 支持扩规则但不能盲乘。
- 待核 / 限制: 20,371生成配置与235固定test set之逐ID对应需manifest导入。

P108 RoboArena (2025)

原作: <https://arxiv.org/abs/2506.18123>

本次PDF: <https://arxiv.org/pdf/2506.18123v2>

PDF SHA256: 0f793633ba5767b6e93f01056dcd5c3357dabcaf70844cd0a157a364fa843698

阅读页: 1、4、5、6、7、8。分布式A/B协定、偏好排名模型、DROID平台与完整实验分母。

- 研究类型: 稳健性、失败与评测品质; 分布式真实评测
- 领域: 居家整理与清洁、餐饮与烹饪
- 环境: 7个学术机构使用DROID平台, evaluators自行选scene/task; 没有固定封闭的环境总数。
- 任务: 开放指令集合, 涵盖数百task instructions; 不是固定17task, 17是外部窄基准比较。
- 题数 / 数据: 超过600次pairwise评估; 为创建oracle ranking, 额外跑其余5policies, 全计4,284 policy rollouts。不能称4,284独立题。
- 评估方式: 双盲pairwise preference + progress; 扩充Bradley-Terry估计policy排名与task effects, 另产生有视频证据的质性报告。
- Split / 信息条件: 连续累积开放评测; 没有一般train/test固定题库; 同一次A/B需相同task条件。
- 来源关系: DROID共同硬件/数据; RoboReward重用其真实成功 / 失败rollouts。与RobotArena ∞ 是不同工作。
- 可复用: 可作开放题库 / 偏好排名的评测方法参考; 规模必须标明是rollouts还是task。
- 待核 / 限制: 精确去重scene与语义task总量需要evaluation database, 不从hundreds推成确定数。

P109 REFLECT / RoboFail (2023)

原作: <https://arxiv.org/abs/2306.15724>

本次PDF: <https://arxiv.org/pdf/2306.15724v4>

PDF SHA256: 6018e97d117acefc2b31a0df616b29eb479b95035bf47ea2fd5882a6631ae6c3

阅读页: 1、2、4、5、6、7。数据规模与错误taxonomy、说明 / 定位 / 修正三种评测及GT信息。

- 研究类型: 稳健性、失败与评测品质; 错误辨识与程序恢复
- 领域: 居家整理与清洁、餐饮与烹饪
- 环境: AI2-THOR simulation与UR5e toy kitchen; sim用GT对象 / 状态辨识, real靠感知。
- 任务: 10simulation tasks、11real tasks; 规划失败与运行失败两大群。
- 题数 / 数据: 100sim failure cases (每task10) + 30real failure demonstrations; 没有把正常train视频混入失败case总量。
- 评估方式: Exp: 人工判说明正确且有用; Loc: 时间落在标注区间; Co-plan: 运行修正后goal state成功。; real结果表主要报Exp/Loc, 不能把sim约80% Co-plan当real自主恢复率。
- Split / 信息条件: 方法zero-shot failure reasoning; GT perception与action primitives降低sim难度。
- 来源关系: sim手动注入failures, real由teleop模拟失败政策; 并非全为自主机器人自然犯错。
- 可复用: 可借规划与运行失败taxonomy, 明确分『指出错误』『提出修正』『真的恢复』。
- 待核 / 限制: sim/real语义task重叠未去重; 完整raw failure时间 / 场景ID仍待导入。

P110 AHA (2024)

原作：<https://arxiv.org/abs/2410.00371>

本次PDF：<https://arxiv.org/pdf/2410.00371v1>

PDF SHA256：d647c7bff1ccb2d0ae805bab761177aba8cd50d81d0418ca174e9ae97054791b

阅读页：1、2、4、5、6、7、8。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：稳健性、失败与评测品质；错误辨识与程序恢复
- 领域：居家整理与清洁
- 环境：RLBench、ManiSkill与realRoboFail；非添加三套物理环境。
- 任务：7failure modes的Yes/No判断+原因解释；识别失败不等同真正恢复。
- 题数 / 数据：49KtrainingfailureQA；test11K（10未见RLBench tasks），ManiSkill-Fail130pairs（4tasks），realRoboFail7tasks。
- 评估方式：binary success labelaccuracy、ROUGE-L、cosinesimilarity、LLM fuzzy match。
- Split / 信息条件：RLBench train/test taskdisjoint，跨sim与real另测；额外VQA/LVIS训练数据不可算failurecases。
- 来源关系：FailGen改keyframes/gripper动作合成失败；RoboFail重用。
- 可复用：可大量增加失败规则cases，同时用跨来源/真实子集验证而不冒称添加语义工作。
- 待核 / 限制：keyframe产生failurelabels是生成机制标签，和视觉可观测真因未必完全相同。

P111 RoboReward (2026)

原作：<https://arxiv.org/abs/2601.00675>

本次PDF：<https://arxiv.org/pdf/2601.00675v2>

PDF SHA256：601200a96f8e30137cd3166d6d330ff9ff2ceb0de6a4c43949d808e6e9c0d29a

阅读页：1、2、3、6、7、8、9、22、27。OXE/RoboArena来源、counterfactual/clipping生成、5级rubric、完整split与人工验证附录。

- 研究类型：稳健性、失败与评测品质；奖励与完成度评测
- 领域：居家整理与清洁
- 环境：多OXE来源与RoboArena实拍；14embodiments是机体种类，非14生活环境。
- 任务：给task description+rollout video预测1-5progress；反事实重写指令和截短视频扩增负例，不自动添加实体失败任务。
- 题数 / 数据：45,072train / 6,232val / 2,831人类验证test；合54,135 episode-reward pairs。RoboArena test子集1,000。
- 评估方式：主metric progress label MAE，总体采group-wise平均；不同子数据源分列，另以RL下游验证。
- Split / 信息条件：按original task description分组互斥；同一视频的counterfactual/clips需跟父episode分组，字符串互斥不证明语义互斥。
- 来源关系：OXE成功demo及RoboArena自然成功 / 失败；生成标签是弱监督，test另人工逐例确认。
- 可复用：是有效扩充任务 / 评分规则的重要来源；应区分重标问题与新物理轨迹。
- 待核 / 限制：跨OXE子集的母episode重复与semantic task去重仍需ID核。

P112 EgoOops (2024)

原作: <https://arxiv.org/abs/2410.05343>

本次PDF: <https://arxiv.org/pdf/2410.05343v3>

PDF SHA256: fcf3b48c7dea45c46f41391de07a874453ef74d8762655f4104e34d8dfa9bb23

阅读页: 1、3、4、6、7、15。5程序完整清单、6种运行错误、50视频、cross-validation与三端点。

- 研究类型: 稳健性、失败与评测品质; 错误辨识与程序恢复
- 领域: 工艺与修缮、装配与生产作业、实验室操作
- 环境: 固定坐姿工作站, 原对象 / 工具 / 程序文字位置固定; 4名学生佩戴ego camera。
- 任务: 5task: 电路、混色、离子反应、积木、纸板工艺; 6运行错误类型, 未涵盖所有顺序 / 漏步错误。
- 题数 / 数据: 50videos、538segments、95execution mistakes; 每fold30train/10val/10test, 5-fold。
- 评估方式: 端到端step alignment + mistake/correction mAP@tIoU0.1/0.2/0.3; GT segments分类是oracle子问题。; alignment另F1/precision/recall/MoF。
- Split / 信息条件: 每fold各task一正常一错误test视频; 作者称group-kfold控制worker, 精确ID仍需查。
- 来源关系: 自录多领域程序; 一半刻意错、一半尽量正常但也有自然失误。
- 可复用: 补料理以外程序错误; 规则由文字指定, 不能仅凭视觉常识判定。
- 待核 / 限制: 4名参与者与5-fold worker grouping的精确分配需manifest查。

P113 REPAIR-Bench (2026)

原作: <https://arxiv.org/abs/2606.29937>

本次PDF: <https://arxiv.org/pdf/2606.29937v1>

PDF SHA256: c63b11a21f43bad4c9a0709836fb1f9ca225602ea2192d55be74dd59ea385cfd

阅读页: 1、2、3、4、5、6。RFM-HRI来源、排除样本、3端点、各split、时间与偏好评分。

- 研究类型: 稳健性、失败与评测品质; 错误辨识与程序恢复
- 领域: 医疗与手术支持
- 环境: lab与hospital的crash-cart guidance交互; 不是完整医疗操作或手术任务。
- 任务: 3端点: 失败时刻、失败类型、用户偏好恢复策略; 4诱发failure conditions + success。
- 题数 / 数据: 来源214trials/41人; 排30后正式analysis184trials/38人。不能将214全部写成已用评测样本。
- 评估方式: 视觉failure classification F1等; localization秒级absolute error与tIoU F1°; recovery用Hit/precision/recall/F1@k, GT是人的偏好, 未证明机器人运行恢复成功。
- Split / 信息条件: visual tasks约75/25 participant分组; recovery文本60/20/20随机split, 不能宣称三端点都participant-disjoint。visual任务刻意不给语音。
- 来源关系: RFM-HRI旧数据添加标注与preference; failure offset以机器人错误回应结束作标记, 不是物理抓取失败时刻。
- 可复用: 补user-centered interaction recovery; 必须和物理任务恢复及其成功证据分开。
- 待核 / 限制: 前处理阶数/cutoff不同段落叙述不一, 重现需code确认; source214与41×5亦不完全一致。

P114 RobotArena infinity (2025)

原作: <https://arxiv.org/abs/2510.23571>

本次PDF: <https://arxiv.org/pdf/2510.23571v3>

PDF SHA256: d08b1e9db69b3e2efbb9e51be4044370272927d0d53c97807368bfdb42892ba9

阅读页: 1、3、5、6、7、8、9、25。real-to-sim来源、VLM评分与human BT ranking、BridgeSim规模及real验证范围。

- 研究类型: 稳健性、失败与评测品质; 转移与评测有效性
- 领域: 居家整理与清洁
- 环境: BridgeSim70环境; 另DROIDSim、RH20TSim。总量仅概述hundreds, 不能用70代称三套全库。
- 任务: 由真实demo生成task + digital twin, 再扰动初态/texture; 未给共同语义task类别总数。
- 题数 / 数据: BridgeSim上8,749pairwise comparisons; 是对policy视频的偏好标注, 不是8,749不同task。
- 评估方式: Gemini结合video + privileged sim states评progress, 取最后30%frames平均; human pairwise BT ranking另列。; real/sim相关验证只展示1个carrot-to-plate任务的3policy, 不能外推全库已校准。
- Split / 信息条件: Bridge/DROID/RH20T来源与policy训练来源分in/out; 同场景pairwise保持相同初态。
- 来源关系: 真实Bridge、DROID、RH20T衍生; 不同于RoboArena在真机直接分散评估。
- 可复用: 提供多来源real-to-sim与偏好评分途径; 要区分生成场景、物理成功checker和VLM judge。
- 待核 / 限制: DROIDSim / RH20TSim精确场景ID量与跨来源等价未导入。

P115 RoboMME-Interference (2026)

原作: <https://arxiv.org/abs/2606.22338>

本次PDF: <https://arxiv.org/pdf/2606.22338v3>

PDF SHA256: 95baa91cdd2a1d6c0791a31627a8daee1d9e9ff70d58d60e76f53e4e3d142c40

阅读页: 1、2、3、4。9/16task选择、history干扰规则、完整系统网格与50episode评测。

- 研究类型: 稳健性、失败与评测品质; 长期记忆与生活助理
- 领域: 跨域 / 用途未指定
- 环境: 沿RoboMME配置, 添加跨session history; 不是新物理环境。
- 任务: 16原task中选9个有可分离demo的families: 4程序、3object、2spatial memory; 其余7不适用。
- 题数 / 数据: $9 \times 50 = 450$ 基底test episodes; history条件no-history及 $k=0/1/3/7$; 11memory systems + 无memory baseline造成25,200内核rollouts, 非同量独立题。
- 评估方式: 成功率与Wilson95%CI; 随干扰增加的退化曲线; retrieval改进另列。
- Split / 信息条件: 不重训released checkpoint, 仅变history; 每distractor32stored frames且来自不同family, 避免混入相互矛盾信息。
- 来源关系: RoboMME的9-family子集加history规则; 非全新9task。
- 可复用: 展示规则扩充可增加可评条件而不改语义task数; 记忆干扰可做本库共通延伸。
- 待核 / 限制: 原始RoboMME benchmark须独立登记检查; 跨history条件query IDs应保留父关系。

P116 OopsieVerse (2026)

原作: <https://arxiv.org/abs/2606.31993>

本次PDF: <https://arxiv.org/pdf/2606.31993v1>

PDF SHA256: cbe5a184d84ac4490de9dbbfde077c3b9a7905c1d6bc581e739540b078af3d2

阅读页: 1、2、4、5、6、7。DamageSim三类伤害、32实作/21task设计、demo及safe-success评分。

- 研究类型: 稳健性、失败与评测品质; 安全与约束评测
- 领域: 居家整理与清洁、餐饮与烹饪
- 环境: OmniGibson与RoboCasa/Robosuite两后端; 热 / 流体伤害只在支持相应物理的后端可用。
- 任务: 32task instantiations对应21unique task designs; 不是32不同语义任务。
- 题数 / 数据: 5示范task共90demonstrations, health feedback有/无各半; IL每task30rollouts。
- 评估方式: task completion与safe completion分开; 后者需goal成功且所有tracked object health维持>95。; damage由力、温度、液体接触的参数模型计算, 不能等同已校准的真实损害概率。
- Split / 信息条件: 不同collection/curation/RL/VLA设置分开; 5task IL子集不代表全32皆同程度实验。
- 来源关系: BEHAVIOR1K与RoboCasa任务加damage观测 / reward / termination; 共享goal与backend instantiations。
- 可复用: 为同一goal增加保护对象 / 低破坏条件的直接先例, 规则差异应独立可查。
- 待核 / 限制: damage threshold跨材料 / 跨后端的物理标定程度须另验证。

P123 WatchAct (2026)

原作: <https://arxiv.org/abs/2606.26443>

本次PDF: <https://arxiv.org/pdf/2606.26443v1>

PDF SHA256: 42a137d5b56c9e1dd7d421cba16f8f06fe42cace6418e7338136400df3e7954c

阅读页: 1、2、3、4、5、6、8、14、15。14task完整taxonomy、3K个案、video-sim配对、4项验证与plan/physical/end-to-end协定。

- 研究类型: 人类观测到机器人转移; 人类示范与技能转移
- 领域: 居家整理与清洁
- 环境: LIBERO配对真实桌面视频; 11桌面regions + 6container regions只是命名区域, 非17个环境。
- 任务: 14task scenarios归4认知domains; event、procedure、implicit intent、episodic, 含模仿、反转、恢复旧位置、续作、修错、条件分支。
- 题数 / 数据: 3,000 video-language-simulator bundles; policy实验每task10trials, 与全部3K的plan reasoning范围分开。
- 评估方式: Plan SR在symbolic executor; Task SR在物理simulation; PR完成子goal比例。; 顺序唯一task直接比oracle, 允多解的task比symbolic终态; oracle-plan execution与integrated pipeline分开。
- Split / 信息条件: LIBERO-finetuned policies转到paired tasks; 新对象/指令in/out-domain另列, 固定每command300steps。
- 来源关系: LIBERO扩新对象 / predicate; LLM先产spec再照spec拍人类video, 不是从任意网络video全自动转robot。
- 可复用: 最接近『视频→任务规格→可运行场景』的前作; 还受限Pick/Place/Open/Close, 排除pour/wipe/cut/stir。
- 待核 / 限制: physical评测每task10trials中task指类型或instance的manifest需核, 不先乘成3万或宣称3K全测。

P124 RoboReel (2026)

原作: <https://arxiv.org/abs/2609.08209>

本次PDF: <https://arxiv.org/pdf/2609.08209v2>

PDF SHA256: 4f0b2629e1e663390e169e7ae24496406246958dbec7bb20f3973de31a9e34ff

阅读页: 1、2、3、4、5、6、7、9、21、24、25、27、29。10task、4suites、配对搜集、附录完整统计、success predicate和eval banks。

- 研究类型: 人类观测到机器人转移; 人类示范与技能转移
- 领域: 居家整理与清洁
- 环境: 1个实际桌面rig与ManiSkill3/SAPIEN配对场景, 4人类camera views; calibration与distractors另分setting。
- 任务: 10task (推/抓方块、抽屉、锅盖、烤面包机、碗盘、篮子、玩具收纳、堆杯); 4suites ND/WD/ED/PD, 不是40语义task。
- 题数 / 数据: 正文2,000ND/WD human demos; 附录含PD共3,000human demos=12,000视角mp4, 另2,000robot trajectories。每结果cell3runs×20=60rollouts。
- 评估方式: simulation goal predicates; 比如drawer只需关至少一半、toaster80%进程, 不能与更严格同名task直接比。; 表格报3runs mean/SEM; SeeDo仅5项支持task, N/A不是0。
- Split / 信息条件: 每task-condition100 human demos取80train/20eval; oracle-filtered initial-state banks固定初态。
- 来源关系: PartNet-Mobility + SAM3D real twin; explicit/latent/keypoint三种LfO代表比较, 借不同既有policy。正文称接受后发布, 素材取得待核。
- 可复用: 可借真实human→sim配对及同条件多方法对比; 不应把camera/views文件量作添加题量。
- 待核 / 限制: 100seed与每bank300entry在同段并列, 需原生manifest厘清最终bank量; 发布可得性尚未验证。

P127 BridgeData V2 (2023)

原作: <https://arxiv.org/abs/2308.12952>

本次PDF: <https://arxiv.org/pdf/2308.12952v3>

PDF SHA256: aa5fdac48bf9122b22f88150d45575cb0685f2a2f761ca6fc570be743022819b

阅读页: 1、3、4、5、6。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 机器人数据与通用策略; 真实操作benchmark
- 领域: 居家整理与清洁、餐饮与烹饪、衣物与洗护
- 环境: 24environments, 含7toy kitchens及tabletops/sinks/laundrysetups, 4环境类别。
- 任务: 13skills; 同skill换object可成不同原作task, 未报全库范式task总数。
- 题数 / 数据: 60,096trajectories = 50,365expert+9,731scripted; 主task每method10trials。
- 评估方式: tasksuccess; goalimage与languageconditions分别比较。
- Split / 信息条件: seen/unseenobject/environment/otherinstitution; RT1input分辨率与history较大须注记。
- 来源关系: BridgeData原版扩充, 后被OXE/OpenVLA/Octo重用。
- 可复用: 补家电、表面、衣物与颗粒工具操作; 保留human/scripteddemo品质类型。

- 待核 / 限制：13skill不是13全部task；不同原作method观测预算未完全一致。

P128 RoboNet (2019)

原作：<https://arxiv.org/abs/1910.11215>

本次PDF：<https://arxiv.org/pdf/1910.11215v2>

PDF SHA256：01a03705dfb76192445b8c09fa3e85d67a1d9165b2c00df3672cfd10cc66052a

阅读页：1、3、4、5、6。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：机器人数据与通用策略；跨数据集集成与评测方法
- 领域：跨域 / 用途未指定
- 环境：4lab environments、113camera configurations、7arenatypes等不同环境层级。
- 任务：主要object relocation，可用推或抓放；manyrobots不增加相同数量goal families。
- 题数 / 数据：15Mframes、约162Ktrajectories；7platforms，Table1caption称6arms有文字差异。
- 评估方式：endgoal distance与operator判断是否覆盖goal；作者明言不同experiments不可直接比难度。
- Split / 信息条件：held-out robot或view再fine-tune300–400targettrajectories；不叫完全zero-shotrobottransfer。
- 来源关系：多institution数据与existingrobotcorpora集成；同物理trajectory可能多view。
- 可复用：重要早期集成前作；以哪种目标、哪种信息与哪个分母比较，比合并大小更关键。
- 待核 / 限制：release-version轨迹精确数及scene去重待manifest；不从15Mframes推testcases。

P129 RH20T (2023)

原作：<https://arxiv.org/abs/2307.00595>

本次PDF：<https://arxiv.org/pdf/2307.00595>

PDF SHA256：6156500a1340a2e976681f0f8deea8ce493fb4af227d8a5b2696cb3c384bb755

阅读页：1、2、3、4、5、6。147task来源、7硬件配置、pairing阶层、110K数据与实际few-shot实验。

- 研究类型：机器人数据与通用策略；人类示范与技能转移
- 领域：居家整理与清洁、装配与生产作业
- 环境：7robot configurations、>50table covers；covers不是不同场景layout。
- 任务：147tasks = 48选自RLBench + 29MetaWorld + 70自定义；42verbs是skill标签，不是147完全独立新设计。
- 题数 / 数据：>110K robot sequences与等量human sequences；hierarchy可配出数百万pairs但不是同量独立视频。本文ACT主实验只在1个block-to-weight任务，每configuration20trials。
- 评估方式：人类收集时0–9quality、成功/失败约10:1；ACT实验分reach/grasp/place success，60秒上限。
- Split / 信息条件：新环境含新camera/tablecover/robot；pretrain335同task + 195相近task，fine-tune75demo起，再缩小数据。
- 来源关系：RLBench与MetaWorld任务规格被实拍移植；新实拍数据是新素材，但goal定义有上游来源。
- 可复用：是从前作选task再扩新task、兼有人类视频与robot轨迹的重要前例。

- 待核 / 限制：paired视频之精确实例对应与跨机体可比性需原生metadata导入。；DROID原作表I将RH20T依unique multi-view trajectories记为约13K，与RH20T原作110K口径不同；保留两种出处，未完成原始manifest去重。

P141 HoloAssist (2023)

原作：<https://arxiv.org/abs/2309.17024>

本次PDF：<https://arxiv.org/pdf/2309.17024v1>

PDF SHA256：af4fda7dcdcc0e5c9e4e4649f19bea3da6b3afe52e7a83d1adc8e7a79c011421

阅读页：1、3、4、5、6、7、8、9。20task来源、sessions/标签、mistake/intervention/forecasting、split与指针。

- 研究类型：辅助与协作；对话协作与任务完成
- 领域：餐饮与烹饪、办公与教育、工艺与修缮、装配与生产作业
- 环境：HoloLens2 wearer + 远程instructor；16对象种类，非16场景。
- 任务：20程序；414coarse action classes；mistake detection、intervention type、3D手预测及action recognition。
- 题数 / 数据：2,221sessions、166小时、222人 / 350pairs；1,545train、213val、463test。错误/介入表只评10%全数据子集。
- 评估方式：动作top-1/5；错误F-score与precision/recall；3种intervention分类。；手轨迹看过去3秒、预测0.5/1/1.5秒，用MPJPE厘米；只保留正确action。
- Split / 信息条件：每task按session70/10/20，并非保证参与者或instructor/performer pair全互斥。
- 来源关系：新录human-human交互；字幕 / 动作 / 介入共用session，非多个独立数据库。
- 可复用：提供人类教学、介入时机、程序错误与短期手预测；是协作型多模态来源。
- 待核 / 限制：fine action label总数和各endpoint精确可评IDs仍需manifest；不从coarse414推整套任务数。

P142 Habitat 3.0 (2023)

原作：<https://arxiv.org/abs/2310.13724>

本次PDF：<https://arxiv.org/pdf/2310.13724v1>

PDF SHA256：6383018901acbf7677050585da9a30707437cf7119def797be500f33a68021af

阅读页：1、2、5、6、7、8、20、25、26。avatar/HITL、2任务、59scene split、合作人口与metrics。

- 研究类型：辅助与协作；对话协作与任务完成
- 领域：居家整理与清洁
- 环境：HSSD211源scene中的59实验scene = 37train/12val/10test；12base avatars不是12场景。
- 任务：2families：social navigation找/跟人；social rearrangement两代理搬2对象。
- 题数 / 数据：附录按scene抽train1000、val100、test15；即37Ktrain、1,200val、150test基底episodes，协作partners另作条件。
- 评估方式：导航Finding Success/SPS/Following Rate/Collision Rate；rearrangement SR与relative efficiency对human-alone比较。
- Split / 信息条件：未见scene + new partner population；oracle/learned low-level skills分开。导航主设置有持续humanoid GPS，不是只凭RGB找人。

- 来源关系：HSSD、AMASS、SMPL-X、Habitat底座；human avatar使用kinematic attach等简化，与real人类动力不同。
- 可复用：是可比较human/robot角色与partner泛化的重要底座，不能再当全新场景资产。
- 待核 / 限制：全来源211scenes和59实验子集不能合并计数；不同HSSD版本与HomeRobot/PARTNR需scene ID对齐。

P144 CAP/EgoGym (2026)

原作：<https://arxiv.org/abs/2602.09017>

本次PDF：<https://arxiv.org/pdf/2602.09017v1>

PDF SHA256：b0428cf26ad882127851059de2fafebb3ae164e38f631b9d941ca8ac0ebbed4

阅读页：1、2、4、5、6、7、8、11。数据、接触prompt、EgoGym设计、3task真实与跨机体eval、tool chaining。

- 研究类型：人类观测到机器人转移；模拟平台与任务套件
- 领域：居家整理与清洁、办公与教育
- 环境：数据报424environments=Pick289/Open87/Close48，为作者收集配置口径；EgoGym是程序生成MuJoCo套件。
- 任务：3utility task families：Pick、Open、Close；不因接触座标不同自动变新语义任务。
- 题数 / 数据：20,365human-tool demonstrations、23.1小时；real Pick250trials，Open/Close每checkpoint100trials；EgoGym有915Objaverse object pool。
- 评估方式：task success；oracle human contact prompt、VLM contact prompt、retry设置分开。
- Split / 信息条件：real新scene/object zero-shot；sim用作training loop model selection，不能当独立未见test。
- 来源关系：Objaverse assets + iPhone手持工具数据；CAP可作高级模型tool calls的低级utility。
- 可复用：支持multimodal tool use与robot skills组合，但示范用contact anchors、主eval有oracle条件，应明列。
- 待核 / 限制：424是否跨Pick/Open/Close具有同址重用需ID核；EgoGym完整eval bank量待code。

P145 NIABench (2026)

原作：<https://arxiv.org/abs/2605.01368>

本次PDF：<https://arxiv.org/pdf/2605.01368v1>

PDF SHA256：add5ffdd033bc8c450f79b317f31c0df3735d7a4789a9e8f833e3dbcab4f5b12

阅读页：1、2、3、4、5、6。2K来源、7test tasks、非中断规则、text-only状态与3指针。

- 研究类型：辅助与协作；对话协作与任务完成
- 领域：居家整理与清洁、餐饮与烹饪、办公与教育
- 环境：AI2-THOR四room categories；4是类型，非精确四个scene IDs。主model采文字state，没有raw visual perception。
- 任务：7test tasks：cut tomato、toast bread、watch TV、work、sleep、study、shower；2,000训练script episodes，human主程序不允许被中断。
- 题数 / 数据：2K corpus再分train/val；7个代表evaluation episodes；75%一个oracle assistance、20%两个、5%无需协助。
- 评估方式：SelectionAcc比oracle step-action pair；HumanStepSaved减少的人类primitive steps；SuccessAcc查最终sim state。
- Split / 信息条件：2K按scene/oracle数分train/val，7held-out另设；real只2小型验证任务。

- 来源关系：AI2-THOR高级动作adapter；800atomic actions是候选动作词汇，不是800已实作工作任务。
- 可复用：可加不打断人类、适时协助与no-op合法答案等规则；不能宣称2K都为held-out test。
- 待核 / 限制：7代表情境内是否另有多个随机initial seeds及确切case量需code核。

P146 DexH2R (2025)

原作：<https://arxiv.org/abs/2506.23152>

本次PDF：<https://arxiv.org/pdf/2506.23152v3>

PDF SHA256：c48a1c58f5201ee324223c711cba95a429ea7446bc43e4d59f452e829eda1709

阅读页：1、2、3、4、5、6、7。data/rig、handover动态定义、完整split、pose与trajectory指针。

- 研究类型：辅助与协作；灵巧手操作benchmark
- 领域：跨域 / 用途未指定
- 环境：UR10e + ShadowHand固定capture setup，18视角（含2wrist ego），不是18环境。
- 任务：1内核human→robot handover family；56对象 / 39人，包含动态接近与终态抓握。
- 题数 / 数据：4,282trials、456Kframes、79,911成功grasp poses；2,888train / 591val / 803test trajectories。
- 评估方式：grasp succ1/succ6外力稳定、penetration、diversity；approach success、trajectory length、inference frames、safety率。
- Split / 信息条件：test含新object/newsobject、newobject/seensubject、seenobject/newsobject三群；不是803独立任务语义。
- 来源关系：真实teleoperation human-object-robot交互，grasp模型另用DexGraspNet预训练。
- 可复用：补人机交接、动态手型 / 接触安全，区分pose、trajectory及物理handover完成。
- 待核 / 限制：每test子群细分ID与final pose对母trajectory的多对一关系待manifest。

P147 HRIBench (2026)

原作：<https://arxiv.org/abs/2607.13056>

本次PDF：<https://arxiv.org/pdf/2607.13056v1>

PDF SHA256：d779bea84ddd0cbca254797e628b09dbf95118efa086cfe333dd6156a4a2ded2

阅读页：1、3、4、5、6、7。role scripts、13tasks、786过滤池、50/10真实split与coordination metrics。

- 研究类型：辅助与协作；对话协作与任务完成
- 领域：跨域 / 用途未指定
- 环境：Franka simulation结合合成人类骨架/trajectory；候选由2K生成并筛。
- 任务：13 role-conditioned tasks；Instructor / Collaborator / Intruder三角色。
- 题数 / 数据：2,000候选中786通过；正文实验每task50adaptation+10held-out，因此650adaptation / 130held-out。摘要『>650 evaluation episodes』不等于主实测test量。
- 评估方式：CSR/time/idle、temporal sync/latency/order、collision/contact/contradiction/disruption；partial安全summary需按适用component。

- Split / 信息条件：固定policy无关Intruder扰动时序；real3task各10trials，只是adaptation验证。
- 来源关系：生成scripts/human motion并sim验证；两个同名HRI Bench不得合成同一来源或版本。
- 可复用：加入等待、同步、角色及干预恢复规则；数据候选通过不等于全部是test。
- 待核 / 限制：786与13×60=780剩6条用途未明，需manifest；摘要650eval与正文130held-out须分列。

P148 Assistax (2025)

原作：<https://arxiv.org/abs/2507.21638>

本次PDF：<https://arxiv.org/pdf/2507.21638v3>

PDF SHA256：53953a170eca350244258f44b0b043e960f2bcece29e1074e805ab251bc95547

阅读页：1、3、4、5、6、7、8、9。5assistive tasks、robot/human控制、preferences、630partner池与MARL/AHT评测。

- 研究类型：辅助与协作；协作控制benchmark
- 领域：个人照护
- 环境：MJX/JAX五种assistive配置，使用简化rigid geometry；不是临床或柔性皮肤物理验证。
- 任务：Scratch、Tooth Brushing、Feeding、Bed Bathing、Arm Assist；force/speed/contact偏好另外参数化。
- 题数 / 数据：每task630pretrained humanoids；AHT以5train/625unseen partners；MARL每曲线16seeds与64eval episodes。
- 评估方式：task/preference return分开，跨任务min-max normalized mean、bootstrap95%CI；新partner泛化。
- Split / 信息条件：partner-disjoint；挑5个high speed preference为train是刻意困难设置；精确episode/context数不等于625新task。
- 来源关系：Assistive Gym inspired任务，Brax humanoid与MJX；原始Assistive Gym需补为上游来源。
- 可复用：补个人照护、人类偏好及协作适应；没有固定统一题库上限。
- 待核 / 限制：不同partner/preferences的物理对应与真实用户有效性未等同验证。

P151 H2R-Bench (2026)

原作：<https://arxiv.org/abs/2608.13049>

本次PDF：<https://arxiv.org/pdf/2608.13049v1>

PDF SHA256：ec3fb6258fea92eda2ba4240561afd8f307606a133031b63ad12d666306af015

阅读页：1、2、3、4、5、6、11、14。source-relative定义、120→240cases、6家族、native interface与五metric。

- 研究类型：世界模型与预测表示；世界模型与视频生成评测
- 领域：衣物与洗护
- 环境：EgoDex test来源视频，没有配对可运行robot simulator环境。
- 任务：6物理变化families：rigid、mechanism、insertion、deformable、bulk、surface；目标2种embodiment。
- 题数 / 数据：120段5秒source clips×2embodiments=240transfer cases；每family20source。11generators的输出视频数不是新题数。
- 评估方式：M1goal/M2events/M3contact/M4embodiment由3个MLLM按0–4rubric评；M5为video quality。；每metric25sampled frames；H2RCORE加权contact与embodiment共60%，属视频证据评分，非实际控制成功。

- Split / 信息条件: EgoDex test衍生; video-conditioned与frame-conditioned界面分组, 不能不控制输入信息比较。
- 来源关系: EgoDex来源; 与H2RBench human-transfer及RoboWM-Bench不同任务, 不能因名称相似合并。
- 可复用: 可加入human→robot视频转移端点; 应作世界模型章, 与可运行操作题数分开。
- 待核 / 限制: contact的视频可见正确不能保证力 / 深度 / 可达性, 仍缺物理execution证据。

P152 RoboWM-Bench (2026)

原作: <https://arxiv.org/abs/2604.19092>

本次PDF: <https://arxiv.org/pdf/2604.19092v2>

PDF SHA256: 4450ceffa72850511da6c91b3ce6f73bc070d372104dc8f60ce6fbf8f84ed566

阅读页: 1、3、4、5、6、7、14、15。video→action两路、task suite、主表与sim附录、10初态与execution成功。

- 研究类型: 世界模型与预测表示; 世界模型与视频生成评测
- 领域: 餐饮与烹饪、衣物与洗护
- 环境: LeHome/IsaacSim原生与real-to-sim桌面; 固定camera、随机对象初态。
- 任务: 主表8human-hand及8robot-task条件, 附录另6simulation-native条件; 含同名重用, 不直接加成22语义task。
- 题数 / 数据: 每task10个共同initial configurations; Cosmos-finetune每task50trajectories是额外训练。bimanual附录又为另条件。
- 评估方式: generated video经HaMeR retargeting或IDM转action, 再进simulation; key nodes全通过且达goal才Task SR, 另Step SR。
- Split / 信息条件: 固定初态 / 种子跨model; human与robot视频使用不同action extraction pipeline, pipeline误差须分开分析。
- 来源关系: LeHome底座与real reconstruction, PAI-Bench作同视频视觉分数对照。
- 可复用: 提供生成视频到物理可运行性的桥梁, 但需把视频模型和action extractor责任拆解。
- 待核 / 限制: 全部task条件与语义去重清单需release manifest; retargeting/IDM失误会影响world model分数。

P164 The Imitator Game (2026)

原作: <https://arxiv.org/abs/2608.22301>

本次PDF: <https://arxiv.org/pdf/2608.22301v1>

PDF SHA256: f38c19c22603063351fd35a218cc5a1477609c973c0a79cbe972a2bb78f01e1b

阅读页: 1、4、5、6、7、8、20。L0-L3保留/变更条件、IG-10K规模、六domains、sim/real及Arena协定。

- 研究类型: 人类观测到机器人转移; 人类示范与技能转移
- 领域: 居家整理与清洁、餐饮与烹饪、包装、仓储与物流、零售与购物、实验室操作、医疗与手术支持
- 环境: 200+ paired task-scene variants; 同human clip可对多level robot场景, 非全新independent demonstration。
- 任务: 50+base tasks, 6生活/工作domains (分量12+7+17+4+6+7=53); 实验10tasks (5seen+5unseen) ×4levels。
- 题数 / 数据: 11,720real paired episodes + 10Ksim pairs (sim重用human clip); 每task-level sim10trials、real5trials。15/30/45task训练套件相互包含。

- 评估方式：sim SR与ordered subgoal SR；人类SUCCESS/PARTIAL/FAIL、0-10imitation quality、pairwise preference。；L0动作近似、L1布局改变、L2对象替代、L3功能替代；level是demo-execution pair属性，不是task固定难度。
- Split / 信息条件：sim/real分开训练与比较；same domain/setting/task/level/episode才做A/B，少数task不定义L3。
- 来源关系：ManiSkill3、手工waypoints、VR真机pairs；与RH20T等比较，但多level共用源human clip。
- 可复用：是意图 / 功能替代及多域human-robot数据近邻；我们须纳入其6用途群与可替代规则。
- 待核 / 限制：53分域与表2『50 tasks』的版本口径须manifest确认；不可把4levels机械乘所有task。

P165 LIBERO-Recover (2026)

原作：<https://arxiv.org/abs/2609.05178>

本次PDF：<https://arxiv.org/pdf/2609.05178v3>

PDF SHA256: ee23bf31934cc0e262b4b30458be149df135ec3695c866939c482c0b55fe414a

阅读页：1、2、3、4、5、6、9。failure对normal variation的区分、2178scenario生成、恢复数据与RSR/RD/RC。

- 研究类型：稳健性、失败与评测品质；错误辨识与程序恢复
- 领域：居家整理与清洁
- 环境：LIBERO自然rollout失败的state snapshots；不是2178不同room layouts。
- 任务：130上游tasks、4recovery levels；LIBERO100再拆90/10报告，不能另加两suite。
- 题数 / 数据：2,178recovery scenarios；413training failure scenes有3,184human recovery trajectories，训练使用场景排出最终eval。
- 评估方式：Recovery Success Rate完成原goal；Recovery Degradation比较failure前后；RC=1-task-level success率标准差。；RC公式实际是跨task变异，不完全等同文中所说同task不同failure的稳定性。
- Split / 信息条件：六policy产failure，Qwen定位/分类；自然failure分布不平衡。eval每task10trials、520step，需固定scenario/perturbation解读。
- 来源关系：LIBERO延伸；失败条件要execution-induced且需改plan但仍可恢复，不能把任何位置变化都叫failure。
- 可复用：可引入真实policy失败状态而非纯人工扰动；恢复题需要前史与可恢复证据。
- 待核 / 限制：recoverability对每scenario的完整验证证据、2178与training排除先后、eval task词义需manifest查。

P166 SafeVLA-Bench (2026)

原作：<https://arxiv.org/abs/2606.00773>

本次PDF：<https://arxiv.org/pdf/2606.00773v2>

PDF SHA256: ecb59f541415c25bcb45263b2c7058d15a124829c8dab6d7b5eac681f36c1f4a

阅读页：1、3、4、5、6、34、46。STL库、8scored families、适用性registry、58tasks/27entries及指针定义。

- 研究类型：稳健性、失败与评测品质；安全与约束评测
- 领域：居家整理与清洁、餐饮与烹饪
- 环境：LIBERO+RoboCasa365两host，事后instrumentation保留原生观测/动作/初态/success。

- 任务：58tasks = LIBERO四10-task suites + RoboCasa365 atomic-seen18tasks；8safety families归scene/object/robot三group。
- 题数 / 数据：LIBERO每model-suite200episodes (10×20)，RC每task50；24distinct policies、27policy-host entries不是27benchmarks。
- 评估方式：native SR、Safety、Success-but-Unsafe、Violation Severity Index；VSI是spec-normalized worst violation depth。；有意义且signals可用才套STL，额外diagnostics不影响Safety；代理threshold不是物理安全认证。
- Split / 信息条件：固定seeds配对；RC policies有两个独立seed groups，跨组unpaired；不跨host直接排总榜。
- 来源关系：对既有LIBERO/RC trajectories加规则评分；不是新生成58个目标任务。
- 可复用：本库规则扩充应借其适用性registry与success/safety分离，而不是每task强乘所有评估方式。
- 待核 / 限制：缺人类近距离、实际spill/thermal等signals；composite全程排除某clause可能漏掉部分phase。

P167 DexGarmentLab (2025)

原作：<https://arxiv.org/abs/2505.11032>

本次PDF：<https://arxiv.org/pdf/2505.11032v3>

PDF SHA256：447ce546d76be47536883a64aac1e9fc7ea1f214433bc6915d9acce2eab57f65

阅读页：1、2、4、5、6、7、8、9、10、18、20、32。15task场景、物理抓持修正、14实测task、100demo/50episode、real验证。

- 研究类型：布料 / 柔性物操作；柔性物操作benchmark
- 领域：衣物与洗护、个人照护
- 环境：双UR10e + ShadowHand，15task scene设置；>2500garments/8类不是2500不同task。
- 任务：15定义含fling/fold/hang/wear/store；主simulation实验14task (wear glove未在主表)，不能报全15同程度测完。
- 题数 / 数据：每实测task100generated demonstrations；每task50episodes与3seeds；real4task各3garments×5初态 = 15trials。
- 评估方式：task-specific成功与mean/std；demo生成成功率和policy成功率分开。；以friction/adhesion取代GarmentLab attach blocks，两者同名折衣控制难度并不相同。
- Split / 信息条件：garment形状/初态/位置变化；文中2%test training data是模型脱机切分，不等于50episode物理eval。
- 来源关系：ClothesNet与UniGarmentManip/GarmentLab相关资产和方法；更改抓持物理具实质差异。
- 可复用：灵巧双手与穿衣 / 收纳广度的重要来源；应追实际物理规则差异。
- 待核 / 限制：各task成功predicate与garment ID split仍需完整config清单，不能只以模型shape库算coverage。

P168 HRIBench (perception, 2025) (2025)

原作：<https://arxiv.org/abs/2506.20566>

本次PDF：<https://arxiv.org/pdf/2506.20566v1>

PDF SHA256：7148bb0244bccd22b8b8050d609fa6304f05059d5224f76470c5b87616428af7

阅读页：1、2、3、4、5。5domain来源、1000VQA、非语言线索、自录/复用与accuracy-latency表。

- 研究类型：理解、推理与规划；人体与交互感知评测
- 领域：社交与沟通

- 环境：Kuri/Quori自录非语言交互 + 既有公开数据；5domains是能力群，非5物理环境。
- 任务：nonverbal、verbal intent、human-robot-object relation、social navigation、person identification五种。
- 题数 / 数据：每domain200VQA，总1000；overall accuracy/latency排除person identification，因此总体比较用其余800题范围。
- 评估方式：逐题accuracy与latency秒；unsupported/refused identity标N/A，不能填0后和其他模型无条件平均。
- Split / 信息条件：主为VLM zero-shot评测；各domain人类baseline由不同expert完成。
- 来源关系：HandMeThat加视觉、CoMaD、MuSoHu、YouTube视频与自录gestures；不是2026interaction-centric HRI Bench。
- 可复用：提供HRI感知与实时性题型；选合宜导航路径的VQA不等于实体导航运行。
- 待核 / 限制：不同question形式random accuracy不同，不能全统一25%random；上游素材和case IDs未导入。

P169 X2Real (2026)

原作：<https://arxiv.org/abs/2609.27449>

本次PDF：<https://arxiv.org/pdf/2609.27449v1>

PDF SHA256：5cff92f0d0a008824b9299b9e8f9259404e6177fd54a55c4d4eede0aff18f521

阅读页：1、3、4、5、6、13、14、23、24、27、28、29。44task架构、training/eval分离、资产/DSL、DAG metrics、desktop/mobile与sim-real验证。

- 研究类型：一般操作 benchmark；模拟操作benchmark
- 领域：居家整理与清洁
- 环境：Mana/IsaacLab场景；多embodiments与green-booth训练配置，appearance/task/embodiment分别扰动。
- 任务：44simulation tasks / 10能力维度；含3mobile tasks与3challenge tasks，能力数不是生活domain数。
- 题数 / 数据：近300小时训练轨迹；desktop各300demo、mobile各1,000、3challenging总>20K trajectories；mobile eval每task每ID/OOD40episodes。
- 评估方式：DAG依赖达成、无failure且sink nodes完成才success；latched node进度加权10分；层级macro平均避免大类垄断。；sim-real本文overall r为success0.74/progress0.84，精密task更弱，不用一般task子集高r外推全部。
- Split / 信息条件：green-booth demonstrations与OOD背景/task/robot配置分离；模型不取得frame-level subtask标签。
- 来源关系：Mana基于IsaacLab/Arena，资产来自多3D库与AIG3D；不等同创建完整新生活任务ontology。
- 可复用：统一runtime、DAG过程与收集/评测分离可借；主张泛化应按能力与实测subset支持。
- 待核 / 限制：desktop完整eval case IDs与3challenge是否纳同一overall分母需release设置核。

P170 MotionForge (2026)

原作：<https://arxiv.org/abs/2609.25689>

本次PDF：<https://arxiv.org/pdf/2609.25689v1>

PDF SHA256：26bf90c839b269529d60ec9d7b97df9c98670c0297089faf96f14d7e2bfc8c1a

阅读页：1、2、3、4、5、6、7。40semantic families、motion taxonomy、实时协定、生成validation及ID/OOD50seeds。

- 研究类型：一般操作 benchmark；动态操作benchmark

- 领域：装配与生产作业、包装、仓储与物流
- 环境：4scene families：Factory Conveyor、Circular Motion、Home Tabletop、Embodied Interaction；5K背景variation非5Klayouts。
- 任务：40semantic tasks、11motion patterns；17long/23short，仅改速度的variants合并为同family。
- 题数 / 数据：约20K产生demo中选每task50 = 2Ktrain；每task每ID/OOD condition50固定seeds，7policies另算rollouts。
- 评估方式：macro task success；policy推论时环境仍以120Hz进行，latency对成功有实际影响。；LH依8秒+2skills或20秒门槛定义，作者明示长不一定更难。
- Split / 信息条件：object/background/light/speed单factor与joint OOD；保留不支持最高speed的task例外。
- 来源关系：generated scenes + 共用oracle skills；task质检要求oracle>50%为生成合格条件，不是learning-policy成绩。
- 可复用：补发送带、抛接与动态速度规则；可区分场景生成量与语义task量。
- 待核 / 限制：不同硬件的native inference latency不可无条件比较，需固定evaluation hardware/runtime。

P171 Bench2Dex (2026)

原作：<https://arxiv.org/abs/2609.15726>

本次PDF：<https://arxiv.org/pdf/2609.15726v1>

PDF SHA256：f70ca3ecb4dd8fc9a1acc6410a0bd4e370203ca65331b3fcc76209996fb8ed03

阅读页：1、2、3、4、5、6、7、8、10。12hands、26task-embodiment settings、tactile界面、stable success及4channel协定。

- 研究类型：一般操作 benchmark；灵巧手操作benchmark
- 领域：装配与生产作业
- 环境：IsaacLab bimanual配置；12hand morphologies、6views，无独立房屋总数。
- 任务：26task-embodiment settings，不能先乘12手型为312已完成tasks。
- 题数 / 数据：约1.3Kteleop demonstrations；4policy×26settings×4channels×50rollouts = 20,800evaluation executions。每policy每channel1,300。
- 评估方式：terminal predicate需稳持预设0.5s；LSCR记录依赖合法的阶段；success time只在成功episode量。；baseline只用RGB/关节，触觉数据支持不等于已证实tactile policy收益；触觉为几何depth proxy。
- Split / 信息条件：None/Equi/Inv对齐anchor，Full独立抽样，不假定逐case困难单调。
- 来源关系：已有hand meshes + 统一tactile registry；未对齐真实触觉hardware。
- 可复用：可借跨手型 / 触觉信号规格与稳定判分；不要把支持的传感轴当实评完成量。
- 待核 / 限制：26设置的unique semantic task去重与tactile-conditioned baseline尚不等同完成。

P172 LabUtopia (2025)

原作：<https://arxiv.org/abs/2505.22634>

本次PDF：<https://arxiv.org/pdf/2505.22634v2>

PDF SHA256：b0b27a506f9ec028871b09e93a5a3aead74e382739b65fa5092af90ab062e862

阅读页：1、3、4、5、6、7、8、9、10。LabSim/LabScene、scene与仪器来源、5levels、success协定及实验范围。

- 研究类型：一般操作 benchmark；专业场域操作benchmark
- 领域：实验室操作
- 环境：约100expert-reviewed lab scene assets，另程序填入仪器；对象类别/scene数不得相加。
- 任务：摘要30distinct tasks、结论>30，§4另称>50；5levels从atomic到mobile，但level3主要是generalization条件，并非全是新语义task。
- 题数 / 数据：各level有demo/rollout实验，本文已读段未报统一case总量；表2列10atomic及6短流程，long流程另3例。
- 评估方式：task完成后goal tolerance需维持2秒；success rate与long流程stage分开。；chemical engine由知识库+LLM推state变化，不等同第一原理化学物理。
- Split / 信息条件：novel shape/material/layout设置；全在simulation，real transfer留未来。
- 来源关系：designer scene assets、PubChem数据与IsaacSim；procedure模板需逐task核，不从约100场景×50tasks直接乘题量。
- 可复用：补实验室用途与流程；其阶层是设计/泛化混合，需用共同task粒度对齐。
- 待核 / 限制：最终task registry究竟30或>50，以及scene/instrument各精确IDs，需code版本确认。

P173 LabDex (2026)

原作：<https://arxiv.org/abs/2608.18618>

本次PDF：<https://arxiv.org/pdf/2608.18618v1>

PDF SHA256：0d4be91ff766826af94f01245c225e27a15cfb88fae60183c9393f1af17ee41c

阅读页：1、3、4、5、6、7、11、12、13。层级数据、real/sim平台、atomic/composite/workflow完整表及success。

- 研究类型：一般操作 benchmark；专业场域操作benchmark
- 领域：实验室操作
- 环境：FR3/XHand实际工作站与配对simulation；3camera views非3场景。
- 任务：概述7atomic categories、30+atomic、10+composite、1workflow；实验明列26atomic、表3九composite、1七步workflow。附录定义composite10项。
- 题数 / 数据：概述8K+demo/1M+steps；real预设每task200train、sim50；每task每model50eval trials。
- 评估方式：goal稳定2秒；atomic SR，composite/workflow全成功、各atomic成功与平均已完成步数。
- Split / 信息条件：初态在训练范围内随机；novel objects/distractors另实验，非主eval全部OOD。
- 来源关系：real teleop关键姿态映射sim，长流程可切atomic；不能把完整轨迹与各段全部当独立新样本。
- 可复用：是同SOP分不同粒度与运行平台的例子；原子step、composite、workflow必须保留父子关系。
- 待核 / 限制：30+/10+概要与26/10完整清单之差异需最终manifest确认；real/sim数据量需分开。

P174 Labimus (2026)

原作：<https://arxiv.org/abs/2606.31037>

本次PDF：<https://arxiv.org/pdf/2606.31037v2>

PDF SHA256：103d1eb5ee800d0306734bab26f9242f067cff584fb84c9929cd3ea3869e7e3a

阅读页：1、2、5、6、9、10、11、12、14。SOP→DSL、6atomic/7步流程、3评分tier、4conditions与v0验证边界。

- 研究类型：一般操作 benchmark；专业场域操作benchmark
- 领域：实验室操作
- 环境：Tianyi humanoid于fume-hood工作站；digital twin与procedural layouts，>30functional assets。
- 任务：6atomic operations+1个7step solid-weighing workflow；Tier2重评原task精度，不能算两个新操作。
- 题数 / 数据：v0只实测4atomic+1precision条件；每task-condition50episodes×3seeds=150trials；其余与整个Tier3仍未实验。
- 评估方式：success、precision pass、conditional precision among successes、weighted step progress；S-P量成功与精度差距。；SOP的mass/position门槛是这个模拟规格，不代表已完成真实实验室有效性验证。
- Split / 信息条件：100teleop demos/task，标准test布局已有分布移动，另light/texture/combined；3×4是设计矩阵，不是v0全部实测。
- 来源关系：ArtVIP资产+IsaacSim；SOP解析会排除无physical effect的纯观察/记录步，故完整科学程序仍有缺口。
- 可复用：可借SOP权重、数量精度及conditional metric；要如实标示设计完整度与实验完成度。
- 待核 / 限制：未完成tool pickup/scoop-weigh/Tier3验证；real-world validation明列未来。

P175 Pipette (2026)

原作：<https://arxiv.org/abs/2606.12936>

本次PDF：<https://arxiv.org/pdf/2606.12936v3>

PDF SHA256：72ad55814d9958242cd534f45f540f9bcd86bcd2bfbf21beaa2278e6c2bb93a3

阅读页：1、2、3、4、5、6、7、11、12、17。12tasks全表、资产库、structured task注册、augmentation验证与100episode协定。

- 研究类型：一般操作 benchmark；专业场域操作benchmark
- 领域：实验室操作
- 环境：IsaacSim/IsaacLab场景；3robots、12tools、26equipment、55consumables、9instruments为资产分量。
- 任务：12wet-lab tasks=4sample/culture、4lid/hatch、4placement；pipette-to-petri positioning不同已量测真正移液量。
- 题数 / 数据：每task30human train demos+成功筛选augmented；每model每task100eval episodes，即单数据设置1,200。
- 评估方式：依task pose/joint/geometric thresholds及持续时间判success；macro task SR。；语言parser只草拟配置，prim/threshold/evaluator仍需人验证；success-verified augmentation不是新task。
- Split / 信息条件：3models×raw/augmented条件，Panda为主但flask-shaker用AgileX；同task内固定机体比较。
- 来源关系：existing/generated USD assets、Hunyuan；replay重新渲染并同步state/action，不只是改像素。
- 可复用：可补biomedical wet-lab器材用途与scene/task登记；须区分设备操作与完成真正生物实验。
- 待核 / 限制：all-asset唯一ID与各task primitives的实际精度需原生配置；某lid为virtual button触发，不能当直接灵巧开盖。

P176 AutoBio (2025)

原作：<https://arxiv.org/abs/2505.14030>

本次PDF：<https://arxiv.org/pdf/2505.14030v3>

PDF SHA256: 987d557fe26642e96a1d4c9b3021c3d373717d4a5bc3f9eae48b5bc9de84df91

阅读页: 1、4、5、6、7、8。特殊仪器physics/render、16task与9实测subset、100episode与mixed metric。

- 研究类型: 一般操作 benchmark; 专业场域操作benchmark
- 领域: 实验室操作
- 环境: MuJoCo/Blender, single/dual-arm工作站; Aloha及UR5e不同end-effectors。
- 任务: 16定义分3difficulty levels; 实验每level3项, 共9tasks, 非全部16。
- 题数 / 数据: 9tasks各100demo=900train、792K+frames; 每task100eval episodes、3runs。
- 评估方式: 大多binary success; thermal mixer panel用relative progress, 平均表不全是success percentage。
- Split / 信息条件: 20/100demo数据规模比较; held-out初态参数泛化; render两版本共享轨迹。
- 来源关系: 实验室asset digitization; quasi-static liquid不模拟波/倒水, DexHand主要只控制thumb作简化gripper。
- 可复用: 补螺纹、旋钮、显示面板与精度规则; 光学外观逼真不能替代完整材料动力学。
- 待核 / 限制: 16task的全部IDs与模型可用support需最终code核; 不要把9task成绩外推全16。

P177 H2RBench (human transfer) (2026)

原作: <https://arxiv.org/abs/2609.24778>

本次PDF: <https://arxiv.org/pdf/2609.24778v2>

PDF SHA256: dd841fb3a72307c335d2c7268ac813f8209a448dd2242d6e49db90da7a0169d1

阅读页: 1、4、5、6、7、17。4task全表、fixed robot/human scaling、real-to-sim、90rollout及transfer metrics。

- 研究类型: 人类观测到机器人转移; 人类示范与技能转移
- 领域: 装配与生产作业
- 环境: 4个real-to-sim task环境, PolaRiS/Marble/IsaacLab, real human由第三人称multi-view录制。
- 任务: 4families: mug-to-plate、bowl stacking、donut insertion、sequential blocks-to-box。
- 题数 / 数据: robot demo budgets40/100/100/100; human上限100/300/300/300; 每method/task90randomized rollouts across3seeds。
- 评估方式: final/mean-stage SR; human增益用 Δlogit ; sim/real分别训练policy, 再以r/p/MMRV比排名。
- Split / 信息条件: fixed robot data、只增加human demos; sim与real是不同pipeline验证, 不是同一policy直接sim2real。
- 来源关系: PolaRiS、TRELLIS、GELLO、四种既有H2R方法; 与human-only预训练数据库不同。
- 可复用: 提供人类数据规模增益的受控比较, 无需靠多拿robot data制造规模优势。
- 待核 / 限制: 各human/robot pair是否一对一不应由demo预算推定; 完整IDs需原生release。

P178 RoboRecover (2026)

原作: <https://arxiv.org/abs/2609.28952>

本次PDF: <https://arxiv.org/pdf/2609.28952v1>

PDF SHA256: 63986a4660ca344bb479e10ce0aa378f0c5b8a2ce86623d7725c5474f9a51faf

阅读页: 1、3、4、5、6、13。scenario构造、replay验证、filter、train/test及RSR；未逐行重现程序。

- 研究类型: 稳健性、失败与评测品质；失败与恢复benchmark
- 领域: 居家整理与清洁
- 环境: RoboTwin和LIBERO两个既有模拟后端，透过action prefix重播取得失败状态。
- 任务: 原任务上的恢复情境；4阶段×4偏差类型只有9个有数据的测试组，不能算16个完整任务家族。
- 题数 / 数据: 2,000 recovery scenarios；两个后端各800train/200test，合计1,600/400。训练与测试task names有重叠。
- 评估方式: Overall RSR以scenario平均；9组macro另报。reference policies×5回合形成20次筛选，只留10–90%可恢复率，难度依筛选模型而定。；重播验证位置差<2mm、末5帧SSIM>0.99；策略从恢复点初始化，不能读取前缀历史。
- Split / 信息条件: 每后端800/200；同task不同scenario可跨split，不宣称语义task完全未见。
- 来源关系: RoboTwin与LIBERO原任务；natural、action-perturbed与human-constructed三种失败构造。
- 可复用: 可扩充既有task的恢复规则，但增加的是恢复cases；不自动增加生活domain或原始目标数。
- 待核 / 限制: 每个被测policy对每scenario的重复次数需核最终运行manifest；筛选成功率不可当新policy成绩。

P179 REBOOT (2026)

原作: <https://arxiv.org/abs/2609.22591>

本次PDF: <https://arxiv.org/pdf/2609.22591v1>

PDF SHA256: 1f5401dfe2a8209a83cb96780a43fbfa0938f8a743eb8285be793fbdd60cf6f5

阅读页: 1、3、4、5、6、7、8。assembly清单、精度层级、expert/recovery数据、初态与实验协定。

- 研究类型: 稳健性、失败与评测品质；精密组装与恢复benchmark
- 领域: 装配与生产作业
- 环境: 真实双臂WidowX/Trossen工作站；NIST Assembly Task Board #1。
- 任务: 表2为9对象×安装/移除=18tasks；精度、对称性及5操作phase是task属性。
- 题数 / 数据: $18 \times (60 \text{ expert} + 60 \text{ recovery}) = 2,160 \text{ demonstrations}$ 。§protocol写每task/policy20rollouts，主分析却用 $15 \times 18 \times 3 = 810$ ，保留差异。
- 评估方式: 逐task物理完成率，另按clearance、symmetry、phase及failure分析；初始对象3–6cm范围变化，goal board固定。
- Split / 信息条件: expert/recovery及模型设置受控比较；recovery demonstrations刻意重现先前观察到的policy失败。
- 来源关系: 沿用标准assembly board；9对象不是9独立工作环境。
- 可复用: 补精密插接、对称性与failure phase；组装和拆解可保留相反目标关系。
- 待核 / 限制: p7的10 connector types与表2的9对象、20与15rollouts需要release核对；failure清单是否含slip也有版本差异。

P180 SafeManip (2026)

原作: <https://arxiv.org/abs/2605.12386>

本次PDF: <https://arxiv.org/pdf/2605.12386v3>

PDF SHA256: 561f1135594da0aca29135e76d5abec42f8cac6a946d0f92c6380b1c213488fc

阅读页: 1、4、5、6、14、15。8类/10模板、ManipVerse、事件监测、90host tasks及各policy协定。

- 研究类型: 稳健性、失败与评测品质; 安全与过程规则benchmark
- 领域: 居家整理与清洁
- 环境: RoboCasa365及LIBERO; 主RoboCasa多task实验在pretraining scenes, target-scene实验另列。
- 任务: 50 RoboCasa+40 LIBERO=90 host task entries; 8 safety categories、10 LTLf templates, 只绑定适用task。
- 题数 / 数据: 每policy/task50episodes, RoboCasa单设置2,500、LIBERO单设置2,000; 不同训练variant不是新题。
- 评估方式: native SR; 每trigger violation V/N与unsafe exposure U/N, 分母是触发事件, 非episode数。恢复后monitor可重新启动。; LIBERO只有部分规则适用; 支持10模板不代表每task实测10种违规。
- Split / 信息条件: 不同host/checkpoint/target设置分开, 不能把pretrain-scene与target-scene结果直接比。
- 来源关系: 重用RoboCasa365/LIBERO并增加ManipVerse predicate与DFA监测; 和SafeVLA是不同评测规则。
- 可复用: 任务联集之外, 另存task可适用的规则; 安全规则数和语义task数各有自己的分母。
- 待核 / 限制: 数据hours与原RoboCasa365文章版本有差异; 需固定release, 不能反改原作数值。

P182 SoftVTBench (2026)

原作: <https://arxiv.org/abs/2608.18701>

本次PDF: <https://arxiv.org/pdf/2608.18701v1>

PDF SHA256: 1f353c40268ba3a98d5a2f51892e92c042f89ea87c7ccbe49c10c3ce956fe827

阅读页: 1、3、5、6、7、8、9、13。40setting、rigid twins、ID/OOD抽样、FEM evaluator与DSR。

- 研究类型: 布料 / 柔性物操作; 柔性物与触觉操作benchmark
- 领域: 跨域 / 用途未指定
- 环境: IsaacSim/IsaacLab/TacEx; 10软对象+10对应rigid twins, >50props是assets。
- 任务: 4suites各10task settings=40; 主要skill固定pick-and-place, 对象/位置变化不等于40个独立动作家族。
- 题数 / 数据: 4,000 expert demonstrations; ID每suite500=2,000episodes。OOD每soft suite/config900, 两suite共1,800; 9个单factor条件不是完整交叉乘积。
- 评估方式: Task SR另报; DSR要求完成task且全程peak deformation $\leq \tau$, τ 由稳定抓持90th percentile预先校准。FEM states仅给evaluator。
- Split / 信息条件: held-out初态; OOD light/mass/Young modulus各3级、单factor控制。以同seed/初态作对照。
- 来源关系: LIBERO风格spatial layouts与matchedrigid assets; touch rendering是模拟信号。
- 可复用: 同task加入材料保护规则的清楚范例; 不能用不动来获取低形变高分。
- 待核 / 限制: τ 是benchmark容忍度而非材料真实损坏点; continuous/binary gripper设置要控制。

P183 WireCraft (2026)

原作: <https://arxiv.org/abs/2606.18097>

本次PDF: <https://arxiv.org/pdf/2606.18097v1>

PDF SHA256: 7f2bbb231c2ff416c001d7c06e6efc0d68691404f48ed4e22afde76e1ff48e9a

阅读页: 1、2、3、4、5、6、7、23、25。三类DLO tasks、两种physics、robot/data流程、success与real对照。

- 研究类型: 布料 / 柔性物操作; 线材操作benchmark
- 领域: 装配与生产作业
- 环境: IsaacLab/IsaacSim; chain或FEM wire、UR5/Franka/Trossen三robot; 可生成配置, 无固定环境总数。
- 任务: 3families: connector insertion、clip routing、channel seating; insertion选4connector shapes, 其他代表场景仍有限。
- 题数 / 数据: script、RL、sim teleop、real数据; 已读协定未报全库固定cases。real Ethernet每metric/setting10rollouts。
- 评估方式: reach为held plug距socket $\leq 2\text{cm}$, insert另要求真正插入; channel $>80\%$ wire length入槽。; 最佳checkpoint依eval reach挑选, 属best-observed成绩; 不可假称独立validation selection。
- Split / 信息条件: 7种real/sim数据mixtures以同40K checkpoint比较; 额外65K结果不纳主公平比较。
- 来源关系: 同一3family经不同physics/embodiment重现; 不可把backend数相乘当新语义task。
- 可复用: 补线材穿引、插接与保持槽内的几何判分, 标示物理近似与场景覆盖边界。
- 待核 / 限制: 文章写接受后release, 未据此宣称目前资产已取得; 全库demo/case manifest待查。

P184 DLO-Lab (2026)

原作: <https://arxiv.org/abs/2606.04206>

本次PDF: <https://arxiv.org/pdf/2606.04206v1>

PDF SHA256: 91128b16d310632077dd23caa908483ba75b8851a77808b98368fbce1dcea0b0

阅读页: 1、2、3、4、5、6、7、18、19。10tasks、differentiable physics、算法信息条件、success appendix。

- 研究类型: 布料 / 柔性物操作; 线材操作与物理benchmark
- 领域: 装配与生产作业
- 环境: Taichi/Genesis的rod与rigid/MPM coupling; 近点kinematic抓持简化, 不是完整摩擦抓持。
- 任务: 10tasks: 8固定horizon与2长流程Letter Art/Wiring Ring; 主要实验state-based, 不全是视觉策略。
- 题数 / 数据: main optimization/RL比较3seeds、预算内最高return。附录RL每task15trajectories, GD单一optimized, CMA-ES选best checkpoint的top15。
- 评估方式: return与goal success; RL/GD/CMA-ES的信息、样本挑选与动力学梯度访问不同, 不能视为统一closed-loop protocol。
- Split / 信息条件: 主比较没有一套统一held-out visual split; VLM长流程与SmolVLA4task子集另列。
- 来源关系: 物理模块及task设计; letter/rope shapes是几何目标, 非完整日常领域。
- 可复用: 可借线材task定义, 但做all-in-one比较需要先统一观测、重置、预算与selection。
- 待核 / 限制: 需release IDs才能创建所有randomized cases; 不同algorithm native evaluation不可直接相加。

P185 RGBench (2025)

原作: <https://arxiv.org/abs/2511.06434>

本次PDF: <https://arxiv.org/pdf/2511.06434v2>

PDF SHA256: abc60e4860b3f9e166eeb0391fbf21186ec162cf7ffa413ed321ba8851b61970

阅读页: 1、2、3、4、5、6、13、15。garment来源、三primitive、real/sim pair、distance及performance benchmarking。

- 研究类型: 布料 / 柔性物操作; 柔性物模拟器评测
- 领域: 衣物与洗护
- 环境: 配对真实dual-Piper/Jaka工作站与garment simulation; direct-vertex与robot-URDF modes分开。
- 任务: 3manipulation primitives: Grasp/Fling/Fold; 9garment types的real GT比较, 主表是其中子集。
- 题数 / 数据: 6,000+garment assets = 4,000+industry + 2,000+ClothesNet; 非6,000eval tasks。已读段落未报全部paired trajectory数。
- 评估方式: 真实/模拟点云的Chamfer与Hausdorff L1, r2s/s2r分开; runtime/memory/mesh vertices另测simulation engine。
- Split / 信息条件: 人工配对动作及材料/形状参数; 主要评测simulation fidelity, 不是policy完成率。
- 来源关系: ClothesNet重用; BCM外部验证不是新独立数据源。
- 可复用: 补benchmark的模拟有效性检验; 这个评分层与policy task success有不同目的。
- 待核 / 限制: 全部paired trajectory IDs及industry assets再分发范围需release核; 不要用mesh数充题数。

P186 BiFold (2025)

原作: <https://arxiv.org/abs/2501.16458>

本次PDF: <https://arxiv.org/pdf/2501.16458v2>

PDF SHA256: f80ff8748e8d36c77c1f3decdfdf8b86e43da9909071a194e963c876c3ce56f3

阅读页: 1、3、4。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 布料 / 柔性物操作; 柔性物操作benchmark
- 领域: 衣物与洗护
- 环境: VR-Folding/CLOTH3D重渲染, SoftGym; 真实RGB-D衣物观测。
- 任务: language-guided single/bimanual folding; 新方向/位置规则与instructionparaphrase分开。
- 题数 / 数据: 近4KVRdemos分成约7Kactions、>1Kunique prompts; 90/10sample split。
- 评估方式: singlearm以meanvertexerror<0.0125m判success; bimanual另用image metrics, 不预设相同判分。
- Split / 信息条件: 先flattenedcloth; H=3history支持指令歧义, 未证明所有sample分割已按parenttrajectory群聚。
- 来源关系: VR-Folding既有demos+CLOTH3Dtextures、添加语言与actionparsing; 不是全部新physical demonstrations。
- 可复用: 补指定折法、手别与历史依赖; 语言改写不自动算新task。
- 待核 / 限制: 部分只有真实图像推action展示, 完整realautonomous成绩分母需原始实验核。

P188 DRAPER (2024)

原作: <https://arxiv.org/abs/2409.15159>

本次PDF: <https://arxiv.org/pdf/2409.15159v2>

PDF SHA256: 82f9a63cec8b5a6595ee60eff3f5f7d00bfb25d91cfd2fbe557897633d230632

阅读页: 1、4、5、6。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 布料 / 柔性物操作; 柔性物操作benchmark
- 领域: 衣物与洗护
- 环境: RealAdapt Towels改SoftGym grasp近似; Franka与UR3e对照, camera/gripper差异显式处理。
- 任务: flattening及3种foldpatterns: allcornersinward、corners-edgeinward、diagonal-cross。
- 题数 / 数据: flatteningtrain2Ktrajectories, foldtrain1K; UR3eablation每setting10trials。
- 评估方式: realflattening NC>95%且20steps内; simulation>99%/30steps; fold用IoU/proxy并承认自遮挡限制。
- Split / 信息条件: materials/size/camera/platform泛化; 各policy保持相近trainingbudget, 非直接沿用原bestscore。
- 来源关系: 既有四controller在共同deploymentframework; RealAdapt是grasping/physics规则衍生环境。
- 可复用: 这类工作正是all-in-one需借鉴的共同运行/判分控制, 而非只搬tasknames。
- 待核 / 限制: real与sim门槛不同不能混算同一SR; 多层抓取和tweezerhardware要入taskinterface。

P191 ClothesNet (2023)

原作: <https://arxiv.org/abs/2308.09987>

本次PDF: <https://arxiv.org/pdf/2308.09987v1>

PDF SHA256: bdbcb57fbe8831c335e596f96e984f928bbd504a8bdd7e0be8ec0bcb191f02c9

阅读页: 1、2、4、6、7、8。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 布料 / 柔性物操作; 柔性物数据与感知评测
- 领域: 衣物与洗护
- 环境: 约4,400garment meshes/11categories; ClothesNetM3,051可用subset, mesh不是环境。
- 任务: 分类、boundarysegmentation、keypoints三感知端点; simfold直接控制vertices, dressing/hanging多为可支持用途。
- 题数 / 数据: 3Dclassification1,984train/496testmeshes; 2D2,455meshes渲染9,820images再80/20。
- 评估方式: classificationaccuracy、segmentationmIoU、keypoint品质; simfoldnegativevertexdistance, 非完整robotgraspcontrol。
- Split / 信息条件: 2D按images切80/20, 未在已读段保证same-mesh views不跨split; 3D子集量和3051全集不同。
- 来源关系: CGTrader等mesh整理, 后被RGBench/GarmentLab等重用。
- 可复用: 补garment资产/语义标签, 清楚区分perceptionvalidation与可交互环境。
- 待核 / 限制: 资产种类不等于全部运行任务已验证; 不能把4400meshes称4400robotcases。

P192 Phys-Liquid (2025)

原作: <https://arxiv.org/abs/2511.11077>

本次PDF: <https://arxiv.org/pdf/2511.11077v1>

PDF SHA256: 827b09bcc3b8968cc32b21f332b5b31286c3784578fc04a00435cb0dd6b6700b

阅读页: 1、2、3、4、5、6、11。渲染组成、100sequences、90/10切分、reconstruction与real验证。

- 研究类型: 布料 / 柔性物操作; 液体感知benchmark
- 领域: 实验室操作
- 环境: Blender/Mantaflow的5lab scenes、20containers、8lights、5colors、6orthographic views。
- 任务: 单/多视角液体形状与体积重建, 未直接评robot pouring控制。
- 题数 / 数据: 100simulation sequences×81timesteps=8,100液体meshes; 97,200images含RGB和mask两种, 不能全叫独立RGB题。90/10sequence split。
- 评估方式: 2D IoU、3D CD/Volume IoU/F-score、dimension RMSE、scale MAPE; 部分baseline只比50张random test images。
- Split / 信息条件: 以整条temporal sequence切90/10, 避免相邻frames跨split; real 10containers验证不等于10固定interaction tasks。
- 来源关系: simulation-generated感知数据; 不同视角与mask共享同一物理状态。
- 可复用: 可作液体观测模块与量测参考; 仍需另建可运行倒液任务及物理终态判分。
- 待核 / 限制: p4文字Three scenes与Lab1–Lab5冲突, 以Table1和数据组成5为据; 完整real case IDs未报。

P193 GRIP (2025)

原作: <https://arxiv.org/abs/2503.05020>

本次PDF: <https://arxiv.org/pdf/2503.05020v2>

PDF SHA256: 04cf205cc12587bbc6680049d1eaa00b17736f5efde4581b6e2043a79bd684a5

阅读页: 1、3、4、5、6。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 布料 / 柔性物操作; 柔性物与抓取benchmark
- 领域: 跨域 / 用途未指定
- 环境: IPC平行physics; UMIsoftgripper/LEAHand; 800singleobjects, 800bimanual含400重用, union1200。
- 任务: grasp synthesis/validation与stressprediction; single/bimanual不同graspconditions。
- 题数 / 数据: 100,000grasp poses (概要); stresssubset8bowls+8mugs, 每类6train/2test; 非100K不同tasks。
- 评估方式: sixdirectiongravity稳定抓持、penetration/absolutecontactdistance、stressrelativeMAE/KL; simulationfidelityrealcheck只4objects。
- Split / 信息条件: DexGraspNet/PartNetassets重用; stress按object切, graspwholepool分割另需release核。
- 来源关系: 固定对象union和多gripper/material/randomizedpose; 全量对象与real2sim4个子集分开。
- 可复用: 可补接触稳定性与材料保护规则; candidatepose生成和有效评测case分开。
- 待核 / 限制: 50N停止closure和gravity0.1秒/方向是本protocol, 不能当通用安全标准。

P196 Deform360 (2026)

原作: <https://arxiv.org/abs/2607.05390>

本次PDF: <https://arxiv.org/pdf/2607.05390v1>

PDF SHA256: 3f23966cb31f3614a8b27aba9ae558ef4684e812dd86ef6cd072d1788c6faf95

阅读页: 1、4、5、6、8、9、10、11、12、13、27。198objects、capture/重建、1980episodes、多层generalization及2D/3D metrics。

- 研究类型: 布料 / 柔性物操作; 柔性物数据与世界模型benchmark
- 领域: 衣物与洗护
- 环境: 一套41camera环绕capture rig; 41视角不是41环境。人类持UMI tactile grippers操作。
- 任务: 3D重建/重模拟、future prediction、episode及object generalization; 198objects不是198语义task。
- 题数 / 数据: 198对象=28线材+98片材+72体积柔性物; 每对象5single+5bimanual, 共1,980episodes。清理后74,850videos、23.3M多视角frames。
- 评估方式: 3D Chamfer/track MSE; 2D PSNR/SSIM/LPIPS; 接触accuracy/F1使用36个同步过滤视角。
- Split / 信息条件: 分episode内future frames、同对象未见episodes、未见objects三种; 不同方法适用不同设置, 不能共用一个排行分母。
- 来源关系: 3DGS+tracking+normal-pressure tactile重建; 收集刻意避免slip, 未提供完整shear/slip涵盖。
- 可复用: 补材料与动力学覆盖, 亦示范为何要将episode、view视频、frame和hours各自计数。
- 待核 / 限制: 各generalization split的精确train/test ID数需release protocol; 未宣称所有198对象已完成real-robot closed-loop task验证。

P197 EgoSim / MultiEgoView (2025)

原作: <https://arxiv.org/abs/2502.18373>

本次PDF: <https://arxiv.org/pdf/2502.18373v1>

PDF SHA256: db15f931833027b80e416c0bdb47bd3c7695ef3cce6733988110484295f4f7d2

阅读页: 1、2、5、6、7。数据构成、四场景、body-camera位置、35活动、切分与body pose metrics。

- 研究类型: 人类视频与动作数据; 身体摄影机数据与感知benchmark
- 领域: 跨域 / 用途未指定
- 环境: 24locations分布于4virtual scenes; real数据在其中一个扫描courtyard收集。6个body cameras是视角。
- 任务: 主要实验为全身3D pose estimation; real演出35种BABEL活动, 非35robot运行目标。
- 题数 / 数据: synthetic 119.4行为hours/77.4M六视角images; real约5h、13participants。5秒segments数未报。
- 评估方式: global/PA MPJPE、translation/rotation/joint-angle error、jerk。
- Split / 信息条件: synthetic依BABEL60/20/20; real random80/20与cross-participant10/3另列。
- 来源关系: AMASS/BABEL/BEDLAM motion/labels/assets; 同一motion多bodyviews与多场景重渲染, 非独立动作数据。
- 可复用: 支持头、腰、手腕、膝摄影机的感知来源; 加入视角泛化, 不能当物理task completion。

- 待核 / 限制：精确train/test片段IDs、重渲染motion去重需manifest；动作辨识/定位虽可支持，主实验未全评。

P198 TACO (2024)

原作：<https://arxiv.org/abs/2401.08399>

本次PDF：<https://arxiv.org/pdf/2401.08399v2>

PDF SHA256：2cd9fef96e133851d367c485aad1578b4979baef4d9b57037a1a246476735efd

阅读页：1、2、3、4、5、6、7、8。capture/annotation、131triplets、数据与generalization splits、三benchmark与metrics。

- 研究类型：人类视频与动作数据；双手工具交互理解与预测benchmark
- 领域：跨域 / 用途未指定
- 环境：12third-person+1lego相机的capture工作站；作者明列缺乏scene diversity。
- 任务：3研究端点：compositional action recognition、motion forecasting、cooperative grasp synthesis；15actions、131tool-action-object triplets。
- 题数 / 数据：约2.5K motion sequences、5.2M多视角frames；196对象meshes/20categories/14participants。不是5.2M独立交互题。
- 评估方式：recognition Top1/5；forecast10frames→10frames的joint/translation/rotation error；grasp penetration/contact/collision/FID，非运行成功率。
- Split / 信息条件：train:S1:S2:S3:S4=4:1:1:1.5:2.5，分已见、geometry、interaction、compound；另60/40sequence的annotation验证不可混成主split。
- 来源关系：自己的multi-view capture；DexYCB交叉数据验证；marker removal使用inpainting。
- 可复用：把动作、对象组合和研究端点分层记录，支持工具交互的组合泛化设计。
- 待核 / 限制：完整各split精确sequence数需manifest；不含articulated objects，不能外推完整工具环境。

P200 SABER (2026)

原作：<https://arxiv.org/abs/2605.09613>

本次PDF：<https://arxiv.org/pdf/2605.09613v1>

PDF SHA256：e4556b7aadaed076ac2792ec2c15b91853acad3f5eac7403898badc1396e8f98

阅读页：1、2、3、5、6、9、10、11、12、13。零售数据streams、native/retarget区别、训练mixtures、RoboBenchMart10tasks与100rollouts。

- 研究类型：人类视频与动作数据；零售示范数据与技能转移
- 领域：包装、仓储与物流、零售与购物
- 环境：多真实超市的头戴/360°视频；camera capture无robot。精确店面数未报；下游是RoboBenchMart模拟。
- 任务：视频列12内核retail活动；下游10tasks=fridge2、board-to-board3、floor2、basket3，主要搬放与开关。
- 题数 / 数据：100+h视频导出44.8Ksupervision samples=25Klatent+18.6Khand+1.2Kbody，streams共享capture。每task100eval rollouts。
- 评估方式：success同时要求joint velocity<0.2、target到位、未扰动非target；非fridge tasks另报0/√3/2/3/1进度。

- Split / 信息条件：下游训练含2.5Ktask-aligned RoboBenchMart demos + 4.8Krobot anchor；不是human-only零样本转移。
- 来源关系：三stream由相同人类capture生成，RoboBenchMart为下游父benchmark；不要重新计一次新10task。
- 可复用：补商店补货/拿取/购物用途；可转移数据与可运行环境需要分别取得。
- 待核 / 限制：不同stream的episode交集及各超市scene IDs未报；checkpoint选择与held-out sampling需code核。

P201 EgoSAT (2026)

原作：<https://arxiv.org/abs/2606.24422>

本次PDF：<https://arxiv.org/pdf/2606.24422v1>

PDF SHA256：3cdd4d6866e119e6133a58a10ad4eff1ec3dd77fc61f49704b61835d9c312199

阅读页：1、3、9、10、11、12、13、14、22、28。interaction curation、stream prefix、六题型、QA数及confidence/answerability分析。

- 研究类型：理解、推理与规划；串流理解与预测benchmark
- 领域：居家整理与清洁
- 环境：Ego4D的56scenario labels；不是56有资产的机器人环境。
- 任务：present narration/state switch、short/multi-step anticipation、short/multi-step retrieval，共6题型。
- 题数 / 数据：1,997video sessions、约165h、约4,800QA；同一query的MC与open-ended版本不算独立证据。
- 评估方式：MCQ accuracy、interaction precision/recall、state switch两端都正确；confidence slope与predictable/unpredictable分组。
- Split / 信息条件：每query严格截到当下prefix；online cache方法与每题prefix重处理成本不同；SFT cross-scenario另比较。
- 来源关系：Ego4D原视频/interaction labels加新queries；不重新计成独立165h视频。
- 可复用：预测题需记可预测性与合法观测截止时间，不能让未来frame泄漏。
- 待核 / 限制：约4,800的精确query及SFT/evaluation split IDs待release核；future answer多解性不能当单纯模型错误。

P202 EgoMonth (2026)

原作：<https://arxiv.org/abs/2608.13113>

本次PDF：<https://arxiv.org/pdf/2608.13113v1>

PDF SHA256：6747ddc4c6f9303ea3e7ed2e427b1e8707235e60cd4cf05e45abfd4d13cdffc1

阅读页：1、4、5、6、7、19。收集/筛选、14题型全表、738clips/301h、人工QA、macro/micro与sampling。

- 研究类型：理解、推理与规划；长期记忆视频benchmark
- 领域：居家整理与清洁、餐饮与烹饪、办公与教育、零售与购物、交通移动与车辆维修、休闲与运动
- 环境：20participants各20–120天生活纪录；室内外场景无可去重实体场所总数。
- 任务：14QA types、3认知层级；6activity用途类别。层级是作者设计，不是已校准的机器人难度。
- 题数 / 数据：738clips、18,072minutes≈301h、1,443四选一人工QA；原始30人400+h筛到20人300+h。
- 评估方式：14类macro平均与全部QA micro；直接答案比对，无LLM judge。人类评测3annotators， κ 0.78。

- Split / 信息条件: benchmark zero-shot evaluation, 非training dataset; 固定sampling但model frame上限不同。
- 来源关系: 新收集长期生活视频, 与EgoLife是不同capture来源; 一人多日仍属群聚数据。
- 可复用: 扩到长期生活记忆与跨日状态, 预算应固定并用participant群聚估计不确定性。
- 待核 / 限制: 跨日task所需实际视觉覆盖与每model frame cap要并列; 人格推论题不等于客观人格ground truth。

P203 EGOSTREAM (2026)

原作: <https://arxiv.org/abs/2605.31557>

本次PDF: <https://arxiv.org/pdf/2605.31557v2>

PDF SHA256: 2b7fad2f7b3b003fe66a26ce10fe8f4c0b2950ae9a0a072a3f9215790a59ef17

阅读页: 1、3、4、5、6、8。五父来源、人工filter、AVW与7recall regimes、8528扩充和stream protocol。

- 研究类型: 理解、推理与规划; 串流记忆benchmark
- 领域: 居家整理与清洁
- 环境: Ego4D VQA、EgoLife、EgoTempo、Multi-Hop EgoQA、HD-EPIC五来源; 无添加可运行场景。
- 任务: 7记忆题型: detail/spatial/temporal/event/social/causal/prospective; 7recall时间区间另是条件。
- 题数 / 数据: 2,634candidate→2,335human-verified→2,250final QA; 依Answer Validity Window扩成8,528question-recall evaluations。
- 评估方式: 4-way accuracy, 依语义/recall报; 每frame processing time及受限memory, 固定backbone比较不同memory managers。
- Split / 信息条件: query到时才揭露; memory construction须query-agnostic, 不能无界保存原frames再重读; 不是所有题都可乘7。
- 来源关系: 五来源QA与evidence重用/改写; baseQA与多recall conditions有父子关系。
- 可复用: 示范正当扩题: 保留base question, 添加不同合法历史条件, 并明示扩充规则和依赖。
- 待核 / 限制: 无global scene union; 同一QA的多recall测例需群聚统计, 不能算8528独立语义问题。

P204 S-EMBER (2026)

原作: <https://arxiv.org/abs/2607.02689>

本次PDF: <https://arxiv.org/pdf/2607.02689v2>

PDF SHA256: a19dd911977b7b7ad2651673df90d5ea20fbd44471297b335afdb6e3a0884e04

阅读页: 1、3、4、5、6、7、8、14。新capture、2090scenario labels/33活动、9448QA、多长度答案、joint grounding与judge验证。

- 研究类型: 理解、推理与规划; 串流记忆与证据定位benchmark
- 领域: 居家整理与清洁、餐饮与烹饪、零售与购物
- 环境: 613用户Ray-Ban Meta capture; 2,090fine-grained scenario labels合并33activity categories, 非2090实体scene资产。
- 任务: 8memory QA categories; answer generation与temporal grounding两endpoint。
- 题数 / 数据: 3,141videos、388h、9,448QA; 每题三种verbosity参考答案, 不把答案条数当三倍题数。另5-way MC版本。

- 评估方式：free-form overall/clean accuracy用judge；MC exact match；temporal mIoU/Recall@1；GQ@τ要求答对且定位正确。judge另600正负pair验证。
- Split / 信息条件：visual-only且prefix cutoff；open models固定128frames、closed native limits另列，非完全同观测预算。
- 来源关系：新生活capture；questions由当下trigger往回问；视频scenario标签不提供可运行robot state。
- 可复用：我们可采用答案与证据的联合判分，但不能让多verbosity或MC改写虚增独立题。
- 待核 / 限制：全部实体场所数未报；GQ判分可靠性取决judge与grounding，需保留分项成绩。

P205 CapMem (2026)

原作：<https://arxiv.org/abs/2609.17688>

本次PDF：<https://arxiv.org/pdf/2609.17688v1>

PDF SHA256: f65b30af25bbaa68d3825316d901fac09df58f2fe57b133428750addc1aeec4e

阅读页：1、3、4、5、8、16、18、22。75videos七来源、4用途/16scenario、QA filter、CleanQA、frame-aligned controls与部分API评测。

- 研究类型：理解、推理与规划；caption记忆benchmark
- 领域：居家整理与清洁、宠物照护与动物活动
- 环境：4application domains、16scenario labels、75公共ego videos；无实体scene union。
- 任务：CleanQA/DirectVideoQA/CaptionQA是同题三种信息条件；50question templates与5diagnostic分析维度不等于50task goals。
- 题数 / 数据：2,109candidate→1,000final MCQs、33.7h；Ego4D占56videos/742QA。Gemini VideoQA只跑786题，其他主设置1,000。
- 评估方式：MC accuracy、token/runtime成本、visual tags/evidence位置/视频长度分项；CleanQA 15–35%gate是方法筛选规则。
- Split / 信息条件：无额外train；full-caption1fps看全片而direct有frame cap，另6Qwen frame-aligned及cross-captioner受控实验。
- 来源关系：Ego4D/EgoLife/EgoPet/EPIC/HoloAssist/ENIGMA-51/CASTLE2024；只release annotations/metadata，不重发原视频。
- 可复用：可借相同问题在不同记忆表示下的受控比较；先对齐看过的frames再比较caption收益。
- 待核 / 限制：作者标明只涵部分wearable用途；blindgate低于/高于门槛的解释需谨慎，不能直接证明污染。

P206 EmbodiedMemory-Bench (2026)

原作：<https://arxiv.org/abs/2609.28236>

本次PDF：<https://arxiv.org/pdf/2609.28236v1>

PDF SHA256: 14adce97c24c0e4080ec7f707206f2dcc6ff9155bacf63b0d6cf84287eba4580

阅读页：1、3、4、5、6、15、18、27。四family、AI2THOR/ProcTHOR场景生成、2554验证episodes、sim success及source/split设计。

- 研究类型：理解、推理与规划；可运行具身记忆benchmark
- 领域：居家整理与清洁

- 环境：1,118source scenes；AI2-THOR单房间组成virtualhome并保存状态、ProcTHOR multi-room筛选。不是1118全部新建独立house。
- 任务：4families：Passive Observation、Dynamic Tracking、Interaction Failure、Experience Generalization；125visible object types/83target/33receptacle是资产类别。
- 题数 / 数据：2,554episodes = 1,036+1,052+263+203；143候选被排除。四history介入条件同用800episodes而非添加3200unique basecases。
- 评估方式：运行action到sim目标终态的SR，四family等权macro避免1036/1052大类垄断；另history介入成对比较。
- Split / 信息条件：训练与eval scenes/trajectories分离，parent trajectories先split再展开turns；target task在history之后才给。
- 来源关系：AI2-THOR/ProcTHOR、PDDL distractor、LLM生成experience后必须ground与重播验证；这是episode而非2554独立语义families。
- 可复用：和我们『既有环境+新任务/规则』非常接近；差异要用更广用途与来源联集证明，不能只比episode数。
- 待核 / 限制：scene IDs跨host重用与完整episode manifest需原生release核；同history多condition需保留pair ID。

P207 EgoCoT-Bench (2026)

原作：<https://arxiv.org/abs/2605.19559>

本次PDF：<https://arxiv.org/pdf/2605.19559v1>

PDF SHA256：98ac34ca6c5e5e85367bbc76844e70d30939b29b4c58188ffdbe431af5e9b237

阅读页：1、3、4、5、6。来源/scene graph审核、12subtasks全表、3172QA、SCR与judge验证。

- 研究类型：理解、推理与规划；视频推理与证据benchmark
- 领域：居家整理与清洁、餐饮与烹饪、装配与生产作业
- 环境：Ego4D、EPIC、MECCANO、Charades-Ego、HD-EPIC及自录；351clips不是351独立环境。
- 任务：4研究groups/12subtasks，从object grounding到state回顾、预测、progress与goal tracking。
- 题数 / 数据：3,172四选一QA、351video clips；参考reasoning与时空证据同属一题。
- 评估方式：答案exact match；Qwen-Max judge给reasoning0–5。SCR = 答对但reasoning≤2的比例，分母仅答对题。；judge与人类在2,800responses比较QWK/一致率；它衡量输出解释与证据一致，不证明模型内部思考忠实。
- Split / 信息条件：主文是benchmark evaluation；精确train/dev manifest未列。MCQ、rationale与evidence非不同题库。
- 来源关系：父视频及添加人工修订STSG；五公共父库与自录不代表六份互不重叠世界经验。
- 可复用：可加入答案与证据一致性的评测；不要把rationale judge直接叫物理成功验证。
- 待核 / 限制：Table1写Open/Close而metrics说全部四选一；以主实验协定为准并保留差异。

P208 DYAD (2026)

原作：<https://arxiv.org/abs/2609.09023>

本次PDF：<https://arxiv.org/pdf/2609.09023v1>

PDF SHA256：698811f9c48df7ba4dfef3eab17ed4c8336186b171cbc82e4ea597e06349fdf0

阅读页：1、2、3、4、5、6。单helper政策、三reference tasks、原始/有效/eligible counts、participant splits与oracle限制。

- 研究类型：辅助与协作；协作与协助预测benchmark
- 领域：装配与生产作业
- 环境：同一gearbox组装工作站、20performers与同一trainedhelper；6pilot sessions不纳正式20。
- 任务：3endpoint：causal8步辨识、介入前verbal/physical mode预测、oracle context下回应生成；不是完整robot助手。
- 题数 / 数据：20sessions/5h58m、528step intervals、611requests、851有效assistance events；mode eligible829, response376=120dev+256test。
- 评估方式：mode macro-F1/AUPRC, participant bootstrap；step segmentF1/edit/mAP/MoF；response rubric judge+BERTScore。
- Split / 信息条件：mode participant五fold每fold12/4/4、3秒观测到onset前0.5秒；step5val/15test；response120/256。当次trigger禁止入model。
- 来源关系：human-human assistance demonstration；851events中有效outcome极不平衡，作者不测outcome prediction。
- 可复用：可加协作规则，但需另外建need detection negatives及可运行robot feasibility。
- 待核 / 限制：没有non-intervention negatives，不能宣称会判断何时需要帮忙；mode是一位helper政策不是普世最佳协助。

P209 HUI360 (2026)

原作：<https://arxiv.org/abs/2608.11051>

本次PDF：<https://arxiv.org/pdf/2608.11051v1>

PDF SHA256：9b4575648e06d38fb681f06af41179b35afb217270d1526216532130f6c3026f

阅读页：1、3、4、5、6、8。9场所/30setup、原始与裁切时数、SSUP重标、physical interaction定义及anticipation协定。

- 研究类型：辅助与协作；人机交互预测benchmark
- 领域：公共场馆与服务
- 环境：HUI360有9真实场所、30robot placements/setups；SSUP-A两public-space field sessions另列。
- 任务：预测是否将发生与平台的物理interaction；不是广义社交意图。不同anticipation horizons重评同tracks。
- 题数 / 数据：HUI360 68recordings/71.3h原始→1,937episodes/11.3h有效人像片段，4,310tracks含375interaction。SSUP-A 27,698tracks为重标旧数据。
- 评估方式：AUROC主、F1/AP另报；跨location、跨dataset、0.33–2秒horizons及input-frequency robustness。
- Split / 信息条件：HUI360 locations1–7train、8–9test；SSUP第一/二场次train/test。近onset窗口排除，negative以最近距离proxy挑选。
- 来源关系：新HUI360+既有SSUP-HRI重标；1Mannotations不是1M独立interaction。
- 可复用：扩到公共空间交互预测，场地与摆位可独立记录；自动contact proxy应保留人工修正。
- 待核 / 限制：本文normalization用全HUI360均值/标准差，若严格train-only协定需修正；最终eligible test窗口量需manifest。

P210 RoCo Challenge (2026)

原作：<https://arxiv.org/abs/2603.15469>

本次PDF：<https://arxiv.org/pdf/2603.15469v1>

PDF SHA256: 1b91dade9b97b3cbbde4f382166932d5d38a29b4038328808755568fc5b47c29

阅读页: 1、3、4、5、6、12。三scenario、sim/real差异、两种demo、single model与weighted score。

- 研究类型: 辅助与协作; 协作组装benchmark
- 领域: 装配与生产作业
- 环境: IsaacSim工作站与Galaxea R1 Lite实机; simulation人类参与由初始化partial state模拟。
- 任务: 1gearbox workflow的3scenario: 从零组装、partial state续作、error recovery。real只3planet gears, sim含sun/ring更多parts。
- 题数 / 数据: sim>300automatically generated demos, real另>300teleop demos; 精确官方eval回合数在已读protocol未报。
- 评估方式: single model需处理三scenario; assembled-parts/recovery分数以0.4/0.2/0.4加权。
- Split / 信息条件: 私有工作站上统一random lighting/texture/colors; real track任务规格有缩减, 不能视为完全同题sim-real transfer。
- 来源关系: 同gearbox assembly的起始状态/恢复规则扩充; 与人类实时协作要分开。
- 可复用: 可借从零/续作/修复三类规则; 不同backend的task目标改动要版本化。
- 待核 / 限制: 完整task/case IDs及官方评测分母待competition config; 结论的300+泛称不能覆盖两份不同demo。

P211 AssemblyGrid (2026)

原作: <https://arxiv.org/abs/2609.16075>

本次PDF: <https://arxiv.org/pdf/2609.16075v1>

PDF SHA256: 8661b2c5550168645f05f00d371e18fbdb54c431355ebf45b56a117ba5934f2d

阅读页: 1、10、11、12、13、14、15、16、17、18、19、20、21、22、54、56。decentralized信息、9scenario全表、instance/seed区分、production metrics及held-out protocol; 未逐式读57页全部附录。

- 研究类型: 辅助与协作; 多机器人生产调度benchmark
- 领域: 装配与生产作业
- 环境: 抽象grid生产模拟, geometry/reach/workspace限制; 不模拟robot-specific接触physics。
- 任务: Flow/Coalition/Concurrency三workload families×easy/medium/hard=9official scenarios, 程度为family内配置, 不保证每policy单调。
- 题数 / 数据: 每scenario50held-out instances; 3algorithms×9scenarios×10trainingseeds=270training runs, 每个final checkpoint同50test instances。
- 评估方式: 主要delivered products/throughput, admitted completion与offered-demand fulfilment分母不同; 候选admission/coalition/blocking为diagnostics。; finite-batch timeout的makespan未定, 不把未完成当正常完成时间; RL与nonlearning的不确定性分别按trainingseeds与instances。
- Split / 信息条件: train/val/finaltest generationseeds分离, 主测unseen realizations而非新topology; finalcheckpoint, 无事后best选择。
- 来源关系: local support-fraction cue为合法interface; centralized privileged reference与decentralizedpolicy分组。
- 可复用: 补生产规划与协作资源约束; 可借明确区分instance、executionseed、trainingseed的计数方式。
- 待核 / 限制: robot-specificphysics、newtopology、failure/communication interventions明列未纳v1实验; 不要称完整工厂机器人控制。

P212 ARB4WM (2026)

原作: <https://arxiv.org/abs/2606.16605>

本次PDF: <https://arxiv.org/pdf/2606.16605v1>

PDF SHA256: 7164d9a676e577b14d43e71e8cc37115faf37eba06430b824a84b05822e11b4b

阅读页: 1、2、8、9、12。20tasks完整列表、5objectives、20eval runs、nAUC真实分母与defense metrics。

- 研究类型: 世界模型与预测表示; 世界模型与鲁棒性benchmark
- 领域: 跨域 / 用途未指定
- 环境: 10MetaWorld+10DMC任务, 作者称industrial proxy; 未提供真实industrial scene。
- 任务: 20host tasks在5white-box objectives、各optimizer/temporal exposure下重评。
- 题数 / 数据: 每setting20evaluation runs, seed20–39; 4Dreamer-family agents, 不能把agent数乘入独立题库。
- 评估方式: MetaWorld SR、DMC return; nAUC公式除benchmark常数1或1000, 不是各policy clean score, 虽文中称clean-normalized。defense recovery另用clean-attack分母。
- Split / 信息条件: 只在eval perturb pixels, 不改dynamics/reward/parameters; cross-model transfer只是另subsetDMC Reacher Easy。
- 来源关系: MetaWorld/DMC task复用加新攻击protocol; hosttask和规则variants分开。
- 可复用: 可扩充传感失真规则, 固定合法attacker access和预算; 不要把视觉攻击当材料或安全有效性验证。
- 待核 / 限制: all-setting unique episode IDs未报; 攻击强度不是可跨任务直接相加的难度刻度。

P214 COIN (interactive) (2026)

原作: <https://arxiv.org/abs/2604.16886>

本次PDF: <https://arxiv.org/pdf/2604.16886v1>

PDF SHA256: 0e8f4586f184eb25ae2bd4bc596b3385b4e27319784a61dfa8c67bd98ba07f3c

阅读页: 1、4、5、6、7、15。90tasks分层、ManiSkill3规格、1000demo、六metrics、10trials及不同model inputs。

- 研究类型: 导航与家务运行; 交互推理与操作benchmark
- 领域: 跨域 / 用途未指定
- 环境: ManiSkill3桌面Panda, PartNet/Sketchfab等assets; 3reasoning domains是能力类别, 不是生活用途。
- 任务: 20Primitive+20Composition+50interactive reasoning=90task definitions; 含partialobservability下交互取得信息。
- 题数 / 数据: Primitive每task50demo=1,000trajectories、5views; 主SR平均10trials, views不把traj变五倍。
- 评估方式: SR/类别SR、VQA、trajectory/gripper稳定、Composition/Primitive success ratio; 六metrics分母不同。
- Split / 信息条件: VLA在Primitive fine-tune、validationSR选checkpoint; model用1/3views不同, Voxposer有GObjectlist, 需保留信息条件。
- 来源关系: ManiSkill3资产与task扩充; expertVQA看示范不等于运行时在线推理成绩。
- 可复用: 可借Primitive→composition→interactivegoal的父子关系; 我们的规模优势需超出这种单桌面推理范围。
- 待核 / 限制: 人类只10task代表subset、3people×2trials; 不可把40%sim/100%real当全50task人类上限。

P216 HAP (2026)

原作: <https://arxiv.org/abs/2609.18548>

本次PDF: <https://arxiv.org/pdf/2609.18548v1>

PDF SHA256: 0cbfc4268916f842b362862865080ed9f76fbefdb51c290d6e567b9e03abf8a

阅读页: 1、2、5、6。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 未来动作 / 交互预测; 动作与轨迹预测
- 领域: 跨域 / 用途未指定
- 环境: Bottle12RGB-D recordings sessions, clutter/reach变化; camera估计作headmotion proxy。
- 任务: 预测6DoF headmotion; EgoPAT3Dv2父benchmark另列。
- 题数 / 数据: Bottle382clips, sessions10train/1val/1test; 单一test session不是广泛场地泛化证明。
- 评估方式: translation ADE/FDE(mm)、rotation ADE/FDE(degrees); DA3/ORB3感知backend敏感性另测。
- Split / 信息条件: session disjoint; 各模型同window/horizon/smoothed pose。
- 来源关系: 新Bottle capture + EgoPAT3D、pseudo3D head targets。
- 可复用: 补视角移动/遮挡规则与active perception预测, 而非只评手部。
- 待核 / 限制: camera pose proxy不等于独立mocap GT; dataset完整release ID待核。

P217 TRS + RVG (2026)

原作: <https://arxiv.org/abs/2609.13293>

本次PDF: <https://arxiv.org/pdf/2609.13293v1>

PDF SHA256: 13aaaf69bfbfa5c99ef154700c56eb0f34385c23b6bb5503a53965250a5e7e6a

阅读页: 1、2、6、7。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 稳健性、失败与评测品质; 稳健性与分布外评测
- 领域: 餐饮与烹饪
- 环境: EGTEA/EPIC原数据; 破坏TSN feature tokens, 不是重新收集真实sensor failures。
- 任务: action anticipation下六main corruptions; 额外standalone blur是severity transfer。
- 题数 / 数据: EGTEA processed split10,321clips; EK100自订training videos90/10切, 不可和官方leaderboard直接比。
- 评估方式: joint verb+noun Top1、平均corrupted accuracy及Relative Robustness=AvgC/clean。
- Split / 信息条件: compatibility graph只train labels、 λ EGTEA val选; EK pipeline125verbs/352nouns不同官方97/300。
- 来源关系: 既有视频加新corruption protocol, 不添加生活domains或原始action库。
- 可复用: 可以添加robustness规则cases并保持原task引用, 清楚标记feature-level扰动。
- 待核 / 限制: 本文自订index space与official split不同; clean低时RR可能误导, 须同报absolute accuracy。

P222 Uni-Hand (2025)

原作: <https://arxiv.org/abs/2511.12878>

本次PDF: <https://arxiv.org/pdf/2511.12878v4>

PDF SHA256: f71d9925369c1a5feb6fe1ecf4b409c2c11ae40edf1f0c8c7d568d12a00417ca

阅读页: 1、9、10。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 未来动作 / 交互预测; 动作与轨迹预测
- 领域: 跨域 / 用途未指定
- 环境: 新CABH头戴RGB-D与HAT固定ALOHAcamera; 既有五publicdatasets另列。
- 任务: CABH3humanHOLtasks; HAT5robottransfertasks, 5个不是所有publicdatasetssemanticunion。
- 题数 / 数据: CABH1,200videos; HAT2,800handvideos (400/400/400/800/800), 每task10physicaltrials。
- 评估方式: hand/headtrajectory与contactstate预测; HAT按完整predictedtrajectory运行。
- Split / 信息条件: HAT只取第一帧产生完整motion, 是look-then-move而非同等closed-loop视觉policy。
- 来源关系: CABH/HAT新数据; EgoPAT3D/H2O/HOT3D/Ego4D/EPIC重用。
- 可复用: 补humanmotion到robotinterface, 但必须标明executionmode与观测限制。
- 待核 / 限制: CABH精确split与全部frameID仍需manifest; 依据单帧的open-looptransfer不可当通用在线成功率。

P224 EMPIRE (2026)

原作: <https://arxiv.org/abs/2608.22449>

本次PDF: <https://arxiv.org/pdf/2608.22449v1>

PDF SHA256: e49c2bea71f4e0913128fd930c8536111ea26aa22782f634ac9ce7497f14aa03

阅读页: 1、2、4、5、6。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 未来动作 / 交互预测; 动作与轨迹预测
- 领域: 跨域 / 用途未指定
- 环境: EgoDex原recordings, 没有添加111独立物理场景。
- 任务: 111tasklabels下bimanual5秒motionforecast + explicitplans; 原作194只保留subset。
- 题数 / 数据: 650,910trainwindows、6,836testwindows; non-overlapping5swindows, parentepisodes先分。
- 评估方式: best-of8按MPJPE选trajectory再算wrist/fingerrelative; 不是单次控制policy。
- Split / 信息条件: 原EgoDexofficialsplit; 85unseentasks仅Part1ablations, fulltrain111tasks都seen。
- 来源关系: EgoDex→EMPIRE650K, Qwencaption/plan + MANOfitting; 100caseaudit84%usable, 未全部人工审核。
- 可复用: 可借规划界面与预测粒度, 同时保留生成标签品质及best-ofK预算。
- 待核 / 限制: difficulty按baselineMPJPE分43/49/19, 仅模型相对难度; 不得当通用easy/medium/hard真值。

P225 Exo2EgoPose (2026)

原作：<https://arxiv.org/abs/2607.15890>

本次PDF：<https://arxiv.org/pdf/2607.15890v2>

PDF SHA256：de7fddd04e06fecbb6bf89e299b81ad55b49b90cbbb5d57ec0856fd8cd1a5c43

阅读页：1、2、5、6。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：未来动作 / 交互预测；动作与轨迹预测
- 领域：装配与生产作业
- 环境：AssemblyHands/EgoExo4D/EgoMe原场景，exovideo供训练supervision。
- 任务：vision-language3Dhandposeforecast；EgoMe-pose为添加derivedbenchmark。
- 题数 / 数据：AssemblyHands6120/355/355；EgoExo10869/1540/1540；EgoMe6067/1344/2648 train/val/test episodes。
- 评估方式：root-alignedMPJPE/MPJVE(mm)，不同source15/30fps。
- Split / 信息条件：EgoMe只保留correctimitation，>95%frames有效；generatedpose和depth不是全部mocapGT。
- 来源关系：Assembly101→AssemblyHands及EgoMe新pose标注；父场景不能再加。
- 可复用：补exo示范监督与finefingerprediction，但不混成robotphysicalexecution。
- 待核 / 限制：root-alignederror不检验世界坐标全局定位；episode数不可代替独立sourceclip数。

P226 EgoTraj (2026)

原作：<https://arxiv.org/abs/2605.19004>

本次PDF：<https://arxiv.org/pdf/2605.19004v1>

PDF SHA256：c6789c21ac3754c8b4f240cc614ab7712284681a8b02fa63e9ec08d9dbcfea82

阅读页：1、2、3、4、5、6、7。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：未来动作 / 交互预测；动作与轨迹预测
- 领域：交通移动与车辆维修
- 环境：7outdoorwaypoints/21origin-destinationpairs；waypoint和route不等于21独立地理环境。
- 任务：wearer6DoFtrajectoryprediction，gaze/sceneannotations作modalities。
- 题数 / 数据：75participants各1session，10.7h/1.15Mframes；38,606annotatedframes非相同数量testcases。
- 评估方式：ADE/FDE与headrotationL1error；route多样性另用DTW。
- Split / 信息条件：held-outsessions；地理场域和路径可能重用，不等于unseencitygeneralization。
- 来源关系：新QuestProcapture；VLMsemanticlabels与真实trajectory/pose区分。
- 可复用：扩到户外行走的预测用途；属人类导航数据，不是机器人交互模拟房屋。
- 待核 / 限制：exactheld-outwindowcount和完整protocol需要release核；不将1.15Mframes当predictionquestions。

P228 SFHand / EgoHaFL (2025)

原作: <https://arxiv.org/abs/2511.18127>

本次PDF: <https://arxiv.org/pdf/2511.18127v2>

PDF SHA256: 523777e21488e904c826eaab83130b80cffb36f33c1de90506f75949869bee9d

阅读页: 1、2、3、4、5、6。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 未来动作 / 交互预测; 动作与轨迹预测
- 领域: 跨域 / 用途未指定
- 环境: Ego4D→EgoHOD/EgoVid衍生视频; worldcoordinates由估计camera/hand取得。
- 任务: streaming3Dhandstateforecast (type/box/pose/globaltrajectory); Kitchen/Adroit只做下游representationtransfer。
- 题数 / 数据: 247K三秒clips=242Ktrain/5Ktest, 3.95Mhandannotations; 不是3.95M独立taskcases。
- 评估方式: ADE/FDE、wristalignedJPE/PA-JPE、2Dboxrecall/FPS; SFHand*使用GTstate oracle另列。
- Split / 信息条件: test时间autoregression吃前一步预测; 普通SFHand不可和oracle58.8FPS/accuracy混成同设置。
- 来源关系: Ego4D/EgoHOD/EgoVid共同视频, 再用HaMeR生成pose。
- 可复用: 补streaming预测规则及teacher-forcing/oracle边界, sourceclip/traininglabel分开。
- 待核 / 限制: paper『4M Ego4D videos』实为衍生片段层级, 不能当4M原始长视频; scene/video-disjoint split需核。

P229 UniEgoMotion (2025)

原作: <https://arxiv.org/abs/2508.01126>

本次PDF: <https://arxiv.org/pdf/2508.01126v2>

PDF SHA256: 841c3f6b142a703b951a3bbf3b4b85d7ce9d771d5fcebda569b703a3c857baa7

阅读页: 1、2、3、4、5。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 未来动作 / 交互预测; 动作与轨迹预测
- 领域: 餐饮与烹饪、休闲与运动、音乐与表演
- 环境: EgoExo4D原takes, 添加pseudoSMPL-X重建。
- 任务: reconstruction、forecasting、generation三不同观测条件; 同数据重用。
- 题数 / 数据: EE4D-Motion110+h; 143Ktrain8sclips (每2s抽)、4,400valclips (每20s抽)。
- 评估方式: MPJPE/PA/handerror、headpose、footcontact/sliding、semantic/FID; 不同endpoint分项。
- Split / 信息条件: officialtake-levelsplit; forecast看2s预测6s, generation只看一帧, reconstruction可看全input。
- 来源关系: EgoExo4Dmulti-viewoptimization生成新motionlabels; 非110h新独立capture。
- 可复用: 补全身与scene-awareforecast, 但应防止把reconstruction偷看未来当forecast。
- 待核 / 限制: 三端点accuracy/inputs不同, 不能用同一个难度或成功率比较; best-ofK需最终protocol固定。

P230 EgoH4 (2025)

原作: <https://arxiv.org/abs/2504.08654>

本次PDF: <https://arxiv.org/pdf/2504.08654v1>

PDF SHA256: 16c00d83861cf54090431f84a857bd58983670d1635fa09e3cb8a8b6fc048006

阅读页: 1、2、5、6。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 未来动作 / 交互预测; 动作与轨迹预测
- 领域: 跨域 / 用途未指定
- 环境: EgoExo4Dbody/handannotations合并, 原场景重用。
- 任务: in-view/out-of-viewhandtrajectory/poseforecast, body作constraint。
- 题数 / 数据: 156Ktrain/34Ktest是按hand-side的sequencecounts; 同片左右手不可当独立scene。
- 评估方式: ADE/FDE、MPJPE/lastframeMPJPE, 单一generatedsample, 没有best-ofK放大。
- Split / 信息条件: officialtrain/valastrain/test, 2sobs→1sforecast10fps; GT2Dhands作input, autobody只train。
- 来源关系: EgoExo4Dbody与handsubset; metric对不同validjoints适用分母不同。
- 可复用: 加入遮挡/视野外预测的规则对照, 并标明ground-truth感知input优势。
- 待核 / 限制: 要核hand-side数转uniqueclip的关系; 不能将156K+34K称190K独立humanactivities。

P233 OCT/HOI forecasting (2022)

原作: <https://arxiv.org/abs/2204.01696>

本次PDF: <https://arxiv.org/pdf/2204.01696>

PDF SHA256: c866b4f79af2ef6de72a2ee55996af607cd4a69c977889bb3c3f67b0242fad17

阅读页: 1、4、5、6。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 未来动作 / 交互预测; 动作与轨迹预测
- 领域: 餐饮与烹饪
- 环境: EPIC55/100及EGTEA原视频, EK100扩充EK55。
- 任务: handtrajectory与objectcontacthotspot联合预测。
- 题数 / 数据: EK55train8523/evaltrajectory1894/hotspot241; EK10024148/3513/401; EGTEA1880/442/69。三种数字分别是训练、轨迹评测与hotspot评测。
- 评估方式: trajectory取20samples最小error; contactpoints全部转heatmap评, 不是20次独立case。
- Split / 信息条件: 评原validation, 正式actiontest不用于此derivedtask; hotspot只人工审核challengingsubset。
- 来源关系: autoannotations + 人工filteredhotspots, 后被多篇forecast论文重用。
- 可复用: 是hand/hotspot联合规则的基础来源; 保留每个target的可用label分母。
- 待核 / 限制: 不同target只覆盖各自subset, 1894不能全视为1894jointlabelcases。

P241 AFF-ttention (2024)

原作：<https://arxiv.org/abs/2406.01194>

本次PDF：<https://arxiv.org/pdf/2406.01194v2>

PDF SHA256：5bc6b87af40d139d6f59d0cb6bd989130ccd236b866623dc409b6fe248d789a5

阅读页：1、3、10、11。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：未来动作 / 交互预测；动作与轨迹预测
- 领域：餐饮与烹饪
- 环境：EPIC-Kitchens添加STAannotations；Ego4D v1/v2原场景。
- 任务：next-activeobject box/noun/verb/time-to-contact联合预测。
- 题数 / 数据：添加EPIC-STA验证集；已读原文mainsections未给精确casecount，待annotationmanifest。
- 评估方式：N、N+V、N+TTC、All Top5mAP；不是四个互不相干task库。
- Split / 信息条件：Ego4Dv1/v2训练量和test榜分列，v2含v1；EPICval自建benchmark。
- 来源关系：EPIC父标注→STA、OCT-stylehotspots；STAformer++是后续方法版本。
- 可复用：论文名字像方法但附带新benchmark，应纳入来源总库并连回EPIC。
- 待核 / 限制：精确newannotationID与共同scene/task映射待code核，未知不填0。

P246 Decision-aware uncertainty (2026)

原作：<https://arxiv.org/abs/2603.10061>

本次PDF：<https://arxiv.org/pdf/2603.10061v2>

PDF SHA256：4efc1650b0634e90b675a99e738d4660ad1c454cbd8b1023bc814cafbcb53992c

阅读页：1、2、3、4、5。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：Survey / 评测方法；评测方法与不确定性
- 领域：餐饮与烹饪
- 环境：EGTEA/EPIC100既有视频。
- 任务：partial-prefixactionprediction下correctness/calibration/selectiveutility/confidencegeometry四种诊断。
- 题数 / 数据：预设K10候选、M5stochasticsamples/input；原作精确evalsegmentIDs未报。
- 评估方式：Top1/Recall@K、Top1/SetECE、accuracy-coverage、entropy；不是physicalsecurity验证。
- Split / 信息条件：称用officialtest，singleGemini2.5Flash-lite；K/M改变结果及成本，不能算多出5倍题。
- 来源关系：对既有benchmarks加uncertaintyprotocol；有助规则/拒答评测。
- 可复用：我们可加入拒答/澄清阈值与accuracy-coverage曲线，但要有相应标签和同模型预算。
- 待核 / 限制：Set-ECE用TopK平均confidence对setcorrectness，是作者定义，需另外验证适用性。

P247 EgoSpanLift (2025)

原作: <https://arxiv.org/abs/2511.18470>

本次PDF: <https://arxiv.org/pdf/2511.18470v1>

PDF SHA256: b2ea7307cbe26217da35558970ceadb9f521d3f0841c60ff431031d39a98003f

阅读页: 1、5、7、8。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 未来动作 / 交互预测; 动作与轨迹预测
- 领域: 居家整理与清洁、餐饮与烹饪、医疗与手术支持、交通移动与车辆维修、休闲与运动、音乐与表演
- 环境: AEA的143recordings/7.3h与EgoExo4D五活动子集; 排除soccer/basketball/dance。
- 任务: 3Dvisualspanforecast, 多个视角范围是同target不同granularity。
- 题数 / 数据: FoVS-Aria约23.2Ksample (19.3K/1.9K/2.1K); FoVS-EgoExo341.4K (274.7K/29.6K/37K), 概述364.6K。
- 评估方式: 3DIoU/F1、fovealregiondistance; 16格/3.2m=20cmcell resolution, 不当精确gaze接触。
- Split / 信息条件: AEA location4heldout; look2spredict2s, EgoExo预测4s; split约数四舍五入不精确加总。
- 来源关系: AEA/EgoExo4DSLAM+gaze衍生volume; windowoverlap与sourcecaptures要追踪。
- 可复用: 补注视/可见区域预测, 让世界观测能力不只局限于问答或手轨迹。
- 待核 / 限制: visualspan≠robotactiveperceptionpolicy; 也未覆盖所有EgoExo8activities。

P250 EgoMAN (2025)

原作: <https://arxiv.org/abs/2512.16907>

本次PDF: <https://arxiv.org/pdf/2512.16907v2>

PDF SHA256: 3edd340c61e8cb14c7aee576baa1f86ace5b4367000ec8ea612f039df07d7c24

阅读页: 1、2、3、4、5、6。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 未来动作 / 交互预测; 动作与轨迹预测
- 领域: 居家整理与清洁、餐饮与烹饪、交通移动与车辆维修
- 环境: EgoExo4D/Nymeria以1014pretrain/498finetune/78testscene标签分开; HOT3D testonly。
- 任务: interactionstage-aware6DoFwristforecast; semantic/spatial/motionQA三训练类别。
- 题数 / 数据: EgoMAN-Bench2844unseen+990HOT3DOOD=3834trajectories; 3MQA为生成supervision概述, 非3Mtestquestions。
- 评估方式: ADE/FDE/rotation/DTW, best-ofK1/5/10; waypointcontact/traj-distance另报。
- Split / 信息条件: sceneheldout及datasetOOD; up-to5sforecast, GTduration/masks用于判分。
- 来源关系: EgoExo4D/Nymeria/HOT3D重用, 再生成interaction/QAlabels; 可与OpenEgo、UniHand有父素材重叠。
- 可复用: 是端点/规则扩充产生大QA量的对照; 主benchmark应以3834testtrajectory分母比较。
- 待核 / 限制: 219K/220K+trajectory概要与74K+17Ktrain分项不是同一层; 待release对hand/clip单位核。

67篇方法 / 背景参考的筛查

- P035 EgoVLPv2: EgoVLPv2使用EgoClip/EgoMCQ及既有下游数据; 模型融合改进不另计一份新视频库。(PDF 1, 5, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2307.05463>
- P036 EgoT2: EgoT2在Ego4D的7既有任务做task translation, 保留作跨任务模型参考。(PDF 1, 2, 5; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2212.06301>
- P043 Embodied VideoAgent: Embodied VideoAgent用Ego4D-VQ3D、OpenEQA、EnvQA; 添加memory/tool方法, 不把下游来源再加总。(PDF 1, 2, 5; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2501.00358>
- P044 HiERO: HiERO在EgoMCQ/EgoNLQ/EgoProceL/Goal-Step验证hierarchical features, 未另计父数据规模。(PDF 1, 2, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2505.12911>
- P046 RULSTM: RULSTM是EPIC/EGTEA的anticipation方法与challenge参考, 原生题库归父来源。(PDF 1, 4; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/1905.09035>
- P047 AVT: AVT使用EK55/EK100/EGTEA/50Salads, 四个评测集合不能当四份新数据。(PDF 1, 2, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2106.02036>
- P048 EGO-TOPO: EGO-TOPO从EPIC/EGTEA建环境affordance图, 保留拓扑表示与forecasts设计参考。(PDF 1, 3, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2001.04583>
- P049 AntGPT: AntGPT研究goal inference与actionsequenceforecast, LTA定义归Ego4D等父benchmark。(PDF 1, 3; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2307.16368>
- P050 PALM: PALM用caption/识别/LLM预测既有LTA标签; 多次prompt不增加基础题数。(PDF 1, 4, 8; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2311.17944>
- P052 StillFast: StillFast针对既有short-term object interaction anticipation, 属方法; 初筛仅摘要/任务定义。(PDF 1; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2304.03959>
- P055 FUTR: FUTR在Breakfast与50Salads测长期预测, 保留horizon/分割方式参考。(PDF 1, 2, 5; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2205.14022>
- P056 Forecasting hands and objects: 未来手/物体位置预测在公开第一人称及street数据验证; 本轮未另登记独立新数据资源。(PDF 1, 2, 8; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/1705.07328>
- P059 EMAG: EMAG在Ego4D/EPIC55研究ego-motion及跨库泛化, 非新capture来源。(PDF 1, 4, 8; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2405.20030>
- P078 PerAct: PerAct有18RLBench tasks/249variations及7real tasks/18variations; 保留方法实验, RLBench子集不重算整库。(PDF 1, 3; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2209.05451>
- P117 UMI: UMI四个实机task验证工具/界面; 可借cuporientation等规则, 未纳成本轮独立benchmark总数。(PDF 1, 6, 7; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2402.10329>
- P118 EgoMimic: EgoMimic三个real long-horizon tasks研究human-robot对齐; 保留任务扩充参考。(PDF 1, 5, 10; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2410.24221>
- P121 EgoZero: EgoZero七个real tasks验证smart-glasses到robot技能; 是方法实验而非七种新生活领域。(PDF 1, 2, 5; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2505.20290>
- P122 EgoBridge: EgoBridge的PushT对照与三real tasks用于OT adaptation; 背景和初态规则可借用。(PDF 1, 2, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2509.19626>
- P130 ALOHA / ACT: ALOHA/ACT六个real tasks与两simtasks, 主要界面/策略研究; demo数和task数分开。(PDF 1, 8; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2304.13705>

- P131 Mobile ALOHA: MobileALOHA延伸mobilebimanual操作, 50demos/task; 完整custom实验清单可续做task-level抽取。(PDF 1, 7; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2401.02117>
- P133 RT-2: RT2约6000跨方法/条件rollouts; 沿用robotdata并研究新语义能力, 非6000unique tasks。(PDF 1, 4, 7; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2307.15818>
- P134 OpenVLA: OpenVLA重用OXE970Kdemonstrations; 29evaltasks与7finetunetasks是方法实验范围。(PDF 1, 2, 7; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2406.09246>
- P135 Octo: Octo800Ktrainingtrajectories来自OXE; 多平台policyadaptation不创建800Ktest题。(PDF 1, 2, 3; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2405.12213>
- P136 pi0: π_0 包含约10000h数据与折衣/清洁/盒子组装实验; 保留通用策略与自收数据参考, 完整manifest未由初筛验证。(PDF 1, 3, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2410.24164>
- P137 pi0.5: $\pi_{0.5}$ 验证未见房屋与长流程; 高低层cotrain是方法, 不能把所有提及用途当完整task库。(PDF 1, 3, 10; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2504.16054>
- P138 Diffusion Policy: DiffusionPolicy在既有四benchmark的15tasks评测; 保留控制界面/数据预算参考。(PDF 1, 2, 10; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2303.04137>
- P139 R3M: R3M用Ego4Dpretrain、三sim来源与五realtasks; 来源重用需连父库。(PDF 1, 6, 8; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2203.12601>
- P140 VIP: VIP研究reward/representation; 四realtasks及既有simcases留作评测方法参考。(PDF 1, 7, 8; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2210.00030>
- P149 V-JEPA 2: V-JEPA2有大规模internetpretrain与DROIDadaptation; 保留worldmodel/closed-loop对照, 不把22Mvideos算robot题。(PDF 1, 5, 11; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2506.09985>
- P153 EgoExo-Gen: EgoExo-Gen在EgoExo4D作cross-viewmask/video预测; 可借新输入条件, 素材仍属父来源。(PDF 1, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2504.11732>
- P154 Hand-conditioned ego predictive model: Hand-conditioned predictive model使用Ego4D/BridgeData/RLBench, predictionquality与控制success分开。(PDF 1, 4, 5; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2508.19852>
- P155 EgoExo-WM: EgoExo-WM把HowTo/CrossTask等exo转ego并结合Nymeria; 添加合成表示, 不视为全新独立行为。(PDF 1, 2, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2605.15477>
- P156 Egocentric survey: Egocentric survey按subject/object/environment/hybrid整理; 用于taxonomy与引文扩查。(PDF 1; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2503.15275>
- P157 Human-video robot learning survey: Human-video robotlearning survey区分task/observation/action pathways; 背景综述非新题库。(PDF 1; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2604.27621>
- P158 VLA benchmark survey: VLA数据/benchmark/dataengine survey; 可用于遗漏来源检查, 不沿用二手规模替代原作。(PDF 1, 2; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2604.23001>
- P159 tinyBenchmarks: tinyBenchmarks提供IRT/子集估计方法, 研究对象是LLM; 不能直接假设robot难度模型有效。(PDF 1, 4, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2402.14992>
- P160 Rliable: Rliable提供分层bootstrap/IQM与performanceprofiles; 统计方法, 不是robot环境数据源。(PDF 1, 2, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2108.13264>
- P161 First-person prediction survey: 第一人称未来预测survey, 涵行为/位置/手物交互; 背景与追引文来源。(PDF 1; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2107.13411>
- P162 Egocentric hands survey: 手部egocentric survey区分localization/interpretation/application; 无新robot题库。(PDF 1; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/1912.10867>
- P163 Ego-exo collaboration survey: Ego-exo survey以跨视角transfer/jointlearning整理, 可支持示范来源分类。(PDF 1; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2506.06253>

- P187 SSFold: SSFold报六foldtasks及human demonstrations; 留方法实验参考, 初筛尚不宣称已核所有trial协定。(PDF 1, 2; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2411.02608>
- P189 GPT-Fabric: GPT-Fabric重用smoothing/folding范式, real10/12rollouts; sim粒子距离和real人工查看不可混分。(PDF 1, 5, 7; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2406.09640>
- P190 UniGarmentManip: UniGarmentManip三garment类/三task: unfold/fold/hang; 重用资产/对应学习, 不当三新datasets。(PDF 1, 3, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2405.06903>
- P194 Cloth gripper interface: clothgripperinterface八个cornerfold cases验证kinematicgrasp; 省略摩擦contact, 不能当完整physicsbenchmark。(PDF 1, 2; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2609.29340>
- P195 World models for unfolding: worldmodelforunfolding在Unity/RFuniverse及realcloth验证; 保留模拟与policy方法参考。(PDF 1, 3, 7; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2602.16675>
- P215 World-model evaluation survey: worldmodelevaluation survey列160benchmarks; 作引文追查线索, 其二手数字不直接并入已核来源。(PDF 1, 4; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2609.29669>
- P218 TrajPilot: TrajPilot重用EgoExo4D/GoalStep/EgoPER, 重点是trajectoryconditioning及horizon, 不另算全部label为新task。(PDF 1, 7; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2605.20388>
- P219 FROST-STA: FROST-STA是Ego4D2026challenge submission; query/GT由父challenge定义。(PDF 1, 3; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2606.00694>
- P220 VISTA (Ego4D STA): VISTA-STA合并train+部分val训练、只报officialtest; 不是添加dataset。(PDF 1, 3, 4; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2605.20901>
- P221 STAformer++: STAformer++是AFF-ttention后续架构, EPIC-STA添加资源已连到P241, 避免重列两次。(PDF 1, 2; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2602.14837>
- P223 INSIGHT: INSIGHT在Ego4D/EPIC55/EGTEA测意图推理与预测, 原生题库归父来源。(PDF 1, 2, 5; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2508.01742>
- P227 EggHand: EggHand处理EgoExo4Dhandposeforecast, 保留motion/frame定义与模型baseline参考。(PDF 1, 2, 5; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2605.07642>
- P231 MADiff: MADiff用五publicdatasets与添加interaction-pointdiagnostics; 标注/metrics从父数据衍生, 非新capture。(PDF 1, 6, 9; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2409.02638>
- P232 Diff-IP2D: Diff-IP2D添加jointpredictionmetrics、沿用EPIC/EgoPAT; 并揭示USST的FDE erratum, 保留评分版本参考。(PDF 1, 11; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2405.04370>
- P234 I-CVAE: I-CVAE在Ego4DLTA预测20futureactions; oracleintent/GTactionablation应另列。(PDF 1, 2, 7; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2207.12080>
- P235 TransFusion: TransFusion把contextsummary加入既有STA; GTcontext与推估context不可等同。(PDF 1, 2, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2301.09209>
- P236 ActFusion: ActFusion统一segmentation/anticipation于Breakfast/Salads/GTEA; 两endpoint共用视频。(PDF 1, 2, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2412.04353>
- P237 Gated Temporal Diffusion: GatedTemporalDiffusion在Breakfast/Assembly101/Salads做stochasticLTA; 新模型不增加父库活动数。(PDF 1, 2, 9; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2407.11954>
- P238 Object-centric LTA: object-centricLTA用Ego4D/50Salads/EGTEA; objectprompt数非独立task数。(PDF 1, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2311.00180>
- P239 MVP: MVP研究多尺度video pretraining与既有LTA/summaryforecast; 保留观测horizon参考。(PDF 1, 2, 7; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2307.12854>
- P240 ANTICIPATR: ANTICIPATR在四existingdatasets做futureinstance预测; 重用原split。(PDF 1, 9, 10; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2210.11566>

- P242 NAOGAT: NAOGAT用Ego4DSTA及EK; noun/verb/box/TTCjointmatch是判分组合, 非四倍题。(PDF 1, 7; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2308.08303>
- P243 FactCheck (LTA) : FactCheck的Observe-Plan-Verify是预测流程内迭代, EPIC/EGTEA未运行robot物理环境。(PDF 1, 9, 10; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2606.14778>
- P244 BiAnt: BiAnt在Ego4DLTA研究forward/backwardactionsequencelearning; 初筛未添加独立题库。(PDF 1; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2508.00374>
- P245 ICVL: ICVL在Ego4D/EPIC55/EGTEA研究vision-intentionfusion; 保留方法与prompt参考。(PDF 1, 2; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2505.01713>
- P248 HOIMotion: HOIMotion使用ADT/MoGaze及humanstudy; sceneobjectboxes是forecastinputs, 不是新控制环境。(PDF 1, 2; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2407.02633>
- P249 EgoCast: EgoCast使用EgoExo4D/ADT, 提出较长horizon/估计而非GTpastpose; 保留taskprotocol扩充参考。(PDF 1, 3, 4; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2412.02903>

扩查清单（未计入183已核来源）

- BEHAVIOR-100原作：需和BEHAVIOR-1K及EAI的B100 symbolic评测分开；现有书目未独立登记。
- Assistive Gym与照护 / 穿衣任务来源：补照护场域，不能只以厨房/衣物替代身体接触与可及性；需扩查原作。
- RoboMME及具身记忆相关原作：新记忆来源引用多个未独立收录的父benchmark；需逐个分清重用/新生成。
- ENIGMA-51、CASTLE2024、HO-Cap：已核来源的父素材未全独立登记；依CapMem/OpenEgo原文追查。
- RoboBenchMart、SariBench：SABER的零售环境/下游task父来源需补独立原作与manifest。
- Fold/cloth方法的完整原作清单：SSFold、GPT-Fabric、UniGarmentManip等67篇参考组中的custom实验，可在逐task抽取时补规则/实例；本轮初筛不假称已核所有程序。
- survey与引用链的添加来源：世界模型survey等提供更多候选。候选未审阅前不加进183已核来源，不以二手表格宣称完整搜集。

本次公开自己的阅读摘要、页码、数字及来源指纹；不重新散布原作PDF。