

Robot-use Benchmark：逐篇来源审阅与集成设计

版本v0.11；用途归纳更新2026-10-04，原作审阅2026-10-02。

250篇现有书目全部初筛；143个原登记来源加40个补入来源，共183篇已读数据 / benchmark / 评测相关章节。其余67篇保留方法、原作实验、survey或统计方法索引。不宣称穷尽全球文献。

『已审阅』指核对原作身份并阅读所列PDF页的任务、数据与评测段落；不表示全文逐字精读、原始标注逐题人工复核或程序已重现。

本轮数字与目标

项目	目前确认	下一阶段规划口径
领域	21 已归纳用途类别。183/183份来源均有归类；原22份已补齐。每个用途有任务 / 场景理由；同一来源可涵盖多用途。	按任务、对象与目标归纳，再逐任务创建联集；新用途可扩充分类。
环境	284 已取得命名场景条目。64个已读来源有某种环境量；284条仅是已取ID子集，未完成跨库几何去重。	整理各来源scene/layout/location及重用关系后，计全库联集；不再先配1,000。
任务	2,096 已取得robot任务条目。另有7信息题型、263人类活动。原作 task/skill/instruction的差异已逐篇记录，尚未全部范式去重。	先取原作任务联集，再加有差异证据的新目标 / 规则；不再先配5,000。
题数	114,288 已取得题目定义元数据。111,652 PARTNR train+1,000 val+1,636 OpenEQA；含训练数据，素材未全齐，不是114,288道已集成测试题。	依task、split、合法输入及判分创建case manifest后定量；原作量、已取得量、可评量分列。
评估方式	4 共同判分大类。183份来源均有判分方式与原文依据；具体metrics及评分器仍各自保留，尚未全数挂接。	答案、误差、状态 / 过程、人工 / 模型评审各报；不以4类代表4个完成的通用评分器。

v0.9的12领域 / 1,000场景 / 5,000任务 / 100万题配额已撤回。4种判分方式仍作分类，不作完成量。实际清单仍保留，未知的全库联集不填0。

阅读后的主要发现

有任务就能进一步归纳用途，不必等待同名domain标签

CALVIN的抽屉 / 灯光、Meta-World的咖啡机 / 装配、TACO的搅拌 / 倒液均提供明确用途。RoboNet、GRIP与穿戴动作研究则以正式跨场域用途归类；原22份皆有逐笔证据。

依据：P065、P063、P198、P128、P193、P197，详见逐篇纪录。

大量题目不一定是大量不同任务

Meta-World的50种task与参数instances、RoboRecover的400test recovery scenarios、EGOSTREAM的2,250问题→8,528recall测例，分别增加不同层级。每个数字保留它自己的单位。

依据：P063、P178、P203，详见逐篇纪录。

视频与通用数据集成前作已经很大

HowTo100M的23,611人类活动标签、OXE的527skills与160,266作者报告tasks、OpenEgo的290来源task labels都要比较。它们不是同一种范式机器人任务。

依据：P002、P125、P199，详见逐篇纪录。

环境数最容易混入配置与视频标签

RoboCasa365的layoutxstyle配置、DROID的564workspaces、S-EMBER的2,090scenario labels层级不同。DreamDojo自己的table与正文scene量也不一致，已明列待核。

依据：P071、P126、P204、P150，详见逐篇纪录。

主张范围通常大于实际实验子集

BEHAVIOR-1K的活动定义与原始baseline子集、AutoBio的16定义/9实测、Labimus的完整流程设计与v0已验证部分均应分栏。

依据：P100、P176、P174，详见逐篇纪录。

同源的数据与资产需要保留关系

Ego4D衍生多个QA/预测集合；EgoDex又出现在OpenEgo与EMPIRE；HSSD支持HomeRobot、Habitat3和PARTNR。来源联集不能直接相加这些原作数字。

依据：P013、P119、P199、P224、P099、P142、P143，详见逐篇纪录。

答案、代理量和物理完成有不同证据

摘果waypoint接近、衣物外形IoU、world-model视频品质、人工偏好和实际robot success不能等同。不同predicate、失败排除、oracle信息和best-of-K预算均留在逐篇纪录。

依据：P213、P089、P191、P150、P250，详见逐篇纪录。

现在的难度只能在共同协定下校准

EMPIRE按baseline error分级、LIBERO-Plus按扰动设置分级、RoboRecover按referencepolicy可恢复率筛选，都依赖各自模型和协定。不能取一篇的easy/hard直接替另一篇定级。

依据：P224、P105、P178，详见逐篇纪录。

Survey分布

研究类型沿用书目的12类并按本轮阅读修正所列来源。每篇一个主类，用于survey分布；细部角色和多种判分方式另保留。研究类型不是生活用途，两者不能用篇数配额互相换算。

研究类型	已详细审阅来源	全部书目
人类视频与动作数据	32	32
理解、推理与规划	21	25
未来动作 / 交互预测	18	48
一般操作 benchmark	31	32
布料 / 柔性物操作	21	26
导航与家务运行	11	11
稳健性、失败与评测品质	19	19
人类观测到机器人转移	7	11
机器人数据与通用策略	6	16
辅助与协作	11	11
世界模型与预测表示	5	9
Survey / 评测方法	1	10

用途按原作的任务目标、操作对象、交互关系及场景归纳，包含生活 / 工作用途及跨场域应用。183份来源均至少归入一类，共21类；同一来源可以有多个用途。类别名称是本库的survey编码，不要求原文先给出相同domain标签。

生活 / 工 作 用 途	来源 数 (可 重复 标 记)	来源支持
居家 整理 与清 洁	104	P001、P003、P007、P009、P010、P011、P012、P013、P016、P017、P018、P024、P026、P027、P028、P029、P030、P031、P032、P033、P038、P039、P040、P042、P062、P063、P064、P065、P066、P067、P068、P069、P070、P071、P072、P073、P074、P075、P076、P080、P081、P082、P083、P084、P087、P093、P094、P095、P096、P097、P098、P099、P100、P101、P104、P105、P106、P107、P108、P109、P111、P114、P116、P119、P123、P124、P129、P142、P143、P144、P145、P164、P165、P166、P169、P178、P180、P181、P198、P199、P201、P202、P203、P204、P205、P206、P207、P212、P214、P034、P037、P051、P054、P110、P125、P126、P127、P120、P132、P150、P222、P228、P247、P250
餐饮 与烹 饪	70	P003、P004、P005、P006、P008、P009、P010、P011、P012、P013、P014、P018、P021、P022、P023、P024、P026、P027、P028、P029、P030、P031、P032、P033、P039、P063、P070、P071、P072、P073、P096、P097、P098、P100、P101、P105、P106、P108、P109、P116、P141、P143、P145、P152、P164、P166、P182、P198、P202、P204、P207、P212、P214、P002、P053、P057、P060、P125、P126、P127、P132、P217、P222、P228、P229、P233、P241、P246、P247、P250
衣物 与洗 护	25	P045、P082、P083、P085、P086、P087、P092、P093、P100、P119、P151、P152、P167、P181、P185、P196、P088、P089、P090、P091、P127、P186、P188、P191、P120
办公 与教 育	18	P018、P038、P039、P042、P072、P094、P095、P100、P101、P141、P144、P145、P202、P002、P054、P126、P120、P150
工艺 与修 缮	17	P003、P004、P013、P023、P028、P029、P031、P041、P063、P073、P106、P112、P141、P002、P034、P054、P150
装配 与生 产作 业	30	P015、P016、P023、P063、P067、P068、P069、P076、P079、P082、P083、P106、P112、P115、P119、P129、P141、P170、P171、P177、P179、P183、P184、P207、P208、P210、P211、P120、P150、P225
包 装、 仓储 与物 流	8	P076、P084、P086、P103、P164、P170、P200、P077
零售 与购 物	9	P013、P031、P100、P164、P200、P202、P204、P120、P150

生活 / 工 作用 途	来源 数 (可 重复 标 记)	来源支持
实验 室操 作	12	P021、P031、P072、P112、P164、P172、P173、P174、P175、P176、P192、P120
医疗 与手 术支 持	5	P041、P113、P164、P060、P247
个人 照护	8	P003、P014、P031、P087、P103、P148、P167、P002
交通 移动 与车 辆维 修	12	P003、P004、P013、P014、P031、P202、P002、P060、P150、P226、P247、P250
农业 与园 艺	7	P013、P023、P028、P031、P100、P002、P213
休闲 与运 动	16	P003、P013、P014、P019、P020、P031、P033、P041、P063、P072、P106、P202、P002、P054、P229、P247
公共 场馆 与服 务	3	P102、P103、P209
宠物 照护 与动 物活 动	4	P025、P041、P205、P002
音乐 与表 演	3	P014、P229、P247

生活 / 工 作用 途	来源 数 (可 重复 标 记)	来源支持
社交 与沟 通	7	P013、P019、P020、P032、P033、P061、P168
通用 对象 与机 动作 业	31	P062、P063、P065、P067、P068、P069、P075、P076、P081、P082、P083、P084、P106、P107、P115、P123、P129、P151、P152、P169、P171、P177、P182、P212、P214、P077、P125、P128、P193、P222、P228
协 助、 交接 与陪 伴	17	P058、P061、P073、P097、P103、P113、P141、P142、P143、P145、P146、P147、P148、P168、P208、P209、P210
穿戴 交互 与动 作界 面	25	P013、P014、P018、P019、P020、P058、P119、P197、P198、P199、P051、P053、P057、P060、P216、P222、P224、P225、P226、P228、P229、P230、P233、P247、P250

用途归纳完成：183/183；未归类：0。120份涉及多用途，共431笔用途对应；来源仍只有183份。

用途归纳方法

先从具体任务归纳用途：例如开抽屉 / 收纳归居家、咖啡机 / 餐具归餐饮、插栓 / 螺帽归装配。原作以基础对象或运动目标为主时，归通用作业；以协助人或交接为目标时，归协作服务；以穿戴视角的人体动作信号为目标时，归动作界面。跨用途是正常的多重归类，并不等于未分类。每个用途判定保存任务例子、归纳理由与原文页码。

1. **先找任务、对象与目标**：把原文还原成「谁对什么做什么、完成什么目标」。研究在模拟桌上进行，仍可由抽屉、餐具或装配目标判断用途。
2. **把任务归到用途**：先归纳可辨认的生活 / 工作用途；若原作本来就是跨场域的基础作业、陪伴交接或动作界面，使用有明确范围的正式用途类别。
3. **按实际子集继承**：LIBERO-Plus、MetaWorld+等先核对保留了哪些父任务，再继承相应用途；不把父库所有领域都搬给只用其中一小部分的工作。
4. **每笔保留理由并检查完整性**：每个用途标签都附任务 / 场景证据及页码。建置时检查183份来源皆有归类、所有类别皆有来源，添加来源缺判定时要求补完。

三类正式跨场域用途

- **通用对象与机动作业**：以搬移、抓握、对齐、作业复现、行走或平衡等目标构成的跨场域基础作业与技能测试。纳入条件：原作具有明确的基础作业目标，或其选用子集刻意测跨对象 / 机体的通用技能。范围：不因使用机器人或内含抓取动作就自动加入；单一用途的料理 / 实验室流程仍以其目的归类。
- **协助、交接与陪伴**：以人或协作者的需求、接收物品、共同时序、不中断对方及持续陪伴为目标的服务。纳入条件：合作对象 / 需求 / 交接或陪伴关系是任务定义的一部分。范围：双手或多个机器人本身不足以判定；依实际的交互服务目标归纳。
- **穿戴交互与动作界面**：利用穿戴视角的手部、人体、视线及移动信号，支持动作输入、AR / VR、操作意图与人类到机器人的动作界面。纳入条件：输出或主要数据直接描述姿态、动作、接触、视线或交互动作信号。范围：不因有ego视角就把所有视频QA一律归入；仍须看具体输出与用途。

原22份来源如何完成归纳

来源	本版用途	任务与归纳理由	原文依据
P058 EgoPAT3Dv 2	协助、交接与陪伴、穿戴交互与动作界面	预测人手将接触的位置，让共享工作区的机器人提前配合；同时是头戴设备的动作意图界面。	P058 PDF 1
P063 Meta- World	居家整理与清洁、餐饮与烹饪、工艺与修缮、装配与生产作业、休闲与运动、通用对象与机动作业	50个任务已有明确的用途线索：家居设备、餐饮、修缮 / 装配、球类操作，以及通用取放。	P063 PDF 18；P063 PDF 18；P063 PDF 18；P063 PDF 18
P065 CALVIN	居家整理与清洁、通用对象与机动作业	开抽屉、控制灯与把对象收好属居家整理；方块转动、推移与堆栈则保留为通用作业。	P065 PDF 3；P065 PDF 3
P073 RoboTwin	居家整理与清洁、餐饮与烹饪、工艺与修缮、协助、交接与陪伴	从杯子摆放、苹果收纳、扫除、锤击与人际交互数据归纳，保留每种用途所对应的任务范围。	P073 PDF 8；P073 PDF 5,8；P073 PDF 8
P103 Follow- Bench	包装、仓储与物流、个人照护、公共场馆与服务、协助、交接与陪伴	跟随指定人是陪伴服务；原作亦明列照护、巡逻、导览与物流的应用方向。	P103 PDF 1,6；P103 PDF 1
P105 LIBERO- Plus	居家整理与清洁、餐饮与烹饪	LIBERO-Plus改变观测与初态条件，未改掉原任务的餐具摆放、厨房设备及收纳用途。	P105 PDF 2；P064 PDF 3,4
P106 MetaWorld+	居家整理与清洁、餐饮与烹饪、工艺与修缮、装配与生产作业、休闲与运动、通用对象与机动作业	MetaWorld+保留原50项任务并修正版本和评测协定，因此沿用具体任务支持的用途。	P106 PDF 4；P063 PDF 18；P063 PDF 18；P063 PDF 18；P063 PDF 18
P115 RoboMME- Interference	装配与生产作业、通用对象与机动作业	依示范选物、搬方块、重画路径与插栓，归入通用作业复现与装配基础作业。	P115 PDF 2,3；P115 PDF 3
P146 DexH2R	协助、交接与陪伴	内核就是把人手中的对象交给机器人，归入协助与交接用途。	P146 PDF 1,3
P147 HRIBench	协助、交接与陪伴	按人的指令、时机和动作完成协作，涵盖交接、同步、让行及受干预后续作。	P147 PDF 3,4
P182 SoftVTBench	餐饮与烹饪、通用对象与机动作业	归纳为易损物取放的通用作业；烘焙品形状对象的放置情境另标餐饮处理方向。	P182 PDF 5,6；P182 PDF 5

来源	本版用途	任务与归纳理由	原文依据
P197 EgoSim / MultiEgoView	穿戴交互与动作界面	身体摄影机用来恢复用户动作及支持交互输入，归入穿戴交互与动作界面。	P197 PDF 1,5
P198 TACO	居家整理与清洁、餐饮与烹饪、穿戴交互与动作界面	用原作工具—动作—对象组合归纳：倒液与搅拌属餐饮，清洁器具属居家，手物动作建模亦服务AR / VR界面。	P198 PDF 2,5；P198 PDF 2
P212 ARB4WM	居家整理与清洁、餐饮与烹饪、通用对象与机动作业	同时涵盖对象操作与行走 / 平衡控制，归入通用作业；门窗与咖啡 / 餐盘任务另标对应用途。	P212 PDF 8；P212 PDF 8
P214 COIN (interactive)	居家整理与清洁、餐饮与烹饪、通用对象与机动作业	开柜、找书、操作微波炉都有可辨认用途；纯交互推理与几何控制题保留在通用作业。	P214 PDF 20,23；P214 PDF 4,17
P128 RoboNet	通用对象与机动作业	内核目标是把未知对象推或抓放到指定位置，归入跨场域对象搬移作业。	P128 PDF 3,5
P193 GRIP	通用对象与机动作业	产生稳定抓握并预测对象受力，归入通用抓取与易损物处理作业。	P193 PDF 4,5,6
P216 HAP	穿戴交互与动作界面	预测头部转向以看到被遮挡的操作目标，归入穿戴观察与动作界面。	P216 PDF 1,5
P222 Uni- Hand	居家整理与清洁、餐饮与烹饪、通用对象与机动作业、穿戴交互与动作界面	把手部预测连到交互界面与机器人示教；杯垫摆杯、苹果入盘和盒子上架另提供餐饮 / 整理用途。	P222 PDF 9,10；P222 PDF 9,10
P224 EMPIRE	穿戴交互与动作界面	预测双手未来动作并产生操作计划，归入穿戴交互与动作界面。	P224 PDF 1,4
P228 SFHand / EgoHaFL	居家整理与清洁、餐饮与烹饪、通用对象与机动作业、穿戴交互与动作界面	实时语言引导手部预测归入动作界面；其Kitchen与Adroit下游评测另外归纳家居 / 餐饮与通用作业。	P228 PDF 1,5；P228 PDF 5
P230 EgoH4	穿戴交互与动作界面	包含视野外双手的姿态与动作预测，归入AR / VR等穿戴动作界面。	P230 PDF 1,2

如何把大而广变成可发表的benchmark

先完成来源联集，再扩充任务和规则。集合的上限不能由论文数推定，异质数字不相加。要证明比前作更广、更大，须在相同任务粒度下报去重后任务数，并列各前作未覆盖而本库真正可评的用途、任务与规则。RoboVerse、OXE、OpenEgo等集成型前作必须直接比较。

环境、示范和评分器可以重用；添加目标、过程约束和介入条件要留下父任务与差异。每个case需要明确输入、答案或goal predicate、split、版本及预算。不同机体或传感条件下使用分组榜单；问答、预测、规划和物理控制的证据分开。

本轮是来源审阅与设计依据的完成，尚非通用benchmark全库的实验完成。接下来的论文证据应来自共同任务清单、有效case、可重现判分器与baseline结果。

难度量化

1. 先记可观测条件：步骤/依赖数、对象干扰、容许误差、材料、遮挡、历史长度、恢复和信息预算。这些是条件，不预先加成一个任意难度分数。
2. 同一case固定split、observation/action与budget，选涵盖不同能力的baseline，记逐case成功/误差和重跑。用task/source/scene群聚bootstrap估计不确定性。
3. 在同输出/判分协定内，以baseline成功率或相对误差校准难度，报分布与模型依赖。QA和物理控制不共用一条未验证的分数尺。
4. 有足够模型×题目矩阵后才试IRT或辨识度，检查拟合、单调性和source依赖；用新模型验证分级是否稳定。

Milestones

M1 来源阅读与共同比较

本版250篇筛查、183份逐篇审阅、原文页码/单位/重用纪录和五栏比较表。

验收：所有原143来源有记录，补入40来源；可重算分类分布，未知与冲突公开。

状态：本轮已完成，限现有书目范围

M2 逐ID整理环境与任务联集

取得各来源任务清单，保留source ID、version、split、资产引用；标示equivalent/derived/unresolved。

验收：来源覆盖率按183来源计；每笔任务有父来源和判分定义，不能仅比名称。

状态：已有部分清单；全库去重尚未完成

M3 扩充任务与规则

针对已核来源添加必要过程、精度、安全、恢复、记忆与协作规则；逐条记录相对父任务添加了什么。

验收：添加语义目标与添加测例条件分开计数；每个合法变体有可解性与evaluator验证。

状态：设计可据来源展开；未承诺固定题数

M4 创建可运行评测与论文证据

分问答、预测、规划、控制输出报分；固定观测/动作/时间/抽样预算，做来源与任务群聚切分。

验收：公开case manifest与判分器，报subset实测及不确定性；以去重后覆盖和添加任务证明规模优势。

状态：全库尚未完成；既有小型实验为工程附录

逐篇来源纪录

P100 BEHAVIOR-1K (2024)

原作: <https://arxiv.org/abs/2403.09227>

本次PDF: <https://arxiv.org/pdf/2403.09227v1>

PDF SHA256: ab4033f3e8a8187ad2cfd11f1979d33996ecce1e81fa3d62af33a92bbb17a2b

阅读页: 1、2、3、4、6、7、20、24。人类需求survey、1K activity来源、scene/object表、BDDL与Transition Machine、baseline范围。

- 研究类型: 导航与家务运行; 室内长流程操作
- 领域: 居家整理与清洁、餐饮与烹饪、衣物与洗护、办公与教育、零售与购物、农业与园艺
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 50scenes / 373rooms / 8scene types; 包含house、garden、restaurant、office等; 不能把rooms和scenes相加。
- 任务: 1,000 BDDL activities = 人类需求排序选909 + 沿用BEHAVIOR100的91项; 2,090是survey候选池, 不是已实作任务。
- 题数 / 数据: 程序生成满足initial predicates的配置; 原文baseline只实测CollectTrash、StoreDecoration、CleanTable三活动, 非1,000活动全模型成绩。
- 评估方式: success、goal score Q、时间、导航距离、扰动对象量。; 低级RL与assistive grasp/teleport primitive分开; 高分primitive不能代称低级policy已解题。
- Split / 信息条件: 原文3活动实验; 初态生成规格与实验seed / rollout需另外记录。
- 来源关系: BEHAVIOR100的延伸; ATUS等time-use survey及WikiHow为活动来源。OmniGibson混用物理与temperature/烘焙等heuristic transition, 非所有现象都是精密物理。
- 可复用: 全库广度与生活活动规格的核心比较基准; 新库要提出超过其已有activity和规则的具体联集。
- 待核 / 限制: 全1K activities的去重semantic goal、可用资产及可解性应逐规格核, 不用1K宣称1K模型可评结果。

P082 RoboVerse (2025)

原作: <https://arxiv.org/abs/2504.18904>

本次PDF: <https://arxiv.org/pdf/2504.18904v1>

PDF SHA256: 8c0cb543ef3f0c9a033f06cbbd73a86f2f1177029751e72e86a54d366c355008

阅读页: 1、2、3、5、6、7、8、9、10、34。MetaSim架构、来源迁移全表、操作/导航/人形数据、4级泛化与实验子集。

- 研究类型: 一般操作 benchmark; 跨数据集集成与评测方法
- 领域: 居家整理与清洁、衣物与洗护、装配与生产作业、通用对象与机动作业
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 操作多底座迁移; 导航重用90个Matterport3D scenes; 59camera候选不是59环境。

- 任务：表l迁移276 manipulation task categories，另导航 / 人形。RLBench取80、CALVIN7、LIBERO10等为其迁移子集，不是全源 benchmark相加。
- 题数 / 数据：510.5K manipulation trajectories、约5.5K assets；navigation另R2R10K、RxR20K episodes。主要IL表只评6个代表 task。
- 评估方式：统一success checker / success rate；L0 task-space、L1场景、L2camera、L3光照反射。；不同simulator的migration成功不保证完全等价物理；需固定backend。
- Split / 信息条件：原作90/10；主IL取10train设置+10validation设置，3seeds；OpenVLA另限制20test scenarios。
- 来源关系：直接集成ManiSkill、RLBench、CALVIN、MetaWorld、Robosuite/MimicGen、GAPartNet、Open6DOR、ARNOLD、LIBERO、SIMPLER、RLAfford、GraspNet、GarmentLab、UniDoorManip、GAPartManip；导航R2R/RxR、人形HumanoidBench等。
- 可复用：本研究最重要的集成型比较对象之一；『把前作放一起』已有实作，添加贡献要在coverage、规则、来源联集与评估完整度。
- 待核 / 限制：276类是否存在跨源语义等价未在本文提供完整去重证据；需追MetaConfig IDs。

P071 RoboCasa365 (2026)

原作：<https://arxiv.org/abs/2603.04356>

本次PDF：<https://arxiv.org/pdf/2603.04356v1>

PDF SHA256: f3e6877b8de3dd471afb6951c1e067729e2a57c53fcb3d6daaa0f4af5080206b

阅读页：1、2、3、4、5、6、7、22。新旧资产、pretrain/target场景、365task组成、数据与eval。

- 研究类型：一般操作 benchmark；模拟操作benchmark
- 领域：居家整理与清洁、餐饮与烹饪
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：50新layouts×50styles=2,500 pretrain scenes；另10 target layouts各配一style=10 target scenes。2,500不是2,500 floor plans。
- 任务：365=65 atomic+300 composite；60活动归6家族；220任务需mobile、145不需。主要target评测50任务=18 atomic+16 seen composite+16 unseen composite。
- 题数 / 数据：30K human pretrain+25K human target；60atomic各生成10K（600K synthetic）。target eval每task30trials；demo量不算test题。
- 评估方式：task-specific binary success, per-task horizon；跨task平均。
- Split / 信息条件：pretrain300task；target50含16个pretraining未见composite；场景 / style也分离。
- 来源关系：直接扩充RoboCasa；本文引述旧composite83是另一版本，不能覆盖2024原文75。
- 可复用：是大规模厨房benchmark必要主比较；跨生活用途更广与域内更大是两项不同主张。
- 待核 / 限制：365全任务与本文pretrain/target数据实际涵盖联集需manifest核对；不能从『cover all』概述推论每task都有同量 demo。

P125 Open X-Embodiment (2023)

原作：<https://arxiv.org/abs/2310.08864>

本次PDF：<https://arxiv.org/pdf/2310.08864v9>

PDF SHA256: 13f16aff5afdee583dc25b3c570e9bb0cf6baefb59b539928d919588cd8d9246

阅读页: 1、2、3、4、6。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 机器人数据与通用策略; 跨数据集集成与评测方法
- 领域: 居家整理与清洁、餐饮与烹饪、通用对象与机动作业
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 60来源datasets、22embodiments; 场所数由各dataset metadata而来, 非60新环境。
- 任务: 结论报527skills / 160,266tasks; 方法用语言抽取skills, 不能直接当160,266范式goal definitions。
- 题数 / 数据: 1M+robottrajectories; 主RT-X混合只选9manipulators, 非全22都等量实测。
- 评估方式: 跨robot实机tasksuccess、OOD / emergent skills与移除Bridge对照。
- Split / 信息条件: 不同experiment的hosttask/robot子集不同; dataset-wide规模与policy实测范围分开。
- 来源关系: 集成既有datasets到RLDS; 不统一所有action坐标, absolute/relative/velocity仍可能不同。
- 可复用: all-in-one最重要对照之一: 我们不能以合并文件夹或粗7Dactionformat宣称首次通用benchmark。
- 待核 / 限制: 160,266的逐task IDs与同义/粒度规则未在已读段完备; 21institutions / 34labs的口径也需保留。

P126 DROID (2024)

原作: <https://arxiv.org/abs/2403.12945>

本次PDF: <https://arxiv.org/pdf/2403.12945v2>

PDF SHA256: 9e40a9c934ce78ea315d2c05593d60f9e18edf6dcd3785cd66439518965c3b07

阅读页: 1、2、3、7。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 机器人数据与通用策略; 真实操作benchmark
- 领域: 居家整理与清洁、餐饮与烹饪、办公与教育
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 564workspace scenes分52buildings; 换对象摆位不增加scene。
- 任务: 86是unique verb/task口径; 下游主实验6tasks/4locations, 不是全86实测。
- 题数 / 数据: 76Kdemonstrations/350h; 6task各50–150in-domain demos, 混合DROID训练。
- 评估方式: ID/OOD task success; nativepolicyrollouts分母需appendix/manifest另核。
- Split / 信息条件: 主task各有distractor/novelobject/cameravariation; 不是564场所全部held-out验证。
- 来源关系: 新distributedcapture; DROID表I与RH20T用unique multi-view trajectory重算, 不能代替RH20T原作报告数。
- 可复用: 提供workspaces与objectrandomization的清楚环境定义; 大数据与小评测子集须并列。
- 待核 / 限制: 18researchlabs/13institutions/18robots是不同口径; 主规模不能称86完整独立工作流程。

P132 RT-1 (2022)

原作: <https://arxiv.org/abs/2212.06817>

本次PDF: <https://arxiv.org/pdf/2212.06817v2>

PDF SHA256: 81efe669c8fa50ffc7097886dc78a442fa7a8f7f2451684b93069cb9fbeda767

阅读页: 1、4、5、7、8、9。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 机器人数据与通用策略; 通用策略的原作任务评测
- 领域: 居家整理与清洁、餐饮与烹饪
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 三evalenvironments: robotclassroom与两个realofficekitchens; 13robots不是13独立场景。
- 任务: Table1有744language instructions, 依verb分skill; 不等同744工作家族。
- 题数 / 数据: 约130Kdemonstrations; 主seen>200instructions、unseen21、robustness30/22、long15; 全研究>3,000trials。
- 评估方式: task SR与SayCan长流程成功; architectures在相同RT1数据重训。
- Split / 信息条件: novelinstructions保持object/skill可在别的training组合看过; OOD场景另列。
- 来源关系: 自收Google/EverydayRobot数据, 后被OXE/其他策略重用。
- 可复用: 说明前作也能有数百instructiontasks; 比较规模必须对齐语义粒度。
- 待核 / 限制: >3,000是跨method/condition运行次数; 不能当3,000独立test cases。

P063 Meta-World (2019)

原作: <https://arxiv.org/abs/1910.10897>

本次PDF: <https://arxiv.org/pdf/1910.10897v2>

PDF SHA256: 8ea4fd9e7a2f7a2cfc475ae7e7021e7a6c03b99ae3932b455def9197ff1197e8

阅读页: 1、4、5、6、7、12。50任务定义、观测 / 动作 / reward及MT / ML协定。

- 研究类型: 一般操作 benchmark; 模拟操作benchmark
- 领域: 居家整理与清洁、餐饮与烹饪、工艺与修缮、装配与生产作业、休闲与运动、通用对象与机动作业
- 用途归纳: 50个任务已有明确的用途线索: 家居设备、餐饮、修缮 / 装配、球类操作, 以及通用取放。
- 环境: 50个task environment配置, 共用Sawyer桌面; 不能解读为50种生活场域。
- 任务: 50个非参数性操作类型; 原文又把位置 / goal参数化实例称task, 需保留两种含义。
- 题数 / 数据: MT10含10环境×50参数配置=500; MT50为50×50=2,500训练task instances。这不是500 / 2,500个新语义任务, 也不是正式test QA。
- 评估方式: 各task成功predicate / 目标距离门槛, success与dense reward分开。
- Split / 信息条件: MT同已见任务学习; ML10 / ML45各有5保留task适应; ML1只在同一task变换50train / 50test goal。
- 来源关系: MuJoCo、Multiworld及Gym界面; 后续MetaWorld+等为其扩充, 不可把上游再次全加。
- 可复用: 提供桌面操作任务底座; 位置扩样容易, 生活用途拓宽有限。
- 待核 / 限制: 不同v1 / v2 / 后续release成功predicate细节与本地历史pilot须以commit分开。

P062 RLBench (2019)

原作: <https://arxiv.org/abs/1909.12271>

本次PDF: <https://arxiv.org/pdf/1909.12271v1>

PDF SHA256: fbb04509bea7bf6aa9b97b07c46d95e5c1a900987599693b3fae3fd84377db76

阅读页: 1、3、4、5、6、7。原生task / variation / episode定义、scene、成功条件与few-shot协定。

- 研究类型: 一般操作 benchmark; 模拟操作benchmark
- 领域: 居家整理与清洁、通用对象与机动作业
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 共用1个Panda桌面scene, 加载各task资产; API的TaskEnvironment不等于独立房间。
- 任务: 原文100手写task, 每task多variation (如目标色彩 / 对象), 每variation再抽初态episode。
- 题数 / 数据: episode / demo可随机生成, 原文没有固定全库题数; few-shot原版10%任务meta-test, 1 / 5 / 20 demonstrations是每任务支持样本预算。
- 评估方式: task-specific success conditions, 完成才给+1 sparse reward; few-shot在新episode报success; demo生成器通过验证不代表学习策略已成功。
- Split / 信息条件: 原版90% tasks train、10% unseen tasks test; 每次测试不能先知未见task规则。
- 来源关系: V-REP / PyRep / OMPL; 大量后续benchmark重用其task、资产和成功predicate。
- 可复用: 可直接作任务来源与扩充规则底座; task、variation、episode原作已有清楚先例。
- 待核 / 限制: 后续版本的task总量与常用18-task子集要另附commit, 不能用来改写2019原文。

P064 LIBERO (2023)

原作: <https://arxiv.org/abs/2306.03310>

本次PDF: <https://arxiv.org/pdf/2306.03310v2>

PDF SHA256: ff7d943e2eb37760df684f3ae2931a5a35ef8ea465bd387e62afe49507b8e414

阅读页: 1、2、3、4、5、6、9、10。任务生成、PDDL goals、4 suites、lifelong指针及pretraining切分。

- 研究类型: 一般操作 benchmark; 模拟操作benchmark
- 领域: 居家整理与清洁
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: Robosuite场景配置; layout / objects由PDDL定义, 本文已读段落未报去重layout总数。
- 任务: 130 = Spatial10 + Object10 + Goal10 + LIBERO100; LIBERO100内90短程预训练 + 10长程。LIBERO-Long不是再额外增加10。
- 题数 / 数据: 各task有human demos与随机初态评估; 可生成不代表固定无限题库已发布。
- 评估方式: 全部goal predicates为真才成功; 以success计forward transfer、negative backward transfer、AUC。
- Split / 信息条件: lifelong顺序学task, 过往数据限制; 90→Long10预训练与Spatial/Object/Goal控制变因是不同协定。
- 来源关系: 明确由Ego4D语言behavior templates生成task instructions, 实作建于Robosuite; 已是人类程序到robot benchmark的先例。
- 可复用: 与本研究来源联集主线高度相关; 新贡献需超过同类模板生成与桌面范围。
- 待核 / 限制: 各发布demo / init-state精确ID数需对照版本, 不从别篇约5K反推。

P068 ManiSkill3 (2024)

原作: <https://arxiv.org/abs/2410.00425>

本次PDF: <https://arxiv.org/pdf/2410.00425v2>

PDF SHA256: 0482cef460af5ca0dd09d2b1d0f499b996287d9dadec31b13ca60377a49ee80c

阅读页: 1、3、4、6、7、8、21、22、28。12种类型、平台与task生成、性能和learning评测段落。

- 研究类型: 一般操作 benchmark; 模拟平台与任务套件
- 领域: 居家整理与清洁、装配与生产作业、通用对象与机动作业
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: GPU异质并行模拟; 1024平行instances / cameras是运行规模, 非1024不同生活场景。
- 任务: 原作12 task categories包含tabletop/mobile、room-scale、locomotion、bimanual、multi-agent、drawing/cleaning、dexterous、tactile、classic control、digital twins、soft-body; 这12类不是12生活domain。
- 题数 / 数据: 扩展中的环境注册表与demo来源, 无单一固定全库test题数; 例如SIMPLER转接4种环境。
- 评估方式: task success / return、sample efficiency与wall-clock分开; 渲染FPS / VRAM是系统性能, 非任务成功率。; 本文GPU rasterization与IsaacLab ray tracing比较非完全同画质, 原作有明示。
- Split / 信息条件: 不同RL / IL / VLA / sim2real设置各有来源; 应固定demo数、生成方式与控制器。
- 来源关系: ManiSkill2平台与任务延伸, 另接SIMPLER等; 不能把platform release当完全独立benchmark family。
- 可复用: 可作运行底座; 广泛技术支持不等同每种生活用途已有完整任务与cases。
- 待核 / 限制: 目前API注册task总量随版本变动, 需固定commit再盘点; 本文不提供永续固定总数。

P074 RoboTwin 2.0 (2025)

原作: <https://arxiv.org/abs/2506.18088>

本次PDF: <https://arxiv.org/pdf/2506.18088v2>

PDF SHA256: 316ae82a97968e1a2d88540665401645a190d2699d7d8652e8fc0053ba609bda

阅读页: 1、2、3、6、10、11、19。MLLM产生器、对象库、50task benchmark、Easy/Hard及real验证。

- 研究类型: 一般操作 benchmark; 模拟与真实操作benchmark
- 领域: 居家整理与清洁
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 双臂桌面程序配置; Easy/Hard为clutter / 光照 / texture / 高度分布, 不是两个生活domain。
- 任务: 50 benchmark tasks; 另外真实实验4task×4conditions; RoboTwin-OD 147类731对象。
- 题数 / 数据: 每task50 clean train demos, 测试100rollouts于Easy/Hard条件; 真实测试training另10real+1,000synthetic。
- 评估方式: simulation / real task success; Easy和Hard分开。; MLLM observer的failure detection / localization是产生器辅助诊断, 不能替代所有物理success checker。
- Split / 信息条件: single-task training, Easy到Hard分布外; DP3在模拟可得完美point clouds / clean segmentation, 跨方法需标明。

- 来源关系：RoboTwin延伸，Rodin资产、skill API和sim-in-loop expert生成。
- 可复用：可借双臂流程与有物理回馈的产题；50task不因两种难度变成100语义task。
- 待核 / 限制：100rollouts的公开seed列表与两条件是否完全对应需eval script核。

P143 PARTNR (2024)

原作：<https://arxiv.org/abs/2411.00081>

本次PDF：<https://arxiv.org/pdf/2411.00081v1>

PDF SHA256：7da62f6f2b031d78908d6f063d44b6eae491bb31d03536218f6ee61dd300efd

阅读页：1、2、3、4、5、6、7、8、24、40。生成与评分完整章、原生100K口径、types、split、generation audit及agent信息条件。

- 研究类型：辅助与协作；对话协作与任务完成
- 领域：居家整理与清洁、餐饮与烹饪、协助、交接与陪伴
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：60HSSD houses (37train/13val/10test)，5,819OVMM objects；与其他HSSD来源重用。
- 任务：4非互斥特性：constraint-free/spatial/temporal/heterogeneous；原作task以unique scene-goal pair计，100K不是100K语义family。
- 题数 / 数据：本文100,000train+1,000val+1,000test；全val/test及2Ktrain人工审核。固定公开HF文件本库实数111,652train+1,000val是另一版本，不能覆盖本文或补造test。
- 评估方式：完整state sequence检查propositions、dependencies、temporal/same-argument/terminal constraints；PC、success、failure explanation。；中央/分散、partial/full、oracle/learned skills、privileged/perceived graph分开评。
- Split / 信息条件：source houses互斥；支持human-only技能差异；生成时会排除不能做的折衣。
- 来源关系：Habitat3/HSSD/OVMM底座；1K人工seed衍生100K。原文generation audit约90%instruction、92%evaluator、83%joint，与本库旧92.5%小试作无关。
- 可复用：为十万级rule-conditioned episodes及共同协作评测的关键前作；数量比较须用scene-goal案例粒度。
- 待核 / 限制：本文某处称全tasks HITL，统计处实际描述val/test+2Ktrain审核，应按具体audit范围理解。；HF公开版本无test素材；111,652只是该快照metadata实数。

P199 OpenEgo (2025)

原作：<https://arxiv.org/abs/2509.05513>

本次PDF：<https://arxiv.org/pdf/2509.05513v1>

PDF SHA256：84068f8b5d7e8add70826aacda59a02d425f56125bcf3f1c450fe966db7f7e65

阅读页：1、2、3、4。六来源表、hand/primitive统一、实际0.1%子集实验和held-out metric。

- 研究类型：人类视频与动作数据；集成型人类视频数据与预测benchmark
- 领域：居家整理与清洁、穿戴交互与动作界面
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：作者列10kitchens与610indoor rooms / 600+environments；是多来源合并，未证明全库去重。

- 任务：290 source task labels = 六来源原生task数相加；不等于290范式机器人目标。
- 题数 / 数据：1,107h、344.5K recordings、119.6M frames；实验只train在0.1%子集，10% demonstrations held-out，精确eval IDs/分母需核。
- 评估方式：AED/FED/DTW只算可见hand joints；8/16/32/64 frames horizons。未测robot physical task success。
- Split / 信息条件：作者称demonstration-level holdout 10%，但0.1%子集与holdout母集合关系需ID核。
- 来源关系：CaptainCook4D、HOI4D、HoloAssist、EgoDex、HOT3D、HO-Cap；语言多自动生成且部分人工核，添加的是统一label/format。
- 可复用：最直接的集成数据前作之一；我们必须清楚提出超出统一格式的task联集与评测规则。
- 待核 / 限制：跨来源环境/task去重未完成；data aggregation不可与父来源再次加总。

P002 HowTo100M (2019)

原作：<https://arxiv.org/abs/1906.03327>

本次PDF：<https://arxiv.org/pdf/1906.03327v2>

PDF SHA256: f55dbcb6598acecdedd0178243457eed6daf14626744e9bc50b0622cdbf58894

阅读页：1、2、3、4、5、6。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：人类视频与动作数据；人类程序视频与步骤定位
- 领域：餐饮与烹饪、办公与教育、工艺与修缮、个人照护、交通移动与车辆维修、农业与园艺、休闲与运动、宠物照护与动物活动
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：YouTube instructional/vlog等视频；12 WikiHow用途类别，不是12个物理场景。
- 任务：23,611 visual tasks是WikiHow搜索活动标签，未范式成robot goals。
- 题数 / 数据：1.22M视频 / 136.6M弱配对clip-caption；本库主要供pretraining，下游评CrossTask等既有benchmark。
- 评估方式：下游step recall、retrieval R@K/median rank；非136.6M人工验证评测题。
- Split / 信息条件：移除CrossTask test与YouCook2 val重复video IDs；仍可能有重上传内容。
- 来源关系：WikiHow活动×YouTube搜索；片段共享长视频，后续world-model/ego conversion又会重用。
- 可复用：是扩大生活/工作用途的重要来源；活动标签、可观测步骤及robot可运行目标需逐层转换。
- 待核 / 限制：原作抽400pairs仅51%至少一项提及与画面吻合；不能直接将全部字幕当程序ground truth。

P119 EgoDex (2025)

原作：<https://arxiv.org/abs/2505.11709>

本次PDF：<https://arxiv.org/pdf/2505.11709v3>

PDF SHA256: 7ea269e5885392e65a7e206c2d6b5792022ec499367a070c2c269cbcf187e2b8

阅读页：1、2、3、4、5、6、7、8。194tasks数据、reset类别、48D action表示、两benchmark、1%split与best-of-K。

- 研究类型：人类观测到机器人转移；人类示范与技能转移
- 领域：居家整理与清洁、衣物与洗护、装配与生产作业、穿戴交互与动作界面

- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：tabletop录制；原文明示场景多样性不是重点，没有独立layout总数。
- 任务：194human manipulation tasks；3种reset类型；正式两端点为未来手轨迹及给future goal图的inverse dynamics。
- 题数 / 数据：338,000episodes、829小时、约90Mframes；每task抽1%为held-out，不把90Mframes等同90Mtest题。
- 评估方式：12个wrist/fingertip keypoints的平均 / 终点Euclidean error，best-of-K (1/5/10)，分H=1/2/3秒。；人手预测误差不是robot任务完成率；给future image的inverse dynamics信息更强。
- Split / 信息条件：主test为每task1%同分布；未见task另附录，不可把主结果称OOD。
- 来源关系：新Apple headset录制；部分task来自FurnitureBench等类型，但非同robot轨迹。
- 可复用：大量灵巧行为、工具与衣物候选；转成robot benchmark需具体goal/初态与evaluator对应。
- 待核 / 限制：精确split episodes及同session相依关系需manifest；ARKit confidence为追踪品质非真物理成功。

P150 DreamDojo (2026)

原作：<https://arxiv.org/abs/2602.06949>

本次PDF：<https://arxiv.org/pdf/2602.06949v1>

PDF SHA256：c8f02e22c8fbe98e0b50215e10e1f6baf2f589b1987e5c6dc07175bfe6fe8587

阅读页：1、2、4、5、8、9、10。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：世界模型与预测表示；世界模型与视频生成评测
- 领域：居家整理与清洁、办公与教育、工艺与修缮、装配与生产作业、零售与购物、交通移动与车辆维修
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：Table1的1.135M scenes与正文9,869unique scenes不一致；暂不取其中任一为去重环境总量。
- 任务：6,015skills/tasks由GPT对globalcaptions估计；6个generation evalsets非6生活domains。
- 题数 / 数据：DreamDojo-HV43,827h，加入in-lab55h/EgoDex829h后44,711h；多数eval100samples，两个image-edited sets各25。
- 评估方式：PSNR/SSIM/LPIPS；editedsets无配对futureGT，12volunteers做physics/action-following偏好比较。
- Split / 信息条件：humanpretrain后robotposttrain，GR1是主要验证平台；counterfactual与backgroundedit分项。
- 来源关系：EgoDex + in-house；和EgoScale的scene/task/object统计一致是待核同源线索，非已证实完全相同。
- 可复用：规模非常大的world-model数据源；不能把44K人类视频小时或生成视觉评分当作可运行task库。
- 待核 / 限制：1.135M scene与9,869scene粒度矛盾；表中其他前作hours也不可代替原始论文校核。

P120 EgoScale (2026)

原作：<https://arxiv.org/abs/2602.16710>

本次PDF：<https://arxiv.org/pdf/2602.16710v1>

PDF SHA256：39c691baf374a154e26ffc0098b97037875909495013d4017d97761716ff2735

阅读页：1、3、4、6、7。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：人类观测到机器人转移；人类示范与技能转移
- 领域：居家整理与清洁、衣物与洗护、办公与教育、装配与生产作业、零售与购物、实验室操作
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：作者报9,869scenes的人类视频；语义场所/视频scene定义及与其他corpora交集待核。
- 任务：人类6,015task labels、对齐midtraining344tabletop tasks；主实机只5dexterous goals。
- 题数 / 数据：报告20,854hpretraining，并使用EgoDex829h（不另外相加）；midtrain50human/4hrobot；下游每task100robotdemos, shirt20。
- 评估方式：whole-task SR、fine-grained completion；两trainingseeds、通常每checkpoint/task10trials。
- Split / 信息条件：分大规模人类pretrain、配对midtrain、下游posttrain；非zero-robot-data。
- 来源关系：EgoDex与in-house数据；场景/task/object统计与DreamDojo相同数字，不能假定是独立添加corpus。
- 可复用：人类数据规模的必要对照；要分6,015训练标签、344对齐任务与5实测目标。
- 待核 / 限制：protocol称TaskIII每bottle16trials，但tasklist瓶盖是TaskIV，需manifest厘清。

P181 RoboFoldX (2026)

原作：<https://arxiv.org/abs/2609.10243>

本次PDF：<https://arxiv.org/pdf/2609.10243v2>

PDF SHA256: b7760baa843b43e164d224d5132fc13f534cb5e4bd834d7276340ee3f7d65553

阅读页：1、3、4、5、6、7。数据源、四track、完整折叠流程、30实机回合及FoldScore。

- 研究类型：布料 / 柔性物操作；柔性物操作benchmark
- 领域：居家整理与清洁、衣物与洗护
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：多个真实robot平台/场景，10+embodiments；精确独立工作站数未报。
- 任务：数据20+tasks；主折叠评测4类衣物Shirt/Skirt/Pants/Towel，涵盖取出、翻整、摊平、折叠和堆栈。
- 题数 / 数据：2,000+hours实机数据；主评测每衣物类别30trials，完整workflow须无人工介入。
- 评估方式：SR、成功回合时间、0–5neatness由至少2评者一致评分。FoldScore组合品质35%、可靠性35%、速度30%。
- Split / 信息条件：recovery、cross-task、cross-scene、cross-embodiment四tracks；场景泛化不能只用主4类成绩代表。
- 来源关系：多robot原始收集与统一格式；长workflow可切subtasks，切片不能再视为独立长示范。
- 可复用：提供完整衣物处理流程、人工外观品质与自动成功率并列的设计。
- 待核 / 限制：2,000+hours对应的unique episode IDs及工作站去重需要数据manifest；复合分数权重不是通用难度尺。

P213 Vision to Harvest (2026)

原作：<https://arxiv.org/abs/2609.13606>

本次PDF：<https://arxiv.org/pdf/2609.13606v1>

PDF SHA256: b3ee03d5d25e728c85d714de947fb09d06f56e94067923961d75c365281c22eb

阅读页：1、2、3、4、5、6。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：一般操作 benchmark；专业场域规划benchmark
- 领域：农业与园艺
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：Fuji apple及citrus orchard RGB-D数据；citrus父库432images，实际held-outscene数未报。
- 任务：multi-armCartesian fruit harvesting的offlineallocation/waypointplanning；apple/citrus两作物设置。
- 题数 / 数据：每crop共用同一held-outimage集合；未报可核固定题数，不能将父库432全填成eval cases。
- 评估方式：detection/harvested ratio、arm-order violation、pathdistance/token成本；harvested其实是waypoint距离门槛0.25/0.5/1m。
- Split / 信息条件：zeroshot同prompt；没有在线replanning或真的摘果控制。
- 来源关系：既有果园数据+新plan/verifier；collision指order违反，非完整动力学碰撞检查。
- 可复用：补农业用途与多臂分配，但转成运行benchmark仍需assets、接触和摘取验收。
- 待核 / 限制：exactevalsceneIDs未报；高harvestedratio不可当物理摘取成功。

P001 VLOG (2017)

原作：<https://arxiv.org/abs/1712.02310>

本次PDF：<https://arxiv.org/pdf/1712.02310v1>

PDF SHA256：914ea812883827c588beaafa23c52688332eff8824bb54128a2a9ec92331d3ac

阅读页：1、3、4、5、6、7、8。正文数据搜集、标注、benchmark 与探索实验章节；未逐行审阅模型训练附录。

- 研究类型：人类视频与动作数据；视频数据与感知评测
- 领域：居家整理与清洁
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：网络生活视频中的自然场景；没有可直接计数的模拟 layout 清单。365 是外部场景分类器类别，不能当环境数。
- 任务：30 个对象接触二元分类；8 类手部 / 人物状态分类及未来状态预测。这些是感知标签与评测问题，不是30个机器人操作任务。
- 题数 / 数据：114K 视频、219K 抽样影格的手部状态标注；原作分 uploader 做50/25/25切分。156K 影格另用于未来手位置探索实验。
- 评估方式：对象接触：逐类 AP / mAP。；手状态：分类 accuracy，现在及未来6 / 12 / 30 / 60影格分开。；未来手位置的156K影格探索实验不等于正式的独立机器人 benchmark。
- Split / 信息条件：依 YouTube uploader 分50% train / 25% validation / 25% test，避免同一上传者跨 split。
- 来源关系：视频自行搜集自 YouTube；与 COCO、Charades 的类别交集不表示共用全部数据。
- 可复用：可提供生活操作与接触 / 预测题型；转成机器人控制题仍需资产、状态及成功条件。
- 待核 / 限制：视频可下载现况、精确公开split文件数尚未逐档核对。

P003 COIN (2019)

原作：<https://arxiv.org/abs/1903.02874>

本次PDF：<https://arxiv.org/pdf/1903.02874v1>

PDF SHA256: 4625e83e6d9eaecd1acdfb5c39fa7132bbe4c4c6a58e541473c24c9f738f6762

阅读页: 1、3、4、5、7。数据定义、阶层分类、标注规模、切分与评测章节。

- 研究类型: 人类视频与动作数据; 人类程序视频与步骤定位
- 领域: 居家整理与清洁、餐饮与烹饪、工艺与修缮、个人照护、交通移动与车辆维修、休闲与运动
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: YouTube 教学视频; 原作12 domains是活动分类, 未提供12个物理环境。
- 任务: 原作阶层为12 domains、180人类程序任务、778步骤定义。180个活动可作任务候选, 不能直接当已实作的robot task。
- 题数 / 数据: 11,827视频、46,354步骤片段、476小时; 视频split为9,030 train及2,797 test。
- 评估方式: 步骤时段定位, 以 temporal IoU 0.1–0.5 的 mAP / mAR 衡量。
- Split / 信息条件: 9,030 train / 2,797 test; 不可把46,354步骤片段全称为test题。
- 来源关系: YouTube 视频与人类程序阶层; 与其他网络教学数据可能视频重叠, 尚无逐video ID跨库去重。
- 可复用: 可引入来源有据的180项程序及778步骤; 需另审机器人可行性与每一步的判分。
- 待核 / 限制: 完整12个原作domain到共同领域的逐条映射需保留原生label清单。; 跨数据集YouTube ID重叠未核。

P004 CrossTask (2019)

原作: <https://arxiv.org/abs/1903.08225>

本次PDF: <https://arxiv.org/pdf/1903.08225v2>

PDF SHA256: 1613d28f8d75e86ceedd8b6f2a9c2a4bbf29e5ee8485026bfc7be29826ae7632

阅读页: 1、2、5、6、14。数据创建、主要 / 相关任务定义、原作主评测, 追读附录评分。

- 研究类型: 人类视频与动作数据; 人类程序视频与步骤定位
- 领域: 餐饮与烹饪、工艺与修缮、交通移动与车辆维修
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: wikiHow程序及YouTube视频; 没有原生物理场景ID总数。
- 任务: 83个程序 = 18个主要评测任务 + 65个相关支持任务; 主实验不能写成83个同地位测试任务。
- 题数 / 数据: 约4.7K视频; 正文列主要任务212小时、相关任务161小时。每轮主要任务test为1,850视频。
- 评估方式: 主指针step recall: 每步只预测一个位置, 落在GT时间段才正确。; 20次随机切分的平均; 附录另报mAP, 不能把附录指针冒充唯一主指针。
- Split / 信息条件: 每个主要任务每轮30训练视频; 固定每任务20验证视频不进train/test; 其余1,850视频测试; 重复20次。
- 来源关系: wikiHow中筛选程序, YouTube搜集视频; 相关任务筛选以视频重叠判定的近重复。
- 可复用: 18个评测程序与65个支持程序分开引入; 程序步骤可以映射机器人规格, 但视频切分不能直接沿用作实体控制题。
- 待核 / 限制: 前文376小时与正文212 + 161小时口径不完全一致, 暂保留原文各自约数。; 4.7K总量尚未以发布清单精确重算。

P005 YouCook2 (2017)

原作: <https://arxiv.org/abs/1703.09788>

本次PDF: <https://arxiv.org/pdf/1703.09788v3>

PDF SHA256: 4ef636404bea37184e1fa056fa2a71a92705a1b3bc4ee58917a11806de17fbe3

阅读页: 1、2、3、4、7、8。YouCook2数据、标注、split、程序分段与proposal评测。

- 研究类型: 人类视频与动作数据; 人类程序视频与步骤定位
- 领域: 餐饮与烹饪
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 自然料理视频; 非4个物理场景。Africa / Americas / Asia / Europe是料理来源分类。
- 任务: 89道食谱; benchmark要求定位程序步骤及描述。食谱、步骤、视频为不同层次。
- 题数 / 数据: 2,000视频、176小时; 每道食谱按67 / 23 / 10%分train / val / test。
- 评估方式: 程序分段: Jaccard及mean IoU; proposal: IoU 0.5下precision / recall / F1, 与整体程序分段分开。
- Split / 信息条件: 每食谱67 / 23 / 10%; 本文百分比不自行换算成精确发布ID数。
- 来源关系: YouTube教学视频; 与其他料理视频库的原始video重叠需逐ID核对。
- 可复用: 可提供料理程序与步骤语言; 不能直接把2,000视频列为2,000robot任务。
- 待核 / 限制: 发布版本精确split ID数及素材可得性尚未逐档核。

P006 Breakfast (2014)

原作: https://openaccess.thecvf.com/content_cvpr_2014/html/Kuehne_The_Language_of_2014_CVPR_paper.html

本次PDF: https://openaccess.thecvf.com/content_cvpr_2014/papers/Kuehne_The_Language_of_2014_CVPR_paper.pdf

PDF SHA256: 79ea90c0870d5e1e29b880a953555fe8d9dbd2b825f0f46e13d28d51c33e138f

阅读页: 1、3、5、6。Breakfast数据、动作阶层、数据切分及语法式识别实验。

- 研究类型: 人类视频与动作数据; 人类程序视频与步骤定位
- 领域: 餐饮与烹饪
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 18个真实厨房; 每处3-5台相机, 视角不增加厨房数。
- 任务: 10个料理活动、48个coarse action units; 活动与动作单元分开。
- 题数 / 数据: 52参与者、约77小时、超过400万影格; 11,267个action-unit samples包含约3,600个silence samples。
- 评估方式: 动作串行unit accuracy及逐frame recognition accuracy; grammar解析与flat grammar比较。
- Split / 信息条件: 4组参与者轮替训练与测试; 不能把多视角同次活动当独立受试者。
- 来源关系: 自行录制; 文中ADL等外部对照数字不是Breakfast规模。
- 可复用: 可引入早餐程序及分层步骤; 18厨房是视频录制环境, 非可下载交互layout。
- 待核 / 限制: 后续常用发布版本的视频 / 片段数与本文单位可能不同, 不能直接混写。

P007 Charades-Ego (2018)

原作: <https://arxiv.org/abs/1804.09626>

本次PDF: <https://arxiv.org/pdf/1804.09626v2>

PDF SHA256: 138cfb582bdf3ab17fb6aa3ad7f3dd09505f4410e6c31fd486f2aaf1c35beaf1

阅读页: 1、2、3。短文3页全文, 聚焦配对搜集、来源重叠及评测。

- 研究类型: 人类视频与动作数据; 视频数据与感知评测
- 领域: 居家整理与清洁
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 112个家、112位演员; 第一 / 第三人称依相同脚本重演, 异步录制的精确配准视角。
- 任务: 157个activity classes; 监督及zero-shot第一人称动作识别。
- 题数 / 数据: 6,167 train视频+1,693 test视频=7,860视角视频; 两种视角各34.4小时; 68,536动作标注。
- 评估方式: video-level mAP; 监督与zero-shot设置分别报告。
- Split / 信息条件: 参与者不跨train/test; 视角视频数不直接改称独立活动episode。
- 来源关系: 78.7%脚本取自Charades train, 另增1,000脚本; 与Charades有明确脚本来源关系。
- 可复用: 适合跨视角语义转移; 不能把配对当作同步3D重建或robot轨迹监督。
- 待核 / 限制: 逐配对ID与上游Charades脚本ID尚未在本库去重。

P008 EGTEA Gaze+ (2018)

原作: https://openaccess.thecvf.com/content_ECCV_2018/html/Yin_Li_In_the_Eye_ECCV_2018_paper.html

本次PDF: https://openaccess.thecvf.com/content_ECCV_2018/papers/Yin_Li_In_the_Eye_ECCV_2018_paper.pdf

PDF SHA256: aa3d3ec1981ea4b1b430c3712e3f56d851ac8173cfc5a9db797478cf4d4e3454

阅读页: 1、9、10、11。数据与benchmark章、凝视与动作识别评测。

- 研究类型: 人类视频与动作数据; 视频数据与感知评测
- 领域: 餐饮与烹饪
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 自然厨房料理录制; 本文未在已读段落提供独立厨房总ID数。
- 任务: 7个meal preparation tasks、106个action classes; 凝视估计和动作识别为两个端点。
- 题数 / 数据: 本文报29小时、86 sessions、32人、10,321动作样本; 首split为8,299 train / 2,022 test。
- 评估方式: 凝视估计: precision / recall / F1, 忽略无追踪与saccade影格; 动作识别: mean class accuracy, clip与video层次分开。
- Split / 信息条件: 首split 8,299 / 2,022; 评分时fixation采8影格聚合, 保留原协定。
- 来源关系: EGTEA相关后续版本常报28小时或10,325片段; 本笔不以别篇的数字覆盖所读PDF。
- 可复用: 适合视线、动作与料理先后关系题; sessions不是交互环境数。
- 待核 / 限制: 公开资产版本与后续10,325片段口径需另核对。

P009 EPIC-KITCHENS (2018)

原作: <https://arxiv.org/abs/1804.02748>

本次PDF: <https://arxiv.org/pdf/1804.02748v2>

PDF SHA256: 2b7fe522827a041638ef2d3b27c9508ace434bd504e22c3e3d43894ea144b7a7

阅读页: 1、3、10、11、12、13、14、15。数据搜集与词汇、split、对象侦测、动作识别及anticipation完整评测章节。

- 研究类型: 人类视频与动作数据; 视频数据与感知评测
- 领域: 居家整理与清洁、餐饮与烹饪
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 32位参与者 / 32个厨房; S2保留4位参与者的未见厨房。
- 任务: 3个端点: active-object detection、action recognition、action anticipation; §3.4词汇125 verbs / 331 nouns, 词汇数不是机器人任务数。
- 题数 / 数据: 55小时、39,596动作片段、454,255对象框; 同一片段可支持不同端点, 不能把三种端点直接乘成独立题。
- 评估方式: 侦测: mAP, IoU 0.05 / 0.5 / 0.75。; 识别与anticipation: verb / noun / action各报top-1、top-5及per-class precision / recall。; anticipation观测1秒, 截止于动作开始前1秒; 与看到整段动作的recognition分开。
- Split / 信息条件: S1已见厨房按完整sequence约80/20切分; S2保留4位参与者 / 厨房。各端点可评类别又有最少训练样本门槛。
- 来源关系: 为EPIC-KITCHENS-100、VISOR、EPIC Fields等后续来源的上游家族; 不得把共用视频 / 厨房重复相加。
- 可复用: 可引入对象、操作与短期预测题型; 原生语言动作类别需另对齐正式robot goal与判分。
- 待核 / 限制: 各原生split精确可下载ID数未以本版manifest重算。; 表中与正文不同聚合词汇口径应保留版本, 不能混加。

P010 EPIC-KITCHENS-100 (2020)

原作: <https://arxiv.org/abs/2006.13256>

本次PDF: <https://arxiv.org/pdf/2006.13256v4>

PDF SHA256: 2ad975f70d5b074a2b2616960bb53410a6d66ce973346284574e7b49684ab629

阅读页: 1、2、4、5、6、7、9、10、11、12、13。数据延伸与表1、六个challenge的定义及评测段落。

- 研究类型: 人类视频与动作数据; 视频数据与感知评测
- 领域: 居家整理与清洁、餐饮与烹饪
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 45个录制环境; 包含2018视频与新录像片, 不能和EPIC 2018厨房量直接相加。
- 任务: 6个challenge: 全监督 / 弱监督动作识别、侦测、anticipation、跨年无监督适应、跨模态检索。97 verbs、300 nouns、4,053 action classes不是4,053个实体操作goal。
- 题数 / 数据: 700视频、89,977动作段; train / val / test动作段67,217 / 9,668 / 13,092; 检索采公开val, 另有专用UDA切分。
- 评估方式: 识别top-1 / top-5 accuracy; 侦测mAP于temporal IoU 0.1–0.5。; anticipation以动作开始前1秒为截止, class-mean top-5 recall。; 检索用mAP及nDCG; UDA保留2018→2020的来源 / 目标域设置。
- Split / 信息条件: 主视频495 / 138 / 67; test皆新录像片。主split、UDA、retrieval评测集合不可混为一个test量。

- 来源关系：2018上游视频重新标注，89,977为新版本总量；其约66M masks及手 / 物框多为自动产生，非同量人工评测题。
- 可复用：可复用同一生活视频家族的多端点评测；必须以共用视频与split lineage控制泄漏。
- 待核 / 限制：公开manifest与此PDF版本的精确ID差异尚未逐档重算。

P011 EPIC-KITCHENS VISOR (2022)

原作：<https://arxiv.org/abs/2209.13064>

本次PDF：<https://arxiv.org/pdf/2209.13064v1>

PDF SHA256：912638891fd5608d681de38f6e902f5caa0b4a1925c4b22ffb564b92d69701c9

阅读页：1、3、4、6、7、8、9、10、25。数据 / split表与3个benchmark定义、主要metric；附录标注品质段落。

- 研究类型：人类视频与动作数据；视频数据与感知评测
- 领域：居家整理与清洁、餐饮与烹饪
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：42个EPIC厨房；为上游环境子集，不是添加42个交互场景。
- 任务：3个challenge：VOS、手物关系分割、Where Did This Come From。最后一项有15种来源容器，非15个生活domain。
- 题数 / 数据：179 untrimmed视频、50,729人工标注影格、271,584人工mask；9.9M为筛过的插值mask。WDTCF另有222测试query，取自92视频。
- 评估方式：VOS用Jaccard J及boundary F；只追第一影格已指定对象。；HOS用COCO mask AP，手侧别、接触与active object分开。；WDTCF用来源分类accuracy、证据影格及mask IoU；错误证据影格使IoU为0。
- Split / 信息条件：train / val / test视频115 / 43 / 21，影格32,857 / 7,747 / 10,125；保留未见厨房子集。WDTCF为222题test-only taster。
- 来源关系：直接标注EPIC-KITCHENS-100视频；自动插值从14.5M过滤为9.9M，不能当9.9M独立人工标签。
- 可复用：补充对象变形、接触及来源追溯题；同一视频不能重算为添加环境。
- 待核 / 限制：各VOS subsequence发布ID与视频父ID的完整映射尚未导入。

P012 HD-EPIC (2025)

原作：<https://arxiv.org/abs/2502.04144>

本次PDF：<https://arxiv.org/pdf/2502.04144v2>

PDF SHA256：d3648a8692d038cad2027290facf25c9f5d8ff12b65f912f4dc6d99b99118092

阅读页：1、5、6、7、28。数据与数字厨房、VQA创建 / 评测、recognition、长期VOS附录。

- 研究类型：人类视频与动作数据；视频问答与推理
- 领域：居家整理与清洁、餐饮与烹饪
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：9个新录厨房，413个fixture数字模型；fixture不是413个环境。
- 任务：69食谱；VQA以7类注记创建30种问题prototype，另有动作 / 声音识别和长期VOS。

- 题数 / 数据：正式VQA为26,650道五选一题；100,000是作者估计可生成上限，不是发布题数。VOS另为1,000串行 / 20,548标注影格；41.3小时为原始视频长度。
- 评估方式：VQA报各prototype accuracy后分群平均，5选1；包含blind language基线。；VOS用J / F / J&F；recognition沿用EPIC100训练权重，在新视频评估。
- Split / 信息条件：定位为新数据上的validation / zero-shot benchmark；没有依一般80/10/10重新分配。人类基线只抽600题。
- 来源关系：与EPIC系列研究相承但此批视频新录；使用EPIC100模型训练来源。数字副本不自动具备机器人物理 / 判分界面。
- 可复用：提供比粗动作标签更细的食谱、营养、3D、对象动态、视线问答；是可借鉴的多端点设计。
- 待核 / 限制：原生数字副本的交互物理完整性、本库素材取得与逐题manifest尚未核对。

P013 Ego4D (2021)

原作：<https://arxiv.org/abs/2110.07058>

本次PDF：<https://arxiv.org/pdf/2110.07058v3>

PDF SHA256：d33d9e7a1d4a93ab8e9137e62966b3e2b7d631f4c5b98e481f6fc2220739c2fc

阅读页：1、6、7、8、9、24、29、30、48、49、70、71、72、73、75、77、79。正文五大benchmark全段；附录数据split、episodic memory规模、short / long anticipation协定与统计。

- 研究类型：人类视频与动作数据；综合第一人称数据与评测
- 领域：居家整理与清洁、餐饮与烹饪、工艺与修缮、零售与购物、交通移动与车辆维修、农业与园艺、休闲与运动、社交与沟通、穿戴交互与动作界面
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：74个全球location / 9国；location不是去重后可加载场景ID。VQ3D专用子集另只使用4个扫描。
- 任务：5大benchmark：episodic memory、手物状态变化、影音说话者、社交互动、forecasting。MQ有110活动类别，NLQ有13模板；都不是整个Ego4D的domain / 任务总量。
- 题数 / 数据：3,670小时、931佩戴者为数据规模。NLQ约19.2K query (test约4K)；VQ 22,602 query；MQ 22.2K活动实例；short anticipation 64,798样本 (test 19,780)。各端点母视频重叠，不能相加为独立episode。
- 评估方式：NLQ用recall@k / tIoU；MQ用mAP与recall；VQ用时空AP及搜索效率。；PNR用秒级绝对时间误差、状态分类accuracy、对象侦测AP。；说话者追踪 / diarization / 转录用MOT、speaker error、DER、WER；社交LAM / TTM用mAP、accuracy。；forecasting：轨迹 / 手部位置误差；short anticipation top-5 mAP；long anticipation以20步串行edit distance等设置报告。
- Split / 信息条件：同family内一致 (forecasting与hands共用；memory内共用)，不同family不保证同一切分。NLQ约60/20/20；forecasting原协定40/30/30，另有locomotion切分。test标注及相交narrations不公开。
- 来源关系：上游多机构录制数据；EgoSchema / EgoPlan等后续题库常重用它。主表与附录部分过滤前后数字不同，保留端点与版本。
- 可复用：是跨日常场域及过去 / 现在 / 未来题型的重要上游；覆盖广度和正式robot控制任务量需分开。
- 待核 / 限制：不同端点的跨family视频泄漏需逐ID审核。；本文内MQ表3与过滤后表8、forecasting110.5 / 120小时等口径不能静默合并。

P014 Ego-Exo4D (2023)

原作：<https://arxiv.org/abs/2311.18259>

本次PDF：<https://arxiv.org/pdf/2311.18259v4>

阅读页: 2、4、6、10、19、24、25、28、30、36、38、39、41、42、44、69、73、74。数据、8场域、benchmark总表、关系 / keystone / procedure / 熟练度 / pose评分及切分附录。

- 研究类型: 人类视频与动作数据; 综合第一人称数据与评测
- 领域: 餐饮与烹饪、个人照护、交通移动与车辆维修、休闲与运动、音乐与表演、穿戴交互与动作界面
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 123个自然scene、13城市; 多台ego / exo相机同步录同take, 视角不增加场景或活动次数。
- 任务: 8原生domains、43活动、689 keystone为整体概述; keystone标注子集17活动 / 664标签, 正式识别过滤后278叶节点。4大benchmark family内含跨视角关系、程序、熟练度、3D姿态等端点。
- 题数 / 数据: 整体1,286小时、5,035 takes (概述); 附录切分列5,045 takes, 须查版本差异。keystone识别130,979视角片段, test 33,001, 其中ego 6,373。不能用全部14M自动 / 人工姿态影格替代题数。
- 评估方式: 跨视角mask用visibility accuracy / IoU / 位置误差; 生成视角另有生成metric^o; keystone recognition top-1 accuracy; 程序前置 / 可选 / 错误 / 缺步 / 后续步用calibrated AP^o; 熟练程度用top-1; 指导 / 正确运行时刻用L1时间门槛mAP^o; 人体用MPJPE、MPJVE; 手部用MPJPE及PA-MPJPE; 人工GT与自动GT分开。
- Split / 信息条件: 以take及participant保持互斥, 衍生片段继承父take; 附录列3,082 train / 842 val / 1,121 test^o。procedure测试graph及标签不公开。
- 来源关系: 独立同步多视角搜集; 同take的多视角和多端点共用来源。本文提醒v1过时, 不能混用v1 / v2数字。
- 可复用: 可扩展维修、照护、运动、音乐与熟练度; 多数为人类技能观测, 转成robot运行规格须另定机体与成功条件。
- 待核 / 限制: 概述5,035与附录5,045 takes相差10, 待manifest核对^o; 整体689与keystone子集664不能视为同口径。

P015 Assembly101 (2022)

原作: <https://arxiv.org/abs/2203.14712>

本次PDF: <https://arxiv.org/pdf/2203.14712>

PDF SHA256: f115520e2f1cb8ec65ecf3e197be18dd91e8f34b1ee58fcb36d18e1346d24c1e

阅读页: 1、3、4、5、6、7、8、15。搜集、粗细动作统计、split及四端点实验。

- 研究类型: 人类视频与动作数据; 人类程序视频与步骤定位
- 领域: 装配与生产作业
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 固定多视角录制配置; 8外部 + 4ego相机不是12个环境。
- 任务: 101种take-apart玩具, 15玩具类别; 202粗动作、1,380细动作标签; 4端点为识别、预测、分段、错误侦测。
- 题数 / 数据: 362次拆装sequence, 产生4,321视角视频、513视角小时; 1,013,523细片段及104,759粗片段含多视角重复。
- 评估方式: 识别top-1; 提前1秒预测用class-mean top-5 recall^o; 分段MoF / edit / F1@10,25,50; 错误 / corrective分类precision与recall, early模式只看半段。
- Split / 信息条件: 60/15/25%; 有seen / unseen玩具, 25玩具跨split; 视角与片段应继承原sequence^o。
- 来源关系: 自行搜集; 多视角是同次拆装, 不能用4,321宣称同量独立任务。其细标签与3D手pose专用表又有不同子集。
- 可复用: 可引入装配依赖、顺序变化、犯错与纠正; 应保留玩具、步骤、观测端点三层单位。

- 待核 / 限制：数据表中姿态专用1,456标签与一般1,380标签的完整映射待manifest核对。

P016 IKEA ASM (2020)

原作：<https://arxiv.org/abs/2007.00394>

本次PDF：<https://arxiv.org/pdf/2007.00394v2>

PDF SHA256：5869f1542aa7372df85b6b4006127599aba58b0364d546d963dff8a3876080af

阅读页：1、3、4、5、6、8。数据与split、动作 / 分割 / 追踪 / 姿态评分段落。

- 研究类型：人类视频与动作数据；人类程序视频与步骤定位
- 领域：居家整理与清洁、装配与生产作业
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：5个真实环境，桌上 / 地上共10相机配置；3台同步RGB相机。
- 任务：4种家具（side table、coffee table、TV bench、drawer）与原子装配动作；不是1,113个任务。
- 题数 / 数据：371次assembly，1,113 RGB视角视频及371 depth视频；本文16,764动作标注；254 train / 117 test assembly scans。
- 评估方式：动作frame accuracy、macro-recall、mAP。；零件分割与MOT分开；追踪MOTA、IDF1、IDs等。；3D姿态用MPJPE / PA-MPJPE、PCK@150mm。
- Split / 信息条件：按环境保留family room与office测试；作者明示此主split不保证subject同时互斥，另提供其他切分脚本。
- 来源关系：自行录制；空间标注仅1%影格人工，余下有pseudo-GT；不可把全部影格称人工标注。
- 可复用：家具装配与部件追踪来源；环境泛化与受试者泛化要分开报。
- 待核 / 限制：原子动作label完整清单与不同年份发布版本尚未逐ID对齐。

P017 HOI4D (2022)

原作：<https://arxiv.org/abs/2203.01577>

本次PDF：<https://arxiv.org/pdf/2203.01577v4>

PDF SHA256：82c5f0bf505f59eed426c1efa03f12a4155a5e18416ff03477d9e25c301be74f

阅读页：1、2、7、8。数据概述与三个benchmark完整定义 / 主要评分。

- 研究类型：人类视频与动作数据；视频数据与感知评测
- 领域：居家整理与清洁
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：610个室内rooms（录制环境）；4个参与者，不是610个已接入交互模拟器。
- 任务：16对象类别、800实例；3端点：category-level pose tracking、4D segmentation、action segmentation。pose实验只取4刚体+1关节类别。
- 题数 / 数据：4,000 sequences、2.4M RGB-D影格；4D分割专用376视频 / 14语义类别，不能把全数据量当每个端点实测量。
- 评估方式：pose：5°5cm accuracy、旋转 / 平移误差；以扰动GT pose初始化。；4D分割mIoU；动作分段Acc、edit、F1@10/25/50。

- Split / 信息条件：4D sequence随机7:3 train/test；不等同未见房间或受试者切分。
- 来源关系：自行搜集RGB-D及模型；NOCS / H2O / GTEA是外部对照，不属本库量。
- 可复用：补充对象 / 材质 / 房间变化和3D感知；原文明示未覆盖双手操作。
- 待核 / 限制：610 rooms的逐ID清单与可用重建品质未导入。

P018 HOT3D (2024)

原作：<https://arxiv.org/abs/2411.19167>

本次PDF：<https://arxiv.org/pdf/2411.19167v2>

PDF SHA256：cbe0c55d8c952c673dbff8633b5f23eb87963f7cf09429416eb2f1ac58236232

阅读页：1、3、4、5、6、7。数据、有效标注与subject切分、手 / 物追踪、分割与3D lifting。

- 研究类型：人类视频与动作数据；视频数据与感知评测
- 领域：居家整理与清洁、餐饮与烹饪、办公与教育、穿戴交互与动作界面
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：同一mocap lab中的4种情境布置：inspection、kitchen、office、living room；不是4处独立真实住宅。
- 任务：33刚体对象；手pose、对象6DoF pose、in-hand分割、3D位置lifting。
- 题数 / 数据：833分钟、1.5M多视角timestamps / 3.7M images；其中1.16M timestamps有效完整。HOT3D-Clips为3,832 clips = 2,804 train + 1,028 test。
- 评估方式：手部MKPE毫米误差；对象pose以对称性处理后平移 / 旋转门槛recall；in-hand mask mIoU；lifting用位置门槛recall。对象pose实验提供GT mask，并非端到端自由侦测。
- Split / 信息条件：13名受试者train、6名test，test GT走服务器；部分评测每30影格取一。
- 来源关系：新录Aria / Quest3数据。EgoHOS与UmeTrack为跨数据对照；部分baseline的400K Aria训练图是私有数据，不可算HOT3D公开题。
- 可复用：提供可靠3D接触 / 姿态参考；可控场景多样性与传感视角多样性应分开。
- 待核 / 限制：正文425 recordings与198 Aria + 226 Quest3相差1，需manifest厘清。

P019 EgoBody (2021)

原作：<https://arxiv.org/abs/2112.07642>

本次PDF：<https://arxiv.org/pdf/2112.07642v3>

PDF SHA256：2e3713a6294f2f6db2fb815fc25f0ce080ce1fec87b663ccac54ff669c7de501

阅读页：1、2、4、6、7、8、9、10、11、12。交互分类、capture、数据与split、3DHPS metric。

- 研究类型：人类视频与动作数据；人体与交互感知评测
- 领域：休闲与运动、社交与沟通、穿戴交互与动作界面
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：15个室内scene，有扫描mesh；每次两人交互，一人佩戴HoloLens2。

- 任务：5种社会交互分类用于搜集；主benchmark为interactee的3D人体形状 / 姿态估计，不是5个机器人任务。
- 题数 / 数据：125 sequences / 36人；219,731多视角timestamps、199,111 ego影格；可见interactee子集175,611影格，其中62,155 test。
- 评估方式：MPJPE、vertex-to-vertex error；pelvis translation alignment与Procrustes alignment分开。
- Split / 信息条件：subject不重叠；interactee train / val / test = 90,124 / 23,332 / 62,155。
- 来源关系：自行搜集；同时有MVSet、EgoSet、可见interactee三个相依子集，不能相加。
- 可复用：补社交互动、遮挡与人体观测；不提供完成生活工作的robot action evaluator。
- 待核 / 限制：扫描资产是否可直接用于交互模拟未验证。

P020 EgoHumans (2023)

原作：<https://arxiv.org/abs/2305.16487>

本次PDF：<https://arxiv.org/pdf/2305.16487v2>

PDF SHA256：7d7f42b85231561ddb1a646fefbdec9fe97bc1e02455d7603006aa7ceac3de30

阅读页：1、2、6。数据统计、test切分、tracking评测与主端点定义。

- 研究类型：人类视频与动作数据；人体与交互感知评测
- 领域：休闲与运动、社交与沟通、穿戴交互与动作界面
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：6个地点 = 3室内 + 3室外；7个活动sequence，20人，多人同时戴Aria。
- 任务：篮球、击剑、羽毛球、网球、排球、追逐、搭城堡；主要3D多人追踪，并提供2D/3D姿态与mesh。
- 题数 / 数据：125K ego RGB、250K灰阶、446K外部图像；正式ego train77,260 / test47,740 images。
- 评估方式：CLEAR追踪指针（MOTA、FP、FN、IDs）、IDF1、HOTA；因主要使用off-the-shelf detector，以IDF1作主要tracking指针。
- Split / 信息条件：train/test地点不重叠；同步多人的多视角不能视为独立活动。
- 来源关系：新搜集多视角；COCO用于模型训练对照，不算本benchmark题数。
- 可复用：拓展户外多人交互感知；不能直接宣称涵盖同量可运行robot工作任务。
- 待核 / 限制：各附加pose / mesh端点是否有独立正式leaderboard与有效ID需另查。

P021 Ego-ExoLearn (2024)

原作：<https://arxiv.org/abs/2403.16182>

本次PDF：<https://arxiv.org/pdf/2403.16182v3>

PDF SHA256：bca30af05c678a221e17c8ff0fa92006870fc0b46f569e824b52c98aefc8a15b

阅读页：1、2、3、4、5、6、7、8、11、12、14、16。数据 / 来源、四大benchmark、association、anticipation / planning、skill，及专用split附录。

- 研究类型：人类视频与动作数据；跨视角程序学习

- 领域：餐饮与烹饪、实验室操作
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：4个厨房+3个lab；ego示范跟做与exo教程异步、非同一环境。
- 任务：8程序=5日常+3实验室；4大benchmark含association、action understanding、skill ranking、captioning；39粗步骤，planning取27类；anticipation取19 verbs / 31 nouns。
- 题数 / 数据：432 ego视频96.5小时+315 exo视频23.5小时；34,239有效skill比较对，从40,191候选对筛选。ego anticipation test约17.3K片段。
- 评估方式：association：20候选top-1；anticipation：1秒前class-mean top-5 recall；planning：8步ED@K、5条预测串行；skill：pairwise ranking accuracy；supervised recognition：macro mAP。
- Split / 信息条件：端点采专用过滤集；保留ego→exo、exo→ego、UDA、distillation、co-training不同信息条件。
- 来源关系：日常exo取网络视频，lab exo由资深人员录制；动词 / 名词taxonomy借Ego4D再扩充，不表示视频皆来自Ego4D。
- 可复用：对示范到robot的跨视角程序转移很相关；实验室程序补生活操作库缺域。
- 待核 / 限制：captioning及segmentation专用metric / 完整case ID仍需数据端核对。；附录planning两组split重复写egocentric，保留原文歧义，未擅改。

P022 CaptainCook4D (2023)

原作：<https://arxiv.org/abs/2312.14556>

本次PDF：<https://arxiv.org/pdf/2312.14556v4>

PDF SHA256：03be2a06a5c5cc778808214ae9232f3156dfd3ba60c07140d93d1a20222cc0ae

阅读页：1、2、3、4、5、6、7、8、9、38。采集、错误taxonomy、三大benchmark定义及评测。

- 研究类型：人类视频与动作数据；错误辨识与程序恢复
- 领域：餐饮与烹饪
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：10个真实厨房，8名参与者；Hololens2与GoPro同步。
- 任务：24个WikiHow食谱、7种错误：准备、测量、技术、时间、温度、缺步、顺序；错误类别不另算7生活domain。
- 题数 / 数据：384 recordings、94.5小时、5.3K步骤标注及10K细动作标注；细动作只在约20%数据标注。错误有刻意诱发及自然发生。
- 评估方式：错误辨识accuracy / precision / recall / F1 / AUC；step与recording split分开。；multi-step localization及RobustMSL用mAP、R@K、temporal IoU；只正常数据训练、正常 / 错误数据测试分列。；procedure learning沿EgoProceL采步骤precision / recall / IoU。
- Split / 信息条件：error recognition有step / recording split；MSL有不同泛化split，不能把step split成绩当跨录像泛化。
- 来源关系：新录像片，程序取WikiHow；procedure基线与评分沿EgoProceL，不是重用其全部素材。
- 可复用：可具体借用规则违反与near-failure定义；观测到错误不等于机器人已能运行恢复。
- 待核 / 限制：各原生split精确ID数尚未导入；错误组合空间只被部分采样。

P023 EgoProceL (2022)

原作：<https://arxiv.org/abs/2207.10883>

本次PDF: <https://arxiv.org/pdf/2207.10883v1>

PDF SHA256: 533531617781659b6d42cbb81529f76f79277cb3cf1d05dad3504547b4ecdf9a

阅读页: 1、3、4、5、6、8、9、10。数据选取与联集、procedure问题、key-step排序、评测协定。

- 研究类型: 人类视频与动作数据; 人类程序视频与步骤定位
- 领域: 餐饮与烹饪、工艺与修缮、装配与生产作业、农业与园艺
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 来源数据场景混合; 没有共同去重的独立环境总数。
- 任务: 16个程序, 平均8.7 key-steps; 含料理、玩具机车、搭帐篷、PC组装 / 拆解。
- 题数 / 数据: 62小时、130人; 原作本文未在已读统计表给单一可评test题总数。
- 评估方式: Hungarian matching后按每个key-step计frame precision / recall / F1 / IoU再平均, 避免背景与长步骤垄断分数。
- Split / 信息条件: 采task-specific self-supervised procedure learning设置; K是模型key-step数超参数, 不是数据集总任务量。
- 来源关系: 明确重用CMU-MMAC、EGTEA Gaze+、MECCANO、EPIC-Tents, 再增自录PC装拆; 不是全新独立62小时。
- 可复用: 是从既有程序数据联集再补缺域的直接先例; 我们须说明添加任务 / 规则, 不能把联集本身当全部新贡献。
- 待核 / 限制: 所有视频ID、跨上游重复量和各task可评片段数需manifest核对。

P024 EPIC Fields (2023)

原作: <https://arxiv.org/abs/2306.08731>

本次PDF: <https://arxiv.org/pdf/2306.08731v2>

PDF SHA256: c7c08e1c9614782d2dcddaeec95b253c5d9f756ff2c4d30b712bcac6a90eebd

阅读页: 1、2、3、5、6、7、8、22。重建覆盖、三个benchmark、难度与frame切分。

- 研究类型: 人类视频与动作数据; 3D场景与世界建模
- 领域: 居家整理与清洁、餐饮与烹饪
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: EPIC100的45个厨房; 671视频成功重建, 没有添加671个独立layout。
- 任务: D-NVS新视角合成、UDOS动态 / 半静态对象分割、VOS; 不是671个操作任务。
- 题数 / 数据: 18,790,333已注册camera-pose影格; D-NVS只取50视频 (14.7小时、2.86M注册影格)。
- 评估方式: D-NVS: PSNR, 前景 / 背景分列; UDOS: segmentation mAP; VOS沿VISOR。; 难度依in-action/out-of-action及与train frame的时间距离; hard、medium排除附近1秒train frame。
- Split / 信息条件: 每视频val/test交替抽样; UDOS无监督可看全视频, 不是D-NVS同一可见输入。
- 来源关系: EPIC100 + VISOR的相机与几何扩充, 来源视频 / mask共用。
- 可复用: 提供3D / 视角 / 动态对象评测; 重建相机轨迹不是robot action轨迹。
- 待核 / 限制: 50个benchmark video-scenes与原厨房一对多关系待逐ID导入。

P025 EgoPet (2024)

原作: <https://arxiv.org/abs/2404.09991>

本次PDF: <https://arxiv.org/pdf/2404.09991v1>

PDF SHA256: 8be645841806230228c292995eb6538540f9be6d228b916b37e53fefeeca59ca

阅读页: 1、2、4、5、6、7、8、9、10。数据、3种预测端点、各自标注与指针。

- 研究类型: 人类视频与动作数据; 动作与轨迹预测
- 领域: 宠物照护与动物活动
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 动物网络视频无去重场景总量; VPP额外robot测试有office、park、beach三处。
- 任务: VIP交互辨识 / 17种交互对象; LP预测未来4秒40个位置; VPP预测terrain latent的过去 / 未来。
- 题数 / 数据: 6,646片段、84小时; VIP 1,449标注片段=754train+695test; LP 6,126train / 249val; VPP另20分钟robot测试。
- 评估方式: VIP: accuracy / AUROC及object top-1/top-3; LP: ATE / RPE的RMSE; VPP: latent MSE。
- Split / 信息条件: 三端点分开train/test或val; LP为SLAM pseudo-GT且有人工筛选, 非mocap真值。
- 来源关系: TikTok / YouTube新整理; VPP训练另用既有robot数据, 不能把动物视频数算为robot控制题。
- 可复用: 补充低视角移动与人以外的具身感知; 与操作benchmark应分层比较。
- 待核 / 限制: 正文819原视频与482+338的平台分量不一致, 待manifest厘清。

P026 EgoHOS (2022)

原作: <https://arxiv.org/abs/2208.03826>

本次PDF: <https://arxiv.org/pdf/2208.03826v1>

PDF SHA256: 94b61333b3477ef582a94281cc28852c750d6fbe096ddfe90c9434ca39101f07

阅读页: 1、2、4、5、6、9、10、12。来源、手物标签定义、OOD测试与主要分割评估。

- 研究类型: 人类视频与动作数据; 视频数据与感知评测
- 领域: 居家整理与清洁、餐饮与烹饪
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: Ego4D、EPIC、THU-READ及自录GoPro多来源; 无共同scene ID总数。
- 任务: 左 / 右手、左 / 右 / 双手接触物分割; 直接 / 间接接触有标注, 但本文主要评估直接接触。
- 题数 / 数据: 原作总量11,243图像; OOD另500影格来自30个YouTube视频, 主分割实验预设在此测试。
- 评估方式: mIoU; binary hand、left/right hand、hand+arm、held-object等标签定义分开比较。
- Split / 信息条件: 以原作validation选checkpoint, 500-image OOD为另列测试; 不能把源视频数当测试题数。
- 来源关系: 直接重用Ego4D、EPIC影格; 跨库去重需frame时间戳。
- 可复用: 可作接触判定与视觉状态监督; 11,243不是11,243项可运行操作。
- 待核 / 限制: 正文来源分量7,458+2,121+806+350未加总为11,243; subjects/activity的表格与叙述亦互换, 暂不采这两项总数。

P027 EgoPCA (2023)

原作：<https://arxiv.org/abs/2309.02423>

本次PDF：<https://arxiv.org/pdf/2309.02423v1>

PDF SHA256: b1562d6e36e0c788642711c6bcd038ed83e381ad8f9ae62cc5e341ee516c0a39

阅读页：1、2、4、5、6、8、14。One4All来源统一、采样、表2与原生识别评测；附录类别合并。

- 研究类型：人类视频与动作数据；跨数据集集成与评测方法
- 领域：居家整理与清洁、餐饮与烹饪
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：来源视频混合，不提供新的可计数交互环境。
- 任务：EPIC100、EGTEA、Ego4D-AR、Something-Else合并语义；pretrain394类、test204类，联集401类含zero-shot。
- 题数 / 数据：表2列pretrain20K / 30K / 50K；test3K / 5K / 10K为嵌套子集，不能相加成18K独立题。
- 评估方式：top-1 verb/action accuracy；另用语义、手 / 物位置、手姿、camera motion、模糊程度分析分布。
- Split / 信息条件：上游train与val/test分开抽；不同规模套件彼此包含。
- 来源关系：本身就是多来源语义合并与平衡采样先例；没有将所有源任务转成robot控制。
- 可复用：对任务联集、分布分析、平衡采样直接相关；须辨识此类前作，不能只与单域benchmark比规模。
- 待核 / 限制：§3.4提5K / 10K / 20K但表2及附录为3K / 5K / 10K；采表2口径并保留冲突。

P028 EgoSchema (2023)

原作：<https://arxiv.org/abs/2308.09126>

本次PDF：<https://arxiv.org/pdf/2308.09126v1>

PDF SHA256: 4ae865287c1d40b806c5f51e4b5101fe90f7d246a201668f14bbb9cab00b442f

阅读页：1、2、3、5、6、7、9、14。数据生成与人工过滤、temporal certificate定义、评测与datasheet精确量。

- 研究类型：理解、推理与规划；视频问答与推理
- 领域：居家整理与清洁、餐饮与烹饪、工艺与修缮、农业与园艺
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：Ego4D视频子集，未另外提供去重后环境数。
- 任务：长视频五选一QA；temporal certificate量必要证据时长，不能把3分钟输入长度直接当难度。
- 题数 / 数据：5,063题，每题一段3分钟视频；约250小时为衍生片段量。
- 评估方式：选项accuracy；人类时间 / 影格受限条件另列。；QA人工过滤要求至少30秒certificate，与完整3分钟视频长度区分。
- Split / 信息条件：本文定位zero-shot诊断评测；公开标签子集与完整隐藏评测需依发布版本另外核对。
- 来源关系：Ego4D非重叠3分钟片段产题，与其他Ego4D衍生QA仍可能共用上游视频。
- 可复用：可借certificate、人类验证和blind基线衡量时间推理难度；不评机器人实际完成。
- 待核 / 限制：本库未逐ID对齐所有Ego4D衍生benchmark。

P029 EgoThink (2023)

原作：<https://arxiv.org/abs/2311.15596>

本次PDF：<https://arxiv.org/pdf/2311.15596v2>

PDF SHA256: f52b14647c715c4187f0f53bb90bde9e7d6f2f5d10eefc5da2a39b714076e040

阅读页：1、2、3、4、5、6、13、14。人工QA搜集、700题统计、六能力十二维度、judge协定。

- 研究类型：理解、推理与规划；视频问答与推理
- 领域：居家整理与清洁、餐饮与烹饪、工艺与修缮
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：595个Ego4D母视频；scene统计是语义场景如kitchen，不能当相同数量的独立物理房间。
- 任务：6能力 / 12细分维度：对象、活动、定位、推理、forecasting、planning；输入为单张图像。
- 题数 / 数据：700图像QA，无重复选图；每维度至少50题，activity与forecasting各100。
- 评估方式：GPT-4依问题、答案、reference打0 / 0.5 / 1分；是模型评审分数，不是精确答案匹配accuracy。
- Split / 信息条件：zero-shot评测；无一般train/val/test训练配额。人工审核QA与后续模型judge分开。
- 来源关系：抽Ego4D影格，最多同video两张；能力分类不等同生活domain分类。
- 可复用：可借主观 / 开放答案rubric；planning问答不能当作控制成功证据。
- 待核 / 限制：跨库母视频重叠及judge版本稳定性需实作端固定。

P030 EgoPlan-Bench (2023)

原作：<https://arxiv.org/abs/2312.06722>

本次PDF：<https://arxiv.org/pdf/2312.06722v3>

PDF SHA256: c15ca6dd2823dc0af2a6f55ce15cae49463268b814075cc9260e0d79ba751373

阅读页：1、2、3、5、6、7、14。数据源、goal到QA、统计、选项评分、instruction-tuning数据区别。

- 研究类型：理解、推理与规划；视频问答与推理
- 领域：居家整理与清洁、餐饮与烹饪
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：原作报419 scenes（视频观测场景），非419个已建模robot layouts。
- 任务：下一步planning QA；表2合计3,269 task goals与3,185候选action plans，两者不等同题数。
- 题数 / 数据：4,939评测QA=3,355 val+1,584 test；50K EgoPlan-IT是另外训练集，非50K测试题。
- 评估方式：MC accuracy；部分开放模型以候选答案条件likelihood排序，需保留不同推论界面。；观测只可到下一动作开始前；历史状态不能泄漏GT下一步。
- Split / 信息条件：EgoPlan-Val / EgoPlan-Test；EgoPlan-IT仅用EPIC来源，以Ego4D子集查跨数据泛化。
- 来源关系：EPIC-KITCHENS与Ego4D的衍生QA；不可与上游视频或EgoPlan2直接加成独立新活动。
- 可复用：提供goal / 历史 / 当前观测→下一步的可用题型；不同goal文字仍须做语义等价审核。

- 待核 / 限制：正文3,296 goals与表2的3,269相差27；采表2数字且保留差异。；419 scenes的跨视频物理等价关系未核。

P031 EgoPlan-Bench2 (2024)

原作：<https://arxiv.org/abs/2412.04447>

本次PDF：<https://arxiv.org/pdf/2412.04447v2>

PDF SHA256：86d13b4d204df0eee1eec14c5a5dde9f3cdc465b7e5b96009d4d8b7f4c48f353

阅读页：1、2、3、4、5、6、7。4 domains / 24 scenarios清单、goal过滤、观测选取、MC评分。

- 研究类型：理解、推理与规划；视频问答与推理
- 领域：居家整理与清洁、餐饮与烹饪、工艺与修缮、零售与购物、实验室操作、个人照护、交通移动与车辆维修、农业与园艺、休闲与运动
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：24个语义scenario类别，非24个物理scene；来源1,113个Ego4D视频。
- 任务：4原生domains（Work / Daily life / Hobbies / Recreation）；保留4–20步的goal；284 goal verbs不是284个正式任务。
- 题数 / 数据：1,321道四选一QA；比第一版题少但原作场域更广，两种尺度要分开。
- 评估方式：直接匹配A/B/C/D计accuracy；原作不引入第三方LLM judge。
- Split / 信息条件：评测用QA；原作观测筛选以排除单张即可答与已泄漏动作的影格。
- 来源关系：Ego4D更新版衍生；与第一版方法相承，但不是在同一题集上直接扩成更大数量。
- 可复用：其24 scenario清单是广度候选的重要依据；不能拿少量QA即宣称域内所有任务已覆盖。
- 待核 / 限制：task-goal语义去重与跨EgoPlan版本同源query重叠未逐ID核。

P032 EgoTaskQA (2022)

原作：<https://arxiv.org/abs/2210.03929>

本次PDF：<https://arxiv.org/pdf/2210.03929v1>

PDF SHA256：9a06fc9a9cfb5e7102f62ff34137fd261251eb9bd7c19ec19b07d4b8f36b5e87

阅读页：1、2、4、5、6、7、8、10。LEMMA状态 / 因果标注、QA生成、两种split与metric。

- 研究类型：理解、推理与规划；视频问答与推理
- 领域：居家整理与清洁、餐饮与烹饪、社交与沟通
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：LEMMA多代理家务视频；没有新的独立场景全集。
- 任务：3个scope（world / intent / multi-agent）×4问法（描述 / 预测 / 解释 / 反事实）；属QA taxonomy，不是12个生活工作。
- 题数 / 数据：从368K程序生成候选挑出40K balanced QA，基于约2K ego clips及30K状态 / 人物注记blocks。
- 评估方式：在answer vocabulary上分类，报accuracy；按scope / type / semantic与open/binary分列。
- Split / 信息条件：normal以QA按3:1:1分train/val/test；indirect以多步间接指涉作泛化测试，不可当场景互斥split。

- 来源关系：直接扩充LEMMA标注；因果trace由前 / 后置条件规则生成，belief标注由多数人工票决。
- 可复用：提供规则、前置条件、因果与多代理信念的具体扩充；反事实QA不等于模拟器已验证反事实轨迹。
- 待核 / 限制：40K题的video父ID与上游LEMMA环境重用未导入。

P033 EgoLife (2025)

原作：<https://arxiv.org/abs/2503.03803>

本次PDF：<https://arxiv.org/pdf/2503.03803v3>

PDF SHA256：62089719b6879f1f7f10401989959c9a7e0531aa411284d10c9a713f0634c49a

阅读页：1、3、4、5、6、7。搜集、QA流程、正式题库与当版跑分范围。

- 研究类型：理解、推理与规划；长期记忆与生活助理
- 领域：居家整理与清洁、餐饮与烹饪、休闲与运动、社交与沟通
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：1个自建EgoHouse、6人共同生活7天；15台外部相机不是15个环境。
- 任务：5题型：EntityLog、EventRecall、HabitInsight、RelationMap、TaskMaster。
- 题数 / 数据：约300小时原始 / 266小时保留视频；正式EgoLifeQA 3,000题（每人500）。本版§5快速实验只用Jake的500题；EgoIT-99K为训练数据。
- 评估方式：multiple-choice accuracy；依certificate长度、题型、audio / identity设置分析。；比较captioner时，最终QA由共同GPT-4o回答；这与将GPT当评分judge不同。
- Split / 信息条件：来源为连续一周个人经历；99K / D1模型训练与QA证据时间应另外追踪。
- 来源关系：新录EgoHouse；EgoIT-99K含其他ego来源，不能把训练集99K称本benchmark添加test量。
- 可复用：补多日记忆、习惯与人际关系；需要保留个人 / 共同事件重叠而非把6人同步视频全当独立时长。
- 待核 / 限制：完整3,000题是否有同设置的发布成绩，须另查后续版本。

P034 EgoVLP (2022)

原作：<https://arxiv.org/abs/2206.01670>

本次PDF：<https://arxiv.org/pdf/2206.01670v2>

PDF SHA256：cd7cf25aa25da8a2a88d0875ec2f0a5cf56f99a045eb7c11957a6e27784f584f

阅读页：1、3、4、5、6、7。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：人类视频与动作数据；视频数据与感知评测
- 领域：居家整理与清洁、工艺与修缮
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：Ego4D的129scenario labels；来源环境重用。
- 任务：EgoMCQ包含inter-video/intra-video两种五选一video-text配对；EgoClip是训练库。
- 题数 / 数据：EgoClip约3.85M narrations/2,927h；EgoMCQ约39K题 = 24K inter+15K intra。

- 评估方式：EgoMCQ accuracy；下游retrieval、NLQ、recognition分开。
- Split / 信息条件：EgoClip排除Ego4D val/test；EgoMCQ再人工移除和pretraining共用multi-view的视频。
- 来源关系：Ego4D→EgoClip/EgoMCQ；两位narrators不代表两份独立行为。
- 可复用：原先只列成方法会漏掉真正添加的EgoMCQ；应把论文与其多个资源分开登记。
- 待核 / 限制：39K是概述约数；最终题ID与选项去重需原始manifest。

P037 EgoEnv (2022)

原作：<https://arxiv.org/abs/2207.11365>

本次PDF：<https://arxiv.org/pdf/2207.11365v3>

PDF SHA256：30fca03c8d8d57b800a30c4d921db35c49f8d6339b1679c30268654e7783ba47

阅读页：1、6、7、8。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：理解、推理与规划；空间理解与affordance
- 领域：居家整理与清洁
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：pretraining 900 HM3D scenes；HouseTours选886houses，MP3D90scenes；各自保留source单位。
- 任务：room prediction与NLQ两端点；21real room classes，MP3D9classes不是新的生活domain。
- 题数 / 数据：约15K合成walkthroughs×512steps；HouseTours约32h、MP3D146walkthroughs；QA精确总量未核。
- 评估方式：room分类、NLQ temporal localization；local-state AP另测。
- Split / 信息条件：HouseTours按house切，Ego4D/MP3D用原split；video memory可读query附近全片，非严格在线。
- 来源关系：添加HouseTours labels、Ego4D NLQ沿用，HM3D/MP3D资产重用。
- 可复用：补house-tour与室内环境理解；source录像场所与sim资产必须分开。
- 待核 / 限制：Ego4D段落称1,259scenes，需核是video/session或实体place；不纳跨来源环境总和。

P038 OpenEQA (2024)

原作：

https://openaccess.thecvf.com/content/CVPR2024/html/Majumdar_OpenEQA_Embodied_Question_Answering_in_the_Era_of_Foundation_Models_CVPR_2024_paper.html

本次PDF：

https://openaccess.thecvf.com/content/CVPR2024/papers/Majumdar_OpenEQA_Embodied_Question_Answering_in_the_Era_of_Foundation_Models_CVPR_2024_paper.pdf

PDF SHA256：d2c714b7cfdcee8fe6cde607296c15689ecff298b752611c913458fd3964ca48

阅读页：1、2、3、4、7。EM / Active定义、数据源与生成、题数及LLM-Match协定。

- 研究类型：理解、推理与规划；具身问答与探索
- 领域：居家整理与清洁、办公与教育

- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：搜集阶段100个ScanNet scenes + 87个HM3D scans；这是生成候选history范围，非已验证题目引用的152个history IDs。
- 任务：7问答类别；两种设置EM-EQA / A-EQA。Active只允许导航探索，未包括开柜等操作。
- 题数 / 数据：正式1,636题 = 1,079 ScanNet + 557 HM3D；A-EQA重用这557题，不能加成2,193独立QA。
- 评估方式：LLM-Match给1-5分再范式；不是字符串match或MC accuracy；Active另按路径长度折算效率；object localization有多个合理reference答案。
- Split / 信息条件：来源ScanNet val/test、HM3D val场景；相同QA跨EM与Active，只改可用信息 / 探索权限。
- 来源关系：ScanNet / HM3D + Habitat。与本库固定manifest的152 history IDs口径不同，187候选不等于187已取得交互环境。
- 可复用：是同一问题在记忆与可探索环境两种设置的明确先例；应以共享query而非双倍题数表示。
- 待核 / 限制：Active公开资产 / 运行入口和本文可评557题的可重现范围需另核；已取得QA metadata不代表所有素材到位。

P039 RoboVQA (2023)

原作：<https://arxiv.org/abs/2311.00899>

本次PDF：<https://arxiv.org/pdf/2311.00899v1>

PDF SHA256：0d6f31eb8631105b7abfd15b617c7477404b7e7694955c0a3108fcff05d658bf

阅读页：1、2、3、4、5、6、10。数据搜集、10种QA扩充、VQA人工判分与三种planning介入评测。

- 研究类型：理解、推理与规划；具身问答与探索
- 领域：居家整理与清洁、餐饮与烹饪、办公与教育
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：3栋办公楼，robot / 人手 / 人持夹具3种embodiment。
- 任务：2,722 unique长指令、26,798 unique中程指令；字符串去重不是共同语义任务去重。10种QA包含规划、完成检测、affordance、过去描述 / 未来预测。
- 题数 / 数据：5,246长程episodes、92,948中程episodes、238小时；VQA val/test各约1,000笔，来自各50 episodes。另100个脱机planning episodes / 854步、10个live teleop任务及1个自主5步任务。
- 评估方式：VQA先查已人工判定的答案缓存，未见答案交人工判correct/incorrect；planning分cognitive / physical intervention rate；人类救援使所有任务完成，不能把完成率当自主成功率。
- Split / 信息条件：episodes互斥但scenes可重叠；robot-only与human+robot测试分开。
- 来源关系：自身多机体搜集；SayCan固定60任务是外部baseline范围，不是RoboVQA任务总量。
- 可复用：是大广度robot / human数据与高低级分离评测的直接比较对象；数万指令已大于先前任意5,000配额。
- 待核 / 限制：完整release QA精确行数与文字语义去重量尚未重算。

P040 RoboBench (2025)

原作：<https://arxiv.org/abs/2510.17801>

本次PDF：<https://arxiv.org/pdf/2510.17801v2>

PDF SHA256：b34e12bf6f096b03930eb63d6e6580345d4fc1330c8c54c7f9660c501b7ff204

阅读页：1、2、4、5、6、7、8、9、10、18、22。5维度 / 25端点、数据表、人机标注、Q1-Q3评分及下游控制验证。

- 研究类型：理解、推理与规划；综合具身认知评测
- 领域：居家整理与清洁
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：多来源robot视频与自录配置；未报可相加的去重物理layout总量。
- 任务：5维度、14能力群、25评测端点；不同于25个生活工作任务。
- 题数 / 数据：6,092 questions / 4,336 unique items；含1,895 MC与Q1/Q2/Q3各1,973 / 842 / 1,192，加190navigation。相同item衍生多种问题。
- 评估方式：感知 / affordance / failure用MC accuracy；Q3 binary accuracy。；Q1用MLLM评node correctness与milestone completion；Q2用MLLM评skill/object/parameter。所称world-simulator是模型判断，不是刚体物理模拟运行。；另以CALVIN / LIBERO控制结果查关联，属下游验证子集。
- Split / 信息条件：QA与下游CALVIN ABC→D、LIBERO-Long10任务 / 各50trials分开；模型全对题会被筛掉，难度带有选模依赖。
- 来源关系：多robot来源及RoboMIND失败轨迹；planning failure有人工注入，execution failure来自真rollouts，证据不能混。
- 可复用：最直接的all-in-one具身认知比较对象之一；我们需清楚提出场域 / 任务联集与可验证规则的添加部分。
- 待核 / 限制：来源unique item跨上游重用尚未逐ID去重；v1 unique items为4,333，不套用到v2。

P041 EgoCross (2025)

原作：<https://arxiv.org/abs/2508.10729>

本次PDF：<https://arxiv.org/pdf/2508.10729v2>

PDF SHA256：f4c3606509844a990b9b1c2fc3df05bdab0cff9a08af8fa5446cc9080f49e743

阅读页：1、3、4、7、10。domain选择、五个上游数据、QA数、Close/Open评分与finetuning split。

- 研究类型：理解、推理与规划；视频问答与推理
- 领域：工艺与修缮、医疗与手术支持、休闲与运动、宠物照护与动物活动
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：4个domain来自5数据集，不是4个环境；含内视镜工具视角，不全是人类头戴相机。
- 任务：identification / localization / prediction / counting四类，15细分题型。
- 题数 / 数据：957 QA、798 clips；OpenQA与CloseQA为同一问题两种格式，不是1,914个独立题。
- 评估方式：CloseQA：4选1 accuracy；OpenQA：Qwen-Max检查语义正确与reference。
- Split / 信息条件：主zero-shot全题；SFT / RL pilot将原QA再70:30分train/test，其分数不能与全题zero-shot当相同测集。
- 来源关系：EgoSurgery、CholecTrack20、ENIGMA-51、ExtremeSportFPV、EgoPet的衍生QA。
- 可复用：直接提示家务之外的缺域；跨domain来源联集已有前例，要把多样性贡献做得可量化。
- 待核 / 限制：上述五个上游是否全部在现有书目中独立登记需补查。

P042 RoboSpatial (2024)

原作：<https://arxiv.org/abs/2411.16537>

本次PDF: <https://arxiv.org/pdf/2411.16537v5>

PDF SHA256: 58a5b655a8d69265586b817547ebe08770c6d88ea05ea17d50c2fb56ead76c22

阅读页: 1、2、3、4、5、6。关系与frame定义、生成规则、表2、Val/Home评测。

- 研究类型: 理解、推理与规划; 空间理解与affordance
- 领域: 居家整理与清洁、办公与教育
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 训练4,916 indoor scans + 190 tabletop scenes; validation 40 scans + 77 scenes; 来源重用而非新扫描5K个robot场景。
- 任务: context / compatibility / configuration三类空间关系, ego / world / object三种reference frame。
- 题数 / 数据: 约3M是生成训练QA/relations; 正式Val 6,000题, 每关系2,000; 新录Home另350人工题。
- 评估方式: yes/no accuracy; 座标预测以3D点是否落在reference convex hull判正确。; compatibility以bbox放置无重叠且各轴10cm余量的几何规则构造, 不等于真实可操作性。
- Split / 信息条件: Val scans完全未在training中; 另有indoor↔tabletop泛化与OOD Home。
- 来源关系: ScanNet、Matterport3D、3RScan经EmbodiedScan取几何; 桌面用HOPE、GraspNet-1B; BLINK / SpatialBench是外部eval。
- 可复用: 是规则自动扩题与多reference-frame评测的直接先例; 可扩大题量, 但需保留train与eval区别。
- 待核 / 限制: 源scan之跨库重建重复量及bbox规则边界误差需原生ID / 几何审核。

P045 ManipBench (2025)

原作: <https://arxiv.org/abs/2505.09698>

本次PDF: <https://arxiv.org/pdf/2505.09698v2>

PDF SHA256: 7cd33f53355500d085efdd4c1c80dd05509e3d3b24c6ec7232519a9481e53d53

阅读页: 1、3、4、5、6、27。三种数据源、五种操作类别、MCQ创建及实体验证。

- 研究类型: 理解、推理与规划; 空间理解与affordance
- 领域: 衣物与洗护
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: DROID / Bridge原始场景、自录布料工作站、SIMPLER / RLBench / SoftGym与添加IsaacSim ball场景。
- 任务: pick-place、articulated、deformable、tool、dynamic五种操作类别; 布料10理解维度; 另外7个真实机器人验证任务。
- 题数 / 数据: 12,617 MCQ = 9,180公共robot数据题 + 2,662布料题 + 其余simulation题; 公共数据Q1 6,120、Q2 3,060, 来自同episode的augmentation不算新任务。
- 评估方式: MC accuracy; Q2要pick与place两子题都对才算joint correct, 第二题提供GT pick。; MCQ所称pick-place success不等于实际robot rollout success; 另列UR5物理验证。
- Split / 信息条件: MCQ benchmark与7真机任务分开; 新组合未在MCQ中共现, 并非保证所有对象个别都未见。
- 来源关系: 多既有数据 / simulation衍生 + 自录布料; 有question augmentation共享母episode。
- 可复用: 直接对应多来源robot操作→多模态题库; 需比它更广的工作用途与更完整规则, 而非只加QA格式。
- 待核 / 限制: 各simulation来源精确母episode数与跨题同源关系需manifest导入。

P051 USST / EgoPAT3D trajectories (2023)

原作: <https://arxiv.org/abs/2307.08243>

本次PDF: <https://arxiv.org/pdf/2307.08243v2>

PDF SHA256: 592b977dc3d758aa321266c4f5e7588d29c8fd207b4630fa191021a49d73b634

阅读页: 1、5、6。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 未来动作 / 交互预测; 动作与轨迹预测
- 领域: 居家整理与清洁、穿戴交互与动作界面
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: EgoPAT3D-DT 14scenes = 11seen+3unseen; H2O重用原capture。
- 任务: 3D hand-centroid trajectory forecasting; 2D projection另报, 不是完整手指控制。
- 题数 / 数据: H2O 8,203/1,735/3,715 train/val/test windows; EgoPAT3D-DT 6,356/846/1,605 seen test+2,334 unseen test。
- 评估方式: ADE/FDE, 3D以米、2D以frame size范式; 3D模型投影和2D直接模型分开。
- Split / 信息条件: H2O64frame windows步长15, 窗口重叠; EgoPAT3D有held-out scenes。
- 来源关系: H2O→PT/DT、EgoPAT3D→DT是添加标注; 不把父原片重复计。
- 可复用: 可添加trajectory模块; 相近窗口须依原视频群聚切分与估计。
- 待核 / 限制: 后续Diff-IP2D提及原repo的FDE erratum; 比较成绩需固定修正版本。

P053 HandsOnVLM (2024)

原作: <https://arxiv.org/abs/2412.13187>

本次PDF: <https://arxiv.org/pdf/2412.13187v2>

PDF SHA256: 9ad31595678bd06e9139e118c6a693354034f7c08a91f74988de80f3e5836948

阅读页: 1、5、6、7。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 未来动作 / 交互预测; 动作与轨迹预测
- 领域: 餐饮与烹饪、穿戴交互与动作界面
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: EPIC/H2O/FPHA/Ego4D原视频环境, 无添加可运行robot scenes。
- 任务: VHP显式动作指令与RBHP隐式意图两预测任务; 10observed→4future frames, 4fps。
- 题数 / 数据: RBHP生成7.5K EPIC与8K Ego4D QA-prediction pairs; 24K/epoch是抽样预算而非独立题库。
- 评估方式: ADE/FDE/WDE, 不是语言答对率或robot完成率。
- Split / 信息条件: EPIC validation及H2O/FPHA zero-shot; *版本混合五个额外QA训练来源。
- 来源关系: OCT-style手轨迹标注+GPT生成implicit instructions; 父视频和explicit/implicit变体共享。
- 可复用: 是扩充任务规则的来源: 同轨迹在明示/隐式需求下重测, 保留对照关系。
- 待核 / 限制: 生成指令的精确train/test manifest与ground-truth歧义需核; 不是每次生成都新语义task。

P054 EgoVid-5M / EgoDreamer (2024)

原作: <https://arxiv.org/abs/2411.08380>

本次PDF: <https://arxiv.org/pdf/2411.08380v1>

PDF SHA256: c878ace0c6d18cf230b26b97a809cdaeda44659ed1cdf693245c44b6681b7f9d

阅读页: 1、4、5、6、7、8。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 世界模型与预测表示; 世界模型与视频生成评测
- 领域: 居家整理与清洁、办公与教育、工艺与修缮、休闲与运动
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 重用Ego4D来源, 场景总数未报。
- 任务: 文字与camera kinematics条件下video generation; kinematic label不是robot action。
- 题数 / 数据: 名义5Mclips; 正文4.9Mtrain、1.2Kval, 只有65K具可用IMU的kinematic subset。
- 评估方式: CD-FVD、semantic/action alignment、clarity、motion smoothness/strength及pose errors。
- Split / 信息条件: val按品质/多样性选, 已读段未明示source-video-disjoint; 三个1Mcleaning subsets不是添加数据。
- 来源关系: Ego4D→EgoVid, VIO/MLLM重标; generation评测沿用AIGCBench/VBench部分metrics。
- 可复用: 补ego世界模型, 但评测视觉品质和实际可控物理成功需另验证。
- 待核 / 限制: 5M不能全部叫action-conditioned examples; 4.9M与5M概述差异保留。

P057 Motor attention and action forecasting (2019)

原作: <https://arxiv.org/abs/1911.10967>

本次PDF: <https://arxiv.org/pdf/1911.10967v2>

PDF SHA256: 91f5c905b44c16ebb6de7ac8c6523846a0254a218889c9afb2fc8305e061fc33

阅读页: 1、7、8、9、11。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 未来动作 / 交互预测; 动作与轨迹预测
- 领域: 餐饮与烹饪、穿戴交互与动作界面
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: EGTEA与EPIC-Kitchens原capture。
- 任务: action anticipation、motor attention、interaction hotspot三端点。
- 题数 / 数据: EGTEA10,321action instances; EPIC39,596是父数据, 全量hotspot仅EGTEA, EPIC只many-shot noun subset。
- 评估方式: Top1/5、mean-class accuracy、hotspot F1/KLD、trajectory ADE/FDE。
- Split / 信息条件: EGTEA split1/0.5秒anticipation, EPIC既有train/val及1秒anticipation。
- 来源关系: 增加manualhotspots; EPIC motor attention用fingertip→hotspot线性插值近似, 非完整真实追踪。
- 可复用: 补早期joint HOI预测及标签品质差异, 保留真实/推估label来源。
- 待核 / 限制: 添加hotspot/trajectory标注精确ID数未报, 不能把39,596全当添加标注题。

P058 EgoPAT3Dv2 (2024)

原作: <https://arxiv.org/abs/2403.05046>

本次PDF: <https://arxiv.org/pdf/2403.05046v1>

PDF SHA256: 7496f4c315189a824e5c490ba688d26788d161a66d4cbc6f93caf2d64665979c

阅读页: 1、2、4、5、6。原版 / 添加数据、seen/unseen切分、10段进度评分及HRI定位。

- 研究类型: 未来动作 / 交互预测; 动作与轨迹预测
- 领域: 协助、交接与陪伴、穿戴交互与动作界面
- 用途归纳: 预测人手将接触的位置, 让共享工作区的机器人提前配合; 同时是头戴设备的动作意图界面。
- 环境: 原版5 seen + 6 unseen scenes; 添加9 seen + 2 unseen, 合计22场景 (由原文分量推算)。
- 任务: 从RGB预测人手3D action target; cobot接近 / 避让是应用展示, 非22个操作goal。
- 题数 / 数据: 本轮已读原作未取得精确clip总量; 各test clip按进度10等份评测, 不能乘10当独立轨迹。
- 评估方式: 厘米级target prediction error, early / late分列; 3个训练seed取平均。
- Split / 信息条件: 保留T1/T2训练与D1/D2测试来源、seen/unseen; train clips最多25frames, test不限制。
- 来源关系: EgoPAT3D扩充并修正部分GT; 原baseline也因此改进, 需固定版本后比较。
- 可复用: 可加入人类手部目标提前量 / 距离误差轴, 不能拿10个观测比例冒充10种任务。
- 待核 / 限制: 添加与原版各split精确clip ID总量仍须发布数据核对。

P060 Continuous 4D interaction forecasting (2026)

原作: <https://arxiv.org/abs/2609.08636>

本次PDF: <https://arxiv.org/pdf/2609.08636v1>

PDF SHA256: 831ddd738803ba93751f328695856f63519cd1327b28140774d76cb95ae0ba35

阅读页: 1、2、4、5、6。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 未来动作 / 交互预测; 动作与轨迹预测
- 领域: 餐饮与烹饪、医疗与手术支持、交通移动与车辆维修、穿戴交互与动作界面
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: Ego-Exo4D的787takes, 不等于787独立场地。
- 任务: 3D interaction location + full-body pose联合预测; Cooking/Health/BikeRepair三用途。
- 题数 / 数据: $233,828\text{ windows} = 193,598\text{ train} + 20,484\text{ val} + 19,746\text{ test}$; 1,594,186是有效future targets。
- 评估方式: continuous location errors与MPJPE/PA-MPJPE; 两种target和validity mask分开。
- Split / 信息条件: take-level split; 三域horizon为10/5/4interaction steps, 不是固定秒数。
- 来源关系: Ego-Exo4D + Fiction式事件 + WHAM重建; exoviews仅供offline labels。
- 可复用: 扩展where-to-how预测; source-domain与camera/pose时间对应都可入共同规格。
- 待核 / 限制: take-level不自动证明不同take没有共用实体环境; 作者scene-disjoint说法需place IDs核。

P061 Interact with me (2024)

原作: <https://arxiv.org/abs/2412.16698>

本次PDF: <https://arxiv.org/pdf/2412.16698v3>

PDF SHA256: 35eabf84ae2cfa183887ab3924f91d9f15fa53aac29576e56407b4eee8da3642

阅读页: 1、2、3、4、5。JPL扩充、3组标签、训练augmentation、主要实验。

- 研究类型: 未来动作 / 交互预测; 人体与交互感知评测
- 领域: 社交与沟通、协助、交接与陪伴
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 沿用JPL人机交互视频; 未报添加scene总数。
- 任务: intent 3类、attitude 2类、action 10类; attitude是依action规则产生的标签, 不是独立量测心理状态。
- 题数 / 数据: 200母视频→290 person-level tracks; crop/flip/keypoint noise扩增只增加训练样本, 不增加290个来源个案。
- 评估方式: 三任务各报accuracy及F1; 主表观测首1秒30frames, 另变更窗口; 模型latency另列。
- Split / 信息条件: 本轮已读段落未取得正式train/test track ID分配; 不得把290直接称test题。
- 来源关系: JPL video-level标注扩成人物track; 同视频多个人共享情境。
- 可复用: 补交互意图与社交预测; 需注明人设标签规则及与动作标签的依赖。
- 待核 / 限制: 同母视频track是否跨split及split数须source code核对。

P065 CALVIN (2021)

原作: <https://arxiv.org/abs/2112.03227>

本次PDF: <https://arxiv.org/pdf/2112.03227v4>

PDF SHA256: c8ad4741782fa8fb773377fbf61b8772b86574f255599a229d3f6ad4d878c60e

阅读页: 1、2、3、4、5、7。4环境、34task与全部success criteria、play数据及MTLC / 长链评测。

- 研究类型: 一般操作 benchmark; 模拟操作benchmark
- 领域: 居家整理与清洁、通用对象与机动作业
- 用途归纳: 开抽屉、控制灯与把对象收好属居家整理; 方块转动、推移与堆栈则保留为通用作业。
- 环境: A/B/C/D四个配置; 共用桌面、robot及camera位置, 但滑门 / 抽屉 / 开关位置与材质不同。
- 任务: 34原子任务, 包括方块转动 / 推移 / 抬起、收纳、堆栈、开关门与灯。
- 题数 / 数据: 24小时play、约2.4M steps / 40M可重标窗口是数据潜量; 正式long-horizon 1,000条5步链; 单步每task 10个rollouts。
- 评估方式: task completion依起终状态变化, 不只终点距离; 长链只成功才转下一subgoal, 报链长 / 成功情况。
- Split / 信息条件: single / multi / zero-shot multi环境; ABC→D为未见配置但语义任务已在train出现, 语句另保留未见表达。
- 来源关系: PyBullet自建play环境; 多后续VLA评测重用同1,000 chains, 不能算各自添加题库。
- 可复用: 可借串行可行性、过程状态与长链测试; 34原子任务和5,000子步次数不能混算。
- 待核 / 限制: 模型成绩比较必须固定语言 / 初态链版本及可用sensor。

P066 ManiSkill (2021)

原作: <https://arxiv.org/abs/2107.14483>

本次PDF: <https://arxiv.org/pdf/2107.14483v5>

PDF SHA256: 90472755c9779e6088c8a94faaed0a4de3b9743d2d994c421973b0e7c402b374

阅读页: 1、3、4、5、6、7。原生task / environment定义、4 skills、对象split、demo及评分。

- 研究类型: 一般操作 benchmark; 模拟操作benchmark
- 领域: 居家整理与清洁
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 原作environment以一个对象资产为单位; 表1为52门柜、35抽屉柜、36椅、39桶, 柜体可能含多door/drawer, 不能当162独立房间。
- 任务: 4 skills: OpenCabinetDoor、OpenCabinetDrawer、PushChair、MoveBucket; 涵盖单 / 双臂mobile manipulation。
- 题数 / 数据: 约36K成功demonstrations、1.5M frames; 测试对象每skill10个, cabinet target有多门 / 多抽屉。
- 评估方式: 预定test environment instances的mean success; task-specific终态 / 稳定性判定; training restrictions分track。
- Split / 信息条件: 同对象category下train/test object互斥; 单个scene参数变化另为environment instance。
- 来源关系: SAPIEN + PartNet-Mobility类资产; ManiSkill2继承这4项, 不可视作全部新任务。
- 可复用: 资产拓扑泛化与对象级environment是重要细节; 需转译成共同字段但不抹平原生定义。
- 待核 / 限制: 门柜 / 抽屉柜底层asset ID是否重叠需manifest核。

P067 ManiSkill2 (2023)

原作: <https://arxiv.org/abs/2302.04659>

本次PDF: <https://arxiv.org/pdf/2302.04659v1>

PDF SHA256: 89fb794345d860ee696ca2f4d7a75059b15352b615794eeadb0e6075426136f0

阅读页: 1、2、3、4、5、6、7、8、19、22。20families内容、精密装配规则、rigid-soft平台、评测与部分task-specific附录。

- 研究类型: 一般操作 benchmark; 模拟操作benchmark
- 领域: 居家整理与清洁、装配与生产作业、通用对象与机动作业
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: SAPIEN / MPM配置及2,000+ object models; object assets非同量房屋。
- 任务: 20 families: 6 soft、3精密插入、5 pick-place、5关节 / mobile、1 AvoidObstacles; 继承ManiSkill1的4项。
- 题数 / 数据: 4M+ demonstration frames为训练数据。test依task不同: 如PickSingleYCB每对象5/10 episodes、cabinet两阶段各250等, 不能指定所有task同一题数。
- 评估方式: task-specific真物理成功; 插入必须实际进孔, 非靠近goal pose。; 原文同AssemblingKits基线在pose accuracy可99%、真插入成功只18%, 说明难度高度依赖规则。
- Split / 信息条件: 按对象train/test及challenge stage, 控制器可转换但要保留其action约定。
- 来源关系: 继承ManiSkill1; 任务灵感来自MetaWorld / RLBench / Ravens, 但更改孔洞几何与成功判准, 属有实质规则差异的衍生。

- 可复用：直接支持『同名任务可扩充规则』主张；更严格成功条件必须以独立规则版本记录。
- 待核 / 限制：全20家族不同阶段test episodes总量要从eval manifest按版本重算。

P069 robosuite (2020)

原作：<https://arxiv.org/abs/2009.12293>

本次PDF：<https://arxiv.org/pdf/2009.12293v3>

PDF SHA256：3da1cc7ba84ee487a90d7013325dd6045eea7c2920bc50cdb8ff37db67426fd4

阅读页：1、7、10、11、12、13、14、15、16、17。平台、robots/controllers、全部9 benchmark descriptions与标准评测。

- 研究类型：一般操作 benchmark；模拟平台与任务套件
- 领域：居家整理与清洁、装配与生产作业、通用对象与机动作业
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：9标准task环境，共用可配置arena / robot；10robot模型不是10场域。
- 任务：Lift、Stack、PickPlace、NutAssembly、Door、Wipe、TwoArmLift、TwoArmPegInHole、TwoArmHandover。
- 题数 / 数据：程序随机初始化，未固定全库题量；基线9环境×robot/controller组合，5 seeds是训练重复，不增加task。
- 评估方式：标准SAC实验报normalized episode return，500step horizon；task success条件依具体任务，不能把return当百分比成功率。
- Split / 信息条件：原作比较Panda/Sawyer与OSC/joint velocity，建议固定Panda OSC；未提出全域held-out task split。
- 来源关系：MuJoCo模块平台；LIBERO、RoboCasa、MimicGen等重用，平台与下游bench不可当完全独立环境源。
- 可复用：提供共通模拟 / 控制器 / task界面；平台功能与benchmark实绩分开。
- 待核 / 限制：repo v1.5可用的其余task是否超过本文9个标准评测需分清，不以注册class数覆盖论文结果。

P070 RoboCasa (2024)

原作：<https://arxiv.org/abs/2406.02523>

本次PDF：<https://arxiv.org/pdf/2406.02523v1>

PDF SHA256：7aca93ca3f157e32a46e02d675b3b2c24e3073a7807c038f7f566b73db87bde3

阅读页：1、2、3、4、5、6、8。场景、资产、100tasks组成、MimicGen数据与正式eval子集。

- 研究类型：一般操作 benchmark；模拟操作benchmark
- 领域：居家整理与清洁、餐饮与烹饪
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：10 floor plans×12 styles=120 scenes；只能把10称平面layout数。额外AI textures不添加layout。
- 任务：100=25 atomic (8skills) + 75 composite (20料理活动标签下生成并实作)。
- 题数 / 数据：atomic有1,250 human demos；生成实验72K (24tasks, 排除navigation) 另28K组成100K发布集。主要eval每task50 trials，分5个固定场景。
- 评估方式：物理task success；按skill、数据规模、未见对象 / style分列。

- Split / 信息条件：eval只用未见对象实例；5场景中2种style未见。MimicGen有成功rejection sampling，训练数据成功不代表policy成功。
- 来源关系：Robosuite底座、Objaverse / Luma资产、MimicGen扩样；后续RoboCasa365是同家族延伸。
- 可复用：支持生活工作组合扩充；域仍主要在厨房，须报真实layout与style层次。
- 待核 / 限制：本库先前收集的60个来源场景条目来自不同repo版本，不能与此PDF120 scenes混写，更不能叫60独立layouts。

P072 VLABench (2024)

原作：<https://arxiv.org/abs/2412.18194>

本次PDF：<https://arxiv.org/pdf/2412.18194v1>

PDF SHA256：9dc4aa5cfa6dcb86a30099eda2482bf45814285a8d6662df624ed79f2382788b

阅读页：1、2、4、5、6、7、8、19。100任务、10skills、资产、VLA/流程/VLM三种评测与PS。

- 研究类型：一般操作 benchmark；模拟操作benchmark
- 领域：居家整理与清洁、餐饮与烹饪、办公与教育、实验室操作、休闲与运动
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：MuJoCo/dm_control程序配置；未提供可直接与住宅数比较的独立scene总量。
- 任务：100 = 60 primitive + 40 composite，10操作skills；包含整理桌面、料理、化学示范、纸牌规则等。
- 题数 / 数据：2,164资产 / 163类；VLA主微调只取16类各100trajs = 1,600训练轨迹，非全100task的test量。
- 评估方式：Success与Progress Score分开：PS预设0.2正确对象选取 + 0.8已完成子步比例。；VLM非交互模式输出DSL，转DAG比skill/parameter recall与exact matching；不能把此分数当物理成功率。
- Split / 信息条件：seen/unseen object是整个category的差异；与ManiSkill同category新instance不相同。VLA / workflow / VLM信息条件各异。
- 来源关系：部分RoboCasa assets + Objaverse、生成资产；技能API和标注先验要列清。
- 可复用：已涵盖多种日常语义和物理 / 知识规则；是本研究扩规则与multimodal tool use的近邻。
- 待核 / 限制：各task eval episode数、无交互VLM题库精确量需源manifest核。

P073 RoboTwin (2024)

原作：<https://arxiv.org/abs/2409.02920>

本次PDF：<https://arxiv.org/pdf/2409.02920v3>

PDF SHA256：2c289e8ac5352f42de2908b166176fe6d01f045fbb4fb7214134a63e7c432c4f

阅读页：1、2、4、5、7、8、9。digital twin数据流程、17真实数据任务与6个DP3 benchmark子集。

- 研究类型：一般操作 benchmark；模拟与真实操作benchmark
- 领域：居家整理与清洁、餐饮与烹饪、工艺与修缮、协助、交接与陪伴
- 用途归纳：从杯子摆放、苹果收纳、扫除、锤击与人际交互数据归纳，保留每种用途所对应的任务范围。
- 环境：COBOT Magic工作站与其合成digital twins；未报多房屋总数。

- 任务：数据设计17任务（9tool、5人际、6双臂，标签可重叠）；本文DP3跑6任务。
- 题数 / 数据：真实数据每task30trajs（ $17 \times 30 = 510$ ）；6任务实验比较10/20/50 expert demos。test rollouts精确数本段未报。
- 评估方式：各task completion success rate；示范数是训练条件，不是评测题数。
- Split / 信息条件：real收集范围与synthetic expert评测6task分开；9+5+6不能加为20个不重叠task。
- 来源关系：AIGC由图到3D，MLLM写expert code；RoboTwin2为后续扩充。
- 可复用：双臂、工具、人机交互与digital twin产题可借；版本应明确分层。
- 待核 / 限制：原文引用A.3而此PDF附录信息有限，完整17task manifest与test rollout数仍待code核。

P075 VIMA (2022)

原作：<https://arxiv.org/abs/2210.03094>

本次PDF：<https://arxiv.org/pdf/2210.03094v2>

PDF SHA256: cf849f80368749b0310b43117519ce0abff3e8ae49744e78c4a29b9d17f0695f

阅读页：1、2、3、5、6、8、34、37。VIMA-Bench多模态prompt、17templates、4级泛化、训练与eval。

- 研究类型：一般操作 benchmark；多模态指令操作
- 领域：居家整理与清洁、通用对象与机动作业
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：Ravens桌面平台，对象 / 材质 / 位置程序变化；未报多房屋环境数。
- 任务：17task templates归6非互斥类：对象操作、视觉goal、新概念、示范模仿、视觉约束、推理 / 记忆。
- 题数 / 数据：600K+ expert训练trajectories；程序产生的instances与17templates分开，不能把训练轨迹称600K测试题。
- 评估方式：模拟交互task success；L1位置、L2新组合、L3新对象、L4新task分开。
- Split / 信息条件：offline BC；held-out validation选模型、simulator evaluation。原生动作为参数化pick-place / wipe primitive，非相同低级控制难度。
- 来源关系：Ravens延伸；多模态prompt内图片、语言、示范本来就在单一界面，不能把这点当本研究首次贡献。
- 可复用：多模态指令统一入口的重要前作；可扩大生活用途与规则，但需承认其既有统一界面。
- 待核 / 限制：各泛化级的确切公开eval seeds / case数需发布设置核对。

P076 Ravens / Transporter Networks (2020)

原作：<https://arxiv.org/abs/2010.14406>

本次PDF：<https://arxiv.org/pdf/2010.14406v3>

PDF SHA256: 3a5e78b5c8881863845c46bda0bf8c9071aa79a59a6f9a9f4d8732690482b228

阅读页：1、5、6、7、8。全部10simulation task清单、动作 / 观测、训练量、test与真机验证。

- 研究类型：一般操作 benchmark；模拟操作benchmark
- 领域：居家整理与清洁、装配与生产作业、包装、仓储与物流、通用对象与机动作业

- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：UR5e + 0.5×1m桌面，3 RGB-D视角；real kit assembly / sweeping为额外实验。
- 任务：10task：block insertion、red-in-green、Hanoi、align corner、pyramid、palletizing、kits、packing、rope、sweeping。
- 题数 / 数据：每task训练1/10/100/1,000 demonstrations；每task100 unseen test runs = 一方法设置1,000runs。
- 评估方式：0–100 performance，多步task给partial credit；非所有表中的分数都是binary success percentage。
- Split / 信息条件：对象 / goal位置朝向train/test随机，3task含未见objects；two-pose动作primitive及suction降低控制负担。
- 来源关系：PyBullet桌面，自带script oracle；VIMA、DeformableRavens等衍生共享task与界面。
- 可复用：包装、堆栈、绳索、清扫可作source tasks；需标记primitive与成功判准。
- 待核 / 限制：task各自partial credit及物理predicate严格程度需具体code映射，不以同名插入直接对比ManiSkill2。

P077 CLIPort (2021)

原作：<https://arxiv.org/abs/2109.12098>

本次PDF：<https://arxiv.org/pdf/2109.12098v1>

PDF SHA256：3cc19664beabda203cb1a1ad86659f75f60a099189820d92d59d20067c9ab003

阅读页：1、2、4、5、6。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：一般操作 benchmark；模拟与真实操作benchmark
- 领域：包装、仓储与物流、通用对象与机动作业
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：PyBullet Ravens UR5e桌面；3noiseless cameras融合RGB-D。
- 任务：10language-conditioned tasks；8有seen/unseen semantic variants。
- 题数 / 数据：每模型/设置100evaluation runs，train 1/10/100/1000demos是规模对照。
- 评估方式：Ravens 0–100partial-credit task score，不能全叫binary success rate。
- Split / 信息条件：held-out colors/object categories；56GoogleScannedObjects分37seen/19unseen。
- 来源关系：Ravens task复用并加语言；nominal SE(2) pick-place和通用6DoF policy难度不同。
- 可复用：补语言语义的操作规格；count10tasks，不把每demo和attribute组合当新task。
- 待核 / 限制：真实补充任务及完整source-task对应另需原生code；本列定量限已读sim protocol。

P079 FMB (2024)

原作：<https://arxiv.org/abs/2401.08553>

本次PDF：<https://arxiv.org/pdf/2401.08553v3>

PDF SHA256：c0d7c39378cfc46b87289276d517c5e9ef6aa5932fece6c5d2b0b4a4f120f9e8

阅读页：1、3、4、5、7、8、10、12。资产、三大skill / 六种primitive、长流程、表1及evaluation。

- 研究类型：一般操作 benchmark；真实操作benchmark

- 领域：装配与生产作业
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：可重制Franka工作站，对象与board初态依规定区域和姿态；不是66个环境。
- 任务：functional grasp / reposition / insert三大能力；single-object与multi-object两类流程，3套multi-object互锁装配。表1有6个primitive。
- 题数 / 数据：66训练对象+5新测试对象；表1精确22,550 primitive trajectories由完整流程分割，不能都叫独立22,550长程任务。
- 评估方式：依skill / 长流程success；grasp实验5 seen + 5unseen对象各5次 = 50trials；完整流程另有10次设置。
- Split / 信息条件：对象shape/size/color与初态泛化；board插入间隙1-2mm；可模块评估也可end-to-end，两者分开。
- 来源关系：自制3D printable objects与human demos；长流程和primitive数据共享母轨迹。
- 可复用：精密contact、功能性抓取、重抓与顺序依赖；只有模拟仍可收录规格，不能称已重现其real实验。
- 待核 / 限制：摘要22,500与表1精确22,550为约数差异；未取得完整真机eval。

P080 DexArt (2023)

原作：<https://arxiv.org/abs/2305.05706>

本次PDF：<https://arxiv.org/pdf/2305.05706v1>

PDF SHA256：44354c0496a14f9ef90e19cd93f1521075adb6daff5f0a882cc045a649fbff7e

阅读页：1、2、3、4、5、6。4task、seen/unseen表、22DoF界面、success与视角泛化。

- 研究类型：一般操作 benchmark；灵巧手操作benchmark
- 领域：居家整理与清洁
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：SAPIEN中XArm6 + 16DoF Allegro；对象资产不同，非多house layout。
- 任务：Faucet、Bucket、Laptop、Toilet四task；资产18 / 19 / 17 / 28，共82。
- 题数 / 数据：seen对象11+11+11+17 = 50，unseen7+8+6+11 = 32；3训练seeds；6K point clouds/object为视觉预训练数据。
- 评估方式：success依关节角 / 抬升高度；episodic return另列；测seen/unseen对象和新camera pose。
- Split / 信息条件：同category未见instance；4接触 / 进度reward不等于4独立benchmark。
- 来源关系：PartNet-Mobility资产；额外PMM46类是pretraining，不是DexArt46个任务。
- 可复用：补灵巧手与拓扑泛化；DoF增加代表控制要求，不能直接给跨benchmark单一难度等级。
- 待核 / 限制：完整test episodes per object与seed ID需eval code核。

P081 ARNOLD (2023)

原作：<https://arxiv.org/abs/2304.04321>

本次PDF：<https://arxiv.org/pdf/2304.04321v2>

PDF SHA256：5a2b6c0126bde99772c888036524fd071cf3890034be184e26c437bd42f50fdb

阅读页：1、3、4、5、6、8。scene/objects、8tasks各continuous goal、表2/3、泛化切分与2秒success。

- 研究类型：一般操作 benchmark；模拟操作benchmark
- 领域：居家整理与清洁、通用对象与机动作业
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：20个scene、40对象；Isaac Sim / PhysX5、固定Panda base。
- 任务：8task×各4个数量goal（保留1个novel state）；拾物、重定向、开关drawer/cabinet、pour / transfer water。
- 题数 / 数据：表3共10,080 demonstrations/configurations：train3571、val771、IIDtest773、novel object1078、scene1114、state2000、any-state773。
- 评估方式：完成最终stage后在goal tolerance内保持2秒；transfer水另限≤10%spill；报success rate。
- Split / 信息条件：Normal约70/15/15；novel object / scene / state每次只变一因素；Any State是连续range抽样，非同样extrapolation难度。
- 来源关系：既有室内synthetic scenes + 外部object assets；可接Roboverse但需保留新success规则。
- 可复用：量化精度、稳定维持与spill限制是规则扩充的好依据；同task多目标与新语义task分开。
- 待核 / 限制：本库尚未逐ID导入全部scene/state/test组合。

P083 RoboDojo (2026)

原作：<https://arxiv.org/abs/2607.04434>

本次PDF：<https://arxiv.org/pdf/2607.04434v3>

PDF SHA256：e07c215f30169dde6a792c34b046b1f54818d09331763988732dcf9ead89a9d4

阅读页：1、2、3、4、5、6、7、8、9、16、28、45。42sim/18real、五能力清单、train/eval数量、评分与hidden-layout验证。

- 研究类型：一般操作 benchmark；模拟与真实操作benchmark
- 领域：居家整理与清洁、衣物与洗护、装配与生产作业、通用对象与机动作业
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：Isaac Sim双臂工作站和3类真机平台；各task有公共reset layouts和hidden验证布局。
- 任务：42simulation tasks（12 generalization、6 memory、8 long、8 precision、8 open）+ 18real tasks；同名/同goal的sim/real不能先假定60语义去重任务。
- 题数 / 数据：simulation每task50episodes = 2,100；real每task10trials = 180。sim train34tasks + DLC共35目录3,500trajs, real1,800trajs。
- 评估方式：sim binary success + partial-progress score，五能力宏平均；real三人双盲评分后平均。
- Split / 信息条件：Open8task不在train；generalization每task25标准 + 25随机；正式榜另3seeds及hidden layouts，不加作新task。
- 来源关系：参考RoboTwin、RMBench等，使用新规则及共同sim-real界面；公开表与hidden验证不同地位。
- 可复用：综合能力与可复现实测的近邻；我们simulation-only版本需以同等成功 / partial score证据比较。
- 待核 / 限制：sim/real相同任务之去重关系与hidden验证量未完整公开。

P084 KinDER (2026)

原作：<https://arxiv.org/abs/2604.25788>

本次PDF: <https://arxiv.org/pdf/2604.25788v2>

PDF SHA256: 39d1283a971b7b903edb7885cabdc9dea9c412bd3cfcc8431f0c39154ba44900

阅读页: 1、3、4、5、6、7、14。五大physical-reasoning要求、25环境、4种物理抽象、8实验环境及metrics。

- 研究类型: 一般操作 benchmark; 物理推理与规划benchmark
- 领域: 居家整理与清洁、包装、仓储与物流、通用对象与机动作业
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 25 procedural task-environments: 6 Kinematic2D + 4 Dynamic2D + 5 Kinematic3D + 10 Dynamic3D; 不是25生活场域。
- 任务: 工具、nonprehensile、多物体、几何、动力约束; KinDERBench主实验只取8代表环境, 13baselines。
- 题数 / 数据: 10环境各 ≥ 100 precollected demos; eval每seed50episodes $\times$ 5seeds, 8环境合计2,000runs / baseline (含重复seed运行)。
- 评估方式: success rate; 只在成功episodes比较累积步数cost (每步-1), 另报inference time。
- Split / 信息条件: 不同物体数量OOD; state / RGB与提供skills/PDDL的信息差异需明示。Kinematic版本碰撞回退、rigid attachment, 不等同dynamic真抓取。
- 来源关系: PyMunk / PyBullet / MuJoCo不同backend; 借RoboCasa/MimicLabs资产及BDDL设计。
- 可复用: 支持明确规则 / 物理抽象的比较; 不得将kinematic、dynamic的成功直接合成无条件难度分数。
- 待核 / 限制: 程序分布无固定题库上限; 仅8环境有主baseline结果, 不能声称全25已同程度验证。

P085 SoftGym (2020)

原作: <https://arxiv.org/abs/2011.07215>

本次PDF: <https://arxiv.org/pdf/2011.07215v2>

PDF SHA256: 0e0bd8b74b7d8b3aa1a203694debf47d425adbfe2eab8bf4555b198525e89903

阅读页: 1、3、4、5、6、7、8、14。6 Medium / 4 Hard任务、action抽象、oracle信息及eval切分。

- 研究类型: 布料 / 柔性物操作; 柔性物操作benchmark
- 领域: 衣物与洗护
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: Flex程序物理环境; 主Medium/Hard直接控制picker或杯子, 非完整手臂; SoftGym-Robot另列。
- 任务: 10任务 = 6 Medium (transport/pour water、straighten rope、spread/fold/drop cloth) + 4 Hard (pour amount、fold crumpled、drop-fold、rope configuration)。
- 题数 / 数据: 主实验每task预抽1,000 variations = 800train + 200eval; CEM只抽10个eval variations, 不能称所有方法测同量。
- 评估方式: 按task用覆盖面积、粒子距离、水量 / spill等; 以do-nothing与upper bound范式, 可能小于0.; 5 seeds报median / 四分位, 不是binary success rate。
- Split / 信息条件: 初态variations800/200; DynamicsOracle / StateOracle / RGB信息权限不同, 不能混为同难度。
- 来源关系: Flex与抽象pickers; 后续布料task和数据生成器大量重用。
- 可复用: 柔性物task与连续指针来源; 加上机体、抓持及稳定性规则才适合与robot控制任务比较。
- 待核 / 限制: SoftGym-Robot在本文注明待NVIDIA许可发布; 目前取得状态须另核, 不能由API假定可用。

P086 DeformableRavens (2020)

原作: <https://arxiv.org/abs/2012.03385>

本次PDF: <https://arxiv.org/pdf/2012.03385v4>

PDF SHA256: 7227984ec317cff8190a29c2f53794d0e399fbbb7ed78c8ee21c7b27f78d65f8

阅读页: 1、3、4、5、6、7、13、14。12任务全表、deformable primitive、数据与checkpoint选择、真机cable实验。

- 研究类型: 布料 / 柔性物操作; 柔性物操作benchmark
- 领域: 衣物与洗护、包装、仓储与物流
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 共用UR5桌面, PyBullet绳索 / 布料 / 袋子; 理想nearest-vertex抓持。
- 任务: 12=5 cable、3 fabric、4 bag; 有goal image和无goal图两种设置, bag含打开→装物→搬运。
- 题数 / 数据: 每task1,000成功demo; 每checkpoint20eval episodes、通常3训练runs, bag-color仅1run。表格选10checkpoints最大值。
- 评估方式: cable位置 / 凸包面积、cloth coverage、bag containment/transport依task分开。; 真机cable另10episodes、最多10actions、mask IoU>0.25判成功。
- Split / 信息条件: held-out random seeds; 依eval最大checkpoint报分有选择效应, 不能当独立test后只评一次。
- 来源关系: Ravens延伸; 成功demo经过滤, script成功率与policy测试不是同一分母。
- 可复用: 拓展袋子、绳索与布料多阶段规则; 要额外防止袋插件物等达标漏洞。
- 待核 / 限制: 各task指针中连续coverage与binary success混合, 跨任务总分需保留原生定义。

P087 GarmentLab (2024)

原作: <https://arxiv.org/abs/2411.01200>

本次PDF: <https://arxiv.org/pdf/2411.01200v3>

PDF SHA256: 8b0cea58cae1f425754a11a328f6082eafc8066dd93300c8255ba4ae17ffa999

阅读页: 1、2、3、4、5、6、7、8、9、16、17、20。资产与5种物理交互、20task、实验子集、split及5秒success。

- 研究类型: 布料 / 柔性物操作; 柔性物操作benchmark
- 领域: 居家整理与清洁、衣物与洗护、个人照护
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 20scene与9,000+object models资产库; PhysX多物理方法, scene/asset数不等于实评数。
- 任务: 20tasks归5interaction groups: garment-garment/fluid/FEM/rigid/avatar; 含折、展、挂、吹干、洗、收纳、穿衣。
- 题数 / 数据: 不同task初态 / garment采样; 正文baseline以大件fold/unfold/hang、小件place/hang及若干RL子集为主, 没有统一全20task题数。
- 评估方式: 达task-specific判准后维持至少5秒; fold用IoU、unfold用coverage, 其他物理交互有专用容差。
- Split / 信息条件: objects70/15/15; 另novel state / scene; 主实验并非全部20task同程度跑分。
- 来源关系: ClothesNet、ShapeNet、PartNet/YCB、PartNet-Mobility、Omniverse/actorcore等资产; RoboVerse迁移其子集。

- 可复用：柔性物与日常服务广度的重要来源；应保留materials与state/evaluator可用程度。
- 待核 / 限制：折衣轮廓IoU无法单独检查层次 / 拓扑正确；需更细规则。；完整20task有效case数待manifest。

P088 FlingBot (2021)

原作：<https://arxiv.org/abs/2105.03655>

本次PDF：<https://arxiv.org/pdf/2105.03655v3>

PDF SHA256：ad6e502825c044a1ce13911164ae7817e00628ba7ac3e46358cc277c9d25dc8e

阅读页：1、6、7。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：布料 / 柔性物操作；柔性物操作benchmark
- 领域：衣物与洗护
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：simulation cloths与dualUR5真实工作站；NormalRect/LargeRect/Shirt三object regimes。
- 任务：主要1个unfolding目标；三clothtypes是材料/形状泛化设置。
- 题数 / 数据：2,000trainingcloth settings, 600sim test cases各类200；real各类10cases, 150realadapt episodes不算test。
- 评估方式：normalized final/delta coverage及actions, 允许coverage>1的范式情形不裁成success。
- Split / 信息条件：CLOTH3D test shirts；mesh/material/init分离, 10step budget或预测抓地板终止。
- 来源关系：CLOTH3D与既有clothphysics, dataset task实为具体cloth+material+initialization。
- 可复用：示范同一目标可以有大量物理cases, 而未增加语义task数。
- 待核 / 限制：coverage并不保证可直接折衣；real细节与sim material参数只能作相应范围推论。

P089 SpeedFolding (2022)

原作：<https://arxiv.org/abs/2208.10552>

本次PDF：<https://arxiv.org/pdf/2208.10552v2>

PDF SHA256：2421f14228d394a1a2f683d8156f4ff953dee3dd1deefef64ce0037854b86be1

阅读页：1、5、6、7。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：布料 / 柔性物操作；柔性物操作benchmark
- 领域：衣物与洗护
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：ABB YuMi工作站；known shirt、unseen shirt、towel。
- 任务：smoothing→folding, instruction/2-second/Fling-to-fold三策略并非三个生活domain。
- 题数 / 数据：4,300action records包含1,500拷贝重标；每experiment15trials。
- 评估方式：fold由3reviewers多数决；horizon10；time成功回合平均, FPH/cycle包括失败。
- Split / 信息条件：train单shirt；towel泛化前加20smoothimages再训练, 不是完全zero-shot。

- 来源关系：前作FlingBot比较有不同hardware；1500重标非独立physical actions。
- 可复用：补折衣全流程与吞吐量，不能只报93%而略过任务、排除规则和15次分母。
- 待核 / 限制：排除motion-planning early failures会影响整体systemsucccess解读；须在共同protocol保留此差异。

P090 Cloth Funnels (2022)

原作：<https://arxiv.org/abs/2210.09347>

本次PDF：<https://arxiv.org/pdf/2210.09347v1>

PDF SHA256：06417ac85cf98e06ede6fd96b746e6e1ce3ad99ca09fcd9f61789122d0ecfcdb

阅读页：1、2、4、5、6。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：布料 / 柔性物操作；柔性物操作benchmark
- 领域：衣物与洗护
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：CLOTH3D simulation与真实衣物工作站，5garment categories。
- 任务：canonicalized alignment，另支持folding/ironing；highcoverage不保证对齐。
- 题数 / 数据：每garment category2,000train/400test settings；hard/easy train75/25、test50/50。
- 评估方式：IoU/coverage及分离rigid-alignment和deformable errors；fold success为qualitatively选的error门槛。
- Split / 信息条件：mesh-disjoint，easy/hard是不同初态生成；eachgarmentcategory独立policy。
- 来源关系：CLOTH3D / FlingBot数据生成构想；downstreamfoldheuristic非新end-to-end模型。
- 可复用：把摊平、对齐和指定折法拆成可验收目标，适合作为扩充规则依据。
- 待核 / 限制：real全部trajectory分母未在已读段报出；不可套用sim400为realcase数。

P091 UniFolding (2023)

原作：<https://arxiv.org/abs/2311.01267>

本次PDF：<https://arxiv.org/pdf/2311.01267v1>

PDF SHA256：b51de4cbad0c9715a18e88ce74af68a21192ad10e130a1b956715c87706d8049

阅读页：1、2、5、6。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：布料 / 柔性物操作；柔性物操作benchmark
- 领域：衣物与洗护
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：RFUniverse/ClothDynamics及双Flexiv工作站；2garment categories。
- 任务：两类衣物的unfold+fold流程；60realgarments的train/test40/20。
- 题数 / 数据：VR1,218+1,575=2,793videos，real2,432samples；20heldoutgarments各10trial=200realtrials。
- 评估方式：IoU、normalizedcoverage，wholeflow10steps内按rules折好。

- Split / 信息条件: realgarments2:1, simCLOTH3D9:1; onlinehumanpreference作训练, 不当test免介入证据。
- 来源关系: CLOTH3D、ClothFunnel目的函数及VR-human demonstrations。
- 可复用: 可取shirt具体fold规则和材料差异, human annotations与robotepisodes分开。
- 待核 / 限制: 机器人reach/grasp自动recovery和policyactionbudget的共同计数需要adapter明定。

P092 ICRA cloth competition (2025)

原作: <https://arxiv.org/abs/2508.16749>

本次PDF: <https://arxiv.org/pdf/2508.16749v2>

PDF SHA256: c44a1dff77f6fe471123e7e70b03b6735ed494e18190396a44c5c4232962b274

阅读页: 1、2、5、6、7、8、11。固定unfold primitive、硬件 / grasp execution、coverage metric、数据及比赛规模。

- 研究类型: 布料 / 柔性物操作; 真实操作benchmark
- 领域: 衣物与洗护
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 双UR5e + 单stereo camera标准工作站; 训练在lab、比赛在会场, cloth初态无法精确拷贝。
- 任务: 1个核心任务: 悬挂布料选grasp后stretch展开; 34garment items不是34task。
- 题数 / 数据: 679episodes = 503训练尝试 + 176竞赛trial; 11队各16次 (8衣物×2), 同题型由不同方法运行。
- 评估方式: 主metric projected coverage / 最大面积; 另grasp success及成功抓取条件下coverage。; 30秒grasp计算上限为建议, 非由679样本推导的固定速度门槛。
- Split / 信息条件: 503与176来源 / 用途分开; 训练也含失败抓取; 176是实验运行, 不是176独立任务。
- 来源关系: 部分毛巾来自Household Cloth Object Set, 与其它cloth benchmarks资产可能重用。
- 可复用: 可借真实garment多样性与grasp/coverage分离; 不宜把单次展开当完整折衣 / 收纳任务。
- 待核 / 限制: 场地与初态差异无法完全消除; 本库无法只靠既有视频重跑physical grasp。

P093 MoDeSuite (2025)

原作: <https://arxiv.org/abs/2507.21796>

本次PDF: <https://arxiv.org/pdf/2507.21796v1>

PDF SHA256: 7487d599b51f5e6b76f91382e89b71c431f6314db66766625b35dda08d345dca

阅读页: 1、3、4、5、6。两种mobile robot、8task逐项定义、source继承及learning评测。

- 研究类型: 布料 / 柔性物操作; 柔性物操作benchmark
- 领域: 居家整理与清洁、衣物与洗护
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: IsaacSim / PhysX; Ridgeback-Franka与Spot arm, 走廊 / 桌面配置。
- 任务: 8 = 新5elastic (Place/Bend/Transport/Drag/Lift) + 3既有cloth-like (Cover/Uncover/Curtain); 需base与arm协同。

- 题数 / 数据: RL5独立runs, success在20eval trials计算; 非每task20个语义新任务。
- 评估方式: 依task几何位置、跨越 / 覆盖与无碰撞条件报success; episode return和stability penalty另列。
- Split / 信息条件: 不同机体 / state/RGB输入分开; 本文无单一全库train/test IDs总量。
- 来源关系: 3cloth tasks从前作扩充mobile base control; FEM与PBD为不同材料物理, 不是新生活domain。
- 可复用: 可补『移动时携带 / 拖拉柔性物』而非纯桌面折布; 规则包含通过障碍与稳定。
- 待核 / 限制: 原3task来源与精确scene/config IDs需从引用30及code进一步对齐。

P094 R2R/VLN (2017)

原作: <https://arxiv.org/abs/1711.07280>

本次PDF: <https://arxiv.org/pdf/1711.07280v3>

PDF SHA256: b7589865ee573d4753ee9e25bdc494cbbb199e6ec17d0a349091aed0fd86c420

阅读页: 1、2、4、5、6、7。navigation graph、路径 / 指令搜集、scene split与stop成功定义。

- 研究类型: 导航与家务运行; 导航benchmark
- 领域: 居家整理与清洁、办公与教育
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 90个Matterport3D建筑scene; panorama graph离散移动, 非真轮式动力学。
- 任务: 1个指令导航task family; 7,189 route goals、21,567语言指令 (通常每path3条)。
- 题数 / 数据: train14,025 / val-seen1,020 / val-unseen2,349 / test4,173 instructions。
- 评估方式: navigation error; 主success要求stop后距goal<3m; oracle stop另列。原文不要求全程遵循原path。
- Split / 信息条件: 61train scenes / 11val-unseen / 18test; 不能把全部21,567叫test。
- 来源关系: Matterport3D上游; RxR、RoboVerse、VLN-CE等重用同scene, 场景数不可加总。
- 可复用: 可引入route-following与语言多样性; 路径数和导航task family是不同粒度。
- 待核 / 限制: 下游continuous变体的可导航几何 / case过滤需要另版本。

P095 RxR (2020)

原作: <https://arxiv.org/abs/2010.07954>

本次PDF: <https://arxiv.org/pdf/2010.07954v1>

PDF SHA256: 8a964d95106ff267f934acf705a6b0be304a193f84745fe0ad55f51133d61bd8

阅读页: 1、2、3、4、5、6、9。path采样、90scene重用、多语注记、split与path-adherence metrics。

- 研究类型: 导航与家务运行; 导航benchmark
- 领域: 居家整理与清洁、办公与教育
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 同Matterport3D90个室内场景; 不是比R2R又添加90。

- 任务：16,522 paths；English/Hindi/Telugu三语，同一path有多语 / 多描述与guide/follower traces。
- 题数 / 数据：126,069 instructions；path split 11,089 train / 1,232 val-seen / 1,517 val-unseen / 2,684 test。这些是path数，不能当同数instruction。
- 评估方式：PL、NE、SR、SPL、NDTW、SDTW；原作主重NDTW/SDTW以奖励遵循指定路径，与R2R只到终点不同。
- Split / 信息条件：沿R2R / Matterport场景split；test-standard/test-challenge隐藏；3语每语约14K paths有交集。
- 来源关系：原始scene共用R2R，path另采样；与R2R多任务训练的追加数据不能再算新test。
- 可复用：证明同导航family可以扩语言与过程规则；规则差异应明确保留。
- 待核 / 限制：各language及test子split指令ID量需manifest核。

P096 ALFRED (2019)

原作：<https://arxiv.org/abs/1912.01734>

本次PDF：<https://arxiv.org/pdf/1912.01734v2>

PDF SHA256：84b314c06de82f5a1ff853676d391e05394a2e517986b03faadcbca325c9ee0b

阅读页：1、2、3、4、7、8。7task types、参数 / demo / directive层级、scene及split表、success与partial goal评测。

- 研究类型：导航与家务运行；室内长流程操作
- 领域：居家整理与清洁、餐饮与烹饪
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：AI2-THOR 120 rooms = kitchen/bathroom/bedroom/living各30；不是120房屋。
- 任务：7types：pick-place、stack-place、pick-two、clean-place、heat-place、cool-place、examine-in-light；2,685 task parameter combinations。
- 题数 / 数据：8,055 expert episodes、概述25,743 directives；表2split为21,023 / 820 / 821 / 1,533 / 1,529（合25,726），原文存在17差异。
- 评估方式：全部goal condition成功 / 部分goal-condition比例；另以action length折算效率。；subgoal评测可先强制走expert历史，不能与end-to-end成功混同。
- Split / 信息条件：108train rooms，4val-unseen，8test-unseen；seen folds是train场景子集。
- 来源关系：AI2-THOR 2.0 + PDDL planner；TEACH沿同floorplans/splits，两者场景不可重加。
- 可复用：提供家务状态变更 / 工具切割 / 热冷清洁程序；符号动作语义不等于低级接触摸制。
- 待核 / 限制：25,743概述与表2合计25,726需release IDs厘清，不静默选方便的数字。

P097 TEACH (2021)

原作：<https://arxiv.org/abs/2110.00534>

本次PDF：<https://arxiv.org/pdf/2110.00534v3>

PDF SHA256：512d9ea49367fc5ec3559ab9b866c1aaafb015585dd2363bc7e918b20e42e40a

阅读页：1、2、3、4、5、6、7、9、21。TDL与12task、session→EDH、三种benchmark、全部split与success。

- 研究类型：导航与家务运行；对话协作与任务完成
- 领域：居家整理与清洁、餐饮与烹饪、协助、交接与陪伴
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：AI2-THOR；表2成功收集池覆盖109 rooms，重用ALFRED场景与unseen split。
- 任务：12task types、438参数variants（收集池）；3端点EDH / TfD / TATC，最后一种要同时建模Commander/Follower。
- 题数 / 数据：正文3,047可replay sessions；表3分量合3,045。EDH表3总11,176 = 5475train+608val-seen+2157val-unseen+666test-seen+2270test-unseen。
- 评估方式：EDH完成全部expected state changes为success，GC给部分分；trajectory length weighting另列。；TATC与TfD重用session母数据，不是三倍独立任务量。
- Split / 信息条件：seen/unseen场景；train/val/test按session；旧版EDH因只保留推进任务的state changes而缩减。
- 来源关系：同AI2-THOR与ALFRED场景，语言 / session新human-human收集；TDL支持量词、阶层与共享object约束。
- 可复用：对话工具、澄清、任务阶层与量词规则有可复用形式；收集成功与可重播数需分开。
- 待核 / 限制：本文3,047与split3,045差2；表1还留早期3,215，必须以版本manifest查明。

P098 Habitat 2.0 (2021)

原作：<https://arxiv.org/abs/2106.14405>

本次PDF：<https://arxiv.org/pdf/2106.14405v2>

PDF SHA256：92f9c30479fe4203f656c218fa228c7e5fd71f23a9821b3afa47e06dbe5ab317

阅读页：1、2、4、5、6、7、9、10、11、29。ReplicaCAD构造、Pick基本任务、3种HAB任务与评估假设。

- 研究类型：导航与家务运行；室内长流程操作
- 领域：居家整理与清洁、餐饮与烹饪
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：ReplicaCAD111 layouts创建於单一apartment backdrop；正文105新layout variations与原始配置分量需分清，非111独立住宅。
- 任务：HAB3families：TidyHouse、PrepareGroceries、SetTable；另Pick基础实验。任务goal为object起终3D位置，不是自然语言理解。
- 题数 / 数据：程序clutter/goal episodes；Pick有500 unseen-layout eval样本；技能附录另100eval episodes，不能混作HAB全库题数。
- 评估方式：goal成功与分阶段成功；操作次数用作难度proxy；模拟速度SPS另列。
- Split / 信息条件：未见layout/object配置；抽象抓持与kinematic base控制，并非完整wheel/contact dynamics。
- 来源关系：Replica FRL apartment→ReplicaCAD、YCB clutter；Habitat3/后续rearrangement套件会重用。
- 可复用：可借home-scale长流程与open/close前后置条件；环境分量与传感先验需精确报。
- 待核 / 限制：HAB每family全套eval episode IDs与111layout正式manifest仍待导入。

P099 HomeRobot (2023)

原作：<https://arxiv.org/abs/2306.11565>

本次PDF: <https://arxiv.org/pdf/2306.11565v2>

PDF SHA256: 518b6ba6f64a2c51a1bda3b92902e6ad0d2cbf5567d6d07e93207a28155d61e3

阅读页: 1、2、4、5、6、7、17、18、19、20、24、27。HSSD实际子集、OVMM四stage、scene/objects切分、sim/real成功定义。

- 研究类型: 导航与家务运行; 室内长流程操作
- 领域: 居家整理与清洁
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: HSSD原库200+, 本文实验只用60scenes = 38train/12val/10test; real为1个3-room apartment。
- 任务: 1个OVMM family: find object→pick→find receptacle→place; 129对象类别与21receptacle类, 不是129/21个新任务。
- 题数 / 数据: 2,535对象模型; sim程序产生object/start/goal cases, 已读段未给单一全库题量。real两baseline各20experiments。
- 评估方式: 四stage全过为success、partial success作tie-break; sim Place需静稳50steps; sim Pick是0.8m内magic snap, real Pick要实抓; 两者判准不同。
- Split / 信息条件: 未见scene及未见object instances, 另seen/unseen categories; sim1250step、real300step budget。
- 来源关系: HSSD + AI2-THOR/ABO/GSO objects, 与PARTNR HSSD衍生共享环境家族。
- 可复用: 可提供open-vocabulary寻物与搬运; 需在共同库标记抓持抽象层级。
- 待核 / 限制: HSSD不同项目的branch/scene ID对照需查; 不能把HomeRobot60与PARTNR60直接算120houses。

P101 Embodied Agent Interface (2024)

原作: <https://arxiv.org/abs/2410.07166>

本次PDF: <https://arxiv.org/pdf/2410.07166v3>

PDF SHA256: d10c7fee3594c88ff9f6a061a68b64a380a82d36c6652f3b08c42179044e2a9f

阅读页: 1、4、5、6、7、21、89、90、102、103。4 modules完整I/O与metric、表2、BEHAVIOR100 / VirtualHome标注与符号实作。

- 研究类型: 导航与家务运行; 符号规划与评测界面
- 领域: 居家整理与清洁、餐饮与烹饪、办公与教育
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: VirtualHome与EvalGibson两后端; EvalGibson为BEHAVIOR100创建的符号transition simulator, 不是BEHAVIOR1K全物理运行。
- 任务: 4 modules: goal interpretation、subgoal decomposition、action sequencing、transition modeling。VirtualHome表2为26task names / 338instructions; BEHAVIOR100为100。
- 题数 / 数据: 338 + 100 = 438 instruction instances; 801/673 goals是组成标签, 平均4,164.4 goal options不是4,164题。
- 评估方式: goal / transition以logic F1; trajectory feasibility、goal satisfaction、partial goal success; PDDL planner成功另列; 模块评测其余部分用GT / BFS / planner补齐, 非端到端全系统分数; 只实作LTL部分语法, globally/until尚未实作。
- Split / 信息条件: zero-shot界面评估; 固定单module与pipeline分析分开。
- 来源关系: BEHAVIOR100 VR demos、RobotHow/VirtualHome; 重新标注抽象 / 具体goal以避免无关终态污染。
- 可复用: 是统一任务语言、规则及模块评测的直接前作; 应避免重造G/T轴而不交代与此界面差异。
- 待核 / 限制: 附录称VirtualHome30categories而表2为26names, 待label清单对齐。

P102 NavVerse (2026)

原作: <https://arxiv.org/abs/2607.19695>

本次PDF: <https://arxiv.org/pdf/2607.19695v1>

PDF SHA256: 9e578a0112fb1c6b3969bc02b262c7f35fa90e3321692f5dfa0ad033fef1fc68

阅读页: 1、2、3、4、5、6、8、12、13。200scene构造、3task、10K episodes、物理导航与metric / 难度。

- 研究类型: 导航与家务运行; 导航benchmark
- 领域: 公共场馆与服务
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 100 indoor GRScenes + 50 outdoor城市 + 50 indoor-outdoor组合; 混合scene重用前两组几何, 不是200独立底层环境。
- 任务: ObjNav / PlaceNav / VLN三类; PlaceNav没有纯室内split, 不能机械做3×3完整coverage。
- 题数 / 数据: 4,027 ObjNav + 2,973 PlaceNav + 3,000VLN = 10,000episodes (全生成benchmark); 与evaluation subset量分开。
- 评估方式: SR、SPL、coverage efficiency、collision rate、obstacle distance、navigable surface ratio; Spot goal tolerance1.6m; 难度按各task自身path length的1/3、2/3分位, 不是跨benchmark通用难度。
- Split / 信息条件: indoor90/10、outdoor40/10, mixed沿outdoor split; 共享PID waypoint follower。
- 来源关系: GRUtopia/GRScenes + Virtual Community城市、Google tiles、Objaverse; mixed环境需追父scene。
- 可复用: 补室内到户外的连续导航与工作用途; 可用组合环境扩题, 但须报重用关系。
- 待核 / 限制: 各task evaluation split的精确case ID量与mixed scene父ID需要manifest导入。

P103 Follow-Bench (2025)

原作: <https://arxiv.org/abs/2509.10796>

本次PDF: <https://arxiv.org/pdf/2509.10796v4>

PDF SHA256: d0c3862a5ceea33af287b35df24c711ee5e923e829b298b2688ed9c280e18ace

阅读页: 1、6、7、8、9、10、20。16scenario、配置表、8planners、100trials与安全/舒适metric。

- 研究类型: 导航与家务运行; 社交导航benchmark
- 领域: 包装、仓储与物流、个人照护、公共场馆与服务、协助、交接与陪伴
- 用途归纳: 跟随指定人是陪伴服务; 原作亦明列照护、巡逻、导览与物流的应用方向。
- 环境: CPU 2D simulator; 16scenario types分target trajectories、4crowd模式、4layouts; 非16个真实场所。
- 任务: 1内核family = 跟随指定人, 变更跟随角 / 距离、密度、狭窄通道及遮挡。
- 题数 / 数据: 各configuration100个随机trial; 表V包含多种人数 / 宽度 / 距离, 不能简化为16×100而漏掉配置。
- 评估方式: 无碰撞且重新找到target才成功; TVR、目标personal-zone时间、侵入他人空间、jerk、路径等; 10Hz同步sim clock计jerk, wall-clock planner耗时另外量。
- Split / 信息条件: motion-planning测试假设可见人位置完美; 真人主观偏好另经real interviews, 不冒充sim几何metric。
- 来源关系: 既有2D人群simulator / ORCA/SFM扩充; 不是端到端camera跟人辨识benchmark。

- 可复用：补持续陪伴与社交距离规则；任务完成、安全与舒适分开比。
- 待核 / 限制：全部配置去重后的trial总量需按发布config枚举。

P104 SIMPLER (2024)

原作：<https://arxiv.org/abs/2405.05941>

本次PDF：<https://arxiv.org/pdf/2405.05941v1>

PDF SHA256：6a9481f3c0fc43fa6736e5f5fc8ddb72ebf05aad7dbd0ff31721e4d6bfffec9e5

阅读页：1、3、4、5、6、7、8、18、20。real-to-sim目标、MMRV/Pearson、两机体场景、visual matching与主比较。

- 研究类型：稳健性、失败与评测品质；转移与评测有效性
- 领域：居家整理与清洁
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：2个real robot setups：Google Robot与WidowX/Bridge；4 robot texture版本是视觉补偿，不是4个新环境。
- 任务：Google图6四组（pick、move-near、open/close drawer、open+place）；WidowX图7四组放置 / 堆栈，含grasp子项。原作按group而非唯一语义task计。
- 题数 / 数据：各task有专用real/sim trial安排；Octo多3policy seeds、Google4texture variants，用来降低评估方差，不作新题总量。
- 评估方式：task success；比较sim/real policy排名用Mean Maximum Rank Violation与Pearson r ；validated subset的相关性不保证所有新domain也有相同sim-real关系。
- Split / 信息条件：train on real、evaluate in sim；visual matching与variant aggregation是不同评测策略。
- 来源关系：Google/Bridge真实数据+SAPIEN，另IsaacSim验证；ManiSkill3等重用SIMPLER子集。
- 可复用：为模拟benchmark有效性提供比较方法；没有真机资源时只能先做sim范围，不能宣称完成sim-real验证。
- 待核 / 限制：每task原生trial manifest未完全导入，不虚构统一全库题量。

P105 LIBERO-Plus (2025)

原作：<https://arxiv.org/abs/2510.13626>

本次PDF：<https://arxiv.org/pdf/2510.13626v3>

PDF SHA256：661de08e0ed1bb4bb4774177cac9fafa94f06b5385fa2f4107a1927b9a4aada7

阅读页：1、2、3、4、8、9、10、16。7扰动因素、10,030生成设置、难度分级、额外train数据与评分。

- 研究类型：稳健性、失败与评测品质；稳健性与分布外评测
- 领域：居家整理与清洁、餐饮与烹饪
- 用途归纳：LIBERO-Plus改变观测与初态条件，未改掉原任务的餐具摆放、厨房设备及收纳用途。
- 环境：LIBERO场景扰动：layout、camera、robot初态、语言、light、texture、noise；不是10K新生活场景。
- 任务：7factors / 21components；原作称10,030tasks，多为原LIBERO语义任务的扰动配置。
- 题数 / 数据：10,030benchmark settings；额外>20K成功训练trajectories分开。

- 评估方式：物理success / success drop，依factor平均；5级难度由4个参考模型实测accuracy分层。
- Split / 信息条件：原LIBERO训练到扰动测试，另外有泛化数据post-training；难度依赖校准模型，不能当永久内在难度。
- 来源关系：直接衍生LIBERO；10,030不等于10,030互异goal family。
- 可复用：已有万级评测设置的规模先例；我们若比task数必须先使用共同语义粒度。
- 待核 / 限制：10,030各父task、扰动config和split的逐条去重仍待manifest。

P106 MetaWorld+ (2025)

原作：<https://arxiv.org/abs/2505.11289>

本次PDF：<https://arxiv.org/pdf/2505.11289v2>

PDF SHA256：60d7c336669aaab9834d2e8a6156b410b5cfa28c0c7fe3da0b1da6881af9fc33

阅读页：1、3、4、5、7、16。50task原库、reward版本修正、MT25/ML25、eval统计协定。

- 研究类型：稳健性、失败与评测品质；稳健性与分布外评测
- 领域：居家整理与清洁、餐饮与烹饪、工艺与修缮、装配与生产作业、休闲与运动、通用对象与机动作业
- 用途归纳：MetaWorld+保留原50项任务并修正版本和评测协定，因此沿用具体任务支持的用途。
- 环境：沿用Meta-World Sawyer task environments，非添加50不同环境。
- 任务：50原生task types；添加MT25/ML25中等规模suite及custom task sets。
- 题数 / 数据：multi-task每task50goal episodes；meta每goal适应10episodes后测3episodes；10训练seed不当新task。
- 评估方式：mean success的IQM、95%CI，10seeds；v1/v2 dense reward尺度与设计不同，原文指出历史成绩不可直接混比。
- Split / 信息条件：保留MT/ML角色区别；MT25/ML25自原50选，非另外增加25语义任务。
- 来源关系：Meta-World版本整理与标准化；最应避免把同benchmark历史版本当独立数据源。
- 可复用：提供版本治理与可比较统计方法；对避免旧网页数字混淆尤其重要。
- 待核 / 限制：本库历史pilot的Meta-World commit及reward版本须维持标记，不套用新版baseline成绩。

P107 COLOSSEUM (2024)

原作：<https://arxiv.org/abs/2402.08191>

本次PDF：<https://arxiv.org/pdf/2402.08191v2>

PDF SHA256：ae71956329278bc299039eaa133876b4b132772081418a26c733c4810169edf2

阅读页：1、4、5、6、7、9、18。20task选取、14扰动、适用性、235test sets及real镜像。

- 研究类型：稳健性、失败与评测品质；稳健性与分布外评测
- 领域：居家整理与清洁、通用对象与机动作业
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：RLBench/PyRep场景，外观、camera、质量与friction扰动；不是20,371独立房屋。
- 任务：20基本操作tasks、14perturbation factors；原文20,371 unique task instances为生成配置规模。

- 题数 / 数据：正式235test sets×25episodes = 5,875episodes / model；train20tasks×100demos = 2,000。real另4task镜像。
- 评估方式：task-averaged success与相对无扰动success drop；不适用某factor的task不进该factor分母。
- Split / 信息条件：train不加扰动但保留RLBench原variation；eval固定variation再随机pose；主结果1train seed+1eval seed。
- 来源关系：RLBench子集扩充，YCB distractors；20×14全笛卡儿积不合法（无receiver / compound shape等限制）。
- 可复用：强调只有适用且可运行的扰动才计为case；支持扩规则但不能盲乘。
- 待核 / 限制：20,371生成配置与235固定test set之逐ID对应需manifest导入。

P108 RoboArena (2025)

原作：<https://arxiv.org/abs/2506.18123>

本次PDF：<https://arxiv.org/pdf/2506.18123v2>

PDF SHA256：0f793633ba5767b6e93f01056dcd5c3357dabcaf70844cd0a157a364fa843698

阅读页：1、4、5、6、7、8。分布式A/B协定、偏好排名模型、DROID平台与完整实验分母。

- 研究类型：稳健性、失败与评测品质；分布式真实评测
- 领域：居家整理与清洁、餐饮与烹饪
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：7个学术机构使用DROID平台，evaluators自行选scene/task；没有固定封闭的环境总数。
- 任务：开放指令集合，涵盖数百task instructions；不是固定17task，17是外部窄基准比较。
- 题数 / 数据：超过600次pairwise评估；为创建oracle ranking，额外跑其余5policies，全计4,284 policy rollouts。不能称4,284独立题。
- 评估方式：双盲pairwise preference + progress；扩充Bradley–Terry估计policy排名与task effects，另产生有视频证据的质性报告。
- Split / 信息条件：连续累积开放评测；没有一般train/test固定题库；同一次A/B需相同task条件。
- 来源关系：DROID共同硬件/数据；RoboReward重用其真实成功 / 失败rollouts。与RobotArena ∞ 是不同工作。
- 可复用：可作开放题库 / 偏好排名的评测方法参考；规模必须标明是rollouts还是task。
- 待核 / 限制：精确去重scene与语义task总量需要evaluation database，不从hundreds推成确定数。

P109 REFLECT / RoboFail (2023)

原作：<https://arxiv.org/abs/2306.15724>

本次PDF：<https://arxiv.org/pdf/2306.15724v4>

PDF SHA256：6018e97d117acefc2b31a0df616b29eb479b95035bf47ea2fd5882a6631ae6c3

阅读页：1、2、4、5、6、7。数据规模与错误taxonomy、说明 / 定位 / 修正三种评测及GT信息。

- 研究类型：稳健性、失败与评测品质；错误辨识与程序恢复
- 领域：居家整理与清洁、餐饮与烹饪
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。

- 环境：AI2-THOR simulation与UR5e toy kitchen；sim用GT对象 / 状态辨识，real靠感知。
- 任务：10simulation tasks、11real tasks；规划失败与运行失败两大群。
- 题数 / 数据：100sim failure cases（每task10）+ 30real failure demonstrations；没有把正常train视频混入失败case总量。
- 评估方式：Exp：人工判说明正确且有用；Loc：时间落在标注区间；Co-plan：运行修正后goal state成功。；real结果表主要报Exp/Loc，不能把sim约80% Co-plan当real自主恢复率。
- Split / 信息条件：方法zero-shot failure reasoning；GT perception与action primitives降低sim难度。
- 来源关系：sim手动注入failures，real由teleop模拟失败政策；并非全为自主机器人自然犯错。
- 可复用：可借规划与运行失败taxonomy，明确分『指出错误』『提出修正』『真的恢复』。
- 待核 / 限制：sim/real语义task重叠未去重；完整raw failure时间 / 场景ID仍待导入。

P110 AHA (2024)

原作：<https://arxiv.org/abs/2410.00371>

本次PDF：<https://arxiv.org/pdf/2410.00371v1>

PDF SHA256: d647c7bff1ccb2d0ae805bab761177aba8cd50d81d0418ca174e9ae97054791b

阅读页：1、2、4、5、6、7、8。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：稳健性、失败与评测品质；错误辨识与程序恢复
- 领域：居家整理与清洁
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：RLBench、ManiSkill与realRoboFail；非添加三套物理环境。
- 任务：7failure modes的Yes/No判断 + 原因解释；识别失败不等同真正恢复。
- 题数 / 数据：49KtrainingfailureQA；test11K（10未见RLBench tasks），ManiSkill-Fail130pairs（4tasks），realRoboFail7tasks。
- 评估方式：binary success labelaccuracy、ROUGE-L、cosinesimilarity、LLM fuzzy match。
- Split / 信息条件：RLBench train/test taskdisjoint，跨sim与real另测；额外VQA/LVIS训练数据不可算failurecases。
- 来源关系：FailGen改keyframes/gripper动作合成失败；RoboFail重用。
- 可复用：可大量增加失败规则cases，同时用跨来源/真实子集验证而不冒称添加语义工作。
- 待核 / 限制：keyframe产生failurelabels是生成机制标签，和视觉可观测真因未必完全相同。

P111 RoboReward (2026)

原作：<https://arxiv.org/abs/2601.00675>

本次PDF：<https://arxiv.org/pdf/2601.00675v2>

PDF SHA256: 601200a96f8e30137cd3166d6d330ff9ff2ceb0de6a4c43949d808e6e9c0d29a

阅读页：1、2、3、6、7、8、9、22、27。OXE/RoboArena来源、counterfactual/clipping生成、5级rubric、完整split与人工验证附录。

- 研究类型：稳健性、失败与评测品质；奖励与完成度评测

- 领域：居家整理与清洁
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：多OXE来源与RoboArena实拍；14embodiments是机体种类，非14生活环境。
- 任务：给task description+rollout video预测1-5progress；反事实重写指令和截短视频扩增负例，不自动添加实体失败任务。
- 题数 / 数据：45,072train / 6,232val / 2,831人类验证test；合54,135 episode-reward pairs。RoboArena test子集1,000。
- 评估方式：主metric progress label MAE，总体采group-wise平均；不同子数据源分列，另以RL下游验证。
- Split / 信息条件：按original task description分组互斥；同一视频的counterfactual/clips需跟父episode分组，字符串互斥不证明语义互斥。
- 来源关系：OXE成功demo及RoboArena自然成功 / 失败；生成标签是弱监督，test另人工逐例确认。
- 可复用：是有效扩充任务 / 评分规则的重要来源；应区分重标问题与新物理轨迹。
- 待核 / 限制：跨OXE子集的母episode重复与semantic task去重仍需ID核。

P112 EgoOops (2024)

原作：<https://arxiv.org/abs/2410.05343>

本次PDF：<https://arxiv.org/pdf/2410.05343v3>

PDF SHA256：fcf3b48c7dea45c46f41391de07a874453ef74d8762655f4104e34d8dfa9bb23

阅读页：1、3、4、6、7、15。5程序完整清单、6种运行错误、50视频、cross-validation与三端点。

- 研究类型：稳健性、失败与评测品质；错误辨识与程序恢复
- 领域：工艺与修缮、装配与生产作业、实验室操作
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：固定坐姿工作站，原对象 / 工具 / 程序文字位置固定；4名学生佩戴ego camera。
- 任务：5task：电路、混色、离子反应、积木、纸板工艺；6运行错误类型，未涵盖所有顺序 / 漏步错误。
- 题数 / 数据：50videos、538segments、95execution mistakes；每fold30train/10val/10test，5-fold。
- 评估方式：端到端step alignment + mistake/correction mAP@tIoU0.1/0.2/0.3；GT segments分类是oracle子问题。；alignment另F1/precision/recall/MoF。
- Split / 信息条件：每fold各task一正常一错误test视频；作者称group-kfold控制worker，精确ID仍需查。
- 来源关系：自录多领域程序；一半刻意错、一半尽量正常但也有自然失误。
- 可复用：补料理以外程序错误；规则由文字指定，不能仅凭视觉常识判定。
- 待核 / 限制：4名参与者与5-fold worker grouping的精确分配需manifest查。

P113 REPAIR-Bench (2026)

原作：<https://arxiv.org/abs/2606.29937>

本次PDF：<https://arxiv.org/pdf/2606.29937v1>

PDF SHA256：c63b11a21f43bad4c9a0709836fb1f9ca225602ea2192d55be74dd59ea385cfd

阅读页：1、2、3、4、5、6。RFM-HRI来源、排除样本、3端点、各split、时间与偏好评分。

- 研究类型：稳健性、失败与评测品质；错误辨识与程序恢复
- 领域：医疗与手术支持、协助、交接与陪伴
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：lab与hospital的crash-cart guidance交互；不是完整医疗操作或手术任务。
- 任务：3端点：失败时刻、失败类型、用户偏好恢复策略；4诱发failure conditions + success。
- 题数 / 数据：来源214 trials/41人；排30后正式analysis 184 trials/38人。不能将214全部写成已用评测样本。
- 评估方式：视觉failure classification F1等；localization秒级absolute error与tIoU F1^o；recovery用Hit/precision/recall/F1@k，GT是人的偏好，未证明机器人运行恢复成功。
- Split / 信息条件：visual tasks约75/25 participant分组；recovery文本60/20/20随机split，不能宣称三端点都participant-disjoint。visual任务刻意不给语音。
- 来源关系：RFM-HRI旧数据添加标注与preference；failure offset以机器人错误回应结束作标记，不是物理抓取失败时刻。
- 可复用：补user-centered interaction recovery；必须和物理任务恢复及其成功证据分开。
- 待核 / 限制：前处理阶数/cutoff不同段落叙述不一，重现需code确认；source 214与41×5亦不完全一致。

P114 RobotArena infinity (2025)

原作：<https://arxiv.org/abs/2510.23571>

本次PDF：<https://arxiv.org/pdf/2510.23571v3>

PDF SHA256：d08b1e9db69b3e2efbb9e51be4044370272927d0d53c97807368bfbdb42892ba9

阅读页：1、3、5、6、7、8、9、25。real-to-sim来源、VLM评分与human BT ranking、BridgeSim规模及real验证范围。

- 研究类型：稳健性、失败与评测品质；转移与评测有效性
- 领域：居家整理与清洁
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：BridgeSim 70环境；另DROIDSim、RH20TSim。总量仅概述hundreds，不能用70代称三套全库。
- 任务：由真实demo生成task + digital twin，再扰动初态/texture；未给共同语义task类别总数。
- 题数 / 数据：BridgeSim上8,749 pairwise comparisons；是对policy视频的偏好标注，不是8,749不同task。
- 评估方式：Gemini结合video + privileged sim states评progress，取最后30% frames平均；human pairwise BT ranking另列。；real/sim相关验证只展示1个carrot-to-plate任务的3 policy，不能外推全库已校准。
- Split / 信息条件：Bridge/DROID/RH20T来源与policy训练来源分in/out；同场景pairwise保持相同初态。
- 来源关系：真实Bridge、DROID、RH20T衍生；不同于RoboArena在真机直接分散评估。
- 可复用：提供多来源real-to-sim与偏好评分途径；要区分生成场景、物理成功checker和VLM judge。
- 待核 / 限制：DROIDSim / RH20TSim精确场景ID量与跨来源等价未导入。

P115 RoboMME-Interference (2026)

原作：<https://arxiv.org/abs/2606.22338>

本次PDF: <https://arxiv.org/pdf/2606.22338v3>

PDF SHA256: 95baa91cdd2a1d6c0791a31627a8daee1d9e9ff70d58d60e76f53e4e3d142c40

阅读页: 1、2、3、4。9/16task选择、history干扰规则、完整系统网格与50episode评测。

- 研究类型: 稳健性、失败与评测品质; 长期记忆与生活助理
- 领域: 装配与生产作业、通用对象与机动作业
- 用途归纳: 依示范选物、搬方块、重画路径与插栓, 归入通用作业复现与装配基础作业。
- 环境: 沿RoboMME配置, 添加跨session history; 不是新物理环境。
- 任务: 16原task中选9个有可分离demo的families: 4程序、3object、2spatial memory; 其余7不适用。
- 题数 / 数据: $9 \times 50 = 450$ 基底test episodes; history条件no-history及 $k=0/1/3/7$; 11memory systems + 无memory baseline造成25,200内核rollouts, 非同量独立题。
- 评估方式: 成功率与Wilson95%CI; 随干扰增加的退化曲线; retrieval改进另列。
- Split / 信息条件: 不重训released checkpoint, 仅变history; 每distractor32stored frames且来自不同family, 避免混入相互矛盾信息。
- 来源关系: RoboMME的9-family子集加history规则; 非全新9task。
- 可复用: 展示规则扩充可增加可评条件而不改语义task数; 记忆干扰可做本库共通延伸。
- 待核 / 限制: 原始RoboMME benchmark须独立登记检查; 跨history条件query IDs应保留父关系。

P116 OopsieVerse (2026)

原作: <https://arxiv.org/abs/2606.31993>

本次PDF: <https://arxiv.org/pdf/2606.31993v1>

PDF SHA256: cbef5a184d84ac4490de9dbbfde077c3b9a7905c1d6bc581e739540b078af3d2

阅读页: 1、2、4、5、6、7。DamageSim三类伤害、32实作/21task设计、demo及安全-success评分。

- 研究类型: 稳健性、失败与评测品质; 安全与约束评测
- 领域: 居家整理与清洁、餐饮与烹饪
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: OmniGibson与RoboCasa/Robosuite两后端; 热 / 流体伤害只在支持相应物理的后端可用。
- 任务: 32task instantiations对应21unique task designs; 不是32不同语义任务。
- 题数 / 数据: 5示范task共90demonstrations, health feedback有/无各半; IL每task30rollouts。
- 评估方式: task completion与安全completion分开; 后者需goal成功且所有tracked object health维持>95。; damage由力、温度、液体接触的参数模型计算, 不能等同已校准的真实损害概率。
- Split / 信息条件: 不同collection/curation/RL/VLA设置分开; 5task IL子集不代表全32皆同程度实验。
- 来源关系: BEHAVIOR1K与RoboCasa任务加damage观测 / reward / termination; 共享goal与backend instantiations。
- 可复用: 为同一goal增加保护对象 / 低破坏条件的直接先例, 规则差异应独立可查。
- 待核 / 限制: damage threshold跨材料 / 跨后端的物理标定程度须另验证。

P123 WatchAct (2026)

原作: <https://arxiv.org/abs/2606.26443>

本次PDF: <https://arxiv.org/pdf/2606.26443v1>

PDF SHA256: 42a137d5b56c9e1dd7d421cba16f8f06fe42cace6418e7338136400df3e7954c

阅读页: 1、2、3、4、5、6、8、14、15。14task完整taxonomy、3K个案、video-sim配对、4项验证与plan/physical/end-to-end协定。

- 研究类型: 人类观测到机器人转移; 人类示范与技能转移
- 领域: 居家整理与清洁、通用对象与机动作业
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: LIBERO配对真实桌面视频; 11桌面regions + 6container regions只是命名区域, 非17个环境。
- 任务: 14task scenarios归4认知domains; event、procedure、implicit intent、episodic, 含模仿、反转、恢复旧位置、续作、修错、条件分支。
- 题数 / 数据: 3,000 video-language-simulator bundles; policy实验每task10trials, 与全部3K的plan reasoning范围分开。
- 评估方式: Plan SR在symbolic executor; Task SR在物理simulation; PR完成子goal比例。; 顺序唯一task直接比oracle, 允多解的task比symbolic终态; oracle-plan execution与integrated pipeline分开。
- Split / 信息条件: LIBERO-finetuned policies转到paired tasks; 新对象/指令in/out-domain另列, 固定每command300steps。
- 来源关系: LIBERO扩新对象 / predicate; LLM先产spec再照spec拍人类video, 不是从任意网络video全自动转robot。
- 可复用: 最接近『视频→任务规格→可运行场景』的前作; 还受限於Pick/Place/Open/Close, 排除pour/wipe/cut/stir。
- 待核 / 限制: physical评测每task10trials中task指类型或instance的manifest需核, 不先乘成3万或宣称3K全测。

P124 RoboReel (2026)

原作: <https://arxiv.org/abs/2609.08209>

本次PDF: <https://arxiv.org/pdf/2609.08209v2>

PDF SHA256: 4f0b2629e1e663390e169e7ae24496406246958dbec7bb20f3973de31a9e34ff

阅读页: 1、2、3、4、5、6、7、9、21、24、25、27、29。10task、4suites、配对搜集、附录完整统计、success predicate和eval banks。

- 研究类型: 人类观测到机器人转移; 人类示范与技能转移
- 领域: 居家整理与清洁
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 1个实际桌面rig与ManiSkill3/SAPIEN配对场景, 4人类camera views; calibration与distractors另分setting。
- 任务: 10task (推/抓方块、抽屉、锅盖、烤面包机、碗盘、篮子、玩具收纳、堆杯); 4suites ND/WD/ED/PD, 不是40语义task。
- 题数 / 数据: 正文2,000ND/WD human demos; 附录含PD共3,000human demos = 12,000视角mp4, 另2,000robot trajectories。每结果cell3runs×20 = 60rollouts。
- 评估方式: simulation goal predicates; 比如drawer只需关至少一半、toaster80%进程, 不能与更严格同名task直接比。; 表格报3runs mean/SEM; SeeDo仅5项支持task, N/A不是0。

- Split / 信息条件：每task-condition 100 human demos取80train/20eval；oracle-filtered initial-state banks固定初态。
- 来源关系：PartNet-Mobility + SAM3D real twin；explicit/latent/keypoint三种LfO代表比较，借不同既有policy。正文称接受后发布，素材取得待核。
- 可复用：可借真实human→sim配对及同条件多方法对比；不应把camera/views文件量作添加题量。
- 待核 / 限制：100seed与每bank 300entry在同段并列，需原生manifest厘清最终bank量；发布可得性尚未验证。

P127 BridgeData V2 (2023)

原作：<https://arxiv.org/abs/2308.12952>

本次PDF：<https://arxiv.org/pdf/2308.12952v3>

PDF SHA256：aa5fdac48bf9122b22f88150d45575cb0685f2a2f761ca6fc570be743022819b

阅读页：1、3、4、5、6。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：机器人数据与通用策略；真实操作benchmark
- 领域：居家整理与清洁、餐饮与烹饪、衣物与洗护
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：24environments，含7toy kitchens及tabletops/sinks/laundrysetups，4环境类别。
- 任务：13skills；同skill换object可成不同原作task，未报全库范式task总数。
- 题数 / 数据：60,096trajectories = 50,365expert+9,731scripted；主task每method 10trials。
- 评估方式：tasksuccess；goalimage与languageconditions分别比较。
- Split / 信息条件：seen/unseenobject/environment/otherinstitution；RT1input分辨率与history较大须登记。
- 来源关系：BridgeData原版扩充，后被OXE/OpenVLA/Octo重用。
- 可复用：补家电、表面、衣物与颗粒工具操作；保留human/scripteddemo品质类型。
- 待核 / 限制：13skill不是13全部task；不同原作method观测预算未完全一致。

P128 RoboNet (2019)

原作：<https://arxiv.org/abs/1910.11215>

本次PDF：<https://arxiv.org/pdf/1910.11215v2>

PDF SHA256：01a03705dfb76192445b8c09fa3e85d67a1d9165b2c00df3672cfd10cc66052a

阅读页：1、3、4、5、6。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：机器人数据与通用策略；跨数据集集成与评测方法
- 领域：通用对象与机动作业
- 用途归纳：内核目标是把未知对象推或抓放到指定位置，归入跨场域对象搬移作业。
- 环境：4lab environments、113camera configurations、7arenatypes等不同环境层级。
- 任务：主要objectrelocation，可用推或抓放；manyrobots不增加相同数量goal families。

- 题数 / 数据：15Mframes、约162Ktrajectories；7platforms，Table1caption称6arms有文字差异。
- 评估方式：endgoal distance与operator判断是否覆盖goal；作者明言不同experiments不可直接比难度。
- Split / 信息条件：held-out robot或view再fine-tune300–400targettrajectories；不叫完全zero-shotrobottransfer。
- 来源关系：多institution数据与existingrobotcorpora集成；同物理trajectory可能多view。
- 可复用：重要早期集成前作；以哪种目标、哪种信息与哪个分母比较，比合并大小更关键。
- 待核 / 限制：release-version轨迹精确数及scene去重待manifest；不从15Mframes推testcases。

P129 RH20T (2023)

原作：<https://arxiv.org/abs/2307.00595>

本次PDF：<https://arxiv.org/pdf/2307.00595>

PDF SHA256：6156500a1340a2e976681f0f8deea8ce493fb4af227d8a5b2696cb3c384bb755

阅读页：1、2、3、4、5、6。147task来源、7硬件配置、pairing阶层、110K数据与实际few-shot实验。

- 研究类型：机器人数据与通用策略；人类示范与技能转移
- 领域：居家整理与清洁、装配与生产作业、通用对象与机动作业
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：7robot configurations、>50table covers；covers不是不同场景layout。
- 任务：147tasks = 48选自RLBench + 29MetaWorld + 70自定义；42verbs是skill标签，不是147完全独立新设计。
- 题数 / 数据：>110K robot sequences与等量human sequences；hierarchy可配出数百万pairs但不是同量独立视频。本文ACT主实验只在1个block-to-weight任务，每configuration20trials。
- 评估方式：人类收集时0–9quality、成功/失败约10:1；ACT实验分reach/grasp/place success，60秒上限。
- Split / 信息条件：新环境含新camera/tablecover/robot；pretrain335同task + 195相近task，fine-tune75demo起，再缩小数据。
- 来源关系：RLBench与MetaWorld任务规格被实拍移植；新实拍数据是新素材，但goal定义有上游来源。
- 可复用：是从前作选task再扩新task、兼有人类视频与robot轨迹的重要前例。
- 待核 / 限制：paired视频之精确实例对应与跨机体可比性需原生metadata导入。；DROID原作表I将RH20T依unique multi-view trajectories记为约13K，与RH20T原作110K口径不同；保留两种出处，未完成原始manifest去重。

P141 HoloAssist (2023)

原作：<https://arxiv.org/abs/2309.17024>

本次PDF：<https://arxiv.org/pdf/2309.17024v1>

PDF SHA256：af4fda7dcdcc0e5c9e4e4649f19bea3da6b3afe52e7a83d1adc8e7a79c011421

阅读页：1、3、4、5、6、7、8、9。20task来源、sessions/标签、mistake/intervention/forecasting、split与指针。

- 研究类型：辅助与协作；对话协作与任务完成
- 领域：餐饮与烹饪、办公与教育、工艺与修缮、装配与生产作业、协助、交接与陪伴
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。

- 环境：HoloLens2 wearer + 远程instructor；16对象种类，非16场景。
- 任务：20程序；414coarse action classes；mistake detection、intervention type、3D手预测及action recognition。
- 题数 / 数据：2,221sessions、166小时、222人 / 350pairs；1,545train、213val、463test。错误/介入表只评10%全数据子集。
- 评估方式：动作top-1/5；错误F-score与precision/recall；3种intervention分类。；手轨迹看过去3秒、预测0.5/1/1.5秒，用MPJPE厘米；只保留正确action。
- Split / 信息条件：每task按session70/10/20，并非保证参与者或instructor/performer pair全互斥。
- 来源关系：新录human-human交互；字幕 / 动作 / 介入共用session，非多个独立数据库。
- 可复用：提供人类教学、介入时机、程序错误与短期手预测；是协作型多模态来源。
- 待核 / 限制：fine action label总数和各endpoint精确可评IDs仍需manifest；不从coarse414推整套任务数。

P142 Habitat 3.0 (2023)

原作：<https://arxiv.org/abs/2310.13724>

本次PDF：<https://arxiv.org/pdf/2310.13724v1>

PDF SHA256：6383018901acbf7677050585da9a30707437cf7119def797be500f33a68021af

阅读页：1、2、5、6、7、8、20、25、26。avatar/HITL、2任务、59scene split、合作人口与metrics。

- 研究类型：辅助与协作；对话协作与任务完成
- 领域：居家整理与清洁、协助、交接与陪伴
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：HSSD211源scene中的59实验scene = 37train/12val/10test；12base avatars不是12场景。
- 任务：2families：social navigation找/跟人；social rearrangement两代理搬2对象。
- 题数 / 数据：附录按scene抽train1000、val100、test15；即37Ktrain、1,200val、150test基底episodes，协作partners另作条件。
- 评估方式：导航Finding Success/SPS/Following Rate/Collision Rate；rearrangement SR与relative efficiency对human-alone比较。
- Split / 信息条件：未见scene + new partner population；oracle/learned low-level skills分开。导航主设置有持续humanoid GPS，不是只凭RGB找人。
- 来源关系：HSSD、AMASS、SMPL-X、Habitat底座；human avatar使用kinematic attach等简化，与real人类动力不同。
- 可复用：是可比拟human/robot角色与partner泛化的重要底座，不能再当全新场景资产。
- 待核 / 限制：全来源211scenes和59实验子集不能合并计数；不同HSSD版本与HomeRobot/PARTNR需scene ID对齐。

P144 CAP/EgoGym (2026)

原作：<https://arxiv.org/abs/2602.09017>

本次PDF：<https://arxiv.org/pdf/2602.09017v1>

PDF SHA256：b0428cf26ad882127851059de2fafebb3ae164e38f631b9d941ca8ac0ebbed44

阅读页：1、2、4、5、6、7、8、11。数据、接触prompt、EgoGym设计、3task真实与跨机体eval、tool chaining。

- 研究类型：人类观测到机器人转移；模拟平台与任务套件
- 领域：居家整理与清洁、办公与教育
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：数据报424environments = Pick289/Open87/Close48，为作者收集配置口径；EgoGym是程序生成MuJoCo套件。
- 任务：3utility task families: Pick、Open、Close；不因接触座标不同自动变新语义任务。
- 题数 / 数据：20,365human-tool demonstrations、23.1小时；real Pick250trials, Open/Close每checkpoint100trials；EgoGym有915Objaverse object pool。
- 评估方式：task success；oracle human contact prompt、VLM contact prompt、retry设置分开。
- Split / 信息条件：real新scene/object zero-shot；sim用作training loop model selection，不能当独立未见test。
- 来源关系：Objaverse assets + iPhone手持工具数据；CAP可作高级模型tool calls的低级utility。
- 可复用：支持multimodal tool use与robot skills组合，但示范用contact anchors、主eval有oracle条件，应明列。
- 待核 / 限制：424是否跨Pick/Open/Close具有同址重用需ID核；EgoGym完整eval bank量待code。

P145 NIABench (2026)

原作：<https://arxiv.org/abs/2605.01368>

本次PDF：<https://arxiv.org/pdf/2605.01368v1>

PDF SHA256：add5ffdd033bc8c450f79b317f31c0df3735d7a4789a9e8f833e3dbcab4f5b12

阅读页：1、2、3、4、5、6。2K来源、7test tasks、非中断规则、text-only状态与3指针。

- 研究类型：辅助与协作；对话协作与任务完成
- 领域：居家整理与清洁、餐饮与烹饪、办公与教育、协助、交接与陪伴
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：AI2-THOR四room categories；4是类型，非精确四个scene IDs。主model采文字state，没有raw visual perception。
- 任务：7test tasks：cut tomato、toast bread、watch TV、work、sleep、study、shower；2,000训练script episodes，human主程序不允许被中断。
- 题数 / 数据：2K corpus再分train/val；7个代表evaluation episodes；75%一个oracle assistance、20%两个、5%无需协助。
- 评估方式：SelectionAcc比oracle step-action pair；HumanStepSaved减少的人类primitive steps；SuccessAcc查最终sim state。
- Split / 信息条件：2K按scene/oracle数分train/val，7held-out另设；real只2小型验证任务。
- 来源关系：AI2-THOR高级动作adapter；800atomic actions是候选动作词汇，不是800已实作工作任务。
- 可复用：可加不打断人类、适时协助与no-op合法答案等规则；不能宣称2K都为held-out test。
- 待核 / 限制：7代表情境内是否另有多多个随机initial seeds及确切case量需code核。

P146 DexH2R (2025)

原作：<https://arxiv.org/abs/2506.23152>

本次PDF：<https://arxiv.org/pdf/2506.23152v3>

PDF SHA256：c48a1c58f5201ee324223c711cba95a429ea7446bc43e4d59f452e829eda1709

阅读页：1、2、3、4、5、6、7。data/rig、handover动态定义、完整split、pose与trajectory指针。

- 研究类型：辅助与协作；灵巧手操作benchmark
- 领域：协助、交接与陪伴
- 用途归纳：内核就是把人手中的对象交给机器人，归入协助与交接用途。
- 环境：UR10e + ShadowHand固定capture setup，18视角（含2wrist ego），不是18环境。
- 任务：1内核human→robot handover family；56对象 / 39人，包含动态接近与终态抓握。
- 题数 / 数据：4,282trials、456Kframes、79,911成功grasp poses；2,888train / 591val / 803test trajectories。
- 评估方式：grasp succ1/succ6外力稳定、penetration、diversity；approach success、trajectory length、inference frames、safety率。
- Split / 信息条件：test含新object/newsobject、newobject/seensubject、seenobject/newsobject三群；不是803独立任务语义。
- 来源关系：真实teleoperation human-object-robot交互，grasp模型另用DexGraspNet预训练。
- 可复用：补人机交接、动态手型 / 接触安全，区分pose、trajectory及物理handover完成。
- 待核 / 限制：每test子群细分ID与final pose对母trajectory的多对一关系待manifest。

P147 HRI Bench (2026)

原作：<https://arxiv.org/abs/2607.13056>

本次PDF：<https://arxiv.org/pdf/2607.13056v1>

PDF SHA256：d779bea84ddd0cbca254797e628b09dbf95118efa086cfe333dd6156a4a2ded2

阅读页：1、3、4、5、6、7。role scripts、13tasks、786过滤池、50/10真实split与coordination metrics。

- 研究类型：辅助与协作；对话协作与任务完成
- 领域：协助、交接与陪伴
- 用途归纳：按人的指令、时机和动作完成协作，涵盖交接、同步、让行及受干预后续作。
- 环境：Franka simulation结合合成人类骨架/trajectory；候选由2K生成并筛。
- 任务：13 role-conditioned tasks；Instructor / Collaborator / Intruder三角色。
- 题数 / 数据：2,000候选中786通过；正文实验每task50adaptation+10held-out，因此650adaptation / 130held-out。摘要『>650 evaluation episodes』不等于主实测test量。
- 评估方式：CSR/time/idle、temporal sync/latency/order、collision/contact/contradiction/disruption；partial安全summary需按适用component。
- Split / 信息条件：固定policy无关Intruder扰动时序；real3task各10trials，只是adaptation验证。
- 来源关系：生成scripts/human motion并sim验证；两个同名HRI Bench不得合成同一来源或版本。
- 可复用：加入等待、同步、角色及干预恢复规则；数据候选通过不等于全部是test。
- 待核 / 限制：786与13×60=780剩6条用途未明，需manifest；摘要650eval与正文130held-out须分列。

P148 Assistax (2025)

原作：<https://arxiv.org/abs/2507.21638>

本次PDF: <https://arxiv.org/pdf/2507.21638v3>

PDF SHA256: 53953a170eca350244258f44b0b043e960f2bcece29e1074e805ab251bc95547

阅读页: 1、3、4、5、6、7、8、9。5assistive tasks、robot/human控制、preferences、630partner池与MARL/AHT评测。

- 研究类型: 辅助与协作; 协作控制benchmark
- 领域: 个人照护、协助、交接与陪伴
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: MJX/JAX五种assistive配置, 使用简化rigid geometry; 不是临床或柔性皮肤物理验证。
- 任务: Scratch、Tooth Brushing、Feeding、Bed Bathing、Arm Assist; force/speed/contact偏好另外参数化。
- 题数 / 数据: 每task630pretrained humanoids; AHT以5train/625unseen partners; MARL每曲线16seeds与64eval episodes。
- 评估方式: task/preference return分开, 跨任务min-max normalized mean、bootstrap95%CI; 新partner泛化。
- Split / 信息条件: partner-disjoint; 挑5个high speed preference为train是刻意困难设置; 精确episode/context数不等于625新task。
- 来源关系: Assistive Gym inspired任务, Brax humanoid与MJX; 原始Assistive Gym需补为上游来源。
- 可复用: 补个人照护、人类偏好及协作适应; 没有固定统一题库上限。
- 待核 / 限制: 不同partner/preferences的物理对应与真实用户有效性未等同验证。

P151 H2R-Bench (2026)

原作: <https://arxiv.org/abs/2608.13049>

本次PDF: <https://arxiv.org/pdf/2608.13049v1>

PDF SHA256: ec3fb6258fea92eda2ba4240561afd8f307606a133031b63ad12d666306af015

阅读页: 1、2、3、4、5、6、11、14。source-relative定义、120→240cases、6家族、native interface与五metric。

- 研究类型: 世界模型与预测表示; 世界模型与视频生成评测
- 领域: 衣物与洗护、通用对象与机动作业
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: EgoDex test来源视频, 没有配对可运行robot simulator环境。
- 任务: 6物理变化families: rigid、mechanism、insertion、deformable、bulk、surface; 目标2种embodiment。
- 题数 / 数据: 120段5秒source clips×2embodiments=240transfer cases; 每family20source。11generators的输出视频数不是新题数。
- 评估方式: M1goal/M2events/M3contact/M4embodiment由3个MLLM按0–4rubric评; M5为video quality。; 每metric25sampled frames; H2RCore加权contact与embodiment共60%, 属视频证据评分, 非实际控制成功。
- Split / 信息条件: EgoDex test衍生; video-conditioned与frame-conditioned界面分组, 不能不控制输入信息比较。
- 来源关系: EgoDex来源; 与H2RBench human-transfer及RoboWM-Bench不同任务, 不能因名称相似合并。
- 可复用: 可加入human→robot视频转移端点; 应作世界模型章, 与可运行操作题数分开。
- 待核 / 限制: contact的视频可见正确不能保证力 / 深度 / 可达性, 仍缺物理execution证据。

P152 RoboWM-Bench (2026)

原作: <https://arxiv.org/abs/2604.19092>

本次PDF: <https://arxiv.org/pdf/2604.19092v2>

PDF SHA256: 4450ceffa72850511da6c91b3ce6f73bc070d372104dc8f60ce6fbf8f84ed566

阅读页: 1、3、4、5、6、7、14、15。video→action两路、task suite、主表与sim附录、10初态与execution成功。

- 研究类型: 世界模型与预测表示; 世界模型与视频生成评测
- 领域: 餐饮与烹饪、衣物与洗护、通用对象与机动作业
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: LeHome/IsaacSim原生与real-to-sim桌面; 固定camera、随机对象初态。
- 任务: 主表8human-hand及8robot-task条件, 附录另6simulation-native条件; 含同名重用, 不直接加成22语义task。
- 题数 / 数据: 每task10个共同initial configurations; Cosmos-finetune每task50trajectories是额外训练。bimanual附录又为另条件。
- 评估方式: generated video经HaMeR retargeting或IDM转action, 再进simulation; key nodes全通过且达goal才Task SR, 另Step SR。
- Split / 信息条件: 固定初态 / 种子跨model; human与robot视频使用不同action extraction pipeline, pipeline误差须分开分析。
- 来源关系: LeHome底座与real reconstruction, PAI-Bench作同视频视觉分数对照。
- 可复用: 提供生成视频到物理可运行性的桥梁, 但需把视频模型和action extractor责任拆解。
- 待核 / 限制: 全部task条件与语义去重清单需release manifest; retargeting/IDM失误会影响world model分数。

P164 The Imitator Game (2026)

原作: <https://arxiv.org/abs/2608.22301>

本次PDF: <https://arxiv.org/pdf/2608.22301v1>

PDF SHA256: f38c19c22603063351fd35a218cc5a1477609c973c0a79cbe972a2bb78f01e1b

阅读页: 1、4、5、6、7、8、20。L0-L3保留/变更条件、IG-10K规模、六domains、sim/real及Arena协定。

- 研究类型: 人类观测到机器人转移; 人类示范与技能转移
- 领域: 居家整理与清洁、餐饮与烹饪、包装、仓储与物流、零售与购物、实验室操作、医疗与手术支持
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 200+ paired task-scene variants; 同human clip可对多level robot场景, 非全新independent demonstration。
- 任务: 50+base tasks, 6生活/工作domains (分量12+7+17+4+6+7=53); 实验10tasks (5seen+5unseen) ×4levels。
- 题数 / 数据: 11,720real paired episodes + 10Ksim pairs (sim重用human clip); 每task-level sim10trials、real5trials。15/30/45task训练套件相互包含。
- 评估方式: sim SR与ordered subgoal SR; 人类SUCCESS/PARTIAL/FAIL、0-10imitation quality、pairwise preference; L0动作近似、L1布局改变、L2对象替代、L3功能替代; level是demo-execution pair属性, 不是task固定难度。
- Split / 信息条件: sim/real分开训练与比较; same domain/setting/task/level/episode才做A/B, 少数task不定义L3。
- 来源关系: ManiSkill3、手工waypoints、VR真机pairs; 与RH20T等比较, 但多level共用源human clip。

- 可复用：是意图 / 功能替代及多域human-robot数据近邻；我们须纳入其6用途群与可替代规则。
- 待核 / 限制：53分域与表2『50 tasks』的版本口径须manifest确认；不可把4levels机械乘所有task。

P165 LIBERO-Recover (2026)

原作：<https://arxiv.org/abs/2609.05178>

本次PDF：<https://arxiv.org/pdf/2609.05178v3>

PDF SHA256：ee23bf31934cc0e262b4b30458be149df135ec3695c866939c482c0b55fe414a

阅读页：1、2、3、4、5、6、9。failure对normal variation的区分、2178scenario生成、恢复数据与RSR/RD/RC。

- 研究类型：稳健性、失败与评测品质；错误辨识与程序恢复
- 领域：居家整理与清洁
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：LIBERO自然rollout失败的state snapshots；不是2178不同room layouts。
- 任务：130上游tasks、4recovery levels；LIBERO100再拆90/10报告，不能另加两suite。
- 题数 / 数据：2,178recovery scenarios；413training failure scenes有3,184human recovery trajectories，训练使用场景排出最终eval。
- 评估方式：Recovery Success Rate完成原goal；Recovery Degradation比较failure前后；RC=1-task-level success率标准差。；RC公式实际是跨task变异，不完全等同文中所说同task不同failure的稳定性。
- Split / 信息条件：六policy产failure，Qwen定位/分类；自然failure分布不平衡。eval每task10trials、520step，需固定scenario/perturbation解读。
- 来源关系：LIBERO延伸；失败条件要execution-induced且需改plan但仍可恢复，不能把任何位置变化都叫failure。
- 可复用：可引入真实policy失败状态而非纯人工扰动；恢复题需要前史与可恢复证据。
- 待核 / 限制：recoverability对每scenario的完整验证证据、2178与training排除先后、eval task词义需manifest查。

P166 SafeVLA-Bench (2026)

原作：<https://arxiv.org/abs/2606.00773>

本次PDF：<https://arxiv.org/pdf/2606.00773v2>

PDF SHA256：ecb59f541415c25bcb45263b2c7058d15a124829c8dab6d7b5eac681f36c1f4a

阅读页：1、3、4、5、6、34、46。STL库、8scored families、适用性registry、58tasks/27entries及指针定义。

- 研究类型：稳健性、失败与评测品质；安全与约束评测
- 领域：居家整理与清洁、餐饮与烹饪
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：LIBERO + RoboCasa365两host，事后instrumentation保留原生观测/动作/初态/success。
- 任务：58tasks = LIBERO四10-task suites + RoboCasa365 atomic-seen18tasks；8safety families归scene/object/robot三group。

- 题数 / 数据：LIBERO每model-suite200episodes (10×20) , RC每task50; 24distinct policies 、27policy-host entries不是27benchmarks 。
- 评估方式：native SR 、Safety 、Success-but-Unsafe 、Violation Severity Index; VSI是spec-normalized worst violation depth。; 有意义且signals可用才套STL, 额外diagnostics不影响Safety; 代理threshold不是物理安全认证。
- Split / 信息条件：固定seeds配对; RC policies有两个独立seed groups, 跨组unpaired; 不跨host直接排总榜。
- 来源关系：对既有LIBERO/RC trajectories加规则评分; 不是新生成58个目标任务。
- 可复用：本库规则扩充应借其适用性registry与success/safety分离, 而不是每task强乘所有评估方式。
- 待核 / 限制：缺人类近距离、实际spill/thermal等signals; composite全程排除某clause可能漏掉部分phase 。

P167 DexGarmentLab (2025)

原作: <https://arxiv.org/abs/2505.11032>

本次PDF: <https://arxiv.org/pdf/2505.11032v3>

PDF SHA256: 447ce546d76be47536883a64aac1e9fc7ea1f214433bc6915d9acce2eab57f65

阅读页: 1、2、4、5、6、7、8、9、10、18、20、32。15task场景、物理抓持修正、14实测task 、100demo/50episode 、real验证。

- 研究类型：布料 / 柔性物操作; 柔性物操作benchmark
- 领域：衣物与洗护、个人照护
- 用途归纳：依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境：双UR10e+ShadowHand, 15task scene设置; >2500garments/8类不是2500不同task 。
- 任务：15定义含fling/fold/hang/wear/store; 主simulation实验14task (wear glove未在主表), 不能报全15同程度测完。
- 题数 / 数据：每实测task100generated demonstrations; 每task50episodes与3seeds; real4task各3garments×5初态=15trials 。
- 评估方式：task-specific成功与mean/std; demo生成成功率和policy成功率分开。; 以friction/adhesion取代GarmentLab attach blocks, 两者同名折衣控制难度并不相同。
- Split / 信息条件：garment形状/初态/位置变化; 文中2%test training data是模型脱机切分, 不等于50episode物理eval 。
- 来源关系：ClothesNet与UniGarmentManip/GarmentLab相关资产和方法; 更改抓持物理具实质差异。
- 可复用：灵巧双手与穿衣 / 收纳广度的重要来源; 应追实际物理规则差异。
- 待核 / 限制：各task成功predicate与garment ID split仍需完整config清单, 不能只以模型shape库算coverage 。

P168 HRIBench (perception, 2025) (2025)

原作: <https://arxiv.org/abs/2506.20566>

本次PDF: <https://arxiv.org/pdf/2506.20566v1>

PDF SHA256: 7148bb0244bccd22b8b8050d609fa6304f05059d5224f76470c5b87616428af7

阅读页: 1、2、3、4、5。5domain来源、1000VQA、非语言线索、自录/复用与accuracy-latency表。

- 研究类型：理解、推理与规划; 人体与交互感知评测
- 领域：社交与沟通、协助、交接与陪伴

- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：Kuri/Quori自录非语言交互+既有公开数据；5domains是能力群，非5物理环境。
- 任务：nonverbal、verbal intent、human-robot-object relation、social navigation、person identification五种。
- 题数 / 数据：每domain200VQA，总1000；overall accuracy/latency排除person identification，因此总体比较用其余800题范围。
- 评估方式：逐题accuracy与latency秒；unsupported/refused identity标N/A，不能填0后和其他模型无条件平均。
- Split / 信息条件：主为VLM zero-shot评测；各domain人类baseline由不同expert完成。
- 来源关系：HandMeThat加视觉、CoMaD、MuSoHu、YouTube视频与自录gestures；不是2026interaction-centric HRI Bench。
- 可复用：提供HRI感知与实时性题型；选合宜导航路径的VQA不等于实体导航运行。
- 待核 / 限制：不同question形式random accuracy不同，不能全统一25%random；上游素材和case IDs未导入。

P169 X2Real (2026)

原作：<https://arxiv.org/abs/2609.27449>

本次PDF：<https://arxiv.org/pdf/2609.27449v1>

PDF SHA256：5cff92f0d0a008824b9299b9e8f9259404e6177fd54a55c4d4eede0aff18f521

阅读页：1、3、4、5、6、13、14、23、24、27、28、29。44task架构、training/eval分离、资产/DSL、DAG metrics、desktop/mobile与sim-real验证。

- 研究类型：一般操作 benchmark；模拟操作benchmark
- 领域：居家整理与清洁、通用对象与机动作业
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：Mana/IsaacLab场景；多embodiments与green-booth训练配置，appearance/task/embodiment分别扰动。
- 任务：44simulation tasks / 10能力维度；含3mobile tasks与3challenge tasks，能力数不是生活domain数。
- 题数 / 数据：近300小时训练轨迹；desktop各300demo、mobile各1,000、3challenging总>20K trajectories；mobile eval每task每ID/OOD40episodes。
- 评估方式：DAG依赖达成、无failure且sink nodes完成才success；latched node进度加权10分；层级macro平均避免大类垄断。；sim-real本文overall r for success 0.74/progress 0.84，精密task更弱，不用一般task子集高r外推全部。
- Split / 信息条件：green-booth demonstrations与OOD背景/task/robot配置分离；模型不取得frame-level subtask标签。
- 来源关系：Mana基于IsaacLab/Arena，资产来自多3D库与AIG3D；不等同创建完整新生活任务ontology。
- 可复用：统一runtime、DAG过程与收集/评测分离可借；主张泛化应按能力与实测subset支持。
- 待核 / 限制：desktop完整eval case IDs与3challenge是否纳同一overall分母需release设置核。

P170 MotionForge (2026)

原作：<https://arxiv.org/abs/2609.25689>

本次PDF：<https://arxiv.org/pdf/2609.25689v1>

PDF SHA256：26bf90c839b269529d60ec9d7b97df9c98670c0297089faf96f14d7e2bfc8c1a

阅读页：1、2、3、4、5、6、7。40semantic families、motion taxonomy、实时协定、生成validation及ID/OOD50seeds。

- 研究类型：一般操作 benchmark；动态操作benchmark
- 领域：装配与生产作业、包装、仓储与物流
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：4scene families：Factory Conveyor、Circular Motion、Home Tabletop、Embodied Interaction；5K背景variation非5Klayouts。
- 任务：40semantic tasks、11motion patterns；17long/23short，仅改速度的variants合并为同family。
- 题数 / 数据：约20K产生demo中选每task50=2Ktrain；每task每ID/OOD condition50固定seeds，7policies另算rollouts。
- 评估方式：macro task success；policy推论时环境仍以120Hz进行，latency对成功有实际影响。；LH依8秒+2skills或20秒门槛定义，作者明示长不一定更难。
- Split / 信息条件：object/background/light/speed单factor与joint OOD；保留不支持最高speed的task例外。
- 来源关系：generated scenes + 共用oracle skills；task质检要求oracle>50%为生成合格条件，不是learning-policy成绩。
- 可复用：补发送带、抛接与动态速度规则；可区分场景生成量与语义task量。
- 待核 / 限制：不同硬件的native inference latency不可无条件比较，需固定evaluation hardware/runtime。

P171 Bench2Dex (2026)

原作：<https://arxiv.org/abs/2609.15726>

本次PDF：<https://arxiv.org/pdf/2609.15726v1>

PDF SHA256：f70ca3ecb4dd8fc9a1acc6410a0bd4e370203ca65331b3fcc76209996fb8ed03

阅读页：1、2、3、4、5、6、7、8、10。12hands、26task-embodiment settings、tactile界面、stable success及4channel协定。

- 研究类型：一般操作 benchmark；灵巧手操作benchmark
- 领域：装配与生产作业、通用对象与机动作业
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：IsaacLab bimanual配置；12hand morphologies、6views，无独立房屋总数。
- 任务：26task-embodiment settings，不能先乘12手型为312已完成tasks。
- 题数 / 数据：约1.3Kteleop demonstrations；4policy×26settings×4channels×50rollouts=20,800evaluation executions。每policy每channel1,300。
- 评估方式：terminal predicate需稳持预设0.5s；LSCR记录依赖合法的阶段；success time只在成功episode量。；baseline只用RGB/关节，触觉数据支持不等于已证实tactile policy收益；触觉为几何depth proxy。
- Split / 信息条件：None/Equi/Inv对齐anchor，Full独立抽样，不假定逐case困难单调。
- 来源关系：已有hand meshes + 统一tactile registry；未对齐真实触觉hardware。
- 可复用：可借跨手型 / 触觉信号规格与稳定判分；不要把支持的传感轴当实评完成量。
- 待核 / 限制：26设置的unique semantic task去重与tactile-conditioned baseline尚不等同完成。

P172 LabUtopia (2025)

原作: <https://arxiv.org/abs/2505.22634>

本次PDF: <https://arxiv.org/pdf/2505.22634v2>

PDF SHA256: b0b27a506f9ec028871b09e93a5a3aead74e382739b65fa5092af90ab062e862

阅读页: 1、3、4、5、6、7、8、9、10。LabSim/LabScene、scene与仪器来源、5levels、success协定及实验范围。

- 研究类型: 一般操作 benchmark; 专业场域操作benchmark
- 领域: 实验室操作
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 约100expert-reviewed lab scene assets, 另程序填入仪器; 对象类别/scene数不得相加。
- 任务: 摘要30distinct tasks、结论>30, §4另称>50; 5levels从atomic到mobile, 但level3主要是generalization条件, 并非全是新语义task。
- 题数 / 数据: 各level有demo/rollout实验, 本文已读段未报统一case总量; 表2列10atomic及6短流程, long流程另3例。
- 评估方式: task完成后goal tolerance需维持2秒; success rate与long流程stage分开。; chemical engine由知识库+LLM推state变化, 不等同第一原理化学物理。
- Split / 信息条件: novel shape/material/layout设置; 全在simulation, real transfer留未来。
- 来源关系: designer scene assets、PubChem数据与IsaacSim; procedure模板需逐task核, 不从约100场景×50tasks直接乘题量。
- 可复用: 补实验室用途与流程; 其阶层是设计/泛化混合, 需用共同task粒度对齐。
- 待核 / 限制: 最终task registry究竟30或>50, 以及scene/instrument各精确IDs, 需code版本确认。

P173 LabDex (2026)

原作: <https://arxiv.org/abs/2608.18618>

本次PDF: <https://arxiv.org/pdf/2608.18618v1>

PDF SHA256: 0d4be91ff766826af94f01245c225e27a15cfb88fae60183c9393f1af17ee41c

阅读页: 1、3、4、5、6、7、11、12、13。层级数据、real/sim平台、atomic/composite/workflow完整表及success。

- 研究类型: 一般操作 benchmark; 专业场域操作benchmark
- 领域: 实验室操作
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: FR3/XHand实际工作站与配对simulation; 3camera views非3场景。
- 任务: 概述7atomic categories、30+atomic、10+composite、1workflow; 实验明列26atomic、表3九composite、1七步workflow。附录定义composite10项。
- 题数 / 数据: 概述8K+demo/1M+steps; real预设每task200train、sim50; 每task每model50eval trials。
- 评估方式: goal稳定2秒; atomic SR, composite/workflow全成功、各atomic成功与平均已完成步数。
- Split / 信息条件: 初态在训练范围内随机; novel objects/distractors另实验, 非主eval全部OOD。
- 来源关系: real teleop关键姿态映射sim, 长流程可切atomic; 不能把完整轨迹与各段全部当独立新样本。

- 可复用：是同SOP分不同粒度与运行平台的例子；原子step、composite、workflow必须保留父子关系。
- 待核 / 限制：30+/10+概要与26/10完整清单之差异需最终manifest确认；real/sim数据量需分开。

P174 Labimus (2026)

原作：<https://arxiv.org/abs/2606.31037>

本次PDF：<https://arxiv.org/pdf/2606.31037v2>

PDF SHA256：103d1eb5ee800d0306734bab26f9242f067cff584fb84c9929cd3ea3869e7e3a

阅读页：1、2、5、6、9、10、11、12、14。SOP→DSL、6atomic/7步流程、3评分tier、4conditions与v0验证边界。

- 研究类型：一般操作 benchmark；专业场域操作benchmark
- 领域：实验室操作
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：Tianyi humanoid于fume-hood工作站；digital twin与procedural layouts，>30functional assets。
- 任务：6atomic operations + 1个7step solid-weighing workflow；Tier2重评原task精度，不能算两个新操作。
- 题数 / 数据：v0只实测4atomic + 1precision条件；每task-condition50episodes×3seeds = 150trials；其余与整个Tier3仍未实验。
- 评估方式：success、precision pass、conditional precision among successes、weighted step progress；S-P量成功与精度差距。；SOP的mass/position门槛是这个模拟规格，不代表已完成真实实验室有效性验证。
- Split / 信息条件：100teleop demos/task，标准test布局已有分布移动，另light/texture/combined；3×4是设计矩阵，不是v0全部实测。
- 来源关系：ArtVIP资产 + IsaacSim；SOP解析会排除无physical effect的纯观察/记录步，故完整科学程序仍有缺口。
- 可复用：可借SOP权重、数量精度及conditional metric；要如实标示设计完整度与实验完成度。
- 待核 / 限制：未完成tool pickup/scoop-weigh/Tier3验证；real-world validation明列未来。

P175 Pipette (2026)

原作：<https://arxiv.org/abs/2606.12936>

本次PDF：<https://arxiv.org/pdf/2606.12936v3>

PDF SHA256：72ad55814d9958242cd534f45f540f9bcd86bcd2bfbf21beaa2278e6c2bb93a3

阅读页：1、2、3、4、5、6、7、11、12、17。12tasks全表、资产库、structured task注册、augmentation验证与100episode协定。

- 研究类型：一般操作 benchmark；专业场域操作benchmark
- 领域：实验室操作
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：IsaacSim/IsaacLab场景；3robots、12tools、26equipment、55consumables、9instruments为资产分量。
- 任务：12wet-lab tasks = 4sample/culture、4lid/hatch、4placement；pipette-to-petri positioning不等同已量测真正移液量。
- 题数 / 数据：每task30human train demos + 成功筛选augmented；每model每task100eval episodes，即单数据设置1,200。

- 评估方式：依task pose/joint/geometric thresholds及持续时间判success；macro task SR。；语言parser只草拟配置，prim/threshold/evaluator仍需人验证；success-verified augmentation不是新task。
- Split / 信息条件：3models×raw/augmented条件，Panda为主但flask-shaker用AgileX；同task内固定机体比较。
- 来源关系：existing/generated USD assets、Hunyuan；replay重新渲染并同步state/action，不只是改像素。
- 可复用：可补biomedical wet-lab器材用途与scene/task登记；须区分设备操作与完成真正生物实验。
- 待核 / 限制：all-asset唯一ID与各task primitives的实际精度需原生配置；某lid为virtual button触发，不能当直接灵巧开盖。

P176 AutoBio (2025)

原作：<https://arxiv.org/abs/2505.14030>

本次PDF：<https://arxiv.org/pdf/2505.14030v3>

PDF SHA256：987d557fe26642e96a1d4c9b3021c3d373717d4a5bc3f9eae48b5bc9de84df91

阅读页：1、4、5、6、7、8。特殊仪器physics/render、16task与9实测subset、100episode与mixed metric。

- 研究类型：一般操作 benchmark；专业场域操作benchmark
- 领域：实验室操作
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：MuJoCo/Blender，single/dual-arm工作站；Aloha及UR5e不同end-effectors。
- 任务：16定义分3difficulty levels；实验每level3项，共9tasks，非全部16。
- 题数 / 数据：9tasks各100demo=900train、792K+frames；每task100eval episodes、3runs。
- 评估方式：大多binary success；thermal mixer panel用relative progress，平均表不全是success percentage。
- Split / 信息条件：20/100demo数据规模比较；held-out初态参数泛化；render两版本共享轨迹。
- 来源关系：实验室asset digitization；quasi-static liquid不模拟波/倒水，DexHand主要只控制thumb作简化gripper。
- 可复用：补螺纹、旋钮、显示面板与精度规则；光学外观逼真不能替代完整材料动力学。
- 待核 / 限制：16task的全部IDs与模型可用support需最终code核；不要把9task成绩外推全16。

P177 H2RBench (human transfer) (2026)

原作：<https://arxiv.org/abs/2609.24778>

本次PDF：<https://arxiv.org/pdf/2609.24778v2>

PDF SHA256：dd841fb3a72307c335d2c7268ac813f8209a448dd2242d6e49db90da7a0169d1

阅读页：1、4、5、6、7、17。4task全表、fixed robot/human scaling、real-to-sim、90rollout及transfer metrics。

- 研究类型：人类观测到机器人转移；人类示范与技能转移
- 领域：装配与生产作业、通用对象与机动作业
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：4个real-to-sim task环境，PolaRiS/Marble/IsaacLab，real human由第三人称multi-view录制。

- 任务：4families：mug-to-plate、bowl stacking、donut insertion、sequential blocks-to-box。
- 题数 / 数据：robot demo budgets 40/100/100/100；human 上限 100/300/300/300；每method/task 90 randomized rollouts across 3 seeds。
- 评估方式：final/mean-stage SR；human 增益用 Δlogit ；sim/real 分别训练 policy，再以 $r/p/\text{MMRV}$ 比排名。
- Split / 信息条件：fixed robot data、只增加 human demos；sim 与 real 是不同 pipeline 验证，不是同一 policy 直接 sim $\rightarrow$ real。
- 来源关系：Polaris、TRELLIS、GELLO、四种既有 H2R 方法；与 human-only 预训练数据库不同。
- 可复用：提供人类数据规模增益的受控比较，无需靠多拿 robot data 制造规模优势。
- 待核 / 限制：各 human/robot pair 是否一对一不应由 demo 预算推定；完整 IDs 需原生 release。

P178 RoboRecover (2026)

原作：<https://arxiv.org/abs/2609.28952>

本次 PDF：<https://arxiv.org/pdf/2609.28952v1>

PDF SHA256：63986a4660ca344bb479e10ce0aa378f0c5b8a2ce86623d7725c5474f9a51faf

阅读页：1、3、4、5、6、13。scenario 构造、replay 验证、filter、train/test 及 RSR；未逐行重现程序。

- 研究类型：稳健性、失败与评测品质；失败与恢复 benchmark
- 领域：居家整理与清洁
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：RoboTwin 和 LIBERO 两个既有模拟后端，透过 action prefix 重播取得失败状态。
- 任务：原任务上的恢复情境；4 阶段 $\times$ 4 偏差类型只有 9 个有数据的测试组，不能算 16 个完整任务家族。
- 题数 / 数据：2,000 recovery scenarios；两个后端各 800 train/200 test，合计 1,600/400。训练与测试 task names 有重叠。
- 评估方式：Overall RSR 以 scenario 平均；9 组 macro 另报。reference policies $\times$ 5 回合形成 20 次筛选，只留 10–90% 可恢复率，难度依筛选模型而定。；重播验证位置差 $< 2\text{mm}$ 、末 5 帧 SSIM > 0.99 ；策略从恢复点初始化，不能读取前缀历史。
- Split / 信息条件：每后端 800/200；同 task 不同 scenario 可跨 split，不宣称语义 task 完全未见。
- 来源关系：RoboTwin 与 LIBERO 原任务；natural、action-perturbed 与 human-constructed 三种失败构造。
- 可复用：可扩充既有 task 的恢复规则，但增加的是恢复 cases；不自动增加生活 domain 或原始目标数。
- 待核 / 限制：每个被测 policy 对每 scenario 的重复次数需核最终运行 manifest；筛选成功率不可当新 policy 成绩。

P179 REBOOT (2026)

原作：<https://arxiv.org/abs/2609.22591>

本次 PDF：<https://arxiv.org/pdf/2609.22591v1>

PDF SHA256：1f5401dfe2a8209a83cb96780a43fbfa0938f8a743eb8285be793fbdd60cf6f5

阅读页：1、3、4、5、6、7、8。assembly 清单、精度层级、expert/recovery 数据、初态与实验协定。

- 研究类型：稳健性、失败与评测品质；精密组装与恢复 benchmark
- 领域：装配与生产作业

- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：真实双臂WidowX/Trossen工作站；NIST Assembly Task Board #1。
- 任务：表2为9对象×安装/移除=18tasks；精度、对称性及5操作phase是task属性。
- 题数 / 数据：18×(60 expert+60 recovery)=2,160 demonstrations。§protocol写每task/policy20rollouts，主分析却用15×18×3=810，保留差异。
- 评估方式：逐task物理完成率，另按clearance、symmetry、phase及failure分析；初始对象3–6cm范围变化，goal board固定。
- Split / 信息条件：expert/recovery及模型设置受控比较；recovery demonstrations刻意重现先前观察到的policy失败。
- 来源关系：沿用标准assembly board；9对象不是9独立工作环境。
- 可复用：补精密插接、对称性与failure phase；组装和拆解可保留相反目标关系。
- 待核 / 限制：p7的10 connector types与表2的9对象、20与15rollouts需要release核对；failure清单是否含slip也有版本差异。

P180 SafeManip (2026)

原作：<https://arxiv.org/abs/2605.12386>

本次PDF：<https://arxiv.org/pdf/2605.12386v3>

PDF SHA256：561f1135594da0aca29135e76d5abec42f8cac6a946d0f92c6380b1c213488fc

阅读页：1、4、5、6、14、15。8类/10模板、ManipVerse、事件监测、90host tasks及各policy协定。

- 研究类型：稳健性、失败与评测品质；安全与过程规则benchmark
- 领域：居家整理与清洁
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：RoboCasa365及LIBERO；主RoboCasa多task实验在pretraining scenes，target-scene实验另列。
- 任务：50 RoboCasa+40 LIBERO=90 host task entries；8 safety categories、10 LTLf templates，只绑定适用task。
- 题数 / 数据：每policy/task50episodes，RoboCasa单设置2,500、LIBERO单设置2,000；不同训练variant不是新题。
- 评估方式：native SR；每trigger violation V/N与unsafe exposure U/N，分母是触发事件，非episode数。恢复后monitor可重新启动。；LIBERO只有部分规则适用；支持10模板不代表每task实测10种违规。
- Split / 信息条件：不同host/checkpoint/target设置分开，不能把pretrain-scene与target-scene结果直接比。
- 来源关系：重用RoboCasa365/LIBERO并增加ManipVerse predicate与DFA监测；和SafeVLA是不同评测规则。
- 可复用：任务联集之外，另存task可适用的规则；安全规则数和语义task数各有自己的分母。
- 待核 / 限制：数据hours与原RoboCasa365文章版本有差异；需固定release，不能反改原作数值。

P182 SoftVTBench (2026)

原作：<https://arxiv.org/abs/2608.18701>

本次PDF：<https://arxiv.org/pdf/2608.18701v1>

PDF SHA256：1f353c40268ba3a98d5a2f51892e92c042f89ea87c7ccbe49c10c3ce956fe827

阅读页：1、3、5、6、7、8、9、13。40setting、rigid twins、ID/OOD抽样、FEM evaluator与DSR。

- 研究类型：布料 / 柔性物操作；柔性物与触觉操作benchmark
- 领域：餐饮与烹饪、通用对象与机动作业
- 用途归纳：归纳为易损物取放的通用作业；烘焙品形状对象的放置情境另标餐饮处理方向。
- 环境：IsaacSim/IsaacLab/TacEx；10软对象 + 10对应rigid twins，>50props是assets。
- 任务：4suites各10task settings = 40；主要skill固定pick-and-place，对象/位置变化不等于40个独立动作家族。
- 题数 / 数据：4,000 expert demonstrations；ID每suite500 = 2,000episodes。OOD每soft suite/config900，两suite共1,800；9个单factor条件不是完整交叉乘积。
- 评估方式：Task SR另报；DSR要求完成task且全程peak deformation $\leq \tau$ ， τ 由稳定抓持90th percentile预先校准。FEM states仅给evaluator。
- Split / 信息条件：held-out初态；OOD light/mass/Young modulus各3级、单factor控制。以同seed/初态作对照。
- 来源关系：LIBERO风格spatial layouts与matchedrigid assets；touch rendering是模拟信号。
- 可复用：同task加入材料保护规则的清楚范例；不能用不动来获取低形变高分。
- 待核 / 限制： τ 是benchmark容忍度而非材料真实损坏点；continuous/binary gripper设置要控制。

P183 WireCraft (2026)

原作：<https://arxiv.org/abs/2606.18097>

本次PDF：<https://arxiv.org/pdf/2606.18097v1>

PDF SHA256：7f2bbb231c2ff416c001d7c06e6efc0d68691404f48ed4e22afde76e1ff48e9a

阅读页：1、2、3、4、5、6、7、23、25。三类DLO tasks、两种physics、robot/data流程、success与real对照。

- 研究类型：布料 / 柔性物操作；线材操作benchmark
- 领域：装配与生产作业
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：IsaacLab/IsaacSim；chain或FEM wire、UR5/Franka/Trossen三robot；可生成配置，无固定环境总数。
- 任务：3families：connector insertion、clip routing、channel seating；insertion选4connector shapes，其他代表场景仍有限。
- 题数 / 数据：script、RL、sim teleop、real数据；已读协定未报全库固定cases。real Ethernet每metric/setting10rollouts。
- 评估方式：reach为held plug距socket $\leq 2\text{cm}$ ，insert另要求真正插入；channel>80%wire length入槽。；最佳checkpoint依eval reach挑选，属best-observed成绩；不可假称独立validation selection。
- Split / 信息条件：7种real/sim数据mixtures以同40K checkpoint比较；额外65K结果不纳主公平比较。
- 来源关系：同一3family经不同physics/embodiment重现；不可把backend数相乘当新语义task。
- 可复用：补线材穿引、插接与保持槽内的几何判分，标示物理近似与场景覆盖边界。
- 待核 / 限制：文章写接受后release，未据此宣称目前资产已取得；全库demo/case manifest待查。

P184 DLO-Lab (2026)

原作：<https://arxiv.org/abs/2606.04206>

本次PDF：<https://arxiv.org/pdf/2606.04206v1>

PDF SHA256: 91128b16d310632077dd23caa908483ba75b8851a77808b98368fbce1dcea0b0

阅读页: 1、2、3、4、5、6、7、18、19。10tasks、differentiable physics、算法信息条件、success appendix。

- 研究类型: 布料 / 柔性物操作; 线材操作与物理benchmark
- 领域: 装配与生产作业
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: Taichi/Genesis的rod与rigid/MPM coupling; 近点kinematic抓持简化, 不是完整摩擦抓持。
- 任务: 10tasks: 8固定horizon与2长流程Letter Art/Wiring Ring; 主要实验state-based, 不全是视觉策略。
- 题数 / 数据: main optimization/RL比较3seeds、预算内最高return。附录RL每task15trajectories, GD单一optimized, CMA-ES选best checkpoint的top15。
- 评估方式: return与goal success; RL/GD/CMA-ES的信息、样本挑选与动力学梯度访问不同, 不能视为统一closed-loop protocol。
- Split / 信息条件: 主比较没有一套统一held-out visual split; VLM长流程与SmolVLA4task子集另列。
- 来源关系: 物理模块及task设计; letter/rope shapes是几何目标, 非完整日常领域。
- 可复用: 可借线材task定义, 但做all-in-one比较需要先统一观测、重置、预算与selection。
- 待核 / 限制: 需release IDs才能创建所有randomized cases; 不同algorithm native evaluation不可直接相加。

P185 RGBench (2025)

原作: <https://arxiv.org/abs/2511.06434>

本次PDF: <https://arxiv.org/pdf/2511.06434v2>

PDF SHA256: abc60e4860b3f9e166eeb0391fbf21186ec162cf7ffa413ed321ba8851b61970

阅读页: 1、2、3、4、5、6、13、15。garment来源、三primitive、real/sim pair、distance及performance benchmarking。

- 研究类型: 布料 / 柔性物操作; 柔性物模拟器评测
- 领域: 衣物与洗护
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 配对真实dual-Piper/Jaka工作站与garment simulation; direct-vertex与robot-URDF modes分开。
- 任务: 3manipulation primitives: Grasp/Fling/Fold; 9garment types的real GT比较, 主表是其中子集。
- 题数 / 数据: 6,000+garment assets = 4,000+industry + 2,000+ClothesNet; 非6,000eval tasks。已读段落未报全部paired trajectory数。
- 评估方式: 真实/模拟点云的Chamfer与Hausdorff L1, r2s/s2r分开; runtime/memory/mesh vertices另测simulation engine。
- Split / 信息条件: 人工配对动作及材料/形状参数; 主要评测simulation fidelity, 不是policy完成率。
- 来源关系: ClothesNet重用; BCM外部验证不是新独立数据源。
- 可复用: 补benchmark的模拟有效性检验; 这个评分层与policy task success有不同目的。
- 待核 / 限制: 全部paired trajectory IDs及industry assets再分发范围需release核; 不要用mesh数充题数。

P186 BiFold (2025)

原作: <https://arxiv.org/abs/2501.16458>

本次PDF: <https://arxiv.org/pdf/2501.16458v2>

PDF SHA256: f80ff8748e8d36c77c1f3decdfdf8b86e43da9909071a194e963c876c3ce56f3

阅读页: 1、3、4。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 布料 / 柔性物操作; 柔性物操作benchmark
- 领域: 衣物与洗护
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: VR-Folding/CLOTH3D重渲染, SoftGym; 真实RGB-D衣物观测。
- 任务: language-guided single/bimanual folding; 新方向/位置规则与instructionparaphrase分开。
- 题数 / 数据: 近4KVRdemos分成约7Kactions、>1Kunique prompts; 90/10sample split。
- 评估方式: singlearm以meanvertexerror<0.0125m判success; bimanual另用image metrics, 不预设相同判分。
- Split / 信息条件: 先flattenedcloth; H=3history支持指令歧义, 未证明所有sample分割已按parenttrajectory群聚。
- 来源关系: VR-Folding既有demos+ CLOTH3Dtextures、添加语言与actionparsing; 不是全部新physical demonstrations。
- 可复用: 补指定折法、手别与历史依赖; 语言改写不自动算新task。
- 待核 / 限制: 部分只有真实图像推action展示, 完整realautonomous成绩分母需原始实验核。

P188 DRAPER (2024)

原作: <https://arxiv.org/abs/2409.15159>

本次PDF: <https://arxiv.org/pdf/2409.15159v2>

PDF SHA256: 82f9a63cec8b5a6595ee60eff3f5f7d00bfb25d91cfd2fbe557897633d230632

阅读页: 1、4、5、6。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 布料 / 柔性物操作; 柔性物操作benchmark
- 领域: 衣物与洗护
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: RealAdapt Towels改SoftGym grasp近似; Franka与UR3e对照, camera/gripper差异显式处理。
- 任务: flattening及3种foldpatterns: allcornersinward、corners-edgeinward、diagonal-cross。
- 题数 / 数据: flatteningtrain2Ktrajectories, foldtrain1K; UR3eablation每setting10trials。
- 评估方式: realflattening NC>95%且20steps内; simulation>99%/30steps; fold用IoU/proxy并承认自遮挡限制。
- Split / 信息条件: materials/size/camera/platform泛化; 各policy保持相近trainingbudget, 非直接沿用原bestscore。
- 来源关系: 既有四controller在共同deploymentframework; RealAdapt是grasping/physics规则衍生环境。
- 可复用: 这类工作正是all-in-one需借鉴的共同运行/判分控制, 而非只搬tasknames。
- 待核 / 限制: real与sim门槛不同不能混算同一SR; 多层抓取和tweezerhardware要入taskinterface。

P191 ClothesNet (2023)

原作: <https://arxiv.org/abs/2308.09987>

本次PDF: <https://arxiv.org/pdf/2308.09987v1>

PDF SHA256: bdbcb57f9e8831c335e596f96e984f928bbd504a8bdd7e0be8ec0bcb191f02c9

阅读页: 1、2、4、6、7、8。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 布料 / 柔性物操作; 柔性物数据与感知评测
- 领域: 衣物与洗护
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 约4,400garment meshes/11categories; ClothesNetM3,051可用subset, mesh不是环境。
- 任务: 分类、boundarysegmentation、keypoints三感知端点; simfold直接控制vertices, dressing/hanging多为可支持用途。
- 题数 / 数据: 3Dclassification1,984train/496testmeshes; 2D2,455meshes渲染9,820images再80/20。
- 评估方式: classificationaccuracy、segmentationmIoU、keypoint品质; simfoldnegativevertexdistance, 非完整robotgraspcontrol。
- Split / 信息条件: 2D按images切80/20, 未在已读段保证same-mesh views不跨split; 3D子集量和3051全集不同。
- 来源关系: CGTrader等mesh整理, 后被RGBench/GarmentLab等重用。
- 可复用: 补garment资产/语义标签, 清楚区分perceptionvalidation与可交互环境。
- 待核 / 限制: 资产种类不等于全部运行任务已验证; 不能把4400meshes称4400robotcases。

P192 Phys-Liquid (2025)

原作: <https://arxiv.org/abs/2511.11077>

本次PDF: <https://arxiv.org/pdf/2511.11077v1>

PDF SHA256: 827b09bcc3b8968cc32b21f332b5b31286c3784578fc04a00435cb0dd6b6700b

阅读页: 1、2、3、4、5、6、11。渲染组成、100sequences、90/10切分、reconstruction与real验证。

- 研究类型: 布料 / 柔性物操作; 液体感知benchmark
- 领域: 实验室操作
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: Blender/Mantaflow的5lab scenes、20containers、8lights、5colors、6orthographic views。
- 任务: 单/多视角液体形状与体积重建, 未直接评robot pouring控制。
- 题数 / 数据: 100simulation sequences×81timesteps=8,100液体meshes; 97,200images含RGB和mask两种, 不能全叫独立RGB题。90/10sequence split。
- 评估方式: 2D IoU、3D CD/Volume IoU/F-score、dimension RMSE、scale MAPE; 部分baseline只比50张random test images。
- Split / 信息条件: 以整条temporal sequence切90/10, 避免相邻frames跨split; real 10containers验证不等于10固定interaction tasks。
- 来源关系: simulation-generated感知数据; 不同视角与mask共享同一物理状态。
- 可复用: 可作液体观测模块与量测参考; 仍需另建可运行倒液任务及物理终态判分。
- 待核 / 限制: p4文字Three scenes与Lab1–Lab5冲突, 以Table1和数据组成5为据; 完整real case IDs未报。

P193 GRIP (2025)

原作: <https://arxiv.org/abs/2503.05020>

本次PDF: <https://arxiv.org/pdf/2503.05020v2>

PDF SHA256: 04cf205cc12587bbc6680049d1eaa00b17736f5efde4581b6e2043a79bd684a5

阅读页: 1、3、4、5、6。原作数据构成、任务定义与实验协定相关段落; 阅读范围限所列PDF页, 非全文逐字或程序重现。

- 研究类型: 布料 / 柔性物操作; 柔性物与抓取benchmark
- 领域: 通用对象与机动作业
- 用途归纳: 产生稳定抓握并预测对象受力, 归入通用抓取与易损物处理作业。
- 环境: IPC平行physics; UMIsoftgripper/LEAHand; 800singleobjects, 800bimanual含400重用, union1200。
- 任务: grasp synthesis/validation与stressprediction; single/bimanual不同graspconditions。
- 题数 / 数据: 100,000grasp poses (概要); stresssubset8bowls+8mugs, 每类6train/2test; 非100K不同tasks。
- 评估方式: sixdirectiongravity稳定抓持、penetration/absolutecontactdistance、stressrelativeMAE/KL; simulationfidelityrealcheck只4objects。
- Split / 信息条件: DexGraspNet/PartNetassets重用; stress按object切, graspwholepool分割另需release核。
- 来源关系: 固定对象union和多gripper/material/randomizedpose; 全量对象与real2sim4个子集分开。
- 可复用: 可补接触稳定性与材料保护规则; candidatepose生成和有效评测case分开。
- 待核 / 限制: 50N停止closure和gravity0.1秒/方向是本protocol, 不能当通用安全标准。

P196 Deform360 (2026)

原作: <https://arxiv.org/abs/2607.05390>

本次PDF: <https://arxiv.org/pdf/2607.05390v1>

PDF SHA256: 3f23966cb31f3614a8b27aba9ae558ef4684e812dd86ef6cd072d1788c6faf95

阅读页: 1、4、5、6、8、9、10、11、12、13、27。198objects、capture/重建、1980episodes、多层generalization及2D/3D metrics。

- 研究类型: 布料 / 柔性物操作; 柔性物数据与世界模型benchmark
- 领域: 衣物与洗护
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 一套41camera环绕capture rig; 41视角不是41环境。人类持UMI tactile grippers操作。
- 任务: 3D重建/重模拟、future prediction、episode及object generalization; 198objects不是198语义task。
- 题数 / 数据: 198对象=28线材+98片材+72体积柔性物; 每对象5single+5bimanual, 共1,980episodes。清理后74,850videos、23.3M多视角frames。
- 评估方式: 3D Chamfer/track MSE; 2D PSNR/SSIM/LPIPS; 接触accuracy/F1使用36个同步过滤视角。
- Split / 信息条件: 分episode内future frames、同对象未见episodes、未见objects三种; 不同方法适用不同设置, 不能共用一个排行分母。

- 来源关系：3DGS + tracking + normal-pressure tactile重建；收集刻意避免slip，未提供完整shear/slip涵盖。
- 可复用：补材料与动力学覆盖，亦示范为何要将episode、view视频、frame和hours各自计数。
- 待核 / 限制：各generalization split的精确train/test ID数需release protocol；未宣称所有198对象已完成real-robot closed-loop task验证。

P197 EgoSim / MultiEgoView (2025)

原作：<https://arxiv.org/abs/2502.18373>

本次PDF：<https://arxiv.org/pdf/2502.18373v1>

PDF SHA256：db15f931833027b80e416c0bdb47bd3c7695ef3cce6733988110484295f4f7d2

阅读页：1、2、5、6、7。数据构成、四场景、body-camera位置、35活动、切分与body pose metrics。

- 研究类型：人类视频与动作数据；身体摄影机数据与感知benchmark
- 领域：穿戴交互与动作界面
- 用途归纳：身体摄影机用来恢复用户动作及支持交互输入，归入穿戴交互与动作界面。
- 环境：24locations分布于4virtual scenes；real数据在其中一个扫描courtyard收集。6个body cameras是视角。
- 任务：主要实验为全身3D pose estimation；real演出35种BABEL活动，非35robot运行目标。
- 题数 / 数据：synthetic 119.4行为hours/77.4M六视角images；real约5h、13participants。5秒segments数未报。
- 评估方式：global/PA MPJPE、translation/rotation/joint-angle error、jerk。
- Split / 信息条件：synthetic依BABEL60/20/20；real random80/20与cross-participant10/3另列。
- 来源关系：AMASS/BABEL/BEDLAM motion/labels/assets；同一motion多bodyviews与多场景重渲染，非独立动作数据。
- 可复用：支持头、腰、手腕、膝摄影机的感知来源；加入视角泛化，不能当物理task completion。
- 待核 / 限制：精确train/test片段IDs、重渲染motion去重需manifest；动作辨识/定位虽可支持，主实验未全评。

P198 TACO (2024)

原作：<https://arxiv.org/abs/2401.08399>

本次PDF：<https://arxiv.org/pdf/2401.08399v2>

PDF SHA256：2cd9fef96e133851d367c485aad1578b4979baef4d9b57037a1a246476735efd

阅读页：1、2、3、4、5、6、7、8。capture/annotation、131triplets、数据与generalization splits、三benchmark与metrics。

- 研究类型：人类视频与动作数据；双手工具交互理解与预测benchmark
- 领域：居家整理与清洁、餐饮与烹饪、穿戴交互与动作界面
- 用途归纳：用原作工具—动作—对象组合归纳：倒液与搅拌属餐饮，清洁器具属居家，手物动作建模亦服务AR / VR界面。
- 环境：12third-person+1ego相机的capture工作站；作者明列缺乏scene diversity。
- 任务：3研究端点：compositional action recognition、motion forecasting、cooperative grasp synthesis；15actions、131tool-action-object triplets。

- 题数 / 数据：约2.5K motion sequences、5.2M多视角frames；196对象meshes/20categories/14participants。不是5.2M独立交互题。
- 评估方式：recognition Top1/5；forecast10frames→10frames的joint/translation/rotation error；grasp penetration/contact/collision/FID，非运行成功率。
- Split / 信息条件：train:S1:S2:S3:S4 = 4:1:1:1.5:2.5，分已见、geometry、interaction、compound；另60/40sequence的annotation验证不可混成主split。
- 来源关系：自己的multi-view capture；DexYCB交叉数据验证；marker removal使用inpainting。
- 可复用：把动作、对象组合和研究端点分层记录，支持工具交互的组合泛化设计。
- 待核 / 限制：完整各split精确sequence数需manifest；不含articulated objects，不能外推完整工具环境。

P200 SABER (2026)

原作：<https://arxiv.org/abs/2605.09613>

本次PDF：<https://arxiv.org/pdf/2605.09613v1>

PDF SHA256: e4556b7aadaed076ac2792ec2c15b91853acad3f5eac7403898badc1396e8f98

阅读页：1、2、3、5、6、9、10、11、12、13。零售数据三streams、native/retarget区别、训练mixtures、RoboBenchMart10tasks与100rollouts。

- 研究类型：人类视频与动作数据；零售示范数据与技能转移
- 领域：包装、仓储与物流、零售与购物
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：多真实超市的头戴/360°视频；camera capture无robot。精确店面数未报；下游是RoboBenchMart模拟。
- 任务：视频列12内核retail活动；下游10tasks = fridge2、board-to-board3、floor2、basket3，主要搬放与开关。
- 题数 / 数据：100+h视频导出44.8Ksupervision samples = 25Klatent+18.6Khand+1.2Kbody，streams共享capture。每task100eval rollouts。
- 评估方式：success同时要求joint velocity<0.2、target到位、未扰动非target；非fridge tasks另报0/1/2/3/4/5进度。
- Split / 信息条件：下游训练含2.5Ktask-aligned RoboBenchMart demos + 4.8Krobot anchor；不是human-only零样本转移。
- 来源关系：三stream由相同人类capture生成，RoboBenchMart为下游父benchmark；不要重新计一次新10task。
- 可复用：补商店补货/拿取/购物用途；可转移数据与可运行环境需要分别取得。
- 待核 / 限制：不同stream的episode交集及各超市scene IDs未报；checkpoint选择与held-out sampling需code核。

P201 EgoSAT (2026)

原作：<https://arxiv.org/abs/2606.24422>

本次PDF：<https://arxiv.org/pdf/2606.24422v1>

PDF SHA256: 3cdd4d6866e119e6133a58a10ad4eff1ec3dd77fc61f49704b61835d9c312199

阅读页：1、3、9、10、11、12、13、14、22、28。interaction curation、stream prefix、六题型、QA数及confidence/answerability分析。

- 研究类型：理解、推理与规划；串流理解与预测benchmark
- 领域：居家整理与清洁
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：Ego4D的56scenario labels；不是56有资产的机器人环境。
- 任务：present narration/state switch、short/multi-step anticipation、short/multi-step retrieval，共6题型。
- 题数 / 数据：1,997video sessions、约165h、约4,800QA；同一query的MC与open-ended版本不算独立证据。
- 评估方式：MCQ accuracy、interaction precision/recall、state switch两端都正确；confidence slope与predictable/unpredictable分组。
- Split / 信息条件：每query严格截到当下prefix；online cache方法与每题prefix重处理成本不同；SFT cross-scenario另比较。
- 来源关系：Ego4D原视频/interaction labels加新queries；不重新计成独立165h视频。
- 可复用：预测题需记可预测性与合法观测截止时间，不能让未来frame泄漏。
- 待核 / 限制：约4,800的精确query及SFT/evaluation split IDs待release核；future answer多解性不能当单纯模型错误。

P202 EgoMonth (2026)

原作：<https://arxiv.org/abs/2608.13113>

本次PDF：<https://arxiv.org/pdf/2608.13113v1>

PDF SHA256：6747ddc4c6f9303ea3e7ed2e427b1e8707235e60cd4cf05e45abfd4d13cdfc1

阅读页：1、4、5、6、7、19。收集/筛选、14题型全表、738clips/301h、人工QA、macro/micro与sampling。

- 研究类型：理解、推理与规划；长期记忆视频benchmark
- 领域：居家整理与清洁、餐饮与烹饪、办公与教育、零售与购物、交通移动与车辆维修、休闲与运动
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：20participants各20–120天生活纪录；室内外场景无可去重实体场所总数。
- 任务：14QA types、3认知层级；6activity用途类别。层级是作者设计，不是已校准的机器人难度。
- 题数 / 数据：738clips、18,072minutes≈301h、1,443四选一人工QA；原始30人400+h筛到20人300+h。
- 评估方式：14类macro平均与全部QA micro；直接答案比对，无LLM judge。人类评测3annotators，κ0.78。
- Split / 信息条件：benchmark zero-shot evaluation，非training dataset；固定sampling但model frame上限不同。
- 来源关系：新收集长期生活视频，与EgoLife是不同capture来源；一人多日仍属群聚数据。
- 可复用：扩到长期生活记忆与跨日状态，预算应固定并用participant群聚估计不确定性。
- 待核 / 限制：跨日task所需实际视觉覆盖与每model frame cap要并列；人格推论题不等于客观人格ground truth。

P203 EGOSTREAM (2026)

原作：<https://arxiv.org/abs/2605.31557>

本次PDF：<https://arxiv.org/pdf/2605.31557v2>

PDF SHA256：2b7fad2f7b3b003fe66a26ce10fe8f4c0b2950ae9a0a072a3f9215790a59ef17

阅读页：1、3、4、5、6、8。五父来源、人工filter、AVW与7recall regimes、8528扩充和stream protocol。

- 研究类型：理解、推理与规划；串流记忆benchmark
- 领域：居家整理与清洁
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：Ego4D VQA、EgoLife、EgoTempo、Multi-Hop EgoQA、HD-EPIC五来源；无添加可运行场景。
- 任务：7记忆题型：detail/spatial/temporal/event/social/causal/prospective；7recall时间区间另是条件。
- 题数 / 数据：2,634candidate→2,335human-verified→2,250final QA；依Answer Validity Window扩成8,528question-recall evaluations。
- 评估方式：4-way accuracy，依语义/recall报；每frame processing time及受限memory，固定backbone比较不同memory managers。
- Split / 信息条件：query到时才揭露；memory construction须query-agnostic，不能无界保存原frames再重读；不是所有题都可乘7。
- 来源关系：五来源QA与evidence重用/改写；baseQA与多recall conditions有父子关系。
- 可复用：示范正当扩题：保留base question，添加不同合法历史条件，并明示扩充规则和依赖。
- 待核 / 限制：无global scene union；同一QA的多recall测例需群聚统计，不能算8528独立语义问题。

P204 S-EMBER (2026)

原作：<https://arxiv.org/abs/2607.02689>

本次PDF：<https://arxiv.org/pdf/2607.02689v2>

PDF SHA256：a19dd911977b7b7ad2651673df90d5ea20fbd44471297b335afdb6e3a0884e04

阅读页：1、3、4、5、6、7、8、14。新capture、2090scenario labels/33活动、9448QA、多长度答案、joint grounding与judge验证。

- 研究类型：理解、推理与规划；串流记忆与证据定位benchmark
- 领域：居家整理与清洁、餐饮与烹饪、零售与购物
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：613用户Ray-Ban Meta capture；2,090fine-grained scenario labels合并33activity categories，非2090实体scene资产。
- 任务：8memory QA categories；answer generation与temporal grounding两endpoint。
- 题数 / 数据：3,141videos、388h、9,448QA；每题三种verbosity参考答案，不把答案条数当三倍题数。另5-way MC版本。
- 评估方式：free-form overall/clean accuracy用judge；MC exact match；temporal mIoU/Recall@1；GQ@ τ 要求答对且定位正确。judge另600正负pair验证。
- Split / 信息条件：visual-only且prefix cutoff；open models固定128frames、closed native limits另列，非完全同观测预算。
- 来源关系：新生活capture；questions由当下trigger往回问；视频scenario标签不提供可运行robot state。
- 可复用：我们可采用答案与证据的联合判分，但不能让多verbosity或MC改写虚增独立题。
- 待核 / 限制：全部实体场所数未报；GQ判分可靠性取决judge与grounding，需保留分项成绩。

P205 CapMem (2026)

原作: <https://arxiv.org/abs/2609.17688>

本次PDF: <https://arxiv.org/pdf/2609.17688v1>

PDF SHA256: f65b30af25bbaa68d3825316d901fac09df58f2fe57b133428750addc1aeec4e

阅读页: 1、3、4、5、8、16、18、22。75videos七来源、4用途/16scenario、QA filter、CleanQA、frame-aligned controls与部分API评测。

- 研究类型: 理解、推理与规划; caption记忆benchmark
- 领域: 居家整理与清洁、宠物照护与动物活动
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 4application domains、16scenario labels、75公共ego videos; 无实体scene union。
- 任务: CleanQA/DirectVideoQA/CaptionQA是同题三种信息条件; 50question templates与5diagnostic分析维度不等于50task goals。
- 题数 / 数据: 2,109candidate→1,000final MCQs、33.7h; Ego4D占56videos/742QA。Gemini VideoQA只跑786题, 其他主设置1,000。
- 评估方式: MC accuracy、token/runtime成本、visual tags/evidence位置/视频长度分项; CleanQA 15–35%gate是方法筛选规则。
- Split / 信息条件: 无额外train; full-caption1fps看全片而direct有frame cap, 另6Qwen frame-aligned及cross-captioner受控实验。
- 来源关系: Ego4D/EgoLife/EgoPet/EPIC/HoloAssist/ENIGMA-51/CASTLE2024; 只release annotations/metadata, 不重发原视频。
- 可复用: 可借相同问题在不同记忆表示下的受控比较; 先对齐看过的frames再比较caption收益。
- 待核 / 限制: 作者标明只涵部分wearable用途; blindgate低于/高于门槛的解释需谨慎, 不能直接证明污染。

P206 EmbodiedMemory-Bench (2026)

原作: <https://arxiv.org/abs/2609.28236>

本次PDF: <https://arxiv.org/pdf/2609.28236v1>

PDF SHA256: 14adce97c24c0e4080ec7f707206f2dcc6ff9155bacf63b0d6cf84287eba4580

阅读页: 1、3、4、5、6、15、18、27。四family、AI2THOR/ProcTHOR场景生成、2554验证episodes、sim success及source/split设计。

- 研究类型: 理解、推理与规划; 可运行具身记忆benchmark
- 领域: 居家整理与清洁
- 用途归纳: 依已核读的任务、活动或场景保留用途归纳; 原作任务细节与分类依据一起提供。
- 环境: 1,118source scenes; AI2-THOR单房间组成virtualhome并保存状态、ProcTHOR multi-room筛选。不是1118全部新建独立house。
- 任务: 4families: Passive Observation、Dynamic Tracking、Interaction Failure、Experience Generalization; 125visible object types/83target/33receptacle是资产类别。
- 题数 / 数据: 2,554episodes=1,036+1,052+263+203; 143候选被排除。四history介入条件同用800episodes而非添加3200unique basecases。

- 评估方式：运行action到sim目标终态的SR，四family等权macro避免1036/1052大类垄断；另history介入成对比较。
- Split / 信息条件：训练与eval scenes/trajectories分离，parent trajectories先split再展开turns；target task在history之后才给。
- 来源关系：AI2-THOR/ProcTHOR、PDDL distractor、LLM生成experience后必须ground与重播验证；这是episode而非2554独立语义families。
- 可复用：和我们『既有环境+新任务/规则』非常接近；差异要用更广用途与来源联集证明，不能只比episode数。
- 待核 / 限制：scene IDs跨host重用与完整episode manifest需原生release核；同history多condition需保留pair ID。

P207 EgoCoT-Bench (2026)

原作：<https://arxiv.org/abs/2605.19559>

本次PDF：<https://arxiv.org/pdf/2605.19559v1>

PDF SHA256：98ac34ca6c5e5e85367bbc76844e70d30939b29b4c58188ffdbe431af5e9b237

阅读页：1、3、4、5、6。来源/scene graph审核、12subtasks全表、3172QA、SCR与judge验证。

- 研究类型：理解、推理与规划；视频推理与证据benchmark
- 领域：居家整理与清洁、餐饮与烹饪、装配与生产作业
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：Ego4D、EPIC、MECCANO、Charades-Ego、HD-EPIC及自录；351clips不是351独立环境。
- 任务：4研究groups/12subtasks，从object grounding到state回顾、预测、progress与goal tracking。
- 题数 / 数据：3,172四选一QA、351video clips；参考reasoning与时空证据同属一题。
- 评估方式：答案exact match；Qwen-Max judge给reasoning0–5。SCR = 答对但reasoning≤2的比例，分母仅答对题。；judge与人类在2,800responses比较QWK/一致率；它衡量输出解释与证据一致，不证明模型内部思考忠实。
- Split / 信息条件：主文是benchmark evaluation；精确train/dev manifest未列。MCQ、rationale与evidence非不同题库。
- 来源关系：父视频及添加人工修订STSG；五公共父库与自录不代表六份互不重叠世界经验。
- 可复用：可加入答案与证据一致性的评测；不要把rationale judge直接叫物理成功验证。
- 待核 / 限制：Table1写Open/Close而metrics说全部四选一；以主实验协定为准并保留差异。

P208 DYAD (2026)

原作：<https://arxiv.org/abs/2609.09023>

本次PDF：<https://arxiv.org/pdf/2609.09023v1>

PDF SHA256：698811f9c48df7ba4dfef3eab17ed4c8336186b171cbc82e4ea597e06349fdf0

阅读页：1、2、3、4、5、6。单helper政策、三reference tasks、原始/有效/eligible counts、participant splits与oracle限制。

- 研究类型：辅助与协作；协作与协助预测benchmark
- 领域：装配与生产作业、协助、交接与陪伴
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：同一gearbox组装工作站、20performers与同一trainedhelper；6pilot sessions不纳正式20。

- 任务：3endpoint: causal8步辨识、介入前verbal/physical mode预测、oracle context下回应生成；不是完整robot助手。
- 题数 / 数据：20sessions/5h58m、528step intervals、611requests、851有效assistance events；mode eligible829, response376=120dev+256test。
- 评估方式：mode macro-F1/AUPRC, participant bootstrap；step segmentF1/edit/mAP/MoF；response rubric judge+BERTScore。
- Split / 信息条件：mode participant五fold每fold12/4/4、3秒观测到onset前0.5秒；step5val/15test；response120/256。当次trigger禁止入model。
- 来源关系：human-human assistance demonstration；851events中有效outcome极不平衡，作者不测outcome prediction。
- 可复用：可加协作规则，但需另外建need detection negatives及可运行robot feasibility。
- 待核 / 限制：没有non-intervention negatives，不能宣称会判断何时需要帮忙；mode是一位helper政策不是普世最佳协助。

P209 HUI360 (2026)

原作：<https://arxiv.org/abs/2608.11051>

本次PDF：<https://arxiv.org/pdf/2608.11051v1>

PDF SHA256：9b4575648e06d38fb681f06af41179b35afb217270d1526216532130f6c3026f

阅读页：1、3、4、5、6、8。9场所/30setup、原始与裁切时数、SSUP重标、physical interaction定义及anticipation协定。

- 研究类型：辅助与协作；人机交互预测benchmark
- 领域：公共场馆与服务、协助、交接与陪伴
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：HUI360有9真实场所、30robot placements/setups；SSUP-A两public-space field sessions另列。
- 任务：预测是否将发生与平台的物理interaction；不是广义社交意图。不同anticipation horizons重评同tracks。
- 题数 / 数据：HUI360 68recordings/71.3h原始→1,937episodes/11.3h有效人像片段，4,310tracks含375interaction。SSUP-A 27,698tracks为重标旧数据。
- 评估方式：AUROC主、F1/AP另报；跨location、跨dataset、0.33–2秒horizons及input-frequency robustness。
- Split / 信息条件：HUI360 locations1–7train、8–9test；SSUP第一/二场次train/test。近onset窗口排除，negative以最近距离proxy挑选。
- 来源关系：新HUI360+既有SSUP-HRI重标；1Mannotations不是1M独立interaction。
- 可复用：扩到公共空间交互预测，场地与摆位可独立记录；自动contact proxy应保留人工修正。
- 待核 / 限制：本文normalization用全HUI360均值/标准差，若严格train-only协定需修正；最终eligible test窗口量需manifest。

P210 RoCo Challenge (2026)

原作：<https://arxiv.org/abs/2603.15469>

本次PDF：<https://arxiv.org/pdf/2603.15469v1>

PDF SHA256：1b91dade9b97b3cbbde4f382166932d5d38a29b4038328808755568fc5b47c29

阅读页：1、3、4、5、6、12。三scenario、sim/real差异、两种demo、single model与weighted score。

- 研究类型：辅助与协作；协作组装benchmark
- 领域：装配与生产作业、协助、交接与陪伴
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：IsaacSim工作站与Galaxea R1 Lite实机；simulation人类参与由初始化partial state模拟。
- 任务：1gearbox workflow的3scenario：从零组装、partial state续作、error recovery。real只3planet gears，sim含sun/ring更多parts。
- 题数 / 数据：sim>300automatically generated demos，real另>300teleop demos；精确官方eval回合数在已读protocol未报。
- 评估方式：single model需处理三scenario；assembled-parts/recovery分数以0.4/0.2/0.4加权。
- Split / 信息条件：私有工作站上统一random lighting/texture/colors；real track任务规格有缩减，不能视为完全同题sim-real transfer。
- 来源关系：同gearbox assembly的起始状态/恢复规则扩充；与人类实时协作要分开。
- 可复用：可借从零/续作/修复三类规则；不同backend的task目标改动要版本化。
- 待核 / 限制：完整task/case IDs及官方评测分母待competition config；结论的300+泛称不能覆盖两份不同demo。

P211 AssemblyGrid (2026)

原作：<https://arxiv.org/abs/2609.16075>

本次PDF：<https://arxiv.org/pdf/2609.16075v1>

PDF SHA256：8661b2c5550168645f05f00d371e18fbdb54c431355ebf45b56a117ba5934f2d

阅读页：1、10、11、12、13、14、15、16、17、18、19、20、21、22、54、56。decentralized信息、9scenario全表、instance/seed区分、production metrics及held-out protocol；未逐式读57页全部附录。

- 研究类型：辅助与协作；多机器人生产调度benchmark
- 领域：装配与生产作业
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：抽象grid生产模拟，geometry/reach/workspace限制；不模拟robot-specific接触physics。
- 任务：Flow/Coalition/Concurrency三workload families×easy/medium/hard=9official scenarios，程度为family内配置，不保证每policy单调。
- 题数 / 数据：每scenario50held-out instances；3algorithms×9scenarios×10trainingseeds=270training runs，每个final checkpoint同50test instances。
- 评估方式：主要delivered products/throughput，admitted completion与offered-demand fulfilment分母不同；候选admission/coalition/blocking为diagnostics。；finite-batch timeout的makespan未定，不把未完成当正常完成时间；RL与nonlearning的不确定性分别按trainingseeds与instances。
- Split / 信息条件：train/val/finaltest generationseeds分离，主测unseen realizations而非新topology；finalcheckpoint，无事后best选择。
- 来源关系：local support-fraction cue为合法interface；centralized privileged reference与decentralizedpolicy分组。
- 可复用：补生产规划与协作资源约束；可借明确区分instance、executionseed、trainingseed的计数方式。
- 待核 / 限制：robot-specificphysics、newtopology、failure/communication interventions明列未纳v1实验；不要称完整工厂机器人控制。

P212 ARB4WM (2026)

原作: <https://arxiv.org/abs/2606.16605>

本次PDF: <https://arxiv.org/pdf/2606.16605v1>

PDF SHA256: 7164d9a676e577b14d43e71e8cc37115faf37eba06430b824a84b05822e11b4b

阅读页: 1、2、8、9、12。20tasks完整列表、5objectives、20eval runs、nAUC真实分母与defense metrics。

- 研究类型: 世界模型与预测表示; 世界模型与鲁棒性benchmark
- 领域: 居家整理与清洁、餐饮与烹饪、通用对象与机动作业
- 用途归纳: 同时涵盖对象操作与行走 / 平衡控制, 归入通用作业; 门窗与咖啡 / 餐盘任务另标对应用途。
- 环境: 10MetaWorld + 10DMC任务, 作者称industrial proxy; 未提供真实industrial scene。
- 任务: 20host tasks在5white-box objectives、各optimizer/temporal exposure下重评。
- 题数 / 数据: 每setting20evaluation runs, seed20–39; 4Dreamer-family agents, 不能把agent数乘入独立题库。
- 评估方式: MetaWorld SR、DMC return; nAUC公式除benchmark常数1或1000, 不是各policy clean score, 虽文中称clean-normalized。defense recovery另用clean-attack分母。
- Split / 信息条件: 只在eval perturb pixels, 不改dynamics/reward/parameters; cross-model transfer只是另subsetDMC Reacher Easy。
- 来源关系: MetaWorld/DMC task复用加新攻击protocol; hosttask和规则variants分开。
- 可复用: 可扩充传感失真规则, 固定合法attacker access和预算; 不要把视觉攻击当材料或安全有效性验证。
- 待核 / 限制: all-setting unique episode IDs未报; 攻击强度不是可跨任务直接相加的难度刻度。

P214 COIN (interactive) (2026)

原作: <https://arxiv.org/abs/2604.16886>

本次PDF: <https://arxiv.org/pdf/2604.16886v1>

PDF SHA256: 0e8f4586f184eb25ae2bd4bc596b3385b4e27319784a61dfa8c67bd98ba07f3c

阅读页: 1、4、5、6、7、15。90tasks分层、ManiSkill3规格、1000demo、六metrics、10trials及不同model inputs。

- 研究类型: 导航与家务运行; 交互推理与操作benchmark
- 领域: 居家整理与清洁、餐饮与烹饪、通用对象与机动作业
- 用途归纳: 开柜、找书、操作微波炉都有可辨认同用途; 纯交互推理与几何控制题保留在通用作业。
- 环境: ManiSkill3桌面Panda, PartNet/Sketchfab等assets; 3reasoning domains是能力类别, 不是生活用途。
- 任务: 20Primitive + 20Composition + 50interactive reasoning = 90task definitions; 含partialobservability下交互取得信息。
- 题数 / 数据: Primitive每task50demo = 1,000trajectories、5views; 主SR平均10trials, views不把traj变五倍。
- 评估方式: SR/类别SR、VQA、trajectory/gripper稳定、Composition/Primitive success ratio; 六metrics分母不同。
- Split / 信息条件: VLA在Primitive fine-tune、validationSR选checkpoint; model用1/3views不同, Voxposer有GObjectlist, 需保留信息条件。
- 来源关系: ManiSkill3资产与task扩充; expertVQA看示范不等于运行时在线推理成绩。

- 可复用：可借Primitive→composition→interactivegoal的父子关系；我们的规模优势需超出这种单桌面推理范围。
- 待核 / 限制：人类只10task代表subset、3people×2trials；不可把40%sim/100%real当全50task人类上限。

P216 HAP (2026)

原作：<https://arxiv.org/abs/2609.18548>

本次PDF：<https://arxiv.org/pdf/2609.18548v1>

PDF SHA256：0cbfc4268916f842b362862865080ed9f76fbefdb51c290d6e567b9e03abf8a

阅读页：1、2、5、6。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：未来动作 / 交互预测；动作与轨迹预测
- 领域：穿戴交互与动作界面
- 用途归纳：预测头部转向以看到被遮挡的操作目标，归入穿戴观察与动作界面。
- 环境：Bottle12RGB-D recordings sessions, clutter/reach变化；camera估计作headmotion proxy。
- 任务：预测6DoF head motion；EgoPAT3Dv2父benchmark另列。
- 题数 / 数据：Bottle382 clips, sessions10 train/1val/1test；单一test session不是广泛场地泛化证明。
- 评估方式：translation ADE/FDE(mm)、rotation ADE/FDE(degrees)；DA3/ORB3感知 backend 敏感性另测。
- Split / 信息条件：session disjoint；各模型同window/horizon/smoothed pose。
- 来源关系：新Bottle capture + EgoPAT3D、pseudo3D head targets。
- 可复用：补视角移动/遮挡规则与 active perception 预测，而非只评手部。
- 待核 / 限制：camera pose proxy 不等于独立 mocap GT；dataset 完整 release ID 待核。

P217 TRS + RVG (2026)

原作：<https://arxiv.org/abs/2609.13293>

本次PDF：<https://arxiv.org/pdf/2609.13293v1>

PDF SHA256：13aaaf69bfbfa5c99ef154700c56eb0f34385c23b6bb5503a53965250a5e7e6a

阅读页：1、2、6、7。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：稳健性、失败与评测品质；稳健性与分布外评测
- 领域：餐饮与烹饪
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：EGTEA/EPIC 原数据；破坏TSN feature tokens，不是重新收集真实 sensor failures。
- 任务：action anticipation 下六 main corruptions；额外 standalone blur 是 severity transfer。
- 题数 / 数据：EGTEA processed split10,321 clips；EK100 自订 training videos 90/10 切，不可和官方 leaderboard 直接比。
- 评估方式：joint verb+noun Top1、平均 corrupted accuracy 及 Relative Robustness=Avg C/clean。
- Split / 信息条件：compatibility graph 只 train labels、λ EGTEA val 选；EK pipeline 125 verbs/352 nouns 不同官方 97/300。

- 来源关系：既有视频加新corruptionprotocol，不添加生活domains或原始action库。
- 可复用：可以添加robustness规则cases并保持原task引用，清楚标记feature-level扰动。
- 待核 / 限制：本文自订indexspace与officialsplit不同；clean低时RR可能误导，须同报absoluteaccuracy。

P222 Uni-Hand (2025)

原作：<https://arxiv.org/abs/2511.12878>

本次PDF：<https://arxiv.org/pdf/2511.12878v4>

PDF SHA256: f71d9925369c1a5feb6fe1ecf4b409c2c11ae40edf1f0c8c7d568d12a00417ca

阅读页：1、9、10。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：未来动作 / 交互预测；动作与轨迹预测
- 领域：居家整理与清洁、餐饮与烹饪、通用对象与机动作业、穿戴交互与动作界面
- 用途归纳：把手部预测连到交互界面与机器人示教；杯垫摆杯、苹果入盘和盒子上架另提供餐饮 / 整理用途。
- 环境：新CABH头戴RGB-D与HAT固定ALOHAcamera；既有五publicdatasets另列。
- 任务：CABH3humanH0tasks；HAT5robottransfertasks，5个不是所有publicdatasetssemanticunion。
- 题数 / 数据：CABH1,200videos；HAT2,800handvideos (400/400/400/800/800)，每task10physicaltrials。
- 评估方式：hand/headtrajectory与contactstate预测；HAT按完整predictedtrajectory运行。
- Split / 信息条件：HAT只取第一帧产生完整motion，是look-then-move而非同等closed-loop视觉policy。
- 来源关系：CABH/HAT新数据；EgoPAT3D/H2O/HOT3D/Ego4D/EPIC重用。
- 可复用：补humanmotion到robotinterface，但必须标明executionmode与观测限制。
- 待核 / 限制：CABH精确split与全部frameID仍需manifest；依据单帧的open-looptransfer不可当通用在线成功率。

P224 EMPIRE (2026)

原作：<https://arxiv.org/abs/2608.22449>

本次PDF：<https://arxiv.org/pdf/2608.22449v1>

PDF SHA256: e49c2bea71f4e0913128fd930c8536111ea26aa22782f634ac9ce7497f14aa03

阅读页：1、2、4、5、6。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：未来动作 / 交互预测；动作与轨迹预测
- 领域：穿戴交互与动作界面
- 用途归纳：预测双手未来动作并产生操作计划，归入穿戴交互与动作界面。
- 环境：EgoDex原recordings，没有添加111独立物理场景。
- 任务：111tasklabels下bimanual5秒motionforecast + explicitplans；原作194只保留subset。
- 题数 / 数据：650,910trainwindows、6,836testwindows；non-overlapping5swindows，parentepisodes先分。
- 评估方式：best-of8按MPJPE选trajectory再算wrist/fingerrelative；不是单次控制policy。

- Split / 信息条件：原EgoDexofficialsplit；85unseentasks仅Part1ablations，fulltrain111tasks都seen。
- 来源关系：EgoDex→EMPIRE650K，Qwencaption/plan+MANOfitting；100caseaudit84%usable，未全部人工审核。
- 可复用：可借规划界面与预测粒度，同时保留生成标签品质及best-ofK预算。
- 待核 / 限制：difficulty按baselineMPJPE分43/49/19，仅模型相对难度；不得当通用easy/medium/hard真值。

P225 Exo2EgoPose (2026)

原作：<https://arxiv.org/abs/2607.15890>

本次PDF：<https://arxiv.org/pdf/2607.15890v2>

PDF SHA256：de7fddd04e06fecbb6bf89e299b81ad55b49b90cbbb5d57ec0856fd8cd1a5c43

阅读页：1、2、5、6。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：未来动作 / 交互预测；动作与轨迹预测
- 领域：装配与生产作业、穿戴交互与动作界面
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：AssemblyHands/EgoExo4D/EgoMe原场景，exovideo供训练supervision。
- 任务：vision-language3Dhandposeforecast；EgoMe-pose为添加derivedbenchmark。
- 题数 / 数据：AssemblyHands6120/355/355；EgoExo10869/1540/1540；EgoMe6067/1344/2648 train/val/test episodes。
- 评估方式：root-alignedMPJPE/MPJVE(mm)，不同source15/30fps。
- Split / 信息条件：EgoMe只保留correctimitation，>95%frames有效；generatedpose和depth不是全部mocapGT。
- 来源关系：Assembly101→AssemblyHands及EgoMe新pose标注；父场景不能再加。
- 可复用：补exo示范监督与finefingerprediction，但不混成robotphysicalexecution。
- 待核 / 限制：root-alignederror不检验世界坐标全局定位；episode数不可代替独立sourceclip数。

P226 EgoTraj (2026)

原作：<https://arxiv.org/abs/2605.19004>

本次PDF：<https://arxiv.org/pdf/2605.19004v1>

PDF SHA256：c6789c21ac3754c8b4f240cc614ab7712284681a8b02fa63e9ec08d9dbcfea82

阅读页：1、2、3、4、5、6、7。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：未来动作 / 交互预测；动作与轨迹预测
- 领域：交通移动与车辆维修、穿戴交互与动作界面
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：7outdoorwaypoints/21origin-destinationpairs；waypoint和route不等于21独立地理环境。
- 任务：wearer6DoFtrajectoryprediction，gaze/sceneannotations作modalities。
- 题数 / 数据：75participants各1session，10.7h/1.15Mframes；38,606annotatedframes非相同数量testcases。

- 评估方式：ADE/FDE与headrotationL1error；route多样性另用DTW。
- Split / 信息条件：held-outsessions；地理场域和路径可能重用，不等于unseencitygeneralization。
- 来源关系：新QuestProcapture；VLMsemanticlabels与真实trajectory/pose区分。
- 可复用：扩到户外行走的预测用途；属人类导航数据，不是机器人交互模拟房屋。
- 待核 / 限制：exactheld-outwindowcount和完整protocol需要release核；不将1.15Mframes当predictionquestions。

P228 SFHand / EgoHaFL (2025)

原作：<https://arxiv.org/abs/2511.18127>

本次PDF：<https://arxiv.org/pdf/2511.18127v2>

PDF SHA256：523777e21488e904c826eaab83130b80cffb36f33c1de90506f75949869bee9d

阅读页：1、2、3、4、5、6。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：未来动作 / 交互预测；动作与轨迹预测
- 领域：居家整理与清洁、餐饮与烹饪、通用对象与机动作业、穿戴交互与动作界面
- 用途归纳：实时语言引导手部预测归入动作界面；其Kitchen与Adroit下游评测另外归纳家居 / 餐饮与通用作业。
- 环境：Ego4D→EgoHOD/EgoVid衍生视频；worldcoordinates由估计camera/hand取得。
- 任务：streaming3Dhandstateforecast (type/box/pose/globaltrajectory)；Kitchen/Adroit只做下游representationtransfer。
- 题数 / 数据：247K三秒clips = 242Ktrain/5Ktest，3.95Mhandannotations；不是3.95M独立taskcases。
- 评估方式：ADE/FDE、wristalignedJPE/PA-JPE、2Dboxrecall/FPS；SFHand*使用GTstate oracle另列。
- Split / 信息条件：test时间autoregression吃前一步预测；普通SFHand不可和oracle58.8FPS/accuracy混成同设置。
- 来源关系：Ego4D/EgoHOD/EgoVid共同视频，再用HaMeR生成pose。
- 可复用：补streaming预测规则及teacher-forcing/oracle边界，sourceclip/traininglabel分开。
- 待核 / 限制：paper『4M Ego4D videos』实为衍生片段层级，不能当4M原始长视频；scene/video-disjoint split需核。

P229 UniEgoMotion (2025)

原作：<https://arxiv.org/abs/2508.01126>

本次PDF：<https://arxiv.org/pdf/2508.01126v2>

PDF SHA256：841c3f6b142a703b951a3bbf3b4b85d7ce9d771d5fcebda569b703a3c857baa7

阅读页：1、2、3、4、5。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：未来动作 / 交互预测；动作与轨迹预测
- 领域：餐饮与烹饪、休闲与运动、音乐与表演、穿戴交互与动作界面
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：EgoExo4D原takes，添加pseudoSMPL-X重建。
- 任务：reconstruction、forecasting、generation三不同观测条件；同数据重用。

- 题数 / 数据：EE4D-Motion110+h；143Ktrain8sclips（每2s抽）、4,400valclips（每20s抽）。
- 评估方式：MPJPE/PA/handerror、headpose、footcontact/sliding、semantic/FID；不同endpoint分项。
- Split / 信息条件：officialtake-levelsplit；forecast看2s预测6s，generation只看一帧，reconstruction可看全input。
- 来源关系：EgoExo4Dmulti-viewoptimization生成新motionlabels；非110h新独立capture。
- 可复用：补全身与scene-awareforecast，但应防止把reconstruction偷看未来当forecast。
- 待核 / 限制：三端点accuracy/inputs不同，不能用同一个难度或成功率比较；best-ofK需最终protocol固定。

P230 EgoH4 (2025)

原作：<https://arxiv.org/abs/2504.08654>

本次PDF：<https://arxiv.org/pdf/2504.08654v1>

PDF SHA256：16c00d83861cf54090431f84a857bd58983670d1635fa09e3cb8a8b6fc048006

阅读页：1、2、5、6。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：未来动作 / 交互预测；动作与轨迹预测
- 领域：穿戴交互与动作界面
- 用途归纳：包含视野外双手的姿态与动作预测，归入AR / VR等穿戴动作界面。
- 环境：EgoExo4Dbody/handannotations合并，原场景重用。
- 任务：in-view/out-of-viewhandtrajectory/poseforecast，body作constraint。
- 题数 / 数据：156Ktrain/34Ktest是按hand-side的sequencecounts；同片左右手不可当独立scene。
- 评估方式：ADE/FDE、MPJPE/lastframeMPJPE，单一generatedsample，没有best-ofK放大。
- Split / 信息条件：officialtrain/valastrain/test，2sobs→1sforecast10fps；GT2Dhands作input，autobody只train。
- 来源关系：EgoExo4Dbody与handsubset；metric对不同validjoints适用分母不同。
- 可复用：加入遮挡/视野外预测的规则对照，并标明ground-truth感知input优势。
- 待核 / 限制：要核hand-side数转uniqueclip的关系；不能将156K+34K称190K独立humanactivities。

P233 OCT/HOI forecasting (2022)

原作：<https://arxiv.org/abs/2204.01696>

本次PDF：<https://arxiv.org/pdf/2204.01696>

PDF SHA256：c866b4f79af2ef6de72a2ee55996af607cd4a69c977889bb3c3f67b0242fad17

阅读页：1、4、5、6。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：未来动作 / 交互预测；动作与轨迹预测
- 领域：餐饮与烹饪、穿戴交互与动作界面
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：EPIC55/100及EGTEA原视频，EK100扩充EK55。

- 任务：handtrajectory与objectcontacthotspot联合预测。
- 题数 / 数据：EK55train8523/evaltrajectory1894/hotspot241；EK10024148/3513/401；EGTEA1880/442/69。三种数字分别是训练、轨迹评测与hotspot评测。
- 评估方式：trajectory取20samples最小error；contactpoints全部转heatmap评，不是20次独立case。
- Split / 信息条件：评原validation，正式actiontest不用于此derivedtask；hotspot只人工审核challengingsubset。
- 来源关系：autoannotations+人工filteredhotspots，后被多篇forecast论文重用。
- 可复用：是hand/hotspot联合规则的基础来源；保留每个target的可用label分母。
- 待核 / 限制：不同target只覆盖各自subset，1894不能全视为1894jointlabelcases。

P241 AFF-ttention (2024)

原作：<https://arxiv.org/abs/2406.01194>

本次PDF：<https://arxiv.org/pdf/2406.01194v2>

PDF SHA256：5bc6b87af40d139d6f59d0cb6bd989130ccd236b866623dc409b6fe248d789a5

阅读页：1、3、10、11。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：未来动作 / 交互预测；动作与轨迹预测
- 领域：餐饮与烹饪
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：EPIC-Kitchens添加STAannotations；Ego4D v1/v2原场景。
- 任务：next-activeobject box/noun/verb/time-to-contact联合预测。
- 题数 / 数据：添加EPIC-STA验证集；已读原文mainsections未给精确casecount，待annotationmanifest。
- 评估方式：N、N+V、N+TTC、All Top5mAP；不是四个互不相干task库。
- Split / 信息条件：Ego4Dv1/v2训练量和test榜分列，v2含v1；EPICval自建benchmark。
- 来源关系：EPIC父标注→STA、OCT-stylehotspots；STAformer++是后续方法版本。
- 可复用：论文名字像方法但附带新benchmark，应纳入来源总库并连回EPIC。
- 待核 / 限制：精确newannotationID与共同scene/task映射待code核，未知不填0。

P246 Decision-aware uncertainty (2026)

原作：<https://arxiv.org/abs/2603.10061>

本次PDF：<https://arxiv.org/pdf/2603.10061v2>

PDF SHA256：4efc1650b0634e90b675a99e738d4660ad1c454cbd8b1023bc814cafbcb53992c

阅读页：1、2、3、4、5。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：Survey / 评测方法；评测方法与不确定性
- 领域：餐饮与烹饪

- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：EGTEA/EPIC100既有视频。
- 任务：partial-prefixactionprediction下correctness/calibration/selectiveutility/confidencegeometry四种诊断。
- 题数 / 数据：预设K10候选、M5stochasticsamples/input；原作精确evalsegmentIDs未报。
- 评估方式：Top1/Recall@K、Top1/SetECE、accuracy-coverage、entropy；不是physicalsecurity验证。
- Split / 信息条件：称用officialtest，singleGemini2.5Flash-lite；K/M改变结果及成本，不能算多出5倍题。
- 来源关系：对既有benchmarks加uncertaintyprotocol；有助规则/拒答评测。
- 可复用：我们可加入拒答/澄清阈值与accuracy-coverage曲线，但要有相应标签和同模型预算。
- 待核 / 限制：Set-ECE用TopK平均confidence对setcorrectness，是作者定义，需另外验证适用性。

P247 EgoSpanLift (2025)

原作：<https://arxiv.org/abs/2511.18470>

本次PDF：<https://arxiv.org/pdf/2511.18470v1>

PDF SHA256: b2ea7307cbe26217da35558970ceadb9f521d3f0841c60ff431031d39a98003f

阅读页：1、5、7、8。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：未来动作 / 交互预测；动作与轨迹预测
- 领域：居家整理与清洁、餐饮与烹饪、医疗与手术支持、交通移动与车辆维修、休闲与运动、音乐与表演、穿戴交互与动作界面
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：AEA的143recordings/7.3h与EgoExo4D五活动子集；排除soccer/basketball/dance。
- 任务：3Dvisualspanforecast，多个视角范围是同target不同granularity。
- 题数 / 数据：FoVS-Aria约23.2Ksample（19.3K/1.9K/2.1K）；FoVS-EgoExo341.4K（274.7K/29.6K/37K），概述364.6K。
- 评估方式：3DIoU/F1、fovealregiondistance；16格/3.2m=20cmcell resolution，不当精确gaze接触。
- Split / 信息条件：AEA location4heldout；look2spredict2s，EgoExo预测4s；split约数四舍五入不精确加总。
- 来源关系：AEA/EgoExo4DSLAM+gaze衍生volume；windowoverlap与sourcecaptures要追踪。
- 可复用：补注视/可见区域预测，让世界观测能力不只局限于问答或手轨迹。
- 待核 / 限制：visualspan≠robotactiveperceptionpolicy；也未覆盖所有EgoExo8activities。

P250 EgoMAN (2025)

原作：<https://arxiv.org/abs/2512.16907>

本次PDF：<https://arxiv.org/pdf/2512.16907v2>

PDF SHA256: 3edd340c61e8cb14c7aee576baa1f86ace5b4367000ec8ea612f039df07d7c24

阅读页：1、2、3、4、5、6。原作数据构成、任务定义与实验协定相关段落；阅读范围限所列PDF页，非全文逐字或程序重现。

- 研究类型：未来动作 / 交互预测；动作与轨迹预测

- 领域：居家整理与清洁、餐饮与烹饪、交通移动与车辆维修、穿戴交互与动作界面
- 用途归纳：依已核读的任务、活动或场景保留用途归纳；原作任务细节与分类依据一起提供。
- 环境：EgoExo4D/Nymeria以1014pretrain/498finetune/78testscene标签分开；HOT3D testonly。
- 任务：interactionstage-aware6DoFwristforecast；semantic/spatial/motionQA三训练类别。
- 题数 / 数据：EgoMAN-Bench2844unseen+990HOT3DOOD = 3834trajectories；3MQA为生成supervision概述，非3Mtestquestions。
- 评估方式：ADE/FDE/rotation/DTW，best-ofK1/5/10；waypointcontact/traj-distance另报。
- Split / 信息条件：sceneheldout及datasetOOD；up-to5sforecast，GTduration/masks用于判分。
- 来源关系：EgoExo4D/Nymeria/HOT3D重用，再生成interaction/QAlabels；可与OpenEgo、UniHand有父素材重叠。
- 可复用：是端点/规则扩充产生大QA量的对照；主benchmark应以3834testtrajectory分母比较。
- 待核 / 限制：219K/220K+trajectory概要与74K+17Ktrain分项不是同一层；待release对hand/clip单位核。

67篇方法 / 背景参考的筛查

- P035 EgoVLPv2: EgoVLPv2使用EgoClip/EgoMCQ及既有下游数据; 模型融合改进不另计一份新视频库。(PDF 1, 5, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2307.05463>
- P036 EgoT2: EgoT2在Ego4D的7既有任务做task translation, 保留作跨任务模型参考。(PDF 1, 2, 5; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2212.06301>
- P043 Embodied VideoAgent: Embodied VideoAgent用Ego4D-VQ3D、OpenEQA、EnvQA; 添加memory/tool方法, 不把下游来源再加总。(PDF 1, 2, 5; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2501.00358>
- P044 HiERO: HiERO在EgoMCQ/EgoNLQ/EgoProceL/Goal-Step验证hierarchical features, 未另计父数据规模。(PDF 1, 2, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2505.12911>
- P046 RULSTM: RULSTM是EPIC/EGTEA的anticipation方法与challenge参考, 原生题库归父来源。(PDF 1, 4; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/1905.09035>
- P047 AVT: AVT使用EK55/EK100/EGTEA/50Salads, 四个评测集合不能当四份新数据。(PDF 1, 2, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2106.02036>
- P048 EGO-TOPO: EGO-TOPO从EPIC/EGTEA建环境affordance图, 保留拓扑表示与forecasts设计参考。(PDF 1, 3, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2001.04583>
- P049 AntGPT: AntGPT研究goal inference与actionsequenceforecast, LTA定义归Ego4D等父benchmark。(PDF 1, 3; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2307.16368>
- P050 PALM: PALM用caption/识别/LLM预测既有LTA标签; 多次prompt不增加基础题数。(PDF 1, 4, 8; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2311.17944>
- P052 StillFast: StillFast针对既有short-term object interaction anticipation, 属方法; 初筛仅摘要/任务定义。(PDF 1; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2304.03959>
- P055 FUTR: FUTR在Breakfast与50Salads测长期预测, 保留horizon/分割方式参考。(PDF 1, 2, 5; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2205.14022>
- P056 Forecasting hands and objects: 未来手/物体位置预测在公开第一人称及street数据验证; 本轮未另登记独立新数据资源。(PDF 1, 2, 8; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/1705.07328>
- P059 EMAG: EMAG在Ego4D/EPIC55研究ego-motion及跨库泛化, 非新capture来源。(PDF 1, 4, 8; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2405.20030>
- P078 PerAct: PerAct有18RLBench tasks/249variations及7real tasks/18variations; 保留方法实验, RLBench子集不重算整库。(PDF 1, 3; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2209.05451>
- P117 UMI: UMI四个实机task验证工具/界面; 可借cuporientation等规则, 未纳成本轮独立benchmark总数。(PDF 1, 6, 7; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2402.10329>
- P118 EgoMimic: EgoMimic三个real long-horizon tasks研究human-robot对齐; 保留任务扩充参考。(PDF 1, 5, 10; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2410.24221>
- P121 EgoZero: EgoZero七个real tasks验证smart-glasses到robot技能; 是方法实验而非七种新生活领域。(PDF 1, 2, 5; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2505.20290>
- P122 EgoBridge: EgoBridge的PushT对照与三real tasks用于OT adaptation; 背景和初态规则可借用。(PDF 1, 2, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2509.19626>
- P130 ALOHA / ACT: ALOHA/ACT六个real tasks与两simtasks, 主要界面/策略研究; demo数和task数分开。(PDF 1, 8; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2304.13705>

- P131 Mobile ALOHA: MobileALOHA延伸mobilebimanual操作, 50demos/task; 完整custom实验清单可续做task-level抽取。(PDF 1, 7; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2401.02117>
- P133 RT-2: RT2约6000跨方法/条件rollouts; 沿用robotdata并研究新语义能力, 非6000unique tasks。(PDF 1, 4, 7; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2307.15818>
- P134 OpenVLA: OpenVLA重用OXE970Kdemonstrations; 29evaltasks与7finetunetasks是方法实验范围。(PDF 1, 2, 7; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2406.09246>
- P135 Octo: Octo800Ktrainingtrajectories来自OXE; 多平台policyadaptation不创建800Ktest题。(PDF 1, 2, 3; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2405.12213>
- P136 pi0: π_0 包含约10000h数据与折衣/清洁/盒子组装实验; 保留通用策略与自收数据参考, 完整manifest未由初筛验证。(PDF 1, 3, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2410.24164>
- P137 pi0.5: $\pi_{0.5}$ 验证未见房屋与长流程; 高低层cotrain是方法, 不能把所有提及用途当完整task库。(PDF 1, 3, 10; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2504.16054>
- P138 Diffusion Policy: DiffusionPolicy在既有四benchmark的15tasks评测; 保留控制界面/数据预算参考。(PDF 1, 2, 10; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2303.04137>
- P139 R3M: R3M用Ego4Dpretrain、三sim来源与五realtasks; 来源重用需连父库。(PDF 1, 6, 8; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2203.12601>
- P140 VIP: VIP研究reward/representation; 四realtasks及既有simcases留作评测方法参考。(PDF 1, 7, 8; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2210.00030>
- P149 V-JEPA 2: V-JEPA2有大规模internetpretrain与DROIDadaptation; 保留worldmodel/closed-loop对照, 不把22Mvideos算robot题。(PDF 1, 5, 11; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2506.09985>
- P153 EgoExo-Gen: EgoExo-Gen在EgoExo4D作cross-viewmask/video预测; 可借新输入条件, 素材仍属父来源。(PDF 1, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2504.11732>
- P154 Hand-conditioned ego predictive model: Hand-conditioned predictive model使用Ego4D/BridgeData/RLBench, predictionquality与控制success分开。(PDF 1, 4, 5; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2508.19852>
- P155 EgoExo-WM: EgoExo-WM把HowTo/CrossTask等exo转ego并结合Nymeria; 添加合成表示, 不视为全新独立行为。(PDF 1, 2, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2605.15477>
- P156 Egocentric survey: Egocentric survey按subject/object/environment/hybrid整理; 用于taxonomy与引文扩查。(PDF 1; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2503.15275>
- P157 Human-video robot learning survey: Human-video robotlearning survey区分task/observation/action pathways; 背景综述非新题库。(PDF 1; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2604.27621>
- P158 VLA benchmark survey: VLA数据/benchmark/dataengine survey; 可用于遗漏来源检查, 不沿用二手规模替代原作。(PDF 1, 2; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2604.23001>
- P159 tinyBenchmarks: tinyBenchmarks提供IRT/子集估计方法, 研究对象是LLM; 不能直接假设robot难度模型有效。(PDF 1, 4, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2402.14992>
- P160 Rliable: Rliable提供分层bootstrap/IQM与performanceprofiles; 统计方法, 不是robot环境数据源。(PDF 1, 2, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2108.13264>
- P161 First-person prediction survey: 第一人称未来预测survey, 涵行为/位置/手物交互; 背景与追引文来源。(PDF 1; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2107.13411>
- P162 Egocentric hands survey: 手部egocentric survey区分localization/interpretation/application; 无新robot题库。(PDF 1; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/1912.10867>
- P163 Ego-exo collaboration survey: Ego-exo survey以跨视角transfer/jointlearning整理, 可支持示范来源分类。(PDF 1; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2506.06253>

- P187 SSFold: SSFold报六foldtasks及human demonstrations; 留方法实验参考, 初筛尚不宣称已核所有trial协定。(PDF 1, 2; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2411.02608>
- P189 GPT-Fabric: GPT-Fabric重用smoothing/folding范式, real10/12rollouts; sim粒子距离和real人工查看不可混分。(PDF 1, 5, 7; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2406.09640>
- P190 UniGarmentManip: UniGarmentManip三garment类/三task: unfold/fold/hang; 重用资产/对应学习, 不当三新datasets。(PDF 1, 3, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2405.06903>
- P194 Cloth gripper interface: clothgripperinterface八个cornerfold cases验证kinematicgrasp; 省略摩擦contact, 不能当完整physicsbenchmark。(PDF 1, 2; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2609.29340>
- P195 World models for unfolding: worldmodelforunfolding在Unity/RFuniverse及realcloth验证; 保留模拟与policy方法参考。(PDF 1, 3, 7; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2602.16675>
- P215 World-model evaluation survey: worldmodelevaluation survey列160benchmarks; 作引文追查线索, 其二手数字不直接并入已核来源。(PDF 1, 4; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2609.29669>
- P218 TrajPilot: TrajPilot重用EgoExo4D/GoalStep/EgoPER, 重点是trajectoryconditioning及horizon, 不另算全部label为新task。(PDF 1, 7; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2605.20388>
- P219 FROST-STA: FROST-STA是Ego4D2026challenge submission; query/GT由父challenge定义。(PDF 1, 3; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2606.00694>
- P220 VISTA (Ego4D STA): VISTA-STA合并train+部分val训练、只报officialtest; 不是添加dataset。(PDF 1, 3, 4; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2605.20901>
- P221 STAformer++: STAformer++是AFF-ttention后续架构, EPIC-STA添加资源已连到P241, 避免重列两次。(PDF 1, 2; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2602.14837>
- P223 INSIGHT: INSIGHT在Ego4D/EPIC55/EGTEA测意图推理与预测, 原生题库归父来源。(PDF 1, 2, 5; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2508.01742>
- P227 EggHand: EggHand处理EgoExo4Dhandposeforecast, 保留motion/frame定义与模型baseline参考。(PDF 1, 2, 5; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2605.07642>
- P231 MADiff: MADiff用五publicdatasets与添加interaction-pointdiagnostics; 标注/metrics从父数据衍生, 非新capture。(PDF 1, 6, 9; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2409.02638>
- P232 Diff-IP2D: Diff-IP2D添加jointpredictionmetrics、沿用EPIC/EgoPAT; 并揭示USST的FDE erratum, 保留评分版本参考。(PDF 1, 11; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2405.04370>
- P234 I-CVAE: I-CVAE在Ego4DLTA预测20futureactions; oracleintent/GTactionablation应另列。(PDF 1, 2, 7; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2207.12080>
- P235 TransFusion: TransFusion把contextsummary加入既有STA; GTcontext与推估context不可等同。(PDF 1, 2, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2301.09209>
- P236 ActFusion: ActFusion统一segmentation/anticipation于Breakfast/Salads/GTEA; 两endpoint共用视频。(PDF 1, 2, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2412.04353>
- P237 Gated Temporal Diffusion: GatedTemporalDiffusion在Breakfast/Assembly101/Salads做stochasticLTA; 新模型不增加父库活动数。(PDF 1, 2, 9; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2407.11954>
- P238 Object-centric LTA: object-centricLTA用Ego4D/50Salads/EGTEA; objectprompt数非独立task数。(PDF 1, 6; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2311.00180>
- P239 MVP: MVP研究多尺度video pretraining与既有LTA/summaryforecast; 保留观测horizon参考。(PDF 1, 2, 7; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2307.12854>
- P240 ANTICIPATR: ANTICIPATR在四existingdatasets做futureinstance预测; 重用原split。(PDF 1, 9, 10; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2210.11566>

- P242 NAOGAT: NAOGAT用Ego4DSTA及EK; noun/verb/box/TTCjointmatch是判分组合, 非四倍题。(PDF 1, 7; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2308.08303>
- P243 FactCheck (LTA) : FactCheck的Observe-Plan-Verify是预测流程内迭代, EPIC/EGTEA未运行robot物理环境。(PDF 1, 9, 10; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2606.14778>
- P244 BiAnt: BiAnt在Ego4DLTA研究forward/backwardactionsequencelearning; 初筛未添加独立题库。(PDF 1; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2508.00374>
- P245 ICVL: ICVL在Ego4D/EPIC55/EGTEA研究vision-intentionfusion; 保留方法与prompt参考。(PDF 1, 2; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2505.01713>
- P248 HOIMotion: HOIMotion使用ADT/MoGaze及humanstudy; sceneobjectboxes是forecastinputs, 不是新控制环境。(PDF 1, 2; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2407.02633>
- P249 EgoCast: EgoCast使用EgoExo4D/ADT, 提出较长horizon/估计而非GTpastpose; 保留taskprotocol扩充参考。(PDF 1, 3, 4; 原作摘要 / 贡献与实验摘录初筛; 非全文逐字或完整benchmark协定审核) <https://arxiv.org/abs/2412.02903>

扩查清单（未计入183已核来源）

- BEHAVIOR-100原作：需和BEHAVIOR-1K及EAI的B100 symbolic评测分开；现有书目未独立登记。
- Assistive Gym与照护 / 穿衣任务来源：补照护场域，不能只以厨房/衣物替代身体接触与可及性；需扩查原作。
- RoboMME及具身记忆相关原作：新记忆来源引用多个未独立收录的父benchmark；需逐个分清重用/新生成。
- ENIGMA-51、CASTLE2024、HO-Cap：已核来源的父素材未全独立登记；依CapMem/OpenEgo原文追查。
- RoboBenchMart、SariBench：SABER的零售环境/下游task父来源需补独立原作与manifest。
- Fold/cloth方法的完整原作清单：SSFold、GPT-Fabric、UniGarmentManip等67篇参考组中的custom实验，可在逐task抽取时补规则/实例；本轮初筛不假称已核所有程序。
- survey与引用链的添加来源：世界模型survey等提供更多候选。候选未审阅前不加进183已核来源，不以二手表格宣称完整搜集。

本次公开自己的阅读摘要、页码、数字及来源指纹；不重新散布原作PDF。