

Robot-use Benchmark：逐篇來源審閱與整合設計

版本v0.11；用途歸納更新2026-10-04，原作審閱2026-10-02。

250篇現有書目全部初篩；143個原登記來源加40個補入來源，共183篇已讀資料 / benchmark / 評測相關章節。其餘67篇保留方法、原作實驗、survey或統計方法索引。不宣稱窮盡全球文獻。

『已審閱』指核對原作身份並閱讀所列PDF頁的任務、資料與評測段落；不表示全文逐字精讀、原始標註逐題人工複核或程式已重現。

本輪數字與目標

專案	目前確認	下一階段規劃口徑
領域	21 已歸納用途類別。183/183份來源均有歸類；原22份已補齊。每個用途有任務 / 場景理由；同一來源可涵蓋多用途。	按任務、物件與目標歸納，再逐任務建立聯集；新用途可擴充分類。
環境	284 已取得命名場景條目。64個已讀來源有某種環境量；284條僅是已取ID子集，未完成跨庫幾何去重。	整理各來源scene/layout/location及重用關係後，計全庫聯集；不再先配1,000。
任務	2,096 已取得robot任務條目。另有7資訊題型、263人類活動。原作 task/skill/instruction的差異已逐篇記錄，尚未全部正規化去重。	先取原作任務聯集，再加有差異證據的新目標 / 規則；不再先配5,000。
題數	114,288 已取得題目定義元資料。111,652 PARTNR train + 1,000 val + 1,636 OpenEQA；含訓練資料，素材未全齊，不是114,288道已整合測試題。	依task、split、合法輸入及判分建立case manifest 後定量；原作量、已取得量、可評量分列。
評估方式	4 共同判分大類。183份來源均有判分方式與原文依據；具體metrics及評分器仍各自保留，尚未全數掛接。	答案、誤差、狀態 / 過程、人工 / 模型評審各報；不以4類代表4個完成的通用評分器。

v0.9的12領域 / 1,000場景 / 5,000任務 / 100萬題配額已撤回。4種判分方式仍作分類，不作完成量。實際清單仍保留，未知的全庫聯集不填0。

閱讀後的主要發現

有任務就能進一步歸納用途，不必等待同名domain標籤

CALVIN的抽屜 / 燈光、Meta-World的咖啡機 / 裝配、TACO的攪拌 / 倒液均提供明確用途。RoboNet、GRIP與穿戴動作研究則以正式跨場域用途歸類；原22份皆有逐筆證據。

依據：P065、P063、P198、P128、P193、P197，詳見逐篇紀錄。

大量題目不一定是大量不同任務

Meta-World的50種task與引數instances、RoboRecover的400test recovery scenarios、EGOSTREAM的2,250問題→8,528recall測例，分別增加不同層級。每個數字保留它自己的單位。

依據：P063、P178、P203，詳見逐篇紀錄。

影片與通用資料整合前作已經很大

HowTo100M的23,611人類活動標籤、OXE的527skills與160,266作者報告tasks、OpenEgo的290來源task labels都要比較。它們不是同一種正規化機器人任務。

依據：P002、P125、P199，詳見逐篇紀錄。

環境數最容易混入配置與影片標籤

RoboCasa365的layoutxstyle配置、DROID的564workspaces、S-EMBER的2,090scenario labels層級不同。DreamDojo自己的table與正文scene量也不一致，已明列待核。

依據：P071、P126、P204、P150，詳見逐篇紀錄。

主張範圍通常大於實際實驗子集

BEHAVIOR-1K的活動定義與原始baseline子集、AutoBio的16定義/9實測、Labimus的完整流程設計與v0已驗證部分均應分欄。

依據：P100、P176、P174，詳見逐篇紀錄。

同源的資料與資產需要保留關係

Ego4D衍生多個QA/預測集合；EgoDex又出現在OpenEgo與EMPIRE；HSSD支援HomeRobot、Habitat3和PARTNR。來源聯集不能直接相加這些原作數字。

依據：P013、P119、P199、P224、P099、P142、P143，詳見逐篇紀錄。

答案、代理量和物理完成有不同證據

摘果waypoint接近、衣物外形IoU、world-model影片品質、人工偏好和實際robot success不能等同。不同predicate、失敗排除、oracle資訊和best-of-K預算均留在逐篇紀錄。

依據：P213、P089、P191、P150、P250，詳見逐篇紀錄。

現在的難度只能在共同協定下校準

EMPIRE按baseline error分級、LIBERO-Plus按擾動設定分級、RoboRecover按referencepolicy可恢復率篩選，都依賴各自模型和協定。不能取一篇的easy/hard直接替另一篇定級。

依據：P224、P105、P178，詳見逐篇紀錄。

Survey分佈

研究型別沿用書目的12類並按本輪閱讀修正所列來源。每篇一個主類，用於survey分佈；細部角色和多種判分方式另保留。研究型別不是生活用途，兩者不能用篇數配額互相換算。

研究型別	已詳細審閱來源	全部書目
人類影片與動作資料	32	32
理解、推理與規劃	21	25
未來動作 / 互動預測	18	48
一般操作 benchmark	31	32
布料 / 柔性物操作	21	26
導航與家務執行	11	11
穩健性、失敗與評測品質	19	19
人類觀測到機器人轉移	7	11
機器人資料與通用策略	6	16
輔助與協作	11	11
世界模型與預測表示	5	9
Survey / 評測方法	1	10

用途按原作的任務目標、操作物件、互動關係及場景歸納，包含生活 / 工作用途及跨場域應用。183份來源均至少歸入一類，共21類；同一來源可以有多個用途。類別名稱是本庫的survey編碼，不要求原文先給出相同domain標籤。

生活 / 工 作用 途	來源 數 (可 重複 標 記)	來源支援
居家 整理 與清 潔	104	P001、P003、P007、P009、P010、P011、P012、P013、P016、P017、P018、P024、P026、P027、P028、P029、P030、P031、P032、P033、P038、P039、P040、P042、P062、P063、P064、P065、P066、P067、P068、P069、P070、P071、P072、P073、P074、P075、P076、P080、P081、P082、P083、P084、P087、P093、P094、P095、P096、P097、P098、P099、P100、P101、P104、P105、P106、P107、P108、P109、P111、P114、P116、P119、P123、P124、P129、P142、P143、P144、P145、P164、P165、P166、P169、P178、P180、P181、P198、P199、P201、P202、P203、P204、P205、P206、P207、P212、P214、P034、P037、P051、P054、P110、P125、P126、P127、P120、P132、P150、P222、P228、P247、P250
餐飲 與烹 飪	70	P003、P004、P005、P006、P008、P009、P010、P011、P012、P013、P014、P018、P021、P022、P023、P024、P026、P027、P028、P029、P030、P031、P032、P033、P039、P063、P070、P071、P072、P073、P096、P097、P098、P100、P101、P105、P106、P108、P109、P116、P141、P143、P145、P152、P164、P166、P182、P198、P202、P204、P207、P212、P214、P002、P053、P057、P060、P125、P126、P127、P132、P217、P222、P228、P229、P233、P241、P246、P247、P250
衣物 與洗 護	25	P045、P082、P083、P085、P086、P087、P092、P093、P100、P119、P151、P152、P167、P181、P185、P196、P088、P089、P090、P091、P127、P186、P188、P191、P120
辦公 與教 育	18	P018、P038、P039、P042、P072、P094、P095、P100、P101、P141、P144、P145、P202、P002、P054、P126、P120、P150
工藝 與修 繕	17	P003、P004、P013、P023、P028、P029、P031、P041、P063、P073、P106、P112、P141、P002、P034、P054、P150
裝配 與生 產作 業	30	P015、P016、P023、P063、P067、P068、P069、P076、P079、P082、P083、P106、P112、P115、P119、P129、P141、P170、P171、P177、P179、P183、P184、P207、P208、P210、P211、P120、P150、P225
包 裝、 倉儲 與物 流	8	P076、P084、P086、P103、P164、P170、P200、P077
零售 與購 物	9	P013、P031、P100、P164、P200、P202、P204、P120、P150

生活 / 工 作用 途	來源 數 (可 重複 標 記)	來源支援
實驗室 操作	12	P021、P031、P072、P112、P164、P172、P173、P174、P175、P176、P192、P120
醫療 與手 術支 援	5	P041、P113、P164、P060、P247
個人 照護	8	P003、P014、P031、P087、P103、P148、P167、P002
交通 移動 與車 輛維 修	12	P003、P004、P013、P014、P031、P202、P002、P060、P150、P226、P247、P250
農業 與園 藝	7	P013、P023、P028、P031、P100、P002、P213
休閒 與運 動	16	P003、P013、P014、P019、P020、P031、P033、P041、P063、P072、P106、P202、P002、P054、P229、P247
公共 場館 與服 務	3	P102、P103、P209
寵物 照護 與動 物活 動	4	P025、P041、P205、P002
音樂 與表 演	3	P014、P229、P247

生活 / 工 作用 途	來源 數 (可 重複 標 記)	來源支援
社交 與溝 通	7	P013、P019、P020、P032、P033、P061、P168
通用 物件 與機 動作 業	31	P062、P063、P065、P067、P068、P069、P075、P076、P081、P082、P083、P084、P106、P107、P115、P123、P129、P151、P152、P169、P171、P177、P182、P212、P214、P077、P125、P128、P193、P222、P228
協 助、 交接 與陪 伴	17	P058、P061、P073、P097、P103、P113、P141、P142、P143、P145、P146、P147、P148、P168、P208、P209、P210
穿戴 互動 與動 作介 面	25	P013、P014、P018、P019、P020、P058、P119、P197、P198、P199、P051、P053、P057、P060、P216、P222、P224、P225、P226、P228、P229、P230、P233、P247、P250

用途歸納完成：183/183；未歸類：0。120份涉及多用途，共431筆用途對應；來源仍只有183份。

用途歸納方法

先從具體任務歸納用途：例如開抽屜 / 收納歸居家、咖啡機 / 餐具歸餐飲、插栓 / 螺帽歸裝配。原作以基礎物件或運動目標為主時，歸通用作業；以協助人或交接為目標時，歸協作服務；以穿戴視角的人體動作訊號為目標時，歸動作介面。跨用途是正常的多重歸類，並不等於未分類。每個用途判定儲存任務例子、歸納理由與原文頁碼。

1. **先找任務、物件與目標**：把原文還原成「誰對什麼做什麼、完成什麼目標」。研究在模擬桌上進行，仍可由抽屜、餐具或裝配目標判斷用途。
2. **把任務歸到用途**：先歸納可辨認的生活 / 工作用途；若原作本來就是跨場域的基礎作業、陪伴交接或動作介面，使用有明確範圍的正式用途類別。
3. **按實際子集繼承**：LIBERO-Plus、MetaWorld+等先核對保留了哪些父任務，再繼承相應用途；不把父庫所有領域都搬給只用其中一小部分的工作。
4. **每筆保留理由並檢查完整性**：每個用途標籤都附任務 / 場景證據及頁碼。建置時檢查183份來源皆有歸類、所有類別皆有來源，新增來源缺判定時要求補完。

三類正式跨場域用途

- **通用物件與機動作業**：以搬移、抓握、對齊、作業復現、行走或平衡等目標構成的跨場域基礎作業與技能測試。 納入條件：原作具有明確的基礎作業目標，或其選用于集刻意測跨物件 / 機體的通用技能。 範圍：不因使用機器人或內含抓取動作就自動加入；單一用途的料理 / 實驗室流程仍以其目的歸類。
- **協助、交接與陪伴**：以人或協作者的需求、接收物品、共同時序、不中斷對方及持續陪伴為目標的服務。 納入條件：合作物件 / 需求 / 交接或陪伴關係是任務定義的一部分。 範圍：雙手或多個機器人本身不足以判定；依實際的互動服務目標歸納。
- **穿戴互動與動作介面**：利用穿戴視角的手部、人體、視線及移動訊號，支援動作輸入、AR / VR、操作意圖與人類到機器人的動作介面。 納入條件：輸出或主要資料直接描述姿態、動作、接觸、視線或互動動作訊號。 範圍：不因有ego視角就把所有影片QA一律歸入；仍須看具體輸出與用途。

原22份來源如何完成歸納

來源	本版用途	任務與歸納理由	原文依據
P058 EgoPAT3Dv 2	協助、交接與陪伴、穿戴互動與動作介 面	預測人手將接觸的位置，讓共享工作區的機 器人提前配合；同時是頭戴裝置的動作意圖 介面。	P058 PDF 1
P063 Meta- World	居家整理與清潔、餐飲與烹飪、工藝與 修繕、裝配與生產作業、休閒與運動、 通用物件與機動作業	50個任務已有明確的用途線索：家居裝置、 餐飲、修繕 / 裝配、球類操作，以及通用取 放。	P063 PDF 18；P063 PDF 18； P063 PDF 18；P063 PDF 18； P063 PDF 18
P065 CALVIN	居家整理與清潔、通用物件與機動作業	開抽屜、控制燈與把物件收好屬居家整理； 方塊轉動、推移與堆疊則保留為通用作業。	P065 PDF 3；P065 PDF 3
P073 RoboTwin	居家整理與清潔、餐飲與烹飪、工藝與 修繕、協助、交接與陪伴	從杯子擺放、蘋果收納、掃除、鎚擊與人際 互動資料歸納，保留每種用途所對應的任務 範圍。	P073 PDF 8；P073 PDF 5,8；P073 PDF 8
P103 Follow- Bench	包裝、倉儲與物流、個人照護、公共場 館與服務、協助、交接與陪伴	跟隨指定人是陪伴服務；原作亦明列照護、 巡邏、導覽與物流的應用方向。	P103 PDF 1,6；P103 PDF 1
P105 LIBERO- Plus	居家整理與清潔、餐飲與烹飪	LIBERO-Plus改變觀測與初態條件，未改掉 原任務的餐具擺放、廚房裝置及收納用途。	P105 PDF 2；P064 PDF 3,4
P106 MetaWorld+	居家整理與清潔、餐飲與烹飪、工藝與 修繕、裝配與生產作業、休閒與運動、 通用物件與機動作業	MetaWorld+保留原50項任務並修正版本和 評測協定，因此沿用具體任務支援的用途。	P106 PDF 4；P063 PDF 18；P063 PDF 18；P063 PDF 18；P063 PDF 18；P063 PDF 18
P115 RoboMME- Interference	裝配與生產作業、通用物件與機動作業	依示範選物、搬方塊、重畫路徑與插栓，歸 入通用作業復現與裝配基礎作業。	P115 PDF 2,3；P115 PDF 3
P146 DexH2R	協助、交接與陪伴	核心就是把人手中的物件交給機器人，歸入 協助與交接用途。	P146 PDF 1,3
P147 HRIBench	協助、交接與陪伴	按人的指令、時機和動作完成協作，涵蓋交 接、同步、讓行及受幹預後續作。	P147 PDF 3,4
P182 SoftVTBenc h	餐飲與烹飪、通用物件與機動作業	歸納為易損物取放的通用作業；烘焙品形狀 物件的放置情境另標餐飲處理方向。	P182 PDF 5,6；P182 PDF 5

來源	本版用途	任務與歸納理由	原文依據
P197 EgoSim / MultiEgoView	穿戴互動與動作介面	身體攝影機用來恢復使用者動作及支援互動輸入，歸入穿戴互動與動作介面。	P197 PDF 1,5
P198 TACO	居家整理與清潔、餐飲與烹飪、穿戴互動與動作介面	用原作工具—動作—物件組合歸納：倒液與攪拌屬餐飲，清潔器具屬居家，手物動作建模亦服務AR / VR介面。	P198 PDF 2,5；P198 PDF 2
P212 ARB4WM	居家整理與清潔、餐飲與烹飪、通用物件與機動作業	同時涵蓋物件操作與行走 / 平衡控制，歸入通用作業；門窗與咖啡 / 餐盤任務另標對應用途。	P212 PDF 8；P212 PDF 8
P214 COIN (interactive)	居家整理與清潔、餐飲與烹飪、通用物件與機動作業	開櫃、找書、操作微波爐都有可辨認用途；純互動推理與幾何控制題保留在通用作業。	P214 PDF 20,23；P214 PDF 4,17
P128 RoboNet	通用物件與機動作業	核心目標是把未知物件推或抓放到指定位置，歸入跨場域物件搬移作業。	P128 PDF 3,5
P193 GRIP	通用物件與機動作業	產生穩定抓握並預測物件受力，歸入通用抓取與易損物處理作業。	P193 PDF 4,5,6
P216 HAP	穿戴互動與動作介面	預測頭部轉向以看到被遮擋的操作目標，歸入穿戴觀察與動作介面。	P216 PDF 1,5
P222 Uni- Hand	居家整理與清潔、餐飲與烹飪、通用物件與機動作業、穿戴互動與動作介面	把手部預測連到互動介面與機器人示教；杯墊擺杯、蘋果入盤和盒子上架另提供餐飲 / 整理用途。	P222 PDF 9,10；P222 PDF 9,10
P224 EMPIRE	穿戴互動與動作介面	預測雙手未來動作並產生操作計畫，歸入穿戴互動與動作介面。	P224 PDF 1,4
P228 SFHand / EgoHaFL	居家整理與清潔、餐飲與烹飪、通用物件與機動作業、穿戴互動與動作介面	即時語言引導手部預測歸入動作介面；其Kitchen與Adroit下游評測另外歸納家居 / 餐飲與通用作業。	P228 PDF 1,5；P228 PDF 5
P230 EgoH4	穿戴互動與動作介面	包含視野外雙手的姿態與動作預測，歸入AR / VR等穿戴動作介面。	P230 PDF 1,2

如何把大而廣變成可發表的benchmark

先完成來源聯集，再擴充任務和規則。集合的上限不能由論文數推定，異質數字不相加。要證明比前作更廣、更大，須在相同任務粒度下報去重後任務數，並列各前作未覆蓋而本庫真正可評的用途、任務與規則。RoboVerse、OXE、OpenEgo等整合型前作必須直接比較。

環境、示範和評分器可以重用；新增目標、過程約束和介入條件要留下父任務與差異。每個case需要明確輸入、答案或goal predicate、split、版本及預算。不同機體或感測條件下使用分組榜單；問答、預測、規劃和物理控制的證據分開。

本輪是來源審閱與設計依據的完成，尚非通用benchmark全庫的實驗完成。接下來的論文證據應來自共同任務清單、有效case、可重現判分器與baseline結果。

難度量化

1. 先記可觀測條件：步驟/依賴數、物件幹擾、容許誤差、材料、遮擋、歷史長度、恢復和資訊預算。這些是條件，不預先加成一個任意難度分數。
2. 同一case固定split、observation/action與budget，選涵蓋不同能力的baseline，記逐case成功/誤差和重跑。用task/source/scene群聚bootstrap估計不確定性。
3. 在同輸出/判分協定內，以baseline成功率或相對誤差校準難度，報分佈與模型依賴。QA和物理控制不共用一條未驗證的分數尺。
4. 有足夠模型×題目矩陣後才試IRT或辨識度，檢查擬合、單調性和source依賴；用新模型驗證分級是否穩定。

Milestones

M1 來源閱讀與共同比較

本版250篇篩查、183份逐篇審閱、原文頁碼/單位/重用紀錄和五欄比較表。

驗收：所有原143來源有記錄，補入40來源；可重算分類分佈，未知與衝突公開。

狀態：本輪已完成，限現有書目範圍

M2 逐ID整理環境與任務聯集

取得各來源任務清單，保留source ID、version、split、資產引用；標示equivalent/derived/unresolved。

驗收：來源覆蓋率按183來源計；每筆任務有父來源和判分定義，不能僅比名稱。

狀態：已有部分清單；全庫去重尚未完成

M3 擴充任務與規則

針對已核來源新增必要過程、精度、安全、恢復、記憶與協作規則；逐條記錄相對父任務新增了什麼。

驗收：新增語義目標與新增測例條件分開計數；每個合法變體有可解性與evaluator驗證。

狀態：設計可據來源展開；未承諾固定題數

M4 建立可執行評測與論文證據

分問答、預測、規劃、控制輸出報分；固定觀測/動作/時間/抽樣預算，做來源與任務群聚切分。

驗收：公開case manifest與判分器，報subset實測及不確定性；以去重後覆蓋和新增任務證明規模優勢。

狀態：全庫尚未完成；既有小型實驗為工程附錄

逐篇來源紀錄

P100 BEHAVIOR-1K (2024)

原作：<https://arxiv.org/abs/2403.09227>

本次PDF：<https://arxiv.org/pdf/2403.09227v1>

PDF SHA256：ab4033f3e8a8187ad2cfd11f1979d33996ecce1e81fa3d62af33a92bbb17a2b

閱讀頁：1、2、3、4、6、7、20、24。人類需求survey、1K activity來源、scene/object表、BDDL與Transition Machine、baseline範圍。

- 研究型別：導航與家務執行；室內長流程操作
- 領域：居家整理與清潔、餐飲與烹飪、衣物與洗護、辦公與教育、零售與購物、農業與園藝
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：50scenes / 373rooms / 8scene types；包含house、garden、restaurant、office等；不能把rooms和scenes相加。
- 任務：1,000 BDDL activities = 人類需求排序選909 + 沿用BEHAVIOR100的91項；2,090是survey候選池，不是已實作任務。
- 題數 / 資料：程式生成滿足initial predicates的配置；原文baseline只實測CollectTrash、StoreDecoration、CleanTable三活動，非1,000活動全模型成績。
- 評估方式：success、goal score Q、時間、導航距離、擾動物件量。；低階RL與assistive grasp/teleport primitive分開；高分primitive不能代稱低階policy已解題。
- Split / 資訊條件：原文3活動實驗；初態生成規格與實驗seed / rollout需另外記錄。
- 來源關係：BEHAVIOR100的延伸；ATUS等time-use survey及WikiHow為活動來源。OmniGibson混用物理與temperature/烘焙等heuristic transition，非所有現象都是精密物理。
- 可復用：全庫廣度與生活活動規格的核心比較基準；新庫要提出超過其已有activity和規則的具體聯集。
- 待核 / 限制：全1K activities的去重semantic goal、可用資產及可解性應逐規格核，不用1K宣稱1K模型可評結果。

P082 RoboVerse (2025)

原作：<https://arxiv.org/abs/2504.18904>

本次PDF：<https://arxiv.org/pdf/2504.18904v1>

PDF SHA256：8c0cb543ef3f0c9a033f06cbbd73a86f2f1177029751e72e86a54d366c355008

閱讀頁：1、2、3、5、6、7、8、9、10、34。MetaSim架構、來源遷移全表、操作/導航/人形資料、4級泛化與實驗子集。

- 研究型別：一般操作 benchmark；跨資料集整合與評測方法
- 領域：居家整理與清潔、衣物與洗護、裝配與生產作業、通用物件與機動作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：操作多底座遷移；導航重用90個Matterport3D scenes；59camera候選不是59環境。

- 任務：表l遷移276 manipulation task categories，另導航 / 人形。RLBench取80、CALVIN7、LIBERO10等為其遷移子集，不是全源 benchmark相加。
- 題數 / 資料：510.5K manipulation trajectories、約5.5K assets；navigation另R2R10K、RxR20K episodes。主要IL表只評6個代表 task。
- 評估方式：統一success checker / success rate；L0 task-space、L1場景、L2camera、L3光照反射。；不同simulator的migration 成功不保證完全等價物理；需固定backend。
- Split / 資訊條件：原作90/10；主IL取10train設定+10validation設定，3seeds；OpenVLA另限制20test scenarios。
- 來源關係：直接整合ManiSkill、RLBench、CALVIN、MetaWorld、Robosuite/MimicGen、GAPartNet、Open6DOR、ARNOLD、LIBERO、SIMPLER、RLAfford、GraspNet、GarmentLab、UniDoorManip、GAPartManip；導航R2R/RxR、人形HumanoidBench 等。
- 可復用：本研究最重要的整合型比較物件之一；『把前作放一起』已有實作，新增貢獻要在coverage、規則、來源聯集與評估完整度。
- 待核 / 限制：276類是否存在跨源語義等價未在本文提供完整去重證據；需追MetaConfig IDs。

P071 RoboCasa365 (2026)

原作：<https://arxiv.org/abs/2603.04356>

本次PDF：<https://arxiv.org/pdf/2603.04356v1>

PDF SHA256：f3e6877b8de3dd471afb6951c1e067729e2a57c53fcb3d6daaa0f4af5080206b

閱讀頁：1、2、3、4、5、6、7、22。新舊資產、pretrain/target場景、365task組成、資料與eval。

- 研究型別：一般操作 benchmark；模擬操作benchmark
- 領域：居家整理與清潔、餐飲與烹飪
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：50新layouts×50styles=2,500 pretrain scenes；另10 target layouts各配一style=10 target scenes。2,500不是2,500 floor plans。
- 任務：365=65 atomic+300 composite；60活動歸6家族；220任務需mobile、145不需。主要target評測50任務=18 atomic+16 seen composite+16 unseen composite。
- 題數 / 資料：30K human pretrain+25K human target；60atomic各生成10K（600K synthetic）。target eval每task30trials；demo 量不算test題。
- 評估方式：task-specific binary success，per-task horizon；跨task平均。
- Split / 資訊條件：pretrain300task；target50含16個pretraining未見composite；場景 / style也分離。
- 來源關係：直接擴充RoboCasa；本文引述舊composite83是另一版本，不能覆蓋2024原文75。
- 可復用：是大規模廚房benchmark必要主比較；跨生活用途更廣與域內更大是兩項不同主張。
- 待核 / 限制：365全任務與本文pretrain/target資料實際涵蓋聯集需manifest核對；不能從『cover all』概述推論每task都有同量 demo。

P125 Open X-Embodiment (2023)

原作：<https://arxiv.org/abs/2310.08864>

本次PDF：<https://arxiv.org/pdf/2310.08864v9>

PDF SHA256 : 13f16aff5afdee583dc25b3c570e9bb0cf6baefb59b539928d919588cd8d9246

閱讀頁：1、2、3、4、6。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：機器人資料與通用策略；跨資料集整合與評測方法
- 領域：居家整理與清潔、餐飲與烹飪、通用物件與機動作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：60來源datasets、22embodiments；場所數由各dataset metadata而來，非60新環境。
- 任務：結論報527skills / 160,266tasks；方法用語言抽取skills，不能直接當160,266正規化goal definitions。
- 題數 / 資料：1M+robottrajectories；主RT-X混合只選9manipulators，非全22都等量實測。
- 評估方式：跨robot實機tasksuccess、OOD / emergent skills與移除Bridge對照。
- Split / 資訊條件：不同experiment的hosttask/robot子集不同；dataset-wide規模與policy實測範圍分開。
- 來源關係：整合既有datasets到RLDS；不統一所有action坐標，absolute/relative/velocity仍可能不同。
- 可復用：all-in-one最重要對照之一：我們不能以合併資料夾或粗7Dactionformat宣稱首次通用benchmark。
- 待核 / 限制：160,266的逐task IDs與同義/粒度規則未在已讀段完備；21institutions / 34labs的口徑也需保留。

P126 DROID (2024)

原作：<https://arxiv.org/abs/2403.12945>

本次PDF：<https://arxiv.org/pdf/2403.12945v2>

PDF SHA256 : 9e40a9c934ce78ea315d2c05593d60f9e18edf6dcd3785cd66439518965c3b07

閱讀頁：1、2、3、7。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：機器人資料與通用策略；真實操作benchmark
- 領域：居家整理與清潔、餐飲與烹飪、辦公與教育
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：564workspace scenes分52buildings；換物件擺位不增加scene。
- 任務：86是unique verb/task口徑；下游主實驗6tasks/4locations，不是全86實測。
- 題數 / 資料：76Kdemonstrations/350h；6task各50–150in-domain demos，混合DROID訓練。
- 評估方式：ID/OOD task success；nativepolicyrollouts分母需appendix/manifest另核。
- Split / 資訊條件：主task各有distractor/novelobject/cameravariation；不是564場所全部held-out驗證。
- 來源關係：新distributedcapture；DROID表I與RH20T用unique multi-view trajectory重算，不能代替RH20T原作報告數。
- 可復用：提供workspaces與objectrandomization的清楚環境定義；大資料與小評測子集須並列。
- 待核 / 限制：18researchlabs/13institutions/18robots是不同口徑；主規模不能稱86完整獨立工作流程。

P132 RT-1 (2022)

原作：<https://arxiv.org/abs/2212.06817>

本次PDF：<https://arxiv.org/pdf/2212.06817v2>

PDF SHA256 : 81efe669c8fa50ffc7097886dc78a442fa7a8f7f2451684b93069cb9fbeda767

閱讀頁：1、4、5、7、8、9。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：機器人資料與通用策略；通用策略的原作任務評測
- 領域：居家整理與清潔、餐飲與烹飪
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：Three environments：robotclassroom與兩個realofficekitchens；13robots不是13獨立場景。
- 任務：Table1有744language instructions，依verb分skill；不等同744工作家族。
- 題數 / 資料：約130Kdemonstrations；主seen>200instructions、unseen21、robustness30/22、long15；全研究>3,000trials。
- 評估方式：task SR與SayCan長流程成功；architectures在相同RT1資料重訓。
- Split / 資訊條件：novelinstructions保持object/skill可在別的training組合看過；OOD場景另列。
- 來源關係：自收Google/EverydayRobot資料，後被OXE/其他策略重用。
- 可復用：說明前作也能有數百instructiontasks；比較規模必須對齊語義粒度。
- 待核 / 限制：>3,000是跨method/condition執行次數；不能當3,000獨立test cases。

P063 Meta-World (2019)

原作：<https://arxiv.org/abs/1910.10897>

本次PDF：<https://arxiv.org/pdf/1910.10897v2>

PDF SHA256 : 8ea4fd9e7a2f7a2cfc475ae7e7021e7a6c03b99ae3932b455def9197ff1197e8

閱讀頁：1、4、5、6、7、12。50任務定義、觀測 / 動作 / reward及MT / ML協定。

- 研究型別：一般操作 benchmark；模擬操作benchmark
- 領域：居家整理與清潔、餐飲與烹飪、工藝與修繕、裝配與生產作業、休閒與運動、通用物件與機動作業
- 用途歸納：50個任務已有明確的用途線索：家居裝置、餐飲、修繕 / 裝配、球類操作，以及通用取放。
- 環境：50個task environment配置，共用Sawyer桌面；不能解讀為50種生活場域。
- 任務：50個非引數性操作型別；原文又把位置 / goal引數化例項稱task，需保留兩種含義。
- 題數 / 資料：MT10含10環境×50引數配置=500；MT50為50×50=2,500訓練task instances。這不是500 / 2,500個新語義任務，也不是正式test QA。
- 評估方式：各task成功predicate / 目標距離門檻，success與dense reward分開。
- Split / 資訊條件：MT同已見任務學習；ML10 / ML45各有5保留task適應；ML1只在同一task變換50train / 50test goal。
- 來源關係：MuJoCo、Multiworld及Gym介面；後續MetaWorld+等為其擴充，不可把上游再次全加。
- 可復用：提供桌面操作任務底座；位置擴樣容易，生活用途拓寬有限。
- 待核 / 限制：不同v1 / v2 / 後續release成功predicate細節與本地歷史pilot須以commit分開。

P062 RLBench (2019)

原作：<https://arxiv.org/abs/1909.12271>

本次PDF：<https://arxiv.org/pdf/1909.12271v1>

PDF SHA256：fbb04509bea7bf6aa9b97b07c46d95e5c1a900987599693b3fae3fd84377db76

閱讀頁：1、3、4、5、6、7。原生task / variation / episode定義、scene、成功條件與few-shot協定。

- 研究型別：一般操作 benchmark；模擬操作benchmark
- 領域：居家整理與清潔、通用物件與機動作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：共用1個Panda桌面scene，載入各task資產；API的TaskEnvironment不等於獨立房間。
- 任務：原文100手寫task，每task多variation（如目標色彩 / 物件），每variation再抽初態episode。
- 題數 / 資料：episode / demo可隨機生成，原文沒有固定全庫題數；few-shot原版10%任務meta-test，1 / 5 / 20 demonstrations是每任務支援樣本預算。
- 評估方式：task-specific success conditions，完成才給+1 sparse reward；few-shot在新episode報success。；demo生成器通過驗證不代表學習策略已成功。
- Split / 資訊條件：原版90% tasks train、10% unseen tasks test；每次測試不能先知未見task規則。
- 來源關係：V-REP / PyRep / OMPL；大量後續benchmark重用其task、資產和成功predicate。
- 可復用：可直接作任務來源與擴充規則底座；task、variation、episode原作已有清楚先例。
- 待核 / 限制：後續版本的task總量與常用18-task子集要另附commit，不能用來改寫2019原文。

P064 LIBERO (2023)

原作：<https://arxiv.org/abs/2306.03310>

本次PDF：<https://arxiv.org/pdf/2306.03310v2>

PDF SHA256：ff7d943e2eb37760df684f3ae2931a5a35ef8ea465bd387e62afe49507b8e414

閱讀頁：1、2、3、4、5、6、9、10。任務生成、PDDL goals、4 suites、lifelong指標及pretraining切分。

- 研究型別：一般操作 benchmark；模擬操作benchmark
- 領域：居家整理與清潔
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：Robosuite場景配置；layout / objects由PDDL定義，本文已讀段落未報去重layout總數。
- 任務：130 = Spatial10 + Object10 + Goal10 + LIBERO100；LIBERO100內90短程預訓練 + 10長程。LIBERO-Long不是再額外增加10。
- 題數 / 資料：各task有human demos與隨機初態評估；可生成不代表固定無限題庫已釋出。
- 評估方式：全部goal predicates為真才成功；以success計forward transfer、negative backward transfer、AUC。
- Split / 資訊條件：lifelong順序學task，過往資料限制；90→Long10預訓練與Spatial/Object/Goal控制變因是不同協定。
- 來源關係：明確由Ego4D語言behavior templates生成task instructions，實作建於Robosuite；已是人類程式到robot benchmark的先例。
- 可復用：與本研究來源聯集主線高度相關；新貢獻需超過同類模板生成與桌面範圍。
- 待核 / 限制：各發布demo / init-state精確ID數需對照版本，不從別篇約5K反推。

P068 ManiSkill3 (2024)

原作：<https://arxiv.org/abs/2410.00425>

本次PDF：<https://arxiv.org/pdf/2410.00425v2>

PDF SHA256：0482cef460af5ca0dd09d2b1d0f499b996287d9dadec31b13ca60377a49ee80c

閱讀頁：1、3、4、6、7、8、21、22、28。12種型別、平臺與task生成、效能和learning評測段落。

- 研究型別：一般操作 benchmark；模擬平臺與任務套件
- 領域：居家整理與清潔、裝配與生產作業、通用物件與機動作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：GPU異質並行模擬；1024平行instances / cameras是執行規模，非1024不同生活場景。
- 任務：原作12 task categories包含tabletop/mobile、room-scale、locomotion、bimanual、multi-agent、drawing/cleaning、dexterous、tactile、classic control、digital twins、soft-body；這12類不是12生活domain。
- 題數 / 資料：擴充套件中的環境登錄檔與demo來源，無單一固定全庫test題數；例如SIMPLER轉接4種環境。
- 評估方式：task success / return、sample efficiency與wall-clock分開；渲染FPS / VRAM是系統效能，非任務成功率。；本文GPU rasterization與IsaacLab ray tracing比較非完全同畫質，原作有明示。
- Split / 資訊條件：不同RL / IL / VLA / sim2real設定各有來源；應固定demo數、生成方式與控制器。
- 來源關係：ManiSkill2平臺與任務延伸，另接SIMPLER等；不能把platform release當完全獨立benchmark family。
- 可復用：可作執行底座；廣泛技術支援不等同每種生活用途已有完整任務與cases。
- 待核 / 限制：目前API註冊task總量隨版本變動，需固定commit再盤點；本文不提供永續固定總數。

P074 RoboTwin 2.0 (2025)

原作：<https://arxiv.org/abs/2506.18088>

本次PDF：<https://arxiv.org/pdf/2506.18088v2>

PDF SHA256：316ae82a97968e1a2d88540665401645a190d2699d7d8652e8fc0053ba609bda

閱讀頁：1、2、3、6、10、11、19。MLLM產生器、物件庫、50task benchmark、Easy/Hard及real驗證。

- 研究型別：一般操作 benchmark；模擬與真實操作benchmark
- 領域：居家整理與清潔
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：雙臂桌面程式配置；Easy/Hard為clutter / 光照 / texture / 高度分佈，不是兩個生活domain。
- 任務：50 benchmark tasks；另外真實實驗4task×4conditions；RoboTwin-OD 147類731物件。
- 題數 / 資料：每task50 clean train demos，測試100rollouts於Easy/Hard條件；真實測試training另10real+1,000synthetic。
- 評估方式：simulation / real task success；Easy和Hard分開。；MLLM observer的failure detection / localization是產生器輔助診斷，不能替代所有物理success checker。
- Split / 資訊條件：single-task training，Easy到Hard分佈外；DP3在模擬可得完美point clouds / clean segmentation，跨方法需標明。

- 來源關係：RoboTwin延伸，Rodin資產、skill API和sim-in-loop expert生成。
- 可復用：可借雙臂流程與有物理回饋的產題；50task不因兩種難度變成100語義task。
- 待核 / 限制：100rollouts的公開seed列表與兩條件是否完全對應需eval script核。

P143 PARTNR (2024)

原作：<https://arxiv.org/abs/2411.00081>

本次PDF：<https://arxiv.org/pdf/2411.00081v1>

PDF SHA256：7da62f6f2b031d78908d6f063d44b6eae491bb31d03536218f6ee61dd300efd

閱讀頁：1、2、3、4、5、6、7、8、24、40。生成與評分完整章、原生100K口徑、types、split、generation audit及agent資訊條件。

- 研究型別：輔助與協作；對話協作與任務完成
- 領域：居家整理與清潔、餐飲與烹飪、協助、交接與陪伴
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：60HSSD houses (37train/13val/10test)，5,819OVMM objects；與其他HSSD來源重用。
- 任務：4非互斥特性：constraint-free/spatial/temporal/heterogeneous；原作task以unique scene-goal pair計，100K不是100K語義family。
- 題數 / 資料：本文100,000train+1,000val+1,000test；全val/test及2Ktrain人工審核。固定公開HF檔案本庫實數111,652train+1,000val是另一版本，不能覆蓋本文或補造test。
- 評估方式：完整state sequence檢查propositions、dependencies、temporal/same-argument/terminal constraints；PC、success、failure explanation。；中央/分散、partial/full、oracle/learned skills、privileged/perceived graph分開評。
- Split / 資訊條件：source houses互斥；支援human-only技能差異；生成時會排除不能做的摺衣。
- 來源關係：Habitat3/HSSD/OVMM底座；1K人工seed衍生100K。原文generation audit約90%instruction、92%evaluator、83%joint，與本庫舊92.5%小試作無關。
- 可復用：為十萬級rule-conditioned episodes及共同協作評測的關鍵前作；數量比較須用scene-goal案例粒度。
- 待核 / 限制：本文某處稱全tasks HITL，統計處實際描述val/test+2Ktrain審核，應按具體audit範圍理解。；HF公開版本無test素材；111,652只是該快照metadata實數。

P199 OpenEgo (2025)

原作：<https://arxiv.org/abs/2509.05513>

本次PDF：<https://arxiv.org/pdf/2509.05513v1>

PDF SHA256：84068f8b5d7e8add70826aacda59a02d425f56125bcf3f1c450fe966db7f7e65

閱讀頁：1、2、3、4。六來源表、hand/primitive統一、實際0.1%子集實驗和held-out metric。

- 研究型別：人類影片與動作資料；整合型人類影片資料與預測benchmark
- 領域：居家整理與清潔、穿戴互動與動作介面
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：作者列10kitchens與610indoor rooms / 600+environments；是多來源合併，未證明全庫去重。

- 任務：290 source task labels = 六來源原生task數相加；不等於290正規化機器人目標。
- 題數 / 資料：1,107h、344.5K recordings、119.6M frames；實驗只train在0.1%子集，10% demonstrations held-out，精確eval IDs/分母需核。
- 評估方式：AED/FED/DTW只算可見hand joints；8/16/32/64 frames horizons。未測robot physical task success。
- Split / 資訊條件：作者稱demonstration-level holdout 10%，但0.1%子集與holdout母集合關係需ID核。
- 來源關係：CaptainCook4D、HOI4D、HoloAssist、EgoDex、HOT3D、HO-Cap；語言多自動生成且部分人工核，新增的是統一label/format。
- 可復用：最直接的整合資料前作之一；我們必須清楚提出超出統一格式的task聯集與評測規則。
- 待核 / 限制：跨來源環境/task去重未完成；data aggregation不可與父來源再次加總。

P002 HowTo100M (2019)

原作：<https://arxiv.org/abs/1906.03327>

本次PDF：<https://arxiv.org/pdf/1906.03327v2>

PDF SHA256：f55dbcb6598acecdedd0178243457eed6daf14626744e9bc50b0622cdbf58894

閱讀頁：1、2、3、4、5、6。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：人類影片與動作資料；人類程式影片與步驟定位
- 領域：餐飲與烹飪、辦公與教育、工藝與修繕、個人照護、交通移動與車輛維修、農業與園藝、休閒與運動、寵物照護與動物活動
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：YouTube instructional/vlog等影片；12 WikiHow用途類別，不是12個物理場景。
- 任務：23,611 visual tasks是WikiHow搜尋活動標籤，未正規化成robot goals。
- 題數 / 資料：1.22M影片 / 136.6M弱配對clip-caption；本庫主要供pretraining，下游評CrossTask等既有benchmark。
- 評估方式：下游step recall、retrieval R@K/median rank；非136.6M人工驗證評測題。
- Split / 資訊條件：移除CrossTask test與YouCook2 val重複video IDs；仍可能有重上傳內容。
- 來源關係：WikiHow活動×YouTube搜尋；片段共享長影片，後續world-model/ego conversion又會重用。
- 可復用：是擴大生活/工作用途的重要來源；活動標籤、可觀測步驟及robot可執行目標需逐層轉換。
- 待核 / 限制：原作抽400pairs僅51%至少一項提及與畫面吻合；不能直接將全部字幕當程式ground truth。

P119 EgoDex (2025)

原作：<https://arxiv.org/abs/2505.11709>

本次PDF：<https://arxiv.org/pdf/2505.11709v3>

PDF SHA256：7ea269e5885392e65a7e206c2d6b5792022ec499367a070c2c269cbcf187e2b8

閱讀頁：1、2、3、4、5、6、7、8。194tasks資料、reset類別、48D action表示、兩benchmark、1%split與best-of-K。

- 研究型別：人類觀測到機器人轉移；人類示範與技能轉移
- 領域：居家整理與清潔、衣物與洗護、裝配與生產作業、穿戴互動與動作介面

- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：tabletop錄製；原文明示場景多樣性不是重點，沒有獨立layout總數。
- 任務：194human manipulation tasks；3種reset型別；正式兩端點為未來手軌跡及給future goal圖的inverse dynamics。
- 題數 / 資料：338,000episodes、829小時、約90Mframes；每task抽1%為held-out，不把90Mframes等同90Mtest題。
- 評估方式：12個wrist/fingertip keypoints的平均 / 終點Euclidean error，best-of-K (1/5/10)，分H=1/2/3秒。；人手預測誤差不是robot任務完成率；給future image的inverse dynamics資訊更強。
- Split / 資訊條件：主test為每task1%同分布；未見task另附錄，不可把主結果稱OOD。
- 來源關係：新Apple headset錄製；部分task來自FurnitureBench等型別，但非同robot軌跡。
- 可復用：大量靈巧行為、工具與衣物候選；轉成robot benchmark需具體goal/初態與evaluator對應。
- 待核 / 限制：精確split episodes及同session相依關係需manifest；ARKit confidence為追蹤品質非真物理成功。

P150 DreamDojo (2026)

原作：<https://arxiv.org/abs/2602.06949>

本次PDF：<https://arxiv.org/pdf/2602.06949v1>

PDF SHA256：c8f02e22c8fbe98e0b50215e10e1f6baf2f589b1987e5c6dc07175bfe6fe8587

閱讀頁：1、2、4、5、8、9、10。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：世界模型與預測表示；世界模型與影片生成評測
- 領域：居家整理與清潔、辦公與教育、工藝與修繕、裝配與生產作業、零售與購物、交通移動與車輛維修
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：Table1的1.135M scenes與正文9,869unique scenes不一致；暫不取其中任一為去重環境總量。
- 任務：6,015skills/tasks由GPT對globalcaptions估計；6個generation evalsets非6生活domains。
- 題數 / 資料：DreamDojo-HV43,827h，加入in-lab55h/EgoDex829h後44,711h；多數eval100samples，兩個image-edited sets各25。
- 評估方式：PSNR/SSIM/LPIPS；editedsets無配對futureGT，12volunteers做physics/action-following偏好比較。
- Split / 資訊條件：humanpretrain後robotposttrain，GR1是主要驗證平臺；counterfactual與backgroundedit分項。
- 來源關係：EgoDex + in-house；和EgoScale的scene/task/object統計一致是待核同源線索，非已證實完全相同。
- 可復用：規模非常大的world-model資料來源；不能把44K人類影片小時或生成視覺評分當作可執行task庫。
- 待核 / 限制：1.135M scene與9,869scene粒度矛盾；表中其他前作hours也不可代替原始論文校核。

P120 EgoScale (2026)

原作：<https://arxiv.org/abs/2602.16710>

本次PDF：<https://arxiv.org/pdf/2602.16710v1>

PDF SHA256：39c691baf374a154e26ffc0098b97037875909495013d4017d97761716ff2735

閱讀頁：1、3、4、6、7。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：人類觀測到機器人轉移；人類示範與技能轉移
- 領域：居家整理與清潔、衣物與洗護、辦公與教育、裝配與生產作業、零售與購物、實驗室操作
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：作者報9,869scenes的人類影片；語義場所/影片scene定義及與其他corpora交集待核。
- 任務：人類6,015task labels、對齊midtraining344tabletop tasks；主實機只5dexterous goals。
- 題數 / 資料：報告20,854hpretraining，並使用EgoDex829h（不另外相加）；midtrain50human/4hrobot；下游每task100robotdemos，shirt20。
- 評估方式：whole-task SR、fine-grained completion；兩trainingseeds、通常每checkpoint/task10trials。
- Split / 資訊條件：分大規模人類pretrain、配對midtrain、下游posttrain；非zero-robot-data。
- 來源關係：EgoDex與in-house資料；場景/task/object統計與DreamDojo相同數字，不能假定是獨立新增corpus。
- 可復用：人類資料規模的必要對照；要分6,015訓練標籤、344對齊任務與5實測目標。
- 待核 / 限制：protocol稱TaskIII每bottle16trials，但tasklist瓶蓋是TaskIV，需manifest釐清。

P181 RoboFoldX (2026)

原作：<https://arxiv.org/abs/2609.10243>

本次PDF：<https://arxiv.org/pdf/2609.10243v2>

PDF SHA256：b7760baa843b43e164d224d5132fc13f534cb5e4bd834d7276340ee3f7d65553

閱讀頁：1、3、4、5、6、7。資料來源、四track、完整摺疊流程、30實機回合及FoldScore。

- 研究型別：布料 / 柔性物操作；柔性物操作benchmark
- 領域：居家整理與清潔、衣物與洗護
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：多個真實robot平臺/場景，10+embodiments；精確獨立工作站數未報。
- 任務：資料20+tasks；主摺疊評測4類衣物Shirt/Skirt/Pants/Towel，涵蓋取出、翻整、攤平、摺疊和堆疊。
- 題數 / 資料：2,000+hours實機資料；主評測每衣物類別30trials，完整workflow須無人工介入。
- 評估方式：SR、成功回合時間、0–5neatness由至少2評者一致評分。FoldScore組合品質35%、可靠性35%、速度30%。
- Split / 資訊條件：recovery、cross-task、cross-scene、cross-embodiment四tracks；場景泛化不能只用主4類成績代表。
- 來源關係：多robot原始收集與統一格式；長workflow可切subtasks，切片不能再視為獨立長示範。
- 可復用：提供完整衣物處理流程、人工外觀品質與自動成功率並列的設計。
- 待核 / 限制：2,000+hours對應的unique episode IDs及工作站去重需要資料manifest；複合分數權重不是通用難度尺。

P213 Vision to Harvest (2026)

原作：<https://arxiv.org/abs/2609.13606>

本次PDF：<https://arxiv.org/pdf/2609.13606v1>

PDF SHA256：b3ee03d5d25e728c85d714de947fb09d06f56e94067923961d75c365281c22eb

閱讀頁：1、2、3、4、5、6。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：一般操作 benchmark；專業場域規劃benchmark
- 領域：農業與園藝
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：Fuji apple及citrus orchard RGB-D資料；citrus父庫432images，實際held-outscene數未報。
- 任務：multi-armCartesian fruit harvesting的offlineallocation/waypointplanning；apple/citrus兩作物設定。
- 題數 / 資料：每crop共用同一held-outimage集合；未報可核固定題數，不能將父庫432全填成eval cases。
- 評估方式：detection/harvested ratio、arm-order violation、pathdistance/token成本；harvested其實是waypoint距離門檻0.25/0.5/1m。
- Split / 資訊條件：zeroshot同prompt；沒有線上replanning或真的摘果控制。
- 來源關係：既有果園資料+新plan/verifier；collision指order違反，非完整動力學碰撞檢查。
- 可復用：補農業用途與多臂分配，但轉成執行benchmark仍需assets、接觸和摘取驗收。
- 待核 / 限制：exactevalsceneIDs未報；高harvestedratio不可當物理摘取成功。

P001 VLOG (2017)

原作：<https://arxiv.org/abs/1712.02310>

本次PDF：<https://arxiv.org/pdf/1712.02310v1>

PDF SHA256：914ea812883827c588beaafa23c52688332eff8824bb54128a2a9ec92331d3ac

閱讀頁：1、3、4、5、6、7、8。正文資料蒐集、標註、benchmark 與探索實驗章節；未逐行審閱模型訓練附錄。

- 研究型別：人類影片與動作資料；影片資料與感知評測
- 領域：居家整理與清潔
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：網路生活影片中的自然場景；沒有可直接計數的模擬 layout 清單。365 是外部場景分類器類別，不能當環境數。
- 任務：30 個物件接觸二元分類；8 類手部 / 人物狀態分類及未來狀態預測。這些是感知標籤與評測問題，不是30個機器人操作任務。
- 題數 / 資料：114K 影片、219K 抽樣影格的手部狀態標註；原作分 uploader 做50/25/25切分。156K 影格另用於未來手位置探索實驗。
- 評估方式：物件接觸：逐類 AP / mAP。；手狀態：分類 accuracy，現在及未來6 / 12 / 30 / 60影格分開。；未來手位置的156K影格探索實驗不等於正式的獨立機器人 benchmark。
- Split / 資訊條件：依 YouTube uploader 分50% train / 25% validation / 25% test，避免同一上傳者跨 split。
- 來源關係：影片自行蒐集自 YouTube；與 COCO、Charades 的類別交集不表示共用全部資料。
- 可復用：可提供生活操作與接觸 / 預測題型；轉成機器人控制題仍需資產、狀態及成功條件。
- 待核 / 限制：影片可下載現況、精確公開split檔案數尚未逐檔核對。

P003 COIN (2019)

原作：<https://arxiv.org/abs/1903.02874>

本次PDF：<https://arxiv.org/pdf/1903.02874v1>

PDF SHA256 : 4625e83e6d9eaecd1acdfb5c39fa7132bbe4c4c6a58e541473c24c9f738f6762

閱讀頁：1、3、4、5、7。資料定義、階層分類、標註規模、切分與評測章節。

- 研究型別：人類影片與動作資料；人類程式影片與步驟定位
- 領域：居家整理與清潔、餐飲與烹飪、工藝與修繕、個人照護、交通移動與車輛維修、休閒與運動
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：YouTube 教學影片；原作12 domains是活動分類，未提供12個物理環境。
- 任務：原作階層為12 domains、180人類程式任務、778步驟定義。180個活動可作任務候選，不能直接當已實作的robot task。
- 題數 / 資料：11,827影片、46,354步驟片段、476小時；影片split為9,030 train及2,797 test。
- 評估方式：步驟時段定位，以 temporal IoU 0.1–0.5 的 mAP / mAR 衡量。
- Split / 資訊條件：9,030 train / 2,797 test；不可把46,354步驟片段全稱為test題。
- 來源關係：YouTube 影片與人類程式階層；與其他網路教學資料可能影片重疊，尚無逐video ID跨庫去重。
- 可復用：可引入來源有據的180項程式及778步驟；需另審機器人可行性與每一步的判分。
- 待核 / 限制：完整12個原作domain到共同領域的逐條對映需保留原生label清單。；跨資料集YouTube ID重疊未核。

P004 CrossTask (2019)

原作：<https://arxiv.org/abs/1903.08225>

本次PDF：<https://arxiv.org/pdf/1903.08225v2>

PDF SHA256 : 1613d28f8d75e86ceedd8b6f2a9c2a4bbf29e5ee8485026bfc7be29826ae7632

閱讀頁：1、2、5、6、14。資料建立、主要 / 相關任務定義、原作主評測，追讀附錄評分。

- 研究型別：人類影片與動作資料；人類程式影片與步驟定位
- 領域：餐飲與烹飪、工藝與修繕、交通移動與車輛維修
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：wikiHow程式及YouTube影片；沒有原生物理場景ID總數。
- 任務：83個程式 = 18個主要評測任務 + 65個相關支援任務；主實驗不能寫成83個同地位測試任務。
- 題數 / 資料：約4.7K影片；正文列主要任務212小時、相關任務161小時。每輪主要任務test為1,850影片。
- 評估方式：主指標step recall：每步只預測一個位置，落在GT時間段才正確。；20次隨機切分的平均；附錄另報mAP，不能把附錄指標冒充唯一主指標。
- Split / 資訊條件：每個主要任務每輪30訓練影片；固定每任務20驗證影片不進train/test；其餘1,850影片測試；重複20次。
- 來源關係：wikiHow中篩選程式，YouTube蒐集影片；相關任務篩除以影片重疊判定的近重複。
- 可復用：18個評測程式與65個支援程式分開引入；程式步驟可以對映機器人規格，但影片切分不能直接沿用作實體控制題。
- 待核 / 限制：前文376小時與正文212 + 161小時口徑不完全一致，暫保留原文各自約數。；4.7K總量尚未以發布清單精確重算。

P005 YouCook2 (2017)

原作：<https://arxiv.org/abs/1703.09788>

本次PDF：<https://arxiv.org/pdf/1703.09788v3>

PDF SHA256：4ef636404bea37184e1fa056fa2a71a92705a1b3bc4ee58917a11806de17fbe3

閱讀頁：1、2、3、4、7、8。YouCook2資料、標註、split、程式分段與proposal評測。

- 研究型別：人類影片與動作資料；人類程式影片與步驟定位
- 領域：餐飲與烹飪
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：自然料理影片；非4個物理場景。Africa / Americas / Asia / Europe是料理來源分類。
- 任務：89道食譜；benchmark要求定位程式步驟及描述。食譜、步驟、影片為不同層次。
- 題數 / 資料：2,000影片、176小時；每道食譜按67 / 23 / 10%分train / val / test。
- 評估方式：程式分段：Jaccard及mean IoU。；proposal：IoU 0.5下precision / recall / F1，與整體程式分段分開。
- Split / 資訊條件：每食譜67 / 23 / 10%；本文百分比不自行換算成精確發布ID數。
- 來源關係：YouTube教學影片；與其他料理影片庫的原始video重疊需逐ID核對。
- 可復用：可提供料理程式與步驟語言；不能直接把2,000影片列為2,000robot任務。
- 待核 / 限制：發布版本精確split ID數及素材可得性尚未逐檔核。

P006 Breakfast (2014)

原作：https://openaccess.thecvf.com/content_cvpr_2014/html/Kuehne_The_Language_of_2014_CVPR_paper.html

本次PDF：https://openaccess.thecvf.com/content_cvpr_2014/papers/Kuehne_The_Language_of_2014_CVPR_paper.pdf

PDF SHA256：79ea90c0870d5e1e29b880a953555fe8d9dbd2b825f0f46e13d28d51c33e138f

閱讀頁：1、3、5、6。Breakfast資料、動作階層、資料切分及語法式識別實驗。

- 研究型別：人類影片與動作資料；人類程式影片與步驟定位
- 領域：餐飲與烹飪
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：18個真實廚房；每處3–5臺相機，視角不增加廚房數。
- 任務：10個料理活動、48個coarse action units；活動與動作單元分開。
- 題數 / 資料：52參與者、約77小時、超過400萬影格；11,267個action-unit samples包含約3,600個silence samples。
- 評估方式：動作序列unit accuracy及逐frame recognition accuracy；grammar解析與flat grammar比較。
- Split / 資訊條件：4組參與者輪替訓練與測試；不能把多視角同次活動當獨立受試者。
- 來源關係：自行錄製；文中ADL等外部對照數字不是Breakfast規模。
- 可復用：可引入早餐程式及分層步驟；18廚房是影片錄製環境，非可下載互動layout。
- 待核 / 限制：後續常用發布版本的影片 / 片段數與本文單位可能不同，不能直接混寫。

P007 Charades-Ego (2018)

原作：<https://arxiv.org/abs/1804.09626>

本次PDF：<https://arxiv.org/pdf/1804.09626v2>

PDF SHA256：138cfb582bdf3ab17fb6aa3ad7f3dd09505f4410e6c31fd486f2aaf1c35beaf1

閱讀頁：1、2、3。短文3頁全文，聚焦配對蒐集、來源重疊及評測。

- 研究型別：人類影片與動作資料；影片資料與感知評測
- 領域：居家整理與清潔
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：112個家、112位演員；第一 / 第三人稱依相同指令碼重演，非同步錄製的精確配準視角。
- 任務：157個activity classes；監督及zero-shot第一人稱動作識別。
- 題數 / 資料：6,167 train影片 + 1,693 test影片 = 7,860視角影片；兩種視角各34.4小時；68,536動作標註。
- 評估方式：video-level mAP；監督與zero-shot設定分別報告。
- Split / 資訊條件：參與者不跨train/test；視角影片數不直接改稱獨立活動episode。
- 來源關係：78.7%指令碼取自Charades train，另增1,000指令碼；與Charades有明確指令碼來源關係。
- 可復用：適合跨視角語義轉移；不能把配對當作同步3D重建或robot軌跡監督。
- 待核 / 限制：逐配對ID與上游Charades指令碼ID尚未在本庫去重。

P008 EGTEA Gaze+ (2018)

原作：https://openaccess.thecvf.com/content_ECCV_2018/html/Yin_Li_In_the_Eye_ECCV_2018_paper.html

本次PDF：https://openaccess.thecvf.com/content_ECCV_2018/papers/Yin_Li_In_the_Eye_ECCV_2018_paper.pdf

PDF SHA256：aa3d3ec1981ea4b1b430c3712e3f56d851ac8173cfc5a9db797478cf4d4e3454

閱讀頁：1、9、10、11。資料與benchmark章、凝視與動作識別評測。

- 研究型別：人類影片與動作資料；影片資料與感知評測
- 領域：餐飲與烹飪
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：自然廚房料理錄製；本文未在已讀段落提供獨立廚房總ID數。
- 任務：7個meal preparation tasks、106個action classes；凝視估計和動作識別為兩個端點。
- 題數 / 資料：本文報29小時、86 sessions、32人、10,321動作樣本；首split為8,299 train / 2,022 test。
- 評估方式：凝視估計：precision / recall / F1，忽略無追蹤與saccade影格。；動作識別：mean class accuracy，clip與video層次分開。
- Split / 資訊條件：首split 8,299 / 2,022；評分時fixation採8影格聚合，保留原協定。
- 來源關係：EGTEA相關後續版本常報28小時或10,325片段；本筆不以別篇的數字覆蓋所讀PDF。
- 可復用：適合視線、動作與料理先後關係題；sessions不是互動環境數。
- 待核 / 限制：公開資產版本與後續10,325片段口徑需另核對。

P009 EPIC-KITCHENS (2018)

原作：<https://arxiv.org/abs/1804.02748>

本次PDF：<https://arxiv.org/pdf/1804.02748v2>

PDF SHA256：2b7fe522827a041638ef2d3b27c9508ace434bd504e22c3e3d43894ea144b7a7

閱讀頁：1、3、10、11、12、13、14、15。資料蒐集與詞彙、split、物件偵測、動作識別及anticipation完整評測章節。

- 研究型別：人類影片與動作資料；影片資料與感知評測
- 領域：居家整理與清潔、餐飲與烹飪
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：32位參與者 / 32個廚房；S2保留4位參與者的未見廚房。
- 任務：3個端點：active-object detection、action recognition、action anticipation；§3.4詞彙125 verbs / 331 nouns，詞彙數不是機器人任務數。
- 題數 / 資料：55小時、39,596動作片段、454,255物件框；同一片段可支援不同端點，不能把三種端點直接乘成獨立題。
- 評估方式：偵測：mAP，IoU 0.05 / 0.5 / 0.75。；識別與anticipation：verb / noun / action各報top-1、top-5及per-class precision / recall。；anticipation觀測1秒，截止於動作開始前1秒；與看到整段動作的recognition分開。
- Split / 資訊條件：S1已見廚房按完整sequence約80/20切分；S2保留4位參與者 / 廚房。各端點可評類別又有最少訓練樣本門檻。
- 來源關係：為EPIC-KITCHENS-100、VISOR、EPIC Fields等後續來源的上游家族；不得把共用影片 / 廚房重複相加。
- 可復用：可引入物件、操作與短期預測題型；原生語言動作類別需另對齊正式robot goal與判分。
- 待核 / 限制：各原生split精確可下載ID數未以本版manifest重算。；表中與正文不同聚合詞彙口徑應保留版本，不能混加。

P010 EPIC-KITCHENS-100 (2020)

原作：<https://arxiv.org/abs/2006.13256>

本次PDF：<https://arxiv.org/pdf/2006.13256v4>

PDF SHA256：2ad975f70d5b074a2b2616960bb53410a6d66ce973346284574e7b49684ab629

閱讀頁：1、2、4、5、6、7、9、10、11、12、13。資料延伸與表1、六個challenge的定義及評測段落。

- 研究型別：人類影片與動作資料；影片資料與感知評測
- 領域：居家整理與清潔、餐飲與烹飪
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：45個錄製環境；包含2018影片與新錄影片，不能和EPIC 2018廚房量直接相加。
- 任務：6個challenge：全監督 / 弱監督動作識別、偵測、anticipation、跨年無監督適應、跨模態檢索。97 verbs、300 nouns、4,053 action classes不是4,053個實體操作goal。
- 題數 / 資料：700影片、89,977動作段；train / val / test動作段67,217 / 9,668 / 13,092；檢索採公開val，另有專用UDA切分。
- 評估方式：識別top-1 / top-5 accuracy；偵測mAP於temporal IoU 0.1–0.5。；anticipation以動作開始前1秒為截止，class-mean top-5 recall。；檢索用mAP及nDCG；UDA保留2018→2020的來源 / 目標域設定。
- Split / 資訊條件：主影片495 / 138 / 67；test皆新錄影片。主split、UDA、retrieval評測集合不可混為一個test量。

- 來源關係：2018上游影片重新標註，89,977為新版本總量；其約66M masks及手 / 物框多為自動產生，非同量人工評測題。
- 可復用：可復用同一生活影片家族的多端點評測；必須以共用影片與split lineage控制洩漏。
- 待核 / 限制：公開manifest與此PDF版本的精確ID差異尚未逐檔重算。

P011 EPIC-KITCHENS VISOR (2022)

原作：<https://arxiv.org/abs/2209.13064>

本次PDF：<https://arxiv.org/pdf/2209.13064v1>

PDF SHA256：912638891fd5608d681de38f6e902f5caa0b4a1925c4b22ffb564b92d69701c9

閱讀頁：1、3、4、6、7、8、9、10、25。資料 / split表與3個benchmark定義、主要metric；附錄標註品質段落。

- 研究型別：人類影片與動作資料；影片資料與感知評測
- 領域：居家整理與清潔、餐飲與烹飪
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：42個EPIC廚房；為上游環境子集，不是新增42個互動場景。
- 任務：3個challenge：VOS、手物關係分割、Where Did This Come From。最後一項有15種來源容器，非15個生活domain。
- 題數 / 資料：179 untrimmed影片、50,729人工標註影格、271,584人工mask；9.9M為篩過的插值mask。WDTCF另有222測試query，取自92影片。
- 評估方式：VOS用Jaccard J及boundary F；只追第一影格已指定物件。；HOS用COCO mask AP，手側別、接觸與active object分開。；WDTCF用來源分類accuracy、證據影格及mask IoU；錯誤證據影格使IoU為0。
- Split / 資訊條件：train / val / test影片115 / 43 / 21，影格32,857 / 7,747 / 10,125；保留未見廚房子集。WDTCF為222題test-only taster。
- 來源關係：直接標註EPIC-KITCHENS-100影片；自動插值從14.5M過濾為9.9M，不能當9.9M獨立人工標籤。
- 可復用：補充物件變形、接觸及來源追溯題；同一影片不能重算為新增環境。
- 待核 / 限制：各VOS subsequence發布ID與影片父ID的完整對映尚未匯入。

P012 HD-EPIC (2025)

原作：<https://arxiv.org/abs/2502.04144>

本次PDF：<https://arxiv.org/pdf/2502.04144v2>

PDF SHA256：d3648a8692d038cad2027290facf25c9f5d8ff12b65f912f4dc6d99b99118092

閱讀頁：1、5、6、7、28。資料與數位廚房、VQA建立 / 評測、recognition、長期VOS附錄。

- 研究型別：人類影片與動作資料；影片問答與推理
- 領域：居家整理與清潔、餐飲與烹飪
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：9個新錄廚房，413個fixture數位模型；fixture不是413個環境。
- 任務：69食譜；VQA以7類註記建立30種問題prototype，另有動作 / 聲音識別和長期VOS。

- 題數 / 資料：正式VQA為26,650道五選一題；100,000是作者估計可生成上限，不是發布題數。VOS另為1,000序列 / 20,548標註影格；41.3小時為原始影片長度。
- 評估方式：VQA報各prototype accuracy後分群平均，5選1；包含blind language基線。；VOS用J / F / J&F；recognition沿用EPIC100訓練權重，在新影片評估。
- Split / 資訊條件：定位為新資料上的validation / zero-shot benchmark；沒有依一般80/10/10重新分配。人類基線只抽600題。
- 來源關係：與EPIC系列研究相承但此批影片新錄；使用EPIC100模型訓練來源。數位副本不自動具備機器人物理 / 判分介面。
- 可復用：提供比粗動作標籤更細的食譜、營養、3D、物件動態、視線問答；是可借鑑的多端點設計。
- 待核 / 限制：原生數位副本的互動物理完整性、本庫素材取得與逐題manifest尚未核對。

P013 Ego4D (2021)

原作：<https://arxiv.org/abs/2110.07058>

本次PDF：<https://arxiv.org/pdf/2110.07058v3>

PDF SHA256：d33d9e7a1d4a93ab8e9137e62966b3e2b7d631f4c5b98e481f6fc2220739c2fc

閱讀頁：1、6、7、8、9、24、29、30、48、49、70、71、72、73、75、77、79。正文五大benchmark全段；附錄資料split、episodic memory規模、short / long anticipation協定與統計。

- 研究型別：人類影片與動作資料；綜合第一人稱資料與評測
- 領域：居家整理與清潔、餐飲與烹飪、工藝與修繕、零售與購物、交通移動與車輛維修、農業與園藝、休閒與運動、社交與溝通、穿戴互動與動作介面
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：74個全球location / 9國；location不是去重後可載入場景ID。VQ3D專用子集另只使用4個掃描。
- 任務：5大benchmark：episodic memory、手物狀態變化、影音說話者、社互動動、forecasting。MQ有110活動類別，NLQ有13模板；都不是整個Ego4D的domain / 任務總量。
- 題數 / 資料：3,670小時、931佩戴者為資料規模。NLQ約19.2K query (test約4K)；VQ 22,602 query；MQ 22.2K活動例項；short anticipation 64,798樣本 (test 19,780)。各端點母影片重疊，不能相加為獨立episode。
- 評估方式：NLQ用recall@k / tIoU；MQ用mAP與recall；VQ用時空AP及搜尋效率。；PNR用秒級絕對時間誤差、狀態分類accuracy、物件偵測AP。；說話者追蹤 / diarization / 轉錄用MOT、speaker error、DER、WER；社交LAM / TTM用mAP、accuracy。；forecasting：軌跡 / 手部位置誤差；short anticipation top-5 mAP；long anticipation以20步序列edit distance等設定報告。
- Split / 資訊條件：同family內一致 (forecasting與hands共用；memory內共用)，不同family不保證同一切分。NLQ約60/20/20；forecasting原協定40/30/30，另有locomotion切分。test標註及相交narrations不公開。
- 來源關係：上游多機構錄製資料；EgoSchema / EgoPlan等後續題庫常重用它。主表與附錄部分過濾前後數字不同，保留端點與版本。
- 可復用：是跨日常場域及過去 / 現在 / 未來題型的重要上游；覆蓋廣度和正式robot控制任務量需分開。
- 待核 / 限制：不同端點的跨family影片洩漏需逐ID審核。；本文內MQ表3與過濾後表8、forecasting110.5 / 120小時等口徑不能靜默合併。

P014 Ego-Exo4D (2023)

原作：<https://arxiv.org/abs/2311.18259>

本次PDF：<https://arxiv.org/pdf/2311.18259v4>

PDF SHA256 : 15e31586e111eb32fe54131840b7733b095fb3b20bebb14be9610d11967e26a8

閱讀頁：2、4、6、10、19、24、25、28、30、36、38、39、41、42、44、69、73、74。資料、8場域、benchmark總表、關係 / keystone / procedure / 熟練度 / pose評分及切分附錄。

- 研究型別：人類影片與動作資料；綜合第一人稱資料與評測
- 領域：餐飲與烹飪、個人照護、交通移動與車輛維修、休閒與運動、音樂與表演、穿戴互動與動作介面
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：123個自然scene、13城市；多臺ego / exo相機同步錄同take，視角不增加場景或活動次數。
- 任務：8原生domains、43活動、689 keystone為整體概述；keystone標註子集17活動 / 664標籤，正式識別過濾後278葉節點。4大 benchmark family內含跨視角關係、程式、熟練度、3D姿態等端點。
- 題數 / 資料：整體1,286小時、5,035 takes（概述）；附錄切分列5,045 takes，須查版本差異。keystone識別130,979視角片段，test 33,001，其中ego 6,373。不能用全部14M自動 / 人工姿態影格替代題數。
- 評估方式：跨視角mask用visibility accuracy / IoU / 位置誤差；生成視角另有生成metric。；keystone recognition top-1 accuracy；程式前置 / 可選 / 錯誤 / 缺步 / 後續步用calibrated AP。；熟練程度用top-1；指導 / 正確執行時刻用L1時間門檻mAP。；人體用MPJPE、MPJVE；手部用MPJPE及PA-MPJPE；人工GT與自動GT分開。
- Split / 資訊條件：以take及participant保持互斥，衍生片段繼承父take；附錄列3,082 train / 842 val / 1,121 test。procedure測試 graph及標籤不公開。
- 來源關係：獨立同步多視角蒐集；同take的多視角和多端點共用來源。本文提醒v1過時，不能混用v1 / v2數字。
- 可復用：可擴充套件維修、照護、運動、音樂與熟練度；多數為人類技能觀測，轉成robot執行規格須另定機體與成功條件。
- 待核 / 限制：概述5,035與附錄5,045 takes相差10，待manifest核對。；整體689與keystone子集664不能視為同口徑。

P015 Assembly101 (2022)

原作：<https://arxiv.org/abs/2203.14712>

本次PDF：<https://arxiv.org/pdf/2203.14712>

PDF SHA256 : f115520e2f1cb8ec65ecf3e197be18dd91e8f34b1ee58fcb36d18e1346d24c1e

閱讀頁：1、3、4、5、6、7、8、15。蒐集、粗細動作統計、split及四端點實驗。

- 研究型別：人類影片與動作資料；人類程式影片與步驟定位
- 領域：裝配與生產作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：固定多視角錄製配置；8外部 + 4ego相機不是12個環境。
- 任務：101種take-apart玩具，15玩具類別；202粗動作、1,380細動作標籤；4端點為識別、預測、分段、錯誤偵測。
- 題數 / 資料：362次拆裝sequence，產生4,321視角影片、513視角小時；1,013,523細片段及104,759粗片段含多視角重複。
- 評估方式：識別top-1；提前1秒預測用class-mean top-5 recall。；分段MoF / edit / F1@10,25,50；錯誤 / corrective分類precision與recall，early模式只看半段。
- Split / 資訊條件：60/15/25%；有seen / unseen玩具，25玩具跨split；視角與片段應繼承原sequence。
- 來源關係：自行蒐集；多視角是同次拆裝，不能用4,321宣稱同量獨立任務。其細標籤與3D手pose專用表又有不同子集。
- 可復用：可引入裝配依賴、順序變化、犯錯與糾正；應保留玩具、步驟、觀測端點三層單位。

- 待核 / 限制：資料表中姿態專用1,456標籤與一般1,380標籤的完整對映待manifest核對。

P016 IKEA ASM (2020)

原作：<https://arxiv.org/abs/2007.00394>

本次PDF：<https://arxiv.org/pdf/2007.00394v2>

PDF SHA256：5869f1542aa7372df85b6b4006127599aba58b0364d546d963dff8a3876080af

閱讀頁：1、3、4、5、6、8。資料與split、動作 / 分割 / 追蹤 / 姿態評分段落。

- 研究型別：人類影片與動作資料；人類程式影片與步驟定位
- 領域：居家整理與清潔、裝配與生產作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：5個真實環境，桌上 / 地上共10相機配置；3臺同步RGB相機。
- 任務：4種傢俱（side table、coffee table、TV bench、drawer）與原子裝配動作；不是1,113個任務。
- 題數 / 資料：371次assembly，1,113 RGB視角影片及371 depth影片；本文16,764動作標註；254 train / 117 test assembly scans。
- 評估方式：動作frame accuracy、macro-recall、mAP。；零件分割與MOT分開；追蹤MOTA、IDF1、IDs等。；3D姿態用MPJPE / PA-MPJPE、PCK@150mm。
- Split / 資訊條件：按環境保留family room與office測試；作者明示此主split不保證subject同時互斥，另提供其他切分指令碼。
- 來源關係：自行錄製；空間標註僅1%影格人工，餘下有pseudo-GT；不可把全部影格稱人工標註。
- 可復用：傢俱裝配與部件追蹤來源；環境泛化與受試者泛化要分開報。
- 待核 / 限制：原子動作label完整清單與不同年份發布版本尚未逐ID對齊。

P017 HOI4D (2022)

原作：<https://arxiv.org/abs/2203.01577>

本次PDF：<https://arxiv.org/pdf/2203.01577v4>

PDF SHA256：82c5f0bf505f59eed426c1efa03f12a4155a5e18416ff03477d9e25c301be74f

閱讀頁：1、2、7、8。資料概述與三個benchmark完整定義 / 主要評分。

- 研究型別：人類影片與動作資料；影片資料與感知評測
- 領域：居家整理與清潔
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：610個室內rooms（錄製環境）；4個參與者，不是610個已接入互動模擬器。
- 任務：16物件類別、800例項；3端點：category-level pose tracking、4D segmentation、action segmentation。pose實驗只取4剛體+1關節類別。
- 題數 / 資料：4,000 sequences、2.4M RGB-D影格；4D分割專用376影片 / 14語義類別，不能把全資料量當每個端點實測量。
- 評估方式：pose：5°5cm accuracy、旋轉 / 平移誤差；以擾動GT pose初始化。；4D分割mIoU；動作分段Acc、edit、F1@10/25/50。

- Split / 資訊條件：4D sequence隨機7:3 train/test；不等同未見房間或受試者切分。
- 來源關係：自行蒐集RGB-D及模型；NOCS / H2O / GTEA是外部對照，不屬本庫量。
- 可復用：補充物件 / 材質 / 房間變化和3D感知；原文明示未覆蓋雙手操作。
- 待核 / 限制：610 rooms的逐ID清單與可用重建品質未匯入。

P018 HOT3D (2024)

原作：<https://arxiv.org/abs/2411.19167>

本次PDF：<https://arxiv.org/pdf/2411.19167v2>

PDF SHA256：cbe0c55d8c952c673dbff8633b5f23eb87963f7cf09429416eb2f1ac58236232

閱讀頁：1、3、4、5、6、7。資料、有效標註與subject切分、手 / 物追蹤、分割與3D lifting。

- 研究型別：人類影片與動作資料；影片資料與感知評測
- 領域：居家整理與清潔、餐飲與烹飪、辦公與教育、穿戴互動與動作介面
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：同一mocap lab中的4種情境佈置：inspection、kitchen、office、living room；不是4處獨立真實住宅。
- 任務：33剛體物件；手pose、物件6DoF pose、in-hand分割、3D位置lifting。
- 題數 / 資料：833分鐘、1.5M多視角timestamps / 3.7M images；其中1.16M timestamps有效完整。HOT3D-Clips為3,832 clips = 2,804 train + 1,028 test。
- 評估方式：手部MKPE毫米誤差；物件pose以對稱性處理後平移 / 旋轉門檻recall。；in-hand mask mIoU；lifting用位置門檻recall。物件pose實驗提供GT mask，並非端到端自由偵測。
- Split / 資訊條件：13名受試者train、6名test，test GT走伺服器；部分評測每30影格取一。
- 來源關係：新錄Aria / Quest3資料。EgoHOS與UmeTrack為跨資料對照；部分baseline的400K Aria訓練圖是私有資料，不可算HOT3D公開題。
- 可復用：提供可靠3D接觸 / 姿態參考；可控場景多樣性與感測視角多樣性應分開。
- 待核 / 限制：正文425 recordings與198 Aria + 226 Quest3相差1，需manifest釐清。

P019 EgoBody (2021)

原作：<https://arxiv.org/abs/2112.07642>

本次PDF：<https://arxiv.org/pdf/2112.07642v3>

PDF SHA256：2e3713a6294f2f6db2fb815fc25f0ce080ce1fec87b663ccac54ff669c7de501

閱讀頁：1、2、4、6、7、8、9、10、11、12。互動分類、capture、資料與split、3DHPS metric。

- 研究型別：人類影片與動作資料；人體與互動感知評測
- 領域：休閒與運動、社交與溝通、穿戴互動與動作介面
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：15個室內scene，有掃描mesh；每次兩人互動，一人佩戴HoloLens2。

- 任務：5種社會互動分類用於蒐集；主benchmark為interactee的3D人體形狀 / 姿態估計，不是5個機器人任務。
- 題數 / 資料：125 sequences / 36人；219,731多視角timestamps、199,111 ego影格；可見interactee子集175,611影格，其中62,155 test。
- 評估方式：MPJPE、vertex-to-vertex error；pelvis translation alignment與Procrustes alignment分開。
- Split / 資訊條件：subject不重疊；interactee train / val / test = 90,124 / 23,332 / 62,155。
- 來源關係：自行蒐集；同時有MVSet、EgoSet、可見interactee三個相依子集，不能相加。
- 可復用：補社互動動、遮擋與人體觀測；不提供完成生活工作的robot action evaluator。
- 待核 / 限制：掃描資產是否可直接用於互動模擬未驗證。

P020 EgoHumans (2023)

原作：<https://arxiv.org/abs/2305.16487>

本次PDF：<https://arxiv.org/pdf/2305.16487v2>

PDF SHA256：7d7f42b85231561ddb1a646fefbdec9fe97bc1e02455d7603006aa7ceac3de30

閱讀頁：1、2、6。資料統計、test切分、tracking評測與主端點定義。

- 研究型別：人類影片與動作資料；人體與互動感知評測
- 領域：休閒與運動、社交與溝通、穿戴互動與動作介面
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：6個地點 = 3室內 + 3室外；7個活動sequence，20人，多人同時戴Aria。
- 任務：籃球、擊劍、羽球、網球、排球、追逐、搭城堡；主要3D多人追蹤，並提供2D/3D姿態與mesh。
- 題數 / 資料：125K ego RGB、250K灰階、446K外部影像；正式ego train77,260 / test47,740 images。
- 評估方式：CLEAR追蹤指標（MOTA、FP、FN、IDs）、IDF1、HOTA；因主要使用off-the-shelf detector，以IDF1作主要tracking指標。
- Split / 資訊條件：train/test地點不重疊；同步多人的多視角不能視為獨立活動。
- 來源關係：新蒐集多視角；COCO用於模型訓練對照，不算本benchmark題數。
- 可復用：拓展戶外多人互動感知；不能直接宣稱涵蓋同量可執行robot工作任務。
- 待核 / 限制：各附加pose / mesh端點是否有獨立正式leaderboard與有效ID需另查。

P021 Ego-ExoLearn (2024)

原作：<https://arxiv.org/abs/2403.16182>

本次PDF：<https://arxiv.org/pdf/2403.16182v3>

PDF SHA256：bca30af05c678a221e17c8ff0fa92006870fc0b46f569e824b52c98aefc8a15b

閱讀頁：1、2、3、4、5、6、7、8、11、12、14、16。資料 / 來源、四大benchmark、association、anticipation / planning、skill，及專用split附錄。

- 研究型別：人類影片與動作資料；跨視角程式學習

- 領域：餐飲與烹飪、實驗室操作
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：4個廚房+3個lab；ego示範跟做與exo教程非同步、非同一環境。
- 任務：8程式=5日常+3實驗室；4大benchmark含association、action understanding、skill ranking、captioning；39粗步驟，planning取27類；anticipation取19 verbs / 31 nouns。
- 題數 / 資料：432 ego影片96.5小時+315 exo影片23.5小時；34,239有效skill比較對，從40,191候選對篩選。ego anticipation test約17.3K片段。
- 評估方式：association：20候選top-1；anticipation：1秒前class-mean top-5 recall。；planning：8步ED@K、5條預測序列；skill：pairwise ranking accuracy；supervised recognition：macro mAP。
- Split / 資訊條件：端點採專用過濾集；保留ego→exo、exo→ego、UDA、distillation、co-training不同資訊條件。
- 來源關係：日常exo取網路影片，lab exo由資深人員錄製；動詞 / 名詞taxonomy借Ego4D再擴充，不表示影片皆來自Ego4D。
- 可復用：對示範到robot的跨視角程式轉移很相關；實驗室程式補生活操作庫缺域。
- 待核 / 限制：captioning及segmentation專用metric / 完整case ID仍需資料端核對。；附錄planning兩組split重複寫egocentric，保留原文歧義，未擅改。

P022 CaptainCook4D (2023)

原作：<https://arxiv.org/abs/2312.14556>

本次PDF：<https://arxiv.org/pdf/2312.14556v4>

PDF SHA256：03be2a06a5c5cc778808214ae9232f3156dfd3ba60c07140d93d1a20222cc0ae

閱讀頁：1、2、3、4、5、6、7、8、9、38。採集、錯誤taxonomy、三大benchmark定義及評測。

- 研究型別：人類影片與動作資料；錯誤辨識與程式恢復
- 領域：餐飲與烹飪
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：10個真實廚房，8名參與者；Hololens2與GoPro同步。
- 任務：24個WikiHow食譜、7種錯誤：準備、測量、技術、時間、溫度、缺步、順序；錯誤類別不另算7生活domain。
- 題數 / 資料：384 recordings、94.5小時、5.3K步驟標註及10K細動作標註；細動作只在約20%資料標註。錯誤有刻意誘發及自然發生。
- 評估方式：錯誤辨識accuracy / precision / recall / F1 / AUC；step與recording split分開。；multi-step localization及RobustMSL用mAP、R@K、temporal IoU；只正常資料訓練、正常 / 錯誤資料測試分列。；procedure learning沿EgoProceL採步驟precision / recall / IoU。
- Split / 資訊條件：error recognition有step / recording split；MSL有不同泛化split，不能把step split成續當跨錄影泛化。
- 來源關係：新錄影片，程式取WikiHow；procedure基線與評分沿EgoProceL，不是重用其全部素材。
- 可復用：可具體借用規則違反與near-failure定義；觀測到錯誤不等於機器人已能執行恢復。
- 待核 / 限制：各原生split精確ID數尚未匯入；錯誤組合空間只被部分取樣。

P023 EgoProceL (2022)

原作：<https://arxiv.org/abs/2207.10883>

本次PDF：<https://arxiv.org/pdf/2207.10883v1>

PDF SHA256：533531617781659b6d42cbb81529f76f79277cb3cf1d05dad3504547b4ecdf9a

閱讀頁：1、3、4、5、6、8、9、10。資料選取與聯集、procedure問題、key-step排序、評測協定。

- 研究型別：人類影片與動作資料；人類程式影片與步驟定位
- 領域：餐飲與烹飪、工藝與修繕、裝配與生產作業、農業與園藝
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：來源資料場景混合；沒有共同去重的獨立環境總數。
- 任務：16個程式，平均8.7 key-steps；含料理、玩具機車、搭帳篷、PC組裝 / 拆解。
- 題數 / 資料：62小時、130人；原作文末在已讀統計表給單一可評test題總數。
- 評估方式：Hungarian matching後按每個key-step計frame precision / recall / F1 / IoU再平均，避免背景與長步驟壟斷分數。
- Split / 資訊條件：採task-specific self-supervised procedure learning設定；K是模型key-step數超引數，不是資料集總任務量。
- 來源關係：明確重用CMU-MMAC、EGTEA Gaze+、MECCANO、EPIC-Tents，再增自錄PC裝拆；不是全新獨立62小時。
- 可復用：是從既有程式資料聯集再補缺域的直接先例；我們須說明新增任務 / 規則，不能把聯集本身當全部新貢獻。
- 待核 / 限制：所有影片ID、跨上游重複量和各task可評片段數需manifest核對。

P024 EPIC Fields (2023)

原作：<https://arxiv.org/abs/2306.08731>

本次PDF：<https://arxiv.org/pdf/2306.08731v2>

PDF SHA256：c7c08e1c9614782d2dcddaeec95b253c5d9f756ff2c4d30b712bcac6a90eebd

閱讀頁：1、2、3、5、6、7、8、22。重建覆蓋、三個benchmark、難度與frame切分。

- 研究型別：人類影片與動作資料；3D場景與世界建模
- 領域：居家整理與清潔、餐飲與烹飪
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：EPIC100的45個廚房；671影片成功重建，沒有新增671個獨立layout。
- 任務：D-NVS新視角合成、UDOS動態 / 半靜態物件分割、VOS；不是671個操作任務。
- 題數 / 資料：18,790,333已註冊camera-pose影格；D-NVS只取50影片（14.7小時、2.86M註冊影格）。
- 評估方式：D-NVS：PSNR，前景 / 背景分列；UDOS：segmentation mAP；VOS沿VISOR。；難度依in-action/out-of-action及與train frame的時間距離；hard、medium排除附近1秒train frame。
- Split / 資訊條件：每影片val/test交替抽樣；UDOS無監督可看全影片，不是D-NVS同一可見輸入。
- 來源關係：EPIC100 + VISOR的相機與幾何擴充，來源影片 / mask共用。
- 可復用：提供3D / 視角 / 動態物件評測；重建相機軌跡不是robot action軌跡。
- 待核 / 限制：50個benchmark video-scenes與原廚房一對多關係待逐ID匯入。

P025 EgoPet (2024)

原作：<https://arxiv.org/abs/2404.09991>

本次PDF：<https://arxiv.org/pdf/2404.09991v1>

PDF SHA256：8be645841806230228c292995eb6538540f9be6d228b916b37e53fefeeca59ca

閱讀頁：1、2、4、5、6、7、8、9、10。資料、3種預測端點、各自標註與指標。

- 研究型別：人類影片與動作資料；動作與軌跡預測
- 領域：寵物照護與動物活動
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：動物網路影片無去重場景總量；VPP額外robot測試有office、park、beach三處。
- 任務：VIP互動辨識 / 17種互動物件；LP預測未來4秒40個位置；VPP預測terrain latent的過去 / 未來。
- 題數 / 資料：6,646片段、84小時；VIP 1,449標註片段 = 754train+695test；LP 6,126train / 249val；VPP另20分鐘robot測試。
- 評估方式：VIP：accuracy / AUROC及object top-1/top-3；LP：ATE / RPE的RMSE；VPP：latent MSE。
- Split / 資訊條件：三端點分開train/test或val；LP為SLAM pseudo-GT且有人工篩選，非mocap真值。
- 來源關係：TikTok / YouTube新整理；VPP訓練另用既有robot資料，不能把動物影片數算為robot控制題。
- 可復用：補充低視角移動與人以外的具身感知；與操作benchmark應分層比較。
- 待核 / 限制：正文819原影片與482+338的平臺分量不一致，待manifest釐清。

P026 EgoHOS (2022)

原作：<https://arxiv.org/abs/2208.03826>

本次PDF：<https://arxiv.org/pdf/2208.03826v1>

PDF SHA256：94b61333b3477ef582a94281cc28852c750d6fbe096ddfe90c9434ca39101f07

閱讀頁：1、2、4、5、6、9、10、12。來源、手物標籤定義、OOD測試與主要分割評估。

- 研究型別：人類影片與動作資料；影片資料與感知評測
- 領域：居家整理與清潔、餐飲與烹飪
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：Ego4D、EPIC、THU-READ及自錄GoPro多來源；無共同scene ID總數。
- 任務：左 / 右手、左 / 右 / 雙手接觸物分割；直接 / 間接接觸有標註，但本文主要評估直接接觸。
- 題數 / 資料：原作總量11,243影像；OOD另500影格來自30個YouTube影片，主分割實驗預設在此測試。
- 評估方式：mIoU；binary hand、left/right hand、hand+arm、held-object等標籤定義分開比較。
- Split / 資訊條件：以原作validation選checkpoint，500-image OOD為另列測試；不能把源影片數當測試題數。
- 來源關係：直接重用Ego4D、EPIC影格；跨庫去重需frame時間戳。
- 可復用：可作接觸判定與視覺狀態監督；11,243不是11,243項可執行操作。
- 待核 / 限制：正文來源分量7,458+2,121+806+350未加總為11,243；subjects/activity的表格與敘述亦互換，暫不採這兩項總數。

P027 EgoPCA (2023)

原作：<https://arxiv.org/abs/2309.02423>

本次PDF：<https://arxiv.org/pdf/2309.02423v1>

PDF SHA256：b1562d6e36e0c788642711c6bcd038ed83e381ad8f9ae62cc5e341ee516c0a39

閱讀頁：1、2、4、5、6、8、14。One4All來源統一、取樣、表2與原生識別評測；附錄類別合併。

- 研究型別：人類影片與動作資料；跨資料集整合與評測方法
- 領域：居家整理與清潔、餐飲與烹飪
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：來源影片混合，不提供新的可計數互動環境。
- 任務：EPIC100、EGTEA、Ego4D-AR、Something-Else合併語義；pretrain394類、test204類，聯集401類含zero-shot。
- 題數 / 資料：表2列pretrain20K / 30K / 50K；test3K / 5K / 10K為巢狀子集，不能相加成18K獨立題。
- 評估方式：top-1 verb/action accuracy；另用語義、手 / 物位置、手姿、camera motion、模糊程度分析分佈。
- Split / 資訊條件：上游train與val/test分開抽；不同規模套件彼此包含。
- 來源關係：本身就是多來源語義合併與平衡取樣先例；沒有將所有源任務轉成robot控制。
- 可復用：對任務聯集、分佈分析、平衡取樣直接相關；須辨識此類前作，不能只與單域benchmark比規模。
- 待核 / 限制：§3.4提5K / 10K / 20K但表2及附錄為3K / 5K / 10K；採表2口徑並保留衝突。

P028 EgoSchema (2023)

原作：<https://arxiv.org/abs/2308.09126>

本次PDF：<https://arxiv.org/pdf/2308.09126v1>

PDF SHA256：4ae865287c1d40b806c5f51e4b5101fe90f7d246a201668f14bbb9cab00b442f

閱讀頁：1、2、3、5、6、7、9、14。資料生成與人工過濾、temporal certificate定義、評測與datasheet精確量。

- 研究型別：理解、推理與規劃；影片問答與推理
- 領域：居家整理與清潔、餐飲與烹飪、工藝與修繕、農業與園藝
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：Ego4D影片子集，未另外提供去重後環境數。
- 任務：長影片五選一QA；temporal certificate量必要證據時長，不能把3分鐘輸入長度直接當難度。
- 題數 / 資料：5,063題，每題一段3分鐘影片；約250小時為衍生片段量。
- 評估方式：選項accuracy；人類時間 / 影格受限條件另列。；QA人工過濾要求至少30秒certificate，與完整3分鐘影片長度區分。
- Split / 資訊條件：本文定位zero-shot診斷評測；公開標籤子集與完整隱藏評測需依發布版本另外核對。
- 來源關係：Ego4D非重疊3分鐘片段產題，與其他Ego4D衍生QA仍可能共用上游影片。
- 可復用：可借certificate、人類驗證和blind基線衡量時間推理難度；不評機器人實際完成。
- 待核 / 限制：本庫未逐ID對齊所有Ego4D衍生benchmark。

P029 EgoThink (2023)

原作：<https://arxiv.org/abs/2311.15596>

本次PDF：<https://arxiv.org/pdf/2311.15596v2>

PDF SHA256：f52b14647c715c4187f0f53bb90bde9e7d6f2f5d10eefc5da2a39b714076e040

閱讀頁：1、2、3、4、5、6、13、14。人工QA蒐集、700題統計、六能力十二維度、judge協定。

- 研究型別：理解、推理與規劃；影片問答與推理
- 領域：居家整理與清潔、餐飲與烹飪、工藝與修繕
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：595個Ego4D母影片；scene統計是語義場景如kitchen，不能當相同數量的獨立物理房間。
- 任務：6能力 / 12細分維度：物件、活動、定位、推理、forecasting、planning；輸入為單張影像。
- 題數 / 資料：700影像QA，無重複選圖；每維度至少50題，activity與forecasting各100。
- 評估方式：GPT-4依問題、答案、reference打0 / 0.5 / 1分；是模型評審分數，不是精確答案匹配accuracy。
- Split / 資訊條件：zero-shot評測；無一般train/val/test訓練配額。人工審核QA與後續模型judge分開。
- 來源關係：抽Ego4D影格，最多同video兩張；能力分類不等同生活domain分類。
- 可復用：可借主觀 / 開放答案rubric；planning問答不能當作控制成功證據。
- 待核 / 限制：跨庫母影片重疊及judge版本穩定性需實作端固定。

P030 EgoPlan-Bench (2023)

原作：<https://arxiv.org/abs/2312.06722>

本次PDF：<https://arxiv.org/pdf/2312.06722v3>

PDF SHA256：c15ca6dd2823dc0af2a6f55ce15cae49463268b814075cc9260e0d79ba751373

閱讀頁：1、2、3、5、6、7、14。資料來源、goal到QA、統計、選項評分、instruction-tuning資料區別。

- 研究型別：理解、推理與規劃；影片問答與推理
- 領域：居家整理與清潔、餐飲與烹飪
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：原作報419 scenes（影片觀測場景），非419個已建模robot layouts。
- 任務：下一步planning QA；表2合計3,269 task goals與3,185候選action plans，兩者不等同題數。
- 題數 / 資料：4,939評測QA = 3,355 val + 1,584 test；50K EgoPlan-IT是另外訓練集，非50K測試題。
- 評估方式：MC accuracy；部分開放模型以候選答案條件likelihood排序，需保留不同推論介面。；觀測只可到下一動作開始前；歷史狀態不能洩漏GT下一步。
- Split / 資訊條件：EgoPlan-Val / EgoPlan-Test；EgoPlan-IT僅用EPIC來源，以Ego4D子集查跨資料泛化。
- 來源關係：EPIC-KITCHENS與Ego4D的衍生QA；不可與上游影片或EgoPlan2直接加成獨立新活動。
- 可復用：提供goal / 歷史 / 當前觀測→下一步的可用題型；不同goal文字仍須做語義等價審核。

- 待核 / 限制：正文3,296 goals與表2的3,269相差27；採表2數字且保留差異。；419 scenes的跨影片物理等價關係未核。

P031 EgoPlan-Bench2 (2024)

原作：<https://arxiv.org/abs/2412.04447>

本次PDF：<https://arxiv.org/pdf/2412.04447v2>

PDF SHA256：86d13b4d204df0eee1eec14c5a5dde9f3cdc465b7e5b96009d4d8b7f4c48f353

閱讀頁：1、2、3、4、5、6、7。4 domains / 24 scenarios清單、goal過濾、觀測選取、MC評分。

- 研究型別：理解、推理與規劃；影片問答與推理
- 領域：居家整理與清潔、餐飲與烹飪、工藝與修繕、零售與購物、實驗室操作、個人照護、交通移動與車輛維修、農業與園藝、休閒與運動
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：24個語義scenario類別，非24個物理scene；來源1,113個Ego4D影片。
- 任務：4原生domains (Work / Daily life / Hobbies / Recreation)；保留4–20步的goal；284 goal verbs不是284個正式任務。
- 題數 / 資料：1,321道四選一QA；比第一版題少但原作場域更廣，兩種尺度要分開。
- 評估方式：直接匹配A/B/C/D計accuracy；原作不引入第三方LLM judge。
- Split / 資訊條件：評測用QA；原作觀測篩選以排除單張即可答與已洩漏動作的影格。
- 來源關係：Ego4D更新版衍生；與第一版方法相承，但不是在同一題集上直接擴成更大數量。
- 可復用：其24 scenario清單是廣度候選的重要依據；不能拿少量QA即宣稱域內所有任務已覆蓋。
- 待核 / 限制：task-goal語義去重與跨EgoPlan版本同源query重疊未逐ID核。

P032 EgoTaskQA (2022)

原作：<https://arxiv.org/abs/2210.03929>

本次PDF：<https://arxiv.org/pdf/2210.03929v1>

PDF SHA256：9a06fc9a9cfb5e7102f62ff34137fd261251eb9bd7c19ec19b07d4b8f36b5e87

閱讀頁：1、2、4、5、6、7、8、10。LEMMA狀態 / 因果標註、QA生成、兩種split與metric。

- 研究型別：理解、推理與規劃；影片問答與推理
- 領域：居家整理與清潔、餐飲與烹飪、社交與溝通
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：LEMMA多代理家務影片；沒有新的獨立場景全集。
- 任務：3個scope (world / intent / multi-agent) ×4問法 (描述 / 預測 / 解釋 / 反事實)；屬QA taxonomy，不是12個生活工作。
- 題數 / 資料：從368K程式生成候選挑出40K balanced QA，基於約2K ego clips及30K狀態 / 人物註記blocks。
- 評估方式：在answer vocabulary上分類，報accuracy；按scope / type / semantic與open/binary分列。
- Split / 資訊條件：normal以QA按3:1:1分train/val/test；indirect以多步間接指涉作泛化測試，不可當場景互斥split。

- 來源關係：直接擴充LEMMA標註；因果trace由前 / 後置條件規則生成，belief標註由多數人工票決。
- 可復用：提供規則、前置條件、因果與多代理信念的具體擴充；反事實QA不等於模擬器已驗證反事實軌跡。
- 待核 / 限制：40K題的video父ID與上游LEMMA環境重用未匯入。

P033 EgoLife (2025)

原作：<https://arxiv.org/abs/2503.03803>

本次PDF：<https://arxiv.org/pdf/2503.03803v3>

PDF SHA256：62089719b6879f1f7f10401989959c9a7e0531aa411284d10c9a713f0634c49a

閱讀頁：1、3、4、5、6、7。蒐集、QA流程、正式題庫與當版跑分範圍。

- 研究型別：理解、推理與規劃；長期記憶與生活助理
- 領域：居家整理與清潔、餐飲與烹飪、休閒與運動、社交與溝通
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：1個自建EgoHouse、6人共同生活7天；15臺外部相機不是15個環境。
- 任務：5題型：EntityLog、EventRecall、HabitInsight、RelationMap、TaskMaster。
- 題數 / 資料：約300小時原始 / 266小時保留影片；正式EgoLifeQA 3,000題（每人500）。本版§5快速實驗只用Jake的500題；EgoIT-99K為訓練資料。
- 評估方式：multiple-choice accuracy；依certificate長度、題型、audio / identity設定分析。；比較captioner時，最終QA由共同GPT-4o回答；這與將GPT當評分judge不同。
- Split / 資訊條件：來源為連續一週個人經歷；99K / D1模型訓練與QA證據時間應另外追蹤。
- 來源關係：新錄EgoHouse；EgoIT-99K含其他ego來源，不能把訓練集99K稱本benchmark新增test量。
- 可復用：補多日記憶、習慣與人際關係；需要保留個人 / 共同事件重疊而非把6人同步影片全當獨立時長。
- 待核 / 限制：完整3,000題是否有同設定的發布成績，須另查後續版本。

P034 EgoVLP (2022)

原作：<https://arxiv.org/abs/2206.01670>

本次PDF：<https://arxiv.org/pdf/2206.01670v2>

PDF SHA256：cd7cf25aa25da8a2a88d0875ec2f0a5cf56f99a045eb7c11957a6e27784f584f

閱讀頁：1、3、4、5、6、7。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：人類影片與動作資料；影片資料與感知評測
- 領域：居家整理與清潔、工藝與修繕
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：Ego4D的129scenario labels；來源環境重用。
- 任務：EgoMCQ包含inter-video/intra-video兩種五選一video-text配對；EgoClip是訓練庫。
- 題數 / 資料：EgoClip約3.85M narrations/2,927h；EgoMCQ約39K題 = 24K inter+15K intra。

- 評估方式：EgoMCQ accuracy；下游retrieval、NLQ、recognition分開。
- Split / 資訊條件：EgoClip排除Ego4D val/test；EgoMCQ再人工移除和pretraining共用multi-view的影片。
- 來源關係：Ego4D→EgoClip/EgoMCQ；兩位narrators不代表兩份獨立行為。
- 可復用：原先只列成方法會漏掉真正新增的EgoMCQ；應把論文與其多個資源分開登記。
- 待核 / 限制：39K是概述約數；最終題ID與選項去重需原始manifest。

P037 EgoEnv (2022)

原作：<https://arxiv.org/abs/2207.11365>

本次PDF：<https://arxiv.org/pdf/2207.11365v3>

PDF SHA256：30fca03c8d8d57b800a30c4d921db35c49f8d6339b1679c30268654e7783ba47

閱讀頁：1、6、7、8。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：理解、推理與規劃；空間理解與affordance
- 領域：居家整理與清潔
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：pretraining 900 HM3D scenes；HouseTours選886houses，MP3D90scenes；各自保留source單位。
- 任務：room prediction與NLQ兩端點；21real room classes，MP3D9classes不是新的生活domain。
- 題數 / 資料：約15K合成walkthroughs×512steps；HouseTours約32h、MP3D146walkthroughs；QA精確總量未核。
- 評估方式：room分類、NLQ temporal localization；local-state AP另測。
- Split / 資訊條件：HouseTours按house切，Ego4D/MP3D用原split；video memory可讀query附近全片，非嚴格線上。
- 來源關係：新增HouseTours labels、Ego4D NLQ沿用，HM3D/MP3D資產重用。
- 可復用：補house-tour與室內環境理解；source錄影場所與sim資產必須分開。
- 待核 / 限制：Ego4D段落稱1,259scenes，需核是video/session或實體place；不納跨來源環境總和。

P038 OpenEQA (2024)

原作：

https://openaccess.thecvf.com/content/CVPR2024/html/Majumdar_OpenEQA_Embodied_Question_Answering_in_the_Era_of_Foundation_Models_CVPR_2024_paper.html

本次PDF：

https://openaccess.thecvf.com/content/CVPR2024/papers/Majumdar_OpenEQA_Embodied_Question_Answering_in_the_Era_of_Foundation_Models_CVPR_2024_paper.pdf

PDF SHA256：d2c714b7cfdcee8fe6cde607296c15689ecff298b752611c913458fd3964ca48

閱讀頁：1、2、3、4、7。EM / Active定義、資料來源與生成、題數及LLM-Match協定。

- 研究型別：理解、推理與規劃；具身問答與探索
- 領域：居家整理與清潔、辦公與教育

- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：蒐集階段100個ScanNet scenes + 87個HM3D scans；這是生成候選history範圍，非已驗證題目引用的152個history IDs。
- 任務：7問答類別；兩種設定EM-EQA / A-EQA。Active只允許導航探索，未包括開櫃等操作。
- 題數 / 資料：正式1,636題 = 1,079 ScanNet + 557 HM3D；A-EQA重用這557題，不能加成2,193獨立QA。
- 評估方式：LLM-Match給1–5分再正規化；不是字串match或MC accuracy。；Active另按路徑長度折算效率；object localization有多個合理reference答案。
- Split / 資訊條件：來源ScanNet val/test、HM3D val場景；相同QA跨EM與Active，只改可用資訊 / 探索許可權。
- 來源關係：ScanNet / HM3D + Habitat。與本庫固定manifest的152 history IDs口徑不同，187候選不等於187已取得互動環境。
- 可復用：是同一問題在記憶與可探索環境兩種設定的明確先例；應以共享query而非雙倍題數表示。
- 待核 / 限制：Active公開資產 / 執行入口和本文可評557題的可重現範圍需另核；已取得QA metadata不代表所有素材到位。

P039 RoboVQA (2023)

原作：<https://arxiv.org/abs/2311.00899>

本次PDF：<https://arxiv.org/pdf/2311.00899v1>

PDF SHA256：0d6f31eb8631105b7abfd15b617c7477404b7e7694955c0a3108fcff05d658bf

閱讀頁：1、2、3、4、5、6、10。資料蒐集、10種QA擴充、VQA人工判分與三種planning介入評測。

- 研究型別：理解、推理與規劃；具身問答與探索
- 領域：居家整理與清潔、餐飲與烹飪、辦公與教育
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：3棟辦公樓，robot / 人手 / 人持夾具3種embodiment。
- 任務：2,722 unique長指令、26,798 unique中程指令；字串去重不是共同語義任務去重。10種QA包含規劃、完成檢測、affordance、過去描述 / 未來預測。
- 題數 / 資料：5,246長程episodes、92,948中程episodes、238小時；VQA val/test各約1,000筆，來自各50 episodes。另100個離線planning episodes / 854步、10個live teleop任務及1個自主5步任務。
- 評估方式：VQA先查已人工判定的答案快取，未見答案交人工判correct/incorrect。；planning分cognitive / physical intervention rate；人類救援使所有任務完成，不能把完成率當自主成功率。
- Split / 資訊條件：episodes互斥但scenes可重疊；robot-only與human+robot測試分開。
- 來源關係：自身多機體蒐集；SayCan固定60任務是外部baseline範圍，不是RoboVQA任務總量。
- 可復用：是大廣度robot / human資料與高低階分離評測的直接比較物件；數萬指令已大於先前任意5,000配額。
- 待核 / 限制：完整release QA精確行數與文字語義去重量尚未重算。

P040 RoboBench (2025)

原作：<https://arxiv.org/abs/2510.17801>

本次PDF：<https://arxiv.org/pdf/2510.17801v2>

PDF SHA256：b34e12bf6f096b03930eb63d6e6580345d4fc1330c8c54c7f9660c501b7ff204

閱讀頁：1、2、4、5、6、7、8、9、10、18、22。5維度 / 25端點、資料表、人機標註、Q1–Q3評分及下游控制驗證。

- 研究型別：理解、推理與規劃；綜合具身認知評測
- 領域：居家整理與清潔
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：多來源robot影片與自錄配置；未報可相加的去重物理layout總量。
- 任務：5維度、14能力群、25評測端點；不同於25個生活工作任務。
- 題數 / 資料：6,092 questions / 4,336 unique items；含1,895 MC與Q1/Q2/Q3各1,973 / 842 / 1,192，加190navigation。相同item衍生多種問題。
- 評估方式：感知 / affordance / failure用MC accuracy；Q3 binary accuracy。；Q1用MLLM評node correctness與milestone completion；Q2用MLLM評skill/object/parameter。所稱world-simulator是模型判斷，不是剛體物理模擬執行。；另以CALVIN / LIBERO控制結果查關聯，屬下游驗證子集。
- Split / 資訊條件：QA與下游CALVIN ABC→D、LIBERO-Long10任務 / 各50trials分開；模型全對題會被篩掉，難度帶有選模依賴。
- 來源關係：多robot來源及RoboMIND失敗軌跡；planning failure有人工注入，execution failure來自真rollouts，證據不能混。
- 可復用：最直接的all-in-one具身認知比較物件之一；我們需清楚提出場域 / 任務聯集與可驗證規則的新增部分。
- 待核 / 限制：來源unique item跨上游重用尚未逐ID去重；v1 unique items為4,333，不套用到v2。

P041 EgoCross (2025)

原作：<https://arxiv.org/abs/2508.10729>

本次PDF：<https://arxiv.org/pdf/2508.10729v2>

PDF SHA256：f4c3606509844a990b9b1c2fc3df05bdab0cff9a08af8fa5446cc9080f49e743

閱讀頁：1、3、4、7、10。domain選擇、五個上游資料、QA數、Close/Open評分與finetuning split。

- 研究型別：理解、推理與規劃；影片問答與推理
- 領域：工藝與修繕、醫療與手術支援、休閒與運動、寵物照護與動物活動
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：4個domain來自5資料集，不是4個環境；含內視鏡工具視角，不全是人類頭戴相機。
- 任務：identification / localization / prediction / counting四類，15細分題型。
- 題數 / 資料：957 QA、798 clips；OpenQA與CloseQA為同一問題兩種格式，不是1,914個獨立題。
- 評估方式：CloseQA：4選1 accuracy；OpenQA：Qwen-Max檢查語義正確與reference。
- Split / 資訊條件：主zero-shot全題；SFT / RL pilot將原QA再70:30分train/test，其分數不能與全題zero-shot當相同測集。
- 來源關係：EgoSurgery、CholecTrack20、ENIGMA-51、ExtremeSportFPV、EgoPet的衍生QA。
- 可復用：直接提示家務之外的缺域；跨domain來源聯集已有前例，要把多樣性貢獻做得可量化。
- 待核 / 限制：上述五個上游是否全部在現有書目中獨立登記需補查。

P042 RoboSpatial (2024)

原作：<https://arxiv.org/abs/2411.16537>

本次PDF：<https://arxiv.org/pdf/2411.16537v5>

PDF SHA256：58a5b655a8d69265586b817547ebe08770c6d88ea05ea17d50c2fb56ead76c22

閱讀頁：1、2、3、4、5、6。關係與frame定義、生成規則、表2、Val/Home評測。

- 研究型別：理解、推理與規劃；空間理解與affordance
- 領域：居家整理與清潔、辦公與教育
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：訓練4,916 indoor scans + 190 tabletop scenes；validation 40 scans + 77 scenes；來源重用而非新掃描5K個robot場景。
- 任務：context / compatibility / configuration三類空間關係，ego / world / object三種reference frame。
- 題數 / 資料：約3M是生成訓練QA/relations；正式Val 6,000題，每關係2,000；新錄Home另350人工題。
- 評估方式：yes/no accuracy；座標預測以3D點是否落在reference convex hull判正確。；compatibility以bbox放置無重疊且各軸10cm餘量的幾何規則構造，不等於真實可操作性。
- Split / 資訊條件：Val scans完全未在training中；另有indoor↔tabletop泛化與OOD Home。
- 來源關係：ScanNet、Matterport3D、3RScan經EmbodiedScan取幾何；桌面用HOPE、GraspNet-1B；BLINK / SpatialBench是外部eval。
- 可復用：是規則自動擴題與多reference-frame評測的直接先例；可擴大題量，但需保留train與eval區別。
- 待核 / 限制：源scan之跨庫重建重複量及bbox規則邊界誤差需原生ID / 幾何審核。

P045 ManipBench (2025)

原作：<https://arxiv.org/abs/2505.09698>

本次PDF：<https://arxiv.org/pdf/2505.09698v2>

PDF SHA256：7cd33f53355500d085efdd4c1c80dd05509e3d3b24c6ec7232519a9481e53d53

閱讀頁：1、3、4、5、6、27。三種資料來源、五種操作類別、MCQ建立及實體驗證。

- 研究型別：理解、推理與規劃；空間理解與affordance
- 領域：衣物與洗護
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：DROID / Bridge原始場景、自錄布料工作站、SIMPLER / RLBench / SoftGym與新增IsaacSim ball場景。
- 任務：pick-place、articulated、deformable、tool、dynamic五種操作類別；布料10理解維度；另外7個真實機器人驗證任務。
- 題數 / 資料：12,617 MCQ = 9,180公共robot資料題 + 2,662布料題 + 其餘simulation題；公共資料Q1 6,120、Q2 3,060，來自同episode的augmentation不算新任務。
- 評估方式：MC accuracy；Q2要pick與place兩子題都對才算joint correct，第二題提供GT pick。；MCQ所稱pick-place success不等於實際robot rollout success；另列UR5物理驗證。
- Split / 資訊條件：MCQ benchmark與7真機任務分開；新組合未在MCQ中共現，並非保證所有物件個別都未見。
- 來源關係：多既有資料 / simulation衍生 + 自錄布料；有question augmentation共享母episode。
- 可復用：直接對應多來源robot操作→多模態題庫；需比它更廣的工作用途與更完整規則，而非只加QA格式。
- 待核 / 限制：各simulation來源精確母episode數與跨題同源關係需manifest匯入。

P051 USST / EgoPAT3D trajectories (2023)

原作：<https://arxiv.org/abs/2307.08243>

本次PDF：<https://arxiv.org/pdf/2307.08243v2>

PDF SHA256：592b977dc3d758aa321266c4f5e7588d29c8fd207b4630fa191021a49d73b634

閱讀頁：1、5、6。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：未來動作 / 互動預測；動作與軌跡預測
- 領域：居家整理與清潔、穿戴互動與動作介面
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：EgoPAT3D-DT 14scenes = 11seen+3unseen；H2O重用原capture。
- 任務：3D hand-centroid trajectory forecasting；2D projection另報，不是完整手指控制。
- 題數 / 資料：H2O 8,203/1,735/3,715 train/val/test windows；EgoPAT3D-DT 6,356/846/1,605 seen test+2,334 unseen test。
- 評估方式：ADE/FDE，3D以米、2D以frame size正規化；3D模型投影和2D直接模型分開。
- Split / 資訊條件：H2O64frame windows步長15，視窗重疊；EgoPAT3D有held-out scenes。
- 來源關係：H2O→PT/DT、EgoPAT3D→DT是新增標註；不把父原片重複計。
- 可復用：可新增trajectory模組；相近視窗須依原影片群聚切分與估計。
- 待核 / 限制：後續Diff-IP2D提及原repo的FDE erratum；比較成績需固定修正版本。

P053 HandsOnVLM (2024)

原作：<https://arxiv.org/abs/2412.13187>

本次PDF：<https://arxiv.org/pdf/2412.13187v2>

PDF SHA256：9ad31595678bd06e9139e118c6a693354034f7c08a91f74988de80f3e5836948

閱讀頁：1、5、6、7。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：未來動作 / 互動預測；動作與軌跡預測
- 領域：餐飲與烹飪、穿戴互動與動作介面
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：EPIC/H2O/FPHA/Ego4D原影片環境，無新增可執行robot scenes。
- 任務：VHP顯式動作指令與RBHP隱式意圖兩預測任務；10observed→4future frames，4fps。
- 題數 / 資料：RBHP生成7.5K EPIC與8K Ego4D QA-prediction pairs；24K/epoch是抽樣預算而非獨立題庫。
- 評估方式：ADE/FDE/WDE，不是語言答對率或robot完成率。
- Split / 資訊條件：EPIC validation及H2O/FPHA zero-shot；+版本混合五個額外QA訓練來源。
- 來源關係：OCT-style手軌跡標註+GPT生成implicit instructions；父影片和explicit/implicit變體共享。
- 可復用：是擴充任務規則的來源：同軌跡在明示/隱式需求下重測，保留對照關係。
- 待核 / 限制：生成指令的精確train/test manifest與ground-truth歧義需核；不是每次生成都新語義task。

P054 EgoVid-5M/EgoDreamer (2024)

原作：<https://arxiv.org/abs/2411.08380>

本次PDF：<https://arxiv.org/pdf/2411.08380v1>

PDF SHA256：c878ace0c6d18cf230b26b97a809cdaeda44659ed1cdf693245c44b6681b7f9d

閱讀頁：1、4、5、6、7、8。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：世界模型與預測表示；世界模型與影片生成評測
- 領域：居家整理與清潔、辦公與教育、工藝與修繕、休閒與運動
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：重用Ego4D來源，場景總數未報。
- 任務：文字與camera kinematics條件下video generation；kinematic label不是robot action。
- 題數 / 資料：名義5Mclips；正文4.9Mtrain、1.2Kval，只有65K具可用IMU的kinematic subset。
- 評估方式：CD-FVD、semantic/action alignment、clarity、motion smoothness/strength及pose errors。
- Split / 資訊條件：val按品質/多樣性選，已讀段未明示source-video-disjoint；三個1Mcleaning subsets不是新增資料。
- 來源關係：Ego4D→EgoVid，VIO/MLLM重標；generation評測沿用AIGCBench/VBench部分metrics。
- 可復用：補ego世界模型，但評測視覺品質和實際可控物理成功需另驗證。
- 待核 / 限制：5M不能全部叫action-conditioned examples；4.9M與5M概述差異保留。

P057 Motor attention and action forecasting (2019)

原作：<https://arxiv.org/abs/1911.10967>

本次PDF：<https://arxiv.org/pdf/1911.10967v2>

PDF SHA256：91f5c905b44c16ebb6de7ac8c6523846a0254a218889c9afb2fc8305e061fc33

閱讀頁：1、7、8、9、11。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：未來動作 / 互動預測；動作與軌跡預測
- 領域：餐飲與烹飪、穿戴互動與動作介面
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：EGTEA與EPIC-Kitchens原capture。
- 任務：action anticipation、motor attention、interaction hotspot三端點。
- 題數 / 資料：EGTEA10,321action instances；EPIC39,596是父資料，全量hotspot僅EGTEA，EPIC只many-shot noun subset。
- 評估方式：Top1/5、mean-class accuracy、hotspot F1/KLD、trajectory ADE/FDE。
- Split / 資訊條件：EGTEA split1/0.5秒anticipation，EPIC既有train/val及1秒anticipation。
- 來源關係：增加manualhotspots；EPIC motor attention用fingertip→hotspot線性插值近似，非完整真實追蹤。
- 可復用：補早期joint HOI預測及標籤品質差異，保留真實/推估label來源。
- 待核 / 限制：新增hotspot/trajectory標註精確ID數未報，不能把39,596全當新增標註題。

P058 EgoPAT3Dv2 (2024)

原作：<https://arxiv.org/abs/2403.05046>

本次PDF：<https://arxiv.org/pdf/2403.05046v1>

PDF SHA256：7496f4c315189a824e5c490ba688d26788d161a66d4cbc6f93caf2d64665979c

閱讀頁：1、2、4、5、6。原版 / 新增資料、seen/unseen切分、10段進度評分及HRI定位。

- 研究型別：未來動作 / 互動預測；動作與軌跡預測
- 領域：協助、交接與陪伴、穿戴互動與動作介面
- 用途歸納：預測人手將接觸的位置，讓共享工作區的機器人提前配合；同時是頭戴裝置的動作意圖介面。
- 環境：原版5 seen + 6 unseen scenes；新增9 seen + 2 unseen，合計22場景（由原文分量推算）。
- 任務：從RGB預測人手3D action target；cobot接近 / 避讓是應用展示，非22個操作goal。
- 題數 / 資料：本輪已讀原作未取得精確clip總量；各test clip按進度10等份評測，不能乘10當獨立軌跡。
- 評估方式：釐米級target prediction error，early / late分列；3個訓練seed取平均。
- Split / 資訊條件：保留T1/T2訓練與D1/D2測試來源、seen/unseen；train clips最多25frames，test不限制。
- 來源關係：EgoPAT3D擴充並修正部分GT；原baseline也因此改進，需固定版本後比較。
- 可復用：可加入人類手部目標提前量 / 距離誤差軸，不能拿10個觀測比例冒充10種任務。
- 待核 / 限制：新增與原版各split精確clip ID總量仍須發布資料核對。

P060 Continuous 4D interaction forecasting (2026)

原作：<https://arxiv.org/abs/2609.08636>

本次PDF：<https://arxiv.org/pdf/2609.08636v1>

PDF SHA256：831ddd738803ba93751f328695856f63519cd1327b28140774d76cb95ae0ba35

閱讀頁：1、2、4、5、6。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：未來動作 / 互動預測；動作與軌跡預測
- 領域：餐飲與烹飪、醫療與手術支援、交通移動與車輛維修、穿戴互動與動作介面
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：Ego-Exo4D的787takes，不等於787獨立場地。
- 任務：3D interaction location + full-body pose聯合預測；Cooking/Health/BikeRepair三用途。
- 題數 / 資料：233,828 windows = 193,598 train + 20,484 val + 19,746 test；1,594,186是有效future targets。
- 評估方式：continuous location errors與MPJPE/PA-MPJPE；兩種target和validity mask分開。
- Split / 資訊條件：take-level split；三域horizon為10/5/4 interaction steps，不是固定秒數。
- 來源關係：Ego-Exo4D + Fiction式事件 + WHAM重建；exoviews僅供offline labels。
- 可復用：擴充套件where-to-how預測；source-domain與camera/pose時間對應都可入共同規格。
- 待核 / 限制：take-level不自動證明不同take沒有共用實體環境；作者scene-disjoint說法需place IDs核。

P061 Interact with me (2024)

原作：<https://arxiv.org/abs/2412.16698>

本次PDF：<https://arxiv.org/pdf/2412.16698v3>

PDF SHA256：35eabf84ae2cfa183887ab3924f91d9f15fa53aac29576e56407b4eee8da3642

閱讀頁：1、2、3、4、5。JPL擴充、3組標籤、訓練augmentation、主要實驗。

- 研究型別：未來動作 / 互動預測；人體與互動感知評測
- 領域：社交與溝通、協助、交接與陪伴
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：沿用JPL人機互動影片；未報新增scene總數。
- 任務：intent 3類、attitude 2類、action 10類；attitude是依action規則產生的標籤，不是獨立量測心理狀態。
- 題數 / 資料：200母影片→290 person-level tracks；crop/flip/keypoint noise擴增只增加訓練樣本，不增加290個來源個案。
- 評估方式：三任務各報accuracy及F1；主表觀測首1秒30frames，另變更視窗；模型latency另列。
- Split / 資訊條件：本輪已讀段落未取得正式train/test track ID分配；不得把290直接稱test題。
- 來源關係：JPL video-level標註擴成人物track；同影片多個人共享情境。
- 可復用：補互動意圖與社交預測；需註明人設標籤規則及與動作標籤的依賴。
- 待核 / 限制：同母影片track是否跨split及split數須source code核對。

P065 CALVIN (2021)

原作：<https://arxiv.org/abs/2112.03227>

本次PDF：<https://arxiv.org/pdf/2112.03227v4>

PDF SHA256：c8ad4741782fa8fb773377fbf61b8772b86574f255599a229d3f6ad4d878c60e

閱讀頁：1、2、3、4、5、7。4環境、34task與全部success criteria、play資料及MTLC / 長鏈評測。

- 研究型別：一般操作 benchmark；模擬操作benchmark
- 領域：居家整理與清潔、通用物件與機動作業
- 用途歸納：開抽屜、控制燈與把物件收好屬居家整理；方塊轉動、推移與堆疊則保留為通用作業。
- 環境：A/B/C/D四個配置；共用桌面、robot及camera位置，但滑門 / 抽屜 / 開關位置與材質不同。
- 任務：34原子任務，包括方塊轉動 / 推移 / 抬起、收納、堆疊、開關門與燈。
- 題數 / 資料：24小時play、約2.4M steps / 40M可重標視窗是資料潛量；正式long-horizon 1,000條5步鏈；單步每task10個rollouts。
- 評估方式：task completion依起終狀態變化，不只終點距離；長鏈只成功才轉下一subgoal，報鏈長 / 成功情況。
- Split / 資訊條件：single / multi / zero-shot multi環境；ABC→D為未見配置但語義任務已在train出現，語句另保留未見表達。
- 來源關係：PyBullet自建play環境；多後續VLA評測重用同1,000 chains，不能算各自新增題庫。
- 可復用：可借序列可行性、過程狀態與長鏈測試；34原子任務和5,000子步次數不能混算。
- 待核 / 限制：模型成績比較必須固定語言 / 初態鏈版本及可用sensor。

P066 ManiSkill (2021)

原作：<https://arxiv.org/abs/2107.14483>

本次PDF：<https://arxiv.org/pdf/2107.14483v5>

PDF SHA256：90472755c9779e6088c8a94faaed0a4de3b9743d2d994c421973b0e7c402b374

閱讀頁：1、3、4、5、6、7。原生task / environment定義、4 skills、物件split、demo及評分。

- 研究型別：一般操作 benchmark；模擬操作benchmark
- 領域：居家整理與清潔
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：原作environment以一個物件資產為單位；表1為52門櫃、35抽屜櫃、36椅、39桶，櫃體可能含多door/drawer，不能當162獨立房間。
- 任務：4 skills：OpenCabinetDoor、OpenCabinetDrawer、PushChair、MoveBucket；涵蓋單 / 雙臂mobile manipulation。
- 題數 / 資料：約36K成功demonstrations、1.5M frames；測試物件每skill10個，cabinet target有多門 / 多抽屜。
- 評估方式：預定test environment instances的mean success；task-specific終態 / 穩定性判定；training restrictions分track。
- Split / 資訊條件：同物件category下train/test object互斥；單個scene引數變化另為environment instance。
- 來源關係：SAPIEN + PartNet-Mobility類資產；ManiSkill2繼承這4項，不可視作全部新任務。
- 可復用：資產拓撲泛化與物件級environment是重要細節；需轉譯成共同欄位但不抹平原生定義。
- 待核 / 限制：門櫃 / 抽屜櫃底層asset ID是否重疊需manifest核。

P067 ManiSkill2 (2023)

原作：<https://arxiv.org/abs/2302.04659>

本次PDF：<https://arxiv.org/pdf/2302.04659v1>

PDF SHA256：89fb794345d860ee696ca2f4d7a75059b15352b615794eeadb0e6075426136f0

閱讀頁：1、2、3、4、5、6、7、8、19、22。20families內容、精密裝配規則、rigid-soft平臺、評測與部分task-specific附錄。

- 研究型別：一般操作 benchmark；模擬操作benchmark
- 領域：居家整理與清潔、裝配與生產作業、通用物件與機動作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：SAPIEN / MPM配置及2,000+ object models；object assets非同量房屋。
- 任務：20 families：6 soft、3精密插入、5 pick-place、5關節 / mobile、1 AvoidObstacles；繼承ManiSkill1的4項。
- 題數 / 資料：4M+ demonstration frames為訓練資料。test依task不同：如PickSingleYCB每物件5/10 episodes、cabinet兩階段各250等，不能指定所有task同一題數。
- 評估方式：task-specific真物理成功；插入必須實際進孔，非靠近goal pose。；原文同AssemblingKits基線在pose accuracy可99%、真插入成功只18%，說明難度高度依賴規則。
- Split / 資訊條件：按物件train/test及challenge stage，控制器可轉換但要保留其action約定。
- 來源關係：繼承ManiSkill1；任務靈感來自MetaWorld / RLBench / Ravens，但更改孔洞幾何與成功判準，屬有實質規則差異的衍生。

- 可復用：直接支援『同名任務可擴充規則』主張；更嚴格成功條件必須以獨立規則版本記錄。
- 待核 / 限制：全20家族不同階段test episodes總量要從eval manifest按版本重算。

P069 robosuite (2020)

原作：<https://arxiv.org/abs/2009.12293>

本次PDF：<https://arxiv.org/pdf/2009.12293v3>

PDF SHA256：3da1cc7ba84ee487a90d7013325dd6045eea7c2920bc50cdb8ff37db67426fd4

閱讀頁：1、7、10、11、12、13、14、15、16、17。平臺、robots/controllers、全部9 benchmark descriptions與標準評測。

- 研究型別：一般操作 benchmark；模擬平臺與任務套件
- 領域：居家整理與清潔、裝配與生產作業、通用物件與機動作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：9標準task環境，共用可配置arena / robot；10robot模型不是10場域。
- 任務：Lift、Stack、PickPlace、NutAssembly、Door、Wipe、TwoArmLift、TwoArmPegInHole、TwoArmHandover。
- 題數 / 資料：程式隨機初始化，未固定全庫題量；基線9環境×robot/controller組合，5 seeds是訓練重複，不增加task。
- 評估方式：標準SAC實驗報normalized episode return，500step horizon；task success條件依具體任務，不能把return當百分比成功率。
- Split / 資訊條件：原作比較Panda/Sawyer與OSC/joint velocity，建議固定Panda OSC；未提出全域held-out task split。
- 來源關係：MuJoCo模擬平臺；LIBERO、RoboCasa、MimicGen等重用，平臺與下游bench不可當完全獨立環境源。
- 可復用：提供共通模擬 / 控制器 / task介面；平臺功能與benchmark實績分開。
- 待核 / 限制：repo v1.5可用的其餘task是否超過本文9個標準評測需分清，不以註冊class數覆蓋論文結果。

P070 RoboCasa (2024)

原作：<https://arxiv.org/abs/2406.02523>

本次PDF：<https://arxiv.org/pdf/2406.02523v1>

PDF SHA256：7aca93ca3f157e32a46e02d675b3b2c24e3073a7807c038f7f566b73db87bde3

閱讀頁：1、2、3、4、5、6、8。場景、資產、100tasks組成、MimicGen資料與正式eval子集。

- 研究型別：一般操作 benchmark；模擬操作benchmark
- 領域：居家整理與清潔、餐飲與烹飪
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：10 floor plans×12 styles=120 scenes；只能把10稱平面layout數。額外AI textures不新增layout。
- 任務：100=25 atomic (8skills) + 75 composite (20料理活動標籤下生成並實作)。
- 題數 / 資料：atomic有1,250 human demos；生成實驗72K (24tasks，排除navigation) 另28K組成100K發布集。主要eval每task50 trials，分5個固定場景。
- 評估方式：物理task success；按skill、資料規模、未見物件 / style分列。

- Split / 資訊條件：eval只用未見物件例項；5場景中2種style未見。MimicGen有成功rejection sampling，訓練資料成功不代表policy成功。
- 來源關係：Robosuite底座、Objaverse / Luma資產、MimicGen擴樣；後續RoboCasa365是同家族延伸。
- 可復用：支援生活工作組合擴充；域仍主要在廚房，須報真實layout與style層次。
- 待核 / 限制：本庫先前收集的60個來源場景條目來自不同repo版本，不能與此PDF120 scenes混寫，更不能叫60獨立layouts。

P072 VLABench (2024)

原作：<https://arxiv.org/abs/2412.18194>

本次PDF：<https://arxiv.org/pdf/2412.18194v1>

PDF SHA256：9dc4aa5cfa6dcb86a30099eda2482bf45814285a8d6662df624ed79f2382788b

閱讀頁：1、2、4、5、6、7、8、19。100任務、10skills、資產、VLA/流程/VLM三種評測與PS。

- 研究型別：一般操作 benchmark；模擬操作benchmark
- 領域：居家整理與清潔、餐飲與烹飪、辦公與教育、實驗室操作、休閒與運動
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：MuJoCo/dm_control程式配置；未提供可直接與住宅數比較的獨立scene總量。
- 任務：100 = 60 primitive + 40 composite，10操作skills；包含整理桌面、料理、化學示範、紙牌規則等。
- 題數 / 資料：2,164資產 / 163類；VLA主微調只取16類各100trajs = 1,600訓練軌跡，非全100task的test量。
- 評估方式：Success與Progress Score分開：PS預設0.2正確物件選取 + 0.8已完成子步比例。；VLM非互動模式輸出DSL，轉DAG比skill/parameter recall與exact matching；不能把此分數當物理成功率。
- Split / 資訊條件：seen/unseen object是整個category的差異；與ManiSkill同category新instance不相同。VLA / workflow / VLM資訊條件各異。
- 來源關係：部分RoboCasa assets + Objaverse、生成資產；技能API和標註先驗要列清。
- 可復用：已涵蓋多種日常語義和物理 / 知識規則；是本研究擴規則與multimodal tool use的近鄰。
- 待核 / 限制：各task eval episode數、無互動VLM題庫精確量需源manifest核。

P073 RoboTwin (2024)

原作：<https://arxiv.org/abs/2409.02920>

本次PDF：<https://arxiv.org/pdf/2409.02920v3>

PDF SHA256：2c289e8ac5352f42de2908b166176fe6d01f045fbb4fb7214134a63e7c432c4f

閱讀頁：1、2、4、5、7、8、9。digital twin資料流程、17真實資料任務與6個DP3 benchmark子集。

- 研究型別：一般操作 benchmark；模擬與真實操作benchmark
- 領域：居家整理與清潔、餐飲與烹飪、工藝與修繕、協助、交接與陪伴
- 用途歸納：從杯子擺放、蘋果收納、掃除、鉗擊與人際互動資料歸納，保留每種用途所對應的任務範圍。
- 環境：COBOT Magic工作站與其合成digital twins；未報多房屋總數。

- 任務：資料設計17任務（9tool、5人際、6雙臂，標籤可重疊）；本文DP3跑6任務。
- 題數 / 資料：真實資料每task30trajs（ $17 \times 30 = 510$ ）；6任務實驗比較10/20/50 expert demos。test rollouts精確數本段未報。
- 評估方式：各task completion success rate；示範數是訓練條件，不是評測題數。
- Split / 資訊條件：real收集範圍與synthetic expert評測6task分開；9+5+6不能加為20個不重疊task。
- 來源關係：AIGC由圖到3D，MLLM寫expert code；RoboTwin2為後續擴充。
- 可復用：雙臂、工具、人機互動與digital twin產題可借；版本應明確分層。
- 待核 / 限制：原文引用A.3而此PDF附錄資訊有限，完整17task manifest與test rollout數仍待code核。

P075 VIMA (2022)

原作：<https://arxiv.org/abs/2210.03094>

本次PDF：<https://arxiv.org/pdf/2210.03094v2>

PDF SHA256：cf849f80368749b0310b43117519ce0abff3e8ae49744e78c4a29b9d17f0695f

閱讀頁：1、2、3、5、6、8、34、37。VIMA-Bench多模態prompt、17templates、4級泛化、訓練與eval。

- 研究型別：一般操作 benchmark；多模態指令操作
- 領域：居家整理與清潔、通用物件與機動作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：Ravens桌面平臺，物件 / 材質 / 位置程式變化；未報多房屋環境數。
- 任務：17task templates歸6非互斥類：物件操作、視覺goal、新概念、示範模仿、視覺約束、推理 / 記憶。
- 題數 / 資料：600K+ expert訓練trajectories；程式產生的instances與17templates分開，不能把訓練軌跡稱600K測試題。
- 評估方式：模擬互動task success；L1位置、L2新組合、L3新物件、L4新task分開。
- Split / 資訊條件：offline BC；held-out validation選模型、simulator evaluation。原生動作為引數化pick-place / wipe primitive，非相同低階控制難度。
- 來源關係：Ravens延伸；多模態prompt內圖片、語言、示範本來就在單一介面，不能把這點當本研究首次貢獻。
- 可復用：多模態指令統一入口的重要前作；可擴大生活用途與規則，但需承認其既有統一介面。
- 待核 / 限制：各泛化級的確切公開eval seeds / case數需發布設定核對。

P076 Ravens / Transporter Networks (2020)

原作：<https://arxiv.org/abs/2010.14406>

本次PDF：<https://arxiv.org/pdf/2010.14406v3>

PDF SHA256：3a5e78b5c8881863845c46bda0bf8c9071aa79a59a6f9a9f4d8732690482b228

閱讀頁：1、5、6、7、8。全部10simulation task清單、動作 / 觀測、訓練量、test與真機驗證。

- 研究型別：一般操作 benchmark；模擬操作benchmark
- 領域：居家整理與清潔、裝配與生產作業、包裝、倉儲與物流、通用物件與機動作業

- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：UR5e + 0.5×1m桌面，3 RGB-D視角；real kit assembly / sweeping為額外實驗。
- 任務：10task：block insertion、red-in-green、Hanoi、align corner、pyramid、palletizing、kits、packing、rope、sweeping。
- 題數 / 資料：每task訓練1/10/100/1,000 demonstrations；每task100 unseen test runs＝一方法設定1,000runs。
- 評估方式：0–100 performance，多步task給partial credit；非所有表中的分數都是binary success percentage。
- Split / 資訊條件：物件 / goal位置朝向train/test隨機，3task含未見objects；two-pose動作primitive及suction降低控制負擔。
- 來源關係：PyBullet桌面，自帶script oracle；VIMA、DeformableRavens等衍生共享task與介面。
- 可復用：包裝、堆疊、繩索、清掃可作source tasks；需標記primitive與成功判準。
- 待核 / 限制：task各自partial credit及物理predicate嚴格程度需具體code對映，不以同名插入直接對比ManiSkill2。

P077 CLIPort (2021)

原作：<https://arxiv.org/abs/2109.12098>

本次PDF：<https://arxiv.org/pdf/2109.12098v1>

PDF SHA256：3cc19664beabda203cb1a1ad86659f75f60a099189820d92d59d20067c9ab003

閱讀頁：1、2、4、5、6。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：一般操作 benchmark；模擬與真實操作benchmark
- 領域：包裝、倉儲與物流、通用物件與機動作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：PyBullet Ravens UR5e桌面；3noiseless cameras融合RGB-D。
- 任務：10language-conditioned tasks；8有seen/unseen semantic variants。
- 題數 / 資料：每模型/設定100evaluation runs，train 1/10/100/1000demos是規模對照。
- 評估方式：Ravens 0–100partial-credit task score，不能全叫binary success rate。
- Split / 資訊條件：held-out colors/object categories；56GoogleScannedObjects分37seen/19unseen。
- 來源關係：Ravens task復用並加語言；nominal SE(2) pick-place和通用6DoF policy難度不同。
- 可復用：補語言語義的操作規格；count10tasks，不把每demo和attribute組合當新task。
- 待核 / 限制：真實補充任務及完整source-task對應另需原生code；本列定量限已讀sim protocol。

P079 FMB (2024)

原作：<https://arxiv.org/abs/2401.08553>

本次PDF：<https://arxiv.org/pdf/2401.08553v3>

PDF SHA256：c0d7c39378cfc46b87289276d517c5e9ef6aa5932fece6c5d2b0b4a4f120f9e8

閱讀頁：1、3、4、5、7、8、10、12。資產、三大skill / 六種primitive、長流程、表1及evaluation。

- 研究型別：一般操作 benchmark；真實操作benchmark

- 領域：裝配與生產作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：可重製Franka工作站，物件與board初態依規定區域和姿態；不是66個環境。
- 任務：functional grasp / reposition / insert三大能力；single-object與multi-object兩類流程，3套multi-object互鎖裝配。表1有6個primitive。
- 題數 / 資料：66訓練物件 + 5新測試物件；表1精確22,550 primitive trajectories由完整流程分割，不能都叫獨立22,550長程任務。
- 評估方式：依skill / 長流程success；grasp實驗5 seen + 5unseen物件各5次 = 50trials；完整流程另有10次設定。
- Split / 資訊條件：物件shape/size/color與初態泛化；board插入間隙1–2mm；可模組評估也可end-to-end，兩者分開。
- 來源關係：自製3D printable objects與human demos；長流程和primitive資料共享母軌跡。
- 可復用：精密contact、功能性抓取、重抓與順序依賴；只有模擬仍可收錄規格，不能稱已重現其real實驗。
- 待核 / 限制：摘要22,500與表1精確22,550為約數差異；未取得完整真機eval。

P080 DexArt (2023)

原作：<https://arxiv.org/abs/2305.05706>

本次PDF：<https://arxiv.org/pdf/2305.05706v1>

PDF SHA256：44354c0496a14f9ef90e19cd93f1521075adb6daff5f0a882cc045a649fbff7e

閱讀頁：1、2、3、4、5、6。4task、seen/unseen表、22DoF介面、success與視角泛化。

- 研究型別：一般操作 benchmark；靈巧手操作benchmark
- 領域：居家整理與清潔
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：SAPIEN中XArm6 + 16DoF Allegro；物件資產不同，非多house layout。
- 任務：Faucet、Bucket、Laptop、Toilet四task；資產18 / 19 / 17 / 28，共82。
- 題數 / 資料：seen物件11+11+11+17 = 50，unseen7+8+6+11 = 32；3訓練seeds；6K point clouds/object為視覺預訓練資料。
- 評估方式：success依關節角 / 抬升高度；episodic return另列；測seen/unseen物件和新camera pose。
- Split / 資訊條件：同category未見instance；4接觸 / 進度reward不等於4獨立benchmark。
- 來源關係：PartNet-Mobility資產；額外PMM46類是pretraining，不是DexArt46個任務。
- 可復用：補靈巧手與拓撲泛化；DoF增加代表控制要求，不能直接給跨benchmark單一難度等級。
- 待核 / 限制：完整test episodes per object與seed ID需eval code核。

P081 ARNOLD (2023)

原作：<https://arxiv.org/abs/2304.04321>

本次PDF：<https://arxiv.org/pdf/2304.04321v2>

PDF SHA256：5a2b6c0126bde99772c888036524fd071cf3890034be184e26c437bd42f50fdb

閱讀頁：1、3、4、5、6、8。scene/objects、8tasks各continuous goal、表2/3、泛化切分與2秒success。

- 研究型別：一般操作 benchmark；模擬操作benchmark
- 領域：居家整理與清潔、通用物件與機動作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：20個scene、40物件；Isaac Sim / PhysX5、固定Panda base。
- 任務：8task×各4個數量goal（保留1個novel state）；拾物、重定向、開關drawer/cabinet、pour / transfer water。
- 題數 / 資料：表3共10,080 demonstrations/configurations：train3571、val771、IIDtest773、novel object1078、scene1114、state2000、any-state773。
- 評估方式：完成最終stage後在goal tolerance內保持2秒；transfer水另限≤10%spill；報success rate。
- Split / 資訊條件：Normal約70/15/15；novel object / scene / state每次只變一因素；Any State是連續range抽樣，非同樣extrapolation難度。
- 來源關係：既有室內synthetic scenes + 外部object assets；可接Roboverse但需保留新success規則。
- 可復用：量化精度、穩定維持與spill限制是規則擴充的好依據；同task多目標與新語義task分開。
- 待核 / 限制：本庫尚未逐ID匯入全部scene/state/test組合。

P083 RoboDojo (2026)

原作：<https://arxiv.org/abs/2607.04434>

本次PDF：<https://arxiv.org/pdf/2607.04434v3>

PDF SHA256：e07c215f30169dde6a792c34b046b1f54818d09331763988732dcf9ead89a9d4

閱讀頁：1、2、3、4、5、6、7、8、9、16、28、45。42sim/18real、五能力清單、train/eval數量、評分與hidden-layout驗證。

- 研究型別：一般操作 benchmark；模擬與真實操作benchmark
- 領域：居家整理與清潔、衣物與洗護、裝配與生產作業、通用物件與機動作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：Isaac Sim雙臂工作站和3類真機平臺；各task有公共reset layouts和hidden驗證佈局。
- 任務：42simulation tasks（12 generalization、6 memory、8 long、8 precision、8 open）+ 18real tasks；同名/同goal的sim/real不能先假定60語義去重任務。
- 題數 / 資料：simulation每task50episodes = 2,100；real每task10trials = 180。sim train34tasks + DLC共35目錄3,500trajs，real1,800trajs。
- 評估方式：sim binary success + partial-progress score，五能力宏平均；real三人雙盲評分後平均。
- Split / 資訊條件：Open8task不在train；generalization每task25標準 + 25隨機；正式榜另3seeds及hidden layouts，不加作新task。
- 來源關係：參考RoboTwin、RMBench等，使用新規則及共同sim-real介面；公開表與hidden驗證不同地位。
- 可復用：綜合能力與可復現實測的近鄰；我們simulation-only版本需以同等成功 / partial score證據比較。
- 待核 / 限制：sim/real相同任務之去重關係與hidden驗證量未完整公開。

P084 KinDER (2026)

原作：<https://arxiv.org/abs/2604.25788>

本次PDF：<https://arxiv.org/pdf/2604.25788v2>

PDF SHA256：39d1283a971b7b903edb7885cabdc9dea9c412bd3cfcc8431f0c39154ba44900

閱讀頁：1、3、4、5、6、7、14。五大physical-reasoning要求、25環境、4種物理抽象、8實驗環境及metrics。

- 研究型別：一般操作 benchmark；物理推理與規劃benchmark
- 領域：居家整理與清潔、包裝、倉儲與物流、通用物件與機動作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：25 procedural task-environments：6 Kinematic2D + 4 Dynamic2D + 5 Kinematic3D + 10 Dynamic3D；不是25生活場域。
- 任務：工具、nonprehensile、多物體、幾何、動力約束；KinDERBench主實驗只取8代表環境，13baselines。
- 題數 / 資料：10環境各≥100precollected demos；eval每seed50episodes×5seeds，8環境合計2,000runs / baseline（含重複seed執行）。
- 評估方式：success rate；只在成功episodes比較累積步數cost（每步-1），另報inference time。
- Split / 資訊條件：不同物體數量OOD；state / RGB與提供skills/PDDL的資訊差異需明示。Kinematic版本碰撞回退、rigid attachment，不等同dynamic真抓取。
- 來源關係：PyMunk / PyBullet / MuJoCo不同backend；借RoboCasa/MimicLabs資產及BDDL設計。
- 可復用：支援明確規則 / 物理抽象的比較；不得將kinematic、dynamic的成功直接合成無條件難度分數。
- 待核 / 限制：程式分佈無固定題庫上限；僅8環境有主baseline結果，不能聲稱全25已同程度驗證。

P085 SoftGym (2020)

原作：<https://arxiv.org/abs/2011.07215>

本次PDF：<https://arxiv.org/pdf/2011.07215v2>

PDF SHA256：0e0bd8b74b7d8b3aa1a203694debf47d425adbfe2eab8bf4555b198525e89903

閱讀頁：1、3、4、5、6、7、8、14。6 Medium / 4 Hard任務、action抽象、oracle資訊及eval切分。

- 研究型別：布料 / 柔性物操作；柔性物操作benchmark
- 領域：衣物與洗護
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：Flex程式物理環境；主Medium/Hard直接控制picker或杯子，非完整手臂；SoftGym-Robot另列。
- 任務：10任務=6 Medium（transport/pour water、straighten rope、spread/fold/drop cloth）+ 4 Hard（pour amount、fold crumpled、drop-fold、rope configuration）。
- 題數 / 資料：主實驗每task預抽1,000 variations=800train+200eval；CEM只抽10個eval variations，不能稱所有方法測同量。
- 評估方式：按task用覆蓋面積、粒子距離、水量 / spill等；以do-nothing與upper bound正規化，可能小於0。；5 seeds報median / 四分位，不是binary success rate。
- Split / 資訊條件：初態variations800/200；DynamicsOracle / StateOracle / RGB資訊許可權不同，不能混為同難度。
- 來源關係：Flex與抽象pickers；後續布料task和資料生成器大量重用。
- 可復用：柔性物task與連續指標來源；加上機體、抓持及穩定性規則才適合與robot控制任務比較。
- 待核 / 限制：SoftGym-Robot在本文註明待NVIDIA許可發布；目前取得狀態須另核，不能由API假定可用。

P086 DeformableRavens (2020)

原作：<https://arxiv.org/abs/2012.03385>

本次PDF：<https://arxiv.org/pdf/2012.03385v4>

PDF SHA256：7227984ec317cff8190a29c2f53794d0e399fbbb7ed78c8ee21c7b27f78d65f8

閱讀頁：1、3、4、5、6、7、13、14。12任務全表、deformable primitive、資料與checkpoint選擇、真機cable實驗。

- 研究型別：布料 / 柔性物操作；柔性物操作benchmark
- 領域：衣物與洗護、包裝、倉儲與物流
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：共用UR5桌面，PyBullet繩索 / 布料 / 袋子；理想nearest-vertex抓持。
- 任務：12=5 cable、3 fabric、4 bag；有goal image和無goal圖兩種設定，bag含開啟→裝物→搬運。
- 題數 / 資料：每task1,000成功demo；每checkpoint20eval episodes、通常3訓練runs，bag-color僅1run。表格選10checkpoints最大值。
- 評估方式：cable位置 / 凸包面積、cloth coverage、bag containment/transport依task分開。；真機cable另10episodes、最多10actions、mask IoU>0.25判成功。
- Split / 資訊條件：held-out random seeds；依eval最大checkpoint報分有選擇效應，不能當獨立test後只評一次。
- 來源關係：Ravens延伸；成功demo經過濾，script成功率與policy測試不是同一分母。
- 可復用：拓展袋子、繩索與布料多階段規則；要額外防止袋外掛物等達標漏洞。
- 待核 / 限制：各task指標中連續coverage與binary success混合，跨任務總分需保留原生定義。

P087 GarmentLab (2024)

原作：<https://arxiv.org/abs/2411.01200>

本次PDF：<https://arxiv.org/pdf/2411.01200v3>

PDF SHA256：8b0cea58cae1f425754a11a328f6082eafc8066dd93300c8255ba4ae17ffa999

閱讀頁：1、2、3、4、5、6、7、8、9、16、17、20。資產與5種物理互動、20task、實驗子集、split及5秒success。

- 研究型別：布料 / 柔性物操作；柔性物操作benchmark
- 領域：居家整理與清潔、衣物與洗護、個人照護
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：20scene與9,000+object models資產庫；PhysX多物理方法，scene/asset數不等於實評數。
- 任務：20tasks歸5interaction groups：garment-garment/fluid/FEM/rigid/avatar；含摺、展、掛、吹乾、洗、收納、穿衣。
- 題數 / 資料：不同task初態 / garment取樣；正文baseline以大件fold/unfold/hang、小件place/hang及若干RL子集為主，沒有統一全20task題數。
- 評估方式：達task-specific判準後維持至少5秒；fold用IoU、unfold用coverage，其他物理互動有專用容差。
- Split / 資訊條件：objects70/15/15；另novel state / scene；主實驗並非全部20task同程度跑分。
- 來源關係：ClothesNet、ShapeNet、PartNet/YCB、PartNet-Mobility、Omniverse/actorcore等資產；RoboVerse遷移其子集。

- 可復用：柔性物與日常服務廣度的重要來源；應保留materials與state/evaluator可用程度。
- 待核 / 限制：摺衣輪廓IoU無法單獨檢查層次 / 拓撲正確；需更細規則。；完整20task有效case數待manifest。

P088 FlingBot (2021)

原作：<https://arxiv.org/abs/2105.03655>

本次PDF：<https://arxiv.org/pdf/2105.03655v3>

PDF SHA256：ad6e502825c044a1ce13911164ae7817e00628ba7ac3e46358cc277c9d25dc8e

閱讀頁：1、6、7。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：布料 / 柔性物操作；柔性物操作benchmark
- 領域：衣物與洗護
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：simulation cloths與dualUR5真實工作站；NormalRect/LargeRect/Shirt三object regimes。
- 任務：主要1個unfolding目標；三clothtypes是材料/形狀泛化設定。
- 題數 / 資料：2,000trainingcloth settings，600sim test cases各類200；real各類10cases，150realadapt episodes不算test。
- 評估方式：normalized final/delta coverage及actions，允許coverage>1的正規化情形不裁成success。
- Split / 資訊條件：CLOTH3D test shirts；mesh/material/init分離，10step budget或預測抓地板終止。
- 來源關係：CLOTH3D與既有clothphysics，dataset task實為具體cloth+material+initialization。
- 可復用：示範同一目標可以有大量物理cases，而未增加語義task數。
- 待核 / 限制：coverage並不保證可直接摺衣；real細節與sim material引數只能作相應範圍推論。

P089 SpeedFolding (2022)

原作：<https://arxiv.org/abs/2208.10552>

本次PDF：<https://arxiv.org/pdf/2208.10552v2>

PDF SHA256：2421f14228d394a1a2f683d8156f4ff953dee3dd1deefef64ce0037854b86be1

閱讀頁：1、5、6、7。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：布料 / 柔性物操作；柔性物操作benchmark
- 領域：衣物與洗護
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：ABB YuMi工作站；known shirt、unseen shirt、towel。
- 任務：smoothing→folding，instruction/2-second/Fling-to-fold三策略並非三個生活domain。
- 題數 / 資料：4,300action records包含1,500複製重標；每experiment15trials。
- 評估方式：fold由3reviewers多數決；horizon10；time成功回合平均，FPH/cycle包括失敗。
- Split / 資訊條件：train單shirt；towel泛化前加20smoothimages再訓練，不是完全zero-shot。

- 來源關係：前作FlingBot比較有不同hardware；1500重標非獨立physical actions。
- 可復用：補摺衣全流程與吞吐量，不能只報93%而略過任務、排除規則和15次分母。
- 待核 / 限制：排除motion-planning early failures會影響整體systemsucccess解讀；須在共同protocol保留此差異。

P090 Cloth Funnels (2022)

原作：<https://arxiv.org/abs/2210.09347>

本次PDF：<https://arxiv.org/pdf/2210.09347v1>

PDF SHA256：06417ac85cf98e06ede6fd96b746e6e1ce3ad99ca09fcd9f61789122d0ecfcd

閱讀頁：1、2、4、5、6。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：布料 / 柔性物操作；柔性物操作benchmark
- 領域：衣物與洗護
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：CLOTH3D simulation與真實衣物工作站，5garment categories。
- 任務：canonicalized alignment，另支援folding/ironing；highcoverage不保證對齊。
- 題數 / 資料：每garment category2,000train/400test settings；hard/easy train75/25、test50/50。
- 評估方式：IoU/coverage及分離rigid-alignment和deformable errors；fold success為qualitatively選的error門檻。
- Split / 資訊條件：mesh-disjoint，easy/hard是不同初態生成；eachgarmentcategory獨立policy。
- 來源關係：CLOTH3D / FlingBot資料生成構想；downstreamfoldheuristic非新end-to-end模型。
- 可復用：把攤平、對齊和指定摺法拆成可驗收目標，適合作為擴充規則依據。
- 待核 / 限制：real全部trajectory分母未在已讀段報出；不可套用sim400為realcase數。

P091 UniFolding (2023)

原作：<https://arxiv.org/abs/2311.01267>

本次PDF：<https://arxiv.org/pdf/2311.01267v1>

PDF SHA256：b51de4cbad0c9715a18e88ce74af68a21192ad10e130a1b956715c87706d8049

閱讀頁：1、2、5、6。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：布料 / 柔性物操作；柔性物操作benchmark
- 領域：衣物與洗護
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：RFUniverse/ClothDynamics及雙Flexiv工作站；2garment categories。
- 任務：兩類衣物的unfold+fold流程；60realgarments的train/test40/20。
- 題數 / 資料：VR1,218+1,575=2,793videos，real2,432samples；20heldoutgarments各10trial=200realtrials。
- 評估方式：IoU、normalizedcoverage，wholeflow10steps內按rules摺好。

- Split / 資訊條件：realgarments2:1，simCLOTH3D9:1；onlinehumanpreference作訓練，不當test免介入證據。
- 來源關係：CLOTH3D、ClothFunnel目的函式及VR-human demonstrations。
- 可復用：可取shirt具體fold規則和材料差異，human annotations與robotepisodes分開。
- 待核 / 限制：機器人reach/grasp自動recovery和policyactionbudget的共同計數需要adapter明定。

P092 ICRA cloth competition (2025)

原作：<https://arxiv.org/abs/2508.16749>

本次PDF：<https://arxiv.org/pdf/2508.16749v2>

PDF SHA256：c44a1dff77f6fe471123e7e70b03b6735ed494e18190396a44c5c4232962b274

閱讀頁：1、2、5、6、7、8、11。固定unfold primitive、硬體 / grasp execution、coverage metric、資料及比賽規模。

- 研究型別：布料 / 柔性物操作；真實操作benchmark
- 領域：衣物與洗護
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：雙UR5e + 單stereo camera標準工作站；訓練在lab、比賽在會場，cloth初態無法精確複製。
- 任務：1個核心任務：懸掛布料選grasp後stretch展開；34garment items不是34task。
- 題數 / 資料：679episodes = 503訓練嘗試 + 176競賽trial；11隊各16次（8衣物×2），同題型由不同方法執行。
- 評估方式：主metric projected coverage / 最大面積；另grasp success及成功抓取條件下coverage。；30秒grasp計算上限為建議，非由679樣本推導的固定速度門檻。
- Split / 資訊條件：503與176來源 / 用途分開；訓練也含失敗抓取；176是實驗執行，不是176獨立任務。
- 來源關係：部分毛巾來自Household Cloth Object Set，與其它cloth benchmarks資產可能重用。
- 可復用：可借真實garment多樣性與grasp/coverage分離；不宜把單次展開當完整摺衣 / 收納任務。
- 待核 / 限制：場地與初態差異無法完全消除；本庫無法只靠既有影片重跑physical grasp。

P093 MoDeSuite (2025)

原作：<https://arxiv.org/abs/2507.21796>

本次PDF：<https://arxiv.org/pdf/2507.21796v1>

PDF SHA256：7487d599b51f5e6b76f91382e89b71c431f6314db66766625b35dda08d345dca

閱讀頁：1、3、4、5、6。兩種mobile robot、8task逐項定義、source繼承及learning評測。

- 研究型別：布料 / 柔性物操作；柔性物操作benchmark
- 領域：居家整理與清潔、衣物與洗護
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：IsaacSim / PhysX；Ridgeback-Franka與Spot arm，走廊 / 桌面配置。
- 任務：8 = 新5elastic（Place/Bend/Transport/Drag/Lift） + 3既有cloth-like（Cover/Uncover/Curtain）；需base與arm協同。

- 題數 / 資料：RL5獨立runs，success在20eval trials計算；非每task20個語義新任務。
- 評估方式：依task幾何位置、跨越 / 覆蓋與無碰撞條件報success；episode return和stability penalty另列。
- Split / 資訊條件：不同機體 / state/RGB輸入分開；本文無單一全庫train/test IDs總量。
- 來源關係：3cloth tasks從前作擴充mobile base control；FEM與PBD為不同材料物理，不是新生活domain。
- 可復用：可補『移動時攜帶 / 拖拉柔性物』而非純桌面摺布；規則包含通過障礙與穩定。
- 待核 / 限制：原3task來源與精確scene/config IDs需從引用30及code進一步對齊。

P094 R2R/VLN (2017)

原作：<https://arxiv.org/abs/1711.07280>

本次PDF：<https://arxiv.org/pdf/1711.07280v3>

PDF SHA256：b7589865ee573d4753ee9e25bdc494cbbb199e6ec17d0a349091aed0fd86c420

閱讀頁：1、2、4、5、6、7。navigation graph、路徑 / 指令蒐集、scene split與stop成功定義。

- 研究型別：導航與家務執行；導航benchmark
- 領域：居家整理與清潔、辦公與教育
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：90個Matterport3D建築scene；panorama graph離散移動，非真輪式動力學。
- 任務：1個指令導航task family；7,189 route goals、21,567語言指令（通常每path3條）。
- 題數 / 資料：train14,025 / val-seen1,020 / val-unseen2,349 / test4,173 instructions。
- 評估方式：navigation error；主success要求stop後距goal<3m；oracle stop另列。原文不要求全程遵循原path。
- Split / 資訊條件：61train scenes / 11val-unseen / 18test；不能把全部21,567叫test。
- 來源關係：Matterport3D上游；RxR、RoboVerse、VLN-CE等重用同scene，場景數不可加總。
- 可復用：可引入route-following與語言多樣性；路徑數和導航task family是不同粒度。
- 待核 / 限制：下游continuous變體的可導航幾何 / case過濾需要另版本。

P095 RxR (2020)

原作：<https://arxiv.org/abs/2010.07954>

本次PDF：<https://arxiv.org/pdf/2010.07954v1>

PDF SHA256：8a964d95106ff267f934acf705a6b0be304a193f84745fe0ad55f51133d61bd8

閱讀頁：1、2、3、4、5、6、9。path取樣、90scene重用、多語註記、split與path-adherence metrics。

- 研究型別：導航與家務執行；導航benchmark
- 領域：居家整理與清潔、辦公與教育
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：同Matterport3D90個室內場景；不是比R2R又新增90。

- 任務：16,522 paths；English/Hindi/Telugu三語，同一path有多語 / 多描述與guide/follower traces。
- 題數 / 資料：126,069 instructions；path split 11,089 train / 1,232 val-seen / 1,517 val-unseen / 2,684 test。這些是path數，不能當同數instruction。
- 評估方式：PL、NE、SR、SPL、NDTW、SDTW；原作主重NDTW/SDTW以獎勵遵循指定路徑，與R2R只到終點不同。
- Split / 資訊條件：沿R2R / Matterport場景split；test-standard/test-challenge隱藏；3語每語約14K paths有交集。
- 來源關係：原始scene共用R2R，path另取樣；與R2R多工訓練的追加資料不能再算新test。
- 可復用：證明同導航family可以擴語言與過程規則；規則差異應明確保留。
- 待核 / 限制：各language及test子split指令ID量需manifest核。

P096 ALFRED (2019)

原作：<https://arxiv.org/abs/1912.01734>

本次PDF：<https://arxiv.org/pdf/1912.01734v2>

PDF SHA256：84b314c06de82f5a1ff853676d391e05394a2e517986b03faadcbca325c9ee0b

閱讀頁：1、2、3、4、7、8。7task types、引數 / demo / directive層級、scene及split表、success與partial goal評測。

- 研究型別：導航與家務執行；室內長流程操作
- 領域：居家整理與清潔、餐飲與烹飪
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：AI2-THOR 120 rooms = kitchen/bathroom/bedroom/living各30；不是120房屋。
- 任務：7types：pick-place、stack-place、pick-two、clean-place、heat-place、cool-place、examine-in-light；2,685 task parameter combinations。
- 題數 / 資料：8,055 expert episodes、概述25,743 directives；表2split為21,023 / 820 / 821 / 1,533 / 1,529（合25,726），原文存在17差異。
- 評估方式：全部goal condition成功 / 部分goal-condition比例；另以action length折算效率。；subgoal評測可先強制走expert歷史，不能與end-to-end成功混同。
- Split / 資訊條件：108train rooms，4val-unseen，8test-unseen；seen folds是train場景子集。
- 來源關係：AI2-THOR 2.0 + PDDL planner；TEACH沿同floorplans/splits，兩者場景不可重加。
- 可復用：提供家務狀態變更 / 工具切割 / 熱冷清潔程式；符號動作語義不等於低階接觸控制。
- 待核 / 限制：25,743概述與表2合計25,726需release IDs釐清，不靜默選方便的數字。

P097 TEACH (2021)

原作：<https://arxiv.org/abs/2110.00534>

本次PDF：<https://arxiv.org/pdf/2110.00534v3>

PDF SHA256：512d9ea49367fc5ec3559ab9b866c1aaafb015585dd2363bc7e918b20e42e40a

閱讀頁：1、2、3、4、5、6、7、9、21。TDL與12task、session→EDH、三種benchmark、全部split與success。

- 研究型別：導航與家務執行；對話協作與任務完成
- 領域：居家整理與清潔、餐飲與烹飪、協助、交接與陪伴
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：AI2-THOR；表2成功收集池覆蓋109 rooms，重用ALFRED場景與unseen split。
- 任務：12task types、438引數variants（收集池）；3端點EDH / TfD / TATC，最後一種要同時建模Commander/Follower。
- 題數 / 資料：正文3,047可replay sessions；表3分量合3,045。EDH表3總11,176 = 5475train+608val-seen+2157val-unseen+666test-seen+2270test-unseen。
- 評估方式：EDH完成全部expected state changes為success，GC給部分分；trajectory length weighting另列。；TATC與TfD重用session母資料，不是三倍獨立任務量。
- Split / 資訊條件：seen/unseen場景；train/val/test按session；舊版EDH因只保留推進任務的state changes而縮減。
- 來源關係：同AI2-THOR與ALFRED場景，語言 / session新human-human收集；TDL支援量詞、階層與共享object約束。
- 可復用：對話工具、澄清、任務階層與量詞規則有可復用形式；收整合功與可重播數需分開。
- 待核 / 限制：本文3,047與split3,045差2；表1還留早期3,215，必須以版本manifest查明。

P098 Habitat 2.0 (2021)

原作：<https://arxiv.org/abs/2106.14405>

本次PDF：<https://arxiv.org/pdf/2106.14405v2>

PDF SHA256：92f9c30479fe4203f656c218fa228c7e5fd71f23a9821b3afa47e06dbe5ab317

閱讀頁：1、2、4、5、6、7、9、10、11、29。ReplicaCAD構造、Pick基本任務、3種HAB任務與評估假設。

- 研究型別：導航與家務執行；室內長流程操作
- 領域：居家整理與清潔、餐飲與烹飪
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：ReplicaCAD111 layouts建立於單一apartment backdrop；正文105新layout variations與原始配置分量需分清，非111獨立住宅。
- 任務：HAB3families：TidyHouse、PrepareGroceries、SetTable；另Pick基礎實驗。任務goal為object起終3D位置，不是自然語言理解。
- 題數 / 資料：程式clutter/goal episodes；Pick有500 unseen-layout eval樣本；技能附錄另100eval episodes，不能混作HAB全庫題數。
- 評估方式：goal成功與分階段成功；操作次數用作難度proxy；模擬速度SPS另列。
- Split / 資訊條件：未見layout/object配置；抽象抓持與kinematic base控制，並非完整wheel/contact dynamics。
- 來源關係：Replica FRL apartment→ReplicaCAD、YCB clutter；Habitat3/後續rearrangement套件會重用。
- 可復用：可借home-scale長流程與open/close前後置條件；環境分量與感測先驗需精確報。
- 待核 / 限制：HAB每family全套eval episode IDs與111layout正式manifest仍待匯入。

P099 HomeRobot (2023)

原作：<https://arxiv.org/abs/2306.11565>

本次PDF：<https://arxiv.org/pdf/2306.11565v2>

PDF SHA256：518b6ba6f64a2c51a1bda3b92902e6ad0d2cbf5567d6d07e93207a28155d61e3

閱讀頁：1、2、4、5、6、7、17、18、19、20、24、27。HSSD實際子集、OVMM四stage、scene/objects切分、sim/real成功定義。

- 研究型別：導航與家務執行；室內長流程操作
- 領域：居家整理與清潔
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：HSSD原庫200+，本文實驗只用60scenes = 38train/12val/10test；real為1個3-room apartment。
- 任務：1個OVMM family：find object→pick→find receptacle→place；129物件類別與21receptacle類，不是129/21個新任務。
- 題數 / 資料：2,535物件模型；sim程式產生object/start/goal cases，已讀段未給單一全庫題量。real兩baseline各20experiments。
- 評估方式：四stage全過為success、partial success作tie-break；sim Place需靜穩50steps。；sim Pick是0.8m內magic snap，real Pick要實抓；兩者判準不同。
- Split / 資訊條件：未見scene及未見object instances，另seen/unseen categories；sim1250step、real300step budget。
- 來源關係：HSSD + AI2-THOR/ABO/GSO objects，與PARTNR HSSD衍生共享環境家族。
- 可復用：可提供open-vocabulary尋物與搬運；需在共同庫標記抓持抽象層級。
- 待核 / 限制：HSSD不同專案的branch/scene ID對照需查；不能把HomeRobot60與PARTNR60直接算120houses。

P101 Embodied Agent Interface (2024)

原作：<https://arxiv.org/abs/2410.07166>

本次PDF：<https://arxiv.org/pdf/2410.07166v3>

PDF SHA256：d10c7fee3594c88ff9f6a061a68b64a380a82d36c6652f3b08c42179044e2a9f

閱讀頁：1、4、5、6、7、21、89、90、102、103。4 modules完整I/O與metric、表2、BEHAVIOR100 / VirtualHome標註與符號實作。

- 研究型別：導航與家務執行；符號規劃與評測介面
- 領域：居家整理與清潔、餐飲與烹飪、辦公與教育
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：VirtualHome與EvalGibson兩後端；EvalGibson為BEHAVIOR100建立的符號transition simulator，不是BEHAVIOR1K全物理執行。
- 任務：4 modules：goal interpretation、subgoal decomposition、action sequencing、transition modeling。VirtualHome表2為26task names / 338instructions；BEHAVIOR100為100。
- 題數 / 資料：338 + 100 = 438 instruction instances；801/673 goals是組成標籤，平均4,164.4 goal options不是4,164題。
- 評估方式：goal / transition以logic F1；trajectory feasibility、goal satisfaction、partial goal success；PDDL planner成功另列。；模組評測其餘部分用GT / BFS / planner補齊，非端到端全系統分數；只實作LTL部分語法，globally/until尚未實作。
- Split / 資訊條件：zero-shot介面評估；固定單module與pipeline分析分開。
- 來源關係：BEHAVIOR100 VR demos、RobotHow/VirtualHome；重新標註抽象 / 具體goal以避免無關終態汙染。
- 可復用：是統一任務語言、規則及模組評測的直接前作；應避免重造G/T軸而不交代與此介面差異。
- 待核 / 限制：附錄稱VirtualHome30categories而表2為26names，待label清單對齊。

P102 NavVerse (2026)

原作：<https://arxiv.org/abs/2607.19695>

本次PDF：<https://arxiv.org/pdf/2607.19695v1>

PDF SHA256：9e578a0112fb1c6b3969bc02b262c7f35fa90e3321692f5dfa0ad033fef1fc68

閱讀頁：1、2、3、4、5、6、8、12、13。200scene構造、3task、10K episodes、物理導航與metric / 難度。

- 研究型別：導航與家務執行；導航benchmark
- 領域：公共場館與服務
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：100 indoor GRScenes + 50 outdoor城市 + 50 indoor-outdoor組合；混合scene重用前兩組幾何，不是200獨立底層環境。
- 任務：ObjNav / PlaceNav / VLN三類；PlaceNav沒有純室內split，不能機械做3×3完整coverage。
- 題數 / 資料：4,027 ObjNav + 2,973 PlaceNav + 3,000VLN = 10,000episodes（全生成benchmark）；與evaluation subset量分開。
- 評估方式：SR、SPL、coverage efficiency、collision rate、obstacle distance、navigable surface ratio；Spot goal tolerance 1.6m。；難度按各task自身path length的1/3、2/3分位，不是跨benchmark通用難度。
- Split / 資訊條件：indoor90/10、outdoor40/10，mixed沿outdoor split；共享PID waypoint follower。
- 來源關係：GRUtopia/GRScenes + Virtual Community城市、Google tiles、Objaverse；mixed環境需追父scene。
- 可復用：補室內到戶外的連續導航與工作用途；可用組合環境擴題，但須報重用關係。
- 待核 / 限制：各task evaluation split的精確case ID量與mixed scene父ID需要manifest匯入。

P103 Follow-Bench (2025)

原作：<https://arxiv.org/abs/2509.10796>

本次PDF：<https://arxiv.org/pdf/2509.10796v4>

PDF SHA256：d0c3862a5ceea33af287b35df24c711ee5e923e829b298b2688ed9c280e18ace

閱讀頁：1、6、7、8、9、10、20。16scenario、配置表、8planners、100trials與安全/舒適metric。

- 研究型別：導航與家務執行；社交導航benchmark
- 領域：包裝、倉儲與物流、個人照護、公共場館與服務、協助、交接與陪伴
- 用途歸納：跟隨指定人是陪伴服務；原作亦明列照護、巡邏、導覽與物流的應用方向。
- 環境：CPU 2D simulator；16scenario types分target trajectories、4crowd模式、4layouts；非16個真實場所。
- 任務：1核心family = 跟隨指定人，變更跟隨角 / 距離、密度、狹窄通道及遮擋。
- 題數 / 資料：各configuration 100個隨機trial；表V包含多種人數 / 寬度 / 距離，不能簡化為16×100而漏掉配置。
- 評估方式：無碰撞且重新找到target才成功；TVR、目標personal-zone時間、侵入他人空間、jerk、路徑等。；10Hz同步sim clock計jerk，wall-clock planner耗時另外量。
- Split / 資訊條件：motion-planning測試假設可見人位置完美；真人主觀偏好另經real interviews，不冒充sim幾何metric。
- 來源關係：既有2D人群simulator / ORCA/SFM擴充；不是端到端camera跟人辨識benchmark。

- 可復用：補持續陪伴與社交距離規則；任務完成、安全與舒適分開比。
- 待核 / 限制：全部配置去重後的trial總量需按發布config列舉。

P104 SIMPLER (2024)

原作：<https://arxiv.org/abs/2405.05941>

本次PDF：<https://arxiv.org/pdf/2405.05941v1>

PDF SHA256：6a9481f3c0fc43fa6736e5f5fc8ddb72ebf05aad7dbd0ff31721e4d6bfffec9e5

閱讀頁：1、3、4、5、6、7、8、18、20。real-to-sim目標、MMRV/Pearson、兩機體場景、visual matching與主比較。

- 研究型別：穩健性、失敗與評測品質；轉移與評測有效性
- 領域：居家整理與清潔
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：2個real robot setups：Google Robot與WidowX/Bridge；4 robot texture版本是視覺補償，不是4個新環境。
- 任務：Google圖6四組（pick、move-near、open/close drawer、open+place）；WidowX圖7四組放置 / 堆疊，含grasp子項。原作按group而非唯一語義task計。
- 題數 / 資料：各task有專用real/sim trial安排；Octo多3policy seeds、Google4texture variants，用來降低評估方差，不作新題總量。
- 評估方式：task success；比較sim/real policy排名用Mean Maximum Rank Violation與Pearson r。；validated subset的相關性不保證所有新domain也有相同sim-real關係。
- Split / 資訊條件：train on real、evaluate in sim；visual matching與variant aggregation是不同評測策略。
- 來源關係：Google/Bridge真實資料+SAPIEN，另IsaacSim驗證；ManiSkill3等重用SIMPLER子集。
- 可復用：為模擬benchmark有效性提供比較方法；沒有真機資源時只能先做sim範圍，不能宣稱完成sim-real驗證。
- 待核 / 限制：每task原生trial manifest未完全匯入，不虛構統一全庫題量。

P105 LIBERO-Plus (2025)

原作：<https://arxiv.org/abs/2510.13626>

本次PDF：<https://arxiv.org/pdf/2510.13626v3>

PDF SHA256：661de08e0ed1bb4bb4774177cac9fafa94f06b5385fa2f4107a1927b9a4aada7

閱讀頁：1、2、3、4、8、9、10、16。7擾動因素、10,030生成設定、難度分級、額外train資料與評分。

- 研究型別：穩健性、失敗與評測品質；穩健性與分佈外評測
- 領域：居家整理與清潔、餐飲與烹飪
- 用途歸納：LIBERO-Plus改變觀測與初態條件，未改掉原任務的餐具擺放、廚房裝置及收納用途。
- 環境：LIBERO場景擾動：layout、camera、robot初態、語言、light、texture、noise；不是10K新生活場景。
- 任務：7factors / 21components；原作稱10,030tasks，多為原LIBERO語義任務的擾動配置。
- 題數 / 資料：10,030benchmark settings；額外>20K成功訓練trajectories分開。

- 評估方式：物理success / success drop，依factor平均；5級難度由4個參考模型實測accuracy分層。
- Split / 資訊條件：原LIBERO訓練到擾動測試，另外有泛化資料post-training；難度依賴校準模型，不能當永久內在難度。
- 來源關係：直接衍生LIBERO；10,030不等於10,030互異goal family。
- 可復用：已有萬級評測設定的規模先例；我們若比task數必須先使用共同語義粒度。
- 待核 / 限制：10,030各父task、擾動config和split的逐條去重仍待manifest。

P106 MetaWorld+ (2025)

原作：<https://arxiv.org/abs/2505.11289>

本次PDF：<https://arxiv.org/pdf/2505.11289v2>

PDF SHA256：60d7c336669aaab9834d2e8a6156b410b5cfa28c0c7fe3da0b1da6881af9fc33

閱讀頁：1、3、4、5、7、16。50task原庫、reward版本修正、MT25/ML25、eval統計協定。

- 研究型別：穩健性、失敗與評測品質；穩健性與分佈外評測
- 領域：居家整理與清潔、餐飲與烹飪、工藝與修繕、裝配與生產作業、休閒與運動、通用物件與機動作業
- 用途歸納：MetaWorld+保留原50項任務並修正版本和評測協定，因此沿用具體任務支援的用途。
- 環境：沿用Meta-World Sawyer task environments，非新增50不同環境。
- 任務：50原生task types；新增MT25/ML25中等規模suite及custom task sets。
- 題數 / 資料：multi-task每task50goal episodes；meta每goal適應10episodes後測3episodes；10訓練seed不當新task。
- 評估方式：mean success的IQM、95%CI，10seeds；v1/v2 dense reward尺度與設計不同，原文指出歷史成績不可直接混比。
- Split / 資訊條件：保留MT/ML角色區別；MT25/ML25自原50選，非另外增加25語義任務。
- 來源關係：Meta-World版本整理與標準化；最應避免把同benchmark歷史版本當獨立資料源。
- 可復用：提供版本治理與可比較統計方法；對避免舊網頁數字混淆尤其重要。
- 待核 / 限制：本庫歷史pilot的Meta-World commit及reward版本須維持標記，不套用新版baseline成績。

P107 COLOSSEUM (2024)

原作：<https://arxiv.org/abs/2402.08191>

本次PDF：<https://arxiv.org/pdf/2402.08191v2>

PDF SHA256：ae71956329278bc299039eaa133876b4b132772081418a26c733c4810169edf2

閱讀頁：1、4、5、6、7、9、18。20task選取、14擾動、適用性、235test sets及real映象。

- 研究型別：穩健性、失敗與評測品質；穩健性與分佈外評測
- 領域：居家整理與清潔、通用物件與機動作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：RLBench/PyRep場景，外觀、camera、質量與friction擾動；不是20,371獨立房屋。
- 任務：20基本操作tasks、14perturbation factors；原文20,371 unique task instances為生成配置規模。

- 題數 / 資料：正式235test sets×25episodes = 5,875episodes / model；train20tasks×100demos = 2,000。real另4task映象。
- 評估方式：task-averaged success與相對無擾動success drop；不適用某factor的task不進該factor分母。
- Split / 資訊條件：train不加擾動但保留RLBench原variation；eval固定variation再隨機pose；主結果1train seed+1eval seed。
- 來源關係：RLBench子集擴充，YCB distractors；20×14全笛卡兒積不合法（無receiver / compound shape等限制）。
- 可復用：強調只有適用且可執行的擾動才計為case；支援擴規則但不能盲乘。
- 待核 / 限制：20,371生成配置與235固定test set之逐ID對應需manifest匯入。

P108 RoboArena (2025)

原作：<https://arxiv.org/abs/2506.18123>

本次PDF：<https://arxiv.org/pdf/2506.18123v2>

PDF SHA256：0f793633ba5767b6e93f01056dcd5c3357dabcaf70844cd0a157a364fa843698

閱讀頁：1、4、5、6、7、8。分散式A/B協定、偏好排名模型、DROID平臺與完整實驗分母。

- 研究型別：穩健性、失敗與評測品質；分散式真實評測
- 領域：居家整理與清潔、餐飲與烹飪
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：7個學術機構使用DROID平臺，evaluators自行選scene/task；沒有固定封閉的環境總數。
- 任務：開放指令集合，涵蓋數百task instructions；不是固定17task，17是外部窄基準比較。
- 題數 / 資料：超過600次pairwise評估；為建立oracle ranking，額外跑其餘5policies，全計4,284 policy rollouts。不能稱4,284獨立題。
- 評估方式：雙盲pairwise preference + progress；擴充Bradley–Terry估計policy排名與task effects，另產生有影片證據的質性報告。
- Split / 資訊條件：連續累積開放評測；沒有一般train/test固定題庫；同一次A/B需相同task條件。
- 來源關係：DROID共同硬體/資料；RoboReward重用其真實成功 / 失敗rollouts。與RobotArena ∞ 是不同工作。
- 可復用：可作開放題庫 / 偏好排名的評測方法參考；規模必須標明是rollouts還是task。
- 待核 / 限制：精確去重scene與語義task總量需要evaluation database，不從hundreds推成確定數。

P109 REFLECT / RoboFail (2023)

原作：<https://arxiv.org/abs/2306.15724>

本次PDF：<https://arxiv.org/pdf/2306.15724v4>

PDF SHA256：6018e97d117acefc2b31a0df616b29eb479b95035bf47ea2fd5882a6631ae6c3

閱讀頁：1、2、4、5、6、7。資料規模與錯誤taxonomy、說明 / 定位 / 修正三種評測及GT資訊。

- 研究型別：穩健性、失敗與評測品質；錯誤辨識與程式恢復
- 領域：居家整理與清潔、餐飲與烹飪
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。

- 環境：AI2-THOR simulation與UR5e toy kitchen；sim用GT物件 / 狀態辨識，real靠感知。
- 任務：10simulation tasks、11real tasks；規劃失敗與執行失敗兩大群。
- 題數 / 資料：100sim failure cases（每task10） + 30real failure demonstrations；沒有把正常train影片混入失敗case總量。
- 評估方式：Exp：人工判說明正確且有用；Loc：時間落在標註區間；Co-plan：執行修正後goal state成功。；real結果表主要報Exp/Loc，不能把sim約80% Co-plan當real自主恢復率。
- Split / 資訊條件：方法zero-shot failure reasoning；GT perception與action primitives降低sim難度。
- 來源關係：sim手動注入failures，real由teleop模擬失敗政策；並非全為自主機器人自然犯錯。
- 可復用：可借規劃與執行失敗taxonomy，明確分『指出錯誤』『提出修正』『真的恢復』。
- 待核 / 限制：sim/real語義task重疊未去重；完整raw failure時間 / 場景ID仍待匯入。

P110 AHA (2024)

原作：<https://arxiv.org/abs/2410.00371>

本次PDF：<https://arxiv.org/pdf/2410.00371v1>

PDF SHA256：d647c7bff1ccb2d0ae805bab761177aba8cd50d81d0418ca174e9ae97054791b

閱讀頁：1、2、4、5、6、7、8。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：穩健性、失敗與評測品質；錯誤辨識與程式恢復
- 領域：居家整理與清潔
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：RLBench、ManiSkill與realRoboFail；非新增三套物理環境。
- 任務：7failure modes的Yes/No判斷 + 原因解釋；識別失敗不等同真正恢復。
- 題數 / 資料：49KtrainingfailureQA；test11K（10未見RLBench tasks），ManiSkill-Fail130pairs（4tasks），realRoboFail7tasks。
- 評估方式：binary success labelaccuracy、ROUGE-L、cosinesimilarity、LLM fuzzy match。
- Split / 資訊條件：RLBench train/test taskdisjoint，跨sim與real另測；額外VQA/LVIS訓練資料不可算failurecases。
- 來源關係：FailGen改keyframes/gripper動作合成失敗；RoboFail重用。
- 可復用：可大量增加失敗規則cases，同時用跨來源/真實子集驗證而不冒稱新增語義工作。
- 待核 / 限制：keyframe產生failurelabels是生成機制標籤，和視覺可觀測真因未必完全相同。

P111 RoboReward (2026)

原作：<https://arxiv.org/abs/2601.00675>

本次PDF：<https://arxiv.org/pdf/2601.00675v2>

PDF SHA256：601200a96f8e30137cd3166d6d330ff9ff2ceb0de6a4c43949d808e6e9c0d29a

閱讀頁：1、2、3、6、7、8、9、22、27。OXE/RoboArena來源、counterfactual/clipping生成、5級rubric、完整split與人工驗證附錄。

- 研究型別：穩健性、失敗與評測品質；獎勵與完成度評測

- 領域：居家整理與清潔
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：多OXE來源與RoboArena實拍；14embodiments是機體種類，非14生活環境。
- 任務：給task description + rollout video預測1–5progress；反事實重寫指令和截短影片擴增負例，不自動新增實體失敗任務。
- 題數 / 資料：45,072train / 6,232val / 2,831人類驗證test；合54,135 episode-reward pairs。RoboArena test子集1,000。
- 評估方式：主metric progress label MAE，總體採group-wise平均；不同子資料來源分列，另以RL下游驗證。
- Split / 資訊條件：按original task description分組互斥；同一影片的counterfactual/clips需跟父episode分組，字串互斥不證明語義互斥。
- 來源關係：OXE成功demo及RoboArena自然成功 / 失敗；生成標籤是弱監督，test另人工逐例確認。
- 可復用：是有效擴充任務 / 評分規則的重要來源；應區分重標問題與新物理軌跡。
- 待核 / 限制：跨OXE子集的母episode重複與semantic task去重仍需ID核。

P112 EgoOops (2024)

原作：<https://arxiv.org/abs/2410.05343>

本次PDF：<https://arxiv.org/pdf/2410.05343v3>

PDF SHA256：fcf3b48c7dea45c46f41391de07a874453ef74d8762655f4104e34d8dfa9bb23

閱讀頁：1、3、4、6、7、15。5程式完整清單、6種執行錯誤、50影片、cross-validation與三端點。

- 研究型別：穩健性、失敗與評測品質；錯誤辨識與程式恢復
- 領域：工藝與修繕、裝配與生產作業、實驗室操作
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：固定坐姿工作站，原物件 / 工具 / 程式文字位置固定；4名學生佩戴ego camera。
- 任務：5task：電路、混色、離子反應、積木、紙板工藝；6執行錯誤型別，未涵蓋所有順序 / 漏步錯誤。
- 題數 / 資料：50videos、538segments、95execution mistakes；每fold30train/10val/10test，5-fold。
- 評估方式：端到端step alignment + mistake/correction mAP@tIoU0.1/0.2/0.3；GT segments分類是oracle子問題。；alignment另F1/precision/recall/MoF。
- Split / 資訊條件：每fold各task一正常一錯誤test影片；作者稱group-kfold控制worker，精確ID仍需查。
- 來源關係：自錄多領域程式；一半刻意錯、一半盡量正常但也有自然失誤。
- 可復用：補料理以外程式錯誤；規則由文字指定，不能僅憑視覺常識判定。
- 待核 / 限制：4名參與者與5-fold worker grouping的精確分配需manifest查。

P113 REPAIR-Bench (2026)

原作：<https://arxiv.org/abs/2606.29937>

本次PDF：<https://arxiv.org/pdf/2606.29937v1>

PDF SHA256：c63b11a21f43bad4c9a0709836fb1f9ca225602ea2192d55be74dd59ea385cfd

閱讀頁：1、2、3、4、5、6。RFM-HRI來源、排除樣本、3端點、各split、時間與偏好評分。

- 研究型別：穩健性、失敗與評測品質；錯誤辨識與程式恢復
- 領域：醫療與手術支援、協助、交接與陪伴
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：lab與hospital的crash-cart guidance互動；不是完整醫療操作或手術任務。
- 任務：3端點：失敗時刻、失敗型別、使用者偏好恢復策略；4誘發failure conditions + success。
- 題數 / 資料：來源214 trials/41人；排30後正式analysis 184 trials/38人。不能將214全部寫成已用評測樣本。
- 評估方式：視覺failure classification F1等；localization秒級absolute error與IoU F1。；recovery用Hit/precision/recall/F1@k，GT是人的偏好，未證明機器人執行恢復成功。
- Split / 資訊條件：visual tasks約75/25 participant分組；recovery文本60/20/20隨機split，不能宣稱三端點都participant-disjoint。visual任務刻意不給語音。
- 來源關係：RFM-HRI舊資料新增標註與preference；failure offset以機器人錯誤回應結束作標記，不是物理抓取失敗時刻。
- 可復用：補user-centered interaction recovery；必須和物理任務恢復及其成功證據分開。
- 待核 / 限制：前處理階數/cutoff不同段落敘述不一，重現需code確認；source 214與41x5亦不完全一致。

P114 RobotArena infinity (2025)

原作：<https://arxiv.org/abs/2510.23571>

本次PDF：<https://arxiv.org/pdf/2510.23571v3>

PDF SHA256：d08b1e9db69b3e2efbb9e51be4044370272927d0d53c97807368bfbdb42892ba9

閱讀頁：1、3、5、6、7、8、9、25。real-to-sim來源、VLM評分與human BT ranking、BridgeSim規模及real驗證範圍。

- 研究型別：穩健性、失敗與評測品質；轉移與評測有效性
- 領域：居家整理與清潔
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：BridgeSim 70環境；另DROIDSim、RH20TSim。總量僅概述hundreds，不能用70代稱三套全庫。
- 任務：由真實demo生成task + digital twin，再擾動初態/texture；未給共同語義task類別總數。
- 題數 / 資料：BridgeSim上8,749 pairwise comparisons；是對policy影片的偏好標註，不是8,749不同task。
- 評估方式：Gemini結合video + privileged sim states評progress，取最後30% frames平均；human pairwise BT ranking另列。；real/sim相關驗證只展示1個carrot-to-plate任務的3 policy，不能外推全庫已校準。
- Split / 資訊條件：Bridge/DROID/RH20T來源與policy訓練來源分in/out；同場景pairwise保持相同初態。
- 來源關係：真實Bridge、DROID、RH20T衍生；不同於RoboArena在真機直接分散評估。
- 可復用：提供多來源real-to-sim與偏好評分途徑；要區分生成場景、物理成功checker和VLM judge。
- 待核 / 限制：DROIDSim / RH20TSim精確場景ID量與跨來源等價未匯入。

P115 RoboMME-Interference (2026)

原作：<https://arxiv.org/abs/2606.22338>

本次PDF：<https://arxiv.org/pdf/2606.22338v3>

PDF SHA256：95baa91cdd2a1d6c0791a31627a8daee1d9e9ff70d58d60e76f53e4e3d142c40

閱讀頁：1、2、3、4。9/16task選擇、history幹擾規則、完整系統網格與50episode評測。

- 研究型別：穩健性、失敗與評測品質；長期記憶與生活助理
- 領域：裝配與生產作業、通用物件與機動作業
- 用途歸納：依示範選物、搬方塊、重畫路徑與插栓，歸入通用作業復現與裝配基礎作業。
- 環境：沿RoboMME配置，新增跨session history；不是新物理環境。
- 任務：16原task中選9個有可分離demo的families：4程式、3object、2spatial memory；其餘7不適用。
- 題數 / 資料：9×50=450基底test episodes；history條件no-history及k=0/1/3/7；11memory systems+無memory baseline造成25,200核心rollouts，非同量獨立題。
- 評估方式：成功率與Wilson95%CI；隨幹擾增加的退化曲線；retrieval改進另列。
- Split / 資訊條件：不重訓released checkpoint，僅變history；每distractor32stored frames且來自不同family，避免混入相互矛盾資訊。
- 來源關係：RoboMME的9-family子集加history規則；非全新9task。
- 可復用：展示規則擴充可增加可評條件而不改語義task數；記憶幹擾可做本庫共通延伸。
- 待核 / 限制：原始RoboMME benchmark須獨立登記檢查；跨history條件query IDs應保留父關係。

P116 OopsieVerse (2026)

原作：<https://arxiv.org/abs/2606.31993>

本次PDF：<https://arxiv.org/pdf/2606.31993v1>

PDF SHA256：cbef5a184d84ac4490de9dbbfde077c3b9a7905c1d6bc581e739540b078af3d2

閱讀頁：1、2、4、5、6、7。DamageSim三類傷害、32實作/21task設計、demo及safe-success評分。

- 研究型別：穩健性、失敗與評測品質；安全與約束評測
- 領域：居家整理與清潔、餐飲與烹飪
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：OmniGibson與RoboCasa/Robosuite兩後端；熱 / 流體傷害只在支援相應物理的後端可用。
- 任務：32task instantiations對應21unique task designs；不是32不同語義任務。
- 題數 / 資料：5示範task共90demonstrations，health feedback有/無各半；IL每task30rollouts。
- 評估方式：task completion與safe completion分開；後者需goal成功且所有tracked object health維持>95。；damage由力、溫度、液體接觸的引數模型計算，不能等同已校準的真實損害機率。
- Split / 資訊條件：不同collection/curation/RL/VLA設定分開；5task IL子集不代表全32皆同程度實驗。
- 來源關係：BEHAVIOR1K與RoboCasa任務加damage觀測 / reward / termination；共享goal與backend instantiations。
- 可復用：為同一goal增加保護物件 / 低破壞條件的直接先例，規則差異應獨立可查。
- 待核 / 限制：damage threshold跨材料 / 跨後端的物理標定程度須另驗證。

P123 WatchAct (2026)

原作：<https://arxiv.org/abs/2606.26443>

本次PDF：<https://arxiv.org/pdf/2606.26443v1>

PDF SHA256：42a137d5b56c9e1dd7d421cba16f8f06fe42cace6418e7338136400df3e7954c

閱讀頁：1、2、3、4、5、6、8、14、15。14task完整taxonomy、3K個案、video-sim配對、4項驗證與plan/physical/end-to-end協定。

- 研究型別：人類觀測到機器人轉移；人類示範與技能轉移
- 領域：居家整理與清潔、通用物件與機動作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：LIBERO配對真實桌面影片；11桌面regions + 6container regions只是命名區域，非17個環境。
- 任務：14task scenarios歸4認知domains；event、procedure、implicit intent、episodic，含模仿、反轉、恢復舊位置、續作、修錯、條件分支。
- 題數 / 資料：3,000 video-language-simulator bundles；policy實驗每task10trials，與全部3K的plan reasoning範圍分開。
- 評估方式：Plan SR在symbolic executor；Task SR在物理simulation；PR完成子goal比例。；順序唯一task直接比oracle，允多解的task比symbolic終態；oracle-plan execution與integrated pipeline分開。
- Split / 資訊條件：LIBERO-finetuned policies轉到paired tasks；新物件/指令in/out-domain另列，固定每command300steps。
- 來源關係：LIBERO擴新物件 / predicate；LLM先產spec再照spec拍人類video，不是從任意網路video全自動轉robot。
- 可復用：最接近『影片→任務規格→可執行場景』的前作；還受限於Pick/Place/Open/Close，排除pour/wipe/cut/stir。
- 待核 / 限制：physical評測每task10trials中task指型別或instance的manifest需核，不先乘成3萬或宣稱3K全測。

P124 RoboReel (2026)

原作：<https://arxiv.org/abs/2609.08209>

本次PDF：<https://arxiv.org/pdf/2609.08209v2>

PDF SHA256：4f0b2629e1e663390e169e7ae24496406246958dbec7bb20f3973de31a9e34ff

閱讀頁：1、2、3、4、5、6、7、9、21、24、25、27、29。10task、4suites、配對蒐集、附錄完整統計、success predicate和eval banks。

- 研究型別：人類觀測到機器人轉移；人類示範與技能轉移
- 領域：居家整理與清潔
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：1個實際桌面rig與ManiSkill3/SAPIEN配對場景，4人類camera views；calibration與distractors另分setting。
- 任務：10task（推/抓方塊、抽屜、鍋蓋、烤麵包機、碗盤、籃子、玩具收納、堆杯）；4suites ND/WD/ED/PD，不是40語義task。
- 題數 / 資料：正文2,000ND/WD human demos；附錄含PD共3,000human demos = 12,000視角mp4，另2,000robot trajectories。每結果cell3runs×20 = 60rollouts。
- 評估方式：simulation goal predicates；比如drawer只需關至少一半、toaster80%行程，不能與更嚴格同名task直接比。；表格報3runs mean/SEM；SeeDo僅5項支援task，N/A不是0。

- Split / 資訊條件：每task-condition 100 human demos取80train/20eval；oracle-filtered initial-state banks固定初態。
- 來源關係：PartNet-Mobility + SAM3D real twin；explicit/latent/keypoint三種LfO代表比較，借不同既有policy。正文稱接受後發布，素材取得待核。
- 可復用：可借真實human→sim配對及同條件多方法對比；不應把camera/views檔案量作新增題量。
- 待核 / 限制：100seed與每bank 300entry在同段並列，需原生manifest釐清最終bank量；發布可得性尚未驗證。

P127 BridgeData V2 (2023)

原作：<https://arxiv.org/abs/2308.12952>

本次PDF：<https://arxiv.org/pdf/2308.12952v3>

PDF SHA256：aa5fdac48bf9122b22f88150d45575cb0685f2a2f761ca6fc570be743022819b

閱讀頁：1、3、4、5、6。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：機器人資料與通用策略；真實操作benchmark
- 領域：居家整理與清潔、餐飲與烹飪、衣物與洗護
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：24environments，含7toy kitchens及tabletops/sinks/laundrysetups，4環境類別。
- 任務：13skills；同skill換object可成不同原作task，未報全庫正規化task總數。
- 題數 / 資料：60,096trajectories = 50,365expert+9,731scripted；主task每method 10trials。
- 評估方式：tasksuccess；goalimage與languageconditions分別比較。
- Split / 資訊條件：seen/unseenobject/environment/otherinstitution；RT1input解析度與history較大須註記。
- 來源關係：BridgeData原版擴充，後被OXE/OpenVLA/Octo重用。
- 可復用：補家電、表面、衣物與顆粒工具操作；保留human/scripteddemo品質型別。
- 待核 / 限制：13skill不是13全部task；不同原作method觀測預算未完全一致。

P128 RoboNet (2019)

原作：<https://arxiv.org/abs/1910.11215>

本次PDF：<https://arxiv.org/pdf/1910.11215v2>

PDF SHA256：01a03705dfb76192445b8c09fa3e85d67a1d9165b2c00df3672cfd10cc66052a

閱讀頁：1、3、4、5、6。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：機器人資料與通用策略；跨資料集整合與評測方法
- 領域：通用物件與機動作業
- 用途歸納：核心目標是把未知物件推或抓放到指定位置，歸入跨場域物件搬移作業。
- 環境：4lab environments、113camera configurations、7arenatypes等不同環境層級。
- 任務：主要objectrelocation，可用推或抓放；manyrobots不增加相同數量goal families。

- 題數 / 資料：15Mframes、約162Ktrajectories；7platforms，Table1caption稱6arms有文字差異。
- 評估方式：endgoal distance與operator判斷是否覆蓋goal；作者明言不同experiments不可直接比難度。
- Split / 資訊條件：held-out robot或view再fine-tune300–400targettrajectories；不叫完全zero-shotrobottransfer。
- 來源關係：多institution資料與existingrobotcorpora整合；同物理trajectory可能多view。
- 可復用：重要早期整合前作；以哪種目標、哪種資訊與哪個分母比較，比合併大小更關鍵。
- 待核 / 限制：release-version軌跡精確數及scene去重待manifest；不從15Mframes推testcases。

P129 RH20T (2023)

原作：<https://arxiv.org/abs/2307.00595>

本次PDF：<https://arxiv.org/pdf/2307.00595>

PDF SHA256：6156500a1340a2e976681f0f8deea8ce493fb4af227d8a5b2696cb3c384bb755

閱讀頁：1、2、3、4、5、6。147task來源、7硬體配置、pairing階層、110K資料與實際few-shot實驗。

- 研究型別：機器人資料與通用策略；人類示範與技能轉移
- 領域：居家整理與清潔、裝配與生產作業、通用物件與機動作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：7robot configurations、>50table covers；covers不是不同場景layout。
- 任務：147tasks = 48選自RLBench + 29MetaWorld + 70自定義；42verbs是skill標籤，不是147完全獨立新設計。
- 題數 / 資料：>110K robot sequences與等量human sequences；hierarchy可配出數百萬pairs但不是同量獨立影片。本文ACT主實驗只在1個block-to-weight任務，每configuration20trials。
- 評估方式：人類收集時0–9quality、成功/失敗約10:1；ACT實驗分reach/grasp/place success，60秒上限。
- Split / 資訊條件：新環境含新camera/tablecover/robot；pretrain335同task + 195相近task，fine-tune75demo起，再縮小資料。
- 來源關係：RLBench與MetaWorld任務規格被實拍移植；新實拍資料是新素材，但goal定義有上游來源。
- 可復用：是從前作選task再擴新task、兼有人類影片與robot軌跡的重要前例。
- 待核 / 限制：paired影片之精確例項對應與跨機體可比性需原生metadata匯入。；DROID原作表I將RH20T依unique multi-view trajectories記為約13K，與RH20T原作110K口徑不同；保留兩種出處，未完成原始manifest去重。

P141 HoloAssist (2023)

原作：<https://arxiv.org/abs/2309.17024>

本次PDF：<https://arxiv.org/pdf/2309.17024v1>

PDF SHA256：af4fda7dcdcc0e5c9e4e4649f19bea3da6b3afe52e7a83d1adc8e7a79c011421

閱讀頁：1、3、4、5、6、7、8、9。20task來源、sessions/標籤、mistake/intervention/forecasting、split與指標。

- 研究型別：輔助與協作；對話協作與任務完成
- 領域：餐飲與烹飪、辦公與教育、工藝與修繕、裝配與生產作業、協助、交接與陪伴
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。

- 環境：HoloLens2 wearer + 遠端instructor；16物件種類，非16場景。
- 任務：20程式；414coarse action classes；mistake detection、intervention type、3D手預測及action recognition。
- 題數 / 資料：2,221sessions、166小時、222人 / 350pairs；1,545train、213val、463test。錯誤/介入表只評10%全資料子集。
- 評估方式：動作top-1/5；錯誤F-score與precision/recall；3種intervention分類。；手軌跡看過去3秒、預測0.5/1/1.5秒，用MPJPE釐米；只保留正確action。
- Split / 資訊條件：每task按session70/10/20，並非保證參與者或instructor/performer pair全互斥。
- 來源關係：新錄human-human互動；字幕 / 動作 / 介入共用session，非多個獨立資料庫。
- 可復用：提供人類教學、介入時機、程式錯誤與短期手預測；是協作型多模態來源。
- 待核 / 限制：fine action label總數和各endpoint精確可評IDs仍需manifest；不從coarse414推整套任務數。

P142 Habitat 3.0 (2023)

原作：<https://arxiv.org/abs/2310.13724>

本次PDF：<https://arxiv.org/pdf/2310.13724v1>

PDF SHA256：6383018901acbf7677050585da9a30707437cf7119def797be500f33a68021af

閱讀頁：1、2、5、6、7、8、20、25、26。avatar/HITL、2任務、59scene split、合作人口與metrics。

- 研究型別：輔助與協作；對話協作與任務完成
- 領域：居家整理與清潔、協助、交接與陪伴
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：HSSD211源scene中的59實驗scene = 37train/12val/10test；12base avatars不是12場景。
- 任務：2families：social navigation找/跟人；social rearrangement兩代理搬2物件。
- 題數 / 資料：附錄按scene抽train1000、val100、test15；即37Ktrain、1,200val、150test基底episodes，協作partners另作條件。
- 評估方式：導航Finding Success/SPS/Following Rate/Collision Rate；rearrangement SR與relative efficiency對human-alone比較。
- Split / 資訊條件：未見scene + new partner population；oracle/learned low-level skills分開。導航主設定有持續humanoid GPS，不是隻憑RGB找人。
- 來源關係：HSSD、AMASS、SMPL-X、Habitat底座；human avatar使用kinematic attach等簡化，與real人類動力不同。
- 可復用：是可比較human/robot角色與partner泛化的重要底座，不能再當全新場景資產。
- 待核 / 限制：全來源211scenes和59實驗子集不能合併計數；不同HSSD版本與HomeRobot/PARTNR需scene ID對齊。

P144 CAP/EgoGym (2026)

原作：<https://arxiv.org/abs/2602.09017>

本次PDF：<https://arxiv.org/pdf/2602.09017v1>

PDF SHA256：b0428cf26ad882127851059de2fafebb3ae164e38f631b9d941ca8ac0ebbed44

閱讀頁：1、2、4、5、6、7、8、11。資料、接觸prompt、EgoGym設計、3task真實與跨機體eval、tool chaining。

- 研究型別：人類觀測到機器人轉移；模擬平臺與任務套件
- 領域：居家整理與清潔、辦公與教育
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：資料報424environments = Pick289/Open87/Close48，為作者收集配置口徑；EgoGym是程式生成MuJoCo套件。
- 任務：3utility task families：Pick、Open、Close；不因接觸座標不同自動變新語義任務。
- 題數 / 資料：20,365human-tool demonstrations、23.1小時；real Pick250trials，Open/Close每checkpoint100trials；EgoGym有915Objaverse object pool。
- 評估方式：task success；oracle human contact prompt、VLM contact prompt、retry設定分開。
- Split / 資訊條件：real新scene/object zero-shot；sim用作training loop model selection，不能當獨立未見test。
- 來源關係：Objaverse assets + iPhone手持工具資料；CAP可作高階模型tool calls的低階utility。
- 可復用：支援multimodal tool use與robot skills組合，但示範用contact anchors、主eval有oracle條件，應明列。
- 待核 / 限制：424是否跨Pick/Open/Close具有同址重用需ID核；EgoGym完整eval bank量待code。

P145 NIABench (2026)

原作：<https://arxiv.org/abs/2605.01368>

本次PDF：<https://arxiv.org/pdf/2605.01368v1>

PDF SHA256：add5ffdd033bc8c450f79b317f31c0df3735d7a4789a9e8f833e3dbcab4f5b12

閱讀頁：1、2、3、4、5、6。2K來源、7test tasks、非中斷規則、text-only狀態與3指標。

- 研究型別：輔助與協作；對話協作與任務完成
- 領域：居家整理與清潔、餐飲與烹飪、辦公與教育、協助、交接與陪伴
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：AI2-THOR四room categories；4是型別，非精確四個scene IDs。主model採文字state，沒有raw visual perception。
- 任務：7test tasks：cut tomato、toast bread、watch TV、work、sleep、study、shower；2,000訓練script episodes，human主程式不允許被中斷。
- 題數 / 資料：2K corpus再分train/val；7個代表evaluation episodes；75%一個oracle assistance、20%兩個、5%無需協助。
- 評估方式：SelectionAcc比oracle step-action pair；HumanStepSaved減少的人類primitive steps；SuccessAcc查最終sim state。
- Split / 資訊條件：2K按scene/oracle數分train/val，7held-out另設；real只2小型驗證任務。
- 來源關係：AI2-THOR高階動作adapter；800atomic actions是候選動作詞彙，不是800已實作工作任務。
- 可復用：可加不打斷人類、適時協助與no-op合法答案等規則；不能宣稱2K都為held-out test。
- 待核 / 限制：7代表情境內是否另有多個隨機initial seeds及確切case量需code核。

P146 DexH2R (2025)

原作：<https://arxiv.org/abs/2506.23152>

本次PDF：<https://arxiv.org/pdf/2506.23152v3>

PDF SHA256：c48a1c58f5201ee324223c711cba95a429ea7446bc43e4d59f452e829eda1709

閱讀頁：1、2、3、4、5、6、7。data/rig、handover動態定義、完整split、pose與trajectory指標。

- 研究型別：輔助與協作；靈巧手操作benchmark
- 領域：協助、交接與陪伴
- 用途歸納：核心就是把人手中的物件交給機器人，歸入協助與交接用途。
- 環境：UR10e + ShadowHand固定capture setup，18視角（含2wrist ego），不是18環境。
- 任務：1核心human→robot handover family；56物件 / 39人，包含動態接近與終態抓握。
- 題數 / 資料：4,282 trials、456K frames、79,911成功grasp poses；2,888 train / 591 val / 803 test trajectories。
- 評估方式：grasp succ1/succ6外力穩定、penetration、diversity；approach success、trajectory length、inference frames、safety率。
- Split / 資訊條件：test含新object/news subject、new object/seen subject、seen object/news subject三群；不是803獨立任務語義。
- 來源關係：真實teleoperation human-object-robot互動，grasp模型另用DexGraspNet預訓練。
- 可復用：補人機交接、動態手型 / 接觸安全，區分pose、trajectory及物理handover完成。
- 待核 / 限制：每test子群細分ID與final pose對母trajectory的多對一關係待manifest。

P147 HRI Bench (2026)

原作：<https://arxiv.org/abs/2607.13056>

本次PDF：<https://arxiv.org/pdf/2607.13056v1>

PDF SHA256：d779bea84ddd0cbca254797e628b09dbf95118efa086cfe333dd6156a4a2ded2

閱讀頁：1、3、4、5、6、7。role scripts、13 tasks、786過濾池、50/10真實split與coordination metrics。

- 研究型別：輔助與協作；對話協作與任務完成
- 領域：協助、交接與陪伴
- 用途歸納：按人的指令、時機和動作完成協作，涵蓋交接、同步、讓行及受幹預後續作。
- 環境：Franka simulation結合合成人類骨架/trajectory；候選由2K生成並篩。
- 任務：13 role-conditioned tasks；Instructor / Collaborator / Intruder三角色。
- 題數 / 資料：2,000候選中786通過；正文實驗每task 50 adaptation + 10 held-out，因此650 adaptation / 130 held-out。摘要『>650 evaluation episodes』不等於主實測test量。
- 評估方式：CSR/time/idle、temporal sync/latency/order、collision/contact/contradiction/disruption；partial安全summary需按適用component。
- Split / 資訊條件：固定policy無關Intruder擾動時序；real 3 task各10 trials，只是adaptation驗證。
- 來源關係：生成scripts/human motion並sim驗證；兩個同名HRI Bench不得合成同一來源或版本。
- 可復用：加入等待、同步、角色及幹預恢復規則；資料候選通過不等於全部是test。
- 待核 / 限制：786與13×60=780剩6條用途未明，需manifest；摘要650 eval與正文130 held-out須分列。

P148 Assistax (2025)

原作：<https://arxiv.org/abs/2507.21638>

本次PDF：<https://arxiv.org/pdf/2507.21638v3>

PDF SHA256：53953a170eca350244258f44b0b043e960f2bcece29e1074e805ab251bc95547

閱讀頁：1、3、4、5、6、7、8、9。5assistive tasks、robot/human控制、preferences、630partner池與MARL/AHT評測。

- 研究型別：輔助與協作；協作控制benchmark
- 領域：個人照護、協助、交接與陪伴
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：MJX/JAX五種assistive配置，使用簡化rigid geometry；不是臨床或柔性皮膚物理驗證。
- 任務：Scratch、Tooth Brushing、Feeding、Bed Bathing、Arm Assist；force/speed/contact偏好另外引數化。
- 題數 / 資料：每task630pretrained humanoids；AHT以5train/625unseen partners；MARL每曲線16seeds與64eval episodes。
- 評估方式：task/preference return分開，跨任務min-max normalized mean、bootstrap95%CI；新partner泛化。
- Split / 資訊條件：partner-disjoint；挑5個high speed preference為train是刻意困難設定；精確episode/context數不等於625新task。
- 來源關係：Assistive Gym inspired任務，Brax humanoid與MJX；原始Assistive Gym需補為上游來源。
- 可復用：補個人照護、人類偏好及協作適應；沒有固定統一題庫上限。
- 待核 / 限制：不同partner/preferences的物理對應與真實使用者有效性未等同驗證。

P151 H2R-Bench (2026)

原作：<https://arxiv.org/abs/2608.13049>

本次PDF：<https://arxiv.org/pdf/2608.13049v1>

PDF SHA256：ec3fb6258fea92eda2ba4240561afd8f307606a133031b63ad12d666306af015

閱讀頁：1、2、3、4、5、6、11、14。source-relative定義、120→240cases、6家族、native interface與五metric。

- 研究型別：世界模型與預測表示；世界模型與影片生成評測
- 領域：衣物與洗護、通用物件與機動作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：EgoDex test來源影片，沒有配對可執行robot simulator環境。
- 任務：6物理變化families：rigid、mechanism、insertion、deformable、bulk、surface；目標2種embodiment。
- 題數 / 資料：120段5秒source clips×2embodiments=240transfer cases；每family20source。11generators的輸出影片數不是新題數。
- 評估方式：M1goal/M2events/M3contact/M4embodiment由3個MLLM按0–4rubric評；M5為video quality。；每metric25sampled frames；H2RCORE加權contact與embodiment共60%，屬影片證據評分，非實際控制成功。
- Split / 資訊條件：EgoDex test衍生；video-conditioned與frame-conditioned介面分組，不能不控制輸入資訊比較。
- 來源關係：EgoDex來源；與H2RBench human-transfer及RoboWM-Bench不同任務，不能因名稱相似合併。
- 可復用：可加入human→robot影片轉移端點；應作世界模型章，與可執行操作題數分開。
- 待核 / 限制：contact的影片可見正確不能保證力 / 深度 / 可達性，仍缺物理execution證據。

P152 RoboWM-Bench (2026)

原作：<https://arxiv.org/abs/2604.19092>

本次PDF：<https://arxiv.org/pdf/2604.19092v2>

PDF SHA256：4450ceffa72850511da6c91b3ce6f73bc070d372104dc8f60ce6fbf8f84ed566

閱讀頁：1、3、4、5、6、7、14、15。video→action兩路、task suite、主表與sim附錄、10初態與execution成功。

- 研究型別：世界模型與預測表示；世界模型與影片生成評測
- 領域：餐飲與烹飪、衣物與洗護、通用物件與機動作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：LeHome/IsaacSim原生與real-to-sim桌面；固定camera、隨機物件初態。
- 任務：主表8human-hand及8robot-task條件，附錄另6simulation-native條件；含同名重用，不直接加成22語義task。
- 題數 / 資料：每task10個共同initial configurations；Cosmos-finetune每task50trajectories是額外訓練。bimanual附錄又為另條件。
- 評估方式：generated video經HaMeR retargeting或IDM轉action，再進simulation；key nodes全通過且達goal才Task SR，另Step SR。
- Split / 資訊條件：固定初態 / 種子跨model；human與robot影片使用不同action extraction pipeline，pipeline誤差須分開分析。
- 來源關係：LeHome底座與real reconstruction，PAI-Bench作同影片視覺分數對照。
- 可復用：提供生成影片到物理可執行性的橋梁，但需把影片模型和action extractor責任拆解。
- 待核 / 限制：全部task條件與語義去重清單需release manifest；retargeting/IDM失誤會影響world model分數。

P164 The Imitator Game (2026)

原作：<https://arxiv.org/abs/2608.22301>

本次PDF：<https://arxiv.org/pdf/2608.22301v1>

PDF SHA256：f38c19c22603063351fd35a218cc5a1477609c973c0a79cbe972a2bb78f01e1b

閱讀頁：1、4、5、6、7、8、20。L0-L3保留/變更條件、IG-10K規模、六domains、sim/real及Arena協定。

- 研究型別：人類觀測到機器人轉移；人類示範與技能轉移
- 領域：居家整理與清潔、餐飲與烹飪、包裝、倉儲與物流、零售與購物、實驗室操作、醫療與手術支援
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：200+ paired task-scene variants；同human clip可對多level robot場景，非全新independent demonstration。
- 任務：50+base tasks，6生活/工作domains（分量12+7+17+4+6+7=53）；實驗10tasks（5seen+5unseen）×4levels。
- 題數 / 資料：11,720real paired episodes+10Ksim pairs（sim重用human clip）；每task-level sim10trials、real5trials。15/30/45task訓練套件相互包含。
- 評估方式：sim SR與ordered subgoal SR；人類SUCCESS/PARTIAL/FAIL、0-10imitation quality、pairwise preference。；L0動作近似、L1佈局改變、L2物件替代、L3功能替代；level是demo-execution pair屬性，不是task固定難度。
- Split / 資訊條件：sim/real分開訓練與比較；same domain/setting/task/level/episode才做A/B，少數task不定義L3。
- 來源關係：ManiSkill3、手工waypoints、VR真機pairs；與RH20T等比較，但多level共用源human clip。

- 可復用：是意圖 / 功能替代及多域human-robot資料近鄰；我們須納入其6用途群與可替代規則。
- 待核 / 限制：53分域與表2『50 tasks』的版本口徑須manifest確認；不可把4levels機械乘所有task。

P165 LIBERO-Recover (2026)

原作：<https://arxiv.org/abs/2609.05178>

本次PDF：<https://arxiv.org/pdf/2609.05178v3>

PDF SHA256：ee23bf31934cc0e262b4b30458be149df135ec3695c866939c482c0b55fe414a

閱讀頁：1、2、3、4、5、6、9。failure對normal variation的區分、2178scenario生成、恢復資料與RSR/RD/RC。

- 研究型別：穩健性、失敗與評測品質；錯誤辨識與程式恢復
- 領域：居家整理與清潔
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：LIBERO自然rollout失敗的state snapshots；不是2178不同room layouts。
- 任務：130上游tasks、4recovery levels；LIBERO100再拆90/10報告，不能另加兩suite。
- 題數 / 資料：2,178recovery scenarios；413training failure scenes有3,184human recovery trajectories，訓練使用場景排出最終eval。
- 評估方式：Recovery Success Rate完成原goal；Recovery Degradation比較failure前後；RC=1-task-level success率標準差。；RC公式實際是跨task變異，不完全等同文中所說同task不同failure的穩定性。
- Split / 資訊條件：六policy產failure，Qwen定位/分類；自然failure分佈不平衡。eval每task10trials、520step，需固定scenario/perturbation解讀。
- 來源關係：LIBERO延伸；失敗條件要execution-induced且需改plan但仍可恢復，不能把任何位置變化都叫failure。
- 可復用：可引入真實policy失敗狀態而非純人工擾動；恢復題需要前史與可恢復證據。
- 待核 / 限制：recoverability對每scenario的完整驗證證據、2178與training排除先後、eval task詞義需manifest查。

P166 SafeVLA-Bench (2026)

原作：<https://arxiv.org/abs/2606.00773>

本次PDF：<https://arxiv.org/pdf/2606.00773v2>

PDF SHA256：ecb59f541415c25bcb45263b2c7058d15a124829c8dab6d7b5eac681f36c1f4a

閱讀頁：1、3、4、5、6、34、46。STL庫、8scored families、適用性registry、58tasks/27entries及指標定義。

- 研究型別：穩健性、失敗與評測品質；安全與約束評測
- 領域：居家整理與清潔、餐飲與烹飪
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：LIBERO + RoboCasa365兩host，事後instrumentation保留原生觀測/動作/初態/success。
- 任務：58tasks = LIBERO四10-task suites + RoboCasa365 atomic-seen18tasks；8safety families歸scene/object/robot三group。

- 題數 / 資料：LIBERO每model-suite200episodes (10×20)，RC每task50；24distinct policies、27policy-host entries不是27benchmarks。
- 評估方式：native SR、Safety、Success-but-Unsafe、Violation Severity Index；VSI是spec-normalized worst violation depth。；有意義且signals可用才套STL，額外diagnostics不影響Safety；代理threshold不是物理安全認證。
- Split / 資訊條件：固定seeds配對；RC policies有兩個獨立seed groups，跨組unpaired；不跨host直接排總榜。
- 來源關係：對既有LIBERO/RC trajectories加規則評分；不是新生成58個目標任務。
- 可復用：本庫規則擴充應借其適用性registry與success/safety分離，而不是每task強乘所有評估方式。
- 待核 / 限制：缺人類近距離、實際spill/thermal等signals；composite全程排除某clause可能漏掉部分phase。

P167 DexGarmentLab (2025)

原作：<https://arxiv.org/abs/2505.11032>

本次PDF：<https://arxiv.org/pdf/2505.11032v3>

PDF SHA256：447ce546d76be47536883a64aac1e9fc7ea1f214433bc6915d9acce2eab57f65

閱讀頁：1、2、4、5、6、7、8、9、10、18、20、32。15task場景、物理抓持修正、14實測task、100demo/50episode、real驗證。

- 研究型別：布料 / 柔性物操作；柔性物操作benchmark
- 領域：衣物與洗護、個人照護
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：雙UR10e+ShadowHand，15task scene設定；>2500garments/8類不是2500不同task。
- 任務：15定義含fling/fold/hang/wear/store；主simulation實驗14task（wear glove未在主表），不能報全15同程度測完。
- 題數 / 資料：每實測task100generated demonstrations；每task50episodes與3seeds；real4task各3garments×5初態=15trials。
- 評估方式：task-specific成功與mean/std；demo生成成功率和policy成功率分開。；以friction/adhesion取代GarmentLab attach blocks，兩者同名摺衣控制難度並不相同。
- Split / 資訊條件：garment形狀/初態/位置變化；文中2%test training data是模型離線切分，不等於50episode物理eval。
- 來源關係：ClothesNet與UniGarmentManip/GarmentLab相關資產和方法；更改抓持物理真實差異。
- 可復用：靈巧雙手與穿衣 / 收納廣度的重要來源；應追實際物理規則差異。
- 待核 / 限制：各task成功predicate與garment ID split仍需完整config清單，不能只以模型shape庫算coverage。

P168 HRIBench (perception, 2025) (2025)

原作：<https://arxiv.org/abs/2506.20566>

本次PDF：<https://arxiv.org/pdf/2506.20566v1>

PDF SHA256：7148bb0244bccd22b8b8050d609fa6304f05059d5224f76470c5b87616428af7

閱讀頁：1、2、3、4、5。5domain來源、1000VQA、非語言線索、自錄/復用與accuracy-latency表。

- 研究型別：理解、推理與規劃；人體與互動感知評測
- 領域：社交與溝通、協助、交接與陪伴

- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：Kuri/Quori自錄非語言互動＋既有公開資料；5domains是能力群，非5物理環境。
- 任務：nonverbal、verbal intent、human-robot-object relation、social navigation、person identification五種。
- 題數 / 資料：每domain200VQA，總1000；overall accuracy/latency排除person identification，因此總體比較用其餘800題範圍。
- 評估方式：逐題accuracy與latency秒；unsupported/refused identity標N/A，不能填0後和其他模型無條件平均。
- Split / 資訊條件：主為VLM zero-shot評測；各domain人類baseline由不同expert完成。
- 來源關係：HandMeThat加視覺、CoMaD、MuSoHu、YouTube影片與自錄gestures；不是2026interaction-centric HRI Bench。
- 可復用：提供HRI感知與即時性題型；選合宜導航路徑的VQA不等於實體導航執行。
- 待核 / 限制：不同question形式random accuracy不同，不能全統一25%random；上游素材和case IDs未匯入。

P169 X2Real (2026)

原作：<https://arxiv.org/abs/2609.27449>

本次PDF：<https://arxiv.org/pdf/2609.27449v1>

PDF SHA256：5cff92f0d0a008824b9299b9e8f9259404e6177fd54a55c4d4eede0aff18f521

閱讀頁：1、3、4、5、6、13、14、23、24、27、28、29。44task架構、training/eval分離、資產/DSL、DAG metrics、desktop/mobile與sim-real驗證。

- 研究型別：一般操作 benchmark；模擬操作benchmark
- 領域：居家整理與清潔、通用物件與機動作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：Mana/IsaacLab場景；多embodiments與green-booth訓練配置，appearance/task/embodiment分別擾動。
- 任務：44simulation tasks / 10能力維度；含3mobile tasks與3challenge tasks，能力數不是生活domain數。
- 題數 / 資料：近300小時訓練軌跡；desktop各300demo、mobile各1,000、3challenging總>20K trajectories；mobile eval每task每ID/OOD40episodes。
- 評估方式：DAG依賴達成、無failure且sink nodes完成才success；latched node進度加權10分；層級macro平均避免大類壟斷。；sim-real本文overall r為success0.74/progress0.84，精密task更弱，不用一般task子集高r外推全部。
- Split / 資訊條件：green-booth demonstrations與OOD背景/task/robot配置分離；模型不取得frame-level subtask標籤。
- 來源關係：Mana基於IsaacLab/Arena，資產來自多3D庫與AIG3D；不等同建立完整新生活任務ontology。
- 可復用：統一runtime、DAG過程與收集/評測分離可借；主張泛化應按能力與實測subset支援。
- 待核 / 限制：desktop完整eval case IDs與3challenge是否納同一overall分母需release設定核。

P170 MotionForge (2026)

原作：<https://arxiv.org/abs/2609.25689>

本次PDF：<https://arxiv.org/pdf/2609.25689v1>

PDF SHA256：26bf90c839b269529d60ec9d7b97df9c98670c0297089faf96f14d7e2bfc8c1a

閱讀頁：1、2、3、4、5、6、7。40semantic families、motion taxonomy、即時協定、生成validation及ID/OOD50seeds。

- 研究型別：一般操作 benchmark；動態操作benchmark
- 領域：裝配與生產作業、包裝、倉儲與物流
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：4scene families：Factory Conveyor、Circular Motion、Home Tabletop、Embodied Interaction；5K背景variation非5Klayouts。
- 任務：40semantic tasks、11motion patterns；17long/23short，僅改速度的variants合併為同family。
- 題數 / 資料：約20K產生demo中選每task50 = 2Ktrain；每task每ID/OOD condition50固定seeds，7policies另算rollouts。
- 評估方式：macro task success；policy推論時環境仍以120Hz進行，latency對成功有實際影響。；LH依8秒+2skills或20秒門檻定義，作者明示長不一定更難。
- Split / 資訊條件：object/background/light/speed單factor與joint OOD；保留不支援最高speed的task例外。
- 來源關係：generated scenes + 共用oracle skills；task質檢要求oracle>50%為生成合格條件，不是learning-policy成績。
- 可復用：補傳送帶、拋接與動態速度規則；可區分場景生成量與語義task量。
- 待核 / 限制：不同硬體的native inference latency不可無條件比較，需固定evaluation hardware/runtime。

P171 Bench2Dex (2026)

原作：<https://arxiv.org/abs/2609.15726>

本次PDF：<https://arxiv.org/pdf/2609.15726v1>

PDF SHA256：f70ca3ecb4dd8fc9a1acc6410a0bd4e370203ca65331b3fcc76209996fb8ed03

閱讀頁：1、2、3、4、5、6、7、8、10。12hands、26task-embodiment settings、tactile介面、stable success及4channel協定。

- 研究型別：一般操作 benchmark；靈巧手操作benchmark
- 領域：裝配與生產作業、通用物件與機動作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：IsaacLab bimanual配置；12hand morphologies、6views，無獨立房屋總數。
- 任務：26task-embodiment settings，不能先乘12手型為312已完成tasks。
- 題數 / 資料：約1.3Kteleop demonstrations；4policy×26settings×4channels×50rollouts = 20,800evaluation executions。每policy每channel1,300。
- 評估方式：terminal predicate需穩持預設0.5s；LSCR記錄依賴合法的階段；success time只在成功episode量。；baseline只用RGB/關節，觸覺資料支援不等於已證實tactile policy收益；觸覺為幾何depth proxy。
- Split / 資訊條件：None/Equi/Inv對齊anchor，Full獨立抽樣，不假定逐case困難單調。
- 來源關係：已有hand meshes + 統一tactile registry；未對齊真實觸覺hardware。
- 可復用：可借跨手型 / 觸覺訊號規格與穩定判分；不要把支援的感測軸當實評完成量。
- 待核 / 限制：26設定的unique semantic task去重與tactile-conditioned baseline尚不同完成。

P172 LabUtopia (2025)

原作：<https://arxiv.org/abs/2505.22634>

本次PDF：<https://arxiv.org/pdf/2505.22634v2>

PDF SHA256：b0b27a506f9ec028871b09e93a5a3aead74e382739b65fa5092af90ab062e862

閱讀頁：1、3、4、5、6、7、8、9、10。LabSim/LabScene、scene與儀器來源、5levels、success協定及實驗範圍。

- 研究型別：一般操作 benchmark；專業場域操作benchmark
- 領域：實驗室操作
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：約100expert-reviewed lab scene assets，另程式填入儀器；物件類別/scene數不得相加。
- 任務：摘要30distinct tasks、結論>30，§4另稱>50；5levels從atomic到mobile，但level3主要是generalization條件，並非全是新語義task。
- 題數 / 資料：各level有demo/rollout實驗，本文已讀段未報統一case總量；表2列10atomic及6短流程，long流程另3例。
- 評估方式：task完成後goal tolerance需維持2秒；success rate與long流程stage分開。；chemical engine由知識庫+LLM推state變化，不等同第一原理化學物理。
- Split / 資訊條件：novel shape/material/layout設定；全在simulation，real transfer留未來。
- 來源關係：designer scene assets、PubChem資料與IsaacSim；procedure模板需逐task核，不從約100場景×50tasks直接乘題量。
- 可復用：補實驗室用途與流程；其階層是設計/泛化混合，需用共同task粒度對齊。
- 待核 / 限制：最終task registry究竟30或>50，以及scene/instrument各精確IDs，需code版本確認。

P173 LabDex (2026)

原作：<https://arxiv.org/abs/2608.18618>

本次PDF：<https://arxiv.org/pdf/2608.18618v1>

PDF SHA256：0d4be91ff766826af94f01245c225e27a15cfb88fae60183c9393f1af17ee41c

閱讀頁：1、3、4、5、6、7、11、12、13。層級資料、real/sim平臺、atomic/composite/workflow完整表及success。

- 研究型別：一般操作 benchmark；專業場域操作benchmark
- 領域：實驗室操作
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：FR3/XHand實際工作站與配對simulation；3camera views非3場景。
- 任務：概述7atomic categories、30+atomic、10+composite、1workflow；實驗明列26atomic、表3九composite、1七步workflow。附錄定義composite10項。
- 題數 / 資料：概述8K+demo/1M+steps；real預設每task200train、sim50；每task每model50eval trials。
- 評估方式：goal穩定2秒；atomic SR，composite/workflow全成功、各atomic成功與平均已完成步數。
- Split / 資訊條件：初態在訓練範圍內隨機；novel objects/distractors另實驗，非主eval全部OOD。
- 來源關係：real teleop關鍵姿態對映sim，長流程可切atomic；不能把完整軌跡與各段全部當獨立新樣本。

- 可復用：是同SOP分不同粒度與執行平臺的例子；原子step、composite、workflow必須保留父子關係。
- 待核 / 限制：30+/10+概要與26/10完整清單之差異需最終manifest確認；real/sim資料量需分開。

P174 Labimus (2026)

原作：<https://arxiv.org/abs/2606.31037>

本次PDF：<https://arxiv.org/pdf/2606.31037v2>

PDF SHA256：103d1eb5ee800d0306734bab26f9242f067cff584fb84c9929cd3ea3869e7e3a

閱讀頁：1、2、5、6、9、10、11、12、14。SOP→DSL、6atomic/7步流程、3評分tier、4conditions與v0驗證邊界。

- 研究型別：一般操作 benchmark；專業場域操作benchmark
- 領域：實驗室操作
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：Tianyi humanoid於fume-hood工作站；digital twin與procedural layouts，>30functional assets。
- 任務：6atomic operations + 1個7step solid-weighing workflow；Tier2重評原task精度，不能算兩個新操作。
- 題數 / 資料：v0只實測4atomic + 1precision條件；每task-condition50episodes×3seeds = 150trials；其餘與整個Tier3仍未實驗。
- 評估方式：success、precision pass、conditional precision among successes、weighted step progress；S-P量成功與精度差距。；SOP的mass/position門檻是這個模擬規格，不代表已完成真實實驗室有效性驗證。
- Split / 資訊條件：100teleop demos/task，標準test佈局已有分佈移動，另light/texture/combined；3×4是設計矩陣，不是v0全部實測。
- 來源關係：ArtVIP資產 + IsaacSim；SOP解析會排除無physical effect的純觀察/記錄步，故完整科學程式仍有缺口。
- 可復用：可借SOP權重、數量精度及conditional metric；要如實標示設計完整度與實驗完成度。
- 待核 / 限制：未完成tool pickup/scoop-weigh/Tier3驗證；real-world validation明列未來。

P175 Pipette (2026)

原作：<https://arxiv.org/abs/2606.12936>

本次PDF：<https://arxiv.org/pdf/2606.12936v3>

PDF SHA256：72ad55814d9958242cd534f45f540f9bcd86bcd2bfbf21beaa2278e6c2bb93a3

閱讀頁：1、2、3、4、5、6、7、11、12、17。12tasks全表、資產庫、structured task註冊、augmentation驗證與100episode協定。

- 研究型別：一般操作 benchmark；專業場域操作benchmark
- 領域：實驗室操作
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：IsaacSim/IsaacLab場景；3robots、12tools、26equipment、55consumables、9instruments為資產分量。
- 任務：12wet-lab tasks = 4sample/culture、4lid/hatch、4placement；pipette-to-petri positioning不等同已量測真正移液量。
- 題數 / 資料：每task30human train demos + 成功篩選augmented；每model每task100eval episodes，即單資料設定1,200。

- 評估方式：依task pose/joint/geometric thresholds及持續時間判success；macro task SR。；語言parser只草擬配置，prim/threshold/evaluator仍需人驗證；success-verified augmentation不是新task。
- Split / 資訊條件：3models×raw/augmented條件，Panda為主但flask-shaker用AgileX；同task內固定機體比較。
- 來源關係：existing/generated USD assets、Hunyuan；replay重新渲染並同步state/action，不只是改畫素。
- 可復用：可補biomedical wet-lab器材用途與scene/task登記；須區分裝置操作與完成真正生物實驗。
- 待核 / 限制：all-asset唯一ID與各task primitives的實際精度需原生配置；某lid為virtual button觸發，不能當直接靈巧開蓋。

P176 AutoBio (2025)

原作：<https://arxiv.org/abs/2505.14030>

本次PDF：<https://arxiv.org/pdf/2505.14030v3>

PDF SHA256：987d557fe26642e96a1d4c9b3021c3d373717d4a5bc3f9eae48b5bc9de84df91

閱讀頁：1、4、5、6、7、8。特殊儀器physics/render、16task與9實測subset、100episode與mixed metric。

- 研究型別：一般操作 benchmark；專業場域操作benchmark
- 領域：實驗室操作
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：MuJoCo/Blender，single/dual-arm工作站；Aloha及UR5e不同end-effectors。
- 任務：16定義分3difficulty levels；實驗每level3項，共9tasks，非全部16。
- 題數 / 資料：9tasks各100demo=900train、792K+frames；每task100eval episodes、3runs。
- 評估方式：大多binary success；thermal mixer panel用relative progress，平均表不全是success percentage。
- Split / 資訊條件：20/100demo資料規模比較；held-out初態引數泛化；render兩版本共享軌跡。
- 來源關係：實驗室asset digitization；quasi-static liquid不模擬波/倒水，DexHand主要只控制thumb作簡化gripper。
- 可復用：補螺紋、旋鈕、顯示面板與精度規則；光學外觀逼真不能替代完整材料動力學。
- 待核 / 限制：16task的全部IDs與模型可用support需最終code核；不要把9task成績外推全16。

P177 H2RBench (human transfer) (2026)

原作：<https://arxiv.org/abs/2609.24778>

本次PDF：<https://arxiv.org/pdf/2609.24778v2>

PDF SHA256：dd841fb3a72307c335d2c7268ac813f8209a448dd2242d6e49db90da7a0169d1

閱讀頁：1、4、5、6、7、17。4task全表、fixed robot/human scaling、real-to-sim、90rollout及transfer metrics。

- 研究型別：人類觀測到機器人轉移；人類示範與技能轉移
- 領域：裝配與生產作業、通用物件與機動作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：4個real-to-sim task環境，PolaRiS/Marble/IsaacLab，real human由第三人稱multi-view錄製。

- 任務：4families：mug-to-plate、bowl stacking、donut insertion、sequential blocks-to-box。
- 題數 / 資料：robot demo budgets 40/100/100/100；human 上限 100/300/300/300；每method/task 90 randomized rollouts across 3 seeds。
- 評估方式：final/mean-stage SR；human 增益用 $\Delta \logit$ ；sim/real 分別訓練 policy，再以 $r/p/MMRV$ 比排名。
- Split / 資訊條件：fixed robot data、只增加 human demos；sim 與 real 是不同 pipeline 驗證，不是同一 policy 直接 sim2real。
- 來源關係：Polaris、TRELLIS、GELLO、四種既有 H2R 方法；與 human-only 預訓練資料庫不同。
- 可復用：提供人類資料規模增益的受控比較，無需靠多拿 robot data 製造規模優勢。
- 待核 / 限制：各 human/robot pair 是否一對一不應由 demo 預算推定；完整 IDs 需原生 release。

P178 RoboRecover (2026)

原作：<https://arxiv.org/abs/2609.28952>

本次PDF：<https://arxiv.org/pdf/2609.28952v1>

PDF SHA256：63986a4660ca344bb479e10ce0aa378f0c5b8a2ce86623d7725c5474f9a51faf

閱讀頁：1、3、4、5、6、13。scenario 構造、replay 驗證、filter、train/test 及 RSR；未逐行重現程式。

- 研究型別：穩健性、失敗與評測品質；失敗與恢復 benchmark
- 領域：居家整理與清潔
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：RoboTwin 和 LIBERO 兩個既有模擬後端，透過 action prefix 重播取得失敗狀態。
- 任務：原任務上的恢復情境；4 階段 $\times$ 4 偏差型別只有 9 個有資料的測試組，不能算 16 個完整任務家族。
- 題數 / 資料：2,000 recovery scenarios；兩個後端各 800 train/200 test，合計 1,600/400。訓練與測試 task names 有重疊。
- 評估方式：Overall RSR 以 scenario 平均；9 組 macro 另報。reference policies $\times$ 5 回合形成 20 次篩選，只留 10–90% 可恢復率，難度依篩選模型而定。；重播驗證位置差 $< 2\text{mm}$ 、末 5 幀 SSIM > 0.99 ；策略從恢復點初始化，不能讀取字首歷史。
- Split / 資訊條件：每後端 800/200；同 task 不同 scenario 可跨 split，不宣稱語義 task 完全未見。
- 來源關係：RoboTwin 與 LIBERO 原任務；natural、action-perturbed 與 human-constructed 三種失敗構造。
- 可復用：可擴充既有 task 的恢復規則，但增加的是恢復 cases；不自動增加生活 domain 或原始目標數。
- 待核 / 限制：每個被測 policy 對每 scenario 的重複次數需核最終執行 manifest；篩選成功率不可當新 policy 成績。

P179 REBOOT (2026)

原作：<https://arxiv.org/abs/2609.22591>

本次PDF：<https://arxiv.org/pdf/2609.22591v1>

PDF SHA256：1f5401dfe2a8209a83cb96780a43fbfa0938f8a743eb8285be793fbdd60cf6f5

閱讀頁：1、3、4、5、6、7、8。assembly 清單、精度層級、expert/recovery 資料、初態與實驗協定。

- 研究型別：穩健性、失敗與評測品質；精密組裝與恢復 benchmark
- 領域：裝配與生產作業

- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：真實雙臂WidowX/Trossen工作站；NIST Assembly Task Board #1。
- 任務：表2為9物件x安裝/移除=18tasks；精度、對稱性及5操作phase是task屬性。
- 題數 / 資料：18x(60 expert+60 recovery) = 2,160 demonstrations。§protocol寫每task/policy20rollouts，主分析卻用15x18x3=810，保留差異。
- 評估方式：逐task物理完成率，另按clearance、symmetry、phase及failure分析；初始物件3–6cm範圍變化，goal board固定。
- Split / 資訊條件：expert/recovery及模型設定受控比較；recovery demonstrations刻意重現先前觀察到的policy失敗。
- 來源關係：沿用標準assembly board；9物件不是9獨立工作環境。
- 可復用：補精密插接、對稱性與failure phase；組裝和拆解可保留相反目標關係。
- 待核 / 限制：p7的10 connector types與表2的9物件、20與15rollouts需要release核對；failure清單是否含slip也有版本差異。

P180 SafeManip (2026)

原作：<https://arxiv.org/abs/2605.12386>

本次PDF：<https://arxiv.org/pdf/2605.12386v3>

PDF SHA256：561f1135594da0aca29135e76d5abec42f8cac6a946d0f92c6380b1c213488fc

閱讀頁：1、4、5、6、14、15。8類/10模板、ManipVerse、事件監測、90host tasks及各policy協定。

- 研究型別：穩健性、失敗與評測品質；安全與過程規則benchmark
- 領域：居家整理與清潔
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：RoboCasa365及LIBERO；主RoboCasa多task實驗在pretraining scenes，target-scene實驗另列。
- 任務：50 RoboCasa+40 LIBERO=90 host task entries；8 safety categories、10 LTLf templates，只繫結適用task。
- 題數 / 資料：每policy/task50episodes，RoboCasa單設定2,500、LIBERO單設定2,000；不同訓練variant不是新題。
- 評估方式：native SR；每trigger violation V/N與unsafe exposure U/N，分母是觸發事件，非episode數。恢復後monitor可重新啟動。；LIBERO只有部分規則適用；支援10模板不代表每task實測10種違規。
- Split / 資訊條件：不同host/checkpoint/target設定分開，不能把pretrain-scene與target-scene結果直接比。
- 來源關係：重用RoboCasa365/LIBERO並增加ManipVerse predicate與DFA監測；和SafeVLA是不同評測規則。
- 可復用：任務聯集之外，另存task可適用的規則；安全規則數和語義task數各有自己的分母。
- 待核 / 限制：資料hours與原RoboCasa365文章版本有差異；需固定release，不能反改原作數值。

P182 SoftVTBench (2026)

原作：<https://arxiv.org/abs/2608.18701>

本次PDF：<https://arxiv.org/pdf/2608.18701v1>

PDF SHA256：1f353c40268ba3a98d5a2f51892e92c042f89ea87c7ccbe49c10c3ce956fe827

閱讀頁：1、3、5、6、7、8、9、13。40setting、rigid twins、ID/OOD抽樣、FEM evaluator與DSR。

- 研究型別：布料 / 柔性物操作；柔性物與觸覺操作benchmark
- 領域：餐飲與烹飪、通用物件與機動作業
- 用途歸納：歸納為易損物取放的通用作業；烘焙品形狀物件的放置情境另標餐飲處理方向。
- 環境：IsaacSim/IsaacLab/TacEx；10軟物件 + 10對應rigid twins，>50props是assets。
- 任務：4suites各10task settings = 40；主要skill固定pick-and-place，物件/位置變化不等於40個獨立動作家族。
- 題數 / 資料：4,000 expert demonstrations；ID每suite500 = 2,000episodes。OOD每soft suite/config900，兩suite共1,800；9個單factor條件不是完整交叉乘積。
- 評估方式：Task SR另報；DSR要求完成task且全程peak deformation $\leq \tau$ ， τ 由穩定抓持90th percentile預先校準。FEM states僅給evaluator。
- Split / 資訊條件：held-out初態；OOD light/mass/Young modulus各3級、單factor控制。以同seed/初態作對照。
- 來源關係：LIBERO風格spatial layouts與matchedrigid assets；touch rendering是模擬訊號。
- 可復用：同task加入材料保護規則的清楚範例；不能用不動來獲取低形變高分。
- 待核 / 限制： τ 是benchmark容忍度而非材料真實損壞點；continuous/binary gripper設定要控制。

P183 WireCraft (2026)

原作：<https://arxiv.org/abs/2606.18097>

本次PDF：<https://arxiv.org/pdf/2606.18097v1>

PDF SHA256：7f2bbb231c2ff416c001d7c06e6efc0d68691404f48ed4e22afde76e1ff48e9a

閱讀頁：1、2、3、4、5、6、7、23、25。三類DLO tasks、兩種physics、robot/data流程、success與real對照。

- 研究型別：布料 / 柔性物操作；線材操作benchmark
- 領域：裝配與生產作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：IsaacLab/IsaacSim；chain或FEM wire、UR5/Franka/Trossen三robot；可生成配置，無固定環境總數。
- 任務：3families：connector insertion、clip routing、channel seating；insertion選4connector shapes，其他代表場景仍有限。
- 題數 / 資料：script、RL、sim teleop、real資料；已讀協定未報全庫固定cases。real Ethernet每metric/setting10rollouts。
- 評估方式：reach為held plug距socket $\leq 2\text{cm}$ ，insert另要求真正插入；channel > 80% wire length入槽。；最佳checkpoint依eval reach挑選，屬best-observed成績；不可假稱獨立validation selection。
- Split / 資訊條件：7種real/sim資料mixtures以同40K checkpoint比較；額外65K結果不納主公平比較。
- 來源關係：同一3family經不同physics/embodiment重現；不可把backend數相乘當新語義task。
- 可復用：補線材穿引、插接與保持槽內的幾何判分，標示物理近似與場景覆蓋邊界。
- 待核 / 限制：文章寫接受後release，未據此宣稱目前資產已取得；全庫demo/case manifest待查。

P184 DLO-Lab (2026)

原作：<https://arxiv.org/abs/2606.04206>

本次PDF：<https://arxiv.org/pdf/2606.04206v1>

PDF SHA256 : 91128b16d310632077dd23caa908483ba75b8851a77808b98368fbce1dcea0b0

閱讀頁：1、2、3、4、5、6、7、18、19。10tasks、differentiable physics、演算法資訊條件、success appendix。

- 研究型別：布料 / 柔性物操作；線材操作與物理benchmark
- 領域：裝配與生產作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：Taichi/Genesis的rod與rigid/MPM coupling；近點kinematic抓持簡化，不是完整摩擦抓持。
- 任務：10tasks：8固定horizon與2長流程Letter Art/Wiring Ring；主要實驗state-based，不全是視覺策略。
- 題數 / 資料：main optimization/RL比較3seeds、預算內最高return。附錄RL每task15trajectories，GD單一optimized，CMA-ES選best checkpoint的top15。
- 評估方式：return與goal success；RL/GD/CMA-ES的資訊、樣本挑選與動力學梯度存取不同，不能視為統一closed-loop protocol。
- Split / 資訊條件：主比較沒有一套統一held-out visual split；VLM長流程與SmolVLA4task子集另列。
- 來源關係：物理模組及task設計；letter/rope shapes是幾何目標，非完整日常領域。
- 可復用：可借線材task定義，但做all-in-one比較需要先統一觀測、重置、預算與selection。
- 待核 / 限制：需release IDs才能建立所有randomized cases；不同algorithm native evaluation不可直接相加。

P185 RGBench (2025)

原作：<https://arxiv.org/abs/2511.06434>

本次PDF：<https://arxiv.org/pdf/2511.06434v2>

PDF SHA256 : abc60e4860b3f9e166eeb0391fbf21186ec162cf7ffa413ed321ba8851b61970

閱讀頁：1、2、3、4、5、6、13、15。garment來源、三primitive、real/sim pair、distance及performance benchmarking。

- 研究型別：布料 / 柔性物操作；柔性物模擬器評測
- 領域：衣物與洗護
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：配對真實dual-Piper/Jaka工作站與garment simulation；direct-vertex與robot-URDF modes分開。
- 任務：3manipulation primitives：Grasp/Fling/Fold；9garment types的real GT比較，主表是其中子集。
- 題數 / 資料：6,000+garment assets = 4,000+industry + 2,000+ClothesNet；非6,000eval tasks。已讀段落未報全部paired trajectory數。
- 評估方式：真實/模擬點雲的Chamfer與Hausdorff L1，r2s/s2r分開；runtime/memory/mesh vertices另測simulation engine。
- Split / 資訊條件：人工配對動作及材料/形狀引數；主要評測simulation fidelity，不是policy完成率。
- 來源關係：ClothesNet重用；BCM外部驗證不是新獨立資料源。
- 可復用：補benchmark的模擬有效性檢驗；這個評分層與policy task success有不同目的。
- 待核 / 限制：全部paired trajectory IDs及industry assets再分發範圍需release核；不要用mesh數充題數。

P186 BiFold (2025)

原作：<https://arxiv.org/abs/2501.16458>

本次PDF：<https://arxiv.org/pdf/2501.16458v2>

PDF SHA256：f80ff8748e8d36c77c1f3decdfdf8b86e43da9909071a194e963c876c3ce56f3

閱讀頁：1、3、4。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：布料 / 柔性物操作；柔性物操作benchmark
- 領域：衣物與洗護
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：VR-Folding/CLOTH3D重渲染，SoftGym；真實RGB-D衣物觀測。
- 任務：language-guided single/bimanual folding；新方向/位置規則與instructionparaphrase分開。
- 題數 / 資料：近4KVRdemos分成約7Kactions、>1Kunique prompts；90/10sample split。
- 評估方式：singlearm以meanvertexerror<0.0125m判success；bimanual另用image metrics，不預設相同判分。
- Split / 資訊條件：先flattenedcloth；H=3history支援指令歧義，未證明所有sample分割已按parenttrajectory群聚。
- 來源關係：VR-Folding既有demos + CLOTH3Dtextures、新增語言與actionparsing；不是全部新physical demonstrations。
- 可復用：補指定摺法、手別與歷史依賴；語言改寫不自動算新task。
- 待核 / 限制：部分只有真實影像推action展示，完整realautonomous成績分母需原始實驗核。

P188 DRAPER (2024)

原作：<https://arxiv.org/abs/2409.15159>

本次PDF：<https://arxiv.org/pdf/2409.15159v2>

PDF SHA256：82f9a63cec8b5a6595ee60eff3f5f7d00bfb25d91cfd2fbe557897633d230632

閱讀頁：1、4、5、6。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：布料 / 柔性物操作；柔性物操作benchmark
- 領域：衣物與洗護
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：RealAdapt Towels改SoftGym grasp近似；Franka與UR3e對照，camera/gripper差異顯式處理。
- 任務：flattening及3種foldpatterns：allcornersinward、corners-edgeinward、diagonal-cross。
- 題數 / 資料：flatteningtrain2Ktrajectories，foldtrain1K；UR3eablation每setting10trials。
- 評估方式：realflattening NC>95%且20steps內；simulation>99%/30steps；fold用IoU/proxy並承認自遮擋限制。
- Split / 資訊條件：materials/size/camera/platform泛化；各policy保持相近trainingbudget，非直接沿用原bestscore。
- 來源關係：既有四controller在共同deploymentframework；RealAdapt是grasping/physics規則衍生環境。
- 可復用：這類工作正是all-in-one需借鑑的共同執行/判分控制，而非只搬tasknames。
- 待核 / 限制：real與sim門檻不同不能混算同一SR；多層抓取和tweezerhardware要入taskinterface。

P191 ClothesNet (2023)

原作：<https://arxiv.org/abs/2308.09987>

本次PDF：<https://arxiv.org/pdf/2308.09987v1>

PDF SHA256：bdbcb57f9e8831c335e596f96e984f928bbd504a8bdd7e0be8ec0bcb191f02c9

閱讀頁：1、2、4、6、7、8。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：布料 / 柔性物操作；柔性物資料與感知評測
- 領域：衣物與洗護
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：約4,400garment meshes/11categories；ClothesNetM3,051可用subset，mesh不是環境。
- 任務：分類、boundarysegmentation、keypoints三感知端點；simfold直接控制vertices，dressing/hanging多為可支援用途。
- 題數 / 資料：3Dclassification1,984train/496testmeshes；2D2,455meshes渲染9,820images再80/20。
- 評估方式：classificationaccuracy、segmentationmIoU、keypoint品質；simfoldnegativevertexdistance，非完整robotgraspcontrol。
- Split / 資訊條件：2D按images切80/20，未在已讀段保證same-mesh views不跨split；3D子集量和3051全集不同。
- 來源關係：CGTrader等mesh整理，後被RGBench/GarmentLab等重用。
- 可復用：補garment資產/語義標籤，清楚區分perceptionvalidation與可互動環境。
- 待核 / 限制：資產種類不等於全部執行任務已驗證；不能把4400meshes稱4400robotcases。

P192 Phys-Liquid (2025)

原作：<https://arxiv.org/abs/2511.11077>

本次PDF：<https://arxiv.org/pdf/2511.11077v1>

PDF SHA256：827b09bcc3b8968cc32b21f332b5b31286c3784578fc04a00435cb0dd6b6700b

閱讀頁：1、2、3、4、5、6、11。渲染組成、100sequences、90/10切分、reconstruction與real驗證。

- 研究型別：布料 / 柔性物操作；液體感知benchmark
- 領域：實驗室操作
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：Blender/Mantaflow的5lab scenes、20containers、8lights、5colors、6orthographic views。
- 任務：單/多視角液體形狀與體積重建，未直接評robot pouring控制。
- 題數 / 資料：100simulation sequences×81timesteps=8,100液體meshes；97,200images含RGB和mask兩種，不能全叫獨立RGB題。90/10sequence split。
- 評估方式：2D IoU、3D CD/Volume IoU/F-score、dimension RMSE、scale MAPE；部分baseline只比50張random test images。
- Split / 資訊條件：以整條temporal sequence切90/10，避免相鄰frames跨split；real 10containers驗證不等於10固定interaction tasks。
- 來源關係：simulation-generated感知資料；不同視角與mask共享同一物理狀態。
- 可復用：可作液體觀測模組與量測參考；仍需另建可執行倒液任務及物理終態判分。
- 待核 / 限制：p4文字Three scenes與Lab1–Lab5衝突，以Table1和資料組成5為據；完整real case IDs未報。

P193 GRIP (2025)

原作：<https://arxiv.org/abs/2503.05020>

本次PDF：<https://arxiv.org/pdf/2503.05020v2>

PDF SHA256：04cf205cc12587bbc6680049d1eaa00b17736f5efde4581b6e2043a79bd684a5

閱讀頁：1、3、4、5、6。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：布料 / 柔性物操作；柔性物與抓取benchmark
- 領域：通用物件與機動作業
- 用途歸納：產生穩定抓握並預測物件受力，歸入通用抓取與易損物處理作業。
- 環境：IPC平行physics；UMIsoftgripper/LEAHand；800singleobjects，800bimanual含400重用，union1200。
- 任務：grasp synthesis/validation與stressprediction；single/bimanual不同graspconditions。
- 題數 / 資料：100,000grasp poses (概要)；stresssubset8bowls+8mugs，每類6train/2test；非100K不同tasks。
- 評估方式：sixdirectiongravity穩定抓持、penetration/absolutecontactdistance、stressrelativeMAE/KL；simulationfidelityrealcheck只4objects。
- Split / 資訊條件：DexGraspNet/PartNetassets重用；stress按object切，graspwholepool分割另需release核。
- 來源關係：固定物件union和多gripper/material/randomizedpose；全量物件與real2sim4個子集分開。
- 可復用：可補接觸穩定性與材料保護規則；candidatepose生成和有效評測case分開。
- 待核 / 限制：50N停止closure和gravity0.1秒/方向是本protocol，不能當通用安全標準。

P196 Deform360 (2026)

原作：<https://arxiv.org/abs/2607.05390>

本次PDF：<https://arxiv.org/pdf/2607.05390v1>

PDF SHA256：3f23966cb31f3614a8b27aba9ae558ef4684e812dd86ef6cd072d1788c6faf95

閱讀頁：1、4、5、6、8、9、10、11、12、13、27。198objects、capture/重建、1980episodes、多層generalization及2D/3D metrics。

- 研究型別：布料 / 柔性物操作；柔性物資料與世界模型benchmark
- 領域：衣物與洗護
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：一套41camera環繞capture rig；41視角不是41環境。人類持UMI tactile grippers操作。
- 任務：3D重建/重模擬、future prediction、episode及object generalization；198objects不是198語義task。
- 題數 / 資料：198物件=28線材+98片材+72體積柔性物；每物件5single+5bimanual，共1,980episodes。清理後74,850videos、23.3M多視角frames。
- 評估方式：3D Chamfer/track MSE；2D PSNR/SSIM/LPIPS；接觸accuracy/F1使用36個同步過濾視角。
- Split / 資訊條件：分episode內future frames、同物件未見episodes、未見objects三種；不同方法適用不同設定，不能共用一個排行分母。

- 來源關係：3DGS + tracking + normal-pressure tactile重建；收集刻意避免slip，未提供完整shear/slip涵蓋。
- 可復用：補材料與動力學覆蓋，亦示範為何要將episode、view影片、frame和hours各自計數。
- 待核 / 限制：各generalization split的精確train/test ID數需release protocol；未宣稱所有198物件已完成real-robot closed-loop task驗證。

P197 EgoSim / MultiEgoView (2025)

原作：<https://arxiv.org/abs/2502.18373>

本次PDF：<https://arxiv.org/pdf/2502.18373v1>

PDF SHA256：db15f931833027b80e416c0bdb47bd3c7695ef3cce6733988110484295f4f7d2

閱讀頁：1、2、5、6、7。資料構成、四場景、body-camera位置、35活動、切分與body pose metrics。

- 研究型別：人類影片與動作資料；身體攝影機資料與感知benchmark
- 領域：穿戴互動與動作介面
- 用途歸納：身體攝影機用來恢復使用者動作及支援互動輸入，歸入穿戴互動與動作介面。
- 環境：24locations分佈於4virtual scenes；real資料在其中一個掃描courtyard收集。6個body cameras是視角。
- 任務：主要實驗為全身3D pose estimation；real演出35種BABEL活動，非35robot執行目標。
- 題數 / 資料：synthetic 119.4行為hours/77.4M六視角images；real約5h、13participants。5秒segments數未報。
- 評估方式：global/PA MPJPE、translation/rotation/joint-angle error、jerk。
- Split / 資訊條件：synthetic依BABEL60/20/20；real random80/20與cross-participant10/3另列。
- 來源關係：AMASS/BABEL/BEDLAM motion/labels/assets；同一motion多bodyviews與多場景重渲染，非獨立動作資料。
- 可復用：支援頭、腰、手腕、膝攝影機的感知來源；加入視角泛化，不能當物理task completion。
- 待核 / 限制：精確train/test片段IDs、重渲染motion去重需manifest；動作辨識/定位雖可支援，主實驗未全評。

P198 TACO (2024)

原作：<https://arxiv.org/abs/2401.08399>

本次PDF：<https://arxiv.org/pdf/2401.08399v2>

PDF SHA256：2cd9fef96e133851d367c485aad1578b4979baef4d9b57037a1a246476735efd

閱讀頁：1、2、3、4、5、6、7、8。capture/annotation、131triplets、資料與generalization splits、三benchmark與metrics。

- 研究型別：人類影片與動作資料；雙手工具互動理解與預測benchmark
- 領域：居家整理與清潔、餐飲與烹飪、穿戴互動與動作介面
- 用途歸納：用原作工具—動作—物件組合歸納：倒液與攪拌屬餐飲，清潔器具屬居家，手物動作建模亦服務AR / VR介面。
- 環境：12third-person+1ego相機的capture工作站；作者明列缺乏scene diversity。
- 任務：3研究端點：compositional action recognition、motion forecasting、cooperative grasp synthesis；15actions、131tool-action-object triplets。

- 題數 / 資料：約2.5K motion sequences、5.2M多視角frames；196物件meshes/20categories/14participants。不是5.2M獨立互動題。
- 評估方式：recognition Top1/5；forecast10frames→10frames的joint/translation/rotation error；grasp penetration/contact/collision/FID，非執行成功率。
- Split / 資訊條件：train:S1:S2:S3:S4 = 4:1:1:1.5:2.5，分已見、geometry、interaction、compound；另60/40sequence的annotation驗證不可混成主split。
- 來源關係：自己的multi-view capture；DexYCB交叉資料驗證；marker removal使用inpainting。
- 可復用：把動作、物件組合和研究端點分層記錄，支援工具互動的組合泛化設計。
- 待核 / 限制：完整各split精確sequence數需manifest；不含articulated objects，不能外推完整工具環境。

P200 SABER (2026)

原作：<https://arxiv.org/abs/2605.09613>

本次PDF：<https://arxiv.org/pdf/2605.09613v1>

PDF SHA256：e4556b7aadaed076ac2792ec2c15b91853acad3f5eac7403898badc1396e8f98

閱讀頁：1、2、3、5、6、9、10、11、12、13。零售資料三streams、native/retarget區別、訓練mixtures、RoboBenchMart10tasks與100rollouts。

- 研究型別：人類影片與動作資料；零售示範資料與技能轉移
- 領域：包裝、倉儲與物流、零售與購物
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：多真實超市的頭戴/360°影片；camera capture無robot。精確店面數未報；下游是RoboBenchMart模擬。
- 任務：影片列12核心retail活動；下游10tasks = fridge2、board-to-board3、floor2、basket3，主要搬放與開關。
- 題數 / 資料：100+h影片匯出44.8Ksupervision samples = 25Klatent+18.6Khand+1.2Kbody，streams共享capture。每task100eval rollouts。
- 評估方式：success同時要求joint velocity<0.2、target到位、未擾動非target；非fridge tasks另報0/1/2/3/1進度。
- Split / 資訊條件：下游訓練含2.5Ktask-aligned RoboBenchMart demos + 4.8Krobot anchor；不是human-only零樣本轉移。
- 來源關係：三stream由相同人類capture生成，RoboBenchMart為下游父benchmark；不要重新計一次新10task。
- 可復用：補商店補貨/拿取/購物用途；可轉移資料與可執行環境需要分別取得。
- 待核 / 限制：不同stream的episode交集及各超市scene IDs未報；checkpoint選擇與held-out sampling需code核。

P201 EgoSAT (2026)

原作：<https://arxiv.org/abs/2606.24422>

本次PDF：<https://arxiv.org/pdf/2606.24422v1>

PDF SHA256：3cdd4d6866e119e6133a58a10ad4eff1ec3dd77fc61f49704b61835d9c312199

閱讀頁：1、3、9、10、11、12、13、14、22、28。interaction curation、stream prefix、六題型、QA數及confidence/answerability分析。

- 研究型別：理解、推理與規劃；串流理解與預測benchmark
- 領域：居家整理與清潔
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：Ego4D的56scenario labels；不是56有資產的機器人環境。
- 任務：present narration/state switch、short/multi-step anticipation、short/multi-step retrieval，共6題型。
- 題數 / 資料：1,997video sessions、約165h、約4,800QA；同一query的MC與open-ended版本不算獨立證據。
- 評估方式：MCQ accuracy、interaction precision/recall、state switch兩端都正確；confidence slope與predictable/unpredictable分組。
- Split / 資訊條件：每query嚴格截到當下prefix；online cache方法與每題prefix重處理成本不同；SFT cross-scenario另比較。
- 來源關係：Ego4D原影片/interaction labels加新queries；不重新計成獨立165h影片。
- 可復用：預測題需記可預測性與合法觀測截止時間，不能讓未來frame洩漏。
- 待核 / 限制：約4,800的精確query及SFT/evaluation split IDs待release核；future answer多解性不能當單純模型錯誤。

P202 EgoMonth (2026)

原作：<https://arxiv.org/abs/2608.13113>

本次PDF：<https://arxiv.org/pdf/2608.13113v1>

PDF SHA256：6747ddc4c6f9303ea3e7ed2e427b1e8707235e60cd4cf05e45abfd4d13cdfc1

閱讀頁：1、4、5、6、7、19。收集/篩選、14題型全表、738clips/301h、人工QA、macro/micro與sampling。

- 研究型別：理解、推理與規劃；長期記憶影片benchmark
- 領域：居家整理與清潔、餐飲與烹飪、辦公與教育、零售與購物、交通移動與車輛維修、休閒與運動
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：20participants各20–120天生活紀錄；室內外場景無可去重實體場所總數。
- 任務：14QA types、3認知層級；6activity用途類別。層級是作者設計，不是已校準的機器人難度。
- 題數 / 資料：738clips、18,072minutes≈301h、1,443四選一人工QA；原始30人400+h篩到20人300+h。
- 評估方式：14類macro平均與全部QA micro；直接答案比對，無LLM judge。人類評測3annotators， κ 0.78。
- Split / 資訊條件：benchmark zero-shot evaluation，非training dataset；固定sampling但model frame上限不同。
- 來源關係：新收集長期生活影片，與EgoLife是不同capture來源；一人多日仍屬群聚資料。
- 可復用：擴到長期生活記憶與跨日狀態，預算應固定並用participant群聚估計不確定性。
- 待核 / 限制：跨日task所需實際視覺覆蓋與每model frame cap要並列；人格推論題不等於客觀人格ground truth。

P203 EGOSTREAM (2026)

原作：<https://arxiv.org/abs/2605.31557>

本次PDF：<https://arxiv.org/pdf/2605.31557v2>

PDF SHA256：2b7fad2f7b3b003fe66a26ce10fe8f4c0b2950ae9a0a072a3f9215790a59ef17

閱讀頁：1、3、4、5、6、8。五父來源、人工filter、AVW與7recall regimes、8528擴充和stream protocol。

- 研究型別：理解、推理與規劃；串流記憶benchmark
- 領域：居家整理與清潔
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：Ego4D VQA、EgoLife、EgoTempo、Multi-Hop EgoQA、HD-EPIC五來源；無新增可執行場景。
- 任務：7記憶題型：detail/spatial/temporal/event/social/causal/prospective；7recall時間區間另是條件。
- 題數 / 資料：2,634candidate→2,335human-verified→2,250final QA；依Answer Validity Window擴成8,528question-recall evaluations。
- 評估方式：4-way accuracy，依語義/recall報；每frame processing time及受限memory，固定backbone比較不同memory managers。
- Split / 資訊條件：query到時才揭露；memory construction須query-agnostic，不能無界儲存原frames再重讀；不是所有題都可乘7。
- 來源關係：五來源QA與evidence重用/改寫；baseQA與多recall conditions有父子關係。
- 可復用：示範正當擴題：保留base question，新增不同合法歷史條件，並明示擴充規則和依賴。
- 待核 / 限制：無global scene union；同一QA的多recall測例需群聚統計，不能算8528獨立語義問題。

P204 S-EMBER (2026)

原作：<https://arxiv.org/abs/2607.02689>

本次PDF：<https://arxiv.org/pdf/2607.02689v2>

PDF SHA256：a19dd911977b7b7ad2651673df90d5ea20fbd44471297b335afdb6e3a0884e04

閱讀頁：1、3、4、5、6、7、8、14。新capture、2090scenario labels/33活動、9448QA、多長度答案、joint grounding與judge驗證。

- 研究型別：理解、推理與規劃；串流記憶與證據定位benchmark
- 領域：居家整理與清潔、餐飲與烹飪、零售與購物
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：613使用者Ray-Ban Meta capture；2,090fine-grained scenario labels合併33activity categories，非2090實體scene資產。
- 任務：8memory QA categories；answer generation與temporal grounding兩endpoint。
- 題數 / 資料：3,141videos、388h、9,448QA；每題三種verbosity參考答案，不把答案條數當三倍題數。另5-way MC版本。
- 評估方式：free-form overall/clean accuracy用judge；MC exact match；temporal mIoU/Recall@1；GQ@ τ 要求答對且定位正確。judge另600正負pair驗證。
- Split / 資訊條件：visual-only且prefix cutoff；open models固定128frames、closed native limits另列，非完全同觀測預算。
- 來源關係：新生活capture；questions由當下trigger往回問；影片scenario標籤不提供可執行robot state。
- 可復用：我們可採用答案與證據的聯合判分，但不能讓多verbosity或MC改寫虛增獨立題。
- 待核 / 限制：全部實體場所數未報；GQ判分可靠性取決judge與grounding，需保留分項成績。

P205 CapMem (2026)

原作：<https://arxiv.org/abs/2609.17688>

本次PDF：<https://arxiv.org/pdf/2609.17688v1>

PDF SHA256：f65b30af25bbaa68d3825316d901fac09df58f2fe57b133428750addc1aeec4e

閱讀頁：1、3、4、5、8、16、18、22。75videos七來源、4用途/16scenario、QA filter、CleanQA、frame-aligned controls與部分API評測。

- 研究型別：理解、推理與規劃；caption記憶benchmark
- 領域：居家整理與清潔、寵物照護與動物活動
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：4application domains、16scenario labels、75公共ego videos；無實體scene union。
- 任務：CleanQA/DirectVideoQA/CaptionQA是同題三種資訊條件；50question templates與5diagnostic分析維度不等於50task goals。
- 題數 / 資料：2,109candidate→1,000final MCQs、33.7h；Ego4D佔56videos/742QA。Gemini VideoQA只跑786題，其他主設定1,000。
- 評估方式：MC accuracy、token/runtime成本、visual tags/evidence位置/影片長度分項；CleanQA 15–35%gate是方法篩選規則。
- Split / 資訊條件：無額外train；full-caption1fps看全片而direct有frame cap，另6Qwen frame-aligned及cross-captioner受控實驗。
- 來源關係：Ego4D/EgoLife/EgoPet/EPIC/HoloAssist/ENIGMA-51/CASTLE2024；只release annotations/metadata，不重發原影片。
- 可復用：可借相同問題在不同記憶表示下的受控比較；先對齊看過的frames再比較caption收益。
- 待核 / 限制：作者標明只涵部分wearable用途；blindgate低於/高於門檻的解釋需謹慎，不能直接證明汙染。

P206 EmbodiedMemory-Bench (2026)

原作：<https://arxiv.org/abs/2609.28236>

本次PDF：<https://arxiv.org/pdf/2609.28236v1>

PDF SHA256：14adce97c24c0e4080ec7f707206f2dcc6ff9155bacf63b0d6cf84287eba4580

閱讀頁：1、3、4、5、6、15、18、27。四family、AI2THOR/ProcTHOR場景生成、2554驗證episodes、sim success及source/split設計。

- 研究型別：理解、推理與規劃；可執行具身記憶benchmark
- 領域：居家整理與清潔
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：1,118source scenes；AI2-THOR單房間組成virtualhome並儲存狀態、ProcTHOR multi-room篩選。不是1118全部新建獨立house。
- 任務：4families：Passive Observation、Dynamic Tracking、Interaction Failure、Experience Generalization；125visible object types/83target/33receptacle是資產類別。
- 題數 / 資料：2,554episodes=1,036+1,052+263+203；143候選被排除。四history介入條件同用800episodes而非新增3200unique basecases。

- 評估方式：執行action到sim目標終態的SR，四family等權macro避免1036/1052大類壟斷；另history介入成對比較。
- Split / 資訊條件：訓練與eval scenes/trajectories分離，parent trajectories先split再展開turns；target task在history之後才給。
- 來源關係：AI2-THOR/ProcTHOR、PDDL distractor、LLM生成experience後必須ground與重播驗證；這是episode而非2554獨立語義families。
- 可復用：和我們『既有環境＋新任務/規則』非常接近；差異要用更廣用途與來源聯集證明，不能只比episode數。
- 待核 / 限制：scene IDs跨host重用與完整episode manifest需原生release核；同history多condition需保留pair ID。

P207 EgoCoT-Bench (2026)

原作：<https://arxiv.org/abs/2605.19559>

本次PDF：<https://arxiv.org/pdf/2605.19559v1>

PDF SHA256：98ac34ca6c5e5e85367bbc76844e70d30939b29b4c58188ffdbe431af5e9b237

閱讀頁：1、3、4、5、6。來源/scene graph審核、12subtasks全表、3172QA、SCR與judge驗證。

- 研究型別：理解、推理與規劃；影片推理與證據benchmark
- 領域：居家整理與清潔、餐飲與烹飪、裝配與生產作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：Ego4D、EPIC、MECCANO、Charades-Ego、HD-EPIC及自錄；351clips不是351獨立環境。
- 任務：4研究groups/12subtasks，從object grounding到state回顧、預測、progress與goal tracking。
- 題數 / 資料：3,172四選一QA、351video clips；參考reasoning與時空證據同屬一題。
- 評估方式：答案exact match；Qwen-Max judge給reasoning0–5。SCR = 答對但reasoning ≤ 2 的比例，分母僅答對題。；judge與人類在2,800responses比較QWK/一致率；它衡量輸出解釋與證據一致，不證明模型內部思考忠實。
- Split / 資訊條件：主文是benchmark evaluation；精確train/dev manifest未列。MCQ、rationale與evidence非不同題庫。
- 來源關係：父影片及新增人工修訂STSG；五公共父庫與自錄不代表六份互不重疊世界經驗。
- 可復用：可加入答案與證據一致性的評測；不要把rationale judge直接叫物理成功驗證。
- 待核 / 限制：Table1寫Open/Close而metrics說全部四選一；以主實驗協定為準並保留差異。

P208 DYAD (2026)

原作：<https://arxiv.org/abs/2609.09023>

本次PDF：<https://arxiv.org/pdf/2609.09023v1>

PDF SHA256：698811f9c48df7ba4dfef3eab17ed4c8336186b171cbc82e4ea597e06349fdf0

閱讀頁：1、2、3、4、5、6。單helper政策、三reference tasks、原始/有效/eligible counts、participant splits與oracle限制。

- 研究型別：輔助與協作；協作與協助預測benchmark
- 領域：裝配與生產作業、協助、交接與陪伴
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：同一gearbox組裝工作站、20performers與同一trainedhelper；6pilot sessions不納正式20。

- 任務：3endpoint：causal8步辨識、介入前verbal/physical mode預測、oracle context下回應生成；不是完整robot助手。
- 題數 / 資料：20sessions/5h58m、528step intervals、611requests、851有效assistance events；mode eligible829，response376=120dev+256test。
- 評估方式：mode macro-F1/AUPRC，participant bootstrap；step segmentF1/edit/mAP/MoF；response rubric judge+BERTScore。
- Split / 資訊條件：mode participant五fold每fold12/4/4、3秒觀測到onset前0.5秒；step5val/15test；response120/256。當次trigger禁止入model。
- 來源關係：human-human assistance demonstration；851events中有效outcome極不平衡，作者不測outcome prediction。
- 可復用：可加協作規則，但需另外建need detection negatives及可執行robot feasibility。
- 待核 / 限制：沒有non-intervention negatives，不能宣稱會判斷何時需要幫忙；mode是一位helper政策不是普世最佳協助。

P209 HUI360 (2026)

原作：<https://arxiv.org/abs/2608.11051>

本次PDF：<https://arxiv.org/pdf/2608.11051v1>

PDF SHA256：9b4575648e06d38fb681f06af41179b35afb217270d1526216532130f6c3026f

閱讀頁：1、3、4、5、6、8。9場所/30setup、原始與裁切時數、SSUP重標、physical interaction定義及anticipation協定。

- 研究型別：輔助與協作；人機互動預測benchmark
- 領域：公共場館與服務、協助、交接與陪伴
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：HUI360有9真實場所、30robot placements/setups；SSUP-A兩public-space field sessions另列。
- 任務：預測是否將發生與平臺的物理interaction；不是廣義社交意圖。不同anticipation horizons重評同tracks。
- 題數 / 資料：HUI360 68recordings/71.3h原始→1,937episodes/11.3h有效人像片段，4,310tracks含375interaction。SSUP-A 27,698tracks為重標舊資料。
- 評估方式：AUROC主、F1/AP另報；跨location、跨dataset、0.33–2秒horizons及input-frequency robustness。
- Split / 資訊條件：HUI360 locations1–7train、8–9test；SSUP第一/二場次train/test。近onset視窗排除，negative以最近距離proxy挑選。
- 來源關係：新HUI360+既有SSUP-HRI重標；1Mannotations不是1M獨立interaction。
- 可復用：擴到公共空間互動預測，場地與擺位可獨立記錄；自動contact proxy應保留人工修正。
- 待核 / 限制：本文normalization用全HUI360均值/標準差，若嚴格train-only協定需修正；最終eligible test視窗量需manifest。

P210 RoCo Challenge (2026)

原作：<https://arxiv.org/abs/2603.15469>

本次PDF：<https://arxiv.org/pdf/2603.15469v1>

PDF SHA256：1b91dade9b97b3cbbde4f382166932d5d38a29b4038328808755568fc5b47c29

閱讀頁：1、3、4、5、6、12。三scenario、sim/real差異、兩種demo、single model與weighted score。

- 研究型別：輔助與協作；協作組裝benchmark
- 領域：裝配與生產作業、協助、交接與陪伴
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：IsaacSim工作站與Galaxea R1 Lite實機；simulation人類參與由初始化partial state模擬。
- 任務：1gearbox workflow的3scenario：從零組裝、partial state續作、error recovery。real只3planet gears，sim含sun/ring更多parts。
- 題數 / 資料：sim>300automatically generated demos，real另>300teleop demos；精確官方eval回合數在已讀protocol未報。
- 評估方式：single model需處理三scenario；assembled-parts/recovery分數以0.4/0.2/0.4加權。
- Split / 資訊條件：私有工作站上統一random lighting/texture/colors；real track任務規格有縮減，不能視為完全同題sim-real transfer。
- 來源關係：同gearbox assembly的起始狀態/恢復規則擴充；與人類即時協作要分開。
- 可復用：可借從零/續作/修復三類規則；不同backend的task目標改動要版本化。
- 待核 / 限制：完整task/case IDs及官方評測分母待competition config；結論的300+泛稱不能覆蓋兩份不同demo。

P211 AssemblyGrid (2026)

原作：<https://arxiv.org/abs/2609.16075>

本次PDF：<https://arxiv.org/pdf/2609.16075v1>

PDF SHA256：8661b2c5550168645f05f00d371e18fbdb54c431355ebf45b56a117ba5934f2d

閱讀頁：1、10、11、12、13、14、15、16、17、18、19、20、21、22、54、56。decentralized資訊、9scenario全表、instance/seed區分、production metrics及held-out protocol；未逐式讀57頁全部附錄。

- 研究型別：輔助與協作；多機器人生產排程benchmark
- 領域：裝配與生產作業
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：抽象grid生產模擬，geometry/reach/workspace限制；不模擬robot-specific接觸physics。
- 任務：Flow/Coalition/Concurrency三workload families×easy/medium/hard=9official scenarios，程度為family內配置，不保證每policy單調。
- 題數 / 資料：每scenario50held-out instances；3algorithms×9scenarios×10trainingseeds=270training runs，每個final checkpoint同50test instances。
- 評估方式：主要delivered products/throughput，admitted completion與offered-demand fulfilment分母不同；候選admission/coalition/blocking為diagnostics。；finite-batch timeout的makespan未定，不把未完成當正常完成時間；RL與nonlearning的不確定性分別按trainingseeds與instances。
- Split / 資訊條件：train/val/finaltest generationseeds分離，主測unseen realizations而非新topology；finalcheckpoint，無事後best選擇。
- 來源關係：local support-fraction cue為合法interface；centralized privileged reference與decentralizedpolicy分組。
- 可復用：補生產規劃與協作資源約束；可借明確區分instance、executionseed、trainingseed的計數方式。
- 待核 / 限制：robot-specificphysics、newtopology、failure/communication interventions明列未納v1實驗；不要稱完整工廠機器人控制。

P212 ARB4WM (2026)

原作：<https://arxiv.org/abs/2606.16605>

本次PDF：<https://arxiv.org/pdf/2606.16605v1>

PDF SHA256：7164d9a676e577b14d43e71e8cc37115faf37eba06430b824a84b05822e11b4b

閱讀頁：1、2、8、9、12。20tasks完整列表、5objectives、20eval runs、nAUC真實分母與defense metrics。

- 研究型別：世界模型與預測表示；世界模型與魯棒性benchmark
- 領域：居家整理與清潔、餐飲與烹飪、通用物件與機動作業
- 用途歸納：同時涵蓋物件操作與行走 / 平衡控制，歸入通用作業；門窗與咖啡 / 餐盤任務另標對應用途。
- 環境：10MetaWorld + 10DMC任務，作者稱industrial proxy；未提供真實industrial scene。
- 任務：20host tasks在5white-box objectives、各optimizer/temporal exposure下重評。
- 題數 / 資料：每setting20evaluation runs，seed20–39；4Dreamer-family agents，不能把agent數乘入獨立題庫。
- 評估方式：MetaWorld SR、DMC return；nAUC公式除benchmark常數1或1000，不是各policy clean score，雖文中稱clean-normalized。defense recovery另用clean-attack分母。
- Split / 資訊條件：只在eval perturb pixels，不改dynamics/reward/parameters；cross-model transfer只是另subsetDMC Reacher Easy。
- 來源關係：MetaWorld/DMC task復用加新攻擊protocol；hosttask和規則variants分開。
- 可復用：可擴充感測失真規則，固定合法attacker access和預算；不要把視覺攻擊當材料或安全有效性驗證。
- 待核 / 限制：all-setting unique episode IDs未報；攻擊強度不是可跨任務直接相加的難度刻度。

P214 COIN (interactive) (2026)

原作：<https://arxiv.org/abs/2604.16886>

本次PDF：<https://arxiv.org/pdf/2604.16886v1>

PDF SHA256：0e8f4586f184eb25ae2bd4bc596b3385b4e27319784a61dfa8c67bd98ba07f3c

閱讀頁：1、4、5、6、7、15。90tasks分層、ManiSkill3規格、1000demo、六metrics、10trials及不同model inputs。

- 研究型別：導航與家務執行；互動推理與操作benchmark
- 領域：居家整理與清潔、餐飲與烹飪、通用物件與機動作業
- 用途歸納：開櫃、找書、操作微波爐都有可辨認用途；純互動推理與幾何控制題保留在通用作業。
- 環境：ManiSkill3桌面Panda，PartNet/Sketchfab等assets；3reasoning domains是能力類別，不是生活用途。
- 任務：20Primitive + 20Composition + 50interactive reasoning = 90task definitions；含partialobservability下互動取得資訊。
- 題數 / 資料：Primitive每task50demo = 1,000trajectories、5views；主SR平均10trials，views不把traj變五倍。
- 評估方式：SR/類別SR、VQA、trajectory/gripper穩定、Composition/Primitive success ratio；六metrics分母不同。
- Split / 資訊條件：VLA在Primitive fine-tune、validationSR選checkpoint；model用1/3views不同，Voxposer有GObjectlist，需保留資訊條件。
- 來源關係：ManiSkill3資產與task擴充；expertVQA看示範不等於執行時線上推理成績。

- 可復用：可借Primitive→composition→interactivegoal的父子關係；我們的規模優勢需超出這種單桌面推理範圍。
- 待核 / 限制：人類只10task代表subset、3people×2trials；不可把40%sim/100%real當全50task人類上限。

P216 HAP (2026)

原作：<https://arxiv.org/abs/2609.18548>

本次PDF：<https://arxiv.org/pdf/2609.18548v1>

PDF SHA256：0cbfc4268916f842b362862865080ed9f76fbefdbab51c290d6e567b9e03abf8a

閱讀頁：1、2、5、6。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：未來動作 / 互動預測；動作與軌跡預測
- 領域：穿戴互動與動作介面
- 用途歸納：預測頭部轉向以看到被遮擋的操作目標，歸入穿戴觀察與動作介面。
- 環境：Bottle12RGB-D recordings sessions，clutter/reach變化；camera估計作headmotion proxy。
- 任務：預測6DoF headmotion；EgoPAT3Dv2父benchmark另列。
- 題數 / 資料：Bottle382clips，sessions10train/1val/1test；單一test session不是廣泛場地泛化證明。
- 評估方式：translation ADE/FDE(mm)、rotation ADE/FDE(degrees)；DA3/ORB3感知 backend 敏感性另測。
- Split / 資訊條件：session disjoint；各模型同window/horizon/smoothed pose。
- 來源關係：新Bottle capture + EgoPAT3D、pseudo3D head targets。
- 可復用：補視角移動/遮擋規則與active perception預測，而非只評手部。
- 待核 / 限制：camera pose proxy不等於獨立mocap GT；dataset完整release ID待核。

P217 TRS + RVG (2026)

原作：<https://arxiv.org/abs/2609.13293>

本次PDF：<https://arxiv.org/pdf/2609.13293v1>

PDF SHA256：13aaaf69bfba5c99ef154700c56eb0f34385c23b6bb5503a53965250a5e7e6a

閱讀頁：1、2、6、7。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：穩健性、失敗與評測品質；穩健性與分佈外評測
- 領域：餐飲與烹飪
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：EGTEA/EPIC原資料；破壞TSN feature tokens，不是重新收集真實sensor failures。
- 任務：action anticipation下六main corruptions；額外standalone blur是severity transfer。
- 題數 / 資料：EGTEA processed split10,321clips；EK100自訂training videos90/10切，不可和官方leaderboard直接比。
- 評估方式：joint verb+noun Top1、平均corrupted accuracy及Relative Robustness=AvgC/clean。
- Split / 資訊條件：compatibility graph只train labels、λEGTEA val選；EK pipeline125verbs/352nouns不同官方97/300。

- 來源關係：既有影片加新corruptionprotocol，不新增生活domains或原始action庫。
- 可復用：可以新增robustness規則cases並保持原task引用，清楚標記feature-level擾動。
- 待核 / 限制：本文自訂indexspace與officialsplit不同；clean低時RR可能誤導，須同報absoluteaccuracy。

P222 Uni-Hand (2025)

原作：<https://arxiv.org/abs/2511.12878>

本次PDF：<https://arxiv.org/pdf/2511.12878v4>

PDF SHA256：f71d9925369c1a5feb6fe1ecf4b409c2c11ae40edf1f0c8c7d568d12a00417ca

閱讀頁：1、9、10。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：未來動作 / 互動預測；動作與軌跡預測
- 領域：居家整理與清潔、餐飲與烹飪、通用物件與機動作業、穿戴互動與動作介面
- 用途歸納：把手部預測連到互動介面與機器人示教；杯墊擺杯、蘋果入盤和盒子上架另提供餐飲 / 整理用途。
- 環境：新CABH頭戴RGB-D與HAT固定ALOHAcamera；既有五publicdatasets另列。
- 任務：CABH3humanH0tasks；HAT5robottransfertasks，5個不是所有publicdatasetssemanticunion。
- 題數 / 資料：CABH1,200videos；HAT2,800handvideos（400/400/400/800/800），每task10physicaltrials。
- 評估方式：hand/headtrajectory與contactstate預測；HAT按完整predictedtrajectory執行。
- Split / 資訊條件：HAT只取第一幀產生完整motion，是look-then-move而非同等closed-loop視覺policy。
- 來源關係：CABH/HAT新資料；EgoPAT3D/H2O/HOT3D/Ego4D/EPIC重用。
- 可復用：補humanmotion到robotinterface，但必須標明executionmode與觀測限制。
- 待核 / 限制：CABH精確split與全部frameID仍需manifest；依據單幀的open-looptransfer不可當通用線上成功率。

P224 EMPIRE (2026)

原作：<https://arxiv.org/abs/2608.22449>

本次PDF：<https://arxiv.org/pdf/2608.22449v1>

PDF SHA256：e49c2bea71f4e0913128fd930c8536111ea26aa22782f634ac9ce7497f14aa03

閱讀頁：1、2、4、5、6。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：未來動作 / 互動預測；動作與軌跡預測
- 領域：穿戴互動與動作介面
- 用途歸納：預測雙手未來動作並產生操作計畫，歸入穿戴互動與動作介面。
- 環境：EgoDex原recordings，沒有新增111獨立物理場景。
- 任務：111tasklabels下bimanual5秒motionforecast + explicitplans；原作194只保留subset。
- 題數 / 資料：650,910trainwindows、6,836testwindows；non-overlapping5swindows，parentepisodes先分。
- 評估方式：best-of8按MPJPE選trajectory再算wrist/fingerrelative；不是單次控制policy。

- Split / 資訊條件：原EgoDexofficialsplit；85unseentasks僅Part1ablations，fulltrain111tasks都seen。
- 來源關係：EgoDex→EMPIRE650K，Qwencaption/plan+MANOfitting；100caseaudit84%usable，未全部人工審核。
- 可復用：可借規劃介面與預測粒度，同時保留生成標籤品質及best-ofK預算。
- 待核 / 限制：difficulty按baselineMPJPE分43/49/19，僅模型相對難度；不得當通用easy/medium/hard真值。

P225 Exo2EgoPose (2026)

原作：<https://arxiv.org/abs/2607.15890>

本次PDF：<https://arxiv.org/pdf/2607.15890v2>

PDF SHA256：de7fddd04e06fecbb6bf89e299b81ad55b49b90cbbb5d57ec0856fd8cd1a5c43

閱讀頁：1、2、5、6。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：未來動作 / 互動預測；動作與軌跡預測
- 領域：裝配與生產作業、穿戴互動與動作介面
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：AssemblyHands/EgoExo4D/EgoMe原場景，exovideo供訓練supervision。
- 任務：vision-language3Dhandposeforecast；EgoMe-pose為新增derivedbenchmark。
- 題數 / 資料：AssemblyHands6120/355/355；EgoExo10869/1540/1540；EgoMe6067/1344/2648 train/val/test episodes。
- 評估方式：root-alignedMPJPE/MPJVE(mm)，不同source15/30fps。
- Split / 資訊條件：EgoMe只保留correctimitation，>95%frames有效；generatedpose和depth不是全部mocapGT。
- 來源關係：Assembly101→AssemblyHands及EgoMe新pose標註；父場景不能再加。
- 可復用：補exo示範監督與finefingerprediction，但不混成robotphysicalexecution。
- 待核 / 限制：root-alignederror不檢驗世界坐標全域性定位；episode數不可代替獨立sourceclip數。

P226 EgoTraj (2026)

原作：<https://arxiv.org/abs/2605.19004>

本次PDF：<https://arxiv.org/pdf/2605.19004v1>

PDF SHA256：c6789c21ac3754c8b4f240cc614ab7712284681a8b02fa63e9ec08d9dbcfea82

閱讀頁：1、2、3、4、5、6、7。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：未來動作 / 互動預測；動作與軌跡預測
- 領域：交通移動與車輛維修、穿戴互動與動作介面
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：7outdoorwaypoints/21origin-destinationpairs；waypoint和route不等於21獨立地理環境。
- 任務：wearer6DoFtrajectoryprediction，gaze/sceneannotations作modalities。
- 題數 / 資料：75participants各1session，10.7h/1.15Mframes；38,606annotatedframes非相同數量testcases。

- 評估方式：ADE/FDE與headrotationL1error；route多樣性另用DTW。
- Split / 資訊條件：held-outsessions；地理場域和路徑可能重用，不等於unseencitygeneralization。
- 來源關係：新QuestProcapture；VLMsemanticlabels與真實trajectory/pose區分。
- 可復用：擴到戶外行走的預測用途；屬人類導航資料，不是機器人互動模擬房屋。
- 待核 / 限制：exactheld-outwindowcount和完整protocol需要release核；不將1.15Mframes當predictionquestions。

P228 SFHand/EgoHaFL (2025)

原作：<https://arxiv.org/abs/2511.18127>

本次PDF：<https://arxiv.org/pdf/2511.18127v2>

PDF SHA256：523777e21488e904c826eaab83130b80cffb36f33c1de90506f75949869bee9d

閱讀頁：1、2、3、4、5、6。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：未來動作 / 互動預測；動作與軌跡預測
- 領域：居家整理與清潔、餐飲與烹飪、通用物件與機動作業、穿戴互動與動作介面
- 用途歸納：即時語言引導手部預測歸入動作介面；其Kitchen與Adroit下游評測另外歸納家居 / 餐飲與通用作業。
- 環境：Ego4D→EgoHOD/EgoVid衍生影片；worldcoordinates由估計camera/hand取得。
- 任務：streaming3Dhandstateforecast (type/box/pose/globaltrajectory)；Kitchen/Adroit只做下游representationtransfer。
- 題數 / 資料：247K三秒clips = 242Ktrain/5Ktest，3.95Mhandannotations；不是3.95M獨立taskcases。
- 評估方式：ADE/FDE、wristalignedJPE/PA-JPE、2Dboxrecall/FPS；SFHand*使用GTstate oracle另列。
- Split / 資訊條件：test時間autoregression吃前一步預測；普通SFHand不可和oracle58.8FPS/accuracy混成同設定。
- 來源關係：Ego4D/EgoHOD/EgoVid共同影片，再用HaMeR生成pose。
- 可復用：補streaming預測規則及teacher-forcing/oracle邊界，sourceclip/traininglabel分開。
- 待核 / 限制：paper 『4M Ego4D videos』實為衍生片段層級，不能當4M原始長影片；scene/video-disjoint split需核。

P229 UniEgoMotion (2025)

原作：<https://arxiv.org/abs/2508.01126>

本次PDF：<https://arxiv.org/pdf/2508.01126v2>

PDF SHA256：841c3f6b142a703b951a3bbf3b4b85d7ce9d771d5fcebda569b703a3c857baa7

閱讀頁：1、2、3、4、5。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：未來動作 / 互動預測；動作與軌跡預測
- 領域：餐飲與烹飪、休閒與運動、音樂與表演、穿戴互動與動作介面
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：EgoExo4D原takes，新增pseudoSMPL-X重建。
- 任務：reconstruction、forecasting、generation三不同觀測條件；同資料重用。

- 題數 / 資料：EE4D-Motion110+h；143Ktrain8sclips（每2s抽）、4,400valclips（每20s抽）。
- 評估方式：MPJPE/PA/handerror、headpose、footcontact/sliding、semantic/FID；不同endpoint分項。
- Split / 資訊條件：officialtake-levelsplit；forecast看2s預測6s，generation只看一幀，reconstruction可看全input。
- 來源關係：EgoExo4Dmulti-viewoptimization生成新motionlabels；非110h新獨立capture。
- 可復用：補全身與scene-awareforecast，但應防止把reconstruction偷看未來當forecast。
- 待核 / 限制：三端點accuracy/inputs不同，不能用同一個難度或成功率比較；best-ofK需最終protocol固定。

P230 EgoH4 (2025)

原作：<https://arxiv.org/abs/2504.08654>

本次PDF：<https://arxiv.org/pdf/2504.08654v1>

PDF SHA256：16c00d83861cf54090431f84a857bd58983670d1635fa09e3cb8a8b6fc048006

閱讀頁：1、2、5、6。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：未來動作 / 互動預測；動作與軌跡預測
- 領域：穿戴互動與動作介面
- 用途歸納：包含視野外雙手的姿態與動作預測，歸入AR / VR等穿戴動作介面。
- 環境：EgoExo4Dbody/handannotations合併，原場景重用。
- 任務：in-view/out-of-viewhandtrajectory/poseforecast，body作constraint。
- 題數 / 資料：156Ktrain/34Ktest是按hand-side的sequencecounts；同片左右手不可當獨立scene。
- 評估方式：ADE/FDE、MPJPE/lastframeMPJPE，單一generatedsample，沒有best-ofK放大。
- Split / 資訊條件：officialtrain/valastrain/test，2sobs→1sforecast10fps；GT2Dhands作input，autobody只train。
- 來源關係：EgoExo4Dbody與handsubset；metric對不同validjoints適用分母不同。
- 可復用：加入遮擋/視野外預測的規則對照，並標明ground-truth感知input優勢。
- 待核 / 限制：要核hand-side數轉uniqueclip的關係；不能將156K+34K稱190K獨立humanactivities。

P233 OCT/HOI forecasting (2022)

原作：<https://arxiv.org/abs/2204.01696>

本次PDF：<https://arxiv.org/pdf/2204.01696>

PDF SHA256：c866b4f79af2ef6de72a2ee55996af607cd4a69c977889bb3c3f67b0242fad17

閱讀頁：1、4、5、6。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：未來動作 / 互動預測；動作與軌跡預測
- 領域：餐飲與烹飪、穿戴互動與動作介面
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：EPIC55/100及EGTEA原影片，EK100擴充EK55。

- 任務：handtrajectory與objectcontacthotspot聯合預測。
- 題數 / 資料：EK55train8523/evaltrajectory1894/hotspot241；EK10024148/3513/401；EGTEA1880/442/69。三種數字分別是訓練、軌跡評測與hotspot評測。
- 評估方式：trajectory取20samples最小error；contactpoints全部轉heatmap評，不是20次獨立case。
- Split / 資訊條件：評原validation，正式actiontest不用於此derivedtask；hotspot只人工審核challengingsubset。
- 來源關係：autoannotations + 人工filteredhotspots，後被多篇forecast論文重用。
- 可復用：是hand/hotspot聯合規則的基礎來源；保留每個target的可用label分母。
- 待核 / 限制：不同target只覆蓋各自subset，1894不能全視為1894jointlabelcases。

P241 AFF-ttention (2024)

原作：<https://arxiv.org/abs/2406.01194>

本次PDF：<https://arxiv.org/pdf/2406.01194v2>

PDF SHA256：5bc6b87af40d139d6f59d0cb6bd989130ccd236b866623dc409b6fe248d789a5

閱讀頁：1、3、10、11。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：未來動作 / 互動預測；動作與軌跡預測
- 領域：餐飲與烹飪
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：EPIC-Kitchens新增STAannotations；Ego4D v1/v2原場景。
- 任務：next-activeobject box/noun/verb/time-to-contact聯合預測。
- 題數 / 資料：新增EPIC-STA驗證集；已讀原文mainsections未給精確casecount，待annotationmanifest。
- 評估方式：N、N+V、N+TTC、All Top5mAP；不是四個互不相干task庫。
- Split / 資訊條件：Ego4Dv1/v2訓練量和test榜分列，v2含v1；EPICval自建benchmark。
- 來源關係：EPIC父標註→STA、OCT-stylehotspots；STAformer++是後續方法版本。
- 可復用：論文名字像方法但附帶新benchmark，應納入來源總庫並連回EPIC。
- 待核 / 限制：精確newannotationID與共同scene/task對映待code核，未知不填0。

P246 Decision-aware uncertainty (2026)

原作：<https://arxiv.org/abs/2603.10061>

本次PDF：<https://arxiv.org/pdf/2603.10061v2>

PDF SHA256：4efc1650b0634e90b675a99e738d4660ad1c454cbd8b1023bc814cafb53992c

閱讀頁：1、2、3、4、5。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：Survey / 評測方法；評測方法與不確定性
- 領域：餐飲與烹飪

- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：EGTEA/EPIC100既有影片。
- 任務：partial-prefixactionprediction下correctness/calibration/selectiveutility/confidencegeometry四種診斷。
- 題數 / 資料：預設K10候選、M5stochasticsamples/input；原作精確evalsegmentIDs未報。
- 評估方式：Top1/Recall@K、Top1/SetECE、accuracy-coverage、entropy；不是physicalsafety驗證。
- Split / 資訊條件：稱用officialtest，singleGemini2.5Flash-lite；K/M改變結果及成本，不能算多出5倍題。
- 來源關係：對既有benchmarks加uncertaintyprotocol；有助規則/拒答評測。
- 可復用：我們可加入拒答/澄清閾值與accuracy-coverage曲線，但要有相應標籤和同模型預算。
- 待核 / 限制：Set-ECE用TopK平均confidence對setcorrectness，是作者定義，需另外驗證適用性。

P247 EgoSpanLift (2025)

原作：<https://arxiv.org/abs/2511.18470>

本次PDF：<https://arxiv.org/pdf/2511.18470v1>

PDF SHA256：b2ea7307cbe26217da35558970ceadb9f521d3f0841c60ff431031d39a98003f

閱讀頁：1、5、7、8。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：未來動作 / 互動預測；動作與軌跡預測
- 領域：居家整理與清潔、餐飲與烹飪、醫療與手術支援、交通移動與車輛維修、休閒與運動、音樂與表演、穿戴互動與動作介面
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：AEA的143recordings/7.3h與EgoExo4D五活動子集；排除soccer/basketball/dance。
- 任務：3Dvisualspanforecast，多個視角範圍是同target不同granularity。
- 題數 / 資料：FoVS-Aria約23.2Ksample（19.3K/1.9K/2.1K）；FoVS-EgoExo341.4K（274.7K/29.6K/37K），概述364.6K。
- 評估方式：3DIoU/F1、fovealregiondistance；16格/3.2m=20cmcell resolution，不當精確gaze接觸。
- Split / 資訊條件：AEA location4heldout；look2spredict2s，EgoExo預測4s；split約數四捨五入不精確加總。
- 來源關係：AEA/EgoExo4DSLAM+gaze衍生volume；windowoverlap與sourcecaptures要追蹤。
- 可復用：補注視/可見區域預測，讓世界觀測能力不只侷限於問答或手軌跡。
- 待核 / 限制：visualspan≠robotactiveperceptionpolicy；也未覆蓋所有EgoExo8activities。

P250 EgoMAN (2025)

原作：<https://arxiv.org/abs/2512.16907>

本次PDF：<https://arxiv.org/pdf/2512.16907v2>

PDF SHA256：3edd340c61e8cb14c7aee576baa1f86ace5b4367000ec8ea612f039df07d7c24

閱讀頁：1、2、3、4、5、6。原作資料構成、任務定義與實驗協定相關段落；閱讀範圍限所列PDF頁，非全文逐字或程式重現。

- 研究型別：未來動作 / 互動預測；動作與軌跡預測

- 領域：居家整理與清潔、餐飲與烹飪、交通移動與車輛維修、穿戴互動與動作介面
- 用途歸納：依已核讀的任務、活動或場景保留用途歸納；原作任務細節與分類依據一起提供。
- 環境：EgoExo4D/Nymeria以1014pretrain/498finetune/78testscene標籤分開；HOT3D testonly。
- 任務：interactionstage-aware6DoFwristforecast；semantic/spatial/motionQA三訓練類別。
- 題數 / 資料：EgoMAN-Bench2844unseen+990HOT3DODD = 3834trajectories；3MQA為生成supervision概述，非3Mtestquestions。
- 評估方式：ADE/FDE/rotation/DTW，best-ofK1/5/10；waypointcontact/traj-distance另報。
- Split / 資訊條件：sceneheldout及datasetOOD；up-to5sforecast，GTduration/masks用於判分。
- 來源關係：EgoExo4D/Nymeria/HOT3D重用，再生成interaction/QAlabels；可與OpenEgo、UniHand有父素材重疊。
- 可復用：是端點/規則擴充產生大QA量的對照；主benchmark應以3834testtrajectory分母比較。
- 待核 / 限制：219K/220K+trajectory概要與74K+17Ktrain分項不是同一層；待release對hand/clip單位核。

67篇方法 / 背景參考的篩查

- P035 EgoVLPv2 : EgoVLPv2使用EgoClip/EgoMCQ及既有下游資料；模型融合改進不另計一份新影片庫。(PDF 1, 5, 6 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2307.05463>
- P036 EgoT2 : EgoT2在Ego4D的7既有任務做task translation , 保留作跨任務模型參考。(PDF 1, 2, 5 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2212.06301>
- P043 Embodied VideoAgent : Embodied VideoAgent用Ego4D-VQ3D、OpenEQA、EnvQA ; 新增memory/tool方法, 不把下游來源再加總。(PDF 1, 2, 5 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2501.00358>
- P044 HiERO : HiERO在EgoMCQ/EgoNLQ/EgoProceL/Goal-Step驗證hierarchical features , 未另計父資料規模。(PDF 1, 2, 6 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2505.12911>
- P046 RULSTM : RULSTM是EPIC/EGTEA的anticipation方法與challenge參考, 原生題庫歸父來源。(PDF 1, 4 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/1905.09035>
- P047 AVT : AVT使用EK55/EK100/EGTEA/50Salads , 四個評測集合不能當四份新資料。(PDF 1, 2, 6 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2106.02036>
- P048 EGO-TOPO : EGO-TOPO從EPIC/EGTEA建環境affordance圖, 保留拓撲表示與forecasts設計參考。(PDF 1, 3, 6 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2001.04583>
- P049 AntGPT : AntGPT研究goal inference與actionsequenceforecast , LTA定義歸Ego4D等父benchmark。(PDF 1, 3 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2307.16368>
- P050 PALM : PALM用caption/認別/LLM預測既有LTA標籤 ; 多次prompt不增加基礎題數。(PDF 1, 4, 8 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2311.17944>
- P052 StillFast : StillFast針對既有short-term object interaction anticipation , 屬方法 ; 初篩僅摘要/任務定義。(PDF 1 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2304.03959>
- P055 FUTR : FUTR在Breakfast與50Salads測長期預測, 保留horizon/分割方式參考。(PDF 1, 2, 5 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2205.14022>
- P056 Forecasting hands and objects : 未來手/物體位置預測在公開第一人稱及street資料驗證 ; 本輪未另登記獨立新資料資源。(PDF 1, 2, 8 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/1705.07328>
- P059 EMAG : EMAG在Ego4D/EPIC55研究ego-motion及跨庫泛化, 非新capture來源。(PDF 1, 4, 8 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2405.20030>
- P078 PerAct : PerAct有18RLBench tasks/249variations及7real tasks/18variations ; 保留方法實驗, RLBench子集不重算整庫。(PDF 1, 3 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2209.05451>
- P117 UMI : UMI四個實機task驗證工具/介面 ; 可借cuporientation等規則, 未納成本輪獨立benchmark總數。(PDF 1, 6, 7 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2402.10329>
- P118 EgoMimic : EgoMimic三個real long-horizon tasks研究human-robot對齊 ; 保留任務擴充參考。(PDF 1, 5, 10 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2410.24221>
- P121 EgoZero : EgoZero七個real tasks驗證smart-glasses到robot技能 ; 是方法實驗而非七種新生活領域。(PDF 1, 2, 5 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2505.20290>
- P122 EgoBridge : EgoBridge的PushT對照與三real tasks用於OT adaptation ; 背景和初態規則可借用。(PDF 1, 2, 6 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2509.19626>
- P130 ALOHA / ACT : ALOHA/ACT六個real tasks與兩simtasks , 主要介面/策略研究 ; demo數和task數分開。(PDF 1, 8 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2304.13705>

- P131 Mobile ALOHA : MobileALOHA延伸mobilebimanual操作，50demos/task；完整custom實驗清單可續做task-level抽取。(PDF 1, 7；原作摘要 / 貢獻與實驗摘錄初節；非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2401.02117>
- P133 RT-2 : RT2約6000跨方法/條件rollouts；沿用robotdata並研究新語義能力，非6000unique tasks。(PDF 1, 4, 7；原作摘要 / 貢獻與實驗摘錄初節；非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2307.15818>
- P134 OpenVLA : OpenVLA重用OXE970Kdemonstrations；29evaltasks與7finetunetasks是方法實驗範圍。(PDF 1, 2, 7；原作摘要 / 貢獻與實驗摘錄初節；非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2406.09246>
- P135 Octo : Octo800Ktrainingtrajectories來自OXE；多平臺policyadaptation不建立800Ktest題。(PDF 1, 2, 3；原作摘要 / 貢獻與實驗摘錄初節；非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2405.12213>
- P136 pi0 : π_0 包含約10000h資料與摺衣/清潔/盒子組裝實驗；保留通用策略與自收資料參考，完整manifest未由初節驗證。(PDF 1, 3, 6；原作摘要 / 貢獻與實驗摘錄初節；非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2410.24164>
- P137 pi0.5 : $\pi_{0.5}$ 驗證未見房屋與長流程；高低層cotrain是方法，不能把所有提及用途當完整task庫。(PDF 1, 3, 10；原作摘要 / 貢獻與實驗摘錄初節；非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2504.16054>
- P138 Diffusion Policy : DiffusionPolicy在既有四benchmark的15tasks評測；保留控制介面/資料預算參考。(PDF 1, 2, 10；原作摘要 / 貢獻與實驗摘錄初節；非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2303.04137>
- P139 R3M : R3M用Ego4Dpretrain、三sim來源與五realtasks；來源重用需連父庫。(PDF 1, 6, 8；原作摘要 / 貢獻與實驗摘錄初節；非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2203.12601>
- P140 VIP : VIP研究reward/representation；四realtasks及既有simcases留作評測方法參考。(PDF 1, 7, 8；原作摘要 / 貢獻與實驗摘錄初節；非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2210.00030>
- P149 V-JEPA 2 : V-JEPA2有大規模internetpretrain與DROIDadaptation；保留worldmodel/closed-loop對照，不把22Mvideos算robot題。(PDF 1, 5, 11；原作摘要 / 貢獻與實驗摘錄初節；非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2506.09985>
- P153 EgoExo-Gen : EgoExo-Gen在EgoExo4D作cross-viewmask/video預測；可借新輸入條件，素材仍屬父來源。(PDF 1, 6；原作摘要 / 貢獻與實驗摘錄初節；非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2504.11732>
- P154 Hand-conditioned ego predictive model : Hand-conditioned predictive model使用Ego4D/BridgeData/RLBench，predictionquality與控制success分開。(PDF 1, 4, 5；原作摘要 / 貢獻與實驗摘錄初節；非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2508.19852>
- P155 EgoExo-WM : EgoExo-WM把HowTo/CrossTask等exo轉ego並結合Nymeria；新增合成表示，不視為全新獨立行為。(PDF 1, 2, 6；原作摘要 / 貢獻與實驗摘錄初節；非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2605.15477>
- P156 Egocentric survey : Egocentric survey按subject/object/environment/hybrid整理；用於taxonomy與引文擴查。(PDF 1；原作摘要 / 貢獻與實驗摘錄初節；非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2503.15275>
- P157 Human-video robot learning survey : Human-video robotlearning survey區分task/observation/action pathways；背景綜述非新題庫。(PDF 1；原作摘要 / 貢獻與實驗摘錄初節；非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2604.27621>
- P158 VLA benchmark survey : VLA資料/benchmark/dataengine survey；可用於遺漏來源檢查，不沿用二手規模替代原作。(PDF 1, 2；原作摘要 / 貢獻與實驗摘錄初節；非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2604.23001>
- P159 tinyBenchmarks : tinyBenchmarks提供IRT/子集估計方法，研究物件是LLM；不能直接假設robot難度模型有效。(PDF 1, 4, 6；原作摘要 / 貢獻與實驗摘錄初節；非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2402.14992>
- P160 Rliable : Rliable提供分層bootstrap/IQM與performanceprofiles；統計方法，不是robot環境資料來源。(PDF 1, 2, 6；原作摘要 / 貢獻與實驗摘錄初節；非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2108.13264>
- P161 First-person prediction survey : 第一人稱未來預測survey，涵行為/位置/手物互動；背景與引文來源。(PDF 1；原作摘要 / 貢獻與實驗摘錄初節；非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2107.13411>
- P162 Egocentric hands survey : 手部egocentric survey區分localization/interpretation/application；無新robot題庫。(PDF 1；原作摘要 / 貢獻與實驗摘錄初節；非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/1912.10867>
- P163 Ego-exo collaboration survey : Ego-exo survey以跨視角transfer/jointlearning整理，可支援示範來源分類。(PDF 1；原作摘要 / 貢獻與實驗摘錄初節；非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2506.06253>

- P187 SSFold : SSFold報六foldtasks及human demonstrations ; 留方法實驗參考, 初篩尚不宣稱已核所有trial協定。(PDF 1, 2 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2411.02608>
- P189 GPT-Fabric : GPT-Fabric重用smoothing/folding範式, real10/12rollouts ; sim粒子距離和real人工檢視不可混分。(PDF 1, 5, 7 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2406.09640>
- P190 UniGarmentManip : UniGarmentManip三garment類/三task : unfold/fold/hang ; 重用資產/對應學習, 不當三新datasets。(PDF 1, 3, 6 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2405.06903>
- P194 Cloth gripper interface : clothgripperinterface八個cornerfold cases驗證kinematicgrasp ; 省略摩擦contact, 不能當完整physicsbenchmark。(PDF 1, 2 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2609.29340>
- P195 World models for unfolding : worldmodelforunfolding在Unity/RFuniverse及realcloth驗證 ; 保留模擬與policy方法參考。(PDF 1, 3, 7 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2602.16675>
- P215 World-model evaluation survey : worldmodelevaluation survey列160benchmarks ; 作引文追查線索, 其二手數字不直接併入已核來源。(PDF 1, 4 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2609.29669>
- P218 TrajPilot : TrajPilot重用EgoExo4D/GoalStep/EgoPER, 重點是trajectoryconditioning及horizon, 不另算全部label為新task。(PDF 1, 7 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2605.20388>
- P219 FROST-STA : FROST-STA是Ego4D2026challenge submission ; query/GT由父challenge定義。(PDF 1, 3 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2606.00694>
- P220 VISTA (Ego4D STA) : VISTA-STA合併train+部分val訓練、只報officialtest ; 不是新增dataset。(PDF 1, 3, 4 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2605.20901>
- P221 STAformer++ : STAformer++是AFF-ttention後續架構, EPIC-STA新增資源已連到P241, 避免重列兩次。(PDF 1, 2 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2602.14837>
- P223 INSIGHT : INSIGHT在Ego4D/EPIC55/EGTEA測意圖推理與預測, 原生題庫歸父來源。(PDF 1, 2, 5 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2508.01742>
- P227 EggHand : EggHand處理EgoExo4Dhandposeforecast, 保留motion/frame定義與模型baseline參考。(PDF 1, 2, 5 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2605.07642>
- P231 MADiff : MADiff用五publicdatasets與新增interaction-pointdiagnostics ; 標註/metrics從父資料衍生, 非新capture。(PDF 1, 6, 9 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2409.02638>
- P232 Diff-IP2D : Diff-IP2D新增jointpredictionmetrics、沿用EPIC/EgoPAT ; 並揭示USST的FDE erratum, 保留評分版本參考。(PDF 1, 11 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2405.04370>
- P234 I-CVAE : I-CVAE在Ego4DLTA預測20futureactions ; oracleintent/GTactionablation應另列。(PDF 1, 2, 7 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2207.12080>
- P235 TransFusion : TransFusion把contextsummary加入既有STA ; GTcontext與推估context不可等同。(PDF 1, 2, 6 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2301.09209>
- P236 ActFusion : ActFusion統一segmentation/anticipation於Breakfast/Salads/GTEA ; 兩endpoint共用影片。(PDF 1, 2, 6 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2412.04353>
- P237 Gated Temporal Diffusion : GatedTemporalDiffusion在Breakfast/Assembly101/Salads做stochasticLTA ; 新模型不增加父庫活動數。(PDF 1, 2, 9 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2407.11954>
- P238 Object-centric LTA : object-centricLTA用Ego4D/50Salads/EGTEA ; objectprompt數非獨立task數。(PDF 1, 6 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2311.00180>
- P239 MVP : MVP研究多尺度video pretraining與既有LTA/summaryforecast ; 保留觀測horizon參考。(PDF 1, 2, 7 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2307.12854>
- P240 ANTICIPATR : ANTICIPATR在四existingdatasets做futureinstance預測 ; 重用原split。(PDF 1, 9, 10 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2210.11566>

- P242 NAOGAT : NAOGAT用Ego4DSTA及EK ; noun/verb/box/TTCjointmatch是判分組合，非四倍題。(PDF 1, 7 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2308.08303>
- P243 FactCheck (LTA) : FactCheck的Observe-Plan-Verify是預測流程內迭代，EPIC/EGTEA未執行robot物理環境。(PDF 1, 9, 10 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2606.14778>
- P244 BiAnt : BiAnt在Ego4DLTA研究forward/backwardactionsequencelearning ; 初篩未新增獨立題庫。(PDF 1 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2508.00374>
- P245 ICVL : ICVL在Ego4D/EPIC55/EGTEA研究vision-intentionfusion ; 保留方法與prompt參考。(PDF 1, 2 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2505.01713>
- P248 HOIMotion : HOIMotion使用ADT/MoGaze及humanstudy ; sceneobjectboxes是forecastinputs，不是新控制環境。(PDF 1, 2 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2407.02633>
- P249 EgoCast : EgoCast使用EgoExo4D/ADT，提出較長horizon/估計而非GTpastpose ; 保留taskprotocol擴充參考。(PDF 1, 3, 4 ; 原作摘要 / 貢獻與實驗摘錄初篩 ; 非全文逐字或完整benchmark協定審核) <https://arxiv.org/abs/2412.02903>

擴查清單（未計入183已核來源）

- BEHAVIOR-100原作：需和BEHAVIOR-1K及EAI的B100 symbolic評測分開；現有書目未獨立登記。
- Assistive Gym與照護 / 穿衣任務來源：補照護場域，不能只以廚房/衣物替代身體接觸與可及性；需擴查原作。
- RoboMME及具身記憶相關原作：新記憶來源引用多個未獨立收錄的父benchmark；需逐個分清重用/新生成。
- ENIGMA-51、CASTLE2024、HO-Cap：已核來源的父素材未全獨立登記；依CapMem/OpenEgo原文追查。
- RoboBenchMart、SariBench：SABER的零售環境/下游task父來源需補獨立原作與manifest。
- Fold/cloth方法的完整原作清單：SSFold、GPT-Fabric、UniGarmentManip等67篇參考組中的custom實驗，可在逐task抽取時補規則/例項；本輪初篩不假稱已核所有程式。
- survey與引用鏈的新增來源：世界模型survey等提供更多候選。候選未審閱前不加進183已核來源，不以二手錶格宣稱完整蒐集。

本次公開自己的閱讀摘要、頁碼、數字及來源指紋；不重新散佈原作PDF。