RESEARCH ATLAS

Robot-use Benchmark完整整理

先看整体数字、用途与研究分布、共同结构及实例，再查250篇来源的数据、判分、版本与证据。

快照 2026-10-11：250/250篇已处理。183份主来源和67篇方法 / 综述分开标明。

GitHub证据：279个仓库、286个固定版本；另有1个外部数据库。合计1506个已核验文件，其中2个来自外部数据库。核读限所列片段；没有运行上游模型或机器人。

先看全库：哪些数字已确认

用途分类 source-review-0.11；来源ID清单 2026-10-02；GitHub核读 2026-10-11。三份快照分开标明，旧12领域与早期任务配额只作历史数据。

项目	目前确认实数	实数范围	本版规划口径
领域	**21** 已归纳用途类别	183/183份来源均有归类；原22份已补齐。每个用途有任务 / 场景理由；同一来源可涵盖多用途。	按任务、对象与目标归纳，再逐任务创建联集；新用途可扩充分类。
环境	**284** 已取得命名场景条目	64个已读来源有某种环境量；284条仅是已取ID子集，未完成跨库几何去重。	整理各来源scene/layout/location及重用关系后，计全库联集；不再先配1,000。
任务	**2,096** 已取得robot任务条目	另有7信息题型、263人类活动。原作task/skill/instruction的差异已逐篇记录，尚未全部范式去重。	先取原作任务联集，再加有差异证据的新目标 / 规则；不再先配5,000。
题数	**114,288** 已取得题目定义元数据	111,652 PARTNR train＋1,000 val＋1,636 OpenEQA；含训练数据，素材未全齐，不是114,288道已集成测试题。	依task、split、合法输入及判分创建case manifest后定量；原作量、已取得量、可评量分列。
评估方式	**4** 共同判分大类	183份来源均有判分方式与原文依据；具体metrics及评分器仍各自保留，尚未全数挂接。	答案、误差、状态 / 过程、人工 / 模型评审各报；不以4类代表4个完成的通用评分器。

这是固定250篇书目的来源查核。全库去重后的环境、语义任务和完整可运行题数仍待创建；添加规则要有父任务、差异与判分，不能以排列数当完成量。

用途与文献分布

用途回答做什么生活 / 工作；研究类型回答论文测什么。用途可多选，文献主类一篇一类；来源共享视频或资产时仍需去重。

用途	来源数 / 183	来源支持
居家整理与清洁	104	P001、P003、P007、P009、P010、P011、P012、P013、P016、P017、P018、P024、P026、P027、P028、P029、P030、P031、P032、P033、P038、P039、P040、P042、P062、P063、P064、P065、P066、P067、P068、P069、P070、P071、P072、P073、P074、P075、P076、P080、P081、P082、P083、P084、P087、P093、P094、P095、P096、P097、P098、P099、P100、P101、P104、P105、P106、P107、P108、P109、P111、P114、P116、P119、P123、P124、P129、P142、P143、P144、P145、P164、P165、P166、P169、P178、P180、P181、P198、P199、P201、P202、P203、P204、P205、P206、P207、P212、P214、P034、P037、P051、P054、P110、P125、P126、P127、P120、P132、P150、P222、P228、P247、P250
餐饮与烹饪	70	P003、P004、P005、P006、P008、P009、P010、P011、P012、P013、P014、P018、P021、P022、P023、P024、P026、P027、P028、P029、P030、P031、P032、P033、P039、P063、P070、P071、P072、P073、P096、P097、P098、P100、P101、P105、P106、P108、P109、P116、P141、P143、P145、P152、P164、P166、P182、P198、P202、P204、P207、P212、P214、P002、P053、P057、P060、P125、P126、P127、P132、P217、P222、P228、P229、P233、P241、P246、P247、P250
衣物与洗护	25	P045、P082、P083、P085、P086、P087、P092、P093、P100、P119、P151、P152、P167、P181、P185、P196、P088、P089、P090、P091、P127、P186、P188、P191、P120
办公与教育	18	P018、P038、P039、P042、P072、P094、P095、P100、P101、P141、P144、P145、P202、P002、P054、P126、P120、P150
工艺与修缮	17	P003、P004、P013、P023、P028、P029、P031、P041、P063、P073、P106、P112、P141、P002、P034、P054、P150
装配与生产作业	30	P015、P016、P023、P063、P067、P068、P069、P076、P079、P082、P083、P106、P112、P115、P119、P129、P141、P170、P171、P177、P179、P183、P184、P207、P208、P210、P211、P120、P150、P225
包装、仓储与物流	8	P076、P084、P086、P103、P164、P170、P200、P077

用途	来源数 / 183	来源支持
零售与购物	9	P013、P031、P100、P164、P200、P202、P204、P120、P150
实验室操作	12	P021、P031、P072、P112、P164、P172、P173、P174、P175、P176、P192、P120
医疗与手术支持	5	P041、P113、P164、P060、P247
个人照护	8	P003、P014、P031、P087、P103、P148、P167、P002
交通移动与车辆维修	12	P003、P004、P013、P014、P031、P202、P002、P060、P150、P226、P247、P250
农业与园艺	7	P013、P023、P028、P031、P100、P002、P213
休闲与运动	16	P003、P013、P014、P019、P020、P031、P033、P041、P063、P072、P106、P202、P002、P054、P229、P247
公共场馆与服务	3	P102、P103、P209
宠物照护与动物活动	4	P025、P041、P205、P002
音乐与表演	3	P014、P229、P247
社交与沟通	7	P013、P019、P020、P032、P033、P061、P168
通用对象与机动作业	31	P062、P063、P065、P067、P068、P069、P075、P076、P081、P082、P083、P084、P106、P107、P115、P123、P129、P151、P152、P169、P171、P177、P182、P212、P214、P077、P125、P128、P193、P222、P228
协助、交接与陪伴	17	P058、P061、P073、P097、P103、P113、P141、P142、P143、P145、P146、P147、P148、P168、P208、P209、P210
穿戴交互与动作界面	25	P013、P014、P018、P019、P020、P058、P119、P197、P198、P199、P051、P053、P057、P060、P216、P222、P224、P225、P226、P228、P229、P230、P233、P247、P250

研究类型	主来源	全部书目
人类视频与动作数据	32	32
理解、推理与规划	21	25
未来动作 / 交互预测	18	48
一般操作 benchmark	31	32
布料 / 柔性物操作	21	26
导航与家务运行	11	11
稳健性、失败与评测品质	19	19
人类观测到机器人转移	7	11
机器人数据与通用策略	6	16
辅助与协作	11	11
世界模型与预测表示	5	9
Survey / 评测方法	1	10

评估方式	来源数 / 183（可多选）	原生判分
标准答案比对	64	accuracy、precision / recall / F1、top-k等；各自保留分母。
数值误差与相似度	103	距离 / 角度 / 时间误差、ADE / FDE、IoU、生成品质等；不同量纲不混平均。
环境状态与过程检查	95	成功率、合规完成率、违反率、完成时间与成本；按任务保留条件。
人工或模型评审	21	rubric分数、偏好率或排名；人工与模型裁判、版本和一致性另记。

四类评估方式不是四个已完成的通用评分器，也不应把不同单位的误差混成单一分数。

从Survey到可投稿Benchmark

本次交付完成逐篇来源核读。论文的规模与广度主张仍需靠共同任务联集、真正添加的规则及同协定模型结果验证。

1. **M1　来源阅读与共同比较**

   本版250篇筛查、183份逐篇审阅、原文页码/单位/重用纪录和五栏比较表。

   验收：所有原143来源有记录，补入40来源；可重算分类分布，未知与冲突公开。

   本轮已完成，限现有书目范围

2. **M2　逐ID整理环境与任务联集**

   取得各来源任务清单，保留source ID、version、split、资产引用；标示equivalent/derived/unresolved。

   验收：来源覆盖率按183来源计；每笔任务有父来源和判分定义，不能仅比名称。

   已有部分清单；全库去重尚未完成

3. **M3　扩充任务与规则**

   针对已核来源添加必要过程、精度、安全、恢复、记忆与协作规则；逐条记录相对父任务添加了什么。

   验收：添加语义目标与添加测例条件分开计数；每个合法变体有可解性与evaluator验证。

   设计可据来源展开；未承诺固定题数

4. **M4　创建可运行评测与论文证据**

   分问答、预测、规划、控制输出报分；固定观测/动作/时间/抽样预算，做来源与任务群聚切分。

   验收：公开case manifest与判分器，报subset实测及不确定性；以去重后覆盖和添加任务证明规模优势。

   全库尚未完成；既有小型实验为工程附录

共同结构、格式与实例

保留原作

来源快照

论文、GitHub、数据版本、实际阅读证据

`paper → repo → commit / data release`

→

整理成全库

共同目录

领域、环境、任务、题目、判分＋来源关系

`source · domain · environment`
`task · case · evaluator`

→

逐项验证后发布

可评测子集

有输入、初态、协定、判分与可回查结果

`assets + protocol + evaluator + evidence`

箭头表示整理与验证流程。进共同目录、已取得素材、已能评测各有自己的状态；不把上一层数量直接算成下一层完成量。

结构规格草案 0.2 · 2026-10-11。0.2是界面规格版本，不是题库发布版号。这份文件根据逐篇核读整理共同界面；每篇的仓库、版本与程序证据另见 GitHub 核读表。原生任务索引、已取得素材和可评测题目仍分项计数。

先看最简单的结构

我们只维护三层：**原作快照 → 共同目录 → 可评测子集**。首页仍只回答领域、环境、任务、题数、评估方式。

层	保存什么	何时算完成
原作快照	论文、GitHub commit、子模块、任务 / 数据 / 判分原档引用与hash	身份和版本可回查；下载与阅读各有纪录
共同目录	来源、用途、环境、任务、题目、判分器及它们的关系	字段、ID、引用和原生单位通过检查；语义未决保持未决
可评测子集	完整输入、初态、可见信息、动作 / 输出、预算与判分	素材、协定、判分正反例、切分及运行范围逐项验证

一本论文可以有多个仓库，同一个仓库也可以支持多篇论文。原作、仓库、版本、原生task、case和trial各有自己的ID，不能共用一个「数据量」数字。

用两个例子走完

步骤	CALVIN：操作机器人	OpenEQA：看环境后回答
固定原作	CALVIN主仓库和它指定的calvin_env子模块	OpenEQA固定版本与open-eqa-v0.json
认识环境	A–D四个原生场景；D_eval沿用D的layout	episode_history是观测历史引用，不能直接当作可操作环境
认识任务	34个原作子任务定义，例如开抽屉	7个信息题型，例如对象位置；不是7个机器人工作
找到一题	需绑定实际初态、指令链、观测与动作协定	一个question_id连到问题、历史输入、答案与判分协定
真正判分	由具体goal checker与整条指令链的完成结果判分	依原作开放式回答评审；裁判、prompt与版本一并固定
目前可计什么	已取得34条任务定义；不能把文中1,000条链当成本案已取得	已取得1,636条问题 / 答案元数据；完整历史图像另行取得
进入共同格式	source→environment→task→case→evaluator，保留原生动作尺度	source→history resource→information task→case→evaluator，保留图像可见范围

两个例子共用身份、来源和评测纪录格式，但输入、输出与判分各自保存。对它们添加「指令被打断后恢复」或「不得读取某段历史」时，要写出父任务、变更规则、答案如何产生及添加的评测版本。

目录怎么放

以下为目标目录结构；现有catalog importer保留其0.1版本，不以这张示意冒充全部adapter已实作。

```
benchmark/
  sources/                  每份來源一張卡：身份、版本、原作入口
  catalog/
    domains.jsonl           用途分類與定義
    environments.jsonl      有身份的場景 / layout
    tasks.jsonl             原生任務與共同規格、規則版本
    cases.jsonl             一題的輸入 / 初態 / split / 判分引用
    evaluators.jsonl        原生與共同判分契約
```

```
adapters/                  按來源或資料形態讀取、轉換、驗證
protocols/                 模型可見資訊、預算、輸出及切分規則
releases/                  固定的catalog / evaluation發布清單
```

视频、HDF5、NPZ、3D资产与大型模型存放在数据保存区。目录保存引用、内容hash和依赖关系；网站直接从同一份目录产生表格和下载。

一篇 GitHub 怎么读

依这个顺序走一遍，每一步留实际文件名、commit、行号和阅读结论。

顺序	读什么	要回答的问题
1. 身份与版本	论文 / 作者页 → README → tag / submodule	这是否该篇的作者程序？是原作版、移植版、新版或只是网站？
2. 任务入口	registry、task class、goal DSL、题型或活动表	原作的一个task究竟是什么？目标、参数、变体怎么分？
3. 数据入口	manifest、dataset reader、纪录器、split设置	一笔样本包含什么？时间、单位、座标、label和来源如何对齐？
4. 真正判分	运行入口 → wrapper → 具体checker / metric	程序实际如何判分？分母、失败排除、候选预算与聚合是什么？
5. 整理与映射	来源卡、字段对照与验证纪录	哪些原样保存、哪些要转换、哪些仍不足以形成合法评测？

README中的指令只是入口。要沿实际调用链读到数据与判分。例如LIBERO的基底`_check_success`是占位，真正goal检查在具体problem子类；只读基底会得到错误结论。

每份来源只填一张卡

字段	最少要有什么
来源身份	paper ID、repo及角色、官方性依据、固定版本、读过的文件

字段	最少要有什么
领域	原作任务 / 用途支持的分类；逐任务映射与来源层级标签分开
环境	原生scene / workspace / asset或生成规则；视频观测脉络另存
任务	native ID、原生单位、目标 / 规则 / 必要过程、参数或变体
题数与数据	原生split、case/sample单位、输入 / 标注引用、已取得范围
评估方式	实际checker / metric文件、版本、所需证据、聚合与预算
标准化结论	可复用、需要转换、仍缺少什么；目前是目录或可评测

字段不明时用null和原因。未找到官方GitHub不表示原作没有数据；只有README或网站的仓库，也不表示评测程序已公开。

统一哪些东西

统一身份、字段意思、数据关系及评测界面。 原生表示保留，转换由adapter完成。

共同项目	必须保留的原作细节
身份	source、repo、commit、native ID、split、父数据与衍生关系
时间	原片秒数、frame index、特征时间格、控制频率、预测截止点与horizon
空间	座标frame、世界 / 相机方向、quaternion顺序、单位与变换参数
动作	embodiment、controller、位置 / 速度 / 力矩 / 增量、维数、缩放与夹爪约定
观测与答案	数据里有什么，以及此评测允许模型看什么；参考状态 / 未来 / 答案分开
成功与误差	原生predicate / metric、阈值、时间持续、invalid规则及分母
发布	schema / adapter / evaluator / protocol版本与全部依赖的固定清单

相同形状的tensor可能有不同物理意思；不同形状也可以走相同的adapter界面。控制、问答、定位、预测与世界模型保留各自输出类型与native metric。

从已读程序看到的具体原因

原作	已核对的程序事实	我们要怎么处理
Meta-World现行版	基础obs由当前18维、前一观测18维、goal3维组成；部分说明仍写9D	由固定程序与数据验证schema，记下stack与goal可见性，不只抄文字说明
Meta-World vs CALVIN	Meta-World原生4维控制另乘action_scale；CALVIN有两种7维动作，relative另有位置 / 角度缩放	保存原生ActionSpec及转换，不强制把所有数据视为同一个7维矢量
CALVIN	主仓库pin的calvin_env不是该仓库的目前main；scene_obs存在数据里但原作政策不使用	固定依赖闭合版本，并把保存字段和政策可见字段分开
ManiSkill1/2/3	原作2021在Legacy，ManiSkill2在v0.5.3，现行main为ManiSkill3	不用同一个main代表三篇；版本与映射各自有证据
ManiSkill2	recorder保存T+1个观测与T个transition；depth以uint16并乘2^10写入	保存时间对齐和深度尺度；dtype本身不足以解释数据
ManiSkill3	training loader裁去最后obs；device分支另对success/fail赋值为terminated/truncated	原始保存和training view分开；保留原label，导入adapter需做回读一致性检查
RLBench	condition可以表示关节、抓握、侦测、顺序或OR；variation还会换目标部位	完成条件与必要过程一起保存，不从任务名称推定
CrossTask	18 primary与65 related标注资格不同；时间转到1Hz特征格会floor/ceil	数据子集、时间格与原始秒数分开；没有GT的活动不自动变成可评题
LIBERO-Plus（P105）	分类档有10,030个扰动条目，许多共用底层任务与初态	保存base task→variant→case关系；原生level与共同难度分开

原作	已核对的程序事实	我们要怎么处理
EgoDex（P119）	ARKit世界座标可能每episode不同；best-of-K只计指定位置点	链接episode座标与原片；保存K、padding、所评joint及被略过的旋转分量
WatchAct（P123）	Plan SR、完整终态一致与LIBERO物理成功不同；progress还可能扣初态	同题可建不同protocol，分别保留原metric与添加规则
Open X（P125）	示例可以把tensor形状对齐，原action却可能是位置、速度或增量	容器/schema和物理ActionSpec分开验证，保留每个子数据源
AHA（P110）	名称为F1的Yes/No脚本实际计算accuracy；模型裁判另有无效输出分母	记下原名称与真正公式，保存invalid数与预期题目全集
ALOHA/ACT（P130）	两个sim有具体reward规则；real界面的0 reward只是占位	原实机评分需另有rubric或checker，不能直接沿用通用rollout日志字段
EggHand / EgoH4（P227 / P230）	相同父视频被切成不同窗口；target是否含当前帧、缺失关节mask与MPJPE对齐不同	父take与时间交集去重，逐协定固定历史 / 未来与有效分母
SFHand（P228）	误差只评匹配、IoU及手别正确的子集合；串流仍取得新图像	同时报评分覆盖率与条件误差，标明online observation
OCT / Diff-IP2D（P233 / P232）	文件可相同，实际caller却不同；OCT wrapper的名称对调不等于Diff-IP2D主路径也如此	必须沿入口查到真正调用，保留native名称、公式和修订版
EgoCast（P249）	预设分支与forecasting分支不同；预测输入路径有GT变量覆写问题	固定两个commit；独立GT、窗口与判分验证通过后才能发布成绩
EgoMAN（P250）	程序已公开，但processed data与模型权重未发布；best-of-K还有特定选样规则	分开程序可读、素材取得与可评测；不把文件中的219K / 3M当作已下载

这些是固定来源的静态核读发现，并非本次跑出的模型成绩。逐篇表提供具体code/hash/行号；涉及可运行行为的问题仍需相应测试。

Adapter只做四件事

```
read_native(source_snapshot)
    讀原作，保留native欄位與來源身份

map_catalog(native_record, mapping_version)
    輸出共同目錄；未知、未決和不適用分開

build_case(record_ids, protocol)
    綁定相容環境 / 觀測、初態、輸入、預算與evaluator

evaluate(prediction_or_trajectory, case)
    保留原生指標，輸出分項證據與明確分母
```

这是共同界面规格，不是宣称所有来源已实作这四个函数。数据源没有原生成功条件时，只能先收目录与示范；添加robot task需要另写goal、规则、可解性和判分。

每次导入留下哪些交付物

交付物	用途	本次已有什么
来源卡与阅读证据	说明读了哪个版本、哪些内容、哪些仍缺少	逐篇JSON、固定commit、行段 / JSON pointer与内容hash
字段对照表	native字段→共同含义→转换→不能推定的内容	每篇「可重用 / 需要转换 / 仍需补齐」及共同规格
原生数量纪录	保留task、layout、sample、frame、trial原单位	原文数量摘录、固定ID清单；全库语义联集尚未完成
导入与验证纪录	记录成功、失败、缺漏、来源及schema版本	现有catalog importer 0.1；不包含所有来源的runtime adapter
发布清单	固定要比较的任务、case、资产、协定和评分器	来源审阅与目录下载；添加可运行子集另行验收

GitHub commit只能固定程序。Hugging Face数据revision、下载压缩档hash、子模块commit、视频 / 资产授权和裁判版本仍要各自记录。原作删除或暂停发布的内容保留处理结果；不以同名仓库补位。

广度、规模和难度怎么报

要证明什么	可用的数字	比较条件
用途更广	有任务支持的用途数、用途交集与添加用途	同一分类表与纳入范围；来源级与任务级覆盖分开
任务更多	去重后语义任务数、保留前作数、添加规则数	相同粒度；换初态 / 颜色不当成新的语义任务
环境更多	有版本身份的场景 / layout联集	共用资产、别名、style组合与程序生成规则分开
题目更多	实际case manifest数量及其中可评测数	native split、素材与判分资格清楚；train不冒充test
覆盖有效	按来源 / 用途 / 任务分组的模型结果与缺漏率	缺失预测仍留在expected-case清单，不只报成功读到的交集
难度可量化	同协定内的baseline反应分布与不确定性	真正跑过模型后才校准；不从文献篇数推定难度

难度先记可观测条件：步骤 / 依赖、容许误差、遮挡、干扰物、材料、历史长度、恢复需求和信息预算。取得模型×case结果后，再于兼容的判分协定内校准成功率 / 误差分级，依task / scene群聚估计信赖区间。IRT需要足够的反应矩阵与拟合检查，不能借用另一领域的100题设置就宣称机器人难度已校准。

规则扩充要留下「父任务→差异→新判分」：例如同样把对象放入抽屉，添加关门、指定顺序、不可碰倒另一对象或中途滑脱后恢复，分别写出是否改变语义任务，还是只添加评测条件。每个添加规则都要有合法完成与近失败的可核对例子；参数排列数不直接当完成题数。

限速与可续作

先读缓存，再抓必要的小型来源档；所有程序共用请求调度。GitHub搜索至少间隔6.5秒，一般API至少0.85秒，raw档与各网站至少1秒。收到429或rate-limit 403时依Retry-After / reset暂缓，保留deferred状态，不立即重试。这能降低触发限制的概率，不能保证服务端永远不限制。

代理同样采一次一个短批量、完成即保存；遇模型服务429就停止添加代理请求，继续本机整理。来源已完成、待查核和暂缓都有独立纪录，续作不需要把整批重新抓取。

发布前的最小验收

- 身份与版本：来源、task、scene、case、evaluator能回到原作；子模块 / 资产版本没有偷换。
- 数据保留：原始纪录与共同纪录可以回查；时间、单位、座标、T/T+1及label不因loader而丢失。
- 合法输入：模型看到的字段符合protocol，参考答案 / 未来 / 特权状态按约定管理。
- 判分正确：接受合法完成、拒绝相关近失败，missing/invalid和聚合分母明确。
- 比较公平：native split保留；新split有血缘核对，候选数、时间 / 动作 / 适应预算固定。
- 计数可重算：论文、仓库、task、环境、case、trial不混加；已取得与已可评分栏。

本研究的规模优势应来自有出处的任务与环境联集，以及清楚定义的新规则。程序仓库数、数据文件数或参数乘积，不能代替这些证据。

250篇逐篇索引

每篇保留原文数量、固定程序版本、实际阅读范围、可重用内容与缺口。下列编号可跳到正文；PDF也可搜索来源编号。

P001 · VLOG

P002 · HowTo100M

P003 · COIN

P004 · CrossTask

P005 · YouCook2

P006 · Breakfast

P007 · Charades-Ego

P008 · EGTEA Gaze+

P009 · EPIC-KITCHENS

P010 · EPIC-KITCHENS-100

P011 · EPIC-KITCHENS VISOR

P012 · HD-EPIC

P013 · Ego4D

P014 · Ego-Exo4D

P015 · Assembly101

P016 · IKEA ASM

P017 · HOI4D

P018 · HOT3D

P019 · EgoBody

P020 · EgoHumans

P021 · Ego-ExoLearn

P022 · CaptainCook4D

P023 · EgoProceL

P024 · EPIC Fields

P025 · EgoPet

P026 · EgoHOS

P027 · EgoPCA

P028 · EgoSchema

P029 · EgoThink

P030 · EgoPlan-Bench

P031 · EgoPlan-Bench2

P032 · EgoTaskQA

P033 · EgoLife

P034 · EgoVLP

P035 · EgoVLPv2

P036 · EgoT2

P037 · EgoEnv

P038 · OpenEQA

P039 · RoboVQA

P040 · RoboBench

P041 · EgoCross

P042 · RoboSpatial

P043 · Embodied VideoAgent

P044 · HiERO

P045 · ManipBench

P046 · RULSTM

P047 · AVT

P048 · EGO-TOPO

P049 · AntGPT

P050 · PALM

P051 · USST / EgoPAT3D trajectories

P052 · StillFast

P053 · HandsOnVLM

P054 · EgoVid-5M / EgoDreamer

P055 · FUTR

P056 · Forecasting hands and objects

P057 · Motor attention and action forecasting

P058 · EgoPAT3Dv2

P059 · EMAG

P060 · Continuous 4D interaction forecasting

P061 · Interact with me

P062 · RLBench

P063 · Meta-World

P064 · LIBERO

P065 · CALVIN

P066 · ManiSkill

P067 · ManiSkill2

P068 · ManiSkill3

P069 · robosuite

P070 · RoboCasa

P071 · RoboCasa365

P072 · VLABench

P073 · RoboTwin

P074 · RoboTwin 2.0

P075 · VIMA

P076 · Ravens / Transporter Networks

P077 · CLIPort

P078 · PerAct

P079 · FMB

P080 · DexArt

P081 · ARNOLD

P082 · RoboVerse

P083 · RoboDojo

P084 · KinDER

P085 · SoftGym

P086 · DeformableRavens

P087 · GarmentLab

P088 · FlingBot

P089 · SpeedFolding

P090 · Cloth Funnels

P091 · UniFolding

P092 · ICRA cloth competition

P093 · MoDeSuite

P094 · R2R / VLN

P095 · RxR

P096 · ALFRED

P097 · TEACh

P098 · Habitat 2.0

P099 · HomeRobot

P100 · BEHAVIOR-1K

P101 · Embodied Agent Interface

P102 · NavVerse

P103 · Follow-Bench

P104 · SIMPLER

P105 · LIBERO-Plus

P106 · MetaWorld+

P107 · COLOSSEUM

P108 · RoboArena

P109 · REFLECT / RoboFail

P110 · AHA

P111 · RoboReward

P112 · EgoOops

P113 · REPAIR-Bench

P114 · RobotArena infinity

P115 · RoboMME-Interference

P116 · OopsieVerse

P117 · UMI

P118 · EgoMimic

P119 · EgoDex

P120 · EgoScale

P121 · EgoZero

P122 · EgoBridge

P123 · WatchAct

P124 · RoboReel

P125 · Open X-Embodiment

P126 · DROID

P127 · BridgeData V2

P128 · RoboNet

P129 · RH20T

P130 · ALOHA / ACT

P131 · Mobile ALOHA

P132 · RT-1

P133 · RT-2

P134 · OpenVLA

P135 · Octo

P136 · pi0

P137 · pi0.5

P138 · Diffusion Policy

P139 · R3M

P140 · VIP

P141 · HoloAssist

P142 · Habitat 3.0

P143 · PARTNR

P144 · CAP / EgoGym

P145 · NIABench

P146 · DexH2R

P147 · HRIBench

P148 · Assistax

P149 · V-JEPA 2

P150 · DreamDojo

P151 · H2R-Bench

P152 · RoboWM-Bench

P153 · EgoExo-Gen

P154 · Hand-conditioned ego predictive model

P155 · EgoExo-WM

P156 · Egocentric survey

P157 · Human-video robot learning survey

P158 · VLA benchmark survey

P159 · tinyBenchmarks

P160 · Rliable

P161 · First-person prediction survey

P162 · Egocentric hands survey

P163 · Ego-exo collaboration survey

P164 · The Imitator Game

P165 · LIBERO-Recover

P166 · SafeVLA-Bench

P167 · DexGarmentLab

P168 · HRIBench (perception, 2025)

P169 · X2Real

P170 · MotionForge

P171 · Bench2Dex

P172 · LabUtopia

P173 · LabDex

P174 · Labimus

P175 · Pipette

P176 · AutoBio

P177 · H2RBench (human transfer)

P178 · RoboRecover

P179 · REBOOT

P180 · SafeManip

P181 · RoboFolDeX

P182 · SoftVTBench

P183 · WireCraft

P184 · DLO-Lab

P185 · RGBench

P186 · BiFold

P187 · SSFold

P188 · DRAPER

P189 · GPT-Fabric

P190 · UniGarmentManip

P191 · ClothesNet

P192 · Phys-Liquid

P193 · GRIP

P194 · Cloth gripper interface

P195 · World models for unfolding

P196 · Deform360

P197 · EgoSim / MultiEgoView

P198 · TACO

P199 · OpenEgo

P200 · SABER

P201 · EgoSAT

P202 · EgoMonth

P203 · EGOSTREAM

P204 · S-EMBER

P205 · CapMem

P206 · EmbodiedMemory-Bench

P207 · EgoCoT-Bench

P208 · DYAD

P209 · HUI360

P210 · RoCo Challenge

P211 · AssemblyGrid

P212 · ARB4WM

P213 · Vision to Harvest

P214 · COIN（interactive）

P215 · World-model evaluation survey

P216 · HAP

P217 · TRS + RVG

P218 · TrajPilot

P219 · FROST-STA

P220 · VISTA（Ego4D STA）

P221 · STAformer++

P222 · Uni-Hand

P223 · INSIGHT

P224 · EMPIRE

P225 · Exo2EgoPose

P226 · EgoTraj

P227 · EggHand

P228 · SFHand / EgoHaFL

P229 · UniEgoMotion

P230 · EgoH4

P231 · MADiff

P232 · Diff-IP2D

P233 · OCT / HOI forecasting

P234 · I-CVAE

P235 · TransFusion

P236 · ActFusion

P237 · Gated Temporal Diffusion

P238 · Object-centric LTA

P239 · MVP

P240 · ANTICIPATR

P241 · AFF-ttention

P242 · NAOGAT

P243 · FactCheck（LTA）

P244 · BiAnt

P245 · ICVL

P246 · Decision-aware uncertainty

P247 · EgoSpanLift

P248 · HOIMotion

P249 · EgoCast

P250 · EgoMAN

P001 · VLOG

From Lifestyle Vlogs to Everyday Interactions

内核内容已核读 · 主来源 · 原作 · 独立页面

找到作者的 VLOGToolkit；它提供原作数据读取和四种感知评测，并按 uploader 群聚 bootstrap，不能把视频当成互相独立的样本。

> **版本与身份**
>
> 固定toolkit commit；README连到Berkeley作者数据页。这补足既有VLOG GitHub空缺，未将数据集宣称量视为已下载量。
>
> README指向dfouhey的VLOG数据页，eval.py署名David Fouhey；与原论文作者和数据集相符。

领域	居家整理与清洁
环境	视频的场景 / 距离类别是观测标签，不是可交互环境。
任务	手—物接触、手部状态、场景类别与proxemic分类；本仓库没有机器人动作任务或完整未来手轨迹评测入口。
题数与数据	manifest.txt、splitId.txt、uploaderId.txt、hand_object.npy、hand_state.txt，clip/frame路径连回video ID；外部data_v1.1.tgz与视频尚未闭合取得。
评估方式	evaluateNBinary先排除标签0再算逐类AP/mAP；其他分支算accuracy/top-k。bootstrap的抽样单位为uploader。hand_state分支直接比较类别预测与标签，不能只照过时的posterior注解传矩阵。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **114,000** 视频 · 原文114K，约数 · 原文页 1, 3
- **30** 对象接触标签 · 原文页 5, 7
- **8** 手部 / 人物状态类别 · 原文页 5, 7
- **219,000** 抽样标注影格 · 原文219K，非全部有一致标签 · 原文页 5

依这个顺序读

1. `Readme.md` ↗

   GitHub · dfouhey/VLOGToolkit · 69cef04828

   作者数据入口、数据路径与评测用途。

   L1–40

---

2. `eval.py` ↗

   GitHub · dfouhey/VLOGToolkit · 69cef04828

   数据索引、有效标签、分类/AP与uploader群聚评分。

   L1–406

怎么接入我们的benchmark

可重用

原生video/frame/uploader ID、split、未知标签mask与评分程序。

需要转换

把视频 / 影格保留为context与case；原生分类分项登记，uploader用于分组切分与不确定性。

仍需补齐

外部素材、Python2 / 旧依赖移植、预测输出类型核对与正式case验证。

P002 · HowTo100M

HowTo100M: Learning a Text-Video Embedding by Watching Hundred Million Narrated Video Clips

内核内容已核读 · 主来源 · 原作 · 独立页面

这个仓库提供视频—文字表征训练与跨数据集检索评测；HowTo100M 是训练数据源，程序的主要评测入口另外读 MSR-VTT、YouCook2 和 LSMDC。

> **版本与身份**
>
> 本轮读取固定 commit 的公开程序；不把 README 的历史「largest」叙述当成现时排名。

领域	餐饮与烹饪、办公与教育、工艺与修缮、个人照护、交通移动与车辆维修、农业与园艺、休闲与运动、宠物照护与动物活动
环境	原作视频 / YouTube 来源作观测脉络；这个仓库没有可直接当成本库交互环境的 scene registry。
任务	保留 CSV 的人类 task 标签与视频—文字检索题型；不能把字幕片段或人类活动直接改成机器人任务。
题数与数据	CSV video_id/task/path、caption 起讫时间、2D/3D 特征。loader 明示两种特征各自的采样频率；完整视频与特征由外部下载。
评估方式	eval.py 将视频与文字配对矩阵送到 metrics.py，以正确配对的排名算 R@1/5/10、median rank。README 指出 YouCook2 使用 validation 集合。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **12** WikiHow来源用途类别 · 原文页 3, 4
- **23,611** human visual-task query labels · 原文页 3
- **136,600,000** weak clip-caption pairs（约数） · 原文页 4

依这个顺序读

1. `README.md` ↗
   GitHub · antoine77340/howto100m · 50af0ffb10

   先区分 HowTo100M 训练数据与三个下游检索评测集合。

   L1–65

---

2. `youtube_dataloader.py` ↗
   GitHub · antoine77340/howto100m · 50af0ffb10

   看视频 ID、task、字幕时间段和不同频率特征如何组成输入。

   L19–52 · L144–150

---

3. `eval.py` ↗
   GitHub · antoine77340/howto100m · 50af0ffb10

   找到检索评测入口及送入 metric 的视频—文字相似度矩阵。

   L83–94

---

4. `metrics.py` ↗
   GitHub · antoine77340/howto100m · 50af0ffb10

   核对 R@1、R@5、R@10 和 median rank 的实作。

   L9–29

怎么接入我们的benchmark

可重用

视频 ID、字幕时段、活动标签、下游检索 split 与 metric 可以保留。

需要转换

转成 video/context 纪录与检索 case；分开保存原片时间、各特征频率及对应关系，另记真正使用的下游数据源。

仍需补齐

原始素材 / 特征下载闭合、跨来源视频重复、共同用途映射与本库 evaluator 接线。

P003 · COIN

COIN: A Large-scale Dataset for Comprehensive Instructional Video Analysis

内核内容已核读 · 主来源 · 原作 · 独立页面

COIN 将标注、下载与评测拆成不同仓库。要先读 annotations 的 domain/task/step 与视频 JSON，再读 code 的时段定位 / 逐影格分割评测。 2026-10-11 补读 annotation-tool 的实际导出与时段生成。

> **版本与身份**
>
> 12 domains / 180 tasks 是作者的活动分类，并非本库21类用途或180个已去重的机器人任务。 annotation-tool 为独立固定提交，CSV 标注工作档不能视为已发布的 database JSON；sample 的 0.5 秒间隔不能推为所有视频 fps。

领域	居家整理与清洁、餐饮与烹饪、工艺与修缮、个人照护、交通移动与车辆维修、休闲与运动
环境	视频观测脉络；原作生活用途不是交互场景 ID。
任务	原生 domain/task/step 分类与人类程序活动；定位、分割是信息评测题型，不能等同机器人工作规格。
题数与数据	ActivityNet 风格 database JSON、YouTube ID、视频 URL、步骤 label/segment 及 taxonomy。README 范例的 class 与下载器的 recipe_type 字段需对实际版本检查。 补读：annotation-tool 读 URLID/URL、TagID/Tag、URLID/Frame/Time 三表，导出 instruction_时间.txt 的 CSV 八栏 URLID,URL,TagID,Tag,Start,End,Time,State。输出 Time 为 times（确认保存次数），有别于 frame.txt 的抽帧秒数；Start/End 为时段秒数。影格模式依 newSpace 分开不连续区段，视频模式先以 toFixed(0) 保存整秒文字。导出只保留有 URLID/TagID 的 tagInfo 列，不含没有标注的视频。
评估方式	定位结果包含 action_id、start、end、confidence、video_name；evaluate.number_label 需设为相符的原生标签空间。分割另报逐影格 accuracy；各自保留分母。 补读工具的 State=0/1/2 分别是未标注 / 已标注 / 删除；checked 是另存于浏览器的布尔值，八栏导出没有带出。这些是标注流程状态，并非 AP/F1、GT 品质或独立复核指针。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **12** 原作活动领域 · 原文页 3, 4
- **180** 人类程序任务 · 原文页 3, 4

- **778** 步骤定义 · 原文页 4
- **11,827** 视频 · 原文页 5
- **46,354** 时间标注步骤片段 · 原文页 5
- **2,797** test视频 · 原文页 5

依这个顺序读

1. `README.md` ↗
   GitHub · coin-dataset/annotations · 67e31260e9

   看三层活动分类与视频、步骤时段的 JSON 结构。

   L1–65

---

2. `download_videos.py` ↗
   GitHub · coin-dataset/annotations · 67e31260e9

   看视频 ID、recipe_type 与 video_url 的实际使用方式。

   L1–26

---

3. `README.md` ↗
   GitHub · coin-dataset/code · c1e09e74aa

   区分 step localization 与 frame-wise action segmentation；确认输出格式及所需标签空间。

   L1–46

---

4. `evaluate.py` ↗
   GitHub · coin-dataset/code · c1e09e74aa

   核对同视频同 action 的时段重叠、F1 与 AP。

   L16–26 · L57–64 · L75–96

---

5. `README.md` ↗
   GitHub · coin-dataset/annotation-tool · b4b3d52729

   辅助标注工具的三份输入、影格 / 视频模式及导出入口。

   L1–29 · L35–81

---

6. `input/video.txt` ↗
   GitHub · coin-dataset/annotation-tool · b4b3d52729

   URLID 与视频文件名范例；不是直接套用公开数据的 YouTube key。

   L1–2

---

7. `input/label.txt` ↗
   GitHub · coin-dataset/annotation-tool · b4b3d52729

   工具本地 TagID / Tag 字典范例。

   L1–6

---

8. `input/frame.txt` ↗
   GitHub · coin-dataset/annotation-tool · b4b3d52729

   URLID / Frame / Time 表与范例每 0.5 秒抽帧；非全数据集 fps。

   L1–8 · L49–52

---

9. `lib/js/index.js` ↗
   GitHub · coin-dataset/annotation-tool · b4b3d52729

   实际导出八栏 CSV 文字、列过滤与导入栏名检查 / localStorage。

   L26–124

---

10. `lib/js/config.js` ↗
    GitHub · coin-dataset/annotation-tool · b4b3d52729

    简易逗号切分、按 URLID 合并及 state / checked 工作流程。

    L1–23 · L79–105 · L232–251

---

11. `lib/js/imageTag.js` ↗
    GitHub · coin-dataset/annotation-tool · b4b3d52729

    追到标注保存及区段生成；影格间距分段、视频秒数取整、times 与 checked 的更新。

    L301–318 · L400–426 · L674–700 · L728–766 · L770–826 · L903–1011 · L1019–1034

怎么接入我们的benchmark

可重用

活动 / 步骤 ID、视频血缘、原生时段及 AP/F1 等判分程序。 可另重用工具输入字典、逐视频 tagInfo 与导出字段。

需要转换

活动放 human_activity_definition；视频与时间标注放 context/annotation；定位与分割 case 分开创建，保留秒与影格换算。 工具 URLID/URL → 来源视频引用，TagID/Tag → 工具版本内标签，Start/End → 原生秒区段；Time/State 放标注流程 metadata。需明确创建这些本地 ID 与已发布 COIN JSON/taxonomy 的映射。

仍需补齐

视频有效取得、完整 split 清单、字段别名核对及本库信息题型的 evaluator 接线。 工具读写采直接逗号 / 换行切分，未处理引号包覆的逗号；仍需导出往返、整秒精度、缺列及 checked 遗失验证。此补读未取得视频或运行浏览器工具。

P004 · CrossTask

Cross-task weakly supervised learning from instructional videos

内核内容已核读 · 主来源 · 原作 · 独立页面

CrossTask 的核心是从教学视频定位有顺序的步骤。18 个 primary tasks 有时段标注；65 个 related tasks 用于跨任务学习，不能全部当成同样有答案的评测题。

> **版本与身份**
>
> 公开程序的版本已固定；README 的外部下载与旧依赖尚未作完整可运行重现。

领域	餐饮与烹饪、工艺与修缮、交通移动与车辆维修
环境	教学视频来源；没有交互场景清单。
任务	原生人类活动包含有序 step descriptions；primary 与 related 任务资格需保留。
题数与数据	tasks 档、task/video/URL CSV、每视频特征 NumPy、叙述限制 CSV 及逐步时间标注。read_assignment 对 start floor、end ceil 并使用半开时段。
评估方式	train.py 的 eval 以 DP 产生步骤指派；get_recalls 按有 GT 的步骤计匹配，再以 task 平均。这是步骤定位召回，不是整个程序的物理完成率。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **83** 全部程序 · 原文页 2, 5, 6
- **18** 主要评测程序 · 原文页 5, 6
- **65** 相关训练程序 · 原文页 5, 6
- **4,700** 视频 · 约4.7K · 原文页 2
- **1,850** 每轮test视频 · 原文页 6

依这个顺序读

1. `README.md` ↗
   GitHub · DmZhukov/CrossTask · 9e6fdccbce

   先分清83活动、18/65子集、外部数据报和1秒特征时间格。

   L1–54

---

2. `data.py` ↗
   GitHub · DmZhukov/CrossTask · 9e6fdccbce

   读 task/step 列表、视频 CSV、时间边界转成指派矩阵及 train/test 分割。

   L1–109

---

3. `train.py` ↗
   GitHub · DmZhukov/CrossTask · 9e6fdccbce

   找到 get_recalls 与 eval，核对可用 GT 子集及逐 task 平均方式。

   L1–85 · L144–182

---

4. `dp.pyx` ↗
   GitHub · DmZhukov/CrossTask · 9e6fdccbce

   确认顺序限制与 exactly_one 的动态规划指派，这会影响输出与评分。

   L1–72

怎么接入我们的benchmark

可重用

83个原生活动 ID、primary/related 资格、步骤顺序、视频与时间标注、原作 recall 逻辑。

需要转换

原始秒数与衍生时间格分栏；固定视频分割与随机分割种子。人类活动、定位 case 和模型重跑分开计数。

仍需补齐

完整来源素材及标注包、当前依赖环境重现、本库 split 血缘核对与 evaluator 接线。

P005 · YouCook2

Towards Automatic Learning of Procedures from Web Instructional Videos

内核内容已核读 · 主来源 · 原作 · 独立页面

作者ProcNets仓库将YouCook2视频程序分段、Lua Torch训练/验证与Python proposal评分放在一起；应读实际公式，不把所有分数都当同一种IoU。

> **版本与身份**
>
> 当前公开码是旧Lua Torch/Python2实作；README的PyTorch未来发布叙述不代表已取得该版本。

领域	餐饮与烹饪
环境	网络烹饪视频的观测脉络；未提供可交互场景。
任务	程序片段提议/分段；步骤文字与时间段不是机器人控制任务。
题数与数据	database JSON的annotations/segment、视频duration/total_frame CSV与ResNet特征；均匀采样和temporal augmentation会改变时间到特征索引的换算。
评估方式	Lua iou是intersection/union；名称为jacc的函数实际除以预测片段长度。验证对每个GT找最佳proposal，再逐视频平均。Python另按tIoU算precision/recall并限制每视频proposal数。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **89** 食谱 · 原文页 3, 4
- **2,000** 视频 · 原文页 3, 4
- **176** 小时 · 原文页 3, 4

依这个顺序读

1. `README.md` ↗
   GitHub · LuoweiZhou/ProcNets-YouCook2 · 815ae582b5

   匹配作者论文、数据与评测路径。

   L1–77

---

2. `misc/DataLoader.lua` ↗
   GitHub · LuoweiZhou/ProcNets-YouCook2 · 815ae582b5

   原始时间、均匀采样与augmentation换算。

   L8–12 · L14–18 · L22–30 · L37–41 · L58–63 · L89–97 · L102–106 · L108–112 · L122–135 · L145–149

---

3. `train_bilstm_seq.lua` ↗
   GitHub · LuoweiZhou/ProcNets-YouCook2 · 815ae582b5

   IoU/Jacc实际公式及验证聚合。

   L23–31 · L165–231 · L247–273 · L292–298 · L301–315 · L355–362 · L367–376 · L379–394

---

4. `script/eval_recall_precision.py` ↗
   GitHub · LuoweiZhou/ProcNets-YouCook2 · 815ae582b5

   proposal格式、split与tIoU判分。

   L1–80 · L120–186

怎么接入我们的benchmark

可重用

原生video ID、segment、split、duration/frame信息和两套明确指针。

需要转换

原始秒数与采样索引分栏；记proposal上限、tIoU与逐视频分母，保留原生指针名及公式，不能直接改成robot success。

仍需补齐

完整素材/特征与split闭合、Lua/Python2依赖移植，以及指针等价性验证。

P006 · Breakfast

The Language of Actions: Recovering the Syntax and Semantics of Goal-Directed Human Activities

实作尚未确认 · 主来源 · 原作 · 独立页面

核对原论文数据入口与目前转址后，尚未确认可归属原作的官方GitHub；后续方法的Breakfast实验程序不能替代原作发布。

> **版本与身份**
>
> 这是本轮来源链尚未确认GitHub，不宣称世界上没有Breakfast程序。

领域	餐饮与烹饪
环境	论文中的真实厨房和同步视角是录制脉络，并非已取得的模拟scene。
任务	料理活动与action units分层；沉默单元、活动和影格分类不是不同机器人任务。
题数与数据	原作描述受试者、厨房、视频视角和动作标注；旧数据页已转到实验室首页，原生manifest与格式在本轮尚未取得。
评估方式	原文报unit及frame识别表现和依受试者四折评测；没有已确认官方GitHub evaluator可作程序核读。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **18** 真实厨房 · 原文页 3
- **10** 料理活动 · 原文页 3
- **48** 粗粒度动作单元 · 原文页 3
- **11,267** 动作单元样本（含静默） · 原文页 3
- **52** 参与者 · 原文页 3

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

原文活动阶层、受试者分组与数据取得入口。

需要转换

先收source与原生活动笔记；取得文件后保留subject/session/view/time及原生四折，视角不增加独立活动。

仍需补齐

官方实作或数据报、原生时间格和标注字段、完整评分重现。

P007 · Charades-Ego

Charades-Ego: A Large-Scale Dataset of Paired Third and First Person Videos

内核内容已核读 · 主来源 · 原作 · 独立页面

Charades-Ego原文引用gsig的Charades算法；这是沿用Charades的baseline框架，不是完整ego/exo配对数据发布。程序本身明示Python mAP只是近似官方MATLAB评分。

> **版本与身份**
>
> 原文PDF第2页明列此baseline来源；不要把其README上的原Charades结果当Charades-Ego本次实测。
>
> 原作PDF裸网址github.com/gsig/charades-algorithms及作者挑战页共同支持；仓库明示自己是Charades starter code。

领域	居家整理与清洁
环境	同一人类活动的第一/第三人称录制为成对观测；相机视角不能算两套交互环境。
任务	Charades多标签活动识别，需另保留Ego配对与跨视角设置；原仓库157类不能当157个机器人工作。
题数与数据	CSV id/actions含class/start/end；loader以24FPS换算时间，video验证均匀取25个影格，train/val使用不同采样与label格式。
评估方式	map.py逐类排序算AP，无正例类别为NaN；charades_map把没有任何GT的视频分数压至负无限。原码要求精确排名使用官方MATLAB脚本，这个近似不能静默替代。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **112** 录制住宅 · 原文页 1, 2
- **157** 活动类别 · 原文页 2
- **7,860** 视角视频 · 原文页 2
- **1,693** test视角视频 · 原文页 2
- **68,536** 动作标注 · 原文页 2

依这个顺序读

1. `README.md` ↗

   GitHub · gsig/charades-algorithms · 927794cd04

   确认baseline用途与原Charades引用关系。

   L1–35

---

2. `pytorch/datasets/charadesrgb.py` ↗

   GitHub · gsig/charades-algorithms · 927794cd04

   CSV schema、frame换算及video采样。

   L1–65 · L78–188

---

3. `pytorch/utils/map.py` ↗

   GitHub · gsig/charades-algorithms · 927794cd04

   近似mAP实作与官方评分限制。

   L1–39

怎么接入我们的benchmark

可重用

原生视频/活动ID、时间段、RGB/flow读取和baseline预测格式。

需要转换

补ego/exo对应与subject/session血缘，分开frame、video和跨视角评测；保存原生采样及评分版本。

仍需补齐

Ego配对数据/split、精确官方MATLAB evaluator及当前运行环境。

P008 · EGTEA Gaze+

In the Eye of Beholder: Joint Learning of Gaze and Actions in First Person Video

实作尚未确认 · 主来源 · 原作 · 独立页面

已核对EGTEA Gaze+原作与旧数据网址，但目前未确认官方GitHub。搜索中的第三方下载器不等于原作模型或凝视评分实作。

> **版本与身份**
>
> 原文10321样本与后续版本数字需分开；不能用第三方重打包静默取代。

领域	餐饮与烹饪
环境	自然厨房的人类第一人称录像；不是本轮可交互的环境。
任务	凝视估计与动作识别分开；meal活动、action classes和clip样本是不同粒度。
题数与数据	原文第9页定义24Hz视频/凝视、24影格clip、首split与有效凝视；数据档schema及素材仍待取得。
评估方式	论文凝视P/R/F1忽略未追踪与saccade，8影格聚合；动作使用mean class accuracy且clip/video分开。尚未取得已确认官方evaluator。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **7** 料理任务 · 原文页 9
- **106** 动作类别 · 原文页 9
- **86** 录制sessions · 原文页 9
- **10,321** 动作样本 · 原文页 9
- **2,022** 首split test动作样本 · 原文页 9

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

原作时间格、凝视有效性、clip/video层次和split定义。

需要转换

各建gaze与action case；保留原始时间、座标缩放、validity mask和类别空间，不转成robot action。

仍需补齐

官方程式、可确认的数据发布、原生标注与评分接线。

P009 · EPIC-KITCHENS

Scaling Egocentric Vision: The EPIC-KITCHENS Dataset

内核内容已核读 · 主来源 · 原作 · 独立页面

EPIC-KITCHENS 原始版的标注、读取工具与评分库分开发布；旧网址现已转向明确的 55 版仓库。已核读动作 / 对象标注、GulpIO 流程与分类指针。 2026-10-11 补读官方共用 downloader 的版本选择；旧 download-scripts URL 的 404 保留为候选处置。

> **版本与身份**
>
> 固定提交的 annotations / starter-kit / epic-lib 旧路径均转向 EPIC-55。epic-lib README 警告 v1.4.0 及更早版本的 Gulp flow 可能乱序；原始 GoPro 与发布抽帧版本的 fps / frame index 不可混用。 补读 downloader 固定 4f11fb2b579833f360c3c7bb917bf1e24a9787b5，不宣称是 download-scripts 的已验证转址。其 README 说 data/ 未追踪，但该提交完整 tree 列有四份 CSV，且两份 split 已实读；以固定文件为准。原 Snakefile 的 annotations/master 链接需替换为既有 55 固定版本，不能依今天的预设 challenge 选项推回 2018 评测。

领域	居家整理与清洁、餐饮与烹饪
环境	真实第一人称厨房视频；participant_id、video_id 与 seen / unseen kitchen 测试条件须保留。视频、拍摄者与厨房不是同一个环境计数。
任务	动作辨识以 verb_class、noun_class 及其组合定义；对象框另有自己的标注时间轴。这些是人类视频标签，不是可直接运行的机器人任务。
题数与数据	action CSV 含 uid、video_id、participant_id、narration、start/stop_timestamp、start/stop_frame、verb/noun_class 与 all_noun_classes。对象框使用 (top,left,height,width)；object_frame 和 action_frame 需依对照表对齐。S1/S2 测试只公开片段时间；narration 时间不可代替动作边界。 补读：原 55 starter-kit 的 Snakefile 由 train/test_seen/test_unseen_video_ids.csv 产生 Bristol 的逐视频 RGB / flow tar 路径。另由官方 2022 网页直接链接的 epic-kitchens-download-scripts 提供 epic_downloader.py：先读 55 的 video_id/split 和 100 的 ar/da/cmr 布尔 split CSV，依 video_id 后段长度辨认 extension，再以 --epic55-only 或 --extension-only 过滤；两旗标互斥，未指定时涵盖 100（含重用的 55）。输出一律使用 EPIC-KITCHENS/participant/媒体类型 目录，原始 55 远程 train/test 路径另由 epic_55_split 决定。

评估方式	epic-lib 计算 verb、noun、action 的 top-1/top-5；没有 action 分数时可由 verb/noun 分数构造。precision/recall 先逐类计算，再对指定 many-shot 类别平均；与 100 版的 tail / unseen 指针不同。top-k 使用每列排名内是否包含 GT 的平均。 下载器的 --action-recognition/--train 等筛选取自 100 版 challenge 字段；--epic55-only 只限制视频来源，不能替代原 55 的 S1/S2。需仍沿用 55 starter-kit 的 seen→s1、unseen→s2 与原标注契约。MD5 只用于判断文件是否可跳过下载，不是辨识指针；本次未运行下载或校验媒体。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **32** 录制厨房 · 原文页 1, 3
- **3** benchmark端点 · 原文页 11, 12, 13, 14, 15
- **125** 动词类别 · 原文页 10
- **331** 名词类别 · 原文页 10
- **39,596** 动作片段 · 原文页 3
- **454,255** 对象框 · 原文页 3

依这个顺序读

1. README.md ↗

   GitHub · epic-kitchens/epic-kitchens-55-annotations · 63fa7d78eb

   55 版字段、框座标、原始视频与测试条件

   L1–3 · L11–15 · L31–35 · L47–61 · L67–71 · L75–80 · L82–96 · L100–220 · L222–227 · L229–262 · L264–290 · L296–343 · L347–354 · L370–390 · L392–396 · L401–405 · L410–416

2. README.md ↗

   GitHub · epic-kitchens/epic-kitchens-55-starter-kit-action-recognition · 200ba5a497

   从标注到 RGB / flow 片段与 GulpIO 的流程

   L1–158

3. README.md ↗

   GitHub · epic-kitchens/epic-lib · 7f2499aff5

   数据读取与版本限制

   L1–33

4. `epic_kitchens/metrics.py` ↗

   GitHub · epic-kitchens/epic-lib · 7f2499aff5

   top-k 及 many-shot precision / recall 实作

   L12–18 · L35–41 · L75–95 · L118–124 · L129–157 · L162–184 · L188–194 · L196–202 · L221–242 · L258–267 · L274–346 · L348–356 · L369–385

---

5. `README.md` ↗

   GitHub · epic-kitchens/epic-kitchens-55-annotations · 63fa7d78eb

   补读直接连向旧 download-scripts 的官方 55 版取得说明；404 候选另列处置。

   L352–369

---

6. `Snakefile` ↗

   GitHub · epic-kitchens/starter-kit-action-recognition · 200ba5a497

   核对原 55 数据取得的 video_id 清单、Bristol tar 路径及 S1→seen / S2→unseen；metadata URL 仍指向 master。

   L9–48 · L53–105 · L130–147

---

7. `README.md` ↗

   GitHub · epic-kitchens/epic-kitchens-download-scripts · 4f11fb2b57

   官方另链接的 55 / 100 共用 downloader；数据类型、版本旗标与输出目录。

   L1–18 · L48–63 · L109–121 · L139–167 · L169–189 · L239–281

---

8. `epic_downloader.py` ↗

   GitHub · epic-kitchens/epic-kitchens-download-scripts · 4f11fb2b57

   实际 caller→split CSV→版本筛选→URL / 输出路径；核对预设全数据、MD5 跳过条件与 CLI。

   L30–68 · L133–161 · L174–215 · L248–320 · L328–363 · L366–486

---

9. `data/epic_55_splits.csv` ↗

   GitHub · epic-kitchens/epic-kitchens-download-scripts · 4f11fb2b57

   55 版 metadata 的 participant_id / video_id / split 字段与样列。

   L1–8

---

10. `data/epic_100_splits.csv` ↗

    GitHub · epic-kitchens/epic-kitchens-download-scripts · 4f11fb2b57

    100 版 challenge 布尔字段及旧 / 添加视频共表；不把数据源 filter 当成 55 评测 split。

    L1–8 · L20–24

怎么接入我们的benchmark

可重用

原生类别字典、片段 uid、S1/S2 切分、框座标、GulpIO 数据流程与评分函数。 可重用已钉选的取得程序、两版 split CSV 字段、原生 URL 与输出路径映射。

需要转换

source 固定为 EPIC-55；case 保留 uid 与原始 split；segment 同时保留秒与 frame，记录实际抽帧版本；动作 / 对象时间轴以显式映射关联。verb/noun/action 与 many-shot 报表分项保存。 另记录 acquisition_repo/commit、数据 edition、video_id、来源 split、challenge split、媒体类型与 errata/校验表版本；55/100 重用视频共用 ancestry，但各自保留评测切分。

仍需补齐

尚未取得视频 / flow / 隐藏测试标签，也未运行 GulpIO 或官方提交；跨来源与 EPIC-100 重用关系需由 video_id 创建。 需固定下载器实际依赖的 split/md5/errata CSV 版本，验证完整取得与哈希；本次 split 仅核读字段和列出的样列，未宣称逐列审核。

P010 · EPIC-KITCHENS-100

Rescaling Egocentric Vision

内核内容已核读 · 主来源 · 原作 · 独立页面

EPIC-KITCHENS-100 需保留五项挑战各自的数据与评测约定；本次核读总标注、叙述工具及 C1 动作辨识实际指针，没有把其他挑战概括成已集成。

> **版本与身份**
>
> 固定提交的说明列出 P01_109、P27_103 预抽帧错误；原始视频与标注不受影响，数据取得时必须保存修正版本。narrator 是工具，并非额外 benchmark。EPIC-55 many-shot P/R 不等于本版 tail 指针。

领域	居家整理与清洁、餐饮与烹饪
环境	沿用部分 EPIC-55 厨房视频并添加拍摄；PXX_YY 与 PXX_1YY 的视频来源不同，不能把两版视频量相加当作独立场景。
任务	包含动作辨识、弱监督辨识、动作预测、无监督领域适应、视频文字检索。verb、noun、action 类别与检索句子各有原生 ID，挑战种类不等于独立任务数。
题数与数据	train / validation / test_timestamps CSV 以 narration_id 对齐片段；narration_timestamp、start/stop_timestamp、frame 边界各自保存。anticipation 使用动作前 5 秒观测并留 1 秒间隔；UDA 的 source/target 与 retrieval 的 sentence 表另列。C1 预测含 verb_output[N,97]、noun_output[N,300] 及 narration_id。
评估方式	C1 utils/metrics.py 计算全部样本 verb / noun / action top-1/top-5，以及 unseen participants、tail verbs / nouns / actions 的对应 top-1 子集；布尔遮罩决定分母。其他四项挑战需各自取得 evaluator，不可沿用 C1 得分。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **45** 录制环境 · 原文页 1
- **6** challenge · 原文页 7
- **4,053** 动作类别 · 原文页 5
- **89,977** 动作片段 · 原文页 5

- **700** 视频 · 原文页 5
- **13,092** test动作片段 · 原文页 5

依这个顺序读

1. README.md ↗
   GitHub · epic-kitchens/epic-kitchens-100-annotations · ea8b40457a

   五项挑战、字段、版本与错误修正

   L1–120 · L136–193 · L375–421 · L544–579

---

2. README.md ↗
   GitHub · epic-kitchens/epic-kitchens-100-narrator · d9d429819c

   narration 标注工具与时间来源

   L1–68 · L192–229

---

3. README.md ↗
   GitHub · epic-kitchens/C1-Action-Recognition · 277586f7fc

   C1 输出维度、narration_id 与评测输入

   L1–99

---

4. utils/metrics.py ↗
   GitHub · epic-kitchens/C1-Action-Recognition · 277586f7fc

   top-k、unseen 与 tail 子集实作

   L7–13 · L24–30 · L35–41 · L53–65 · L90–106 · L113–129 · L143–155 · L166–175 · L179–193

怎么接入我们的benchmark

可重用

动作 / 叙述时间、原生 split、tail / unseen 子集、C1 分数格式与 top-k evaluator；narrator 可作为标注来源工具。

需要转换

source 版本标 EPIC-100 并创建对 EPIC-55 的 video 重用边；task / case 记录 challenge、narration_id、合法观测窗；retrieval 与 anticipation 分成不同 profile；指针保留原生子集与分母。

仍需补齐

尚未下载视频、验证 frame 修正版、取得隐藏测试或运行提交；C2–C5 的完整 loader / evaluator 仍需另外核读与测试。

P011 · EPIC-KITCHENS VISOR

EPIC-KITCHENS VISOR Benchmark: VIdeo Segmentations and Object Relations

内核内容已核读 · 主来源 · 原作 · 独立页面

VISOR 是 EPIC-KITCHENS 视频上的分割与对象关系标注。五个仓库分别承担 VOS、HOS、来源追溯、可视化与抽帧工作，不能算成五批独立环境。

> **版本与身份**
>
> VISOR-FrameExtraction 要求先修正插值并列出 P02_01、P03_14；新版名词表追加左右手 / 手套，仍保留旧 hand/glove 类别。VOS 不是未修改的 DAVIS 评分：末影格被纳入。

领域	居家整理与清洁、餐饮与烹饪
环境	EPIC-100 的厨房视频子集；video、subsequence、image 各是不同层级。VISOR 重新抽帧，需 frame_mapping.json 才能对回 EPIC。
任务	VOS 在给定首影格对象遮罩后追踪分割；HOS 判断手侧、接触与手对象组合；WDTCF 用查找对象遮罩追溯来源对象与证据影格。这些为视觉理解，不是机器人完成操作。
题数与数据	每视频 JSON 的 video_annotations 含 image.name/video/subsequence 及 mask id/name/class_id/segments/exhaustive/in_contact_object/on_which_hand。dense type=0 为插值、type=1 为端点 GT，不可同当人工标注。VOS 转成 DAVIS 的 JPEGImages、Annotations、ImageSets 与对象色码映射。
评估方式	VOS 实作排除首影格但保留末影格，以逐对象 J（IoU）与 F（边界 F-measure）评分；空 union 的 J=1。HOS 将手侧 / 接触转类别、遮罩转 RLE，交给 COCO evaluator。WDTCF 必须 query 类别、证据影格字符串吻合，source 类别才可计分，另算 query/source mask IoU；错类别或错影格会归零，非单纯来源分类正确率。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **42** 录制厨房 · 原文页 4
- **3** challenge · 原文页 7
- **179** 视频 · 原文页 4
- **50,729** 人工标注影格 · 原文页 4

- **271,584** 人工mask · 原文页 4
- **222** WDTCF test queries · 原文页 9

依这个顺序读

1. `README.md` ↗
   GitHub · epic-kitchens/VISOR-FrameExtraction · 095cb98a7d

   稀疏 / 插值字段、抽帧修正与 EPIC 重用

   L1–23 · L86–151

---

2. `README.md` ↗
   GitHub · epic-kitchens/VISOR-VOS · 0707a688b9

   首影格条件与转换流程

   L1–54 · L85–145

---

3. `dataset/visor.py` ↗
   GitHub · epic-kitchens/VISOR-VOS · 0707a688b9

   逐片段读图、mask 色码与采样

   L22–134

---

4. `evaldavis2017/davis2017/evaluation.py` ↗
   GitHub · epic-kitchens/VISOR-VOS · 0707a688b9

   评测影格范围及逐对象统计

   L1–111

---

5. `evaldavis2017/davis2017/metrics.py` ↗
   GitHub · epic-kitchens/VISOR-VOS · 0707a688b9

   IoU 与边界 F 实际公式

   L14–52 · L101–152

---

6. `README.md` ↗
   GitHub · epic-kitchens/VISOR-HOS · 8566507382

   HOS / active 子任务

   L1–59 · L99–151

---

7. `hos/evaluation/epick_evaluation.py` ↗
   GitHub · epic-kitchens/VISOR-HOS · 8566507382

   COCO 输出转换

   L28–145

---

8. `README.md` ↗
   GitHub · epic-kitchens/VISOR-WDTCF · 02829f0907

   来源追溯输入与标签

   L1–82

---

9. `evaluation.py` ↗
   GitHub · epic-kitchens/VISOR-WDTCF · 02829f0907

   严格证据影格条件与失败归零

   L25–184

---

10. `README.md` ↗
    GitHub · epic-kitchens/VISOR-VIS · c4865d0c53

    可视化工具角色

    L1–31

怎么接入我们的benchmark

可重用

原生分割多边形、接触 ID、首影格输入限制、VOS evaluator、WDTCF JSON 与四项输出。

需要转换

保留 parent=EPIC-100、frame mapping、subsequence 和 mask ID；人工 / 插值标注分开；以 VOS / HOS / WDTCF 创建独立 case/evaluator profile，且记录 480p / 1080p 座标与缩放。

仍需补齐

尚未取得影格与 mask；HOS 的外部 COCO 实作和在线 C6 提交流程未完整追核；数据转换需验证色码与 frame mapping，不能从可视化结果推定可评测。

P012 · HD-EPIC

HD-EPIC: A Highly-Detailed Egocentric Video Dataset

内核内容已核读 · 主来源 · 原作 · 独立页面

HD-EPIC 的标注包含动作、对象移动、凝视、食谱 / 营养与音频；VQA 原始 schema 支持多视频 / 片段。已追到主程序实际使用的 BaseVLM 与 LlavaVideo 评分，而非把旧单视频 Dataset 当作全部界面。

> **版本与身份**
>
> 固定提交文件已添加 MP4 对齐的中介 calibration / pose / gaze；不得假定与原论文首发资产同版。文件明列 mask 与 bbox 由不同团队标注可能不一致；YouTube 版本只供观看，不作复现输入。
>
> vqa-eval README 自述为 HD-EPIC CVPR2025 benchmark 程序，指向官方 annotations；已核对项目名称和实际数据路径。

领域	居家整理与清洁、餐饮与烹饪
环境	佩戴 Aria 眼镜的真实厨房活动及对应 digital twin / fixture。video、participant、capture、fixture、3D 场景的 ID 分开，不把多个传感流计成新环境。
任务	以每个 JSON 的 question prototype 管理五选一 VQA；动作、对象关联、凝视 priming、食谱和声音是标注层，各自不自动成为可运行任务。
题数与数据	叙述含 unique_narration_id、秒制 start/end_timestamp、另列 narration_timestamp、多个 verb/noun pairs 与 main_actions；assoc_info 连到 mask_info 的 0-based MP4 frame、XYZ、XYXY bbox、fixture。音频以 48kHz sample index 标示。VQA 含 inputs/question/choices/correct_idx（0-based），保留多个 input 的 id 与时间窗。
评估方式	主程序调用模型 run_eval；核读 LlavaVideo 的 answer==correct_idx，再由 run_benchmark 对结果平均。BaseVLM 取回复第一个大写字母转选项索引；invalid 回 -1。analyse_output 按 prototype 前缀分组，另列 invalid / failure。输入会按模型 max_video_length_seconds 降采样，须一并报告 input_total_seconds 与 input_subsampled_seconds。

▼ **原作数字：保留论文的单位与页码**

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **9** 录制厨房与数字副本 · 原文页 1, 5
- **69** 食谱 · 原文页 1

- **30** VQA prototypes · 原文页 6, 7
- **26,650** 五选一VQA题 · 原文页 7
- **1,000** VOS串行 · 原文页 28
- **413** 厨房fixtures · 原文页 1, 5

依这个顺序读

1. `README.md` ↗
   GitHub · hd-epic/hd-epic-annotations · aa1f833feb

   多层标注、座标与 VQA 原生格式

   L1–186 · L218–269

---

2. `README.md` ↗
   GitHub · hd-epic/hd-epic-downloader · d3431a3a90

   资产分包与下载角色

   L1–44

---

3. `README.md` ↗
   GitHub · hd-epic/hd-epic-vqa-eval · d0c233be1f

   原作者 benchmark 程序与配置入口

   L1–45

---

4. `data/vqa_dataset.py` ↗
   GitHub · hd-epic/hd-epic-vqa-eval · d0c233be1f

   旧单视频 loader 限制

   L1–99

---

5. `utils/questions.py` ↗
   GitHub · hd-epic/hd-epic-vqa-eval · d0c233be1f

   原始 inputs 分组及时间转换

   L1–70

---

6. `models/base_model.py` ↗

   GitHub · hd-epic/hd-epic-vqa-eval · d0c233be1f

   正式多输入读取、采样与选项解析

   L8–17 · L22–30 · L35–76 · L110–118 · L122–139 · L163–203 · L207–232 · L235–254 · L256–264 · L267–275 · L282–308

---

7. `models/llavavideo.py` ↗

   GitHub · hd-epic/hd-epic-vqa-eval · d0c233be1f

   具体答案比较和输出字段

   L32–42 · L65–75 · L91–109 · L112–122

---

8. `run_benchmark.py` ↗

   GitHub · hd-epic/hd-epic-vqa-eval · d0c233be1f

   实际入口及跨缓存结果平均

   L2–17 · L57–67 · L72–82 · L95–105 · L130–140

---

9. `scripts/analyse_output.py` ↗

   GitHub · hd-epic/hd-epic-vqa-eval · d0c233be1f

   题型统计与失败分类

   L1–91

怎么接入我们的benchmark

可重用

原始标注层关联、五选一题目、时间 / 框 tag 解析、同输入题目分组及正确率流程。

需要转换

用原生 question ID 建 case，inputs 保留多视频与框；同一次 capture 的多传感 / 多题重用同一环境记录。保留完整毫秒时间和原始座标，另记 native adapter 对时间取整秒、框转 0–1000 的行为；模式 visual_text / narration 与采样预算入 evaluator 约定。

仍需补齐

尚未下载数 TB 传感数据、校准 / digital twin 或运行模型。各模型 wrapper 的 parsing / API 版本仍需个别验证；data/vqa_dataset.py 只支持单视频且旧字段与正式 VQA 不同，不能直接通用。

P013 · Ego4D

Ego4D: Around the World in 3,000 Hours of Egocentric Video

内核内容已核读 · 主来源 · 原作 · 独立页面

Ego4D 是多项挑战共用的人类第一人称视频库。本次核读五类官方仓库入口，以及 NLQ、VQ3D、状态变化、长期预测和音频的核心格式 / 指针；各子挑战的完成度分开记录。

> **版本与身份**
>
> 各仓库固定提交仍有 2022 挑战说明；不得自动视为所有后续版本的同一协定。episodic-memory 列出近零 NLQ 时窗问题，需固定 annotation release。PNR 无正例 batch 预设回 0，evaluate_trained 可回 None，统计时应保留。LTA 注解名称与实际使用函数应依赖锁定的 editdistance 版本核实。

领域	居家整理与清洁、餐饮与烹饪、工艺与修缮、零售与购物、交通移动与车辆维修、农业与园艺、休闲与运动、社交与沟通、穿戴交互与动作界面
环境	多种真实日常与工作观测；video_uid、clip_uid 与实体环境须分层。五个挑战仓库不是五批互不重叠的视频或机器人环境。
任务	episodic memory 包含 NLQ、MQ、VQ2D、VQ3D；手对象包含 PNR、状态变化分类与对象定位；其他入口涵盖 looking/talking-to-me、说话者与转录、短期 / 长期动作及未来手 / 移动预测。子任务数不可当做动作类别或 case 数。
题数与数据	NLQ 原生 videos→clips→annotations→language_queries，case ID 应用 clip_uid+annotation_uid+query_idx；保留 clip/video 的起迄秒与 feature-rate 映射。测试预处理填入的 0,0 是未知答案占位，不是 GT。音频 CTM 使用 channel/tb/dur/word，GT STM 另含 speaker/te/txt；RTTM 用于 diarization。
评估方式	NLQ 逐预测计算时间 overlap 与 top-K 超过阈值的比例，程序只列出 evaluated/GT 数，外层必须检查缺题与重复。PNR 仅对 GT 状态变化为真的片段，以 16-bin 映回 frame 再换秒。LTA 使用 N×Z×K 串行、每笔取 K 个预测中最小 editdistance.eval/Z，积分前缀 ED 得 AUED。VQ3D 提供 L2、角度与依两位标注者框大小 / 差异的阈值。转录先 lower-case/GLM 过滤后调用 SCTK WER；audio-only DER 用 pyannote，另外输出逐档平均。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **74** 原作地理locations · 原文页 1

- **5** benchmark families · 原文页 6
- **110** MQ活动类别 · 原文页 7, 30
- **3,670** 视频小时 · 原文页 1, 24
- **19,200** NLQ queries · 原文19.2K，约数 · 原文页 29
- **22,602** VQ queries · 原文页 29
- **64,798** short-term anticipation样本 · 原文页 75
- **19,780** short-term anticipation test样本 · 原文页 75

依这个顺序读

1. `README.md` ↗
   GitHub · EGO4D/episodic-memory · 5275b9570a

   四项 memory 任务与已知标注问题

   L1–42

---

2. `NLQ/VSLNet/utils/prepare_ego4d_dataset.py` ↗
   GitHub · EGO4D/episodic-memory · 5275b9570a

   复合 ID、时间窗及测试占位

   L28–78 · L95–141

---

3. `NLQ/VSLNet/utils/evaluate_ego4d_nlq.py` ↗
   GitHub · EGO4D/episodic-memory · 5275b9570a

   原生阈值、分母与输出

   L13–119

---

4. `VQ3D/VQ3D/API/metrics.py` ↗
   GitHub · EGO4D/episodic-memory · 5275b9570a

   空间误差与标注不确定性阈值

   L1–43

---

5. README.md ↗

   GitHub · EGO4D/hands-and-objects · 0aea0a4ed6

   状态变化任务

   L1–32

---

6. state-change-localization-classification/i3d-resnet50/evaluation/metrics.py ↗

   GitHub · EGO4D/hands-and-objects · 0aea0a4ed6

   PNR 秒制距离与分类 accuracy

   L1–53

---

7. README.md ↗

   GitHub · EGO4D/social-interactions · 033fefb2b1

   lam / ttm 分支角色

   L1–41

---

8. README.md ↗

   GitHub · EGO4D/forecasting · 38d1931b54

   四类预测入口

   L1–64

---

9. ego4d_forecasting/evaluation/lta_metrics.py ↗

   GitHub · EGO4D/forecasting · 38d1931b54

   best-of-K ED 与 AUED

   L1–115

---

10. README.md ↗

    GitHub · EGO4D/audio-visual · da19e63569

    影音子任务

    L1–38

---

11. `transcription/eval_ai_scoring.py` ↗

    GitHub · EGO4D/audio-visual · da19e63569

    STM / CTM、GLM 与 WER 界面

    L5–28 · L32–40 · L60–73 · L107–117 · L123–132 · L136–142 · L156–162 · L165–171 · L211–218 · L240–254

---

12. `diarization/audio-only/diarization/score_pyannote.py` ↗

    GitHub · EGO4D/audio-visual · da19e63569

    RTTM 排序配对及 DER 聚合

    L1–61

怎么接入我们的benchmark

可重用

官方子挑战入口、NLQ 复合 ID / 时窗、PNR / LTA 指针实作，以及音频格式转换。

需要转换

一个父 source 下建各 challenge 的 task/case/evaluator；精确保留输入可见范围、label/feature/frame/second 单位、K / Z / 阈值及 GT 有效遮罩。原生视频重用以 uid 链接，评分逐项保存，不合成一个成功率。

仍需补齐

尚未取得视频或运行 evaluator。社交任务实作在 lam、ttm 分支，本次只读主分支入口，不能说无程序；VQ2D、MQ、STA、未来手 / 移动与社交的完整实作仍须逐支集成。SCTK / pyannote 外部实作未运行。

P014 · Ego-Exo4D

Ego-Exo4D: Understanding Skilled Human Activity from First- and Third-Person Perspectives

内核内容已核读 · 主来源 · 原作 · 独立页面

Ego-Exo4D 的主文件、姿态、步骤与视角关系仓库分工明确。已核对共享步骤 ID、姿态有效关节 / 座标以及具体评分；挑战年份与论文任务清单不能混为一谈。

> **版本与身份**
>
> 已钉选文件的 challenge 页为 2026，但 pose 仓库 README 仍列 2024；不能把当年开放的 2 项挑战当整个 benchmark 覆盖量。body loader 排除含 bouldering 名称的 take 并依相机 / 标注可用性筛选，应保存实际纳入清单。relation README 的 translation 仍写 Coming Soon，不能只凭此推定 tree 完全无相关程序。

领域	餐饮与烹饪、个人照护、交通移动与车辆维修、休闲与运动、音乐与表演、穿戴交互与动作界面
环境	同时拍摄第一 / 第三人称的熟练活动，文件举运动、音乐、舞蹈、自行车维修。以 take_uid 连多相机与标注，camera 数不等于环境数，scenario 是活动分类。
任务	步骤辨识 / 程序理解、穿戴者身体 / 手部 3D pose、ego-exo 对象 correspondence 等分成子挑战。taxonomy 的 step_id 仅 scenario 内唯一；跨 scenario 共用步骤以 step_unique_id 表示，不能逐 scenario 直接加总。
题数与数据	keystep JSON 有 annotations/taxonomy/vocabulary，含 take_uid、scenario、segments 的 start/end_time、step_id、step_unique_id、is_essential。body loader 读 takes.json、camera_extrinsics、annotation / automatic 与可见旗标，提供 global / aria / 当前相机座标选项。hand GT 以 take_uid/frame_number/right或left_hand_3d 及 hand_valid_3d 索引。
评估方式	手姿态要求 21×3、将公尺转毫米，仅有效关节计 MPJPE；PA-MPJPE 使用平移 / 旋转 / 尺度对齐，逐手影格误差再平均。offset 模式加回 GT wrist，须列成不同条件。细粒度步骤以 ego_segment_name 对齐 label_id，缺预测报错，计 top-1。correspondence 提供边界 F 与轮廓中心距离 / 图像对角线范式；完整聚合入口尚未验证。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **8** 原作技能domains · 原文页 10
- **123** 自然录制scene · 原文页 4, 10

- **43** 整体活动 · 原文页 10
- **278** 正式keystep识别标签 · 原文页 28, 73
- **5,035** 概述takes · 原文页 4, 10
- **33,001** keystep test视角片段 · 原文页 74
- **6,373** keystep test ego片段 · 原文页 74

依这个顺序读

1. `README.md` ↗
   GitHub · EGO4D/Ego-Exo4D-docs · aa763b1cd2

   官方文件仓库身份

   L1–35

---

2. `docs/challenge.md` ↗
   GitHub · EGO4D/Ego-Exo4D-docs · aa763b1cd2

   年份、活动背景与挑战入口

   L1–91

---

3. `docs/annotations/keystep.md` ↗
   GitHub · EGO4D/Ego-Exo4D-docs · aa763b1cd2

   scenario-local / global step ID 与字段

   L1–92

---

4. `README.md` ↗
   GitHub · EGO4D/ego-exo4d-egopose · 2494c0d192

   身体 / 手部任务

   L1–20

---

5. `bodypose/data/dataset_egoexo.py` ↗
   GitHub · EGO4D/ego-exo4d-egopose · 2494c0d192

   座标、take、pseudo/manual 与数据筛选

   L27–55 · L58–100 · L108–114 · L117–142 · L145–159 · L166–172 · L182–195 · L198–204 · L206–232 · L239–246 · L250–330

---

6. `handpose/evaluation/evaluate.py` ↗
   GitHub · EGO4D/ego-exo4d-egopose · 2494c0d192

   有效关节、单位及 MPJPE / PA-MPJPE

   L1–137

---

7. `README.md` ↗
   GitHub · EGO4D/ego-exo4d-keystep · 3ceee681f5

   两种步骤任务入口

   L1–9

---

8. `fine_grained/eval_json.py` ↗
   GitHub · EGO4D/ego-exo4d-keystep · 3ceee681f5

   segment ID 对齐与正确率

   L1–42

---

9. `README.md` ↗
   GitHub · EGO4D/ego-exo4d-relation · d6b7443fef

   关系任务与 translation 文件状态

   L1–14

---

10. `correspondence/evaluation/metrics.py` ↗
    GitHub · EGO4D/ego-exo4d-relation · d6b7443fef

    轮廓中心距离与 F 函数

    L4–10 · L41–47 · L65–74 · L110–139 · L191–197 · L210–216 · L231–237 · L242–258 · L264–271

怎么接入我们的benchmark

可重用

take / 步骤全域 ID、阶层 taxonomy、姿态有效性旗标和手部 evaluator。

需要转换

环境保持实体场景 / take / 相机多层关联；scenario→task 用原生 taxonomy，step_unique_id 保留跨 scenario 共用。姿态与视角关系以独立 profile 记录 frame、座标、米 / 毫米、pseudo/manual、GT wrist 条件与对齐方式。

仍需补齐

尚未取得多视角视频与校准、运行 pose / keystep evaluator，或完整核读程序理解 / proficiency 的实作。

fine_grained/eval_json.py 使用 os.path 却未 import os，为静态发现的集成问题；需在 adapter 测试时修正并保留差异。

P015 · Assembly101

Assembly101: A Large-Scale Multi-View Video Dataset for Understanding Procedural Activities

内核内容已核读 · 主来源 · 原作 · 独立页面

Assembly101 的原生粗 / 细粒度和录制 / 视角可以明确分开；六个官方仓库分别是下载、标注、错误标注及三种理解 baseline。

> **版本与身份**
>
> 下载 README 已加入 2026-05 Hugging Face 与更新的 AssemblyPoses.zip；不要把新特征 / pose 视为 2022 原始实验。mistake 注释指向 2023 Every Mistake Counts in Assembly，与原始三项理解评测需创建衍生关系。

领域	装配与生产作业
环境	人类组装 / 拆卸玩具车；recording/sequence 与 8 固定 RGB、4 头戴单色视角分层。toy_id 是对象身份与泛化切分依据，不直接等于场景数。
任务	标注文件列 202 coarse actions（61 对象、11 verbs）与 1,380 fine-grained actions（90 对象、24 verbs），是原生类别数。粗标注供 temporal segmentation，细标注供 recognition/anticipation；mistake/correction 是另外的程序标签。
题数与数据	fine CSV 含 id、video、start/end_frame、action/verb/noun_id、toy_id/name、is_shared、is_RGB；coarse labels 为片段 frame 边界与 action_cls，coarse_splits 分 assembly/disassembly。视频原始 60fps，动作标注 frame 为 30fps；手 pose 又为 60fps。mistake CSV 含 start/end、verb、this/that、label、remark。
评估方式	temporal utils.py 将连续同类影格折成片段，计范式 edit、全影格 MoF、tIoU=.1/.25/.5 下逐 GT 至多匹配一次的 F1。anticipation 先对 action 分数 marginalize 得 verb/object，再算逐类平均 top-k recall，另列 tail/unseen；不是逐题 accuracy。TSM loader 以 start_frame+片段内采样位置读图。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **101** 玩具型号 · 原文页 1, 4
- **202** 粗动作类别 · 原文页 4
- **1,380** 细动作类别 · 原文页 4

- **362** 独立拆装sequences · 原文页 4
- **4,321** 视角视频 · 原文页 4
- **1,013,523** 细动作视角片段 · 原文页 5

依这个顺序读

1. `README.md` ↗
   GitHub · assembly-101/assembly101-download-scripts · 01835b08ae

   recording / camera 与传感版本

   L1–29 · L67–103

---

2. `README.md` ↗
   GitHub · assembly-101/assembly101-annotations · 01651287ee

   两种标注粒度与 30fps

   L1–25

---

3. `coarse-annotations/README.md` ↗
   GitHub · assembly-101/assembly101-annotations · 01651287ee

   coarse 字典、toy split 与片段格式

   L1–87

---

4. `fine-grained-annotations/README.md` ↗
   GitHub · assembly-101/assembly101-annotations · 01651287ee

   fine 字典与字段

   L1–56

---

5. `README.md` ↗
   GitHub · assembly-101/assembly101-mistake-detection · 6f3a953267

   后续错误标注及其来源

   L1–81

---

6. `README.md` ↗

   GitHub · assembly-101/assembly101-temporal-action-segmentation · 1ef3e0abbb

   feature 与 augmentation 条件

   L1–72

---

7. `utils.py` ↗

   GitHub · assembly-101/assembly101-temporal-action-segmentation · 1ef3e0abbb

   MoF / edit / segment F1 实作

   L68–78 · L89–99 · L107–154 · L165–231 · L271–312 · L383–416

---

8. `README.md` ↗

   GitHub · assembly-101/assembly101-action-anticipation · 7ae5cf6328

   预测仓库身份

   L1–16

---

9. `tempAgg-action-anticipation/evaluate.py` ↗

   GitHub · assembly-101/assembly101-action-anticipation · 7ae5cf6328

   评分维度与分数格式

   L1–105

---

10. `tempAgg-action-anticipation/utils/challenge.py` ↗

    GitHub · assembly-101/assembly101-action-anticipation · 7ae5cf6328

    逐类 top-k recall 与子集

    L1–17 · L35–56 · L111–128 · L145–161 · L169–187

---

11. `README.md` ↗

    GitHub · assembly-101/assembly101-action-recognition · 00d3c3bb3a

    recognition 仓库身份

    L1–16

---

12. `TSM-action-recognition/ops/dataset.py` ↗

    GitHub · assembly-101/assembly101-action-recognition · 00d3c3bb3a

    片段 frame 采样

    L14–45 · L49–99

怎么接入我们的benchmark

可重用

原生粗 / 细字典、toy/view/sequence 身份、跨 toy 切分、错误原因与 temporal evaluator。

需要转换

一个 recording 连多视角 case，分开 fine/coarse/mistake annotation schema；30fps 动作与 60fps pose 显式对时。evaluator 保存 label universe、背景类别、tail/unseen、augmentation 及 macro/micro 聚合，错误与修正另连到原程序上下文。

仍需补齐

尚未取得视频、LMDB、cleaned pose 或运行指针。mistake 仓库 tree 无 Python，发布的是标注并指向后续论文，不能当成已提供错误检测 baseline。anticipation 固定 1064 actions / 17 verbs / 90 objects，需核对其 CSV 子集，不能直接套用完整 1380 / 24 字典；缺题检查被注解，需 adapter 外层验证。

P016 · IKEA ASM

The IKEA ASM Dataset: Understanding People Assembling Furniture through Actions, Objects and Pose

内核内容已核读 · 主来源 · 原作 · 独立页面

IKEA ASM 的 GitHub 包含视频 / 姿态 / 零件处理工具与多项视觉 baseline。本次核读动作数据库、片段转 frame 和具体评分，另确认 tracking 入口依赖 MOT evaluator。

> **版本与身份**
>
> 仓库解析名称为 IkeaASM/IKEA_ASM_Dataset；README 保留早期 dev wording，但已存在实际处理 / 评分程序，不能标为只有计划。物理组装成功不由影格辨识 accuracy 证明。

领域	居家整理与清洁、装配与生产作业
环境	人类组装 IKEA 家具的多视角 RGB/depth 视频；scan_path 与 dev1/dev2/dev3 相机分开，预设 train_cross_env/test_cross_env 是来源切分条件。
任务	原子动作辨识与时间定位、人体姿态、零件分割 / 追踪。frame/clip/pose-based 是模型输入方式，不是三批新任务。背景 NA 不算家具组装任务。
题数与数据	SQLite videos/annotations 表以 video_id 关联；indexing_files 的动作与动作对象关系共同排序，索引 0 插入 NA。ActivityNet 外形 JSON 的 database/annotation 或 results 内 segment 在此 loader 直接切 current_labels[start:end]，实际为 frame index，不能因格式名称就当秒。
评估方式	动作 evaluator 对每视频先算 frame top-1/top-3 和 balanced accuracy 再平均，并调用 ANET detection/classification AP。tIoU 阈值为 .1,.2,.3,.4,.5,.55 至 .95；eval_utils 以真正交集 / 联集及 interpolated P/R 积分。tracking 入口采 dev3 的 MOT 格式并调用 motmetrics，细部 matching 尚未完整核读。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **5** 录制环境 · 原文页 4
- **4** 家具种类 · 原文页 4
- **371** assembly scans · 原文页 4
- **1,113** RGB视角视频 · 原文页 4

- **117** test assembly scans · 原文页 4

依这个顺序读

1. `README.md` ↗
   GitHub · IkeaASM/IKEA_ASM_Dataset · 6fc2d9ea67

   精确论文身份、多模态资产与子任务

   L1–78

---

2. `action/README.md` ↗
   GitHub · IkeaASM/IKEA_ASM_Dataset · 6fc2d9ea67

   baseline 输入与原生 split

   L1–64

---

3. `action/IKEAActionDataset.py` ↗
   GitHub · IkeaASM/IKEA_ASM_Dataset · 6fc2d9ea67

   SQLite、字典排序、frame labels 与相机

   L22–100 · L160–226 · L310–346

---

4. `action/evaluation/evaluate.py` ↗
   GitHub · IkeaASM/IKEA_ASM_Dataset · 6fc2d9ea67

   实际指针与聚合

   L1–112

---

5. `action/evaluation/eval_utils.py` ↗
   GitHub · IkeaASM/IKEA_ASM_Dataset · 6fc2d9ea67

   top-k、tIoU 与 AP 内核公式

   L1–92

---

6. `part-tracking/eval.py` ↗
   GitHub · IkeaASM/IKEA_ASM_Dataset · 6fc2d9ea67

   MOT 子任务入口

   L1–28

怎么接入我们的benchmark

可重用

SQLite / split 索引、动作字典、frame segment 转换及原生动作评分流程。

需要转换

scan→camera→frame 建来源关联，任务字典保留排序与 NA。case 记原始 frame 边界与相机、输出 logits 和片段分数；每视频平均与全 frame pooled 的统计分开，pose/tracking 另建 evaluator。

仍需补齐

尚未取得 SQLite、视频、校准与标注或运行。姿态、分割与完整 MOT matching 需后续独立 adapter。README 的 evaluate 路径与 tree 中 evaluation 不同；入口解析 testset_filename 但创建 Dataset 时未显式传入，需确认实际 split 生效方式。

P017 · HOI4D

HOI4D: A 4D Egocentric Dataset for Category-Level Human-Object Interaction

内核内容已核读 · 主来源 · 原作 · 独立页面

HOI4D 有可直接利用的 room、layout、对象与任务路径，原生任务表也已核读；后续 semantic/action segmentation challenge 的张量与类别空间需独立保存。

> **版本与身份**
>
> 三仓库均引用同一 HOI4D 论文；两个 challenge 仓库同时引用后续 PPTr，不表示这些程序和首版论文的所有协定完全相同。task 表的 T1–T6 是来源内编码，与本计划旧 T 模块无关。
>
> Instructions 的精确标题 / 作者 / 官方项目链接及两个 challenge README 的同题引用、hoi4d.top 指向一致；保留各自 repo 角色。

领域	居家整理与清洁
环境	路径 ZY/H/C/N/S/s/T 分别代表 camera、human、object class、object instance、room、room layout、task。S 与 s 才提供实体房间 / 布局身份，T 不可计为新环境。
任务	task_definitions.csv 按 16 个对象类别列 T1–T6，含取放、开关、切割、倒水、收纳、装订等；有 N/A 和相同文字重复字段。T 编号仅在对象类别内有意义，不能把列×栏或动作 segmentation label 当通用任务总数。
题数与数据	align_rgb/depth、objpose JSON、action/color.json、raw_pc/label.pcd、相机 output.log、motion masks 与 MANO pose 各自保留。CAD 的 canonical frame 定义对象姿态；MANO 转米时除 1000。action challenge HDF5 读 pcd/center/label，与原始 RGB-D 数据是加工关系。
评估方式	semantic test_seg.py 去掉输出 channel 0/1、回加 label offset=2，再聚合各类 intersection/union；跳过 0/1 与 GT 无样本类，计 macro accuracy/mIoU。action train_p4.py 用 frame accuracy、segment edit 与 F1@.1/.25/.5，结果还依 batch 聚合。公开 challenge 输出形状分别 (892,300,8192) 与 (892,150)，是串行×时间×点或串行×时间，不能当任务类别数。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **610** 录制rooms · 原文页 1
- **800** 对象实例 · 原文页 1

- **16** 对象类别 · 原文页 1
- **4,000** sequences · 原文页 1
- **376** 4D分割视频子集（含train/test） · 原文页 8

依这个顺序读

1. `README.md` ↗
   GitHub · leolyliu/HOI4D-Instructions · 15478666c4

   数据路径、姿态与空间资产约定

   L1–113 · L133–169

---

2. `definitions/task/task_definitions.csv` ↗
   GitHub · leolyliu/HOI4D-Instructions · 15478666c4

   逐对象原生任务表

   L1–17

---

3. `README.md` ↗
   GitHub · hoi4d/HOI4D_SemSeg · 66df3ff3f0

   challenge 身份与输出 shape

   L1–55

---

4. `test_seg.py` ↗
   GitHub · hoi4d/HOI4D_SemSeg · 66df3ff3f0

   label offset、skip 与 mIoU

   L20–28 · L31–55 · L65–100 · L144–166

---

5. `README.md` ↗
   GitHub · hoi4d/HOI4D_ActionSeg · ca779d86ad

   action challenge 格式

   L1–54

---

6. `datasets/AS_base.py` ↗
   GitHub · hoi4d/HOI4D_ActionSeg · ca779d86ad

   HDF5 schema 与 train/test 读取

   L1–80

---

7. `train_p4.py` ↗
   GitHub · hoi4d/HOI4D_ActionSeg · ca779d86ad

   frame accuracy / edit / F1

   L66–80 · L88–96 · L114–143 · L147–189 · L258–270

怎么接入我们的benchmark

可重用

room/layout/task 身份、原生任务表、CAD articulation / pose 及 semantic/action 评分。

需要转换

保留 C+T 复合 task ID 并以 parent source 追溯，N/A 不计数，重复语义仅提出待核对关系。environment 用 S/s，case 记原始串行→challenge HDF5 row 的映射、点采样与 label mapping；3D/4D segmentation、动作分割与人体姿态分 profile。

仍需补齐

尚未取得 RGB-D、CAD、HDF5 或运行 CUDA baseline；需要 release.txt 和 challenge row-order / sampling 映射、标注时间单位与原生 challenge evaluator 版本核对。不能把具有人类取放标签的视频当已可运行的机器人题。

P018 · HOT3D

HOT3D: Hand and Object Tracking in 3D from Egocentric Multi-View Videos

内核内容已核读 · 主来源 · 原作 · 独立页面

HOT3D 官方 toolkit 同时服务完整 VRS 串行与 HOT3D-Clips 子集；已核读 schema、DataProvider 和 BOP 转换，不把工具可读取误写成已完成评测。 2026-10-11 补读官方链接的 hand_tracking_toolkit 提交、GT writer 与实际指针 caller；BOP evaluator 仍未核读。

> **版本与身份**
>
> VERSIONS.md 列 v2 修正 MANO 拇指、v3 更新 visibility，metadata.json 的 version 需随数据保留。Clips README 对 T_world_from_object 的文字方向与字段名不一致，已用实际 converter 确认为 model→world 再转 camera，不直接拷贝文字说明。 官方项目页区分 2024 whitepaper / ECCV 2024 hand challenge 与 CVPR 2025 完整论文；此补读固定 hand_tracking_toolkit@bc628e9286c18444b47a0971a89d075ea6f00747，不宣称今日 snapshot 就是 2024 服务器提交或论文全部实验。README 的 pose 栏名和 run_evaluation.par 与程序的 mano_theta / run_evaluation.py 不同，以已读 caller/writer 为准；数据 v1–v3、论文 edition 与 evaluator commit 分开保存。

领域	居家整理与清洁、餐饮与烹饪、办公与教育、穿戴交互与动作界面
环境	Aria / Quest3 头戴设备记录的手与对象交互；sequence、participant、clip、device、stream 分层。HOT3D-Clips 为同一数据的 5 秒 / 150 frame 子串行，多个 image streams 不是独立环境。
任务	3D 手 / 对象追踪与姿态、手形估计；BOP object pose 与手部 pose/shape challenge 使用不同 GT 可见性。动态 object onboarding 只给首影格 GT，静态 onboarding 每影格给 GT。
题数与数据	完整数据用 VRS+CSV providers；clip tar 含 image_STREAM、cameras/hands/hand_crops/objects/info JSON，__hand_shapes 跨 frame 共享。clip_definitions 连原 sequence/device/timestamp；clip_splits 有 train、test_ht_pose、test_ht_shape，test_bop 是两个 test 的联集。相机有 fisheye 模型、projection_params、wxyz quaternion，时间为 ns。 2026-10-11 补读：实际 pose JSON 使用 sequence_name、frame_id、mano_theta[15]、wrist_xform[6]、hand_side（0 左 / 1 右）；wrist 前三项送 global_orient，后三项是米制平移。shape JSON 用 mano_beta[10]，GT writer 每 clip 只存一份左右手共用 shape。HOT3D README 规定 frame_id=0,10,20…；GT writer 的 --every-n-frames 预设 1，须显式对齐 challenge 抽样。

评估方式	已核公开格式转换及hand_tracking_toolkit所列pose / shape评分链；完整BOP评分器不在本篇列出的阅读范围。BOP converter 实际以 inverse(T_world_from_camera) @ T_world_from_object 得模型到相机姿态，平移乘 1000 成毫米，XYXY 转 XYWH；visib_fract 取 modeled/predicted 可见性的最小值。不在 stream 范围的对象以 -1 pose、空 mask、0 visibility 占位，不能当真实姿态。 Hand tracking的实际调用链为 scripts/run_evaluation.py→evaluate→compute_overall_*→compute_pose_metrics/compute_shape_metrics。pose 用 GT mano_beta 搭配预测 pose / wrist 做 MANO FK，20 点移除 wrist 后评 19 点并乘 1000 成毫米；实际回传 MPJPE、PCK_AUC、FINGERTIP_PCK_AUC，没有 docstring 所列的 MPVPE。PCK 用误差≤阈值，0–50 mm 共 101 点，曲线乘 100 后以梯形面积除 50，保留 0–100 尺度；五指尖另算。pose 依 GT landmarks 列数（手 / 影格样本，未必是唯一影格数）加权；shape 在零 pose / 零 wrist 的左手模型算 MPVPE(mm)，再等权平均串行。未提交某 dataset 的整份结果档会略过，不是零分。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **1** mocap lab · 原文页 4
- **4** 情境布置类型 · 原文页 4
- **33** 刚体对象模型 · 原文页 4
- **3,832** curated clips（train+test） · 原文页 4
- **1,028** test clips · 原文页 4

依这个顺序读

1. `README.md` ↗

   GitHub · facebookresearch/hot3d · 146b34afef

   完整串行与 clips 工具身份 / 入口

   `L1–78 · L115–162 · L207–248`

2. `hot3d/clips/README.md` ↗

   GitHub · facebookresearch/hot3d · 146b34afef

   tar schema、GT 可见性与 split 联集

   `L1–150`

3. `hot3d/dataset_api.py` ↗

   GitHub · facebookresearch/hot3d · 146b34afef

   必需资产检查与 providers

   L37–115 · L192–240

---

4. `hot3d/clips/bop_format_converters/hot3d_clips_to_bop_scenewise.py` ↗

   GitHub · facebookresearch/hot3d · 146b34afef

   座标 / 单位 / visibility 的实际转换

   L104–114 · L125–154 · L183–219 · L223–244 · L246–276 · L301–311 · L320–337 · L346–369

---

5. `VERSIONS.md` ↗

   GitHub · facebookresearch/hot3d · 146b34afef

   v1–v3 标注版本

   L1–9

---

6. `README.md` ↗

   GitHub · facebookresearch/hand_tracking_toolkit · bc628e9286

   官方 hand challenge 身份、HOT3D 每十影格的提交范围、pose / shape 分轨与本地验证限制。

   L1–9 · L64–80 · L148–260

---

7. `scripts/run_evaluation.py` ↗

   GitHub · facebookresearch/hand_tracking_toolkit · bc628e9286

   真实命令入口调用 evaluation.evaluate；README 的 .par 范例与文件 .py 不同。

   L15–48

---

8. `hand_tracking_toolkit/submissions.py` ↗

   GitHub · facebookresearch/hand_tracking_toolkit · bc628e9286

   实际 JSON writer：mano_theta 15 维、wrist_xform 6 维、mano_beta 10 维、hand_side 和 20 点 GT。

   L27–105

---

9. `scripts/write_annotations_files.py` ↗
   GitHub · facebookresearch/hand_tracking_toolkit · bc628e9286

   GT 由 UmeTrack FK 产生，按 clip_splits 选 Aria / Quest3；every-n-frames 预设 1，每串行只存一次 shape。

   L38–142

---

10. `hand_tracking_toolkit/evaluation.py` ↗
    GitHub · facebookresearch/hand_tracking_toolkit · bc628e9286

    追完整 pose / shape caller、GT shape 注入、依 GT 列数或依串行聚合，以及缺少 dataset 结果档的跳过规则。

    L50–110 · L113–237 · L280–311

---

11. `hand_tracking_toolkit/metrics.py` ↗
    GitHub · facebookresearch/hand_tracking_toolkit · bc628e9286

    核读实际回传指针、19 点去腕 / 五指尖、米→毫米、0–50 mm PCK 曲线与 canonical shape MPVPE。

    L30–56 · L59–321

---

12. `hand_tracking_toolkit/hand_models/mano_hand_model.py` ↗
    GitHub · facebookresearch/hand_tracking_toolkit · bc628e9286

    MANO PCA pose、6 维 global transform 的位置 / 方向分量、21→20 点原生映射及左右手 FK。

    L52–120 · L137–174 · L233–274

怎么接入我们的benchmark

可重用

VRS/clip schema、对象 / 手模型、同步时间、GT 可见性 split 与 BOP 转换。 可另接手部提交 writer、原生 19 点 / 指尖 PCK 和 canonical shape MPVPE；各自保留聚合单位。

需要转换

保留 full→clip→frame→stream ancestry，BOP scene_id 映回 clip_id 而非添加实体场景。座标转换记明方向、米 / 毫米、相机畸变模型和 visibility 来源；测试缺 GT 依 track 显式标 unknown，不填零。 手部 case 保留 clip/sequence_name、frame_id、hand_side、抽样步长、GT shape 是否已知、PCA pose / wrist 矢量格式及 mm/AUC 尺度；不与 BOP 对象姿态合成共同成功率。

仍需补齐

尚未取得 VRS、tar、对象 / MANO 模型、外部 BOP / 手评测套件或运行。需为外部 evaluator 另钉选提交，验证相机畸变、时间同步和 -1 占位规则。 更新：手 evaluator 的选定源代码已取得并钉选，但隐藏 GT、MANO 资产、BOP 套件与运行仍未完成。 caller 仅按 sequence_name 分组及 frame_id 排序后逐列相减，未显式按 frame_id/hand_side join；接线须验证缺列、重复影格与同影格左右手顺序。本地自选 train 子集也不是官方 validation split。

P019 · EgoBody

EgoBody: Human Body Shape and Motion of Interacting People from Head-Mounted Devices

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoBody 官方仓库主要是数据文件与可视化 / 座标转换工具；它有真实来源程序，但没有在此钉选 tree 找到公开 challenge evaluator。

> **版本与身份**
>
> README 包含 2022 全模态发布与 2023 Motion-X 文字扩充；主程序 calibration 路径多一层 cal_trans，需以实际下载版本核对。读过可视化程序不等于重现 README 的 baseline 成绩。

领域	休闲与运动、社交与沟通、穿戴交互与动作界面
环境	HoloLens 与 Azure Kinect 同步拍摄室内双人交互。文件分 125 sequences、36 subjects、15 scenes；环境以 scene_name/mesh 追溯，EgoSet、MVSet、interactee-visible 子集不是三批新场景。
任务	第一人称观察交互对象 / 穿戴者的 3D 人体 pose、shape、motion。Motion-X 的后加文字描述是衍生标注，不能直接视为原版任务或机器人协作成功。
题数与数据	data_info_release.csv 含 recording_name、body_idx_fpv、start/end_frame、scene_name，data_splits.csv 定义 sequence split。PV 图像名以 timestamp_frame 连 Kinect frame；pv.txt 提供每 frame 的 fx/fy/pv2world，keypoints.npz 有 BODY_25、center、scale；valid_frame 以至少 6 个 OpenPose 关节为可见条件。SMPL/SMPL-X 参数在 master Kinect RGB 座标。
评估方式	README 列 MPJPE、PA-MPJPE、V2V、PA-V2V 原作者结果与 challenge 链接；本次没有取得其精确 scoring 实作，因此不能由渲染器推定对齐 / 遮罩 / 单位的评分规则。核读渲染器确认 Kinect→HoloLens world→PV 变换及 OpenCV/OpenGL Y/Z 翻转。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **15** 室内scene · 原文页 9
- **125** sequences · 原文页 9
- **175,611** EgoSet-interactee影格 · 原文页 10

- **62,155** interactee test影格 · 原文页 10

依这个顺序读

1. `README.md` ↗
   GitHub · sanweiliti/EgoBody · e3ecbb839d

   数据身份、scene/sequence/subset、字段与 evaluator 可见范围

   `L1–90 · L96–185 · L209–263`

---

2. `release_renderer_fpv_gaze.py` ↗
   GitHub · sanweiliti/EgoBody · e3ecbb839d

   split 与 frame 边界、校准、座标方向与可见性

   `L37–46 · L65–77 · L94–109 · L116–137 · L139–157 · L175–183 · L192–198 · L214–220 · L225–237 · L246–260 · L272–278 · L287–301 · L324–332`

怎么接入我们的benchmark

可重用

场景 / recording/split 索引、时间同步、有效影格、人体参数与相机转换流程。

需要转换

scene_name 作 environment 关联，recording 与人物角色分开；case 保留 timestamp/frame、相机和 body index。EgoSet_interactee 作同源 subset；范围外 frame 依 start/end 丢弃，另记 valid 遮罩。pose shape profile 保留 SMPL 与 SMPL-X 模型版本。

仍需补齐

尚未取得注册后数据与人体模型，亦未运行或取得 challenge evaluator。需补齐原作的关节集合、对齐、可见性与 mesh error 协定，再标可评测。

P020 · EgoHumans

EgoHumans: An Egocentric 3D Multi-Human Benchmark

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoHumans 官方仓库提供多人体数据处理、COCO-video 转换与追踪评测。已沿 tracking 文件追到内含 MMTracking 的 dataset evaluator 与 MOT matching。

> **版本与身份**
>
> 作者 TRACKING.md 说因 PyTorch 升级，公开结果与原论文有约 1% 变动；不能将当前程序当原表格的逐位重现。所核读的 external/MMTracking 文件是正式入口依赖，其他内嵌模型 / 数据集未据此宣称全数读完。

领域	休闲与运动、社交与沟通、穿戴交互与动作界面
环境	穿戴 Aria 与外部相机同步记录多人活动，含网球、击剑等；big_sequence/subsequence、相机与人物分层。拼接 COCO video 或增加 ego_slam/exo 视角不添加实体环境。
任务	多人侦测、2D/3D pose、mesh 和身份追踪；主要 tracking 比较以 ego_rgb 和指定 detector 条件进行。GT bbox 与 YOLOX bbox 是不同合法输入条件。
题数与数据	coco_video_format.py 以 parent_sequence+sequence+camera+mode 建 video_name；image 有 image_id/video_id/frame_id，annotation 保留 human_name/camera_name/camera_mode/time_stamp，instance_id 由 aria 人名解析，bbox 用 XYWH。frame_id 在可纳入图像串行内重新编号；无有效人框的 frame 会被跳过。MiDaS 深度 / 3D root 是加工输出，不是直接测量深度。
评估方式	CocoVideoDataset 按 frame_id==0 分视频并检查 track_bboxes 长度；eval_mot 用 1-IoU 距离、预设 .5 门槛、ignore IoF 和 MOTAccumulator，输出 IDF1/MOTA/MOTP/FP/FN/IDSw 等。MOTP 在此转成 1-distance，方向与底层距离不同；全体累积结果与逐类平均需分开。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **6** 录制地点 · 原文页 6
- **7** 活动sequences / 类型 · 原文页 6
- **47,740** test ego图像 · 原文页 6

依这个顺序读

1. `README.md` ↗
   GitHub · rawalkhirodkar/egohumans · d7875dd4b3

   论文身份、活动及 benchmark 角色

   L1–82

---

2. `assets/TRACKING.md` ↗
   GitHub · rawalkhirodkar/egohumans · d7875dd4b3

   原作 tracking 和 GT/detector 条件

   L1–33

---

3. `assets/COCO_VIDEO.md` ↗
   GitHub · rawalkhirodkar/egohumans · d7875dd4b3

   COCO video 加工与深度来源

   L1–61

---

4. `egohumans/tools/create_benchmark/coco_video_format.py` ↗
   GitHub · rawalkhirodkar/egohumans · d7875dd4b3

   原始人物 / 影格到评测 ID 的转换

   L35–41 · L43–77 · L84–90 · L109–141 · L145–152 · L155–178 · L188–225 · L228–241 · L263–335

---

5. `scripts/benchmarks/tracking/0_test_tracking.sh` ↗
   GitHub · rawalkhirodkar/egohumans · d7875dd4b3

   实际 MMTracking 入口与子集设置

   L1–130

---

6. `egohumans/external/mmtracking/mmtrack/datasets/coco_video_dataset.py` ↗
   GitHub · rawalkhirodkar/egohumans · d7875dd4b3

   分视频与 evaluator 调用

   L5–13 · L240–254 · L363–453

---

7. `egohumans/external/mmtracking/mmtrack/core/evaluation/eval_mot.py` ↗

   GitHub · rawalkhirodkar/egohumans · d7875dd4b3

   IoU matching、ignore 与 MOT 聚合

   `L2–20 · L28–82 · L87–93 · L100–139 · L147–161 · L179–185 · L188–194 · L218–227`

怎么接入我们的benchmark

可重用

COCO-video 转换、原人物 ID / 时间、tracking 输入条件与内含 MOT adapter。

需要转换

environment 留真实录制 / subsequence，video ID 只作观测串行；维持原 time_stamp 到重编 frame_id 的对照。case/evaluator 记 detector、GT bbox 可用性、ego_rgb/ego_slam/exo、深度来源、忽略区域与匹配阈值，跨拼接需重命名 instance ID 并保存原值。

仍需补齐

尚未取得图像、pose、MiDaS 加工数据 / 模型或运行；主要验证流程需固定设置档与 detector 输出。2D/3D pose 和 mesh benchmark 的完整 evaluator 不包含在这次 tracking 核读范围。

P021 · Ego-ExoLearn

EgoExoLearn: A Dataset for Bridging Asynchronous Ego- and Exo-centric View of Procedural Activities in Real World

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoExoLearn 的核心是不同时间、不同视角的人类示范跟随。已核读标注、跨视角 association 的选项评分和 skill assessment 的成对排序，两者不是同一种成功率。

> **版本与身份**
>
> annotations README 开头仍说只有 train/val，结尾与 root 更新已提供 test GT；标准化应锁定实际文件，不直接采信旧段落。VQA 与 full-size videos 为后续更新，不能并称首发版本。

领域	餐饮与烹饪、实验室操作
环境	数据列 kitchen / lab，用于日常协助与实验室程序；scene 是粗场景用途，video_uid 才是视频 ID。ego/exo 是异步示范关系，不可当同步多相机标定数据。
任务	跨视角 association、动作分割 / anticipation / planning、参考示范的 skill assessment / captioning；2024-08 又加入 VQA。能力题型与程序活动类别分开。
题数与数据	fine CSV 保留 video_uid、annotation_uid、subset、view、scene、start/end_sec、人工 narration_en；hand/no-hand prompt 文字是 GPT 改写。skill list 每列 better/worse 视频，NPZ arr_0 提供特征，use_exo 时依 action 从 exo 文件随机选一参考。association loader 回 query、options、answer、q_type、uid。
评估方式	association 对 query/options 特征相似度 argmax，按 Ego→Exo / Exo→Ego 分组 accuracy；skill train.py 的 accuracy 是 better 分数严格大于 worse 的配对比例，平手不算对。RankingAttentionLoss 为训练 loss，不能拿它代替评测 accuracy。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **7** ego录制场地（4厨房+3lab） · 原文页 3
- **8** 程序任务 · 原文页 3
- **747** ego+exo视频 · 原文页 3
- **34,239** 有效skill比较对（含所有split） · 原文页 4

- **17,300** ego anticipation test片段 · 原文17.3K，约数 · 原文页 12

依这个顺序读

1. `README.md` ↗
   GitHub · OpenGVLab/EgoExoLearn · e1f11b1ab1

   精确论文身份、场景与发布范围

   L1–78

---

2. `annotations/README.md` ↗
   GitHub · OpenGVLab/EgoExoLearn · e1f11b1ab1

   原生 CSV、生成文字与 test 版本

   L1–31

---

3. `association_benchmark/main.py` ↗
   GitHub · OpenGVLab/EgoExoLearn · e1f11b1ab1

   实际 association 输入与双向 accuracy

   L33–51 · L54–84 · L102–110 · L137–147 · L166–181 · L275–336 · L342–364

---

4. `skill_benchmark/dataset.py` ↗
   GitHub · OpenGVLab/EgoExoLearn · e1f11b1ab1

   better/worse 与随机 exo 读取

   L1–117

---

5. `skill_benchmark/train.py` ↗
   GitHub · OpenGVLab/EgoExoLearn · e1f11b1ab1

   validation 聚合与严格成对比较

   L147–166 · L230–253 · L260–281 · L298–313 · L353–361 · L381–420 · L463–476

---

6. `skill_benchmark/losses.py` ↗
   GitHub · OpenGVLab/EgoExoLearn · e1f11b1ab1

   辨别训练 ranking loss

   L1–22

怎么接入我们的benchmark

可重用

原生标注 / 改写来源、跨视角配对、better/worse 排序与两种内核评分。

需要转换

保留 demo_reference 边及不同 video 时间线；同一视频多问答 / 配对透过 uid 共用，不能重算成新环境。case 保存配对顺序、选项、exo reference 与抽样 seed；人工与生成字幕 provenance 分开。

仍需补齐

尚未取得视频 / gaze / 特征或运行。完整 segmentation/planning/captioning 与添加 VQA evaluator 尚未核读；若比较参考示范版本，需锁定具体 exo reference，不能每次随机抽而不留纪录。

P022 · CaptainCook4D

CaptainCook4D: A Dataset for Understanding Errors in Procedural Activities

内核内容已核读 · 主来源 · 原作 · 独立页面

CaptainCook4D 主仓库是入口；已追到官方 annotations 与 error_recognition 程序，核读原始步骤 JSON、mug cake 图、loader 及实际 step/sub-step metrics。

> **版本与身份**
>
> Error-Dataset/annotations 转向 CaptainCook4D/annotations；2023 初版与 2024 最终 baseline / 2025 衍生工作分开。主 repo 无 Python 不能推定整项无程序，实作在其明确链接的子仓库。

领域	餐饮与烹饪
环境	真实厨房中遵循食谱或刻意诱发错误的录制。recording、recipe、person、environment split 分别管理；同一食谱多录制是 case，不自动增加独立任务。
任务	error recognition、early error recognition、多步定位 / 程序学习；task_graph 的 steps/edges 可保留先后与选择限制。loader 另有五类错误 one-vs-rest 标签及 has_errors，未出现 / 负时间步骤不当作已观察完成。
题数与数据	step_annotations 以 recording_id 连 steps 的 step_id、start/end_time、description、has_errors；error_annotations 另连多个 errors.tag。ImageBind 特征按 2 秒索引，其他 backbone 按 1 秒；floor/ceil 后切片，同一 step 多次出现会串接。early 只取前半特征；recording 12_6 在 ImageBind 分支因无特征跳过。
评估方式	base.py sub-step 以 sigmoid>.5 算 accuracy/P/R/F1，ROC-AUC 用连续分数，但 PR-AUC 实际喂二值预测。step 层取每个 loader batch 的平均分数，再可选全测试集 min-max 范式，以 threshold 判断；GT 平均>.95 才当 error。README 报 step split=.6、recording=.4，core/evaluate.py 目前扫 .5/.6，需固定原作条件。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **10** 录制厨房 · 原文页 4
- **24** 食谱 · 原文页 3
- **7** 错误类别 · 原文页 4, 5

- **384** recordings · 原文页 1

依这个顺序读

1. `README.md` ↗
   GitHub · CaptainCook4D/CaptainCook4D · 1137b884e0

   论文身份、真正的标注及 baseline 链接

   L1–75 · L112–173 · L230–320

---

2. `README.md` ↗
   GitHub · Error-Dataset/annotations · a8a920a329

   官方 annotation 仓库与版本

   L1–131

---

3. `annotation_json/step_annotations.json` ↗
   GitHub · Error-Dataset/annotations · a8a920a329

   原生步骤 JSON 样本

   L1–54

---

4. `task_graphs/mugcake.json` ↗
   GitHub · Error-Dataset/annotations · a8a920a329

   完整单一 recipe steps/edges 范例

   L1–1

---

5. `README.md` ↗
   GitHub · CaptainCook4D/error_recognition · 35ef284a67

   评测 split 与作者阈值

   L1–36

---

6. `dataloader/CaptainCookStepDataset.py` ↗
   GitHub · CaptainCook4D/error_recognition · 35ef284a67

   步骤 / 错误字段、时间采样与 split

   L1–4 · L8–20 · L22–32 · L34–53 · L59–145 · L149–169 · L171–376

---

7. `core/evaluate.py` ↗

   GitHub · CaptainCook4D/error_recognition · 35ef284a67

   入口、阈值扫描与 checkpoint 条件

   L1–59 · L71–138 · L148–164 · L171–179

---

8. `base.py` ↗

   GitHub · CaptainCook4D/error_recognition · 35ef284a67

   真正的 step/sub-step 聚合与 metric 输入

   L10–20 · L75–93 · L117–130 · L179–189 · L342–400 · L406–425 · L427–437 · L440–463

怎么接入我们的benchmark

可重用

24 份 recipe graph 的路径清单、逐步错误 schema、split 类型及 error / early 的数据流程。mugcake.json 作为已逐项阅读的 task graph 范例；其他 graph 不能据此宣称内容全审。

需要转换

case ID 用 recording+step+occurrence，保留完整秒数、重复片段及合并规则；source 关联原始视频、特征与 graph。error labels、early prefix、step/recording/person/environment split 分栏；评分保存阈值、min-max、batch_size 和二值 PR-AUC 的原始行为。

仍需补齐

尚未取得视频 / 特征、运行评分或核读 zero-shot/multi_step_localization 全实作。step 切分内 phase=test/val 对应片段命名互换，应以实际索引存盘；batch 必须维持单一步骤，否则 collate 后 batch 被当 step。程序保留作者绝对路径、手选 epoch 表和 start-end>1 条件，均需 adapter 验证与差异记录。

P023 · EgoProceL

My View is the Best View: Procedure Learning from Egocentric Videos

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoProceL 是程序学习数据与 CnC 方法的共同发布；它明确重用 CMU-MMAC、EGTEA、MECCANO、EPIC-Tent 并加入电脑组拆。已核读数据源、PC Assembly loader 和主评分调用。

> **版本与身份**
>
> download README 明列旧 OneDrive 过期与新 Google Drive，并说父库只有部分视频被使用；以新程序标注清单作 subset 证据。PC_Assembly.py 开头注解仍写 MECCANO，但类别及配置实际为 PC_Assembly。

领域	餐饮与烹饪、工艺与修缮、装配与生产作业、农业与园艺
环境	烹饪、玩具 / 电脑组拆、帐篷搭建等人类程序视频；parent dataset→category→video 需要保留。16 个原生 task 是程序活动，不是 16 个独立房间或全部录制环境。
任务	由同一程序多段视频学习 key-step 与次序，包含缺步、重复步和背景。重用父数据的视频被加上程序标注，不可和父库相加当全新视频。
题数与数据	CSV 与原视频同名，三栏为 step 起始秒、结束秒、step 名；子集按来源 / category 分目录。PC_Assembly loader 配对视频与标注、抽 HDF5 frames/labels；train/val/test 分支尚为 NotImplemented，真正公开路径是 mode=all。
评估方式	procedure_learning→gen_print_results→compute_align_MoF_UoI，以 GT/pred frame overlap 做 Hungarian cluster-label assignment，再计 MoF/IoU/precision；per_keystep 模式排除无 GT 类别并平均。另有 procl_eval 函数实作补上未配对类别的 P/R/F1，但不是本主入口调用，二者不混用。GT 用于事后 cluster 对齐不代表模型已输出语义标签。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **16** 程序任务 · 原文页 1, 5
- **62** 视频小时 · 原文页 1, 5
- **130** 参与者 · 原文页 1

依这个顺序读

1. `README.md` ↗

   GitHub · Sid2697/EgoProceL-egocentric-procedure-learning · bf4d9c2e7a

   精确论文身份、原生 task 与四项父数据

   L1–96 · L126–158

---

2. `EgoProceL-download-README.md` ↗

   GitHub · Sid2697/EgoProceL-egocentric-procedure-learning · bf4d9c2e7a

   逐来源取得与 CSV 单位

   L1–93

---

3. `datasets/PC_Assembly.py` ↗

   GitHub · Sid2697/EgoProceL-egocentric-procedure-learning · bf4d9c2e7a

   实际 PC 子集 loader 与 split 限制

   L1–95

---

4. `RepLearn/TCC/procedure_learning.py` ↗

   GitHub · Sid2697/EgoProceL-egocentric-procedure-learning · bf4d9c2e7a

   主流程及子集 key-step 配置

   L1–29 · L31–43 · L121–127 · L160–171

---

5. `RepLearn/TCC/utils.py` ↗

   GitHub · Sid2697/EgoProceL-egocentric-procedure-learning · bf4d9c2e7a

   主入口调用哪个 evaluator

   L8–26 · L143–206

---

6. `evaluate/metrics.py` ↗

   GitHub · Sid2697/EgoProceL-egocentric-procedure-learning · bf4d9c2e7a

   Hungarian assignment 与聚合差异

   L1–243

怎么接入我们的benchmark

可重用

父数据重用清单、原生秒制 step CSV、PC 组装新来源与聚类评分。

需要转换

source→parent video→新 annotation 建 ancestry；task 记来源内 category，case 是指定多视频集合 / 采样与合法 GT 使用范围。cluster ID 保存 Hungarian assignment 作评分证据；K、背景、per_keystep 与全体聚合明列。

仍需补齐

尚未取得视频 / 标注、产生 HDF5 或运行。需要逐子集对应原视频及相同 frame 采样；不能自行发明 train/test split 或把 mode=all 的结果标为未见环境泛化。

P024 · EPIC Fields

EPIC Fields: Marrying 3D Geometry and Video Understanding

内核内容已核读 · 主来源 · 原作 · 独立页面

EPIC Fields分成重建/读取工具与NVS、UDOS评测；epic-fields本身只是网页仓库，不能当作评测程序。

> **版本与身份**
>
> 评测README明示2024-02-10标注更新，并给前版commit；原始arXiv与新版不能混用。

领域	居家整理与清洁、餐饮与烹饪
环境	相机与点云是视频观测几何；video-scene与原厨房一对多，不能每视频都添加可操作环境。
任务	NVS、动态/半静态分割、VISOR衍生VOS是不同信息/世界模型评测端点。
题数与数据	JSON的camera采COLMAP/OpenCV内参，images为qw-first quaternion加translation的world-to-camera，points含XYZRGB。评测另需EPIC100影格、mask、split与模型cache。
评估方式	NVS先逐视频平均PSNR再跨视频平均，前景/背景仅在适用within-action列出。UDOS依有效mask像素算AP、排除无有效标签影格，motion类型分报。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **45** 上游录制厨房 · 原文页 3
- **671** 重建视频 · 原文页 3
- **18,790,333** camera-pose影格 · 原文页 3
- **50** D-NVS来源视频 · 原文页 5, 6

依这个顺序读

1. README.md ↗
   GitHub · epic-kitchens/epic-fields · 44b9cf1660

   确认此repo只存网页。

   L1–2

---

2. README.md ↗
   GitHub · epic-kitchens/epic-fields-code · e5cd4fdfbb

   数据schema、W2C与重建流程。

   L1–145

---

3. README.md ↗
   GitHub · dichotomies/epic-fields-nvs-udos · 4ac1d11096

   原作评测、下载依赖与标注版本变更。

   L1–79

---

4. evaluate_nvs.py ↗
   GitHub · dichotomies/epic-fields-nvs-udos · 4ac1d11096

   NVS输入范围、PSNR与聚合。

   L7–18 · L31–39 · L54–79 · L81–129 · L134–175 · L177–185

---

5. evaluate_udos.py ↗
   GitHub · dichotomies/epic-fields-nvs-udos · 4ac1d11096

   有效区域与motion mask的AP。

   L3–18 · L36–44 · L53–94 · L96–106 · L111–152 · L154–199 · L201–210

怎么接入我们的benchmark

可重用

video/frame ID、相机转换、原生NVS/UDOS split与评分。

需要转换

明记W2C、qw顺序与轴方向；转NeRF时保存反转/翻轴。两种case的可见输入、mask与聚合分母分开。

仍需补齐

对应版本的EPIC100素材、标注与模型输出闭合、视频重用核对和本库evaluator。

P025 · EgoPet

EgoPet: Egomotion and Interaction Data from an Animal's Perspective

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoPet 分成动物交互 VIP、动物移动 LP，以及四足机器人数据上的 VPP。已核读三项定义与实际评测，不能把动物视频或 latent 回归直接算成机器人完成任务。

> **版本与身份**
>
> 主 README 的会议年份文字不可单独作书目依据，身份由标题 / 作者 / 项目互连确认；LP 文案的 40 点 / 4 秒和命令的 num_pose_prediction=120/fps/pps 需依实际 pose_skip 映射，不能只抄旗标数字。

领域	宠物照护与动物活动
环境	VIP/LP 是动物第一人称视频；VPP 另用四足机器人在 office/park/beach 的录制与日夜 / 地面移转。视频来源、robot episode 与实体地点分层。
任务	VIP 判断是否交互与 17 种交互对象；LP 预测尺度模糊的未来相对轨迹；VPP 从图像预测 proprioception-derived latent，在 -1.5、-.8、0、.8、1.5 秒条件分项比较。
题数与数据	VIP CSV 含 animal、ds_type、video_id、segment_id、start/end_time、interacting_object、video_path；LP 另存 DPVO stride 和 TUM trajectory。LP loader 用 training_set/validation_set、cat/dog、有效文件过滤，test 最长截到 50 秒；sample index 不等于完整来源总量。
评估方式	VIP interaction 使用 sigmoid/accuracy/BinaryAUROC；object top-1/top-3 与 macro AUROC 仅在 GT 有交互样本算。LP 以方向范式增量预测，重建时乘回 GT 增量尺度，再用 evo align=True/correct_scale=True 的 ATE/RPE RMSE；不是无尺度辅助的导航成功率。VPP validation 用 MSE，loader 设 drop_last=True，分布式补齐可能重复样本；百分比形式打印的 loss 不表示 accuracy。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **6,646** 动物视频片段 · 原文页 4
- **695** VIP test片段 · 原文页 6
- **249** LP validation片段 · 原文页 7

- **3** VPP机器人测试地点 · 原文页 7

依这个顺序读

1. README.md ↗
   GitHub · DannyTran123/egopet · 478d62327e

   数据与预训练 / 三项任务角色

   L1–78

---

2. VIP.md ↗
   GitHub · DannyTran123/egopet · 478d62327e

   交互标签、CSV 与对象类别

   L1–91

---

3. LP.md ↗
   GitHub · DannyTran123/egopet · 478d62327e

   未来轨迹定义与子集

   L1–91

---

4. VPP.md ↗
   GitHub · DannyTran123/egopet · 478d62327e

   四足机器人来源与 horizon

   L1–56

---

5. locomotion_prediction/locomotion_prediction_dataloader.py ↗
   GitHub · DannyTran123/egopet · 478d62327e

   有效样本与时间截断

   L47–53 · L59–68 · L100–106 · L119–148 · L156–167 · L172–178 · L186–192 · L208–217 · L221–228 · L230–236

---

6. engine_object_interaction_for_finetuning.py ↗
   GitHub · DannyTran123/egopet · 478d62327e

   GT-positive 条件与分类指针

   L13–21 · L150–158 · L206–234 · L241–264 · L294–302

---

7. `engine_locomotion_prediction_for_finetuning.py` ↗
   GitHub · DannyTran123/egopet · 478d62327e

   逐片段评分和略过错误

   L1–32 · L149–157 · L181–193 · L195–204

---

8. `locomotion_prediction/locomotion_prediction_utils.py` ↗
   GitHub · DannyTran123/egopet · 478d62327e

   GT scale、对齐与 ATE/RPE

   L1–5 · L20–28 · L46–74 · L80–91 · L103–130 · L162–172 · L174–183 · L188–201

---

9. `eval_adaptation_ds.py` ↗
   GitHub · DannyTran123/egopet · 478d62327e

   robot latent 评测入口

   L1–40 · L130–136 · L186–192 · L280–288 · L295–301 · L315–326 · L330–341 · L376–382 · L399–441

---

10. `engine_for_finetuning.py` ↗
    GitHub · DannyTran123/egopet · 478d62327e

    VPP MSE、drop_last 与分布式条件

    L137–151 · L159–202 · L337–351

怎么接入我们的benchmark

可重用

三项原生 task、CSV、轨迹处理与 VIP/LP/VPP 评分流程。

需要转换

animal source 与 robot transfer source 分开并连 pretraining 关系；case 保留 horizon、fps/pps、DPVO stride、方向 / 尺度、有效样本、GT scale 使用范围与 episode split。分类、轨迹 RMSE、latent MSE 保持分项。

仍需补齐

尚未取得视频、DPVO 轨迹、CMS robot 数据或运行。LP 例外只印出后略过，需保存实际评分 / 失败清单；VPP 须额外取得 latent 生成版本，不能宣称提升实体走路成功。

P026 · EgoHOS

Fine-Grained Egocentric Hand-Object Segmentation: Dataset, Model, and Applications

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoHOS 是细粒度手对象分割，第一 / 第二阶交互关系和 contact mask 有明确定义。已核读原生类别、数据配置与实际 MMSegmentation 评分路径。

> **版本与身份**
>
> 此仓库内含 MMSegmentation，已钉选其本地版本；不能换成最新版同名套件而不记录差异。README 中 LaMa / FGVC / homan 等是应用依赖，不是额外 EgoHOS benchmark 来源。

领域	居家整理与清洁、餐饮与烹饪
环境	真实第一人称图像；来源内明列 train/val/test_indomain/test_outdomain。这里 domain 指来源分布测试条件，不直接等于生活用途领域数。
任务	左右手、由左 / 右 / 双手交互的第一阶 / 第二阶对象，以及 dense contact。9 个 label IDs 含背景，是像素类别，不能当 9 个操作任务或对象身份。
题数与数据	文件夹 image/label/contact，EgoHOSDataset 读 .jpg 和 .png，classes/palette 固定 0–8。handobj2 config 保留背景（reduce_zero_label=False）、padding ignore=255；test 预设 test_indomain，crop/resize 360×480。
评估方式	CustomDataset 预设 mIoU；metrics.py 先套 label map / ignore_index，再累加逐类 intersection、pred、GT、union，算 IoU/Acc，summary 以 nanmean。还支持 Dice/Fscore，但不能由支持函数推定原论文都采用。contact 二值 mask 需用其独立配置，不与 9-class 平均混算。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **11,243** 分割标注图像 · 原文页 1, 5, 6
- **500** OOD test图像 · 原文页 2, 9

依这个顺序读

1. README.md ↗
   GitHub · owenzlz/EgoHOS · cd9bdf427e

   身份、label schema、四个 split 与模型流程

   L1–111 · L152–200

---

2. mmsegmentation/mmseg/datasets/egohos.py ↗
   GitHub · owenzlz/EgoHOS · cd9bdf427e

   实际类别 / palette 与扩展名

   L1–34

---

3. mmsegmentation/configs/_base_/datasets/egohos_handobj2.py ↗
   GitHub · owenzlz/EgoHOS · cd9bdf427e

   背景、ignore 与 split 配置

   L1–59

---

4. mmsegmentation/mmseg/datasets/custom.py ↗
   GitHub · owenzlz/EgoHOS · cd9bdf427e

   实际 mIoU 调用与 nanmean 聚合

   L85–93 · L384–392 · L419–427 · L439–447

---

5. mmsegmentation/mmseg/core/evaluation/metrics.py ↗
   GitHub · owenzlz/EgoHOS · cd9bdf427e

   像素计数与 IoU/Dice/F 定义

   L55–103 · L348–395

怎么接入我们的benchmark

可重用

原生 label/palette、contact 与 split、实际 dataset→metrics 调用。

需要转换

case 保留来源图像 / split / raw label mask、接触关系与第一 / 第二阶；像素座标、resize、ignore=255、背景纳入和 nan 规则都进 evaluator profile。手对象分割与物理接触 / 抓取成功不同。

仍需补齐

尚未下载图像、mask、checkpoint 或运行。需取得各 head 配置与来源视频 ID 才能避免跨 split 同源视频；contact 与分阶段模型的全部依赖仍须逐配置测试。

P027 · EgoPCA

EgoPCA: A New Framework for Egocentric Hand-Object Interaction Understanding

文件 / 网站 · 主来源 · 原作 · 独立页面

此公开仓库只有README和LICENSE；README链接匹配的ICCV2023论文，并明写程序尚待发布。不能把它标成已核读到数据处理或评测实作。

> **版本与身份**
>
> silicx/EgoPCA固定10364626...的完整tree仅有README与LICENSE；主页程序发布承诺不是已发布证据。
>
> README自述官方并连到匹配的ICCV论文。

领域	居家整理与清洁、餐饮与烹饪
环境	论文描述多个视频来源；公开仓库未提供scene或观测清单。
任务	One4All / EgoPCA的类别与子集需按论文保留；目前无原生清单程序可核。
题数与数据	未见可读的dataset loader、标注结构或split档；只有发布占位文件。
评估方式	原作accuracy与分析指针见论文；公开树未提供evaluator，不能宣称已接通。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **394** pretrain统一类别 · 原文页 5, 14
- **204** test统一类别 · 原文页 5, 14
- **10,000** 最大One4All-T子集 · 原文页 5, 14

依这个顺序读

1. README.md ↗

   GitHub · silicx/EgoPCA · 10364626df

   核对论文身份和程序尚待发布的明示状态。

   L1–5

怎么接入我们的benchmark

可重用

论文身份、原作来源组成、分类 / 子集定义的引用。

需要转换

先收source及paper-defined task/type笔记；待正式manifest和checker取得后再建case。

仍需补齐

公开实作、原始标注 / split / 子集清单与可重现评分。

P028 · EgoSchema

EgoSchema: A Diagnostic Benchmark for Very Long-form Video Language Understanding

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoSchema 官方仓库含数据取得、原 Ego4D 映射和远程提交 wrapper；完整 GT 未公开。已核读提交程序与两笔来源映射样本，未把远程界面当作本机 evaluator。

> **版本与身份**
>
> README 同时有 Kaggle 入口与旧 coming-soon 文句；这次只确认钉选文件与 wrapper，不用旧介绍推定平台状态。Wasabi 签署网址会过期，下载网址不是稳定数据 ID。

领域	居家整理与清洁、餐饮与烹饪、工艺与修缮、农业与园艺
环境	从 Ego4D 截出的第一人称视频；q_uid 对应一个视频片段，uid_to_ego4d.json 另连 video_uid、starting_sec、ending_sec。多片段可能来自同一原视频 / 场景。
任务	零样本长视频五选一 QA。README 的完整 5,031 题与公开答案 500 题是不同口径，500 题为子集，不能加总；这是原作者文件数字，非本次已集成题数。
题数与数据	视频名对 q_uid；提交 JSON 是 question_uid→0–4 整数。已读两笔 parent mapping，其中一例把 q_uid 对到原视频 240–420 秒；只核对字段与例子，不宣称全量映射已人工审查。
评估方式	validate.py 直接 POST JSON 到作者服务，返回 full/subset MCQ accuracy；程序本身没有本机 scoring 逻辑或完整 hidden labels。未送出任何提交，也未验证服务现时可用性。500 题脱机结果不能当完整 benchmark 成绩。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **5,063** 五选一QA · 原文页 14

依这个顺序读

1. `README.md` ↗

   GitHub · egoschema/EgoSchema · 505c787376

   零样本用途、native 题数、public/hidden 与提交格式

   L1–115

---

2. `uid_to_ego4d.json` ↗

   GitHub · egoschema/EgoSchema · 505c787376

   只读两笔 JSON pointer，确认原 Ego4D 与秒制来源

   JSON /001934bb-81bd-4cd8-a574-0472ef3f6678 · JSON /001d2d1b-d2f9-4c39-810e-6e2087ff9d5a

---

3. `validate.py` ↗

   GitHub · egoschema/EgoSchema · 505c787376

   远程发送程序，不是本地评分器

   L1–43

怎么接入我们的benchmark

可重用

原生 q_uid、五选一输出范围、公开 subset 口径及 Ego4D 来源时间映射。

需要转换

case 留 q_uid 与 parent video/time window；split/label_access 明确区分 public-500、完整公开问题与 hidden answers。evaluator 分 local_subset / remote_full，记录像片采样预算、输出解析和提交回执。

仍需补齐

本次未取得全量视频与 questions.json（超过本工作者小型文字取得上限），未运行模型或服务。需全量 schema / ID 唯一性与 public subset 对齐检查后，才计已取得 / 已集成 cases。

P029 · EgoThink

EgoThink: Evaluating First-Person Perspective Thinking Capability of Vision-Language Models

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoThink 是单图像第一人称思考问答。已核读数据样本、推论输出、实际裁判 prompt 选择与分数聚合；程序沿用 FastChat 格式，但原生分数不是其通用 1–10 分。

> **版本与身份**
>
> README 列 VidEgoThink 为另一篇后续工作；不能因同 repo 宣传链接就把其视频题目计入 EgoThink。现行预设裁判为 gpt-4o，原论文使用的模型 / prompt 必须另依对应版本钉选。

领域	居家整理与清洁、餐饮与烹饪、工艺与修缮
环境	来自人类第一人称图像；样本 source_dataset=ego4d，image_path 为本地图片。能力目录不等于生活场域或新实体环境；原视频时间 / 地点需另外补来源映射。
任务	六类能力目录 Activity、Forecast、Localization、Object、Planning、Reasoning，下含 12 份 annotations.json。导航 / 协助题是文字规划问答，未要求机器人运行。
题数与数据	样本含 source_dataset、image_path、question、answer；eval.py 用 image_path[0] 的文件名定位图像，依目录顺序重新给 question_id，输出 question/model_answer/reference_answer JSONL。assistance/navigation token 预算300，其他30，需保留差异。
评估方式	gen_judgment.py 实际采 judges[math] 的 single-math-v2 prompt：只看问题、参考与模型文字、不看图片，给 0/.5/1；common.py 解析 [[rating]]，最多尝试3次，失败=-1。show_result.py 排除 -1 后平均，去重被注解；应额外报有效率和重复题，不能将保留样本平均当全题 accuracy。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **6** 能力类别 · 原文页 5
- **12** 细分题型 · 原文页 5, 14
- **700** 图像QA · 原文页 5
- **595** 母视频 · 原文页 5

依这个顺序读

1. README.md ↗
   GitHub · AdaCheng/EgoThink · fbafe8fe4e

   精确论文身份、能力与流程

   L1–117 · L152–197

---

2. data/Activity/annotations.json ↗
   GitHub · AdaCheng/EgoThink · fbafe8fe4e

   JSON /0 样本字段与 Ego4D parent

   JSON /0

---

3. eval.py ↗
   GitHub · AdaCheng/EgoThink · fbafe8fe4e

   单图像读取、预算与重编 ID

   L1–145

---

4. judge_prompts.jsonl ↗
   GitHub · AdaCheng/EgoThink · fbafe8fe4e

   原生 reference-only 0/.5/1 prompt

   L1–9

---

5. gen_judgment.py ↗
   GitHub · AdaCheng/EgoThink · fbafe8fe4e

   实际选用 single-math-v2

   L19–24 · L29–33 · L71–75 · L112–116 · L142–146 · L168–175 · L178–182 · L184–199 · L201–205 · L212–225 · L234–242 · L276–296 · L310–329 · L341–349 · L352–356

---

6. common.py ↗
   GitHub · AdaCheng/EgoThink · fbafe8fe4e

   rating 解析 / 失败 / 重试

   L129–137 · L152–160 · L173–196 · L343–354

---

7. `show_result.py` ↗

   GitHub · AdaCheng/EgoThink · fbafe8fe4e

   排除 -1、分组平均与未激活去重

   L3–11 · L32–133 · L142–157 · L169–181

怎么接入我们的benchmark

可重用

十二能力题集结构、单图像 QA schema、原参考答案与具体 0/.5/1 裁判流程。

需要转换

case 用 source+能力目录+原始 row/hash 建稳定 ID，保存生成 question_id 映射；记录图片、token budget、reference、judge model/version/prompt、原 judgment、解析重试与缺失。各能力分项，与 physical navigation evaluator 分开。

仍需补齐

未运行模型 / 付费裁判。仅读 Activity 第一笔数据样本，未逐题查图片与标签；需确认各子集来源 video/time、去重与盲测切分。API 模型版本与裁判可靠性需另外验证。

P030 · EgoPlan-Bench

EgoPlan-Bench: Benchmarking Multimodal Large Language Models for Human-Level Planning

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoPlan-Bench 使用 EPIC-100 / Ego4D 的人类视频做下一步四选一；已核读 sample schema、Video-LLaMA 界面与实际比较方式。EgoPlan-IT 是另外的训练数据。

> **版本与身份**
>
> 原 README 包含不同模型的输入设置，必须记录 history segmentation 是否给定。IT 的自动答案与人工核验 Bench split 不能合并宣称同等标注品质。

领域	居家整理与清洁、餐饮与烹饪
环境	来源为既有 EPIC-100 与 Ego4D。video_source/video_id 连原视频，目标与进度是题目上下文，不能把同视频不同目标当新实体环境。
任务	给 task_goal、进度片段与当前观测，选最合理下一步。原文件列 Val 3,355、Test 1,584（隐藏 GT）、IT 50K；额外 164K 通用 instruction 不属测试题数。
题数与数据	sample_id、video_source、video_id、task_goal、choice_a–d、golden_choice_idx、answer、current_observation_frame、task_progress_metadata 的 narration/start/stop_frame。Ego4D 界面只取最近4个 action、每个8 frames，再加当前影格；不足片段以 padding+clip_mask 补齐。
评估方式	界面对四个候选计模型 loss，取 argmin 回传候选文字；eval_multiple_choice.py 将该文字与 sample.answer 完全比较，再算 accuracy。对外 submission 则是 sample_id+label A–D，两种表示需显式映射。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **419** 原作观测scenes · 原文页 5, 7
- **3,269** 表2 task goals · 原文页 7
- **4,939** 评测QA（val+test） · 原文页 5, 7
- **1,584** test QA · 原文页 7

依这个顺序读

1. README.md ↗
   GitHub · ChenYi99/EgoPlan · 1510afc12b

   原生训练 / 评测量、字段与父数据

   L1–176 · L205–263

---

2. src/__init__.py ↗
   GitHub · ChenYi99/EgoPlan · 1510afc12b

   模型界面入口

   L1–11

---

3. src/egoplan_video_llama_interface.py ↗
   GitHub · ChenYi99/EgoPlan · 1510afc12b

   合法视频读取与四选项 loss

   L32–64 · L70–78 · L81–92 · L95–109 · L138–160 · L169–175

---

4. eval_multiple_choice.py ↗
   GitHub · ChenYi99/EgoPlan · 1510afc12b

   实际文字比较及入口变量问题

   L1–78

怎么接入我们的benchmark

可重用

目标 / 进度 / 当前影格与候选 schema、两个父库映射、四选一 loss scoring。

需要转换

source 分 Bench-Val / Bench-Test / IT，case ID 留原 sample_id、video_source、video_id 与 frame 范围；记合法 action 边界信息、最近4片段与采样预算。输出同时保留候选索引 / 原字符串与 choice2loss，未见 label 不补 GT。

仍需补齐

未下载视频 / IT、运行模型或提交。入口引用未定义 subset_name（打印与 predict_choice 调用），需修正为来源分支后验证；短 action 可能让 (end-start)//8=0，需记录例外策略。不能把问答正确率当物理规划成功。

P031 · EgoPlan-Bench2

EgoPlan-Bench2: A Benchmark for Multimodal Large Language Model Planning in Real-World Scenarios

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoPlan-Bench2 比第一版加入明确 domain/scenario 字段并扩充人类生活用途；已核读完整 eval.py，确认其测量仍是视频下一步四选一。

> **版本与身份**
>
> 与 P030 的 EPIC/Ego4D 双父库不同，本版文件只指 Ego4D；题目集合、父视频与候选需核对后才能算净添加量。

领域	居家整理与清洁、餐饮与烹饪、工艺与修缮、零售与购物、实验室操作、个人照护、交通移动与车辆维修、农业与园艺、休闲与运动
环境	Ego4D v1_288p 视频，原文案 4 major domains / 24 scenarios 是生活用途分类，不是 24 个物理 layout。sample_id 的 UUID 前缀连到父视频，另有 task_start_frame。
任务	依整段进度及当前观测推下一动作。四候选与 task_goal 构成题目；CoT / GroundingDINO 是可选方法处理，不能当多一批评测任务。
题数与数据	sample_id、domain、scenario、task_goal、choice_a–d、golden_choice_idx、answer、task_start_frame、current_observation_frame、task_progress_metadata。eval 从 start 到 current 逐 frame 截视频（含末 frame），或用 linspace 抽预设8张给 image model。
评估方式	extract_characters_regex 取回复第一个大写 A–D，空字符串算错，再与 golden_choice_idx 比较累积 accuracy；保存 raw model_response 与 extracted_answer。parser 的部分 prefix 字符串因少逗号被相接，且非严格字边界匹配，需保存此原始版本。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **4** 原生life domains · 原文页 1, 5
- **24** 语义scenario类别 · 原文页 1, 5
- **1,113** 来源视频 · 原文页 1
- **1,321** 四选一QA · 原文页 1

依这个顺序读

1. `README.md` ↗
   GitHub · qiulu66/EgoPlan-Bench2 · 5c75ffff73

   原生用途分类、字段及 CoT 方法范围

   L1–161

---

2. `eval.py` ↗
   GitHub · qiulu66/EgoPlan-Bench2 · 5c75ffff73

   截片、采样、字母解析与 accuracy

   L1–172

怎么接入我们的benchmark

可重用

来源 domain/scenario、完整观测区间、四候选与推论 / 解析 / 分数纪录。

需要转换

沿用父 Ego4D ancestry，添加 source-local domain/scenario 映射；case 留 sample_id/观测范围。image-8frame、video、CoT 分成 evaluator configuration，不把方法条件算成新任务；选项及字符串一致性可在 intake 检查。

仍需补齐

未取得完整 HF 题库 / 视频或运行。需将所有来源 domain/scenario 逐项映射本计划用途，不能只抄 4/24。输出采 append 且每次 count 重设，重跑需 session ID 与去重；已存在的视觉缓存需绑定 source/sampling hash。

P032 · EgoTaskQA

EgoTaskQA: Understanding Human Tasks in Egocentric Videos

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoTaskQA 可用于「从程序标注产生可追溯问题」的流程。已核读 generation 说明、direct/indirect 切分、LEMMA loader，以及实际答案索引 accuracy。

> **版本与身份**
>
> 已核读一种 baseline 的评分路径；其他 HCRN/HGA/PSAC/VisualBERT 的输入及聚合不据此推定完全相同。direct 名称不表示该 split 只含 direct 问题，原程序实际对 all_qas 分配。

领域	居家整理与清洁、餐饮与烹饪、社交与沟通
环境	沿用 LEMMA 人类活动视频与世界状态标注；interval 里的 video_name/fpv/start/end 是观测区间，不是新的场景资产。
任务	world state+template/program 产生 query/localize/counterfactual 等问答，再作答案分布平衡。reasoning_type 可重复附在同一题上，各类分母不互斥。能生成更多问句不等于增加同样数量的程序或环境。
题数与数据	raw parsed.json 与 templates 产出 direct/indirect/merged/balanced QA；maskX 表示对象屏蔽数。baseline 的 tagged QA 有 interval、question、answer_encode、reasoning_type、各词 / 字编码；vid_intervals 对 feature video_id，HDF5 预设取20 frames。interval=[start,end)，图像文件名为1-based，feature indices 为0-based。
评估方式	所核读 LSTM baseline 对 logits argmax 与 answer_encode 完全比较，validate 先算各 batch accuracy 再平均；另依多个 reasoning tags 计 true/total。test loader shuffle=True/drop_last=True，故不是保证所有 test 题都进分母。direct split 依答案平衡比例 3:1:1；indirect 将 direct 题与特定 query/iterate_until 程序留 train，其余 indirect 一分为二。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **4** QA reasoning types · 原文页 1, 6
- **40,000** balanced QA · 原文页 4
- **368,000** 生成候选QA（非正式题库） · 原文页 4

依这个顺序读

1. `README.md` ↗

   GitHub · Buzz-Beater/EgoTaskQA · 807a34d77d

   精确论文身份与生成 / 实验入口

   L1–50

---

2. `generation/README.md` ↗

   GitHub · Buzz-Beater/EgoTaskQA · 807a34d77d

   世界状态、program、模板与平衡

   L1–45

---

3. `baselines/README.md` ↗

   GitHub · Buzz-Beater/EgoTaskQA · 807a34d77d

   数据 / feature / vocab 格式

   L1–86 · L120–161

---

4. `baselines/preprocess/split.py` ↗

   GitHub · Buzz-Beater/EgoTaskQA · 807a34d77d

   direct/indirect 实际切分逻辑

   L7–20 · L22–30 · L33–54 · L57–110

---

5. `baselines/dataset/dataset.py` ↗

   GitHub · Buzz-Beater/EgoTaskQA · 807a34d77d

   frame 基数与 HDF5 读取

   L1–120

---

6. `baselines/train_pure_lstm.py` ↗

   GitHub · Buzz-Beater/EgoTaskQA · 807a34d77d

   具体答案分类、batch 平均与 test 采样

   L13–21 · L93–105 · L122–131 · L142–185 · L189–205 · L216–227 · L230–255 · L264–281

---

7. `baselines/utils/utils.py` ↗

   GitHub · Buzz-Beater/EgoTaskQA · 807a34d77d

   多标记 reasoning accuracy

   L1–41

怎么接入我们的benchmark

可重用

可追溯 world state / program / template、答案分布平衡、direct/indirect split 与原生 QA schema。

需要转换

task/规则保留 program 和生成版本；case 保留父视频+fpv+半开 frame 区间、maskX、template、answer vocabulary/hash。题数按唯一 QA ID 计，视频 / 模板 / reasoning tags 另算；原 split 按问题分，不自动宣称 video-disjoint。

仍需补齐

尚未取得世界状态 / 视频 / 特征或运行生成与评分。需确认稳定 ID、完整 split 档及字段，而非重跑未固定 seed 的 split.py；评估 all-cases adapter 与原 drop_last 结果需各自标版本。

P033 · EgoLife

EgoLife: Towards Egocentric Life Assistant

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoLife、EgoIT、EgoGPT、EgoRAG 是数据 / 训练集 / 模型 / 方法的不同角色。已核读 EgoRAG 的 QA schema、记忆查找、证据与精确选项评分。

> **版本与身份**
>
> 主 README 中早期 arXiv-on-hold 等消息仍保留，身份以实际论文标题 / arXiv ID 为准。EgoGPT 文件对其他 EgoSchema/EgoPlan/EgoThink 的结果是外部测试，不算 EgoLife 原生题目。

领域	居家整理与清洁、餐饮与烹饪、休闲与运动、社交与沟通
环境	六位参与者一周的真实生活观测，包含 Aria、外部相机与 mmWave；本次内核程序处理人物/日期/视频的记忆串行，不代表所有传感 modality 都已进入每道题。
任务	长期记忆、人物 / 事件 / 习惯等 QA，以 query_time 和过去证据答四选一。EgoIT-99K 是九个既有 ego 数据的 instruction tuning 混合，不是添加 99K EgoLife 测试题。
题数与数据	QA 有 ID、query_time 的 DAY/time 字符串、type、need_audio/need_name、question、choice_a–d、answer、target_time、keywords、reason。caption DB 以 date/start/end/video_path/text 建记忆片段；parse_query 实际使用 keywords。时间为来源自订8位编码，需保留原字符串再创建经核验的时间换算。
评估方式	calculate_accuracy 只对已进 answers 的 model_option 与 metadata.answer strip 后精确比较；query_all/main 遇例外 continue，故漏题可能不进分母。get_answer 遇 API 字符串 error 会随机选 A–D；须另列失败 fallback。主入口 extract_evidence 实际 modality=text，EgoGPT 是可换的 caption/视觉模型，不能把此设置报成每题直接看视频。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **1** EgoHouse · 原文页 3
- **5** QA types · 原文页 5
- **3,000** 正式QA · 原文页 3, 5
- **500** 本文快速实验实评QA · 原文页 7

- **266** 保留视频小时 · 原文页 3

依这个顺序读

1. `README.md` ↗
   GitHub · EvolvingLMMs-Lab/EgoLife · 7a97157908

   EgoLife / EgoGPT / EgoRAG 的角色

   L1–87

---

2. `EgoGPT/README.md` ↗
   GitHub · EvolvingLMMs-Lab/EgoLife · 7a97157908

   EgoIT 混合训练与外部 lmms-eval

   L1–62 · L95–146

---

3. `EgoRAG/README.md` ↗
   GitHub · EvolvingLMMs-Lab/EgoLife · 7a97157908

   QA 与 caption DB schema

   L1–195

---

4. `EgoRAG/main.py` ↗
   GitHub · EvolvingLMMs-Lab/EgoLife · 7a97157908

   实际 query/answer/text-evidence 流程

   L1–9 · L15–21 · L33–41 · L67–112 · L115–170 · L173–183 · L218–242 · L247–256

---

5. `EgoRAG/egorag/agents/RagAgent.py` ↗
   GitHub · EvolvingLMMs-Lab/EgoLife · 7a97157908

   cutoff、keywords、证据、失败回退及分母

   L1–117 · L125–134 · L143–157 · L159–178 · L193–199 · L203–212 · L217–223 · L227–235 · L239–245 · L257–269 · L277–372 · L380–447 · L449–481 · L483–518 · L520–543 · L549–615 · L619–625 · L627–665

怎么接入我们的benchmark

可重用

人物 / 日期 / query time、题目与证据 schema、记忆数据库与四选一评分。

需要转换

case 保留本人、query timestamp、合法 past cutoff、是否提供 keywords，以及 target_time/reason 的 GT 身份。cache/DB 对应 caption model/version、视频范围与读取记录；完整预定题清单与已答题清单并列，漏题、随机回退、解析失败分开。

仍需补齐

尚未下载完整一周视频、EgoIT、创建 DB 或调用模型。需核验每层摘要 / retrieval/filter 的时间截止与 evidence 完整性，并固定 keyword 可用条件；不同人物和同时摄影不能直接计成独立环境。

P034 · EgoVLP

Egocentric Video-Language Pretraining

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoVLP 同时提供 EgoClip 预训练与 EgoMCQ 开发评测；本次核读 EgoMCQ 格式、chunk loader 和实际 accuracy。其他 Ego4D / EPIC / Charades 评测保留父来源。

> **版本与身份**
>
> EgoMCQ 被用来选预训练 checkpoint，应标 development set，不自动当独立最后测试。EgoVLPv2 为后续方法，新闻链接不代表本 repo 已包含其添加结果与全部程序。

领域	居家整理与清洁、工艺与修缮
环境	视频来自 Ego4D；600 秒 chunk 是保存切块，不是物理环境。intra/inter-video 指候选来自同 / 异视频的难度条件，不等于生活用途。
任务	EgoMCQ 给文字查找，从五个视频候选找正解；与从视频选文字答案的 QA 方向不同。EgoClip 数百万 narration clips 是训练单位，不能当 EgoMCQ 测试题或新动作任务。
题数与数据	EgoClip TSV 含 clip_idx/video_uid/narration_source/narration_ind/narration_time/clip_start/end/clip_text/tag_verb/tag_noun；MCQ JSON 有 query/choices/answer/types。loader 依 clip 秒数取可能跨两个600秒文件的 frames，返回 video/text/text_ops/correct/type。val 与 test 都读同一 egomcq.json。
评估方式	egomcq_accuracy_metrics 在各 type 内 argmax 对 label 算 accuracy。重要不一致：loader 注解写 1=inter、2=intra，但 metric 将排序后 type 配给 Intra-video、Inter-video；需对原 JSON 定义后判断，不能直接抄标题。eval config 4frames/224px/loading=lax，失败会以黑图补，应另计数据读取失败。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **39,000** EgoMCQ development questions（约数） · 原文页 6
- **3,850,000** EgoClip narrations（约数） · 原文页 3
- **129** source scenario labels · 原文页 3

依这个顺序读

1. `README.md` ↗
   GitHub · showlab/EgoVLP · 928406c2d5

   EgoClip / EgoMCQ 与父 benchmark 角色

   L1–99 · L124–201

---

2. `configs/eval/egomcq.json` ↗
   GitHub · showlab/EgoVLP · 928406c2d5

   开发评测输入配置

   L1–78

---

3. `data_loader/EgoClip_EgoMCQ_dataset.py` ↗
   GitHub · showlab/EgoVLP · 928406c2d5

   chunk 跨界、原生 MCQ 格式与黑图回退

   L13–95 · L128–183

---

4. `model/metric.py` ↗
   GitHub · showlab/EgoVLP · 928406c2d5

   实际 type 分组与 accuracy

   L208–241 · L341–361

怎么接入我们的benchmark

可重用

原生五候选 query/choice metadata、来源切块映射、pretraining 与 development 分界。

需要转换

case 保留 EgoMCQ ID、候选顺序及各父 video/time；source 分 EgoClip/EgoMCQ/下游父 benchmark，tag 字典作原生训练词汇。evaluator 保存 type 数值与已核定名称、4frame 预算、缺档回退，不能把同 JSON 的 val/test 加成两套题。

仍需补齐

尚未取得 egoclip/egomcq 全量 metadata、视频或运行。需解决 type 名称矛盾、有效样本清单与跨来源视频去重；下游 NLQ/MQ/PNR/OSCC 完整 adapters 仍另按父协定验证。

P035 · EgoVLPv2

EgoVLPv2: Egocentric Video-Language Pre-training with Fusion in the Backbone

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

EgoVLPv2 是跨模态预训练方法与既有 benchmark 的适配实作，保持 related_reference 身份；没有把其下载特征和下游结果当作新环境或新题库。

> **版本与身份**
>
> root README 指明基于 EgoVLP 的特定提交，不能与 P034 的当前固定快照视为完全相同程序。EgoTaskQA 的数据仍属 P032/LEMMA 衍生范围。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	沿用 EgoClip/Ego4D、EPIC-100、Charades-Ego、EgoTaskQA、QFVS 等父来源；此方法不独立定义一组新生活场景。
任务	预训练与 video-text fusion，于 EgoMCQ、retrieval、动作、NLQ/MQ、QA / summarization 进行迁移。任务清单引用原 benchmark，模型比较本身不增加 canonical tasks。
题数与数据	EgoTaskQA 子目录明确沿原作者预处理，formatted_*_qas_encode.json 的 interval 加 .mp4 定位加工视频，question/answer_encode 和 reasoning_type 保留；tokenizer 以30 token 为上限截断，frame 预算由配置定义。NLQ 保留 clip_uid/annotation_uid/query_idx/predicted_times。
评估方式	核读 NLQ 原生时间 overlap/top-K 阈值 recall，分母为传入预测且只列 evaluated/GT。QA validate 在分布式 allgather 后 argmax 对 answer 索引，另计 reasoning tag 正确率；直接 all_acc 公式写成 correct/B*world_size，需检查分母与 tag 报表的一致性，不直接采用此摘要作新结果。

依这个顺序读

1. `README.md` ↗
   GitHub · facebookresearch/EgoVLPv2 · 550c0596b8

   方法身份、来源与子目录角色

   L1–73

---

2. `EgoTaskQA/README.md` ↗
   GitHub · facebookresearch/EgoVLPv2 · 550c0596b8

   原 EgoTaskQA 数据与 direct/indirect 协定

   L1–43

---

3. `EgoTaskQA/EgoTaskQA_dataset.py` ↗
   GitHub · facebookresearch/EgoVLPv2 · 550c0596b8

   加工视频、question/answer 与输入截断

   L14–103

---

4. `EgoTaskQA/main_end2end.py` ↗
   GitHub · facebookresearch/EgoVLPv2 · 550c0596b8

   分布式评分、tag 报表与模型选取路径

   L100–106 · L111–117 · L122–128 · L184–202 · L218–224 · L227–233 · L246–254 · L258–277 · L310–318 · L349–360 · L364–370 · L383–406

---

5. `EgoNLQ/utils/evaluate_ego4d_nlq.py` ↗
   GitHub · facebookresearch/EgoVLPv2 · 550c0596b8

   NLQ 时窗、阈值与分母

   L13–117

怎么接入我们的benchmark

可重用

父 benchmark adapters、固定特征 / 模型版本、EgoTaskQA 的原生 ID 和 NLQ evaluator。

需要转换

用 method→evaluated_on/source 与 derived_feature 边连父数据，不新建一份重复环境 / 任务数。case 在原 benchmark namespace 下保存，另记模型、16frame/224px、30token、分布式采样与 adapter 提交版本。

仍需补齐

未下载权重 / features 或运行。需核验 DistributedSampler padding 的去重、QA pooled 分母及 checkpoint 选择 split；本次读 EgoTaskQA/NLQ 内核，不能代替其他下游完整 adapter 审核。

P036 · EgoT2

Egocentric Video Task Translation

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

EgoT2 将七个 Ego4D 任务互相迁移，属方法参考；已核读数据源与 OSCC/PNR 的实际输入和评分，并辨识 eval_lta.py 的名字与当前输出不同。

> **版本与身份**
>
> 论文表的 ED@20、repo 某个 eval_lta.py 及 challenge submission 属不同路径，须固定可重现入口后比较。父数据版本仍依 Ego4D 原来源，related_reference 不加到183份 benchmark/data 来源量。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	共用 Ego4D 视频，分人与人交互 HHI、人与物 HOI。任务融合不等于跨数据集添加七套环境。
任务	LAM、TTM、ASD、PNR、OSCC、AR、LTA；各有原生条件。faces localized/tracked 是 HHI 的前置输入，PNR/OSCC 用状态变化片段，LTA 与 AR 共用 verb/noun vocabulary。
题数与数据	docs 分别连官方 social-interactions 的 lam/ttm 分支、ASD、hands-and-objects、forecasting。HOI batch 含 orig 的 frames/labels/state_change/fps/info，另有 recognition 或 pnr 辅助视觉输入。提交以 unique_id+state_change bool 或 clip-relative pnr_frame 识别。
评估方式	OSCC 逐例 argmax 后全样本正确率；PNR 仅 GT 有变化时计16-bin到frame的距离，再除各自 fps成秒。eval_pnr.py 平均 batch 平均，无正例预设0需保留。通用输出 metric 在合法 token 子集再取 argmax，另列 out-of-task token 比率。当前 eval_lta.py 只评 forecast_labels 第一动作的 verb/noun accuracy，不是 README 的 ED@20。

依这个顺序读

1. `README.md` ↗
   GitHub · facebookresearch/EgoT2 · 1e261806ca

   七项原生任务、方法及报告指针

   L1–87 · L158–229

2. `docs/PREPARE_HOI.md` ↗
   GitHub · facebookresearch/EgoT2 · 1e261806ca

   HOI 父数据与片段

   L1–48

3. `docs/PREPARE_HHI.md` ↗
   GitHub · facebookresearch/EgoT2 · 1e261806ca

   HHI 分支与原作者依赖

   L1–53

4. `HOI/submission/eval_oscc.py` ↗
   GitHub · facebookresearch/EgoT2 · 1e261806ca

   auxiliary input、bool 提交与 accuracy

   L1–89

5. `HOI/submission/eval_pnr.py` ↗
   GitHub · facebookresearch/EgoT2 · 1e261806ca

   PNR 相对 frame 与 batch 聚合

   L1–95

6. `HOI/evaluation/pnr/metrics.py` ↗
   GitHub · facebookresearch/EgoT2 · 1e261806ca

   有效样本、秒误差、token 错误与重复计数

   L1–257

7. `HOI/submission/eval_lta.py` ↗
   GitHub · facebookresearch/EgoT2 · 1e261806ca

   实际只计第一预测动作的 accuracy

   L19–61

怎么接入我们的benchmark

可重用

七项父任务关系、auxiliary inputs、输出 token 子集与 OSCC/PNR adapters。

需要转换

保持 source=P013 的 benchmark/case 身份，另记 translation method、可用辅助模型与输入。evaluator 对 PNR 秒误差、OSCC accuracy、LTA ED 各自留协定，不能依文件名将第一动作 accuracy 改叫长期 ED。

仍需补齐

未运行训练 / 推论。完整 HHI mAP 和 LTA ED 提交流程仍需追核；PNR/OSCC 通用 metric 的重复 unique_id 只打印、continue 被注解，需全量去重与分母检查。不得由融合模型结果估算新的任务数。

P037 · EgoEnv

EgoEnv: Human-centric environment representations from egocentric video

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoEnv 同时有 HM3D 模拟 walkthrough 与真实视频理解用途；已核读 episode/scene ID、四方位状态标注与具体评测，不能把128维特征当任务。

> **版本与身份**
>
> 文件钉选 Habitat-sim0.2.2 与 Habitat-lab 特定提交；同样 HM3D 名称不等于其他 benchmark 的相同 split/episode。程序库书目年份文字需仍以论文来源核对，不据README单行覆写主书目。

领域	居家整理与清洁
环境	模拟 scene_id 属 HM3D，episode_id 是初态与访问目标形成的导航历程。下游另用 HouseTours / Ego4D 真实视频；RoomPred instance 可区分同类多房间，属来源内 metadata，不是全球唯一环境 ID。
任务	局部对象存在 / 距离与相对 pose 学习，迁移到 RoomPred/NLQ。四方位、23 object classes、512 timestep 是张量轴；不代表 4×23×512 个独立任务。
题数与数据	episode_list.pth 连 state/{type}/{scene_id}_{episode_id}.pth；labels/dists 为 T×4×object，distance=-1 表示未出现。val walkthrough 均匀预选4 query，train 随机 query / memory window。下游特征每秒一笔 T×128；HouseTours 原 YouTube clip 与 Ego4D video/clip/time 必须保留父来源。
评估方式	CardinalObjectStateTask 在每方向对多对象算 average_precision_score，再平均方向；distance argmax accuracy 仅 dists!=-1 的位置。训练 BCE+masked CE 是 loss，不是实体导航成功；RoomPred/NLQ 的完整下游 metrics 不由这个 local-state evaluator 取代。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **900** HM3D pretraining scenes · 原文页 7
- **886** 选用HouseTours houses · 原文页 7
- **2** environment understanding endpoints · 原文页 6
- **146** MP3D video walkthroughs · 原文页 7

依这个顺序读

1. README.md ↗
   GitHub · facebookresearch/ego-env · 6f06c5888b

   模拟生成、版本、metadata 与下游角色

   L1–92 · L104–145

---

2. DATASETS.md ↗
   GitHub · facebookresearch/ego-env · 6f06c5888b

   HouseTours/Ego4D 来源、时间与 room instance

   L1–48

---

3. state_prediction/data/dataset.py ↗
   GitHub · facebookresearch/ego-env · 6f06c5888b

   scene/episode、query 抽样与 label mask

   L16–24 · L28–34 · L46–58 · L64–94 · L97–103 · L108–114 · L117–131 · L137–149 · L178–184 · L196–202 · L210–234

---

4. state_prediction/task.py ↗
   GitHub · facebookresearch/ego-env · 6f06c5888b

   方向 AP、距离 accuracy 与训练 loss

   L9–17 · L21–29 · L45–57 · L97–105 · L118–126 · L132–140 · L158–177 · L179–203 · L208–216 · L218–242

怎么接入我们的benchmark

可重用

真实 scene/episode 分离、四方位对象 / 距离 schema、RoomPred 的 room instance 和 AP/masked accuracy。

需要转换

HM3D source→scene→episode→query 建关联，HouseTours/Ego4D 新标注另连 parent video/time；case 留 query/memory indices、可用历史、pose/angle、missing-distance。128维 feature 作加工 artifact，不计为新题。

仍需补齐

尚未取得 HM3D、导航轨迹、真实视频或运行。README 只提供50条 sample metadata，完整训练需生成；需核验 SCENE_SPLITS、room-instance 身份和下游评分，才能报可用环境 / cases。

P038 · OpenEQA

OpenEQA: Embodied Question Answering in the Era of Foundation Models

内核内容已核读 · 主来源 · 原作 · 独立页面

OpenEQA 的 question/answer/history 格式和文字裁判已可具体追溯；本次核读一笔原始 QA、历史取得方式、两种 prompt 与完整评分脚本。

> **版本与身份**
>
> data README prose 写 simulator2.5，但实际安装命令是 habitat-sim0.2.5；以明确套件版本和历史版本为准。RGB直接下载被作者标为第三方hosting，官方来源身份与实际分发者需分栏。

领域	居家整理与清洁、办公与教育
环境	episode histories 来自 HM3D 与 ScanNet；HM3D 用 Habitat 重播 agent states，ScanNet 从原扫描数据抽取。episode_history 路径连回 scene/source；RGB、depth、pose 是同历史不同观测，不添加场景。
任务	开放词汇环境问答，可讨论 episodic memory 和 active exploration；此核读 evaluator 判文字答案，没有证明某 agent 已完成探索或操作。
题数与数据	open-eqa-v0.json 例含 question_id、question、answer、category、episode_history，可另有 extra_answers。HM3D 版本为 hm3d-v0/场景路径，数据文件提供 RGB-only 或 RGB-D+intrinsics+pose；原 scan/agent state 与 extraction 版本要随 case 保存。
评估方式	llm_match 预设 gpt-4-1106-preview/seed1234/temperature.2/max_tokens32，以原参考与可选 extra_answers 判1–5；parse Your mark 后整数。evaluate-predictions 先核 ID/数量、截掉最后句点后的尾文、逐题缓存，再将clip(score,1,5)线性映成0–100平均。prediction=None 回0后映为0；force 只对提供的 result 遍历，dry-run 只取前5，均不能报全量分数。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **187** 搜集候选scenes / scans · 原文页 4
- **7** 问答类别 · 原文页 3, 4
- **1,636** EM-EQA题 · 原文页 3, 4
- **557** 重用于A-EQA的题子集 · 原文页 3

依这个顺序读

1. README.md ↗

   GitHub · facebookresearch/open-eqa · cfa3fce459

   原生 Q/A/history 及两种应用情境

   L1–72

---

2. data/README.md ↗

   GitHub · facebookresearch/open-eqa · cfa3fce459

   HM3D/ScanNet、传感与 extraction 版本

   L1–101 · L127–168

---

3. data/open-eqa-v0.json ↗

   GitHub · facebookresearch/open-eqa · cfa3fce459

   JSON /0 原始 QA 范例

   JSON /0

---

4. prompts/mmbench.txt ↗

   GitHub · facebookresearch/open-eqa · cfa3fce459

   1–5文字匹配裁判

   L1–27

---

5. prompts/mmbench-extra.txt ↗

   GitHub · facebookresearch/open-eqa · cfa3fce459

   替代答案裁判

   L1–31

---

6. openeqa/evaluation/llm_match.py ↗

   GitHub · facebookresearch/open-eqa · cfa3fce459

   裁判参数、空回答与解析

   L1–82

---

7. `evaluate-predictions.py` ↗

   GitHub · facebookresearch/open-eqa · cfa3fce459

   ID、force/dry-run、缓存和0–100映射

   L1–122

怎么接入我们的benchmark

可重用

稳定 question_id、scene/history 路径、参考答案与替代答案、原始 judge prompt / 范式。

需要转换

environment 保存父 HM3D/ScanNet scene 和 extraction release；case 绑 question_id/history/modalities/观测 budget。evaluator 固定裁判版本、prompt hash、预处理、cached score 来源；完整数据 / 结果 ID 一对一，force/dry-run 和缺题另标。

仍需补齐

尚未取得 histories、运行 simulator / baseline / 付费裁判。只读 QA /0 schema 范例，未逐题验证全库；若更换模型或 prediction，旧 metrics 缓存需按输入hash区分，并另外验证裁判与人工一致性。

P039 · RoboVQA

RoboVQA: Multimodal Long-Horizon Reasoning for Robotics

内核内容已核读 · 主来源 · 原作 · 独立页面

RoboVQA 公开 GitHub 是数据读取与示范评分 notebook，并非完整实机控制评测平台。已读所有 notebook source cells，包含 SequenceExample schema、任务tag解析和 mock eval。

> **版本与身份**
>
> 公开 notebook 的 mock 范例与论文的真实机器人 / 人工介入实验不同。程序授权与其余数据授权在 README 分开列示，后续来源表应各自保存。

领域	居家整理与清洁、餐饮与烹饪、办公与教育
环境	已核原论文第1页：数据来自3栋办公大楼，含机器人、人、人持抓取工具的多 embodiment。公开 notebook 本身只读 images/texts，未提供可直接重设的场景或 robot dynamics。
任务	长程 / 中程指令与高级 VQA，例如成功、affordance、离散进度及文字推理。<task:...> 是问题 / 标注类型，同一视频可带多个 QA；29,520 unique instructions 与829,502 video-text pairs 是原论文报告的不同单位，不是本次取得或可运行题数。
题数与数据	Google Storage train/val TFRecord 里是 tf.train.SequenceExample，feature_lists 的 images 为 JPEG bytes，texts[0] 为包含多个 task/pred/speaker tags 的UTF-8字符串。Tasks 分成 tag→文字，再用 A: 分离输入 / 答案；随机抽 task 与 split 需保存实际选到的内容。
评估方式	run_eval 只取 validation 第一笔 SequenceExample，对其中 QA 调用 mock_call_model 并示范 sentence_bleu，无全量平均或实机 intervention 统计。程序调用为 sentence_bleu(answer,pred_answer)，需按锁定 SacreBLEU 核对候选 / 参考顺序及类型，不能直接把示范印出的数字当正式 benchmark 成绩。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **3** 办公楼 · 原文页 1, 2
- **2,722** unique长程指令字符串 · 原文页 2
- **26,798** unique中程指令字符串 · 原文页 2
- **5,246** 长程episodes · 原文页 2

- **100** 脱机planning episodes · 原文页 4
- **854** 脱机planning steps · 原文页 4

依这个顺序读

1. `README.md` ↗

   GitHub · google-deepmind/robovqa · 93f183129a

   官方 example-code 身份与精确论文

   L1–45

---

2. `data_loading_and_eval.ipynb` ↗

   GitHub · google-deepmind/robovqa · 93f183129a

   所有 source cells；未运行、不把 notebook outputs 当验证

   L8–22 · L29–46 · L53–55 · L65–88 · L98–375 · L384–389 · L399–403 · L412–428 · L435–437 · L447–452 · L461–492 · L501–503 · L512–514

怎么接入我们的benchmark

可重用

原生多tag语料、TFRecord images/texts schema 与 task/source-target parser。

需要转换

source 记 embodiment / episode / building 若来源metadata可取得；case 用record ID+task tag+该tag内QA序号，frame sequence 只保存一次。raw text/tag 与去tag的prompt/answer同存；VQA字符串评分与实机 intervention evaluator 分别建档。

仍需补齐

尚未下载 TFRecords、运行 notebook 或机器人试验。需要全量 ID/split/embodiment metadata、正式 BLEU 协定与 intervention 原始轨迹；get_splits 的 binary/discrete 路由引用未定义常数，使用时需修正并测试，A:范例不受该路由影响。

P040 · RoboBench

Robobench: A Comprehensive Evaluation Benchmark for Multimodal Large Language Models as Embodied Brain

内核内容已核读 · 主来源 · 原作 · 独立页面

RoboBench 的钉选版本已分 MCQ 与 Planning，并提供原生粒度表。本次核读 loader、MCQ、Q1–Q3 planning 的核心规则，以及 point/IoU 辅助 evaluator；不把模型裁判等同物理运行。

> **版本与身份**
>
> README已是ECCV2026 release，不能无版本注记地替换2025 arXiv表。IoU文件开头提mAP，但实际回传平均IoU / pass rates，没有AP排序积分；点 / IoU工具存在也不代表32 manifest全都使用它们。

领域	居家整理与清洁
环境	图像 / 视频中的机器人或人类操作观测；unique_id 中的 images 路径定位样本。cross-embodiment/object/view/attribute 是泛化条件，5 dimensions 是能力分类，不是5种生活用途。
任务	2026 release README 列5 dimensions、14 groups、25 tasks、32 subtask manifests、6,092 QA，MCQ=1,895、Planning=4,197；这是版本化原作者规模，非本次数据集成实数。Q1 多步计划、Q2 下一步、Q3 状态估计会共用同一来源图像。
题数与数据	system_prompt.json 和 dimension/subtask/questions.json；question 有 unique_id、task_type、image_urls、robotic_type、question/options，转 request_id/prompt。Q1–Q3 suffix 在找图时去除；Q1另读 dag.json 的 id→gt_dag，navigation 无同样 DAG。human 在 prompt 被转成 single-arm，原始 embodiment 不能因此覆写。
评估方式	MCQ 取 answer tag / 清除 think 后比A–D集合，不明确输出可用另设裁判范式。Q1模型看首图、GT nodes/DAG、预测计划，给 node correctness与task completion各0–10后平均映0–100；空 critical-state集合依prompt直接Completion=10。Q2 skill/object/parameter三项平均，前两任一0则parameter=0；Q3 yes/no精确比。Q1/Q2解析失败排除均分但overall按原count加权；point/IoU亦只用有效解析作分母，需附valid率。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **25** 认知评测端点 · 原文页 2, 8
- **6,092** questions · 原文页 8

- **4,336** unique items · 原文页 8

依这个顺序读

1. README.md ↗
   GitHub · yulin-luo/RoboBench · 08314edc65

   2026 release原生粒度、两种设置与程序结构

   L1–94 · L161–225 · L279–330

---

2. src/robobench/data/dataset.py ↗
   GitHub · yulin-luo/RoboBench · 08314edc65

   manifest、request ID、Q suffix与prompt

   L1–149

---

3. src/robobench/evaluation/multi_choice.py ↗
   GitHub · yulin-luo/RoboBench · 08314edc65

   MCQ解析、可选裁判和分母

   L1–130

---

4. src/robobench/evaluation/planning.py ↗
   GitHub · yulin-luo/RoboBench · 08314edc65

   Q1 prompt、DAG、Q2/Q3与聚合

   L26–104 · L244–270 · L305–321 · L372–415 · L595–631 · L713–774

---

5. src/robobench/evaluation/point.py ↗
   GitHub · yulin-luo/RoboBench · 08314edc65

   点距离与valid-only分母

   L1–105

---

6. src/robobench/evaluation/iou.py ↗
   GitHub · yulin-luo/RoboBench · 08314edc65

   bbox IoU、门槛通过率与invalid处理

   L1–123

怎么接入我们的benchmark

可重用

原生32 manifest层级、题目/skill/DAG/prompt格式与逐项判分证据。

需要转换

source 固定 release+commit，task 保留原25/32映射，不把 Q1/Q2/Q3 或新视角当新环境；case 保留 raw_question/来源图/embodiment/DAG及观测预算。evaluator 分MCQ、Q1/Q2/Q3和point/IoU等可选工具，native分数、parse_failures与分母同存。

仍需补齐

未取得完整HF数据 / DAG或运行模型裁判。需查 empty-goal cases、裁判一致性、skill语义与可用资产；MLLM imagined rollout 不能宣称物理稳定性 / 真实任务成功。trajectory evaluator 未在本次核读范围。

P041 · EgoCross

EgoCross: Benchmarking Multimodal Large Language Models for Cross-Domain Egocentric Video Question Answering

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoCross 的原作者工具库另指官方 EgoCrossCodes；已补钉选两者，核对开 / 闭集评分和官方testbed。两份内核eval文件的SHA256相同，README / 数据发布内容则不同。

> **版本与身份**
>
> 官方固定README说2026-05挑战结束后发布answers，故不再把它写成永久隐藏GT；本次仅取得questions-only metadata。官方脚本与原作者文件相同不表示两个repository或957题可重复计数。

领域	工艺与修缮、医疗与手术支持、休闲与运动、宠物照护与动物活动
环境	官方957题testbed JSON实际含CholecTrack20、ENIGMA、EgoPet、EgoSurgery、ExtrameSportFPV五个原生dataset标记。这是父数据源，不是5个实体环境；primary_category/question_type另为能力分类。
任务	闭集四选一与开集文字问答，保留多种活动 / 视角来源。官方文件区分source-limited/open-source challenge条件；不从benchmark名称推定统一robot action space。
题数与数据	实际解析questions-only档有957列、957唯一id，0列含correct_option_letter，0列含question_id；字段包括dataset、primary_category、question_type、question_text、options、original_video_fps、video_path列表。官方README说另可取得957题answers档，添加correct_option_letter/answer_text/detailed_answer及global question_id，未在本次取得。
评估方式	闭集从JSON prediction解析并小写后完全比correct_option_letter，模型例外记success=False。开集先以参考字符串 / 数字子字符串包含规则直接给5，否则文字裁判给0–5，score>=4才算success再平均；不是单纯平均0–5分。来源通常.5fps，部分手术影格条件为1fps，original_video_fps和实际观测采样不同。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **4** 原作domains · 原文页 3, 4
- **15** 细分QA类型 · 原文页 3, 4

- **957** QA · 原文页 4
- **798** clips · 原文页 4

依这个顺序读

1. README.md ↗
   GitHub · MyUniverse0726/EgoCross · f81f41d29d

   原作者工具与官方challenge repo互连

   L1–79

---

2. eval_os_closedset.py ↗
   GitHub · MyUniverse0726/EgoCross · f81f41d29d

   读取、采样、JSON解析、失败记录

   L60–66 · L111–117 · L191–197 · L350–501 · L503–524

---

3. eval_gpt_openset.py ↗
   GitHub · MyUniverse0726/EgoCross · f81f41d29d

   开集shortcut与0–5裁判

   L12–18 · L22–58 · L68–78 · L80–117 · L127–137 · L139–145 · L166–172 · L186–202 · L215–221 · L228–237 · L243–249 · L253–260 · L268–280

---

4. README.md ↗
   GitHub · EgoCross-Benchmark/EgoCrossCodes · 6737720c12

   957题questions/answers版本及取得方式

   L1–92

---

5. datasets/egocross_testbed_imgs.json ↗
   GitHub · EgoCross-Benchmark/EgoCrossCodes · 6737720c12

   JSON /0逐项阅读；另对全档做row/ID/字段数量统计

   JSON /0

---

6. `eval_os_closedset.py` ↗

   GitHub · EgoCross-Benchmark/EgoCrossCodes · 6737720c12

   确认官方闭集内核与必要字段

   L322–377 · L403–424 · L482–508

---

7. `eval_gpt_openset.py` ↗

   GitHub · EgoCross-Benchmark/EgoCrossCodes · 6737720c12

   确认官方开集内核与>=4成功阈值

   L25–35 · L83–139 · L230–246 · L270–280

怎么接入我们的benchmark

可重用

957题唯读metadata、来源标记、原题与四选项、原作者 / 官方core evaluators和答案发布说明。

需要转换

source保留原作者repo与challenge repo roles；case以官方id加source version，answers档以id一对一join，global question_id未取得则不杜撰。video_path串行保存原fps/采样率和父视频映射；closed exact-match、open substring shortcut / judge / >=4规则各自版本化。

仍需补齐

尚未取得影格与需另取得的answers档，也未运行 / 提交。questions-only不具eval脚本必需的answer和question_id字段，不能直接以README早期命令宣称能评分。开集substring捷径需保留原作口径并另分析误判；裁判/API程序仍有外部依赖。

P042 · RoboSpatial

RoboSpatial: Teaching Spatial Understanding to 2D and 3D Vision-Language Models for Robotics

内核内容已核读 · 主来源 · 原作 · 独立页面

RoboSpatial 必须分生成工具NVlabs/RoboSpatial与benchmark评测RoboSpatial-Eval；两个repo互相链接，身份已确认。已核读范例loader、生成入口与新版Context评分。

> **版本与身份**
>
> 固定Eval README要求5/13以前fork更新Context逻辑，属2026 challenge版本。应和CVPR2025原论文结果分版本比较；预测点数由1改2也会改变成功机会。已读生成派发，未宣称完整spatial_analysis几何算法逐行审完。

领域	居家整理与清洁、办公与教育
环境	生成工具沿用EmbodiedScan整理的ScanNet/3RScan/Matterport3D/ARKitScenes等扫描；dataset/scene_name/image_name分层。RoboSpatial-Home是另外发布的评测集合，不能与生成数据总量直接相加。
任务	grounding、context（空间指点）、configuration（关系）、compatibility（能否容纳）；Home评测用后三类。BOP/GraspNet统一loader在固定README仍为待办，不能报已支持全部资产。
题数与数据	ExampleLoader要求dataset/scene_name/image_name/objects/camera_annotations，含intrinsic/extrinsic、Name与bbox_3d[0]的9DOF；重复类别生成局部chair_0等名称。generator按unique/all-visible pair模式、grid/threshold/buffer/sample数产生unary/pairwise与grounding JSON。Home例字段img/category/question/answer，Context另需mask。
评估方式	新版Context解析最多前2点（可设1），范式xy乘width-1/height-1、round后clamp，任一点落非零mask像素算对；不再用GT点的距离。binary答案用yes/no开头判断。实时评分分母为原json_data数；pregenerated按(question,img)匹配，unmatched跳过分母，需额外报matching coverage。README总分按三类平均，VQA avg只平均configuration/compatibility。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **4,916** train indoor scans · 原文页 5
- **190** train tabletop scenes · 原文页 5
- **6,000** RoboSpatial-Val QA · 原文页 5

- **350** RoboSpatial-Home QA · 原文页 6

依这个顺序读

1. `README.md` ↗
   GitHub · NVlabs/RoboSpatial · 7a1b901cd8

   生成与评测角色、待办支持及来源身份

   L1–81 · L110–164 · L180–208

---

2. `data/README.md` ↗
   GitHub · NVlabs/RoboSpatial · 7a1b901cd8

   扫描 / EmbodiedScan父来源

   L1–46

---

3. `robospatial/data_loader/example_loader.py` ↗
   GitHub · NVlabs/RoboSpatial · 7a1b901cd8

   中介字段、局部对象ID与可见对象限制

   L20–28 · L55–75 · L102–109 · L111–118 · L122–134 · L139–163 · L170–178 · L182–238 · L240–247 · L249–259 · L261–280 · L294–303

---

4. `robospatial/annotation_generator.py` ↗
   GitHub · NVlabs/RoboSpatial · 7a1b901cd8

   生成类型、派发与参数

   L11–24 · L34–41 · L44–70 · L120–131 · L139–171 · L176–185 · L229–248 · L250–258 · L277–284 · L297–306

---

5. `README.md` ↗
   GitHub · chanhee-luke/RoboSpatial-Eval · c0095be6ca

   Home三类、聚合、point budget及版本修正

   L1–100 · L141–196

---

6. `evaluation.py` ↗

   GitHub · chanhee-luke/RoboSpatial-Eval · c0095be6ca

   真实mask/yes-no判分与两种分母

   `L12–54 · L60–121 · L123–137 · L140–146 · L156–174 · L190–216 · L222–263 · L265–271 · L281–287 · L294–300 · L302–308 · L316–344 · L349–374 · L382–398 · L410–416 · L419–434 · L436–442 · L446–474 · L478–494`

怎么接入我们的benchmark

可重用

扫描来源/scene ID、相机/9DOF box中介格式、生成参数，以及二值/point-in-mask评测。

需要转换

保留生成数据与Home benchmark的source/subset区别；case以原question+img并附稳定hash，mask/座标缩放/图像尺寸版本化。局部对象索引映回来源instance，不当跨图全球ID；evaluator记num_points_to_match、clamp、mask版本、matched/total与分项聚合。

仍需补齐

未下载Home图像 / mask与全扫描或运行生成。需核验Home对train来源的重用关系、各loader座标约定及full-scene occupancy；范例loader只含当前图可见 / 标注对象，不能假定所有未见空间都为空。生成几何关系不等于具体机器人能抓取或放置成功。

P043 · Embodied VideoAgent

Embodied VideoAgent: Persistent Memory from Egocentric Videos and Embodied Sensors Enables Dynamic Scene Understanding

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

Embodied VideoAgent 是可调用导航 / 操作工具的持续记忆agent，保留related_reference角色。本次确认程序实际用Habitat/HSSD场景与两agent流程，不能推定为ALFRED或TEACh移植。

> **版本与身份**
>
> 此repo明确标ICCV2025 Embodied VideoAgent；README中VideoAgent为2024前作，不能将两者数据/评测混计。生成10 layouts不等于10种新任务，更不代表全套测例已创建。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	Habitat-sim0.3.0 withbullet，generate_episodes 指向home-robot-remake/HSSD场景；scene_config与layout_i、agent_position、island_index分层。预设for循环生成同场景10个layout只是范例设置，不是已发布benchmark规模。
任务	另一LLM生成用户要求，agent用CHAT/GOTO/OPEN/CLOSE/PICK/PLACE/SEARCH及appearance/environment检索处理。object memory接受timestamp/RGB/depth/depth_mask/camera pose/FOV，对象记忆与工具技能不是固定题库。
题数与数据	episode JSON含scene、agent_position、island_index、objects；需另有pickable/unpickable/receptacle资产档。记忆相机座标定义为右x、下y、入画面z。生成器用对象 / 容器box提议位置与contact_test后稳定step；重新随机layout必须保存具体初态。
评估方式	two_agent_pipeline 限max_iterations=100，输出tool_cnt与action_cnt，核读入口未提供独立goal-success evaluator。PICK检查距离<=2及可见性后将对象移到y-10000并设STATIC；PLACE直接设translation/DYNAMIC后step，OPEN/CLOSE直接改joint velocities。这是抽象工具运行条件，不是末端效应器接触摸制benchmark。

依这个顺序读

1. `README.md` ↗
   GitHub · Embodied-VideoAgent/embodied-videoagent · 342c06f727

   精确论文、Habitat环境与sensor座标

   L1–90

---

2. `generate_episodes.py` ↗
   GitHub · Embodied-VideoAgent/embodied-videoagent · 342c06f727

   HSSD父场景、随机layout与初态输出

   L1–101 · L136–178

---

3. `env/actions.py` ↗
   GitHub · Embodied-VideoAgent/embodied-videoagent · 342c06f727

   额外no-op/backward actions

   L1–22

---

4. `env/executor.py` ↗
   GitHub · Embodied-VideoAgent/embodied-videoagent · 342c06f727

   工具语义、距离/可见性条件及状态修改

   L4–10 · L12–19 · L42–53 · L58–70 · L101–107 · L146–176 · L193–207 · L225–254 · L263–279 · L286–293 · L295–307 · L314–321 · L323–373 · L383–400

---

5. `two_agent_pipeline.py` ↗
   GitHub · Embodied-VideoAgent/embodied-videoagent · 342c06f727

   LLM任务生成、工具集、预算与输出

   L64–70 · L153–159 · L171–177 · L190–204 · L231–244 · L246–270

怎么接入我们的benchmark

可重用

RGB-D/pose记忆界面、工具回馈、scene/layout初态与部分物理状态处理。

需要转换

method连父Habitat/HSSD/资产版本；environment分scene与layout，case需先固定user task生成结果、初始episode及合法sensor/tool约定。工具调用、sim actions、dialogue与终态证据分别记录，另加独立goal判定后才可列可评测。

仍需补齐

未下载场景 / 模型、运行agent或对外服务。尚缺固定任务清单、task生成seed、独立success checker与完整初态重播验证；executor回复success字符串不能单独当benchmark通过。真实机器人动作转移需新的控制与验证。

P044 · HiERO

HiERO: understanding the hierarchy of human behavior enhances reasoning on egocentric videos

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

HiERO是视频表征与阶层活动推理方法；重用Ego4D、EgoClip/EgoMCQ与EgoProceL，不能将下游数据重新计为新任务库。

> **版本与身份**
>
> README提到2026 HiERO-StepG；本笔核读固定commit的2025方法仓库，不合并扩展成绩。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	视频与clip观测脉络、活动图，不是可交互场景。
任务	视频文字对齐、自然语言或步骤时间定位、程序分割；保持各下游任务身份。
题数与数据	Ego4D原生annotation与特征；NLQ以clip_uid、annotation_uid、query_idx定位题目，GT为clip_start_sec/clip_end_sec。
评估方式	GoalStep程序计算时间窗IoU与top-K阈值recall；EgoProceL另算MoF、IoU、precision及coverage，各自保留平均方法。

依这个顺序读

1. `README.md` ↗

   GitHub · sapeirone/HiERO · 1b56b0d31f

   确认精确论文、下游数据与后续HiERO-StepG扩展。

   L1–92

2. `ego4d_goalstep/utils/evaluate.py` ↗

   GitHub · sapeirone/HiERO · 1b56b0d31f

   核对NLQ数据键及IoU/recall。

   L1–81

3. `egoprocel/evaluate.py` ↗

   GitHub · sapeirone/HiERO · 1b56b0d31f

   核对程序评测指针、分母及coverage。

   `L7–17 · L30–40 · L58–68 · L98–108 · L126–139 · L144–180 · L182–186`

怎么接入我们的benchmark

可重用

原生题目身份、时间窗、父数据引用与评测程序。

需要转换

以context、信息题型及时间标注入库；分开EgoMCQ、NLQ和程序分割case，活动图不计作物理环境。

仍需补齐

原片与特征闭合、原生split及共同切分核对、各任务evaluator接线。

P045 · ManipBench

ManipBench: Benchmarking Vision-Language Models for Low-Level Robot Manipulation

内核内容已核读 · 主来源 · 原作 · 独立页面

ManipBench将真实机器人图像、布料及模拟图像问答拆成三个仓库；问答正确率与另行运行机器人的成功率须分开。 2026-10-11 补读官方直接链接的 robot-side 实作；仓库有实际运行程序，物理成功由人工输入纪录。

> **版本与身份**
>
> Fabric README保留main_old.py为论文版。真实Q1打印len(episodes)分母与回传有效total_count不同；Q2额外点数注明不是论文指针。 robot-side 固定 e25872ebd357559d5675daa07d05268afd5bd0b8；官方 question README 第25行证明其角色。readme.md 列的 moka_real_world_image_preprocess.py / moka_real_world.py 是服务器指令且不在此 robot repo 完整 tree；实际本地入口由 run.sh 和 pipeline main 确认。这是已取得的实作与尚待配对的环境 / 服务器契约，不是空白 README 或整库 unavailable。

领域	衣物与洗护
环境	题目使用真实或模拟场景图像；图片不等于相应可交互环境已取得。 补读 MOKA robot-side 路径使用 RealSense RGB / depth、已校准的相机到机器人 base 矩阵及预设右臂 / 夹爪；这是需现场设置的物理实验入口。
任务	真实数据含抓点与路径选择、抓点和落点双问；布料含状态、空间、时序和反事实题型。
题数与数据	question/options/answer/image或多图JSON；真实数据用correct_answer.json、wrong_answers_v批量、格点及随机候选顺序；完整图片外部提供。 补读：run.sh 指向 moka_real_world_pipeline.py，工作目录按 tasks/task_name/model_Vversion 创建。info.json 传 model_info、version、图像与 task_description 路径、点 / 格数；服务器 log.json 提供 plan_success、picking_point、points、end_point 和可选 height。相机存 color_image.png、显示用 depth_image.png 与原始 raw_depth_image.npy；程序用 depth[y,x]/1000 反投影，Z 再加 0.005，经固定 4×4 校准矩阵转 base。
评估方式	真实Q1解析选项后比对correct标记，Q2分抓点与落点；布料main.py比对答案；模拟脚本以文件名编码GT选项。解析失败、缺档及分母规则要保留。 补读：plan_success 只决定是否有抓放点可运行，不能当物理任务成功。generate_exp_seq.py 对模型次序 random.shuffle，运行后人工输入 y/n，其他输入记 false，将 {task_name_version: bool} 加入 vlm_list.json 的 task_tested，最后才写回。已读路径没有由传感器自动判定物理成功；其人工纪录、运行中止与问答 checker 的分母需分开。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **5** 操作类别 · 原文页 4
- **7** 额外真机验证任务 · 原文页 6
- **12,617** MCQ · 原文页 3, 4
- **2,662** 布料MCQ子集 · 原文页 5

依这个顺序读

1. `README.md` ↗

   GitHub · slurm-lab-usc/ManipBench-Real-Robot-question · 39b4a3c1bd

   区分原作总量、真实问答子集及robot-side仓库。

   L1–118

---

2. `manipbench_question_pipeline.py` ↗

   GitHub · slurm-lab-usc/ManipBench-Real-Robot-question · 39b4a3c1bd

   核对候选随机化、解析及Q1/Q2判分。

   L17–23 · L26–92 · L96–108 · L111–117 · L121–121 · L172–245 · L364–409

---

3. `README.md` ↗

   GitHub · slurm-lab-usc/ManipBench-Fabric-Manipulation-Code · 7a24890b0e

   确认题型、图片缺口及新版与main_old差异。

   L1–59

---

4. `main.py` ↗

   GitHub · slurm-lab-usc/ManipBench-Fabric-Manipulation-Code · 7a24890b0e

   核对题目字段与答案比较。

   L40–46 · L50–66 · L68–89 · L92–101 · L105–114 · L118–127 · L130–139 · L143–195

---

5. `README.md` ↗

   GitHub · slurm-lab-usc/ManipBench-Sim-Robot-question · 6d39a15f8a

   确认模拟图像问答范围。

   L1–46

---

6. `evaluation_scripts/pick_and_place/PutCarrotOnPlate/evaluate_random.py` ↗

   GitHub · slurm-lab-usc/ManipBench-Sim-Robot-question · 6d39a15f8a

   确认GT选项编码与计分单位。

   L1–140

---

7. `readme.md` ↗

   GitHub · Enyu-Zhao/ManipBench-Real-World · e25872ebd3

   robot-side 真实实验说明；区分服务器端指令、相机与机器人操作。

   L1–44

---

8. `run.sh` ↗

   GitHub · Enyu-Zhao/ManipBench-Real-World · e25872ebd3

   仓库内实际入口是 moka_real_world_pipeline.py，含 task/version/model 与高度参数。

   L1–1

---

9. `image_capture.py` ↗

   GitHub · Enyu-Zhao/ManipBench-Real-World · e25872ebd3

   RealSense z16 / BGR 串流、raw_depth_image.npy、显示深度图与回传的 depth intrinsics。

   L49–133

---

10. `moka_real_world_pipeline.py` ↗

    GitHub · Enyu-Zhao/ManipBench-Real-World · e25872ebd3

    读 info/log JSON 接线、深度→相机→robot-base、人工逐步运行与抓放 / translate / gripper 调用。

    L26–49 · L51–107 · L119–171 · L192–261 · L265–340 · L344–408 · L412–462

---

11. `generate_exp_seq.py` ↗

    GitHub · Enyu-Zhao/ManipBench-Real-World · e25872ebd3

    实验顺序打乱、调用机器人 pipeline、人工 y/n 成功判定及写回 task_tested；不是自动 success checker。

    L20–83

怎么接入我们的benchmark

可重用

三子集的题目格式、GT、候选生成及答案检查。 可另重用 robot-side 的 info/log 契约、逐次模型 / 任务版本纪录及人工成功字段，作为独立物理 trial profile。

需要转换

case保留父episode、题型、候选批量与顺序、图像及答案引用；固定抽样seed，不将候选变换算成新的语义任务。 物理 trial 另保留 task_name、version、model、相机 intrinsics、raw depth 尺度、crop、calibration、抓放点 / 高度、人工判定来源与中止原因；原 VQA profile 不因此改成 robot episode。

仍需补齐

完整图片、版本一致题目集、统一解析与分母契约；物理操作另需robot-side实验程序。 更新：robot-side 选定源代码已补读；仍需配对服务器脚本 / task_description、现场相机 / 机器人设置、可重播试验清单、人工判定规则与 seed。capture 路径未记录 depth_scale 或显式 RGB-depth 对齐；height_required 分支的 log.height 注解为 mm 却未作 /1000，需先验证单位，不能直接运行为标准 case。

P046 · RULSTM

What Would You Expect? Anticipating Egocentric Actions with Rolling-Unrolling LSTMs and Modality Attention

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

RULSTM同一仓库含2019方法、PAMI扩展及EK55/EK100版本；动作前时间窗、数据身份与原生采样设置须保留。

> **版本与身份**
>
> 现行repo含EK100等后续版本；P046原作EK55设置及后续基线不可合成新数据源。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	第一人称视频和特征LMDB；程序中的env是LMDB读取环境，不是机器人场景。
任务	动作预测及early recognition；同一标注在多个提前量报分，不等于多个新活动任务。
题数与数据	CSV含标注ID、video、start/end frame与verb/noun/action；LMDB特征按frame索引。SequenceDataset设置time_step、fps、sequence_length及action_samples，不足历史者列入discarded_ids。
评估方式	utils.py实作top-k accuracy、逐类平均top-k recall与多时间点结果；TTA使用原生2.0至0.25秒格。EK55/EK100 label space、split及官方JSON需分开。

依这个顺序读

1. `README.md` ↗
   GitHub · fpv-iplab/rulstm · e648c7ee40

   核对论文及两代数据与CSV。

   L15–94 · L180–229

2. `RULSTM/dataset.py` ↗

   GitHub · fpv-iplab/rulstm · e648c7ee40

   核对过去和动作内特征、时间设置与discarded IDs。

   `L23–64 · L110–158 · L184–209`

---

3. `RULSTM/utils.py` ↗

   GitHub · fpv-iplab/rulstm · e648c7ee40

   核对top-k、macro recall、TTA和官方输出。

   `L43–96 · L108–155`

怎么接入我们的benchmark

可重用

原生CSV/LMDB字段、动作映射、时间采样、排除清单及metrics。

需要转换

保存context截止点、提前量、frame到时间换算及label空间；action_features只在合法协定中暴露。

仍需补齐

特征素材闭合、排除样本分母、父EPIC数据重复及训练污染核对。

P047 · AVT

Anticipative Video Transformer

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

AVT是重用EK55/EK100、EGTEA及50Salads的预测方法；README还固定了外部RULSTM commit，必须把模型repo与父数据 / 评测来源分开。

> **版本与身份**
>
> 原作外部RULSTM固定57842b27d6264318be2cb0beb9e2f8c2819ad9bc；不能预设使用其他commit的评测。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	视频或预取特征的观测脉络，无交互场景定义。
任务	依tau_a提前量及tau_o观测长度做动作预测，另有未来特征学习；辨识与预测模式不能混用。
题数与数据	base_video_dataset保存orig_start/orig_end，转换出过去窗口和future_i窗口并另记discarded样本；不同数据根目录与特征频率保留。
评估方式	BasicLossAccuracy对各target类型计cross-entropy、top1/top5；common.utils.accuracy会展平时间维。正式EPIC评测另依README固定的RULSTM界面。

依这个顺序读

1. `README.md` ↗

   GitHub · facebookresearch/AVT · b082c99a6b

   确认精确论文、父数据和指定外部commit。

   L13–55 · L71–142

2. `docs/DATASETS.md` ↗

   GitHub · facebookresearch/AVT · b082c99a6b

   核对其他数据集标注来源。

   L1–20

3. `datasets/base_video_dataset.py` ↗
   GitHub · facebookresearch/AVT · b082c99a6b

   读时间窗口、future与discard规则。

   L23–32 · L38–71 · L73–79 · L82–100 · L106–112 · L116–138

---

4. `func/train_eval_ops.py` ↗
   GitHub · facebookresearch/AVT · b082c99a6b

   读target/logits与分类指针。

   L10–37 · L51–102 · L113–121 · L129–159

---

5. `common/utils.py` ↗
   GitHub · facebookresearch/AVT · b082c99a6b

   核对accuracy分母和多维输出处理。

   L17–44

怎么接入我们的benchmark

可重用

时间窗转换、target字典、标签空间及原生metric。

需要转换

case分开context、未来reference、tau_a/tau_o和数据版本；future字段作训练目标或评分证据，不能自动全部给推论端。

仍需补齐

素材闭合、外部RULSTM指定版本、discarded分母与共同split核对。

P048 · EGO-TOPO

EGO-TOPO: Environment Affordances from Egocentric Video

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

EGO-TOPO把视频中的活动区域建成图，再用于动作预测；图节点不是已重建且可操作的房屋场景。

> **版本与身份**
>
> EPIC/EGTEA数据与其后AntGPT等工作重用，不能将图或模型论文各自的数据量相加。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	EPIC55与EGTEA视频、推断的活动区域及访问图；保存video来源与时间关系。
任务	拓扑活动图与长期动作预测，是既有数据上的方法 / 表示，不添加独立数据集。
题数与数据	每视频graph.pth、locnet特征与配对分数；epic_utils用video、start/end frame、labels及图历史选出指定frame的图。
评估方式	metrics.py提供top-k accuracy、逐类平均top-k recall与TTA；图建构品质和动作预测分数需分项。

依这个顺序读

1. README.md ↗

   GitHub · facebookresearch/ego-topo · 81b5396e2a

   确认论文身份、父数据与建图/预测流程。

   L1–95

2. build_graph/README.md ↗

   GitHub · facebookresearch/ego-topo · 81b5396e2a

   确认graph及pairwise score产物。

   L1–51

3. `anticipation/anticipation/datasets/epic_utils.py` ↗

   GitHub · facebookresearch/ego-topo · 81b5396e2a

   核对frame范围、访问标签与历史图选择。

   L13–19 · L23–33 · L35–53 · L68–74 · L95–101 · L105–115 · L117–154 · L165–169

---

4. `anticipation/anticipation/utils/metrics.py` ↗

   GitHub · facebookresearch/ego-topo · 81b5396e2a

   核对accuracy、macro recall和TTA。

   L1–55

怎么接入我们的benchmark

可重用

父视频ID、图 / visit时间、特征引用与动作评测。

需要转换

图存context衍生资源，保留产生器和source hash；用观测截止点取图历史，不把完整未来图自动暴露给模型。

仍需补齐

原片与预计算特征、建图窗口/切分核对及evaluator接线。

P049 · AntGPT

AntGPT: Can Large Language Models Help Long-term Action Anticipation from Videos?

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

AntGPT用LLM产生未来动作串行；Ego4D v1/v2、EPIC55及EGTEA仍是父数据，文字解析及串行修补是评测契约的重要部分。

> **版本与身份**
>
> 此核读针对指定GPT ICL脚本；不能把其他GPT/Llama/Transformer脚本的配置及成绩当同一协定。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	视频、caption / 动作上下文和既有数据切分，非交互模拟环境。
任务	长期verb/noun/action串行预测；候选串行及不同语言模型不增加独立任务。
题数与数据	taxonomy/dicts.json、上下文与未来动作文字、LLM回应及相似度检索池；脚本将串行截断或补齐为20动作，并做词汇映射。
评估方式	eval_icl.py逐样本取K候选最小范式editdistance.eval。短/空答案有补齐策略，未知词有模糊匹配和预设类别；action ED在此脚本使用verb/noun索引相加，需与官方定义核对。

依这个顺序读

1. `README.md` ↗
   GitHub · brown-palm/AntGPT · 2dbc211ae8

   确认原作和多个父数据版本。

   L15–114

2. `GPT_models/ICL_COT/eval_icl.py` ↗
   GitHub · brown-palm/AntGPT · 2dbc211ae8

   读串行修补、词汇fallback、K候选评分与输出。

   L3–15 · L17–25 · L36–112 · L142–150 · L162–170 · L193–201 · L203–229

怎么接入我们的benchmark

可重用

父数据血缘、候选输出、vocab映射与原作解析 / 评分程序。

需要转换

case保存上下文模式、候选K、20个动作的horizon、prompt/检索池版本及修补规则；不得把20动作当20秒或20道新题。

仍需补齐

原始素材及split闭合、解析失败处理、action度量对照官方evaluator及本库协定。

P050 · PALM

PALM: Predicting Actions through Language Models

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

已找到作者名下的PALM程序，README明列动作辨识、图像描述与语言模型预测三个模块；不能把论文引用的VideoBLIP仓库当成PALM。

> **版本与身份**
>
> 固定commit为7d4e6cd6426a51857214cdd3ec818568624ab320。metric注解提到Damerau，但实作调用editdistance.eval；移植时应保持函数及套件版本，不能只照注解更换公式。annotation_utils也有作者本机绝对路径，需改成版本化数据引用。
>
> GitHub精确名称搜索找到kim-sanghwan/PALM；README自述为ECCV2024 PALM官方实作，论文标题与作者Sanghwan Kim相符。原PDF只列VideoBLIP等引用，已分开处理。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	Ego4D视频与clip观测脉络；annotation_utils将clip_uid映到video_uid和视频scenario，这些不是机器人可交互场景。
任务	先取得辨识动作与图像caption，再预测未来verb/noun串行；本篇是重用既有长期动作预测数据的方法，不添加独立机器人工作库。
题数与数据	README指定recognized-action JSON与caption JSON进入预测模块；annotation_utils保留clip/video关系，并将原生verbs/nouns词汇及同义字映成taxonomy索引。
评估方式	eval_utils对形状N×Z×K的候选串行计范式editdistance.eval，逐样本取K候选最小值再平均；AUED对不同前缀长度的ED做梯形积分。K、Z和文字到标签解析都影响分数。

依这个顺序读

1. README.md ↗

   GitHub · kim-sanghwan/PALM · 7d4e6cd642

   核对精确论文身份及三阶段输入输出。

   L1–9

2. `action_anticipation_module/EGO4D-prediction/utils/annotation_utils.py` ↗

   GitHub · kim-sanghwan/PALM · 7d4e6cd642

   核对clip/video关系和原生verb/noun映射。

   L1–100

---

3. `action_anticipation_module/EGO4D-prediction/utils/eval_utils.py` ↗

   GitHub · kim-sanghwan/PALM · 7d4e6cd642

   核对候选最小ED、前缀AUED与实际调用。

   L1–59

怎么接入我们的benchmark

可重用

三段模型输入路径、clip/video血缘、词汇映射、候选串行与ED/AUED程序。

需要转换

创建以原生clip与观测截止点为键的forecast case；分开模型可见的辨识动作、caption、未来GT及候选预算，保留taxonomy和解析规则版本。

仍需补齐

原始视频、辨识/caption中间档与split闭合；需核对原作配置的预测长度、候选数及依赖版本，并接回正式Ego4D评测。

P051 · USST / EgoPAT3D trajectories

Uncertainty-aware State Space Transformer for Egocentric 3D Hand Trajectory Forecasting

内核内容已核读 · 主来源 · 原作 · 独立页面

USST的实作包含EgoPAT3D-DT / H2O-PT重标注数据流程；未来手轨迹须连同观测比例、相机座标与seen / unseen切分保存。

> **版本与身份**
>
> 已核读EgoPAT3D主要数据与评分路径；不将H2O分支或外部EgoPAT3D新版本视为已同等验证。

领域	居家整理与清洁、穿戴交互与动作界面
环境	第一人称视频中的既有拍摄场景；EgoPAT3D loader明列scene与record切分，不是添加可操作模拟场景。
任务	由过去图像 / 位置预测未来2D或3D手部轨迹；global与local版本是不同座标 / 输入设置。
题数与数据	EgoPAT3D的pkl含traj2d、traj3d及num_preserve；mp4和T×4×4 odometry以scene/record/clip对齐。loader保存有效长度、范式参数并裁切或补零。
评估方式	utils先反范式，再依观测比例计逐轨迹平均欧氏距离ADE、最后一点FDE及各轴绝对误差；3D、2D像素、norm2d不可混报。test.py分开seen与unseen。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **14** EgoPAT3D-DT scenes · 原文页 6
- **3,715** H2O-PT test windows · 原文页 6
- **1,605** EgoPAT3D-DT seen-test windows · 原文页 6
- **2,334** EgoPAT3D-DT unseen-test windows · 原文页 6

依这个顺序读

1. README.md ↗

   GitHub · oppo-us-research/USST · beebdb963a

   确认论文身份、EgoPAT3D-DT / H2O-PT及模型设置。

   L1–110

---

2. src/EgoPAT3DLoader.py ↗

   GitHub · oppo-us-research/USST · beebdb963a

   读scene split、轨迹字段、odometry与有效长度。

   L28–36 · L38–87 · L90–137 · L146–190 · L194–205 · L208–231 · L233–308

---

3. src/utils.py ↗

   GitHub · oppo-us-research/USST · beebdb963a

   读反范式、观测比例及实际ADE/FDE。

   L57–205

---

4. test.py ↗

   GitHub · oppo-us-research/USST · beebdb963a

   确认seen / unseen及eval_space分项。

   L52–74 · L76–88

怎么接入我们的benchmark

可重用

父数据ID、场景切分、轨迹 / odometry字段与原生距离函数。

需要转换

case保留scene/record/clip、有效影格、观测比例与座标系；camera pose是观测或转换证据，不能当作robot action。

仍需补齐

原始视频与重标注资产闭合、H2O专用loader / 评分分支细读及可运行adapter验证。

P052 · StillFast

StillFast: An End-to-End Approach for Short-Term Object Interaction Anticipation

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

StillFast在Ego4D STA上预测下一个交互对象、动作与接触时间；官方测试提交和本机validation必须分开记录。

> **版本与身份**
>
> 本机Overall mAP有更多诊断组合，不等于官方只报的STA字段；静态核读还发现add的空字典分支有不可达的内层len(preds)>0条件，集成前须核对空输出对分母的影响。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	Ego4D视频的观测影格及短历史片段，无交互模拟环境。
任务	共同预测box、noun、verb、time_to_contact；四种STA指针组合不是四份独立素材。
题数与数据	annotation以uid、video_id、frame和objects索引；objects含box / noun_category_id / verb_category_id / time_to_contact。训练标签有noun+1与依ROI版本决定的verb offset，输出JSON再还原。
评估方式	实际validation调用OverallMeanAveragePrecision(top_k=5)：IoU严格大于0.5、TTC误差不超过0.25；依GT数折免(K−1)×GT个高分false positives。正式成绩依README指定的Ego4D evaluator / 隐藏test。

依这个顺序读

1. README.md ↗

   GitHub · fpv-iplab/stillfast · 199ba4902b

   确认Ego4D v1/v2、数据与官方评分入口。

   L1–102

2. `stillfast/datasets/ego4d_sta_still.py` ↗
   GitHub · fpv-iplab/stillfast · 199ba4902b

   读UID、影格、objects和类别offset。

   L17–23 · L34–41 · L48–54 · L56–67 · L78–84 · L93–136 · L144–154

---

3. `stillfast/tasks/sta.py` ↗
   GitHub · fpv-iplab/stillfast · 199ba4902b

   追到validation metric与提交JSON的类别还原。

   L1–178

---

4. `stillfast/evaluation/sta_metrics.py` ↗
   GitHub · fpv-iplab/stillfast · 199ba4902b

   读匹配、K个false-positive折免及STA具体条件。

   L2–6 · L15–19 · L32–40 · L61–203 · L205–217 · L233–237 · L266–270 · L288–292 · L294–298 · L308–312 · L359–363 · L368–378 · L380–388 · L398–402 · L407–411 · L414–420 · L428–439 · L463–467 · L487–491 · L496–500 · L523–529 · L532–543 · L551–555 · L566–592

怎么接入我们的benchmark

可重用

STA annotation、uid结果格式、类别offset还原及原生匹配规则。

需要转换

case保留版本、frame / 历史窗口、对象GT与TTC单位；box数与视频题数分开，evaluator保存top_k、IoU/TTC及类别平均规则。

仍需补齐

视频 / LMDB与split闭合、官方evaluator版本对照及空预测 / 标签offset边界案例核对。

P053 · HandsOnVLM

HandsOnVLM: Vision-Language Models for Hand-Object Interaction Prediction

内核内容已核读 · 主来源 · 原作 · 独立页面

HandsOnVLM公开了EPIC手轨迹与reasoning数据界面；核读发现评分变量命名和实际函数不一致，必须保留程序版本并先校核。

> **版本与身份**
>
> 静态核读另见inference正常回传3项而evaluate_epic_kitchen_traj以2项接收；尚未运行，不能宣称此commit可直接跑通或原文数值有相同问题。

领域	餐饮与烹饪、穿戴交互与动作界面
环境	EPIC-KITCHENS第一人称视频与人类手轨迹；reasoning子集由有对应提问的影格筛选。
任务	一般或文字条件的双手未来2D轨迹预测；预设评估入口是ek100 validation，非所有父数据的统一测试。
题数与数据	dataset提供future_hands[2,5,2]、future_valid[2]、contact_point、image_abs_paths及prompt；评分移除首点后用双手×4个未来点。reasoning用valid_index筛子集，图像张量的重复不增加题数。
评估方式	traj_eval含ADE/FDE与四步加权WDE、位置及手的有效遮罩；但evaluate_traj_stochastic把compute_fde存为ade、compute_ade存为fde，最后回传均值而非已算出的min。推论包装还跳过无效生成，需另报覆盖率。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **2** hand-prediction task formulations · 原文页 5
- **8,000** Ego4D zero-shot generated query pairs（约数） · 原文页 6
- **7,500** EPIC generated query pairs（约数） · 原文页 6

依这个顺序读

1. `README.md` ↗

   GitHub · Kami-code/HandsOnVLM-release · 1163d45a7b

   确认精确论文、数据及评估入口。

   L1–110

---

2. `docs/prepare_data.md` ↗

   GitHub · Kami-code/HandsOnVLM-release · 1163d45a7b

   确认EPIC、Drive资产与LITA依赖。

   L1–6

---

3. `handsonvlm/dataset/epic_dataset.py` ↗

   GitHub · Kami-code/HandsOnVLM-release · 1163d45a7b

   读future字段、图像与reasoning子集。

   L11–46 · L48–72 · L77–102 · L111–118 · L122–155 · L158–158

---

4. `handsonvlm/evaluation/evaluate.py` ↗

   GitHub · Kami-code/HandsOnVLM-release · 1163d45a7b

   确认实际ek100 validation入口。

   L1–26

---

5. `handsonvlm/evaluation/handsonvlm_inference.py` ↗

   GitHub · Kami-code/HandsOnVLM-release · 1163d45a7b

   读输出有效性、四步截取及metric接线。

   L7–64 · L109–138 · L142–151 · L155–177 · L214–224

---

6. `hoi_forecast/evaluation/traj_eval.py` ↗

   GitHub · Kami-code/HandsOnVLM-release · 1163d45a7b

   读实际遮罩、ADE/FDE调用与WDE计算。

   L2–254

怎么接入我们的benchmark

可重用

EPIC来源链、prompt / 轨迹字段、reasoning筛选和有效遮罩。

需要转换

case保留提问、原始影格ID、2D范式座标、4步时间点与valid masks；metric保存实际函数、候选数及失败输出处理，不直接信任打印名称。

仍需补齐

外部资产及原始EPIC视频、时间步长核对、评分命名 / 均值修正对照与完整推论接线。

P054 · EgoVid-5M / EgoDreamer

EgoVid-5M: A Large-Scale Video-Action Dataset for Egocentric Video Generation

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoVid的公开repo主要是Ego4D衍生视频标注与清洗工具；相机运动控制标注不能直接视为可运行机器人控制。

> **版本与身份**
>
> 本笔覆盖公开数据处理路径；不宣称EgoDreamer模型或所有外部清洗依赖已核读。

领域	居家整理与清洁、办公与教育、工艺与修缮、休闲与运动
环境	Ego4D v1/v2来源视频及clip窗口；来源视频须另行取得。
任务	文字 / 相机运动条件的第一人称视频数据；本次固定tree见标注、pose及品质计算工具，未取得完整EgoDreamer生成 / 评测实作。
题数与数据	CSV的video_id=来源视频_起始影格_终止影格，含fps、frame_num、noun/verb、llava_cap、name和各项品质分数；pose资产含3×3 intrinsics及逐影格4×4相机外参。README提醒raw IMU已知问题。
评估方式	光流清洗程序每8影格采样，将flow按平均图像尺寸缩放到512基准，再存均值 / 分箱比例；这是素材品质证据，不是操作成功率。flow_0_4程序实为>0且≤5，与栏名 / README有差异。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **5,000,000** EgoVid clips（名义约数） · 原文页 4
- **1,200** EgoVid-val samples（约数） · 原文页 7
- **65,000** kinematic-annotated subset（约数） · 原文页 7

依这个顺序读

1. README.md ↗

   GitHub · JeffWang987/EgoVid · 45c59d0df9

   确认来源素材、CSV、pose字段与精确论文。

   L1–120

---

2. processor/egovid-metadata/Optical-flow/optical-flow-score.py ↗

   GitHub · JeffWang987/EgoVid · 45c59d0df9

   核对frame步长、尺寸范式及分箱实作。

   L1–30 · L45–138

怎么接入我们的benchmark

可重用

父视频ID、精确clip范围、文字 / pose标注和清洗provenance。

需要转换

source记Ego4D重用关系；case保留frame/fps、caption来源、pose座标与quality filter版本。5M名称不能直接算成本库已取得评测题数。

仍需补齐

完整CSV与视频 / pose资产闭合、实际clip去重、生成模型与正式evaluator，以及清洗栏名 / 实作差异校核。

P055 · FUTR

Future Transformer for Long-term Action Anticipation

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

FUTR重用Breakfast与50Salads，预测动作类别及持续比例；观测 / 预测百分比和frame级MoC是原生协定的一部分。

> **版本与身份**
>
> FUTR是方法repo，父数据与EGO-TOPO / 其他预测方法可能重用；样本窗口与原片不能重复相加。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	既有长视频及预计算视觉特征，无新可操作场景。
任务	从过去视频预测后续动作分段；一支视频的多个观测比例是不同评测设置，不是不同语义任务。
题数与数据	groundTruth逐影格标签、features/*.npy及mapping.txt；dataset返回features、past_label、trans_future_target、trans_future_dur，保留sample_rate、NONE、pad_idx及n_query截断。
评估方式	predict.py将预测类别 / duration展开到未来影格，再按观测与预测比例截取；eval_file累积每类正误影格，最后对有GT的类别平均得到MoC，非全影格micro accuracy。

依这个顺序读

1. README.md ↗
   GitHub · gongda0e/FUTR · a3440100ef

   确认精确论文、父数据与split / 观测比例。

   L1–97

2. `data/basedataset.py` ↗

   GitHub · gongda0e/FUTR · a3440100ef

   读特征 / GT窗口、duration与padding规则。

   L1–162

---

3. `predict.py` ↗

   GitHub · gongda0e/FUTR · a3440100ef

   读duration展开、截取窗口和MoC类别平均。

   L8–14 · L42–48 · L69–111

---

4. `utils.py` ↗

   GitHub · gongda0e/FUTR · a3440100ef

   核对每类影格正误与duration范式入口。

   L7–20 · L23–31 · L39–60

怎么接入我们的benchmark

可重用

来源视频 / split、逐影格GT、类别字典与MoC计算。

需要转换

case保留来源视频长度、obs_fraction、pred_fraction、特征步长及label mapping；duration比例要连同视频长度保存，不改写成固定秒数。

仍需补齐

视频 / 特征闭合、Breakfast四split / 50Salads五split核对及共同输出adapter。

P056 · Forecasting hands and objects

Forecasting Hands and Objects in Future Frames

实作尚未确认 · 方法 / 综述 · 原作 · 独立页面

已核对论文前四页与现有GitHub搜索纪录；本轮未找到可确认的作者实作，不能把同名时间串行或较新对象预测repo当原作。

> **版本与身份**
>
> 核对的是1705.07328v3论文及本轮搜索范围；未找到不等于全网证明不存在。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	论文的第一人称与街景视频观测；未取得对应的交互环境或程序数据契约。
任务	从当前影格预测未来手 / 对象是否出现及其bounding boxes，包含当前不可见对象；不是机器人动作运行。
题数与数据	论文显示当前图像 / 光流、未来时间与框标注的研究设置；公开数据档、字段和原生split仍未确认。
评估方式	论文讨论未来对象presence/location及AP；原作评分脚本未取得，本笔不宣称程序或数值已重现。

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

可保留来源、预测目标与时间视野的定义参考。

需要转换

先作方法参考登记；取得视频、future boxes、标签与split后，才可创建完整forecast cases。

仍需补齐

作者仓库、数据manifest、确切字段和可运行evaluator。

P057 · Motor attention and action forecasting

Forecasting Human-Object Interaction: Joint Prediction of Motor Attention and Actions in First Person Video

内核内容已核读 · 主来源 · 原作 · 独立页面

作者实作可读出 EGTEA / EPIC 的动作、手部与接触点数据格式；分类评分可追到实作，但手部 / hotspot 测试入口停留在可视化版本，不能宣称完整重现论文评测。

> **版本与身份**
>
> 固定 77675f97143202b0a8e4555a3f30334ebe3c219f（2019-11-22），早于已读的 2020 v2 论文。设置引用作者本机路径；本轮未下载数据 / 权重，未将被注解的实验码当成有效评分器。
>
> 论文为 Liu、Tang、Li、Rehg 的 Forecasting Human-Object Interaction: Joint Prediction of Motor Attention and Actions in First Person Video（arXiv:1911.10967；本地 PDF 为 v2 / ECCV 2020）。论文连至作者页，作者页同列本 repo、相同 arXiv ID、四位作者及额外标注；页面标题的 Egocentric Activity 是同一作品的标题差异。Repo 是方法与既有 EGTEA / EPIC 数据的转接实作，不是另一套独立机器人任务库。

领域	餐饮与烹饪、穿戴交互与动作界面
环境	既有 EGTEA Gaze+ / EPIC-Kitchens 的人类第一视角厨房视频。论文 §4.1 将 EGTEA 转为 320×256、24 fps，EPIC 为 512×288、30 fps；手部与接触位置投影在最后可观测影格，没有可运行机器人环境。
任务	联合预测未来 verb/noun/action、motor attention 与 interaction hotspot。EGTEA 用 split1、提前 0.5 秒；EPIC 用指定 train/val 做消融、提前 1 秒，challenge seen/unseen 另列。106 / 2513 是各设置的 action 类数；论文补充的 7381 / 14951 是额外标注样本数，不是新任务数。
题数与数据	根层 video_list 与 verb_dict/noun_dict/action_dict；每笔 filename、video_info.{width,height,fps,num_frames}、label=[verb,noun,action]、target。EPIC target=[hotspot_xy,fingertip_xy]，整数代表缺失；以 12 点直线插值产生手部热图。EGTEA target=[hand,hotspot_xy]，hand 有 12 笔 [x1,y1,x2,y2,num_hand]；num_hand=0 或 hotspot=(0,0) 改用均匀先验。座标是各自图像像素，缺失标记不能转成真实原点；通用 convert_dataset.py 的产物并不足以供 joint loader 使用。

评估方式	eval_joint.py 对原图 / 水平翻转分类输出取平均，计 top-1/top-5（%）与 mean class accuracy；后者对所有设置类别取平均，零支持类别依 epsilon 得零。论文 §4.3 另报 hotspot F1/KLD 与手部平均 / 最终位移（空间 / 时间下采样后范式；手部结果仅 EGTEA）。但 test_joint.py 的 compare_hotspot 忽略输入预测，改造三张 8×8 中心先验；compare_hand 用 GT 最大值>0.01 的切片、argmax 点欧氏距离，末项取扁平化后最后有效切片，函数本身没有论文范式。这些评分调用与汇总均被注解；不能将函数名称视为已接通的论文评测。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **3** joint forecasting endpoints · 原文页 11

依这个顺序读

1. `README.md` ↗

   GitHub · 2020aptx4869lm/Forecasting-Human-Object-Interaction-in-FPV · 77675f9714

   核对训练 / 测试入口与外部数据、权重依赖。

   L1–23

2. `exp_configs/egtea-o/egteao-action_split1_i3d_res50v1_vae.json` ↗

   GitHub · 2020aptx4869lm/Forecasting-Human-Object-Interaction-in-FPV · 77675f9714

   确认 106 类、split1 设置、32 帧步长 2 与私人数据路径。

   L1–28

3. `exp_configs/epic-kitchens/epic-kitchens-action_trainval_i3d_csn152_vae.json` ↗

   GitHub · 2020aptx4869lm/Forecasting-Human-Object-Interaction-in-FPV · 77675f9714

   确认 EPIC train/val 的 2513 action 类及独立设置。

   L1–30

4. `libs/datasets/custom_dataset_joint.py` ↗

   GitHub · 2020aptx4869lm/Forecasting-Human-Object-Interaction-in-FPV · 77675f9714

   读实际 JSON keys、两数据集相反的 target 顺序、12 时片热图与缺失标注处理。

   L22–56 · L223–253 · L256–369 · L382–509 · L522–590

5. `tools/convert_dataset.py` ↗

   GitHub · 2020aptx4869lm/Forecasting-Human-Object-Interaction-in-FPV · 77675f9714

   README 的通用转换器只写 label_dict/video_list，并未产生 joint loader 必要字段或 EPIC 分支。

   L68–70 · L74–147

---

6. `eval_joint.py` ↗

   GitHub · 2020aptx4869lm/Forecasting-Human-Object-Interaction-in-FPV · 77675f9714

   核对推论翻转平均及实际只计分类 top-1/top-5、mean class accuracy。

   L59–64 · L97–108 · L127–216

---

7. `libs/utils/metrics.py` ↗

   GitHub · 2020aptx4869lm/Forecasting-Human-Object-Interaction-in-FPV · 77675f9714

   确认按样本加权的 top-k 百分比与 confusion matrix 各列召回的平均。

   L21–86

---

8. `test_joint.py` ↗

   GitHub · 2020aptx4869lm/Forecasting-Human-Object-Interaction-in-FPV · 77675f9714

   核对 hotspot 中心先验覆写、有效手部切片的位移算法与被注解的评分 / 输出。

   L78–215 · L298–407 · L440–461 · L486–554

怎么接入我们的benchmark

可重用

保留父数据集 / split 身分、类别字典、clip 引用、原生热图建置及分类指针实作。

需要转换

case 以父数据集+split+filename 定位，task 分为分类、接触点与手部预测；按数据集解开 target，附图像大小、提前时间、像素 / 热图座标和真实 / 插值 / 均匀先验标记。evaluator 分别保留分类、F1/KLD、位移单位。

仍需补齐

需取得作者额外 joint JSON、标注与可观测 clip 边界，重建相符类别字典；修复 / 验证 hotspot 与手部评分入口、范式及有效切片汇整，再做运行验证。

P058 · EgoPAT3Dv2

EgoPAT3Dv2: Predicting 3D Action Target from 2D Egocentric Vision for Human-Robot Interaction

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoPAT3Dv2 的作者 repo 同时保留原版与扩充版读取器；可追到逐帧 3D 目标误差与进度分箱，但 HDF5 版本、手部特征错写及评分汇整差异须先处理。

> **版本与身份**
>
> 固定 a24b3a5a2453931de69a17dfc7116057dc849136（2024-03-19）。configs/README.md 在 manifest 中是空档；README 测试命令未带程序所需 model_epoch/checkpoint。test_DDP 后处理固定 4K 内参，v>=2160 分支错改 u，且 x1/y1 使用前轮 z；重现前须确认保留原行为或另列修正版。论文 §IV-A 说扩充分配 9+2 新场景，§V-B 又说添加12场景，不能以文字自行决定总场景数。
>
> README 的完整标题、十一位作者与论文 arXiv:2403.05046v1 一致；论文指定的 ai4ce 项目页直接连本 repo 与 Hugging Face 数据。这是 ICRA 2024 EgoPAT3Dv2 的实作及 EgoPAT3D 扩充数据入口，原版 D1 与扩充版 D2 有重用关系，不能加总当作两份互斥数据集。

领域	协助、交接与陪伴、穿戴交互与动作界面
环境	头盔安装 Azure Kinect 的人类对象操作视频。论文 §VI 的 UR10e 避让 / 朝预测点移动是另行展示；已读 repo 提供预测数据与模型测试，没有该展示的机器人任务成功评分器。
任务	在线以 X1:t 预测同一段操作最终 3D 手部目标；目标必须转到当前影格相机座标，并非未来全身动作或机器人控制。T1/T2 指原版 / 扩充训练来源，D1/D2 指测试数据版本，seen/unseen 指场景是否在训练出现。论文报告可用 clips 由 4129 增为 9579；本轮未下载资产核算此数。
题数与数据	原版 HDF5 用 /{annotrain|annovalidate|annotest}/{scene}/{video} 与 /sequences/{scene}/{video}/{color,transformation/odometry}；扩充版将 /color/{scene}/{video}/{frame} 与 annotation、/transformation/{scene}/{video}/{frame} 分置两档。annotation 每列前三值为三个边界，3:6 / 6:9 为两段目标 xyz；原版要求 z>0.1，扩充版 z>0。长度=end-start、RGB 读 start+1...end，累乘 odometry 后以逆矩阵转换目标，单位公尺。RGB resize 224×224；training 直接排除长度>25 的 clips，测试以最长段补零并回传真实长度。handLM 为 21×2、hand 为 landmark 5 的 x/y；两 RGB 读取器的 handLM 奇数栏实际也写 lm.x，不能当成正确的 x/y 特征。

评估方式	test_DDP.py 依模型 / epoch、scene、video 输出 start-end.txt（逗号分隔 xyz）与 start-end_gt.txt。eval.py 算每帧 ‖pred-gt‖2，以 i/(L-1) 落入十个宽 0.1、两端皆包含的区间；先在 clip 内平均，再平均同 recording 的 clips，最后等权平均 recordings，×100 得 cm；Overall 使用 linspace(2,1,10) 加权。边界影格可能进入相邻两箱，短 clips 可出现空箱。论文 §IV-B 写按影格等分十阶段、余数给较早阶段，并报三个 seed 平均；目前入口不自动做三 seed 汇整。eval.py 的 --mode 是 store_true，仅用于输出命名，真正 split 由 test_DDP 的设置决定。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **22** 原版＋添加scenes · 5+6+9+2推算 · 原文页 4

依这个顺序读

1. `README.md` ↗

   GitHub · ai4ce/EgoPAT3Dv2 · a24b3a5a24

   确认作者 / 论文、外置 HDF5 数据及 test_DDP→eval.py 流程。

   L1–45

2. `configs/cfg_defaults.py` ↗

   GitHub · ai4ce/EgoPAT3Dv2 · a24b3a5a24

   确认原版 / 扩充版、seen/unseen、单笔测试 batch 及预设路径。

   L15–35 · L42–75

3. `configs/cn_t_post_hand_newloss_1_d1_seen.yaml` ↗

   GitHub · ai4ce/EgoPAT3Dv2 · a24b3a5a24

   实际 D1 seen RGB 设置与作者 HPC 路径。

   L1–21

4. `data_utils/Dataset_RGBD.py` ↗

   GitHub · ai4ce/EgoPAT3Dv2 · a24b3a5a24

   原版 annotation、color/odometry、有效深度门槛及逐帧转换。

   L10–114

5. `data_utils/Dataset_RGBD_enhanced.py` ↗

   GitHub · ai4ce/EgoPAT3Dv2 · a24b3a5a24

   扩充版两个 HDF5 的群组、clip 筛选、影格偏移与手部输出。

   L13–120 · L136–140

---

6. `data_utils/testDataset.py` ↗

   GitHub · ai4ce/EgoPAT3Dv2 · a24b3a5a24

   区分旧 pointcloud/IMU 基线所需字段，避免误列为 RGB 方法必要输入。

   L9–34 · L42–100

---

7. `test_DDP.py` ↗

   GitHub · ai4ce/EgoPAT3Dv2 · a24b3a5a24

   追 seen/unseen 读取器分派、真值 / 预测输出及固定内参后处理。

   L19–38 · L58–87 · L160–237 · L256–261

---

8. `eval.py` ↗

   GitHub · ai4ce/EgoPAT3Dv2 · a24b3a5a24

   核对欧氏误差、公分单位、含双端点的十箱及 recording 层级平均。

   L45–61 · L92–104 · L248–282 · L284–345 · L397–409

怎么接入我们的benchmark

可重用

scene/video/clip 边界、逐帧目标与 odometry 引用、D1/D2 及 seen/unseen 分派、欧氏误差实作。

需要转换

case 保存 dataset_version+split+scene+video+start/end，附实际影格索引、公尺相机座标、有效长度与手部缺失遮罩；evaluator 明列进度分箱、recording 平均、Overall 时间权重与 seed。原版 / 扩充版以来源重用关系相连。

仍需补齐

需取得并固定 Hugging Face HDF5 版本 / 场景清单，核对修正版标注与影格采样时间；修正或隔离 handLM 的 x/x 特征、补足 checkpoint/model_epoch 参数与私人路径，再验证评分分箱及后处理。

P059 · EMAG

EMAG: Ego-motion Aware and Generalizable 2D Hand Forecasting from Egocentric Videos

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

EMAG 是重用 Ego4D / EPIC-Kitchens-55 的双手位置预测方法。已读数据与 ADE/FDE 计算程序，但公开设置、读取器与 trainer 的字段 / 时间维度不一致；不可标成可直接运行的跨数据集评测。

> **版本与身份**
>
> 固定 0386bd9de2bd2ec3504e5b645a095c46e9a565ca（2025-03-25），与 2024 论文区分。loader 传 ego_feat，trainer 却读 egos_input；loader 保留五时点且没有裁切，test_step reshape 明定四时点；两份设置皆未定义 trainer 初始化所读的 model_config.loss。论文称 homography，文件路径 / 变量称 fundamental/fmat，未取得矩阵资产前不能宣称两者等价。非截断 tree 未列 EPIC 专用 loader 或前处理发布。
>
> README 自称 ECCVW 2024 官方实作，列 Hatano、Hachiuma、Saito，与 arXiv:2405.20030 论文及其指定作者页一致；作者页 Code 连至 masashi-hatano/EMAG。论文也引用 SORT、hoi-forecast、EGO4D/forecasting 作为相关工具 / 比较方法，不能把它们替代成本论文的实作。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	论文在 EPIC-Kitchens-55 厨房视频及 Ego4D 多种人类活动上做同数据集 / 跨数据集预测；数据属人类第一视角图像，没有机器人可运行动作界面。已读程序入口使用 Ego4D schema，EPIC 另有设置但没有独立 loader / 转换脚本。
任务	论文 §4.2 用八张 4 FPS 观测，预测未来一秒四时点的左右手 2D 位置，并以未来 ego-motion 为辅助训练目标。跨数据集的方向（EPIC→Ego4D 或反向）及 train/val 必须各自保留；活动类别分析不是添加机器人任务。
题数与数据	读 annotations/fho_hands_{mode}.json 的 /clips/*/{video_uid,clip_uid,frames}，由 frames/*/{pre_45,pre_30,pre_15,pre_frame,contact_frame}/boxes 的 left_hand/right_hand 创建 [2,5,2] 座标与 [2,5] mask；以来源 w/h 范式。排除设置 delete 清单、pre_45.clip_frame≤interval×8 或全零 mask。输入 image_frame/{clip_uid}/{frame:06d}.png、optical_flow/{clip_uid}/npy/*.npy、fundamental/{clip_uid}/*.npy，另读 hand-objects/interval={interval}/{clip_uid}/{pre45}.pkl 的 bboxes_obj/bboxes_hand/attention_mask。回传 frames、flows、bboxes、ego_feat、future_hands、future_egos、hands_mask、egos_mask 与影格 h/w；八个观测索引终于 pre45-interval。影格步长不能直接当秒；pickle 与图像均未下载 / 反串行化。

评估方式	论文 §4.3 定义图像高度256 px尺度的 ADE（所有未来时点、左右手）与 FDE（末时点、左右手）。实作 test_step 固定四时点、套 hands_mask，scaling_original 按 meta 中的来源 w/h 还原像素；calculate_L2_loss 排除 GT=(0,0)，分别累积左右手所有有效时点与第四时点的 L2 距离，test_epoch_end 只输出四个分手平均。没有此处的左右手合并报表，也没有保证来源 PNG 高度为256的转换步骤；原始分辨率不同会改变分数。

依这个顺序读

1. `README.md` ↗

   GitHub · masashi-hatano/EMAG · 0386bd9de2

   确认完整作品 / 作者及公开训练、评测入口。

   `L4–20 · L32–52`

2. `configs/config_ego4d.yaml` ↗

   GitHub · masashi-hatano/EMAG · 0386bd9de2

   核对预设 val split、八帧输入 / 四步输出、间隔、外部路径及排除视频。

   `L1–96`

3. `configs/config_epic.yaml` ↗

   GitHub · masashi-hatano/EMAG · 0386bd9de2

   确认 EPIC 间隔16与另一套 normalization，不把两数据设置视为等价。

   `L1–15 · L42–90`

4. `datamodule/ego4d_dataset.py` ↗

   GitHub · masashi-hatano/EMAG · 0386bd9de2

   追 JSON 标注、五时点遮罩、RGB/flow/3×3矩阵与 pickle bounding boxes 的实际字段。

   `L35–62 · L77–171 · L179–239 · L241–290`

5. `datamodule/lit_ego4d_data_module.py` ↗

   GitHub · masashi-hatano/EMAG · 0386bd9de2

   确认 test_type=val 且只实例化 Ego4D 读取器。

   `L33–51 · L53–110 · L128–134`

6. `lit_main.py` ↗

   GitHub · masashi-hatano/EMAG · 0386bd9de2

   核对实际预设设置、checkpoint 与 test 调用。

   L12–38 · L63–76

---

7. `models/lit_EMAGTrainer.py` ↗

   GitHub · masashi-hatano/EMAG · 0386bd9de2

   核对输入契约、四时点 reshape、遮罩及每只手平均 / 最终欧氏距离。

   L15–31 · L74–98 · L243–316 · L334–359

---

8. `utils/util.py` ↗

   GitHub · masashi-hatano/EMAG · 0386bd9de2

   确认从范式座标回复到来源影格 h/w，并未自行缩到高256。

   L4–28

怎么接入我们的benchmark

可重用

原生 clip_uid、观测锚点、标注时点与有效性 mask，左右手 / 对象框引用及分手位移算法。

需要转换

case 以父数据集版本+split+clip_uid+锚点定位；保留 2D x/y、来源影格尺寸与秒 / 帧对照，明列四步 horizon、两手缺失规则与图像高度256的评分尺度。跨数据集保留训练来源与评测来源，不合并其原生 case。

仍需补齐

须补齐图像、flow、手物框与 ego-motion 前处理来源 / 版本及 EPIC 格式转换；修复 ego_feat/egos_input key、五标注时点对四输出时点的契约与缺少的 model_config.loss 设置，确认两手合并、分辨率及遮罩后才可运行验证。

P060 · Continuous 4D interaction forecasting

From Where to How: Continuous 4D Interaction Forecasting from Egocentric Video

内核内容已核读 · 主来源 · 原作 · 独立页面

此来源不只是项目页：有 Coherent4D 的事件分段、共同座标及 SMPL 附加程序。正式预测指针只能读到论文定义，尚无公开评分器可直接沿用。

> **版本与身份**
>
> 固定67386704bf335af977232594d0f86428d0623c8e（2026-09-14）。非截断tree有网站、统计与process程序，没有发布完整训练 / 评分实作。SMPL指南指定外部 FIction-WHAM b520bc8f1d755be658c4d2bafdffe5081d09cfe2；本轮只读该依赖声明，未读取 / 运行外部模型。chunk脚本不创建split，须承接来源take分割，不能把每个chunk随机切分。
>
> README 的完整标题、六位作者及 arXiv:2609.08636 与本地 v1 论文一致，论文作者页直接连 CorrineQiu/from-where-to-how。Coherent4D 是在 Ego-Exo4D 上建置的配对位置 / 姿态数据；HIGFlow 是方法名称。FIction、Detic、Llama 与 WHAM 是来源 / 依赖，不能替代本论文版本。
>
> **分类覆核：**既有Coverage已将本作纳入数据 / 评测主来源；本次维持此判定。原文定义Coherent4D数据、固定split、联合预测目标和具体指针，应同时承认数据、评测与方法贡献。早期书目M / no标记属初筛快照，不能用来否定此后原文审阅结果。公开仓库未发布预测scorer是另一项可得性缺口。

领域	餐饮与烹饪、医疗与手术支持、交通移动与车辆维修、穿戴交互与动作界面
环境	Ego-Exo4D 的 Aria 第一视角程序视频；Cooking、Health、Bike Repair 三个 domain。第三视角用于脱机标注 / SMPL 重建，不是预测输入。787 unique takes 是来源录制单位，不能当成787个独立机器人环境。
任务	共同预测有序3D交互位置与同时间的全身 SMPL 状态。原生21个程序任务由 CSV 按 domain 指定；Cooking/Health/Bike Repair 分别预测10/5/4个事件，并非秒数。公开统计为233828 samples（train193598、val20484、test19746）、1594186个非padding未来 targets、跨domain去重535个对象标签；这些均为来源统计，未以完整资产重算。

题数与数据	build_chunks 读 pickle 根层 dataset，按 interactions.time 排序并以 chunk_size 不重叠切分，产生 id={take_name}_{datum_idx}_{chunk_idx}。每笔含 observation_start/end_time_s、history_interactions、target_interactions、target_mask、source_meta 及可选 env_objects；事件有 time_s、time_rel_s、location_norm、object。首个未来事件是时间零，history 严格在前30秒（起点截于0）；尾段以 None 加 mask=0。F0 取自 source_meta.source_observation_end_time_s，不随 chunk 时间原点重新设置；位置用 clip(R0.T@(p-t0)/5,-1,1)。SMPL 附加 history/target_pose_mask、*_pose_frame、*_pose_time_delta_s、*_root_orient6d_f0、*_root_trans_f0_m、*_body_pose_local6d（23×6）、*_joints_f0_m（19×3）。pose位置保留公尺，6D旋转为3×3矩阵前两栏按列展平；不能套用不同6D排列。
评估方式	固定 tree 没有 HIGFlow 预测 / benchmark 评分器。已读论文 §III-C：位置先反缩放至度量空间，ADE 先平均每样本有效事件再跨样本平均，ADE90 是每样本 ADE 的90百分位，FDE 取最后有效事件；姿态用19关节 MPJPE、每姿态相似变换对齐的 PA-MPJPE、Root Trans. 及23个非root关节 Body Geo.，位置报mm、旋转报度。Single 用第一候选；Best-5 以各样本有效步的关节误差选一条候选，再用同一候选算所有pose指针。数据建置的最近影格检查采 floor(time_s×fps)，预设fps30、误差上限0.49秒；它只是标注有效性检查，不能充作预测评分。配对有效性须用 target_mask & target_pose_mask。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **3** source procedural domains · 原文页 5
- **19,746** test forecast samples · 原文页 5
- **233,828** all forecast samples · 原文页 5

依这个顺序读

1. `README.md` ↗

   GitHub · CorrineQiu/from-where-to-how · 67386704bf

   辨认论文、Coherent4D/HIGFlow 角色、数据规模及 Ego-Exo4D 重用。

   L1–57

2. `data/README.md` ↗

   GitHub · CorrineQiu/from-where-to-how · 67386704bf

   确认事件步数、有效 target 与跨 domain 对象标签去重单位。

   L1–13

3. `data/dataset_statistics.csv` ↗

   GitHub · CorrineQiu/from-where-to-how · 67386704bf

   核对各 domain、split、takes、samples、targets 与 object labels。

   L1–5

4. `data/dataset_task_sunburst_stats.csv` ↗

   GitHub · CorrineQiu/from-where-to-how · 67386704bf

   读21个原生程序任务及其 domain / 样本统计。

   L1–22

5. `process/README.md` ↗

   GitHub · CorrineQiu/from-where-to-how · 67386704bf

   厘清五阶段建置、外置资产与 pose 附加顺序。

   L1–39

6. `process/02_shared_coordinate_construction/README.md` ↗

   GitHub · CorrineQiu/from-where-to-how · 67386704bf

   确认 F0 空间参照、5公尺缩放、pose 公尺字段与 chunk 继承关系。

   L1–40

7. `process/05_forecast_sample_generation/README.md` ↗

   GitHub · CorrineQiu/from-where-to-how · 67386704bf

   核对事件 horizon、30秒观测、history 压缩及 split 前提。

   L1–48

8. `process/05_forecast_sample_generation/build_chunks.py` ↗

   GitHub · CorrineQiu/from-where-to-how · 67386704bf

   读实际 pickle schema、非重叠事件分段、时间原点、history、padding mask 与输出 metadata。

   L31–36 · L106–137 · L151–225 · L227–261 · L267–463 · L517–533 · L571–629

9. `process/04_smpl_state_attachment/README.md` ↗
   GitHub · CorrineQiu/from-where-to-how · 67386704bf

   确认外部 WHAM/SMPL、19关节、配对遮罩、时间容差与姿态单位。

   L1–29 · L59–110

---

10. `process/04_smpl_state_attachment/attach_smpl.py` ↗
    GitHub · CorrineQiu/from-where-to-how · 67386704bf

    核对最近影格实作、F0 复用、旋转6D排列、米制姿态字段与逐 token 成功遮罩。

    L101–116 · L158–174 · L210–226 · L521–535 · L883–977 · L1054–1079 · L1194–1249 · L1264–1302 · L1309–1377

怎么接入我们的benchmark

可重用

原生 domain/task_name 统计、take/datum/chunk 身分、事件时间、F0 metadata、位置 / pose 分离遮罩与实际建置函数。

需要转换

source 记 Ego-Exo4D 派生与外部重建版本；task 保留 CSV domain/task_name，case 用 take+datum+chunk，保存30秒观测引用、事件horizon、绝对 / 相对秒与空间参照。位置范式 / 裁切、公尺pose及毫米 / 角度评分分开记；不可由裁切座标还原超界真值。

仍需补齐

需取得原始takes、确定的take-level split清单、建置后位置 / pose caches、SMPL/19关节regressor与模型依赖；补公开预测/evaluator及30张观测影格抽取对照。再验证mask、数据规模、共同座标与论文报表一致性。

P061 · Interact with me

Interact with me: Joint Egocentric Forecasting of Intent to Interact, Attitude and Social Actions

内核内容已核读 · 主来源 · 原作 · 独立页面

SocialEgoNet 是 JPL-Social 的官方分类实作；已追到人物 JSON、133点姿态图与 weighted F1/accuracy。attitude 只评有交互真值的人物，且训练程序把 test 目录兼作 validation，集成不能忽略这两个协定限制。

> **版本与身份**
>
> 固定d81ad122080ca734a866dfcf3c4bd4db60078390（2026-02-26）。train.py 的validation与test都读test/，每epoch评一次同一目录，结束后保存最后模型；不能宣称独立validation或由此推断论文实验的split。config数据路径是../JPL_Social/，与README「放于项目内」须对齐工作目录。仅读程序 / 论文，未下载Google Drive数据或加载repo内权重。
>
> 本地 arXiv:2412.16698v3（2025-05-08）第1页直接连 biantongfei/SocialEgoNet。README 列 ICME2025、同一 arXiv ID 与五位作者；上方链接标题使用 joint prediction/self-centred 字样，正式引用仍是 Joint Egocentric Forecasting of Intent to Interact, Attitude and Social Actions，属同一作品。JPL-Social 是既有 JPL-Interaction 的人物层级扩充标注，不是新拍摄的独立视频库。

领域	社交与沟通、协助、交接与陪伴
环境	JPL-Interaction 的人形观察者 / 机器人第一视角社交视频，背景与照明有变化。论文 §III 报告200段视频、16位受试者、6种场景设置、320×240与30FPS；JPL-Social 对可见人物创建290条person tracks。视频、人物tracks、姿态影格和场景数不能互换。
任务	预测 intent、attitude、action。constants 的 intent=[Interacting,Interested,Not_Interested]；attitude=[Positive,Negative,Not_Interacting]，前两者是论文的两种有效态度，2是非交互状态；action=[Handshake,Hug,Pet,Wave,Punch,Throw,Point,Gaze,Leave,No_Response]。论文添加Gaze/No_Response并以人物为标注单位，并非十种机器人可运行指令。
题数与数据	一个人物JSON描述 video_name/person_id、frame_size=[w,h]、侦测 / 交互起讫、三项class与frames；实际reader取 frames[*].{frame_id,keypoints}，keypoints=[133,3]为像素x/y及confidence。x/y转为2*(xy/[w,h]-0.5)，score保留；输出固定[30,133,3]。以frames[0].frame_id作起点，时间缺口及不足30帧以最近姿态补齐，不套confidence门槛，也不回传补帧mask。walk_frame、interact_start_frame、gaze、box与contact_class没有被此reader用作模型输入。README误写key points，实际必须是keypoints；文件 / 人物来源ID须另行保留以免只剩feature张量。

评估方式	scripts/test.py 对每项logits做softmax/argmax，汇总所有test样本后计 sklearn f1_score(average="weighted")×100 与accuracy×100。attitude先依真值!=2排除非交互人物，仍保留3个输出logits；误预测Not_Interacting仍会计错，不能依预测intent过滤。论文表II的83.15%是三项accuracy的算术平均，其分母并不相同，也不是三项同时正确率。公开测试程序没有计算latency或三项平均；论文latency另外区分姿态抽取成本。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **200** 母视频 · 原文页 3
- **290** person tracks（全部split） · 原文页 3
- **10** 交互动作类别 · 原文页 3

依这个顺序读

1. `README.md` ↗
   GitHub · biantongfei/SocialEgoNet · d81ad12208

   确认 exact paper、父数据 / 下加载口、metadata 与命令。

   L1–21 · L28–82 · L85–111

2. `scripts/constants.py` ↗
   GitHub · biantongfei/SocialEgoNet · d81ad12208

   核对三组类别顺序、133点与30FPS及各身体区域图边。

   L22–54

3. `scripts/data.py` ↗
   GitHub · biantongfei/SocialEgoNet · d81ad12208

   读人物JSON、首次侦测锚点、补帧、座标公式及attitude真值过滤。

   L11–66

4. `scripts/DataLoader.py` ↗
   GitHub · biantongfei/SocialEgoNet · d81ad12208

   确认23身体 / 68脸 / 42手部点分图，x/y/score三个node特征。

   L5–55

5. `config/test.yaml` ↗
   GitHub · biantongfei/SocialEgoNet · d81ad12208

   确认30帧、测试batch128及相对数据路径。

   L1–14

---

6. `config/train.yaml` ↗
   GitHub · biantongfei/SocialEgoNet · d81ad12208

   确认训练40epochs与相同人物串行设置。

   L1–17

---

7. `scripts/Models.py` ↗
   GitHub · biantongfei/SocialEgoNet · d81ad12208

   核对attitude仍有3个logits与chain输出，避免误当纯二分类模型。

   L6–35 · L75–95

---

8. `scripts/test.py` ↗
   GitHub · biantongfei/SocialEgoNet · d81ad12208

   核对weighted F1 / accuracy百分比、依真值排除attitude=2及完整test目录汇整。

   L19–43 · L46–69

---

9. `scripts/train.py` ↗
   GitHub · biantongfei/SocialEgoNet · d81ad12208

   核对validation/test共用目录、训练保留第三attitude类及最后权重输出。

   L28–42 · L58–91 · L107–128

怎么接入我们的benchmark

可重用

人物JSON与video/person识别、三组label字典、姿态图边、分身体部位特征及具体weighted F1 / accuracy算法。

需要转换

case以父视频+person_id+观测锚点定位，task分开intent/attitude/action，保留attitude=2的训练类与评分排除规则；保存像素原值、范式公式、confidence及补帧来源。evaluation记录每项有效样本数，合并指针明列算术平均。

仍需补齐

需取得并固定外部人物JSON及train/test清单，核对同视频 / 受试者是否跨split及augmentation来源；创建真正独立validation协定、确认首次侦测锚点与论文观测窗口一致，再做运行验证。

P062 · RLBench

RLBench: The Robot Learning Benchmark & Learning Environment

内核内容已核读 · 主来源 · 原作 · 独立页面

RLBench 以 Python Task、CoppeliaSim 场景 / 模型和 condition 对象组成任务。应沿 task 的成功条件读到 backend，而不是只看任务名称或示范档。

> **版本与身份**
>
> README 明示action mode曾有破坏性变更；本轮固定公开commit，不能混用其他版本的动作约定。

领域	居家整理与清洁、通用对象与机动作业
环境	CoppeliaSim/PyRep 任务场景与模型；任务 class 数、variation 数和独立环境数不能直接等同。
任务	Task class 绑定场景对象与 condition。open_drawer 包含 top/middle/bottom 三个 variation，并以 JointCondition 门槛0.15检查绝对关节位移。
题数与数据	示范将多视角 RGB、depth、mask 分档，并把图像从 observation 移除后保存低维数据；加载时需闭合图像与状态引用。
评估方式	各 task 注册具体 condition。ConditionSet 可累积有序条件或做同时 AND；OrConditions 做 OR。这些状态 / 过程语义要一起保留。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **1** 共用桌面scene · 原文页 4
- **100** 原版task definitions · 原文页 1
- **10** 原版meta-test tasks · 100的10% · 原文页 6

依这个顺序读

1. `README.md` ↗
   GitHub · stepjam/RLBench · 02720bba4c

   辨认套件、action API 版本与任务 / 示范入口。

   L1–55

---

2. `rlbench/tasks/open_drawer.py` ↗
   GitHub · stepjam/RLBench · 02720bba4c

   看任务变体、语言描述、关节选择及成功条件注册。

   L1–33

---

3. `rlbench/backend/conditions.py` ↗
   GitHub · stepjam/RLBench · 02720bba4c

   核对关节位移、侦测、抓握，以及有序 / 无序 condition 组合的真实逻辑。

   L1–194

---

4. `rlbench/dataset_generator.py` ↗
   GitHub · stepjam/RLBench · 02720bba4c

   看每个视角的 RGB / depth / mask 与低维 observation 如何分档保存。

   L26–66 · L104–144

怎么接入我们的benchmark

可重用

task ID、variation、场景模型、语言描述、示范与 condition 程序。

需要转换

task、variation、初态、传感及 action mode 分开存；evaluator 指向具体条件程序。原生variation可作绑定变化，不自动当添加共同任务。

仍需补齐

完整模型 / 示范资产闭合、跨来源语义对齐及统一协定下的运行验证。

P063 · Meta-World

Meta-World: A Benchmark and Evaluation for Multi-Task and Meta Reinforcement Learning

内核内容已核读 · 主来源 · 原作 · 独立页面

原作仓库已转到Farama的现行Meta-World。当前代码可以核读任务、动作和评测界面，但README已引用MetaWorld+，必须保留与2019原作协议的版本差异。

> **版本与身份**
>
> 发现现行state_space.md仍写9D且表格列18维，但程序_get_obs明确组成39维；字段标准化以固定程序与测试查核，不能只抄说明页。
>
> 旧入口rlworkgroup/metaworld的已保存GitHub metadata回应指向Farama-Foundation/Metaworld，按仓库别名保留，不另外算成未读的第二个仓库。

领域	居家整理与清洁、餐饮与烹饪、工艺与修缮、装配与生产作业、休闲与运动、通用对象与机动作业
环境	Sawyer/MuJoCo任务环境；source task/env ID不等于独立家居场景。
任务	MT与ML清单保留原生任务和train/test成员；现行v3任务与2019版不可仅删掉版本后缀就宣称等价。
题数与数据	四维动作是xyz增量控制加gripper；set_xyz_action另乘action_scale。基础观测为当前18维、前一观测18维与目标3维，goal可被屏蔽；benchmark还可加task ID。
评估方式	evaluation.py在成功时终止episode，用info.success按任务计成功率，再对任务平均。meta评测另外包含适应步数、适应episode和evaluation episode预算。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **50** 操作task types · 原文页 1, 4
- **2,500** MT50训练参数化instances · 原文页 6
- **5** ML10 / ML45保留test任务 · 原文页 7

依这个顺序读

1. README.md ↗
   GitHub · Farama-Foundation/Metaworld · c0dafaf155

   核对现行论文链接、Gymnasium API及MT/ML任务分割。

   L1–55

---

2. metaworld/env_dict.py ↗
   GitHub · Farama-Foundation/Metaworld · c0dafaf155

   任务名称如何映到class及train/test清单。

   L80–110

---

3. metaworld/sawyer_xyz_env.py ↗
   GitHub · Farama-Foundation/Metaworld · c0dafaf155

   以程序确认动作缩放、frame stack与39维基础观测。

   L320–336 · L475–527

---

4. metaworld/envs/sawyer_drawer_open_v3.py ↗
   GitHub · Farama-Foundation/Metaworld · c0dafaf155

   核对info.success与不同reward版本，避免用reward替代成功。

   L66–88 · L115–188

---

5. metaworld/evaluation.py ↗
   GitHub · Farama-Foundation/Metaworld · c0dafaf155

   核对每任务episode数、成功终止、平均方式及meta适应预算。

   L48–103 · L106–169

怎么接入我们的benchmark

可重用

版本化task IDs、train/test清单、reset参数、info.success与正式evaluation流程。

需要转换

记下v3、reward版本、goal可见性、action_scale、观测stack和适应预算；共同ActionSpec保留原生4维与转换规则，不强塞成7维。

仍需补齐

2019原作相符release的独立重现、跨来源task/scene对齐及统一case清单。

P064 · LIBERO

LIBERO: Benchmarking Knowledge Transfer for Lifelong Robot Learning

内核内容已核读 · 主来源 · 原作 · 独立页面

LIBERO最清楚的入口是benchmark注册表：每个Task把语言、BDDL、init-state档与示范路径连起来。成功判定要沿wrapper找到实际problem子类；base class的False是占位。

> **版本与身份**
>
> 不能只读bddl_base_domain._check_success就断言没有判分器；必须追TASK_MAPPING到实际problem子类。

领域	居家整理与清洁
环境	problem类型、MuJoCo场景与对象资产由BDDL和wrapper连接；suite或task数不能直接当layout数。
任务	Task含name/language/problem/problem_folder/bddl_file/init_states_file。原作100-task集合拆成90/10；程序有五个suite清单但不可重算同一组任务。
题数与数据	HDF5示范含多视角RGB/可选depth、proprioception、action/state/reward/done；另存模型XML和初态。评测需固定.pruned_init等来源。
评估方式	具体problem子类以parsed goal predicates合取检查成功；evaluation脚本固定步数和checkpoint，保存loss与success_rate两种不同指针。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **130** task definitions · 原文页 1, 2, 5
- **4** task suites · 原文页 5
- **90** LIBERO100内pretraining tasks · 原文页 5
- **10** LIBERO100内long tasks · 原文页 5

依这个顺序读

1. `README.md` ↗

   GitHub · Lifelong-Robot-Learning/LIBERO · 8f1084e313

   核对130任务、suite划分与原始用途。

   L15–55

---

2. `libero/libero/benchmark/__init__.py` ↗

   GitHub · Lifelong-Robot-Learning/LIBERO · 8f1084e313

   找Task字段、BDDL、示范和初态引用；90/10不重复加成。

   L35–77 · L108–160

---

3. `libero/libero/envs/env_wrapper.py` ↗

   GitHub · Lifelong-Robot-Learning/LIBERO · 8f1084e313

   看控制/相机约定、TASK_MAPPING和初态恢复。

   L25–104 · L118–145

---

4. `libero/libero/envs/problems/libero_tabletop_manipulation.py` ↗

   GitHub · Lifelong-Robot-Learning/LIBERO · 8f1084e313

   以具体problem确认goal_state经predicate逐一判定。

   L135–143

---

5. `scripts/create_dataset.py` ↗

   GitHub · Lifelong-Robot-Learning/LIBERO · 8f1084e313

   核对HDF5的传感、actions、states、rewards、dones和init_state。

   L20–60 · L238–278

---

6. `libero/lifelong/evaluate.py` ↗

   GitHub · Lifelong-Robot-Learning/LIBERO · 8f1084e313

   固定task/checkpoint/seed，区分行为模仿loss与rollout success。

   L72–114 · L261–301

怎么接入我们的benchmark

可重用

Task注册、BDDL及init states、HDF5示范和具体problem evaluator。

需要转换

保持task、scene/assets、initial state、case protocol分离；将原生goal program与predicate实作一起引用，HDF5映到typed episode数据。

仍需补齐

跨来源等价判定、素材闭合、controller/相机一致性与本库case验证。

P065 · CALVIN

CALVIN: A Benchmark for Language-Conditioned Policy Learning for Long-Horizon Robot Manipulation Tasks

内核内容已核读 · 主来源 · 原作 · 独立页面

CALVIN 要一起固定 benchmark 主仓库与 calvin_env 子模块。数据是按时间步保存的多传感器 / 动作 / 状态，评测则是连续指令链；不能把训练窗口当成正式评测题。

> **版本与身份**
>
> mees/calvin在fa03f01...的Git tree明确pin calvin_env到1431a46...，与calvin_env目前main 797142c...不同。要重现CALVIN就使用gitlink，不直接替换成依赖仓库的最新main。

领域	居家整理与清洁、通用对象与机动作业
环境	A–D场景与机体 / 传感配置由calvin_env提供；D_eval是评测设置，不能直接另算独立layout。
任务	task函数以start_info/end_info变化定义；语言可对应相同原生task。正式long-horizon评测是从同一初态连续运行指令，失败就停止prefix。
题数与数据	每步NumPy字典包含rgb/depth/tactile、actions、rel_actions、robot_obs、scene_obs；语言档另外保存ann/task/embedding及起讫索引。scene_obs是评分/状态数据，README明示原作不供政策使用。
评估方式	rollout用原作task oracle比对起终info；evaluate_sequence保持环境状态延续，子任务失败即回传成功prefix长度。count_success计至少完成1至5项的比例。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **4** 桌面配置 · 原文页 3
- **34** 原子tasks · 原文页 3, 5
- **1,000** 5步instruction chains · 原文页 5
- **340** 单步评测rollouts / 一设置 · 34×10 · 原文页 5

依这个顺序读

1. `README.md` ↗

   GitHub · mees/calvin · fa03f01f19

   核对原作、数据分割、相机 / 触觉和相对 / 绝对动作配置。

   L1–75

---

2. `dataset/README.md` ↗

   GitHub · mees/calvin · fa03f01f19

   读取具体NPZ字段、动作缩放、状态可见范围和语言索引。

   L1–134

---

3. `calvin_models/calvin_agent/datasets/disk_dataset.py` ↗

   GitHub · mees/calvin · fa03f01f19

   确认连续时间步、语言片段和训练窗口的组成。

   L71–130

---

4. `calvin_models/calvin_agent/evaluation/evaluate_policy.py` ↗

   GitHub · mees/calvin · fa03f01f19

   确认固定初态、连续子任务、失败中止及原作task oracle。

   L79–179

---

5. `calvin_models/calvin_agent/evaluation/utils.py` ↗

   GitHub · mees/calvin · fa03f01f19

   确认至少连续成功1至5项的prefix成功率。

   L77–84

---

6. `calvin_env/envs/tasks.py` ↗

   GitHub · mees/calvin_env · 1431a46bd3

   以主仓库实际pin的子模块核对起终状态条件和抽屉位移判定。

   L10–33 · L245–255

怎么接入我们的benchmark

可重用

NPZ字段、语言片段、场景定义、固定串行 / 初态和task oracle。

需要转换

保留7维absolute与relative两种动作的区别、世界座标和50/20缩放；训练窗口、指令链case、子任务运行各自识别。依协定分开政策输入和评分状态。

仍需补齐

完整素材闭合、共同跨来源任务对齐及本库协定下的运行验证。

P066 · ManiSkill

ManiSkill: Generalizable Manipulation Skill Benchmark with Large-Scale Demonstrations

内核内容已核读 · 主来源 · 原作 · 独立页面

2021原作应读haosulab/ManiSkill-Legacy，不能用现在ManiSkill3的main代替。其四种基本任务会依PartNet模型与目标link产生更多环境ID，这些不是全部新的工作种类。

> **版本与身份**
>
> 来源版本固定为Legacy commit58964d08…；与ManiSkill2 v0.5.3和ManiSkill3分别保存，不混用数量及API。

领域	居家整理与清洁
环境	SAPIEN场景绑定PartNet-Mobility模型；model/link ID与level控制资产及初态变化。
任务	OpenCabinetDoor、OpenCabinetDrawer、PushChair、MoveBucket四种原生基本任务，再衍生模型 / link设置。
题数与数据	观测可为点云 / RGBD / 状态；示范及资产外部取得，模型分割与初态在YAML / level设置。读取时需保留观测模式和模型身份。
评估方式	具体task先产生条件旗标，base_env要求连续保持0.5秒；Evaluator依episode终止时eval_info计比例，不能以某一帧接近目标替代。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **4** skills · 原文页 4, 5
- **162** 按4类相加的资产条目 · 52+35+36+39，非跨类去重 · 原文页 4
- **36,000** 成功demo trajectories · 约数 · 原文页 6

依这个顺序读

1. `README.md` ↗

   GitHub · haosulab/ManiSkill-Legacy · 58964d08b4

   确认2021身份、4种任务、162模型及原生系统。

   L1–75

---

2. `mani_skill/env/__init__.py` ↗

   GitHub · haosulab/ManiSkill-Legacy · 58964d08b4

   区分基本任务ID、model绑定及target-link绑定。

   L1–118

---

3. `mani_skill/env/push_chair.py` ↗

   GitHub · haosulab/ManiSkill-Legacy · 58964d08b4

   看具体成功条件：接近目标、姿态站立和静止。

   L267–277

---

4. `mani_skill/env/base_env.py` ↗

   GitHub · haosulab/ManiSkill-Legacy · 58964d08b4

   确认条件持续0.5秒才算通过，以及成功 / 时间上限终止的差别。

   L178–181 · L524–571

---

5. `mani_skill/eval/evaluator.py` ↗

   GitHub · haosulab/ManiSkill-Legacy · 58964d08b4

   按指定level运行，收集最终eval_info并以episode数平均。

   L1–59

---

6. `mani_skill/assets/config_files/chair_models_custom_split_example.yml` ↗

   GitHub · haosulab/ManiSkill-Legacy · 58964d08b4

   模型ID、位姿和初始关节设置如何构成具体初态。

   L1–28

怎么接入我们的benchmark

可重用

四种任务定义、model/link registry、level、初态和持续条件evaluator。

需要转换

基本task、模型绑定、目标link和level分层存；保留成功持续时间、观测模式和native done/time-limit约定。

仍需补齐

全部资产 / 示范闭合、跨世代移植差异和共同case协定验证。

P067 · ManiSkill2

ManiSkill2: A Unified Benchmark for Generalizable Manipulation Skills

内核内容已核读 · 主来源 · 原作 · 独立页面

原ManiSkill2网址目前只是搬家说明；实作应固定mani-skill/ManiSkill的v0.5.3。它把episode设置、HDF5轨迹、JSON信息和原生success评测分开保存。 2026-10-11 另补读 ManiSkill2-Learn 的 BC 数据与单程序评测入口，与主 benchmark 的 v0.5.3 契约分开记录。

> **版本与身份**
>
> v0.5.3解析到commit493be361...；最新main是ManiSkill3，因此每个来源链接都带ref/commit。 Learn 固定 e9860aff595da3ad34829d62c923be0b50001427，与主 benchmark v0.5.3 的提交分开；其 README 指明 0.5.0 起改 Gymnasium，较旧环境用 ms2_gym 分支（本次未核读该分支）。README 另说早期 checkpoint / 环境 0.3、0.4 的 RGBD camera order 不同，须保留实际 wrapper / 观测版本，不把 Learn、ManiSkill2022 challenge 或 ManiSkill3 当成同一版主 benchmark。

领域	居家整理与清洁、装配与生产作业、通用对象与机动作业
环境	SAPIEN任务依env_id、asset模型、reset_kwargs和control_mode创建；柔体另外依赖原作Warp版本。
任务	注册的env/task与原作家族保留其单位；不是每个asset模型、随机seed都增加一个基础任务。
题数与数据	HDF5 traj_id配合JSON episodes/env_info；reset初态使观测 / env_states比actions多一笔。depth以uint16保存，原作写入前乘2^10，必须保存这个尺度。 补读 Learn：tools/convert_state.py 依 HDF5 traj 后缀寻找 JSON episodes 的 episode_id/reset_kwargs，逐 state 重建刚体观测，或由 env_init_state 重播动作取得柔体观测；控制模式须先在主 ManiSkill2 转好。输出为 T 笔 obs/actions/rewards，dones 直接来自原 success，episode_dones 仅尾笔为真，next_obs 要加 --with-next。输出 traj_{cnt} 重新编号，须另存原 episode 映射。BC 的 buffer_filenames 范例仍是 SOME_DEMO_FILE；ReplayMemory→FileCacheWorker 实际读 HDF5 groups，num_samples 限制每档前几条排序轨迹，-1 才是全部，不能称为随机 split。

评估方式	Evaluator按episode_cfg的reset_kwargs重建，终止时读info.success等scalar；PickCube示例要求对象放到目标且robot静止。reward、terminated、truncated不互相替代。 补读 Learn 的独立路径：run_rl.py --evaluation / --resume-from→build_evaluation→Evaluation.run；单程序策略预设 mode=eval，BC 范例 num=10、num_procs=1 只是设置值。live step_dict 把 terminated 命名为 dones，以 terminated OR truncated 判 episode_dones；Evaluation 在终止那一步把 dones 记为 finish，statistics.csv 存 length/reward/finish，显示的是 mean(finish) 的「Success or Early Stop Rate」。此 caller 并未直接取 info.success；只有绑定环境的终止契约相符时才能解作成功率。only_save_success_traj 筛存盘、不缩减 statistics 的所有已评 trial 分母；与前述主 benchmark Evaluator 的 info.success 分开。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **20** task families · 原文页 1, 3, 4
- **6** soft-body families · 原文页 3
- **2,000** object models · 超过 · 原文页 1
- **4,000,000** demonstration frames · 超过 · 原文页 1

依这个顺序读

1. `README.md` ↗

   GitHub · haosulab/ManiSkill2 · 63e0e7db63

   确认搬家与原作指定的v0.5.3版本。

   L1–6

2. `README.md` ↗

   GitHub · mani-skill/ManiSkill · 493be36121

   确认ManiSkill2、原生任务家族、刚体 / 柔体资产与控制模式。

   L1–85

3. `mani_skill2/envs/pick_and_place/pick_cube.py` ↗

   GitHub · mani-skill/ManiSkill · 493be36121

   看观测模式差异和放置 / robot-static合成success。

   L54–83 · L141–150

4. `mani_skill2/utils/wrappers/record.py` ↗

   GitHub · mani-skill/ManiSkill · 493be36121

   读episode identity/reset/control、T+1观测、T动作与深度编码。

   L146–186 · L222–325

---

5. `mani_skill2/evaluation/evaluator.py` ↗

   GitHub · mani-skill/ManiSkill · 493be36121

   按episode_cfg/reset_kwargs运行，检查episode ID唯一性与success输出。

   L45–91

---

6. `README.md` ↗

   GitHub · haosulab/ManiSkill2-Learn · e9860aff59

   baseline 身份、Gymnasium / camera-order 版本差异、控制模式先转换与示范 / 评测入口。

   L1–23 · L174–195 · L246–268 · L292–324 · L336–363

---

7. `configs/brl/bc/pointnet.py` ↗

   GitHub · haosulab/ManiSkill2-Learn · e9860aff59

   BC 示例的 replay 字段 / 占位数据路径与 num=10、单程序评测；不是 benchmark 固定 trial 数。

   L1–60

---

8. `tools/convert_state.py` ↗

   GitHub · haosulab/ManiSkill2-Learn · e9860aff59

   HDF5+JSON reset 契约、刚体 state / 柔体 action 路径、输出 dones / episode_dones、可选 next_obs 与轨迹重编号。

   L39–142 · L149–185 · L196–248

---

9. `maniskill2_learn/env/replay_buffer.py` ↗

   GitHub · haosulab/ManiSkill2-Learn · e9860aff59

   由 buffer_filenames 建构 ReplayMemory/FileCache；容量与 num_samples 如何控制读取。

   L30–145

---

10. `maniskill2_learn/utils/file/cache_utils.py` ↗

    GitHub · haosulab/ManiSkill2-Learn · e9860aff59

    追到实际 HDF5 group reader、逐档限制 / 键排序，以及布尔字段和 episode_dones 的读取处理。

    L77–128 · L156–181 · L215–256 · L289–385 · L447–480

---

11. `maniskill2_learn/apis/run_rl.py` ↗

    GitHub · haosulab/ManiSkill2-Learn · e9860aff59

    checkpoint / evaluation CLI 到 evaluator.run、结果输出与 evaluation env_cfg / seed。

    L35–79 · L265–268 · L293–315 · L351–395

---

12. `maniskill2_learn/env/builder.py` ↗

    GitHub · haosulab/ManiSkill2-Learn · e9860aff59

    Evaluation 的建构；num_procs>1 会选 BatchEvaluation，与本次单程序示例分清。

    L18–27

---

13. `maniskill2_learn/env/env_utils.py` ↗

    GitHub · haosulab/ManiSkill2-Learn · e9860aff59

    实际 gym.make、观测 wrapper、时间上限和 obs_frame 默认值。

    L96–186

---

14. `maniskill2_learn/env/wrappers.py` ↗

    GitHub · haosulab/ManiSkill2-Learn · e9860aff59

    Gymnasium terminated/truncated 原样传递及 ignore_dones 可抑制 terminated；不自行改写为 info.success。

    L61–107 · L190–239 · L683–695

---

15. `maniskill2_learn/env/vec_env.py` ↗

    GitHub · haosulab/ManiSkill2-Learn · e9860aff59

    live step_dict 的 dones=terminated、episode_dones=terminated OR truncated。

    L149–166

---

16. `maniskill2_learn/env/evaluation.py` ↗

    GitHub · haosulab/ManiSkill2-Learn · e9860aff59

    单程序实际评测循环、策略采样模式、最后一步 finish、level 数限制和 statistics.csv 分母。

    L34–46 · L252–300 · L328–483

怎么接入我们的benchmark

可重用

env/task IDs、episode ID、reset kwargs、control mode、HDF5/JSON及原生success。 可另重用 baseline 的 HDF5 视觉转换、ReplayMemory 输入及 length/reward/finish 原生报表。

需要转换

原始T+1观测与T个transition保留对齐；深度尺度、obs mode、state、success、时间上限分栏，不用共通dtype猜单位。 另保存 Learn commit、checkpoint、实际 env_cfg、seed、num/eval_levels、sample_mode 与输入 / 输出 trajectory ID 映射；原 success、示范 dones、live terminated/truncated/finish 分栏。FileCache 的 purify_items 可补 worker_indices、把 dones 转 bool，并将读取片段末项 episode_dones 设真，不能依训练 buffer 片段另增物理 episode。

仍需补齐

完整资产 / 示范闭合、共同split血缘与本库eval adapter验证。 Learn 的示范 / checkpoint / 资产未取得或运行；需替换示例占位路径、保存完整 reset / split 血缘，验证控制模式、观测处理与主 benchmark 的 success / 终止关系。converter 的 obs_frame 预设 base，而 make_gym_env 预设 world，数据生成 / 训练 / 评测都需显式对齐。

P068 · ManiSkill3

ManiSkill3: GPU Parallelized Robotics Simulation and Rendering for Generalizable Embodied AI

内核内容已核读 · 主来源 · 原作 · 独立页面

ManiSkill3的核心是矢量化场景 / 任务API，数据以HDF5+JSON链接episode、env kwargs和观测。读取训练loader时还要检查它是否删掉最终观测或改写label。

> **版本与身份**
>
> 固定commit62ff3a58…。发现trajectory/dataset.py的device分支把success指定成terminated、fail指定成truncated；本库导入应保留原始label并针对此分支验证，不能盲用loader输出。本轮为静态核读，未运行重现此问题。

领域	居家整理与清洁、装配与生产作业、通用对象与机动作业
环境	SAPIEN矢量化环境可变机体、scene与对象；环境ID、asset场景与并行env数不是同一个数量。
任务	具体task子类提供evaluate，基底scene evaluate可能是空字典。PickCube成功为对象到位且机器人静止；is_grasped则另列。
题数与数据	JSON记episodes/env_info/env_id/env_kwargs；HDF5保存traj_ID和多模态obs/actions/terminated/truncated，reward/success/fail可选。训练Dataset会裁掉最后一笔obs，不适合作为原始保存格式。
评估方式	BaseEnv将success/fail合成terminated，time limit另由外层处理。baseline可输出回报、成功和失败；必须保留各自定义及矢量化episode边界。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **12** 技术task categories · 原文页 3
- **20** robot models · 超过 · 原文页 6
- **4** SIMPLER转接环境 · 原文页 4

依这个顺序读

1. `README.md` ↗
   GitHub · mani-skill/ManiSkill · 62ff3a5896

   核对RSS2025论文、版本、机体与运行平台范围。

   L1–94

---

2. `mani_skill/envs/tasks/tabletop/pick_cube.py` ↗
   GitHub · mani-skill/ManiSkill · 62ff3a5896

   读实际extra observation与success组合。

   L132–159

---

3. `mani_skill/envs/sapien_env.py` ↗
   GitHub · mani-skill/ManiSkill · 62ff3a5896

   追get_info/evaluate及success/fail/terminated的关系。

   L1050–1079 · L1155–1165

---

4. `mani_skill/trajectory/dataset.py` ↗
   GitHub · mani-skill/ManiSkill · 62ff3a5896

   核对HDF5/JSON、动作与观测长度、label及device分支。

   L13–20 · L36–154

---

5. `examples/baselines/tdmpc2/evaluate.py` ↗
   GitHub · mani-skill/ManiSkill · 62ff3a5896

   核对实际baseline的checkpoint、eval episode和成功 / 失败 / 回报输出。

   L21–61 · L82–122

怎么接入我们的benchmark

可重用

Task/evaluate、JSON episode metadata、HDF5数据与原生控制 / 观测模式。

需要转换

以源文件创建可逆episode view，再提供训练 / 评测查看；保留T+1末态、信息白名单、control mode、机体与逐episode指针。

仍需补齐

完整素材、跨版本任务对齐、GPU/CPU实测与adapter回读一致性验证。

P069 · robosuite

robosuite: A Modular Simulation Framework and Benchmark for Robot Learning

内核内容已核读 · 主来源 · 原作 · 独立页面

robosuite 提供可配置任务与状态判定；论文的 SAC 图表来自另一个 v1.0 benchmark 仓库。已核读 Lift、示范串行化及 return 统计链，不能把现行 v1.5 环境直接当原实验版本。

> **版本与身份**
>
> 主程序固定5ce6643f3092639d08f7b0f90ed1c6a84f50552c；SAC固定b229f7442f3590dd0e0cad21dc6ae52f410a34bc，依赖rlkit b7f97b2463df1c5a1ecd2d293cfcc7a4971dd0ab。SAC requirements 只写robosuite>=1.0.1，却使用mujoco-py/Gym旧API。notebook第89–100行把Wipe与Door都写成NutAssemblyRound；Door示例variant为2000 epochs，论文 / 文件为500。加载variant后，乱数初始化仍取CLI args.seed，不能只相信JSON seed。
>
> 对应 arXiv:2009.12293v3（2025-01-18），题名与作者以固定论文首页为准；虽收录年份为2020，本 PDF 明述 v1.5。PDF 第15页直接连到 robosuite-benchmark；主仓库 README 指回同一论文。

领域	居家整理与清洁、装配与生产作业、通用对象与机动作业
环境	MuJoCo 的 robot＋arena＋objects 组合。已读 Lift 使用0.8×0.8公尺桌面，桌高0.8公尺；cube 的 xy 初态在桌面原点附近各±0.03公尺抽样。模型数、任务数与初始化 case 数分开。
任务	论文九个标准环境；实验细化到 PickPlaceCan、NutAssemblyRound 等子型，双臂设置另存。Lift 的具体 checker 只要求 cube 中心 z 大于桌面 z＋0.04公尺；不额外要求持续抓握或停留。其余八个 checker 未逐一核读。
题数与数据	原生 observation 是具名传感 dict；Lift 有 cube_pos、公尺制相对位置与 xyzw cube_quat，传感率跟 control_freq。HDF5 data/demo_N 存 states、actions 与 model_file XML；data attrs 存 env、env_info、repository_version、date/time。写入前删掉最后一笔 state 以对齐 actions，只收成功示范；此格式本身不含 RGB。20 Hz 是已读基线设置，动作维度 / 缩放须保留各 controller 设置。
评估方式	基线链为 train→experiment→MdpPathCollector→CustomBatchRLAlgorithm._log_stats→get_custom_generic_path_information→eval_util。Returns 是每回合 reward 总和，ExplReturns 截至 exploration horizon；统计函数的 reward_scale 参数没有运行除法，缩放在环境端。例示 run 每epoch收2500步、每回合500步，通常为5回合；论文另对5个训练 seeds 报均值与标准差。现行 base.done 是 horizon 条件且 info 为空，不能当 task success。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **9** 标准benchmark环境 · 原文页 13, 14, 15, 16
- **10** robot models · 原文页 7

依这个顺序读

1. `README.md` ↗

   GitHub · ARISE-Initiative/robosuite · 5ce6643f30

   确认 v1.5 与论文链接。

   L5–22

---

2. `docs/algorithms/benchmarking.md` ↗

   GitHub · ARISE-Initiative/robosuite · 5ce6643f30

   辨识基线仍标为 v1.0，报500步 return 与5个训练 seeds。

   L5–13

---

3. `README.md` ↗

   GitHub · ARISE-Initiative/robosuite-benchmark · b229f7442f

   确认 SAC 仓库角色及 rlkit 固定依赖。

   L1–5 · L23–29

---

4. `requirements.txt` ↗

   GitHub · ARISE-Initiative/robosuite-benchmark · b229f7442f

   核对旧 mujoco-py / Gym 与未锁上限的 robosuite。

   L1–6

---

5. `notebooks/create_benchmark_environments.ipynb` ↗

   GitHub · ARISE-Initiative/robosuite-benchmark · b229f7442f

   九任务实验子型、共同设置及两处错误 env_name。

   L7–19 · L36–50 · L75–125

---

6. `robosuite/environments/manipulation/lift.py` ↗

   GitHub · ARISE-Initiative/robosuite · 5ce6643f30

   实际初态、对象传感、reward 与对象中心高于桌面4公分的判定。

   L145–193 · L224–273 · L275–344 · L356–415 · L433–444

---

7. `robosuite/environments/base.py` ↗

   GitHub · ARISE-Initiative/robosuite · 5ce6643f30

   step→reward→task checker；done 仅反映 horizon。

   L429–465 · L467–548

---

8. `robosuite/scripts/collect_human_demonstrations.py` ↗

   GitHub · ARISE-Initiative/robosuite · 5ce6643f30

   HDF5 写入字段、仅保存成功轨迹及 state/action 对齐。

   L148–207

---

9. `robosuite/scripts/playback_demonstrations_from_hdf5.py` ↗

   GitHub · ARISE-Initiative/robosuite · 5ce6643f30

   以 env_info、模型 XML、states/actions 还原；分开状态重播与动作重播。

   L41–108

---

10. `scripts/train.py` ↗

    GitHub · ARISE-Initiative/robosuite-benchmark · b229f7442f

    variant 加载与实际乱数 seed 来源。

    L51–104 · L107–113

---

11. `util/rlkit_utils.py` ↗

    GitHub · ARISE-Initiative/robosuite-benchmark · b229f7442f

    建环境、确定性 SAC policy、collector 与统计入口。

    L31–62 · L90–106 · L139–163

---

12. `util/rlkit_custom.py` ↗

    GitHub · ARISE-Initiative/robosuite-benchmark · b229f7442f

    采样预算及 Returns / ExplReturns 的具体加总。

    L199–217 · L275–290 · L312–374

---

13. `rlkit/samplers/data_collector/path_collector.py` ↗

    GitHub · rail-berkeley/rlkit · b7f97b2463

    检查依步数收集完整 episode 的逻辑。

    L29–59

---

14. `rlkit/core/eval_util.py` ↗

    GitHub · rail-berkeley/rlkit · b7f97b2463

    return 平均、标准差与极值的真正实作。

    L65–113

---

15. `runs/Door-Panda-OSC-POSE-SEED17/Door_Panda_OSC_POSE_SEED17_2020_09_13_00_26_44_0000--s-0/variant.json` ↗

    GitHub · ARISE-Initiative/robosuite-benchmark · b229f7442f

    具体 run 的2000 epochs、2500 eval steps、20 Hz与seed17。

    L1–35 · L49–61

怎么接入我们的benchmark

可重用

任务 class、版本化 controller/env 设置、初态抽样、HDF5 模型 / 状态与具体 checker，以及原生 return 统计。

需要转换

source 保存论文v3与两仓库commit；environment 保存robot/arena；task 保存子型；case 保存seed、初态、horizon/control_freq；evaluator 分列二元checker、shaped reward、episode return。模型XML与资产引用需闭合。

仍需补齐

原实验所用 robosuite 精确commit仍未锁定；尚需其余任务checker、控制器动作约定及资产 / 重播验证，不能宣称已重现原图。

P070 · RoboCasa

RoboCasa: Large-Scale Simulation of Everyday Tasks for Generalist Robots

内核内容已核读 · 主来源 · 原作 · 独立页面

2024 RoboCasa 的数据界面可由官方 v0.2 tag 核读：25项 single-stage 数据注册、5项 multi-stage 数据注册、HDF5 重播与具体几何 checker。这些数据入口不是论文100项任务的完整清单；现行 main 已转为 RoboCasa365。

> **版本与身份**
>
> v0.2固定756598a5be52e052339bb2d957426e39015c2afb；目前main固定456174f62b89b8fca99eaaf33949c29fec9cfc2a，属P071。不可把v0.2的0-based layout/style、PnPCounterToCab、HDF5 env_args与365的1-based ID、PickPlaceCounterToCabinet、LeRobot格式按名称直接合并。旧版仍要求robosuite master并留有旧controller入口，需要额外锁定兼容版本。
>
> 对应 arXiv:2406.02523v1（2024-06-04）及八位作者的 RSS 2024 论文。v0.2 README 直接列此题名 / 作者并连原论文；v0.2 是同一作品的后续维护版，未宣称其commit就是投稿时程序。

领域	居家整理与清洁、餐饮与烹饪
环境	原论文10个floor plans×12个styles＝120种厨房组合；v0.2 scene_registry 的layout ID为0–9、style为0–11，分别解到YAML。fixtures包括柜子、台面、家电；一个layout的材质变化不另算平面配置。
任务	论文100项＝25 atomic＋75 composite。已读PnPCounterToCab把对象从台面放入柜内；get_ep_meta.lang插入抽样对象名称，_get_obj_cfgs给name/obj_groups/graspable/placement及两个干扰物。数据registry的5个composite入口只涵盖ArrangeVegetables、MicrowaveThawing、RestockPantry、PreSoakPan、PrepareCoffee，不能据此说其余任务不存在。
题数与数据	registry以human_path、mg_path、horizon及download_links连接v0.1数据；human_raw读demo.hdf5，human_im / mg_im分别挑选带图像 / 生成材质的文件，NavigateKitchen没有mg_path。HDF5 data.attrs.env_args提供env_name/type/env_kwargs；data/demo_N内含states、actions或actions_abs、obs/<camera>_image，attrs含model_file与ep_meta。ep_meta、XML、资产与初态需一起还原，frame index、控制频率与视频抽帧分开记。

评估方式	已闭合run_random_rollouts→PnPCounterToCab._check_success→obj_inside_of AND gripper_obj_far。前者检查对象8个bbox角点对fixture内部3轴的投影，后者要求eef与对象中心距离>0.25公尺。obj_inside_of的0.05加在未范式轴矢量的内积上，不能直接标为5公分容许误差。create_eval_env固定(1,1)/(2,2)/(4,4)/(6,9)/(7,10)，obj_instance_split=B。论文每task50 trials；这里main只是3回合×100步随机动作示例，不是正式BC-Transformer评测预算。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **10** floor plans · 原文页 4
- **120** layout-style scenes · 原文页 4
- **100** tasks · 原文页 5
- **75** composite tasks · 原文页 5
- **100,000** generated trajectories · 原文页 6

依这个顺序读

1. `README.md` ↗

   GitHub · robocasa/robocasa · 756598a5be

   确认2024作品与后续v0.2 / robosuite v1.5依赖。

   L1–29 · L90–98

2. `robocasa/models/scenes/scene_registry.py` ↗

   GitHub · robocasa/robocasa · 756598a5be

   10种layout、12种style各有独立ID与YAML引用。

   L7–62 · L65–118

3. `robocasa/utils/dataset_registry.py` ↗

   GitHub · robocasa/robocasa · 756598a5be

   逐项核读25＋5数据入口、horizon、v0.1数据路径、raw/image/MimicGen选择。

   L1–354

4. `robocasa/environments/kitchen/single_stage/kitchen_pnp.py` ↗
   GitHub · robocasa/robocasa · 756598a5be

   PnPCounterToCab的指令、fixtures、目标 / 干扰物、初始开门及成功条件。

   L24–139

---

5. `robocasa/utils/object_utils.py` ↗
   GitHub · robocasa/robocasa · 756598a5be

   从checker追到bounding-box投影与gripper距离阈值。

   L12–60 · L349–356

---

6. `robocasa/scripts/playback_dataset.py` ↗
   GitHub · robocasa/robocasa · 756598a5be

   HDF5 reader与模型、ep_meta、states、actions还原。

   L133–191 · L214–272 · L378–395

---

7. `robocasa/utils/eval_utils.py` ↗
   GitHub · robocasa/robocasa · 756598a5be

   五个固定场景组合、B对象split与成功时计数的参考loop。

   L16–59 · L62–103

---

8. `README.md` ↗
   GitHub · robocasa/robocasa · 456174f62b

   确认目前main承载365版，避免把新版本规模回填2024论文。

   L5–22 · L142–150

怎么接入我们的benchmark

可重用

layout/style YAML引用、原生task class、对象抽样与语言模板、v0.1 HDF5数据源、task checker。

需要转换

source固定论文v1与程序v0.2；environment分layout/style/asset；task保留PnP等原生ID；case记对象split、场景pair、初态与控制设置；evaluator分开bool成功、step horizon及trial数。raw、rendered、MimicGen数据保留派生关系。

仍需补齐

完整75 composite与已公开数据入口的逐项对应、原始2024程序 / robosuite精确版本、正式policy runner设置与50 trials seed清单，以及HDF5 / 资产闭合验证。

P071 · RoboCasa365

RoboCasa365: A Large-Scale Simulation Framework for Training and Benchmarking Generalist Robots

内核内容已核读 · 主来源 · 原作 · 独立页面

RoboCasa365 应从 TASK_SET_REGISTRY、split 建环境、LeRobot extras 和具体 task checker 读起。现进程式的 all_tasks 来自数据registry而非365项完整任务名册；论文与后续文件的trial数、horizon也已不同。

> **版本与身份**
>
> 主仓库同时残留旧eval_utils的PandaMobile/B split；365应沿env_utils＋Gym读取。Gym预设split="test"，create_env只接受None/all/pretrain/target，因此调用时需明设split。LeRobot playback拒绝filter_key；--use_abs_actions没有进入use_actions分支，而底层get_episode_actions(abs_actions=True)也明确未实作。README要求robosuite master，LeRobot与policy runner版本尚未固定；本次没有宣称运行兼容。
>
> 对应 arXiv:2603.04356v1（2026-03-04 / ICLR 2026），四位作者及题名与README的RoboCasa365引用一致。与P070共用官方仓库，但这份笔记固定365时代main：456174f62b89b8fca99eaaf33949c29fec9cfc2a。

领域	居家整理与清洁、餐饮与烹饪
环境	pretrain由layout 11–60与style 11–60交叉组成2500组；target只用(1,1)…(10,10)十组，不是10×10。create_env同时切换obj_instance_split。Kitchen会再排除任务不支持的layout/style；2500不能保证每task都有2500个有效场景。
任务	论文365＝65 atomic＋300 composite；target50明列18 atomic-seen、16 composite-seen、16 composite-unseen。固定registry经AST计数为65 atomic＋252 composite＝317个key，all_tasks直接串接这两表；pretrain300与target50联集316，另外一个key是PlaceOnDishRack。这是数据 / 评测入口的覆盖差异，不以317覆盖论文365，也不推论未列者没有环境实作。
题数与数据	get_ds_meta输出path/horizon/filter_key/task/split/source；human预设pretrain100、target500 demos，MimicGen一般10000但OpenCabinet特例5000。缺folder回None，soup会略过。LeRobot读data/*/episode_NNNNNN.parquet的action，按meta/modality.json重排；重播另需extras/dataset_meta.json的env_args，及每episode的states.npz、model.xml.gz、ep_meta.json。ep_meta保留layout_id/style_id/object_cfgs/fixture_refs/cam_configs/lang及底盘初态。action原始顺序为eef平移3、旋转3、gripper1、base/torso4、mode1；Gym提供三个video.*视角、state.*与annotation.human.task_description，不能直接按LeRobot字段字典顺序拼接。

评估方式	Gym.step→Kitchen.reward / 具体_check_success；PickPlaceCounterToCabinet要求bbox位于某一柜内区域且eef离对象>0.25公尺。obj_inside_of仍在未范式轴投影使用0.05，非固定5公分容差。Gym将checker转为reward 0/1与info.success；ignore_done=True且truncated固定False，registry的horizon必须由policy runner另行取用。论文§G.2每task30 trials、期限内曾成功即算成功、跨task平均；现行文件改50 rollouts且v1.0.1把horizon增至1.5倍。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **50** 新pretrain floor layouts · 原文页 4
- **2,500** pretrain layout-style scenes · 原文页 4
- **10** target scenes · 原文页 4
- **365** tasks · 原文页 5
- **50** target eval tasks · 原文页 6
- **600,000** synthetic pretrain demos · 60×10K · 原文页 6

依这个顺序读

1. `README.md` ↗

   GitHub · robocasa/robocasa · 456174f62b

   辨认2024/365两篇论文及v1.0.1 horizon、2026-07标注更新。

   L5–22 · L129–150

2. `docs/benchmarking/benchmarking_overview.md` ↗

   GitHub · robocasa/robocasa · 456174f62b

   当前文件的50 rollouts与1.5倍horizon，对照论文30 trials。

   L16–33

3. `docs/datasets/datasets_overview.md` ↗

   GitHub · robocasa/robocasa · 456174f62b

   300 pretrain、50 target与18/16/16三组数据。

   L3–71

4. `robocasa/utils/dataset_registry.py` ↗

   GitHub · robocasa/robocasa · 456174f62b

   task数据条目、target清单与all_tasks实际组成。

   L1–40 · L2130–2170 · L2802–2860 · L2931–2962

---

5. `robocasa/utils/dataset_registry_utils.py` ↗

   GitHub · robocasa/robocasa · 456174f62b

   数据路径、demo_fraction/filter_key、缺数据时略过及task horizon取得。

   L11–89 · L121–169 · L240–253

---

6. `robocasa/models/scenes/scene_registry.py` ↗

   GitHub · robocasa/robocasa · 456174f62b

   1–10 target与11–60 pretrain的layout/style群组。

   L14–92 · L162–199

---

7. `robocasa/utils/env_utils.py` ↗

   GitHub · robocasa/robocasa · 456174f62b

   split到场景 / 对象的映射、12维action切片与成功时计数的参考loop。

   L57–154 · L157–193

---

8. `robocasa/wrappers/gym_wrapper.py` ↗

   GitHub · robocasa/robocasa · 456174f62b

   typed observation/action、预设split、success、done与未注册TimeLimit的行为。

   L33–140 · L143–177 · L303–328 · L342–385 · L400–424

---

9. `robocasa/environments/kitchen/atomic/kitchen_pick_place.py` ↗

   GitHub · robocasa/robocasa · 456174f62b

   具体PickPlaceCounterToCabinet的对象配置、指令与checker。

   L24–137

---

10. `robocasa/utils/object_utils.py` ↗

    GitHub · robocasa/robocasa · 456174f62b

    完整追到fixture内部几何投影及eef距离。

    L14–64 · L645–652

---

11. `robocasa/environments/kitchen/kitchen.py` ↗

    GitHub · robocasa/robocasa · 456174f62b

    20 Hz、场景组合排除、ep_meta及reward委派。

    L376–396 · L424–445 · L1167–1214 · L1530–1540

---

12. `robocasa/scripts/dataset_scripts/playback_dataset.py` ↗

    GitHub · robocasa/robocasa · 456174f62b

    LeRobot重播的真实reader调用与filter/absolute-action限制。

    L254–304 · L315–345

---

13. `robocasa/utils/lerobot_utils.py` ↗

    GitHub · robocasa/robocasa · 456174f62b

    Parquet action排序、meta/modality.json与必需extras实体字段。

    L63–79 · L123–165 · L199–346

---

14. `robocasa/utils/eval_utils.py` ↗

    GitHub · robocasa/robocasa · 456174f62b

    核对main残留的PandaMobile、B对象split与五场景旧界面，避免误用于365评测。

    L14–57

怎么接入我们的benchmark

可重用

有版本的task sets、pretrain/target分割、LeRobot modality及extras、场景 / 对象生成设置与具体bool checker。

需要转换

source记论文v1及commit；task全集、数据覆盖、target集合分栏。case记split、layout/style pair、对象分割、seed、控制频率及实际horizon；evaluator保存trial数、期限内成功与跨task平均，禁止和P070或不同horizon结果直接合并。

仍需补齐

365任务与317个数据key的完整对照、正式policy runner依赖commit / seed清单、per-frame subtask标注的实际文件schema，以及LeRobot视频 / extras / 资产的闭合验证。

P072 · VLABench

VLABench: A Large-Scale Benchmark for Language-Conditioned Robotics Manipulation with Long-Horizon Reasoning Tasks

内核内容已核读 · 主来源 · 原作 · 独立页面

VLABench 有交互VLA评测与脱机VLM技能串行评测两条不同链。已追到select_fruit的容器几何、progress实作、HDF5 writer/reader及DSL匹配；metric.py的pass不代表全库没有评分器，但现行总分与CLI确有静态缺陷。

> **版本与身份**
>
> VLM get_final_score虽声明0.4/0.4/0.1/0.1，实际total_score只加前两项，因此完美匹配上限80；get_final_score_dict调用get_result_save_path时漏eval_dim。evaluate_vlm.py引用未声明的task_list_json/save_dir。交互Evaluator捕捉episode例外后不加入task_infos，均值分母会缩小；必须另列请求、完成、失败及错误数。README的旧CLI拼字/参数也不等于现行parser。这些是静态检查结果，未运行上游。
>
> 固定论文为arXiv:2412.18194v1（2024-12-24），README引用相同题名与11位作者。固定程序cf588fe60c0c7282174fe979f5913170cfe69017（2025-11-11）已有2025评测轨道与数据更新，不能视作2024预览版的原封快照。

领域	居家整理与清洁、餐饮与烹饪、办公与教育、实验室操作、休闲与运动
环境	MuJoCo/dm_control依scene、components、robot及MJCF资产组装；select_fruit_series具体使用studyroom_0与table。观测依模型的ncam迭代，不能把样例四视角当所有任务固定相机数。物理步、NUM_SUBSTEPS=100与policy步数分开；视频10 fps不是通用控制频率。
任务	论文100项（60 primitive＋40 composite）；原生task、config_manager与condition以注册名连接。select_fruit的seen类别为apple/banana/orange/pear，unseen为peach/lemon/kiwi/mango；contain检查对象worldbody位置点落在Plate的平面范围及预设0–0.1公尺上方，不检查整个对象bbox或稳定接触。PourCondition只比较top/bottom site高度，是姿态代理，不代表液体流动。
题数与数据	HDF5为data/<时间名>/observation、meta_info、trajectory、instruction；observation可含rgb uint8、depth/q_state/q_velocity/q_acceleration/ee_state及点云float32。meta_info保存entities、target_entity、episode_config字符串；writer略过segmentation、instrinsic、extrinsic等字段，点云补零且未另存有效点数。trajectory为8维xyz/Euler/两指gripper；脚本只从xyz减robot_position，不能宣称已做含旋转的完整座标转换。VLM题目则是task/exampleN/input的input.png/input_mask.png/instruction.txt与output/operation_sequence.json，GT为skill_sequence[{name,params}]。

评估方式	交互链：Evaluator→load_env→dm_control终止→ConditionSet→ContainCondition→Plate/FlatContainer.contain；success取timestep.last。未提供episode_config时用42+i seeds；预设最多200个policy步，可由task_config覆盖。当前API分别平均success、intention、progress；intention是历史最小eef距离<0.1公尺，primitive progress将当前已满足condition与曾抓握target计数合并，没有实作论文0.2/0.8加权PS。脱机VLM链用技能/参数多重集合recall、技能参数联合recall及DAG节点匹配百分比；这些0–100分数不能转称物理成功率。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **100** task categories · 原文页 4
- **60** primitive tasks · 原文页 4
- **40** composite tasks · 原文页 4
- **2,164** 资产items · 原文页 6

依这个顺序读

1. `README.md` ↗
   GitHub · OpenMOSS/VLABench · cf588fe60c

   核对作品、2025数据发布与VLA/VLM分流。

   L1–39 · L139–184 · L193–204

2. `VLABench/configs/task_config.json` ↗
   GitHub · OpenMOSS/VLABench · cf588fe60c

   引擎设置、studyroom、水果类别与容器split。

   L1–18 · L92–119

3. `VLABench/tasks/config_manager.py` ↗
   GitHub · OpenMOSS/VLABench · cf588fe60c

   seen/unseen抽样及原生entity→class/XML映射。

   L40–114 · L122–150

4. VLABench/tasks/hierarchical_tasks/primitive/select_fruit_series.py ↗
   GitHub · OpenMOSS/VLABench · cf588fe60c

   指令、contain条件与pick/place expert串行。

   L8–30 · L87–97

5. VLABench/envs/__init__.py ↗
   GitHub · OpenMOSS/VLABench · cf588fe60c

   episode_config与task注册的加载入口。

   L15–55

6. VLABench/tasks/dm_task.py ↗
   GitHub · OpenMOSS/VLABench · cf588fe60c

   状态重建、condition实例化、终止checker与episode保存。

   L25–76 · L124–152 · L165–222 · L298–303 · L442–460

7. VLABench/tasks/condition.py ↗
   GitHub · OpenMOSS/VLABench · cf588fe60c

   Contain、同时AND、累积条件及Pour姿态代理。

   L43–64 · L178–199 · L299–355

8. VLABench/configs/constant.py ↗
   GitHub · OpenMOSS/VLABench · cf588fe60c

   plate_seen/unseen皆实际映到Plate class。

   L153–157

9. VLABench/tasks/components/specific_entities/common_containers.py ↗
   GitHub · OpenMOSS/VLABench · cf588fe60c

   Plate继承FlatContainer，闭合contain dispatch。

   L102–105

10. VLABench/tasks/components/container.py ↗
    GitHub · OpenMOSS/VLABench · cf588fe60c

    容器轴对齐bounds、平面半径及高度判定，非抽象stub。

    L34–102

11. VLABench/envs/dm_env.py ↗
    GitHub · OpenMOSS/VLABench · cf588fe60c

    480×480多视角观测、原生拼字instrinsic与进度委派。

    L7–41 · L118–150 · L213–235

12. VLABench/utils/skill_lib.py ↗
    GitHub · OpenMOSS/VLABench · cf588fe60c

    8维waypoint为xyz＋Euler＋两指gripper；成功末步可能不记入示范。

    L18–66

13. scripts/trajectory_generation.py ↗
    GitHub · OpenMOSS/VLABench · cf588fe60c

    成功筛选、只减底座平移的trajectory转换与meta_info来源。

    L47–110

14. VLABench/utils/data_utils.py ↗
    GitHub · OpenMOSS/VLABench · cf588fe60c

    HDF5群组、dtypes、丢弃字段及点云补零。

    L12–87

15. tutorials/3.process_dataset.ipynb ↗
    GitHub · OpenMOSS/VLABench · cf588fe60c

    实际HDF5 reader与作者保存的样例字段形状；未运行notebook。

    L39–52 · L86–118 · L156–160

16. VLABench/tasks/hierarchical_tasks/primitive/base.py ↗
    GitHub · OpenMOSS/VLABench · cf588fe60c

    最近接近距离、曾抓握与当前条件比例的真正进度。

    L4–60

17. VLABench/evaluation/metric.py ↗
    GitHub · OpenMOSS/VLABench · cf588fe60c

    确认仅为未实作函数，不能当正式metric入口。

    L4–23

18. scripts/evaluate_policy.py ↗
    GitHub · OpenMOSS/VLABench · cf588fe60c

    CLI预算、track JSON加载与metric选择。

    L11–47

19. VLABench/evaluation/evaluator/base.py ↗
    GitHub · OpenMOSS/VLABench · cf588fe60c

    seed/episode来源、exception分母、IK动作、last成功与三个独立均值。

    L39–109 · L122–205

20. VLABench/evaluation/evaluator/vlm.py ↗
    GitHub · OpenMOSS/VLABench · cf588fe60c

    图片/指令/GT串行格式、脱机计分与输出路径错配。

    L54–110 · L233–279 · L300–325

21. VLABench/evaluation/utils.py ↗
    GitHub · OpenMOSS/VLABench · cf588fe60c

    技能pattern→DAG、recall/exact比例及漏加权重的总分。

    L7–98 · L148–339

22. `scripts/evaluate_vlm.py` ↗

    GitHub · OpenMOSS/VLABench · cf588fe60c

    未定义CLI属性及few-shot/CoT输出设置。

    L14–64

怎么接入我们的benchmark

可重用

原生task/config/condition、确定性episode_config、HDF5与DSL case结构、分开的物理checker及图匹配metric。

需要转换

同一source保留交互与脱机两种case/evaluator；映射name/params/target_entity_name/target_container_name时保存图依赖模式、few-shot、CoT及信息可见性。保留8维Euler waypoint、9维joint＋gripper控制与观测四元数各自语义，不依维度误并。

仍需补齐

大型track JSON与外部vlm_evaluation_v1.0的完整case清单尚未取得，不能填全库episode数；仍需修正CLI/metric、固定model与dm_control版本、资产闭合，以及逐task验证进度支持。

P073 · RoboTwin

RoboTwin: Dual-Arm Robot Benchmark with Generative Digital Twins (early version)

内核内容已核读 · 主来源 · 原作 · 独立页面

P073 应绑官方early_version分支。已核读早期DP3的PKL→Zarr→reader→rollout→锤击checker与公开seed档；真实17项数据任务、论文6项实验、后续分支任务表必须分开。

> **版本与身份**
>
> 本体固定early_version f14a315ac4c9c72bfea05b523874f787080dfcf2，非main ea8b21121ebb3cd201ff5b3fe361944ac94eda3f。早期README明记2024-10-01改get_obs及实验结果，真实数据仍标Coming Soon。TopK摘要写出各项suc/(topk×test_num)，没有求和成单一平均，不能直接把文字输出当总平均。
>
> 对应arXiv:2409.02920v3（2025-04-16），题名带early version、九位作者。早期与现行README都直接引用该arXiv；CVPR 2025的RoboTwin为2504.13059，不能替代P073。

领域	居家整理与清洁、餐饮与烹饪、工艺与修缮、协助、交接与陪伴
环境	早期SAPIEN双臂桌面，physics timestep预设1/250秒。锤击配置有头部、前方与两腕相机，320×240、1024个世界座标xyzRGB点；conbine=False只取头部点云。论文真实Cobot Magic数据另为30 Hz、三个640×480 RGB-D视角及主 / 从臂记录，不能与模拟schema混用。
任务	论文评测6项；真实数据设计17项各30条轨迹，标签可重叠。分支README列15个名称，但完整tree只有14个具体env档，block_sweep未在该commit提供。已读block_hammer_beat的play_once为pass，不能称expert产生器已公开。checker要求工具target_pose转到世界后，xy与方块各差<0.02公尺且0.78<z<0.81；没有接触、冲量或敲击次数检查。
题数与数据	PKL保存observation/<camera>的rgb/depth、intrinsic_cv/extrinsic_cv/cam2world_gl，以及pointcloud/joint_action/endpose。depth乘1000存float64，单位毫米；点云xyz为世界公尺、RGB限0–1。joint_action是左右各6关节get_drive_target加gripper，共14维，并非实测qpos；endpose为左右xyz/RPY/gripper。转档将joint_action同时写成Zarr data/state与data/action，endpose写tcp_action，meta/episode_ends为累积排他端点。DP3 reader读state/action/point_cloud，以episode mask和padding创建时间窗。
评估方式	eval_policy_dp3→test_policy→setup_demo→apply_dp3→check_success。指定checkpoint测100个seed；checkpoint=-1扫描300...3000十个checkpoint，各取前20 seeds再选Top5。锤击seed档100笔，范围100000–100102，略过100025/100029/100040。step_lim=400按预测chunk长度累计，TOPP再展为250 Hz动作；get_obs本身也会scene.step，因此400不能当400个physics frames。每episode成功只累加一次suc。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **17** 数据收集任务 · 原文页 8
- **6** DP3评测任务 · 原文页 7, 8
- **510** 真实demo trajectories · 17×30推算 · 原文页 8

依这个顺序读

1. `README.md` ↗

   GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

   区分early、CVPR 1.0与2.0，找到官方legacy分支。

   L8–31 · L281–288

---

2. `README.md` ↗

   GitHub · RoboTwin-Platform/RoboTwin · f14a315ac4

   50示范发布、模态、较新任务表及尚未发布的真实数据。

   L5–8 · L21–49 · L83–123 · L137–167

---

3. `task_config/block_hammer_beat.yml` ↗

   GitHub · RoboTwin-Platform/RoboTwin · f14a315ac4

   相机、1024点、双臂及PKL数据选项。

   L1–25

---

4. `envs/block_hammer_beat.py` ↗

   GitHub · RoboTwin-Platform/RoboTwin · f14a315ac4

   初态、400步上限、play_once占位及工具参考点成功条件。

   L6–64

---

5. `envs/base_task.py` ↗

   GitHub · RoboTwin-Platform/RoboTwin · f14a315ac4

   深度/座标、drive targets、PKL字段、DP3 chunk控制与checker。

   L48–84 · L97–122 · L694–738 · L746–773 · L889–908 · L1035–1069 · L1099–1109 · L1111–1220 · L1222–1311 · L1320–1387

---

6. `script/pkl2zarr_dp3.py` ↗
   GitHub · RoboTwin-Platform/RoboTwin · f14a315ac4

   state/action都来自joint_action；episode_ends累积边界。

   L17–58 · L66–95

---

7. `policy/3D-Diffusion-Policy/3D-Diffusion-Policy/diffusion_policy_3d/dataset/robot_dataset.py` ↗
   GitHub · RoboTwin-Platform/RoboTwin · f14a315ac4

   Zarr reader、episode mask与时间窗sample。

   L13–58 · L73–90

---

8. `policy/3D-Diffusion-Policy/3D-Diffusion-Policy/dp3_policy.py` ↗
   GitHub · RoboTwin-Platform/RoboTwin · f14a315ac4

   policy/runner与apply_dp3的接点。

   L31–45

---

9. `script/eval_policy_dp3.py` ↗
   GitHub · RoboTwin-Platform/RoboTwin · f14a315ac4

   checkpoint选择、20/100 trials、seed与成功率分母。

   L42–99 · L105–134

---

10. `task_config/eval_seeds/block_hammer_beat.txt` ↗
    GitHub · RoboTwin-Platform/RoboTwin · f14a315ac4

    100个不连续eval seeds，不能用连续range代替。

    L1–1

怎么接入我们的benchmark

可重用

early_version任务class、checker、eval seeds、相机 / 点云设置、PKL/Zarr转换及DP3评测。

需要转换

source分early/1.0/2.0，task保留论文子集关系；case存seed、checkpoint选择方式及chunk预算。state标为command target，另记depth的mm→m转换、world/OpenGL/OpenCV、RPY与episode边界。

仍需补齐

block_sweep程序、其他论文任务逐一checker覆核、17项真实数据manifest、可运行expert产生器、资产target_pose与兼容SAPIEN/DP3依赖锁定。

P074 · RoboTwin 2.0

RoboTwin 2.0: A Scalable Data Generator and Benchmark with Strong Domain Randomization for Robust Bimanual Robotic Manipulation

内核内容已核读 · 主来源 · 原作 · 独立页面

RoboTwin 2.0 的50项任务清单与逐task步数上限可直接核对；现行main已有XPolicyLab评测及新版HDF5。已闭合Lift Pot的几何checker、seed筛选、action计数、数据时间对齐与图像解码，须与2025论文版区分。

> **版本与身份**
>
> XPolicyLab实际gitlink为fa431ecd893ee706883e64fe5fe1464ec8cd928d；.gitmodules的branch=main不是版本pin。本次只读RoboTwin端集成与本地codec。具体schema风险：save_freq用作每N个控制步抽帧，却原值写入frequency；还另插入端点帧，不能据此重建固定Hz时间轴。extrinsics_matrix优先写cam2world_gl，缺少时才写extrinsic_cv，座标方向不由字段名保证。JPEG有legacy色序与XPL-RGB1两制，不能无条件再交换RGB/BGR。
>
> 对应arXiv:2506.18088v2（2025-08-27），题名 / 作者以固定PDF为准。官方README连同一arXiv，并记录2025-08论文更新；本次main commit ea8b21121ebb3cd201ff5b3fe361944ac94eda3f则是2026-09-24的后续集成版。

领域	居家整理与清洁
环境	SAPIEN桌面双臂，论文正式设置为Aloha AgileX。现行clean与randomized不是两个生活场域；randomized包含clutter、背景、光照，table_z_bias实际抽[-0.03,0]公尺，并改用unseen语言。两份YAML都将depth/pointcloud关闭，不能把论文DP3使用的完美点云当所有方法共同输入。
任务	all_tasks与step-limit档各列50个原生task；左右 / 数量变体按原清单保留。Lift Pot从两个060_kitchenpot模型抽样；成功需世界z>0.82公尺、两TCP各距指定contact point<0.03公尺，以及pot局部z轴与世界z轴内积>0.8。此check不另测双臂接触力或持续时间。
题数与数据	原生PKL仍是observation/joint_action/endpose字典；关节读值来自drive targets，非real_jointState。现行转档输出HDF5 data_format_version="v1.0"、instructions JSON字符串、additional_info/frequency、state/action与vision；state=values[:-1]、action=values[1:]，只保留N−1组。joint字段用left/right_arm_joint_states及left/right_ee_joint_states，pose用left/right_ee_poses；vision含cam_head/cam_left_wrist/cam_right_wrist的colors定长JPEG bytes、shape、可选depths与矩阵。在线adapter用单数joint_state键，且EE/TCP有不同原点。

评估方式	main→eval_remote_policy→take_action→lift_pot.check_success→eval_success；逐task成功数除以test_num（预设100）。从100000×(1+seed)往后找候选；expert_check预设打开，先play_once且要求plan_success与checker通过，再重置同seed评policy。unstable、setup错误及首个action前的rollout错误会被略过；因此100是有效试验数，不是连续100个初态。期限按take_action_cnt而非physics frames；每次action内部再规划 / 插值，达条件即锁定成功。论文50 clean示范训练、Easy/Hard各自100rollouts的结果不由本轮运行重现。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **50** simulation benchmark tasks · 原文页 11
- **731** RoboTwin-OD对象 · 原文页 6
- **4** 真实验证tasks · 原文页 10
- **100** 每task设置的rollouts · 原文页 11

依这个顺序读

1. `README.md` ↗

   GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

   核对2.0作品、legacy分支、DP3修正与2026 XPolicyLab集成。

   L8–31 · L35–49 · L59–78 · L249–256

2. `.gitmodules` ↗

   GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

   子模块repo与追踪分支；实际pin另以git tree为准。

   L1–4

3. `env_cfg/eval/all_tasks.yml` ↗

   GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

   实读50个评测task IDs。

   L9–59

4. `env_cfg/task_config/_eval_step_limit.yml` ↗

   GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

   50个task各自的action上限，lift_pot为400。

   L1–50

---

5. `env_cfg/task_config/demo_clean.yml` ↗

   GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

   clean条件、50 demonstrations、语言与模态设置。

   L3–38

---

6. `env_cfg/task_config/demo_randomized.yml` ↗

   GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

   randomized改背景 / clutter / 高度 / 光照，并切unseen指令。

   L3–38

---

7. `envs/lift_pot.py` ↗

   GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

   实际两种pot资产、双臂expert及高度 / TCP距离 / 方向checker。

   L7–58

---

8. `envs/utils/actor_utils.py` ↗

   GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

   contact point由资产局部matrix与scale转成世界点，含articulation覆写。

   L16–62 · L100–144

---

9. `envs/utils/transforms.py` ↗

   GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

   pot方向分数的实际旋转与内积。

   L523–530

---

10. `envs/robot/robot.py` ↗

    GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

    jointState是drive targets；EE与TCP原点有0.12公尺差异。

    L494–506 · L557–603

---

11. `envs/_base_task.py` ↗

    GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

    随机化、obs、保存间隔、action计数与成功锁定。

    L55–153 · L201–224 · L438–501 · L608–624 · L1480–1550 · L1552–1640 · L1704–1740

---

12. `envs/utils/pkl2hdf5.py` ↗

    GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

    t/t+1成对字段、版本、指令、相机matrix与JPEG字段。

    L79–168 · L171–220

---

13. `envs/utils/parse_hdf5.py` ↗

    GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

    HDF5 reader到decode_image_bit。

    L11–53

---

14. `data/decode_image_bit.py` ↗

    GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

    legacy与XPL-RGB1 JPEG的不同色彩解码规则。

    L14–46 · L164–223 · L272–299 · L423–442

---

15. `scripts/eval_policy_xpolicylab.py` ↗

    GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

    种子 / expert筛选、实际success统计与XPolicyLab观测动作映射。

    L270–332 · L774–851 · L877–999 · L1041–1064 · L1093–1168 · L1214–1245

怎么接入我们的benchmark

可重用

50 task IDs、逐task步数、clean/randomized设置、对象contact-point数据模型、具体checker与seed筛选loop。

需要转换

source固定主repo及XPolicyLab gitlink；case存embodiment、语言分割、随机化、被接受 / 略过seed、action计数与checkpoint。分开PKL命令、HDF5 t/t+1配对、在线单数键，保留EE/TCP、pose/quaternion与JPEG marker约定。

仍需补齐

2025论文对应的程序 / asset版本闭合、所有50 checker逐项覆核、XPolicyLab与policy模型依赖取得、正式accepted-seed manifest及时间 / 座标schema验证。

P075 · VIMA

VIMA: General Robot Manipulation with Multimodal Prompts

内核内容已核读 · 主来源 · 原作 · 独立页面

VIMA-Bench提供任务、数据与成功判定，VIMA仓库提供模型与交互范例。已核读多模态prompt、四级partition、T+1/T数据对齐，以及visual_manipulation与without_touching的具体checker；primitive步数不能当低级控制步数。

> **版本与身份**
>
> train与L1 YAML整档相同（SHA256 bf577e269939b6b9850f1d4fe1deb4e532b1badae6711cb4c74b9f438c611322）；泛化须靠不同初始化，不能把相同YAML当已固定test cases。VIMA example.py一直重设seed42，reset失败才加seed；显示范例设hide_arm_rgb=False，README benchmark预设True。其TimeLimit是oracle_max_steps+2，并非完成全级评测的统计脚本。
>
> 对应arXiv:2210.03094v2（2023-05-28 / ICML 2023），收录年份2022是首版年。两个官方仓库都连同一arXiv；VIMABench固定97e0af11e126fd477c9d81eeabfb6c739021c680，VIMA固定8449837aa453f8ec9ba229cb956e3bbef5c796ea。

领域	居家整理与清洁、通用对象与机动作业
环境	PyBullet / UR5桌面，前方与俯视RGB＋segmentation；基础physics为240 Hz。位置bounds为x=[0.25,0.75]、y=[−0.5,0.5]公尺。吸盘pick-place或spatula push是完整primitive，一次env.step内含多个移动、接触与settle步。
任务	全库17个模板；train/L1/L2各13、L3为12、L4为4个模板，不能直接算17×4套独立任务。L4是sweep_without_touching、novel_adj_and_noun、follow_motion、same_texture。visual_manipulation的goal含objects/matches/target poses/metric/params/max_progress；图像placeholder与语言由generate_prompt共同生成，不能把prompt_assets丢掉后称为同一任务。
题数与数据	发布说明为650K成功训练轨迹，非测试case总量且本轮未重新清点资产。每trajectory含rgb_front/<t>.jpg、rgb_top/<t>.jpg、obs.pkl（segm/ee）、action.pkl、trajectory.pkl（prompt/prompt_assets/steps/success/failure及seed、对象映射、action_bounds等meta）。writer明确保存T个actions与T+1个observations；loader将JPEG HWC转CHW。action为pose0/pose1各2D位置＋xyzw四元数，模型范例另运行位置反范式与quaternion范围转换。

评估方式	env.step→task.update_goals→具体check_success→info.success/failure；reward固定0，done也可能来自失败或primitive timeout。visual_manipulation设置pos_eps=0.1公尺，is_match只比xy距离，忽略z与旋转；完成的goal逐一移除，误把distractor当目标 / 对象亦失败。without_touching每50个physics steps检查对象点集与禁止区域重叠，一次违规即锁定failure，最后还需完成精确目标数；不是逐接触事件的检查。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **17** task templates · 原文页 2, 3
- **6** 非互斥prompt/task类型 · 原文页 3
- **600,000** expert training trajectories · 超过 · 原文页 1

依这个顺序读

1. `README.md` ↗

   GitHub · vimalabs/VIMABench · 97e0af11e1

   17模板、4级泛化、650K训练轨迹及原生媒体 / action。

   L1–19 · L46–158

2. `vima_bench/tasks/__init__.py` ↗

   GitHub · vimalabs/VIMABench · 97e0af11e1

   task class注册、YAML插值解析及过滤辅助key。

   L11–94

3. `vima_bench/tasks/partition_files/train.yaml` ↗

   GitHub · vimalabs/VIMABench · 97e0af11e1

   13个训练模板与对象 / 材质集合。

   L1–200

4. `vima_bench/tasks/partition_files/placement_generalization.yaml` ↗

   GitHub · vimalabs/VIMABench · 97e0af11e1

   L1沿用训练对象和材质；整档bytes与train相同。

   L103–125

5. `vima_bench/tasks/partition_files/combinatorial_generalization.yaml` ↗
   GitHub · vimalabs/VIMABench · 97e0af11e1

   L2交换材质集合的角色，保留13模板设置。

   L1–204

---

6. `vima_bench/tasks/partition_files/novel_object_generalization.yaml` ↗
   GitHub · vimalabs/VIMABench · 97e0af11e1

   L3的12个模板及新形状 / 容器。

   L1–69

---

7. `vima_bench/tasks/partition_files/novel_task_generalization.yaml` ↗
   GitHub · vimalabs/VIMABench · 97e0af11e1

   L4四个未见模板，空值不等于零案例。

   L1–11

---

8. `vima_bench/tasks/task_suite/instruction_following/simple_manipulation.py` ↗
   GitHub · vimalabs/VIMABench · 97e0af11e1

   图像placeholder、goal tuple与10公分平面匹配；rotation被忽略。

   L22–76 · L205–233 · L302–353 · L484–536

---

9. `vima_bench/tasks/task_suite/base.py` ↗
   GitHub · vimalabs/VIMABench · 97e0af11e1

   goal移除、distractor失败条件、prompt资产与xy/yaw匹配实作。

   L72–96 · L313–430 · L448–498

---

10. `vima_bench/tasks/task_suite/constraint_satisfaction/without_touching.py` ↗
    GitHub · vimalabs/VIMABench · 97e0af11e1

    语言约束与需追踪的禁止区域 / 对象点集。

    L25–66 · L352–369

---

11. `vima_bench/tasks/task_suite/constraint_satisfaction/base.py` ↗

    GitHub · vimalabs/VIMABench · 97e0af11e1

    每50个simulation steps检查点集入区，锁定违规及精确对象数。

    L130–143 · L155–369

---

12. `vima_bench/env/base.py` ↗

    GitHub · vimalabs/VIMABench · 97e0af11e1

    两pose API、meta_info、zero reward、success/failure与constraint调用链。

    L28–57 · L159–199 · L320–389 · L391–455 · L581–591 · L660–682

---

13. `vima_bench/tasks/components/action_primitives.py` ↗

    GitHub · vimalabs/VIMABench · 97e0af11e1

    PickPlace如何将2D位置补z并透过接触下降 / 吸盘运行。

    L177–241

---

14. `scripts/data_generation/run.py` ↗

    GitHub · vimalabs/VIMABench · 97e0af11e1

    成功筛选、T+1观测/T动作与三个pickle＋JPEG的保存。

    L39–145

---

15. `scripts/data_loading.py` ↗

    GitHub · vimalabs/VIMABench · 97e0af11e1

    真正的分档reader、CHW RGB与prompt_assets复原。

    L10–48

---

16. `README.md` ↗

    GitHub · vimalabs/VIMA · 8449837aa4

    确认另一仓库的角色是模型与示范。

    L1–24

---

17. `scripts/example.py` ↗

    GitHub · vimalabs/VIMA · 8449837aa4

    模型action反范式、固定seed范例、reset重试与oracle_max_steps+2限制。

    L79–106 · L200–240 · L476–496

怎么接入我们的benchmark

可重用

模板class、版本化partition/YAML参照、prompt_assets、obs/action时序、seed与具体几何 / 过程checker。

需要转换

case ID需含template、partition、seed、对象/材质及prompt媒体；保留T+1/T对齐、2D双pose primitive、oracle-only goals、违规记忆与50-frame检查频率。任务模板、轨迹量及rollout数分栏。

仍需补齐

正式eval seed/case manifest及跨task聚合设置、其余checker逐一覆核、全部示范 / prompt媒体闭合，以及policy checkpoint与视觉信息条件验证。

P076 · Ravens / Transporter Networks

Transporter Networks: Rearranging the Visual World for Robotic Manipulation

内核内容已核读 · 主来源 · 原作 · 独立页面

Ravens的具体评测链是task goal→delta reward→test累积return→plot平均，包含部分分数。已核读插入、清扫及数据writer/reader；done不是统一成功旗标，图表的百分比标签也不能直接当原生分数单位。

> **版本与身份**
>
> 固定manifest显示仓库已封存。具体问题：plot.py把0–1 mean/std直接印成%且ylabel写Task Success，没有×100，也掩盖partial credit；6DOF插入子类设sixdof与pos_eps=0.02，仍继承只看xy/yaw的is_match，未增加z/roll/pitch判定。test预设task=hanoi但registry为towers-of-hanoi，应明设task。Dataset.sample是先等概率选episode再选非末步，不是全库frame均匀抽样。
>
> 对应Transporter Networks: Rearranging the Visual World for Robotic Manipulation，arXiv:2010.14406v3（2022-01-05；CoRL 2020作品）。README明称此论文的reference repository；正式作者清单以固定PDF为准。固定程序4752ffab487ebd387781ad7890aa540ae2780970为2024-03-14快照，非2020原始版本。

领域	居家整理与清洁、装配与生产作业、包装、仓储与物流、通用对象与机动作业
环境	PyBullet / UR5桌面，工作区0.5×1公尺；三个RealSenseD415模拟视角、640×480 RGB-D。环境预设240 Hz，demos/test脚本明设480 Hz；这是physics频率，不是示范frame或policy primitive频率。相机参数在固定cameras.py，没有逐episode嵌入color/depth档。
任务	论文十项桌面任务；当前registry有15个ID，包含五个额外子型，不能回填成15项原始benchmark。BlockInsertion的goal是object/match-matrix/target-pose与pose metric，最多3次动作；SweepingPiles配置50个小方块，最多20次push，以zone内对象采样点比例给部分分数。
题数与数据	Dataset分color/depth/action/reward/info五个文件夹，用相同NNNNNN-seed.pkl连接；color uint8、depth float32公尺。每个episode是(obs,act,reward,info)串行，最后一笔act=None。demos先保存当前obs/action与既有reward，才env.step，因此第t笔reward对应前一动作；导出transition时应将action[t]对上reward[t+1]。info保存GT对象position/quaternion/dimensions；test还会将末笔goal传给agent，信息可见性须按policy另记。action含pose0/pose1，各为xyz公尺＋xyzw四元数，并非VIMA的2D位置界面。

评估方式	Environment.step→task.primitive→Task.reward/done；pose metric用xy距离<0.01公尺及对称修正后yaw差<15°。zone metric将每对象局部采样点转入zone，算合法点比例；点集由visual-shape尺寸以0.02公尺网格创建，并非精确mesh体积。reward是累积进度差值；test加总成completion return，goal完结或_rewards>0.99才由Task.done回True，primitive timeout也可使env.done=True。论文每task100 unseen runs；程序实际遍历test Dataset.n_episodes。test数据只收oracle return>0.99的奇数seed，训练为偶数seed。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **10** simulation tasks · 原文页 6
- **100** 每task unseen test runs · 原文页 6
- **2** real验证tasks · 原文页 8

依这个顺序读

1. `README.md` ↗

   GitHub · google-research/ravens · 4752ffab48

   十项原始任务、论文关系及data/train/test/plot流程。

   L1–28 · L76–103

2. `ravens/tasks/__init__.py` ↗

   GitHub · google-research/ravens · 4752ffab48

   原生ID与额外easy/translation/sixdof等变体。

   L18–51

3. `ravens/tasks/block_insertion.py` ↗

   GitHub · google-research/ravens · 4752ffab48

   L形对象 / fixture、goal tuple、3次primitive上限及6DOF子类。

   L25–64 · L82–106

4. `ravens/tasks/sweeping_piles.py` ↗

   GitHub · google-research/ravens · 4752ffab48

   50小对象、0.12×0.12公尺目标区与zone评分。

   L25–63

5. `ravens/tasks/task.py` ↗

   GitHub · google-research/ravens · 4752ffab48

   完整pose/zone reward、goal消耗、done与采样点定义。

   L39–75 · L211–320 · L341–364 · L396–404

---

6. `ravens/environments/environment.py` ↗

   GitHub · google-research/ravens · 4752ffab48

   观测 / action schema、primitive dispatch、timeout与公尺深度重建。

   L45–103 · L179–255 · L270–341 · L398–406

---

7. `ravens/tasks/primitives.py` ↗

   GitHub · google-research/ravens · 4752ffab48

   实际吸盘pick-place与spatula push，区分高级动作与physics步。

   L22–128

---

8. `ravens/tasks/cameras.py` ↗

   GitHub · google-research/ravens · 4752ffab48

   三个640×480 RGB-D视角及固定intrinsics/extrinsics。

   L22–62

---

9. `ravens/demos.py` ↗

   GitHub · google-research/ravens · 4752ffab48

   even/odd seed、oracle成功筛选与末笔None action。

   L43–92

---

10. `ravens/dataset.py` ↗

    GitHub · google-research/ravens · 4752ffab48

    五类PKL分档、seed解析、tuple还原及episode/step抽样。

    L26–90 · L96–169

---

11. `ravens/test.py` ↗

    GitHub · google-research/ravens · 4752ffab48

    逐test dataset episode还原seed、运行task.max_steps及累积return。

    L30–40 · L61–115

---

12. `ravens/plot.py` ↗

    GitHub · google-research/ravens · 4752ffab48

    真正的mean/std与未乘100的百分比显示。

    L36–67

怎么接入我们的benchmark

可重用

十项原始task与变体映射、goal tuple、pose/zone evaluator、seed编码、RGB-D与原生pick-place/push。

需要转换

source分论文v3与2024commit；case记task变体、seed、goal、primitive步数与physics频率。保留terminal None action及reward后移配对；evaluator分开二元goal完成、delta reward、0–1累积完成度和展示用×100比例，不能全叫success rate。

仍需补齐

原论文checkpoint选择及完整100-case数据manifest、其余任务checker逐一覆核、相机 / 资产 / seed闭合；6DOF及continuous变体需独立评测协定。

P077 · CLIPort

CLIPort: What and Where Pathways for Robotic Manipulation

内核内容已核读 · 主来源 · 原作 · 独立页面

CLIPort已追到Ravens/PyBullet的bowl / rope任务、示范读写与Task.reward/is_match。mean_reward可含部分分数；bowl文字目标与checker有一对一配对落差，且eval没有按episode seed重设Python random，不能保证完全重建示范语义变体。

> **版本与身份**
>
> 本轮固定cliport/cliport@2be5c47b5bb9bb7040ad90693288b87b1e18e7ad（2023-05-22），晚于2021v1；未取得论文实验的逐项commit对照。README承认部分seen/unseen train相同、多任务Google对象训练集较小及旋转augmentation与方向语句冲突。记录的是所列选读区段；不声称全仓库 / 完整数据 / 实机实验已验证。
>
> 固定论文为 Shridhar、Manuelli、Fox 的 CLIPort: What and Where Pathways for Robotic Manipulation, arXiv:2109.12098v1 / CoRL 2021。PDF 的 code-availability 指向 cliport.github.io；仓库 README 1–9 同时吻合题名、三位作者、arXiv 与项目网址，足以确认 cliport/cliport 为本论文官方程式。openai/CLIP 与 Ravens 是重用依赖，不能另算 CLIPort benchmark。

领域	包装、仓储与物流、通用对象与机动作业
环境	PyBullet 桌面 UR5 / 预设吸盘；agent有三个480×640无噪RGB-D视角，oracle另有俯视图像与segmentation。示范与评测入口将physics设为480Hz，但每笔数据是完成pick/place primitive并等待物体静止后的决策步，不能当480fps视频。工作区x=[0.25,0.75]、y=[-0.5,0.5]公尺；Task bounds的z上限0.3，dataset/action bounds为0.28，需按用途保留。实机Franka结果不等于此UR5环境可直接重播。
任务	任务文件的10个goal-conditioned家族需与seen/unseen/full属性子集及seq流程分开。已读PutBlockInBowl：随机1–3个碗、1至碗数个block、6个distractor，语言指定两种颜色；goal=(objects,matches,target_poses,replace,rotations,metric,params,max_reward)，步数重设为blocks+1。seen与unseen类别在train均取TRAIN_COLORS，unseen只在非train改EVAL_COLORS。AlignRope是20节绳 / 四种边方向、可正反向匹配；节数、语句变化与生成seed均不能当添加任务数。

题数与数据	RavensDataset把同一episode写成color/depth/action/reward/info五个目录下的{episode_id:06d}-{seed}.pkl；color为uint8、depth为float32公尺。串行元素为(obs,act,reward,info)，最后一笔act=None；reward是到达该obs的前一步回馈。act.pose0/pose1各是(position_xyz公尺,quaternion_xyzw)；info含lang_goal及object_id→(pos,rot,dimensions)特权状态。读入后以3.125mm/pixel融合成320×160×6 RGB+重复三次height，p0_theta固定0、p1_theta为相对负yaw（弧度）。seq以i+1为goal，其他任务用末帧。train seed从0每次+2，val从1、test从10001每次+2；只保存oracle总reward>0.99，实际case数须枚举落地文件，不能用要求生成的n或README估计值替代。
评估方式	callchain：eval.main→ds.load(i)/seed→env.reset（Python random非逐case重设）→最多task.max_steps次env.step→Task.reward→is_match或zone点覆盖。pose逐object在可配对target中找到任一匹配即加max_reward/objects；is_match只看XY距离与对称性处理的z-yaw，不看高度，bowl容差0.05m、rope0.02m。zone算局部座标点落入矩形范围且低于z上限的比例。reward为累计完成度差值，完成当前goal后弹出相应语言；done是goals空或_rewards>0.99，primitive timeout也会直接done=True且reward=0。结果JSON保存episodes=(total_reward,last_info)与mean_reward；预设n_demos=100、n_repeats=1，test_best依val mean_reward选模型（未找到则last.ckpt）。因此不得把done、mean_reward与二元success混用。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **10** language-conditioned Ravens task types · 原文页 6
- **100** evaluation runs per setting · 原文页 6

依这个顺序读

1. `README.md` ↗

   GitHub · cliport/cliport · 2be5c47b5b

   身份、四阶段 train/val/test 流程、重复训练集与 SE(2) augmentation 限制。

   `L1–18 · L121–148 · L273–284 · L319–331`

2. `cliport/tasks/README.md` ↗

   GitHub · cliport/cliport · 2be5c47b5b

   10 个 goal-conditioned 原生任务家族与 seen/unseen/full/seq 标签、Ravens 重用及修改 COM 的资产。

   `L1–58 · L60–66`

3. `cliport/tasks/put_block_in_bowl.py` ↗

   GitHub · cliport/cliport · 2be5c47b5b

   具体语言、对象数、goal tuple、5cm XY 容差、步数和颜色切分。

   L11–99

---

4. `cliport/tasks/align_rope.py` ↗

   GitHub · cliport/cliport · 2be5c47b5b

   20 节绳、四个方向描述、可反向 match matrix 与20步上限；不是20个独立case。

   L14–104

---

5. `cliport/tasks/cameras.py` ↗

   GitHub · cliport/cliport · 2be5c47b5b

   三个480×640 RGB-D视角与只供oracle使用的俯视相机。

   L7–58

---

6. `cliport/environments/environment.py` ↗

   GitHub · cliport/cliport · 2be5c47b5b

   pose0/pose1运行、settle后计分、timeout终止、depth还原与特权info。

   L20–84 · L149–151 · L198–233 · L250–301 · L305–323

---

7. `cliport/demos.py` ↗

   GitHub · cliport/cliport · 2be5c47b5b

   偶 / 奇seed与test偏移、macro-action步记录、只保存总reward>0.99的示范。

   L15–89

---

8. `cliport/dataset.py` ↗

   GitHub · cliport/cliport · 2be5c47b5b

   五个pickle字段、seed命名、heightmap/角度标签、sequential goal选择与多任务切分。

   L24–208 · L243–263 · L395–449

---

9. `cliport/tasks/task.py` ↗

   GitHub · cliport/cliport · 2be5c47b5b

   pose与zone的真正checker、delta reward、goal推进及done语义。

   L19–54 · L165–227 · L229–270 · L316–323

---

10. `cliport/eval.py` ↗

    GitHub · cliport/cliport · 2be5c47b5b

    依示范seed重建case、累积reward平均与val最佳checkpoint挑选。

    L16–49 · L83–165 · L168–215

---

11. `cliport/cfg/eval.yaml` ↗

    GitHub · cliport/cliport · 2be5c47b5b

    预设100个val instances、一次repeat与路径依赖。

    L10–38

---

12. `cliport/utils/utils.py` ↗

    GitHub · cliport/cliport · 2be5c47b5b

    确认Python random只随train_run初始化；eval每case的env.seed只改局部NumPy RNG。

    L773–780

怎么接入我们的benchmark

可重用

重用task class与原生属性切分、goal tuple、语言顺序、episode seed、相机与pose-action字段、具体reward/checker。

需要转换

source绑paper edition+commit；environment绑资产 / 相机 / 物理设置；task保留家族及seen/unseen/full/seq；case以task+mode+seed+示范文件识别并保存五档引用；evaluator分列delta_reward、total_reward、done及终止原因。把世界座标、公尺、xyzw、heightmap投影和特权info可见性写入profile；同一train数据的seen/unseen别名记reuse关系。

仍需补齐

尚未闭合Google Scanned Objects修改COM后资产、所有case档与实机采集格式。PutBlockInBowl注解要求每block放不同碗，goal也设replace=False，但reward丢弃replace并逐对象独立匹配，不消耗target；加上只验XY，需协调者明列原生checker限制，不能宣称严格一对一装碗或3D落碗验证。val_best只取目录第一个匹配results-val档，且n_repeats共用同checkpoint / case seed，需固定文件与replicate定义才能可比较。另有seed再现性缺口：demos.py同时以episode seed重设np.random与Python random；eval.py只在repeat开始用train_run调用utils.set_seed，逐case仅重设np.random及env.seed，而env.seed只创建self._random。PutBlockInBowl等任务的random.sample颜色未按case重设，因此存下seed不等于已验证同一示范场景 / 语句；需保存或修订完整RNG协定。

P078 · PerAct

Perceiver-Actor: A Multi-Task Transformer for Robotic Manipulation

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

PerAct 是使用 RLBench 的方法参考，不另建18任务 / 249 variations的新任务库。已读replay与keypoint定义，并沿作者peract分支的reader、open_drawer condition、YARR rollout及accumulator闭合一条具体评测路径；test可为每个task加载不同的val最佳checkpoint。

> **版本与身份**
>
> 主仓库02fb87681c5a47be9dbf20141bedb836ee2d3ef9（2024-05-09），README明说论文DataParallel改为公开版DDP。补读依赖固定RLBench ad991951bc53e4f3b73b803a75cf4b7d55295cf7与YARR 8d0f2e228b97efa207eeccedfc6dac9334342ba3。P077 PyBullet、P062较新RLBench与本版数据 / checker各有版本边界；本轮只审所列区段。
>
> 论文为Shridhar、Manuelli、Fox的Perceiver-Actor: A Multi-Task Transformer for Robotic Manipulation, arXiv:2209.05451v2（2022-11-11）。README题名、作者、arXiv与peract.github.io相符；84–109明指MohitShridhar/RLBench及MohitShridhar/YARR的peract分支，不是P062的stepjam/RLBench现行快照。两fork是运行 / 计分依赖。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	作者fork的RLBench/CoppeliaSim 4.1 / PyRep桌面操作，EndEffectorPoseViaPlanning后接Discrete gripper。policy取front/left_shoulder/right_shoulder/wrist四个128×128 RGB与世界点云；配置不直接输出depth/mask，loader仍读depth产生点云。场景界限[-0.3,-0.5,0.6,0.7,0.5,1.6]为公尺，100^3 voxel在此配置每格1cm。Franka真实实验的teleop ZIP及Drive数据是外部附件，未取得 / 未验证。
任务	18个task是README 232–249手选RLBench subset；249是论文v2的variations，不是task或trial数。已读open_drawer的bottom/middle/top三variation，成功条件为指定joint相对初态位移>0.15m。task、variation_number、语句、demo初态各自存放；其余17个checker未逐一选读。

题数与数据	路径为{split_root}/{task}/all_variations/episodes/episodeN，包含low_dim_obs.pkl、variation_number.pkl、variation_descriptions.pkl与camera/%d.png。24-bit depth除DEPTH_SCALE后以near+depth*(far-near)还原公尺，结合intrinsics/extrinsics产生点云。reader即使仅激活四视角，仍检查全部五相机RGB/depth影格数与low_dim_obs一致。fill_replay按自然序读demo、取第一句description；keypoint为gripper_open改变、末帧或joint_velocities在0.1容差内停止，stopped_buffer=4。action为xyz公尺+xyzw+gripper共8D；保留拼法trans_action_indicies / rot_grip_action_indicies，rotation是xyz Euler+180后5度bin。replay另含ignore_collisions、rgb/point_cloud/矩阵、task、lang_goal、1024D sentence embedding、77×512 token embedding及demo。low_dim_state是gripper_open、两指位置及[-1,1]决策进度。末keypoint的100 reward为合成训练标签；增广replay条目数不能当demo/case数。
评估方式	eval→IndependentEnvRunner→_run_eval_independent→RolloutGenerator→CustomMultiTaskRLBenchEnv→RLBench TaskEnvironment.step→Task.success→open_drawer JointCondition。demo index=eval_from_eps_number+ep，variation与初态自文件恢复。范例checker成功时RLBench回1并terminal，PerAct乘100；reward<1归零，IK / path / invalid-action错误直接失败终止；预设25决策后timeout。SimpleAccumulator对episode累积reward取mean，稀疏0/100协定的eval_envs/return/{task}数值等于百分比成功率，但保留return名称及scale，不泛推到有reward shaping的task。预设每task25 episodes；method seed另记。best模式每task依val CSV独立选现存checkpoint、平手取最后，因此test不保证同一权重。YARR依weight是否dict决定test_data.csv文件名，仍需另核对demo_path实际split。

依这个顺序读

1. `README.md` ↗

   GitHub · peract/peract · 02fb87681c

   身份、作者fork、18 task清单、val/test流程与实机附件。

   L1–13 · L42–55 · L84–109 · L214–263 · L309–347 · L413–423 · L448–462

2. `conf/config.yaml` ↗

   GitHub · peract/peract · 02fb87681c

   100 demos/task、四相机、场景界限与task-uniform replay。

   L6–24

3. `conf/method/PERACT_BC.yaml` ↗

   GitHub · peract/peract · 02fb87681c

   100^3 voxel、5度rotation bin与每10原始步重取起点。

   L5–9 · L37–42 · L48–63

4. `rlbench/backend/const.py` ↗

   GitHub · MohitShridhar/RLBench · ad991951bc

   实际目录 / pickle / PNG命名与24-bit depth scale。

   L1–29

---

5. `rlbench/utils.py` ↗

   GitHub · MohitShridhar/RLBench · ad991951bc

   自然序episode、variation/description、五相机完整性检查与depth还原。

   L41–147 · L209–236 · L254–308

---

6. `helpers/demo_loading_utils.py` ↗

   GitHub · peract/peract · 02fb87681c

   夹爪切换、最后帧与低关节速度停止点。

   L8–42

---

7. `agents/peract_bc/launch_utils.py` ↗

   GitHub · peract/peract · 02fb87681c

   replay schema、pose标签、合成训练reward与示范增广。

   L32–209 · L212–274

---

8. `helpers/utils.py` ↗

   GitHub · peract/peract · 02fb87681c

   四元数 / Euler bin、policy observation及相机矩阵。

   L43–59 · L72–82 · L322–418

---

9. `helpers/custom_rlbench_env.py` ↗

   GitHub · peract/peract · 02fb87681c

   demo reset、100倍reward及IK/path/action错误终止。

   L20–91 · L134–198 · L314–391

---

10. `rlbench/tasks/open_drawer.py` ↗
    GitHub · MohitShridhar/RLBench · ad991951bc

    三种drawer variation、语句与JointCondition(0.15)。

    L9–33

11. `rlbench/backend/conditions.py` ↗
    GitHub · MohitShridhar/RLBench · ad991951bc

    prismatic joint相对初态的绝对位移严格大于0.15m。

    L30–40

12. `rlbench/backend/task.py` ↗
    GitHub · MohitShridhar/RLBench · ad991951bc

    reward预设None、fail优先 / success AND与TTM引用。

    L118–120 · L180–187 · L287–311

13. `rlbench/task_environment.py` ↗
    GitHub · MohitShridhar/RLBench · ad991951bc

    action后由success给0/1 reward、从Demo恢复初态。

    L94–126 · L159–161

14. `eval.py` ↗
    GitHub · peract/peract · 02fb87681c

    planner与每task独立选最佳val checkpoint。

    L14–31 · L83–105 · L124–152 · L220–272

15. `conf/eval.yaml` ↗
    GitHub · peract/peract · 02fb87681c

    每task25 episodes与每episode25决策是不同预算。

    L1–28

16. `yarr/runners/independent_env_runner.py` ↗
    GitHub · MohitShridhar/YARR · 8d0f2e228b

    创建自订env后进入真正的runner。

    L74–126

---

17. `yarr/runners/_independent_env_runner.py` ↗
    GitHub · MohitShridhar/YARR · 8d0f2e228b

    逐task换权重、demo index范围、accumulator写CSV。

    L112–139 · L154–200 · L230–283

---

18. `yarr/utils/rollout_generator.py` ↗
    GitHub · MohitShridhar/YARR · 8d0f2e228b

    demo reset、deterministic action、timeout与终止。

    L17–89

---

19. `yarr/utils/stat_accumulator.py` ↗
    GitHub · MohitShridhar/YARR · 8d0f2e228b

    episode return平均；pop至少需两个完成episode。

    L24–56 · L81–119 · L129–151

怎么接入我们的benchmark

可重用

作者fork reader / demo reset、18-task subset、variation/description、keypoint生成、planner与具体condition、YARR return aggregation。

需要转换

source记P078方法与P062 RLBench重用关系并保存三个commit；case以split+task+episode+variation+Demo初态hash识别。raw sensor、policy observation、连续pose与voxel/Euler标签分层；保留原始frame到keypoint的映射、augmentation起点与碰撞旗标。evaluator另存task→checkpoint、decision/trial budget、return scale、error/timeout。

仍需补齐

README只锁peract分支，补pin不能证明是论文实验版本。尚需五相机图像 / TTM / Demo资产闭合、其余17 checker核对与实机附件版本。不能套用P062现行RLBench reader。YARR pop只在>1个完成episode时输出，单case试读不保证有CSV指针。

P079 · FMB

FMB: a Functional Manipulation Benchmark for Generalizable Robotic Learning

内核内容已核读 · 主来源 · 原作 · 独立页面

FMB有真实Franka数据转RLDS与策略rollout，但环境step固定回reward=0、done=False；成功需依官方实物评测程序另行记录。已追到combined / insert-only builder、ResNet reader与robot action，发现state/peg_id字段不兼容、负ID转uint8、primitive过滤后episode边界未重算等具体集成问题。

> **版本与身份**
>
> 固定rail-berkeley/fmb@d4da6ce044a9806f41e58bf7423b5a3c05289925（2024-05-28），早于论文v3（2024-09-03）；不能认定涵盖v3所有实验。官方procedure是以SHA256固定的网站文字快照，无与paper/commit同版的证明。combined、single、multi、insert-only TFDS builders是不同schema / subset，不能仅因均1.0.0合并；本轮选读combined与insert-only。
>
> 固定论文为Luo、Xu等人的FMB: a Functional Manipulation Benchmark for Generalizable Robotic Learning，arXiv:2401.08553v3（2024-09-03）。PDF及README均指functional-manipulation-benchmark.github.io，README 136–140列相同作者与arXiv；绑定中的项目Code链接指rail-berkeley/fmb。此repo是控制器 / 数据builder / baseline，CAD与数据压缩包另行发布。

领域	装配与生产作业
环境	真实Franka Panda、两个侧面与两个腕部RGB-D相机、抓取区、reorientation fixture及插入板。论文单物体位置随机于20×20cm、板于35×35cm；多物体抓取区20×30cm，板固定。控制器预设10Hz；gripper切换会另等待，视频以20fps写出，均不能用来推定原始数据有精确等间隔timestamp。形状 / 颜色 / 长短 / 大小是对象属性，板号或相机数不等于environment/case数。
任务	原生任务含single_object_manipulation及三种multi_object assembly；combined builder的primitive有grasp、place_on_fixture、regrasp、rotate、move_up、go_to_board、insert。论文Table 1的六种分段标签与程序中的过渡primitive不强制一对一合并。22,550为论文统计的分段轨迹（single 15,350、multi 7,200），不等于完整任务episodes：论文另列2,700个single全流程、4,050个额外insert及每assembly150个multi全流程。本轮未下载文件，无实际落地case计数。

题数与数据	combined builder 1.0.0读.npy dictionary：actions(T,7)、primitive[T]、obs/{side_1,side_2,wrist_1,wrist_2及_depth,q,dq,tcp_pose,tcp_vel,tcp_force,tcp_torque,gripper_pose}，single另有object_info。RLDS steps.observation为256×256 JPEG RGB、float32 depth、joint_pos/vel(7)、eef_pose(7)、eef_vel(6)、eef_force/torque(3)、state_gripper_pose及object/shape/color/size/length；episode_metadata保留file_path、episode_task与生成语句，USE embedding为512D。depth仅astype，未提供raw depth到公尺的scale；size/length为类别字符串。action是base-frame xyz增量（m）、左乘的xyz Euler增量（rad）及gripper 0=open/1=close；env裁剪前六维至±0.06m / ±0.25rad。builder只有train，ResNet reader预设train[:95%]/train[95%:]，不是对象held-out benchmark split。reward在原始最后步硬设1、discount全1，不能作量测成功标签。
评估方式	callchain：ResNet simulate_policy→rollout→FrankaFMB.step；env固定回(obs,0,False,{})，rollout亦丢弃reward/done、可按Esc停止，只存observation/action与视频。N=100是程序调用参数，不是官方protocol；grasp/regrasp 60步、insert/place_on_fixture 100步、rotate 200步、long_horizon 300步，action chunk可能跨越外层上限。官方procedure另定grasp/rotate/place/regrasp各50 trials（5 seen+5 unseen对象各5次）、insert 45（9 shapes各5次）、single multi-stage 10、每multi-object assembly 10（5初态各2次）。成功依牢固抓持、fixture上斜放、rotate ±15度、底面完全插入正确孔等实物条件；multi-object需全部插入。未找到此路径的机器自动量测或success JSON，必须保留人工 / 外部判读地位。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **66** 原生对象 · 原文页 4
- **5** 额外未见测试对象 · 原文页 4
- **3** multi-object assemblies · 原文页 8
- **22,550** primitive demonstration trajectories · 原文页 7

依这个顺序读

1. `README.md` ↗

   GitHub · rail-berkeley/fmb · d4da6ce044

   身份、builder与checkpoint设置、force/torque座标框架更动、实物评测入口。

   `L1–16 · L30–66 · L95–140`

2. `ResNet/README.md` ↗

   GitHub · rail-berkeley/fmb · d4da6ce044

   dataset版本、primitive/object筛选、tcp_frame及action chunk选项。

   L28–46 · L49–62

---

3. `fmb_dataset_builder/fmb_dataset/fmb_dataset_dataset_builder.py` ↗

   GitHub · rail-berkeley/fmb · d4da6ce044

   实际raw keys→RLDS字段、语言生成、terminal reward、ID dtype与train-only split。

   L36–97 · L135–280 · L285–469

---

4. `fmb_dataset_builder/fmb_single_object_insert_dataset/fmb_single_object_insert_dataset_dataset_builder.py` ↗

   GitHub · rail-berkeley/fmb · d4da6ce044

   只保留insert步却沿用原始i计算is_first/is_last，以及其实际schema。

   L166–215 · L241–397

---

5. `ResNet/src/rlds/rlds_dataset.py` ↗

   GitHub · rail-berkeley/fmb · d4da6ce044

   95/5切分、primitive/peg filter、decoder必读state、eef→tcp rename及chunk padding。

   L16–181 · L229–260

---

6. `robot_infra/envs/franka_fmb_env.py` ↗

   GitHub · rail-berkeley/fmb · d4da6ce044

   10Hz、7D delta action、四相机观测、实机HTTP状态及无成功checker。

   L36–82 · L133–149 · L197–221 · L225–270

---

7. `ResNet/src/rollout_main.py` ↗

   GitHub · rail-berkeley/fmb · d4da6ce044

   人工reset/object ID、policy缩放、rollout忽略reward/done、视频保存及每primitive预算。

   L24–42 · L106–179 · L216–270 · L348–384

怎么接入我们的benchmark

可重用

raw→RLDS字段、primitive语句与object属性、父轨迹file_path、控制器delta-action定义、官方逐skill初态 / trial / 成功准则。

需要转换

source同时绑paper v3、repo commit与TFDS dataset名称/1.0.0；task区分完整assembly与primitive；case保留父episode、原始frame index、board/object ID、切分后segment及protocol trial。对象泛化split需另存held-out清单，不沿用95/5切片。把raw depth scale、force/torque frame、gripper及action范式作profile字段；evaluator单列合成demo reward与实物成功判读。

仍需补齐

combined及insert-only builder均无observation.state/peg_id，但ResNet decoder 137–140无条件读state，peg filter/shape_vec又用peg_id；需版本化adapter，不能宣称可直接串接。combined把-1 ID sentinel转uint8后成255，schema文字却仍说-1。insert-only过滤后仍用原始i标is_first/is_last，可能没有first或terminal步。README说旧checkpoint force/torque在base frame、新dataset预期eef frame，不能只按同名字段合并。尚缺深度尺度、物理资产 / 相机校正、protocol附图座标、实际trial结果与观察者判读记录。

P080 · DexArt

DexArt: Benchmarking Generalizable Dexterous Manipulation with Articulated Objects

内核内容已核读 · 主来源 · 原作 · 独立页面

DexArt已追到四个具体RL task的state / success、底层contact、对象annotation reader与paper评测入口。原生success是episode内曾达is_eval_done的比例；bucket的成功比early_done宽松，laptop reset又随机抽对象，不能将eval_per_instance名称当每个对象精确等量试验的证据。

> **版本与身份**
>
> 固定d6ab75e1a0b81384d1ac918cbfd4d97b1f230149（2026-05-11），晚于2023v1；README的2023-11checkpoint发布也晚于论文。所读门槛只代表此commit；无论文精确experiment lock或assets版本对照，不宣称重现paper表格。未运行PPO、感知预训练或SAPIEN。
>
> 固定论文为Bao、Xu、Qin、Wang的DexArt: Benchmarking Generalizable Dexterous Manipulation with Articulated Objects，arXiv:2305.05706v1 / CVPR 2023。README 1–13和171–176吻合完整题名、作者及arXiv，确认Kami-code/dexart-release为官方模拟环境 / 训练程序；不是同名搜索命中即视为官方。DexPoint及vendored Stable-Baselines3是重用实作。

领域	居家整理与清洁
环境	SAPIEN articulated objects与xArm6腕接Allegro手；create_env预设frame_skip=10，已读laptop scene timestep=0.004s，即该配置每control step为0.04s。policy相机64×64，另外1000×1000的viz_only相机不算policy观测。四task各有point-cloud裁切bound和rand_pos/rand_degree；例如laptop位置扰动为每轴[0,0.1)m、yaw±60度，不是对称±0.1m。基底pose、对象scale、摩擦、handle与joint annotation都是case重建依赖。
任务	四个原生task labels是faucet、bucket、laptop、toilet；TRAIN_CONFIG的seen/unseen ID数分别11/7、11/8、11/6、17/11（共82个配置中的对象ID），不是82个task或实测episodes。*_half只是训练对象子集。laptop reader读assets/sapien/{id}/mobility.urdf与mobility_v2.json的joint字段，结合annotation/laptop_scale.json、laptop_joint_annotation.json中left/middle及robot-relative position。外部asset包未下载，仅核对程序期待的字段，未声称这些JSON内容已读。

题数与数据	BaseRLEnv.step依序控制、update_cached_state、更新robot imagination、读观测、算reward与done。action为[-1,1]的robot.dof矢量：前六维还原Cartesian速度，Jacobian IK得arm速度并裁至±π，再积分成joint target；后段映射到hand joint位置limits，不能当全矢量都是joint velocity。obs含state/oracle_state（所读laptop为joint qpos+palm线/角速度+位置+step/horizon）、instance_1-point_cloud(512,3)、instance_1-seg_gt(512,4)及imagination_robot。点云由camera转robot座标后裁切，少点时重复第一点，空云补零；四mask顺序handle/instance_body/hand/arm。pretrain生成器把512个感知点及96个robot imagination点组成(608,7)样本，保存{task}/{train|val|test}_{id}.npy，再np.load合并；seen同时产生train与val，unseen产生test。其内容是random-action / random-joint-state感知样本，不是成功操作轨迹或固定时间同步action标签。
评估方式	入口 examples/evaluate_policy.py→create_env→BaseRLEnv.step→task.update_cached_state→sim contact checker。contact以scene contact的sum(abs(impulse))>=1e-2认定。laptop：progress=1-|q-middle|/(|left-middle|-init_open_rad)，需>0.95且palm距handle<=0.2m、至少两指及palm接触；toilet相似progress>0.95，但距离<=0.1m、两指接触即可。faucet需|hinge qpos|>1.5rad，距离<=0.2m及两指+palm接触。bucket eval需progress>0.7且base-link升高>0.25m；early_done则>0.9、state=3及>0.3m，且is_done实际只看250步horizon。四个task的horizon均250；faucet、laptop、toilet在各自成功条件成立时提早结束。主循环只要任一步is_eval_done为真就锁定episode成功，即使bucket之后落下仍记成功。最终印mean(success_list)，shaped reward另累加但不作该成功率。通用SB3 evaluate_policy回mean/std reward，不能替代此入口。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **4** 操作tasks · 原文页 3
- **82** articulated objects · 表1四类相加 · 原文页 3
- **32** unseen test objects · 表1分量相加 · 原文页 3

依这个顺序读

1. `README.md` ↗

   GitHub · Kami-code/dexart-release · d6ab75e1a0

   精确作者 / arXiv、外部assets、paper评测入口与DexPoint重用。

   `L1–19 · L35–48 · L110–118 · L165–182`

2. `dexart/env/task_setting.py` ↗

   GitHub · Kami-code/dexart-release · d6ab75e1a0

   四task的seen/unseen/half对象ID、相机、点云与初态随机化。

   L8–13 · L20–89 · L116–152

---

3. `dexart/env/create_env.py` ↗

   GitHub · Kami-code/dexart-release · d6ab75e1a0

   xArm6+Allegro、task dispatch、frame_skip、pc_seg/noise与robot imagination。

   L13–62

---

4. `dexart/env/sim_env/laptop_env.py` ↗

   GitHub · Kami-code/dexart-release · d6ab75e1a0

   实际mobility/annotation读取、hinge辨识、scale、0.004s物理步与随机object reset。

   L13–141

---

5. `dexart/env/rl_env/base.py` ↗

   GitHub · Kami-code/dexart-release · d6ab75e1a0

   控制与观测callchain、camera→robot点云、seg_gt、history及TimeLimit标记。

   L99–139 · L153–176 · L198–229 · L465–482 · L484–544 · L565–595 · L598–646

---

6. `dexart/env/rl_env/pc_processing.py` ↗

   GitHub · Kami-code/dexart-release · d6ab75e1a0

   过滤 / 抽样 / padding / noise与xyz+四类mask的真实顺序。

   L21–73

---

7. `dexart/env/sim_env/base.py` ↗

   GitHub · Kami-code/dexart-release · d6ab75e1a0

   env seed范围与接触impulse门槛，而非只用几何接近。

   L67–72 · L110–132

---

8. `dexart/env/rl_env/laptop_env.py` ↗
   GitHub · Kami-code/dexart-release · d6ab75e1a0

   progress公式、两指加palm接触、成功 / reward / annotation及250步上限。

   L38–148

---

9. `dexart/env/rl_env/faucet_env.py` ↗
   GitHub · Kami-code/dexart-release · d6ab75e1a0

   绝对joint角度>1.5rad且接触，与shaped reward分离。

   L37–141

---

10. `dexart/env/rl_env/bucket_env.py` ↗
    GitHub · Kami-code/dexart-release · d6ab75e1a0

    eval与early_done门槛不同、lift高度、reward及仅horizon终止。

    L54–100 · L123–174 · L194–199

---

11. `dexart/env/rl_env/toilet_env.py` ↗
    GitHub · Kami-code/dexart-release · d6ab75e1a0

    95% annotation progress与两指接触、0.1m近距离判定。

    L56–144 · L164–169

---

12. `examples/evaluate_policy.py` ↗
    GitHub · Kami-code/dexart-release · d6ab75e1a0

    总trial循环、deterministic PPO、episode任一步成功及最终mean。

    L14–81

---

13. `examples/pretrain/generate_dataset.py` ↗
    GitHub · Kami-code/dexart-release · d6ab75e1a0

    random-state点云样本与.npy merge reader；不是专家action示范。

    L10–45 · L49–103

---

14. `stable_baselines3/common/evaluation.py` ↗

    GitHub · Kami-code/dexart-release · d6ab75e1a0

    通用mean_reward evaluator与paper的success入口不同。

    L11–35 · L72–131

怎么接入我们的benchmark

可重用

四task checker、contact门槛、native object ID/split、对象annotation loader、robot/point-cloud观测profile与episode-any-success聚合。

需要转换

task记动作目标；environment绑SAPIEN、robot、资产/annotation版本；case记task+object ID+split+初态+seed，不以渲染帧或pretrain样本数当case。evaluator分开is_eval_done、early_done、reward、done、any_step_success及horizon；保留每task不同的角度 / progress / 接触与高度门槛。点云、seg_gt、imagination及可选previous观测需标示来源与policy可见性。

仍需补齐

外部assets的URDF、scale、joint left/middle及relative-position JSON尚未闭合或验证，须固定asset版本 / hash。eval_per_instance预设10、README示例100，总数为该值×instance_list长度；但已读laptop reset用random.randint抽ID，没有逐ID均衡控制或per-ID结果保存，需记实际抽样频数。程序stdout只有总成功率，缺trial明细与失败 / 落下后状态。BaseRLEnv在horizon处因task.is_done已为True而写TimeLimit.truncated=False，需协调者分离超时与成功，不能把done当成功。

P081 · ARNOLD

ARNOLD: A Benchmark for Language-Grounded Task Learning With Continuous States in Realistic 3D Scenes

内核内容已核读 · 主来源 · 原作 · 独立页面

ARNOLD已追到NPZ重建、两阶段策略、具体joint / pickup / orientation / water checker及score聚合。水量实作是cup world-AABB内粒子比例，成功还需连续稳定；normalized训练state不可直接当checker原生target。checkpoint选择有list.argmax静态错误，且GT辅助结果必须独立保存。

> **版本与身份**
>
> 固定arnold-benchmark/arnold@40ad6861f45b676bf538b7a0e180d81c8d454823（2024-04-01），晚于论文v2，README另含CVPR 2024 Challenge公告；不能混用Challenge与ICCV paper的case/split。P077/P078方法在此的轴、单位、keypoint及checker均已改写，需标为重用方法的另一实验版本。未运行Isaac Sim、policy、Cython或上游shell。
>
> 固定论文为Gong、Huang等人的ARNOLD: A Benchmark for Language-Grounded Task Learning With Continuous States in Realistic 3D Scenes，arXiv:2304.04321v2（2023-09-11）。PDF第7页直接指arnold-benchmark/arnold，README作者、题名与arXiv相符。此repo含benchmark与改写的PerAct/6D-CLIPort基线；它们是P077/P078方法的重用，不是原仓库数据或同一评测协定。

领域	居家整理与清洁、通用对象与机动作业
环境	Isaac Sim / USD、Franka与五相机front/base/left/wrist_bottom/wrist（配置128×128）。load_task将stage设为y-up、1单位=0.01m、gravity=(0,-1,0)且magnitude=981；physics设120Hz。场景 / 机器人 / 对象 / material USD依NPZ info重建，路径改写假设原始路径含VRKitchen2.0或指定materials字符串。README的20 scenes / 40 objects / 10k demos是来源声明，未以本地asset / NPZ枚举验证。
任务	8个原生task为pickup_object、reorient_object、open/close_drawer、open/close_cabinet、pour_water、transfer_water。训练样本分act1抓取 / act2操作，sample_weights=0.2/0.8；一般四keyframes（初态、预抓、抓住、终态），water六帧并混合frame3位置与frame4姿态作第二动作。二次policy决策不等于3或6个planner stages。7个split需保留train/val/test/novel_object/novel_scene/novel_state/any_state；预设eval只跑后五者。

题数与数据	每case是.npz，gt为keyframe对象串行，info包含scene_parameters、robot_parameters、objects_parameters及robot_shift。gt使用instruction、robot_base、position_rotation_world、gripper_joint_positions、images；每camera有rgb、semanticSegmentation、depthLinear、camera内参 / pose。Reader把position/finger由cm除100成m、wxyz转xyzw，以机器人前方0.5m为中心；PerAct点云维持y-up，CLIPort heightmap换轴成z-up。depthLinear先clip到[0,10]，Cython反投影乘100到cm、世界变换后再除100；不能把raw depth直接当cm。target_points注解写[6]，实际concat xyz+xyzw是7D（rot=None才3D）。parse_state从文件名取标签：pickup目标/40、reorient角度/180、pour为(100-p)/100、transfer为p/100，其他直接取浮点；runtime CheckerParameters.target_state另取info中的cm / 度 / 比例 / 百分点原生单位。尚未读任何示范NPZ内容，字段证据来自reader。
评估方式	eval→load_task→OpenDrawer或PourWater/TransferWater.step→120Hz physics callback→具体Checker.start_checking→BaseChecker。joint把位置按lower/upper化为0–100%，必要时翻转target，要求比例差<0.1且每physics-step百分点差<0.05；pickup要求相对初始y高度误差<5cm且每step y位移<0.1原生单位；orientation要求对象y轴相对世界y的角度误差<20度，稳定性检查同样是y位移，不是角速度。water用所有粒子落在cupShape世界AABB的比例，误差<10百分点、受约束杯偏离直立<30度，transfer另需两杯外spill<10%；pour只看原杯残余量。各条件需连续success_steps>steps_per_second*2，失败清零；末planner stage完成后最多再step 300次读success，callback已从reset启动，并未在末阶段重新开始2秒计时。horizon=2400是planner主循环tick预算，额外gripper等待及success period另计。eval写stats[fname]=1/0/-1、score=correct/total（0–1），-1包含timeout及捕捉到的例外并留在分母；console另乘100。0gt/1gt/2gt与use_gt旗标必须区分。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **20** 3D scenes · 原文页 4
- **40** objects · 原文页 4
- **8** task types · 原文页 5
- **10,080** 全部split的valid demonstrations · 原文页 5
- **773** IID test instances · 原文页 5

依这个顺序读

1. `README.md` ↗

   GitHub · arnold-benchmark/arnold · 40ad6861f4

   精确身份、8-task/7-split声明、外部数据及尚待发布的demonstration generator。

   `L1–22 · L32–60`

2. `configs/default.yaml` ↗

   GitHub · arnold-benchmark/arnold · 40ad6861f4

   GT介入、五个eval splits、相机、两阶段策略与planner预算。

   L23–40 · L75–108

---

3. `dataset.py` ↗

   GitHub · arnold-benchmark/arnold · 40ad6861f4

   npz gt、四 / 六关键帧、cm/wxyz转换、act1/act2与normalized state。

   L19–37 · L40–76 · L78–206 · L228–279 · L282–325

---

4. `utils/env.py` ↗

   GitHub · arnold-benchmark/arnold · 40ad6861f4

   五视角的固定顺序。

   L1–7

---

5. `utils/transforms.py` ↗

   GitHub · arnold-benchmark/arnold · 40ad6861f4

   camera内参 / pose与点云座标转换。

   L145–165

---

6. `utils/compute_points.pyx` ↗

   GitHub · arnold-benchmark/arnold · 40ad6861f4

   depth乘100进cm camera frame；未编译此Cython程序。

   L7–28

---

7. `tasks/__init__.py` ↗

   GitHub · arnold-benchmark/arnold · 40ad6861f4

   npz info重建USD资产、物理与fluid字段、checker dispatch及y-up/cm stage。

   L39–109 · L111–210

---

8. `environment/parameters.py` ↗
   GitHub · arnold-benchmark/arnold · 40ad6861f4

   Object/Scene/Robot与CheckerParameters的实际schema。

   L16–44 · L55–87

9. `tasks/base_task.py` ↗
   GitHub · arnold-benchmark/arnold · 40ad6861f4

   120Hz、RMPFlow与Franka / sensor setup。

   L122–179 · L332–374

10. `tasks/open_drawer.py` ↗
    GitHub · arnold-benchmark/arnold · 40ad6861f4

    两次policy step、三planner stages、2400 tick timeout与末阶段checker读取。

    L104–227

11. `tasks/pour_water.py` ↗
    GitHub · arnold-benchmark/arnold · 40ad6861f4

    pour检查原容器残余水量；六stage动作完成后才读success。

    L66–94 · L123–125 · L145–194 · L265–295

12. `tasks/transfer_water.py` ↗
    GitHub · arnold-benchmark/arnold · 40ad6861f4

    transfer检查接收杯、原杯upright及spill；不是pour同一目标。

    L41–100

13. `tasks/checkers/base_checker.py` ↗
    GitHub · arnold-benchmark/arnold · 40ad6861f4

    physics callback与连续超过2秒保持条件，失败即清零。

    L14–39 · L44–93

14. `tasks/checkers/joint_checker.py` ↗

    GitHub · arnold-benchmark/arnold · 40ad6861f4

    关节范围比例、方向翻转、±0.1与每step变化门槛。

    L36–84 · L87–153

15. `tasks/checkers/pickup_checker.py` ↗

    GitHub · arnold-benchmark/arnold · 40ad6861f4

    y高度目标、5cm容差与每physics-step位移。

    L7–74

16. `tasks/checkers/orient_checker.py` ↗

    GitHub · arnold-benchmark/arnold · 40ad6861f4

    对象y轴相对世界y的角度、20度容差；稳定度仍取y位置。

    L8–69

17. `tasks/checkers/water_checker.py` ↗

    GitHub · arnold-benchmark/arnold · 40ad6861f4

    AABB粒子比例、±10百分点、upright<30度与spill<10%。

    L13–30 · L55–82 · L100–112 · L126–207

18. `ckpt_selection.py` ↗

    GitHub · arnold-benchmark/arnold · 40ad6861f4

    val成功率及跨task平均选模型；list.argmax静态缺陷。

    L84–110 · L133–214

19. `eval.py` ↗

    GitHub · arnold-benchmark/arnold · 40ad6861f4

    GT模式、NPZ case读取、-1错误、分母与逐task/split输出JSON。

    L29–49 · L82–111 · L113–229

20. `eval_pipeline.sh` ↗

    GitHub · arnold-benchmark/arnold · 40ad6861f4

    官方串接checkpoint选择与0gt/1gt分开评测。

    L1–34

怎么接入我们的benchmark

可重用

NPZ字段 / USD物理设置、语言与native continuous target、四类checker、两阶段policy / 多stage planner、task/split/case成功记录。

需要转换

source绑v2+commit；case保留NPZ文件名、object/scene/state split、raw info和asset引用。创建cm↔m、wxyz↔xyzw、y-up↔z-up的明确转换，normalized learning goal与runtime target分栏。evaluator保存每步稳定性单位、hold ticks、planner耗时、GT介入、checkpoint及-1原因，水量保留particle-AABB proxy名称。

仍需补齐

ckpt_selection.py 204产生Python list、205直接.argmax()，在此静态路径不能完成best checkpoint挑选，需协调者处理且保留修补版本；本轮未运行确认。缺USD/material/fluid资产及实际NPZ manifest、其余具体task stage覆写的逐项核对。water AABB不是精确杯内几何或真实体积，须保留限制。GT log名称对任意use_gt组合未全区分；bare except把不同错误压成-1且已有score会跳过整个split，需追加设置hash / 错误分类。README尚列demonstration generator为TODO。

P082 · RoboVerse

RoboVerse: Towards a Unified Platform, Dataset and Benchmark for Scalable and Generalizable Robot Learning

内核内容已核读 · 主来源 · 原作 · 独立页面

RoboVerse官方repo已确认，但2026固定commit的MetaSim、trajectory reader与generalization level均有版本变化。已闭合maniskill.pick_cube config-port的初态→PositionShiftChecker→IL SuccessOnce聚合，另读Zarr产生 / 加载链。发现NaN可令整批checker成功、L2/L3与paper定义错位，以及trial尾批 / normalizer切分问题。

> **版本与身份**
>
> 固定RoboVerseOrg/RoboVerse@5f3ec0185d2d3bcb59d53b0bd1f5b0f8a6f2ce14（2026-09-08），对应paper 2504.18904v1（2025-04-26）的官方延续repo，而非paper原始实验pin。README如今把MetaSim与RoboVerse分成同tag发行的两套package；trajectory v2/v3、native/config ports与generalization protocol各自记版本。旧usage的RandomizationCfg不可直接作现行DRConfig schema；本轮只选读所列task / data / evaluator。
>
> 固定paper为Geng等人的RoboVerse: Towards a Unified Platform, Dataset and Benchmark for Scalable and Generalizable Robot Learning，arXiv:2504.18904v1（2025-04-26）。PDF指roboverseorg.github.io，README 134–141题名、作者与arXiv一致，确认RoboVerseOrg/RoboVerse为官方平台。本文不等于较早同名RoboVerse环境，也不把集成的RLBench、ManiSkill、LIBERO、ARNOLD等数据算成新独立来源。

领域	居家整理与清洁、衣物与洗护、装配与生产作业、通用对象与机动作业
环境	平台把task/robot/scene内容放roboverse_pack，模拟内核在packages/metasim/metasim。已读范例是Franka提起4cm红cube，ScenarioCfg与runtime backend共同决定物理 / 相机 / 控制时间；不能赋予全平台单一FPS。eval创建camera0的256×256 RGB/depth并依task选pose。此maniskill.pick_cube是跨simulator config port，该基类文件明分它与*_native/SAPIEN3 official-demo port；未独立验证任何跨引擎parity。
任务	pick_cube alias与maniskill.pick_cube共用一个task，目标cube比reset初态沿z移动>=0.1m，最大250原生步；不要求抓持或放置。traj_filepath指roboverse_data/trajs/maniskill/pick_cube/v2/franka_v2.pkl.gz，下载helper在constructor被调用，本轮未运行。全平台registry条目、object variants、来源task、demo与benchmark trial必须分开；本轮未声称现行registry总数等于paper task数。

题数与数据	legacy v2内容为{robot_name:[{init_state,actions,states?},...]}，init/state是entity→pos/rot/dof_pos；actions支持dof_pos_target/dof_vel_target/dof_effort_target。v3转换只是把state分objects/robots、action包上robot名称；缺states仍可回初态+actions，但不能做state-anchored replay。现行get_traj按内容辨识、拒v1，遇roboverse.episode会要求load_episode另一API，不能只改扩展名。TensorState保存objects/robots/cameras；root/body state为[pos,quat,lin_vel,ang_vel]13维，joint数据与body_names需绑定，部分backend字段可None。另一路data2zarr读demo_NNNN/metadata.json及各camera.mp4（head_camera可退到rgb.mp4），用joint_qpos、joint_qpos_target或robot_root_state/robot_ee_state(_target)生成state/action；EE为robot-local xyz+wxyz+两指共9D，delta_ee另有相对quat。输出data/{camera,state,action}与meta/episode_ends，保留downsample/padding/action-space设置。RobotImageDataset从Zarr抽episode内sequence、相机值除255。未取得外部traj、MP4或Zarr，case数应依实际episode_ends / 文件manifest，而非metadata要求处理的num_episodes。
评估方式	DefaultRunner.evaluate→get_task_class→ManiskillBaseTask→get_traj(v2→v3)→env.reset/checker.reset→BaseTaskEnv.step→handler.set_dof_targets/simulate/get_states→_terminated→PositionShiftChecker.check→util.get_pos。正常checker以reset差值z>=0.1m且总位移<=100m回bool，base reward仍为0，timeout另回。runner每个outer step运行joint action一次、EE action两次，仅读最后一次success；SuccessOnce是outer steps上的OR，SuccessEnd是末步，TimeOut只累积不停止个别env；全batch曾成功或max_step耗尽才退出。final_stats为SuccessOnce成功数/总完成数，并保存demo索引、DR level/mode/seed。选取demo靠task_id_range_low/high及max_demo，并没有自动套用paper90/10索引。现行DRManager确为L1 scene+material、L2加light、L3加camera，与paper / 旧usage文件的L2 camera、L3 light/reflection不能同名比较。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **90** navigation Matterport3D scenes · 原文页 8
- **276** 已迁移操作task categories · 原文页 7, 8
- **510,500** 操作trajectories · 原文510.5K · 原文页 8
- **6** 主IL实验代表tasks · 原文页 10

依这个顺序读

1. `README.md` ↗

   GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

   身份、MetaSim新目录与多来源重用，不把整个平台清单当paper实验集。

   `L8–13 · L23–55 · L65–101 · L131–143`

2. `docs/source/dataset_benchmark/benchmark/overview.md` ↗
   GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

   benchmark范围与randomization wrapper声明。

   L1–12

---

3. `docs/source/dataset_benchmark/benchmark/usage.md` ↗
   GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

   仍使用旧RandomizationCfg / L2相机、L3光照的文件版本。

   L3–55

---

4. `roboverse_pack/tasks/maniskill/pick_cube.py` ↗
   GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

   具体4cm cube、Franka、v2轨迹、250步及z位移checker。

   L12–37

---

5. `roboverse_pack/tasks/maniskill/maniskill_base.py` ↗
   GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

   config port与native port不同；初态reader、checker reset及terminated挂接。

   L12–39 · L53–106

---

6. `packages/metasim/metasim/types.py` ↗
   GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

   action/state/camera数据结构、预设可空字段及camera wxyz惯例。

   L29–87 · L133–198 · L237–273 · L336–347

---

7. `packages/metasim/metasim/utils/demo_util/loader.py` ↗
   GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

   pickle/gzip/JSON/YAML实际读取，不运行其中内容。

   L9–43

---

8. `packages/metasim/metasim/utils/demo_util/demo_util.py` ↗
   GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

   依内容辨识v2、明拒v1与roboverse.episode的独立reader要求。

   L17–118

---

9. `packages/metasim/metasim/utils/demo_util/demo_util_v2.py` ↗
   GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

   robot→demo[]、init_state/actions/states及flat entity namespace。

   L15–108

---

10. `packages/metasim/metasim/utils/demo_util/demo_util_v3.py` ↗
    GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

    v3只改in-memory state/action namespace，并非新磁盘trajectory格式。

    L1–67

---

11. `roboverse_learn/il/data2zarr_dp.py` ↗
    GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

    metadata+MP4→Zarr、joint/EE/delta模式及episode_ends。

    L21–77 · L147–265 · L273–318 · L329–347

---

12. `roboverse_learn/il/datasets/robot_image_dataset.py` ↗
    GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

    真正Zarr reader、episode mask、normalizer范围、相机键与postprocess。

    L33–174

---

13. `packages/metasim/metasim/task/base.py` ↗
    GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

    action→handler→terminated/timeout的原生step contract。

    L143–171 · L225–330

---

14. `packages/metasim/metasim/example/example_pack/tasks/checkers/util.py` ↗
    GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

    handler tensor root_state的前三维位置读取。

    L8–40

15. `packages/metasim/metasim/example/example_pack/tasks/checkers/checkers.py` ↗
    GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

    PositionShiftChecker真正门槛与NaN回传全True的例外路径。

    L189–230

16. `packages/metasim/metasim/randomization/dr_manager.py` ↗
    GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

    现行L1环境/材质、L2光照、L3相机的具体dispatch。

    L1–41 · L78–90 · L155–203 · L432–474 · L510–516

17. `roboverse_learn/il/utils/eval_args.py` ↗
    GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

    eval的demo范围、250决策及level/seed预设。

    L9–49

18. `roboverse_learn/il/runners/default_runner.py` ↗
    GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

    真正评测的init-state selection、DR、SuccessOnce/End与分母。

    L18–30 · L280–309 · L346–546

19. `roboverse_learn/il/runners/default_eval_runner.py` ↗
    GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

    checkpoint/EMA、obs/action chunk配置与policy输出。

    L17–45 · L71–95

怎么接入我们的benchmark

可重用

官方native task ID / aliases、ScenarioCfg、typed state/action、v2 parser和v3转换、metadata→Zarr链、具体checker及SuccessOnce/End结果。

需要转换

source保留paper v1与2026 code snapshot；task标config_port或native_port并连回ManiSkill等上游。case保存robot、task、原demo index、asset/初态hash、backend、控制步长及DR实际factor，不只存level数字。明分v2磁盘trajectory、v3内存state、roboverse.episode与IL Zarr四种界面；保留joint名称 / 单位、wxyz、camera座标及EE local/delta语义。

仍需补齐

PositionShiftChecker 219–221只要cur_pos任何元素NaN就回整批True，沿此task链会被SuccessOnce计成功，需先修补并标版本。尾批demo_end_idx只截到num_demos、不截到要求的low+max_demos，SuccessOnce分母固定num_envs，需核对超额或不满批处理。RobotImageDataset normalizer.fit吃全buffer而非train mask；get_validation_dataset取downsample后train_mask的补集，可能把未选训练episodes纳入val，需固定真正paper split。尚缺2025实验commit/资产/90-10 case清单及旧L2/L3到现行factor对照；v1数据已明示不支持。

P083 · RoboDojo

RoboDojo: A Unified Sim-and-Real Benchmark for Comprehensive Evaluation of Generalist Robot Manipulation Policies

内核内容已核读 · 主来源 · 原作 · 独立页面

RoboDojo与XPolicyLab分别提供sim任务 / 计分与policy / data adapter。已闭合stack_bowls、push_T的checker、RewardManager、EvalEnv及summary，并读HDF5→RGB→LeRobot reader。success_rate与partial score不同；unstable/abandoned layout不在相同分母，summary还有embodiment键遗失与layout排序问题。

> **版本与身份**
>
> RoboDojo固定cb2a37d58dbbeb2777b0c2b30e97ecb8ab91095c（2026-10-08），不同于旧inventory 726e9aabfaa642203722eb126f5eaf0f37f3e1ad；XPolicyLab固定de9b445e4e46388542c412e406c73d359a5802fd（2026-10-10）。RoboDojo README记9月16–17日get_obs单帧与RGB修正、HF数据更新及swap_T assets修正，要求XPolicyLab bb9a0b5f5136a74503b679af830bfd0a3a837d5c或后续；未独立验证本两pin的完整runtime兼容性。7月paper、9月数据修订、10月程序与8月XPolicyLab paper须分开建版本，不把政策数当benchmark task数。未启动server、sim、policy或远程评测。
>
> 固定RoboDojo论文为Chen等人的完整sim-and-real benchmark，arXiv:2607.04434v3（2026-07-08）。PDF第1页直接连两repo，主README题名/arXiv吻合。XPolicyLab现行README另引用2608.09892（2026年8月的独立工具论文）；本P083只审其RoboDojo adapter角色，不把那篇的政策数或新功能倒算成7月RoboDojo benchmark。

领域	居家整理与清洁、衣物与洗护、装配与生产作业、通用对象与机动作业
环境	Isaac Sim / Isaac Lab配置化场景，TaskEnv由sim/scene/robot/camera/task YAML创建，可有target双臂与support arm。选读stack_bowls从8个bowl asset ID中选3个同类对象，xlim[-0.45,0.45]、ylim[-0.25,0.07]相对Table；评测改读已存Eval_Layout。主README此版为sim eval-only，真实ARX X5/Piper/Piper X的18 tasks使用RoboDojo-RealEval另行部署；本轮未取得真实trial视频、三人评分或隐藏验证layout。

任务	summary DIMENSIONS确列42个base tasks：Generalization12、Precision8、Long-Horizon8、Memory6、Open8；12个*_random是对应base task的泛化设置，不另算42以外新canonical任务。stack_bowls完整成功需三碗轴向<45度、最低碗<7度、相邻中心XY距离<=0.04m且高度差>=0.005m、target robot回原位（每座标差<=0.15m、旋转<=20度）。此stack checker不验接触且未设最大垂直间隔。process score为两碗阶段15、三碗阶段100，要求gripper开度>=0.8；transition每action最多推进一阶，100仍须完整成功gate。push_T以quat差<7度、XY距离<0.007m及robot回原位成功；is_lift相对初态>0.01m的query允许次数0，触发即失败；不是IoU评测。
题数与数据	case来源为Assets/Eval_Layout/RoboDojo/{config_name}/{eval_seed}/{task}_N.json。SeedManager按N排序后重新以0..len-1编ordinal，该ordinal才是程序layout_id；未取得外部layout JSON，不能用文件名suffix直接替代。runtime obs含data_format_version='v1.0'、instruction、additional_info.frequency、vision/state/action及env_idx；RGB为HWC，float depth保持距离，approximate_depth=clip(raw*1000,0,65535).uint16。实际ObsManager写extrinsic_matrix，与XPolicyLab README宣称runtime extrinsics_matrix不同。XPolicyLab load(RoboDojo,v1.0)递归读HDF5、解析instruction/subtasks JSON，colors经decode_image_bit；pose为xyz+qwqxqyqz。legacy JPEG及有XPL-RGB1 COM marker的新JPEG可共存，decoder只对有marker者做BGR→RGB。LeRobot v2.1 converter取state/action下left_arm_joint_states、left_ee_joint_states、right_arm_joint_states、right_ee_joint_states依序串接；三相机映到cam_high/left_wrist/right_wrist，缺相机补黑，各arm补到共同最大维度。paper的3500 trajectories=34训练tasks各100+100 DLC辅助（Open无task-specific训练），1859602 frames及25Hz是paper统计，未下载重新点算。
评估方式	policy deploy→update_obs/get_action→EvalEnv.take_action→robot control→RewardManager.step→Func_Parser→is_episode_end。check按列表顺序移除已完成stage，嵌套list交替OR/AND，query计事件次数；完整reward只回0/1。stack_bowls上限800个take_action，push_T600，非physics ticks；capture frequency另由dt与collect_freq决定。EvalEnv完整成功记episode score=1，失败若有process score则/100；_result.json含details{record_index:{layout_id,success,score}}、success_rate（0–1）、score（0–100平均）、eval_time（已计数episodes，不是秒）。无效、unstable及部分PhysX broken layouts被排除 / 补样，abandoned另存resume manifest；要求50不能当50次尝试。summary采每task/policy/embodiment/seed最新timestamp结果；独立task前50笔，Generalization合base25+random25，三seed0/1/2共126个完整cell。先平均每维tasks，再五维等权平均，seed标准差为population std；未完成cell留空，overview可显示已完成部分平均。真实paper协定每task10 trials、三位评分者分别打成功与substeps后平均，不能以sim RewardManager替代。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **42** simulation tasks · 原文页 7
- **18** real tasks · 原文页 7, 8
- **2,100** simulation eval episodes · 原文页 7

- **180** real eval trials / policy · 18×10 · 原文页 9

依这个顺序读

1. `README.md` ↗
   GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

   paper身份、September数据 / RGB修正、sim eval-only与XPolicyLab责任界线。

   L5–7 · L13–37 · L54–107

---

2. `task/RoboDojo/task_registry.py` ↗
   GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

   按task名加载class与YAML，不将文件数当canonical task数。

   L1–21

---

3. `task/RoboDojo/config/_task.yml` ↗
   GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

   共同设置、teleop/datagen、每task trial覆写及support robot。

   L1–145

---

4. `task/RoboDojo/config/stack_bowls.yml` ↗
   GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

   三个同类bowl、asset候选及桌面初态取值范围。

   L1–17

---

5. `task/RoboDojo/tasks/stack_bowls.py` ↗
   GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

   800步、三碗完整成功与15/100 transition process score。

   L5–99

---

6. `task/RoboDojo/tasks/push_T.py` ↗
   GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

   600步、7度 / 7mm位置对齐及禁止lift。

   L5–37

---

7. `env/environment/task_env.py` ↗
   GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

   runtime robot/scene/camera/physics及控制调用。

   L10–100

---

8. `env/seed_manager/seed_manager.py` ↗
   GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

   Eval_Layout JSON排序、layout ordinal、resume排除及实际文件reader。

   L27–100

---

9. `env/observation_manager/obs_manager.py` ↗
   GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

   传感同步、frequency、depth/approximate_depth与真实runtime字段。

   L16–66 · L81–220

---

10. `env/reward_manager/reward_manager.py` ↗
    GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

    函数descriptor、嵌套AND/OR、query事件计数、transition及满分成功gate。

    L28–69 · L78–161 · L236–297 · L315–405 · L527–664 · L792–803 · L829–831

---

11. `env/reward_manager/func_parser.py` ↗
    GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

    实际object pose几何、gripper与robot回原位条件。

    L61–74 · L996–1019 · L1126–1157 · L1523–1536 · L1631–1645 · L1672–1741 · L1978–2001

---

12. `src/eval_client/main.py` ↗
    GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

    合并configs、eval budget、seed调度、PhysX / unstable中断及补样。

    L254–346 · L347–378 · L378–442

---

13. `src/eval_client/eval_env.py` ↗

GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

policy client、控制步计数、任务结束、partial score与_result.json分母。

L43–194 · L208–285 · L337–389 · L410–465 · L638–652 · L771–867

---

14. `scripts/internal/summarize_result.py` ↗

GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

42-task taxonomy、25+25 / 50、三seed、五维等权平均及缺漏cell语义。

L1–95 · L96–116 · L247–322 · L339–412 · L427–482 · L511–551

---

15. `README.md` ↗

GitHub · XPolicyLab/XPolicyLab · de9b445e4e

独立XPolicyLab paper、trajectory v1.0、pose、RGB byte版本与LeRobot profile。

L7–28 · L323–429 · L448–489

---

16. `policy/demo_policy/deploy.py` ↗

GitHub · XPolicyLab/XPolicyLab · de9b445e4e

reset/update_obs/get_action到TASK_ENV.take_action的单例与batch契约。

L1–42

---

17. `utils/data_loader.py` ↗

GitHub · XPolicyLab/XPolicyLab · de9b445e4e

converter真正reader：RoboDojo/xspark v1.0 HDF5递归、JSON语句与RGB decoder。

L1–58

---

18. `utils/process_data.py` ↗

GitHub · XPolicyLab/XPolicyLab · de9b445e4e

JPEG COM标记XPL-RGB1、legacy / standard byte的RGB解码分支。

L291–305 · L345–396 · L423–526

---

19. `scripts/transform_lerobot_v21_format.py` ↗

    GitHub · XPolicyLab/XPolicyLab · de9b445e4e

    bimanual state/action字段、padding / 缺相机、原帧逐一转存及max_fps。

    L25–51 · L154–159 · L200–274 · L376–425 · L484–604 · L639–702

怎么接入我们的benchmark

可重用

42-task capability mapping、base/random关系、layout replay与seed调度、具体几何 / 事件 / 阶段checker、逐trial success/score及HDF5 / JPEG reader。

需要转换

source同时锁RoboDojo与XPolicyLab commit；case键包含paper/code版、task、base/random、embodiment、config、eval_seed、layout ordinal和实际文件hash，record_index另存。evaluator区分success、process score、末阶段gate、unstable/abandoned与实际分母；按五维聚合而非所有task混平均。数据profile保留v1.0容器、JPEG marker、pose wxyz、观测 / 动作对齐、相机缺失与padding mask、原频率及LeRobot版本。

仍需补齐

尚缺固定layout/robot/object资产包、原始HDF5样本、真实评分数据与hidden-layout验证。summary load_entries其实按details字典record key排序而非payload.layout_id；main又将(policy,embodiment,seed)写入data[policy][task][seed]，多embodiment同名结果可能互相覆盖。latest timestamp还会跨不同checkpoint/action_type选最后结果，须额外绑run配置。LeRobot转换合并多频率来源时以max_fps创建dataset，convert_one逐原帧写入无resampling，需保存原时间轴或分流。geometry-only stack条件、runtime extrinsic键差异、score gate与unstable排除均需协调者在schema / protocol层明示。

P084 · KinDER

KinDER: A Physical Reasoning Benchmark for Robot Learning and Planning

内核内容已核读 · 主来源 · 原作 · 独立页面

KinDER将程序化环境与baselines分两repo；已读ClutteredRetrieval2D / Motion2D的具体几何成功、5D动作与vector schema，再追到demo保存 / IL reader及MPC评测CSV。非成功demo可被手动保存却未被reader筛除；MPC steps漏算成功那一步，execution_time也不是环境运行时间。

> **版本与身份**
>
> 主repo固定5b2dbac482142b879b48449b3fa2af63f641aed3（2026-09-11，pyproject 0.2.5），baselines固定f763946435c9ed8ab0f89e645f1014b07c1a1e8a（2026-09-15），均晚于paper v2。env ID的-v0不表示reset/碰撞实作从未变更；registry还会因backend导入失败而跳过整组环境，本机可用ID数不能作全库case/env数。paper的25/13与现行README添加项目分开保留；本轮未安装、run CI、重播、训练或运行planner。
>
> 固定paper为Huang、Li、Saxena等人的KinDER: A Physical Reasoning Benchmark for Robot Learning and Planning，arXiv:2604.25788v2（2026-05-04）。PDF首页指prpl-group.com/kinder-site；已读该项目页快照中精确title、arXiv、kindergarden主repo及kinder-baselines companion链接，避免只靠作者页上的其他研究链接。主repo提供KinDERGarden/Gym，companion提供KinDERBench方法，不是两份独立benchmark。

领域	居家整理与清洁、包装、仓储与物流、通用对象与机动作业
环境	paper v2声明25个程序化环境 / 13 baselines，跨Kinematic2D、Dynamic2D、Kinematic3D、Dynamic3D；现行0.2.5另列kinematic3d_v2/Vega等内容，须依paper版本选子集。已读两个Kinematic2D环境的world=[0,2.5]²，原点左下、x向右、y向上；使用2D原生长度座标与theta弧度，不把render DPI当物理尺度。CRV robot是圆形底座、伸缩臂与吸盘；kinematic转移没有速度积分。观测排除固定墙面等initial_constant_state，planner可透过专用state API取得；allow_state_access是方法可见信息条件。
任务	ClutteredRetrieval2D需把target_block完整放入target_region；o1/o10/o25代表阻挡物数，registry保存同一class的variant_ids，并非固定case数。最初robot必须在最大free-space连通分量，目标不得已与region重叠；这是初态有效性检查，不等于已证明全局可解。Motion2D-p0-v0是MPC预设task，成功只要求robot的(x,y)参考位置在target rectangle内；与完整block包含判定不同。每步reward均-1，包含成功那一步，不能当正向成功奖励。

题数与数据	ConstantObjectKinDEREnv由exemplar与type_features产生可逆vectorize/devectorize；ClutteredRetrieval-o1文档具体39维：robot9维，target_block/target_region/obstruction各10维（x,y,theta,static,color_rgb,z_order,width,height）。名称及feature顺序需保留，不能按任意字典排序重新编号。action=[dx,dy,dtheta,darm,vac]：位移±0.05、角度±π/16、臂长增量±0.1、vac∈[0,1]；吸附对象按前一步gripper相对变换搬移，碰撞则整个候选state不采用。demo写{sanitized_env_id}/{seed}/{timestamp}.p（dill），有env_id/timestamp/seed/observations/actions/rewards/terminated/truncated，T actions通常配T+1 observations；timestamp是保存时间，不是逐frame时间。GUI render_fps=20不能证明每action间隔固定。IL reader依数字seed目录排序、每目录取glob第一个.p，zip(observations[:-1],actions)生成observation.state/action/episode_index/frame_index；预设无images，render_images=True才以同seed和actions重播产生图像，本轮未运行。
评估方式	ClutteredRetrieval chain为vector wrapper.step→ObjectCentricKinematic2DRobotEnv.step→_get_reward_and_done→is_inside，逐一检查target rectangle顶点是否在goal rectangle；base回truncated=False、无原生maximum horizon。MPC另一条完整路径：run_experiment依Motion2D-p0配置创建eval env及allow_state_access=True的独立sim env→TrajOptAgent/PredictiveSampling→KinderTrajOptProblem.get_transition→Motion2D.contains_point，实际eval success直接取env.step的terminated。预设每cfg seed50 episodes、max_eval_steps=200；planning horizon=100、num_rollouts=10、replan_interval=3是规划预算，不是trial数。results.csv记success、steps、planning_time、execution_time、reward及正常episode的eval_episode；例外直接插入失败 / 零数值列。evaluate_stats读config.env.env_id、seed与CSV success，先取每job成功率，再对收集到的job rates平均与sample std(ddof=1)。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **25** procedural task-environments · 原文页 4, 5
- **8** 主实验环境 · 原文页 6
- **50** 每环境每seed eval episodes · 原文页 7

依这个顺序读

1. `README.md` ↗

   GitHub · Princeton-Robot-Planning-and-Learning/kindergarden · 5b2dbac482

   官方主环境、object-centric/vector API、backend版本与外部assets / demos。

   `L7–16 · L26–57 · L79–99 · L124–147 · L149–194`

2. README.md ↗

   GitHub · Princeton-Robot-Planning-and-Learning/kinder-baselines · f763946435

   companion baselines与model/skill套件角色。

   L1–31

---

3. pyproject.toml ↗

   GitHub · Princeton-Robot-Planning-and-Learning/kindergarden · 5b2dbac482

   package 0.2.5、Pymunk/MuJoCo与未锁精确版次的几何依赖。

   L5–43

---

4. src/kinder/__init__.py ↗

   GitHub · Princeton-Robot-Planning-and-Learning/kindergarden · 5b2dbac482

   按backend注册、o1/o10/o25 variants及metadata，不从本机注册结果推全库数量。

   L34–96 · L119–136 · L560–592 · L647–654

---

5. src/kinder/core.py ↗

   GitHub · Princeton-Robot-Planning-and-Learning/kindergarden · 5b2dbac482

   vector/object映射、state-access权限与planner内部transition。

   L124–199 · L215–267 · L300–318 · L344–350 · L376–407

---

6. src/kinder/envs/kinematic2d/clutteredretrieval2d.py ↗

   GitHub · Princeton-Robot-Planning-and-Learning/kindergarden · 5b2dbac482

   原生2D座标、对象初态、碰撞采样、完整包含checker与固定feature顺序。

   L36–86 · L137–248 · L306–438

---

7. src/kinder/envs/kinematic2d/base_env.py ↗

   GitHub · Princeton-Robot-Planning-and-Learning/kindergarden · 5b2dbac482

   5D action、上一时刻吸附对象转换、碰撞回退、reward/termination与无预设horizon。

   L99–199 · L206–249

---

8. `src/kinder/envs/kinematic2d/utils.py` ↗

   GitHub · Princeton-Robot-Planning-and-Learning/kindergarden · 5b2dbac482

   真正包含判定：inner rectangle的每个顶点皆在outer rectangle内。

   L422–437

---

9. `src/kinder/envs/kinematic2d/motion2d.py` ↗

   GitHub · Princeton-Robot-Planning-and-Learning/kindergarden · 5b2dbac482

   MPC预设Motion2D的实际goal：robot参考位置落入region。

   L34–55 · L117–145 · L261–297

---

10. `docs/envs/ClutteredRetrieval2D.md` ↗

    GitHub · Princeton-Robot-Planning-and-Learning/kindergarden · 5b2dbac482

    task/variant及action字段说明；25-step random-action展示不是评测预算。

    L7–43

---

11. `docs/envs/variants/ClutteredRetrieval2D/ClutteredRetrieval2D-o1.md` ↗

    GitHub · Princeton-Robot-Planning-and-Learning/kindergarden · 5b2dbac482

    o1版本的39维feature索引。

    L24–66

---

12. `scripts/collect_demos.py` ↗

    GitHub · Princeton-Robot-Planning-and-Learning/kindergarden · 5b2dbac482

    dill .p字段、T+1观测、手动保存非成功轨迹与20fps GUI。

    L1–10 · L95–119 · L152–195 · L233–260 · L348–372

---

13. `kinder-imitation-learning/src/kinder_imitation_learning/dataset.py` ↗

    GitHub · Princeton-Robot-Planning-and-Learning/kinder-baselines · f763946435

    实际.p reader、首档选择、obs/action对齐、可选重播图像与丢弃flags。

    L18–174

---

14. `kinder-trajopt/experiments/conf/config.yaml` ↗

    GitHub · Princeton-Robot-Planning-and-Learning/kinder-baselines · f763946435

    50评测episodes、100步planning horizon、10候选rollouts。

    L17–28

15. `kinder-trajopt/experiments/conf/env/motion2d-p0.yaml` ↗

    GitHub · Princeton-Robot-Planning-and-Learning/kinder-baselines · f763946435

    Motion2D-p0-v0、200运行步、每3步replan及不用world-model checkpoint。

    L1–5

16. `kinder-trajopt/src/kinder_trajopt/agent.py` ↗

    GitHub · Princeton-Robot-Planning-and-Learning/kinder-baselines · f763946435

    PredictiveSampling/MPC设置、观测到action与可选world-model。

    L26–80

17. `kinder-trajopt/src/kinder_trajopt/trajopt_problem.py` ↗

    GitHub · Princeton-Robot-Planning-and-Learning/kinder-baselines · f763946435

    simulated candidate成本为到termination前的负累积reward；可选world-model仍用env reward。

    L18–44 · L68–108

18. `kinder-trajopt/experiments/run_experiment.py` ↗

    GitHub · Princeton-Robot-Planning-and-Learning/kinder-baselines · f763946435

    实际eval loop、seed、success CSV、exception fallback及时间 / 步数指针范围。

    L33–107 · L110–146

19. `kinder-trajopt/scripts/evaluate_stats.py` ↗

    GitHub · Princeton-Robot-Planning-and-Learning/kinder-baselines · f763946435

    每job success平均与job间ddof=1标准差；不是独立重评审。

    L17–67

怎么接入我们的benchmark

可重用

环境class/variant registry、程序化reset、object/feature映射、action bounds、几何checker、.p轨迹schema及具体MPC success CSV。

需要转换

source锁paper v2与两repo commit，environment再绑backend/package版本与完整config；task家族、variant对象数、reset seed/case和method trial分开。case保存初态vector+feature manifest及父demo文件hash，保留T/T+1关系。evaluator保存terminated/truncated、execution步数、planning rollout预算、state-access / world-model设置；rendered images标为重播衍生数据，连回原seed与code版本。

仍需补齐

collector手动G键可保存terminated=False，但IL loader不检查terminated/truncated，并任选同seed第一个.p、未验证各episode env_id一致；需明确挑档及成功标签。重播图像只依seed、未比对stored observations，环境修订后不能宣称画面仍对齐。MPC steps在done前break而少算成功步；execution_time只包agent.update，不含env.step；抽到的实际episode seed未写CSV，例外列又缺eval_episode。summarizer不依seed去重，重复job可冒充更多独立seed。需补paper环境 / baseline清单、外部3D资产及prpl_utils/relational_structs/tomsgeoms2d精确版本；未验证其余dynamic tasks或真实mobile-manipulator实验。

P085 · SoftGym

SoftGym: Benchmarking Deep Reinforcement Learning for Deformable Object Manipulation

内核内容已核读 · 主来源 · 原作 · 独立页面

已核读 SoftGym 的环境 / 状态界面、10 个论文任务对应的具体计分及 picker 动作。它提供 FleX 柔性物与流体交互环境；normalized_performance 是任务专属连续量，不能当共同成功率。此 commit 的 ClothFoldCrumpled reward 与 performance 存在公式差异。

> **版本与身份**
>
> 固定 2022-01-14 commit；README 含 2021 年添加 depth rendering，不能视为原论文提交时完整快照。内核核读限所列 Python 段落，未运行 FleX、基线或加载 pickle。 已补固定SoftAgent db2fbb5d的CEM / DrQ / 初态生成核心段落；未运行baseline，也未把这个后续版本当成论文完整再现。
>
> README 的完整题名、四位作者及 CoRL 2020 引用对应 arXiv:2011.07215；不是论文引用的 CURL、DrQ 或 rlpyt 基线仓库。

领域	衣物与洗护
环境	NVIDIA FleX / PyFlex，布料、绳索、流体以粒子及 shape states 表示。预设以抽象 picker 或杯子直接控制；程序含 sawyer / franka 分支，但本次未验证 Robotics 版 PyFlex，不能据此宣称完整手臂环境可运行。布料位置为原生 xyz、y 为高度、面积投影到 xz；camera 设置使用弧度值。
任务	README 列 6 Medium＋4 Hard 任务。SOFTGYM_ENVS 有 12 个注册名称：ClothFlattenPPP / ClothFoldPPP 是同 class 的控制变体；env_arg_dict 另外有未注册项目，不能全部算任务。RopeConfiguration 的 S/O/M/C/U 为 goal 变体。num_variations=1000 是预设生成预算，未读取实际初态资产，不能当已验证 case 数。

题数与数据	初态 pickle 保存 (cached_configs, cached_init_states)，以 config_id 关联；Flex 状态有 particle_pos(N×4，xyz＋inverse mass)、particle_vel(N×3)、shape_pos(N×14)、phase、camera_params。液体子类改用 glass_x / glass_y / glass_rotation、glass_states、poured_glass_states、glass_params 等字段，不能硬套同一状态 schema。布料 config 含 ClothPos / ClothSize / ClothStiff / camera_params / flip_mesh。观测可为 cam_rgb、key_point 或补零粒子 point_cloud；RopeConfiguration RGB 与 goal RGB 沿通道拼成 6 通道。未指定 config_id 时，训练从前 80% 初态抽取，eval_flag 从后 20% 抽取；1000 配置因而对应 800/200 索引，非 rollout 次数。 补核SoftAgent：generate_cached_states设置num_variations=1000，但main覆写env_names为仅ClothFold；DrQ预设num_variations=1，README要求另设1000才对应原论文条件。CEM输出initial_states / action_trajs / configs，不能把100万train steps或候选rollouts计为题数。
评估方式	FlexEnv.step 在 action_repeat 次物理步后计算 reward / info，到 horizon 才 done，没有通用成功门槛。ClothFlatten：100×100 xz 占格面积；ClothFold：−平均对应粒子距离−1.2×固定半侧偏移；ClothDrop：−平均粒子至 target_pos 距离；ClothFoldDrop 沿用 ClothFold。ClothFoldCrumpled 的 reward 以 flat_pos 与 norm(mean(...,axis=1)) 算固定项，info 却以 init_pos 与 mean(norm(...)) 计算，两者不能互换。RopeFlatten：−|端点距离−绳长|，以 −绳长 与 0 范式；RopeConfiguration 预设对下采样点做 Hungarian 最小配对距离。PassWater：−10×杯外粒子比例−|terminal_x−glass_x|；PourWater：目标杯内且控制杯外的粒子比例；PourWaterAmount：−|int(N×target_amount)−目标杯有效粒子数|/N。多数 info 用初态与上界范式、未裁切；PourWaterAmount 延用父类 reward_max=1，与其负误差理论上界 0 不同。 补核SoftAgent实际baseline：CEM取得完整env state，在副本环境set_state后逐candidate累加reward作成本；是可查找真实模拟动力学的oracle规划条件。预算由timestep_per_decision / max_iters / plan_horizon决定。DrQ使用sample=False推论，报每episode回报的平均，以及info的episode×time平均与末帧平均；这些不等同任务成功率。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **10** Medium+Hard tasks · 原文页 3, 4
- **6** 有广泛baseline的Medium tasks · 原文页 3
- **200** 每task评测variations · 原文页 7

依这个顺序读

1. `README.md` ↗

   GitHub · Xingyu-Lin/softgym · bb383f64cd

   确认论文身分、Medium / Hard 任务与 SoftAgent 关系。

   L1–70

2. `softgym/registered_env.py` ↗
   GitHub · Xingyu-Lin/softgym · bb383f64cd

   区分参数字典、真正注册名称、PPP 别名与各自 horizon / action_repeat。

   L14–196

---

3. `softgym/envs/flex_env.py` ↗
   GitHub · Xingyu-Lin/softgym · bb383f64cd

   核对 pickle 状态对、80/20 索引分割、Gym step 与图像翻转。

   L17–118 · L153–197 · L217–230

---

4. `softgym/envs/cloth_env.py` ↗
   GitHub · Xingyu-Lin/softgym · bb383f64cd

   核对 ClothSize / ClothStiff、粒子与四角观测、camera 及 scene 创建。

   L10–166

---

5. `softgym/action_space/action_space.py` ↗
   GitHub · Xingyu-Lin/softgym · bb383f64cd

   读取 picker 增量、抓取门槛与 PPP 绝对位置及内部步数。

   L22–60 · L117–179 · L185–224

---

6. `softgym/envs/cloth_flatten.py` ↗
   GitHub · Xingyu-Lin/softgym · bb383f64cd

   面积网格与相对初态的展布计分。

   L10–33 · L110–159 · L176–202

---

7. `softgym/envs/cloth_fold.py` ↗
   GitHub · Xingyu-Lin/softgym · bb383f64cd

   粒子镜像配对、固定半侧位移与 1.2 权重。

   L85–169

---

8. `softgym/envs/cloth_drop.py` ↗
   GitHub · Xingyu-Lin/softgym · bb383f64cd

   落布目标粒子位置的平均距离与范式。

   L147–188

9. `softgym/envs/cloth_fold_crumpled.py` ↗
   GitHub · Xingyu-Lin/softgym · bb383f64cd

   核对 hard 变体覆写后 reward / info 的不同基准及聚合。

   L1–14 · L77–139

10. `softgym/envs/cloth_fold_drop.py` ↗
    GitHub · Xingyu-Lin/softgym · bb383f64cd

    空中初态与沿用 ClothFoldEnv evaluator 的关系。

    L1–18 · L91–150

11. `softgym/envs/rope_flatten.py` ↗
    GitHub · Xingyu-Lin/softgym · bb383f64cd

    端点距离、绳长及 reward_min 范式。

    L47–99

12. `softgym/envs/rope_configuration.py` ↗
    GitHub · Xingyu-Lin/softgym · bb383f64cd

    字形 goal、六通道观测与预设 Hungarian 配对误差。

    L14–51 · L160–238

13. `softgym/envs/pass_water.py` ↗
    GitHub · Xingyu-Lin/softgym · bb383f64cd

    杯子状态、轴向包围盒内水量、溢水惩罚及位移。

    L13–41 · L183–216 · L365–399 · L553–576

14. `softgym/envs/pour_water.py` ↗

GitHub · Xingyu-Lin/softgym · bb383f64cd

目标杯独占粒子比例、状态栏位与 reward_max。

L53–62 · L161–199 · L377–411 · L602–623

---

15. `softgym/envs/pour_water_amount.py` ↗

GitHub · Xingyu-Lin/softgym · bb383f64cd

目标水量量化、负误差与继承范式分母。

L12–65 · L148–190

---

16. `README.md` ↗

GitHub · Xingyu-Lin/softagent · db2fbb5dc3

补核SoftGym官方基线库、依赖与预设variation数。

L1–62

---

17. `experiments/generate_cached_states.py` ↗

GitHub · Xingyu-Lin/softagent · db2fbb5dc3

确认生成1000个初态但main只保留ClothFold；不是一次生成全部任务。

L36–53

---

18. `experiments/run_cem.py` ↗

GitHub · Xingyu-Lin/softagent · db2fbb5dc3

核对任务horizon、规划预算、真实轨迹与info统计。

L29–54 · L70–124 · L130–151

---

19. `cem/cem.py` ↗

GitHub · Xingyu-Lin/softagent · db2fbb5dc3

追CEM取完整state、规划并恢复环境的oracle信息权限。

L35–59 · L62–81 · L98–116

---

20. `cem/parallel_worker.py` ↗

GitHub · Xingyu-Lin/softagent · db2fbb5dc3

确认真正在副本模拟器重设state、累加reward并取负成本。

L8–45

---

21. `experiments/run_drq.py` ↗

GitHub · Xingyu-Lin/softagent · db2fbb5dc3

核对reward scaling、预设1个variation、train step与episode数分离。

L9–25 · L40–83

---

22. `drq/train.py` ↗

GitHub · Xingyu-Lin/softagent · db2fbb5dc3

确认deterministic policy inference与原生reward/info mean/final分母。

L44–67 · L124–173

怎么接入我们的benchmark

可重用

任务 class、原生 task 名称、具体 metric、可重设的 config/state、camera 与 action_mode 设置。

需要转换

source→固定 commit；environment→FleX 场景与物理设置；task→论文目标并保留注册别名；case→config_id＋状态哈希＋split；evaluator→各 class 公式。保留 raw reward、performance、normalized_performance 三栏及 oracle/RGB 权限。picker 每支为 [dx,dy,dz,pick]，位移范围 ±0.01、pick>0.5；PPP 为 [x,y,z,pick]、内部步长 0.01，最多 300 步，不把 horizon 当秒或影格。

仍需补齐

初态 / rope goal 资产与生成 seed 的清单；SoftAgent其余算法及paper checkpoint / 跨seed聚合的完整闭合；ClothFoldCrumpled 与 PourWaterAmount 的 evaluator 差异决策；PyFlex 运行及分母为零的验证。

P086 · DeformableRavens

Learning to Rearrange Deformable Cables, Fabrics, and Bags with Goal-Conditioned Transporter Networks

内核内容已核读 · 主来源 · 原作 · 独立页面

已核读模拟主仓库与实体 cable 实验补充仓库。12 个添加柔性物任务共用 Task.reward 分支，但 cloth coverage、袋口凸包、袋子搬运与真机 mask IoU 是不同指针；bag-items 的 task.done 只要求正分，不能直接当论文完整成功。

> **版本与身份**
>
> 两仓库均固定 2023-06-11 commit；模拟 README 的 metric 概述仍只写 pose/zone，实际添加分支更多。原生状态 / 示范及 PyBullet、Franka 控制均未运行。
>
> 模拟 README 明示 ICRA 2021 完整题名及作者、继承 google-research/ravens，并直接链接 gctn_physical；后者 README 反向指向模拟仓库。论文 arXiv:2012.03385v4 含后加真机章节，不能把 2023 真机程序视为 2020 初稿内容。

领域	衣物与洗护、包装、仓储与物流
环境	模拟为 PyBullet UR5 桌面与三台 RGB-D camera，z 轴向上；柔性 cloth/bag 需 deformable world，environment 注解要求至少 480 Hz，CLI 预设却是 240，必须保留实验命令设置。真机另为 Franka Panda＋手部 Azure Kinect、foam 工作面及校正转换。
任务	添加 5 cable、3 cloth、4 bag，共 12；全 registry 另含原 Ravens 任务与 insertion-goal。cloth-flat 等程序名称对应论文 fabric-*；bag-items-easy/hard 对应 bag-items-1/2。cable-ring-notarget 只是无可见标线，load.py 未将它列为 goal-image conditioned 任务。bag-items 以打开、插入、搬运三 stage 及各 stage primitive 参数组成。
题数与数据	Dataset 将 color/depth/action/info 存成各目录相同的 {episode:06d}-{length}.pkl；RGB uint8 为 T×3×480×640×3，depth float32 为 T×3×480×640。最后一笔另存 last_color/last_depth/last_info，不在 action 长度内；goal 预设取同回合最后状态，也可抽未来时间。action 有 camera_config、primitive、params.pose0/pose1；info 保存 object_id→(position,rotation,dimensions) 及 extras。真机 trial_info 的 img_dict/eval_metrics 应比 act_dict/gctn_dict 多一笔，旧 trial 有缺尾；depth 原始毫米、mask 160×320，需保留 crop 与相机外参。人类示范取像不是 robot rollout。

评估方式	模拟 reward 回传当步 delta，extras.total_rewards 保留当前值。cable-target 检查每珠到任一目标 XY 距离 <3.5×radius、全数合格才 done；ring 面积除 πr² 达0.75，bag-alone-open 达0.70。cloth-flat 以目标交集/目标面积达0.85，另记 IoU；cloth-cover 要 cube 在 segmentation 不可见且距四角中心≤0.25。bag-items 在 stage3 以物体入 zone 比例与袋口珠入 zone 比例各占0.5，done 只要求 total_rewards>0；训练 main.py 另过滤不完整示范，测试 load.py 仅排除 t=0 或 exit_gracefully，不能沿用示范过滤作 test success。bag-color-goal 以目标物可见像素位于目标袋口凸包的比例≥0.95，先要求可见袋口珠比例>0.33；不是完整3D containment。load.py 每2000 iteration 评测一次，共10 snapshots，各20个有效回合，seed 从10000开始，保留重抽计数与 final_info；论文第5页对3训练runs的60个指针先平均再取10 snapshots最大值，bag-color-goal仅1 run。真机 evaluate_masks 算交集/联集，另有交集/min(mask面积)；论文成功为10动作内 IoU>0.25，程序只存连续值、README 使用手动退出，尚无完整自动成功汇总。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **12** deformable tasks · 原文页 4, 5
- **12,000** scripted成功demo · 12×1,000 · 原文页 5
- **20** 每checkpoint每run eval episodes · 原文页 5

依这个顺序读

1. `README.md` ↗

   GitHub · DanielTakeshi/deformable-ravens · 73982748bd

   核对论文、Ravens 衍生关系、数据与真机补充来源。

   L1–18 · L51–138 · L147–163

2. `Tasks.md` ↗

   GitHub · DanielTakeshi/deformable-ravens · 73982748bd

   确认该文件主要记录前代 Transporter 任务，不把旧 cable 算成新套件。

   L1–12 · L72–91

3. `ravens/tasks/__init__.py` ↗

   GitHub · DanielTakeshi/deformable-ravens · 73982748bd

   分开 12 添加柔性物名称与继承 registry。

   L1–55

4. `ravens/dataset.py` ↗

   GitHub · DanielTakeshi/deformable-ravens · 73982748bd

   核对 episode/time 索引、三视角 RGB-D、动作及 last_* goal。

   L68–226

---

5. `ravens/environment.py` ↗

   GitHub · DanielTakeshi/deformable-ravens · 73982748bd

   读实际 UR5 场景、空观测初始化、终止失败与 task.done 的分离。

   L20–76 · L135–180 · L247–325

---

6. `ravens/tasks/defs_cables.py` ↗

   GitHub · DanielTakeshi/deformable-ravens · 73982748bd

   确认 cable 目标 / ring 子类、珠粒参数、goal 和 0.75 门槛。

   L396–408 · L449–481 · L555–576 · L600–632 · L637–677 · L721–731

---

7. `ravens/tasks/defs_cloth.py` ↗

   GitHub · DanielTakeshi/deformable-ravens · 73982748bd

   读 pixel IoU / goal coverage、遮挡 checker 与具体 cloth 任务。

   L190–235 · L313–316 · L354–391 · L433–483

---

8. `ravens/tasks/defs_bags.py` ↗

   GitHub · DanielTakeshi/deformable-ravens · 73982748bd

   读袋子 task、stage、0.70 面积门槛及可见袋口凸包内物体比例。

   L44–84 · L251–258 · L402–428 · L476–520 · L660–705 · L899–949 · L1098–1192

---

9. `ravens/tasks/task.py` ↗

   GitHub · DanielTakeshi/deformable-ravens · 73982748bd

   追到底层 reward 与所有添加 metric 的 done 条件。

   L726–750 · L845–1106 · L1108–1164

---

10. `main.py` ↗

    GitHub · DanielTakeshi/deformable-ravens · 73982748bd

    区分成功 demo 过滤、1000 生成预算与多次训练。

    L47–81 · L163–194 · L234–274

---

11. `load.py` ↗

    GitHub · DanielTakeshi/deformable-ravens · 73982748bd

    核对具体测试 goal、L2/SSIM、10 snapshots、20 accepted episodes 与 seed 起点。

    L17–79 · L157–212 · L224–244 · L249–265 · L282–290 · L339–376

---

12. `README.md` ↗

    GitHub · DanielTakeshi/gctn_physical · ac002ece13

    确认真机参考实作的机器相依与手动退出惯例。

    L1–75

---

13. `get_demo_data.py` ↗

    GitHub · DanielTakeshi/gctn_physical · ac002ece13

    核对人类摆放后取像数据；不将取像当机器人 action。

    L66–103

---

14. `main.py` ↗

    GitHub · DanielTakeshi/gctn_physical · ac002ece13

    核对真机 trial_info、毫米 depth、逐步 metric 与预设 10 动作。

    L104–192 · L376–399

---

15. `daniel_utils.py` ↗

    GitHub · DanielTakeshi/gctn_physical · ac002ece13

    具体 160×320 binary mask IoU 与另两个 pixel 指针。

    L562–601

---

16. `inspect_results.py` ↗

    GitHub · DanielTakeshi/gctn_physical · ac002ece13

    验证历史 rollout 缺值及重新计算 IoU 的 reader。

    L43–66 · L100–123

怎么接入我们的benchmark

可重用

添加 task subclasses、metric 分支、RGB-D / goal 配对、seed 与 snapshot 的结果 pickle，以及真机 mask evaluator。

需要转换

source 分两个 commit；environment 分 UR5 模拟与 Panda 真机；task 保存 paper_name↔code_name 与 Ravens 继承；case 绑 seed / goal episode / 初态；evaluator 分 delta、raw score、task.done、termination_reason 及 paper-success。t=0 为取像而非操作，所以 max_steps=21/11/3 等不能直接作动作数；有效 cable 通常20、cloth-flat10、cloth-cover2次，bag依子类8或9次。

仍需补齐

数据 / goal 资产清单与每次重抽 seed；论文 bag-items 完整成功的结果汇总对接；10-snapshot 选择与独立测试分割；真机10-goal清单、手动停止纪录、完整校正和缺尾 trial 处理。

P087 · GarmentLab

GarmentLab: A Unified Simulation and Benchmark for Garment Manipulation

内核内容已核读 · 主来源 · 原作 · 独立页面

已核读 Isaac Sim 场景、Fold / Hang / Bimanual 范例、点云数据管线及 RL fold 的具体 evaluator。公开程序可作来源与部分任务参考，但所读路径未实现论文整套20任务及持续5秒成功验收；多处数据键、split 与计分接线尚未闭合。

> **版本与身份**
>
> 固定 2025-03-02 commit，晚于2024论文；READMEs与论文宣称不代表此公开版本已实现所有协定。本次未启动 SimulationApp、未下载 USD/模型，亦未将 template 或文件数当核读完整性。
>
> README 直接链接 arXiv:2411.01200、官方 GarmentLab 页面与同名仓库，BibTeX 题名及作者对应 NeurIPS 2024 论文。LearningBaseline/unigarmentmanip 是本仓库中的基线实作，不另外算新 benchmark。

领域	居家整理与清洁、衣物与洗护、个人照护
环境	Isaac Sim 4.0.0 / PhysX；BaseEnv 导入 USD 房间与地面、激活 GPU dynamics / CCD；GarmentConfig 保存 USD、pos、ori、scale、stretch/bend/shear stiffness、friction 和 collision offsets。FoldEnv 使用 Franka、顶视 Recording_Camera 的 depth / point-cloud / segmentation；BimanualEnv 配两支 Franka。原生 Euler / quaternion 与 USD scale 混用，不能直接假定所有输入角度或资产尺寸相同。
任务	README 宣称20任务、5交互群、11衣物类别、20场景及9000+资产，均为不同单位且非本次验证的可运行 case 数。本轮追查 Fold、Hang、双臂展布及 RL fold 子路径；demo 是固定资产 / 抓点串行。RL fold/config 实际 task_name 为 hang，须由协调者核对任务名称与实验配置，不能仅依文件夹分类。
题数与数据	collector 把 pcd_points / mesh_points 写入 {garment}/p_{index}.npz、另存 rgb_{index}.png；loader 还要求 keypoints_visible_mask、pcd_keypoints_id、visible_mesh_indices，需补前处理来源。loader 回传两份点云与 correspondence 索引，交替产生同衣物跨变形及跨衣物配对，不是 robot episode。get_deformation_paths 先按衣物目录数字排序再切 split；config.train_ratio=1 会把所有衣物给 train、val 为空，不能套用论文 split。BaseEnv 的 .npy record/replay 是 callback 框架，base callback 为 pass，未提供统一有效轨迹 schema。

评估方式	HangEnv.get_reward 读 garment_mesh.get_world_pose() 的 z>门槛（预设0.3，demo传0.5），未检查挂架接触或5秒稳定。FoldEnv 与 FoldDemo 没有 fold success checker。BimanualEnv 以 trial/reference coverage>0.75，但 evaluator 会停止 / 重设衣物姿态且面积 min/span 使用xy、pos2d却使用xz，必须标为原生疑点。RL fold 的 eval_policy 平均30次 SimEnv.step(...,True) 布尔值；SimEnv 计算抓点到指定粒子的误差，两个 reward_action>0 才成功，误差恰为0.1经非线性分支后仍为正。虽计算0.8×reward_action＋0.2×reward_result，非eval实际回传 reward_action，eval也未用结果形状误差。FoldTask.calculate_metrics 是 Cartpole 范本，不是主 fold evaluator。点云 simple_val 以归一化特征 argmax 找 correspondence，报平均欧氏距离与 distance<threshold 比例；val_score.py 却读 points/keypoints_id、取 train 的0.8子集，而且调用 cal_distance_accuracy 时少了必填 distance_threshold。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **20** scene资产 · 原文页 2
- **20** tasks · 原文页 6
- **5** 物理交互groups · 原文页 6
- **11** garment categories · 原文页 2, 17

依这个顺序读

1. `README.md` ↗

   GitHub · GarmentLab/GarmentLab · 6ee0620fdd

   识别论文、20任务宣称、Isaac Sim 4.0.0 与外部资产。

   `L1–49 · L51–65 · L82–118 · L120–128`

2. `Env/Config/GarmentConfig.py` ↗

   GitHub · GarmentLab/GarmentLab · 6ee0620fdd

   USD、位姿、scale、弹簧 / 碰撞材料参数。

   `L1–35`

3. `Env/env/BaseEnv.py` ↗

   GitHub · GarmentLab/GarmentLab · 6ee0620fdd

   场景导入、GPU 物理、record/replay callback 与无成功条件的 step。

   `L37–133`

4. demo/FoldDemo.py ↗
   GitHub · GarmentLab/GarmentLab · 6ee0620fdd

   固定衣物 / 抓点的示范流程，不是完整测试 case manifest。

   L1–40

5. Env/env/FoldEnv.py ↗
   GitHub · GarmentLab/GarmentLab · 6ee0620fdd

   确认场景与相机实作，以及没有 fold success checker。

   L1–87

6. demo/HangDemo.py ↗
   GitHub · GarmentLab/GarmentLab · 6ee0620fdd

   实际调用 get_reward(pick_threshold=0.5)。

   L8–35

7. Env/env/HangEnv.py ↗
   GitHub · GarmentLab/GarmentLab · 6ee0620fdd

   高度判断的具体成功函数。

   L29–59

8. Env/env/BimanualEnv.py ↗
   GitHub · GarmentLab/GarmentLab · 6ee0620fdd

   状态改写的 coverage ratio 与面积座标轴混用。

   L29–134

9. LearningBaseline/unigarmentmanip/collect/collect_cd/collect_front_open_deformation.py ↗
   GitHub · GarmentLab/GarmentLab · 6ee0620fdd

   原始 npz 与 RGB 写入键值、garment/frame 命名。

   L229–303 · L312–365

10. `LearningBaseline/unigarmentmanip/train/dataloader/dataloader.py` ↗
    GitHub · GarmentLab/GarmentLab · 6ee0620fdd

    点云 correspondence 字段、跨变形 / 跨对象配对与补样。

    L15–146

---

11. `LearningBaseline/unigarmentmanip/train/dataloader/utils.py` ↗
    GitHub · GarmentLab/GarmentLab · 6ee0620fdd

    以衣物目录做 split 与配对，不把 pair 数当衣物数。

    L5–40 · L46–65 · L88–115

---

12. `LearningBaseline/unigarmentmanip/train/base/config.py` ↗
    GitHub · GarmentLab/GarmentLab · 6ee0620fdd

    train_ratio=1 与 correspondence threshold 的实际预设。

    L1–46

---

13. `LearningBaseline/unigarmentmanip/utils/val_score.py` ↗
    GitHub · GarmentLab/GarmentLab · 6ee0620fdd

    验证入口读取 train 子集、旧 npz 键以及遗漏参数。

    L38–110

---

14. `LearningBaseline/unigarmentmanip/train/val/simple_val.py` ↗
    GitHub · GarmentLab/GarmentLab · 6ee0620fdd

    cosine correspondence 配对、欧氏误差与门槛 accuracy。

    L27–89

---

15. `LearningBaseline/rl_fold/rl_fold.py` ↗
    GitHub · GarmentLab/GarmentLab · 6ee0620fdd

    确认实际 eval 入口与30次 rollout 调用。

    L44–100

---

16. `LearningBaseline/rl_fold/config/config.yaml` ↗

    GitHub · GarmentLab/GarmentLab · 6ee0620fdd

    具体 garment、demo_point / target_point 及 task_name=hang。

    L1–38

---

17. `LearningBaseline/rl_fold/rl_utils/task_defne.py` ↗

    GitHub · GarmentLab/GarmentLab · 6ee0620fdd

    辨识 FoldTask 里的 Cartpole 范本残留，不能当 fold checker。

    L14–60 · L111–135

---

18. `LearningBaseline/rl_fold/rl_utils/rl_env.py` ↗

    GitHub · GarmentLab/GarmentLab · 6ee0620fdd

    task 在此提供 action/observation space，避免将范本 checker 误当主 evaluator。

    L111–130

---

19. `LearningBaseline/rl_fold/rl_utils/ppo.py` ↗

    GitHub · GarmentLab/GarmentLab · 6ee0620fdd

    eval_policy 真正调用 SimEnv.step(...,True) 并平均布尔回传。

    L160–216

---

20. `LearningBaseline/rl_fold/rl_utils/simulation_env.py` ↗

    GitHub · GarmentLab/GarmentLab · 6ee0620fdd

    读取抓点误差、unused 混合 reward、每回合 reset 与实际成功旗标。

    L31–149

怎么接入我们的benchmark

可重用

USD / 材料设置、场景与传感配置、固定任务脚本、点云配对结构及已查明的原生 checker。

需要转换

source 绑 commit；environment 绑资产与物理参数；task 对应实际脚本 / 配置及论文标签；case 需另建 garment_id＋初态＋示范 / seed；evaluator 分 geometry matching、抓点成功、挂衣高度、论文持续成功。数据配对数、render frames、衣物对象与30次RL评测不可混算。

仍需补齐

完整20任务 case/split manifest；fold IoU / 持续5秒的可运行 checker；原始npz→标注npz→val_score的字段桥接与threshold修正；coverage轴向与state mutation决策；资产、真机benchmark文件及校正尚未纳入可运行接线。

P088 · FlingBot

FlingBot: The Unreasonable Effectiveness of Dynamic Manipulation for Cloth Unfolding

内核内容已核读 · 主来源 · 原作 · 独立页面

已核读 FlingBot 的模拟 / 真机 task 与 replay HDF5、coverage checker、evaluation 入口及汇总。原生 task 是衣物形状 / 材质 / 初态的一笔配置，目标仍是展布；模拟与真机 coverage 的原始单位不同。另确认非重复 loader 的末笔等待问题及汇总过滤会影响分母。

> **版本与身份**
>
> 固定2021-10-13 commit，原论文PDF缓存为后续2021-10-18版；保留版本差异。environment/Memory.py是symlink文字，实作读到learning/Memory.py。未运行任何模拟、GPU模型、机器人控制或下载衣物HDF5。
>
> 论文 arXiv:2105.03655 与 README 作者 Huy Ha / Shuran Song 对应。binding 的 columbia-robovision/flingbot 在缓存 GitHub metadata 解析为 real-stanford/flingbot；保留 requested_repo 与 resolved_repo，不能当两个独立来源。论文亦使用 columbia-ai-robotics 旧网址。 旧入口columbia-robovision/flingbot的已保存GitHub metadata回应指向real-stanford/flingbot，按仓库别名保留，不另外算成未读的第二个仓库。

领域	衣物与洗护
环境	模拟为修改 SoftGym/PyFlex 的 CUDA 粒子布料环境，抽象双picker配合UR5可达性边界；使用Blender或OpenGL，论文设置为Blender。真机为两支UR5、RG2 / WSG50、顶视Azure Kinect及前视RealSense；setup.py 只留一件衣物参考与设备位置参数，未提供完整论文实体资产清单。
任务	展布 / 最大覆盖面积是一个目标族；Normal Rect、Large Rect、Shirt 是形状 / 尺寸泛化设置。fling、stretchdrag、drag、place 是 action primitives，不是四个新的生活任务。TaskLoader 的 task_name 是 HDF5 配置ID；生成group key是对当时记录数字取SHA1，不是状态内容哈希。论文600模拟测试配置＝三类各200，真机三类各10次；2000训练配置及150真机调适回合另列，未下载HDF5验证实际记录数。

题数与数据	task HDF5 以group保存 particle_pos、particle_vel、shape_pos、phase、cloth_size、cloth_stiff、mesh_verts / faces / stretch/bend/shear edges；flatten_area、initial_coverage、cloth_mass、task_difficulty为attribute。方布尺寸为粒子数，预设半径0.00625m；mesh尺寸用[-1,-1]、flatten_area取trimesh面积/2。replay每个{episode:09d}_step{step:02d}（尾步加_last）为一笔action；含observations、actions单像素mask、rewards、is_terminal、next_observations及rotation/scale/action_primitive/task_name/preaction_coverage/postaction_coverage/max_coverage。RGB/255＋depth为4×H×W、策略预设仅用RGB与64×64输入；action需连同图像旋转缩放与可达性转换解码。
评估方式	模拟coverage是100×100 xz占格的面积（原生m²）；step reward为A_after−A_before，学习label预设再除flatten_area。方布reference来自展平网格，mesh取表面面积/2。真机coverage是HSV背景分割后最大连通区像素占全图像比例，再除同相机的flatten_area参考；不能把此原始值当m²。10 primitive actions内可提前终止：模拟最大粒子位移<0.05，真机前后mask IoU>0.9，均代表停滞而非成功。collect_stats报normalized final/best/delta coverage，未裁至[0,1]；跳过failed_grasp/cloth_stuck/timed_out、缺max_coverage及postcoverage/reference<0.05的记录。其episode_length直接读零起始尾步索引，真正动作数需+1。run_sim预设统计最近128个step groups；visualize.summarize用1e7上限读全buffer，不可把在线平均当全测试分数。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **1** cloth-unfolding goal family · 原文页 6
- **600** simulation test initializations · 原文页 7
- **30** real test cases，3types×10 · 原文页 7

依这个顺序读

1. `README.md` ↗

   GitHub · real-stanford/flingbot · c5f35c785c

   确认论文、SoftGym/PyFlex 衍生、三种测试衣物设置与真机设备。

   `L1–46 · L79–87 · L123–215 · L217–280`

2. `environment/tasks.py` ↗

   GitHub · real-stanford/flingbot · c5f35c785c

   核对任务生成、mesh / 粒子状态、HDF5 格式及 nonrepeat loader。

   `L105–219 · L261–421 · L436–479`

3. `environment/simEnv.py` ↗

   GitHub · real-stanford/flingbot · c5f35c785c

   action primitive、逐步记录、coverage delta 与终止机制。

   L33–117 · L431–516 · L663–689 · L782–807

---

4. `environment/flex_utils.py` ↗

   GitHub · real-stanford/flingbot · c5f35c785c

   实际 xz 网格面积与方布 flatten reference。

   L358–415

---

5. `environment/Memory.py` ↗

   GitHub · real-stanford/flingbot · c5f35c785c

   确认该档是指向 learning/Memory.py 的链接内容。

   L1–1

---

6. `learning/Memory.py` ↗

   GitHub · real-stanford/flingbot · c5f35c785c

   episode-step HDF5 的 attribute/dataset、最后步与嵌套数据。

   L9–23 · L55–80 · L106–165

---

7. `learning/utils.py` ↗

   GitHub · real-stanford/flingbot · c5f35c785c

   读取 replay 的 observation/action mask 及 normalized coverage label。

   L12–44 · L76–100

---

8. `environment/utils.py` ↗

   GitHub · real-stanford/flingbot · c5f35c785c

   RGB/255 与原生 depth 组成 CHW，以及真机 segmentation 后处理。

   L579–602

---

9. `run_sim.py` ↗

   GitHub · real-stanford/flingbot · c5f35c785c

   确认 eval / 训练入口与定期 collect_stats。

   L37–109

---

10. `utils.py` ↗

    GitHub · real-stanford/flingbot · c5f35c785c

    eval 停止更新、loader 接线、raw/final/delta 统计、排除规则与零起始步索引。

    L17–88 · L100–157 · L186–336 · L337–376

---

11. `visualize.py` ↗

    GitHub · real-stanford/flingbot · c5f35c785c

    脱机 summary 使用全buffer上限，与训练128步窗口分开。

    L1–43

---

12. `real_world/setup.py` ↗

    GitHub · real-stanford/flingbot · c5f35c785c

    真机衣物 reference、workspace crop 与空白设备配置。

    L7–52

---

13. `real_world/realWorldEnv.py` ↗

    GitHub · real-stanford/flingbot · c5f35c785c

    真机同名 task 与原生 IoU 停滞、失败旗标、传感缩放。

    L1–63 · L96–163 · L367–394

---

14. `real_world/utils.py` ↗

    GitHub · real-stanford/flingbot · c5f35c785c

    真机 mask coverage 是图像像素比例，并核对像素至机器人座标转换。

    L22–69

怎么接入我们的benchmark

可重用

Task状态重设、HDF5 reader/writer、action transformation字段、raw与normalized coverage及failure flags。

需要转换

source保存旧repo别名及resolved commit；environment分模拟 / 真机与renderer；task保存展布目标及primitive；case用dataset哈希＋task_name＋形状设置；rollout另存episode/step/action_count；evaluator明列面积或像素比例、reference方法及过滤后分母。

仍需补齐

三测试HDF5 / 训练HDF5的哈希与mesh split；nonrepeat loader末笔问题修正或保留原版行为；未排除失败的系统评测分母；真机衣物完整表、校正与背景设置；native step index转操作次数验证。

P089 · SpeedFolding

SpeedFolding: Learning Efficient Bimanual Folding of Garments

内核内容已核读 · 主来源 · 原作 · 独立页面

已核读 SpeedFolding 的真机流程、SQLite/PNG 格式、BiMaMa 数据 reader、折线指令与具体 coverage reward。evaluation.py 只记录事件 / 时间，folded 事件也不是独立成功判定；论文折衣成功须保留三位人类评阅者多数决。公开版本另有 reader / writer 界面不一致。

> **版本与身份**
>
> 固定2023-12-11 commit，晚于2022论文；README已明示硬件相依参考程序。未连接数据库、相机或YuMi，未下载15.2GB数据集或运行模型。
>
> README直接链接 arXiv:2208.10552 与 pantor 官方项目页，明示 IROS 2022 / ABB YuMi＋PhoXi 的硬件相依参考实作。

领域	衣物与洗护
环境	实体ABB YuMi双臂平行夹爪、海绵工作面、PhoXi顶视灰阶 / 深度，以及额外webcam coverage。软件包含OMPL与PhoXi C++ wrappers，README明示不易直接运行。pixel_to_transform从校正point cloud取xyz、以theta设置gripper姿态；图像位姿不能直接当已校正机器人动作。
任务	流程是先平整衣物，再依用户折线 / 2-second heuristic / fling-to-fold完成折衣。shirt.json有两种顺序、每种三条折线，属同一目标的候选程序，不是6个任务。loader的fling、fling-to-fold、pick-and-hold、drag、done为训练primitive类别。论文每组实验15 trials，4300训练action records含1500拷贝重标；不能把records、物理操作、完整折衣trial及任务名称混算。
题数与数据	SQLite actions(id,episode_id,action_id,data JSON)与 images(episode_id,action_id,scene,camera,hash)；PNG路径为 collection/episode_id/{action_id}-{scene}-{camera}.png，scene含before/after，camera可为color/depth/ortho-color/ortho-depth。JSON保存type、poses[{x,y,theta}]、reward、needs_annotation、is_human_annotated、is_self_supervised。Saver把0.85–1.25m深度反向线性映射0–255并裁切，0深度先改1.25m，不能把PNG值当公尺。BiFoldingDataset读灰阶与量化深度两通道，按1032×772来源尺寸crop后resize到256×192、theta为弧度及20个离散方向。预设以episode_id的SHA256低16bit阈值做约80/20 train/test，非衣物对象切分；run.py每个action新建Episode，因此该ID未必代表整个物理trial。

评估方式	reward.segment以灰阶阈值90、形态学与最大轮廓产生mask；calculate_reward为tanh(64×A_before×(A_after−A_before))，A为mask像素占比。另一个coverage＋confidence reward函数存在，但run.py调用前者。Experiment.take_coverage用校正webcam、阈值130并回传轮廓面积/图像面积。done是模型分类的Sufficiently Smoothed停止决策；运行折线后直接记folded事件，不代表成品合格。Evaluation记相对启动秒数及profile duration，未实作三人投票或完整FPH。论文成功要求10动作内且三位评阅者多数通过，排除motion-planning早退；表I duration只平均成功trial，cycle time/FPH包含成功与失败。程序CLI horizon预设3，README实验设10；run.py horizon限制平整循环，后续折线及move另外运行，须明订共同action budget。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **4,300** training action records，含重标 · 原文页 6
- **15** trials per experiment · 原文页 6, 7

依这个顺序读

1. `README.md` ↗

   GitHub · pantor/speedfolding · db06519a2f

   确认论文身分、硬件限制、来源结构与测试命令。

   L29–87

2. `learning/database.py` ↗

   GitHub · pantor/speedfolding · db06519a2f

   SQLite schema、JSON action、图像引用及episode_id哈希分割。

   L13–109 · L121–126

3. `manipulation/saver.py` ↗

   GitHub · pantor/speedfolding · db06519a2f

   实际writer签名、每次新ID与depth压至PNG的尺度。

   L11–78

4. `learning/bimama/dataset.py` ↗

   GitHub · pantor/speedfolding · db06519a2f

   观测灰阶＋深度、五个primitive classes、heatmaps、标注权重及split。

   L20–103 · L109–175

---

5. `data/instructions/shirt.json` ↗

   GitHub · pantor/speedfolding · db06519a2f

   两个折线顺序候选、三条折线与两个grasp-points。

   L1–27

---

6. `manipulation/heuristics/matching.py` ↗

   GitHub · pantor/speedfolding · db06519a2f

   读取template与instructions，pixel equality配准后选候选。

   L13–28 · L54–106

---

7. `manipulation/heuristics/folding.py` ↗

   GitHub · pantor/speedfolding · db06519a2f

   折线像素化、轮廓抓点及镜像放置。

   L9–98

---

8. `manipulation/experiment.py` ↗

   GitHub · pantor/speedfolding · db06519a2f

   像素→3D pose、webcam coverage及折线运行，没有成品裁判。

   L77–92 · L210–244 · L1033–1087

---

9. `learning/inference.py` ↗

   GitHub · pantor/speedfolding · db06519a2f

   done由模型primitive分类选出，非折衣成功checker。

   L181–229 · L272–286

---

10. `learning/reward.py` ↗

    GitHub · pantor/speedfolding · db06519a2f

    灰阶分割、area fraction及实际tanh reward；辨别备用confidence reward。

    L5–64

---

11. `manipulation/evaluation.py` ↗

    GitHub · pantor/speedfolding · db06519a2f

    具体event elapsed time / profile duration，而非成功率计算器。

    L1–47

---

12. `manipulation/run.py` ↗

    GitHub · pantor/speedfolding · db06519a2f

    horizon、folded事件、每action新Episode、失败排除及实际writer调用。

    L17–29 · L69–129 · L143–209

怎么接入我们的benchmark

可重用

折线JSON＋template、图像 / action DB索引、primitive运行脉络、coverage reward及事件计时。

需要转换

source绑commit；environment绑YuMi工作站与相机校正；task绑衣物与折线程序；case添加完整trial_id、garment_id与初态，连到多个action record；evaluator分smoothing confidence、grasp failure、coverage、成品人评与duration/cycle/FPH，明列排除及分母。重标记录保留来源action关系，量化depth需用尺度 / 缺测mask解码。

仍需补齐

人评票决与完整trial成品图像 / 耗时表；去除重标后的数据lineage及物理trial切分；公开reader/writer兼容性修正；硬件 / template / weights资产与校正接线。

P090 · Cloth Funnels

Cloth Funnels: Canonicalized-Alignment for Multi-Purpose Garment Manipulation

内核内容已核读 · 主来源 · 原作 · 独立页面

已核读 Cloth Funnels 模拟的 task HDF5、mesh split、replay reader/writer、刚体 / 变形距离及实际 eval_buffer。生成脚本规划每类400个eval配置，但公开eval链只选hard子集；汇总固定取每回合最大IoU步，并非函数参数宣称的第n步或最终步。

> **版本与身份**
>
> 固定2025-08-23 commit，晚于2022 arXiv；README标ICRA2023但BibTeX仍填2022，保留原论文与公开程序版本。只核读所列模拟来源段落，未运行GPU、下载task/weights或宣称真机全流程可用。
>
> README 题名、七位作者与 arXiv:2210.09347 对应本篇；binding旧网址 columbia-ai-robotics/cloth-funnels 解析为 real-stanford/cloth-funnels。保留原始别名、canonical repo与同一commit，避免重复来源。 旧入口columbia-ai-robotics/cloth-funnels的已保存GitHub metadata回应指向real-stanford/cloth-funnels，按仓库别名保留，不另外算成未读的第二个仓库。

领域	衣物与洗护
环境	修改版FleX/PyFlex粒子衣物与抽象双picker，可达性与table参数另存；本轮核读README主张的模拟评测链。原生xyz中y为高度，canonicalized-alignment要求指定平面姿态与衣物形状；高coverage不能代替对齐。真机文件虽在tree，本轮未声称真机 / 熨烫评测已完整核读。
任务	主要目标为canonicalized-alignment，place/fling为预设primitive；longsleeve/pants/dress/jumpsuit/skirt为五衣物类别。生成脚本每类目标配额2000 train＝1500 hard＋500 easy、400 eval＝200 hard＋200 easy；第二次命令的num_tasks是累积配额，不再相加。实际eval loader只取hard，因此README的200与整份400有子集差异；未下载HDF5确认实际完成配额。fold_finish为下游shirt heuristic，不另当完成验证的benchmark。
题数与数据	类别JSON以train/test清单选mesh，生成器按args.eval抽对应衣物ID；不能用同档未被调用的is_eval前缀helper替代。task HDF5包含particle_pos（扰动后起始状态）、init_particle_pos（canonical目标）、particle_vel、shape_pos、phase、mesh_verts/faces/edges/nocs、cloth_instance、pkl_path、init_rgb/task_rgb、cloth_height/width与keypoint groups。flatten_area为mesh表面面积/2，get_config.cloth_area却是cloth_height×cloth_width；距离范式用后者。replay为episode_stepXX[_last]，有观测、单像素action mask、旋转 / scale / primitive、pre/postaction_verts / masks、各metric与deformable_weight。writer丢掉task_name及cloth_instance，但保留task_pkl_path与init_verts；sum(init_verts)仅是既有查找惯例，不是可靠唯一ID。

评估方式	SimEnv.deformable_reward→learning.utils.deformable_distance：goal/current先将y设0，保留相同mesh顶点对应；以SVD及5次距离子集配准取得变形残差，逆向配准取得刚体偏移，允许x镜像取较小距离。原生l2_distance是变形项、icp_distance是刚体项、pointwise_distance是未配准点距；各除sqrt(cloth_height×cloth_width)，weighted_distance预设0.65×变形＋0.35×刚体。mask为RGB通道和>0；IoU=交集/联集，coverage=当前mask像素/目标mask像素。init mask失败时退用当前mask，应保留异常。SimEnv保存rewards=0，学习reader才从pre–post metric重建reward并用0.072等尺度标准化，不能直接平均rewards栏。eval_buffer先hard-only，再每个episode固定选postaction_iou最大步，无视evaluate(mode,n)，10轮循环实际重复相同选择，报mean与std/sqrt(N)。fold_finish在最后一步以三段shirt heuristic替代policy primitive，没有独立折衣成品checker；应分开canonicalization与downstream成功。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **5** garment categories · 原文页 5
- **400** unseen-mesh test settings per category · 原文页 5

依这个顺序读

1. `README.md` ↗

   GitHub · real-stanford/cloth-funnels · 3b355304a6

   确认论文、200个crumpled eval叙述、五衣物类及FlingBot/SoftGym来源。

   L1–46 · L81–85 · L125–155 · L162–249

2. `cloth_funnels/conf/config.yaml` ↗

   GitHub · real-stanford/cloth-funnels · 3b355304a6

   核对训练8步 / eval覆写10步、primitive、观测与0.65权重。

   L1–20 · L29–49 · L57–114

3. `cloth_funnels/cloth_data/cloth3d_pickle/longsleeve.json` ↗

   GitHub · real-stanford/cloth-funnels · 3b355304a6

   实际train/test mesh ID列表，非由文件名前缀猜split。

   L1–1

4. `cloth_funnels/tasks/generate_tasks_script.py` ↗
   GitHub · real-stanford/cloth-funnels · 3b355304a6

   2000训练与400测试生成配额、hard/easy的不同扰动。

   L1–41

---

5. `cloth_funnels/tasks/generate_tasks.py` ↗
   GitHub · real-stanford/cloth-funnels · 3b355304a6

   确认canonical goal / 扰动初态、HDF5字段、cloth_area与hard-only loader。

   L54–173 · L255–293 · L330–367 · L374–424 · L457–505 · L532–596

---

6. `cloth_funnels/environment/Memory.py` ↗
   GitHub · real-stanford/cloth-funnels · 3b355304a6

   读到symlink目标，避免把链接文字当writer。

   L1–1

---

7. `cloth_funnels/learning/Memory.py` ↗
   GitHub · real-stanford/cloth-funnels · 3b355304a6

   episode-step串行化及被刻意省略的task_name/cloth_instance字段。

   L109–178

---

8. `cloth_funnels/learning/utils.py` ↗
   GitHub · real-stanford/cloth-funnels · 3b355304a6

   追到SVD配准与范式距离、reward重建及HDF5 reader。

   L32–199 · L270–343

---

9. `cloth_funnels/environment/simEnv.py` ↗
   GitHub · real-stanford/cloth-funnels · 3b355304a6

   实际调用metric、mask计分、zero reward字段、失败reset、fold_finish与canonical reference。

   L6–41 · L696–779 · L782–832 · L855–873 · L876–922 · L945–1024 · L1330–1404 · L1430–1450

---

10. `cloth_funnels/environment/flex_utils.py` ↗
    GitHub · real-stanford/cloth-funnels · 3b355304a6

    实际导入版本的粒子覆盖面积函数。

    L269–300

---

11. `cloth_funnels/utils/env_utils.py` ↗
    GitHub · real-stanford/cloth-funnels · 3b355304a6

    六点几何导出三段下游折衣动作，不是成功裁判。

    L890–936

---

12. `cloth_funnels/utils/utils.py` ↗
    GitHub · real-stanford/cloth-funnels · 3b355304a6

    eval_tasks / TaskLoader与SimEnv接线，另读到sum(init_verts)重建查找。

    L100–148

---

13. `cloth_funnels/run_sim.py` ↗
    GitHub · real-stanford/cloth-funnels · 3b355304a6

    eval不更新模型、max_steps为buffer大小限制而非唯一case数。

    L106–120 · L134–170 · L184–193

---

14. `cloth_funnels/scripts/eval_buffer.py` ↗
    GitHub · real-stanford/cloth-funnels · 3b355304a6

    完整阅读hard过滤、legacy metric名称与固定max_iou步选择。

    L8–38 · L41–160

怎么接入我们的benchmark

可重用

mesh split与task目标 / 初态、固定对应顶点、分解距离 / mask metric、HDF5状态与primitive数据。

需要转换

source绑canonical repo及commit；environment保留FleX/renderer/座标系；task保存对齐目标、衣物类及fold_finish协定；case用task来源哈希＋原group ID＋mesh ID＋扰动；evaluator把legacy名称映到deformable/rigid/pointwise并保存范式面积、镜像规则与step-selection。保留hard子集分母及policy-step与heuristic动作数，禁止自动转成共同success。

仍需补齐

实际task HDF5清单与case/replay稳定对照；非重复loader末笔等待修正；最大IoU / nth / last选步协定；失败reset未落档的分母；下游fold / 真机与熨烫成功规则及资产校正。

P091 · UniFolding

UniFolding: Towards Sample-efficient, Scalable, and Generalizable Robotic Garment Folding

内核内容已核读 · 主来源 · 原作 · 独立页面

已核读 UniFolding 的 VR HDFStore、runtime YAML/NPZ/PLY、动作与标注格式、模拟几何计分及真机状态机。真机 SUCCESS 是流程状态：fold1/fold2 条件以最后 action 类型推定，并无成品几何验收；原始论文10步内按折法完成的成功率需另保留评阅证据。

> **版本与身份**
>
> 固定2024-10-18 commit，晚于2023论文。核读限Python数据 / task / metric与控制流程，未核读所有电机控制 / Unity插件底层，未运行上游程序、连接标注数据库 / 通知或下载模型与大型资产。 已补读VR-Garment c9014f62的收集与回放数据契约；它本是GarmentTracking工具，UniFolding引用作Stage0上游。未使用VR硬件或运行Unity。
>
> README 明示官方 CoRL 2023 程序，完整题名、六位作者与 arXiv:2311.01267 相符。RFUniverse、CLOTH3D、VR-Garment 与 ClothFunnels 各有重用角色，不把框架 / 母数据集当成本篇新benchmark。

领域	衣物与洗护
环境	模拟是Unity 2022.3 LTS上的RFUniverse，README要求另取得Cloth Dynamics 2.0.9 beta；CLOTH3D衣物依category meta与instance filter加载。真机是双Flexiv Rizon 4、AG-95与Photoneo MotionCam3D＋MindVision RGB。Unity左手系先转Open3D右手系，再转virtual/world/左右robot frames；virtual以z为高度，配置另有particle_scale=100与time_scale=4，不能直接沿用FleX的y-up或将步数当秒。
任务	两种衣物tshirt_long / tshirt_short的展开→fold1→fold2流程；附录C先同时折两袖，再对半折本体，精确抓放点由VR人类示范生成。ActionTypeDef包含FLING/DRAG/FOLD_1/FOLD_2/PICK_AND_PLACE/DONE及恢复 / HOME等，是动作enum而非同数量任务。ExperimentVirtual.execute_action只实作FLING，random_fold用于初态，不能宣称runtime模拟提供完整折衣动作集。论文60件真衣物以2:1分割，20件held-out各10trials＝200次测试；2432是训练sample、每sample16次人类偏好比较，不是测试cases。

题数与数据	VR data.h5 的Pandas df以instance_id/video_id/sample_id标识，读pcd_path_frame1→NumPy Nx6 xyz/rgb、nocs_path_frame1、coverage_frame1/2、左右gripper_point/theta_frame1/2、action_type、folding_step、is_smoothed/is_smoothing。raw fold依folding_step映为fold1/fold2；pose内部顺序为左pick、左place、右pick、右place，角度wrap至±π。VR依instance_id打乱切分，所读stage1 config为8/1/1；runtime real/virtual却依sample打乱，不能等同论文对象held-out split。runtime metadata按namespace记pcd.processed.begin、processed_nocs.begin、pose_virtual、reward.begin/end及episode_idx/trial_idx/action_step；NPZ键为points/nocs，real另接受PLY。annotation.action_poses原顺序左pick、右pick、左place、右place，reader重排后将角度全设0；虚拟fling place亦用0占位，应保存validity而非当有效目标。偏好0/1/2/3分别为左对优 / 右对优 / 相等 / 不可比较，经label smoothing后监督分数模型。 VR-Garment补查：PoseData包含dualHandPoses（position / Euler / 手势）、localParticles（solver renderable positions / normals）、左右grasp solver indices、solver / actor local-to-world矩阵和Time.time。Record名义每0.04秒调用，应保留实际timestamp而非假设等间隔。JSON录制再回放输出AnimationData及color/depth/mask图像引用的BSON；四个随机相机视角共用同一段示范。
评估方式	虚拟get_deformable_reward以canonical初态粒子覆盖面积作max_coverage，在virtual XY平面用100×100粒子网格；IoU另外把两组XY点共同缩放至0–99并画半径2圆，以点阵交集/联集计算，不是RGB图像mask IoU。reward.py沿用ClothFunnels分解形式，但此版把z归零、同顶点SVD配准5次、镜像取min，距离除sqrt(初态粒子覆盖面积)，stage2权重0.7；与P090用长×宽范式不同。runtime学习用begin–end的l2/icp改善量；VR则用同instance的coverage_frame1最大值范式、stage1以max(tanh(2Δcoverage+coverage_after),0)给fling标签，fold等固定0.8、done为0，均非实测成功率。真机state machine把fold成功设为最后action_type==FOLD_1/FOLD_2，garment_fling_drag_success固定True且有TODO；operable只看mask面积上限、reachable看mask横向均值，没有成品折法验收。step_idx>max_num_steps非全域强制终止，部分转移还要求不可操作，lift与fold前drag循环不按每个物理动作累加。论文要求10动作内按规则完成，这与状态机SUCCESS需分栏。 VR收集工具的开始 / 清除 / 保存由手势或按键触发，超过maxFrameCount仅提示；录完不表示通过折叠成功判分。ClothImitation2 / AnimationImitation2是录制与回放场景，不能加成两个新任务；四视角不加成四段独立示范。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **20** held-out real garments · 原文页 6
- **200** real trials，20garments×10 · 原文页 6
- **2,793** VR manipulation videos · 原文页 5

依这个顺序读

1. `README.md` ↗

   GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

   确认论文、数据 / 硬件、VR收集与四阶段流程。

   L1–9 · L48–70 · L109–146 · L154–166

---

2. `RFUniverse/README.md` ↗

   GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

   Unity/RFUniverse与需另取得的Cloth Dynamics版本，非完整自含模拟器。

   L1–38 · L66–76

---

3. `common/datamodels.py` ↗

   GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

   动作enum、两支手臂pick/place、观测与四类偏好标注。

   L13–135 · L182–210 · L236–276

---

4. `learning/datasets/vr_dataset.py` ↗

   GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

   HDFStore df、frame pair / fold_step映射、虚拟示范reward与instance split。

   L25–60 · L134–137 · L146–227 · L252–314 · L357–422

---

5. `config/virtual_experiment_stage1/train_virtual_base.yaml` ↗

   GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

   确认8/1/1 split、点云抽样、voxel与tanh reward设置。

   L1–31 · L63–86

---

6. `learning/components/obj_data_loader.py` ↗

   GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

   CLOTH3D instance filter、category meta与worker分块，勿当数据split。

   L9–85

---

7. `learning/datasets/runtime_dataset_virtual.py` ↗
   GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

   虚拟log的NOCS / points、抓点零值占位、metric delta及sample切分。

   L210–231 · L246–302 · L316–359

---

8. `learning/datasets/runtime_dataset_real.py` ↗
   GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

   metadata与annotation读取、pose重排、偏好label及sample切分。

   L131–187 · L216–308 · L323–365

---

9. `learning/components/cloth_dynamics_env.py` ↗
   GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

   读Unity消息解码、左右手座标、depth前景及NOCS对应。

   L126–158 · L189–208 · L309–330 · L359–375

---

10. `manipulation/experiment_virtual.py` ↗
    GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

    虚拟座标转换、只支持FLING的runtime运行与具体reward调用。

    L39–113 · L274–355

---

11. `common/metric_utils.py` ↗
    GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

    XY粒子面积与100×100点阵IoU的真正公式。

    L1–70

---

12. `common/geometry_util.py` ↗
    GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

    面积grid辅助函数与SVD刚体配准。

    L90–142

---

13. `learning/components/reward.py` ↗

GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

投影、镜像、分解距离及面积范式的具体实作。

L1–101

---

14. `config/virtual_experiment_stage2/experiment_virtual_base.yaml` ↗

GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

runtime粒子缩放 / 时间尺度、5步收集及0.7 reward权重。

L19–78 · L127–140

---

15. `run_virtual.py` ↗

GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

一笔action的begin/end观测、metric及episode/garment/trial/step脉络。

L64–113 · L132–155

---

16. `Makefile` ↗

GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

两类衣物测试target覆写每件10trials并关闭探索。

L81–98

---

17. `config/real_experiment/experiment_real_base.yaml` ↗

GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

真机校正、mask门槛、10步与barrier / runtime training设置。

L5–79

---

18. `config/real_experiment/experiment_real_tshirt_long.yaml` ↗

GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

长袖test使用的base继承与衣物设置。

L1–19

---

19. `config/real_experiment/experiment_real_tshirt_short.yaml` ↗

GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

短袖test使用的base继承与衣物设置。

L1–19

---

20. `run_real.py` ↗

GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

依garment与trial运行状态机，及测试target仍可能进入训练路径。

L82–117 · L143–228

---

21. `manipulation/statemachine_garment.py` ↗

GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

核对SUCCESS条件、TODO布尔、非全域步数上限与错误处理。

L19–138 · L249–306 · L325–348 · L395–459

---

22. `manipulation/experiment_real.py` ↗

GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

mask / point cloud传感、可操作 / 可达判断及实体fold动作dispatch。

L493–570 · L635–665 · L742–767

---

23. `README.md` ↗

GitHub · xiaoxiaoxh/VR-Garment · c9014f626e

核对VR硬件、Unity2021.3、record/replay两场景及数据角色。

L1–71

---

24. `Assets/Scripts/Imitation2/ObiSceneManagerImitation2.cs` ↗

GitHub · xiaoxiaoxh/VR-Garment · c9014f626e

读PoseData字段、名义25Hz / Time.time、手姿及抓取粒子、JSON保存。

L62–124 · L160–168 · L457–575

---

25. `Assets/Scripts/Imitation2/AnimateImitation2.cs` ↗

    GitHub · xiaoxiaoxh/VR-Garment · c9014f626e

    读四视角图像 / 相机矩阵、mesh/hand数据与BSON回放输出。

    L83–129 · L250–324 · L452–476 · L484–541

怎么接入我们的benchmark

可重用

原生动作 / 观测 / annotation dataclasses、frame pairs与偏好、instance与sample索引、模拟几何metric及真机流程状态。

需要转换

source固定commit并标记VR-Garment/CLOTH3D/ClothFunnels重用；environment保存Unity/Open3D/virtual/world/robot座标链；task保存衣物类与两段折法；case保留完整garment/trial/step、checkpoint、split粒度；evaluator分模拟距离、VR训练reward、preference target、真机流程状态及独立成品成功。保留特权粒子/NOCS，勿当真机可观测量；人类VR示范须经primitive与校正adapter才能成为robot命令。 VR原生Unity / solver座标、Euler顺序、BSON/JSON与视角 / timestamp对应须保留并校验；不得直接视为米制robot命令。

仍需补齐

VR→UniFolding前处理与data.h5/NPZ/annotation/instance清单闭合；对象held-out真机200trials的逐次成品评阅；严格10物理action budget；pure evaluation入口与网络 / barrier相依隔离；Unity付费插件 / CLOTH3D / 硬件校正取得与运行验证。

P092 · ICRA cloth competition

A Dataset and Benchmark for Robotic Cloth Unfolding Grasp Selection: The ICRA 2024 Cloth Competition

内核内容已核读 · 主来源 · 原作 · 独立页面

竞赛仓库公开双臂布料观测格式与半自动面积量测；coverage 原始面积与范式竞赛得分需要分开。

> **版本与身份**
>
> 钉选2024竞赛仓库；README的未来式文字不能否定已存在的evaluation-service。已读内核章节，未重现比赛。

领域	衣物与洗护
环境	真实双UR5e / Robotiq工作站及双目深度相机；Drake场景供运动规划，布料点云凸包焊接为障碍，不代表完整柔性物理模拟。
任务	布料摊展竞赛中的抓取与展开结果；每次sample/scene及衣物初态不是新的任务语义。
题数与数据	CompetitionObservation含左右RGB、与左图对齐depth_map、confidence_map、世界座标point_cloud、相机 / 左右臂 / TCP世界姿态与关节；文件为PNG/TIFF/PLY/JSON，读写程序明确处理RGB/BGR。README指向83GB外部数据，未下载。
评估方式	组织者选框 / 正负点→SAM遮罩→按平均深度±outlierThreshold过滤→每像素投影面积加总。server.py把此原始面积写为coverage；README所述相对最大可展面积之比例仍需衣物基准面积，不能直接把输出值当0–1成功率。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **1** 内核unfold grasp-selection任务 · 原文页 6, 7
- **34** cloth items · 原文页 8
- **679** recorded unfolding episodes · 原文页 8
- **176** 11方法竞赛trials · 原文页 8, 11

依这个顺序读

1. README.md ↗
   GitHub · Victorlouisdg/cloth-competition · 34dcac88c9

   确认竞赛、数据与程序角色

   L1–24

---

2. cloth-tools/cloth_tools/dataset/format.py ↗
   GitHub · Victorlouisdg/cloth-competition · 34dcac88c9

   原生双目 / 深度 / 世界座标 / 双臂观测保存及读取

   L29–75 · L78–222

---

3. cloth-tools/cloth_tools/drake/scenes.py ↗
   GitHub · Victorlouisdg/cloth-competition · 34dcac88c9

   双UR5e工作站与布料碰撞近似

   L31–91

---

4. evaluation-service/README.md ↗
   GitHub · Victorlouisdg/cloth-competition · 34dcac88c9

   人工选区与竞赛coverage定义

   L1–19

---

5. evaluation-service/backend/server.py ↗
   GitHub · Victorlouisdg/cloth-competition · 34dcac88c9

   SAM遮罩、深度离群值、相机投影面积与输出

   L42–82 · L81–178

怎么接入我们的benchmark

可重用

原生观测字段、相机标定 / 机体座标、选区与面积量测纪录。

需要转换

environment记工作站与标定版本，case连sample及衣物初态；evaluator保留原面积单位、最大面积分母、人工框点、SAM版本、过滤参数与复核。

仍需补齐

数据资产、衣物最大面积基准、合法介入规则与一致性评估、可重设初态及整体竞赛分数聚合尚需接入。

P093 · MoDeSuite

MoDeSuite: Robot Learning Task Suite for Benchmarking Mobile Manipulation with Deformable Objects

内核内容已核读 · 主来源 · 原作 · 独立页面

MoDeSuite有8种移动柔性物任务；具体Spot-Place程序可追到9维控制、观测组合与on_table判定，但结束信号及README命令需要核对。

> **版本与身份**
>
> README连2507.21796，仓库2026发布。README写scripts/，实际程序在script/；安装 / 授权需读正式文件，不仅靠MIT徽章。本笔以Spot-Place为具体程序抽读，不宣称8类所有程序都逐行核读。

领域	居家整理与清洁、衣物与洗护
环境	Isaac Sim 4.2 / Isaac Lab，Spot带臂与轮式Franka；含杆、带、布等及桌面、走廊、障碍。Spot-Place使用USD桌与杆，num_envs=4是平行复本，不是4种不同环境。
任务	README列Place/Bend/Transport/Drag/Lift/Uncover/Cover/Curtain共8种，分5弹性 / 3塑性；Gym的机体与PPO/SAC注册不能当新语义任务。Cover文字误重复Uncover描述，需以各具体程序与论文厘清。
题数与数据	Spot-Place配置9维动作=3基座+6手臂，sim.dt=1/200、decimation=2；policy观测拼杆节点位置、机体位置 / 四元数、桌中心、关节位置 / 速度。play记action/obs/reward/timestep至pickle；不可把58维配置声明当已验证实际tensor形状。
评估方式	on_table要求杆端落在桌中心x±0.38、y±0.54、z至z+0.08内且杆中点高于桌面；reward另外含距离、成功bonus及失衡罚分。_get_dones返回(time_out, on_table或失衡)，对DirectRLEnv界面的terminated/truncated及wrapper需专门验证，不能直接把done当成功。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **8** mobile deformable tasks · 原文页 1, 3, 4, 5
- **5** 添加elastic tasks · 原文页 3
- **20** 评测trials / 设置 · 原文页 6

依这个顺序读

1. README.md ↗
   GitHub · carolzyy/MoDeSuite · 470681a7ff

   核对精确论文、8种任务、两种机体及外部数据

   L1–150

---

2. task/Drag/__init__.py ↗
   GitHub · carolzyy/MoDeSuite · 470681a7ff

   同一任务因机体 / 算法出现不同Gym ID

   L1–49

---

3. task/Place/spot_place_env.py ↗
   GitHub · carolzyy/MoDeSuite · 470681a7ff

   资产、步频、控制 / 观测、原生成功条件与done顺序

   L25–98 · L171–204 · L249–365

---

4. script/play.py ↗
   GitHub · carolzyy/MoDeSuite · 470681a7ff

   rollout记录与输出格式；不是已验证总表评分器

   L168–218

怎么接入我们的benchmark

可重用

8种原生任务标签、机体 / USD配置、各task class、控制与成功predicate。

需要转换

task连原生class，environment拆资产/初态/机体；case记seed、步频、控制约定及信息预算；evaluator独立保留success、失衡、timeout与reward。

仍需补齐

USD / 示范数据闭合、Isaac Lab精确版本、各8类具体predicate逐项接线、done顺序与实际obs维度运行验证；本机未运行。

P094 · R2R / VLN

Vision-and-Language Navigation: Interpreting visually-grounded navigation instructions in real environments

内核内容已核读 · 主来源 · 原作 · 独立页面

R2R的基本身份是scan→path_id→instruction_id；同一路径的3份语言说明是不同题目，共用环境与路径。评分逐条检查轨迹连通性与终点距离。

> **版本与身份**
>
> 主README说2019API由单笔改为batched并有v0.1旧版。钉选现有commit的R2R实作，未宣称重现2018所有设置；RxR共享父环境需去重。

领域	居家整理与清洁、办公与教育
环境	Matterport3D真实室内RGB-D全景与离散导航图。README的90个原始环境是父资产规模，不能当R2R每个split的已取得环境数。
任务	自然语言引导导航；scan是环境、path_id是一条来源路径、instr_id=path_id_说明序号是一道语言条件题。每路径3句的假设写在原evaluator，扩充语言数时不能原样沿用。
题数与数据	原生item含scan/path/heading/instructions；R2RBatch拆instructions成多笔，reset由首viewpoint和heading开始。观测字典有feature、navigableLocations和teacher最短路径；teacher属监督信号，不能预设作测试输入。
评估方式	输出instr_id与(viewpoint,heading,elevation)串行。程序要求完整ID集合、正确起点与合法图边；navigation error / oracle error用图上最短距离。成功为误差<3m，SPL=成功×最短路长/max(实走长,最短路长)，按指令题平均。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **90** building scenes · 原文页 2, 6
- **7,189** navigation paths · 原文页 5
- **21,567** instruction instances（全部split） · 原文页 5
- **4,173** test instructions · 原文页 6

依这个顺序读

1. README.md ↗
   GitHub · peteanderson80/Matterport3DSimulator · 589d091b11

   原始论文身份、Matterport资产及版本变更

   L1–50 · L77–84

---

2. tasks/R2R/env.py ↗
   GitHub · peteanderson80/Matterport3DSimulator · 589d091b11

   路径 / 多说明拆题、初态、teacher与合法观测

   L104–152 · L157–211 · L215–222

---

3. tasks/R2R/eval.py ↗
   GitHub · peteanderson80/Matterport3DSimulator · 589d091b11

   预期题目ID、3公尺严格阈值、轨迹有效性和SPL

   L1–106

怎么接入我们的benchmark

可重用

scan / viewpoint / path / instruction身份、导航图、语言和原生evaluator。

需要转换

environment键连Matterport父资产；task存导航目标语义；case保留instr_id与语言、split、起点 / 朝向、传感 / 步数预算；teacher隔离为reference。

仍需补齐

Matterport资产访问、图与图像版本闭合、split防泄漏、动作 / 停止规则和模拟器API匹配。

P095 · RxR

Room-Across-Room: Multilingual Vision-and-Language Navigation with Dense Spatiotemporal Grounding

内核内容已核读 · 主来源 · 原作 · 独立页面

RxR公开多语指令、跟随示范、视角轨迹与读取程序；同一Matterport场景、语言改写、示范和后加合成指令应分开计数。

> **版本与身份**
>
> README含2021修正7个pose档和2022添加landmarks / 100万合成指令；不可将现有完整下载内容当2020论文原始数据量。仓库已封存不等于外部数据不可用。

领域	居家整理与清洁、办公与教育
环境	重用Matterport3D scan / 全景viewpoint和导航连通图；与R2R同父资产，不可跨来源直接相加。
任务	英语、印地语、泰卢固语导航与细粒度语言 / 视觉对齐。guide instruction是题目条件，follower demonstration是人类运行示范；二者非两套独立环境。
题数与数据	gzip JSONL guide含split/instruction_id/annotator_id/language/path_id/scan/path/heading/timed_instruction；少数word无时间字段。follower有demonstration_id及父instruction_id。NPZ包含pano/time/audio_time、展平16数相机矩阵和mask/features；time为秒，heading为弧度且零朝+y、z向上。
评估方式	README定义NE、<3m SR、SPL、DTW/nDTW/sDTW；follower数据已有metrics。已读仓库的具体程序是加载 / 可视化，不是完整竞赛evaluator；RxR与RxR-Habitat两种运行 / 提交协定需分别接线，不能以预存人类分数代模型评测。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **90** Matterport3D scenes · 原文页 3
- **16,522** paths · 原文页 4, 5
- **126,069** instructions（全部split） · 原文页 5
- **2,684** test paths · 原文页 4

依这个顺序读

1. `README.md` ↗
   GitHub · google-research-datasets/RxR · d22df5940a

   原始数据schema、时空对齐、标准指针和后加数据版本

   L1–131 · L133–300 · L315–357

---

2. `visualizations/setup.py` ↗
   GitHub · google-research-datasets/RxR · d22df5940a

   读取JSONL/NPZ与导航图、scan到mesh链接

   L42–92

---

3. `marky-mT5/render_landmarks.py` ↗
   GitHub · google-research-datasets/RxR · d22df5940a

   后加landmark数据读取与MatterSim相机设置

   L24–46

怎么接入我们的benchmark

可重用

多语ID、source scan、path、guide-follower关系、秒制词语 / 视角对齐与原native metrics。

需要转换

case键保留instruction_id；示范另连demonstration_id。environment沿Matterport资产键去重；pose/语音时间基准分开。后加marky合成指令与原人类数据另标来源版本。

仍需补齐

竞赛scorer与stop/action预算核对、全量数据 / 资产取得、时间缺值处理、机器产生指令与原split隔离。

P096 · ALFRED

ALFRED: A Benchmark for Interpreting Grounded Instructions for Everyday Tasks

内核内容已核读 · 主来源 · 原作 · 独立页面

ALFRED把家务类型、具体场景 / 对象 / 轨迹和语言repeat分开；成功取决于终态条件，与每步API成功、reward和示范长度加权分数不同。

> **版本与身份**
>
> 主程序同时保留原论文与后续model links；不把所有外部model repo当新benchmark。ALFWorld是同系环境的不同界面，需显式重用关系。

领域	居家整理与清洁、餐饮与烹饪
环境	AI2-THOR室内场景与对象状态；原生目录tuple包含scene_num，具体轨迹还需原始初态与版本。现行README仍指THOR2.1.0数据 / 文件。
任务	评测器分7种家务类型：直接放置、清洁后放置、加热后放置、冷却后放置、放两物、持物照灯、透过可移容器放置。对象 / 场景 / 语言repeat是下层条件，不与7种直接混算。
题数与数据	traj task_id/task_type、pddl_params、plan.high_pddl/low_actions、turk_annotations.anns[repeat_idx].task_desc；模型输出离散action与交互mask。原生trial名称不等于本库policy重跑trial。
评估方式	EvalTask从视觉和语言rollout，STOP / max_steps / max_fails可终止，再取get_goal_satisfied与条件满足数。例：照灯要求持有目标且灯可见并打开。GC全局累加条件分母，PLW按原示范low_actions长度加权，非导航图最短距离SPL。t=0的除法及被exception跳过的题需adapter明确处理。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **120** rooms · 原文页 3
- **7** task types · 原文页 3
- **2,685** task parameter combinations · 原文页 3
- **8,055** expert demonstration episodes · 原文页 3

- **25,743** 概述language directives · 原文页 3
- **1,529** 表2 test-unseen directives · 原文页 4

依这个顺序读

1. `README.md` ↗
   GitHub · askforalfred/alfred · f91f4c0c96

   原始论文、数据版本与环境依赖

   L1–53

---

2. `models/eval/eval_task.py` ↗
   GitHub · askforalfred/alfred · f91f4c0c96

   完整具体rollout评测、task/repeat身份、停止与分母

   L1–206

---

3. `env/tasks.py` ↗
   GitHub · askforalfred/alfred · f91f4c0c96

   reward与成功分离，拿物照灯的具体条件

   L75–124 · L126–155 · L237–272

---

4. `gen/utils/dataset_management_util.py` ↗
   GitHub · askforalfred/alfred · f91f4c0c96

   goal/对象/容器/scene与多trial目录身份

   L5–51

怎么接入我们的benchmark

可重用

7种native task类别、PDDL参数、初态 / 低层操作与终态条件、language repeats。

需要转换

原task_id/scene/repeat_idx拆为source instance与case键，留示范 / 语言父子关系；原生SR/GC/PLW分开记录，失败和未产出题也入分母清单。

仍需补齐

完整THOR初态重播、资产版本、split与合法模型信息、missing/error题处理和原生/共同协定对照。

P097 · TEACh

TEACh: Task-driven Embodied Agents that Chat

内核内容已核读 · 主来源 · 原作 · 独立页面

TEACh需要保留game→EDH/TfD instance的关系；两种题目检查不同目标。现有CLI有静态可见的漏题 / 变量问题，不能下载后直接宣称可评测。

> **版本与身份**
>
> 2022-12修订只保留有助主任务的EDH状态变化，删无相关变化instances与2个valid_unseen game；不能混用早期paper数字与当前文件。软件 / 图像 / 其他数据授权分开。

领域	居家整理与清洁、餐饮与烹饪、协助、交接与陪伴
环境	AI2-THOR家务场景，Commander与Driver/Follower不同视角和角色；game可派生多个EDH或TfD片段，不能各自算新屋子。
任务	EDH依对话 / 操作历史完成后续指定状态改变，TfD依完整任务参数检查终态。task definition有components、数量determiner及relations；Toast要求BreadSliced且isCooked=1。
题数与数据	game_id、instance_id、driver_actions_future、state_changes、expected_init_goal_conditions_*，输出game含初 / 终态objects及custom_object_metadata。dialog acts是后加da_metadata；答案状态不能当一般模型输入。
评估方式	EDH从state_changes建checker；TfD取原task_id并套task_params。check_episode_progress合成component/relation的成功与条件数。GC分母扣除初态已满足部分；PLW依future动作长度。cli/eval.py有未定义edh_instance_files纪录行，且缺输出题创建error纪录后未加入traj_stats；需修正并保留原版差异，否则可能阻断 / 漏计分母。这是静态阅读发现，未运行重现。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **109** 表2收集池rooms · 原文页 5
- **12** task types · 原文页 3, 5
- **438** 收集池parameter variants · 原文页 5
- **11,176** 表3 EDH instances（全部split） · 分量相加 · 原文页 5

- **2,270** test-unseen EDH instances · 原文页 5

依这个顺序读

1. `README.md` ↗
   GitHub · alexa/teach · 903191e256

   精确论文、授权分件与2022数据修订

   L1–95

---

2. `src/teach/meta_data_files/task_definitions/101__toast.json` ↗
   GitHub · alexa/teach · 903191e256

   原生component与可机器检查的吐司条件

   L1–23

---

3. `src/teach/dataset/task_THOR.py` ↗
   GitHub · alexa/teach · 903191e256

   任务component/relation与递归成功聚合

   L22–48 · L1057–1197

---

4. `src/teach/eval/compute_metrics.py` ↗
   GitHub · alexa/teach · 903191e256

   EDH/TfD差异、初态未满足条件与PLW/SR聚合

   L1–202

---

5. `src/teach/cli/eval.py` ↗
   GitHub · alexa/teach · 903191e256

   预期instance集合、步数/API失败限制、漏题处理问题

   L23–130

怎么接入我们的benchmark

可重用

game/instance/task参数、角色视角、历史、state-change和task checker。

需要转换

EDH/TfD各自protocol，case连game父来源与历史截止；state/reference隔离；evaluator保存初 / 终条件数、完整预期ID、失败原因和step/API预算。

仍需补齐

数据修订版闭合、原始重播与instance有效性、CLI修正验证、缺输出 / 零分母政策、原生对照跑通。

P098 · Habitat 2.0

Habitat 2.0: Training Home Assistants to Rearrange their Habitat

内核内容已核读 · 主来源 · 原作 · 独立页面

Habitat-Lab负责episode / 任务 / 评分，Habitat-Sim负责传感与物理。二者共同支持多代论文；目前HEAD不能直接代表2021的Habitat2.0原设置。

> **版本与身份**
>
> 现有README同时引用Habitat1/2/3。这次核读指定现有commit中的具体界面，历史2.0重现版本仍需另定；未将添加3.0能力归给2021论文。

领域	居家整理与清洁、餐饮与烹饪
环境	Habitat2.0研究使用家居可交互重排环境；现行Sim另外支持多种扫描场景、CAD、机器人URDF与RGB-D。引擎支持的数据集列表不等于已取得或可对比的环境全集。
任务	对象重排及导航 / 抓放等子任务；具体task config和measure才决定条件。Lab的benchmark速度脚本与模型任务成功率不可混为同一评估。
题数与数据	RearrangeEpisode包含ao_states、rigid_objs(handle,transform)、targets、markers、target/goal_receptacles与name_to_receptacle。现行from_json把episode_id重设为列序号，标准库须保留原source文件与record index避免ID碰撞。
评估方式	具体RearrangePickSuccess检查持有正确对象、未违反hold constraint，且末端到rest位置距离低于配置阈值；-1可关闭rest检查。成功定义依配置改变，不能只存measure名称；reward、渲染FPS及task success分开。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **111** ReplicaCAD layouts · 原文页 2
- **3** HAB long-range families · 原文页 10, 11
- **500** Pick unseen-layout eval episodes · 原文页 9

依这个顺序读

1. README.md ↗
   GitHub · facebookresearch/habitat-lab · 0fb6f43ffe

   原论文身份与Lab/Sim角色依赖

   L14–78

---

2. README.md ↗
   GitHub · facebookresearch/habitat-sim · 57ee4941dc

   引擎、资产与机体支持；非添加独立任务库

   L14–27 · L47–70

---

3. habitat-lab/habitat/datasets/rearrange/rearrange_dataset.py ↗
   GitHub · facebookresearch/habitat-lab · 0fb6f43ffe

   具体rearrangement episode字段与读取时ID重设

   L23–76

---

4. habitat-lab/habitat/tasks/rearrange/sub_tasks/pick_sensors.py ↗
   GitHub · facebookresearch/habitat-lab · 0fb6f43ffe

   具体pick成功条件及配置阈值

   L205–249

---

5. src_python/habitat_sim/utils/datasets_download.py ↗
   GitHub · facebookresearch/habitat-sim · 57ee4941dc

   数据UID、版本、LFS与实体资产取得状态

   L527–539 · L727–767 · L785–825

怎么接入我们的benchmark

可重用

episode schema、资产UID / 版本、任务配置与原生measure。

需要转换

source拆论文/程序/资产角色，environment存scene及对象初态；case ID以来源版本＋原档＋原索引生成；evaluator钉选实作与阈值。

仍需补齐

2021论文匹配的Lab/Sim/资产版本及完整任务配置、LFS实体资产、原生重播与共同协定接线。

P099 · HomeRobot

HomeRobot: Open-Vocabulary Mobile Manipulation

内核内容已核读 · 主来源 · 原作 · 独立页面

HomeRobot的OVMM流程分找物、抓物、找容器、放置；真正overall成功还要求零robot-scene碰撞。已沿官方submodule读到实际放置与稳定性checker。

> **版本与身份**
>
> home-robot tree把Habitat-Lab钉在b727ca9f7123101aaedb737ca9ccc1b153525dd9；本次直接读此版checker，没有用现行HabitatHEAD代替。README另指定home-robot-ovmm-challenge-2024 tag，与本main快照分开。

领域	居家整理与清洁
环境	真实Stretch与Habitat模拟分开；模拟依赖HSSD ovmm资产、对象、Stretch模型和episode配置。相同HSSD屋子被多任务重用需按父资产键去重。
任务	将指定类别对象从起始容器搬到目标容器；四阶段是同一长程任务进度，不自动算4道独立题。原生episode允许多个candidate对象 / 容器。
题数与数据	OVMMEpisode记object_category/start_recep_category/goal_recep_category及candidate goal集合。wrapper读head_rgb/depth、GPS/compass/joint及task goal；depth由[0,1]映射min/max并特判边值；相机座标模式与GT semantic开关必须记入protocol。
评估方式	原子放置量测检查对象与合法容器接触、排除地板与过深穿透，父checker再检查放开、末端回rest距离及可选的稳定步数。阶段success具有历史累积性；metrics_utils的overall_success=END.ovmm_place_success且robot_scene_colls==0，partial=(找物+抓物+找容器+overall)/4。缺失字段在聚合时被略过，须额外保存完整预期episode与缺值数。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **60** 实际benchmark HSSD scenes · 原文页 5
- **10** test scenes · 原文页 5
- **1** OVMM task family · 原文页 5, 7
- **2,535** objects · 原文页 5

- **20** real experiments / baseline · 原文页 6

依这个顺序读

1. `README.md` ↗
   GitHub · facebookresearch/home-robot · ede6a67a2d

   OVMM任务与2024挑战tag

   L10–48

---

2. `projects/habitat_ovmm/README.md` ↗
   GitHub · facebookresearch/home-robot · ede6a67a2d

   HSSD资产、episode与GT/Detic评测条件

   L10–67 · L130–163

---

3. `.gitmodules` ↗
   GitHub · facebookresearch/home-robot · ede6a67a2d

   官方依赖Habitat-Lab；tree另固定submodule commit

   L1–6

---

4. `src/home_robot_sim/home_robot_sim/env/habitat_ovmm_env/habitat_ovmm_env.py` ↗
   GitHub · facebookresearch/home-robot · ede6a67a2d

   观测 / 深度 / 相机座标与动作转换

   L114–181 · L220–241 · L290–398

---

5. `projects/habitat_ovmm/evaluator.py` ↗
   GitHub · facebookresearch/home-robot · ede6a67a2d

   scene_episode键、阶段/END指针与分母

   L194–224 · L255–324

---

6. `projects/habitat_ovmm/utils/metrics_utils.py` ↗
   GitHub · facebookresearch/home-robot · ede6a67a2d

   零碰撞overall成功与四项partial平均

   L1–113

---

7. habitat-lab/habitat/datasets/ovmm/ovmm_dataset.py ↗
   GitHub · facebookresearch/habitat-lab · b727ca9f71

   OVMM categories/candidate goal与episode subset

   L27–41 · L153–204

---

8. habitat-lab/habitat/tasks/ovmm/ovmm_sensors.py ↗
   GitHub · facebookresearch/habitat-lab · b727ca9f71

   阶段成功保留历史且依赖前一阶段

   L453–585

---

9. habitat-lab/habitat/tasks/ovmm/sub_tasks/place_sensors.py ↗
   GitHub · facebookresearch/habitat-lab · b727ca9f71

   接触目标容器、穿透限制与排除地板

   L83–144

---

10. habitat-lab/habitat/tasks/rearrange/sub_tasks/place_sensors.py ↗
    GitHub · facebookresearch/habitat-lab · b727ca9f71

    放置稳定性与具体PlaceSuccess条件

    L206–347

怎么接入我们的benchmark

可重用

对象 / 容器category、候选集合、场景episode身份、观测/动作转换、原子与阶段checker。

需要转换

case固定数据版本、scene_episode、机体、GT或感知模式、步数与控制比例；native放置、overall零碰撞及partial三项分开存。依赖源钉选b727ca9而非目前Habitat main。

仍需补齐

HSSD/机体/episode资产闭合、传感配置与相机内参检查、原生感知 / 控制运行验证、论文与2024挑战版本对照。

P100 · BEHAVIOR-1K

BEHAVIOR-1K: A Human-Centered, Embodied AI Benchmark with 1,000 Everyday Activities and Realistic Simulation

内核内容已核读 · 主来源 · 原作 · 独立页面

BEHAVIOR-1K的activity、definition、instance已在原程序分开；1,000种活动不等于1,000个已加载case。Q-score与全条件成功也有不同分母。

> **版本与身份**
>
> 本次HEAD为2026-10快照，内含新BDDL3及矢量化eval；README引用2024论文。此前库存用4b0f43d版本，两次快照不混算已取得任务与cases。

领域	居家整理与清洁、餐饮与烹饪、衣物与洗护、办公与教育、零售与购物、农业与园艺
环境	OmniGibson场景、对象 / 材料 / 系统、机器人与预采样状态；scene_model和activity_instance_id共同定位初态，不按并行num_envs增算场景种类。
任务	原生activity_name是活动，activity_definition_id选同一活动不同完成规格，activity_instance_id选预配置状态。添加definition可能改规则；重跑rollout_id只改试验，不增加活动数。
题数与数据	cached filename含scene_model/activity/definition/instance；evaluator逐实例写task、instance_id、rollout_id、steps、success及metrics。可选online sampling、robot pose、asset whitelist/blacklist及task highlighting，均影响合法题目配置。
评估方式	PredicateGoal委派compiled BDDL目标检查，各env用独立object scope。成功Q=1；未成功时对每一备选goal，计初态不满足而现在满足的predicate数÷该option全部predicate数，再取最大。此分母不是初态未满足数。timeout可依人类示范长度乘系数或明定max_steps；时间标准化需保留human stats版本。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **50** scenes · 原文页 1, 4
- **373** rooms（包含于50scene） · 原文页 4
- **8** 原作scene types · 原文页 4

- **1,000** BDDL activities · 原文页 3
- **3** 原文baseline活动 · 原文页 6, 7

依这个顺序读

1. `README.md` ↗
   GitHub · StanfordVL/BEHAVIOR-1K · cd484e0477

   精确论文、1,000活动为作者声明

   L1–24

---

2. `OmniGibson/omnigibson/tasks/behavior_task.py` ↗
   GitHub · StanfordVL/BEHAVIOR-1K · cd484e0477

   活动/定义/实例身份、各并行环境的predicate scope

   L65–99 · L166–181 · L201–250

---

3. `OmniGibson/omnigibson/termination_conditions/predicate_goal.py` ↗
   GitHub · StanfordVL/BEHAVIOR-1K · cd484e0477

   BDDL目标判断与成功终止

   L1–53

---

4. `OmniGibson/omnigibson/metrics/task_metric.py` ↗
   GitHub · StanfordVL/BEHAVIOR-1K · cd484e0477

   Q-score确切分子 / 分母、时间与初态

   L1–81

---

5. `OmniGibson/omnigibson/eval/evaluator.py` ↗
   GitHub · StanfordVL/BEHAVIOR-1K · cd484e0477

   相机/超时设置、instance和rollout输出

   L265–295 · L636–697

怎么接入我们的benchmark

可重用

活动/definition/instance、BDDL目标、预采样场景与细项metrics。

需要转换

来源活动与本库语义任务分开，environment接scene+assets，case保留definition/instance/机体/传感/初态；Q-score及success分栏并保存初始predicate mask和备选goal。

仍需补齐

资产 / 知识库 / BDDL / 模拟器版本闭合、全部活动定义及可运行子集清单、物理有效性与原生重播。

P101 · Embodied Agent Interface

Embodied Agent Interface: Benchmarking LLMs for Embodied Decision Making

内核内容已核读 · 主来源 · 原作 · 独立页面

EAI统一四种决策模块，但BEHAVIOR与VirtualHome各有具体评分程序。目标理解的JSON错误处理不同，不能只因同名F1就合并成一个分数。

> **版本与身份**
>
> 原embodied-agent-eval repo现转址embodied-agent-interface/embodied-agent-interface，属同一仓库身份。这次深入核对goal interpretation，其他模块仅确认界面与来源角色，未宣称全codebase或所有模块已跑通。

领域	居家整理与清洁、餐饮与烹饪、办公与教育
环境	重用BEHAVIOR/iGibson与VirtualHome环境 / 状态图。形式goal、PDDL problem或语言题不自动添加物理场景。
任务	goal interpretation、subgoal decomposition、action sequencing、transition modeling四种信息 / 决策评测；同一底层家务任务可接受不同信息及要求，应创建不同case protocol。
题数与数据	BEHAVIOR以demo identifier连goal conditions、objects、instruction与LLM输出；VirtualHome以scene_id、script/file_id连状态 / 动作目标。保留node goals/edge goals/action goals与原形式语法，不能直接flatten丢掉顺序 / 备选完成方式。
评估方式	已核读goal interpretation：BEHAVIOR精确比对conditions，对备选目标取命中最多option，累计TP/FP/FN；解析失败代空预测。VirtualHome JSON解析失败直接continue并记format error，幻觉对象另记录；跨环境F1分母与失败规则需分开。transition env.step调用抽象control，不能宣称真实机器人成功。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **4** 能力modules · 原文页 4, 5, 6
- **26** VirtualHome表2task names · 原文页 7
- **100** BEHAVIOR100 tasks · 原文页 7, 89
- **438** instruction instances · 338+100 · 原文页 7

依这个顺序读

1. README.md ↗
   GitHub · embodied-agent-interface/embodied-agent-interface · 531c62f8df

   精确论文、4模块、父环境与程序改名

   L1–69 · L92–105

---

2. docs/source/modules/goal_interpretation.md ↗
   GitHub · embodied-agent-interface/embodied-agent-interface · 531c62f8df

   初态与语言到形式目标的评测约定

   L1–70

---

3. src/behavior_eval/evaluation/goal_interpretation/scripts/evaluate_results.py ↗
   GitHub · embodied-agent-interface/embodied-agent-interface · 531c62f8df

   条件精确比对、备选goal、解析错误与global计数

   L133–162 · L362–449 · L451–490 · L529–579

---

4. src/virtualhome_eval/evaluation/goal_interpretation/scripts/evaluate_results.py ↗
   GitHub · embodied-agent-interface/embodied-agent-interface · 531c62f8df

   VirtualHome schema、不同错误处理与node/edge/action分数

   L15–59 · L95–147 · L153–217 · L275–310

---

5. src/behavior_eval/transition_model/eval_env.py ↗
   GitHub · embodied-agent-interface/embodied-agent-interface · 531c62f8df

   符号 / 抽象action效果界面不等于逐步物理操作

   L133–142 · L155–157

怎么接入我们的benchmark

可重用

原goal/schema、scene/demo/script身份、模块界面、细粒度错误与evaluator。

需要转换

同一父task连多protocol case；state/可见对象名/语言与reference答案分开；保留环境特定parser、备选goal及micro计数，不扁平为通用accuracy。

仍需补齐

其余3模块各具体checker逐一接线、原始资产、判分分母完整性、形式规划器与物理运行的比较界线。

P102 · NavVerse

NavVerse: Benchmarking Indoor-to-Outdoor Embodied Navigation in Continuous Robot Simulation

内核内容已核读 · 主来源 · 原作 · 独立页面

NavVerse提供室内、室外与连接场景的连续导航；原程序的成功距离是参考路径近似值，collision指针是卡住代理量，不等同接触传感。

> **版本与身份**
>
> 原PDF p1连umich-curly.github.io/NavVerse-Benchmark，与此同名组织库和题名相符；本次固定2026-09后更新之commit，非宣称逐项重现7月版本。

领域	公共场馆与服务
环境	作者报100室内＋50室外＋50连接场景，来源USD/navmesh/scene_scale/collider设置另存。这是作者release声明，尚非本库已取得200个资产。
任务	ObjNav/VLN/PlaceNav三种条件导航；原episode_target_type分obj/place，instruction_type分target/vln，避免把同一终点的两种指令视为新场景。
题数与数据	VLNEpisode含scene_id/scene_type/episode_id/path/scale/navmesh_preset、goals(instance/type/location/radius/reference_path)、start_position/start_rotation；episode_label=scene_id+episode_id。JSON读取错误会continue，导入应另列遗漏。
评估方式	距离取当前点到各reference_path点的直距＋后续路径长，再扣目标半径；成功需STOP且距离<1.6。SPL由该初始距离与实走长计。collision以有移动指令但pose变化<0.015判断，collision_rate平均此代理信号，非直接物理碰撞次数；保留原名与操作定义。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **200** 含组合的scene entries · 原文页 3, 12
- **3** navigation task types · 原文页 5
- **10,000** 生成episodes（全benchmark） · 4027+2973+3000 · 原文页 5

依这个顺序读

1. `README.md` ↗
   GitHub · UMich-CURLY/NavVerse-Benchmark · 8b89bfee4f

   原作范围、版本化场景包与episode档分离

   L1–17 · L48–81 · L130–155

---

2. `navverse/episode.py` ↗
   GitHub · UMich-CURLY/NavVerse-Benchmark · 8b89bfee4f

   scene/episode/goal与两种instruction schema

   L23–142

---

3. `navverse/measures.py` ↗
   GitHub · UMich-CURLY/NavVerse-Benchmark · 8b89bfee4f

   success/SPL/碰撞率的实际公式

   L1–12 · L194–265 · L291–350 · L430–462 · L546–642

---

4. `baselines/eval_navverse.py` ↗
   GitHub · UMich-CURLY/NavVerse-Benchmark · 8b89bfee4f

   split manifest验证与隔离episode目录

   L1400–1420

怎么接入我们的benchmark

可重用

场景与episode schema、split manifests、语言/目标条件和native measures。

需要转换

environment固定场景包hash+navmesh/collider；case存scene_episode+目标/指令/机体/控制模式；metric存实际距离近似、STOP及卡住判定而非仅缩写。

仍需补齐

10,000作者报episode的全量取得 / ID完整性、各机体控制与场景有效性、物理contact及近似指针对照。

P103 · Follow-Bench

Follow-Bench: A Unified Motion Planning Benchmark for Socially-Aware Robot Person Following

内核内容已核读 · 主来源 · 原作 · 独立页面

正确的Follow-Bench是MedlarTea的机器人跟随规划库；社交距离、搜索、无碰撞分开记录，不能混同另一个LLM指令遵循同名benchmark。

> **版本与身份**
>
> 原2025paper有2026-05v4；此repo5月创建，site仍有旧6planner与paper8planner叙述差异。ir-sim/RDA-planner为上游组件，不能当独立新benchmark。
>
> 官方project页的Benchmark Code按钮仍为空href；另以完整题名、来源owner自述Hanjing YE（原第一作者）与mobile navigation/person-following身分核对MedlarTea/follow-bench。

领域	协助、交接与陪伴、个人照护、公共场馆与服务、包装、仓储与物流
环境	内含ir-sim模拟器与socialRPF规划器；走廊、交叉口、门口、杂物场地及动态人群。人数、宽度、障碍、跟随距离和随机初态是场景设置。
任务	跟随特定人的后方或侧方、失去视线后搜索；README每设置100 seeds是原规划，不表示本次已有100次新结果。seed改人物 / 布局时是新instance，policy-only重跑另计trial。
题数与数据	env_basic_info.json存step_time、robot/target半径；object_info.json实际按JSONL逐行读count、target_visible、robot/target/obstacles/humans。robot位置为索引1:3，速度4:6，碰撞旗标6，需保留schema与单位。
评估方式	无碰撞与搜索成功分开；连续失踪>max_search_steps才search失败。可见率分母max_steps，路径按差分，zone时间按step_time累加。avg_velocity直接mean速度分量，并非速度模长；private-zone计算扣target_radius，与人群半径异质情况须核对。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **16** scenario types · 原文页 6
- **1** person-following family · 原文页 6
- **100** 每configuration trials · 原文页 7, 8

依这个顺序读

1. `README.md` ↗

   GitHub · MedlarTea/follow-bench · 202d164501

   场景、人数/宽度/跟随条件、计量单位与上游组件

   L1–105 · L171–208

---

2. `socialRPF/example/robot_person_following/evaluate_scripts/evaluate_iso.py` ↗

   GitHub · MedlarTea/follow-bench · 202d164501

   逐步log schema、碰撞/可见率/搜索/舒适度确切计算

   L1–162

怎么接入我们的benchmark

可重用

布局/人群/目标轨迹配置、原log与多项距离/舒适度/搜索metrics。

需要转换

case记target identity、follow位置/距离、seed、max_steps与step_time；evaluator保留碰撞与搜索各分母，不把单一无碰撞当完成全部任务。

仍需补齐

完整场景包 / log对齐、速度与社交区域计量修订审核、真实ROS部署repo认领、各planner同预算验证。

P104 · SIMPLER

Evaluating Real-World Robot Manipulation Policies in Simulation

内核内容已核读 · 主来源 · 原作 · 独立页面

SIMPLER是实机设置的模拟评测，不是新的实机大数据集；两种配置为视觉匹配与变体平均。已核对子模块中的done=success及抓取历史成功规则。

> **版本与身份**
>
> SimplerEnv main基于CPU ManiSkill2；README另连maniskill3分支。此tree的ManiSkill2_real2sim钉在ef7a4d4；不得替换为最新ManiSkill3后仍称同设置。

领域	居家整理与清洁
环境	Google Robot与WidowX+Bridge的SAPIEN/ManiSkill2实转模拟设置；背景overlay、纹理、光照、干扰物等变体是设置，不自动添加语义任务。
任务	抓取、移近、抽屉开关 / 放物，以及WidowX放置 / 堆栈等；ENVIRONMENT_MAP把不同罐姿态映射同class＋参数，需保留variant关系。
题数与数据	reset options指定robot xy/quat和object xy或episode_id；模型输出world_vector、rot_axangle、gripper、terminate_episode。控制频率、sim_freq、相机、overlay与subtask推进全部是case协定。
评估方式	此钉选子库get_done=info.success；外层直到模型停止或truncated，保存最后done。抓取可按提起>1cm且无有效外部接触，或连握5步；打开episode_stats时曾显著提起>2cm达5步亦可成功。另以Pearson/MMRV比较模型sim-real表现排序，不是单题完成率。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **2** real robot setups · 原文页 6
- **8** 图6–7主要task groups · 4+4，drawer开/关合组 · 原文页 7, 8

依这个顺序读

1. `README.md` ↗

   GitHub · simpler-env/SimplerEnv · eddb569074

   两种实转模拟协定与ManiSkill2/3版本

   L1–64 · L78–100

---

2. `simpler_env/__init__.py` ↗

   GitHub · simpler-env/SimplerEnv · eddb569074

   task alias至环境/参数映射，变体不能按名称全加

   L1–88

---

3. `simpler_env/evaluation/maniskill2_evaluator.py` ↗

   GitHub · simpler-env/SimplerEnv · eddb569074

   初态扫描、模型/控制输出、终止与最后成功判定

   L15–219

---

4. `simpler_env/utils/metrics.py` ↗

   GitHub · simpler-env/SimplerEnv · eddb569074

   sim-real Pearson及MMRV的模型排序分母

   L134–163

---

5. `mani_skill2_real2sim/envs/sapien_env.py` ↗

   GitHub · simpler-env/ManiSkill2_real2sim · ef7a4d4fdf

   此版本terminated直接取info.success

   L547–582

---

6. `mani_skill2_real2sim/envs/custom_scenes/grasp_single_in_scene.py` ↗

   GitHub · simpler-env/ManiSkill2_real2sim · ef7a4d4fdf

   提起高度、接触与历史5步成功条件

   L401–461

怎么接入我们的benchmark

可重用

真实setup对应、task alias/config、初态扫描及原生task metrics。

需要转换

case保留视觉匹配/变体平均、variant权重、时间/动作约定；evaluator存瞬间/历史成功旗标、subtask及固定子库版本。sim-real correlation另为模型层聚合。

仍需补齐

完整资产、真实结果配对与不确定性、每变体分母/权重、各task具体checker接线、原生模型运行。

P105 · LIBERO-Plus

LIBERO-Plus: In-depth Robustness Analysis of Vision-Language-Action Models

内核内容已核读 · 主来源 · 原作 · 独立页面

LIBERO-Plus的10,030是扰动任务条目；实际分类JSON确有10,030笔，但大量条目共享原LIBERO任务和初态。原difficulty level保留为来源标签。

> **版本与身份**
>
> fork替代LIBERO套件使用方式不代表数据独立；RLDS/LeRobot链接是训练数据表示，不能各自重复计数。当前分类笔数为文件结构核对，未运行全部变体。

领域	居家整理与清洁、餐饮与烹饪
环境	重用LIBERO桌面，扩充对象、纹理、相机、光照、机器人初态及noise。多扰动名称不代表不同房屋或独立原始数据。
任务	7扰动维度；分类档结构计数：spatial2,402、object2,518、goal2,591、libero_10为2,519，合10,030。这是native variant entries，不是本库10,030去重语义目标。
题数与数据	Task保留name/language/problem_folder/bddl_file/init_states_file；getter依_language_/_view_/_table_/_light_等字样回取共同或专属初态。分类JSON的id基准与API task index需明确映射。
评估方式	具体_check_success逐一AND goal_state predicate；rollout在max_steps内累积done成功。README要求num_trials_per_task由50改1，是该扰动协定，不等同所有来源都一试可充分估计成功率。difficulty_level为作者扰动级别，尚非跨benchmark校准难度。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **10,030** 扰动task settings · 原文页 8
- **7** 扰动factors · 原文页 2, 8
- **21** 扰动components · 原文页 8

依这个顺序读

1. README.md ↗

   GitHub · sylvestf/LIBERO-plus · 4976dc3002

   精确来源、7扰动维度、外部资产与每变体1trial建议

   L1–43 · L67–91

---

2. libero/libero/benchmark/task_classification.json ↗

   GitHub · sylvestf/LIBERO-plus · 4976dc3002

   抽读id/name/category/difficulty_level；全量笔数仅结构计数，不宣称每笔人工语义核对

   JSON /libero_spatial/0 · JSON /libero_spatial/1

---

3. libero/libero/benchmark/__init__.py ↗

   GitHub · sylvestf/LIBERO-plus · 4976dc3002

   Task字段、语言重写与变体如何共用init-state

   L37–96 · L154–245

---

4. libero/libero/envs/problems/libero_tabletop_manipulation.py ↗

   GitHub · sylvestf/LIBERO-plus · 4976dc3002

   具体成功为全部goal predicate合取

   L253–273

---

5. libero/lifelong/evaluate.py ↗

   GitHub · sylvestf/LIBERO-plus · 4976dc3002

   done成功累积与预算 / 分母

   L261–288

怎么接入我们的benchmark

可重用

10,030原生分类条目、7维度与level、BDDL/语言和init-state来源。

需要转换

保留base-task→perturbation variant→case关系，normalization不丢variant；level存native_difficulty，原假设 / 配置 / seed与规则差异可追。

仍需补齐

10,030条目逐笔asset/init-state闭合、语言/variant语义等价审核、外部training数据取得与分母 / CI。

P106 · MetaWorld+

Meta-World+: An Improved, Standardized, RL Benchmark

内核内容已核读 · 主来源 · 原作 · 独立页面

现行Meta-World README直接引用2505.11289，与MetaWorld+相符。重点是固定观测、动作、成功终止和meta适应预算，而不是把新实验版本计成另一份独立任务库。

> **版本与身份**
>
> 部分旧state-space说明与现进程式不一致；不得以9D旧描述生成本版schema。

领域	居家整理与清洁、餐饮与烹饪、工艺与修缮、装配与生产作业、休闲与运动、通用对象与机动作业
环境	与Meta-World来源共用Sawyer/MuJoCo任务体系；保留版本重用关系。
任务	50个任务可组成MT1/10/50与ML1/10/45。train任务、test任务与goal variations需要各自保留单位。
题数与数据	实际程序使用39维基础观测与4维控制；多任务观测可附task ID，目标是否可见取决于约定。
评估方式	成功率依完成的episode和info.success统计；meta适应数据与最终评测episode分开，预算是可比较性的必要条件。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **50** 沿用的task types · 原文页 4
- **25** 添加中型suite训练task量 · 原文页 7, 16
- **50** MT每task eval episodes · 原文页 5

依这个顺序读

1. `README.md` ↗
   GitHub · Farama-Foundation/Metaworld · c0dafaf155

   确认论文身份、MT/ML用途与现行API。

   L1–55

---

2. `metaworld/sawyer_xyz_env.py` ↗
   GitHub · Farama-Foundation/Metaworld · c0dafaf155

   核对动作缩放、观测stack与屏蔽goal。

   L320–336 · L475–527

---

3. `metaworld/envs/sawyer_drawer_open_v3.py` ↗
   GitHub · Farama-Foundation/Metaworld · c0dafaf155

   对照独立success信号与reward版本。

   L66–88 · L115–188

---

4. `metaworld/evaluation.py` ↗
   GitHub · Farama-Foundation/Metaworld · c0dafaf155

   看正式计分、task平均和meta适应/测试分离。

   L48–103 · L106–169

怎么接入我们的benchmark

可重用

原生evaluation.py、task清单、versioned reset和success判定。

需要转换

与P063记为同一程序来源的版本关系；task identity、goal instance及trial分开，保留动作缩放与可见信息。

仍需补齐

共同跨来源语义去重、素材闭合与新benchmark协定下的baseline。

P107 · COLOSSEUM

THE COLOSSEUM: A Benchmark for Evaluating Generalization for Robotic Manipulation

内核内容已核读 · 主来源 · 原作 · 独立页面

Colosseum在20个RLBench任务上加入扰动；变体产生、示范seed及RVT评测在不同文件 / 仓库。RVT所称success rate来自100倍缩放的成功reward。

> **版本与身份**
>
> scene程序用函数参数数量兼容upstream/PerAct RLBench；安装可成功不代表两版本物理 / 评分完全一致。RVT repo沿用RVT README，身份由Colosseum官方README明确链接确认。

领域	居家整理与清洁、通用对象与机动作业
环境	RLBench/PyRep/CoppeliaSim TTM场景；scene加载自定义TTM并在episode / step套变体。原README20任务×14因素不可直接当280独立场景 / 新语义任务。
任务	源任务＋对象/桌面/背景/相机/光照/物理参数等扰动。例CloseBox只有1原生task variation、4句说明，成功登记JointCondition(box_joint,2.6)，依固定RLBench版本判。
题数与数据	factor含variation/name/enabled/targets及参数；demo保存NumPy random state，可依指定demo index恢复。正式示范在外部tar，未取得，实例必须带variant配置与资产版本。
评估方式	官方链接RVT runner以指定demo初态评测，例预设25episodes和25控制步，使用规划式末端姿态＋离散gripper。wrapper将原task reward>=1的成功缩放100；IK/path/invalid-action错误给0并终止。CSV success rate取eval_envs/return，需保留0–100尺度与实际完成 / 缺题数。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **20** base tasks · 原文页 4
- **14** perturbation factors · 原文页 4
- **20,371** 生成task instances · 原文页 4
- **5,875** 主protocol eval episodes · 235×25 · 原文页 7

依这个顺序读

1. `README.md` ↗
   GitHub · robot-colosseum/robot-colosseum · 098a910ae1

   原论文、20任务/14变化因子、原生RVT评测repo

   L1–54

---

2. `colosseum/rlbench/tasks/close_box.py` ↗
   GitHub · robot-colosseum/robot-colosseum · 098a910ae1

   具体JointCondition成功predicate和语言变体

   L1–32

---

3. `colosseum/variations/manager.py` ↗
   GitHub · robot-colosseum/robot-colosseum · 098a910ae1

   factor enable/targets及reset/step时套用

   L29–104

---

4. `colosseum/rlbench/extensions/scene.py` ↗
   GitHub · robot-colosseum/robot-colosseum · 098a910ae1

   TTM资产与变体生命周期、RLBench fork兼容性

   L66–120

---

5. `colosseum/rlbench/extensions/task_environment.py` ↗
   GitHub · robot-colosseum/robot-colosseum · 098a910ae1

   demo NumPy状态保存与重设

   L59–85

---

6. `rvt/eval.py` ↗
   GitHub · robot-colosseum/rvt_colosseum · 3cd92a3f01

   25episodes/25step预设、示范初态及CSV聚合

   L194–218 · L295–362

---

7. `rvt/utils/custom_rlbench_env.py` ↗

   GitHub · robot-colosseum/rvt_colosseum · 3cd92a3f01

   reward_scale=100、动作错误处理、demo reset与variation

   L219–219 · L328–350 · L377–406

怎么接入我们的benchmark

可重用

20task定义、factor schema、TTM/示范seed、原生成功条件与RVT评测入口。

需要转换

task连RLBench父任务，case固定factor值/激活时间/初态/控制预算；evaluator保存成功布尔、100倍报分和错误分母，重复来源不增语义任务。

仍需补齐

RLBench/PyRep/fork精确依赖闭合、所有factor资产与demo取得、YARR聚合环节和同预算原生跑通。

P108 · RoboArena

RoboArena: Distributed Real-World Evaluation of Generalist Robot Policies

内核内容已核读 · 主来源 · 原作 · 独立页面

RoboArena主库是远程policy界面，志工client收集实机A/B偏好与部分成功。它是跨站实机评测流程，不是固定题库自动判分器。

> **版本与身份**
>
> 主库与志工client分开固定commit；后者owner名与原第一作者Pranav Atreya相符且明示RoboArena志工用途。未运行其服务登录、上传或机器人指令。

领域	居家整理与清洁、餐饮与烹饪
环境	DROID真实机器人各站点、相机和桌面设置；evaluation session记录现场任务及A/B两次rollout。自愿站点数、机体、任务及试验各是不同单位。
任务	现场人员先输入任务，再分配A/B policies；人工重设同一初态，两者是成对试验，不是两种任务。另连sim-evals是提交前模拟检查。
题数与数据	policy obs有wrist/exterior RGB、7joint/6cartesian/1gripper state与prompt；actions为N×8或N×7且整chunk运行。client存逐步state/action NPZ、3视角视频、session/command、partial/binary success及valid标记；控频约15Hz但视频编码10fps，媒体时间需对齐。
评估方式	人员给0–100部分分数后除100，只有==1才binary成功；另给A/B/tie偏好、长文字和session有效性。主库没有本机全局排名scorer，中央服务未访问；须保留人评protocol和成对初态 / 有效性，不能以主观partial当物理predicate。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **7** 参与机构（非scene） · 原文页 1
- **4,284** 跨7policies的实测rollouts · 原文页 8

依这个顺序读

1. README.md ↗
   GitHub · robo-arena/roboarena · a07f93db00

   原benchmark、policy服务与DROID/模拟测试角色

   L1–72

---

2. roboarena/policy.py ↗
   GitHub · robo-arena/roboarena · a07f93db00

   观测字段、action chunk和session reset

   L7–30

---

3. roboarena/policy_server.py ↗
   GitHub · robo-arena/roboarena · a07f93db00

   相机需求、控制space及服务schema

   L12–48

---

4. README.md ↗
   GitHub · pranavatreya/roboarena_evaluator · 5992b26f91

   志工client的A/B偏好 / 部分分数 / 有效session流程

   L1–9 · L60–75

---

5. evaluation_client/main.py ↗
   GitHub · pranavatreya/roboarena_evaluator · 5992b26f91

   15Hz控制、部分分数转binary、媒体 / NPZ回传及人工reset

   L385–465 · L474–552 · L552–586

怎么接入我们的benchmark

可重用

policy界面、传感 / action chunk需求、A/B session设计、人评与逐步证据schema。

需要转换

environment记站点/配置，case记任务与reset证据；trial按session×policy独立存，pairwise preference作比较记录。去识别人员信息，公开报表保留站点分组与有效性。

仍需补齐

中央排名算法与完整数据访问、人工rubric一致性、各站机体/时间校准、实体任务初态对等及完整分母。

P109 · REFLECT / RoboFail

REFLECT: Summarizing Robot Experiences for Failure Explanation and Correction

内核内容已核读 · 主来源 · 原作 · 独立页面

REFLECT/RoboFail公开失败设置、历史摘要与修正运行流程；LLM对子目标的Yes判断和修正后的模拟状态成功是两种不同证据。

> **版本与身份**
>
> 原columbia-ai-robotics/reflect已转址real-stanford/reflect，属同一来源。README含旧commit示例链接；本笔固定c2f9db9，未运行LLM或模拟器。

领域	居家整理与清洁、餐饮与烹饪
环境	AI2-THOR FloorPlan场景和另附真实传感数据；RGB-D、声音、robot state形成scene graph，GT detection与感知模型模式需区分。
任务	失败原因 / 时刻辨识、运行错误与规划错误、生成恢复计划及运行检查。tasks.json的scenario会共用task_idx，但failure设置 / 原计划不同。
题数与数据	name/task_idx/scene/actions/success_condition、chosen_failure/params、gt_failure_reason/step；GT时间可能字符串或list，转换需原video_fps。events/step_i.pickle与nav_actions/interact_actions及L1/L2摘要有共同时间关系。
评估方式	run_reasoning以ans.split(", ")[0]=="Yes"解析子目标，输出prediction和GT并列于reasoning.json，GT不可回流模型。修正后另用check_task_success读THOR对象状态；例如task_idx=5检查干净mug装有coffee，未检查countertop位置。原checker并非完整自然语言目标所有条件，自建规则须另版，不覆写原分数。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **10** simulation task types · 原文页 5
- **11** real task types · 原文页 5
- **100** simulation failure cases · 原文页 5
- **30** real failure demonstrations · 原文页 5

依这个顺序读

1. `README.md` ↗

   GitHub · real-stanford/reflect · c2f9db993e

   原论文、sim/real数据与模块角色

   L1–51

---

2. `main/tasks.json` ↗

   GitHub · real-stanford/reflect · c2f9db993e

   两个具体task/scene/失败注入/GT时间与目标schema

   L1–61

---

3. `main/data.py` ↗

   GitHub · real-stanford/reflect · c2f9db993e

   逐事件pickle与nav/interact动作索引

   L1–35

---

4. `main/exp.py` ↗

   GitHub · real-stanford/reflect · c2f9db993e

   子目标/计划失败推理、输出解析及修正计划生成

   L238–347 · L350–395

---

5. `main/execute_replan.py` ↗

   GitHub · real-stanford/reflect · c2f9db993e

   运行修正动作后实际调用task checker

   L13–29 · L194–200

---

6. `main/utils.py` ↗

   GitHub · real-stanford/reflect · c2f9db993e

   时间字符串转换、10个task index的具体终态检查

   L269–355

怎么接入我们的benchmark

可重用

scenario/parent task、失败注入、传感时间链、原子actions及实体状态checker。

需要转换

同一case分诊断/恢复protocol，隔离GT原因与时间；保留parser、LLM版本、history截止、预算及原checker范围，新加目标条件以derived-rule标记。

仍需补齐

全量传感资产与对象映射、GT/感知模式公平性、文字诊断一致性、任务自然语言与程序predicate差异审核。

P110 · AHA

AHA: A Vision-Language-Model for Detecting and Reasoning Over Failures in Robotic Manipulation

内核内容已核读 · 主来源 · 原作 · 独立页面

AHA公开failure生成及失败问答评测；Yes/No脚本把正确率称为F1，LLM fuzzy评分则会略过无有效裁判输出的题。共同报表需要保留实际公式与分母。

> **版本与身份**
>
> 固定ICLR2025公开码；README依赖PerAct RLBench并含fork更新，不将其视为与所有RLBench版本相同。只核对生成来源及评分内核，未生成数据或调用裁判。

领域	居家整理与清洁
环境	RLBench/FailGen产生的机器人失败片段，另重用REFLECT等test来源；示例是时间格状拼图，不是额外可操控场景。
任务	判断子任务成功与解释失败原因；下游恢复应用另有运行protocol，问答分数本身不等于恢复成功。
题数与数据	GT JSON含字符串id、image和human/gpt conversations；Yes/No预测为JSONL整数question_id与text。样本格图包含时间顺序与未来空白格说明；source video/frame范围需追回父数据。
评估方式	Yes/No程序取逗点前小写答案，(yes正确+no正确)/indx_num为accuracy而非标准F1；预设indx_num不能当全数据实数。fuzzy用claude-3-haiku-20240307，解析correct/partially/incorrect→1/.5/0，按列序配对且只对有效裁判分数平均；须保存ID、invalid count和裁判回执。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **7** failure modes · 原文页 5
- **11,000** held-out RLBench failure QA（约数） · 原文页 8
- **130** ManiSkill-Fail pairs · 原文页 8
- **49,000** failure training pairs（约数） · 原文页 5

依这个顺序读

1. README.md ↗
   GitHub · NVlabs/AHA · 0d39c05915

   精确论文与RLBench/FailGen来源

   L1–75

---

2. aha/evaluation/REFLECT_test.json ↗
   GitHub · NVlabs/AHA · 0d39c05915

   选读一笔id/image/conversations与failure问答样本

   JSON /0

---

3. aha/evaluation/eval_metrics/check_answer_Yes_No.py ↗
   GitHub · NVlabs/AHA · 0d39c05915

   字符串ID对整数question_id、逗点前答案及实际accuracy公式

   L20–55 · L89–123

---

4. aha/evaluation/eval_metrics/LLM_fuzzy.py ↗
   GitHub · NVlabs/AHA · 0d39c05915

   模型裁判提示 / 版本、0/0.5/1解析与有效样本平均

   L27–76 · L78–112

怎么接入我们的benchmark

可重用

问答schema、父benchmark标记、二元 / 文字理由分开评测、原parser。

需要转换

case以父视频+子任务+时间窗+prompt建键；GT/预测用ID对齐，不仅等长zip。evaluator保存原称F1与实际accuracy别名、fuzzy模型/提示/解析和完整分母。

仍需补齐

全量图像和time-window映射、FailGen设置/数据split闭合、裁判一致性与invalid处理、下游物理恢复证据。

P111 · RoboReward

RoboReward: General-Purpose Vision-Language Reward Models for Robotics

文件 / 网站 · 主来源 · 原作 · 独立页面

已找到并核读HELM中的RoboReward官方入口，以及其连出的数据卡；目前确认的是排行榜网站与数据格式，未确认专用训练 / 评测后端实作。

> **版本与身份**
>
> HELM main的固定commit可查到对应2601.00675前端；未将整个HELM通用后端宣称为RoboReward专用评测程序。数据卡引用v0.0.1排行榜，latest与固定版本要分开。

领域	居家整理与清洁
环境	OXE和RoboArena的真实机器人rollout视频；源自多机体 / 场景，奖励配对不能当添加物理轨迹或环境。
任务	看task instruction＋rollout video预测1–5结束进度；反事实指令和时间截短产生不同评分题，但保留同一父视频关系。
题数与数据	官方数据卡列video/task/reward/gpt5_mini_check；train45,072、val6,232、test2,831，合54,135配对（作者数据卡数字，未全量下载）。自动检查输出是标签审核证据，不能作模型输入；test另由人验证。
评估方式	原文主指针为progress MAE并按来源群组聚合。HELM前端只渲染MiniLeaderboard与链接，不能当本地scorer；数据卡指出五级rubric，但本次未取得完整原生评分后端 / 输出解析和group aggregation程序。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **2,831** 人工验证RoboRewardBench test pairs · 原文页 3, 27
- **45,072** train episode-reward pairs · 原文页 8
- **6,232** validation pairs · 原文页 8
- **54,135** 全部split pairs · 原文页 22

依这个顺序读

1. `helm-frontend/src/components/Landing/RoboRewardLanding.tsx` ↗
   GitHub · stanford-crfm/helm · 63754d05db

   精确arXiv、HF数据/模型与排行榜链接；此档是前端展示

   L1–101

怎么接入我们的benchmark

可重用

官方数据卡schema、五级分数、train/val/test口径、OXE/RoboArena来源链。

需要转换

case以video＋instruction＋截短窗口识别；同一父episode的反事实 / 截短放在同split lineage群。reward/reference和审核信号隔离；evaluator维持MAE与群组分母。

仍需补齐

全量视频 / 原始episode ID映射、官方scorer实作、模型输出解析、生成 / 人工审核纪录和语义去重。

P112 · EgoOops

EgoOops: A Dataset for Mistake Action Detection from Egocentric Videos referring to Procedural Texts

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoOops官方库公开程序 / 视频 / 错误标注；文件5种task key对应论文4类活动。实际instruction有-1特殊值，不能照README的零基索引直接取句子。

> **版本与身份**
>
> 官方README明示数据task名称与paper不同；annotations快照和外部视频ZIP版本需双重固定。

领域	工艺与修缮、装配与生产作业、实验室操作
环境	第一人称程序活动视频，包括化学演示、纸板制作、电路和积木；task key/QR对象不是可运行机器人场景。
任务	程序文字对齐与错误动作侦测/解释。blacklight与ion都映射论文IR活动；6个mistake labels包括修正动作，不能一律当物理失败。
题数与数据	已取得metadata结构计数50video纪录、538segments、5个procedure key。segment有秒制startTime/endTime、instruction、labels/caption；[]和空caption表示正确步。实际有instruction=-1，应保留特殊值而非Python负索引。全量只结构扫描，未逐段人工验证。
评估方式	此仓库是annotations/metadata，未包含官方模型scorer或可用split定义；原文评分需另接入。538标注片段不是538道已验证测试题，视频资产与合法观测尚未闭合。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **5** 程序tasks · 原文页 3
- **6** 错误taxonomy类型 · 原文页 3
- **50** videos · 原文页 4
- **538** segments · 原文页 4
- **95** 标注execution mistakes（全库） · 原文页 4

依这个顺序读

1. README.md ↗
   GitHub · Y-Haneji/EgoOops-annotations · ec0746d4dd

   标注schema、视频来源与数据/论文名称映射

   L1–72

---

2. meta/metadata.json ↗
   GitHub · Y-Haneji/EgoOops-annotations · ec0746d4dd

   完整首例与一笔-1错误片段、程序文本；全量只做结构计数

   L1–80 · JSON /videos/1/segments/4 · JSON /instructions/cardboard/0

---

3. meta/mistake_classes.json ↗
   GitHub · Y-Haneji/EgoOops-annotations · ec0746d4dd

   6个原生mistake label类别

   L1–8

---

4. meta/microqr/blacklight.json ↗
   GitHub · Y-Haneji/EgoOops-annotations · ec0746d4dd

   同一程序内QR对象编号映射

   L1–16

怎么接入我们的benchmark

可重用

视频/task/segment身份、秒制时间、程序文本、multi-label与QR对象映射。

需要转换

保留原5task keys并连论文4活动名称；case连video/time/instruction，-1转明确特殊状态而不丢原值；错误/修正/正确和字幕各保留。

仍需补齐

视频取得、participant/split清单、-1语义正式确认、原文scorer与原生评测再现。

P113 · REPAIR-Bench

REPAIR-Bench: A Benchmark for Robot Error Perception And Interaction Recovery

实作尚未确认 · 主来源 · 原作 · 独立页面

已核对REPAIR-Bench原作与有界GitHub搜索；目前未确认此篇的官方程式库。同名软件修复benchmarks不属于这篇HRI研究。

> **版本与身份**
>
> 固定2606.29937v1 PDF与既有原文阅读纪录。搜索未确认不代表作者永远没有code；不把GitHub软件RepairBench套上这篇。

领域	医疗与手术支持、协助、交接与陪伴
环境	原文是实验室 / 医院的crash-cart取物引导交互，重用RFM-HRI人类反应数据；不是可操作整套医院任务的模拟环境。
任务	三种端点：失败时刻定位、失败类型分类、用户偏好的恢复策略；人类偏好预测不同于机器人实际恢复成功。
题数与数据	原作来源214交互/41人；排除后分析184交互/38人，含面部AU、头姿、语音 / 文字与问卷。native code schema未核实，不能把论文字段描述当可直接导入的文件规格。
评估方式	原文有时序定位误差 / tIoU F1、分类F1及恢复Hit/precision/recall/F1@k。视觉与文字端点split不同；滤波等前处理叙述尚需程序厘清。未运行scorer。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **3** 评测端点 · 原文页 1, 2
- **214** 来源interaction trials · 原文页 2
- **184** 过滤后usable trials（含各split） · 原文页 3, 4

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

原文三种端点、排除规则、participant/session来源链与人类偏好标签设计。

需要转换

数据取得后以participant→interaction→temporal case编号；各端点保留信息 / 时间截止及split，恢复偏好标明human label而非physical success。

仍需补齐

官方实作 / 数据档schema、184笔分析subset清单、前处理及端点split、GT时间与偏好映射。

P114 · RobotArena infinity

RobotArena ∞: Scalable Robot Benchmarking via Real-to-Sim Translation

内核内容已核读 · 主来源 · 原作 · 独立页面

RobotArena∞公开Genesis测试与GVL裁判流程，但自动场景生成仍列未发布。实际GVL入口使用图像加NPZ特权状态，不是单纯视频问答。

> **版本与身份**
>
> 固定预设branch fix/stable_version_genesis；README的Preview措辞与bash实际gemini-2.5-pro参数不同，需以运行manifest为准。未调用Gemini。

领域	居家整理与清洁
环境	真实画面转成Genesis Robot Arenas；预设 / 生成scene及背景、相机、对象位置扰动。∞指生成扩展能力，不是无限个已取得环境；README自动生成码未勾选发布。
任务	指定语言的操作目标在多扰动设置下评测。支持多个policy server是方法界面，不能按policy数扩大任务量。
题数与数据	预设测试65步含5步预热，存5fps MP4和同名NPZ；world/base是末端pos/quat/gripper，对象是13维pos/quat/linear/angular velocity。可加入weld抓持约束，须记assistance模式。
评估方式	GVL入口以Gemini图像＋NPZ状态评0–100进度，可做no_object/no_robot/none ablation；接触文字由5cm距离启发式推估。分数regex抓整数后clip，解析/API失败可漏frame。聚合对repeat取逐frame median，再取最高30%等；avg_last_10实际取最后num_top帧，不固定10。需固定frame身份与完整分母。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **70** BridgeSim环境 · 原文页 9, 25
- **8,749** BridgeSim人类pairwise comparisons · 原文页 8, 25

依这个顺序读

1. `README.md` ↗
   GitHub · offjangir/RobotArena · 31ae600006

   精确来源、扰动与原生发行范围

   L1–40 · L400–465 · L557–585 · L605–617

---

2. `bash_scripts/GVL.bash` ↗
   GitHub · offjangir/RobotArena · 31ae600006

   真实入口GVL_multithreaded和模型/重复设置

   L6–8 · L10–16

---

3. `src/pipeline/default_test.py` ↗
   GitHub · offjangir/RobotArena · 31ae600006

   动作与场景轨迹保存、预热及焊接辅助

   L417–450 · L497–516

---

4. `src/pipeline/GVL_multithreaded.py` ↗
   GitHub · offjangir/RobotArena · 31ae600006

   裁判输入、状态/接触近似、采样/解析与缺值

   L27–88 · L465–548 · L623–755

---

5. `src/pipeline/GVL_metrics.py` ↗
   GitHub · offjangir/RobotArena · 31ae600006

   跨裁判repeat中位数、top30%与尾段聚合

   L1–122

怎么接入我们的benchmark

可重用

scene/variant配置、成对MP4/NPZ、policy界面、明确裁判提示与聚合码。

需要转换

case固定原真实来源、生成版本、scene/扰动/辅助抓持；judge输入与policy输入分开，记模型版本/ablation/采样/每frame回执和native聚合公式。

仍需补齐

自动场景生成release、全部资产与原生匹配、实体成功checker对照、裁判一致性/漏frame处理及完整可重跑protocol。

P115 · RoboMME-Interference

RoboMME-Interference: Benchmarking Robot Memory Under Interference

内核内容已核读 · 主来源 · 原作 · 独立页面

RoboMME-Interference在既有RoboMME任务上添加跨session干扰规则；已取得并结构核对25,200列发布结果，这些是多方法rollouts，不是25,200种任务。

> **版本与身份**
>
> 此repo主要提供cross-session分析与检索扩充，README重现指令能重算发布CSV图表，不代表重新跑25,200个机器人试验。

领域	通用对象与机动作业、装配与生产作业
环境	重用RoboMME场景与任务；lesson session、k个干扰session、query是历史条件，不是增加k个新的场景种类。
任务	9native任务家族，no-history/k0/k1/k3/k7；同一query跨memory系统重跑属trial比较。原作者easy/medium/hard另为来源标签。
题数与数据	CSV已结构计数25,200rows，含variant/family/split/episode/seed/difficulty/condition/success/status、buffer构成与latency字段；前2例latency等字段为空。取得结果CSV不等于取得每次图像 / 状态或独立验证运行。
评估方式	analysis以字符串true转success_bool，按variant/condition及family分组计分母与Wilson CI。视觉gate利用lesson_span/filler真实边界校准阈值，再以query相似度选segment；校准集合须和最终test分开，purity/coverage是检索品质，不是物理成功。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **9** 适用的原task families · 原文页 2, 3
- **450** 基底test episodes · 9×50 · 原文页 4
- **25,200** 内核grid policy rollouts · 450×(11×5+1)，由协定推算 · 原文页 3, 4

依这个顺序读

1. README.md ↗
   GitHub · SoumilRathi/robomme-interference · 3536f63bbd

   父benchmark、9家族/5条件/方法网格及重现范围

   L1–24 · L58–90

---

2. results/canonical_rollouts.csv ↗
   GitHub · SoumilRathi/robomme-interference · 3536f63bbd

   只读表头与前2列；全量25,200列做结构计数

   L1–3

---

3. scripts/analyze_cross_session_results.py ↗
   GitHub · SoumilRathi/robomme-interference · 3536f63bbd

   success字符串处理、groupby分母与Wilson区间

   L98–128 · L147–192

---

4. retrieval/robomme_visual_gate.py ↗
   GitHub · SoumilRathi/robomme-interference · 3536f63bbd

   检索分段、threshold校准与purity/coverage gate

   L1–96

怎么接入我们的benchmark

可重用

query/lesson/distractor protocol、发布结果表与原生聚合、检索选框证据。

需要转换

case固定query父episode、历史session有序列表、memory budget与k；trial才连variant/result。原task来源仍是RoboMME，不重算为独立新任务库。

仍需补齐

底层RoboMME环境/政策版本与可运行资产、历史图像/embedding、校准split证据、相同query配对不确定性及完整运行回执。

P116 · OopsieVerse

OopsieVerse: A Safety Benchmark with Damage-Aware Simulation for Robot Manipulation

内核内容已核读 · 主来源 · 原作 · 独立页面

OopsieVerse把机体 / 对象损伤追踪加到既有模拟器；任务成功和健康值是两条评分线。已核对thermal公式、health累积及观测 / HDF5映射。

> **版本与身份**
>
> 固定2026-10公开码；本次深入热损伤及共同health流程，未宣称所有损伤机制、全部任务或真实安全性能已验证。

领域	居家整理与清洁、餐饮与烹饪
环境	BEHAVIOR-1K/OmniGibson及RoboCasa/RoboSuite父环境＋damageable对象 / 机体部件；损伤模型扩充不自动产生新的生活场域。
任务	完成原操作目标并控制损伤；需要记录允许的damage条件、阈值及破坏后能力改变。各任务具体completion function仍由其配置提供。
题数与数据	obs.health为float32部件矢量；info.damage_info分object/part/evaluator，HDF5 attr health_list_link_names固定矢量映射，另存task_completion/reward。health是真实可见传感或仅sim特权信号需在protocol声明。
评估方式	各part由100开始，每次update扣各evaluator damage并下界0，object health取最小part。thermal超出阈值按scale×温差且cap100；OG取Temperature，读取失败回0。step有init_skip_steps和可覆写reward_fn；计量必须固定步频/暖机/scale，损伤分数是模拟模型输出。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **21** unique task designs · 原文页 5
- **32** 跨simulator task instantiations · 原文页 5
- **90** 5task demos · 原文页 5
- **30** IL每task评测rollouts · 原文页 7

依这个顺序读

1. `README.md` ↗

   GitHub · UT-Austin-RobIn/oopsieverse · a739f99e94

   精确论文与BEHAVIOR/RoboCasa/RoboSuite父来源

   L9–38

---

2. `damagesim/core/damageable_env.py` ↗

   GitHub · UT-Austin-RobIn/oopsieverse · a739f99e94

   damage激活/锁定、health观测字段

   L43–77 · L240–269

---

3. `damagesim/core/damageable_mixin.py` ↗

   GitHub · UT-Austin-RobIn/oopsieverse · a739f99e94

   初始100、各part累积扣损与最小part健康

   L69–99 · L129–174

---

4. `damagesim/core/evaluators/thermal.py` ↗

   GitHub · UT-Austin-RobIn/oopsieverse · a739f99e94

   过热/过冷损伤确切公式

   L24–75

---

5. `damagesim/omnigibson/evaluators/thermal.py` ↗

   GitHub · UT-Austin-RobIn/oopsieverse · a739f99e94

   具体OG Temperature读取及缺值行为

   L1–60

---

6. `damagesim/omnigibson/damageable_env.py` ↗

   GitHub · UT-Austin-RobIn/oopsieverse · a739f99e94

   step与damage更新、task completion、串行化健康部件索引

   L233–290 · L437–472 · L1087–1125

怎么接入我们的benchmark

可重用

父task＋damage配置、各part健康与细项诊断、HDF5部件字典。

需要转换

case固定机体/材料/损伤参数/步频/初始health与合法观测；evaluator分task completion、damage trajectory、约束违反，原先无损伤与扩充协定分版。

仍需补齐

全任务completion predicates与assets对齐、机械/电气子模型逐项接线、步频与真实损伤校准、回放T/T+1及状态闭合验证。

P117 · UMI

Universal Manipulation Interface: In-The-Wild Robot Teaching Without In-The-Wild Robots

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

UMI是示范搜集与跨机体部署界面。需要分开原始视频/SLAM、重播buffer、训练pose表达和实际控制；README的SLAM可用比例不是任务成功率。

> **版本与身份**
>
> 固定d095ba9；code另重用Diffusion Policy与ORB_SLAM3，不把内含的其他task示例当新UMI独立数据。只核读内核转换与控制修正，未运行硬件。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	野外手持gripper/相机搜集与实机部署两种场景；有左右gripper及非gripper相机，frame serial/场景和episode需保留关系。
任务	UMI可搜集多种操作示范并训练Diffusion Policy；示范source与下游robot task不同层，SLAM成功不能替代物理任务成功判断。
题数与数据	dataset_plan.pkl含grippers/tcp_pose/gripper_width/demo_start/end_pose及cameras/video_path/video_start_end。转成Zarr robotN_eef_pos/rot_axis_angle/width。训练把原每手7D转成pos3+rot6+gripper1；mat_to_pose10d本身是9D，不能从函数名猜10D。
评估方式	已读部署端有桌面高度与双臂球碰撞姿态修正，属控制辅助；未核得通用跨任务自动成功checker。数据读取保留每key的horizon/latency_steps/down_sample；当前action转换实际用obs_pose_repr，即使另有action_pose_repr设置也需验证。

依这个顺序读

1. `README.md` ↗

   GitHub · real-stanford/universal_manipulation_interface · d095ba9590

   原始论文、SLAM与数据转换链

   L1–24 · L47–87

2. `scripts_slam_pipeline/07_generate_replay_buffer.py` ↗
   GitHub · real-stanford/universal_manipulation_interface · d095ba9590

   dataset_plan、每gripper姿态与多相机frame对齐

   L75–145

---

3. `diffusion_policy/dataset/umi_dataset.py` ↗
   GitHub · real-stanford/universal_manipulation_interface · d095ba9590

   各观测/动作的horizon/latency/downsample与座标表示

   L30–44 · L91–125 · L334–372

---

4. `umi/common/pose_util.py` ↗
   GitHub · real-stanford/universal_manipulation_interface · d095ba9590

   rotvec、旋转6D以及pose10d函数实际输出

   L17–44 · L86–115

---

5. `eval_real.py` ↗
   GitHub · real-stanford/universal_manipulation_interface · d095ba9590

   部署端桌面和双臂碰撞修正属于控制介入

   L64–106

怎么接入我们的benchmark

可重用

视频→SLAM→dataset_plan→Zarr的来源链、gripper/相机身份与时间/座标转换。

需要转换

human-held demonstration与robot trial分开；case固定座标anchor、原7D/训练10D/部署格式、延迟补偿及控制修正；处理品质和task success另列。

仍需补齐

原视频/SLAM资产与校准、全部示范有效性、下游task rubric、时间/pose转换与跨机体运行验证。

P118 · EgoMimic

EgoMimic: Scaling Imitation Learning via Egocentric Video

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

EgoMimic把Aria人类数据与Eve机器人数据转成相似HDF5结构，但人类future palm位置和机器人关节动作仍是不同动作语义。

> **版本与身份**
>
> 主README仍连旧Eve名称；已读EgoMimic-Eve README明确回指本作。两repo commit各固定；不把hardware代码等同数据已取得。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	Aria Glasses的人类观测与Eve/ViperX单臂或双臂桌面平台；实际camera extrinsics/arm侧及人机数据源要分开。
任务	人机共同模仿学习，示例包括groceries、laundry、小物放碗；mask/插值与同一demo多chunk是表示 / 样本扩充，不是添加语义任务。
题数与数据	人类future palm经future camera→world→目前camera变换，单手3D / 双手6D，actions_xyz再插值成100步actions_xyz_act；每300frame另存demo。robot原HDF5为qpos/qvel/effort/action14D，图像可JPEG padded且compress_len另存。type栏明记human/robot。
评估方式	eval_real输出actions_joints_act，可temporal aggregate，按query_frequency送到实机；此选读程序是rollout，不提供统一任务成功判分。数据筛掉出界/跳动frame，case需保存原时间映射；offline action loss与physical success分开。

依这个顺序读

1. `README.md` ↗

   GitHub · SimarKareer/EgoMimic · 6d63e9a3cd

   原作、三组样本数据与独立人/机器人normalization

   L1–18 · L37–54 · L82–92

2. `data_processing.md` ↗
   GitHub · SimarKareer/EgoMimic · 6d63e9a3cd

   手眼标定与人类/机器人转换入口

   L19–77

3. `egomimic/scripts/aria_process/aria_to_robomimic.py` ↗
   GitHub · SimarKareer/EgoMimic · 6d63e9a3cd

   future palm到目前camera frame、筛样、HDF5 chunk与插值

   L181–258 · L299–330 · L468–519

4. `egomimic/utils/dataset.py` ↗
   GitHub · SimarKareer/EgoMimic · 6d63e9a3cd

   时序padding/goal采样及robot=0/hand=1标记

   L122–196

5. `egomimic/scripts/evaluation/eval_real.py` ↗
   GitHub · SimarKareer/EgoMimic · 6d63e9a3cd

   joint-action rollout/temporal aggregation而非任务判分

   L225–240 · L279–303

6. `README.md` ↗
   GitHub · SimarKareer/EgoMimic-Eve · b0e45c3f75

   硬件repo与主论文的相互认领

   L1–31

7. `scripts/record_episodes.py` ↗
   GitHub · SimarKareer/EgoMimic-Eve · b0e45c3f75

   原robot14D关节/动作、JPEG压缩长度与HDF5格式

   L302–338

怎么接入我们的benchmark

可重用

人机两域、转换矩阵、原HDF5/处理后chunk关系、type与action keys。

需要转换

source保留raw VRS/MPS与Eve session；case分domain/action语义/arm/camera/normalization，300frame chunk共享parent demo避免split泄漏，插值点不当独立观测。

仍需补齐

原始资产与校准版本、前处理保留索引、robot/human action对齐验证、下游人工/物理判分协定与全量split。

P119 · EgoDex

EgoDex: Learning Dexterous Manipulation from Large-Scale Egocentric Video

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoDex官方库提供HDF5/MP4 loader及best-of-K轨迹误差。829小时包含split冻结后追加数据；每frame样本量不能当不同任务或episode数。

> **版本与身份**
>
> apple/ml-egodex已转址apple-aiml-research/ml-egodex，属同一源。README分约725h train/7h test/97h extra；不可将追加部分混进原冻结test。

领域	居家整理与清洁、衣物与洗护、装配与生产作业、穿戴交互与动作界面
环境	Vision Pro/ARKit第一人称桌面人类操作；每episode的ARKit origin由设备初始化，不保证跨episode一致，不能把相同world坐标当同一场所。
任务	作者报194种人类操作task，829小时数据；test/robot部署是不同用途。loader __len__回总frame数，不是194任务的题数。
题数与数据	同索引MP4/HDF5，30Hz对齐；camera intrinsic3×3、各joint transforms N×4×4、可选confidence；reversible语言用llm_description/description2及which_llm_description。loader比较字符串"1"，需验证实际attr类型。
评估方式	evaluate_distance采B×T×48 GT与K×B×T×48 prediction，排除任何padding的chunk，选出12个位置点而略过6D旋转；平均距离与终点距离各自best-of-K，可能选不同候选。这是人类轨迹预测误差，非机器人完成率。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **194** 人类操作tasks · 原文页 2, 4, 6
- **2** 轨迹benchmark端点 · 原文页 6
- **338,000** human episodes · 原文页 2, 4
- **829** 视频小时 · 原文页 4

依这个顺序读

1. `README.md` ↗
   GitHub · apple-aiml-research/ml-egodex · 718d9ebd8e

   原作、split/extra与SE3/语言/置信度schema

   L1–9 · L37–87

---

2. `simple_dataset.py` ↗
   GitHub · apple-aiml-research/ml-egodex · 718d9ebd8e

   frame到episode定位、座标与reversible指令 / 置信度取值

   L15–75

---

3. `compute_metrics.py` ↗
   GitHub · apple-aiml-research/ml-egodex · 718d9ebd8e

   48D动作中只评位置、padding排除、各K独立最小化

   L11–50

怎么接入我们的benchmark

可重用

episode/media配对、ARKit座标、joint confidence、语言方向及best-of-K metrics。

需要转换

case固定episode/frame/history/horizon/K及query joints；raw SE3和prediction action表达分开，split冻结后extra另版，confidence缺失和padding明确标记。

仍需补齐

大型媒体取得、194task完整manifest、语言方向标签确认、joint/action映射与全test一致聚合；robot retargeting需另协定。

P120 · EgoScale

EgoScale: Scaling Dexterous Manipulation with Diverse Egocentric Human Data

实作尚未确认 · 主来源 · 原作 · 独立页面

NVIDIA官方EgoScale页目前提供论文与方法 / 视频介绍，未提供可确认的GitHub实作；相似名称搜索结果不可直接当官方benchmark程序。

> **版本与身份**
>
> 以2602.16710与NVIDIA研究页核对身份；Exoscale云端SDK、EgoScaler不同论文及unofficial候选不视为本作官方实作。已补看dipfocus候选README（论文整理 / 骨架）及paragonLab候选（实为Fast-WAM）；wingAGI候选README界面404，未据此断言repo不存在。

领域	居家整理与清洁、衣物与洗护、办公与教育、装配与生产作业、零售与购物、实验室操作
环境	原文的人类pretraining scene labels与实机桌面评测场地不同层次；EgoDex和in-house来源保留来源链，未取得完整场景manifest。
任务	原文6,015人类训练标签、344对齐midtraining任务与5个主实机目标需分开；本次没有将训练标签当已可运行robot task。
题数与数据	官方页述20k+小时action-labelled egocentric video与少量人机对齐数据；原文细量与6D手 / 机体转换须原始数据 / 实作确认，未取得完整字段规格。
评估方式	原文whole-task成功与细项完成度；当前页未给可运行scorer、全量reset banks或逐次rollout纪录，不能由视频展示推算整体成绩。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **9,869** 作者报告human scene labels · 原文页 3
- **6,015** human pretraining task labels · 原文页 3
- **344** aligned midtraining tabletop tasks · 原文页 4
- **5** real-robot evaluation tasks · 原文页 6, 7
- **20,854** human pretraining hours · 原文页 3

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

训练来源/中间对齐/下游评测三层设计、原作reported规模及机体差异。

需要转换

source保留EgoDex/in-house父来源，task分training labels与下游目标，case待manifest后固定观测/hand→robot action转换与审核规则。

仍需补齐

官方实作认领、可访问数据与schema、实机protocol和trial集合、与同源大corpus的重叠映射。

P121 · EgoZero

EgoZero: Robot Learning from Smart Glasses

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

EgoZero公开Aria示范前处理和Franka点轨迹控制；提供的Franka底层done固定False，不能直接把现有success日志当自动任务成功评测。

> **版本与身份**
>
> 固定51dc1c6；公开code偏数据处理/实机部署，硬件另依Franka-Teach。未向MPS提交数据或运行机器人。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	人类Aria录像与Franka/iPhone RGB-D实机部署，需ArUco/相机/robotframe的标定；手持示范场景不等于已可重播机器人环境。
任务	由人类点 / 手部轨迹学习操作；原README按指定手消失来分demo，用另一手reset，这是搜集协定而非任务语义。
题数与数据	每demo保存original.mp4、palm/wrist/index/thumb/grasp/pose.npy、fingers_keypoints及first_frame_g2w；人工标记对象点 / triangulation另存。Frankafeatures为pos3+quat4+gripper1；底层声明action_dim=7却按pos/quat/gripper切片，须核对wrapper实际编码。
评估方式	eval.sh选eval_point_track、10queries/10history与temporal_agg；日志平均goal_achieved。所读Franka step总回done=False，wrapper把done设为goal_achieved，因此此路径未提供task-specific自动成功checker。实机操作展示与论文实验评分需另保留人工 / 任务规则。

依这个顺序读

1. `README.md` ↗

   GitHub · vliu15/egozero · 51dc1c622b

   原作、手部缺席分段、人工点击与数据/部署流程

   L6–16 · L50–87

2. `preprocess.py` ↗
   GitHub · vliu15/egozero · 51dc1c622b

   每demo保存的视频、手部与姿态/映射字段

   L485–521

---

3. `scripts/eval.sh` ↗
   GitHub · vliu15/egozero · 51dc1c622b

   真正部署入口为eval_point_track及历史/查找预算

   L31–45

---

4. `franka-env/franka_env/envs/franka_env.py` ↗
   GitHub · vliu15/egozero · 51dc1c622b

   底层action切片、RGB-D观测、reward/done返回

   L98–113 · L143–204

---

5. `point_policy/suite/point_policy.py` ↗
   GitHub · vliu15/egozero · 51dc1c622b

   点动作转实机指令与goal_achieved沿用done

   L219–231 · L277–292 · L435–451

---

6. `point_policy/eval_point_track.py` ↗
   GitHub · vliu15/egozero · 51dc1c622b

   末步goal_achieved平均的限制

   L532–566

怎么接入我们的benchmark

可重用

示范切分规则、对象点 / 手轨迹、pose标定、部署query/history约定。

需要转换

人类demo连原VRS/MPS与分段时间，policy action保留几何/关节/夹爪转换；case需加具体任务goal与判分器，不能直接沿用placeholder done。

仍需补齐

全量数据/权重、原始校准与采样纪录、action形状验证、每task成功rubric及可重现测试初态。

P122 · EgoBridge

EgoBridge: Domain Adaptation for Generalizable Imitation from Egocentric Human Data

实作尚未确认 · 方法 / 综述 · 原作 · 独立页面

EgoBridge原作项目页的Code Release链接实际是#占位符；未确认官方程式库，不能将受其启发的机器翻译repo当机器人实作。

> **版本与身份**
>
> 以2509.19626和EgoBridge完整题名核对，项目页code href=#。搜索的AttentionBridge/AB-2是NMT衍生研究。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	原文/项目页的人类egocentric与robot观测两域，含模拟及三项真实单臂 / 双臂操作；研究方法重用源数据，不是独立通用环境包。
任务	Optimal Transport对齐人机策略latent并联合模仿学习；比较in-domain及新对象/场景/人类示范行为的转移。
题数与数据	方法需human/robot observation-action串行、动作距离与域标签；未确认公开loader、精确tensor/座标或数据发行schema。
评估方式	原文实机成功率和generalization设置可供参考；项目页成果视频与方法图不提供可运行的benchmark checker或已可导入case清单。

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

人机父来源区分、视觉/传感/运动学差异、OT/DTW对齐与generalization设计。

需要转换

方法列related reference；human demo与robot episode保留各自embodiment/action约定，另记对齐关系，不把latent样本算新实体任务。

仍需补齐

正式code release、来源数据schema、对齐 / 切分manifest、下游成功判定和原生重现。

P123 · WatchAct

WatchAct: A Benchmark for Behavior-Grounded Robot Manipulation

内核内容已核读 · 主来源 · 原作 · 独立页面

WatchAct有14种行为理解题型，规划用符号状态评分，LIBERO另跑物理运行；Plan Success、完整终态一致和实体成功不能合并成同一数值。

> **版本与身份**
>
> 本次固定97d8873；先前原作索引使用7036927快照，不能直接当同版本。未调用VLM、translator或policy server，也未运行LIBERO。

领域	居家整理与清洁、通用对象与机动作业
环境	观察人类视频后在LIBERO桌面运行；视频camera_perspective/spatial_reference与模拟相机 / 世界坐标要分开。符号场景图不等于新的物理场景。
任务	14native题型如Imitation/Reversal/Temporal_Sort、Count/Moment、Implicit Intent与Episodic等，属行为条件与推理方式；具体robot goal / 对象 / 初态另定，不把14题型当14生活用途。
题数与数据	row有id/original_id、language_instruction、video、camera_perspective、spatial_reference；按original_id群组抽样。规划输出action_plan_json，翻译/符号推演产initial/final/goal_state；运行端是BDDL、init_state、prompt切换与policy action chunk。
评估方式	Plan SR对需变化的interest objects全对即成功，可能忽略side effects；all_success才要求完整终态相等。Imitation/Reversal可改用串行匹配SR。LIBERO物理成功从done取，progress另记max(0,final-initial)，Right/Horizontal检查几何且对象已释放、接触桌面。汇总依evaluated_count加权，error_count与缺题需另保留。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **14** task scenarios · 原文页 4
- **4** 认知capability groups · 原文页 4
- **3,000** paired video-simulator instances · 原文页 1, 4
- **10** policy每task评测trials · 原文页 6

依这个顺序读

1. `README.md` ↗

   GitHub · Baiqi-Li/WatchAct · 97d8873e41

   14题型/4能力与规划、翻译、物理运行分离

   L1–19 · L38–49 · L66–100

---

2. `video_planning/scripts/run_vlm_evaluation.py` ↗

   GitHub · Baiqi-Li/WatchAct · 97d8873e41

   输入字段、视频采样及original_id群组抽样

   L542–608 · L712–732

---

3. `video_planning/scripts/run_action_plan_simulation.py` ↗

   GitHub · Baiqi-Li/WatchAct · 97d8873e41

   planning simulation是符号状态更新

   L205–272 · L476–482

---

4. `video_planning/scripts/run_action_plan_scoring.py` ↗

   GitHub · Baiqi-Li/WatchAct · 97d8873e41

   目标变化、完整状态、sequence覆写与分母

   L370–468 · L586–621 · L708–736

---

5. `action_execution/run_libero_execution.py` ↗

   GitHub · Baiqi-Li/WatchAct · 97d8873e41

   物理运行done、原始/初始/net completion与trial聚合

   L123–140 · L185–215 · L246–269 · L460–498

---

6. `action_execution/custom_predicates.py` ↗

   GitHub · Baiqi-Li/WatchAct · 97d8873e41

   Right/Horizontal必须resting及几何条件

   L122–199

怎么接入我们的benchmark

可重用

视频/语言/视角条件、原题型、original_id lineage、planning与physical两种checker。

需要转换

同一来源题分planning case与execution case，各固定translator/模型信息/预算；存PlanSR/all_success/physical_success、原始及net progress不同metric。新加无副作用规则另版。

仍需补齐

全视频与BDDL/init-state资产对齐、翻译前后语义验证、底层LIBERO版本、初态已达标剔除与完整missing/error分母协定。

P124 · RoboReel

Monkey See, Can Monkey Do? A Benchmark for Evaluating Robot Skill Learning by Observation

文件 / 网站 · 主来源 · 原作 · 独立页面

RoboReel已有官方GitHub网站仓库；固定index.html的Code与Data仍为disabled Soon按钮，动画 / 展示脚本不是benchmark运行码。

> **版本与身份**
>
> 固定2609.08209v2及网站a3589a9快照。网站source含动画生成工具和展示视频，不宣称robot benchmark程序 / 全数据已公开。

领域	居家整理与清洁
环境	原文是实拍桌面人类视频与ManiSkill3/SAPIEN对应场景；多相机视频不是多个独立物理环境。
任务	10个操作task、4个evaluation suites；任务条件 / 干扰和同一task的多视角保留关系，不乘为40种语义任务。
题数与数据	原文正文2,000人类示范，附录含PD共3,000＝12,000视角视频，另2,000robot trajectories。这些是原文reported量；GitHub展示mp4不能替代正式数据release。
评估方式	原文用模拟predicate、固定初态bank及3runs×20rollouts之每cell设置；抽屉 / toaster等阈值需保留。固定网站没有原生checker / bank清单，未跑评测。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **10** task types · 原文页 4, 5
- **4** evaluation suites · 原文页 4
- **3,000** 含ND/WD/PD的human demos · 原文页 24, 25
- **2,000** paired robot trajectories · 原文页 24, 25
- **60** 每model/task/setting结果cell rollouts · 原文页 29

依这个顺序读

1. `README.md` ↗

   GitHub · RoboReel/roboreel.github.io · a3589a9c08

   网站仓库名称

   L1–1

---

2. `index.html` ↗

   GitHub · RoboReel/roboreel.github.io · a3589a9c08

   Code/Data发布状态与精确论文 / 作者身份

   L100–104 · L771–775

怎么接入我们的benchmark

可重用

10task/4suites设计、paired人机来源关系、原文成功阈值与多视角区分。

需要转换

human demo为parent，多view作同一示范媒体；robot episode别存，case固定suite/初态bank/合法观测与原文predicate版本。

仍需补齐

正式code/data发布、配对及split manifest、初态bank数量矛盾厘清、每任务checker与资产取得。

P125 · Open X-Embodiment

Open X-Embodiment: Robotic Learning Datasets and RT-X Models

内核内容已核读 · 主来源 · 原作 · 独立页面

Open X-Embodiment提供共用RLDS容器与数据读取示例；相同tensor形状并不自动统一不同机体动作的物理意义，父数据集也不能重复计数。

> **版本与身份**
>
> 固定9eeb68b；README的3Hz/单workspace RGB是RT-1-X模型界面，不代表所有OXE数据的原采样率和可见模态。Notebook source cells与输出分开核读。

领域	居家整理与清洁、餐饮与烹饪、通用对象与机动作业
环境	聚合多来源、多机体的robot episodes，包括Bridge、RoboNet等；每个子数据原有场景和授权/版本，OXE不是额外一份完全独立的环境数据。
任务	主要是跨机体训练数据与RT-X方法；不能把数据集数、机体数、skill labels和实际评测题数互换。
题数与数据	RLDS episode含steps，notebook以TFDS builder从固定dataset/version读取。Kuka示例拼world_vector/rotation_delta/gripper_closedness_action，Mutex直接取action；图像resize128。另一例保留is_first/is_last/is_terminal且只对齐图像，并未对齐所有action语义。
评估方式	仓库读取 / 混合示例和RT-1-X inference不是覆盖全部子数据的通用成功checker。README指出7个控制变量可能是absolute/delta/velocity；相等TensorSpec只是形状检查。tf.data.repeat重复采样不增加独立数据；train[:10]也是示例subset。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **60** pooled source datasets（本PDF版本） · 原文页 3
- **22** robot embodiments · 原文页 3
- **527** 作者报告skills · 原文页 6
- **160,266** 作者报告tasks，语言语义去重待核 · 原文页 6

依这个顺序读

1. `README.md` ↗

   GitHub · google-deepmind/open_x_embodiment · 9eeb68b989

   数据聚合角色、RLDS、RT-1-X输入与native action差异

   L1–37 · L45–61

---

2. `colabs/Open_X_Embodiment_Datasets.ipynb` ↗

   GitHub · google-deepmind/open_x_embodiment · 9eeb68b989

   只读列出的code cells：数据版本、Kuka/Mutex读取与轨迹容器；未读大型嵌入输出或运行notebook

   JSON /cells/5/source · JSON /cells/7/source · JSON /cells/13/source · JSON /cells/16/source · JSON /cells/17/source · JSON /cells/26/source · JSON /cells/34/source · JSON /cells/35/source

---

怎么接入我们的benchmark

可重用

RLDS episode/step结构、子数据dataset/version引用与来源引用规则。

需要转换

source维持OXE→子dataset→原episode lineage，case保留子来源ID与split；另补ActionSpec的座标/单位/absolute-delta-velocity/夹爪约定及task-specific evaluator。

仍需补齐

全子数据素材与精确manifest、跨来源重复episode、任务语义对齐、共同测试split与各机体可运行成功判定。

P126 · DROID

DROID: A Large-Scale In-The-Wild Robot Manipulation Dataset

内核内容已核读 · 主来源 · 原作 · 独立页面

DROID有原始搜集平台与policy-learning两个官方仓库；raw/RLDS、更新语言与相机标定是同一来源的不同发行物。实机成功由人员标记。

> **版本与身份**
>
> 2024-12添加75k成功episodes的多语言、2025-04更新36k标定为作者公布更新，不添加独立数据集。policy loader依赖Octo85b83fc，不能自动换成目前HEAD。

领域	居家整理与清洁、餐饮与烹饪、办公与教育
环境	多站点DROID robot及相机配置；schema有lab/building/scene_id/robot_serial与外参，不用平台数代替环境数。scene_id=-1表示未提供值，须保留未知而非新场景。
任务	language/goal条件对象操作；示范、失败、下游自选任务和eval trials不同集合。三句语言描述对同episode不增加实体轨迹。
题数与数据	raw为trajectory.h5、metadata与多视角MP4/SVO；RLDS有episode_metadata和steps含3图、state、action_dict、多语言与episode flags。training transform用cartesian_position转pos3+rot6+gripper1，另移除第一action；预设只取success路径及有语言数据。
评估方式	实机GUI由人员按键保存success/failure，metadata未提供success时为None。RobotEnv的step返回action_info，不能当task success。文件flat action7D注解提6joint velocities，但RobotEnv区分cartesian7/joint8，使用时应以明确action_dict及converter核对语义。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **564** unique robot workspaces · 原文页 3
- **52** buildings · 原文页 3
- **86** verb-based task labels · 原文页 3
- **6** downstream evaluation tasks · 原文页 7
- **76,000** robot demonstration trajectories（约数） · 原文页 3

依这个顺序读

1. `README.md` ↗
   GitHub · droid-dataset/droid · 33ae6a6727

   平台、论文与官方policy-learning链接

   L1–22

---

2. `README.md` ↗
   GitHub · droid-dataset/droid_policy_learning · 9a29c832b4

   语言/标定更新、RLDS与Octo固定依赖

   L1–43 · L46–74

---

3. `docs/the-droid-dataset.md` ↗
   GitHub · droid-dataset/droid · 33ae6a6727

   RLDS与原HDF5/MP4/SVO层级

   L44–82 · L84–103

---

4. `droid/postprocessing/schema.py` ↗
   GitHub · droid-dataset/droid · 33ae6a6727

   UUID/lab/scene、success未知值、版本与相机标定

   L12–89

---

5. `droid/robot_env.py` ↗
   GitHub · droid-dataset/droid · 33ae6a6727

   cartesian7D/joint8D、15Hz与velocity范围

   L16–33 · L49–63

---

6. `examples/droid_dataloader.py` ↗
   GitHub · droid-dataset/droid_policy_learning · 9a29c832b4

   过滤/视角/窗口/normalization的训练view

   L14–79

---

7. `robomimic/utils/rlds_utils.py` ↗

   GitHub · droid-dataset/droid_policy_learning · 9a29c832b4

   success路径筛选、绝对10D动作与action时间截取

   L1–65

---

8. `droid/user_interface/eval_gui.py` ↗

   GitHub · droid-dataset/droid · 33ae6a6727

   A/B按键标记成功/失败与实机eval来源

   L552–578 · L611–625

怎么接入我们的benchmark

可重用

UUID/lab/scene/version、原始与RLDS映射、相机标定、action_dict、人评标签。

需要转换

一个parent episode连raw/RLDS/语言更新/标定版本；case固定模型可见相机、座标/control mode、初态与人评rubric；training选样不得当完整benchmark分母。

仍需补齐

大型素材、UUID至更新标定/语言的全量join、原成功标签和case集合、原生评分者一致性、实机或匹配模拟运行。

P127 · BridgeData V2

BridgeData V2: A Dataset for Robot Learning at Scale

内核内容已核读 · 主来源 · 原作 · 独立页面

BridgeData V2提供raw/自订TFRecord/RLDS多种表示。预设训练action会被改写成到达状态差分，gripper还会使用后续状态重新标记，不能只改文件扩展名。

> **版本与身份**
>
> 固定bc60a35，README清楚区分raw demos与scripted zip及多种表示。此repo是训练/部署方法实作，不能把其所有分支范例当Bridge添加benchmark。

领域	居家整理与清洁、餐饮与烹饪、衣物与洗护
环境	WidowX在多种桌面/厨房环境的搜集与部署；raw示范和scripted数据、经转换的TFRecord/RLDS共用来源episode。
任务	goal-image或language条件的操作；各算法/目标重标与视角不是新的物理任务。CALVIN/SuSIE子目录为其他实验来源，需另标parent。
题数与数据	自订TFRecord每example一trajectory，含observations与next_observations的image/state、actions、terminals/truncates和可选language。relabel_actions用next_proprio[:6]-current_proprio[:6]，gripper阈值>.95/<.05再回填中间值；chunk补首obs/末action，goal与language另采样。
评估方式	部署从checkpoint还原action_mean/std；采样后可加noise、sticky-gripper状态机与屏蔽部分姿态自由度，再送WidowX。这些是控制协定。所读eval程序提供rollout，没有通用任务成功predicate；原作实机成功标记需另建protocol。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **24** source environments · 原文页 5
- **13** skills · 原文页 5
- **60,096** expert+scripted trajectories · 原文页 5
- **10** real trials per method/task · 原文页 6

依这个顺序读

1. `README.md` ↗
   GitHub · rail-berkeley/bridge_data_v2 · bc60a35b70

   原作、表示与方法角色、真实controller来源

   L1–27 · L41–74

---

2. `jaxrl_m/data/bridge_dataset.py` ↗
   GitHub · rail-berkeley/bridge_data_v2 · bc60a35b70

   TFRecord schema、action重标、chunk padding与goal relabeling

   L41–81 · L257–312 · L349–397

---

3. `experiments/eval.py` ↗
   GitHub · rail-berkeley/bridge_data_v2 · bc60a35b70

   checkpoint action反范式、sticky gripper与DOF限制

   L82–150 · L325–369

怎么接入我们的benchmark

可重用

父episode、多格式映射、原生7D action/重标规则、goal和语言条件。

需要转换

保存raw_action与training_action的转换/normalization版本；补值mask、来源时间、goal采样一起记入case；评测固定action execution horizon及gripper/DOF后处理。

仍需补齐

raw→NumPy→TFRecord/RLDS全量ID映射、相机/场景metadata、测试split与成功rubric、与OXE子数据去重、原生部署验证。

P128 · RoboNet

RoboNet: Large-Scale Multi-Robot Learning

内核内容已核读 · 主来源 · 原作 · 独立页面

RoboNet原生loader会检查数据hash，统一T个图像/状态与T−1个action；不同机体维度可补零、截短或推估autograsp，必须保留转换来源。

> **版本与身份**
>
> 固定d83eee2的2019来源实作；RoboNet另被OXE重发为RLDS，需保留同一父episode关系。未运行TF模型或原数据loader。

领域	通用对象与机动作业
环境	多机器人HDF5 interaction sequences，metadata带robot/ncam/维度/长度/文件hash。任务环境或对象配置不能由机体名与record数推定。
任务	动作条件视频预测、逆动态 / 视觉控制及标注点预测；frame、subsequence、同episode多camera皆不是添加语义任务。
题数与数据	env/state、policy/actions、camera图像及可选bbox_annotations；loader以min(state_T,img_T,action_T+1)决定可用T，action取T−1。Mismatch模式可PAD_ZERO/CLEAVE，autograsp根据后一state及边界推估添加控制维。
评估方式	标注variant预设拆non-annotated train/val/test并另列annotated robots；指定train_ex_per_source时另走分支，须固定split规则。metrics提供分布像素距离和normalize到1的PSNR/MSE等，值受resize/camera/horizon影响，不是物理task完成率。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **4** lab environments · 原文页 5
- **113** camera configurations · 原文页 5
- **15,000,000** video frames（约数） · 原文页 1

依这个顺序读

1. `README.md` ↗
   GitHub · SudeepDasari/RoboNet · d83eee20f3

   原作、数据与inverse/video prediction方法角色

   L1–20

---

2. `robonet/datasets/util/hdf5_loader.py` ↗
   GitHub · SudeepDasari/RoboNet · d83eee20f3

   state/action维度、autograsp推估、标注缩放与T对齐

   L78–174

---

3. `robonet/datasets/variants/annotation_benchmark_dataset.py` ↗
   GitHub · SudeepDasari/RoboNet · d83eee20f3

   有/无标注与robot-specific评测模式

   L1–54

---

4. `robonet/video_prediction/metrics.py` ↗
   GitHub · SudeepDasari/RoboNet · d83eee20f3

   像素距离与MSE/PSNR的实际计量公式

   L13–88

怎么接入我们的benchmark

可重用

内容hash、原robot/相机/维度、T/T−1对齐、标注模式与视觉metrics。

需要转换

case记parent HDF5、选取camera/起始frame/context/horizon、原维度和补零/截断/autograsp推估；像素误差附图像分辨率，原标注缺失与零placeholder分开。

仍需补齐

数据资产与完整metadata、场景/语义目标映射、原train/test与annotated子集隔离、视觉控制真实成功协定及跨来源去重。

P129 · RH20T

RH20T: A Comprehensive Robotic Dataset for Learning Diverse Skills in One-Shot

内核内容已核读 · 主来源 · 原作 · 独立页面

RH20T API能按时间对齐多相机、TCP和力矩，但不同机体有不同前处理；tactile原始数据可加载，按时间查找界面仍是占位。

> **版本与身份**
>
> 固定aa31244 API版；README列出的界面和实作范围分开。未下载大数据或进行online机器人投影运行。

领域	居家整理与清洁、装配与生产作业、通用对象与机动作业
环境	多机器人配置与相机串行的实拍操作场景；scene folder是数据record脉络，机体/摄影机数不能当独立环境数。
任务	多样操作示范与多模态学习数据；此库主要提供loader/visualizer/online preprocessor，任务目标与评测协定需连原文 / 来源metadata。
题数与数据	时间查找以毫秒，图像选最近low-frequency timestamp，TCP/FT/关节/夹爪值另线性插值。TCP7D四元数、FT6D；Kuka位置除1000，Franka/UR5姿态及不同gripper各有processor；标定和raw/zeroed FT不能混用。
评估方式	没有从此数据API取得通用task成功scorer。get_tactile(timestamp)与detect_outlier仍NotImplemented，高频gripper getter也未实作；不能由tactile.npy存在推定整套评测界面可用。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **147** task definitions · 原文页 3
- **42** skill verbs · 原文页 3
- **110,000** robot sequences · 超过；另等量human sequences · 原文页 2, 3
- **20** 主实验每configuration trials · 原文页 5

依这个顺序读

1. README.md ↗
   GitHub · rh20t/rh20t_api · aa31244347

   数据API、相机/TCP/FT与毫秒查找入口

   L1–60

---

2. rh20t_api/configurations.py ↗
   GitHub · rh20t/rh20t_api · aa31244347

   机体单位/姿态/夹爪转换及标定矩阵

   L1–83

---

3. rh20t_api/scene.py ↗
   GitHub · rh20t/rh20t_api · aa31244347

   最近影格、连续值插值、原始tactile与未实作界面

   L38–75 · L114–115 · L467–489 · L528–550 · L563–592 · L617–639

---

4. rh20t_api/online.py ↗
   GitHub · rh20t/rh20t_api · aa31244347

   机体base到相机的TCP/FT投影

   L127–155

怎么接入我们的benchmark

可重用

配置ID、相机serial、raw/aligned数据、毫秒时间与机体/相机转换参数。

需要转换

source/native scene与实际workspace分开；case保存各模态原始时间/插值方式/数据缺失、TCP encoding、FT零偏和gripper单位；sensor trace不是直接可运行action。

仍需补齐

全量metadata/素材、任务goal及split、四元数插值有效性、tactile/高频gripper接线与原生评测判分。

P130 · ALOHA / ACT

Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

ALOHA提供双臂搜集，ACT提供训练及两个模拟任务。sim的成功从最高reward判定；真实模式的reward占位不能当原文实机成功率。

> **版本与身份**
>
> ALOHA/ACT各固定commit；真实环境中的0 reward是软件界面占位，不能推论原论文实机研究使用此栏自动评分。未运行硬件或sim。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	真实双臂ALOHA与MuJoCo/DM-Control两个模拟场景分开；数据中的四相机 / 四个主从臂不算四种任务环境。
任务	ACT repo两个sim任务为Transfer Cube/Bimanual Insertion；joint-control和EE-control是运行表示，scripted/human是示范来源，不能各算新的语义task。
题数与数据	HDF5 obs qpos/qvel/effort与action均14D，RGB相机分key。搜集T次action产T+1 timesteps，但保存配对只取前T。ACT real数据从start_ts−1取action，sim从start_ts取，padding与mean/std要保存。
评估方式	sim Transfer reward4为左gripper接触且方块不接触桌；Insertion reward4为peg碰到pin。eval用全episode最高reward==max_reward作成功，非最后稳定状态。real_env.get_reward固定0，eval real分支max_reward也0，此自动数值不能代替实机任务审核。

依这个顺序读

1. `README.md` ↗
   GitHub · tonyzhaozh/aloha · 06369f03cd

   硬件/搜集与ACT的角色分工

   L1–12

2. README.md ↗
   GitHub · tonyzhaozh/act · 742c753c0d

   两个原生sim环境与示范/方法入口

   L1–25 · L55–68

3. aloha_scripts/record_episodes.py ↗
   GitHub · tonyzhaozh/aloha · 06369f03cd

   T+1观测搜集后存T、14D双臂HDF5

   L88–101 · L127–165

4. aloha_scripts/real_env.py ↗
   GitHub · tonyzhaozh/aloha · 06369f03cd

   真实reward占位与每臂6关节+gripper

   L111–112 · L142–151

5. utils.py ↗
   GitHub · tonyzhaozh/act · 742c753c0d

   sim/real不同action时间偏移、padding与normalization

   L23–76

6. sim_env.py ↗
   GitHub · tonyzhaozh/act · 742c753c0d

   Transfer/Insertion具体接触式分阶reward

   L143–169 · L192–229

7. imitate_episodes.py ↗
   GitHub · tonyzhaozh/act · 742c753c0d

   最高reward成功聚合及real模式限制

   L179–194 · L280–313

怎么接入我们的benchmark

可重用

HDF5原结构、两个sim checker、机体/相机配置、action/padding与示范来源。

需要转换

real/sim分protocol；case固定初态与目标、joint或EE动作、数据时间偏移、temporal aggregation及原最高reward指针。新加稳定性规则另版。

仍需补齐

原实机任务rubric、全量素材 / split、终端观测与T对齐、sim/real重播与独立成功判定。

P131 · Mobile ALOHA

Mobile ALOHA: Learning Bimanual Mobile Manipulation with Low-Cost Whole-Body Teleoperation

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

Mobile ALOHA扩充双臂示范为14D手臂＋2D底盘；共训练的静态数据会补零底盘，部署还有13步对齐，不能与原ALOHA时间 / 动作表达混用。

> **版本与身份**
>
> mobile-aloha和act-plus-plus各自固定版本，README称两个sim为LEGACY。未跑VINN/ACT/diffusion或机器人。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	Mobile ALOHA真实底盘/双臂与沿用ACT的两个桌面模拟场景；不能把legacy sim当已提供全部移动任务的模拟版。
任务	全身双臂移动操作与静态数据共训练；原sim transfer/insertion是父来源重用。新物理任务应追到实机活动/场景与具体目标。
题数与数据	HDF5原action14D、base_action2D；有JPEG压缩长度。loader串为16D，没有base_action时补2维零，并5步卷积平滑base。缺少底盘标注和真的静止需要metadata区分。
评估方式	real部署将手臂chunk[:-13]与底盘chunk[13:]拼接，query频率同步调整；temporal_agg还改采样方式。最高reward评估沿用ACT，real reward与max_reward均0，不能直接作实机任务成功。实际移动任务评分仍需原文 / 人评协定。

依这个顺序读

1. README.md ↗

   GitHub · MarkFzp/mobile-aloha · 0e403249c7

   原作、ALOHA父库与ACT++官方链接

   L1–13

2. README.md ↗
   GitHub · MarkFzp/act-plus-plus · 26bab0789d

   共训练与沿用的两个legacy模拟任务

   L1–23 · L55–67

3. aloha_scripts/record_episodes.py ↗
   GitHub · MarkFzp/mobile-aloha · 0e403249c7

   控制时间、14D action＋2D base与JPEG metadata

   L90–107 · L203–229

4. utils.py ↗
   GitHub · MarkFzp/act-plus-plus · 26bab0789d

   缺底盘补零、平滑、real action时间偏移与padding

   L48–98 · L282–291

5. imitate_episodes.py ↗
   GitHub · MarkFzp/act-plus-plus · 26bab0789d

   13步base/arm对齐、temporal aggregation与real reward限制

   L294–321 · L395–421 · L442–462 · L498–509

6. aloha_scripts/real_env.py ↗
   GitHub · MarkFzp/mobile-aloha · 0e403249c7

   真实reward固定0的界面

   L170–171

怎么接入我们的benchmark

可重用

机体/动作分量、示范来源、压缩schema、base smoothing与延迟对齐。

需要转换

case保存原14+2与模型16D表示、base有效mask、时间偏移/控制频率、静态/移动父数据及实机判分来源；重用legacy tasks不增联集。

仍需补齐

原移动任务初态/goal/rubric、素材与校准、13步时序假设及temporal_agg互作用验证、对应可运行sim资产。

P132 · RT-1

RT-1: Robotics Transformer for Real-World Control at Scale

内核内容已核读 · 主来源 · 原作 · 独立页面

RT-1官方库主要公开策略网络、action tokenizer和checkpoint。700-task是其中模型的训练标签说明，并非可直接下载的700题评测清单。

> **版本与身份**
>
> 固定4569641封存快照，README明示初期组件发行；RT-1-X/OXE是相关但不同版本与数据发行，不能合并成同一份独立benchmark。

领域	居家整理与清洁、餐饮与烹饪
环境	原研究Google robot实机工作脉络；库中三个checkpoint分主模型、多机体、sim-real数据训练，checkpoint数不是环境数。
任务	语言条件robot控制方法；每个原生任务 / held-out评测case需另接原数据与实验协定，不能从README700-task标签推定可运行task registry。
题数与数据	动作TensorSpec指定顺序、shape、dtype、min/max。int32 one-hot转一token，float每维clip/normalize后离散分桶；detokenize按相同顺序还原，部分越界离散token预设0。token值本身不代表物理单位。
评估方式	此选读库提供模型与tokenizer测试，未由公开组件取得通用task成功checker、完整reset/split清单。checkpoint/API可加载不等于原作实机评测可重现。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **3** evaluation environments · 原文页 8
- **744** language instructions · 原文页 7
- **21** held-out novel instructions · 原文页 8
- **15** long-horizon instructions · 原文页 9
- **3,000** 全研究real trials（>3000） · 原文页 8

依这个顺序读

1. README.md ↗

   GitHub · google-research/robotics_transformer · 4569641b81

   方法组件、checkpoint角色与发行范围

   L1–14 · L37–54

---

2. tokenizers/action_tokenizer.py ↗

   GitHub · google-research/robotics_transformer · 4569641b81

   action_order/各field范围、one-hot/浮点tokenization及反转

   L42–89 · L103–157

怎么接入我们的benchmark

可重用

官方模型界面、action spec/order/量化与checkpoint来源。

需要转换

列为策略/训练参考，case另连来源dataset/robot/goal；保存token↔action转换的vocab_size、bounds、dtype及控制模式，不硬写统一7D。

仍需补齐

逐任务数据/资产、原实机成功rubric与split、传感/时间/动作物理语义以及匹配模型部署验证。

P133 · RT-2

RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control

实作尚未确认 · 方法 / 综述 · 原作 · 独立页面

RT-2原作项目页提供论文与实机示例；本次未确认Google/原作者发布的RT-2 GitHub实作，第三方同名实作不作原生benchmark来源。

> **版本与身份**
>
> 固定原作PDF与官方项目页查核范围；未找到官方repo不是宣称世界上不存在任何实作。搜索kyegomez/RT-2不当原作者发行。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	原作实机移动操作平台与语言/视觉条件；项目页示例没有提供可重设的完整场景与资产manifest。
任务	将web视觉语言知识转到robot action tokens的策略方法；语义泛化/推理示例可补研究分类，但不是公开固定题库。
题数与数据	原文描述动作离散token化与VLM共同训练；本次未确认原数据loader、checkpoint、完整action spec及训练/评测episode ID清单。
评估方式	原文实机试验和泛化结果属作者报告；没有确认可直接沿用的原作task checker或逐trial判分实作。示范视频不当添加自动评测数据。

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

原作方法、语义泛化设置及输入/动作共同表示的设计参考。

需要转换

列为方法参考；若补数据，case需另连可公开的dataset/robot/goal/protocol，保留原作与第三方重现的身份差异。

仍需补齐

可确认的官方实作、模型/数据版本、action解码、原生测试任务/初态/分母与实机成功审核。

P134 · OpenVLA

OpenVLA: An Open-Source Vision-Language-Action Model

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

OpenVLA是VLA方法，重用OXE/Bridge/LIBERO数据与任务。模型action解码依dataset专属q01/q99，LIBERO部署再改gripper范围与方向。

> **版本与身份**
>
> 固定c8f03f4；README后加OFT/FAST并非vanilla OpenVLA同版本。此库是Prismatic fork且由原作者页认领，fork属性不代表非官方。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	BridgeData V2真实WidowX和LIBERO模拟设置；添加模型 / 微调不新建独立benchmark环境。
任务	语言条件操作策略与既有task-suite评测。原作训练数据量和LIBERO任务数应追到父来源，不累加成新的任务联集。
题数与数据	predict_action以dataset专属unnorm_key解码action tokens，依mask使用q01/q99还原。维度由stats的q01长度决定；虽范例7D，不能忽略dataset/controller。LIBERO observation字典含state，但程序注明OpenVLA不使用proprio作输入。
评估方式	LIBERO使用固定initial_states[episode_idx]，suite预算220/280/300/520/400步，另有暖机；gripper[0,1]→[-1,+1]且OpenVLA再反号。成功取原env.done，原goals沿LIBERO。需记下成功/例外和整体分母。

依这个顺序读

1. README.md ↗

   GitHub · openvla/openvla · c8f03f48af

   原作、后续OFT/FAST、数据重用及模型界面

   L1–37 · L65–83

2. `prismatic/models/vlas/openvla.py` ↗

   GitHub · openvla/openvla · c8f03f48af

   依unnorm_key取stats、mask与action维度

   L90–131

---

3. `experiments/robot/libero/run_libero_eval.py` ↗

   GitHub · openvla/openvla · c8f03f48af

   原生init-state、各suite步数、合法输入与gripper变换

   L150–235

怎么接入我们的benchmark

可重用

模型与原dataset/suite对应、action解码统计、各task评测脚本。

需要转换

method与source task/case分离；case固定预算/初态/图像前处理，policy adapter保存unnorm_key/mask/gripper方向。原native分数与我们添加规则各有版本。

仍需补齐

完整checkpoint/数据/资产、各来源训练重叠与holdout、normalize与实机controller对照、原生运行再现。

P135 · Octo

Octo: An Open-Source Generalist Robot Policy

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

Octo提供可组合的多相机/语言/goal界面及OXE loader；其80万轨迹是训练混合，模型task字典与benchmark语义任务不是同一计数单位。

> **版本与身份**
>
> 固定241fb35；DROID另钉较早Octo85b83fc，不可互相套用。README连1.5 checkpoint，模型版本、程序版本与数据版本分开保存。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	重用多来源robot数据及既有ALOHA/WidowX运行环境；模型支持的机体/相机种类不等于独立benchmark环境。
任务	多任务goal-image或language条件policy；create_tasks组装的是一次条件输入，并不定义全库独立task。
题数与数据	task含goal/text及pad_mask_dict；缺模态填零但mask=False。observations为B×window×...，timestep_pad_mask区分padding。output为sample_shape×B×action_horizon×action_dim；以mean/std或p01/p99和mask反范式并裁到机体维度。
评估方式	例子在aloha-sim-cube-v0用history=1、exec_horizon=50，跑3次400step上限并记episode return。它是示例protocol，不能作全部Octo/所有机体的统一成功判定；底层checker仍属原环境。

依这个顺序读

1. README.md ↗

   GitHub · octo-models/octo · 241fb3514b

   原方法、训练混合与evaluation/loader入口

   L1–28 · L65–90

2. `octo/model/octo_model.py` ↗

   GitHub · octo-models/octo · 241fb3514b

   task/missing-modality mask、候选维度和反范式

   L76–134 · L174–253

---

3. `examples/03_eval_finetuned.py` ↗

   GitHub · octo-models/octo · 241fb3514b

   既有ALOHA sim wrapper、history与exec-horizon及回报方式

   L43–110

怎么接入我们的benchmark

可重用

task/obs/action模块界面、missing/timestep masks、数据源stat与normalization。

需要转换

保留OXE子来源/episode与method分离；case固定language或goal、可见相机/历史、sample_shape与exec horizon，数值表示和缺失mask不可丢。

仍需补齐

完整pretraining mixture与来源去重、模型版本/目标机体stat、各原benchmark正式protocol、素材与原生运行验证。

P136 · pi0

$π_0$: A Vision-Language-Action Flow Model for General Robot Control

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

π0的openpi界面保留机体与模型两种表示；模型预设输出50步、32维，ALOHA adapter再转成14维控制。

> **版本与身份**
>
> 固定215abfb现行openpi同时含π0/FAST/π0.5；此笔以π0界面为主，不能把后续π0.5功能与成绩归到最初π0版本。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	原π0研究机体与openpi公开ALOHA/DROID示例应分开；checkpoint场景标签与原私有训练数据不是公开环境manifest。
任务	通用VLA与任务微调，含towel等示例；训练10k+小时和各checkpoint不当新独立benchmark task/case量。
题数与数据	模型预设action_horizon50/action_dim32；ALOHA外部state/action14D，input转换关节sign/gripper angular，缺wrist图片填零且image_maskFalse；output只回前14维。DeltaActions/AbsoluteActions依mask和当前state转换。
评估方式	policy.infer返回action和infer_ms；timer只包模型sample_actions，不含input/output转换或网络。此policy界面不是task成功checker；各示例要承接原环境或实机rubric，不能以推论成功当任务完成。

依这个顺序读

1. `README.md` ↗
   GitHub · Physical-Intelligence/openpi · 215abfb217

   原π0与FAST/π0.5、base与task checkpoints分开

   L1–19 · L59–84

2. `src/openpi/models/pi0_config.py` ↗
   GitHub · Physical-Intelligence/openpi · 215abfb217

   action维度/长度及π0/π0.5旗标

   L18–55

---

3. `src/openpi/policies/aloha_policy.py` ↗
   GitHub · Physical-Intelligence/openpi · 215abfb217

   相机缺失mask、关节/夹爪转换与14D输出

   L25–102 · L181–202

---

4. `src/openpi/transforms.py` ↗
   GitHub · Physical-Intelligence/openpi · 215abfb217

   依state与mask做delta/absolute及padding

   L204–242 · L328–337

---

5. `src/openpi/policies/policy.py` ↗
   GitHub · Physical-Intelligence/openpi · 215abfb217

   input→model→output转换与infer_ms范围

   L67–106

怎么接入我们的benchmark

可重用

机体adapter、相机mask、state/action表示、checkpoint/config与normalization链。

需要转换

method与task/case分开；保留原生维度、padding、关节/夹爪映射、delta mask、history/horizon和全流程预算，模型输出容器不拿来计环境或任务量。

仍需补齐

原π0训练数据/正式测试清单、各机体scorer、完整素材/校准/模型与control spec对照、原生基线运行。

P137 · pi0.5

$π_{0.5}$: a Vision-Language-Action Model with Open-World Generalization

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

π0.5与π0共用openpi，但state离散token、prompt预算和模型旗标不同。公开LIBERO示例还固定了双相机、5步action chunk与原suite预算。

> **版本与身份**
>
> README明示此repo目前只支持π0.5 flow matching head；不能宣称公开码已覆盖原作所有head和私有数据。与P136共用repo/commit但分开记录方法配置。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	π0.5原研究开放环境泛化与公开LIBERO/DROID示例不是同一环境集合；公开示例重用父benchmark资产。
任务	升级的VLA方法和跨环境泛化；不因π0.5/model-head或checkpoint新名字重计底层LIBERO任务。
题数与数据	pi05旗标预设离散state输入，prompt max_token_len200（π0预设48）；TokenizePrompt需state与prompt。LIBERO范例传agentview/wrist RGB各旋转180度、EEF pose/gripper state及task文字，数据可见性和只RGB baseline不同。
评估方式	公开LIBERO预设50trials/task、10步暖机、每次运行action chunk前5步；suite上限220/280/300/520/400，按原env.done计成功，seed与预存初态都要固定。这些是公开示例协定，不等于原文全部open-world评测。

依这个顺序读

1. `README.md` ↗
   GitHub · Physical-Intelligence/openpi · 215abfb217

   π0.5与公开flow-head/下游checkpoints的范围

   L1–19 · L73–81

2. `src/openpi/models/pi0_config.py` ↗
   GitHub · Physical-Intelligence/openpi · 215abfb217

   pi05/discrete_state_input与48/200 prompt长度

   L18–55

---

3. `src/openpi/transforms.py` ↗
   GitHub · Physical-Intelligence/openpi · 215abfb217

   state进prompt token的真实转换

   L247–267

---

4. `examples/libero/main.py` ↗
   GitHub · Physical-Intelligence/openpi · 215abfb217

   原benchmark对象初态、相机方向、chunk与成功

   L25–40 · L57–71 · L89–156 · L189–197

怎么接入我们的benchmark

可重用

π0.5专属配置/transform、公开LIBERO runner与原native成功来源。

需要转换

method_version区分π0/0.5；case固定state可见性、prompt/token预算、双相机方向、replan/暖机/suite步数，父benchmark与数据重用关系独立保存。

仍需补齐

原文泛化场景与trial manifest、完整训练 / 测试素材、模型head/数据切分对照、公平信息预算与原生结果再现。

P138 · Diffusion Policy

Diffusion Policy: Visuomotor Policy Learning via Action Diffusion

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

Diffusion Policy跨既有benchmark比较；Push-T的mean_score是每次rollout最高部分reward的平均，且checkpoint聚合有max与低loss选样两种口径。

> **版本与身份**
>
> 固定5ba07ac；README/runner已公开说明原作与修正聚合范围。未运行原模型，未假定目前main可逐数字重现原paper。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	Push-T、robomimic、Kitchen等父环境以及实机评测分开；方法repo包含多套实验，不代表这些全是新的独立环境数据。
任务	Diffusion Policy学习动作串行；每个task仍追到父benchmark。Push-T是将T形物推到目标pose，图像/lowdim两种观测不增语义任务。
题数与数据	Push-T Zarr含img/state/action，SequenceSampler按episode mask、horizon与padding出样本。模型观测image与agent_pos，action是2D推动控制目标；训练state还含物体pose但不是全数模型可见。
评估方式	coverage=物体与目标交集/目标面积；reward=clip(coverage/.95,0,1)，done在coverage>.95。runner取每episode最高reward平均为mean_score，仍可有部分分数。multirun的max与k_min_train_loss依不同epoch选样，需分开报；runner注记原作只聚合前n_envs的历史差异。

依这个顺序读

1. README.md ↗

   GitHub · real-stanford/diffusion_policy · 5ba07ac666

   原作、三seed实验纪录与paper聚合键

   L1–20 · L28–59

2. `diffusion_policy/dataset/pusht_image_dataset.py` ↗
   GitHub · real-stanford/diffusion_policy · 5ba07ac666

   Zarr episode/sequence、模型观测与2D action

   L15–65 · L74–90

---

3. `diffusion_policy/env/pusht/pusht_env.py` ↗
   GitHub · real-stanford/diffusion_policy · 5ba07ac666

   几何coverage、reward尺度与done阈值

   L109–138 · L311–317

---

4. `diffusion_policy/env_runner/pusht_image_runner.py` ↗
   GitHub · real-stanford/diffusion_policy · 5ba07ac666

   每rollout最大reward、seed分母与已记录原作差异

   L222–251

---

5. `multirun_metrics.py` ↗
   GitHub · real-stanford/diffusion_policy · 5ba07ac666

   跨epoch max与低train/val-loss选样

   L30–97

怎么接入我们的benchmark

可重用

父task/数据source、Zarr/串行窗口、具体Push-T grader与experiment config/log。

需要转换

case保留观测可见性、episode/seed、horizon/控制与图像前处理；metric保存coverage、scaled reward、binary done和checkpoint选择规则，不把mean_score全称成功率。

仍需补齐

各其他父benchmark版本/资产与checker接线、原作vs修正seed集合、固定checkpoint/held-out再现和全套baseline。

P139 · R3M

R3M: A Universal Visual Representation for Robot Manipulation

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

R3M主库提供Ego4D表征训练，BC评测在eval分支。已分开固定两个commit；不能只看其中一份README的coming-soon文句判断code可得性。

> **版本与身份**
>
> 主库b2334e7与eval分支600d866分开。eval分支root README仍说coming soon，但evaluation目录已有程序；main README明确连此分支。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	下游重用MetaWorld fork、Franka Kitchen、Adroit/RoboHive；人类Ego4D训练视频和robot环境是不同数据层。
任务	学习通用视觉表示，再用少量示范BC；表征模型是方法，并未新定义所有下游操作task。
题数与数据	Ego4D预处理为224×224编号JPG＋manifest.csv（clip路径、长度、语言配对）。BC读multiview demo pickle并取前num_demos；encoder接收0–255图像，wrapper选择是否拼接proprio，需保留信息预算。
评估方式	Adroit/Kitchen调用原env.evaluate_success；MetaWorld fallback取每trajectory最后env_infos.success平均×100；每次eval seed含epoch偏移，另追踪max_success。最后步成功、跨epoch最佳、原环境成功函数都不能混为单一通用指针。

依这个顺序读

1. `README.md` ↗

   GitHub · facebookresearch/r3m · b2334e7268

   原作、数据格式与明确eval分支入口

   L1–38

2. `r3m/utils/data_loaders.py` ↗
   GitHub · facebookresearch/r3m · b2334e7268

   预先抽frame的Ego4D与manifest读取

   L30–61

---

3. `evaluation/README.md` ↗
   GitHub · facebookresearch/r3m · 600d866675

   BC评测来源与MetaWorld/RoboHive指定版本

   L1–25

---

4. `evaluation/r3meval/core/train_loop.py` ↗
   GitHub · facebookresearch/r3m · 600d866675

   demo截取、env-specific成功与跨epochmax

   L97–115 · L141–180

---

5. `evaluation/r3meval/utils/obs_wrappers.py` ↗
   GitHub · facebookresearch/r3m · 600d866675

   图像量程与可选proprio拼接

   L120–159

---

6. `r3m/models/models_r3m.py` ↗
   GitHub · facebookresearch/r3m · 600d866675

   表征输入0–255、相似度与learned reward界面

   L78–107

怎么接入我们的benchmark

可重用

Ego4D父来源、表示界面、BC demo/相机/机体数据与eval分支。

需要转换

method与task/case分离；case固定相机/proprio、demo数、encoder输入量程、seed与checkpoint规则；原benchmark versions另列。

仍需补齐

Ego4D与downstream素材、MetaWorld fork/RoboHive v0.0.5依赖闭合、固定eval initial states和完整重现。

P140 · VIP

VIP: Towards Universal Visual Reward and Representation via Value-Implicit Pre-Training

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

VIP学习的是视觉reward/表示；embedding距离和环境任务成功是不同评估。程序的success门槛是episode累积solved次数，并非连续稳定时间。

> **版本与身份**
>
> 固定81b0520；前述sum门槛属目前公开env基底，具体task可能另override，集成每task时仍需沿具体class核对。未跑MPPI。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	Ego4D人类训练视频、实机示例和MuJoCo系下游环境；原场景与数据仍属各父来源。
任务	以goal-image/embedding引导robot任务与reward learning；fold_towel等展示是应用例子，不能由曲线距离直接认定任务语义正确。
题数与数据	自订视频依video文件夹存frames；model依图像shape resize/crop224和normalization，max>2时除255。sim=-L2(embedding1,embedding2)，此单位是特征距离而非几何公尺。
评估方式	MPPI读goal_embedding并用H/paths_per_cpu/num_cpu/kappa配置优化；env.evaluate_success预设判sum(solved)>5再按paths算百分比，未要求连续。embedding reward、原生solved与工程时间分开保存。

依这个顺序读

1. `README.md` ↗
   GitHub · facebookresearch/vip · 81b0520145

   原作、Ego4D/自订视频与reward用途

   L1–9 · L24–38 · L68–82

2. `vip/models/model_vip.py` ↗
   GitHub · facebookresearch/vip · 81b0520145

   图像预处理及负Euclidean embedding距离

   L68–91

---

3. `evaluation/trajopt/trajopt/run_mppi.py` ↗
   GitHub · facebookresearch/vip · 81b0520145

   目标embedding、MPPI采样预算与trajectory保存

   L27–67 · L94–103 · L126–134

---

4. `evaluation/mj_envs/mj_envs/envs/env_base.py` ↗
   GitHub · facebookresearch/vip · 81b0520145

   原environment success百分比及solved数门槛

   L260–282

怎么接入我们的benchmark

可重用

表示/goal数据界面、原reward数学定义、MPPI配置与环境成功引用。

需要转换

evaluator标明learned reward或ground-truth环境条件；case固定goal frame、相机、normalization、planner预算和solved门槛，避免将reward作通用正解。

仍需补齐

各task实际solved predicate、原素材/goal设置、planner与环境版本、reward与任务正确性的反例校准。

P141 · HoloAssist

HoloAssist: an Egocentric Human Interaction Dataset for Interactive AI Assistants in the Real World

内核内容已核读 · 主来源 · 原作 · 独立页面

HoloAssist提供多传感程序交互数据和多种任务；PyHoloAssist另提供投影工具。recognition、anticipation、hand forecasting各用不同观测窗口与分母。

> **版本与身份**
>
> 主release与PyHoloAssist各固定commit；后者是作者工具，不替代完整benchmark。UTF16 README行号指解码文字，外部链接定位到文件，不捏造GitHub逐行fragment。

领域	餐饮与烹饪、办公与教育、工艺与修缮、装配与生产作业、协助、交接与陪伴
环境	人类HoloLens工作session与指导者交互，RGB/depth/眼动/手/头/IMU/音频同步到RGB；session/设备/活动不是可直接运行的robot environment。
任务	细/粗动作识别与anticipation、错误与介入侦测/预测、手部forecast；原Narration/Conversation/细/粗行为是标注种类，与生活用途/robot task不同层。
题数与数据	session中*_synced数据按RGB时钟排列，原annotation有id/start/end（秒）及attributes。anticipation取[0,t_start-time_range]并筛长度，hand forecast只取correct action，用过去3秒预测起始后1.5秒；不能把全量mistake数据当hand test分母。
评估方式	分类top1/top5与precision/recall依class平均设置；hand分支ks=15/30/45是前缀frame数，不是候选数，且输出名称*_acc实际为masked 3D Euclidean距离。NUM_CLASSES<=10分支优先，配置要固定。投影工具nearest-neighbor假设时间顺序。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **20** 程序tasks · 原文页 3
- **414** coarse action classes · 原文页 5
- **2,221** sessions · 原文页 4, 7
- **463** test sessions · 原文页 7

依这个顺序读

1. README.md ↗
   GitHub · Ember-HoloAssist/holoassist-release · f53ad2b5c3

   主论文、同步模态、四种原始标注与正误行为

   L1–10 · L30–88 · L139–181

---

2. README.md ↗
   GitHub · taeinkwon/PyHoloAssist · 9d0dfe238f

   原档UTF16，已正确解码；投影用途和PSI/校准数据依赖

   utf-16 解码文字行号 · L1–17

---

3. hand_eye_project.py ↗
   GitHub · taeinkwon/PyHoloAssist · 9d0dfe238f

   逐时间前进的nearest-neighbor同步方式

   L17–34

---

4. src/data_loader/raw_loader.py ↗
   GitHub · Ember-HoloAssist/holoassist-release · f53ad2b5c3

   原事件ID、识别/预测窗口、正确动作hand子集

   L54–64 · L193–250 · L296–322

---

5. src/test_net.py ↗
   GitHub · Ember-HoloAssist/holoassist-release · f53ad2b5c3

   top-k分类、手部prefix15/30/45及masked距离

   L114–126 · L394–424 · L483–550 · L719–726

怎么接入我们的benchmark

可重用

session/事件/模态同步、label字典、各任务窗口和有效mask、投影校准。

需要转换

case固定benchmark kind、观测截止/预测horizon、原事件/participant/split；相同session多题连父来源，手部距离/分类百分比/介入标签分开。

仍需补齐

全量素材与同步校准、手部座标/单位核对、每任务split/排除清单、不同传感缺失处理和全部端点重现。

P142 · Habitat 3.0

Habitat 3.0: A Co-Habitat for Humans, Avatars and Robots

内核内容已核读 · 主来源 · 原作 · 独立页面

Habitat3.0把人类avatar和机器人交互加入同一平台；已深入核对social navigation配置与成功判定，其他协作场景仍需各自的task配置。

> **版本与身份**
>
> 本次读现有Lab0fb6f43/Sim57ee494固定快照，不能当2023原文全部实验的精确重现；HSSD Spot范例明确采kinematic模式。

领域	居家整理与清洁、协助、交接与陪伴
环境	HSSD等父资产中的Spot和human avatar，含交互/协作设置；Habitat3是平台版本，不添加整份与Habitat2不重叠的房屋数据。
任务	social navigation、人机共同场景与协作重排；本笔以social navigation深入读code，不能由平台支持列表计所有可评task。
题数与数据	YAML固定agent0 Spot/agent1 human，分别有velocity/停止/oracle等actions，局部定位、另一agent信息、humanoid detection与RGB-D/深度等配置。所列sensor与policy实际obs_keys要分别保存。
评估方式	SocialNavSeekSuccess在安全距离区间且朝向条件成立时累加following_step，未在离开区间时归零；达门槛后可再要求当前角度。不是连续跟随时长；use_geo_distance、min/max距离、face/look配置及机体索引均影响判定。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **59** 实验HSSD scenes · 原文页 7, 26
- **2** social task families · 原文页 6
- **150** 基底test episodes · 10scene×15 · 原文页 26

依这个顺序读

1. README.md ↗
   GitHub · facebookresearch/habitat-lab · 0fb6f43ffe

   三代Habitat同库、HITL与multi-agent角色

   L14–78

---

2. README.md ↗
   GitHub · facebookresearch/habitat-sim · 57ee4941dc

   模拟器 / 资产角色和三代引用

   L14–27 · L47–70

---

3. habitat-lab/habitat/config/benchmark/multi_agent/hssd_spot_human_social_nav.yaml ↗
   GitHub · facebookresearch/habitat-lab · 0fb6f43ffe

   Spot+human、HSSD、actions/sensors与kinematic模式

   L1–66

---

4. habitat-lab/habitat/tasks/rearrange/social_nav/social_nav_sensors.py ↗
   GitHub · facebookresearch/habitat-lab · 0fb6f43ffe

   距离/朝向/累积跟随步数的具体成功条件

   L469–551

怎么接入我们的benchmark

可重用

agent/机体/资产配置、交互action/sensor契约、具体social success与细项measure。

需要转换

environment连HSSD父来源，case固定各agent可见信息、控制/模拟模式及人类行为来源；metric存累积步数/距离/朝向与时间单位。

仍需补齐

原Habitat3论文版本的全episode/asset组合、其他协作task predicates、真实human traces与共同protocol、原生运行验证。

P143 · PARTNR

PARTNR: A Benchmark for Planning and Reasoning in Embodied Multi-agent Tasks

内核内容已核读 · 主来源 · 原作 · 独立页面

PARTNR的题目已包含命题、依赖与过程限制。判分追踪何时完成，并用约束取消不合法的命题，不能只比对最后对象位置。

> **版本与身份**
>
> 固定ddfff19；先前已取得111652train+1000val题目metadata是不同阶段的库存，不因本次code核读再加一次。Habitat-Sim0.3.3及HSSD partnr版本需要与本paper绑定。

领域	居家整理与清洁、餐饮与烹饪、协助、交接与陪伴
环境	Habitat中的人/机器人协作与HSSD partnr资产；房屋与episode分开，val_mini/train_2k是原split子集而非新独立数据。
任务	自然语言规划/协作、具体对象目标与前后顺序/同对象等约束；Agent使用Tool/Skill和WorldGraph，因此可支持多模态工具流程的来源设计。
题数与数据	CollaborationEpisode继承scene/初态，再存instruction、evaluation_propositions、proposition_dependencies、evaluation_constraints、object_states。quantity可unroll成多命题，需保留原/展开ID；真值条件和planner可见world graph不同。
评估方式	先按依赖决定哪些proposition能评，记首次满足时间；TemporalConstraint要求前置严格更早，TerminalSatisfaction要求指定命题在最后仍成立。percent_complete是已满足且未被任一constraint取消的命题比例，空命题回0；success需比例==1。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **60** 论文house scenes · 原文页 5, 7
- **4** task characteristic types · 原文页 4, 7
- **100,000** 论文train scene-goal episodes · 原文页 7
- **1,000** 论文test episodes · 原文页 7

依这个顺序读

1. `README.md` ↗
   GitHub · facebookresearch/partnr-planner · ddfff19f4b

   原作、agent/planner/tool/skill、集中/分散与信息流

   L1–36 · L46–79

---

2. `INSTALLATION.md` ↗
   GitHub · facebookresearch/partnr-planner · ddfff19f4b

   Habitat0.3.3、HSSD partnr和原episodes依赖

   L14–26 · L32–62

---

3. `habitat_llm/agent/env/dataset.py` ↗
   GitHub · facebookresearch/partnr-planner · ddfff19f4b

   CollaborationEpisode字段与constraint类别解析

   L30–54 · L101–129

---

4. `habitat_llm/agent/env/measures.py` ↗
   GitHub · facebookresearch/partnr-planner · ddfff19f4b

   数量展开、首次满足时间、constraint与success链

   L84–154 · L182–196 · L219–259

---

5. `habitat_llm/agent/env/evaluation/evaluation_functions.py` ↗
   GitHub · facebookresearch/partnr-planner · ddfff19f4b

   时序DAG、终态持续条件与percent-complete分母

   L354–381 · L421–450 · L453–525 · L601–677

怎么接入我们的benchmark

可重用

原生episode、命题/依赖/DAG/终态规则、agent/tool信息契约与评分轨迹。

需要转换

case保存原命题及展开映射、agent权限/观测/工具/步数预算；evaluator保留首次时间和完整state sequence，不能扁平化为一组终态AND。

仍需补齐

全部scene/asset/skill版本闭合、原始split和环境去重、模态/工具预算公平性、原生与共同grader对照运行。

P144 · CAP / EgoGym

Contact-Anchored Policies: Contact Conditioning Creates Strong Robot Utility Models

内核内容已核读 · 主来源 · 原作 · 独立页面

CAP/EgoGym来源有公开policy和real2sim抓取路径；此路径的稀疏成功是提升高度，且包含重力补偿辅助，不能由此推定完整EgoGym实验全部已可重现。

> **版本与身份**
>
> 固定8ab1117；目前深入的是公开real2sim pick流程，未宣称每个CAP应用、全部人类数据与实机checker皆公开或已运行。

领域	居家整理与清洁、办公与教育
环境	MuJoCo real2sim scene.xml和可替换对象/干扰物，另有实机/人类gripper数据；对象asset、机体与scene设置应各自有ID。
任务	接触条件化policy；已核对的RUM-Pick-v0是具体抓取测试，不等于原文所有utility/EgoGym任务。
题数与数据	loader按同一trajectory slice取RGB、可选depth及action；sim observation含RGB和object_2d/3d_position。评测可明确使用这些位置作conditioning，属信息预算差异；2D投影参数480×360与obs声明256需核对。
评估方式	default sparse以对象升高>carry_threshold(.02)给1，terminated=bool(reward)。dense模式reward一般非零，不能沿用此termination当成功。step含600次physics控制、首次grasp另gravcomp=1和2000步，应保留辅助/成本设置；总成功按指定episode数聚合。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **424** 数据收集environments · 原文页 4
- **3** utility task families · 原文页 2, 7, 8
- **20,365** demonstrations · 原文页 4
- **250** real Pick trials · 原文页 8

依这个顺序读

1. README.md ↗

   GitHub · jeffacce/cap-policy · 8ab11176ec

   精确论文与发布/硬件指南

   L1–20

---

2. imitation-in-homes/dataloaders/decord_dataset.py ↗

   GitHub · jeffacce/cap-policy · 8ab11176ec

   video/action/depth共享切片索引和数据格式

   L237–251 · L285–292 · L326–351

---

3. imitation-in-homes/real2sim/tasks/pick.py ↗

   GitHub · jeffacce/cap-policy · 8ab11176ec

   原生action、目标观测、carry threshold与辅助physics

   L22–61 · L99–189

---

4. imitation-in-homes/real2sim/evaluate.py ↗

   GitHub · jeffacce/cap-policy · 8ab11176ec

   object/seed调度、2D/3D/无条件与分母

   L16–51 · L140–188 · L190–213

怎么接入我们的benchmark

可重用

原对象/场景配置、数据切片、目标条件与稀疏lift checker。

需要转换

case区分2D/3D/无条件与合法观测，保存位置单位/分辨率、7D增量/Euler与gripper阈值、physics substeps及重力辅助。

仍需补齐

完整EgoGym原生manifest/接触标注、所有utility task规则、素材/模型与校准、dense/sparse判分分离及原文对照。

P145 · NIABench

Assistance Without Interruption: A Benchmark and LLM-based Framework for Non-Intrusive Human-Robot Assistance

内核内容已核读 · 主来源 · 原作 · 独立页面

NIABench有候选动作词库、何时/做什么的ranker与AI2-THOR示例，但词库不等于评测题。所读simulation示例是固定人机阶段，尚需完整benchmark闭环。

> **版本与身份**
>
> 固定45065e5；README保留旧renytek13 clone路径，当前官方组织库与精确题名一致。未运行模拟或模型。

领域	居家整理与清洁、餐饮与烹饪、办公与教育、协助、交接与陪伴
环境	AI2-THOR多agent场景；公开7个simulation脚本是示例，没有据此推算完整benchmark环境数。
任务	在不打断人类多步活动的前提下选协助时刻及robot action；candidate primitive、human step、完整episode是不同层级。
题数与数据	InterventionDataset期待human_task_seq、robot_vocab与oracle_labels(best_robot_action/human_step_idx)，每个oracle label成一训练example；缺失action会落到index0/unknown no_op，导入应另外检查。公开robot_instructions为类别词库，训练episode/权重另待取得。
评估方式	reason.py对B×S×C logits joint argmax选step/action；simulation示例固定human→robot→human，不直接调用ranker结果。utils把total_step_count印为Human、人类实做数印Human Saved，需回读真实分子/分母；视频每frame重复两次也不能当实际时长。完整非干扰/省力metric仍需闭合。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **4** room categories · 原文页 3
- **7** held-out代表tasks/episodes · 原文页 3, 5
- **2,000** scripted corpus episodes · 原文页 3

依这个顺序读

1. `readme.md` ↗

   GitHub · Cognition2Action-Lab/NIABench · 45065e59df

   原作、model/模拟入口与AI2-THOR来源

   L1–11 · L59–86

---

2. `datasets/robot_instructions.json` ↗

   GitHub · Cognition2Action-Lab/NIABench · 45065e59df

   候选primitive动作片段，不是完整case

   L1–80

---

3. `model.py` ↗

   GitHub · Cognition2Action-Lab/NIABench · 45065e59df

   human_task_seq/robot_vocab/oracle_labels转训练example

   L114–158

---

4. `reason.py` ↗

   GitHub · Cognition2Action-Lab/NIABench · 45065e59df

   step×candidate joint argmax与未知词/预设路径

   L46–164

---

5. `simulation/cut_tomato.py` ↗

   GitHub · Cognition2Action-Lab/NIABench · 45065e59df

   FloorPlan28两agent固定示例流程

   L1–47 · L103–115

---

6. `simulation/utils.py` ↗

   GitHub · Cognition2Action-Lab/NIABench · 45065e59df

   原生步数计数、视频重复frame与输出标签

   L1–43 · L190–214

怎么接入我们的benchmark

可重用

人类计划/候选动作/oracle schema、joint决策界面、示例scene与步数纪录。

需要转换

case固定人类主计划、合法协助时机与候选集合；原primitive词库映射task而非当题库；evaluator另明定干扰、助益、任务完成与计算分母。

仍需补齐

完整benchmark episodes/split/权重、ranker到simulation接线、真正省力/非干扰scorer、原始评估结果与实机协定。

P146 · DexH2R

DexH2R: A Benchmark for Dynamic Dexterous Grasping in Human-to-Robot Handover

内核内容已核读 · 主来源 · 原作 · 独立页面

DexH2R提供人到机器人的动态交接数据与抓取/接近策略。所读DP评测将进入最终抓取插值记为成功，不能直接解读为真实对象已稳定交接。

> **版本与身份**
>
> 固定43c5e5c；README仍用wang-youzhuo旧owner和空DiffusionPolicy链接，所读为4DVLab当前固定版。只核读列出的DP内核片段，未宣称CVAE/MotionNet全部核读。

领域	协助、交接与陪伴
环境	真实多视角人类交接，Kinect/RealSense/ZCam合计18视角；人类MANO与Shadow Hand qpos、对象mesh/point cloud及逐时刻对象pose。相机数不当作环境数。
任务	动态灵巧抓取、人到机器人的接近与交接；subject/object/sequence形成数据阶层，grasp pose preparation和approaching motion是方法/子流程。
题数与数据	原数据按subject zip；sequence含calibration、mano、obj_pose、qpos和real_obj_pcd。depth原始int16需按文件转uint16；DP loader又将image/depth除255，需区分原始物理深度与模型输入。Zarr包含agent_pos/action/final_grasp/traj_index等；先建随机val_mask后被索引区间覆写，应保存实际mask_start/end。
评估方式	compute_pose_distance最后只回传平移距离×100(cm)，算出的旋转差未加入。接近门槛、非零对象变化与最少frame触发ls_interpolate，dp_success_rate取此旗标。安全率扣除GT穿透基线后判断是否零穿透；名为max_pener_depth的量在累加后除总frame，不能直接称最大深度。这是静态程序判读，未跑策略。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **1** dynamic handover family · 原文页 3, 6
- **56** objects · 原文页 3
- **4,282** handover trials · 原文页 3
- **803** test trajectories · 原文页 7

- **79,911** successful grasp poses · 原文页 3, 7

依这个顺序读

1. `README.md` ↗
   GitHub · 4DVLab/DexH2R · 43c5e5c948

   论文身分、18视角、subject/object/sequence及相机标定

   L1–85

---

2. `DiffusionPolicy/DP/diffusion_policy/dataset/eval_dp_dataset.py` ↗
   GitHub · 4DVLab/DexH2R · 43c5e5c948

   Zarr字段、明确episode切片与RGB/depth预处理

   L14–58 · L86–121

---

3. `DiffusionPolicy/DP/diffusion_policy/workspace/eval_dp_baseline_workspace.py` ↗
   GitHub · 4DVLab/DexH2R · 43c5e5c948

   平移距离、插值触发、穿透修正与输出metrics

   L123–129 · L349–377 · L401–423 · L575–607

怎么接入我们的benchmark

可重用

多相机标定、原生split、对象与手姿态、DP输入及指针公式。

需要转换

environment绑定拍摄/标定与robot；task描述交接条件；case保留subject/object/sequence与完整初态；将接近、抓取稳定、交接完成分别定义evaluator。

仍需补齐

数据/mesh资产取得、depth尺度验证、穿透函数及最末trajectory汇总完整查核、实际稳定抓取/交接checker与重现。

P147 · HRIBench

HRIBench: Benchmarking Interaction-Centric Human-Robot Collaboration

实作尚未确认 · 主来源 · 原作 · 独立页面

此篇2026 HRIBench研究交互型人机协作，与2025年的同名感知benchmark不同；目前核对的原文与搜索未确认其官方程式库。

> **版本与身份**
>
> 核对2607.13056v1及cached exact-title/HRIBench搜索；命中interaction-lab/HRIBench对应另一篇2025感知工作，未作此篇实作。no_confirmed_code_repository是本次有界查核结果。
>
> P147是Interaction-Centric Human-Robot Collaboration；P168是2025 robot perception，两者保留不同source ID。

领域	协助、交接与陪伴
环境	论文设计动态人类、对象与robot共处的模拟交互场景；可变layout/人类动作/时序/视角，尚无取得的scene asset或instance manifest。
任务	论文p4分Instructor、Collaborator、Intruder三角色，13个task，每task超过50trajectory variants，合计超过650episode；数量属论文声明。
题数与数据	论文scenario script将每个act写为(role,goal,temporal/causal constraints,human-motion distribution,reward/success)。生成经脚本、场景、motion synthesis与simulation filtering；尚未取得串行/标注与可解析schema。
评估方式	论文p5列Effectiveness(CSR/CT/IR)、Coordination(TSync/Rsp/OC)、Safety/robustness(CFR/HCS/CIR/DSR)；未取得对应实作，因此只作原作协定记录，不宣称已跑或可直接集成。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **13** role-conditioned tasks · 原文页 4
- **786** 验证trajectory pool · 原文页 6
- **650** adaptation trajectories · 13×50 · 原文页 6
- **130** 主held-out eval trajectories · 13×10 · 原文页 6

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

角色/交互脚本分解、13任务与650+episode的原作规模及多维评估构想。

需要转换

task保存人类角色/目标/允许介入，case固定motion/timing seed；每个指针指向其原文公式和未来scorer；不可合并P168同名HRIBench。

仍需补齐

官方repo/数据入口、13task清单与case manifest、成功/安全/恢复checker、生成资产与运行重现。

P148 · Assistax

Assistax: A Multi-Agent Hardware-Accelerated Reinforcement Learning Benchmark for Assistive Robotics

内核内容已核读 · 主来源 · 原作 · 独立页面

Assistax有明确的JAX/Brax/MJX环境、双agent观测/动作与奖励界面；feeding原始done固定0，累积回报不能当成喂食完成率。

> **版本与身份**
>
> 固定a7d94f4；目前registry多于README顶部5张照护示意图，应以注册清单标明当前版本。未运行JAX、训练或临床评估。

领域	个人照护、协助、交接与陪伴
环境	目前registry有scratchitch、bedbathing、armmanipulation、pushcoop、handover、feeding、teethbrushing共7个环境类别；这是程序注册名称数，非房间/layout数。
任务	生活照护与协作控制；不同task指定human/robot或robot1/robot2。disability、preference及sparse reward是可选协定设置，不自行增加语义任务。
题数与数据	功能式reset/step使用JAX key和state，按agent分obs/action/reward/done。feeding机器人7 actuator、人类头部2 actuator；观测含pose、force与joint angle，属state-based而非预设RGB视觉题。episode_length预设1000、action_repeat预设1。
评估方式	feeding混合距离、姿态、速度、口部接触力与控制成本；原始done=0，结束依外层episode wrapper。MASAC回报mask在首次done后截断；__all__在heterogeneous模式取agent reward平均。用户偏好/身体受限设置改变score，必须随case记录。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **5** assistive tasks · 原文页 5
- **630** 每task partner policies · 原文页 7
- **625** 每task unseen partners（非episodes） · 原文页 9
- **64** MARL每次评测episodes · 原文页 8

依这个顺序读

1. README.md ↗
   GitHub · assistive-autonomy/assistax · a7d94f4e20

   官方题名、套件用途及multi-agent界面

   L1–85

---

2. assistax/envs/__init__.py ↗
   GitHub · assistive-autonomy/assistax · a7d94f4e20

   7个registry名称及episode/auto-reset/preference wrapper顺序

   L28–97

---

3. assistax/envs/base_env.py ↗
   GitHub · assistive-autonomy/assistax · a7d94f4e20

   agent actuator索引、全域状态分流与shared/heterogeneous reward

   L20–69 · L104–121 · L215–241

---

4. assistax/envs/feeding.py ↗
   GitHub · assistive-autonomy/assistax · a7d94f4e20

   feeding观测、距离/速度/力等奖励及done=0

   L175–204 · L245–310

---

5. assistax/baselines/MASAC/eval_masac.py ↗
   GitHub · assistive-autonomy/assistax · a7d94f4e20

   只累计第一次episode结束以前的未折扣回报

   L69–80

怎么接入我们的benchmark

可重用

registry、actuator/observation映射、wrapper参数、具体奖励与return聚合。

需要转换

source固定commit；environment保存task类别/MJX资产与控制设置；case保存人类policy、preference、disability、seed与时限；evaluator分原生return和另定的任务完成条件。

仍需补齐

其余6环境完整checker、资产/控制界面实测、统一测例清单、各方法在相同人类策略/偏好下的基线。

P149 · V-JEPA 2

V-JEPA 2: Self-Supervised Video Models Enable Understanding, Prediction and Planning

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

V-JEPA 2同库包含2、2-AC及较新2.1。可复用EPIC动作预测评测与DROID reader，但既有数据集和新模型结果不能另算一套独立任务库。

> **版本与身份**
>
> 固定204698b；当前README已加入2.1，本条文献仍为2506.09985的V-JEPA 2，不把2.1添加内容当作原版论文成果。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	自然视频理解/预测与DROID真实机器人轨迹；原数据的厨房、场景和相机沿用父来源，不因V-JEPA checkpoint添加环境。
任务	视频理解、下一动作anticipation、action-conditioned latent预测与图像目标规划是不同评估用途；本次程序核读重点为EK100与DROID，不据此列出完整机器人测例。
题数与数据	EK100使用start_frame/stop_frame、verb_class/noun_class；32frame、8fps及1秒时间设置需保留。实作取af=sf×ap+(1−ap)×ef−at×fps，val预设ap=0，应核定该stop-frame基准与目标协定；不足历史以首frame补。DROID从trajectory.h5加载cartesian_position/gripper_position及相机外参，降采样后算平移/相对旋转/夹爪变化量；失败样本会随机换另一样本。
评估方式	ClassMeanRecall预设top5，recall对有出现的类别平均，accuracy对样本平均，均乘100。validation对多个probe分别取accuracy/recall最大值，可能不是同一probe；不能当单一固定模型完整结果。机器人任务成功checker未在本次所读路径确认。

依这个顺序读

1. `README.md` ↗

   GitHub · facebookresearch/vjepa2 · 204698b45b

   论文身分与2/2-AC/2.1版本范围

   L1–75

2. `configs/eval/vitl/ek100.yaml` ↗
   GitHub · facebookresearch/vjepa2 · 204698b45b

   EK100 split、32frame/8fps与预测时间设置

   L1–38

3. `evals/action_anticipation_frozen/dataloader.py` ↗
   GitHub · facebookresearch/vjepa2 · 204698b45b

   实际导向EK100 reader

   L15–81

4. `evals/action_anticipation_frozen/epickitchens.py` ↗
   GitHub · facebookresearch/vjepa2 · 204698b45b

   标注frame到合法观测区间的实际公式

   L99–154

5. `evals/action_anticipation_frozen/eval.py` ↗
   GitHub · facebookresearch/vjepa2 · 204698b45b

   val时间点预设及多probe分项max聚合

   L90–101 · L230–277 · L640–710

6. `evals/action_anticipation_frozen/metrics.py` ↗
   GitHub · facebookresearch/vjepa2 · 204698b45b

   class-mean recall和sample accuracy不同分母

   L1–58

7. `app/vjepa_droid/droid.py` ↗
   GitHub · facebookresearch/vjepa2 · 204698b45b

   DROID视频/HDF5对齐、相机座标与相邻状态差分action

   L87–229

怎么接入我们的benchmark

可重用

EK100评估公式与split界面、DROID姿态/外参/视角的数据流程。

需要转换

来源关联指向EPIC/DROID；case显式保存观测截止、target frame、补帧与样本替代策略；action保存delta与camera_frame选项；evaluator保留topk、分母和probe选择规则。

仍需补齐

观测时间基准核验、完整robot planning/evaluation协定、资产/权重取得、固定case而非重抽样及原生重现。

P150 · DreamDojo

DreamDojo: A Generalist Robot World Model from Large-Scale Human Videos

内核内容已核读 · 主来源 · 原作 · 独立页面

DreamDojo具有动作条件视频生成的真实评估入口；内核输出为PSNR/SSIM/LPIPS。预训练视频时数、评估样本与机器人可运行任务需分开。

> **版本与身份**
>
> 固定02f119b；从docs/EVAL追到cosmos_predict2/action_conditioned.py，不误把套件内一般VQA metrics当作本论文主scorer。没有下载44k小时数据或权重。

领域	居家整理与清洁、办公与教育、工艺与修缮、装配与生产作业、零售与购物、交通移动与车辆维修
环境	GR-1实验室机器人视频、EgoDex与DreamDojo-HV评估素材；人类视频库是预训练来源。README宣称44k小时不表示本次已取得或等量可评测。
任务	由首影格和动作串行预测后续视频；文件In-lab清单含10个原生dataset路径，另有EgoDex/HV两组来源。路径、100个抽样与49frame是不同单位。
题数与数据	统一reader输出 video/lam_video/action/fps/num_frames/__key__/padding_mask/image_size/ai_caption；根据path字符串选MANO、一般视频或LeRobot。LeRobot schema保留state/action的start/end、rotation_type、absolute。restrict_len可以指定100，不等于底层独立episode总量；文件定义train前95%、test后5%，full全量，须落实固定抽样清单。
评估方式	生成片与GT先转[0,1]逐frame算PIQ PSNR/SSIM/LPIPS，再对样本平均；这段没有排除首个条件影格。恢复筛选查找*_psnr.json但输出为*_metrics.json，可能重算；plot脚本只接受恰501个档的文件夹。以上是程序限制，尚未运行验证，也不是robot物理成功率。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **43,827** DreamDojo-HV video hours · 原文页 5
- **44,711** three-source mixture hours · 原文页 5
- **6,015** GPT-estimated skill/task labels · 原文页 5

- **25** samples per edited-background eval set · 原文页 10

依这个顺序读

1. `README.md` ↗
   GitHub · NVIDIA/DreamDojo · 02f119b759

   官方论文、数据/模型与公开范围

   L1–56

---

2. `docs/EVAL.md` ↗
   GitHub · NVIDIA/DreamDojo · 02f119b759

   三类评估集及49frame/100sample抽样设置

   L1–47

---

3. `eval.sh` ↗
   GitHub · NVIDIA/DreamDojo · 02f119b759

   实际入口与本机路径/连续checkpoint轮询设置

   L1–16

---

4. `groot_dreams/data/schema.py` ↗
   GitHub · NVIDIA/DreamDojo · 02f119b759

   LeRobot state/action切片、absolute与rotation metadata

   L28–105

---

5. `groot_dreams/dataloader.py` ↗
   GitHub · NVIDIA/DreamDojo · 02f119b759

   数据类型dispatch、字段、抽样和restrict_len语义

   L1–168 · L193–227

---

6. `cosmos_predict2/action_conditioned.py` ↗
   GitHub · NVIDIA/DreamDojo · 02f119b759

   case选取、生成/GT比较及metric聚合

   L278–304 · L366–407

---

7. `scripts/plot_psnr.py` ↗

   GitHub · NVIDIA/DreamDojo · 02f119b759

   绘图依固定输出文件数筛选的限制

   L15–40

怎么接入我们的benchmark

可重用

评估集分组、LeRobot modality metadata、可追到metric实作的生成入口。

需要转换

以原生clip/episode ID和实际采样frame作case；保存action representation、完整GT视频及不可见未来、scorer前处理；预测视频与物理环境分列，父EgoDex重用关系明确。

仍需补齐

固定抽样及ID清单、checkpoint/套件版本、条件影格是否计分与断点恢复修正、原生跑分和物理行为有效性checker。

P151 · H2R-Bench

H2R-Bench: Benchmarking Human-to-Robot Manipulation Video Generation in World Models

文件 / 网站 · 主来源 · 原作 · 独立页面

H2R-Bench的官方GitHub目前主要是展示网站。README明列240个视频转换case与5维加权指针，但评估程序与标注尚未放在此库。

> **版本与身份**
>
> 固定6549ae1，README L73明说evaluation code与benchmark annotations尚不在库内；本次处置为website_only。

领域	衣物与洗护、通用对象与机动作业
环境	EgoDex test来源的人类第一人称操作片，转成平行夹爪或灵巧手的视频；两个target embodiment不自动等于两种实体场景。
任务	将同一人类示范转成指定robot embodiment视频；README记录6个操作家族，120source clips×2embodiments=240transfer cases；11是模型数。
题数与数据	公开库的主要内容在docs/项目网站，评估标注与可直接加载的case manifest未提供；因此240为原作声明，不记为本次已集成题量。EgoDex为父来源。
评估方式	H2RCore=100×(0.15目标状态+0.15事件完成+0.30功能接触转移+0.30机体正确+0.10视频品质)。所读README提供定义/榜单，未提供足以重现的scorer或标注，视频高分不代表真实robot完成。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **6** manipulation families · 原文页 4
- **120** source clips · 原文页 4
- **240** video-transfer cases · 原文页 4, 5

依这个顺序读

1. README.md ↗

   GitHub · Rongdingyi/H2R-Bench · 6549ae11bb

   论文作者/ID、案例组成、H2RCore公式与未公开声明

   L1–75

怎么接入我们的benchmark

可重用

来源120clip×2embodiment的case设计、5项指针权重与公开榜单作比较参考。

需要转换

先建source/task/evaluator规格记录；取得EgoDex子集ID后创建lineage与240case清单；各分项与总分一起保留。

仍需补齐

case标注、来源clip ID、生成条件、评审rubric/程序与评分一致性验证。

P152 · RoboWM-Bench

RoboWM-Bench: A Benchmark for Evaluating World Models in Robotic Manipulation

内核内容已核读 · 主来源 · 原作 · 独立页面

RoboWM-Bench把生成视频经IDM/手部轨迹抽取后放入Isaac Lab评估，能连到真实task checker；其成功定义仍须逐题保留，不能只比较视频品质。

> **版本与身份**
>
> 固定0a8b0ea；README的Code badge实际连HF权重，核读本GitHub内实作。未安装Isaac或运行任何世界模型。

领域	餐饮与烹饪、衣物与洗护、通用对象与机动作业
环境	IsaacSim5.1与库内IsaacLab_5_1、LeHome式操作场景；robot track列7个Gym名称，其中pull_and_push共享名称。human track列12个原生task目录；不能加上随附IsaacLab全部任务当RoboWM规模。
任务	robot视频经IDM解码为Franka动作；human视频经Phantom抽手轨迹再运行。pick/摆盘/丢垃圾/抽屉/按钮/推拉及human track柔性、倒水等，各有独立判分。
题数与数据	World-model输入为初始RGB和prompt；robot轨迹文件名.json实为每行一个action，pose.jsonl依episode文件名索引。parquet转档按episode尾3位排序后重编0..N，须保存映射避免pose错配。Franka为7arm+2gripper joint targets，夹爪有额外阈值与关节裁切。
评估方式	回放先30step稳定，再取轨迹中曾成功；例外回False列入attempts。pick用abs(z−ori_z)>0.05，未限制向上；摆盘成功只看XY各≤0.15；倒水预设至少1%粒子落在XY±0.02、Z±0.5的对称盒内。step_interval计数跨调用，部分成功条件不检查稳定、容器内部或释放；需保留原版并另定严格扩充。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **8** 主表human-hand task条件 · 原文页 7
- **8** 主表robot task条件 · 原文页 7
- **6** 附录sim-native task条件 · 原文页 14
- **10** 每task共享initial configurations · 原文页 6

依这个顺序读

1. `README.md` ↗

   GitHub · fffstrong/RoboWM-Bench · 0a8b0eab3e

   世界模型→动作→模拟流程、环境版本和两种track

   L1–125 · L149–218

---

2. `tools/parquet_actions_to_json.py` ↗

   GitHub · fffstrong/RoboWM-Bench · 0a8b0eab3e

   parquet action逐行输出及重新编号/pose配对

   L24–43 · L70–95

---

3. `scripts/robot/eval_franka.py` ↗

   GitHub · fffstrong/RoboWM-Bench · 0a8b0eab3e

   动作裁切、30step稳定、any-time success与分母

   L123–138 · L207–241 · L285–355 · L419–439 · L481–505

---

4. `source/lehome/lehome/tasks/franka_task/Task00_Pick/pick.py` ↗

   GitHub · fffstrong/RoboWM-Bench · 0a8b0eab3e

   joint target与pick checker实际调用

   L125–156 · L291–300

---

5. `source/lehome/lehome/tasks/franka_task/Task01_Put_on_plate/tableware.py` ↗

   GitHub · fffstrong/RoboWM-Bench · 0a8b0eab3e

   分阶段contact/lift/place

   L328–372

---

6. `source/lehome/lehome/utils/success_checker.py` ↗

   GitHub · fffstrong/RoboWM-Bench · 0a8b0eab3e

   间隔检查、绝对高度差、XY对齐和水粒子近似

   L1–26 · L63–90 · L115–141 · L197–208 · L430–467

---

7. `source/lehome/lehome/tasks/human_task/Task07_Franka_Tableware_Pour_Water/tableware.py` ↗

   GitHub · fffstrong/RoboWM-Bench · 0a8b0eab3e

   human track倒水实际调用预设checker

   L364–373

怎么接入我们的benchmark

可重用

两条video-to-action管线、原始初图/prompt、具体success与stage score。

需要转换

case固定原视频ID、解码器/轨迹/pose映射及sim资产；将视频生成、动作解码、物理回放结果分别保存；添加规则用新evaluator版本，不覆写原作score。

仍需补齐

完整初态/资产取得、原生case清单、各task checker全覆盖、时间/间隔计数核验、IDM/Phantom抽取误差与GPU运行基线。

P153 · EgoExo-Gen

EgoExo-Gen: Ego-centric Video Prediction by Watching Exo-centric Videos

实作尚未确认 · 方法 / 综述 · 原作 · 独立页面

EgoExo-Gen先预测跨视角手物mask再生成第一人称视频；原作实验是Ego-Exo4D子集及H2O转移，目前未确认其官方实作repo。

> **版本与身份**
>
> 核对2504.11732 ICLR2025原文p5–6与cached题名/EgoExo-Gen搜索。搜索的awesome lists只保留为线索，没有当作本篇官方code。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	Ego-Exo4D cooking来源涵盖60location、564小时的原生子集描述；H2O作外部分布测试，不添加物理robot环境。
任务	Exo视频及HOI mask+Ego首影格→未来Ego mask/视频；cross-view mask prediction与video generation是两个评估输出。
题数与数据	原文p6列33,448训练clip、平均1秒；validation抽1000clip，其中500标HOI mask；H2O val122clip。16frame模型输入、mask480²与视频256²；选4个exo视角中手mask比例最高者，需保留view selection。此为原文数量，未下载case。
评估方式	Mask用IoU、对齐质心后的Contour Accuracy、范式质心Location Error；视频用SSIM/PSNR/LPIPS/FVD。不同mask/视频子集及source split不可混同；缺官方scorer和明确clip ID。

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

Ego/Exo同步父来源、两阶段HOI建构、原生指针与子集设计。

需要转换

source关联Ego-Exo4D/H2O；case保存take/clip/view/narration、可见exo完整视频和ego首影格；GT mask不可直接视为所有方法合法输入。

仍需补齐

官方实作、clip ID/annotation release、mask生成版本与data leakage检查、相同前处理的评估脚本。

P154 · Hand-conditioned ego predictive model

Ego-centric Predictive Model Conditioned on Hand Trajectories

实作尚未确认 · 方法 / 综述 · 原作 · 独立页面

Ego-PM论文明确连到showlab/Ego-PM，但本次API取得回404；已记下原文的两阶段预测/评测设计，不把失效入口当作已核读程序。

> **版本与身份**
>
> 2508.19852v2 p1提供明确URL；2026-10-10T07:46:30Z API回404。404仅证明该次无法取得，不推定作者从未公开或不存在。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	Ego4D人类第一人称视频、BridgeData及RLBench下游测试；p1图另标Meta-World，需要实作/资产版本才能厘清完整场景范围。
任务	先预测hand trajectory，再以其为条件逐frame预测视觉结果；原文p5列RLBench9task。single-step和consecutive prediction是协定设置，不自动增加语义任务。
题数与数据	输入为历史视觉、语言与action history；输出hand action与future frame。未取得loader、split manifest、座标/时间尺度或BridgeData实体完成标注。
评估方式	人类数据以hand mask IoU衡量action prediction；视频用EgoVLP/CLIP/FID/SSIM/PSNR/LPIPS等；robot章节报Success Rate。没有code时不能把手mask IoU当robot success，也无法核验物理checker。

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

论文的观测→手轨迹→视觉未来结构、跨数据集评估项目。

需要转换

先登录source与proposed task/evaluator；待repo可取再创建case及native fields；保持Ego4D/Bridge/RLBench lineage。

仍需补齐

可取得的官方repo、原始case/split、轨迹格式、评估前处理及物理完成checker。

P155 · EgoExo-WM

EgoExo-WM: Unlocking Exo Video for Ego World Models

文件 / 网站 · 方法 / 综述 · 原作 · 独立页面

EgoExo-WM原作页面仍将Code标为Coming Soon；可整理其人类全身动作世界模型协定，尚无取得的官方loader/scorer。

> **版本与身份**
>
> 2605.15477v2与2026-10-10已取得的UT Austin官方页相符，Code仍Coming Soon。原文p7说未发布的是比较方法EgoControl，不误当本篇可用性证据。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	Nymeria训练数据及HOMAGE、LEMMA、Ego-Exo4D Bike/Cooking测试视频；将HowTo100M/CrossTask/100DOH的exo片转ego作训练。生成视角沿用原拍摄事件lineage。
任务	全身动作条件下的2秒未来视觉预测，另用世界模型替候选人体动作排序；这是人类motion planning评估，不是添加robot物理任务库。
题数与数据	原文固定200小时训练预算：190h Nymeria+10h转换exo；测试描述HOMAGE/LEMMA取150clip、Bike/Cooking各125clip，前两者150是各组或合计仍待manifest核定，未先加总。2秒=4Hz×8frame；不同来源motion估计器/标注需分开。
评估方式	视觉用DINOv3-L latent L2，动作一致性用wrist PCK@20；pixel与latent方法采不同wrist predictor需保留。planning每case产生4个horizon8候选，以最末latent距goal排序，再评whole-body/wrist MPJPE，5次run均值/标准差；不是取4个GT最小error当部署成功。

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

原生来源lineage、统一2秒/4Hz条件、预测与候选动作排序的分项度量。

需要转换

source记human-motion schema与frame clock；case分合法goal/obs、候选动作及未来GT；将conversion比例和take/clip重用关系保留。

仍需补齐

官方code/weights与测试clip IDs、150clip范围、wrist评估器差异、底层actor motion到robot动作的可运行转换。

P156 · Egocentric survey

Challenges and Trends in Egocentric Vision: A Survey

实作尚未确认 · 方法 / 综述 · 原作 · 独立页面

这篇Ego综述以subject/object/environment/hybrid四类整理视觉研究，适合补充文献分类；目前未确认作者提供独立程序/数据库。

> **版本与身份**
>
> 已读2503.15275v4 p2–5；原文后段的EPIC/Ego4D/HOI4D链接是被引用数据源，不当作本survey的implementation。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	文献中的环境是穿戴相机所见的生活空间、背景结构与交互上下文；综述本身不产生可运行scene。
任务	四类为主体理解(视线/姿态/动作)、对象理解(社交/人类身分/物体)、环境理解(建模/定位)、混合理解(摘要/多视角/VQA)。属研究输出分类，非四个生活用途domain。
题数与数据	原文另按datasets的基础特性、标注与适用task汇整；图3指出同视频中action/object/location有不同时间粒度。不可把subject、物体和场景的segment数相加当题数。
评估方式	综述不提供统一evaluator；各理解/预测任务需回原作保留自己的GT及度量。

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

四类taxonomy、视角动态/遮挡/多粒度挑战及dataset线索。

需要转换

研究分类保留source metadata；用途domain由实际活动推导；case限定时间窗口、传感与可见信息，来源书目和数据量分开。

仍需补齐

作者配套repo确认、被引sources逐一原作查核及实际case/metric取得。

P157 · Human-video robot learning survey

Robot Learning from Human Videos: A Survey

文件 / 网站 · 方法 / 综述 · 原作 · 独立页面

这是Human-video robot learning综述的官方阅读清单，可补分类与来源线索，没有自己的可运行benchmark或case库。

> **版本与身份**
>
> 固定6d3c7c7，对应2604.27621；README为持续更新的survey companion，本次选读所列分类/数据区段。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	分类覆盖第一/第三人称数据及真实robot研究；清单不提供自身环境资产。
任务	Information Transfer分task-oriented、observation-oriented、action-oriented；learning formulation另列WAM、VLA、ICL/VCL且明说可重叠。这些是文献分类，不是添加生活用途或任务数。
题数与数据	每篇列paper/code/project、年份、方法标记；dataset表有viewpoint、组织、原作入口。🌟 表示作者列为有code、🤖 表示有real robot实验，仍须回原作核验。
评估方式	没有自有scorer、split或benchmark leaderboard；方法性能应回各被引用benchmark。

依这个顺序读

1. `README.md` ↗
   GitHub · IRMVLab/awesome-robot-learning-from-human-videos · 6d3c7c7073

   综述身分、task/observation/action转移分类与dataset列例

   `L1–32 · L44–82 · L136–141 · L198–211 · L288–305 · L450–482`

怎么接入我们的benchmark

可重用

三类信息转移定义、视频数据表、相似工作检索线索。

需要转换

每个被引paper解析到source并与既有ID去重；保留survey分类为source metadata，对task的用途另按原作判定；星号不直接提升integration status。

仍需补齐

被引新来源的独立原文/code核读、版本和资产授权；清单本身不能生成robot case。

P158 · VLA benchmark survey

Vision-Language-Action in Robotics: A Survey of Datasets, Benchmarks, and Data Engines

文件 / 网站 · 方法 / 综述 · 原作 · 独立页面

VLA综述的GitHub清单将数据、benchmark和data engine分开，适合设计对照表；其中预留分类与空code链接不能视为来源不存在。

> **版本与身份**
>
> 固定24b5e02，当前清单有年份/venue格式不一致，正式书目以主库已核验原作为准。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	以tabletop/multi-scene描述benchmark场景范围；不提供自己的环境asset或scene ID。
任务	benchmark采桌面/多场景×短/长串行的四格分类，Multi-Scene+Simple格明列Reserved。dataset另有real/synthetic/mixed；engine有video2data/hardware/generative。
题数与数据	列出论文、网站/code与delta/absolute、EEF/DoF、image/3D/video等标记；同一来源可同时是dataset和engine。来源链结仍需原作确认，空链接不代表没有实作。
评估方式	列出binary/graded success、reset、OOD split、embodiment shift、seeds/task counts/CI的比较要素；未包含可运行统一scorer。

依这个顺序读

1. `README.md` ↗
   GitHub · ziyaow1010/vla-datasets-benchmarks · 24b5e028b7

   数据/benchmark/engine角色、场景×时序分类、比较协定

   L1–95 · L155–199 · L332–346

怎么接入我们的benchmark

可重用

角色拆分、原生action/观测标记与比较报告字段。

需要转换

清单列只增加source关联；数据与engine共用同source而非重计；将技术标记保留profile内，公开表仍用领域/环境/任务/题数/评估方式。

仍需补齐

回到各原作补case manifest、scorer、版本与原生计量；不以四格预留内容推断领域没有研究。

P159 · tinyBenchmarks

tinyBenchmarks: evaluating LLMs with fewer examples

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

tinyBenchmarks提供用少量anchor题推估原benchmark分数的IRT工具；对本计划是抽样与难度校准参考，100题不是所有robot领域适用的固定答案。

> **版本与身份**
>
> 工具固定e9a8b10，原实验库c9df154；package缺pickle时连mutable main下载，正式adapter需把数值资产另行固定hash。未运行模型/IRT或pickle。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	原研究为LLM评估题库，没有robot物理环境；MMLU、AlpacaEval等是父benchmark。
任务	评估任务是以少数已跑题估计完整benchmark/model表现。100为每个tiny dataset的anchor数，非100个新语义task；模型family外推与题目抽样需分开切分。
题数与数据	package读seen_examples、examples_weights、A/B、optimal_lambdas与scenario/subscenario positions；y_input为按anchor顺序的response矢量。原实验data包含models与各benchmark结果矩阵，以model row拆IID/non-IID。未下载或反串行化pickle。
评估方式	以sigmoid(sum(a×theta−b))拟合能力，IRT加权anchor、pIRT混合观测与未测预测、gpIRT再混合；不是补出真正运行结果。README说公开小集从5seed选test平均最佳版本，因此新robot设计应另留独立validation/test model families，不能直接保证相同误差。

依这个顺序读

1. `README.md` ↗

   GitHub · felipemaiapolo/tinyBenchmarks · e9a8b1031b

   100anchor设计、数据角色与seed选择说明

   L1–85

2. `tinyBenchmarks/__init__.py` ↗

   GitHub · felipemaiapolo/tinyBenchmarks · e9a8b1031b

   IRT sigmoid、theta拟合、scenario权重及三种估计式

   L1–105

---

3. `README.md` ↗

   GitHub · felipemaiapolo/efficbench · c9df1547a4

   原论文实验库与工具库区分

   L1–14

---

4. `run_experiment.py` ↗

   GitHub · felipemaiapolo/efficbench · c9df1547a4

   model-level IID/non-IID split及sampling/latent dimension设置

   L1–93 · L155–196

怎么接入我们的benchmark

可重用

anchor/index/权重、模型response矩阵、IRT估计流程与分布外评估概念。

需要转换

先取得本benchmark多policy×case的实测response，再按来源/场域/任务分层；calibration、anchor selection与最终model test分开，预估分数明标estimate并附误差。

仍需补齐

robot response矩阵、跨policy/embodiment外推验证、难度参数稳定性与估计CI；不能用目前metadata假造IRT难度。

P160 · Rliable

Deep Reinforcement Learning at the Edge of the Statistical Precipice

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

rliable可为已有的多run、多task结果加上分布与不确定性；它不定义robot任务，也不能让不同原生metric自动变可比。

> **版本与身份**
>
> 固定3ccd9f4；API标示archived。这是来源实作核读，未安装套件或宣称CI已计算。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	方法评估库，不添加环境；原展示使用Atari/ALE/DM Control/Procgen。robot使用时仍保留原environment/source lineage。
任务	对既有task结果作聚合、bootstrap与performance profile，不是添加task registry或case dataset。
题数与数据	输入每个algorithm的num_runs×num_tasks(×其他维度)矩阵，需固定同一task列顺序、metric尺度与missing值策略。不能把不同分布的未知/不适用填0。
评估方式	mean先按task平均再总平均；median是task均值的中位数；IQM将所有run×task分数flatten后trim25%；optimality gap=gamma−mean(min(score,gamma))。bootstrap预设只重抽run，task_bootstrap才同时抽task；概率提升按task算Mann–Whitney再平均。不同方法同case配对与共享source的相依性需另设计。

依这个顺序读

1. `README.md` ↗
   GitHub · google-research/rliable · 3ccd9f4dea

   原论文身分与run×task矩阵使用方法

   L1–38 · L62–83

2. `rliable/metrics.py` ↗

   GitHub · google-research/rliable · 3ccd9f4dea

   mean/median/IQM/optimality gap/提升概率的具体公式

   `L20–95`

---

3. `rliable/library.py` ↗

   GitHub · google-research/rliable · 3ccd9f4dea

   stratified resampling、固定task或task-bootstrap、CI与profile界面

   `L26–49 · L71–122 · L211–283 · L301–323`

怎么接入我们的benchmark

可重用

原生公式、CI与performance profiles、固定task集合/未知task母体两种推论区分。

需要转换

先对同协定同单位结果创建可比score矩阵；保存run/case/scene群组与分层权重，再报per-domain及整体CI。公式不直接混合SR、距离与LPIPS。

仍需补齐

真实policy结果矩阵、不同来源群聚重抽样策略、缺失结果规则、范式依据；所读update_indices使用全域np.random，重现时需验证RNG设置。

P161 · First-person prediction survey

Predicting the Future from First Person (Egocentric) Vision: A Survey

实作尚未确认 · 方法 / 综述 · 原作 · 独立页面

第一人称未来预测综述把问题拆为Action、Region、Trajectory三组九种challenge，并明确区分预测与已发生动作辨识。未确认独立survey实作repo。

> **版本与身份**
>
> 已读2107.13411 p5/7/14；原文p12的GitHub是个别被引方法，非综述自行发布的benchmark。论文当时「缺长期共同benchmark」不能当作2026现况。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	原文汇整20份dataset与17项属性，包括native vs lab环境、场景数、摄影者、scripted与否、audio/hand/object annotations。这些是综述时点统计，非新独立数据。
任务	Action含短/长期anticipation与future caption；Region含next active object、hotspot、gaze；Trajectory含wearer、他人/对象、手。另列recognition/segmentation为相关但非future prediction。
题数与数据	短期预测观测窗口为[action_start−segment_length−anticipation_time, action_start−anticipation_time]。原文分时数、frame、视频、segment、class、environment、subject，正好作计数格式依据。
评估方式	原文p14说明best-of-many、topk/mean recall、ADE/FDE、IoU/mAP不同度量；需固定候选K与预测horizon才可比较，seen/unseen kitchen split也分开。

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

三组九题型、严格观测截止定义、20dataset×17属性的历史比较方法。

需要转换

每个future case记observation_end、target_start、horizon、candidate_budget与parent source；不同模型引用同数据只添加result/relationship。

仍需补齐

各被引方法的版本与case清单、统一时间基准、部署型安全/任务完成评测。

P162 · Egocentric hands survey

Analysis of the hands in egocentric vision: A survey

实作尚未确认 · 方法 / 综述 · 原作 · 独立页面

Hands in egocentric vision综述使用Localization、Interpretation、Application三层，有助分清手部标注与机器人任务。未确认作者配套GitHub。

> **版本与身份**
>
> 已读1912.10867 p2/15；其历史dataset表保留论文年代，不冒称目前已完整涵盖所有手部数据。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	头戴/胸前/肩上摄影位置、RGB/depth传感、原生数据拍摄场景；相机位置不等于三种工作用途domain。
任务	Localization含segmentation/detection/tracking/left-right identification/pose；Interpretation含grasp/gesture/action-interaction/activity；Application使用这些结果作HCI/HRI等。activity可由多个action构成，不能当等粒度task相加。
题数与数据	原文表1按dataset/year/modality/device/camera location/frames/videos/duration/subjects/resolution/annotation列对照，明确区分全部frame和已标注frame；两个同名EgoGesture也需要年份/作者识别。
评估方式	各定位/姿态/辨识来源有各自label和metric；综述不是可运行的共同scorer，手部信息详细程度也不是经验证的robot task difficulty。

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

定位→解释→应用分工、传感/标注/时数/数量字段与历史dataset列表。

需要转换

依原作ID导入source，手部GT按mask/bbox/joint/gesture等profile保存；只有指定合法输入、目标及scorer的片段才升为case。

仍需补齐

所有原生数据与scorer的当前入口、重复来源去重、可转移到robot action的标定/对应。

P163 · Ego-exo collaboration survey

Bridging Perspectives: A Survey on Cross-view Collaborative Intelligence with Egocentric-Exocentric Vision

文件 / 网站 · 方法 / 综述 · 原作 · 独立页面

Ego–Exo综述配套清单可沿跨视角信息方向整理研究与数据，没有添加一套独立机器人评测。

> **版本与身份**
>
> 固定a2f15a0，README连2506.06253、标示最后更新2025-11-14；本次不声称清单含其后所有研究。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	第一人称、第三人称及同步/多视角数据；原场景仍属Charades-Ego、Assembly101、Ego-Exo4D等父来源。
任务	以Ego→Exo、Exo→Ego、Joint Learning分研究，内分生成、理解、affordance、检索、追踪、操作等；视角方向不是生活用途domain。
题数与数据	表列title/venue/year/code与dataset/paper/project，部分GitHub栏实际是组织页/网站；需解析到真正reader/evaluator库。
评估方式	综述未提供统一scorer；跨视角辨识、生成品质与robot操作成功分开比较。

依这个顺序读

1. `README.md` ↗
   GitHub · ayiyayi/Awesome-Egocentric-and-Exocentric-Vision · a2f15a07fa

   survey身分、三种跨视角方向、操作/数据例子

   `L1–65 · L81–107 · L192–238`

怎么接入我们的benchmark

可重用

跨视角转移方向、dataset与code入口作来源追踪。

需要转换

将survey→被引source存relation；同一同步拍摄事件的不同视角共用episode lineage，不能当独立场景或任务倍增。

仍需补齐

每个候选repo的官方身分/版本确认、同步与摄影标定、原生split/scorer和可用case。

P164 · The Imitator Game

The Imitator Game: Benchmarking Robot Imitative Ability Beyond Action Prediction

内核内容已核读 · 主来源 · 原作 · 独立页面

The Imitator Game提供人类视频→robot模仿的配对数据、分级场景与模拟评估。任务完成、轨迹相似及盲测偏好是三种不同证据。

> **版本与身份**
>
> 固定d6d16ec；README对应2608.22301。所读为共用DP评测链与两个具体task版本，未宣称整个ManiSkill内含任务或全部基线已验证。

领域	居家整理与清洁、餐饮与烹饪、包装、仓储与物流、零售与购物、实验室操作、医疗与手术支持
环境	ManiSkill/SAPIEN双Panda imitator scene，人类demonstrator另有视频。pinned tree中L0/L1/L2/L3各50个config，合计200个task-level设置；不能未去重就宣称200个独立语义任务。
任务	以示范模仿操作，可用video-only、language-only或两者。task透过human/robot/sim ID mapping关联，L-level与input mode保留case设置；盲测arena另有human preference协定。
题数与数据	LeRobot metadata/parquet/video对齐timestamp秒与episode；MANO姿态是同episode特征，不是另一数据集。is_right=-1表示缺侦测、数值补0需mask。评测按task随机抽human episode与video frame；原始action范例双臂8+8=16D，应固定reference IDs与normalizer。
评估方式	例子成功为两对象几何中心在各篮XY bounds及Z上界，is_robot_static另外输出但未加入success。TSS=1/(1+DTW/path_length)，直接对action矢量L2，尺度/单位会影响分数；success轨迹截到首次成功，fail截GT长度；ss<2走fail分支需核验。eval status=success代表流程完成，物理完成另看success_once/at_end。GT seed=None且batch任一truncated就重置群组，需要固定抽样/同步假设。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **6** 用途domains · 原文页 5
- **53** 按domain分量推算base tasks · 原作概述50+，表2约50 · 原文页 5
- **10** 主评测task types · 原文页 7, 8

- **11,720** real paired episodes · 原文页 5
- **10,000** sim paired episodes · 原文页 5

依这个顺序读

1. `README.md` ↗
   GitHub · imitator-game/The-Imitator-Game · d6d16ec511

   原作、场景/数据/基线与human A/B评测定位

   L1–100

---

2. `examples/baselines/lerobot_dataset/README.md` ↗
   GitHub · imitator-game/The-Imitator-Game · d6d16ec511

   LeRobot时间/episode、同row MANO与原视频关系

   L1–115

---

3. `examples/baselines/_template/eval_template_imitator.py` ↗
   GitHub · imitator-game/The-Imitator-Game · d6d16ec511

   共用eval调用与status字段语义

   L113–160

---

4. `examples/baselines/lerobot_dataset/evaluate_processor.py` ↗
   GitHub · imitator-game/The-Imitator-Game · d6d16ec511

   human↔sim task mapping及reference episode抽样

   L217–262 · L293–326

---

5. `examples/baselines/diffusion_policy/eval_dp_imitator.py` ↗
   GitHub · imitator-game/The-Imitator-Game · d6d16ec511

   分级设置、video/language输入、双臂action与batch/truncation/TSS流程

   L97–139 · L178–276 · L314–409

---

6. `examples/baselines/lerobot_dataset/trajectory_metrics.py` ↗
   GitHub · imitator-game/The-Imitator-Game · d6d16ec511

   DTW/TSS公式与随机GT trajectory

   L1–21 · L47–103 · L130–175 · L273–302

---

7. `mani_skill/envs/tasks/tabletop/dual_tasks/_008_pick_apple_banana_baskets.py` ↗
   GitHub · imitator-game/The-Imitator-Game · d6d16ec511

   具体双对象入篮checker

   L337–415

---

8. `mani_skill/envs/tasks/tabletop/dual_tasks_l3/_008_pick_apple_banana_baskets_l3.py` ↗
   GitHub · imitator-game/The-Imitator-Game · d6d16ec511

   L3对应checker与相同goal关系

   L283–346

怎么接入我们的benchmark

可重用

人类/robot/sim mapping、native level configs、LeRobot schema、完成与TSS的独立指针。

需要转换

case固定human示范及frame IDs、sim资产/初态、level/input mode、双臂action spec；reference trajectory与方法输出分隔，success/TSS/human preference分栏报告。

仍需补齐

所有task checker覆盖、完整IG10K资产取得、case固定种子、action尺度/TSS可比性、同步batch条件与盲测评审一致性。

P165 · LIBERO-Recover

LIBERO-RECOVER: Beyond Task Success Towards Failure Recovery in Robotic Manipulation Models

实作尚未确认 · 主来源 · 原作 · 独立页面

已核读同名网站与同owner的LIBERO-Recovery评估库，但目前程序的人工XY扰动协定与论文「自然运行失败」不同；不能直接当作论文完整release。

> **版本与身份**
>
> 网站c8cdf8d仍匿名且Paper/Code/Data皆Soon；code7584d1b README计划2026-10-20发布，该日期尚未到。2609.05178v3 p4明说不人工扰动，与此版做法不同，故处置identity_or_version_unresolved。
>
> 网站题名与论文相符、候选eval库同owner；未把匿名网站与当前custom-scene code的关系直接认定为完整论文版本。

领域	居家整理与清洁
环境	沿用LIBERO/MuJoCo；程序scene定义为.bddl+_sim_state.npy pair。这是任务设置/物理初态组合，非必然独立房屋。网站列2178recovery scenarios，未取得对应完整资产manifest。
任务	论文L1重试/L2调适/L3对象状态恢复/L4环境恢复；程序目前主要对custom state加±2cm自由对象XY扰动，5closed+5open起始试验。语义任务、failure scenario和10次trial不能相加。
题数与数据	原文2000+自然失败情境；网站另列3184恢复示范、625731frame、110task types，单位不同。程序frame记双相机、EEF/axis-angle/gripper状态，模型example只送image+lang；manifest存scene/trial/gripper_init/obj_deltas/success等。缺完整failure trajectory/原始goal与recover标注的链接。
评估方式	最多520step，done取原LIBERO goal conjunction；close/open分报。outer reset宣称12次重试，但内层env_wrapper.reset会吞RandomizationError并持续重试，须验证失败行为；建构/重置失败被跳过会影响分母。flat_state扰动索引还需确认time/qpos布局。没有据此重现论文四层恢复结果。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **130** 上游tasks · 原文页 4, 5
- **4** recovery levels · 原文页 3, 4
- **2,178** recovery scenarios · 原文页 5

- **3,184** recovery training trajectories · 原文页 5

依这个顺序读

1. `README.md` ↗
   GitHub · liulin815/libero-recover · c8cdf8d1b3

   旧库仅一行README

   L1–1

---

2. `index.html` ↗
   GitHub · liulin815/libero-recover · c8cdf8d1b3

   同名匿名网站、Coming Soon与原生数量单位

   L20–41 · L63–97 · L580–595

---

3. `README.md` ↗
   GitHub · liulin815/LIBERO-Recovery · 7584d1baf3

   10/20未来发布计划及当前custom scene协定

   L1–100

---

4. `examples/LIBERO/eval_files/eval_libero_custom_scene.py` ↗
   GitHub · liulin815/LIBERO-Recovery · 7584d1baf3

   扰动、重置、双gripper split、模型输入及case/结果manifest

   L79–151 · L166–204 · L212–244 · L310–371 · L386–451 · L501–543

---

5. `LIBERO/libero/libero/envs/env_wrapper.py` ↗
   GitHub · liulin815/LIBERO-Recovery · 7584d1baf3

   step转接与内层reset重试

   L87–105

---

6. `LIBERO/libero/libero/envs/bddl_base_domain.py` ↗
   GitHub · liulin815/LIBERO-Recovery · 7584d1baf3

   done实际由_check_success覆写

   L779–809

---

7. `LIBERO/libero/libero/envs/problems/libero_tabletop_manipulation.py` ↗

   GitHub · liulin815/LIBERO-Recovery · 7584d1baf3

   具体子类以goal predicate AND判成功

   L135–162

怎么接入我们的benchmark

可重用

已读custom state replay、gripper设置、扰动/输入/原生success及manifest界面。

需要转换

保留论文source、候选website与code各自版本；case要连到自然失败τ_fail/s_f及目标，人工扰动另列衍生协定；记seed/实际state hash、gripper settle、无效reset与分母。

仍需补齐

原作到code的明确完整release对应、全部场景/数据、论文四层标注与规则；修正或确认flat_state/重置/分母后再运行。

P166 · SafeVLA-Bench

SafeVLA-Bench: A Benchmark for the Success-Safety Gap in Vision-Language-Action Models

文件 / 网站 · 主来源 · 原作 · 独立页面

已确认SafeVLA-Bench的作者网站库与原论文相符；榜单提供task-aware安全评估定义，但新找到的SafeVLA-Bench-release入口取得回404，尚未读到其STL scorer。

> **版本与身份**
>
> 网站固定3178c93并直接引用2606.00773；leaderboard L160连JFan5/SafeVLA-Bench-release，但本次API404。Jatshi同名库是另一研究，未混入。

领域	居家整理与清洁、餐饮与烹饪
环境	沿用LIBERO四suite及RoboCasa-365 atomic-seen，所加的是事后trajectory instrumentation与安全规则；不自动增加独立scene或task。
任务	论文p5记58个既有task，使用7种机制template组合和对象tag选适用条款。8个安全family分scene interaction、object handling、execution三组；规则条款数不是task数。
题数与数据	作者榜单宣称24policy、27policy–benchmark entries、22,500 scored rollouts；LIBERO每row每suite10task×20episode=200，RoboCasa18family×50=900。这些是已报run数，不能直接当独立评测case量；两组RoboCasa seed互不配对。
评估方式	SR沿用父benchmark；Safety=满足所有适用条款的episode比例；SBU=成功且违规占全部episode，SBU/SR才是成功中违规比例；VSI为每episode最严重违规的范式深度。signal不可用是N/A。9月版本由per-step force重新算RoboCasa，旧action-log数字不能混报。阈值属文中模拟proxy，不是实体安全认证。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **58** host task types · 原文页 5, 6
- **8** scored safety clause families · 原文页 4, 5
- **200** LIBERO每policy-suite episodes · 原文页 6
- **50** RC每policy-task episodes · 原文页 6

依这个顺序读

1. `README.md` ↗

   GitHub · JFan5/safevla.org · 3178c93fc6

   网站用途、safevla.org与展示内容

   L1–30

---

2. `index.html` ↗

   GitHub · JFan5/safevla.org · 3178c93fc6

   精确论文ID、榜单规模、8spec与N/A语义

   L13–16 · L43–86 · L343–373

---

3. `leaderboard.html` ↗

   GitHub · JFan5/safevla.org · 3178c93fc6

   每suite rollout分母、种子群组、release入口与9月重计版本

   L128–177

怎么接入我们的benchmark

可重用

适用条款registry概念、原生success与附加规则分离、四种度量的分母及结果版本注记。

需要转换

task保留原LIBERO/RoboCasa ID，evaluator另版本化STL/threshold/tags；case保留相同input/action/budget，添加per-step raw signal evidence与N/A，而非把安全规则乘成新task数。

仍需补齐

release repo可访问、compute_stl_robustness.py实作、per-episode verdict/force logs、clauses与template明细及重现。

P167 · DexGarmentLab

DexGarmentLab: Dexterous Garment Manipulation Environment with Generalizable Policy

内核内容已核读 · 主来源 · 原作 · 独立页面

DexGarmentLab的15个衣物任务场景与2500+衣物资产可扩充柔性物覆盖；所读Fold Tops验收主要看终态点云的XY范围比例，尚不能单独证明指定折法。

> **版本与身份**
>
> 固定e4e298e；论文2505.11032v3。只核读Fold Tops实际判分链和共用reader；公开15任务不表示本次已逐场运行，未下载大资产或权重。

领域	衣物与洗护、个人照护
环境	IsaacSim4.5.0、双UR10e/灵巧手、衣物与衣架/人体/收纳等资产。README的15 task scenes、8衣物类别、2500+garments属不同计量，不能相乘作已测环境量。
任务	6种衣物自身任务(fling/fold×tops/dress/trousers)与9种衣物–环境交互(hang/wear/store)。衣物位置/形状、材质与环境资产设置是case条件。
题数与数据	Zarr原生keys为 state/action/object_point_cloud/garment_point_cloud/environment_point_cloud/points_affordance_feature；SequenceSampler有horizon/padding/episode mask。Fold Tops控制以action前30维/后30维分双手joint position，每个action运行5physics步；HALO含脚本接近/离开和分stage策略，不能只截神经网络输出当完整policy。
评估方式	Fold Tops依预测操作点定义XY boundary，终态分割点云至少88%在该范围即通过；不看Z/层拓扑/边缘对应。脚本中还有暂时gravity_scale=10再还原，需纳入protocol。随机位置/asset取time.time种子，未固定测例不能只靠run次数重现。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **15** task definitions · 原文页 5
- **14** 主simulation eval tasks · 原文页 8
- **2,500** garment models · 超过 · 原文页 5
- **50** 每task评测episodes / seed设置 · 原文页 8

- **15** real每task trials · 原文页 10

依这个顺序读

1. `README.md` ↗
   GitHub · wayrise/DexGarmentLab · e4e298e696

   原作、IsaacSim版本、15task与衣物/环境交互分组

   L1–114

---

2. `Validation_Core.md` ↗
   GitHub · wayrise/DexGarmentLab · e4e298e696

   HALO/DP3/DP不同观测界面

   L1–72

---

3. `Model_HALO/SADP/structure_aware_diffusion_policy/dataset/robot_dataset.py` ↗
   GitHub · wayrise/DexGarmentLab · e4e298e696

   Zarr state/action/点云/affordance、串行采样与normalizer

   L1–109

---

4. `Env_Validation/Fold_Tops_HALO.py` ↗
   GitHub · wayrise/DexGarmentLab · e4e298e696

   双手各30joint目标、物理子步/重力、最后验收及时间seed

   L207–261 · L384–443

---

5. `Env_Config/Utils_Project/Position_Judge.py` ↗
   GitHub · wayrise/DexGarmentLab · e4e298e696

   RGB yellow比例与点云XY box比例checker，实际选用后者

   L1–75

怎么接入我们的benchmark

可重用

15任务原生列表、Zarr特征、分stage控制、现有点云/图像判分规则。

需要转换

environment保存衣物mesh/材料/接触与robot关节规格；case明定asset/seed/实际初态及全部scripted stage；evaluator保留原88%区域标准，另版本化指定折法/拓扑/稳定检查。

仍需补齐

资产和测试衣物split取得、固定seed/metadata、全部task checker、joint单位/物理时间、真实折叠正确性标注与原生基线。

P168 · HRIBench (perception, 2025)

HRIBench: Benchmarking Vision-Language Models for Real-Time Human Perception in Human-Robot Interaction

内核内容已核读 · 主来源 · 原作 · 独立页面

2025 HRIBench是人类感知VQA，不是2026同名协作模拟。官方README明列1000题但只公开4/5类；GitHub存模型输出logs，未包含完整图像题库与grader。

> **版本与身份**
>
> 固定b993469，README指2506.20566及Shi等2025作者；与P147的2607.13056保持不同source，不能靠HRIBench名称合并。
>
> P168: Real-Time Human Perception in HRI (ISER2025)；P147: Interaction-Centric Human-Robot Collaboration (2026)。

领域	社交与沟通、协助、交接与陪伴
环境	真实HRI图像与其他公开dataset场景；五类是感知评估领域，不是五个独立物理场景。
任务	Non_Verbal、Ins_Follow、HROI、Social_Nav、Id_Rec各200VQA，共1000为原作声明；README只宣布前4类可下载，Id_Rec仍未公开，因此宣布可取范围为800题，本次未下载图像题库。
题数与数据	每case应有driod.txt(prompt/options)、correct_answer.json、wrong_answers.json与processed_frame.png。GitHub结果按demo_ID保存choices/correct_answer/response/time_taken，另有summary；所读HROI结果档201顶层key中200是demo、1是summary，不能算201题。demo_0的choice标签有重复，导入须验证选项顺序/唯一性。
评估方式	此结果summary预存17/200=0.085 accuracy与0.478秒average time，仅作已公布log例子，非本次跑分；没有从response解析到correct的grader实作。各模型latency需要硬件/API/计时范围一致才可比。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **5** 感知domains · 原文页 1
- **1,000** VQA · 原文页 1, 2

- **800** overall表格对应四domain题范围 · 4×200，identification排除 · 原文页 5

依这个顺序读

1. README.md ↗
   GitHub · interaction-lab/HRIBench · b993469d3c

   精确2506.20566身分、5×200题及公开限制

   L1–40

---

2. HROI/answers_of_InternVL2_5-1B.json ↗
   GitHub · interaction-lab/HRIBench · b993469d3c

   原始结果中3个demo及summary；未逐条人工核读整份结果

   JSON /demo_0 · JSON /demo_1 · JSON /demo_199 · JSON /summary

---

怎么接入我们的benchmark

可重用

5种题型、原生数据目录约定、带time_taken的模型输出schema。

需要转换

case_id由source+native category+demo_ID组成；原图像/合法person-reference/options与GT分开；result的200demo和模型trial不倍增任务；保留800公开/1000声明/本次取得图像0三种口径。

仍需补齐

Google Drive题库实际取得、缺第五类、README重复图片路径说明厘清、选项ID验证、response grader与latency协定。

P169 · X2Real

X2Real: an eXtensive simulation benchmark for real-world generalist policies

实作尚未确认 · 主来源 · 原作 · 独立页面

X2Real论文提出44个阶层式长串行task与Policy Space统一界面，但本次官方GitHub及项目页均回404；只能先登录原文规模与界面设计。

> **版本与身份**
>
> 2609.27449v1 p1明列X-Square-Robot/x2real；2026-10-10T07:46:54Z GitHub API回404，原作项目页亦404。保留明确入口与取得纪录，未以第三方名称相似库替代。

领域	居家整理与清洁、通用对象与机动作业
环境	论文以Isaac Lab-Arena/Mana设计单臂、双臂、移动操作及可换gripper；多轴appearance/task setting/embodiment随机化，不以其笛卡儿积宣称已验证环境数。
任务	原文摘要44个阶层长串行task、10项能力维度；后文分reasoning4项、manipulation5项与挑战任务，能力taxonomy不是生活用途domain。每task以subtask DAG描述。
题数与数据	论文近300h标注模拟轨迹；桌面task每个300条demo、移动每个1000条，3个challenge超20,000条。这些是training/demo量，不能当评测题数；未取得case/split/asset manifest。
评估方式	原文DAG节点有rule checker、episode有进度与success；Policy Space处理观测映射、action适配、历史与episode lifecycle。需要实作才能核验same task/observation/budget与ID/OOD分离；未重现其0.84 sim-real相关性。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **44** simulation tasks · 原文页 3
- **10** 能力维度 · 原文页 3
- **3** mobile tasks · 原文页 29
- **40** mobile每task每condition episodes · 原文页 29

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

44task的原作比较规模、DAG子任务、与policy-specific前处理解耦的界面概念。

需要转换

source固定2609.27449版本，先整理task/spec并保留planned/imported区别；case日后绑定相同DAG、asset/seed、randomization和evaluator；demo与trial独立计数。

仍需补齐

可取得的code与项目页、44task对应原始规格、全部case及asset、Policy Space adapter与实际评测重现。

P170 · MotionForge

MotionForge: A Data Generation Pipeline and Large-Scale Benchmark for Long-Horizon Manipulation of Dynamic Objects with Domain Shifts

实作尚未确认 · 主来源 · 原作 · 独立页面

MotionForge原文定义动态操作与延迟感知评测；已排除同名Blender动画工具仓库，精确paper-ID与robot关键字搜索仍未确认本篇官方code。

> **版本与身份**
>
> 原文2609.25689v1；同名mayalhc/motionforge是Blender动画工具，与作者/任务不同。2026-10-11两个精确GitHub查找均无结果；只宣称本次未确认，不宣称程序永久不存在。

领域	装配与生产作业、包装、仓储与物流
环境	原文分Factory Conveyor、Circular Motion、Home Tabletop、Embodied Interaction四个scene family，各10task；families代表场景/动态配置，非四个完全独立生活用途。
任务	40个semantic task families中17个long-horizon，11种primary motion pattern；只改速度的variants在原文计数协定合并，这点可直接用来对齐我们的task granularity。
题数与数据	生成约20kepisodes，训练每task只取50successful demo、共2000；每scene family训练一个model，所以每policy方法有4个family-specific模型。80k训练steps×batch32不是独立数据题量。
评估方式	每task每方法50个固定seed，对40task macro-average；R1环境120Hz独立于推论前进，action execution horizon预设16，latency按方法原生pipeline量测。ID/OOD只改指定因素，测例需要保存连续时间/延迟规则，不可换同步step后沿用原作分数。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **4** scene families · 原文页 3
- **40** semantic task families · 原文页 3
- **17** long-horizon families · 原文页 4
- **50** 每task每condition eval episodes · 原文页 6

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

原文40task/17long/11motion分类、速度variant去重口径与R1时间协定。

需要转换

task以语义family去重，case另含动态因果/速度/对象/外观与seed；result保留latency、policy-family training scope与真实时间控制规则。

仍需补齐

官方repo、task与motion生成器、固定case/scene/asset manifest、R1 scheduler/scorer及来源实测。

P171 · Bench2Dex

Bench2Dex: Benchmarking Visuo-Tactile Bimanual Dexterous Manipulation Across Dexterous Hands

内核内容已核读 · 主来源 · 原作 · 独立页面

Bench2Dex有可追溯的YAML任务、视触觉HDF5 reader与具体success engine。26任务、12机体、8模态和1300示范各有不同单位；双手/多模态不直接倍增任务。

> **版本与身份**
>
> 固定fd90dcc；success语义依metric_schema_version与evaluation_protocol而变，不能拿不同版本同名success_rate直接合并。只核读所列实际片段，未跑Isaac或policy。

领域	装配与生产作业、通用对象与机动作业
环境	IsaacSim5.1/IsaacLab2.3.2；26个task YAML包含桌面、资产路径、物理属性、布局与generalization flags，跨12种robot embodiment。相同场景的双手与多传感不算独立环境。
任务	原生26task从放置/分类、清洁、工具使用、拼图到盛汤/琴键等；YAML stages可有depends_on。task_manifest先选scenes_final再scenes；其中task.md只有3栏但parser要求6栏，可能退回Unknown，需我们的导入器自行正确映射原表。
题数与数据	HDF5 robot/qpos、action/commanded、cameras/*/rgb、robot/tactile/tacmap/*与site_names。同一start_ts取所有模态；缺commanded会改用qpos作action，必须记来源。tactile为uint8图像且顺序跨episode严格一致；activeDOF/padding/NaN mask保存，尾chunk mask长度仍需测试。1300demo为原作声明，未取得payload。
评估方式	core-v1.8：reach_and_stop以terminal条件持续dwell(预设0.5秒)为成功，fixed_horizon改看budget末态；instant/at_end/stable分开。Soup Serving以汤杓进锅→到碗上方两次，再归杓/摆碗/碗直立判分，没有直接量测流体体积。安全成功另排drop/high-speed；joint limits预设diagnostic。空结果回0在本库应标N/A；robust ratio需baseline和perturbed两组才定义。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **26** task-embodiment settings · 原文页 8
- **12** dexterous-hand morphologies · 原文页 2, 5
- **20,800** 跨4policy的evaluation rollouts · 原文页 8

- **50** 每policy/task/channel rollouts · 原文页 8

依这个顺序读

1. `README.md` ↗
   GitHub · Bench2Dex/Bench2Dex · fd90dcc625

   原作ID、规模声明与Isaac版本

   L1–88

---

2. `scenes/task.md` ↗
   GitHub · Bench2Dex/Bench2Dex · fd90dcc625

   26个release task ID与YAML入口

   L1–39

---

3. `collector/task_manifest.py` ↗
   GitHub · Bench2Dex/Bench2Dex · fd90dcc625

   scene优先序、metadata parser与缺值fallback

   L12–105

---

4. `scenes/76_soup_serving.yaml` ↗
   GitHub · Bench2Dex/Bench2Dex · fd90dcc625

   实例资产/初态/custom checker/stage DAG/dwell与safety设置

   L1–137

---

5. `success/engine.py` ↗
   GitHub · Bench2Dex/Bench2Dex · fd90dcc625

   all/any/sequence/hold_duration/custom语义

   L1–86

---

6. `success/custom/task_76_soup_serving.py` ↗
   GitHub · Bench2Dex/Bench2Dex · fd90dcc625

   两次舀取状态机与实际末态条件

   L1–44 · L54–152

---

7. `policy/ACT-Tactile/act_tactile_dataset.py` ↗

   GitHub · Bench2Dex/Bench2Dex · fd90dcc625

   tactile site顺序、同步sampling、command/qpos fallback与padding

   L20–36 · L47–169

---

8. `benchmark/metrics.py` ↗

   GitHub · Bench2Dex/Bench2Dex · fd90dcc625

   success protocol、空结果/有效结果分母与OOD比例

   L1–70 · L413–491 · L498–515 · L549–575 · L817–874

怎么接入我们的benchmark

可重用

26task目录、YAML stage/terminal规格、视触觉schema、成功/安全/鲁棒聚合公式。

需要转换

task映射原ID及领域用途，保留scene版本；case固定control/physics/query时计与embodiment/activeDOF；evaluator原样报stable/instant/safety，添加实际舀取量规则另版本化。

仍需补齐

完整assets/HDF5取得、12机体适配、所有task checker/时钟实测、manifest字段修复、NaN/padding与空结果处理、传感单位/校准。

P172 · LabUtopia

LabUtopia: High-Fidelity Simulation and Hierarchical Benchmark for Scientific Embodied Agents

内核内容已核读 · 主来源 · 原作 · 独立页面

LabUtopia把场景/观测放在task、完成检查放在controller；只读task类别会漏掉真正判分。此版同时存在不同HDF5字段格式，导入时需要分开对接。

> **版本与身份**
>
> 固定8df7278，README已指IsaacSim5.1；论文为2505.22634，不能把现在的软件依赖版本直接当成2025原论文设置。未运行Isaac或远程policy。

领域	实验室操作
环境	实验室USD场景和Franka/移动机器人等配置；所读level1_pick指定lab_001、3相机与对象初态range。多个YAML/相机不直接当独立物理环境。
任务	以基础、组合、泛化和长串行四层组织实验室操作；配置task_type/controller_type决定行为，scene/对象组合构成具体case。此轮核读pick，不将每个config别名视为新语义task。
题数与数据	NavDataset使用joint_positions/robot_position/cam_01_rgb/cam_02_rgb/hand_cam_rgb，action取joint_positions串行；其validation只copy同一数据与sequence表，非独立holdout。新converter期待agent_pose/actions与相机字段，缺shape预设7、缺FPS预设60；source<=target FPS时保留所有frame，须确认输出timebase。
评估方式	pick controller要求物体Z比初始高0.1且连续60次check；reset时计success_count。task.done只是reset_needed，base timeout还调on_task_complete(True)，不能用task.done替代controller成功。50个inference episodes只是README范例；正式case/budget须按发布协定固定。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **100** 基础lab scene assets · 约数 · 原文页 5
- **30** 摘要声称distinct tasks · 与§4 >50不一致，未定为全库唯一值 · 原文页 1, 3
- **5** benchmark levels · 原文页 7, 8

依这个顺序读

1. `README.md` ↗

   GitHub · Rui-li023/LabUtopia · 8df7278426

   当前Isaac版本、task/controller分工与60Hz数据约定

   L1–95 · L274–313 · L328–373

---

2. `config/level1_pick.yaml` ↗

   GitHub · Rui-li023/LabUtopia · 8df7278426

   具体场景、对象range、3相机、robot和budget

   L1–69

---

3. `tasks/base_task.py` ↗

   GitHub · Rui-li023/LabUtopia · 8df7278426

   观测state与reset/timeout信号

   L286–356

---

4. `controllers/base_controller.py` ↗

   GitHub · Rui-li023/LabUtopia · 8df7278426

   60次持续成功及episode计数

   L19–41 · L122–150

---

5. `controllers/pick_controller.py` ↗

   GitHub · Rui-li023/LabUtopia · 8df7278426

   pick抬高0.1m的具体连续判定

   L20–25 · L50–78 · L129–154

---

6. `policy/dataset/nav_dataset.py` ↗

   GitHub · Rui-li023/LabUtopia · 8df7278426

   HDF5旧schema、state/action窗口及validation副本

   L1–41 · L81–121

---

7. `scripts/convert_labsim_data_to_lerobot.py` ↗

   GitHub · Rui-li023/LabUtopia · 8df7278426

   新schema、FPS侦测/降采样及LeRobot字段转换

   L55–84 · L109–162 · L183–244

怎么接入我们的benchmark

可重用

YAML场景/传感/初态、task/controller分工、具体pick evaluator与HDF5→LeRobot路径。

需要转换

先辨识HDF5 schema版本和action是否command/state；创建episode级split；case记physics/control/check频率、连续成功时间与timeout独立结果；原文规模和当前config采样分开。

仍需补齐

全部task完成checker、原文到当前版本对照、独立validation、旧/新数据schema转接、FPS/shape fallback验证与场景资产/基线重现。

P173 · LabDex

LabDex: A Hierarchical Benchmark for Dexterous Manipulation in Laboratories

文件 / 网站 · 主来源 · 原作 · 独立页面

LabDex的GitHub目前是展示网站，Code标Coming Soon；作者链接的HF dataset card已核对，但还没有可核验的task evaluator实作。

> **版本与身份**
>
> 固定3d1c43b网站与2608.18618一致；2026-10-11已读serandt/LabDex公开card。Code仍Coming Soon，未把网站或8000+声明当已集成case。

领域	实验室操作
环境	实体与模拟共用Franka Research3+XHand，三个相机视角、20+laboratory assets；同场景多视角不增加环境数。
任务	原文概观为30+Atomic、10+Compositional、1Long-Horizon workflow；实验表实际比较26atomic instances、7种操作类别。整体collection、已报评估subset及family是不同层次。
题数与数据	HF card声明8000+demo和1M+trajectory steps，包含同步多视角RGB、proprio、action、hierarchical annotations；card未给详细键名/文件布局，本次没有下载demo。50为每task评估trial数，非demo总量。
评估方式	原文成功要求末stage后状态在目标容差内连续2秒；atomic报SR，composite/workflow另报各atomic成功及每rollout平均完成数。必须取得容差、stage/时间checker才可运行。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **7** atomic operation categories · 原文页 4, 5
- **26** 实验atomic task instances · 原文页 5, 11
- **10** 附录列出compositional definitions · 依完整清单枚举 · 原文页 12, 13
- **1** long workflow · 原文页 13
- **50** 每task每model eval trials · 原文页 5

依这个顺序读

1. `docs/index.html` ↗

   GitHub · Zhipeng-Tang/LabDex · 3d1c43b63f

   原作ID、数据入口、Code Coming Soon及三层技能

   L35–91 · L279–307

怎么接入我们的benchmark

可重用

三层task结构、原生demo/trajectory量、2秒稳定成功协定与作者dataset入口。

需要转换

environment保留robot/相机/asset版本；task创建atomic→composite→workflow关系，不重加共享subtask；case记phase/容差/稳定时间和split。

仍需补齐

正式code、可解析episode manifest、确切action/clock schema、容差与每task成功规则、真实/模拟数据分割。

P174 · Labimus

Labimus: A Simulation and Benchmark for Humanoid Dexterous Manipulation in Chemical Laboratory

文件 / 网站 · 主来源 · 原作 · 独立页面

Labimus的官方网站可核对6种原子操作和1条七步秤重流程；目前这个GitHub只有展示内容，尚未取得模拟与精度checker。

> **版本与身份**
>
> 网站固定caea61f，原作2606.31037；所读GitHub tree展示index.html与媒体，没有benchmark Python实作，不据此宣称pipeline已复现。

领域	实验室操作
环境	Isaac Sim化学工作站、Tianyi humanoid、30+功能资产，包含可动仪器、粉末粒子与数字秤量测；网站视频不是可运行USD资产包。
任务	6atomic operations加1个7-step workflow。三种评估层(task completion/precision/step progress)×四个appearance条件形成12格评测设计；不能称12个新语义任务。
题数与数据	原文/网站描述procedural layout及Standard/Lighting/Textures/Combined；仍未取得具ID的scene、episode、示范和控制数据，未能算本次可用case数。
评估方式	同一物理动作分报binary completion、protocol precision和长流程stage进度；网站秤重例以原文±0.001g作模拟量测容差，另有位置容差。这些是原作任务标准，需相应物理量/仪器读值及校准，不只看对象是否放到秤上。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **6** atomic definitions · 原文页 9
- **1** 7-step workflow definition · 原文页 9
- **150** 每task-condition实验trials · 原文页 12

依这个顺序读

1. `index.html` ↗

   GitHub · labimus/labimus.github.io · caea61fd73

   精确原作/作者、任务列、三种评测层与四种条件

   `L188–214 · L250–280 · L363–382 · L449–468`

怎么接入我们的benchmark

可重用

6+1任务粒度、动作完成与量测有效性分离、四种环境条件。

需要转换

case保留仪器状态/粒子质量、单位、stage顺序和容差；evaluator同时输出完成/精度/进度；添加精度规则另有版本与支持证据。

仍需补齐

可公开取得的simulation code、asset与episode清单、instrument/particle校准、精度与stage scorer、各条件实际基线。

P175 · Pipette

Pipette: An Embodied Simulation Platform, Benchmark, and Data-Efficient Augmentation Framework for Wet-Lab Robotics

实作尚未确认 · 主来源 · 原作 · 独立页面

Pipette原文明确提供GitHub，但本次取得回404。已整理12个wet-lab任务的共通格式与成功验证augmentation设计，实作仍待取得。

> **版本与身份**
>
> 同一2606.12936的v3题名已改为Success-Verified Simulation Augmentation，书目旧题名Data-Efficient保留版本注记。官方hbhuiyou/Pipette取得404，只作当次不可用判定。
>
> 精确arXiv ID相同；论文版本改题名，不创建成另一份独立benchmark。

领域	实验室操作
环境	Isaac Sim/Isaac Lab、100+交互USD/消耗品资产；主要Franka Panda，部分task使用AgileX。三个RGB视角是传感配置，非三环境。
任务	12个sample handling、instrument/lid interaction、placement/alignment等wet-lab任务；NL parser辅助产生场景/任务设置，原文仍要求人工和模拟验证。
题数与数据	原文HDF5逐步记top/main/wrist RGB、proprio、sim state、action、language；成功验证后转LeRobot、去stale frame、对齐并降到10Hz，图像400²、robot-command8D。raw与augmented episode分别存，关联同一原示范；数据增强不是添加语义task。
评估方式	原文依对象pose、actuator state或几何关系与registered threshold判success；每episode JSON应记成功/失败理由/runtime/policy及control频率/gripper threshold。code及文中另提的technical supplement未取得，尚无法验证12task具体判分。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **12** wet-lab tasks · 原文页 5, 7
- **1,200** 每policy每数据设置eval episodes · 12×100 · 原文页 17
- **360** raw human training trajectories · 12×30 · 原文页 17

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

task entry(scene/robot/sensor/instruction/target/constraints/criterion)与HDF5→LeRobot对齐流程。

需要转换

创建原demo→augmentation lineage和各自render/action；case固定scene/初态/clock/8D命令语义，evaluator保留task-specific threshold与有效性。

仍需补齐

可取GitHub、12task/资产/episode清单、technical supplement、实际converter/evaluator与simulation重现。

P176 · AutoBio

AutoBio: A Simulation and Benchmark for Robotic Automation in Digital Biology Laboratory

内核内容已核读 · 主来源 · 原作 · 独立页面

AutoBio初步版有真实task/evaluator程序与LeRobot数据；MuJoCo和Blender是同任务的两种渲染版本。必须保留render lineage与各task具体量测，不能只拿生成视频数当题数。

> **版本与身份**
>
> 固定0850421，README明列Preliminary Version。未安装MuJoCo/Blender或运行policy；未将renderer份数当新任务或独立示范。

领域	实验室操作
环境	MuJoCo生物实验室资产与Blender Cycles外观渲染；pipette例为双UR5e和灵巧手/夹爪。physics scene、相机和render edition分别记录，Blender不另增物理环境。
任务	当前factory接受13个原生task名称，README列9种dataset各有MuJoCo/Blender版本；这两个范围不是同一清单。原子操作与完整仪器任务需要按原作版本对照；pickup导入模块未在固定tree找到。
题数与数据	LeRobot v2.0每episode parquet与videos，meta包含episodes/info/stats/tasks；README视频224²@50fps。runtime使用observation/state、图像与prompt，task_info指定state_indices/action_indices/camera_mapping。RDT数据用fps创建action/history timestamps并保存缺图像mask；不可将补0当真实sensor。
评估方式	每action保持10个MuJoCo physics步，chunk外检查time_limit/early_stop，可能超出名义budget到chunk末；不健康模拟回False。pipette checker追踪tip入液面、拇指命令变化与最后抬离液面，未直接对抽取体积作容差检查。history deque追加qpos未明确copy，也需验证历史状态是否别名。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **16** task definitions · 原文页 6
- **9** 实验task子集 · 3levels×3tasks · 原文页 7
- **900** train demonstrations · 9×100 · 原文页 7

- **100** 每task eval episodes / run · 原文页 8

依这个顺序读

1. `README.md` ↗
   GitHub · autobio-bench/AutoBio · 0850421335

   preliminary身分、9类数据的两种render与LeRobot2.0

   L1–80

---

2. `autobio/task.py` ↗
   GitHub · autobio-bench/AutoBio · 0850421335

   task factory原生名称、state/step/serializer界面

   L16–83 · L90–146

---

3. `autobio/evaluate.py` ↗
   GitHub · autobio-bench/AutoBio · 0850421335

   master seed生成每episode seed、结果bool列表

   L18–21 · L43–100

---

4. `autobio/evaluator.py` ↗
   GitHub · autobio-bench/AutoBio · 0850421335

   合法观测、10physics步/action、健康/时间/成功条件

   L174–266

---

5. `autobio/mani_pipette.py` ↗
   GitHub · autobio-bench/AutoBio · 0850421335

   双UR5e task_info、初态、液面/操作条件的具体checker

   L132–239

---

6. `RoboticsDiffusionTransformer/data/lerobot_vla_dataset.py` ↗
   GitHub · autobio-bench/AutoBio · 0850421335

   FPS相对timestamp、图像history/padding、state/action范式

   L12–45 · L181–240

怎么接入我们的benchmark

可重用

明确task/serializer/factory、LeRobot结构、paired renderer来源、具体task checker与seed协定。

需要转换

source+task+episode为底层ID，render variant作observation版本；case固定physics/action时间、joint顺序、初态及scorer；量化体积/精度可作添加规则，保持原版可比。

仍需补齐

preliminary版本缺件、13factory与原作task清单对齐、完整资产/数据、command/state normalizer、history/budget验证与全部task重现。

P177 · H2RBench（human transfer）

H2RBench: A Real-to-Sim Benchmark for Evaluating Human-to-Robot Transfer

内核内容已核读 · 主来源 · 原作 · 独立页面

H2RBench提供基于PolaRiS的6个Gym场景注册与human-to-robot transfer评测。此版rubric按曾完成的子条件累积，与末态全部同时完成有差异。

> **版本与身份**
>
> 固定5082e75。README arXiv仍TODO且clone示例为旧DavidZ2851/polaris；官方h2rbench.github.io连此库并列精确2609.24778，身分相符。与P151视频生成H2R-Bench保持不同source。

领域	装配与生产作业、通用对象与机动作业
环境	Isaac Lab与PolaRiS真实场景重建/3D Gaussian splat；固定registry6个Gym ID为放红杯、叠积木、套环、挂杯、玩具入盒、叠碗。authoring scene.json与runtime scene.usda/渲染资产不是同一种环境描述。
任务	6个原生task setup有Rubric前置依赖；新case须保存human/robot数据转移的训练条件与实际goal，不能把完整PolaRiS父资产库当本篇全部已评任务。
题数与数据	initial_conditions.json含instruction/poses；task_config.yaml有object_randomization/waypoints。当前randomize以poses[0]为底再取range，未逐条使用所有原始pose；旋转入参xyzw、输出wxyz。policy推论入口送obs+language，human示范训练/配对数据另需manifest，不能从此eval入口推定已有video prompting。
评估方式	每criterion曾达成即latched，progress=ever_reached/total，成功为全数曾达成；空criteria会success=True但progress0，应拒作合法case。放置看XY投影覆盖与finger条件；插入有速度稳定/XY/Z检查，其closure计数须确认跨episode重置。续跑先生成ic后快转RNG，第一个恢复episode仍用旧ic，需修正或保存实际初态。视频固定15fps不是控制clock证据。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **4** manipulation task families · 原文页 5
- **340** 固定robot demonstration预算 · 40+100+100+100 · 原文页 5
- **1,000** human demonstration上限预算 · 100+300+300+300 · 原文页 5

- **90** 每method/task eval rollouts · 原文页 6

依这个顺序读

1. `README.md` ↗
   GitHub · xiaochy/H2RBench · 5082e75c4c

   作者/原作项目与PolaRiS来源关系

   L1–80

---

2. `src/polaris/environments/__init__.py` ↗
   GitHub · xiaochy/H2RBench · 5082e75c4c

   6个具体环境与reach/lift/place/insert依赖条件

   L1–128

---

3. `PolaRiS-Hub/put_red_cup_no_curtain/scene.json` ↗
   GitHub · xiaochy/H2RBench · 5082e75c4c

   authoring scene的asset/path/pose/scale

   L1–47

---

4. `src/polaris/utils.py` ↗
   GitHub · xiaochy/H2RBench · 5082e75c4c

   instruction/poses与task randomization设置

   L18–59

---

5. `src/polaris/utils_/eval_utils.py` ↗
   GitHub · xiaochy/H2RBench · 5082e75c4c

   seed、仅取第一个基准pose、xyzw→wxyz转换

   L6–64

---

6. `scripts/eval_policy.py` ↗
   GitHub · xiaochy/H2RBench · 5082e75c4c

   case抽样/续跑、model界面、rubric结果和budget

   L20–153

---

7. `src/polaris/environments/manager_based_rl_splat_environment.py` ↗
   GitHub · xiaochy/H2RBench · 5082e75c4c

   reset/step均评rubric，缺rule不计正常progress

   L42–96 · L179–198

---

8. `src/polaris/environments/rubrics/base.py` ↗
   GitHub · xiaochy/H2RBench · 5082e75c4c

   max-ever criteria、依赖和progress/empty-rule

   L1–77

---

9. `src/polaris/environments/rubrics/checkers.py` ↗
   GitHub · xiaochy/H2RBench · 5082e75c4c

   具体XY覆盖和稳定插入checker

   L8–91 · L222–261

怎么接入我们的benchmark

可重用

6环境注册、scene/initial_conditions/task_config界面、可追溯predicate与依赖进度。

需要转换

case绑定source episode、重建/碰撞/渲染资产版本与座标系；记实际初态、human训练子集和固定budget；保持ever-success与同时末态成功分项。

仍需补齐

human/robot完整配对数据、资产和training split、续跑初态一致性、stateful predicate reset、非空rubric/全部终态有效性及跨机体基线。

P178 · RoboRecover

RoboRecover: Benchmarking Robot Policy Recovery under Execution Deviations

内核内容已核读 · 主来源 · 原作 · 独立页面

公开程序是 LIBERO / RoboTwin 的恢复起点、固定 split 与回放后推论 overlay。已核读 JSON reader、回放 / 新推论预算、LIBERO 成功传递与 RoboTwin 入柜任务的具体 checker；完整2,000个 scenario JSON 的托管仍待发布，两个 example 并非完整数据集。

> **版本与身份**
>
> 固定 RoboRecover 089b942；LIBERO 延伸核读恰为 lock 指定8f1084e。lock 所有 historical_revision_verified 均为 false；README 指 LIBERO MuJoCo3.3.2 / robosuite1.4.x、RoboTwin SAPIEN3.0.0b1，不可用 upstream 最新版代换。RoboTwin FastWAM / LingBot-VA recovery adapters 仍 pending；论文六政策结果不等于仓库六个可用 adapter。
>
> 收录论文为 arXiv:2609.28952v1，PDF 第1页直接连至 RUCKBReasoning/RoboRecover；README 的双平台、action-prefix recovery 与论文一致。README 第78行仍使用 CuteClaire/RoboRecover 拷贝网址，保留为别名待确认，不另算来源。

领域	居家整理与清洁
环境	LIBERO 的 MuJoCo 桌面任务与 RoboTwin 2.0 的 SAPIEN 双臂场景各自重用原 benchmark。LIBERO 依 suite/task_id 找 BDDL、episode_idx 找原生 init state；RoboTwin 依 task_name/task_config/seed、embodiment 与 camera YAML 初始化。scenario 是同一任务运行偏离后的起点，不另计为新的 environment 或 task。
任务	论文定义 Recovery Stage=Approach/Contact/Move/Place，Deviation Type=Wrong Target/Wrong Pose/Stage Rollback/Scene Change；实际两个 test CSV 都有9种 stage–type 组合，不是4×4皆存在。静态解析各200个不重复 test sample_id，LIBERO 含38个 task_name、RoboTwin 含34个；论文另述 train 涵盖40 / 42个任务。2,000是恢复 scenarios，两平台各800 train / 200 test，不是2,000项技能。

题数与数据	split CSV 字段为 sample_id/path/sha256/original_sha256/actions/replay_prefix_steps/task_name/s_stage/d_stage；两个 example 的实际 SHA256 各匹配该平台 test 第一列。LIBERO JSON 包含 task_suite_name/task_id/episode_idx/seed、initial_state.xyz/quat/rpy/gripper、actions；RoboTwin 包含 task_name/task_config/instruction、initial_state.joint_vector/left_endpose/right_endpose/left_gripper/right_gripper 及 annotation_meta.frame_index/video_fps。验证器接受 LIBERO 7D、RoboTwin 14或16D action，qpos / ee 应另存 action_type；不可把 gripper 或范式 action 一律当公尺。reader 只在长于 annotated_step+1 时截取，不补短 prefix。LIBERO 模型输入是两视角 RGB、末端位置 / axis-angle / gripper state；annotation video_fps=10 的 example 不代表所有控制频率。
评估方式	先以原 reset 重建，再回放 prefix、清空推论历史并给新的 S 步预算；正式设置 post-replay wait=0，prefix 不扣推论额度。LIBERO suite 预设预算 spatial/object/goal/10/90 分别 220/280/300/520/400；RoboTwin 以原 task.step_lim 和可选 max_infer_steps 取较小值。LIBERO native done 来自 goal predicates；RoboTwin Base_Task 将具体 check_success 锁存至 eval_success，所读入柜 checker 要求 |dx|、|dy|各<0.05，对象比初高0.007至0.12且对应夹爪张开（原生模拟长度单位）。论文 Overall RSR 是每 scenario 成功数 / 排定 trials 后等权平均；Macro-9 再对9个 stage–type group 等权平均。程序 build_summary 按 task/error_type 直接累加 trial 并使用 eval_success_at_end，可能包含 replay_already_done；不能原封当成论文 RSR。LIBERO _to_summary 主要输出 status_counts，effective_failure 只加 timeout_failure/env_crash，亦不等于完整失败分母。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **2,000** recovery scenarios（含train） · 原文页 3, 4
- **400** held-out recovery scenarios · 原文页 4
- **9** 测试集有数据的stage-type groups · 原文页 5, 6

依这个顺序读

1. `README.md` ↗

   GitHub · RUCKBReasoning/RoboRecover · 089b9420e8

   核对双平台身分、数据未完整托管与 scenario 等权评分协定。

   `L1–19 · L55–71 · L105–153`

2. `dependencies.lock.json` ↗

   GitHub · RUCKBReasoning/RoboRecover · 089b9420e8

   保留 upstream commit 与 historical_revision_verified=false，不能宣称重现了论文原始环境。

   L1–52

---

3. `tools/prepare_data.py` ↗

   GitHub · RUCKBReasoning/RoboRecover · 089b9420e8

   split membership、SHA256、action shape 与数值检查。

   L10–37

---

4. `examples/libero.json` ↗

   GitHub · RUCKBReasoning/RoboRecover · 089b9420e8

   LIBERO task/reset、stage/type 与第一个 action 的实际字段。

   JSON /task_suite_name · JSON /task_id · JSON /episode_idx · JSON /seed · JSON /initial_state · JSON /s_stage · JSON /d_stage · JSON /annotated_step · JSON /actions/0

---

5. `examples/robotwin.json` ↗

   GitHub · RUCKBReasoning/RoboRecover · 089b9420e8

   RoboTwin config、instruction、关节 / 末端初态与 annotation frame 约定。

   JSON /task_name · JSON /task_config · JSON /instruction · JSON /initial_state · JSON /annotation_meta · JSON /actions/0

---

6. `overlays/RoboTwin/script/robotwin_trace_utils.py` ↗

   GitHub · RUCKBReasoning/RoboRecover · 089b9420e8

   JSON 必要字段、annotated_step 截取与动态 task class 解析。

   L21–29 · L84–101 · L123–175

---

7. `overlays/RoboTwin/script/eval_ood_replay_then_infer.py` ↗

   GitHub · RUCKBReasoning/RoboRecover · 089b9420e8

   回放与推论分段、异常状态、具体 summary 的 trial 分母。

   L348–442 · L480–556 · L596–643

---

8. `overlays/RoboTwin/envs/_base_task.py` ↗
   GitHub · RUCKBReasoning/RoboRecover · 089b9420e8

   每次物理 step 的 check_success 如何设置 eval_success。

   L1707–1715

---

9. `overlays/RoboTwin/envs/put_object_cabinet.py` ↗
   GitHub · RUCKBReasoning/RoboRecover · 089b9420e8

   入柜 task 的高度 / 平面距离 / 张开夹爪联合条件。

   L67–81 · L119–130

---

10. `overlays/openpi/examples/libero/eval_filtered_repro.py` ↗
    GitHub · RUCKBReasoning/RoboRecover · 089b9420e8

    LIBERO reset、7D prefix、done 解读、suite 预算与状态统计。

    L104–110 · L245–302 · L428–470 · L703–741 · L770–802 · L918–937 · L1244–1271

---

11. `libero/libero/envs/env_wrapper.py` ↗
    GitHub · Lifelong-Robot-Learning/LIBERO · 8f1084e313

    在 dependencies.lock 指定版本追 TASK_MAPPING 到 task。

    L43–88 · L103–104

---

12. `libero/libero/envs/bddl_base_domain.py` ↗
    GitHub · Lifelong-Robot-Learning/LIBERO · 8f1084e313

    step 的 done 直接覆写为具体 task 的 _check_success。

    L801–809

---

13. `libero/libero/envs/problems/libero_tabletop_manipulation.py` ↗
    GitHub · Lifelong-Robot-Learning/LIBERO · 8f1084e313

    goal_state 的逐项 predicate 合取；不是 base class 的占位 False。

    L135–154

怎么接入我们的benchmark

可重用

固定 split / 逐档哈希、JSON schema、upstream task/reset 关系、stage–type 标签、replay/infer 分段与具体成功 checker。

需要转换

source 保留两层 commit；environment 指向原生模拟器 / 资产；task 仍用平台与 native task key；case 用平台 +split+sample_id，保存 reset 引用、prefix、原指令及偏离来源；evaluator 另记 step budget、repeat、scheduled/invalid/status。domain 只按任务内容映射。从 results.jsonl 重算 scenario 等权 RSR、Macro-9，将回放已完成与 state mismatch 保留为独立有效性状态。

仍需补齐

完整 scenario archive / 数据授权及 simulator assets；各 adapter 完整环境验证；原论文历史 upstream revision 证实；正式排定 trial 名册及 replay_already_done 的统一处置；各 task checker 全覆盖。本轮只核读代表性内核路径，未跑模型或模拟。

P179 · REBOOT

REBOOT: From Failure to Recovery - A Dataset and Benchmark for Precision Assembly

内核内容已核读 · 主来源 · 原作 · 独立页面

已核读 REBOOT 的 depth reader、frame / video 对齐、phase.json 裁切读取与通用 evaluator。原生18任务及人工五阶段判定主要定义于论文；所查固定版本未提供 REBOOT 专用自动 phase scorer。另实查官方 RCA recovery 数据 metadata，确认仅30 episodes、train split 且没有 meta/phase.json，不能直接把论文2,160段视为已闭合的公开数据。

> **版本与身份**
>
> 固定 depth 分支269d539，不以 upstream LeRobot 最新版替代；HF实查固定fb4e5c5。README 的『2,160 bimanual』与论文83段实际协作需分开解读；论文1-based phase公式、范例tau_0=0及程序0-based slice 也要保留来源差异。未下载 parquet/video，未安装或运行上游程序。
>
> arXiv:2609.22591v1 第16页及作者 nanayawoa 的项目页均连至此 fork；README 自称 LeRobot (REBOOT fork)，承接 Trossen fork、LeRobot v0.4.3 与 depth PR2604。这是数据录制 / 读取支持仓库，不是18项组装任务的完整模拟器。

领域	装配与生产作业
环境	实体 NIST Assembly Task Board #1，Trossen WidowX AI 两支6关节 follower 与 leader teleoperation；四台 RGB-D 视角为 high、low、left_wrist、right_wrist。论文对象初位在名义位置周围3–6 cm 变动，目标板固定。双臂硬件 / 14D state 不等于每段双臂协作：论文第10页只有83 / 2,160段属双臂，且主要为 recovery_install。
任务	依第23页表10保留9种对象各 install/remove，共18项：M12、USB-A、USB-C、RJ45、NEMA 1-15P、HAN10E、RCA、16mm bar/cylinder。每 task 保留 C1/C2/continuous symmetry、clearance（mm）、precision tier。共同五阶段是 Align(pick)、Engage(pick)、Transport、Align(place)、Engage(place)，不是90个独立任务。论文每 task 有60 expert+60 recovery，总2,160；第7页『10 types』与具体9列 inventory 不一致，采表10枚举并标记差异。

题数与数据	论文 action/state 为两臂各6 joint+1 gripper 的14D绝对目标 / 状态，30 Hz；保留关节及夹爪原生尺度，不推定全部维度为角度。实查 REBOOT26/rca_recovery_install@fb4e5c5：info.codebase_version=v3.0、30 episodes、26,939 frames、1 task、splits.train='0:30'；action/observation.state 为 float32[14]，RGB 为480×640×3 video、四个 *_depth 为 480×640×1 depth。data/chunk-*/file-*.parquet 与 videos/{video_key}/chunk-*/file-*.mp4 透过 episode metadata 的 chunk/file/from_timestamp 连接；reader 裁定 delta_indices 不跨 episode，另输出 *_is_pad。相机程序以 z16 读 uint16，docstring 称 mm，但数据 info 未提供 depth scale，仍需校准信息。论文 phase schema 含 repo_id/task_id/episode_index、phase_boundaries.tau_0…tau_5、failure.originating_phase/failure_mode/t_f/t_r/t_s；trim reader 则要求外层 episodes[]，按 failure.<cut-key>（预设t_r）取 [start,stop)。抽查的 RCA dataset file inventory 未含 meta/phase.json；其他38个 API 列出项目未逐一查数据，不能断言全部缺标注。
评估方式	论文以人工标记的 last-completed phase / first failure phase 形成每阶段分布及最终成功率，不能由 clearance 单栏推导自动成功。正文第7页写20 rollouts/task/policy，第8页与附录A.5写15，后者18×3×15=810；须厘清实际使用名册。公开 lerobot_eval.py 读 info.final_info.is_success 或 info.is_success，缺值用False，沿 episode 合并为 any(success)，再平均成 pc_success（百分比），同时计 reward；它不判断 connector engagement 或 phase 边界，不能代替 REBOOT grader。失败词汇也有版本差：第6页四类，附录与第7页另含 slip。裁切器会移除 dtype=depth / 名称结尾_depth 的 feature，重新产生 index/timestamp，未重映射 phase/failure 时间，不能直接把其输出当原版完整 recovery case。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **18** assembly/disassembly tasks · 原文页 5
- **2,160** expert+recovery demonstration episodes · 原文页 5, 6
- **810** 主分析总evaluation rollouts · 15×18×3；与protocol 20次不一致 · 原文页 8

依这个顺序读

1. `README.md` ↗

   GitHub · anon-robo-account/REBOOT · 269d53958c

   确认 fork 角色、LeRobot v3/depth 与 REBOOT26 官方数据源。

   L11–27 · L47–67

2. `src/lerobot/datasets/lerobot_dataset.py` ↗
   GitHub · anon-robo-account/REBOOT · 269d53958c

   从 metadata 到 parquet / MP4 reader、episode 边界 padding、timestamp offset 与 depth 分流。

   `L161–217 · L233–260 · L934–1060 · L1117–1160 · L1321–1338`

---

3. `src/lerobot/cameras/realsense/camera_realsense.py` ↗
   GitHub · anon-robo-account/REBOOT · 269d53958c

   RealSense z16、uint16 depth 与相机后处理，避免当 RGB 范式。

   `L280–291 · L327–365 · L420–461`

---

4. `dtset-trim/dataset_episode_trim.py` ↗
   GitHub · anon-robo-account/REBOOT · 269d53958c

   实际 phase.json schema、failure.t_r、半开 frame slice，以及删除 depth / 重建索引的行为。

   `L1–18 · L74–157 · L191–259 · L269–279`

---

5. `src/lerobot/scripts/lerobot_eval.py` ↗
   GitHub · anon-robo-account/REBOOT · 269d53958c

   具体程序只汇总环境 is_success 与 reward，没有 REBOOT 五阶段的物理 / 视觉判定。

   `L198–231 · L366–381 · L438–463`

怎么接入我们的benchmark

可重用

14D通道名称、四相机 / depth schema、LeRobot v3 episode 索引读取、原生 task inventory、人工 phase/failure 表达及裁切窗解析。

需要转换

source 分别保留程序 commit 与每个 HF dataset revision；environment 记硬件 / board；task 用 object+install/remove；case 用 dataset revision+episode_index，另存 expert/recovery 与双臂旗标；frame/time 用30 Hz与原 offset 连接。保留 source_frame_index 与 trim offset，重新映射 phase/t_f/t_r/t_s，避免删 depth；evaluator 独立保存人工阶段判定与通用 rollout success，不合并。

仍需补齐

36个理论 task×episode-type 分组与官方实际38个数据 repo / 分片的对照及去重；完整 episode 与 phase annotation 名册；RCA 本次固定版本仅30段及缺phase的原因；15/20 rollout 协定厘清；原生 joint/gripper/depth 校准尺度；公开 REBOOT 专用 grader 或人工评分流程。

P180 · SafeManip

SafeManip: A Property-Driven Benchmark for Temporal Safety Evaluation in Robotic Manipulation

内核内容已核读 · 主来源 · 原作 · 独立页面

已追到 privileged HDF5/JSON reader、simulator contact grounding、LTLf DFA、可恢复的 repeated-violation 状态机与实际聚合器。公开 code 有20个 enforced specifications / 8类，但所读 analysis/monitor_metrics/RQ1 的分母与论文v3 per-trigger pooled metrics 不一致；id.csv 也有9个当前公式无法匹配。

> **版本与身份**
>
> AST / CSV静态比对发现9 / 20个当前公式不能由id.csv文字join到ID；例如collision已改sustained、grasp拆成两spec、release改用object_dropped。id.csv也将释放公式列为GraspStability、旧抓握公式列为ReleaseStability，与ApplicableProperty不同。不要用旧P1...ID自行覆写native property_name。README明示working forks被gitignore，但monitor/sim公开extension确实存在，不能把整个来源误标为无程序。
>
> 收录 arXiv:2605.12386v3（2026-09-28），第6页列此 GitHub；README 题名一致但仍匿名。程序固定2026-09-26 commit，早于该 PDF 修订，尤其评分与ID映射不可假定完全同步。

领域	居家整理与清洁
环境	沿用 RoboCasa365 厨房与 LIBERO 桌面模拟，主体是可取得 privileged simulator state 的安全监测层。论文50个RoboCasa tasks、4×10个LIBERO tasks是重用范围，不另当90个新环境。固定scene实验依seed锁定layout / 初态，应与一般scene variation分开。gitlink 的 LIBERO=8f1084e、LIBERO_openpi=f78abd6、RoboCasa=4f8a298。
任务	8类：碰撞 / 接触、抓握稳定、释放稳定、交叉污染、action onset、mechanism、containment、enclosure/access。论文表2的10个template与表4 / 程序20个enforced spec不同单位；静态AST逐一抽出20个name/ltl，抓握拆同步与掉落合法性，action onset有8种skill。task applicability 必须取原生场景 / 对象及ApplicableProperty表；LIBERO无某些语义触发不能当免费安全分数。monitor目前每property每episode使用binding={}，未枚举全对象组合。

题数与数据	LIBERO reader 读 data/demo_*/states、可选actions及init_state attr、data.attrs.bddl_file_name；直接set_state_from_flattened后forward，另设timestep=t+1防止监测状态每frame重置。若actions数等于states数，尝试最后action补一个terminal frame，故监测长度可能T+1；其replay_summary仍硬编split='train'，即使fallback可读eval rollout。输出privileged_static_info、privileged_dynamic_info[{step,data}]、replay_summary；dynamic含task.timestep/success、robot.end_effector_pose、scene对象 / fixture pose与predicates。env_ext quaternion由body_xquat输出wxyz。monitor输出property_name/ltl/binding、num_frames、violations/satisfied、original/repeated、repaired_traces、accepting_by_property/recovery_accepting_by_property；raw per-frame repeated trace预设移除。frame index、原生step、call_stride与秒数须分开，不从monitor行数推定物理时间。
评估方式	具体collision grounding先排除合法robot/object/fixture/receiver/source-support/tool接触，剩余geom pair累加forbidden_contact_age，>20 frames才令forbidden_contact_sustained=True，enforced公式为G(!forbidden_contact_sustained)。SETTLE_TIMEOUT_FRAMES=100、SKILL_ONSET_FRAMES=10是本commit帧阈值。DFA逐frame转移；repeated monitor进reject后冻结main并推进recovery DFA，recovery接受才结束unsafe episode及重新启动，保留次数与duration。论文v3定义聚合后Vφ/Nφ及Uφ/Nφ，aggregate先pool counts，task success独立。实际monitor_metrics却算violated_instances/evaluated_instances及exposure_frames/monitored_frames；analysis.metrics的violations_per_skill_onset以evidence里所有skill_*_onset_candidate_count的最大快照作分母，RQ1再平均各列ratio，不是每property trigger总数。因此这些现成CSV / 图不能直接标成v3正式per-trigger结果。timeout未触发而视频已结束时run_monitor把该property归satisfied，必须保存截断 / 未观测完成的限制。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **90** 两来源host task entries · 原文页 6
- **10** 安全规则templates · 原文页 4, 5
- **50** 每policy/task evaluation episodes · 原文页 6

依这个顺序读

1. `README.md` ↗

   GitHub · chengyuehuang511/SafeManip · cb9ca772c5

   确认 safety layer 角色、gitignored working forks 与固定 / 变动场景流程。

   `L13–69 · L83–92 · L309–353`

2. `.gitmodules` ↗

   GitHub · chengyuehuang511/SafeManip · cb9ca772c5

   模拟器 / 模型是独立 gitlink，不能把 parent tree 当完整上游程序。

   L1–41

---

3. `SafeManip/analysis/ApplicableProperty.csv` ↗

   GitHub · chengyuehuang511/SafeManip · cb9ca772c5

   以50个task字段对应property applicability，不将所有安全类别套到每task。

   L1–15

---

4. `SafeManip/monitor/extract_privileged_from_dataset_libero.py` ↗

   GitHub · chengyuehuang511/SafeManip · cb9ca772c5

   HDF5 states/actions/BDDL reader、逐frame还原与末端frame补回。

   L107–219 · L267–305

---

5. `SafeManip/monitor/sim/libero/env_ext.py` ↗

   GitHub · chengyuehuang511/SafeManip · cb9ca772c5

   实际输出 task/scene/robot/predicates 与 wxyz quaternion。

   L50–131

---

6. `SafeManip/monitor/sim/robocasa/predicates.py` ↗

   GitHub · chengyuehuang511/SafeManip · cb9ca772c5

   allowed contact class 排除后，连续 forbidden contact 超过20 frames 才触发 sustained。

   L436–456 · L4140–4273

---

7. `SafeManip/monitor/specs.py` ↗

   GitHub · chengyuehuang511/SafeManip · cb9ca772c5

   具体 collision invariant 与 grasp weak-until，和文章template分层保存。

   L443–460 · L527–531

---

8. `SafeManip/monitor/predicates.py` ↗
   GitHub · chengyuehuang511/SafeManip · cb9ca772c5

   predicate wrapper 只查已grounded值，必须往 sim implementation 追。

   L119–163

---

9. `SafeManip/monitor/monitor.py` ↗
   GitHub · chengyuehuang511/SafeManip · cb9ca772c5

   每property使用单一空binding，逐frame喂入已grounded atom。

   L72–93 · L225–276

---

10. `SafeManip/monitor/LTLfDFA.py` ↗
    GitHub · chengyuehuang511/SafeManip · cb9ca772c5

    实际 MONA/DFA 创建、唯一转移与终止 / trap 判定。

    L161–246 · L267–287

---

11. `SafeManip/monitor/repeated_violation_monitor.py` ↗
    GitHub · chengyuehuang511/SafeManip · cb9ca772c5

    违反后冻结main、启动recovery、恢复时reset，以及collision具体recovery公式。

    L105–245 · L248–319 · L1408–1437

---

12. `SafeManip/monitor/run_monitor_on_privileged.py` ↗
    GitHub · chengyuehuang511/SafeManip · cb9ca772c5

    reader→predicate修补→monitor→输出；截断timeout会被列为satisfied的实际语义。

    L103–133 · L1238–1324 · L1328–1409 · L1524–1569 · L1640–1681

---

13. `SafeManip/monitor/monitor_metrics.py` ↗
    GitHub · chengyuehuang511/SafeManip · cb9ca772c5

    instance分母的violation_rate与frame exposure，不是per-trigger。

    L77–125 · L137–230

---

14. `SafeManip/analysis/metrics.py` ↗

    GitHub · chengyuehuang511/SafeManip · cb9ca772c5

    onset候选计数、零分母空值、task/safety/safe-success的分离。

    L72–85 · L266–397

---

15. `SafeManip/analysis/id.csv` ↗

    GitHub · chengyuehuang511/SafeManip · cb9ca772c5

    旧公式 / 类别映射与当前spec不一致。

    L1–20

---

16. `SafeManip/analysis/RQ1.py` ↗

    GitHub · chengyuehuang511/SafeManip · cb9ca772c5

    图表以ratio列取平均，未依论文先pool trigger与violation数。

    L743–766 · L1846–1864

怎么接入我们的benchmark

可重用

原生property_name、enforced LTLf、recovery LTLf、predicate grounding / 帧阈值、静态scene角色、逐frame trace与unsafe episode区间。

需要转换

source保留PDF版 / parent commit / simulator gitlink；environment与task指向原生RoboCasa/LIBERO；case=原生task+policy+seed+scene/split+episode；evaluator拆task success、whole-rollout satisfaction、repeated counts、unsafe frames、per-property trigger counts。保留template→enforced-spec→category映射与NA applicability。零分母记NA，禁止把空类别回传0当成已证安全；从trace另建有版本的trigger registry后才算v3 pooled metrics。

仍需补齐

v3 per-trigger Nφ 的完整程序 / 可核对输出；当前20个公式与id.csv / ApplicableProperty的版本对齐；被gitignore的working policy/simulator fork与公开extension的接线；末端补frame及硬编train provenance验证；全部grounding与机制的独立有效性检查。本轮未跑MONA、模型或模拟。

P181 · RoboFolDeX

RoboFolDeX: A Physical-World Benchmark for Long-Horizon Robotic Manipulation of Deformable Objects

实作尚未确认 · 主来源 · 原作 · 独立页面

完成 pinned PDF、GitHub 搜索缓存与官方 challenge 页的限量身分查找，仍未确认作者授权的公开程序仓库或数据 reader。保留长时程实体折衣任务、人工品质评分与 FoldScore 的论文规格；不以其他 cloth benchmark 或通用VLA程序替代。

> **版本与身份**
>
> 以2026-09-18 v2 PDF为准；第3页仍称review期间省略access links，与首页已列Midea网址并存，不能据此补猜程序网址。无repo commit可记；各PDF/搜索/HTML/HTTP receipt均记本地SHA256及read范围。未运行JS、提交policy、联系作者或下载模型 / 数据。
>
> RoboFolDeX 指 Chenhuan Liu、Yi Xu 等的 arXiv:2609.10243v2，机构为 Fudan / Midea / CMU。PDF第1页给出的第一方平台为 ai.midea.com/#/fold-challenge。FoldChallenge 是这篇的实体评测平台名称，不是可据以自动推定的 GitHub owner/repo。

领域	居家整理与清洁、衣物与洗护
环境	真实双臂长时程衣物整理，从篮中取衣、桌面翻转 / 摊平、多次折叠到最后放置 / 堆栈。数据涵盖桌面 / 家庭场景与照明、背景、layout变化；论文列Aloha、YAM、Piper、Astribot、Franka、UR5、自研移动双臂、AgiBot G2等，10+是宣称的embodiment规模，未取得完整registry。
任务	主题是衣物折叠，参考实验分Shirt、Skirt、Pants、Towel；完整数据另外含其他deformable及少量rigid任务。20+是论文来源层task宣称，不是已枚举的可运行task数。四个track为recovery-data utilization、cross-task、cross-scene、cross-embodiment；它们是训练 / 转移协定，不另计为四项操作技能。
题数与数据	论文宣称2,000+小时真实robot trajectories。观测为两腕相机+外部workspace相机RGB、自然语言指令、proprioception；action为未来end-effector pose trajectory。论文描述共用metadata语义：task、object category/instance、scene、embodiment、operator、data source、completion及failure/termination reason；本轮未取得实际文件名 / keys、action维度与座标系、时间频率或split名册，因此不能将这些概念冒写成已验证JSON schema。hours、tasks、robot embodiments与episode/case数分开，case总数保持未知。

评估方式	论文标准完整episode需无人工介入且无不可恢复失败，通常每衣物类别30次独立实体trials、初态随机化；品质由至少两名相同评审跨方法独立评定，达成一致才记录。neatness等级0–5查看形状、紧密、平整、稳定与边缘；FoldScore=35×平均范式品质Q̄+35×完整success rate R+30×max(0,1–t/Tmax)，t只在成功trials平均，无成功时时间项为0。PDF称quality mapping及细rubric在Appendix，但固定版本共9页、第8–9页为references，未附该表；Tmax也未给数值。故不能自行用neatness/5或任意时限做『官方scorer』。π0.5的pre-flattened短流程baseline与basket-to-stack完整流程须分开。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **2,000** real-robot data hours · 下限 / 2,000+ · 原文页 1, 4
- **20** 数据task种类 · 20+，非全数主评测 · 原文页 4
- **30** 每衣物类别物理trials · 原文页 5, 6

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

已明确的实体任务流程、四track设计、observations/action的语义、0–5品质尺度及FoldScore公式。

需要转换

source记PDF v2与FoldChallenge第一方平台；environment保存实体硬件 / 相机 / 场景；task保存衣物类别与完整或局部流程；case待原生trial/garment instance/init metadata公开后创建。evaluator先标人工评分及paper_specified_formula，品质 / success / 成功trial时间三项分存，数据重用track保留训练来源与target embodiment。

仍需补齐

作者确认的程序repo、可检验reader/schema、公开数据manifest / 授权 / split、完整品质rubric及Q映射、Tmax、submission/execution界面与实体trial结果。SPA大型JS及可能需交互的页面内容本轮未展开，平台『operational』仅依论文声明。

P182 · SoftVTBench

SoftVTBench: A Deformation-Aware Visuo-Tactile Dataset and Benchmark for Deformable-Object Manipulation

内核内容已核读 · 主来源 · 原作 · 独立页面

核读的是旧v0.1的四suite task/config、HDF5 reader、具体goal checker、FEM Kabsch变形计算、per-object calibration及正式softvtbench_metrics。它与收录论文的数据规模、asset清单及90th-percentile门槛不同，且runtime禁用了drop termination；本笔是有版本限制的程序核读，不代表已重现4,000示范版DSR。

> **版本与身份**
>
> 固定58056111f（2026-07-22）。repo身分由PDF明链与相同作者确认，但README的2607.04234、1,628/33、pi05-only、半最大值calibration都属旧版；PDF为2608.18701、4,000/50+、Diffusion/π0.5/FastWAM、90th-percentile。另有README NoDrop叙述与正式code不一致，以及deprecated global-threshold scorer，全部分开记录。未运行任何模拟或上游模型。
>
> arXiv:2608.18701v1 第1页直接连至此repo，作者与README的Bowen Jing、Mingxin Wang等一致，故为第一方来源。但2026-07-22固定commit的README / 项目页仍连2607.04234并使用Safety-Aware旧题名；不能据此改写收录PDF身分或当作新paper版本已完整发布。

领域	通用对象与机动作业、餐饮与烹饪
环境	Isaac Sim / Isaac Lab，Franka Panda及双指GelSight Mini，FEM deformable对象、刚性对照与tactile proxy；与Tabero / LIBERO有重用关系。task JSON分fixtures、objects、regions、robot_base_pos / wxyz orientation、obj_of_interest与tactile_targets，soft / rigid twin及场景variation要各自保留，不将旧LIBERO BDDL文件名当作当前soft task身分。
任务	Object-Soft、Spatial-Soft、Object-Rigid、Spatial-Rigid是2×2 matched suites，内核为pick-and-place。收录论文每suite10 tasks / 1,000 demos，另500 ID evaluation episodes / suite（50/task），soft suites各9种单因子OOD条件、每suite/config合计900 OOD trials。程序的generic softvtbench_tasks.json另列libero_10/spatial/object/goal各0–9，不能直接当四个soft/rigid suite mapping。实查object_soft config有10 tasks；task0为取white swirled soft pastry放basket，其asset soft_pastry001与旧alphabet_soup BDDL并存。

题数与数据	PDF宣称4,000 demonstrations、50+ assets；README旧v0.1是1,628 demonstrations（500/500/421/207）与33 assets，均非本轮实际下载数。20 Hz同步第三人称 / 腕部RGB、左右tactile RGB/marker motion、proprioception、language及binary/continuous gripper；FEM为evaluator-only。所读HDF5使用data/demo_*、actions、obs/eef_pose（xyz+wxyz）、obs/gripper_pos、states/deformable_object/<asset>/nodal_pos_w与soft_extras。assembly保留original_demo_id并按(task_id,demo_id)去重；缺success attr预设True，导入需额外验证。7D converter以xyz+axis-angle+单指gripper为state，接受7D或legacy8D action，13D force-in-action需另一converter；较短视频路径有随机drop state/action再切video的分支，不能宣称与PDF『无重采样』完全一致。模型7D、legacy8D、13D及server padded32D不可混为一种action space。
评估方式	goal checker逐个goals合取xy距离与(|Δz|−height_diff)<height_threshold；IN/ON尚共用此公式，force条件只在enable_force_threshold='True'且sensor存在时激活。task0阈值xy=0.2、height=0.2、force=0.05（原生模拟尺度），soft asset建置会跳过该rigid contact sensor。client预设30次推论×10动作、8连续success steps；但正式JSONL scorer取最后success_now，须核对其与experiment_success一致，且成功 / terminated会在debug记录前break。FEM正式metric_id=fem_rms_rigid_aligned_bbox_pct_v1，以首个节点状态作reference，proper Kabsch禁止reflection，D(t)=100×RMS位移 / reference bbox diagonal，D_peak=max_t D(t)。程序SafeSuccess=GoalSuccess且D_peak≤tau，未另检NoDrop，harness也禁用*_dropped；不能宣称符合PDF的drop即停。旧calibrator用0.5×max stable peak；例如soft_pastry001 tau=0.44692%，PDF表9的90th-percentile tau为7.6%，差异不是单纯改名。正式scorer重算HDF5 nodes、检JSONL metric ID；goal rate分母是已知goal episodes，safe rate分母是全部episodes，未知safety保留n_safe_unknown且不算safe。strict通过且分母一致前，goal_safe_gap不具有PDF TSR−DSR的精确语义。rigid诊断可令safe=goal，公表仍应保留N/A / 适用性。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **40** object/spatial ×soft/rigid task settings · 原文页 5, 6
- **4,000** expert demonstrations · 原文页 6
- **2,000** ID evaluation episodes · 原文页 7
- **1,800** OOD evaluation episodes / configuration · 原文页 8, 9

依这个顺序读

1. README.md ↗

   GitHub · TuojingAI/SoftVTBench · 58056111f0

   第一方作者身分、旧数据规模、v0.1模型范围与50次/task预算。

   L3–33 · L47–105 · L229–238 · L375–407

---

2. configs/benchmark_protocol_v1.json ↗

   GitHub · TuojingAI/SoftVTBench · 58056111f0

   正式程序protocol与README文字差异。

   JSON root

---

3. configs/object_soft/libero_object.json ↗

   GitHub · TuojingAI/SoftVTBench · 58056111f0

   task_id、language、native BDDL来源、goals、assets / regions与robot pose。

   JSON /task_suite_name · JSON /total_tasks · JSON /tasks/0

---

4. SoftVTBench/source/tac_manip/tac_manip/tasks/manipulation/libero/config/franka/franka_libero_env_cfg.py ↗

   GitHub · TuojingAI/SoftVTBench · 58056111f0

   JSON task reader、success term注册，soft对象跳过rigid contact sensor建置。

   L90–126 · L388–401 · L829–835

---

5. SoftVTBench/source/tac_manip/tac_manip/tasks/manipulation/libero/mdp/terminations.py ↗

   GitHub · TuojingAI/SoftVTBench · 58056111f0

   实际位置 / 高度 / 可用时contact-force合取；IN与ON共用位置近似。

   L103–169

---

6. SoftVTBench/benchmarks/common/closedloop_policy_inference.py ↗

   GitHub · TuojingAI/SoftVTBench · 58056111f0

   取出success后由client检查；runtime禁用timeout与object_dropped。

   L43–66 · L89–104

---

7. `SoftVTBench/benchmarks/openpi/openpi_inference_client.py` ↗
   GitHub · TuojingAI/SoftVTBench · 58056111f0

   action模式、30×10预算、8连续成功step与debug success_now字段。

   L555–594 · L726–789 · L2053–2069 · L2178–2186

---

8. `experiments/object_soft/replay_format/assemble_object_soft_replay_format.py` ↗
   GitHub · TuojingAI/SoftVTBench · 58056111f0

   native示范metadata、FEM summaries、success筛选及task/demo去重。

   L29–52 · L66–83 · L168–180 · L243–257

---

9. `SoftVTBench/benchmarks/common/convert_all_libero_to_lerobot_openpi.py` ↗
   GitHub · TuojingAI/SoftVTBench · 58056111f0

   7D / legacy8D转换、wxyz到axis-angle、视频对齐与13D拒绝条件。

   L122–176 · L257–348

---

10. `experiments/common/deformation.py` ↗
    GitHub · TuojingAI/SoftVTBench · 58056111f0

    metric ID、proper Kabsch去平移 / 旋转后的RMS与bbox百分比。

    L6–53

---

11. `experiments/common/calibrate_safety_thresholds.py` ↗
    GitHub · TuojingAI/SoftVTBench · 58056111f0

    旧版tau=0.5×最大stable compression peak，并非PDF的90th percentile。

    L1–10 · L36–89

---

12. `configs/safety_thresholds.json` ↗
    GitHub · TuojingAI/SoftVTBench · 58056111f0

    每asset的tau、d_ref、kappa、stable trial数及calibration版本。

    JSON root

---

13. `experiments/common/softvtbench_metrics.py` ↗

    GitHub · TuojingAI/SoftVTBench · 58056111f0

    正式HDF5/JSONL scorer、missing-evidence语义、百分比与不同分母。

    L55–98 · L109–225 · L233–274 · L302–331

---

14. `experiments/spatial_soft/evaluation/spatial_soft_safety_metrics.py` ↗

    GitHub · TuojingAI/SoftVTBench · 58056111f0

    此global-threshold旧档已deprecated，不能作正式scorer。

    L1–14

---

15. `SoftVTBench/benchmarks/common/metrics.py` ↗

    GitHub · TuojingAI/SoftVTBench · 58056111f0

    附加force诊断的local-frame定义及max其实为Top5%均值。

    L121–189 · L261–300

怎么接入我们的benchmark

可重用

具体task/config、native HDF5与视频索引、policy/evaluator通道分离、Kabsch FEM公式、per-asset门槛及explicit metric ID。

需要转换

source绑PDF v1与程序v0.1两个版本；environment记solver / scene / tactile assets；task以suite+native task_id+asset identity创建；case分demo、ID trial、OOD trial并保存paired seed / initial state。evaluator保留TSR/DSR与程序Goal/Safe label的版本关系，另记tau生成方法、reference nodes、百分比尺度、成功horizon及drop规则。domain依实际pick/place用途映射。附加force的squeeze=2min(|fLz|,|fRz|)，applied-force z扣除成对squeeze，*_max是非零Top5%均值，不映成物理peak。

仍需补齐

对应2608.18701的4,000版release / split manifest、90th-percentile calibration与rescorer、soft_stw_cuboid_hq等新版asset对照；drop termination及300-step协定闭合；terminal debug / sustained goal的对齐；数据与USD / Tabero tactile runtime资产取得验证；原生HDF5 success类型、跨root重复JSONL/HDF5及视频时间对齐。

P183 · WireCraft

WireCraft: A Simulation Benchmark for Industrial DLO Manipulation

文件 / 网站 · 主来源 · 原作 · 独立页面

限量primary discovery找到作者身分支持的WireManip/WireCraft，固定tree不截断且只含223 bytes / 4行README。README声明程序预计2026年11月初发布；当日2026-10-11尚无task、reader或scorer可核读，因此本篇处置为公开README占位，不再泛称没有候选，也不采用同名第三方项目。

> **版本与身份**
>
> pinned PDF June2026写upon acceptance；9月新建README改成2026年11月初发布计划，当日仍在未来。这是作者公告，非程序已公开或会准时发布的保证。本轮只抓小型metadata / README与两个作者页，未下载资产或运行上游。
>
> 收录arXiv:2606.18097v1，第一作者Chongyu Zhu、University of Toronto。既有精化搜索找到WireManip/WireCraft；本轮固定commit作者为GitHub ChongyuZhu，其公开profile同名且company=University of Toronto，README完整题名相符。共同作者Zachary Tang的第一方页也确认原论文与本人参与，但该页未直接连repo。作者身分证据足以提出高可信来源绑定候选，仍将绑定修改交协调者。

领域	装配与生产作业
环境	以下为论文规格，尚无repo实作可验证：Isaac Lab2.2.1 / Isaac Sim4.5，另声称验证5.1。DLO有PhysX D6刚性segment chain及FEM deformable两种表示，对齐task / connector界面而非声称材料参数等价。模拟支持UR5、Franka、Trossen Stationary AI；实体validation用UR5+Robotiq2F-85、腕部与侧视RGB、3D打印Ethernet接头 / task board。实体腕部force/torque sensor读值未用于policy，只需在sim匹配其几何offset。
任务	三个family为connector insertion、clip routing、channel seating。论文注册五种connector geometry，其中cylinder/cuboid/Ethernet/DisplayPort进入所报实验，USB-A为额外asset；不能把五个connector全当已评测tasks。clip difficulty最多3个clips；channel由5 segments组成，可为直线或每joint最多±20°弯曲。family、variant、fixture数、reset variation与episode均不同单位，无公开registry可确认精确全部task count。
题数与数据	论文称scripted、RL rollout、sim teleoperation、real UR5四种来源共用LeRobot-compatible schema。UR5 state/action各7D（6 joint+gripper），双RGB与instruction同步；这是论文语义，未取得实际feature keys、parquet/video path、dataset revision或reader。IL/VLA比较使用同一1,000条scripted insertion trajectories，非全benchmark总case数。RL另用42D privileged observation与Cartesian delta pose+gripper action，clip到[-1,1]再乘0.01；不与joint-space dataset action直接合并。原生physics dt=1/120 s、decimation=2、control=60 Hz，其他实体数据时间约定需待公开。

评估方式	只有paper-defined protocol：insertion分SRreach（夹持plug进入socket周边2 cm）及SRinsert（tip就座），不得以reach代替insert；3 mm是Ethernet测试clearance，不是插入成功阈值。clip需seated于clips；channel需超过80%线长在channel内，尚无公开离散化 / checker细节。RL报3 seeds的mean±std，8秒horizon；IL/VLA附录F用4 seeds×16 rollouts=64/checkpoint、800 simulator steps，不可与8秒 / 60 Hz budget预设等同。checkpoint以相同evaluation rollouts的reach success取前三，并非held-out validation选模；insert来自同checkpoint、未另优化。公开tree无可运行scorer，不能声称已核对这些条件的程序实作。

▼ **原作数字：保留论文的单位与页码**

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **3** industrial DLO task families · 原文页 3, 4
- **10** real Ethernet每metric/setting rollouts · 原文页 23, 25

依这个顺序读

1. `README.md` ↗

   GitHub · WireManip/WireCraft · 9acbc318c1

   完整题名及未来程序release计划；完整tree确证此commit仅README。

   L1–4

怎么接入我们的benchmark

可重用

可重用论文的task families / 变化轴、两种DLO表示、数据源分类及reach/insert/channel的不同度量；README作release追踪。

需要转换

source保留paper v1及placeholder commit；environment按simulation model / robot / physical setup分开；task按family+fixture/connector geometry；case在公开reset seed / episode manifest后创建。evaluator先标paper_specified、runtime_unavailable，保存native units、budget、policy可见信息及checkpoint选择协定。各data-source mixing实验保留R/S/P组成，不做语义等价合并。

仍需补齐

11月release是否履行、真正task registry / reader / concrete scorer、dataset与3D assets manifest / 授权、精确insert/clip判定、8秒vs800步预算对齐、各实验checkpoint / split closure。

P184 · DLO-Lab

DLO-Lab: Benchmarking Deformable Linear Object Manipulations with Differentiable Physics

内核内容已核读 · 主来源 · 原作 · 独立页面

已核读8-task registry、原生RL/DiffRL action与时间约定、coiling/lifting/wrapping的具体reward、trajectory aggregation，以及LeRobot导出 / 读取。原生episodic return、存活到horizon的diagnostic success及论文视频人工success三者不同；生成示范的过滤也只排除absorbing，不证明任务完成。

> **版本与身份**
>
> 固定2026-10-08的4af05620，晚于June2026 PDF，包含新的LeRobot输出及registry整理；未宣称与论文原始程序完全一致。envs/README称reward非负 / loss近似负reward是设计指南，具体lifting/wrapping程序有penalty与不同loss，标准化以实作为准。README的SharePoint资产与Mushroom-RL fork未下载；未运行模拟 / policy。
>
> arXiv:2606.04206v1 → dlo-lab-26.github.io第一方[Code] → UMass-Embodied-AGI/DLO-Lab；README列相同六位作者与2606.04206。项目页另一个zzyunzhi/template只是网页模板，不纳入benchmark source。

领域	装配与生产作业
环境	Genesis衍生的Taichi differentiable rod simulator，ROD material可设E/G、segment radius/mass、接触friction与塑性；场景配Franka、cones/posts、rings等。coiling具体为60个rod vertices、间距0.02 m、radius0.01 m与固定cone，control_idx=[1]在reset直接attached_to_gripper，不能视为已包含自由抓取成功。scene dt=0.001 s、substeps=5；一次policy action跨steps_interval个scene steps，须另保留此数与split，不以视频fps推控制频率。
任务	registry正好8个固定horizon任务：coiling、gathering、lifting、separation、slingshot、unknotting、wiring_post、wrapping。论文第6页另列Letter Art与Wiring-ring，属DLO agent的长时程分解实验，未在此8-task registry中，分开建task来源 / 协定。grasp候选、rod nodes、posts、robot arms与rollout次数都不是task数；未取得固定case manifest，案例总数不填虚构值。

题数与数据	RL privileged observation按(rope vertices+additional objects)×6+grasp points×14，包含位置 / 速度、末端pose及arm joints；RL action每control point 6D，先乘_act_magnitude、clip、L2限制，再拆xyz / rotation，Pink controller预设translation=m、rotation=degrees。DiffRL只有每point3D translation并从rope vertex反传，不能共享同一action schema。数据导出另统一为observation.state float32[16]、action[12]、action.joint[18]，单臂左侧zero padding；action排列[right_xyz,left_xyz,right_rot,left_rot]。相机front/wrist_right/wrist_left，单臂wrist_left为黑图，不是第三个真实视角。timestamp=step_idx×scene.dt×n_substeps_per_step；初frame有zero action，之后capture在step之后，末frame action/action.joint又拷贝前frame，必须保留原对齐。导出data/chunk-000/file-000.parquet、meta/info.json/stats.json/tasks.parquet、meta/episodes/...与videos/chunk-*/observation.images.<cam>/episode_*.mp4，split只声明train。filter reader只读consolidated file-000；需保持其前置条件。
评估方式	coiling reward=exp(−0.1Σv‖v−(0,0,0.15)‖)，是距离proxy而非绕圈成功。lifting reward=5×两环高度和+rope相对抬高项−0.5×rope到两环最近距离−100×末端距环小于0.08 m的penalty；loss_criterion另外含stretch loss，不能当相同分数。wrapping以xy-plane角度和 / 2π的绝对winding、与1圈的平方误差及到三柱最近距离超出0.015 m的penalty计reward。coiling eval_traj累加substep reward，另回final_reward及forward_time，NaN/failed final用survival_ratio−100；CMA可选cum或final做优化。PPO保存undiscounted return及末reward，diagnostic success_rate=(episode_length==n_outer_steps)，只是未提前失效。论文主表报固定budget内最大episodic return、3 seeds；附录像片人工success用每RL方法15条、GD1条、CMA最佳checkpoint的top15条。这些不是同一个自动success metric。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **10** DLO task definitions · 原文页 3, 4
- **8** 主固定horizon评测tasks · 原文页 5, 6
- **15** 附录RL每task evaluation trajectories · 原文页 18, 19

依这个顺序读

1. `README.md` ↗

   GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

   确认论文、外部assets、八task与本版添加数据导出流程。

   L3–39 · L68–81 · L154–209

2. `experiments/envs/registry.py` ↗

   GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

   实际唯一task→Train_Env subclass清单。

   L16–50

---

3. `experiments/envs/base.py` ↗

   GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

   scene dt / substeps、RL观测/action sizing、DiffRL的3D vertex控制。

   L30–108 · L298–353 · L418–439

---

4. `experiments/envs/env_coiling.py` ↗

   GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

   60节点scene、指定grasp vertex、exp-distance reward、NaN failure、sum/final return与observation。

   L42–80 · L111–134 · L149–204 · L326–351 · L353–469

---

5. `experiments/envs/env_lifting.py` ↗

   GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

   两环高度 / rope距离与gripper近距离penalty；differentiable loss不等于负reward。

   L188–272

---

6. `experiments/envs/env_wrapping.py` ↗

   GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

   封闭rope winding number、15mm柱半径距离penalty及不同优化loss。

   L211–262 · L341–414

---

7. `experiments/utils/controller.py` ↗

   GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

   Pink IK的translation公尺、rotation预设degrees与world target更新。

   L501–580

---

8. `experiments/trajopt/cmaes.py` ↗
   GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

   由eval_traj取得cum/final reward，依use_last_state_reward选CMA最佳轨迹。

   L90–123 · L292–334

---

9. `experiments/rl/rudinppo.py` ↗
   GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

   PPO使用undiscounted return；success_rate栏其实只是episode_length==horizon。

   L299–358

---

10. `experiments/datagen/config.py` ↗
    GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

    16D state / 12D action / 18D joints及单臂padding、相机字段。

    L10–30 · L100–153

---

11. `experiments/datagen/generate_dataset.py` ↗
    GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

    run_config reader、post-step数据截取、failed filter、T+1纪录与action时序。

    L77–126 · L135–211 · L335–417 · L570–608

---

12. `experiments/datagen/export.py` ↗
    GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

    实际parquet schema、视频template、v3 metadata与train-only split。

    L54–132 · L388–440 · L610–630

---

13. `experiments/datagen/filter_dataset.py` ↗
    GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

    单一consolidated parquet reader与episode/frame/video重编号。

    L40–73 · L197–255

怎么接入我们的benchmark

可重用

8-task registry、具体reward/loss、scene / material / control-point参数、macro/micro-step约定、LeRobot字段与frame/video reader。

需要转换

source保存此Genesis衍生commit及外部dependency / asset来源；environment按DLO拓朴、材料、fixture、robot/grasp attachment创建；task保存原goal文字与reward program。case保存seed、randomization、grasp indices、horizon、algorithm、sampling budget及checkpoint；evaluator分cum_return/final_reward、simulation-survival及人工task success。数据另记arm_present / camera_present mask、原raw action及缩放后物理action、前后state/action对齐，task名称去重不靠生成episode数。

仍需补齐

assets与Mushroom-RL/Pink等依赖的完整pin / 验证；论文视频success rubric / 标注及top15选择名册；完整task checker覆盖；LeRobot产生数据的action-time与SHAC格式验证；data generation仅依absorbing过滤且在n_envs>1时用obs0选action后tile给各env，不能直接视为独立闭回路成功示范。

P185 · RGBench

Real Garment Benchmark (RGBench): A Comprehensive Benchmark for Robotic Garment Manipulation featuring a High-Fidelity Scalable Simulator

内核内容已核读 · 主来源 · 原作 · 独立页面

这是服装模拟fidelity评测，不是学习policy的task-success榜。已核读98-capture registry、processed CSV / PCD reader、PyBullet fixed-point回放、具体Chamfer / stability计算与两阶段聚合；GarmentDynamics本体仍只有外部import插槽及已发布baseline数字。

> **版本与身份**
>
> 固定2026-07-30的5cc3d072。公开来源是evaluation harness加asset子集，不能将paper『Ours / mujoco_style3d』baseline当成此repo可跑的普通MuJoCo。比较脚本扫描所有timestamp run且aggregate时丢robot、按garment/action/simulator/mode平均，重复sample会被重复加权。n_samples亦非处处3。现有cloth params依GarmentDynamics拟合，跨sim使用须保留校准协定。未下载6.7GB数据、checkpoint或运行sim。
>
> arXiv:2511.06434v2（2025-11-12）首页 → rgbench.github.io → hwk0809/RGBench；README的AAAI2026题名与作者相符。网站模板eliahuhorwitz/Academic-project-page-template与Nerfies不算benchmark来源。

领域	衣物与洗护
环境	真实双臂衣物操弄capture与同一动作的cloth simulator配对。公开数据文件列Piper / RealSense D455，固定PDF则描述Piper或JAKA K1 / RealSense L515，应保存各版本capture硬件证据。fixed_point以录制末端位置驱动mesh anchors；robot mode包含robot tracking/contact。所读PyBullet wrapper在grasp/fold读取position并把grabber orientation固定identity，不能直接宣称完整6DoF姿态精确重放。普通MuJoCo仅fixed_point；GarmentDynamics不等于普通MuJoCo wrapper。
任务	Grasp、Fling、Fold三种原生动作；native case key=(garment,action,robot,sample_id)。静态解析完整experiment_library得到9 garment keys、98 entries、98个不重复data_subfolder。baseline CSV有105行：fixed_point三动作各21行，robot的fold/grasp各21行，缺robot-fling的21个cells；runner也明示fling只支持fixed_point。baseline只有7件衣物，grey_sunwear / khaki_blazer的数据仍有但未入baseline。PDF6k+ mesh assets=4k+自有工业assets+2k+ ClothesNet来源，不是6,000个task或capture；mesh分辨率variants亦不增加衣物数。

题数与数据	每capture含calibration/world_to_camera_transform.json、两臂joints/*joint_states_and_end_pose.csv、segment_pcds/pointcloud_<absolute_timestamp>_segmented.pcd；mesh另由HF来源供应。实际load_processed_data要求time、pos_1...pos_gripper，或pos_x/y/z、orn_w/x/y/z；文件列header.stamp.secs/nsecs及JSON position/name是另一层ROS输入约定，不可直接喂此reader。pose输出quaternion=wxyz，base_rotation_quat输入给SciPy用xyzw，位置以R_base_to_world.apply(local)+translation组合。PCD由camera_to_world=inv(world_to_camera)转世界座标，timestamp减master_start_time。main逐一遍历PCD，再用target_time+camera_delay+fling_prepare_time+fling_wait_time推进sim；不是重采样成共同FPS。保留原seconds、delay、sim step大小、record/calculation windows与point/vertex数。
评估方式	compute_cost输出单向Chamfer L1 sim→real及real→sim、L2 sim→real、双方向one-sided Hausdorff、sim_stability_score及两点云平均z差绝对值。Chamfer L1是每source point找Manhattan nearest distance后平均；L2用Euclidean距离而非平方距离，单位维持m。CPU/GPU对Nx3路径同义，但batch输入CPU只取[0]、GPU平均batch，不能未验证就扩成batched evaluator。stability实际将同一frame vertices[1:-1]与相邻vertex-index三点均值作L2偏差，再除总vertex数N，并非跨时间稳定性。HD委派point-cloud-utils且未传norm，PDF公式却写L1；pyproject只限>=0.30，本轮未锁定/核读该依赖版本的HD实作，norm一致性列为缺件。record window决定计算哪些frame，calculation window再按sim_time取mean/std；benchmark primary fidelity metric为cd_l1_r2s。空sim mesh frame会跳过，低于z门槛的vertices函数只警告仍原样返回。这些误差不能转成操作success率。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **6,000** garment assets · 6,000+ · 原文页 1, 3
- **3** manipulation primitives · 原文页 4, 5
- **9** real comparison garment types · 原文页 5, 13

依这个顺序读

1. `README.md` ↗

   GitHub · hwk0809/RGBench · 5cc3d07209

   公开范围、两种actuation mode、asset / capture授权与论文身分。

   `L15–38 · L143–154 · L327–354 · L423–449`

2. `configs/experiment_library.yaml` ↗

   GitHub · hwk0809/RGBench · 5cc3d07209

   原生(garment,action,robot,sample) key、capture路径、camera delay及两个时间窗。

   L1–45

3. `configs/main.yaml` ↗

   GitHub · hwk0809/RGBench · 5cc3d07209

   Hydra registry binding、数据 / calibration path与实际mode / delay设置。

   L8–44 · L47–98 · L116–124

4. `configs/cloth_params/green_tshirt.yaml` ↗

   GitHub · hwk0809/RGBench · 5cc3d07209

   mesh resolution、物理参数与shoulder vertex ID；不能混用其他mesh的index。

   L1–22

5. `rgbench/csv_data.py` ↗

   GitHub · hwk0809/RGBench · 5cc3d07209

   真实reader要time/pos_* / orn_*处理后字段，并做base transform与起点裁切。

   L24–78 · L465–558

6. `rgbench/transforms.py` ↗

   GitHub · hwk0809/RGBench · 5cc3d07209

   相机外参的反矩阵、手眼refinement与缺档时identity fallback。

   L79–123

7. `rgbench/envs/__init__.py` ↗

   GitHub · hwk0809/RGBench · 5cc3d07209

   选择具体PyBullet/IsaacSim/MuJoCo wrapper，GarmentDynamics属外部closed-source dependency。

   L6–55

8. `rgbench/envs/pybullet/cloth_pybullet_fixed_point_env.py` ↗

   GitHub · hwk0809/RGBench · 5cc3d07209

   以CSV pose驱动固定vertex anchor、time stepping及世界座标mesh读取。

   L41–78 · L115–123 · L184–249 · L336–376 · L429–482

---

9. `scripts/run_benchmark.py` ↗

   GitHub · hwk0809/RGBench · 5cc3d07209

   依每个真实PCD timestamp推进sim、计算方向性cost，再依calculation window汇总。

   L45–86 · L165–244 · L259–286 · L302–376

---

10. `rgbench/metrics.py` ↗

    GitHub · hwk0809/RGBench · 5cc3d07209

    Chamfer L1/L2具体nearest-neighbor与单帧vertex-index stability。

    L17–39 · L59–88 · L91–122 · L125–176

---

11. `rgbench/visualization.py` ↗

    GitHub · hwk0809/RGBench · 5cc3d07209

    以sim_time过滤calculation window，再对frame等权mean/std。

    L252–295

---

12. `rgbench/output.py` ↗

    GitHub · hwk0809/RGBench · 5cc3d07209

    metrics.csv尾端mean/std列与index=False的输出约定。

    L110–124

---

13. `scripts/compare_to_paper.py` ↗

    GitHub · hwk0809/RGBench · 5cc3d07209

    取iloc[-2]后依cell平均、baseline join与rank；重跑sample未去重。

    L49–127

---

14. `results/paper_baselines.csv` ↗

    GitHub · hwk0809/RGBench · 5cc3d07209

    baseline长表keys与实际n_samples可为2，不能一律假设3。

    L1–6

---

15. `results/README.md` ↗

    GitHub · hwk0809/RGBench · 5cc3d07209

    7件baseline garments、105/126涵盖与GarmentDynamics不可由此repo重现。

    L13–36 · L61–93

怎么接入我们的benchmark

可重用

98个capture registry / 每case时间窗、world calibration、CSV pose与PCD reader、BaseEnvWrapper到具体sim stepping、方向性Chamfer与result schema。

需要转换

source分capture dataset、工业asset subset、ClothesNet重用与code commit；environment保存sim engine/version/mode、robot / sensor、mesh/material；task记动作primitive；case用capture key，simulator/mode/mesh resolution是trial条件。evaluator分direction/norm/unit、raw frame errors、window mean/std及跨sample mean。保存case frame coverage、camera delay与calibration SHA；不要把105列baseline或不同sim run倍增case。raw ROS→processed CSV明示转换，保持wxyz/xyzw与base-transform方向。

仍需补齐

HF capture / mesh与校准档的实际revision及完整性验证；GarmentDynamics本体、完整工业library与不同component条款；HD norm / 依赖pin；spatial vertex-order stability的指针命名或实作厘清；数据文件与processed CSV / capture硬件版本对齐；重跑sample去重、mean/std尾列存在性与跳过frame的coverage检查。

P186 · BiFold

BiFold: Bimanual Cloth Folding with Language Guidance

内核内容已核读 · 主来源 · 原作 · 独立页面

BiFold同库含ICRA原作和加入时间上下文的workshop版本；可复用语言/双手pick-place标注与SoftGym评估，但像素预测分数和物理折叠结果要分开。

> **版本与身份**
>
> 固定0b763d1，README同时连2501.16458和2505.07600；只有列出片段经核读，未把workshop额外设置并为原作新task。

领域	衣物与洗护
环境	客制SoftGym/PyFlex，加载CLOTH3D衣物；VR folding为父双手数据，真实图像另一路径。重贴texture/render与顺序版衍生数据不当成独立物理场景。
任务	单手/双手语言折叠，包含逐步与rollout评测；左右pick/place是动作字段，不是4种独立任务。原作与temporal extension各自保留合法history设置。
题数与数据	vr_folding_dataset.zarr配actions/<partition>.csv，含left/right_grip_from/to、end_idx与text；3D vertex经相机矩阵投到pixel、depth依depth_scale还原。frame_start/frame_end是case对齐基础，未来end位置只作GT label，不能自动暴露给policy。
评估方式	同初态先跑oracle、再跑model；成功为平均对应particle距离<2×particle_radius，另报mask IoU及50/80/90门槛，task分组后macro平均。KeypointMSE实作是最近点L2距离且另除valid数量，不能直接当一般MSE；真实图像预测分数亦不是实体折叠成功。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **7,000** parsed bimanual folding actions（约数） · 原文页 3
- **1,000** unique prompts（>1K） · 原文页 3

依这个顺序读

1. README.md ↗
   GitHub · Barbany/bifold · 0b763d16ef

   两篇版本、SoftGym/CLOTH3D、VR folding和真实图像来源

   L1–25 · L56–63 · L99–167

---

2. bifold/data/bimanual_dataset.py ↗
   GitHub · Barbany/bifold · 0b763d16ef

   Zarr+CSV、camera矩阵、左右手vertex→pixel及start/end frame

   L19–52 · L117–206

---

3. bifold/env/softgym_evaluator.py ↗
   GitHub · Barbany/bifold · 0b763d16ef

   具体双手物理评测、oracle目标与粒子/IoU门槛

   L27–49 · L78–87 · L103–128 · L423–469 · L527–624

---

4. bifold/metrics/utils.py ↗
   GitHub · Barbany/bifold · 0b763d16ef

   模拟mask IoU是0–100

   L1–7

---

5. bifold/metrics/__init__.py ↗
   GitHub · Barbany/bifold · 0b763d16ef

   图像IoU与名称KeypointMSE的实际公式

   L76–125

怎么接入我们的benchmark

可重用

Zarr/CSV/相机投影、原生partition、oracle相同初态比较与各metric公式。

需要转换

case固定cloth asset/config/state、文字、history与相机；分开标注预测/物理粒子误差/视觉IoU；VR与CLOTH3D lineage保留，衍生render与顺序数据去重。

仍需补齐

资产/原生split取得、temporal版本切分、GT多解/粒子对应有效性、KeypointMSE分母确认、真实成品与simulation重现。

P187 · SSFold

SSFold: Learning to Fold Arbitrary Crumpled Cloth Using Graph Dynamics from Human Demonstration

文件 / 网站 · 方法 / 综述 · 原作 · 独立页面

已找到SSFold的网站源代码，确认同作者与同篇研究；真正Code仍指向取得404的SSFold-main，不能把网站repo当作graph-dynamics训练/评测实作。

> **版本与身份**
>
> 网站213f5e9；Code链接zcswdt/SSFold-main于本次回404。网站arXiv按钮连作者GitHub profile，正式paper URL沿用已核对2411.02608，不采错链接。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	真实UR5折布，从皱褶初态开始；网站表示跨颜色/形状/刚度测试，但未提供可解析scene/物理初态清单。
任务	合并摊平与折叠、sequential pick/place及partial point-cloud connectivity；原作网站主要报4种folding tasks。示范视频与generalization展示不直接当额外独立task数。
题数与数据	作者Data链接为Google Drive，网站媒体及图标已可读；未取得完整human demonstrations/graph/action schema、split/episode ID与坐标尺度。
评估方式	网站报4种折法的原作成功率，缺公开grader与trial明细时无法重算或判断分母。graph预测误差、terminal折法与real success须分别规格化。

依这个顺序读

1. README.md ↗

   GitHub · zcswdt/SSFold · 213f5e9841

   明示SeqSpatialFold Website

   L1–1

2. `index.html` ↗

   GitHub · zcswdt/SSFold · 213f5e9841

   精确题名/作者、数据与失效code入口、4种UR5折法

   L68–84 · L143–178 · L184–222

怎么接入我们的benchmark

可重用

四种主task与皱褶→成品设计、partial-observation graph概念、作者原始数据入口。

需要转换

先登录source/task规格，case需cloth/初态/示范/目标折法/动作预算和物理checker；可见connectivity与隐藏真实mesh分隔。

仍需补齐

SSFold-main可取得实作、Drive数据manifest、graph/action/标定格式、成功/摊平及折法判定规则与测试split。

P188 · DRAPER

DRAPER: Towards a Robust Robot Deployment and Reliable Evaluation for Quasi-Static Pick-and-Place Cloth-Shaping Neural Controllers

内核内容已核读 · 主来源 · 原作 · 独立页面

DRAPER的来源分散在SoftGym扩充、Agent-Arena和real-robot界面；两个仓库已有改名。需固定三者版本、数据模式与task config，不能把同一布料环境的fork视为独立benchmark。

> **版本与身份**
>
> softgym-deepcloth解析到halid1020/softgym(8a21966)，agent-arena-v0解析到actoris_harena(4d9c9c9)，硬件库405d4c2；目前generic框架不等于原论文固定实验release。

领域	衣物与洗护
环境	共用SoftGym布料整形与realadapt towel场景；realadapt config声明1000variation，但eval tier只取30、val取3。Franka/UR3e是另一硬件界面层，未运行。
任务	主要布料摊平/整形及跨sim-real适应；domain字符串如rainbow-rectangular-fabrics是布料分布设置，不是生活用途domain。多论文共享initial_states需创建reuse关系。
题数与数据	TrajectoryDataset以observation/action/goal/trajectory_lengths存数据，T+1观测对T个action并附terminal补0；whole/cross-trajectory模式与goal索引需验证。实机界面RGB由BGR转换，v1/v2 depth作单frame min-max并将背景置1，已非metric depth；action为4个[-1,1]pick-place座标另带orientation。
评估方式	Towel flattening成功需要keypoints全可见且normalized coverage≥0.99，canonical模式另加IoU。记录coverage/improvement/形状距离与首次成功步；perform_single可因environment done、agent terminate/success、arena success或max_steps终止，因此done不等于完成。当前towel.step调用reward参数数目与定义不同，正式adapter需修正/验证。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **3** fold pattern definitions · 原文页 5, 6
- **10** UR3e ablation trials per setting · 原文页 6

依这个顺序读

1. `README.md` ↗
   GitHub · halid1020/softgym · 8a2196648c

   DRAPER/其他论文共用扩充与初态数据

   L1–7 · L32–46

---

2. `README.md` ↗
   GitHub · halid1020/actoris_harena · 4d9c9c9273

   Agent-Arena与共用SoftGym关系

   L1–19 · L41–45

---

3. `agent_arena/api.py` ↗
   GitHub · halid1020/actoris_harena · 4d9c9c9273

   eval configs与checkpoint、已存在结果跳过

   L80–127

---

4. `agent_arena/arena/softgym/builder.py` ↗
   GitHub · halid1020/actoris_harena · 4d9c9c9273

   domain/task/action/picker设置解析

   L7–62

---

5. `agent_arena/arena/softgym/builders/fabric_domain_builder.py` ↗
   GitHub · halid1020/actoris_harena · 4d9c9c9273

   flattening接线与1000variation中30eval/3val

   L99–112 · L298–318

---

6. `agent_arena/arena/softgym/tasks/rect_fabric/towel_flattening.py` ↗
   GitHub · halid1020/actoris_harena · 4d9c9c9273

   可见性/coverage成功与多种progress metrics

   L18–55 · L93–162

---

7. `agent_arena/utilities/perform_single.py` ↗
   GitHub · halid1020/actoris_harena · 4d9c9c9273

   终止、成功、动作耗时与逐步评估

   L7–126

---

8. `agent_arena/utilities/trajectory_dataset.py` ↗
   GitHub · halid1020/actoris_harena · 4d9c9c9273

   T+1观测/terminal action补0与不同window模式

   L224–269 · L325–374

---

9. `README.md` ↗
   GitHub · halid1020/robot_control_cloth · 405d4c2ae4

   DRAPER的ROS硬件界面角色

   L1–7

---

10. `interface/agent_arena_interface.py` ↗
    GitHub · halid1020/robot_control_cloth · 405d4c2ae4

    normalized pixel action及real-depth转换

    L96–125 · L140–186

怎么接入我们的benchmark

可重用

明确arena配置、eval/val初态索引、source改名关系、T+1 trajectory和real-depth/action转换。

需要转换

source分方法/框架/模拟/硬件repo角色；case固定init-state hash、观测尺度、像素顺序、policy checkpoint与停止条件；保留整形metric各自分母。

仍需补齐

原DRAPER paper-era configuration/checkpoint对照、repo版本兼容、reward/trajectory mode界面验证、初态资产与全部pipeline重现。

P189 · GPT-Fabric

GPT-Fabric: Smoothing and Folding Fabric by Leveraging Pre-Trained Foundation Models

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

GPT-Fabric的folding、smoothing与physical分三库。Folding比较多种合法expert终态，smoothing衡量覆盖；这些不能合并成同一成功率。

> **版本与身份**
>
> folding102f4ce、smoothing06d9592、physical e0e6195；README提旧model版本变动只是历史信息，本次未调用LLM API或运行robot。实机库本轮只核对README入口，内核核读限两个模拟分支。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	SoftGym/PyFlex方形/矩形布料，沿用Foldsformer初态与demonstration sub-goals；相同config与expert reference保持父来源关联。实机库另有平台专用程序。
任务	4种原生folding样式及smoothing；每个fold可有多个合法终态。smoothing的trails参数是pick-place步数，并非多次独立episode或题数。
题数与数据	cached配置、expert info-*.pkl、model info.pkl、示范子目标与query消息构成评测数据；每种reference fold只是同题多解。smoothing输出message_step.jsonl和[coverage,improvement] CSV，3位小数为输出格式；GIF跳frame倍速不代表控制时间。
评估方式	fold每次run对8/9/16个expert粒子终态取最小平均距离，再对run和config平均，输出乘1000为mm；不取最低run当主结果。smoothing分(A−A0)/(Amax−A0)与A/Amax，前者Amax=A0需处理。naive loop传last_step_info=None，即使回传history也不能假设每模式有上一动作提示；LLM model/prompt/API失败处理须固定。

依这个顺序读

1. `README.md` ↗
   GitHub · slurm-lab-usc/GPT-fabric-folding · 102f4cec4f

   论文身分、Foldsformer父初态/子目标、多合法expert结果

   `L1–10 · L43–71`

2. `slurm_utils.py` ↗
   GitHub · slurm-lab-usc/GPT-fabric-folding · 102f4cec4f

   8/9/16种expert终态的最小粒子误差

   L71–117

---

3. `eval.py` ↗
   GitHub · slurm-lab-usc/GPT-fabric-folding · 102f4cec4f

   run×config结果与最终mean非best-of-run

   L234–279

---

4. `README.md` ↗
   GitHub · slurm-lab-usc/GPT-Fabric-Smoothing · 06d9592abf

   smoothing入口、trails是动作数、GIF速度

   L1–10 · L39–75

---

5. `softgym/envs/cloth_flatten.py` ↗
   GitHub · slurm-lab-usc/GPT-Fabric-Smoothing · 06d9592abf

   面积/范式改善/相对最大面积的三种度量

   L180–214

---

6. `RGBD_manipulation.py` ↗
   GitHub · slurm-lab-usc/GPT-Fabric-Smoothing · 06d9592abf

   primitive运行、历史/输出、coverage CSV及GIF抽frame

   L1432–1459 · L1658–1687 · L1699–1713

---

7. `README.md` ↗
   GitHub · slurm-lab-usc/gpt-fabric-physical-experiments · e0e6195604

   实机专用入口，非可直接移植到别人的平台

   L1–6

怎么接入我们的benchmark

可重用

多合法目标、原生粒子/coverage metrics、VLM消息与几何primitive的接线范例。

需要转换

case固定init/config、合法示范/提示、expert目标集合、动作与query预算；来源渲染/示范去重；物理结果、VLM格式有效性、延迟/查找次数分开报。

仍需补齐

完整数据取得、历史模型/提示版本、API失败分母、coverage零分母、实机成品scorer/平台标定与重现。

P190 · UniGarmentManip

UniGarmentManip: A Unified Framework for Category-Level Garment Manipulation via Dense Visual Correspondence

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

UniGarmentManip透过衣物dense correspondence把示范动作转到新衣物。程序提供3类衣物/3种代表任务的研究框架，但数据配对样本与实际操控episode须分开。

> **版本与身份**
>
> 固定fe15994，CVPR2024原作；本次核读双手fold链与共用correspondence reader，未声称所有支线及实机实验已重现。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	GarmentGym/PyFlex衣物模拟；3种衣物类别、单/双臂、flat/messy与多步设置属不同变化维度，不以笛卡儿积当全部已验证场景。
任务	主要unfolding/fling、folding、hanging；训练dense correspondence是支持方法，两point cloud或20对correspondence不是20个robot任务。
题数与数据	HDF5有points/colors/vertices/visible_vertices/visible_indices、camera_intrisics/camera_extrisics、rgb/depth/faces。reader按mesh与deform层配对，__getitem__交替cross-shape/cross-deform，从visible vertices找20对correspondence。converter将.pkl换成h5漏了点，但reader只找.h5，需核对/修正文件名契约。
评估方式	动作从demo点的normalized feature相似度argmax映射到新point cloud，再投影回world控制；fold checker先等稳定，按final/init coverage比例与肩/袖/角点距离判定，各fold type门槛不同。此为几何启发式，不直接验证层拓扑；GT mesh indices只供训练/判分不能直接作policy观测。

依这个顺序读

1. README.md ↗
   GitHub · luhr2003/UniGarmentManip · fe15994326

   原作、3类/3任务及数据/环境/示范模块

   L1–43

---

2. train/dataloader/preprocess/pickle2h5.py ↗
   GitHub · luhr2003/UniGarmentManip · fe15994326

   原始record→HDF5字段与输出文件名

   L15–42

---

3. train/dataloader/dataloader.py ↗
   GitHub · luhr2003/UniGarmentManip · fe15994326

   mesh/deformation配对、可见性GT与对应点采样

   L81–109 · L234–255 · L338–366 · L403–407

---

4. task/fold/double_from_flat.py ↗
   GitHub · luhr2003/UniGarmentManip · fe15994326

   示范/mesh固定、特征相似点→world pick/place与环境checker

   L101–152 · L198–232

---

5. garmentgym/garmentgym/env/bimanual_fold.py ↗
   GitHub · luhr2003/UniGarmentManip · fe15994326

   具体funnel/simple折法的area与语义keypoint距离规则

   L608–727

怎么接入我们的benchmark

可重用

mesh/deformation/visibility配对结构、示范到控制的几何转换、已读两种fold成功条件。

需要转换

source按garmentUID与deformationID分层，case保存示范串行/目标fold/相机/mesh尺度；将point-correspondence训练example与robot rollout分别计数。

仍需补齐

衣物/示范split、文件名和schema一致性、完整hanging/fling与其他fold checker、坐标单位/动作预算与跨衣物重现。

P191 · ClothesNet

ClothesNet: An Information-Rich 3D Garment Model Repository with Simulated Clothes Environment

实作尚未确认 · 主来源 · 原作 · 独立页面

ClothesNet官方页面可核对3D衣物及标注格式，下载须走作者表单；目前没有确认其官方GitHub，Google Sites依赖和同名旧研究已排除。

> **版本与身份**
>
> 官方Google Sites页与2023原作题名/作者相符；google/safevalues是网站依赖，lixiangbao/ClothesNet_PyTorch自述为另一篇2018人体衣着生成实作，皆未当作本篇code。

领域	衣物与洗护
环境	约4400个3D garment models、11衣物类别，作模拟场景的资产来源；garment model不是robot环境或完整评测episode。
任务	衣物感知：分类、boundary segmentation、keypoint detection；robot交互方向：rearranging/folding/hanging/dressing。用途方向与11衣物类别不相乘当已定义task数。
题数与数据	每衣物folder含mesh OBJ/MTL/texture、边界OBJ/MTL、10个keypoint的PCD与2048个sampled mesh points。官网约4400是原作量，未下载资产，没有据此生成4400case。官方数据条款限非商业科学研究且禁止转发/分发。
评估方式	官网说明感知及robot交互基准，但未确认可取的完整evaluator/code；需原作split、keypoint语义对应、成功predicate及物理参数才可接入完整robot评测。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **4,400** garment meshes（约数） · 原文页 4
- **3,051** ClothesNetM meshes · 原文页 4
- **496** 3D classification test meshes · 原文页 6
- **3** clothes-understanding endpoints · 原文页 6

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

原始衣物UID、类别/边界/关键点等标注结构与可引用的原作下加载口。

需要转换

以source+garment ID登录asset并关联environment/task；metadata与我们的规格独立发布，原始衣物数据报保留官方下载方式与条款，未获允许前不纳入再分发包。

仍需补齐

作者数据取得、确切文件manifest/单位/标注顺序/物理参数、split/evaluator、原始数据再分发授权。

P192 · Phys-Liquid

Phys-Liquid: A Physics-Informed Dataset for Estimating 3D Geometry and Volume of Transparent Deformable Liquids

内核内容已核读 · 主来源 · 原作 · 独立页面

Phys-Liquid提供液体几何/尺度估计reader及F-score/voxel IoU程序，但README的总量仍是N占位、完整下加载口TBD；不能把样本库视为完整benchmark已取得。

> **版本与身份**
>
> 固定2d4e3c8，AAAI26 source/sample repo；split_data.py只是指定结果文件夹拷贝工具，没有据此宣称已取得完整train/test。

领域	实验室操作
环境	模拟实验室透明液体/容器，颜色、照明、场景与旋转设置；六张生成/重建视角属同一样本的观测，不增加六个环境。
任务	透明液体segmentation、多视角mask、3D reconstruction及metric scale/volume估计；属于感知/量测任务，不直接验证robot倒水或吸液完成。
题数与数据	sample/frame目录有multiview_images.png、volumes.json、real_volume.json；拼图切成6×256²。pseudo volume乘1e-6、width乘1e-2；label_mode可为体积比、三轴比、算术/几何平均，需记模式与单位。缺档/GT会跳过，README没有可用总量数字。
评估方式	F-score先各自质心对齐，随机采10000surface points，以距离门槛(预设0.02)算precision/recall；不测绝对位置误差。frame缺pred/GT/加载错误被略过，再sample内均值→sample间均值。voxel IoU以各网格grid_index相交，shared origin/voxel尺度需验证；这些都不是task成功率。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **5** lab scenes · 原文页 3, 4
- **100** simulation configuration sequences · 原文页 3, 4
- **10** held-out sequences · 原文页 4
- **97,200** RGB与mask image files合计 · 原文页 3, 4

依这个顺序读

1. README.md ↗
   GitHub · dualtransparency/Phys-Liquid-AAAI · 2d4e3c8770

   原作、四阶段重建与sample/full release状态

   L1–36

---

2. volume_estimate/dataset.py ↗
   GitHub · dualtransparency/Phys-Liquid-AAAI · 2d4e3c8770

   sample/frame结构、6视角拼图、体积/尺度ratio标签

   L9–108 · L113–140

---

3. metrics/F-Score.py ↗
   GitHub · dualtransparency/Phys-Liquid-AAAI · 2d4e3c8770

   质心对齐、点采样、距离门槛与跳过/聚合分母

   L10–94 · L112–189

---

4. metrics/volume_iou.py ↗
   GitHub · dualtransparency/Phys-Liquid-AAAI · 2d4e3c8770

   mesh体素化与grid-index IoU

   L20–50

---

5. split_data.py ↗
   GitHub · dualtransparency/Phys-Liquid-AAAI · 2d4e3c8770

   手列13个结果目录拷贝，非完整split生成协定

   L1–60

怎么接入我们的benchmark

可重用

具体label生成、前处理与原生几何metrics，可作universal benchmark的量测能力来源。

需要转换

case_id连到物理sample/frame与view；保存原始/重建mesh、座标/单位/scale mode，GT只给scorer；报attempted/valid/skipped与metric seed，避免有效子集分母混淆。

仍需补齐

完整公开数据/精确数量、正式split manifest、物理单位、voxel共同grid、sample间相依性与task级液体操作验收。

P193 · GRIP

GRIP: A General Robotic Incremental Potential Contact Simulation Dataset for Unified Deformable-Rigid Coupled Grasping

内核内容已核读 · 主来源 · 原作 · 独立页面

GRIP有柔性/刚性抓取HDF5结构和Finray可视化程序；整体10万姿态与8子集是不同于目前公开Finray范围的声明。完整生成/评分pipeline尚未发布。

> **版本与身份**
>
> 固定56a4520；README计划仅勾Finray，其他子集/生成pipeline未勾，虽写完整dataset链接仍需依实际发布manifest核对。未把100frames或renderer输出当独立case。

领域	通用对象与机动作业
环境	IPC柔性–刚性耦合抓取，手型与material分子集；overview记1200objects/100000poses。finray_soft_837与finray_rigid_710可能共用object ID，不直接相加当独立对象或环境。
任务	抓取及stress-field等下游学习来源；每个pose/手型/材质形成具体抓取设置。双手/单手子集与对象变体不直接增加语义task。
题数与数据	HDF5分object_config(密度、Young模数、Poisson比、摩擦)和trajectories(关节/SE3/mesh/contact)。Finray文件称每H5有20个成功trajectory、每条100frame，前40抓取、后60作重力验证；是已筛成功的数据，不可从此推未筛候选的成功率。未下载大archive。
评估方式	本库没有完整生成/失败判定程序，不能重现10万候选的过滤率。visualizer有soft分支rajectories/object_points拼字，object_type在README称类别但程序用rigid判material；contacts文件语义与viewer矢量相加用法仍需核定。record_fps24只决定输出视频，不是simulation timebase。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **1,200** unique selected objects，800+800−400 · 原文页 1, 4
- **100,000** grasp poses（概要数） · 原文页 1
- **4** stressprediction held-out objects · 原文页 6

依这个顺序读

1. README.md ↗

   GitHub · BeLI0o/GRIP_Dataset · 56a4520167

   原作、公开计划、object/hand/material阶层与成功过滤轨迹

   L1–35 · L61–100 · L107–188

---

2. scripts/finray_h5_visualizer.py ↗

   GitHub · BeLI0o/GRIP_Dataset · 56a4520167

   真实HDF5路径、pose/time索引、刚/柔分支与渲染clock

   L143–227

怎么接入我们的benchmark

可重用

object/material参数、pose/time结构、mesh及contact纪录，作柔性物task/资产来源。

需要转换

用objectUID+hand/material+poseID形成instance，frame作其轨迹；记successful-only选择条件、未筛样本来源和力/位置/时间单位；修正或版本化reader而不更改原始bytes。

仍需补齐

完整/已公开子集manifest、生成/验收器、失败数据、HDF5类型/单位实测、viewer路径和object_type对应。

P194 · Cloth gripper interface

A Simple Gripper Interface for Simulator-Agnostic Cloth Manipulation

实作尚未确认 · 方法 / 综述 · 原作 · 独立页面

这篇提供模拟器无关的cloth gripper概念界面，适合参考action contract；原文未提供可确认的GitHub，不能当成已取得的跨模拟器adapter。

> **版本与身份**
>
> 已读2609.29340v2 p3–4；原文Drive链接为示例素材，cached精确gripper-interface搜索未确认GitHub。只登录方法/界面参考，没有假造code路径。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	原文在constraint-based不可伸长四边形cloth mesh模拟；说明如何接position/force/constraint三类solver，并非已验证所有backend等价。
任务	两种grasping volume：box pinch与square-pyramid point grasp；属抓持模型选项，没有因此添加两种完整折布task或case库。
题数与数据	指令由gripper位置/四元数/jaw state组成；在open→closed时用local-volume内的节点、面中心和边中心挑grasp support，保存local座标直到open清除；squeeze按数个simulation steps插值。尚无可取原生程序、trajectory schema或split。
评估方式	原文比较抓持策略/可控性与计算成本；抓持用移动位置约束，没有计算夹爪压力、摩擦或完整局部变形。此模型的稳定抓持不等于真实摩擦/滑脱测试通过。

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

清楚的pose/jaw/grasp-region契约与solver适配概念。

需要转换

environment必存grasp_model、mesh分辨率、抓持集合与squeeze时间；action记local/world pose及jaw edge；不同backend分别验证，不将相同函数名称当物理等价。

仍需补齐

作者实作、solver界面、原生评测数据与可重现案例；压力/摩擦/滑脱/恢复能力另需支持的物理模型。

P195 · World models for unfolding

Learning to unfold cloth: Scaling up world models to deformable object manipulation

文件 / 网站 · 方法 / 综述 · 原作 · 独立页面

已找到与论文题名、三位作者相符的项目网站repo；其方法/结果区仍是模板文字，未包含Unity/Obi/DreamerV2实作。

> **版本与身份**
>
> 网站a7b0550为2024版本，论文2602.16675于2026收录；题名/作者相符但网站不能证明2026实验程序已公开。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	论文Unity/RFUniverse Gym界面与ObiCloth，固定一个cloth corner、Franka在空中展开；与桌面flattening有不同物理设置和目标。
任务	主目标为in-air unfolding，5种garment types×4种agent设置=20个trained agents，不能称20种新任务。
题数与数据	原文每step两张64×64×3图像，加EEF xyz/gripper width/张力boolean；action为4维[-1,1]位移与jaw控制。RGB/normal image及replay-buffer版本分开；每agent1M训练step不是1M评测case，完整数据/episodes未取得。
评估方式	原文用4×4网格估计unfold面积proxy、除最大值并加时间penalty；失败/近成功/成功按episode内最高unfold量分类，与末态/持续成功不同。没有scorer程序就无法核验门槛与投影/面积实作。

依这个顺序读

1. `README.md` ↗

   GitHub · jrome5/Learning-to-unfold-cloth.github.io · a7b0550ec3

   网站repo题名

   L1–2

2. `docs/index.html` ↗

   GitHub · jrome5/Learning-to-unfold-cloth.github.io · a7b0550ec3

   作者/abstract相符，主要内容仍为placeholder

   L7–30 · L33–68

怎么接入我们的benchmark

可重用

原文action/observation界面、固定角约束、5garment×4agent对照与最高进度评估。

需要转换

case固定pinned corner/cloth parameters、输入RGB或normals、张力信息来源与budget；保存maximum progress和final state分项，标明privileged observation。

仍需补齐

真正方法repo、Unity/Obi资产/界面、demo/replay与split、成功界线/scorer、原生重现与跨backend可比性。

P196 · Deform360

Deform360: A Massive Multi-view Visuotactile Dataset for Deformable World Models

内核内容已核读 · 主来源 · 原作 · 独立页面

Deform360有明确多视角/触觉对齐与annotation contract，可直接作数据层参考；README明示world-model训练、baseline和checkpoint未公开。

> **版本与身份**
>
> 固定d8522a4；所读公开库定位access/preprocessing/annotation/alignment，未把能生成annotation推论为已发布world-model baseline。

领域	衣物与洗护
环境	BRICS capture dome真实柔性物交互；原作198对象/13类、1980交互，41同步RGB相机及4组16×32触觉sensor。13对象类别不是13生活domain，41views不是41episodes。
任务	柔性物世界模型/多视触觉研究数据；dataset utility提供对齐和annotations，不等同机器人物理任务registry或已发布的world-model benchmark runner。
题数与数据	原作215.7h、约23.3Mframes须保留其跨视角统计口径。episode/<camera>/undistorted.mp4与K/c2w、aligned timestamps、provenance hash；预设检查相机frame/timeline一致。H5键data：mask bool/uint8二值、depth uint16毫米且0无效、velocity m/s；不可像RGB除255。
评估方式	这些检查验证数据形状/时间/校准一致性，不是world-model或robot成功分数。触觉nearest配对保留match/accepted/duplicate信息，未接受格补0须连valid mask使用；用于预测task时另外限制query以前的可见数据。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **198** deformable objects · 原文页 5, 6
- **1,980** physical interaction episodes · 原文页 6
- **74,850** 同步/品质filter后view videos · 原文页 6
- **215.7** 累加多视角video hours · 单视角行为20,483秒约5.69h，非215.7h独立行为 · 原文页 6

依这个顺序读

1. README.md ↗
   GitHub · lhy0807/deform360 · d8522a4403

   198objects/1980interactions/41camera与release scope

   L1–85

---

2. deform360/dataset.py ↗
   GitHub · lhy0807/deform360 · d8522a4403

   相机K/c2w校验、frame数/输出provenance与timestamp_us

   L130–269 · L421–478

---

3. deform360/tactile.py ↗
   GitHub · lhy0807/deform360 · d8522a4403

   nearest时间对齐、accepted mask与共同camera timeline

   L304–353 · L408–449

---

4. deform360/annotations.py ↗
   GitHub · lhy0807/deform360 · d8522a4403

   HDF5 data数组、mask/depth/velocity单位与encode/decode

   L1–83 · L175–206

怎么接入我们的benchmark

可重用

明确图像/姿态/深度/速度/触觉契约、common timeline与output hash校验，可复用到标准化来源层。

需要转换

source/episode是主lineage，camera/frame/sensor作子记录；保存微秒时间、c2w方向、单位、invalid值与alignment政策，case另绑定真正预测目标和scorer。

仍需补齐

完整数据/annotations取得、interaction/对象split、world-model评测协定/程序与checkpoint、从感知数据创建物理可运行task的验证。

P197 · EgoSim / MultiEgoView

EgoSim: An Egocentric Multi-view Simulator and Real Dataset for Body-worn Cameras during Motion and Activity

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoSim提供真正的身体穿戴相机模拟扩充，内核在SIPCharacter C++，不是AirSim通用的image benchmarker。它产生多相机/IMU/骨架数据，并非robot任务成功评测器。

> **版本与身份**
>
> 固定e48780e；NeurIPS2024作品于2502.18373存盘。只核读实际EgoSim扩充，未把整个AirSim所有功能当成本文评测范围。

领域	穿戴交互与动作界面
环境	Unreal Engine/AirSim的SIPCharacter avatar，可接FBX/SMPL系列动画与多socket身体摄影机；6camera sockets是同avatar的传感位置，非6个独立场景。MultiEgoView实拍数据另有下载来源。
任务	身体相机视角、运动/活动数据生成及下游感知研究。avatar动画和camera placement本身不构成已带robot goal/scorer的操作task。
题数与数据	record有VehicleName、相对创建时间TimeStampMs、TimeStampAnimationS、6组相机position/quaternion(xyzw)、IMU acc/velocity及bone世界pose。settings采NED转换，record直接写Unreal Actor/Bone位置；位置/加速度单位需验证，不能看到注解convert to meters就假定已换算。
评估方式	本次未确认完整语义下游benchmark scorer，capture FPS不是活动理解成功率。tick依clock_speed和record_interval采样；camera2角速度噪声用dist_vel1，camera3所读角速度噪声被注解，与六份std设置未完全对称，需逐sensor记实际生成条件。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **4** virtual scenes · 原文页 5
- **24** locations within scenes · 原文页 5
- **35** real human activity types · 原文页 6

- **119.4** synthetic motion hours（6views） · 原文页 5

依这个顺序读

1. `README.md` ↗
   GitHub · eth-siplab/EgoSim · e48780e6c8

   原作、MultiEgoView、最多6socket与IMU/相机设置

   L1–85

---

2. `Unreal/Plugins/AirSim/Source/Vehicles/SIPCharacter/SimModeSIPCharacter.cpp` ↗
   GitHub · eth-siplab/EgoSim · e48780e6c8

   settings NED→Unreal spawn变换与avatar创建

   L117–154

---

3. `Unreal/Plugins/AirSim/Source/Vehicles/SIPCharacter/SIPCharacterPawn.cpp` ↗
   GitHub · eth-siplab/EgoSim · e48780e6c8

   camera lag、IMU噪声配置与实际tick推导

   L148–162 · L185–205 · L427–492 · L503–520 · L533–550

---

4. `Unreal/Plugins/AirSim/Source/Vehicles/SIPCharacter/SIPCharacterPawnSimApi.cpp` ↗
   GitHub · eth-siplab/EgoSim · e48780e6c8

   record字段、双时计、6相机/IMU及所有bone world pose

   L18–105

怎么接入我们的benchmark

可重用

SIPCharacter生成器、sensor mount/lag设置、完整record字段与双时计。

需要转换

environment保存UE场景/avatar/animation/插件版本；case保存socket视角、noise与时序/座标转换，body poses作label时不得作隐式policy输入；观测生成与下游任务/判分分层。

仍需补齐

MultiEgoView原生reader与split、UE资产/animation权利及取得、坐标/时间/IMU统计实测、下游task/scorer与部署验证。

P198 · TACO

TACO: Benchmarking Generalizable Bimanual Tool-ACtion-Object Understanding

内核内容已核读 · 主来源 · 原作 · 独立页面

TACO的公开库主要是人体手–工具–对象数据加载和投影工具。pre-release与V1的串行、triplet和视角数不同，必须分版计数。

> **版本与身份**
>
> 固定b385ac1；CVPR2024原作2401.08399，README后续更新到V1与额外工具。未将可视化成功当作理解或机器人操作成功。 已补核TLabel be7121d0的文件、schema与quality入口，限后加工具角色；未运行adapter / export或宣称TACO数量因此增加。

领域	餐饮与烹饪、居家整理与清洁、穿戴交互与动作界面
环境	真实双手工具操作，多视角RGB与ego RGB-D。pre-release为8个allocentric views，V1为12个，且共用206object models；不同view或release不当成独立物理场景。
任务	〈tool,action,object〉triplet理解与generalization：pre-release244sequences/137triplets，V1 2317sequences/151triplets。triplet是原生语义组合，sequence是观测样本，不自行当151种可运行robot目标。
题数与数据	按triplet/sequence组织RGB-D、Hand_Poses、Object_Poses及Camera_Parameters；MANO48Dpose+10Dshape+translation，输出778vertices/21joints。hand模型结果除1000、object_cm.obj乘0.01后进同m座标；camera extrinsics明示world_to_camera。缺shape helper会补0beta，需标missing/default。 额外工具TLabel的固定README / schema已补读：它另有schema_version、sensor_info、capabilities、episodes，以及14个触觉语义字段；这不表示原TACO已有这些触觉信号。TLabel的L1–L4描述信息完整程度，非本benchmark的任务难度。
评估方式	所读是loader与可视化，不是完整原作benchmark grader；frame数与pose数不符会跳过。需要原作task split/metric才可做辨识/轨迹/交互评测。后加TLabel workflow只是工具支持，不能据此把原作RGB-D清单宣称添加实测触觉模态。 TLabel的QualityScorer以一致性30%、平滑25%、完整性25%、覆盖20%合成数据品质分数；不是对GT量测准确率、机器人成功率或校准后的难度。data_quality另可用户自述；schema预设confidence=1.0也不能当已验证的可信度。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **3** benchmark endpoints · 原文页 6, 7, 8
- **131** tool-category/action/target-category triplets · 原文页 5
- **15** action labels · 原文页 4
- **2,500** motion sequences · 约2.5K · 原文页 4

依这个顺序读

1. `README.md` ↗
   GitHub · leolyliu/TACO-Instructions · b385ac1e89

   原作、244/2317版本差异及后加annotation工具

   L1–85 · L198–223

---

2. `dataset_utils/hand_pose_loader.py` ↗
   GitHub · leolyliu/TACO-Instructions · b385ac1e89

   MANO shape/pose/translation与mm→m

   L10–76

---

3. `dataset_utils/video_utils.py` ↗
   GitHub · leolyliu/TACO-Instructions · b385ac1e89

   视频顺序、BGR/RGB与frame cap

   L16–49

---

4. `dataset_utils/project_pose_to_egocentric_view.py` ↗
   GitHub · leolyliu/TACO-Instructions · b385ac1e89

   cm对象mesh→m、世界pose、逐frame world-to-camera与数据完整性

   L20–120

---

5. `README.md` ↗
   GitHub · liesliy/tlabel · be7121d011

   确认是后加的跨传感触觉annotation工具，不是原TACO数据。

   L1–99

---

6. `docs/tlabel-format.md` ↗

   GitHub · liesliy/tlabel · be7121d011

   核对schema版本、capabilities、sensor_info与episode引用，保留物理单位。

   L1–112

---

7. `tlabel/core/schema.py` ↗

   GitHub · liesliy/tlabel · be7121d011

   确认14个语义字段、预设confidence及用户自述data_quality。

   L21–102

---

8. `tlabel/quality/scorer.py` ↗

   GitHub · liesliy/tlabel · be7121d011

   区分数据完整性 / 平滑 / 一致性加权分数与robot任务成功。

   L39–89

怎么接入我们的benchmark

可重用

版本化triplet/sequence ID、MANO/对象pose/camera校准、单位明确的投影流程。

需要转换

source保留pre-release→V1 relation；case以triplet+sequence+时间/视角定位；camera/object/hand座标及units统一但保留原始值，缺frame/shape单列invalid/default状态。

仍需补齐

完整data/asset与官方split、原benchmark scorer与基线、object/contact物理化以转robot任务、default shape与时间同步验证。

P199 · OpenEgo

OpenEgo: A Large-Scale Multimodal Egocentric Dataset for Dexterous Manipulation

内核内容已核读 · 主来源 · 原作 · 独立页面

已确认OpenEgo官方对应repo，提供六来源的统一数据API与LeRobot转档。其290 tasks是原作来源表加总，与本库跨来源去重任务联集不同。

> **版本与身份**
>
> 固定51f704a，README明确连2509.05513及原作网站；有MIT code不代表六份底层数据享有同一授权。未下载完整1107h或运行转档。

领域	居家整理与清洁、穿戴交互与动作界面
环境	汇整CaptainCook4D、HOI4D、HoloAssist、EgoDex、HOT3D、HO-Cap；原作1107h/119.6Mframes/344.5krecordings/600+environments沿用父来源，并非重新拍摄的独立环境池。
任务	意图对齐action primitives与dexterous hand trajectory学习。原表24+16+20+194+33+3=290个原生task labels；各父来源粒度可能不同，须保留来源再归并。
题数与数据	API按mp4列demo，读joints.hdf5、annotation.json、metadata.hdf5；Action.start/end是秒，round(timestamp×fps)并采end-exclusive slice。EgoDex joint slice与annotation getter仍NotImplemented；按parent目录建name索引会让同目录多视频互相覆写查找。EgoDex直接取transform平移，需核验与camera-frame声明的对齐。
评估方式	此repo主要是数据API/转档，不含可核验的手轨迹baseline evaluator。LeRobot action实际存下一frame双手21×3×2=126D座标，末frame重复，非robot actuator command。缺visibility会补全1、缺annotation会空列表、不同FPS仅warning并截各模态最短长度，正式case不得预设这些都有效。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **290** 六来源task labels合计 · 原文页 3
- **1,107** 来源video hours合计 · 原文页 3
- **344,500** source recordings · 344.5K约数 · 原文页 3

依这个顺序读

1. README.md ↗
   GitHub · ahadjawaid/openego · 51f704ae36

   精确原作ID、六父来源、原生加总与API声明

   L1–95

---

2. openego/data/openego.py ↗
   GitHub · ahadjawaid/openego · 51f704ae36

   实际视频索引、source辨识、EgoDex特殊加载与未实作分支

   L1–137

---

3. openego/data/annotations.py ↗
   GitHub · ahadjawaid/openego · 51f704ae36

   action timestamps/actors/objects、frame界线及visibility

   L9–105

---

4. port_openego_to_lerobot.py ↗
   GitHub · ahadjawaid/openego · 51f704ae36

   126D人手状态/next-frame target、终态与不同FPS/缺标注处理

   L32–77 · L84–122 · L173–226

怎么接入我们的benchmark

可重用

原source ID、Action时间/对象/actor、统一reader与显式next-pose转档schema。

需要转换

用父source+完整video相对路径+segment界线建ID；保留measured/estimated/converted pose与座标单位、visibility unknown、原FPS；126D next-pose prediction与robot运行action分开profile。

仍需补齐

EgoDex未实作分支、六来源坐标/units/hand-order转换验证、case级去重与split、parent数据权利、真正预测scorer和robot retarget验证。

P200 · SABER

SABER: A Scalable Action-Based Embodied Dataset for Real-World VLA Adaptation

实作尚未确认 · 主来源 · 原作 · 独立页面

SABER的公司research页确认论文及HF数据入口，但本次公开取得HF card回401，没有找到GitHub。可先整理retail用途及三种action representation，不能宣称素材或scorer已取得。

> **版本与身份**
>
> 2026-10-11原项目路径转向DreamVu首页；research页仍列精确2605.09613与DreamVu/SABER-10K，但公开HF raw请求401。401只表示本次未取得，未推定资源不存在或尝试绕过访问限制。

领域	包装、仓储与物流、零售与购物
环境	多个真实grocery store；头戴GoPro配固定ALIA360°六个同步视角，拍摄时没有robot。相机数/视角数不能当商店或环境数。
任务	零售补货、取放商品、货架不同高度、篮车/冷藏柜与走道活动；原文主张domain-specific VLA adaptation，尚无已取得的固定任务/评测case清单。
题数与数据	原文约100小时双流拍摄；Stream1为25K约10秒ego episodes的LAPA latent tokens，Stream2为18.6K ego episodes的人类21点hand pose/修正后retarget，Stream3由exo SMPL转UnitreeG1。三stream来自相同拍摄，不相加当独立物理episodes；手动修正的human pose与retarget不是原生robot控制纪录。
评估方式	原文包含VLA适配实验及人工annotation QC；尚无取得的评估code/episode verdict，不能重现其提升倍数，也不能把人工QC比例当任务成功率。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **44,800** 三supervision streams samples · 约数；不是unique physical episodes · 原文页 10
- **10** RoboBenchMart downstream tasks · 原文页 13
- **100** 每task evaluation rollouts · 原文页 13

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

retail用途与双流传感、latent/hand/body三层action来源分工。

需要转换

source记拍摄session及三stream lineage；case分清human估计/人工修正/retarget/robot命令，保存相机同步与合法输入；SABER-10K名称不代替实际case manifest。

仍需补齐

可用数据/card与code入口、stream schema/单位、店面/session/split ID、retarget校准与VLA评估协定/基线。

P201 · EgoSAT

EgoSAT: A Comprehensive Benchmark of Egocentric Streaming Interaction Understanding

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoSAT已有streaming runner、query helper与正式main-table scorer；标准化时必须保留完整native JSON和effective queryset，单纯压成答案JSONL会丢掉判分信息。

> **版本与身份**
>
> 固定7f65bbb；原作2606.24422。examples/evaluation_fixtures是合成格式例，不记为本库添加真实评测题或原作模型跑分。本轮未运行模型/API/scorer。

领域	居家整理与清洁
环境	Ego4D的1997段第一人称视频、约165h/56场景类型；场景类型不是已取得的56个simulator环境。原始Ego4D视频不在此repo重新分发。
任务	回顾、当下、预测三模式，约4800QA；另有answerability/branchiness/surprise与state-switch probes。group、step、两probe配对及QA数分开，不从56×3推算task/case量。
题数与数据	原生GT含video_uid、video_metadata.interval_start/end、samples；helper产effective queryset保留idx/t_eval/t_eval_rel/window/horizon/options/memory。runner只裁整个interval，真正每query可见prefix需由adapter依window运行；共通格式须保存原JSON、token probabilities、queryset references与model flavor。
评估方式	MCQ对有效queryset中有GT的题计full denominator，缺/无效回答为错；缺GT略过。scorer先扫现有prediction文件，所以整份缺失的GT仍需外部expected-case manifest检查。confidence是有效cand_conf值均值，不能当accuracy或完整校准分数。state-switch需前后两probe均对，主值用valid pairs，另有total/missing/invalid计数及仅成功pair的after-confidence。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **56** Ego4D scenario labels · 原文页 9
- **1,997** video sessions · 原文页 9, 10
- **4,800** QA pairs · 约数 · 原文页 10
- **6** QA task types · 原文页 11

依这个顺序读

1. `README.md` ↗

   GitHub · leiyj23/EgoSAT · 7f65bbb201

   原作、Ego4D父来源、1997视频/约4800QA与三种时间推理

   L1–85

---

2. `evaluation/README.md` ↗

   GitHub · leiyj23/EgoSAT · 7f65bbb201

   正式输入、不同prediction flavor与各metric分母

   L1–124

---

3. `benchmark_val/runner.py` ↗

   GitHub · leiyj23/EgoSAT · 7f65bbb201

   interval视频裁切、空GT纪录与source/query身份

   L196–225 · L520–599

---

4. `benchmark_val/helper.py` ↗

   GitHub · leiyj23/EgoSAT · 7f65bbb201

   retrospective/prospective query时间与合法window

   L1992–2018 · L2385–2410

---

5. `docs/model_guide.md` ↗

   GitHub · leiyj23/EgoSAT · 7f65bbb201

   model adapter契约、time_offset/相对时间与因果取frame模板

   L58–82 · L143–211

---

6. `evaluation/metrics.py` ↗

   GitHub · leiyj23/EgoSAT · 7f65bbb201

   零分母None与基本度量

   L1–61

---

7. `evaluation/evaluate_main_table.py` ↗

   GitHub · leiyj23/EgoSAT · 7f65bbb201

   完整queryset MCQ、valid-only confidence与state-switch成对分母

   `L351–388 · L463–597 · L600–722`

怎么接入我们的benchmark

可重用

真正runner/helper/scorer、合法时间窗口、prediction flavor与透明分子/分母。

需要转换

case保存source/video/interval/query idx与精确clock、options顺序和pair ID；central input loader限定可见frame，GT独立；score保留total/valid/missing和conditional confidence，不丢native payload。

仍需补齐

完整Ego4D/QA资产与release split、每model相同expected queryset、adapter实际prefix审核、全文件缺失计分及confidence字段可用性验证。

P202 · EgoMonth

EgoMonth: A Month-Level Egocentric Video Benchmark for Long-Term Spatiotemporal Memory

文件 / 网站 · 主来源 · 原作 · 独立页面

susu801/EgoMonth 的 README 与网站对应同名论文的 301 小时 / 738 clips / 1,443 QA / 14 题型，但 pinned 完整 tree 只有静态页面与图片。文件声称存在的 scripts/ 与评测程序均不在此 commit；尚不能视为已公开可运行 benchmark。

> **版本与身份**
>
> 程序来源固定 81143141d98b4511ff1adcae9a5ccf3a9f0f9606（2026-09-22），PDF 为 2608.13113v1。非截断 tree 的 15 个 entries 中没有 scripts/、.py 或数据 JSON；README/index.html 的存在声明与此版本实物不一致。未尝试用别人的同名仓库填补。
>
> 核对 arXiv:2608.13113v1 首页题名、作者及正文。候选仓库完整题名、统计与题型一致，足以确认内容所指论文；但 pinned PDF 未连到该仓库，README/index.html 仅署名 EgoMonth Team，未提供作者名单或 arXiv 反向链接，因此 susu801 的作者官方身分仍未独立证实。

领域	居家整理与清洁、餐饮与烹饪、办公与教育、零售与购物、交通移动与车辆维修、休闲与运动
环境	人类日常第一人称录像，20 名参与者各跨 20–120 天、室内外与不同设备；论文有学习工作、交通、饮食、购物、休闲、家务六种活动分类，没有可运行 scene registry 或实体场所去重总数。
任务	保留 Table 1 的 14 QA 类型：Habit Inference、Personality Inference；Detail Retrieval、Spatial Relation、Self-localization、Temporal Ordering、Event Time、Object Location；Procedure Planning、Event Counting、Object Counting、Route Reasoning、Cross-view Spatial Reasoning、Direction Judgement。三组分别是 Schema Consolidation、Episodic Indexing、Cascading Reasoning；它们是视频记忆 / 推理题型，非机器人动作任务。
题数与数据	已读到的 schema 仅是 README 文件示例：JSON list，每笔 video_path 为一至多个相对视频路径，question、四个 options、correct_options 字母与 task_type；文件称以 CONFIG["video_root"] 接路径，但没有可核对的 loader。论文报 738 clips、18,072 分钟与 1,443 人工四选一题；这些是论文统计，未取得 QA manifest，不能宣称已清点实际 release。跨日参与者 / session ID、时间戳格式、每类实际题数与 split 档均未见。

评估方式	论文 §4.1 与 README 定义 micro Acc = 全部答对题数 / 全部题数（完整论文集合 N=1,443），macro Avg = 14 个题型各自 accuracy 的等权平均；直接比对正解，无 LLM judge。各模型观测预算不同，例如 16 / 64 / 256 / 512 frames 或 1 fps，需保留。固定 tree 未含 README 所称的 Qwen 等脚本，因此无法核对答案字母 parser、多视频拼接 / 抽帧、错误 / 空回答如何入分母，也没有可追的 concrete scorer。

▼ **原作数字：保留论文的单位与页码**

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **14** memory QA types · 原文页 5
- **6** 作者activity categories · 原文页 6
- **1,443** human-authored MCQs · 原文页 6, 7
- **738** video clips · 原文页 6

依这个顺序读

1. `README.md` ↗

   GitHub · susu801/EgoMonth · 81143141d9

   确认论文对应、文件声明的数据键、macro/micro 及缺失 scripts 声明。

   L1–9 · L35–99

2. `index.html` ↗

   GitHub · susu801/EgoMonth · 81143141d9

   核对网站题型、Code 按钮与所列评测命令；Code 仅回到同一仓库。

   L27–73 · L86–112 · L181–218

怎么接入我们的benchmark

可重用

可重用有来源的 14 题型、三认知层级、论文统计、文件示例 schema，以及 macro / micro 的分开定义；仓库先列文件来源。

需要转换

source 保留 paper v1 与候选 repo commit / 身分状态；environment 用参与者与生活录像脉络；task 保留原生 task_type。release 到位后，case 以原始 QA ID 关联有序 video_path[]、question/options/correct_options，另保存 participant/day/session、媒体时间及观测预算；单片与跨片同属一题，不能按片重复计数。evaluator 分列 micro 与每类及 macro 分母。

仍需补齐

作者官方链接、QA / split / 视频 manifest、可读 loader、实际答案解析与 scorer、跨日时间对齐、抽帧及例外处理。现阶段不能产生已验证可运行 case 清单。

P203 · EGOSTREAM

EGOSTREAM: A Diagnostic Benchmark for Streaming Episodic Memory in Egocentric Vision

文件 / 网站 · 主来源 · 原作 · 独立页面

已确认 saroo25/Egostream 是论文官方网站的静态源代码。首页明示 data 尚未公开且 GitHub coming soon；唯一 Python 档 server.py 只是 HTTP 静态服务器，没有数据 reader、memory manager 或评测 scorer。

> **版本与身份**
>
> pinned paper 是 2605.31557v2（2026-06-01）；website repo main 固定 8cb0dab06659a56a7de75b88770f31eecec17944。完整非截断 tree 已核，public release 状态与论文「匿名仓库已分享」叙述不一致。这是 website-only / release 未找到，不是 GitHub 404 或 rate-limit deferred。
>
> arXiv:2605.31557v2 首页连到 saroo25.github.io/Egostream；网站题名、Rosario Forte / Giuseppe Lando / Antonino Furnari 与 Catania 单位一致，并反连同一 arXiv。网站 cache 与 pinned index.html SHA256 相同，可确认此 repo 的网站角色。论文 p.3 所称匿名 GitHub release，未在 pinned PDF 链接或公开网站找到可解析的 release 地址。

领域	居家整理与清洁
环境	重用 Ego4D Episodic Memory VQA、EgoLife、EgoTempo、Multi-Hop EgoQA 与 HD-EPIC 的人类第一人称视频；没有添加可运行机器人环境。父来源、视频、参与者与重写 QA 关系必须保留。
任务	7 个 primary memory dimensions：detail、spatial、temporal、event、social、causal、prospective；每题另可有 secondary tags。7 个 recall regimes 是同题的时间条件：0 秒、0–5 秒、5–30 秒、30–180 秒、180–1,800 秒、1,800–28,800 秒、超过 28,800 秒，不应计成额外语义 task。
题数与数据	论文流程 2,634 candidates → 2,335 人工核对 → 2,250 final base questions，再依 AVW 展成 8,528 question–recall evaluations。每题概念上关联来源视频、四选一题 / 正解、evidence moment、primary / secondary labels、AVW 与 recall timestamp；目前没有公开 annotation 档可验证这些概念的实际 JSON keys、时间原点、split 或 loader。Appendix A.6 以秒为 delay 单位，Instant=0，其余依 regime 截取高斯分布采样，只接受落在该题 AVW 的时间，ultra-long 用 TTL；不是每题固定乘 7。

评估方式	论文 §3.4 定义四选一 accuracy = 正确推论数 / 适用 question–recall 推论数，完整实验分母 8,528；语义类别与 recall regime 用各自子集分母，不能用 2,250 代替。串流只准使用 recall time 前画面，建记忆时不可先知 query，亦不可无限保存原影格再重读；需记 memory budget 与平均每 frame 处理时间。Appendix A.7 描述 ingestion / QA 分离并要求回复选项 index；实际 parser、skip / error 计数、记忆限制与 timing scorer 未公开，论文协定不可记成程序已核。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **7** primary memory dimensions · 原文页 4, 5
- **2,250** base validated questions · 原文页 5
- **8,528** question × applicable recall evaluations · 原文页 6

依这个顺序读

1. `README.md` ↗

   GitHub · saroo25/Egostream · 8cb0dab066

   确认仓库自述为静态 landing page。

   L1–3

2. `index.html` ↗

   GitHub · saroo25/Egostream · 8cb0dab066

   核对作者、paper link、未公开公告、AVW 与串流协定。

   L34–111 · L113–211

3. `server.py` ↗

   GitHub · saroo25/Egostream · 8cb0dab066

   核对 Python 入口只提供静态网站，不能冒称 benchmark runner。

   L1–62

4. `script.js` ↗

   GitHub · saroo25/Egostream · 8cb0dab066

   核对 JavaScript 只有菜单、卷动与显示动画，没有隐藏数据 / scorer 调用。

   L1–38

怎么接入我们的benchmark

可重用

可保留官方网站 / paper 的题型、AVW 定义、因果观测限制、原生统计及子题扩充关系；网站程序仅作 discovery 证据。

需要转换

source 记 v2、website repo commit 与五父来源；task 记 primary dimension、secondary tags；case 分成 base QA 与带 recall timestamp / AVW / regime 的条件化评测纪录，保留群聚 parent ID。evaluator 分开记整体 / 类别 / regime accuracy、实际有效推论分母、memory / frame budget 及时间成本。

仍需补齐

公开 annotations / split / source manifest、AVW 与 recall 抽样清单 / seed、数据 reader、串流 memory manager、答案解析与 concrete scorer。尚无可核实的 executable release；不能把网站部署程序当评测。

P204 · S-EMBER

S-EMBER: A Large-Scale Benchmark for Streaming Egocentric Memory Retrieval

内核内容已核读 · 主来源 · 原作 · 独立页面

官方 S-EMBER 已有具体 JSONL reader、五选一 scorer、temporal IoU 与 optional Gemini judge；核读专用 sember task 及两条模型 / API 路径。此 commit 预设只回报 MCQ accuracy 或 mIoU，尚未实作 paper v2 的完整 clean / overall / hallucination / R@1 / GQ 协定；另有缺片降为纯文字与 judge 异步错配等集成问题。

> **版本与身份**
>
> 固定 code 18db1323a60c86f50d9cf91df2083237a9895c50（2026-07-08）早于 paper 2607.02689v2（2026-08-26）。pyproject 标 lmms_eval 0.7.1、task metadata 0.2；Qwen runner 预设 uniform_nframes=768、fixed_frame_pixels=786432，而 paper v2 主表是 open models 128 frames。此读取范围不是整个继承 framework 或所有外部 decoder 已核。
>
> pinned arXiv:2607.02689v2 首页直接指定 facebookresearch/S-EMBER 与 facebook/S-EMBER dataset；README 题名、作者及 arXiv 对应一致。仓库包含 lmms-eval 的其他 task，但本篇只追 lmms_eval/tasks/sember 与其直接调用；没有把 FALCONBench 等继承 task 当成本篇数据。

领域	居家整理与清洁、餐饮与烹饪、零售与购物
环境	613 名用户以 Ray-Ban Meta 录下日常人类第一人称、visual-only 观测。论文的 2,090 fine-grained scenario labels 合并为 33 activity categories，均非可运行场景资产或去重实体场所数。
任务	原生八类为 location_trace、sequential_action、counting_objects_events、visual_detail_recall、temporal_ordering_recognition、time_duration、object_comparison、spatial_aware_reasoning。两个 task entry 是 sember_mcq（五选一）与 sember_grounding（答案＋证据时间段）；同题三种 verbosity 参考答案及 MCQ 变体不产生三倍独立 case。

题数与数据	两个 YAML 以 datasets.load_dataset(path="json", data_files={test: data/sember_*.jsonl}) 加载 test split。程序按 SEMBER_VIDEO_DIR/<video_id>.mp4 取视频，忽略 HF 的 video 路径栏；doc_to_visual 产生 {video_path, video_end: question_time}。MCQ 使用 question_id、question、options、correct_letter（scorer 可 fallback correct_index）、question_category；grounding 使用 answer、answers[].answer_text、answer_start_time / answer_end_time，并保留 memory_recency、answer_range、duration、video_category。question_time、证据区间及 duration 以原片秒为单位；未做跨视频共用时间轴。论文 / README 报 9,448 QA、3,141 videos、388 小时，本轮未下载 HF JSONL / 视频，未把这些数字宣称为本地验算。
评估方式	MCQ parser 优先接受单一 A–E，否则取第一个独立字母；空白 / 不可解析为错。aggregate = 100×答对数 / 所有传入结果，另印每类 accuracy / parsed 数，并非八类 macro。grounding 只解析 Answer: 与 Time:[非负数,非负数]；IoU = max(0,min(end)−max(start)) / (max(end)−min(start))，缺 GT、无法解析或 union≤0 均为 0。mIoU = 100×IoU 总和 / 所有结果，未解析仍在分母，未裁到 question_time / duration。API summary 同样把 FAILURE 留在分母；--max-samples 限制后只对该子集计分。optional judge 收集 answer 与 answers[].answer_text，以任一可接受答案匹配；CORRECT / WRONG / UNPARSED / ERROR 均入 total，仅 CORRECT 入分子。paper v2 的 Acccl、Accov、hallucination union-check、R@1≥τ 及 GQ@τ 并未在上述专用公开 scorer 实作；其论文主表以原始 IoU 0–1 报告，而程序回传 0–100。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **2,090** fine-grained scenario labels · 原文页 6
- **8** question categories · 原文页 5
- **9,448** QA pairs · 原文页 1, 4
- **3,141** unique video clips · 原文页 4, 5

依这个顺序读

1. README.md ↗

   GitHub · facebookresearch/S-EMBER · 18db1323a6

   确认 paper / repo / dataset 身分及 grounding 预设与 optional judge 的差别。

   L1–63 · L124–168 · L191–213

2. `data/README.md` ↗

   GitHub · facebookresearch/S-EMBER · 18db1323a6

   核对八类、JSONL 字段与以秒计的 query / evidence 时间。

   L75–174

---

3. `lmms_eval/tasks/sember/sember_mcq.yaml` ↗

   GitHub · facebookresearch/S-EMBER · 18db1323a6

   定位 test JSONL、doc_to_visual、结果处理与自订 aggregator。

   L1–31

---

4. `lmms_eval/tasks/sember/sember_grounding.yaml` ↗

   GitHub · facebookresearch/S-EMBER · 18db1323a6

   确认 grounding 的公开 metric 只有 temporal IoU。

   L1–35

---

5. `lmms_eval/api/task.py` ↗

   GitHub · facebookresearch/S-EMBER · 18db1323a6

   追到 datasets.load_dataset 与实际 test split / task callback。

   L1138–1174 · L1206–1208 · L1571–1582

---

6. `lmms_eval/tasks/sember/utils.py` ↗

   GitHub · facebookresearch/S-EMBER · 18db1323a6

   核对视频解析、MCQ parser、IoU 公式、失败与聚合分母。

   L17–163 · L171–289

---

7. `lmms_eval/models/simple/internvl3.py` ↗

   GitHub · facebookresearch/S-EMBER · 18db1323a6

   追秒→frame index、None 过滤、缺片空回答与 video bounds。

   L154–218 · L363–405 · L455–506

---

8. `lmms_eval/models/simple/qwen3_vl.py` ↗
   GitHub · facebookresearch/S-EMBER · 18db1323a6

   追 video_end 传递、frame budget、metadata 及缺片仍生成文字回答的路径。

   L182–244 · L285–366 · L378–447

---

9. `scripts/data/filter_jsonl_by_videos.py` ↗
   GitHub · facebookresearch/S-EMBER · 18db1323a6

   核对本地视频过滤如何改变被评题目与印出的错误混合单位。

   L28–100

---

10. `scripts/mcq/run_qwen3vl.sh` ↗
    GitHub · facebookresearch/S-EMBER · 18db1323a6

    确认提供的 Qwen runner 预设 768 frames，与 paper v2 主表不同。

    L51–87

---

11. `tools/api_baseline.py` ↗
    GitHub · facebookresearch/S-EMBER · 18db1323a6

    追 API 的裁片 / 抽帧、JSONL reader、失败保留与实际 scorer。

    L110–188 · L249–281 · L464–658 · L666–720

---

12. `tools/judge_grounding.py` ↗
    GitHub · facebookresearch/S-EMBER · 18db1323a6

    核对 gold-answer union、verdict parser、异步顺序与逐题 / 分类分母。

    L53–119 · L122–174 · L177–224

怎么接入我们的benchmark

可重用

可重用原生八类、两个 task YAML、JSONL loader、per-question logs、五选一 parser / deterministic IoU 作待修正的原生 evaluator；保留完整 / 缺片子集与 API / local 路径。

需要转换

source 记 paper v2、repo commit、HF 另行固定的数据版本及 lmms-eval 衍生关系；domain / environment 从 video_category_broad / video_category 分层，不能将 2,090 labels 当 scene assets。case 以 question_id 关联 video_id、question_time、options / answer variants 与多 reference intervals，MCQ / grounding 共用 parent QA。evaluator 各自保存 score unit、全分母、parsed / failed / 缺片数、可见 prefix、frame/pixel budget；追加 paper v2 的各分项与同题 joint GQ，保留和旧版 scorer 的差别。

仍需补齐

HF 原生题目 / 视频 manifest 及数据 revision、有效题数验算、缺片一致处置、strict schema / timestamp validation、judge ID 对齐与 parser 修正、完整 paper v2 metrics 接线。Qwen 的实际解码委派 qwen-vl-utils>=0.0.14，未固定精确版本；需另验证采样时间 / 外部 reader 的 cutoff，不宣称已完成 runtime 重现。

P205 · CapMem

CapMem: A Benchmark for Caption-Based Episodic Memory in Egocentric Video

实作尚未确认 · 主来源 · 原作 · 独立页面

CapMem 的 pinned paper 有完整标注、单一 evaluation split、caption / frame 协定与 retrieve-and-verify 规则，Appendix G 亦宣称发布程序；但已收录 PDF / project / 搜索来源未提供可确认的本篇 GitHub release。未把同名记忆游戏或 CapMemUtils 当成实作，也未假造 loader / scorer 文件。

> **版本与身份**
>
> 全篇依 pinned 2609.17688v1 与既有 2026-10-10 搜索 / project cache；没有已确认 repo commit 可记。论文 p.24 的 release 声明不能替代可读源代码。没有新批量搜索、模型运行或资产下载。
>
> 核对 arXiv:2609.17688v1（2026-09-15），Dingli Liang、Yiqiao Xie 等九位作者。project_candidates 的本篇没有 project 或 repo；既有 CapMem egocentric 搜索为 0，广义 CapMem 搜索的前 8 / 10 个结果未创建作者或论文对应。因此状态是尚未确认程序仓库，不是证明全网无 code 或 repository 404。

领域	居家整理与清洁、宠物照护与动物活动
环境	75 段既有公共人类第一人称视频，共 33.7 小时，来源为 Ego4D、EgoLife、EgoPet、EPIC-KITCHENS、HoloAssist、ENIGMA-51、CASTLE2024。四用途是 Daily Life & Domestic、Outdoor & Mobility、Work & Procedural、Pet Related；16 scenario labels 不等于 16 个已去重可运行世界。
任务	主题是 Episodic Memory Video Caption QA；CleanQA（仅问题 / 选项）、Direct VideoQA（抽样影格）、CaptionQA（时间化文字记忆）是同题三种信息条件。Ego / Exo × Who / What / Where / When / How 为问题分类，50 templates 是出题样板；Object、Attribute、Spatial、Action 为可重叠标记，不是额外物理任务。
题数与数据	论文 Appendix E 的 2,109 人工 candidates 经双 reviewer 留 1,276，文字捷径 filter 删 352 后剩 924，再复核恢复 76，得到 1,000 题。Appendix G 指定每题包含 question identifier、父数据 / 视频 ID、四选项与正解、evidence timestamps、domain / scenario、Ego / Exo、4W1H、evidence-location、多视觉 tags；此为论文所述内容，没有实际文件可验证 JSON key 名称或 loader。单一 1,000-question evaluation split，无独立 dev；来源影音 / 原库标注不重发。影格 cache 是 1 fps，full-coverage caption 用连续 30 / 60 秒窗；caption 完成后以文字回答同视频各题。

评估方式	论文用四选一 QA accuracy（正确题 / 实际评测题）及每题 token 成本；主设置 N=1,000，Gemini 3 Flash Direct VideoQA 仅 N=786，相关配对比较须对齐这 786 题。duration 子集 208 / 792 题，evidence-location 子集 348 / 507 / 145 题；multi-label tags 的分母重叠。CleanQA 15%–35% 是 model 进入主评测的 gate，不是 case 成功门槛。Direct 的 InternVL / Qwen frame caps 为 128 / 768；full-caption 无 video-level cap，六 Qwen 的 frame-aligned control 才用与 direct 相同的 frames。Appendix D 的 retrieve-and-verify 最多三 seed、neighbor=1、NMS 45 秒，最多三段各四个影格验证；仅 strong 视觉支持、合法字母且无 clock-time cue 才覆盖原 CaptionQA。该 override policy 在全 benchmark 错误分析后选定，作者明示属 post-hoc proof of concept。未取得 concrete scorer，答案 parser、无效输出、例外 / 遗漏题入分母方式及实际 filter 实作均未核实。

▼ **原作数字：保留论文的单位与页码**

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **4** 作者application domains · 原文页 3, 4
- **16** scenario labels · 原文页 3, 18
- **1,000** final MCQs · 原文页 4, 18
- **786** Gemini DirectVideoQA已评子集 · 原文页 5

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

可重用原生用途 / 题型 / 多标签、单一 evaluation split 的论文统计、公开 prompt 文字、input-budget 对照与 post-hoc 限制。

需要转换

source 绑 paper v1 并保留七个父媒体来源；domain / environment 保留四用途与 scenario labels。case 用 CapMem QA ID 关联 parent video / evidence 与选项，三种信息条件及 30 / 60 秒 caption 版本作同题条件；evaluator 保存 matched question IDs、完整或 786 子集、frame IDs / captioner / QA model、caption 一次性成本与逐题摊提成本。retrieve-and-verify 另记 override / wrong→correct / correct→wrong，不能与无视觉 CaptionQA 混记。

仍需补齐

作者可验证 release URL、官方 annotations / question IDs / split manifest、JSON schema、reader、caption cache 索引、各协定实际 scorer 与可追溯排除清单；还需独立 dev / held-out policy 验证。未取得的 LICENSE-DATA / LICENSE-CODE 仅是论文声明，不列成已读文件。

P206 · EmbodiedMemory-Bench

EmbodiedMemory-Bench: Benchmarking Embodied Memory for Long-Horizon Embodied Tasks

内核内容已核读 · 主来源 · 原作 · 独立页面

循官方 project 搬移页确认 ZJU-OmniAI/Embodied-Omni 的 embodied_memory/ 为本篇公开程序，已追 manifest loader、history sanitization、simulator runner、四家族具体 success / ERR 与 macro 分母。HF 有 frozen release，但公开 loader 与发布路径不一致；code 亦将任一 ERR 视为不能成功，与 paper 的可恢复终态 SR 有实质差异。

> **版本与身份**
>
> code 固定 f0409a8ecd858acd1f53c69f6424e0c4af83737b，只核 embodied_memory 子项目。HF 固定 3b45bd3f3a67a23b09b78d27c3ab563a700e832a；README 说公开 episode-level 名称 / 描述 / probe instructions 已英文化并更新 hash，原语言 revision 为 28694bf83b78049ac96ba01c9ffb13aeac7eaef9，不能混用。HF canonical manifest SHA256=6c69644b9fc4755065830e4884a12898e3ed0db32c1825dbecf623c37b9b1bc2 是发布者 metadata 声明，本轮未下载 full2554 逐例重播验算。
>
> pinned arXiv:2609.28236v1 题名及 Lizhou Liang 等作者与 embodied_memory/README 一致。PDF 原始 ZJU-OmniAI project 转址到 Embodied-Omni/EmbodiedMemoryBench，新页直接连官方 monorepo 与 lzLiang/EmbodiedMemoryBench；不将参考文献的 OpenBMB/MiniCPM-V 当成 benchmark。只核本篇 embodied_memory 子树，未扩读同 monorepo 的 reasoner / navigator。

领域	居家整理与清洁
环境	AI2-THOR 单房间组合的多房间脉络与 ProcTHOR 场景；论文 Table 9 报 1,118 个 globally unique source scene IDs、四 room types，不能加总各家族重叠 scene counts。当前 env 以 probe.scene reset，使用 500×500 RGB、visible_objects、agent_state、available_actions 与高级离散目标动作。原生 x/y/z、objectId、rotation_y（0–360）及相机角度须保留；不把 Navigate / PickUp 等界面当连续机器人关节控制。
任务	manifest 四家族 l2_passive、l2_dynamic、l2_interaction、l3_owner_habit 分别对应 Passive Observation、Dynamic Tracking、Interaction Failure、Experience Generalization。probe_retrieve / probe_track_location 要到记忆位置并拾取目标；probe_avoid_failure 要选非已知锁定容器存放物品；owner_habit 以先前 correction 对新对象选择合规 receptacle。construction schema 的 L0–L3 enums 不等于四个发布家族。

题数与数据	data.load_manifest 读 JSONL 的 id、family、source.episode_path、source.episode_sha256；拒绝重复 id，先依 family / per_family 选择，再检查 episode 档与可选 SHA256。run 另以 source.probe_id 精确配对一个 probe。episode JSON loader 是 json.load；schema 含 episode_id/name/difficulty、sessions[].context_trajectory.steps[] 的 step_id/image_path/visible_objects/agent_state/action/feedback、micro_probe 或 macro_probe，以及 hidden_rules / memory_cues / expected_actions / evaluation_hooks。时间原生单位是有序 session / step，非视频秒。paper 与 HF metadata / audit report 同报 2,554=1,036+1,052+263+203、split=all；本轮仅机械清点小型 experience_generalization manifest 的 203 个唯一 id，未重新验证全部 2,554 episodes。
评估方式	实际链为 CLI evaluate→load_manifest→run.evaluate→env.step→EpisodeEvaluator.evaluate_probe。env 为每次 action 尝试记 success / feedback，无效动作及 Done / Stop 也计入 actual_steps；预设 8-step budget 覆盖 schema 的 30 / 60 预设。success 读 simulator world_state 的持物 / parent / 状态并核对成功运行的导航或放置；L2 可接受原生指定的同类且同记忆容器对象，owner_habit 保留 executable receptacle alias。ERR 只比对成功动作的 frozen triggers，L2 是先去不同 receptacle type、interaction 是重复已知错误 action–target、owner_habit 是违规放置；每 subtask ERR=min(1,触发数/max(1,required_memory_integration 数))，probe 对 subtasks 平均。run.summarize 以每家族 task_completed 布尔值 / 已记录 rows 计 SR，再对实际出现家族等权 macro；ERR 同样先家族平均。不能将 smoke 选样或中止前 summary 当 Full-2554。InvalidPhaseOutput 保留作该例失败，infra exception 写错误并中止，不产生新的完整 summary。RAR/AES/MAE 是附带 diagnostics，不等于 paper 主 metric。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **1,118** benchmark source scenes · 原文页 6
- **4** memory task families · 原文页 5
- **2,554** validated executable episodes · 原文页 6
- **800** history介入paired base episodes · 原文页 27

依这个顺序读

1. `embodied_memory/README.md` ↗

   GitHub · ZJU-OmniAI/Embodied-Omni · f0409a8ecd

   确认 paper / project / data 身分及 compact public evaluation 入口。

   L10–31 · L49–77 · L127–196

2. `embodied_memory/src/emem_bench/data.py` ↗
   GitHub · ZJU-OmniAI/Embodied-Omni · f0409a8ecd

   核 manifest id / family / source path、hash 检查与 history 图片解析。

   L8–58 · L61–112

3. `embodied_memory/src/emem_bench/construction/schema.py` ↗
   GitHub · ZJU-OmniAI/Embodied-Omni · f0409a8ecd

   核对 actions / feedback、sessions、micro / macro probes 及 evaluator-only annotations。

   L153–225 · L243–344

4. `embodied_memory/src/emem_bench/cli.py` ↗
   GitHub · ZJU-OmniAI/Embodied-Omni · f0409a8ecd

   确认预设每家族 1 例、8 steps、evaluate / offline score 不同路径。

   L20–28 · L132–157 · L182–217

5. `embodied_memory/src/emem_bench/evaluation/run.py` ↗
   GitHub · ZJU-OmniAI/Embodied-Omni · f0409a8ecd

   追实际 simulator 运行、单一 manifest probe 配对、infra failure 与分母。

   L18–38 · L58–175

6. `embodied_memory/src/emem_bench/evaluation/env.py` ↗
   GitHub · ZJU-OmniAI/Embodied-Omni · f0409a8ecd

   看场景 reset、动作尝试、终止、世界状态及当前 action ID。

   L135–193 · L209–374 · L711–748 · L845–977

7. `embodied_memory/src/emem_bench/evaluation/evaluator.py` ↗
   GitHub · ZJU-OmniAI/Embodied-Omni · f0409a8ecd

   追四家族可运行终态判定、同类 receptacle alias、ERR 触发与聚合；不是采用 ordered-subsequence stub。

   L202–357 · L377–424 · L518–562 · L717–866 · L1073–1152 · L1154–1288 · L1405–1438

8. `embodied_memory/src/emem_bench/evaluation/planner.py` ↗
   GitHub · ZJU-OmniAI/Embodied-Omni · f0409a8ecd

   核对 full_context 真正给模型的字段及每 session 80-step 上限。

   L409–461 · L740–806

---

9. `embodied_memory/src/emem_bench/evaluation/protocol.py` ↗
   GitHub · ZJU-OmniAI/Embodied-Omni · f0409a8ecd

   核对 emem ingestion 可见数据、串行动作重新绑定与 simulator fail 处理。

   L902–971 · L1017–1161

---

10. `embodied_memory/src/emem_bench/evaluation/tool_agent.py` ↗
    GitHub · ZJU-OmniAI/Embodied-Omni · f0409a8ecd

    核对先 ingest 历史再接 target，仅从可见 feedback 作后续 memory writes。

    L160–290

---

11. `embodied_memory/src/emem_bench/evaluation/grounding.py` ↗
    GitHub · ZJU-OmniAI/Embodied-Omni · f0409a8ecd

    确认依当前 available_actions 修复 / 绑定模型预测并保存修复纪录。

    L98–269 · L272–459

怎么接入我们的benchmark

可重用

官方 frozen manifest 身分 / family / hash、episode schema、session-step 脉络、模型可见字段过滤、动态 action registry、trace 与具体 state / ERR evaluator 可重用；case、probe、action attempts 需分开。

需要转换

source 同时记 paper v1、GitHub commit 与 HF revision；domain / environment 保留 room type、host simulator、scene provenance 与重用关系。task 维持四家族 / probe 规则；case key 用 manifest id 及 episode_id+probe_id，另以 organized_view 建可携 execution_path，不覆写原研究路径或 lineage。history/action/feedback、model-visible context 与 evaluator-only rules 分开映射；evaluator 保存 terminal-state SR 与此版 ERR-veto SR 差异、逐类分母、8-step / 80-per-session budget、grounding repair 与实际 world-state。

仍需补齐

修正 published manifest→loader 路径桥接、核对 ERR-veto 与论文 scorer、全 release hashes / 素材 / scene reset 闭合、完整 runtime 及同一预算重现。单一 nested episode 尝试超过本轮 512 KiB 小文字上限，已停止且保留 receipt；不把该档视为已读或不存在，亦未下载 RGB / 模型 / simulator。

P207 · EgoCoT-Bench

EgoCoT-Bench: Benchmarking Grounded and Verifiable Operation-Centric Chain of Thought Reasoning for MLLMs

内核内容已核读 · 主来源 · 原作 · 独立页面

GitHub DStardust/EgoCoT 是本篇官方补充网站，HF 另有公开 dev / test 标注、媒体重建 manifest 与实际 reconstruction reader。已核程序只有媒体处理与网站示例，未找到正式 Acc / R / SCR scorer 或 test 正解；不能把网站题目点击函数当成 benchmark evaluator。

> **版本与身份**
>
> GitHub 71e6114c155c7a593fa39e2af801b51e836b53ca 是网站；HF 31c4aa4adc88632c6efe984cf8c5399cc75f6fc3 是 clean public release，只重发自录媒体，不能将其与较早含第三方处理片的版本混用。raw README / CSV / reconstruction script 均固定 HF revision。viewer/rows endpoint 未回传 dataset revision，本轮只保存带时间与 SHA256 的一列 dev / test 与 features 作辅助字段核对，不声称已核 pinned Parquet 全体内容；未下载视频或运行 reconstruction。
>
> pinned arXiv:2605.19559v1 连到 dstardust.github.io/EgoCoT，固定 repo index.html 与既有 website cache 的 SHA256 相同；其 Dataset 按钮连 DStardust/EgoCoT-Bench，dataset card 反连同一 paper / project。PDF 作者有 Yang Dai、Dian Jiao、Tianwei Lin、Wenqiao Zhang；网站页眉只列前三人，文献作者以 PDF 为准。搜索的 EmbodiedGPT/EgoCOT_Dataset 是 2023 年另一候选，未将同名视为本篇；页脚 Academic Project Page Template 亦非 benchmark。

领域	居家整理与清洁、餐饮与烹饪、装配与生产作业
环境	五个公共人类第一人称父来源 Ego4D、EPIC-KITCHENS、Charades-Ego、MECCANO、HD-EPIC 加自录像片，涵盖生活、厨房及组装操作；没有可交互的机器人环境。pinned reconstruction CSV 清点为 351 个 (source_dataset,source_video_id)，但有 352 个 processed_clip_id / output paths；MECCANO 0001_part1 有 416×234 与 588×331 两版，必须保留版本关系。
任务	4 groups / 12 subtasks：Egocentric Grounding & Perception＝Active Object Grounding、Hand-Object Association、Manipulation State Perception；Spatio-Temporal Retrospection＝State Retrospection、Location/Visibility Retrospection、Hand-Object Temporal Retrospection；Predictive & Causal Inference＝Next State Anticipation、Next Action Anticipation、Local Cause-Outcome Inference；High-level Grounded Reasoning＝Progress Reasoning、Hand-Object Grounded CoT、Goal-Oriented Object Tracking。均是四选一视频理解及公开解释 / 证据品质，不是可运行操作技能。

题数与数据	HF pinned tree 的实际数据档为 data/dev-00000-of-00001.parquet 与 data/test-00000-of-00001.parquet；card 指定 load_dataset 后取 dev / test，300 / 2,872 题。小型官方 viewer 回应各抽一列：qid、question、choices[{label,text}]、answer、cot[{step,text}]、media_id、source、big_category_en、sub_category_en、type；dev 有答案与解释，test 范例 answer=""、cot=[]。两份 viewer 的 features 没有独立 evidence / bbox 栏，不能依 card 的 may include 自造结构化证据。pinned CSV 实际 3,172 个唯一 qid；columns 含 processed_clip_id、source_dataset/video_id、source_start_sec/end_sec、target_width/height、resize_mode、fps、preprocess_version、expected_local_output_path、coordinate_system。所有 start/end 为空、resize_mode=stretch、座标系 processed_clip；2,859 QA 引用 4 fps、313 QA 引用 8 fps，这是题目列数而非影格数。63 个自录输出与第三方待重建媒体分开。
评估方式	paper §3.2.4 的 Acc 为四选一 exact match / 全部评测题；R 是 Qwen-Max 对公开生成解释与参考解释的 0–5 分；SCR = 答对且 R≤2 的题数 / 所有答对题数×100，分母不是全题数，零答对的处置未由公开程序核实。paper 的 3,172 题结果不可当作 public hidden-test 2,872 题分数；card 的 dev 193 个 video、test 351 个 video 与总 351 个来源显示不能假定 video-disjoint。paper 另以 2,800 responses 核对 judge，人类一致性样本不是额外 benchmark cases。GitHub handleAnswer 只对四个写死示例比字母，leaderboard 只排序 HTML；HF scripts tree 唯一程序 reconstruct_media.py 没有模型推论、judge、R / SCR 聚合或提交验证。正式 test scorer / labels 在本轮已核来源中未公开。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **12** reasoning subtasks · 原文页 3, 4
- **3,172** QA pairs · 原文页 3
- **351** video clips · 原文页 3

依这个顺序读

1. `index.html` ↗

   GitHub · DStardust/EgoCoT · 71e6114c15

   核对作者、官方 dataset 链接、dev/test 可见信息及提交字段。

   `L510–585 · L865–905 · L2580–2599`

2. `index.html` ↗
   GitHub · DStardust/EgoCoT · 71e6114c15

   追真正 JavaScript：只排序已写好的分数并比对四个示例题，没有模型结果的 benchmark 聚合。

   L229–298 · L302–465

---

3. `static/js/index.js` ↗
   GitHub · DStardust/EgoCoT · 71e6114c15

   核对其余 JS 是网站交互与视频轮播。

   L1–142

---

4. `scripts/reconstruct_media.py` ↗
   Hugging Face · DStardust/EgoCoT-Bench · 31c4aa4adc

   追 CSV reader、来源视频定位、fps / resize / 逐影格处理与重复输出去重；不运行程序。

   L18–103 · L106–147

---

5. `manifests/media_reconstruction.csv` ↗
   Hugging Face · DStardust/EgoCoT-Bench · 31c4aa4adc

   核 qid / 来源 / 处理版本 / 座标栏及同来源两个不同分辨率输出。

   L1–4 · L109–109 · L2472–2472 · L3171–3173

怎么接入我们的benchmark

可重用

可重用 qid、group / subtask / type、选项及 public dev 解释、来源 / processed clip 映射、重建 CSV 与实际 reader；paper 的 Acc / R / SCR 保留各自定义。

需要转换

source 同时记 paper v1、website commit、HF revision 与五父数据源；task 按四群十二类，case 按 qid 保留 dev/test、media_id、options，将 cot 记公开参考解释而非模型私有思考。environment 记 human-egocentric context；媒体引用需带来源 ID、processed resolution / fps / coordinate_system，351 sources 与 352 processed variants 分开。evaluator 分别记 Acc 的 N、R 的判读数及 SCR 的答对分母；test 空正解标为 withheld，不能转成错误标签或零分。

仍需补齐

正式 evaluator / submission runner、hidden test labels、judge prompt与精确版本 / 解析 / 失败处置、完整结构化时空 evidence、父素材取得与重建验证。reconstruction script 用整段 source_video_id 视频，未使用 start/end / resize_mode 栏；CSV 的 start/end 全空，对含切段后缀的 source_video_id 仍须外部定位到正确已裁素材。读影格失败时 continue 而不补位，可能改变输出时间轴；需校核处理后 timestamps / bbox。

P208 · DYAD

DYAD: A Multimodal Dataset of Co-Located Human Assistance

实作尚未确认 · 主来源 · 原作 · 独立页面

DYAD pinned paper 将数据与 benchmark code 列为规划中的 controlled-access research release；已收录 PDF / project / GitHub 搜索没有可确认的本篇仓库。已核三个 endpoint 的标注与分母，但没有公开 reader 或 concrete scorer 可读，不能把同名 app builder / 其他 dyadic dataset 当成来源。

> **版本与身份**
>
> 来源固定为 2609.09023v1 与既有 2026-10-10 discovery/search caches；未确认 repo 就不造 commit 或 source path。851 assistance events、528 step intervals、611 requests、829 mode cases、256 response test pairs、传感影格均为不同单位；数字来自已核 paper，没有本地 release 逐列验算。
>
> 核对 arXiv:2609.09023v1（2026-09-08），Akhil Ajikumar、Mahya Qorbani、Sakib Reza、Sean Andrist、Mohsen Moghaddam。paper p.3 Table II 明示 planned release，正文说 will provide annotations/manifests/benchmark code under controlled access；未附本篇 release URL。既有 DYAD co-located assistance 搜索成功回传 0；DYAD 广义搜索前 8 / 1,197 结果不足以证明全网无仓库。

领域	装配与生产作业、协助、交接与陪伴
环境	单一 gearbox 组装工作站的同地人类 performer–helper 协作；20 名 HoloLens 2 佩戴者各一 session，同一受训 helper 遵循先言语引导、等待自我修正、必要时实体帮助的规则。六 pilot 不计正式 20 sessions / 5 小时 58 分钟。人类示范不是已运行机器人协作。
任务	三个分开评测的 reference endpoints：因果组装步骤辨识、已知将有介入时的 verbal / physical mode anticipation、给 oracle 脉络的 helper response generation。八个 step labels 是 Gear on shaft、Bearing in holder、Second holder、First holder、Part search、Shaft assembly in post、Attach crank、Verify rotation。九 trigger labels 是 out of reach、cannot find part、cannot decide next step、wrong part、ordering violation、wrong orientation、wrong screwdriver、stabilization needed、missed screw；null trigger 表示分类外需要，不能当没有介入的负例。

题数与数据	论文 Table II 的观测为 ego RGB 24–30 Hz / 896×504、depth 5 Hz / 320×288 16-bit、gaze 30 Hz 3D origin/direction、hands 20 Hz 每手 26 joints / 4×4 poses、head 30 Hz 4×4 transform、Kinect RGB-D 15 Hz（RGB 1280×720 JPEG）。音频不在规划发布范围，使用去识别逐字稿。三层标注各有 task step（step/objects/tool）、request（utterance/confidence）、assistance（onset/offset、mode、initiation、hard stop、trigger、objects、helper utterance、outcome）。全部转 session-relative clock 并保存 null；两场原始绝对式 hour 栏需保留各自 origin，不能当 elapsed hours。这些是论文 principal fields / 单位，尚未核到实际 JSON keys、文件布局、reader 或同步转换程序。
评估方式	mode 的论文清点是 export 852→删一重复 851→有 mode label 850→完整 pre-onset RGB window 829（610 verbal / 219 physical）；window=[onset−3.5s,onset−0.5s]。五 fold 各 12/4/4 performers，合并 829 个唯一 OOF events 算 binary macro-F1、physical-class AUPRC，四 seeds 为 0/1/2/42，2,000 participant bootstrap replicates 不能算新 cases。当次 trigger / initiation / outcome / speech / step label 等不得作输入。step track 是 5 validation / 15 test sessions，1 Hz 因果 RGB、四 frame lookback；segment F1@IoU0.1、collapsed-sequence edit、temporal mAP@0.1、frame mAP 与 MoF 分别保留，528 intervals 中一笔 null 不能擅自丢成零标签。response 将 request end 前5秒至后15秒内最近的 verbal assistance 配对，376 pairs=120 dev+256 held-out test；oracle 提供先前步骤、10轮真实对话、10次介入及 CAD 图，当次 trigger 不提供。每 query 一次生成、100-token cap；Claude Opus 4.5 依正确性、完整性、脉络相关性、可行动清晰度、简洁度与整体各评0–5，另 BERTScore P/R/F1。以上均为 paper protocol；segment matcher、judge prompt / parser、null / 例外处理、aggregation 程序未找到，没有宣称本轮算过成绩。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **3** reference endpoints · 原文页 4, 6
- **829** eligible pre-onset mode events · 原文页 4, 5
- **256** held-out response pairs · 原文页 6
- **851** valid assistance records · 原文页 4, 5

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

可重用三层事件结构、八步骤 / 九 trigger 原生词表、单 helper policy、三 endpoint 的信息边界与原生分母；规划 release 与实际可用素材分开记。

需要转换

source 保存 v1 与 controlled-access-planned 状态；domain 记组装 / 协作，environment 记 workstation、performer、helper policy。case 将 session、step interval、request、assistance event 与各 endpoint 的 eligible sample 建关联，保留原始时钟 / session origin / 同步率 / nullable 栏。evaluator 分开 mode OOF、step sequence / frame 与 response pair，各自保留 split、seed、可见信息及分母，三 endpoint 没有共同成功分数。

仍需补齐

官方 release / access 流程及程序 URL、native annotation / manifest、同步 clock reader、829 OOF IDs、step null-policy、response 配对与评分实作。没有 non-intervention negatives，不能接成 assistance-need detector；827 个有 outcome 标签的事件中 812 个为 effective，这种高度偏态是作者不设 outcome prediction 的原因，不能以所有 851 events 当此 endpoint 分母。

P209 · HUI360

HUI360: A 360{\deg} Egocentric Dataset and Baselines for Human-Robot Interaction Anticipation

内核内容已核读 · 主来源 · 原作 · 独立页面

HUI360 已核官方 baseline 与 Interact360 标注 / CSV 管线。论文结果必须对应 baseline legacy 分支与固定 HF dataset revision；新版 main 的 32-frame / 16-frame cutoff、数据 main 及最佳 F1 threshold 搜索不能直接当论文 30 / 15 协定。已追到实际 track reader、窗口标签、AUROC / F1 / AP scorer，未运行模型或下载大型数据。

> **版本与身份**
>
> 主核论文baseline legacy=32a90eb716e503ef8a0daabc052ce7c34ba36a95，README / config 指定 dataset rlorlou/HUI360@3c8a342548534b6b92d32b0099e266962facdf45，30-frame输入、15-frame两cutoff、25epochs。另读 main=a6bd61c8539061242cbf756a18847c0900a8707c（2026-08-29）新版内核设置 / reader入口 / scorer，预设32frames / 16cutoff / 75epochs及hf_dataset_revision: main，不能混用数字。Interact360=d11ec02d666965968293813b9c17501cf1568cf6（2026-05-06），其README的CSV教学虽TBD，实际export程序已存在且已核。以上是选定内核区段，不是全基线架构 / 整个标注模型codebase已审完。
>
> arXiv:2608.11051v1 的官方 project 明确分开 Code (Baselines)=hucebot/HUI360-Baselines 与 Code (Pipeline)=RaphaelLorenzo/Interact360；前者 README 直接连同一 arXiv 并要求论文使用 legacy，后者虽仍有 arXiv TDB placeholder，但官方 project、HAL 与题名均指向本篇。SSUP-HRI 是重用父数据，不另当 HUI360 新收集来源。

领域	公共场馆与服务、协助、交接与陪伴
环境	robot-egocentric 360° equirectangular 观测。paper 的新 HUI360 有 9 真实场所、30 robot setups、68 recordings；71.3 小时原始数据裁成 1,937 episodes / 11.3 小时（15 fps）。4,310 person tracks 中 375 有物理交互；另 SSUP-A 是 SSUP-HRI 两个 field sessions 的重标注，27,698 tracks / 419 interactions，不可当独立新捕捉数据。本轮没有可交互 robot policy 环境，评的是脱机 anticipation。
任务	预测人是否即将与平台发生物理 interaction；positive onset 依投放、拿取等实际事件与人工修订，并非对 gaze / 社交意图的通用判定。RF / MLP / LSTM 是模型，T_ADV horizons 5/10/15/20/30 frames（15 Hz 下约0.33/0.67/1/1.33/2秒）与输入降采样是同一 task 的条件。论文 HUI locations1–7 train、8–9 test，SSUP 第一 / 二场次 train/test；实际程序依 checkpoint 的 include_recordings_val 等清单选样，变量 val 不能擅自解读成另有第三份验证集。

题数与数据	Interact360 读 episodes/<id>/annotations_360.json 的 image_file/image_shape/detections；track_id 可由 associated_track_id 合并，含 validity、bbox、mask_rle、mask_size、engagement_level、17点 ViTPose 与308点 Sapiens。bbox / pose 是原全景像素，x 可跨图像宽度边界，不能直接裁成普通2D box。detect_interactions 的相交面积>min_pixels_intersection（预设10,000）给 level3，否则0，之后允许人工修订。export 只收 checked/valid 类 flags，依validity与quality连续段筛选，写 data-<recording>-<index>-of-<total>.csv；unique_track_identifier=recording_episode_track。timestamp 由文件名 %Y_%m_%d_%H_%M_%S_%f 解析；另存 timestamp_sec、相对track秒、time_to_first_interaction秒，无交互用99999.0 sentinel。缺 Sapiens 数据可填0，需视作缺失而非真座标。baseline CSV reader 把 engagement / 时间 / ID 列列为 metadata，指定LSTM features为 mask area+bbox+17×(x,y,score)，即56维 / frame；keypoints先box-normalize再用固定HUI mean/std。
评估方式	legacy get_track_input_possible_indices 将 image_index 连续存在、validity、至少9个 ViTPose score≥0.5与mask_size筛选做AND，再找连续段。第一个 engagement>0 定义 onset；interaction_cutoff / positive_cutoff 以frame计。非交互 track 可截到最大mask面积（近距离proxy），并依设置把窗口对齐该处。force_positive_samples 会排除交互track的早期负窗。__len__ 是合格track数，__getitem__ 为各track固定或随机选一个候选窗口；固定索引清单与subsample必须保存。legacy infer 对每个窗口得到 sigmoid(logit) 或 RF predict_proba[:,1]，用>0.5算 binary P/R/F1，整个pass的分数送 roc_auc_score；training.evaluate 另算 average_precision_score。其 N 是实际送入的合格track窗口，AUROC比较正负样本排序，F1分母为2TP+FP+FN，不是4,310 raw tracks、375 interactions或百万 detections。new main 可用 stride 展开多窗口，需重记样本数；main infer 直接算 AUROC/AP，并在同一集合用100个threshold搜索最佳F1。未下载实际CSV，因此不宣称验算任何eligible test case数。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **9** real locations · 原文页 3, 4
- **30** robot setups within locations · 原文页 4
- **1,937** HUI360 extracted episodes · 原文页 4
- **4,310** HUI360 person tracks · 原文页 4

依这个顺序读

1. README.md ↗

   GitHub · hucebot/HUI360-Baselines · a6bd61c853

   确认本篇身分及 legacy 才对应论文结果。

   L1–18

---

2. README.md ↗

   GitHub · hucebot/HUI360-Baselines · 32a90eb716

   确认 legacy 与论文使用的固定 HF 数据版。

   L1–3 · L47–52

---

3. process/detect_interactions.py ↗

   GitHub · RaphaelLorenzo/Interact360 · d11ec02d66

   核实 mask intersection 的 level 3 标注与预设 pixel 门槛。

   L23–52 · L81–105 · L148–157

---

4. export/export_utils.py ↗

   GitHub · RaphaelLorenzo/Interact360 · d11ec02d66

   核日期字符串、人工检查 flags、associated track 合并及 invalid 标记。

   L9–36 · L78–126

---

5. export/export_to_dataset_plain_csv.py ↗

   GitHub · RaphaelLorenzo/Interact360 · d11ec02d66

   追逐 detection→track/frame CSV、onset、时间单位、quality 筛选与输出文件名。

   L128–295 · L298–394 · L396–445 · L595–624

---

6. experiments/configs/expe_classifier/lstm_config.yaml ↗

   GitHub · hucebot/HUI360-Baselines · 32a90eb716

   核数据 revision、30-frame 输入、15-frame cutoffs、recording split 及固定采样。

   L1–29 · L65–156

---

7. `datasets/HUIDataset.py` ↗

   GitHub · hucebot/HUI360-Baselines · 32a90eb716

   追 CSV reader、连续有效影格、正 / 负例窗口、normalize、每 track 一个样本的分母。

   L130–217 · L248–451 · L486–574 · L612–701 · L759–896

---

8. `infer.py` ↗

   GitHub · hucebot/HUI360-Baselines · 32a90eb716

   核 checkpoint 协定、实际 inference、AUROC / binary F1 与全同硬分类分支。

   L396–443 · L530–637 · L670–700 · L771–804

---

9. `training.py` ↗

   GitHub · hucebot/HUI360-Baselines · 32a90eb716

   核 validation AP、threshold sweep 及全同预测时未初始化回传值。

   L55–68 · L131–185

---

10. `experiments/configs/in_hui/lstm_base.yaml` ↗

    GitHub · hucebot/HUI360-Baselines · a6bd61c853

    分开记新版 32 / 16、stride 与可变动 HF main。

    L36–46 · L82–113 · L260–267

---

11. `infer.py` ↗

    GitHub · hucebot/HUI360-Baselines · a6bd61c853

    核新版 per-input metric、同集合最佳 threshold 与 checkpoint 版本限制。

    L61–83 · L152–177 · L188–227 · L339–359

---

12. `utils/eval_utils.py` ↗

    GitHub · hucebot/HUI360-Baselines · a6bd61c853

    确认新版以100个threshold求同一label集合的最高binary F1。

    L10–34

怎么接入我们的benchmark

可重用

可重用两仓库原生track/frame结构、人工curation flags、mask-intersection标签、legacy reader / window selector / score path及固定normalization；SSUP重用关系独立记录。

需要转换

source 必须同存 paper v1、baseline legacy或main commit、dataset revision、Interact360 commit。environment 区分 location / setup / recording；task 保存物理interaction定义与horizon。case 用dataset+recording+episode+track+window起讫 / sample index，另保留raw track与条件化window父子关系；frame index、文件名时间、relative seconds、panorama seam / pose confidence / 缺失标记分开。evaluator 保存正负样本N、filters、采样seed / stride、threshold来源、AUROC/AP/F1及normalization版本，不能转成机器人完成工作成功率。

仍需补齐

固定revision的完整CSV / track manifest与checkpoint protocol对齐、eligible windows实际清点、SSUP跨全景边界与missing-pose处理验证、legacy边界分支修正、独立threshold选择、原始图像 / curation与标注版本闭合。只做静态核读；snapshot_download、大型骨架 / 图像、模型、GUI与模拟均未运行。

P210 · RoCo Challenge

RoCo Challenge at AAAI 2026: Benchmarking Robotic Collaborative Manipulation for Assembly Towards Industrial Automation

实作尚未确认 · 主来源 · 原作 · 独立页面

收录论文是AAAI2026第一届RoCo齿轮箱组装；目前找到的两个devkit是IROS2026第二届Task Board/Brick，不能当作同版原作实验。已核读其新界面作延伸来源并明列版本缺口。

> **版本与身份**
>
> TaskBoard45dd6ad、Brick8e7ad4d均明示2nd IROS2026且创建于原文3月之后。原文RoCo2026网站/同名repo取404，org首页转向IROS2026。原作到实作版本未闭合，故identity_or_version_unresolved。
>
> 组织相同但edition/task/scoring不同；这是版本差异，不把两个新repo错标成AAAI2026齿轮箱程序。

领域	装配与生产作业、协助、交接与陪伴
环境	原文为Isaac Sim Galaxea R1及onsite R1Lite齿轮箱；新TaskBoard/Brick devkit是另一edition的场景/机体配置，不合并为同一环境版本。
任务	AAAI原文3情境：从零组装、接手partial state、错误检测/恢复。新TaskBoard的9个parts是单一板件任务的计分部件；Brick有2种起始/目标结构格式。上述数字不可加总作原文task数。
题数与数据	新TaskBoard API有physics step、joint rad/metre、wxyz EE pose、RGB/depth(m)/intrinsics及snap_fired；Brick用23Djoint array与structure_start/goal或structure.json。原文第一届case/资产/数据版本尚未完整取得对应。
评估方式	AAAI原文S_sim=(4S1+2S2+4S3)/10；新TaskBoard按part pass/total，snap parts看触发，open parts看mesh/AABB位置距goal<0.01m且不检朝向。新Brick main只到Policy.is_done，完整grader需另接。原文重现不能套用第二届这套分母/吸附机制。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **3** assembly scenarios per track · 原文页 3, 4, 5
- **300** sim demonstrations · >300 · 原文页 5
- **300** real demonstrations · >300；不同数据 · 原文页 5

依这个顺序读

1. `README.md` ↗
   GitHub · rocochallenge/RoCo_TaskBoardAssembly · 45dd6ad6e0

   明示2nd IROS2026、9parts及active/unused资产

   L1–90

---

2. `task/policy_api.py` ↗
   GitHub · rocochallenge/RoCo_TaskBoardAssembly · 45dd6ad6e0

   当前step/关节/EE/camera/snap信号约定

   L130–175

---

3. `task/run_pick_place.py` ↗
   GitHub · rocochallenge/RoCo_TaskBoardAssembly · 45dd6ad6e0

   当前TaskBoard具体位置/snap判分与per-part输出

   L493–515 · L552–653

---

4. `README.md` ↗
   GitHub · rocochallenge/RoCo_BrickAssembly · 8e7ad4dae6

   第二届brick场景、23D控制及禁止runtime privileged信号

   L1–90

---

5. `src/rocobrick/task_config/Task.py` ↗
   GitHub · rocochallenge/RoCo_BrickAssembly · 8e7ad4dae6

   type1/type2结构/初态与topology解析

   L21–83

---

6. `run/main.py` ↗
   GitHub · rocochallenge/RoCo_BrickAssembly · 8e7ad4dae6

   运行到policy完成；完整grading未在此入口汇总

   L1–29

怎么接入我们的benchmark

可重用

原文3种assembly/recovery情境，以及新devkit清楚的observation/action/part-target契约作延伸参考。

需要转换

source明确分AAAI2026与IROS2026 editions；task/instance/scorer各绑版本，原作weighted score保持原协定；新9part和brick规则只在对应来源比较。

仍需补齐

第一届有效code/data入口、原作初态/GT/evaluator；新Brick完整评分接线与privileged input隔离；各edition独立baseline与真实物理验证。

P211 · AssemblyGrid

AssemblyGrid v1: A Benchmark for Multi-Robot Production with Temporary Coalitions, Local Information, and Geometric Constraints

内核内容已核读 · 主来源 · 原作 · 独立页面

AssemblyGrid提供明确的问题/instance/schema与KPI，可借镜标准化设计；其canonical环境是无量纲任务层几何，不能直接当接触式robot物理操作。

> **版本与身份**
>
> 固定3bb72dd；easy/medium/hard只在同family内排序。doc规则与core的legacy同名字段须选canonical口径，未运行training或simulation。

领域	装配与生产作业
环境	official abstract-v1 geometry，tick无量纲；固定robot base/reach/payload及操作位置，没有joint、grasp/contact或collision-free轨迹保证。UR10派生验证是另一非canonical profile。
任务	Flow、Coalition、Concurrency各easy/medium/hard，共9官方scenario；recipe规定材料/先后/XOR选项/coalition角色。历史Geometry及AG-*扩充tracks不直接加进官方9。
题数与数据	instance_definition保存grid/topology、robot population、recipe、资源、demand、时间、合作、local信息及generation_seed；算法/运行seed另存。local proposal_support是聚合支持比例，不是free-form message或global可行性oracle。
评估方式	completion=delivered/spawned，throughput=delivered/ticks；delivered-only mean flow需连unfinished count看。restricted flow把未完成者截尾到目前t；batch_makespan只在batch全部完成时有效，generic makespan仍可回局部值，不能混用。coalition成功分母committed+expired；utilization只对exact-capacity且有机会的状态平均，approx upper bounds分开。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **3** workload families · 原文页 12, 13
- **9** official scenarios · 原文页 14
- **50** 每scenario held-out instances · 原文页 20

- **270** MARL training runs · 原文页 20

依这个顺序读

1. `README.md` ↗
   GitHub · Fouad-Bahrpeyma/AssemblyGrid_v1 · 3bb72ddc2f

   9个官方scenario与3family×3level

   L1–90

---

2. `docs/BENCHMARK_SPEC.md` ↗
   GitHub · Fouad-Bahrpeyma/AssemblyGrid_v1 · 3bb72ddc2f

   normative范围、recipe有效性、local信息、regime、KPI与统计单位

   L1–199

---

3. `Experiments/env/benchmark.py` ↗
   GitHub · Fouad-Bahrpeyma/AssemblyGrid_v1 · 3bb72ddc2f

   扩充tracks与instance hash字段、canonical/legacy metric字典

   L74–112 · L149–204 · L264–310

---

4. `Experiments/env/core.py` ↗
   GitHub · Fouad-Bahrpeyma/AssemblyGrid_v1 · 3bb72ddc2f

   实际completion/flow/makespan、terminal/truncation及conditional KPI

   L925–955 · L995–1005 · L1465–1474 · L1797–1838 · L2310–2416

怎么接入我们的benchmark

可重用

规范recipe/schema/semantic/realizability三层验证、instance hash、训练seed与execution seed分离、canonical KPI明确化。

需要转换

source固定v1/abstract profile；task按recipe目标，environment按grid与geometry配置，case加generation/execution seeds与信息契约；维持tick及抽象reach单位，实体秒/碰撞另验证。

仍需补齐

官方instance全量manifest取得、neural candidate-slot/identity alias上限测试、与物理robot的适配/抽象误差验证、同seed范围的基线。

P212 · ARB4WM

ARB4WM: An Adversarial Robustness Benchmark for World Models in Continuous Control

内核内容已核读 · 主来源 · 原作 · 独立页面

ARB4WM在既有DMC与Meta-World上加视觉攻击/防御评测；要保存攻击强度、时间窗口与底层task版本，不能把攻击条件当成新物理任务。

> **版本与身份**
>
> 固定66ebc33；read-only核对，不运行对抗算法或policy。MetaWorld-v3及conditional metric界面是此版具体行为，不等同所有Dreamer/MetaWorld标准协定。

领域	通用对象与机动作业、居家整理与清洁、餐饮与烹饪
环境	DeepMind Control Suite vision与Meta-World visual manipulation，MetaWorld wrapper使用MT1(name-v3)及train_tasks[0]。source/backend/seed需保留，不把同底层task的五种attack objective当新环境。
任务	4种Dreamer-family模型、policy/value/latent/RSSM等目标与temporal/full/partial攻击是评估条件。动作任务仍来自父benchmark。
题数与数据	sweep记epsilon/alpha/attack steps、optimizer、defense/adaptive模式、seed、task/model与run_tag；大型logs/checkpoints未包含。world-model image界面与attack前处理需一起固定，0–1/0–255尺度不能共用同数值epsilon。
评估方式	DMC主值为累积return，MetaWorld sweep明确取success rate；同名returns容器仍需标metric。图像SSIM/PSNR按data_range255且在defense前计算。SES用SR×(1–平均首次成功步/该batch观察到的max steps)，不是固定budget范式。clean Tester用eval_envs，attack建构收到train_envs，需核对paired seeds/环境；success_once与图像统计对已结束env的遮罩也需验证。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **20** existing host control tasks · 原文页 8
- **5** adversarial loss objectives · 原文页 8
- **20** 每setting evaluation runs · 原文页 8

依这个顺序读

1. `README.md` ↗
   GitHub · zaoanguai/ARB4WM · 66ebc330e6

   Dreamer系列、借用benchmark与release范围

   L1–37

---

2. `envs/metaworld.py` ↗
   GitHub · zaoanguai/ARB4WM · 66ebc330e6

   MT1-v3/固定train task、reward/success/terminated与repeat

   L9–26 · L50–84

---

3. `test_robustness.py` ↗
   GitHub · zaoanguai/ARB4WM · 66ebc330e6

   clean/attack环境对象、epsilon sweep与MetaWorld/DMC分开取值

   L61–158

---

4. `tester.py` ↗
   GitHub · zaoanguai/ARB4WM · 66ebc330e6

   首episode masked return、success累积及conditional回传

   L36–105 · L117–136

---

5. `Attack/attacker.py` ↗
   GitHub · zaoanguai/ARB4WM · 66ebc330e6

   攻击后评估、image-quality metrics、success_once/步数与SES

   L15–48 · L76–191 · L200–248 · L345–362

怎么接入我们的benchmark

可重用

父env wrapper、可重现attack配置/命名、原生return/SR/SES及图像差异分项。

需要转换

case先绑定同父task/初态/seed，再加威胁模型/合法扰动budget；保留clean/attacked pairs、时间作用范围、defense前后metrics及不同episode分母。

仍需补齐

checkpoint/原始campaign、clean-attack环境与seed对齐、active-episode masking、固定budget效率指针与完整攻击规范重现。

P213 · Vision to Harvest

From Vision to Harvest: Benchmarking Vision-Language Models for Multi-Arm Robotic Fruit Harvesting

实作尚未确认 · 主来源 · 原作 · 独立页面

Vision to Harvest评估从果园图像生成多臂采收计划；原文的harvested ratio与collision ratio是计划几何指针，不能当作实际采摘完成与碰撞传感结果。未确认官方GitHub。

> **版本与身份**
>
> 已读2609.13606v1 p3/5与现有repository discovery；未确认source code或将相关harvesting/MIP工具当作本篇完整实作。

领域	农业与园艺
环境	两份真实orchard RGB-D来源：Fuji apple与citrus；citrus父数据432张图像，论文再取heldout场景，未提供本次可取得的benchmark场景ID manifest。
任务	从初始canopy观测分配水果及生成各Cartesian arm的顺序/waypoints。作者明说online perception/replanning留待future work，因此属观测后计划评测，不是完整闭环采果。
题数与数据	oracle采GroundingDINO/SAM2→depth投3D→DBSCAN→MIP分配/规划；VLM用原始图像及workspace/robot constraints，输出每臂JSON顺序/waypoints，未提供定时轨迹。没有公开reader/标注子集入口可核验。
评估方式	五类原生指针为detection ratio、距离门槛内waypoint的harvested ratio、含x轴arm-order violation的scene比例、总路径距离、tokens/scene。Verifier不修复计划；碰撞定义是顺序可行性proxy，没有实际触碰或水果detach验收。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **2** crop types，非两种生活domain · 原文页 5

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

农业用途、原图→多臂计划的任务定义、原生空间可行性与效率指针。

需要转换

case绑crop/scene/image-depth标定、arm配置/工作空间、固定prompt与距离门槛；将计划品质和可运行物理采收分层，保留oracle与VLM合法输入差异。

仍需补齐

官方code、heldout scene/GT清单、JSON parser/一对一水果匹配/ verifier与完整控制、动态feedback及真正采果验收。

P214 · COIN（interactive）

Chain Of Interaction Benchmark (COIN): When Reasoning meets Embodied Interaction

实作尚未确认 · 主来源 · 原作 · 独立页面

此COIN是2026 Chain of Interaction，与P003的2019视频COIN不同。论文定义90个交互推理task及6类指针，但目前未确认官方GitHub。

> **版本与身份**
>
> 2604.16886v1；原文引用ERQA、MuJoCoAR等他作repo不是此COIN code。原作名称同P003但题名/ID/数据皆不同，维持独立source。
>
> P214=Chain Of Interaction (2026)；P003=COIN instructional video dataset (2019)。

领域	居家整理与清洁、餐饮与烹饪、通用对象与机动作业
环境	ManiSkill3/Panda桌面操作，PartNet-Mobility与其他对象资产；5个camera views与depth/segmentation/proprio是观测设置，不是5环境。
任务	COIN-Primitive20、COIN-Composition20、COIN-50共50，合计90task。原作三种reasoning domains是对象中心、robot理解、组合推理，不直接当生活用途。VQA probes和子任务串行另有层级。
题数与数据	原文20primitive各50teleop demos共1000，不能当全90task都各50demo。两action space：VLA delta EEF+gripper；CodeAsPolicy7joint absolute+gripper。完整case/split、teleop原档及scorer尚未取得。
评估方式	原文SR、CSR、VQA score、trajectory stability(TS)、gripper stability(GS)、GCS=SRcomposition/SRprimitive；TS使用速度/加速度/jerk变异系数的指数分项，GS有预期切换次数等依赖。缺code时不能核对零分母、采样频率与稳定性实作，也不能把TS/GS当物理安全。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **90** task definitions across three suites · 原文页 4
- **1,000** Primitive demonstrations · 原文页 5
- **10** SR evaluation trials · 原文页 7

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

90task三层设计、部分可观测交互、两种policy动作界面与6类原作指针。

需要转换

task维持原生20/20/50集合；case分清操控、subtask planning与VQA，固定camera/segmentation是否合法、action转换和score版本；新规则另列衍生关系。

仍需补齐

官方repo/全部task与示范/合法split、动作转换、TS/GS/GCS精确grader与原生baseline。

P215 · World-model evaluation survey

Do World Models Make Better Robots? A Survey of Evaluation Benchmarks for Predictive Embodied Intelligence

实作尚未确认 · 方法 / 综述 · 原作 · 独立页面

这篇综述以160个评测artifact创建四类evaluation lane，适合补方法论与查漏；它排除纯数据/模型，因此不能直接和我们183份含数据源的总库比篇数。未确认配套GitHub。

> **版本与身份**
>
> 已读2609.29669v1 p4/5/7；以上比例是该survey报告的分布，未冒称本轮已重建/验证全部160项分类。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	跨policy、embodied-agent、world-model evaluation与prediction-to-action bridge；这些是研究评估分类，非4种应用环境或生活domain。
任务	作者160benchmark中选86代表项进主taxonomy；lane数为37policy、85embodied、34world-model、4bridge。这是该survey自订单位/范围的统计，不添加160组我们已取得的task。
题数与数据	其criterion包含有scoring protocol的dataset或有task distribution的interactive environment，排除纯datasets/models/simulators；名单及reference不代表作者下载了所有资产或跑过所有模型。
评估方式	作者按open-loop43、closed-loop113、bridge4分类；另有VLA-vs-world-model对照explicit11、partial11、agnostic138，是不同轴。11不是bridge数。可借鉴同一budget/task/observation下比较直接policy和world-model policy，而非用视频品质推论控制增益。

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

明确inclusion/exclusion、paper-ID去重、原作计数单位与预测→控制证据分层。

需要转换

将其160项作后续查漏线索并与本库source ID映射；沿用本库183来源/67参考口径。文献taxonomy和任务/环境ontology分开，未审查的新线索不算完成收录。

仍需补齐

配套machine-readable catalogue/code确认、对160项逐条原作交叉核验、真正matched-policy实验与来源case数据。

P216 · HAP

HAP: A Hand-Driven Active Perception Framework for Egocentric Head Motion Prediction

文件 / 网站 · 主来源 · 原作 · 独立页面

HAP官方GitHub目前只有接受后公开的承诺。原文可提供hand-driven head-motion prediction的格式与评估参考，但没有可核读的模型/数据处理实作。

> **版本与身份**
>
> 固定525d603 README6行；原作2609.18548明说code will be released。未因repo存在就计为内核程序已公开。

领域	穿戴交互与动作界面
环境	EgoPAT3Dv2与添加Bottle的ego RGB-D；Bottle382clips来自12sessions，10train/1val/1test。session不是直接可运行robot environment。
任务	以观测手部motion、target intention与occlusion context预测未来6-DoF头部运动；不是已完成robot active-camera control或grasping benchmark。
题数与数据	原文用camera motion作head proxy，DA3估计/平滑、另以ORB-SLAM3对照；9D输出含translation与rotation representation。Bottle手/对象由视觉模型和depth处理，需保留estimated标记、split与观测窗口。
评估方式	四指针tADE/tFDE(毫米)、rADE/rFDE(SO3 geodesic角度)。不同pose-estimation backend、平滑/观测长度/预测horizon必须固定；没有code时不能确认causal preprocessing或masked未来步的计分。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **382** Bottle clips · 原文页 5
- **12** recording sessions · 原文页 5
- **1** held-out test session · 原文页 5

依这个顺序读

1. README.md ↗

   GitHub · HAP-ego/HAP · 525d603983

   目前只承诺paper接受后发布程序/重现数据

   L1–6

怎么接入我们的benchmark

可重用

Bottle session split、6DoF/9D表示、角度/位置分项误差与遮挡条件。

需要转换

case保存camera/head proxy来源、hand/object annotation方法、observed prefix/horizon/有效未来mask；head motion prediction与控制摄影机效益另分evaluator。

仍需补齐

公开implementation、Bottle clip IDs/annotations、表示/尺度/clock与scorer、causal feature处理及基线重现。

P217 · TRS + RVG

Reliable Egocentric Action Anticipation via Temporal Reliability Suppression and Compositional Graph Decoding

实作尚未确认 · 主来源 · 原作 · 独立页面

TRS+RVG在既有EGTEA/EPIC feature pipeline上研究缺帧/噪声鲁棒预测；原文特别说明其EPIC标签和split与官方榜单不同。未确认官方code。

> **版本与身份**
>
> 已读2609.13293v1 p6–7；本文processed EPIC index space与官方taxonomy不同，不把其125/352当EPIC官方类别数。cachedTRS/RVG题名搜索未确认code。

领域	餐饮与烹饪
环境	既有EGTEA Gaze+、EPIC-KITCHENS视频/预抽TSN features；添加的是feature corruption与解码协定，不产生新物理场景。
任务	下一verb–noun joint action预测；TRS处理temporal可靠度、RVG用training-label compatibility graph重排组合。19×51=969候选scores不是969种实际观测task。
题数与数据	原文EGTEA19verbs/51nouns/106actions、processed split1共10321clips；EPIC pipeline125verb/352noun indexes且public-train videos再90/10 video-disjoint分割，明说不能与official97/300榜单直接比较。input为10个1024D TSN tokens，非直接对raw pixels加噪。
评估方式	joint top1要求verb与noun同对；AvgC跨corruption平均、RR=100×AvgC/clean accuracy应连同绝对accuracy看。PMI graph只用training labels，weight由EGTEAval校准后移到EPIC；高强度mask/drop等作用于6/10tokens，缺code还需核定具体indices与seed。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **6** main temporal corruption conditions · 原文页 7

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

原文corruption定义、training-only graph、native feature label space及group metrics。

需要转换

source关联原EPIC/EGTEA；case固定feature提取器/hash、clip/observed timestamps、corruption mask/seed与label vocabulary；official和within-pipeline两种结果分表。

仍需补齐

官方repo/features/split ID与graph数据、精确corruptor/scorer、missing/zero-denominator处理与同协定基线。

P218 · TrajPilot

How You Move Tells What You'll Do: Trajectory-Conditioned Egocentric Prediction

文件 / 网站 · 方法 / 综述 · 原作 · 独立页面

已核对 arXiv:2605.20388v1、作者项目页及同实验室 TrajPilot 候选库；固定版本的完整文件树只有一行 README，没有 data reader、模型或 metric 实作。以下任务与协定来自论文，不能视为已完成程序评测集成。

> **版本与身份**
>
> 固定 repo commit 85afac4ae7a800fc104a4499c349b09979c34941 的完整树只有 README.md；未将作者网页算成模型程序。论文附录称 atomic/Keystep 等使用 validation takes，但结果表称 test split，需保留原文标示差异并取得 manifest 才能对齐。Aria pose 与 RGB估计 PI3 的 oracle 条件也不可混同。
>
> 论文题名 How You Move Tells What You'll Do: Trajectory-Conditioned Egocentric Prediction，作者 Sejoon Jun、Hai Nguyen-Truong、Luigi Seminara、Lorenzo Torresani。PDF 连到 farsightlab.github.io/TrajPilot，页面题名、作者与 arXiv ID 一致；farsightlab/TrajPilot 与该项目共用命名空间，但公开 README 只有名称，项目页未提供可核验的方法程序链接。排除搜索中的 mimozing3003/TrajPilot-AI-Autonomous-Driving-Research-Platform：它描述自动驾驶，与本篇论文不符。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	脱机人类第一人称视频：Ego-Exo4D atomic / Keystep、Ego4D GoalStep、EgoPER，另做 EPIC-KITCHENS-100 anticipation 与 Ego-Exo4D 篮球投篮结果分类。相机运动是观测 / 条件信号，并非可直接运行的机器人控制。
任务	分开记录提供 start+goal 的程序规划、移除 goal 的未来动作预测，以及 made / missed 二分类。规划 horizon H=3–8 是动作串行长度；8,472 个 atomic 文字标签、1,165 类 closed collapse、375 个 Keystep 标签、310 个 GoalStep 标签和57个 EgoPER 标签均为各自词汇表，不能加总成任务数。Scorer 使用训练集候选未来轨迹，Oracle 使用实际未来轨迹，两者信息条件分开。
题数与数据	论文附录 A.1：atomic 为 take-disjoint 的140,413 train segments / 2,237 takes 与11,425 validation segments / 312 takes；连续 segment 形成 H=3–8 windows，但未提供公开 window manifests。每段16张 RGB，384×384，V-JEPA 池化为1664维特征；atomic 区间以相邻时间戳中点决定，其余以标注区间中点与边界采样。Aria 或 PI3 相机姿态对齐视频时间并转成相对 [Δx,Δy,Δz,Δrx,Δry,Δrz]，旋转为 rotation vector；实际 tensor schema、尺度 / 单位与插值实作未公开。篮球子集294 train / 74 test events、42 / 10 takes，test 为37 made+37 missed；模型仅看平均1秒的出手前片段，16张采样自30 fps来源视频。

评估方式	没有具体 metric/scorer 程序可读。论文区分 middle-step R@1/5 与 full-sequence R@1/5，MSeq/FSeq 为整段全对比例；Full 包含观测端点，Future 不含 observed Start。Closed-vocabulary 另报 Mid/Full mAcc、exact-sequence SR、mIoU、Levenshtein，实际 macro/micro、重复标签与跨 horizon 权重须等程序确认。EK100 的 verb/noun/action 为 mean-class Recall@5，另列 instance accuracy；篮球 accuracy 分母为74个事件，balanced accuracy 为两类 recall 平均，各类 recall 分母37。模型内部 Scorer 的候选排序 / fallback 不是 benchmark 成功判定，不能取代 evaluator。

依这个顺序读

1. README.md ↗
   GitHub · farsightlab/TrajPilot · 85afac4ae7

   确认公开 pinned repo 只有名称，没有 data / task / metric 程序。

   L1–1

怎么接入我们的benchmark

可重用

重用论文所界定的来源数据集、take 层级 split、原生动作词汇与规划 / anticipation / outcome 任务分类；repo 仅可重用身份与版本证据。

需要转换

source 连回各母数据集；case 以 take_id+segment/window+H+split+词汇版本识别，保存 start/goal 可见性与 No-Traj / Scorer / Oracle。camera_pose 另存来源 Aria/PI3、时间轴与相对6DoF格式；evaluation 分列 step retrieval、sequence exact match、class recall、event accuracy及其分母。

仍需补齐

公开 reader、window / label-bank manifests、轨迹采样与单位、实际 scorer/gating 和全部 metric 实作；尚不能核验论文指针或形成可运行套件。

P219 · FROST-STA

FROST-STA: Frozen Dense Features for the Ego4D Short-Term Object Interaction Anticipation

实作尚未确认 · 方法 / 综述 · 原作 · 独立页面

核读 FROST-STA 五页 primary PDF 与既有 discovery/search 后，受限的精确 repo 查找仍未确认作者程序库。可记录 EgoVis 2026 的 Ego4D STA 方法与论文协定，没有 pinned reader、decoder 或 evaluator 可以冒称已核读。

> **版本与身份**
>
> 本次bounded discovery：cached「FROST STA」有145笔候选、缓存前8笔均非本篇；添加GitHub「"FROST-STA" in:name,description,readme」有49笔，只核对返回前5笔，皆不相关；「"2606.00694" in:readme」为0笔。另一次限定GitHub与作者名的网页查找未返回结果。这表示本轮未确认公开库，不能推论所有49笔均核读或repo绝对不存在；本轮补查HTTP均200，没有将429/defer当成不存在。
>
> 精确论文为 FROST-STA: Frozen Dense Features for the Ego4D Short-Term Object Interaction Anticipation，Chaoyang Wang、Lexuan Xu，Beihang University，arXiv:2606.00694v1（2026-05-30）。sun0710 是论文中的挑战赛参赛名称，并未提供可验证的 GitHub 身份。V-JEPA 2.1、StillFast、AFF-ttention 与 VISTA 是引用 / 基础方法，不能代替 FROST-STA 官方库。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	Ego4D 未裁切人类第一人称视频；query 时刻之前的短片及最后观测影格。下一 active object 定义包含手直接接触或透过手持工具接触的对象；不提供机器人交互环境。
任务	每个 query 输出排序的 (active-object box, noun, verb, time-to-contact, confidence) 假设。这是同一 Ego4D STA benchmark 上的方法参考，非添加独立数据库或一组可运行操作技能。
题数与数据	论文 §2.1：取 query 前0.5秒内8张影格，视频分支resize为384 pixels；最后观测影格resize为1080 pixels，为框定位参照。TTC 使用秒。§3.1 使用官方 train 加挑战赛允许的 validation annotations 训练25 epochs，并未另报独立 validation benchmark；八个 heads 及epoch15–25 checkpoint合并。实际 annotation键名、frame index边界、resize逆映射、去重、split ID与样本数没有 reader / manifest 可核。
评估方式	仅论文 §3.2：Top-5 mAP，框匹配写为 IoU>0.5；Noun检查noun，Noun+Verb加入verb，Noun+TTC加入|TTC误差|<0.25秒，Overall同时要求全部条件。论文报告的5.13是官方test server返回的Overall Top-5 mAP，非本轮运行结果。具体AP插值、Top-5对每query/GT的预算、每类GT分母、空GT / 遗漏query处理、边界采>或≥及macro平均均无本篇实作可查；不能借用其他STA repo便宣称它们一致。

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

重用已核对的论文身份、Ego4D依存关系、五元组输出及论文明列的输入窗口、train+permitted-val条件与指针名称。

需要转换

以source→Ego4D STA方法关系建档；每query为case，保留box座标参照、noun/verb taxonomy版本、TTC秒、confidence排序与head/checkpoint预算。论文结果单列paper_reported_test_server，将训练使用的validation与可独立评测split分开。

仍需补齐

可由作者primary source确认的repo及40位revision、annotation / split reader、模型输出串行化、合并程序与完整metric实作；在取得前维持paper-only集成状态。

P220 · VISTA（Ego4D STA）

VISTA: Technical Report for the Ego4D Short-Term Object Interaction Anticipation at EgoVis 2026

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

已核读精确VISTA repo的STA reader、split设置、submission串行化与具体Top-5 mAP程序。公开train设置使用train+大部分val，仅24个holdout且每次只跑1个batch的proxy；最终ensemble预设version 2.0，库内scorer却只接受1.0，集成时须显式处理。

> **版本与身份**
>
> 读取commit 62e39d137426e12f30fe4efd12122f8c188b4b33。初始prediction writer回传version 1.0；dynamic_metric_head_ensemble与包装shell预设最终version 2.0，而本地validate_results_json拒绝非1.0。ensemble/proxy使用无+1的连续IoU，scorer使用+1像素IoU；ensemble的IoU匹配可含0.5，scorer严格>0.5；论文写TTC<0.25，程序为≤。README的scaffold称呼不代表只有README，亦不代表已完整重现官方submission。
>
> arXiv:2605.20901v1，Qiaohui Chu等人的 VISTA: Technical Report for the Ego4D Short-Term Object Interaction Anticipation at EgoVis 2026，PDF第1页直接指向CorrineQiu/VISTA；README与8张2FPS视频、Faster R-CNN still branch、四prediction heads相符。不是其他同名VISTA项目，也不是FROST-STA。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	Ego4D v2人类第一人称视频之STA query；数据被预先拆成train / val / test_unannotated sample directories，每例含短片历史影格与最后高解析影格。没有robot rollout或simulation场景。
任务	预测每个query下一交互的active-object box、noun、verb、TTC及score；一例可有多个GT对象。类别不是固定新任务清单：build_label_maps_from_roots扫train+val中有效noun/verb ID，排序重编成连续index，输出时再还原；须保留mapping与母数据taxonomy版本。
题数与数据	reader扫排序后的label.json，读uid、split、video_uid、frame、observation.history_frames[*].file与last_history_frame_highres_file；GT优先future_prediction_target.objects，fallback raw_annotation.objects，读box_xyxy/box/bbox、noun_category_id/noun_id、verb_category_id/verb_id、time_to_contact/ttc。train/val排除空标注与所有框无效的样本；test仍需label.json但不要求GT。history_frames保留既有顺序，超过8取最后8，不足8以前端第一张补齐，并不在reader内由fps重建时间戳。论文/设置为8张2FPS、视频384×384；still short-side train640–800、eval800，max1333。框随图像缩放，dump依orig_size还原xyxy像素，TTC秒不缩放；可改读split/uid.pt的1664维JEPA cache。train_include_val=true时以有效样本排序后前24个作holdout，其余val并train，并非take-disjoint的新split。

评估方式	run_official_metric_only.py是真正本地scorer：以uid对齐，CLI要求所有GT uid都有results（可空list）；无GT对象的query不入评分。IoU面积使用(x2-x1+1)(y2-y1+1)，框须IoU>0.5，TTC条件为绝对误差≤0.25秒。每query按score贪婪一对一匹配各metric的GT；Top-5不是截前5，而是每个metric忽略排序前4×该query GT数的FP。Noun / Noun+Verb / Noun+TTC / Overall皆按noun类别分组：recall分母是全评测集中该noun的GT对象数，AP以precision envelope对recall积分乘100，再只对出现GT的noun做macro平均。compute_proxy_hits则只查score前5，只要任一GT匹配就给该query一个hit，分母为batch中有GT的query；eval.py以batch size加权再跨rank平均，与mAP不同。预设train max_val_batches=1、run_official=false、best_metric_source=proxy；test设置只产生每head最多100个hypotheses，四headensemble再保留100。论文5.40为test server结果，本轮未重跑或证明本地Lite实作与server完全等价。

依这个顺序读

1. `README.md` ↗
   GitHub · CorrineQiu/VISTA · 62e39d1374

   核对精确EgoVis 2026 STA方法、数据依存与公开评测入口。

   L1–22 · L69–77 · L95–103 · L158–188 · L197–223

2. `configs/vista_train.yaml` ↗
   GitHub · CorrineQiu/VISTA · 62e39d1374

   固定train+val、24个holdout、8-frame输入、proxy验证与四prediction-head设置。

   L19–40 · L58–110

3. `configs/vista_test.yaml` ↗
   GitHub · CorrineQiu/VISTA · 62e39d1374

   test_unannotated、完整推论dump及top100输出预算。

   L19–40 · L58–106

4. `evals/vista_sta/dataloader.py` ↗
   GitHub · CorrineQiu/VISTA · 62e39d1374

   实读label-map来源、validation前24个holdout、其余并入train及DataLoader分母。

   L15–114 · L139–182

5. `evals/vista_sta/ego4d_sta.py` ↗
   GitHub · CorrineQiu/VISTA · 62e39d1374

   追到label.json字段、历史影格pad、类别重编码、过滤与box/image座标。

   L84–148 · L171–203 · L258–335 · L436–496 · L512–625 · L664–776

---

6. `evals/vista_sta/losses.py` ↗
   GitHub · CorrineQiu/VISTA · 62e39d1374

   区分top5样本hit proxy与AP；核对原始像素框逆缩放及submission串行化。

   L10–20 · L68–150

---

7. `evals/vista_sta/eval.py` ↗
   GitHub · CorrineQiu/VISTA · 62e39d1374

   追到batch proxy汇总、head选择、scorer调用与test禁用本地GT评分。

   L637–640 · L704–718 · L772–843 · L854–875 · L1321–1346

---

8. `evals/vista_sta/utils.py` ↗
   GitHub · CorrineQiu/VISTA · 62e39d1374

   确定run_official_evaluator只是subprocess包装，需另读具体计分程序。

   L230–258

---

9. `evals/vista_sta/run_official_metric_only.py` ↗
   GitHub · CorrineQiu/VISTA · 62e39d1374

   核对+1像素IoU、TTC边界、greedy匹配、4×GT之FP额度、noun-class AP分母与version检查。

   L11–15 · L71–144 · L190–345 · L376–428

---

10. `evals/vista_sta/dynamic_metric_head_ensemble.py` ↗
    GitHub · CorrineQiu/VISTA · 62e39d1374

    核对noun/verb/IoU/TTC合并、head权重与输出version 2.0，不将ensemble当metric。

    L23–150 · L153–362

---

11. `scripts/ensemble_vista.sh` ↗

    GitHub · CorrineQiu/VISTA · 62e39d1374

    最终四head包装命令未覆写ensemble的version 2.0预设。

    L1–22

怎么接入我们的benchmark

可重用

重用STASampleDirItem及label.json reader、noun/verb双向map、UID submission schema、具体STAMeanAveragePrecisionLite与head ensemble参数，保留其来源commit。

需要转换

case键为Ego4D版本+split+uid，video_uid/frame另存；框保留原图像像素xyxy、orig_size与resize比例，时间以TTC秒与实际history-frame串行描述。evaluator分开记proxy query-hit与noun-macro Top-5 mAP，保存FP-budget=4×GT、IoU+1、比较边界与head/top100预算。

仍需补齐

原始视频至sample label.json的可验证制作流程、实际manifest/hash与frame时间戳仍需补齐；未取得数据、features、weights，无法报有效case总数。需固定24个holdout身份并按完整benchmark split评分；须对齐ensemble version 2.0与scorer要求1.0、以边界例核验本地scorer/server差异，不能只改字符串便宣称等价。

P221 · STAformer++

Integrating Affordances and Attention models for Short-Term Object Interaction Anticipation

实作尚未确认 · 方法 / 综述 · 原作 · 独立页面

P221精确论文连到作者AFFttention库，但pinned版本停在2024年；已实读旧版STA reader与metric，尚无法把它核定为2026 STAformer++的完整实作。入口虽引用DETR，但必要模块不在完整树中，且新版Swin-T/EgoVideo/DETR配置未对上。

> **版本与身份**
>
> 固定commit 1a1253fa2bde09ef1de4894f3bf872c1fbf270de，日期2024-07-15；2026论文§4是明确架构延伸。完整tree未truncated，因此缺失的DETR/hand模块不是缓存挑档漏抓。README要求依StillFast配置，程序仍import stillfast但目录叫stillfast_code，另有硬编码本机/省略号路径；只能主张已读具体旧版程序段，不能主张新版可重现。
>
> 论文为 Integrating Affordances and Attention models for Short-Term Object Interaction Anticipation，Lorenzo Mur-Labadia等，arXiv:2602.14837v1；P221-discovery保留PDF第1、9页指向Imur98/AFFttention的超链接。这是2024 AFF-ttention的延伸，作者与repo关联已确认；未确认的是2026新版方法与公开程序版本的一致性。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	脱机Ego4D STA v1/v2及由EPIC-KITCHENS active-object tracks/action segments衍生的STA视频标注。environment affordance为历史视频相似场域的noun/verb先验，并非交互模拟器或新机器人场景。
任务	每query输出(box,noun,verb,TTC,score)，另利用environment affordance及interaction hotspot调整预测。论文添加STAformer++的Swin-T、EgoVideo、DETR与learned affordance integration，不能只因同一repo有字样就视为已公开可运行；旧版配置是Dino2D_with_EgoVLP、ROI_HEADS.VERSION=aff。论文EPIC-STA的33,804 train / 7,055 val是衍生标注instances，104 noun / 51 verb是taxonomy，不是添加robot tasks。

题数与数据	Ego4D reader依TRAIN/VAL/TEST_LISTS读info.video_metadata及annotations；每例uid、video_id、frame、objects[*].box/noun_category_id/verb_category_id/time_to_contact。v2配置指向v2数据，但活跃读取仍用video_id、video_uid行被注解，需明确版本适配。fast clip以frame-arange(N×stride)[::-1]取历史，负索引夹到0；配置N=16、stride=1，不能未读metadata就假设FPS。noun+1，非v1 ROI verb+1；writer再减回。AFF档以v_id/frame寻找AFF_N_top3、AFF_V_top3，找不到用全1先验。EPIC pkl为eid、video_id、timestamp、objects内平行arrays；合并noun群组、剔除含others的整例及指定verb后重编ID。EPIC框被乘(1920,1080,1920,1080)，影格int(timestamp×30+1)，16张含当前影格、最低1；AFF却以round(timestamp×30)+2查找，两个frame convention不可混同。test分支直接读val_annotations.pkl，不能列成独立test split。
评估方式	STATask.validation_epoch_end先以uid建dict（重复UID会覆写），再调用OverallMeanAveragePrecision(top_k=5)，输出8个class-agnostic AP及4个按noun平均的mAP。匹配为+1像素面积IoU>0.5、TTC误差≤0.25秒及各项noun/verb条件，按score贪婪一对一配GT；每query、每metric忽略前4×GT对象数个FP。recall分母是已加入GT中的相应类别对象数；AP为VOC precision-envelope积分×100，mAP预设仅平均有GT的noun，不按noun-verb joint class平均。需保留程序缺陷：add的空preds={}分支再次判断len(preds)>0，因而不加入GT；空array字典与真正空字典行为不同，不能宣称未检测案例分母已安全处理。Ego4D _load_annotations对无objects例还会造出[0,0,100,100]及零标签dummy target，不能拿test-unannotated当validation真值。

依这个顺序读

1. `README.md` ↗
   GitHub · lmur98/AFFttention · 1a1253fa2b

   确认公开库仍介绍2024 AFF-ttention / STAformer、外部affordance资产及StillFast依存。

   `L3–14 · L25–51 · L55–78`

2. `stillfast_code/models/stillfast.py` ↗
   GitHub · lmur98/AFFttention · 1a1253fa2b

   核对实际FasterRCNN入口、DETR未完成分支及导入但不在pinned tree的模块。

   `L1–30 · L73–128`

3. `stillfast_code/test_dir/Aff_ttention_v2/config.yaml` ↗
   GitHub · lmur98/AFFttention · 1a1253fa2b

   确认16影格stride1、v2 taxonomy、ROI aff head与split配置。

   `L13–35 · L39–76 · L114–120 · L142–162`

4. `stillfast_code/datasets/ego4d_sta_still.py` ↗
   GitHub · Imur98/AFFttention · 1a1253fa2b

   读annotations/videos结构、train清理、video_id/v2差异、dummy GT与类别offset。

   L22–82 · L102–153 · L232–258

---

5. `stillfast_code/datasets/ego4d_sta_still_video.py` ↗
   GitHub · Imur98/AFFttention · 1a1253fa2b

   固定历史frame索引、AFF_N/V_top3 sidecar及输出targets。

   L9–17 · L72–110 · L168–226

---

6. `stillfast_code/datasets/ek_55_sta_dataset.py` ↗
   GitHub · Imur98/AFFttention · 1a1253fa2b

   核对EPIC分类合并/剔除、pkl split、30FPS、框乘1920×1080与affordance时间偏移。

   L79–116 · L138–213 · L224–256 · L260–405

---

7. `stillfast_code/models/faster_rcnn_AFF_sta.py` ↗
   GitHub · Imur98/AFFttention · 1a1253fa2b

   确定已公开的affordance是sidecar prior乘softmax后范式，并非完整新版learned memory实作。

   L209–243 · L364–405 · L423–489

---

8. `stillfast_code/tasks/sta.py` ↗
   GitHub · Imur98/AFFttention · 1a1253fa2b

   核对UID聚合去重、OverallMeanAveragePrecision(top_k=5)及submission offset逆映射。

   L44–90 · L94–193

---

9. `stillfast_code/evaluation/sta_metrics.py` ↗
   GitHub · Imur98/AFFttention · 1a1253fa2b

   读具体matching、FP容忍预算、AP分母、macro noun averaging及空预测处理缺陷。

   L1–205 · L215–266 · L268–359 · L416–524

怎么接入我们的benchmark

可重用

可重用已核读的旧版Ego4D/EPIC reader规格、noun/verb offset、affordance sidecar schema与原生AP/mAP定义，标成AFF-ttention 2024 lineage；论文2026方法另存版本关系。

需要转换

保留source→Ego4D/EPIC衍生标注关系；case使用版本+split+uid/eid，区分原annotation、清理后有效case与taxonomy。显式映射EPIC normalized xyxy→1920×1080像素、timestamp→影格及独立AFF lookup frame；保留noun合并/剔除表、background offset、FP-budget及AP vs noun-macro mAP。

仍需补齐

新版STAformer++正确revision与Swin-T/EgoVideo/DETR/learned-affordance完整实作；pinned tree缺少入口导入的detr_criterion.py、detr_backbone.py、detr_transformer.py、detr_matcher.py及ego4d_sta_hands_still_video.py，DETR_head也未在入口定义。另缺正式annotation/sidecar资产与portable路径、v1/v2字段适配、EPIC双frame偏移核验及空预测/无GT的计分测例。

P222 · Uni-Hand

Uni-Hand: Universal Hand Motion Forecasting in Egocentric Views

内核内容已核读 · 主来源 · 原作 · 独立页面

已核读Uni-Hand human-video demo与作者指向的MMTwin/EgoPAT3D reader及具体ADE/FDE。主库现行流程只以首影格条件预测右手腕与接触转换；不能将论文全部2D/3D、多关节、head-motion及robot结果视为同一套已公开评测。

> **版本与身份**
>
> 主库commit 7f3edd5955fcb786b78b343510d7b2297694393b；MMTwin commit bd0faf148ae574accd5a4c1e7cd173f6416a52e6。README称toy有100段视频，而本版split roster是100 train+5 test，保留此粒度/版本差异。主库unseen_envs已标deprecated且两个test loader读同档；MMTwin的test_novel才是实际不同scene split。论文表1的USST修正引用不能视为本轮已核读或新版metric等价证明。
>
> arXiv:2511.12878v4（2026-05-11），Junyi Ma等，精确题名Uni-Hand: Universal Hand Motion Forecasting in Egocentric Views。PDF连作者项目页，页面Code指IRMVLab/UniHand、Data指IRMVLab/MMTwin；MMTwin README反向指Uni-Hand为extended version，本身论文为2504.07375。项目页footer的nerfies是网页模板，论文USST erratum是baseline依存，均非本篇模型库。

领域	穿戴交互与动作界面、通用对象与机动作业、居家整理与清洁、餐饮与烹饪
环境	主库为RealSense L515人类示范的pick-and-place / open-door场景，首RGBD影格产生固定相机座标点云；MMTwin用EgoPAT3D-DT移动头戴视角，以odometry将轨迹表成首camera参照。CABH的cup/apple/box与HAT robot-transfer属论文/前身不同子集，不可和主库toy split混成独立robot environment registry。
任务	Uni-Hand论文涵盖手部2D/3D中心与指定关节、head motion及contact/separation；本次主库实际epoch loop取joint0，注明TODO multi-finger，preprocess只读right_keypoints；motion_feat为全零，视觉使用第一张feature，观测mask只保留第0个手腕点。输出是未来腕点与两个接触/分离峰，非完整21关节姿态，也不是可直接运行的末端action。

题数与数据	主库以date folder读traj3d_in_cam_dict_refine.pkl、date.npy视觉特征、rgb数字文件名与date_folders.csv。所谓traj3d原始值实为21×(u像素,v像素,depth-mm)；reader对depth除1000、u/w与v/h、z/max_depth后各减0.5，保留有效frame IDs，截/零补至40。CSV两个原始frame ID映到有效串行的0-based index；没有FPS/秒换算。config为1280×720、max_depth=1、50^3 voxel、0.02公尺格、origin[-0.5,-0.5,0]。split档有100 train与5 test唯一ID且无交集；它们是清单笔数，未下载素材核验有效case。val/test/test_novel全部走同一test_split.txt。MMTwin则有明列scene/record train/val/test；novel scenes13/14/15，pkl读traj2d/traj3d/num_preserve，最多40点，3D以odometry连乘转首camera，再以(u/w,v/h,z/3)-0.5编码，非train的未来motion/odometry先以最后观测值替代。
评估方式	主库实际scorer在epoch_feat.py：单次diffusion sample，gap=1、3点moving-average平滑；加回0.5并以内参反投影XYZ，z使用预设max_depth=1，单位公尺。future slice=[1,nframes)，ADE先对该case所有有效未来点的Euclidean error取平均，FDE只取最后有效点，最后对case平均，非全数据逐frame加权。CE将future contact曲线Gaussian平滑、取最高两个局部峰并排序，两个峰的绝对index误差平均后再跨case平均；缺峰用-1补而未剔除。存在明确索引疑点：pred峰是future slice相对index，GT是完整valid串行index，scorer未加start_=1或减GT offset，CE不是可直接当秒的MAE。MMTwin actual loop用固定ratio（预设0.6），floor(nframes×ratio)作观测长度，单次sample；相同逐case ADE/FDE，test_space=3d为公尺，其他值走投影、clip/floor像素再除图像尺寸的2D距离，并非best-of-K。论文robot SR为每task 10次trial的报告；已读repo没有该robot成功checker。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **3** CABH interaction tasks · 原文页 9
- **5** HAT robot tasks · 原文页 10
- **1,200** CABH videos · 原文页 9
- **50** HAT physical trials，5×10 · 原文页 10

依这个顺序读

1. `README.md` ↗

   GitHub · IRMVLab/UniHand · 7f3edd5955

   确认Uni-Hand主库的human-video demo范围、MMTwin前身关系与heuristic grasp。

   `L1–27 · L116–140 · L193–199 · L236–261 · L279–326`

2. README.md ↗

   GitHub · IRMVLab/MMTwin · bd0faf148a

   确认MMTwin/EgoPAT3D/CABH数据角色，CABH专用模型程序仍标示待发布。

   L5–35 · L161–184 · L194–216

---

3. unihand/configs/traineval.yaml ↗

   GitHub · IRMVLab/UniHand · 7f3edd5955

   固定相机内参、depth尺度、40影格、split、gap与平滑预算。

   L1–63

---

4. unihand/data_utils/train_split.txt ↗

   GitHub · IRMVLab/UniHand · 7f3edd5955

   实读100个唯一train roster ID，与test比较无交集。

   L1–100

---

5. unihand/data_utils/test_split.txt ↗

   GitHub · IRMVLab/UniHand · 7f3edd5955

   实读5个唯一test roster ID；这不是5个task。

   L1–5

---

6. unihand/data_utils/date_folders.csv ↗

   GitHub · IRMVLab/UniHand · 7f3edd5955

   确认CSV实际只有date与两个整数frame标记，非秒制contact timestamp。

   L1–6

---

7. preprocess_human_video/generate_hand_trajs.py ↗

   GitHub · IRMVLab/UniHand · 7f3edd5955

   确认right-hand 21点是u/v/depth-mm，只有000000影格写入点云。

   L37–59 · L76–96 · L124–154 · L157–179

---

8. `unihand/data_utils/HumanDataLoader.py` ↗

   GitHub · IRMVLab/UniHand · 7f3edd5955

   追到有效frame对齐、pixel/depth范式、padding、voxel与contact index，三个非train split共用清单。

   L31–168 · L194–213 · L245–315 · L330–374

---

9. `unihand/traineval.py` ↗

   GitHub · IRMVLab/UniHand · 7f3edd5955

   确认demo入口选用TrainEvalLoop与test/test_novel loader。

   L23–31 · L85–107 · L119–149

---

10. `unihand/netscripts/epoch_feat.py` ↗

    GitHub · IRMVLab/UniHand · 7f3edd5955

    核对实际单腕/首frame/单次sample评测、ADE/FDE公尺分母、CE两峰与索引偏移。

    L34–114 · L201–221 · L300–322 · L573–746 · L778–786

---

11. `unihand/viz_predicted_trajs.py` ↗

    GitHub · IRMVLab/UniHand · 7f3edd5955

    确认相机座标中的固定grasp_offset，没有机器人controller/success checker。

    L21–25 · L85–119

---

12. `options/expopts.py` ↗

    GitHub · IRMVLab/MMTwin · bd0faf148a

    固定EgoPAT3D的seen/unseen、ratio0.6、40frame与diffusion预算。

    L1–37 · L40–74

---

13. `data_utils/EgoPAT3DLoader.py` ↗

    GitHub · IRMVLab/MMTwin · bd0faf148a

    核对scene/record split、traj2d/traj3d/num_preserve、首camera投影及非train未来motion屏蔽。

    L38–133 · L147–173 · L220–343 · L437–456

---

14. `traineval.py` ↗

    GitHub · IRMVLab/MMTwin · bd0faf148a

    追到test_novel选择、seed与实际metric loop参数。

    L23–46 · L126–136 · L149–185

---

15. `netscripts/epoch_feat.py` ↗

    GitHub · IRMVLab/MMTwin · bd0faf148a

    确认真正运行的ratio mask、单次sample与逐case ADE/FDE，2D为图像尺寸范式。

    L27–84 · L451–587 · L613–620

怎么接入我们的benchmark

可重用

重用两库各自split与reader、有效frame index、内参/voxel设置、逐case ADE/FDE与contact峰值定义；保留MMTwin为前身与母数据转接来源。

需要转换

case以repo版本+dataset+scene/date/clip+观测长度识别；把u/v/depth-mm、范式latent及XYZ-m分开保存，记录camera参照与有效frame至原frame映射。evaluator分开ADE、FDE、CE、paper-reported robot SR，保存每case未来点数、sample数、smoothing/gap与ratio。grasp_offset属另行校准的camera-frame几何转换。

仍需补齐

RGBD、refined trajectories、特征、点云与weights未取得，roster不等于可运行case数；需修正/核验CE offset、缺峰策略、改max_depth时的反范式一致性。需补独立validation/novel split、论文其余数据集/多target/robot协定，以及相机到robot基座外参、运动控制与成功判定。MMTwin不能充当Uni-Hand所有新版结果的实作证据。

P223 · INSIGHT

Intention-Guided Cognitive Reasoning for Egocentric Long-Term Action Anticipation

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

精确INSIGHT旧网址已转址至iLearn-Lab/AAAI26-INSIGHT；已读feature reader、stage1分类、具体串行ED与GRPO reward。ED只平均有GT对应的prediction records、没有强制五候选或20步；另有reader语法错误及reward/plugin命名缺口，尚不能直接运行完整流程。

> **版本与身份**
>
> commit ab9495968b80ccae7a905ecb663a9d101873cf75（canonical iLearn-Lab/AAAI26-INSIGHT）。read-only静态解析没有导入/运行上游程序；全部模型、ms-swift与MiniLM均未运行。README称完整两阶段，但本轮只核读所列来源段，未认定论文分数可重现。
>
> 论文为 Intention-Guided Cognitive Reasoning for Egocentric Long-Term Action Anticipation，Qiaohui Chu、Haoyu Zhang、Meng Liu、Yisen Feng、Haoxiang Shi、Liqiang Nie；cached PDF为arXiv:2508.01742v2（2025-11-15），第1页直接指向CorrineQiu/INSIGHT。GitHub metadata依repository ID转址后full_name为iLearn-Lab/AAAI26-INSIGHT，README题名/作者与AAAI26引用一致；这是搬移别名，不是另一篇同名项目。 旧入口CorrineQiu/INSIGHT的已保存GitHub metadata回应指向iLearn-Lab/AAAI26-INSIGHT，按仓库别名保留，不另外算成未读的第二个仓库。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	脱机人类第一人称视频，Ego4D-v2 LTA及EPIC-Kitchens-55 / EGTEA Gaze+；stage1读full-frame与hand-object区域的预抽特征。不存在可供policy rollout的交互环境。
任务	stage1是verb/noun action recognition，stage2产生think/intention/answer文字与未来verb-noun串行。Ego4D论文协定观测8个action segments、预测5条各20个action的串行；8不是8张frame。EK55/EGTEA则预测视频前25/50/75%之后会出现的verb集合，报All/Freq/Rare mAP，不是同一ED题型。
题数与数据	ActionDataset按train.json / val.json / fho_lta_test_unannotated.json的clips分组clip_uid，再依action_idx排序；长clip切window_size=8、stride=1重叠窗口，短clip逐action成例。每action读split/<clip_uid>_<action_idx>.pt两路特征，标签verb_label/noun_label；缺feature会使不完整窗口被舍弃。main配置input_dim=1408、117 verb / 521 noun，collate再摊平窗口，因此同action可能重复计数。reader未提供原影格时间/fps/feature采样manifest；test就算is_test=True仍会在getitem读mask feature。stage2依外部ms-swift chat JSONL，messages assistant含<answer>与<intention>，images提供路径；cal_ED把images[0]父目录当clip_uid，GT同ID会覆写。pred JSONL用clip_uid、res_list；没有公开的完整stage1→chat/prediction转换与split资产。

评估方式	stage1 train/validate是分类正确action occurrences除以flattened有效标签数×100；main的co-occurrence validation在各top5 verb/noun组合中挑raw_cooccurrence>0且概率乘积最大的pair。prior缺档时只由train创建，但重叠窗口会重复action。cal_ED以逗号分动作、第一个词为verb，其余为noun；保留大小写，不做taxonomy ID校验。具体DP允许插入/删除/替换及相邻交换（受限交换递归，未证明与官方Damerau实作等价）。对每条res_list候选截至GT长度L，分别取最小action/verb/noun距离，三项可来自不同候选，再各除L、最后按处理到的prediction records平均。候选数不强制5、L不强制20；缺GT的prediction被跳过，完全缺prediction的GT不进分母，重复prediction ID可重复计数，L=0给0，空res_list会使min失败。reward不是此ED：只接受两个英文字token的pair并lowercase，至少20对才开gate，内容分数分母固定20；intention为MiniLM cosine经β=0.8、γ=40 sigmoid映射，R=gate×(0.85内容+0.05意图+0.05语言+0.05格式)，shell再以0.9此R+0.1外部soft_overlong组合。意图reward不是意图分类accuracy；EK55/EGTEA的All/Freq/Rare mAP scorer未在此版本公开。

依这个顺序读

1. `README.md` ↗
   GitHub · iLearn-Lab/AAAI26-INSIGHT · ab9495968b

   核对精确论文身份、两阶段范围与外部特征依存。

   `L1–36 · L123–140 · L146–172 · L204–223`

2. `HandObject/README.md` ↗
   GitHub · iLearn-Lab/AAAI26-INSIGHT · ab9495968b

   确认feature与annotation文件命名、stage1输出用途。

   `L1–31 · L43–70`

3. `HandObject/dataset.py` ↗
   GitHub · iLearn-Lab/AAAI26-INSIGHT · ab9495968b

   读clip/action_idx窗口、数据过滤与实际feature加载；第25行语法错误已静态确认。

   `L10–134`

4. `HandObject/main.py` ↗
   GitHub · iLearn-Lab/AAAI26-INSIGHT · ab9495968b

   追到flattened action分母、co-occurrence重排、train-only prior与val/test设置。

   `L30–113 · L126–213 · L350–427`

5. `HandObject/train.py` ↗

   GitHub · iLearn-Lab/AAAI26-INSIGHT · ab9495968b

   区分stage1分类accuracy与长期串行评测。

   L14–105

---

6. `CognitiveReasoning/README.md` ↗

   GitHub · iLearn-Lab/AAAI26-INSIGHT · ab9495968b

   确认chat标签schema及GRPO reward与脱机ED分工。

   L1–43 · L65–70

---

7. `CognitiveReasoning/cal_ED.py` ↗

   GitHub · iLearn-Lab/AAAI26-INSIGHT · ab9495968b

   核对实际字符串parser、相邻交换DP、best候选、GT长度分母与缺失case处理。

   L8–159

---

8. `CognitiveReasoning/my_rewards_intention.py` ↗

   GitHub · iLearn-Lab/AAAI26-INSIGHT · ab9495968b

   具体reward：20-pair gate、ED/20、MiniLM intention sigmoid、格式与语言项。

   L2–15 · L22–105 · L149–217 · L220–318

---

9. `CognitiveReasoning/plugin_in_log_intention.py` ↗

   GitHub · iLearn-Lab/AAAI26-INSIGHT · ab9495968b

   核对reward registry及与实际文件名不同的my_rewards_new_intention导入。

   L1–20 · L665–677

---

10. `CognitiveReasoning/run_external_reward_func_7B_qwen_intention.sh` ↗

    GitHub · iLearn-Lab/AAAI26-INSIGHT · ab9495968b

    确认GRPO五个generation、0.9/0.1权重与尚未具体化的data/plugin路径。

    L6–42

怎么接入我们的benchmark

可重用

保留clip/action身份、两路feature schema、stage1 taxonomy与train-only co-occurrence规格、脱机ED的实际parser/DP，以及reward各分量。公开来源以canonical repo记录并保留旧alias。

需要转换

分开source、action-occurrence、8-action context window、20-action forecast case与多候选输出；case键应包含clip_uid+最后观测action_idx，不能只用image父目录。evaluator分列stage1 accuracy、各自best-of-K normalized ED、intention相似度reward及论文mAP；保留实际K、L、分母、缺失/重复UID与大小写/多词noun策略。

仍需补齐

完整annotation/features与chat生成/预测脚本、8→20对齐及五候选验证；需对所有GT补齐失败case并核验官方ED一致性。静态ast.parse确认HandObject/dataset.py第25行assert末尾逗号造成SyntaxError；plugin导入my_rewards_new_intention但树只有my_rewards_intention.py，shell指plugin_new_in_log_intention.py但树只有plugin_in_log_intention.py；reward使用nullcontext却未导入。需修正这些运行缺口及补EK55/EGTEA mAP实作。

P224 · EMPIRE

EMPIRE: Explicit Manipulation Planning as a Learnable Intermediate Representation for Egocentric Hand-Motion Forecasting

内核内容已核读 · 主来源 · 原作 · 独立页面

已追完EMPIRE的index/episode reader、30→12FPS采样、混合MANO动作表示及best-of-8 joint scorer。公开库有核心程序，但EMPIRE-651K数据与前处理明示尚未发布；650,910训练窗口与111活动标签为论文数字，未由实际dataset逐笔验证。

> **版本与身份**
>
> 固定commit bea74bb146baa750b02f291754cafd5ed6cd0bfe。标准StageII配置与predicted_plan ablation使用预测plan；ground_truth_plan另列。直接运行eval_mse的预设K=5、COT_GENERATE_THEN_CONDITION=0，可能使用GT plan suffix；正式shell才设置K=8与online生成，因此两入口不可混同。online分支重读raw image/coarse instruction而不用GT suffix，但数据加载仍依赖reference-plan存在；不能宣称是完全无标注部署封装。所有内容仅静态核读，未运行数据前处理、模型、MANO或评测。
>
> arXiv:2608.22449v1，Wen Wang、Ruibing Hou、Hong Chang、Shiguang Shan、Xilin Chen，EMPIRE: Explicit Manipulation Planning as a Learnable Intermediate Representation for Egocentric Hand-Motion Forecasting。PDF第1页直接连wangwen-banban/EMPIRE，README题名/arXiv一致。VITRA为程序与数据格式基础，EgoDex为母数据，Being-H0为比较baseline，三者不能另算本篇新数据。

领域	穿戴交互与动作界面
环境	EgoDex/Apple Vision Pro的人类桌面操作第一人称视频，RGB、相机内外参、双手追踪骨架转MANO、task caption与per-hand plan。reader在query frame的camera座标表示整段未来姿态；公开FrameDataset只支持human，不提供robot交互环境。
任务	从current RGB、初始双手状态与caption生成操作plan，再预测双手未来motion；plan描述不是可运行robot技能。论文650,910个5秒train windows、6,836个test windows、111个活动标签需分开计数。Part1 ablation另以训练任务重叠定义26 seen tasks/1,247 windows与85 unseen tasks/5,589 windows；并非全五partition训练的预设unseen切分。task summary从episode名称或obj_class/video_name解析label，再对指定training annotation snapshot比对，没有封闭111-task registry。

题数与数据	preferred layout为dataset/episode_frame_index.npz（index_frame_pair[N,2]=episode_index/frame_index、index_to_episode_id[E]）、episodic_annotations/id.npy及statistics.json；legacy .npy字典/processed_episodes_vitra_format也可读。episode含video_name、video_decode_frame、intrinsics、extrinsics及left/right的beta、kept_frames、global_orient_worldspace、transl_worldspace、hand_pose、joints_worldspace、text/anno_type；caption→instruction、plan→cot只是alias。标准设置source_fps=30、target_fps=12，step=2.5，以np.rint取整，并可依此过滤index rows；future=59创建含current的60个window位置，再取next-state而产生60个未来action。OOB虽clip索引，但被mask剔除，60个slots不保证60个有效影格。text范围采[start,end)，plan匹配却允许end且取最近范围。每hand51维为逐步腕平移m、腕旋转xyz Euler-radians及下一步绝对15×3手指Euler；use_rel=false仍保留腕部relative分量。两手102维action补到288；原state122维含betas，padding移除betas后补到296。predicted plan ABI为schema_version=1.0、plans[episode_id:frame_index]，主StageII配置明确读该sidecar。
评估方式	run_full_eval预设REPEAT_TIMES=8、ONLINE_PLAN=1、save_repeated_samples；model config为flow matching 4步。eval_mse先依mask选范式动作MSE最小者，分母为有效action scalar数，这不是论文MPJPE。compute_egodex_metrics优先读sampled_actions[N,K,T,D]，逐候选反范式并recon_traj：累加腕平移、左乘腕旋转、手指使用绝对角，再以MANO重建21关节；beta固定0、左手套轴修正，剔除初始state，只评未来。mask为hand/frame有效性，非独立joint可见性。每window MPJPE=全部有效hand-frame之21-joint Euclidean均值；等价分母21×有效hand-frame数。选该MPJPE最小的同一候选来算wrist joint0与finger-relative（扣wrist后只取其余20关节），不可各指针另挑best。FDE为每个有GT手最后有效frame的joint均值，再对手平均。最终对非NaN windows的metric等权nanmean，再m×1000转mm；num_samples仍包含无有效手而为NaN的records，须另报有效分母。若NPZ没有sampled_actions，scorer把pred_actions当K=1，无法恢复best-of-8。shard merge按sample_positions排序并检查连续性；task summary再分组，并不将总分改成task-macro平均。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **111** retained source task labels · 原文页 4
- **650,910** training windows · 原文页 4
- **6,836** held-out test windows · 原文页 4, 6

依这个顺序读

1. `README.md` ↗

   GitHub · wangwen-banban/EMPIRE · bea74bb146

   确认精确论文、dataset coming soon、VITRA依存与正式eval链。

   L1–22 · L35–50 · L84–117

---

2. `docs/DATA_SCHEMA.md` ↗

   GitHub · wangwen-banban/EMPIRE · bea74bb146

   核对index/episode/plan ABI，明确区分runtime格式与未发布dataset/preprocessing。

   L1–85

---

3. `empire/datasets/schema.py` ↗

   GitHub · wangwen-banban/EMPIRE · bea74bb146

   读preferred/legacy resolver、index形状、caption/plan别名、canonical sample ID与sidecar验证。

   L25–158 · L164–195 · L198–264

---

4. `empire/configs/train_stage2_actor.json` ↗

   GitHub · wangwen-banban/EMPIRE · bea74bb146

   固定predicted-plan条件、60步、30→12FPS、8次sample及4-step flow matching设置。

   L1–110

---

5. `empire/configs/ablations/ground_truth_plan.json` ↗

   GitHub · wangwen-banban/EMPIRE · bea74bb146

   核对GT-plan ablation与预设sidecar条件的差别。

   L1–108

---

6. `empire/configs/ablations/predicted_plan.json` ↗

   GitHub · wangwen-banban/EMPIRE · bea74bb146

   核对明确的predicted plan来源与sidecar路径。

   L1–110

---

7. `empire/datasets/data_mixture.py` ↗

   GitHub · wangwen-banban/EMPIRE · bea74bb146

   empire_train只是一个具名dataset mixture，没有111个task registry。

   L1–7

---

8. `empire/datasets/dataset.py` ↗

   GitHub · wangwen-banban/EMPIRE · bea74bb146

   追到EpisodicDatasetCore/EvalDataset、plan选择、suffix数据及model tensor字段。

   L30–219 · L219–259 · L268–340

---

9. `empire/datasets/human_dataset.py` ↗

   GitHub · wangwen-banban/EMPIRE · bea74bb146

   核读FPS推断/采样、anchor-camera转换、有效mask、相对腕/绝对finger混合表示、padding及evaluation同约定。

   L48–123 · L169–283 · L345–439 · L536–597 · L639–661 · L731–787 · L791–842 · L873–947 · L1040–1202 · L1283–1406 · L1430–1558 · L1596–1686 · L1681–1750 · L1850–1899

---

10. `empire/utils/data_utils.py` ↗

    GitHub · wangwen-banban/EMPIRE · bea74bb146

    追到mean/std范式及实际step-wise wrist/pose重建，不能把latent MSE当MPJPE。

    L268–408 · L462–539

---

11. `scripts/run_full_eval.sh` ↗

    GitHub · wangwen-banban/EMPIRE · bea74bb146

    正式入口预设K=8、online plan、保留全部sample、merge→joint metric→task summary。

    L1–106

---

12. `scripts/eval_mse.py` ↗

    GitHub · wangwen-banban/EMPIRE · bea74bb146

    核对K预算、GT-plan/online分支、MSE预选与sampled_actions/UID/FPS输出。

    L21–116 · L152–190 · L192–274 · L275–391 · L379–444 · L450–583

---

13. `scripts/merge_eval_shards.py` ↗

    GitHub · wangwen-banban/EMPIRE · bea74bb146

    确认按sample_positions排序及连续性检查；字段只取各shard交集。

    L1–56

---

14. `scripts/egodex_eval_utils.py` ↗

    GitHub · wangwen-banban/EMPIRE · bea74bb146

    重建左右手21关节、beta=0、左手chirality、初始frame剔除及mask。

    L19–74 · L157–190 · L192–289 · L291–307

---

15. `empire/models/mano.py` ↗

    GitHub · wangwen-banban/EMPIRE · bea74bb146

    确认SMPL-X MANO补五个指尖并转OpenPose 21-joint顺序。

    L1–57

---

16. `scripts/compute_egodex_metrics.py` ↗

    GitHub · wangwen-banban/EMPIRE · bea74bb146

    完整核读具体joint scorer：per-hand有效frame、best MPJPE、wrist/finger-relative/FDE、NaN与window平均。

    L1–406

---

17. `scripts/summarize_egodex_all_tasks.py` ↗

    GitHub · wangwen-banban/EMPIRE · bea74bb146

    核对task解析、training snapshot定义seen/unseen及episode/raw-file/window各自计数。

    L1–98 · L157–238

怎么接入我们的benchmark

可重用

重用versioned schema/resolver、canonical sample ID、plan sidecar、FPS/mask逻辑、MANO adapter、step重建、best-of-K MPJPE与task provenance摘要；保留EgoDex/VITRA lineage。

需要转换

分开source/domain/environment/task/window/evaluator；case键为dataset revision+episode_id+frame_index，保存source/video/target FPS及np.rint后实际indices。将51维混合action、102有效维、288/296 padding及mean/std明确分层；保留anchor-camera与xyz-radians、公尺/mm转换。evaluator保存K、4步设置、全部sampled_actions、选中best_k、21/20 joint定义、每window有效hand-frame及NaN分母。

仍需补齐

未发布的index/episodes、骨架→MANO拟合与caption/plan前处理、数据/统计/sidecar/weights/MANO资产尚未闭合；不能验证650,910/6,836笔或真正split无泄漏。需核对eval dataset statistics.json与scorer STATISTICS_PATH均使用对应training normalization，避免反范式版本不同。须锁定ONLINE_PLAN、各shard皆保留sampled_actions、真正K与完整case coverage；数据格式称HF-compatible不代表已确认HF dataset repo/revision。

P225 · Exo2EgoPose

Exo2EgoPose: Leveraging Exocentric Demonstrations for Vision-Language guided Egocentric 3D Hand Pose Forecasting

文件 / 网站 · 主来源 · 原作 · 独立页面

已确认精确Exo2EgoPose论文与作者repo；固定版本完整树只有四行README，明示source code与benchmark仍在准备。可核读论文任务/数据/指针定义，没有pinned data reader、MPJPE/MPJVE或CALVIN成功checker可检查。

> **版本与身份**
>
> repo固定commit 17c1d8c09e357045aadcdad13708ce48b30cff2e（2026-09-22），tree未truncated且只有README.md。论文摘要写code available，而此快照README仍为will be released soon；依实际程序状态栏public_readme_only。论文未提供真正benchmark文件，未以同名repo或母数据现行版本补成已发布。
>
> Zhaofeng Shi、Heqian Qiu、Lanxiao Wang、Xiang Li、Hongliang Li，Exo2EgoPose: Leveraging Exocentric Demonstrations for Vision-Language guided Egocentric 3D Hand Pose Forecasting，cached PDF为arXiv:2607.15890v2（2026-08-05）。PDF第1页直接指向ZhaofengSHI/Exo2EgoPose，README精确题名一致；因此是已确认作者库的placeholder，不是repo找不到或无关同名库。

领域	装配与生产作业、穿戴交互与动作界面
环境	脱机AssemblyHands/Assembly101玩具组装、Ego-Exo4D活动与EgoMe正确模仿配对视频；AssemblyHands/Ego-Exo4D有同步多视角，EgoMe-pose的Ego/Exo配对可能不同步。CALVIN ABC→D是另行teacher-to-policy蒸馏的robot下游实验。
任务	VL-EHPF在t时刻输入1–10步Ego影格、语言instruction与同段手姿，输出t+1至t+10的42×3座标（两手各21点）及42点validity。论文DERM把涵盖观测与未来的配对Exo视频当训练监督，从Ego输入重建Exo表征，再交GLMM；推论公式只含Ego/语言/pose，不能把实际未来Exo影格加入test条件。它预测人体pose，不直接输出robot动作。

题数与数据	论文报AssemblyHands衍生episode train/val/test=6,120/355/355，Ego-Exo4D=10,869/1,540/1,540，EgoMe-pose=6,067/1,344/2,648；这是episode数，不是10-frame forecast windows、joint数或实际可下载case数。AssemblyHands/EgoMe-pose为15FPS、Ego-Exo4D为30FPS，RGB resize224×224，10步预测因此有不同时间长度。AssemblyHands保留每手>10个valid joints且root有效的frame，world→Ego camera并依共用frame ID连Assembly101文字；随机Exo view配对，从原val随机切50%作test。Ego-Exo4D须Aria去畸变、world→camera及joint-order映射，文字window为atomic timestamp前0.5秒至后1秒且每frame pose有效，也将原val随机半分作test。EgoMe-pose以InterHand相对姿态+RootNet root-depth转绝对座标，剔除false imitation、hand confidence<0.6或有效frame比例≤95%的episode；异步Exo以片段相对位置线性对齐。上述随机seed、episode/frame清单、joint permutation、标注档schema均无公开reader可核。
评估方式	仅论文§4.1.2：MPJPE比较root-aligned predicted/GT关节的Euclidean距离；MPJVE比较关节位移，论文单位写mm，没有可核程序证明另除Δt，不能改记mm/s。这与EMPIRE的absolute-camera MPJPE不同。虽模型预测validity，实际scorer使用GT或pred mask、两手/root是否计入、分母是有效joint-frame或先逐episode平均、位移是否包含最后观测点及缺失邻接frame处理均待程序确认，不能用10×42固定分母填空。CALVIN表列连续完成1–5任务比例、Avg.L.与Avg.R.，采ABC训练→D测试及Exo2EgoPose teacher蒸馏GR-1类student；本版无robot action adapter、trial manifest或具体success checker可读，不能把手姿误差换成robot成功率。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **355** AssemblyHands test episodes · 原文页 5
- **1,540** EgoExo4D test episodes · 原文页 5
- **2,648** EgoMe-pose test episodes · 原文页 6

依这个顺序读

1. `README.md` ↗

   GitHub · ZhaofengSHI/Exo2EgoPose · 17c1d8c09e

   精确题名与source code/benchmark尚在准备的公开状态。

   L1–4

怎么接入我们的benchmark

可重用

重用已确认paper/repo身份、三个衍生数据集的母来源、42点/10步/validity任务契约及论文明列的split/采样条件；repo仅提供发布状态证据。

需要转换

case以母数据版本+衍生episode+query frame+split+FPS识别；保存world/camera/root-aligned三层座标、两手joint-order与validity。另记train-only Exo监督、同步/相对时间线性对齐、原val→新val/test关系；CALVIN蒸馏独立为下游reuse关系，metric保留pose与robot两类原生单位。

仍需补齐

程序与EgoMe-pose benchmark尚未发布；缺前处理、reader、精确split/seed、有效case manifest、MPJPE/MPJVE具体分母与root/mask约定、weights及CALVIN蒸馏/运行成功判定。不能运行或声称本轮重现论文分数。

P226 · EgoTraj

EgoTraj: Real-World Egocentric Human Trajectory Dataset for Multimodal Prediction

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoTraj提供户外行人头部/视线/视频数据与EgoViz reader；公开文件可支持数据对齐，但不是完整trajectory预测baseline实作。四元数顺序在README与reader注解不一致，需核验。

> **版本与身份**
>
> 固定902c354、原作2605.19004；README结果是原作报告，本轮只核读数据/可视化界面，未重跑预测模型。

领域	交通移动与车辆维修、穿戴交互与动作界面
环境	真实都市步行、7个预设waypoints间自行选路，MetaQuestPro录制；75participants不是75个不同物理环境，位置为session-relative、Y向上、地平面x-z，没有地理坐标。
任务	行人trajectory forecasting与AR导航研究，原文/README采1.5秒观测→3.5秒预测；不同participant/waypoint/unfamiliar splits另列。不是robot实际导航任务完成benchmark。
题数与数据	HDF5按session含pose position/rotation/velocity/angular_velocity/timestamp、gaze origin/direction、video segment/frame/has_video；scene annotations为1fps，用pose_idx回连30Hz数据。README称quaternion wxyz，reader按xyzw解读；原始数据必须核定。未匹配视频frame以NaN标示。
评估方式	README列ADE/FDE(m)、L1_head与bootstrap结果，但repo主要EgoViz，未确认完整baseline/scorer。视频在拍摄时已叠红色gaze dot，RGB-only是否允许这个线索需在case条件明示；1fps VLM scene descriptions也需有独立可见性/生成版本。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **75** participants and recording sessions · 原文页 4, 5
- **10.7** recording hours · 原文页 5
- **7** navigation landmarks · 原文页 4

依这个顺序读

1. `README.md` ↗
   GitHub · yehiahmad/EgoTraj · 902c354d17

   原作、75participants、sensor clock、预测/split与数据契约

   `L1–60 · L61–79 · L124–167 · L222–248`

---

2. `ego_viz.py` ↗
   GitHub · yehiahmad/EgoTraj · 902c354d17

   30Hz近邻重采样及HDF5/annotation/video join读取

   `L1079–1120 · L1235–1275`

怎么接入我们的benchmark

可重用

session/pose_idx跨模态join、原生视线与local坐标、数据reader和source split设计。

需要转换

case固定participant/session/观测截止与预测窗口；统一quaternion及clock、保留has_video mask、原始/叠点图像与VLM annotation来源；模态消融先界定合法可见线索。

仍需补齐

全部数据/split manifest、quaternion查核、baseline/scorer与姿态metric定义、含gaze-dot版本的公平输入设计。

P227 · EggHand

EggHand: A Multimodal Foundation Model for Egocentric Hand Pose Forecasting

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

EggHand 是在 EgoH4 / EgoExo4D 手部轨迹上评测的预测方法；「action」在这里是未来 42 个人体关节座标，不能直接当成机器人控制命令。已逐段核对采样、相机对齐与六项误差的有效样本口径。

> **版本与身份**
>
> 已读 revision 的 implementation note 明载 warmup 为 1% 而非论文 5%；推论 BF16 / 四步 denoising 与训练精度分开。阅读范围是列出的来源段落，未声称重现论文分数。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	EgoExo4D 衍生的 EgoH4 人体视频 / 手部轨迹，非新建模拟场景。相机外参为 world→camera 3×4；以最早可见帧（offset −19，含边界补帧）的相机位置与前向创建座标系。
任务	一个 3D 双手预测设置：42 关节 × xyz。state offsets −19…0，4 个图像 offsets −18 / −12 / −6 / 0，target offsets 0…9；target 包含当前 timestep，不能称为 10 个纯未来帧。
题数与数据	README 列 train 555 episodes / 41,314 samples、val 109 episodes / 8,830 samples，10 Hz，LeRobot v2.1。episode、重叠时间窗和关节数分开记；与 EgoH4 / EgoExo4D 保留父数据关系。原始 126D 关节与 12D 外参经模型投影，32D latent action 不是原生 actuator 维度。
评估方式	以公尺计算 wrist ADE / FDE、绝对 MPJPE / MPJPE-F、wrist-relative R-MPJPE / R-MPJPE-F。论文的 MPJPE 栏对应后两项相对误差。GT 三轴全零才排除关节；relative 额外要求 wrist 有效，包含对齐后零误差的 wrist。ADE 先手腕→帧→sample 平均，MPJPE 池化有效 joint×time；不共用分母。全无效 sample 不计，异常直接停止并报 sample index。

依这个顺序读

1. README.md ↗

   GitHub · JYOUN9/EggHand_Code · 72d9b8f58c

   核对官方身分、数据 split / 频率、训练与推论设置、论文字段对照。

   L1–104

2. `docs/IMPLEMENTATION.md` ↗
   GitHub · JYOUN9/EggHand_Code · 72d9b8f58c

   确认原生依赖版本、时间索引、补边、mask 和 paper / code 指针差异。

   L1–35

---

3. `inference/evaluate.py` ↗
   GitHub · JYOUN9/EggHand_Code · 72d9b8f58c

   追踪数据字段、逐座标训练 mask、GT 有效关节、分母与错误处理。

   L86–123 · L176–193 · L275–297 · L357–395 · L487–490 · L535–643

---

4. `gr00t/model/transforms.py` ↗
   GitHub · JYOUN9/EggHand_Code · 72d9b8f58c

   检查 world-to-camera 外参、首个历史相机的 canonical frame、零座标关节与 raw tensors。

   L356–450

怎么接入我们的benchmark

可重用

重用原生 joint keys、episode / frame 对照、相机对齐与原生 evaluator。；保留同一评测的 absolute / relative 六栏，不把不同 alignment 的 MPJPE 合成一栏。

需要转换

case 固定 source episode、base timestep、完整 observation / target offsets、padding mask、m 单位与 camera reference。；训练 per-coordinate 非零 mask 和评测 per-joint mask 各自保存；添加缺失值策略必须另立协定。；数据 split 沿用父 take / episode，防止重叠窗口跨 train / test。

仍需补齐

本次未下载视频 / 模型、未运行基线；数据与 checkpoint revision 仍需固定。；目前原生对齐会把全零缺失关节当点平移；不能事后把它误认为观测到的手。

P228 · SFHand / EgoHaFL

SFHand: Learning Embodied Manipulation by Streaming Egocentric 3D Hand Forecasting

内核内容已核读 · 主来源 · 原作 · 独立页面

SFHand / EgoHaFL 有可读取的手部串流预测数据与 evaluator；目前 README 仍把 Franka Kitchen 评测与 3D 标注产生程序列为 Coming soon。已沿 loader→stream→模型输入→matching→metric 查核，将人体预测与机器人实作分开。

> **版本与身份**
>
> 阅读版本为 pinned GitHub commit；DATA / MODEL 外部保存库另需固定 revision。论文尺度与程序 clip 子采样各自登记，不把新观测帧或四种输出当新任务。

领域	穿戴交互与动作界面、居家整理与清洁、餐饮与烹饪、通用对象与机动作业
环境	Ego4D v1 真实活动短片 / 自动 MANO 标注；EgoHaFL 为衍生 annotations，不是 247K 个模拟环境。Franka Kitchen 下游环境须追到父 benchmark，公开源代码尚未完整涵盖。
任务	串流、语言引导的 hand type / 2D box / 3D pose / 3D trajectory 四类输出，共用同一 clip。每步喂入截至当下的新图像，hand state 由前次预测接续；不是一次只看首帧的全盲长期预测。
题数与数据	论文报告约 247K 个 3 秒 clips（242K train / 5K test）、每 clip 16 个 annotated frames，约 3.95M 标注帧；不是 3.95M 独立问题。eval config clip_length=8、max_hand=10、camera depth 0<z<2.5。loader 保留前 10 个有效 hand，LMDB uid / video_id / start/end / caption 与 native split 一起保存。
评估方式	Hungarian matching 后，以 IoU>−1 / 0.5 及手别正确筛选，再计 camera translation ADE / 最后一步 FDE、wrist-aligned MPJPE / PA-MPJPE，输出 cm。precision=matched 中达 IoU 且手别正确 / matched 中达 IoU；recall 分母也是 matched pairs 数，未匹配额外预测不在该分母。误差是条件于匹配及分类正确的子集合，不能当完整 detection precision/recall 或所有手的平均误差。err_data 未看到跨 rank gather，正式分布式评测需核对汇总。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **247,000** 3-second clips（约数） · 原文页 5
- **5,000** test clips（约数） · 原文页 5

- **3,950,000** hand annotations（约数） · 原文页 5

依这个顺序读

1. `README.md` ↗
   GitHub · ut-vision/SFHand · 86e3e34e57

   确认原生数据来自 Ego4D v1，发布范围与未发布组件。

   L1–92

---

2. `configs/config/clip_base_eval.yml` ↗
   GitHub · ut-vision/SFHand · 86e3e34e57

   固定 test CSV、clip 长度、max_hand 与深度有效范围。

   L1–42

---

3. `dataset/egodataset.py` ↗
   GitHub · ut-vision/SFHand · 86e3e34e57

   读取 clip / caption / LMDB、16-frame 子采样、深度筛选与最多 10 手的截断。

   L20–194

---

4. `engine_pretrain.py` ↗
   GitHub · ut-vision/SFHand · 86e3e34e57

   追踪每步添加图像、autoregressive hand state、matching-only 分母与误差。

   L90–288

---

5. `model/matcher.py` ↗
   GitHub · ut-vision/SFHand · 86e3e34e57

   确认 Hungarian 一对一匹配只保留 min(predictions,targets) 对。

   L21–92

---

6. `model/clip.py` ↗
   GitHub · ut-vision/SFHand · 86e3e34e57

   核对名为 future 的参数在这个 forward 中没有被使用，避免凭变量名误判。

   L274–317

---

7. `main.py` ↗

   GitHub · ut-vision/SFHand · 86e3e34e57

   查核 distributed 包装、eval 保存的原生统计。

   L135–164

怎么接入我们的benchmark

可重用

重用 EgoHaFL CSV / LMDB uid、原始 clip 时间窗、有效手数与原生匹配 evaluator。；保留 4 类预测输出及 IoU 门槛，同列呈现 coverage / 条件误差。

需要转换

标准 case 写明 rolling RGB observation、autoregressive hand input、文字来源、clip horizon / frame stride、深度过滤与 hand cap。；保留原始 metrics；若要完整 detection precision / recall，另建版本并将所有未匹配预测 / GT 纳入分母。；跨 Ego4D 衍生数据以 video / 时间交集去重，不将标注帧数乘成添加题数。

仍需补齐

本次未下载 Ego4D 视频 / MANO 权重，未运行模型或确认论文分数。；embodied evaluation 与 annotation pipeline 尚未公开于本次 revision；matching error 空集合与多 rank 汇总需要 adapter 验证。

P229 · UniEgoMotion

UniEgoMotion: A Unified Model for Egocentric Motion Reconstruction, Forecasting, and Generation

内核内容已核读 · 主来源 · 原作 · 独立页面

UniEgoMotion 把重建、生成和预测放在同一人体动作框架；它的 EE4D-Motion 是 EgoExo4D 的处理版本。已核对切窗 / split、可见信息 mask、3D 评分与地面接触代理量，不能把三种设置当成三批独立原始数据。

> **版本与身份**
>
> 本次固定官方 commit，三种 task 共用 EE4D-Motion。论文 / README 的数据量为来源报告量，不是本案已取得题数；时间窗口和 eval 抽样不可省略。

领域	餐饮与烹饪、休闲与运动、音乐与表演、穿戴交互与动作界面
环境	EgoExo4D 多用途人类活动的 Aria 视频、轨迹与拟合 SMPL-X 身体；没有添加可运行机器人环境。EE4D-Motion 使用父数据 take / train-val 关系。
任务	原生三种 model task：recon 全观测重建；gen 仅第一影格可见；fore 可见 window 前 1/4（典型 20/80 帧）。这些是观测协定差异，不能直接增加三倍独立情境。
题数与数据	DATASET.md：原始 4,792 takes、约 208 小时，筛选为 train 2,032 / val 560 takes、约 110 小时。segment key 的 start/end 使用 30 Hz 原始 index、含末端；motion 为 10 Hz。dataset 每 20 motion frames 建窗，正式 evaluation 再用每第十个 validation sample。SMPL-X 是拟合结果，需保留失败 / 屏蔽筛选及父 take ID。
评估方式	评分含全身 / body 前 22 joints / hand 25:55 的 MPJPE 与 PA-MPJPE、head / trajectory 误差、足滑、穿地、腾空与接地距离。rotation error 是 R差的 Frobenius norm，非角度。接触指针各有 4 cm / 8 cm 等阈值；足滑按串行长度归一且乘 1000，不是成功率。compute_3d_metrics 遍历 GT key，评整段和每 20 帧；pred trajectory=None 时以 GT trajectory 替代，此条件下 trajectory 误差不能证明模型预测能力。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **3** motion endpoints · 原文页 3
- **143,000** training clips（约数） · 原文页 5

- **4,400** validation clips · 原文页 5

依这个顺序读

1. `README.md` ↗
   GitHub · chaitanya100100/UniEgoMotion · 580c92c6d7

   确认方法、官方 repo 与数据依赖。

   L1–60

---

2. `DATASET.md` ↗
   GitHub · chaitanya100100/UniEgoMotion · 580c92c6d7

   核对父 take、数据筛选、原生 30 Hz index 与 10 Hz motion、validation 抽样。

   L1–56

---

3. `dataset/ee4d_motion_dataset.py` ↗
   GitHub · chaitanya100100/UniEgoMotion · 580c92c6d7

   检查训练统计来源、20-frame stride、reconstruction / generation / forecast mask。

   L36–91 · L230–250

---

4. `eval/compute_3d_metrics.py` ↗
   GitHub · chaitanya100100/UniEgoMotion · 580c92c6d7

   追踪 GT key 分母、whole-clip / 20-frame segment、缺失 trajectory 的替代。

   L15–109 · L113–124

---

5. `eval/metrics.py` ↗
   GitHub · chaitanya100100/UniEgoMotion · 580c92c6d7

   确认 rotation norm、body / hand joint subsets、PA 与 foot / floor 指针的真正计算。

   L9–127 · L192–275

怎么接入我们的benchmark

可重用

重用 take lineage、SMPL-X / Aria 对照、明确 mask 与 evaluator 各原生字段。；保留 reconstruction / generation / forecast 的条件差异，不混合 rank。

需要转换

canonical case 固定 take、start/end、30→10 Hz 对照、valid frames、观测 mask 和 train-only normalization revision。；把 supplied-GT trajectory 与 predicted trajectory 设为不同 evaluation condition；报分时明示。；全段与分段 metrics 分开；若另评纯未来区间，添加 evaluator 版本并保留原生成绩。

仍需补齐

未下载受原始数据 / SMPL-X 授权约束的完整资产，未跑模型。；语义生成评分与模型内部 diffusion 未在本次列出的 3D reader 范围内完整审核。

P230 · EgoH4

The Invisible EgoHand: 3D Hand Forecasting through EgoBody Pose Estimation

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoH4 评测由头部 / 图像与可见 2D 手位置推估及预测 3D 手部，特别区分视野内外。已核对数据模块、20+10 帧切分与 metric 实作；这是 EgoExo4D 上的新评测任务，不是新采集的一批视频。

> **版本与身份**
>
> 固定目前官方 commit；trainer 注解有 17-joint 遗留文字，但实际使用 57 joints。future condition 于 decoder 被排除，不能因 sample 接收 GT-shaped tensor 就直接判定数据泄漏。

领域	穿戴交互与动作界面
环境	EgoExo4D 的 Aria 头部相机、相机姿态及人体 / 手部标注。机器人控制与物理成功不在本来源评测范围内；场景应沿用父 take。
任务	3D 手轨迹及手姿态 forecasting，并可分离观测段 reconstruction；native 30 帧中前 20 帧观测、后 10 帧未来，按可见 / 视野外比例分组。全身 57 joints 是移除重复 wrist 后的输出维度，不是 57 个任务。
题数与数据	论文报告约 156K train / 34K test sequences；公开 config 的 test.split=val，并 concatenate manual body dataset 与 manual hand+auto body dataset。窗口 size=30、slice=1、frame interval=3，需保存 take_uid / start_frame 和标注类型，避免把交叠片段或不同标注视为独立原片。
评估方式	原生 evaluator 分 body / wrist / hand / full，计 obs/fut ADE、末帧 FDE、10 个未来 timestep 和 in-/out-of-view 子群；不以单一 success 评分。calc_jpe 先乘 visibility，再以 jpe!=0 筛选，会连真正零误差也排除。该固定版本以绝对座标 L2 计手部误差，没有在所读 test_step 运行 wrist-relative 对齐；比较论文相对 MPJPE 栏时必须核对。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **156,000** hand-side training sequences（约数） · 原文页 5
- **34,000** hand-side test sequences（约数） · 原文页 5

依这个顺序读

1. `README.md` ↗

   GitHub · masashi-hatano/EgoH4 · baa8ae87ce

   确认官方论文、运行入口与 checkpoint 来源。

   L1–46

---

2. `config/data_module/egoexo.yaml` ↗

   GitHub · masashi-hatano/EgoH4 · baa8ae87ce

   核对原生 split、30-frame window、interval=3 与范式界限。

   L1–47

---

3. `config/trainer/egoh4.yaml` ↗

   GitHub · masashi-hatano/EgoH4 · baa8ae87ce

   查核模型维度及 30 timestep 设置；注解与实际维度不可混读。

   L1–39

---

4. `datamodule/lit_egoexo4d_data_module.py` ↗

   GitHub · masashi-hatano/EgoH4 · baa8ae87ce

   确认测试实际用 EgoExo4D val、body / hand loader concatenation。

   L14–44

---

5. `datamodule/dataset/egoexo4d_hand_body_pose_dataset.py` ↗

   GitHub · masashi-hatano/EgoH4 · baa8ae87ce

   追踪 take、连续窗口、out-of-view 分组、17+42 关节、mask 与只载前 20 帧图像。

   L15–127 · L296–383

---

6. `models/lit_EgoH4Trainer.py` ↗

   GitHub · masashi-hatano/EgoH4 · baa8ae87ce

   检查 57 关节、观测 / 未来分开、per-timestep 误差及零误差过滤。

   L273–436

---

7. `models/transformer_cond_diffusion_model.py` ↗

   GitHub · masashi-hatano/EgoH4 · baa8ae87ce

   确认 sample 只用 x_start.shape 建噪声，不把 GT 座标直接当预测。

   L314–345

---

8. `models/transformer_module.py` ↗

   GitHub · masashi-hatano/EgoH4 · baa8ae87ce

   确认 future token 只读 noisy pose channels、没有读 future condition。

   L236–283

怎么接入我们的benchmark

可重用

重用 parent take / sequence indexing、可见性标注、原生 20+10 与分组 evaluator。；以各分项原生误差作基准；0...1 视野外比例是 case 属性，不直接标成难度分数。

需要转换

canonical case 固定 observation boundary、camera / pose 座标、joint order、3D / 2D masks 及 annotation provenance。；保留 native evaluator；修正零误差 mask 或添加 wrist-relative metric 时另建协定与相同 fixture 对照。；test dataset 所称 test 对应父数据 val，标准格式同时保留两个 split 名称。

仍需补齐

本次只查核列出的公开来源段落，未取得完整数据或运行 diffusion◦；body / hand concatenation 之重叠 take 与实际数量需要用下载后的 annotation manifest 核对。

P231 · MADiff

MADiff: Motion-Aware Mamba Diffusion Models for Hand Trajectory Prediction on Egocentric Videos

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

MADiff 是重用多个既有 Ego 数据集的手轨迹方法。已读到的官方版本提供 H2O / EgoPAT3D 两个 backend，并附 ACT 条件输入教学；论文五个数据集的覆盖、目前程序入口与添加机器人教学分开登记。

> **版本与身份**
>
> 目前 README 为 T-PAMI 2025、引用同一 arXiv；版本添加 H2O / EgoPAT3D backend 与 ACT 教学。已读原生程序与论文范围不相同，必须按版本列出。 补查MMTwin README：它对应2504.07375，CABH列三种人类操作任务，CABH专用模型仍待发布；EgoPAT3D配套程序已在P222核读。这是相关延伸，不改写MADiff本篇的任务或可运行范围。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	父数据 EK55、EK100、EGTEA Gaze+、EgoPAT3D-DT、H2O-PT；目前公开入口主要为后两个。EgoPAT3D loader 有 11 个已见 scene IDs 与 novel 13 / 14 / 15；ID 是父数据场景，不能当 MADiff 新建环境。
任务	同一手部轨迹 forecasting 方法在不同数据与观测配置测试。现行两个 backend 设置 target=2d、observation ratio=0.6；H2O max_frames=64，EgoPAT3D=40。ACT 教学将 forecast 作额外 token，没有提供一套新的正式 robot benchmark 题单 / 判分器。
题数与数据	原生数据与权重需外部下载，来源依赖 USST 预处理。读取 native filename、scene/recording split、有效帧数、trajectory / GLIP / motion features；论文五数据集的 train/test 样本表不能算为五批全新原始视频。
评估方式	实际 H2O / EgoPAT3D eval loop 对纯未来区间逐串行计 normalized-image ADE 与末点 FDE，并非档内未用 helper 的 weighted error。H2O 每题 1 次抽样、gap=999；EgoPAT3D gap=333。test_novel 虽有 loader，traineval 对 tuple 取 [0]，预设入口只评 test。H2O rank 档只汇整 ADE、文件名需隔离运行以免读到旧档。

依这个顺序读

1. `README.md` ↗

   GitHub · IRMVLab/MADiff · 9f13e5a703

   核对官方论文、目前两个 backend、USST 数据和 ACT 延伸。

   L1–121

---

2. `traineval.py` ↗

   GitHub · IRMVLab/MADiff · 9f13e5a703

   查核 backend dispatch、test tuple 只取第一个 loader、原生种子与推论入口。

   L17–141

---

3. `configs/h2o.yml` ↗

   GitHub · IRMVLab/MADiff · 9f13e5a703

   固定 H2O 2D 64-frame 设置。

   L1–16

---

4. `configs/egopat3d.yml` ↗

   GitHub · IRMVLab/MADiff · 9f13e5a703

   固定 EgoPAT3D 2D 40-frame 设置。

   L1–15

---

5. `src/H2OLoader.py` ↗

   GitHub · IRMVLab/MADiff · 9f13e5a703

   追踪 split、2D / 3D normalization、未来 motion feature 的观测值延用与 padding。

   L28–89 · L93–137 · L294–375

---

6. `src/EgoPAT3DLoader.py` ↗

   GitHub · IRMVLab/MADiff · 9f13e5a703

   辨识 scene/recording split、novel scene test、有效长度与输出。

   L41–99 · L273–350

---

7. `netscripts/epoch_feat_h2o.py` ↗
   GitHub · IRMVLab/MADiff · 9f13e5a703

   核对固定 60% 观测、single sample、纯未来 ADE / FDE、跨 rank 保存。

   L1–31 · L426–523 · L543–576

---

8. `netscripts/epoch_feat_egopat.py` ↗
   GitHub · IRMVLab/MADiff · 9f13e5a703

   核对 EgoPAT3D 的噪声填入、333 gap 与误差路径。

   L1–33 · L419–489

---

9. `docs/MADiff_for_Robotics.md` ↗
   GitHub · IRMVLab/MADiff · 9f13e5a703

   区分人体预测、固定 forecast token 与 ACT 实体操作教学。

   L1–70

---

10. `README.md` ↗
    GitHub · IRMVLab/MMTwin · bd0faf148a

    补读MADiff官方链接的3D延伸身分及CABH数据角色；它有不同arXiv，完整配套程序核读另见P222。

    L1–38 · L161–216

怎么接入我们的benchmark

可重用

重用父数据 split、scene IDs、有效长度、座标转换与实际调用的 ADE / FDE。；ACT forecast-token 教学可作 human-to-robot 界面参考，与正式测题清单分开。

需要转换

case 包含 dataset revision、backend、filename、60% boundary、max_frames、normalization 与 feature revision。；novel test 建独立入口和完整 expected-case manifest；抽样次数、diffusion gap 各自固定。；把论文五数据集与目前两 backend / MMTwin 3D 延伸保留版本关系，不合并报为新环境。

仍需补齐

未跑模型、未取得特征 / checkpoint；没有重现论文数字。；机器人教学缺可下载任务 / 示范 / evaluator；MMTwin本次仅补读README；其EgoPAT3D程序核读见P222，不把CABH待发布模型当成已可用。

P232 · Diff-IP2D

Diff-IP2D: Diffusion-Based Hand-Object Interaction Prediction on Egocentric Videos

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

Diff-IP2D 重用 OCT / EPIC 的轨迹与接触标注，但实际轨迹入口评的是 WDE / FDE。逐段追到 runtime caller 后，已把它和 repo 内沿用但未在该路径调用的 OCT evaluator 分开；不能只看文件名就判断评估方式。

> **版本与身份**
>
> 原生程序 import 了 evaluate_traj_stochastic，但所读实际轨迹路径使用 compute_wde / compute_fde；OCT wrapper 的名称对调不能直接套到此主结果。固定版本的来源差异均保留。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	来源视频与人工评测 labels 重用 EPIC-KITCHENS / OCT；论文也包含其他 Ego 数据实验，README 的当前完整部署仅 EK100，EK55 / EG 发布仍列待补。
任务	未来 2D 双手 waypoint 与 object affordance/contact hotspot；典型 10 个过去 token→4 future 点。改 diffusion 架构不是添加语义任务，沿用 label 要连回 OCT 父来源。
题数与数据	features / bbox / 有效性、uid / raw frame 与 homography 均有原生字段。training loader 会加 future features，evaluation loader 不加；manual-merged annotations 不等同 OCT 原始 annotation folder。各外部文件与 checkpoint 要固定 hash / split，不能只记 repo commit。
评估方式	主循环将预测转 numpy 后调用 compute_wde：4 未来点权重 0.25 / 0.5 / 0.75 / 1.0，求和未除以权重总和；FDE 为末点，normalized image 单位。tensor 分支反而为普通平均，但不是此路径。输出先按 batch 的有效手平均，再跨抽样 / batch / rank 平均，与全数据有效手池化不同。heatmap SIM/AUC-J/NSS 沿用 OCT，仍需按 uid 配对、NaN 分母明示；原始 metrics rank equal-average 也要保留。

依这个顺序读

1. `README.md` ↗

   GitHub · IRMVLab/Diff-IP2D · 733ae0150f

   确认 EK100 发布范围、OCT 数据沿用、自制 training features 与各外部档。

   L1–163

---

2. `datasets/datasetopts.py` ↗

   GitHub · IRMVLab/Diff-IP2D · 733ae0150f

   确认 4 Hz、2.5+1 s 与 split 约定。

   L5–65

---

3. `datasets/ho_utils.py` ↗

   GitHub · IRMVLab/Diff-IP2D · 733ae0150f

   与 OCT 逐行比较 normalized hand labels / missing mask，添加 homography 子采样。

   L12–103

---

4. `datasets/holoaders.py` ↗

   GitHub · IRMVLab/Diff-IP2D · 733ae0150f

   查核 future features 限 train、observation homographies、uid / label 对齐。

   L87–124 · L193–258 · L303–366

---

5. `options/expopts.py` ↗

   GitHub · IRMVLab/Diff-IP2D · 733ae0150f

   固定 10 observation / 4 future、sample_times=10、fast_test。

   L1–28

---

6. `netscripts/epoch_feat.py` ↗

   GitHub · IRMVLab/Diff-IP2D · 733ae0150f

   追踪 numpy WDE 与 FDE 真正路径、batch / rank 平均与 affordance caller。

   L44–100 · L103–140 · L460–567 · L626–676

---

7. `evaluation/traj_eval.py` ↗

   GitHub · IRMVLab/Diff-IP2D · 733ae0150f

   逐行比较 OCT 文件：除注解外相同；此 wrapper 不是所读主循环的 WDE caller。

   L5–122

---

8. `evaluation/affordance_eval.py` ↗

   GitHub · IRMVLab/Diff-IP2D · 733ae0150f

   与 OCT 对照 heatmap / score 原生公式及省略 logging 的差别。

   L8–32 · L46–160 · L163–206

怎么接入我们的benchmark

可重用

重用 OCT lineage、native labels / split、真正在主循环调用的 WDE / FDE 与热图 evaluator。；保留 full / fast diffusion 与 sample_times，不能将 10 次抽样当 10 道题。

需要转换

source 同时记 paper version、code commit、data archive hash；canonical case 禁止 training-only future features 出现在评测输入。；原生 WDE、FDE、heatmap 各列公式和有效分母；若改为 sample-weighted global mean，需添加 evaluator 版本。；以父 participant/video/time 去重；EPIC55/100、OCT / Diff-IP2D 保留 overlap 关系。

仍需补齐

未下载 weights / features 或运行，README checkpoint links 与其他数据部署仍需逐一取得。；已有函数不等于已有完整测试任务，case metadata 与 raw video 权限尚未集成。

P233 · OCT / HOI forecasting

Joint Hand Motion and Interaction Hotspots Prediction from Egocentric Videos

内核内容已核读 · 主来源 · 原作 · 独立页面

OCT / HOI-Forecast 以既有厨房 Ego 视频自动创建训练 labels，另外人工标注评测轨迹与接触热区。已核对 labels、时间窗及实际评分入口，并记下目前程序的 ADE / FDE 命名对调与热图配对条件，供标准化时保留原始口径。

> **版本与身份**
>
> 本次核对的是固定官方 commit。文中指出可直接验读的程序语义；不将未运行的静态差异扩张成对论文分数的判定。

领域	餐饮与烹饪、穿戴交互与动作界面
环境	EPIC-KITCHENS-55 / 100 与 EGTEA Gaze+ 的人类厨房视频；EK100 延伸 EK55，与 Diff-IP2D 等工作共享视频或 labels。不是添加模拟场景。
任务	两个相关输出：未来左右手 2D 轨迹与 next-active object 接触热区。典型 4 Hz、2.5 秒历史 / 1 秒未来；label 有边界点+4 future 点，epoch eval 去掉第一点。任务输出维度与多次生成 samples 不计为新情境。
题数与数据	训练 labels 自动产生，评测 hand trajectory / hotspot 人工标注；uid、participant / video、frame indices、RULSTM split 必须一起保留。README 600 MB 是含 feature / partition / labels 的文件大小，不是题数。未取得完整 labels，不能从目录片段宣称已集成全量。
评估方式	原生 compute_ade / compute_fde 正确区分平均 / 末点，但 evaluate_traj_stochastic 把 compute_fde 放入 ade_list、compute_ade 放入 fde_list，造成输出名称对调；实际 epoch 确实调用这个 wrapper。invalid GT 座标误差乘零、时间长度分母仍保留。hotspot 在 32×32 Gaussian heatmap 计 SIM / AUC-J / NSS，NaN 个别剔除；zip 两个 dict values 依 insertion order 配对，未按 uid join。另列的 F1 选当次数据最优 threshold，不是固定阈值分数。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **1,894** EK55 evaluation hand trajectories · 原文页 5
- **3,513** EK100 evaluation hand trajectories · 原文页 5
- **442** EGTEA evaluation hand trajectories · 原文页 5

- **69** EGTEA evaluation hotspots · 原文页 5

依这个顺序读

1. `README.md` ↗
   GitHub · stevenlsw/hoi-forecast · fbc85a17cd

   分离 automatic training labels / manual evaluation、父数据与两种评测命令。

   L1–142

---

2. `datasets/datasetopts.py` ↗
   GitHub · stevenlsw/hoi-forecast · fbc85a17cd

   固定 4 Hz、2.5 s history、1 s future、RULSTM splits。

   L5–66

---

3. `datasets/ho_utils.py` ↗
   GitHub · stevenlsw/hoi-forecast · fbc85a17cd

   查核 normalized 2D、首个边界点、缺失手 sentinel 与有效 mask。

   L12–86

---

4. `datasets/holoaders.py` ↗
   GitHub · stevenlsw/hoi-forecast · fbc85a17cd

   核对 uid / native split、label type 与 history/future frame alignment assertion。

   L189–251

---

5. `traineval.py` ↗
   GitHub · stevenlsw/hoi-forecast · fbc85a17cd

   区分 traj validation 与 affordance eval loader。

   L19–109

---

6. `netscripts/epoch_feat.py` ↗
   GitHub · stevenlsw/hoi-forecast · fbc85a17cd

   追踪去掉首 GT 点、多次抽样、dict 与 evaluator 的实际调用。

   L72–133

---

7. `evaluation/traj_eval.py` ↗

   GitHub · stevenlsw/hoi-forecast · fbc85a17cd

   核对 ADE / FDE 函数、stochastic wrapper 的对调与有效座标分母。

   L5–121

---

8. `evaluation/affordance_eval.py` ↗

   GitHub · stevenlsw/hoi-forecast · fbc85a17cd

   核对 Gaussian heatmap、SIM/AUC-J/NSS、key 对齐、NaN 与最佳 threshold。

   L8–32 · L46–76 · L79–227

怎么接入我们的benchmark

可重用

重用人工 eval uid / labels、native splits、可追溯自动标注来源。；保留原生 wrapper 输出及其实际定义，将任何更正以新 evaluator version 登记。

需要转换

先以 uid join 预测和 GT，再检查 expected-case coverage、顺序、shape、有效手及 frame boundary。；canonical metric 明列公式、单位、mask 分母、sampling 次数和热图 kernel；原 native 名称附别名映射，不静默改名后混报。；两个任务共享 clip/case lineage，多次 stochastic sample 仅增加 trial，不添加独立数据。

仍需补齐

本次未运行上游模型或重现 README 分数。；完整数据获取、生成标注程序的全流程及 licensed raw video 尚未集成；runtime adapter 需用小型有答案 fixture 查验原生 / 更正版差异。

P234 · I-CVAE

Intention-Conditioned Long-Term Human Egocentric Action Forecasting

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

已沿 Ego4D clips→窗口 / 意图→ICVAE generate→本地 ED/AUED 核读内核程序。这是重用 Ego4D 的方法来源；52 个 scenario-derived intention、20 个未来位置与 K=5 候选是不同单位。串接预测、GT 条件消融及 challenge 分数必须分开。

> **版本与身份**
>
> 固定作者 repo commit 5b95d85e0bec6bd94851c867054c535c1afc6248；此程序快照早于 arXiv v4，没有宣称逐版结果一致。README 的已提供完整 code 不是本次核读完整码库的证据；本次仅核以上内核区段与 taxonomy 结构。未取得权重、完整数据或重跑模型。
>
> 清单题名为 Intention-Conditioned Long-Term Human Egocentric Action Forecasting（2022 初稿）；已核缓存为 arXiv:2207.12080v4（2024-04-08），题名改为 Intention-Conditioned Long-Term Human Egocentric Action Anticipation。作者均为 Esteve Valls Mascaró、Hyemin Ahn、Dongheui Lee。repo README 保留 Forecasting 标题，但链接并引用 WACV 2023 的 Anticipation，且具名第一作者维护，可确认为同一方法的作者程序，而非同名第三方。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	脱机人类第一人称 Ego4D 日常活动；物理场景信息来自 ego4d.json 的 scenarios，程序将单一 scenario 视为高层 intention。没有 robot reset、control 或可运行成功条件；scenario 数不代表场景 layout 或机器人任务数。
任务	H3M 由过去片段辨识 verb、noun、intention；I-CVAE 预测 Z=20 个未来 verb–noun 标签，通常产生 K=5 串行。固定 taxonomy 为 115 verbs、478 nouns、52 intentions；论文 p.6 的 53 scenarios 是另一统计口径。设置档 N=8，论文端到端表格包含 N=2/4/6/8，最佳结果用 N=6，不能一律写 N=4。

题数与数据	外部 fho_lta_{train,val,test_unannotated}.json 根为 clips；使用 video_uid、clip_uid、action_idx、verb_label、noun_label、action_clip_start_sec/end_sec，预处理另读 action_clip_start_frame/end_frame。按 clip_uid 分组、action_idx 排序；case key 为最后观测的 clip_uid_action_idx。input_clips / forecast_clips 各为 N / Z 笔，标签 tensor 次序 [verb,noun]，forecast_times.label_clip_times 保留秒；缺 test label 补 -1，不能当有效类别。意图 mapper 仅纳入恰一个且在 52 类 taxonomy 中的 scenario，未提供多 scenario 的明确处置。SlowFast 特征存 clip_uid_action_idx.pt；frame_to_feat 实际 int(frame/16)，W 参数未用；slice [start_feat:end_feat]，预设左补至 15 格。论文描述 2304 维特征，不能把 feature index 当秒或控制步。完整标注 / features / ego4d.json 未随本次取得，没有声称完整 case 数。原生每 clip 窗口数为 max(0,L-N-Z)，循环缺 +1，最后一个完整窗口未取。
评估方式	ICVAE_Task.validation_step 分别评 verbs、nouns；pred [B,K,Z]→[B,Z,K]。lta_metrics.edit_distance 对每 case 取 min_k(editdistance.eval(pred_seq,gt_seq)/prefix_length)，再对 case 平均；AUED 对长度 1..Z 的 ED 做 trapz/(Z-1)，ED_19 是 Z=20 的末点，非第 19 个未来动作。validation_epoch_end 再不加权平均各 batch 指针；非 test 的 test_epoch_end 先依 clip key 合并去重后评分，两者分母流程不同。论文称 Damerau–Levenshtein 并报 action ED；此档实际 import editdistance、调用 eval，未见 transposition 专用实作，也未在这条 Task 链计 action-pair ED，不能直接宣称重现 challenge scorer。单模块 validation 使用 GT observed_labels 与 GT intention；create_prediction 才设 FROM_PREDICTION 串接 H3M。test GT 未公开，submission 每 case 含 verb / noun 的 K×Z 整数数组。

依这个顺序读

1. `README.md` ↗

   GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

   题名、WACV 2023 引文与第一作者维护身分。

   `L1–5 · L10–40`

2. `Quickstart.MD` ↗

   GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

   Ego4D 外部特征 / 标注依赖及单模块、串接测试的区别。

   `L11–44`

3. `ego4d/datasets/ptv_dataset_helper_features.py` ↗

   GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

   原生 clips JSON、秒字段改名、按 action_idx 排序及实际窗口数。

   `L108–170 · L371–457`

4. `ego4d/datasets/LTA_features.py` ↗

   GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

   split、scenario→intention、verb/noun 次序、case key 及预测缺失时的回退。

   L197–263 · L296–313 · L336–402 · L405–499

---

5. `preprocess_dataset.py` ↗

   GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

   影格到特征索引、左侧补零与预处理入口限制。

   L6–56 · L66–142

---

6. `data/config/config_ICVAE.yaml` ↗

   GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

   此设置的 8 observed / 20 future、115 verbs / 478 nouns / 52 intentions。

   L1–18 · L28–82

---

7. `ego4d/config/defaults.py` ↗

   GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

   实际 K 预设为 5；不能把未覆写的预设 horizon 当论文设置。

   L666–687

---

8. `ego4d/models/lta_models.py` ↗

   GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

   ICVAE 继承 CAE，定位实际 generate 实作。

   L15–58

---

9. `ego4d/models/architectures/cae.py` ↗

   GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

   从观测与意图采样 K 个 latent，只经 decoder / head 生成未来类别。

   L72–131

---

10. `ego4d/tasks/ICVAE_Task.py` ↗
    GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

    GT 条件 validation、batch 平均、去重输出与本地计分调用链。

    L122–246

---

11. `ego4d/evaluation/lta_metrics.py` ↗
    GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

    best-of-K ED、prefix 范式、AUED 梯形积分与函数注解差异。

    L6–14 · L71–115

---

12. `create_prediction.py` ↗
    GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

    H3M action / intention 预测合并与 FROM_PREDICTION 串接。

    L140–165 · L172–212

怎么接入我们的benchmark

可重用

固定 taxonomy、clips 字段及排序、case key、原生 ED/AUED 实作与 H3M→ICVAE 预测界面。

需要转换

source 记 paper version+repo commit 并指回 Ego4D；domain 记人类活动，environment 记 video/scenario provenance；task 分 H3M recognition 与 LTA forecasting；case 用 dataset revision+split+clip_uid+最后 observed action_idx+N/Z；保留观测秒 / 影格与特征索引三种座标、GT/predicted intention 来源及不可见未来 label。evaluator 保留 verb/noun、best-of-K、prefix normalization、AUED 与 batch/global 聚合差别；不转成机器人 success。

仍需补齐

须固定 Ego4D v1 标注 / feature revision 与 split manifest；核对 52 类 intention 排除的视频与 case 分母、末窗口少取及 batch 平均；比对正式 Damerau/action scorer。FROM_PREDICTION 缺 clip 时会借用随机其他 clip 的 intention 并填 -1，接轨须改成可追踪缺件。preprocess_dataset.py 的 Namespace 以字典取用且未定义 dir_annotations 参数，Quickstart 的 test_model.py 也不在固定 tree；这些都须在允许运行前修复 / 指定正确入口。

P235 · TransFusion

Summarize the Past to Predict the Future: Natural Language Descriptions of Context Boost Multimodal Object Interaction Anticipation

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

作者页直接连 algvr/transfusion，已核 Ego4D v1/v2 reader、语言摘要输入及实际 Top-5 STA mAP。此来源是脱机下一次人类对象交互预测；外部摘要、SlowFast TTC 替换与跨 GPU 合并都是结果协定的一部分。论文 EK100 路径在现行入口尚未闭合。

> **版本与身份**
>
> 固定 55d3a4eca3325dc65f5f0391cc27105ba110c00f。论文方法、作者专页 CVPR 2024 release、Ego4D v1/v2 与 EK100 pseudo-label 实验各留版本关系；同名 LiDAR TransFusion 不属本篇。仅核上述内核来源，未运行上游、下载完整视频 / 模型 / 摘要套件。
>
> 精确题名与 Pasca、Gavryushin 等八位作者相符；清单 2023 是 arXiv 初稿，缓存为 arXiv:2301.09209v4（2024-03-10）。PDF p.1 连作者专页，专页 HTML 52–117 行显示相同题名、作者、CVPR 2024 与 Code→algvr/transfusion。专页 / 现行 repo 支持两版 Ego4D，不能把这个版本直接当 v4 文中全部 EK100 实验的完整 release。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	Ego4D 人类第一人称日常场景，包含厨房、园艺、维修等；论文另以 EPIC-KITCHENS-100 厨房视频验证。输入是 prediction frame 与其过去的语言化情境，没有 robot state/action 或 simulator。
任务	每个 prediction uid 可有多个将交互的对象，预测 box、noun、verb、time_to_contact、score。v1 固定 mapping 有 87 nouns / 74 verbs，v2 为 128 / 81；这些是词汇类别，不是添加任务数。Noun、Noun-Verb、Noun-TTC、Overall 为不同匹配限制的指针，另有 noun-only / verb-only 消融。

题数与数据	fho_sta_{train,val,test_unannotated}.json 以 annotations、noun_categories、verb_categories、info.video_metadata 组成；每笔 uid、video_id(v1)/video_uid(v2)、frame、clip_id、clip_uid、clip_frame、objects[{box,verb_category_id,noun_category_id,time_to_contact}]。框为原图像 xyxy 像素，TTC 为秒；det_sec=frame/fps，fps 读各视频 metadata，不能一律硬设 30。reader 转 Bboxes/all_nouns/all_verbs/det_diff，objects_to_entries 只留最后对象 TTC，再对所有对象拷贝，接轨应保留原始每对象 TTC 并验证此假设。LMDB 模式可缩至高 480，jpg 模式不先缩框。noun ID 0 移至末类以让 0 作背景，输出再还原；v1/v2 对 nut/tape 等字符串处理不同。设置 subset=0 实际使用原始 orig_split；另排除 5 个 UID、有框过滤与读图失败跳下一笔，故完整 case 分母须由版本化可读 uid manifest 计算，不能直接沿用论文的 64,798 统计。test 中 ball/take 与固定框为 loader placeholder，不能当 GT。语言 JSON 用 prediction uid 索引，v1 将 object_lang/action_lang 直接串接，v2 加分号；目前 current 策略消费预先生成摘要。
评估方式	EgoNAOTrainer 的 train/val 均建 STAMeanAveragePrecision(top_k=5)，先将预测与 GT 框转整数。每图按 confidence 递减、以最大有效 IoU 一对一配对；IoU 使用像素端点 +1 面积，实作 boxes>0.5，abs(TTC error)<=0.25 秒。论文 p.5 写 IoU>=0.5、TTC<0.25，边界不可混写。Top-5 实作对每种配对条件豁免该图最高分的 (5-1)×GT对象数个 FP；不是只计五类。剩余预测依 class/confidence 合并，recall=累积TP/该类GT对象数，precision=TP/(TP+FP)，取单调 precision envelope 的 VOC 积分；count_all_classes=False，对有 GT 的类别作宏平均×100，joint 指针按 noun 平均。trainer 输出 results[uid]=至多5个 {box,noun_category_id,verb_category_id,time_to_contact,score}，所以在线 raw-pred 指针与导出档重评有额外截断差异。DDP 本地 AP 后同步不等于合并数据再计 AP；README 要合并 JSON 用 EGO4D/forecasting 正式脚本。TTC loss 在两设置均为 0，README 指论文结果使用外部 SlowFast TTC；这次没有把本地 scorer 充当已核正式 server 结果。

依这个顺序读

1. `README.md` ↗

   GitHub · algvr/transfusion · 55d3a4eca3

   作者方法、数据版本、官方评分依赖与 TTC 后处理。

   L1–6 · L19–37 · L43–91

2. `data_preprocessing/utils/annotations_df_utils.py` ↗

   GitHub · algvr/transfusion · 55d3a4eca3

   STA annotations→DataFrame、原始 category/frame/TTC、split 与排除条件。

   L74–124 · L127–274

3. `data_preprocessing/utils/path_utils.py` ↗
   GitHub · algvr/transfusion · 55d3a4eca3

   uid-keyed 外部语言摘要替换；现行入口接受的数据源。

   L62–125

---

4. `data_preprocessing/datasets/base_nao_dataset.py` ↗
   GitHub · algvr/transfusion · 55d3a4eca3

   video_id/video_uid、框缩放与 label mapping。

   L40–147

---

5. `data_preprocessing/utils/dataset_utils.py` ↗
   GitHub · algvr/transfusion · 55d3a4eca3

   noun 0 移至末类以保留背景；非单纯全类别 +1。

   L82–143

---

6. `data_preprocessing/datasets/egonao_datasets.py` ↗
   GitHub · algvr/transfusion · 55d3a4eca3

   image/bboxes/labels/verb/ttc/id/orig_shape 及读图失败时跳下一笔。

   L90–103 · L131–183

---

7. `runner/nao/configs/ego_nao_res50_ego4d.yml` ↗
   GitHub · algvr/transfusion · 55d3a4eca3

   v1 原生 split、外部摘要、current 策略与 TTC loss 关闭。

   L11–79 · L129–145

---

8. `runner/nao/configs/ego_nao_res50_ego4dv2.yml` ↗
   GitHub · algvr/transfusion · 55d3a4eca3

   v2 mapping / 摘要资产与多 GPU 设置。

   L11–79 · L122–152

---

9. `data_preprocessing/train_test_splits/utils.py` ↗

   GitHub · algvr/transfusion · 55d3a4eca3

   subset=0 实际沿用 orig_split，不运行名称所示的新分层切分。

   L97–144

---

10. `runner/nao/snao_data.py` ↗

    GitHub · algvr/transfusion · 55d3a4eca3

    split 套用、空 test 回退与语言 wrapper 连接。

    L84–152 · L155–175 · L207–224

---

11. `modeling/narration_embeds/collate_wrapper_utils.py` ↗

    GitHub · algvr/transfusion · 55d3a4eca3

    current / previous wrapper 的实际选择。

    L13–45

---

12. `modeling/narration_embeds/datasets/current_embeddings_dsets.py` ↗

    GitHub · algvr/transfusion · 55d3a4eca3

    current word wrapper 按 prediction uid 取得摘要；无生成时间审核。

    L63–101

---

13. `runner/nao/ego_nao_data.py` ↗

    GitHub · algvr/transfusion · 55d3a4eca3

    EgoNaoDataset 接外部摘要 wrapper 的实际路径。

    L53–79

---

14. `runner/nao/ego_nao_trainer.py` ↗

    GitHub · algvr/transfusion · 55d3a4eca3

    模型预测→本地 scorer、整数框、每图仅输出前 5 笔及输出字段。

    L15–31 · L107–158 · L195–250 · L400–438 · L500–501

---

15. `runner/metrics_losses/ego_metrics.py` ↗

    GitHub · algvr/transfusion · 55d3a4eca3

    实际 IoU/TTC 配对、FP 豁免、每类 GT 分母与 AP 积分。

    L4–59 · L123–205 · L207–288 · L302–364 · L468–561

---

16. `runner/utils/adapt_ttc_values.py` ↗

    GitHub · algvr/transfusion · 55d3a4eca3

    依 score 配对替换 TTC 及未闭合的 CLI / test_keys。

    L7–46

怎么接入我们的benchmark

可重用

版本化 category mapping、原始 annotation→case 字段、语言 uid lookup、STA 配对与 AP 聚合，以及 submission JSON 外形。

需要转换

source 记 paper/repo/Ego4D revision；domain/environment 指人类视频及该笔场景；task 保留下一次交互预测；case key=(dataset_version,split,uid)，frame 与 clip_frame 各留参照系，boxes 记 xyxy/原图尺寸，objects 与 TTC 逐笔保留。label 同时存原 category ID 与背景重编号；context 记生成模型、输入最大 frame/time、摘要资产 SHA、GT / 预测模式。evaluator 区分本地 / 导出 / 正式 server、Top-5 FP 预算、noun macro AP、TTC来源及 DDP 合并策略。

仍需补齐

需固定外部 context、Ego4D 标注与 SlowFast TTC revision；目前 loader 只按 uid 取字符串，无法证明摘要只使用过去影格，w_leak=False 也不是此证明。核对多对象 TTC 被压成一值、5 笔输出截断与实际可读 case 分母。adapt_ttc_values.py 使用 argparse 的 description 参数、连字号 positional 名称却以底线取值，且 test_keys 未定义，不能视为可直接运行的 TTC 集成器；README 所述 evaluate_wandb_jsons.py 不在固定 tree。EK100 论文采 UniDet 产生 pseudo boxes 并依视频分割，现行 get_annotations_df 只接受 Ego4D，须找对应 release / 处理过的 manifest 才能宣称重现。

P236 · ActFusion

ActFusion: a Unified Diffusion Model for Action Segmentation and Anticipation

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

已核 ActFusion 的 feature/label loader、full_len 遮罩推论、TAS scorer 与 LTA MoC。固定 release 的预设 LTA 仍使用完整视频长度；不可标成论文 ActFusion⁺ 的未知未来长度协定。训练亦用 test split 分数选 best checkpoint，需保留模型选择条件。

> **版本与身份**
>
> 固定 00ba6c1df0ac30cfcb90110278dd3616a589ced4。release 的 50 Salads epochs=7001、n_mask=10，Breakfast batch_size=16、feature layers=[7,8,9]；论文表 S5 / §5.2 有 5000 epochs、50 Salads mask=25、Breakfast batch_size=4 等差异，不能把公开 JSON 称作逐项相同的论文设置。README 的 default_configs.py 实际位于 src/default_configs.py。本次未运行任何上游模型或训练。
>
> arXiv:2412.04353v1（2024-12-05），Dayoung Gong、Suha Kwak、Minsu Cho，NeurIPS 2024。官方作者帐号 gongda0e 的 README 明列相同 arXiv、题名、作者与会议；搜索中更早同名 magrogovich/ActFusion 不采用。PDF 提及 FUTR 和 DiffAct 是比较方法 / 重用程序，不能拿它们当 ActFusion release。此 repo 创建及固定 commit 为 2025-07-08，晚于论文。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	离线程序活动视频；Breakfast 与 50 Salads 是第三人称烹饪来源，GTEA 是第一人称烹饪来源，不能全部标 Ego 或机器人环境。程序以预先提取 I3D 特征为输入，不提供物理控制或 robot success。
任务	同一模型做 temporal action segmentation（TAS，完整观测）及 dense long-term anticipation（LTA，部分观测）；论文 TAS 用 50 Salads/Breakfast/GTEA，LTA 用前两者。原生 action 数从外部 mapping.txt 的列数取得，event_list 的行序编码与 read_mapping_dict 的首栏数字必须一致；这次未取得该数据报，未冒称固定程序类别数。论文 50 Salads 的 50 videos/17 fine-grained labels、Breakfast 的 1712 videos/48 labels、GTEA 的 28 videos/11 labels是原作统计，不能直接当本次加载的有效 case 数。

题数与数据	datasets/{dataset}/features/{video}.npy、groundTruth/{video}.txt（一行一个 frame label）、mapping.txt（ID 名称）、splits/{train,test}.split{split}.bundle。reader 接受二 / 三维 features，swapaxes 后为 augmentation×T×F，assert T 与 GT/boundary 长度一致；未知 label=-100。事件边界在 label 改变点及前一格置1，再可 Gaussian smoothing。sample_rate=8（50 Salads）或1（Breakfast），temporal_aug 对各 offset::rate 建样本，但 dataset 长度仍是 video 数；回复用 nearest interpolation 与首末值填充。时间原生为 annotation frame index，无可靠 fps/秒转换资产随 repo；2048 是输入 feature 维度。paper 指 5/4/4 folds，程序每次只读指定 --split，没有自动跨 fold 聚合；完整数据报及有效长度未下载。
评估方式	预设 decoder-agg：LTA α=0.2/0.3，full_len=feature[0]时间长度，observed_len=round(α×full_len)，切掉未来视觉特征后仍把 full_len 传给 ddim_sample 追加 mask tokens；这是已知全长设置。各 temporal offset 概率平均，median filter（50 Salads=30、Breakfast=15 个采样位置）、argmax，回复至 GT 全长。LTA 对 β=0.1/0.2/0.3/0.5，以 [int(αT):int((α+β)T)] 的原始 frame 范围计各 GT 类别 n_T/n_F，先跨 videos 累加，再对有 GT frame 的类平均 n_T/(n_T+n_F)×100；不是 frame micro accuracy，也不是 best-of-K。TAS Acc=所有评测 frame 正确数/总 frame；Edit=每视频压缩连续同标签后的 (1-Levenshtein/max(segment_count))×100 再视频平均；F1@10/25/50 以同类 segment IoU 门槛一对一配对，跨视频累积 TP/FP/FN 后计 F1。只排除字面 background，不能预设所有 SIL/action_start 类被排除。LTA 同时回传的 Acc/Edit/F1 是 observed prefix 上的分段分数，不能标成 future MoC。sampling seed=video_idx，25 sampling steps / 1000 diffusion steps；offset 不是添加试验数。

依这个顺序读

1. `README.md` ↗

   GitHub · gongda0e/ActFusion · 00ba6c1df0

   精确论文与作者、自称官方 release、MS-TCN 数据 / DiffAct 重用。

   `L1–9 · L31–64 · L84–109`

2. `main.py` ↗

   GitHub · gongda0e/ActFusion · 00ba6c1df0

   mapping、bundle split、单模型 TAS/LTA 入口与 α 设置。

   `L29–46 · L62–109 · L115–145`

3. `src/dataset.py` ↗
   GitHub · gongda0e/ActFusion · 00ba6c1df0

   feature/GT 对齐、未知标签、时间降采样、boundary 与回复全长。

   L11–107 · L110–126 · L129–189

---

4. `src/model/actfusion.py` ↗
   GitHub · gongda0e/ActFusion · 00ba6c1df0

   训练遮罩与推论 full_len mask-token、DDIM步数 / seed。

   L192–248 · L342–429

---

5. `src/trainer.py` ↗
   GitHub · gongda0e/ActFusion · 00ba6c1df0

   各 offset 聚合 / median、MoC 调用及 test 指针选 checkpoint。

   L150–186 · L278–381 · L384–481 · L519–547

---

6. `src/utils.py` ↗
   GitHub · gongda0e/ActFusion · 00ba6c1df0

   具体 frame Acc、segment Edit/F1、MoC 的计数与分母。

   L71–200 · L239–264

---

7. `src/default_configs.py` ↗
   GitHub · gongda0e/ActFusion · 00ba6c1df0

   只产生两数据集设置；核对 release 与论文超参数差异。

   L5–73 · L75–167

怎么接入我们的benchmark

可重用

bundle/video key、mapping、逐格 labels/features 对齐、TAS 具体 Edit/F1 与 LTA class-count scorer。

需要转换

source 保存 paper version/commit 及 MS-TCN feature来源；domain/environment 依数据集视角分开；task 分 TAS 和 LTA，case=(dataset revision,fold,video,α,β,length_protocol)，frames/segments/augmentation 不互相加总。另记 F、feature_stride、offset、original_frame_index、round/int 边界、median 窗、seed、DDIM budget；evaluator 区分 frame micro、video-mean Edit、pooled segment F1、class macro MoC。

仍需补齐

需固定完整 mapping/split/feature bytes与原始 fps，检验 mapping 行序=数字 ID、未知 -100、背景与末 segment end 的边界（实作最终 end=i，非 i+1）。论文 §5.4 的 ActFusion† 用 r=4×observed length，此 release 的 CLI/config/已核 sampler 未提供该协定；须添加明确 adapter/取得对应作者版本。train 在 test_test_dataset 上计 TAS 五项平均与八格 LTA MoC 平均选 best / combined 模型，须改为独立 validation 或如实标注。TAS及不同 α 共写同一 prediction/{video}.txt，导入须另用 protocol key 防覆写。GTEA 无随附设置与数据；不能只凭 main.py 的分支宣称已接通。

P237 · Gated Temporal Diffusion

Gated Temporal Diffusion for Stochastic Long-Term Dense Anticipation

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

已核 GTDA 的 Breakfast/50Salads 与 Assembly101 loader、DDIM inference 及 Mean/Max MoC / Frame Diversity。三个指针有不同分母：candidate-pooled class accuracy、逐 case/β oracle 选样后 class accuracy，以及候选两两 frame disagreement；不可折成共同 success 或把 Top-1 当部署模型选出的最佳预测。

> **版本与身份**
>
> 固定 010bad63c802e1666f64943dd098f3ac7be13118（2025-05-29），晚于ECCV 2024。readme所称 precomputed_<dataset> 命名与实际 predict_precomp_bf_prob.sh 不同。论文对Breakfast/Assembly用50 DDIM steps，50Salads用10；不能把两个已读脚本的50套全数据集。paper p.14 明指ANTICIPATR协定不同，不应与P240数值直接合并。仅读内核区段及小型split/label来源，未跑模型或加载pickle / 大资产。
>
> arXiv:2407.11954v1（2024-07-16），Olga Zatsarynna、Emad Bahrami、Yazan Abu Farha、Gianpiero Francesca、Juergen Gall；PDF p.1 直接给 olga-zats/GTDA，README 引同一 ECCV 2024 论文。GTD 是 stochastic diffusion、GTAN 是其 deterministic backbone；同 repo 两个模式不增加独立来源数。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	脱机烹饪（Breakfast、50 Salads）及玩具车组装 / 拆解（Assembly101）。Assembly CSV 含固定 RGB 相机与头戴 HMC view，程序按存在的 numpy feature 过滤，没有只选 Ego view 的条件；视角字段必须留在 case，不能把所有来源标第一人称。
任务	以 α=0.2/0.3 的观测预测 β=0.1/0.2/0.3/0.5 的逐格动作标签。Breakfast mapping=48类含 SIL；50Salads mapping=19类（17动作+action_start/action_end）；Assembly 使用 coarse action_cls/action_id，附带 actions.csv 有202类，不是全部细粒度 action 组合。每训练 video/view 衍生 α=.2/.3/.5 的3个 observation case，另有40%概率改为 .15+.25U；这些不是3支添加视频。

题数与数据	Breakfast/50s 为 D×T 的 .npy、逐行 label .txt、mapping.txt、split bundle。sample 回传 features、classes、classes_all、classes_one_hot、mask_past、mask_future、vid_len、file_name；feature 只取 [:int(αT)] 并 [::sample_rate]，collate 在未来 / padding补零，label padding=C+1。--part_obs 将 prediction span设为全视频的 .5，所需长度仍源自完整 GT T。Assembly CSV 为 video_id,view,action_type,video_start_frame,video_end_frame；coarse_labels/{action_type}_{video_id}.txt 每行 tab 分隔 start,end,label（尾空栏依实作），依 end-start 展开，程序注明 @30fps；TSM_features/{video_id}/{view}/features.npy 用 [start:end] 裁切。feature缺档、空segment或无长度会跳过，lmdb分支未实作。固定 split4 bundle 1136 train / 576 test unique video keys，无交集；这是名单数。Assembly train/val CSV 4684/1424列、204/61个 video_id，各16种view；尚非有效运行case数。保存预测 pickle 以 action_type_video_id_view 或 Breakfast file_name 为key，值为K组复原逐格预测，gt_ 前缀是全长GT。
评估方式	在线 validate 强制 batch_size=1，stochastic 用 EMA 产生 K=25 候选；Breakfast示例 sample_rate=3，Assembly=6，预测每个采样位置重复该倍数回原格。对 [int(αT):int((α+β)T)] 计 n_T/n_F。Mean MoC 先把所有视频、全部K候选的每GT类别正误格数相加，再对有GT的类别平均 T/(T+F)，输出0..1；不是每视频MoC的平均。Max/Top-1 MoC 对每视频及每β依GT挑该范围MoC最高的一个候选，累积其类别计数后再宏平均，同视频不同β可选不同候选。precomputed Frame Diversity 对每case取 K(K-1)/2 配对的 [1-相同frame数/该future窗长] 平均，再等权平均case。完整K=25对应300配对；test_num_samples 预设1会除零，不能沿用其预设。eval_file 另算 normalized segment Levenshtein error，但目前 MoC caller 丢弃该回传，不能当正式主指针。程序把 x_0 GT传到 predict，但底层只用 zeros_like取得形状，生成值起于高斯噪声；仍依赖GT长度，与GT action值泄漏需分辨。

依这个顺序读

1. `README.md` ↗

   GitHub · olga-zats/GTDA · 010bad63c8

   正式题名、作者与 Breakfast/Assembly features / annotation 外部依赖。

   L1–25 · L34–94

2. `src/main.py` ↗

   GitHub · olga-zats/GTDA · 010bad63c8

   数据分支、真实 action dict、α 与 evaluation 入口。

   L148–224

3. `src/batch_gen.py` ↗

   GitHub · olga-zats/GTDA · 010bad63c8

   bundle、3 个训练 observation case、部分未来长度、零补 features 与 masks。

   L34–136 · L159–216

---

4. `src/batch_gen_assembly.py` ↗

   GitHub · olga-zats/GTDA · 010bad63c8

   view/action_type identity、coarse segment/end-exclusive 展开与缺 feature 排除。

   L18–20 · L78–179 · L182–255 · L278–332

---

5. `src/trainers.py` ↗

   GitHub · olga-zats/GTDA · 010bad63c8

   EMA sampling、原 frame 回复、Mean/Max MoC、输出 pickle 与无效 stochastic Acc。

   L22–55 · L283–341 · L345–456 · L459–569

---

6. `src/bit_diffusion.py` ↗

   GitHub · olga-zats/GTDA · 010bad63c8

   确认 x_0 仅供形状；self-condition 是先前预测，输入 features 按观测 mask。

   L305–352 · L380–471

---

7. `src/evaluation.py` ↗

   GitHub · olga-zats/GTDA · 010bad63c8

   实际 class TP/FN 计数、frame mismatch、segment edit 距离。

   L12–87

---

8. `src/diff_evaluate.py` ↗

   GitHub · olga-zats/GTDA · 010bad63c8

   预存候选选择、best-per-case-and-horizon、成对 Frame Diversity 与聚合分母。

   L14–150

---

9. `src/main_diff_evaluate.py` ↗

   GitHub · olga-zats/GTDA · 010bad63c8

   precomputed 评测缺 mapping 的入口与 Assembly 空 dict 问题。

   L16–29 · L43–83

---

10. `scripts/prob/predict_bf_prob.sh` ↗

    GitHub · olga-zats/GTDA · 010bad63c8

    Breakfast split4、K=25、sample_rate=3、50/1000步与 epoch85。

    L1–33

---

11. `scripts/prob/predict_assembly_prob.sh` ↗

    GitHub · olga-zats/GTDA · 010bad63c8

    Assembly val、K=25、sample_rate=6与部分观测。

    L1–30

---

12. `scripts/determ/predict_bf_determ.sh` ↗

    GitHub · olga-zats/GTDA · 010bad63c8

    GTAN 无 diffusion，且示例用不同 split1。

    L2–29

---

13. `scripts/prob/predict_precomp_bf_prob.sh` ↗

    GitHub · olga-zats/GTDA · 010bad63c8

    K=25 的 precomputed 示例未传 --mapping_file。

    L1–19

---

14. `datasets/50salads/mapping.txt` ↗

    GitHub · olga-zats/GTDA · 010bad63c8

    17 动作外另含 action_start/action_end，原生19类。

    L1–19

---

15. `datasets/breakfast/mapping.txt` ↗

    GitHub · olga-zats/GTDA · 010bad63c8

    48类含 SIL，保留原始ID。

    L1–48

16. `datasets/assembly101/actions.csv` ↗

    GitHub · olga-zats/GTDA · 010bad63c8

    coarse action_id/verb_id/noun_id/action_cls 字段与边界 ID；不等于 fine labels。

    L1–16 · L195–203

17. `datasets/assembly101/train.csv` ↗

    GitHub · olga-zats/GTDA · 010bad63c8

    原生训练 CSV 的 video、view、action_type、起讫影格样例。

    L1–12

18. `datasets/assembly101/val.csv` ↗

    GitHub · olga-zats/GTDA · 010bad63c8

    原生 validation CSV 与多视角身份。

    L1–12

19. `datasets/breakfast/splits/train.split4.bundle` ↗

    GitHub · olga-zats/GTDA · 010bad63c8

    固定 split4 训练名单样例；另以全列 key scan 检验计数。

    L1–8

20. `datasets/breakfast/splits/test.split4.bundle` ↗

    GitHub · olga-zats/GTDA · 010bad63c8

    固定 split4 评测名单样例；另以全列 key scan 检验计数。

    L1–8

怎么接入我们的benchmark

可重用

原生 mapping、split与view身份、coarse-to-frame规则、TP/FN累积、候选pickle结构及Frame Diversity程序。

需要转换

source 记paper/repo/data-feature revision，domain/environment依烹饪或组装与view分类；task区分deterministic GTAN / stochastic GTD；case=(dataset revision,fold或train/val,video,action_type,view,α,β)，candidate_index属case内试样。保留annotation frame reference、sample_rate、GT-length protocol、K、EMA/checkpoint、diffusion T/D；evaluator标明Mean MoC / oracle Top-1 MoC / pairwise diversity各自分母与0..1尺度，不能直接对齐P236的百分比或P240的mAP。

仍需补齐

固定TSM/I3D及Assembly coarse annotation版本、实际feature存在清单，验证start/end与view长度裁切。在线stochastic分支没有累加frame error/num_frames却仍输出Acc，会得到0/0，应列为无效字段。precomputed读取硬编码/home/user/diff_results/final，与writer的 ./diff_results 不同；predict_precomp_bf_prob.sh未传mapping_file；Assembly的main_diff_evaluate把actions_dict设空，eval_file会以零长类别数组索引，须修复后才能重评。固定test_num_samples>=2并检查候选数 / 长度、有效GT窗；原程序min(pred_len,GT_len)可能缩短评测分母。尚未闭合50Salads的示例脚本 / checkpoints与完整跨fold聚合。

P238 · Object-centric LTA

Object-centric Video Representation for Long-term Action Anticipation

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

已核 ObjectPrompt 的 Ego4D clips→视觉 / 对象features→K串行→ED/AUED 与submission内核。现行release有README维度及fps矛盾，对象特征 / prompt生成资产未闭合；论文的50Salads MoC和EGTEA next-action实验不能因共用论文而视为已核可运行。

> **版本与身份**
>
> 固定 a826b3d0317f03ee2636c200fb6255ac36f305ba；README、YAML、论文附录的视频采样与特征维度须逐项核合，不能以下载到README/feature说明代替内核码核读。paper最终test报action ED但本地Task只评两head。source tree中的ego4dv2仅见范例注解，不能当实际存在的v2设置。未加载模型、PT资产或重跑任何结果。
>
> arXiv:2311.00180v1（2023-10-31），Ce Zhang、Changcheng Fu、Shijie Wang、Nakul Agarwal、Kwonjoon Lee、Chiho Choi、Chen Sun。PDF p.1直接连brown-palm/ObjectPrompt，README对应同名WACV2024论文。清单2023是初稿年；程序固定2023-12-31 commit。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	人类脱机视频。Ego4D与EGTEA Gaze+为第一人称；50Salads为第三人称烹饪。对象box及attention token是观测表征，不是robot pose、抓取目标或可运行动作。
任务	公开设置做Ego4D LTA：N=3个已标注过去segment、Z=20个未来verb–noun、K=5串行，115 verbs / 478 nouns。ObjectPrompt detector的81类embedding槽、每frame 10 detections与action taxonomy不同。论文另有EGTEA Gaze+ next-action top1/class-mean accuracy，以及50Salads α/β dense MoC；本repo tree只有Ego4D配置与clips reader，后两者的数据 / scorer未闭合。

题数与数据	fho_lta_{train,val,test_unannotated}.json根clips，以相邻clip_uid分组再按action_idx排序；用action_clip_start_sec/end_sec切.mp4，forecast_labels_idx为[Z,2]且次序verb,noun，last_observed_id=clip_uid_最后observed action_idx。设置input_segments=[-3,0)、output=[0,20)，mask预设false，名义上L个连续segments提供max(0,L-3-20+1)个完整窗口，仍须检验排序、短segment及资产可读性。test label填-1。image/object档为各clip_uid.pt；object每token先D维特征，尾6栏是xyxy四值、class_id、confidence；依模型切片及配置，GLIP是256+6=262，CLIP是768+6=774；image维度分别256 / 768。bbox原始座标单位 / 缩放未由读取器验证。每segment选4个frame，每frame10对象，image token另存，可对应论文把整张frame算第11个object的叙述。README写1FPS及GLIP232、CLIP image256，与配置image/object.fps=30和实际维度不符。索引由int(t*fps)取用，strict只把最后观测segment末端扣半个feature frame；validation/test仍random抽interval frame，不能声称固定center sampling。
评估方式	ClassificationModule.generate的naive方法先把head logits clamp(min=0)，各verb/noun head独立Categorical抽K串行；k=1才argmax。Task用[B,Z,K]逐head调用distributed_AUED：每case/prefix取min_k(editdistance.eval/该prefix长度)，再case平均；prefix 1..20积分trapz/(20-1)，ED_19即ED@20，AUED_mean只是verb/noun两head平均。epoch再不按batch size加权平均；DDP all_gather后仍须检查sampler重复和最后batch分母。这条链没有joint action-pair ED；论文称Damerau–Levenshtein，本地实际用editdistance.eval，正式server一致性未验证。top1/top5为每position正确case/该batch case，对时间位置与head再平均，并非EGTEA所需class-mean。AUED在Z=1硬回1.0，不可拿来评next-action。test单GPU、无本地GT scorer，submission是{last_observed_id:{verb:K×Z,noun:K×Z}}。

依这个顺序读

1. `README.md` ↗

   GitHub · brown-palm/ObjectPrompt · a826b3d031

   精确论文、Ego4D v1、外部 features 说明与维度 / fps歧义。

   `L1–3 · L34–71 · L95–110`

2. `configs/ego4d/sf_video_image_object_glip.yaml` ↗

   GitHub · brown-palm/ObjectPrompt · a826b3d031

   N=3/Z=20、30fps、10对象、GLIP256维及checkpoint指针。

   `L1–57`

3. `configs/ego4d/sf_video_image_object_clip.yaml` ↗

   GitHub · brown-palm/ObjectPrompt · a826b3d031

   同协定的CLIP768维对照。

   L1–57

---

4. `src/defaults.py` ↗

   GitHub · brown-palm/ObjectPrompt · a826b3d031

   K=5、naive sampling、strict、mask与输入来源预设。

   L104–113 · L169–210 · L232–296

---

5. `src/datasets/base_dataset.py` ↗

   GitHub · brown-palm/ObjectPrompt · a826b3d031

   原生clips / case创建、秒→feature索引、multi-modal tensor、split和reader。

   L34–48 · L84–174 · L239–336 · L338–472 · L474–522 · L528–649

---

6. `src/datasets/clip_samplers.py` ↗

   GitHub · brown-palm/ObjectPrompt · a826b3d031

   random / last / uniform clip采样与短片段回传差异。

   L11–44

---

7. `src/models/model.py` ↗

   GitHub · brown-palm/ObjectPrompt · a826b3d031

   对象尾6栏的实际切片、confidence处理及K串行生成。

   L147–199 · L340–352 · L406–482

---

8. `src/tasks/video_classification_task.py` ↗

   GitHub · brown-palm/ObjectPrompt · a826b3d031

   GT label只供loss/scorer，逐head/step分数、epoch聚合与test submission。

   L16–52 · L107–214

---

9. `src/utils/eval_util.py` ↗

   GitHub · brown-palm/ObjectPrompt · a826b3d031

   top-k分母、best-of-K ED/AUED与不等价的submission缺件检查。

   L9–13 · L34–50 · L52–152 · L154–168

---

10. `scripts/run.py` ↗

    GitHub · brown-palm/ObjectPrompt · a826b3d031

    validation checkpoint选择、固定seed、test限定单GPU。

    L23–98 · L136–151

怎么接入我们的benchmark

可重用

Ego4D原始case key / label字段、multimodal feature尾栏解析、confidence阈值及ED/AUED原生逻辑。

需要转换

source保存paper/repo/Ego4D版本与GLIP/CLIP prompt / features来源；domain/environment按数据集视角分离；task区分Ego4D sequence、EGTEA next-action、50Salads dense timeline。case=(dataset revision,split,clip_uid,last_observed_action_idx,N,Z)，时间保留原video秒、feature fps及index；box另记座标系，object_class_id与action noun分开。evaluator保留K、clamped-logit sampling、prefix normalization、head mean、batch aggregation与正式server角色；不产生共通success。

仍需补齐

取得并固定外部object/image features、prompt词表（most-common/kmeans/coco）与其只由training数据创建的证据；先解决30vs1FPS、GLIP262vs232与CLIP image768vs256，再验证shape与索引边界。reader只load特征、模型只信任尾栏，不能由README认定完整feature extraction已核。RandomClipSampler在短segment时回[a,b]，fill_video却期待[[a,b]]，要修复或给出可追踪排除规则。若任一激活modality缺anno，convert仍可能以至少一modality收案，getitem却要求全部激活key，须检查case完整性。submission checker硬从i=7起查且用位置i组key，与N=3的actual action_idx reader不同；不能当全case覆盖验证。50Salads/EGTEA仍需对应release与各自scorer。

P239 · MVP

Multiscale Video Pretraining for Long-Term Activity Forecasting

实作尚未确认 · 方法 / 综述 · 原作 · 独立页面

已核精确MVP论文与第一作者官方页；作者页该篇的Code/Project链接是空href，两笔GitHub查找均零结果，作者公开repo名单也无可确认MVP实作。未发现已能固定版本并核读的官方方法repo；保留paper-level数据 / 评测规格，不借用同名MVP或其他方法程序。

> **版本与身份**
>
> 无confirmed method-code commit可提供；已固定的1210bac9afe61febf68d5a205a31285254ee1141只属第一作者网站index.html，不计为方法repo。查找范围限下列PDF、官方页、两笔GitHub repository search与第一作者14个公开repo metadata，结论是尚未确认，不是声称全球不存在程序。补查均HTTP200，没有429 / 403 rate limit或deferred；未重试、未下载模型 / 数据资产。
>
> Multiscale Video Pretraining for Long-Term Activity Forecasting，Reuben Tan、Matthias De Lange、Michael Iuzzolino、Bryan A. Plummer、Kate Saenko、Karl Ridgeway、Lorenzo Torresani。缓存PDF为arXiv:2307.12854v1（2023-07-24）；作者页同名项目列Submission, 2023，未提供足以确认后续会议版的链接。MVP指Multiscale Video Pretraining，不是任何同缩写的机器人预训练或重建repo。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	论文研究脱机人类第一人称视频：Ego4D多种日常活动及EPIC-KITCHENS-55/100厨房活动。不是可reset的机器人环境；未取得作者实际reader，没有把母数据集全库时数当MVP有效样本数。
任务	方法是self-supervised multiscale video pretraining，转移到三种分开的任务：order-agnostic未来verb/noun集合、order-specific未来verb–noun串行、video-summary forecasting。最后一种是从候选文字摘要检索正确摘要，不是生成文字摘要。训练用future clip representation作target，不能当测试时可见未来影格。
题数与数据	已核论文§3.1及附录B.1：video以10FPS抽样，每clip8frames（约0.8秒），observed/future clip串行以N_O/N_F表示，K是两串行的时间offset、S是timescale stride、N_P=N_F/S是预测尺度数。保留上述clip/time单位，K不能误当Ego4D常见的5候选。order-agnostic label是N_verb与N_noun两个multi-hot矢量；order-specific是每预测位置的verb/noun ID；summary task是observed clip串行与整段摘要文字配对。附录A说Ego4D沿用官方train/validation，test为held-out challenge，且各split出现的类别不一致；EK55/100是不同版本，没有提供足以固定case清单的文件。原生串行化key、annotation文件名、category ID对照、观测百分比清单、summary候选集合与split manifest均未公开可核。正文泛定义预测剩余视频，而§4.2.1实验提next8 timesteps，不能未加分辨地套Ego4D Z=20。

评估方式	只有paper-level规格，未核到作者scorer。order-agnostic按verb与noun类别报mAP（presence within future span，非box IoU AP）；零positive类别是否纳入、AP积分 / tie及样本权重规则未能核实。order-specific报verb/noun/action edit distance，action为verb–noun组合；精确distance实作、范式分母、候选数及选样规则没有code可确认，不能直接移植P234/P238的best-of-5。summary forecasting以R@1/5/10评估：分子是正确摘要进topK的video query数，分母是被评query数；完整候选池大小、同视频多摘要及重复处理未能核实。预训练contrastive region accuracy是另一个训练诊断，不是下游action成功率。附录B.2称下游冻结video model、训练linear probes，应保留这一转移设置。

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

可重用论文定义的pretraining→downstream关系、三种task区分、8frame/10FPS clip与时间尺度概念，以及各评测名称；没有可直接重用的已核reader/scorer。

需要转换

source记arXiv v1、PDF SHA及author-page固定commit，作者网站明确标为publication evidence；domain/environment保存人类Ego4D与EK版本；task分unordered multi-label、ordered sequence、summary retrieval。case/evaluator先保存描述性规格与未解析字段，不虚建案例、秒座标或通用success。未来若取得实作，须另建observed/future窗口、label vocabulary、summary candidate-set与training-only target可见性。

仍需补齐

需要有作者或primary paper明确连回的官方repo与40位commit、small example annotations/loader、split/category manifest，以及三种实际scorer及分母。另需厘清order-agnostic实验的8步与剩余全片定义、ordered ED的范式/候选预算、summary retrieval候选集合。不能用Ego4D/EPIC数据本身或rxtan2的网站模板repo补成MVP实作。

P240 · ANTICIPATR

Rethinking Learning Approaches for Long-Term Action Anticipation

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

已沿ANTICIPATR的TSV/feature reader→instance-set预测→timeline / 集合前处理→evaluator核读。其future比例以剩余视频为基准，与P236/P237的全视频比例不同；公开commit的scorer链还有会阻止合法计分的变量、shape与case键错误，不能宣称直接重现论文结果。

> **版本与身份**
>
> 固定 a7f0af215f50680e6b784df195a17884cb520bbf（2023-04-06）。论文§4与附录A.1.3定义remaining-length protocol及dense重建，与其引用的全长比例benchmark需分项对待。主评测应保留模型提出的instance集合；loss配对不是scorer，loss_segment/loss_siou以跨rank平均target instance数（至少1）范式，不是case成功率。仅核内核source区段与小型原生文字数据，未安装、加载pickle / checkpoint或跑上游模型。
>
> Rethinking Learning Approaches for Long-Term Action Anticipation，Megha Nawhal、Akash Abdu Jyothi、Greg Mori，ECCV 2022；缓存arXiv:2210.11566v1（2022-10-20）。PDF p.3直接连Nmegha2601/anticipatr，README列同题名作者。原生方法是两阶段Anticipation Transformer；不是固定20个verb–noun的Ego4D LTA。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	脱机人类活动：Breakfast/50Salads第三人称烹饪；EK55/EGTEA Gaze+第一人称厨房。此release的stage2 build_dataset只注册bf与ek，50Salads/EGTEA虽有pretraining名单及论文结果，不能视为stage2已接通。
任务	预测未来action instance集合，每instance是(label,start,end)，query数是最多预测槽数，不是任务数。stage1 snippet anticipation、stage2以冻结snippet encoder配合video encoder/decoder是论文方法关系，本次内核核读以stage2数据 / 计分为主。Breakfast时间条件dense timeline评测；EK55时间无关future-label presence评测。固定Breakfast词表48类含SIL；EK示例容量125 verbs/352 nouns/3806 actions，many-shot档实际26 verbs/71 nouns，不能照ek.py的旧注解32 nouns。

题数与数据	名为.csv的split实际无header、tab分隔：video_path,start_frame,end_frame,verb_id[,noun_id]；另*_nframes.csv是video_path与全长frame数。DatasetSegmentRecord.num_frames=end-start+1。外部feature pickle是video→frame_index→2048维矢量，reader不载RGB；目前切取range(start-31,end+31)中存在的key，会涵盖观测终点之后至+30的feature index，须验证提特征的时间支持域。局部fps=1只是idx模数，不能解读为1Hz；CLI fps预设60。target含video_id、labels_onehot、instance labels、label_mask、segments、duration、prediction_duration、observation_duration、ratio_idx、prediction_idx、observation_positions、fps；segments=(native_start/end-observation_duration)/prediction_duration，duration以秒存，observation/prediction_duration仍是frame数，单位混用不能抹平。EK action ID依各自CSV中的verb/noun频率另建int_to_idx，可能造成train/val ID漂移。
评估方式	实际入案：只取end<=t的完整past与start>t的future，且各至少3个action；Breakfast future另需end<=pred_t，跨边界action被排除。EK α=.25/.5/.75预测全部remaining；Breakfast α=.2/.3、β=.1/.2/.3/.4/.5，pred_t=t+int(β*(T-t))，论文表只报β=.1/.2/.3/.5。以固定val_S1文字档依相同条件作结构重算（未载features）：Breakfast252视频/1548segments只产生12个窗口、5个video keys；EK67视频/7742segments产生172窗口、60个video keys。这是入案逻辑统计，非成功跑分。模型输出pred_logits[B,Q,C+1]及pred_segments[B,Q,2]；后者实作ReLU+0.1，并未保证<=1或end>=start。get_unrolled_timeline将segment乘prediction_duration，重叠处逐类取最大softmax，去no-action后argmax；却把整个future multi-hot label拷贝到所有时间位置当GT，未重建instance的逐格GT。get_mAP再把timeline presence加总clip至0/1，外层预定调用sklearn average_precision_score macro/micro；get_accuracy预定用1-hamming_loss按class平均×100，不能等同论文的class-normalized逐格MoC。snapshot的get_accuracy写acc[k]但k未定义，get_AP_perclass未初始化preds[k_ap]/targets[k_ap]便append，get_accuracy_perclass对1D数组argmax(axis=1)；所以没有可认定正确的实际评测分母 / 合法输出。engine更以video name为唯一key覆写不同α/β窗口；单process下前述12/172窗口最多只留5/60笔。

依这个顺序读

1. `README.md` ↗

   GitHub · Nmegha2601/anticipatr · a7f0af215f

   精确论文与两阶段方法 / 外部数据源。

   `L1–3 · L15–38 · L42–50`

2. `src/datasets/__init__.py` ↗

   GitHub · Nmegha2601/anticipatr · a7f0af215f

   此release实际注册只有ek与bf。

   `L1–12`

3. `src/datasets/bf.py` ↗

   GitHub · Nmegha2601/anticipatr · a7f0af215f

   Breakfast feature/split路径与α=.2/.3。

   L13–43

---

4. `src/datasets/ek.py` ↗

   GitHub · Nmegha2601/anticipatr · a7f0af215f

   EK55 feature/split与α=.25/.5/.75。

   L14–44

---

5. `src/datasets/baseds_longfuture.py` ↗

   GitHub · Nmegha2601/anticipatr · a7f0af215f

   原生TSV、instance/set target、入案条件、相对remaining窗口与features时间界线。

   L21–53 · L75–180 · L183–277 · L295–372

---

6. `src/datasets/ds_utils.py` ↗

   GitHub · Nmegha2601/anticipatr · a7f0af215f

   video_id编码 / 反解，以及engine只按视频创建键。

   L19–67

---

7. `src/main.py` ↗

   GitHub · Nmegha2601/anticipatr · a7f0af215f

   类别容量、matcher/query/fps预设与loader。

   L19–86 · L117–131

---

8. `run_scripts/run_anticipatr.sh` ↗

   GitHub · Nmegha2601/anticipatr · a7f0af215f

   实际EK示例125 verbs/352 nouns/3806 actions、900 queries。

   L1–3

---

9. `src/models/antr.py` ↗

   GitHub · Nmegha2601/anticipatr · a7f0af215f

   pred_logits / pred_segments、timeline生成、loss分母与scorer前处理错误。

   L29–95 · L135–190 · L206–229 · L241–324

---

10. `src/models/matcher.py` ↗

    GitHub · Nmegha2601/anticipatr · a7f0af215f

    实际greedy matching；import Hungarian不等于运行Hungarian。

    L21–80

---

11. `src/utils/segment_utils.py` ↗

    GitHub · Nmegha2601/anticipatr · a7f0af215f

    所称generalized_segment_iou实际是普通一维IoU。

    L4–31

---

12. `src/engine.py` ↗

    GitHub · Nmegha2601/anticipatr · a7f0af215f

    criterion→每例metric→video-key字典覆写→all_gather→evaluator。

    L73–123

---

13. `src/metrics/longfuture_metrics.py` ↗

    GitHub · Nmegha2601/anticipatr · a7f0af215f

    具体AP / accuracy实作、预期macro/micro与静态可见失效点。

    L12–96

---

14. `data/bf/longfuture/annotations/bf_verbs.csv` ↗

    GitHub · Nmegha2601/anticipatr · a7f0af215f

    48类含SIL。

    L1–49

---

15. `data/bf/longfuture/split/val_S1.csv` ↗

    GitHub · Nmegha2601/anticipatr · a7f0af215f

    无header的TSV segment样例与单一verb栏。

    L1–12

16. `data/bf/longfuture/split/val_S1_nframes.csv` ↗

    GitHub · Nmegha2601/anticipatr · a7f0af215f

    原生视频长度表。

    L1–12

17. `data/ek/longfuture/split/val_S1.csv` ↗

    GitHub · Nmegha2601/anticipatr · a7f0af215f

    含重叠instance的TSV、verb/noun尾栏。

    L1–12

18. `data/ek/longfuture/split/val_S1_nframes.csv` ↗

    GitHub · Nmegha2601/anticipatr · a7f0af215f

    EK视频长度表与path身份。

    L1–12

19. `data/ek/longfuture/annotations/EPIC_many_shot_nouns.csv` ↗

    GitHub · Nmegha2601/anticipatr · a7f0af215f

    实际71个many-shot noun ID。

    L1–72

20. `data/ek/longfuture/annotations/EPIC_many_shot_verbs.csv` ↗

    GitHub · Nmegha2601/anticipatr · a7f0af215f

    实际26个many-shot verb ID。

    L1–27

怎么接入我们的benchmark

可重用

版本化TSV与length table、dataset-specific video_id、instance(label,start,end)、观测 / future比例及原生query输出界面；普通temporal IoU函数可作原生定义参照。

需要转换

source记paper/commit及EgoTopo/MS-TCN feature来源；domain/environment保留view与dataset；task分instance-set模型、dense timeline与future-label set评测；case键必须包含dataset/split/video/α/β与有效窗口，而不只video。frame、秒、normalized-future座标分栏，native inclusive标注与rasterizer [start,end)保留差异；global action mapping与many-shot mask另版本化。evaluator必须重建合法GT timeline与每类正确/总GT格数，或保存per-case presence及score以计AP；β剩余长度协定不可直接换算成P236/P237表格同一格。

仍需补齐

优先修复criterion/evaluator未定义变量、mask形状、GT timeline与engine窗口覆写，再确认macro/micro / 空类 / frequent/rare的分母。须固定global action ID，noun分支instance["nouns"]与创建时"noun"也不一致。确认末端+30 feature索引是否越界可见、实际feature pickle及stage1 checkpoint版本、min-three入案排除，并取得50Salads/EGTEA的stage2 reader/scorer。build_matcher永远回GreedyMatcher，CLI hungarian未接；generalized_segment_iou只算普通IoU；greedy将targets依长度排序后未还原原索引，需对照label配对。以上静态疑点尚未运行验证，不可把程序已下载当可重现。

P241 · AFF-ttention

AFF-ttention! Affordances and Attention models for Short-Term Object Interaction Anticipation

内核内容已核读 · 主来源 · 原作 · 独立页面

已核STA reader→预测affordance prior→AFF ROI head→OverallMeanAveragePrecision，以及添加EPIC STA pickle的读取格式。固定release的v2设置仍遇v1字段硬编码及未随repo提供的import；AFF、hotspots和完整运行环境尚未闭合，不能以README结果或外部权重链接宣称可重现整篇。

> **版本与身份**
>
> 固定 1a1253fa2bde09ef1de4894f3bf872c1fbf270de（2024-07-15）。已核propagate_AFF_from_node.py用top1/3/5 visual及cross-modal邻居、1.5×最近距离筛选、softmax(2×similarity)加权后逐类max、max-normalize再softmax；论文式(3)是加权sum后exp，不能混成同一prior配方。该脚本np.save被注解，不能直接认定会产出reader所需档；其diagnostic n_samples从1起算、最后分母多1，也不是STA mAP。generate_AFF_labels.py是另一cluster频率版本，root标TRAIN但输出名含VAL，需要provenance而非靠文件名判split。README连的weights与config checkpoint亦不同。只核以上内核source / 小型词表，未跑模型、simulator或下载大资产。
>
> AFF-ttention! Affordances and Attention models for Short-Term Object Interaction Anticipation，Lorenzo Mur-Labadia、Ruben Martinez-Cantin、Jose J. Guerrero、Giovanni Maria Farinella、Antonino Furnari；Guerrero在清单/README也写Josechu。缓存arXiv:2406.01194v2（2024-06-05），README对应ECCV 2024，PDF hyperlink discovery直接指lmur98/AFFttention。README另连2407.04369 challenge report，不能混为本篇PDF版本或后续STAformer++。

领域	餐饮与烹饪
环境	Ego4D v1/v2日常活动与作者整理的EPIC-Kitchens STA第一人称视频。affordance node/zone是视频中视觉相似的活动区域及其已观察交互，不是3D场景layout或机器人可运行技能；hotspot是图像中的人手交互概率。
任务	下一次对象交互的box、noun、verb、TTC与confidence。v1 taxonomy87 nouns/74 verbs，v2 128/81；类别、prediction frame、GT object、zone/visit与policy trial各为不同单位。P241有新的curated EPIC STA标注贡献，不能与P235的EK100 pseudo-box实验或母EK action数据直接合并计数。

题数与数据	Ego4D JSON读info.video_metadata与annotations；每ann含uid、video_id(v1)/video_uid(v2)、frame、objects[{box,noun_category_id,verb_category_id,time_to_contact}]。still图为video_id_七位frame.jpg；fast LMDB以video_id为父目录、video_id_十位frame为key，值是JPEG；sampler取frame-15..frame共16格、早于0补0，没有取未来影格。frame索引与TTC秒保留各自单位。target是boxes/noun_labels/verb_labels/ttc_targets；noun固定+1，verb在ROI_HEADS.VERSION不含v1时+1，因此两个aff设置都+1，与数据集v1/v2名称无关。train移除退化框 / 无对象ann；test无objects时loader制造假框与0 label，不能作GT。AFF档是list[dict]的numpy对象容器，key为v_id、frame、AFF_N_top3、AFF_V_top3等；reader把它们命名AFF_N_GT/AFF_V_GT，实际来源是predicted_AFF档，缺项填全1 prior。EPIC pickle则是[{eid,video_id,timestamp,objects:{noun_category_id[],verb_category_id[],boxes[],time_to_contact[]}}]；框被当normalized xyxy乘(1920,1080,1920,1080)。图像frame=int(timestamp*30+1)，AFF lookup却round(timestamp*30)+2；timestamp秒与这两个索引不可混用。EPIC noun合群/排除others、verb删除稀用词都会改case分母；test分支实际重用val_annotations.pkl。未取得完整标注资产，未宣称有效case总数。
评估方式	STATask.validation_epoch_end先list_gather所有rank、以uid创建pred/GT dict去重，再OverallMeanAveragePrecision(top_k=5)。每图依score排序，针对各配对条件对尚未匹配的GT选最大IoU；IoU用xyxy像素端点+1面积，门槛>0.5，TTC abs(error)<=0.25秒。Top-5对每图每条件豁免(5-1)×GT对象数个最高分FP；余下按confidence创建precision=TP/(TP+FP)、recall=TP/该类GT对象数，取单调precision envelope的VOC积分。12个输出中前8个是合并类别的AP，后4个map_box_noun、map_box_noun_verb、map_box_noun_ttc、map_box_noun_verb_ttc才按有GT的noun类别宏平均×100；checkpoint用最后一项，不能把global AP混入主表mAP。AFF head将预测prior×各head softmax后重新范式，去背景、每proposal保留verb_topk=1、noun×verb分数>0.002（不是config的0.05），per verb–noun NMS后最多100 detections；此预测budget与scorer的Top-5 FP豁免不同。export把noun减1、verb减相应offset，输出results[uid]的box/score/noun_category_id/verb_category_id/time_to_contact。test仅导出，无公开GT scorer结果。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **1** STA joint prediction formulation · 原文页 10

依这个顺序读

1. `README.md` ↗

   GitHub · Imur98/AFFttention · 1a1253fa2b

   精确论文、STAformer/AFF/hotspot角色、Ego4D版本及添加EPIC STA标注。

   L3–14 · L25–51 · L55–76

---

2. `stillfast_code/test_dir/Aff_ttention_v1/config.yaml` ↗

   GitHub · Imur98/AFFttention · 1a1253fa2b

   v1类别、16-frame输入、aff head、split与输出开关。

   L13–35 · L39–76 · L114–162

---

3. `stillfast_code/test_dir/Aff_ttention_v2/config.yaml` ↗

   GitHub · Imur98/AFFttention · 1a1253fa2b

   v2类别与数据路径；不能用folder名称代替reader版本核对。

   L11–35 · L39–76 · L115–162

---

4. `stillfast_code/datasets/ego4d_sta_still.py` ↗

   GitHub · Imur98/AFFttention · 1a1253fa2b

   原始STA schema、train清理、硬编码v1 key与label offsets。

   L22–38 · L40–82 · L102–153 · L180–203 · L232–258

---

5. `stillfast_code/datasets/ego4d_sta_still_video.py` ↗

   GitHub · Imur98/AFFttention · 1a1253fa2b

   past-frame sampler、预测AFF加载 / lookup、缺件均匀prior与batch字段。

   L9–17 · L72–110 · L168–226

---

6. `stillfast_code/datasets/sta_hlmdb.py` ↗

   GitHub · Imur98/AFFttention · 1a1253fa2b

   LMDB父目录 / 10位frame key与JPEG bytes。

   L8–21 · L36–56

---

7. `stillfast_code/models/stillfast.py` ↗
   GitHub · Imur98/AFFttention · 1a1253fa2b

   Dino/EgoVLP及aff head实际分派、外部StillFast依赖与缺import。

   L1–25 · L73–128

---

8. `stillfast_code/models/faster_rcnn.py` ↗
   GitHub · Imur98/AFFttention · 1a1253fa2b

   noun_labels改名labels并把AFF附加target送入head。

   L120–154

---

9. `stillfast_code/models/faster_rcnn_AFF_sta.py` ↗
   GitHub · Imur98/AFFttention · 1a1253fa2b

   Bayes乘prior再范式、verb_topk、score/NMS与最终预测。

   L190–260 · L287–391 · L396–441 · L443–584

---

10. `stillfast_code/tasks/sta.py` ↗
    GitHub · Imur98/AFFttention · 1a1253fa2b

    跨rank收集后uid去重、去AFF target、实际Overall mAP及提交ID还原。

    L36–92 · L94–193

---

11. `stillfast_code/evaluation/sta_metrics.py` ↗
    GitHub · Imur98/AFFttention · 1a1253fa2b

    具体GT配对、FP预算、VOC积分与global AP/noun-macro mAP分母。

    L4–59 · L121–205 · L207–359 · L416–523

---

12. `code_extract_affordances/generate_AFF_labels.py` ↗
    GitHub · Imur98/AFFttention · 1a1253fa2b

    cluster/node/visit/STA→每zone标签分布与数据档格式。

    L1–26 · L28–61 · L83–91

---

13. `propagate_affordances/propagate_AFF_dataset.py` ↗
    GitHub · Imur98/AFFttention · 1a1253fa2b

    v2 validation query v_id/frame/STA targets；标签供diagnostics。

    L8–30 · L80–96

---

14. `propagate_affordances/propagate_AFF_from_node.py` ↗
    GitHub · Imur98/AFFttention · 1a1253fa2b

    train-node descriptors、query visual matching、weighted-max priors、诊断分母与输出未写档。

    L24–50 · L61–122 · L124–165 · L281–391 · L396–412

---

15. `stillfast_code/datasets/ek_55_sta_dataset.py` ↗
    GitHub · Imur98/AFFttention · 1a1253fa2b

    EPIC专用pickle/eid/timestamp、class merge/filter、normalized框与frame偏移。

    L79–120 · L138–213 · L224–256 · L260–405

怎么接入我们的benchmark

可重用

Ego4D v1/v2 taxonomy、STA JSON与EPIC pickle reader的原生字段、predicted-prior lookup / Bayes fusion、具体mAP与submission adapter。

需要转换

source记paper/commit、Ego4D或curated EPIC annotation revision、StillFast base与prior/hotspot资产；domain/environment为人类视频和zone provenance。task保持STA；case用dataset+split+uid/eid，另存video/frame/timestamp、原框座标、class_remap/背景offset。zone/visit/node及其training STA/narration是source附属数据，不增加case。evaluator固定score生成、verb_topk/NMS/100候选、Top-5豁免、TTC门槛、noun macro AP与uid去重；跨source不等价为robot success。

仍需补齐

优先修复Ego4D reader的video_id硬编码与v2 video_uid；固定StillFast base commit / 安装布局，补缺的ego4d_sta_hands_still_video、faster_rcnn_HANDS_sta、faster_rcnn_prior_HANDS_sta、detr_criterion等被无条件import的模块。移除...及作者绝对路径，固定完整split/annotation与predicted_AFF/hotspot SHA。AFF数据库生成 / descriptor采样仍需train-only及时间可见性核验；当前code以train_nodes匹配visual query，不能因GT栏名就指为oracle，也不能因文件名train就视为已证明无泄漏。EPIC需要固定class_names、实际class remap及两套frame偏移，且test=val不能当独立test。hotspot读入有外部placeholder，当前Ego4D __getitem__的contact-point调用与heatmap target被注解，selected aff链未核到完整hotspot重权重运行路径。

P242 · NAOGAT

Leveraging Next-Active Objects for Context-Aware Anticipation in Egocentric Videos

实作尚未确认 · 方法 / 综述 · 原作 · 独立页面

已核NAOGAT原作、WACV刊载页及作者现行project：GitHub仍标示Soon，EK-100添加NAO框标注须向作者索取。可收录论文层级的STA方法与标注衍生关系，尚无可固定commit并核读的官方reader / evaluator。

> **版本与身份**
>
> 2023年arXiv摘要承诺接受后提供code；2026-10-11读到同篇project仍为GitHub(Soon)，有Code标题但没有方法链接。project文末误标WACV 2023，刊载年份以CVF 2024为准；本笔技术内容仅按已固定arXiv v3核读，未声称和会议PDF逐段一致。探索用/wacv24短网址返回404，其后由作者about找到可用现行project；这不是GitHub repo不可用或全球无code的证明。本轮小型HTML读取除该404外均200，未遇429 / rate-limited403；未联系作者或读取内嵌视频。
>
> 精确题名为Leveraging Next-Active Objects for Context-Aware Anticipation in Egocentric Videos；Sanket Thakur、Cigdem Beyan、Pietro Morerio、Vittorio Murino、Alessio Del Bue。核读缓存arXiv:2308.08303v3（2023-10-05）；CVF确认WACV 2024、pp.8657–8666。作者about以略不同的Short-Term题名连回同一arXiv及本project。ANACTO、GANOv2是另篇方法；网站模板richzhang/webpage-template亦非NAOGAT程序。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	Ego4D人类第一人称日常活动及EPIC-KITCHENS-100厨房视频，皆为脱机观测。STA假设下一交互对象在最后观测影格可见；EK-100原有action anticipation并不保证此条件。未提供可reset的robot场景或动作控制界面。
任务	输入截至T的RGB串行，预测下一active object的noun类别n、最后观测影格中的bounding box b、未来动作verb v及距接触的δ秒。NAO定位与动作 / TTC联合预测属一个STA问题的不同输出，不是四套机器人任务。EK-100实验仍须和Ego4D STA分开记录。
题数与数据	§3–4.2：16影格、4 FPS；训练resize高度248–280 pixels并crop224。Faster R-CNN侦测输入为每对象4个框座标加confidence，固定Q笔不足时padding；Q/Nq的实际值、座标顺序 / 范式与串行化key未能由reader核实。Ego4D forecasting部分称逾1000视频、STA标注30 FPS；EK-100母库97 verbs / 300 nouns / 约90K action segments皆非本篇有效case数。附录§7的EK-100框由GT noun匹配侦测器结果产生，失败再用hand-object ROI及top-3 noun候选；noun仍沿用EK标签，不是新人工重标整库。12.5% training、6% Unseen及约22% Tail的NAO缺失分别有不同分母；附录另把22%称validation中的「Test Set」，需原始ID核对。现行project只提供索取标注的联系方式，没有已取得的annotation档、split manifest或loader。

评估方式	仅核到paper protocol：§4.3以noun / verb top-1判对、box IoU≥0.5及|TTC误差|≤0.25秒；联合条件须全部满足。Table1列8种b/n/v/δ组合的AP，但正文概述称4组，应保留各字段而非并成单一成功率。候选预算、AP积分 / macro平均、confidence合成及漏标样本处理没有scorer可核，不能径套另一篇Ego4D的Top-5实作。EK-100 Table2分Unseen/Tail/Overall及action/verb/noun；§4.3仅援引先前方法的metric，未在本版明列其Top-k / 类别平均细节。§4.4剔除无NAO的tail clips后所得分数属另一次过滤评测，不能覆盖原validation分母。

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

可重用原作身份、Ego4D STA / EK-100衍生框标注关系、四项预测输出、16frame/4FPS输入及论文明列的IoU与TTC门槛；尚无已核可运行reader或scorer。

需要转换

source保留arXiv v3及WACV 2024关系；domain/environment限定人类视频脉络，task以STA定义建档。未来case须带video/segment身份、最后观测影格、原生box参照、noun/verb taxonomy、δ秒及缺失NAO原因；Ego4D、EK原split及过滤子集分开。evaluator保存各AP组合与尚待核实的EK metric，不把母库frames/segments或模型queries当case数。

仍需补齐

作者可确认的官方方法repo / commit、EK衍生框文件及授权、精确split与NAO缺失ID、座标 / 时间转换reader、分类与AP evaluator。需厘清附录Test Set / 正文Tail Set及EK metric细节；ANACTO或GANOv2程序不可代填。

P243 · FactCheck（LTA）

FactCheck: Feasibility-aware Long-term Action Anticipation with Multi-agent Collaboration

实作尚未确认 · 方法 / 综述 · 原作 · 独立页面

已核FactCheck原作的Observe–Plan–Verify流程、数据与mAP设置，并找到通信作者列出的同篇IET Software论文；该条目仅连Paper，尚无confirmed官方方法repo。本文的Verifier是LLM推理模块，报告的mAP是未来类别集合评测，不能当成实体可行性验证或机器人成功率。

> **版本与身份**
>
> cached repository query「FactCheck action anticipation」为0笔；arXiv摘要及PDF链接抽取没有method code链接，Qwen/Grok链接属模型引用。通信作者同篇publication条目只列期刊Paper。一次依该链接读取Wiley得到HTTP403 Forbidden，共享network.py没有标成rate_limited，未重试；期刊版code/data availability仍未核到，另列为待查来源，不能把403当repo不存在。技术结论限固定arXiv v1；未确认全球不存在程序。
>
> FactCheck: Feasibility-aware Long-term Action Anticipation with Multi-agent Collaboration；Rui Cao、Jiannong Cao、Bo Yuan、Zhiyuan Wen、Mingjin Zhang。固定核读arXiv:2606.14778v1（2026-06-10）；首页的Journal 2023与DOI xxx/xxxx是模板内容。通信作者Zhiyuan Wen的publications页列同五位作者及IET Software 2026、DOI 10.1049/sfw2/7118691。此FactCheck是动作预测方法，非同名新闻 / 文字事实查核项目。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	脱机EPIC-KITCHENS-55与EGTEA Gaze+人类第一人称厨房活动。Observer由已观测片段的辨识结果重建对象状态，并非从robot simulator取得真实状态。§5.4的长程操作及人机协作属未来应用构想，没有本篇实体robot评测环境。
任务	§3以M个action segments构成视频、N=floor(αM)个历史片段预测Z=floor(βM)个未来verb–noun动作；α为25/50/75%，β≤1−α。Observer产生历史动作、意图 / 环境摘要及图；Planner生成有序草稿；Verifier依Object Availability、Affordance Validity、State Consistency修正。三个agent是推理角色，不是三台robot，也不是三个独立benchmark。§5.1.1实际评测取剩余视频中的动作类别集合，须保留「串行生成、集合计分」差异。

题数与数据	§4.1与§5.1.3：每action segment均匀抽4影格，以冻结CLIP-ViT-L/14-336px加训练分类head辨识verb/noun；抽样是每片段4张，非4 FPS。History Action Abstract是一句生成文字。图的noun node保存Attr(n)=(v,t_start,t_end)，edge weight计历史转移频率；时间单位未明列。Table3提供示意JSON的nodes[].id/state/history及edges[].src/tgt/w；§5.1.3另称图串行化为JSONL，未取得真正文件或parser，不能将示例当已验证schema。Planner用Qwen2.5-3B/7B-Instruct与QLoRA；摘要及Verifier用grok-4-1-fast-reasoning，Verifier prompt含3个人工few-shot范例。母库的EK-55 39.6K segments / 125 verbs / 352 nouns及EGTEA 86 videos / 10,325 action instances / 19 verbs / 53 nouns，不是本篇测试case数。精确split ID、完整提示与范例、生成输出及数据reader均缺。
评估方式	§5.1.1按α=25/50/75%的观测比例，对剩余(1–α)部分的未来类别做mAP-All / mAP-Freq / mAP-Rare；Freq/Rare沿EGO-TOPO分组，这里未提供类别表或频率门槛。未核到实际sequence→class score转换、重复动作处理、AP积分 / 空positive类别及各α平均方式。没有独立的物理可行性真值、constraint violation rate或robot rollout；Table3是定性修正案例，不能作scorer。§5.1.1称沿用train/test split，§5.2.1却将EK-55结果称validation；§3的floor与79动作案例「50%=40个observed」亦不一致，须以原始case生成器厘清。

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

可重用三角色流程、历史信息可见性、三种feasibility约束、图标意字段、每segment4影格与多观测比例，以及mAP-All/Freq/Rare的原生名称。未取得作者可运行checker或dataset reader。

需要转换

source保留arXiv v1及作者页所列journal关系；domain/environment归人类视频预测。task同时保存有序生成目标与无序集合计分。case应保留video/segment、α/β、observed recognized labels、生成摘要 / 图、draft与refined outputs，并与GT分离；evaluator记类别与频率分组、提示 / 模型版本及采样预算。图中的状态为推断记忆，不升格成已确认的实体世界状态。

仍需补齐

官方method repo与commit、完整graph schema / 读写器、观测切点及split manifest、sequence-to-score与mAP实作、三个few-shot范例及API设置。需厘清noun node与文中action edge的链接语义、JSONL和表中JSON示例的对应、floor边界及test/validation称法；若要评机器人可行性，还缺独立状态真值与运行判准。

P244 · BiAnt

Bidirectional Action Sequence Learning for Long-term Action Anticipation with Large Language Models

实作尚未确认 · 方法 / 综述 · 原作 · 独立页面

BiAnt的固定论文、Panasonic作者页与精确arXiv-ID查找均未提供可确认的方法repo。已核明forward为8段观测→20段预测，backward为训练时16→12；测试只做forward，以5组候选的最低edit distance评测。

> **版本与身份**
>
> 缓存「BiAnt」repository search共有74笔但只返回8笔，这8笔为无关帐号 / 项目，未声称已排除全部74笔。添加精确查找「"2508.00374" in:readme」HTTP200、total_count=0、incomplete_results=false。Panasonic作者页同篇条目只有arXiv link；arXiv页无method repo链接。结论为限定查证范围内尚未确认code，不是不存在证明；本轮小型读取 / 查找均200，未遇rate limit。
>
> Bidirectional Action Sequence Learning for Long-term Action Anticipation with Large Language Models；Yuji Sato（Panasonic Connect）、Yasunori Ishii（Panasonic Holdings）、Takayoshi Yamashita（Chubu University）。固定arXiv:2508.00374v1（2025-08-01）；arXiv comments及Panasonic的Ishii作者页均列MVA2025 / Best Poster Award。同页其他Panasonic code links、AntGPT基线及名称相似BiAnt搜索结果不代表本篇实作。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	Ego4D v2脱机人类第一人称日常活动，例子包含桌面纸板处理与洗衣。没有可交互的robot环境；automated driving / robotics为动机，不是添加已测试场景。
任务	以过去action segments中的辨识noun / verb标签预测未来verb–noun串行。训练同时用[forward]和[backward]提示；原来8个observed加20个future action形成28段窗口，反向训练取倒序16段作context、余12段作target。推论只输入8段已观测动作作forward预测，backward所用未来标签属训练数据，不能放进测试可见context。
题数与数据	§3–4将动作形式记为a=(n,v)，Fig.2的实际prompt文字则用verb noun；转换时须以字段身份而非tuple位置硬套。母库词汇为117 verbs / 521 nouns；每segment约240 frames是论文概述，不是固定片长，没有已核FPS / 时间边界或串行化key。visual encoder与action recognition在本方法LLM训练时冻结，具体骨干与reader未能核实，不以AntGPT目前程序补填。LLM为Llama2-7B、参数有效微调、8-bit量化；forward/backward loss权重均1。Table1是Ego4D v2 test；§4另明示task-token ablation使用官方validation中的160样本，未提供这160笔ID或完整test case数。附录S1的16是backward context长度，不是推论观测长度。

评估方式	§4报noun / verb / action三种ED，越低越好；K=5生成候选中选最低ED，Z=20为每条预测的action位置数，不是20秒。未核到距离算法的操作集合 / 范式分母、三种指针是否各自挑不同候选、未知标签 / 长短输出处理、候选采样参数与scorer。Table1的test分数与160-sample validation ablation及附录S1数字需分开，不能将160当整个benchmark题数，亦不能将best-of-5 ED改叫单次成功率。

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

可保留Ego4D v2依存关系、117/521词汇规模、8→20 forward / 16→12 backward设置、方向提示与K=5 ED协定，以及test和160样本ablation的区分。没有可直接重用的已核BiAnt loader或evaluator。

需要转换

source固定arXiv v1并记MVA2025；domain/environment归人类视频。task将training direction和inference direction分开；case须保留video/clip/segment ID、stopping boundary、verb/noun taxonomy、observed window、20步GT与5条候选。backward pairs仅连train split；evaluator保存ED种类及候选预算，native action index不任意转成秒或robot控制命令。

仍需补齐

官方BiAnt repo及commit、28段窗口与反向样本产生器、GT / 辨识label来源和split隔离、prompt/output parser、精确label-ID表、160笔ablation manifest与ED实作。AntGPT是文中采用的baseline，未确认其任何固定commit包含BiAnt改动。

P245 · ICVL

Vision and Intention Boost Large Language Model in Long-Term Action Anticipation

实作尚未确认 · 方法 / 综述 · 原作 · 独立页面

已核ICVL的原作方法、训练例子选择与两套评测协定；缓存查找及精确arXiv-ID查找均无repo，另查的候选作者帐号只有其他题名的项目。尚未确认官方ICVL实作；院校作者页的412访问限制另列，不能当成没有code的证明。

> **版本与身份**
>
> 核读范围为固定arXiv v1方法与实验，未创建新的会议 / 期刊版本假设。cached「ICVL egocentric」为0笔；一次「"2505.01713" in:readme」亦HTTP200、0笔、incomplete_results=false。另核Mia-YatingYu候选帐号返回的3笔公开repo metadata，题名均不匹配ICVL；帐号候选不构成作者为本篇公开code的证明。Congqi Cao院校页一次返回HTTP412 Precondition Failed，未读到正文且未重试；此为author-page access limitation，非rate limit或repository unavailable。结论限已查证来源，非宣称全球没有code。
>
> Vision and Intention Boost Large Language Model in Long-Term Action Anticipation；Congqi Cao、Lanshu Hu、Yating Yu、Yanning Zhang，Northwestern Polytechnical University。固定arXiv:2505.01713v1（2025-05-03）；ICVL在本篇指Intention-Conditioned Vision-Language，不是同缩写的其他数据库或实验室。AntGPT、PALM及候选帐号的STDD / Open-MeDe / Cue-R1均非本篇code。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	Ego4D人类第一人称日常环境，及EPIC-KITCHENS-55 / EGTEA Gaze+的厨房活动视频；都是脱机视频预测。意图是VLM从已观测影格推断的文字，并非添加人工意图真值集，也没有robot场景 / 控制界面。
任务	ICVL先辨识历史verb–noun labels，再从按时间顺序抽取的观测影格逐步推断intention；每次VLM输入包含先前生成的intention context，以最后结果作最终意图。ICAF以意图embedding为query、视觉embedding为key/value，再与文字prompt合并预测未来串行。Ego4D目标是noun / verb / action串行；EK-55与EGTEA明定为剩余视频中会出现的verb集合，不能把两者共用一个sequence evaluator。

题数与数据	§3：segment Si对应Ai=(vi,ni)；每段均匀取k影格形成visual embeddings，总数T=Nseg×k，意图另取Nfrm影格；k/Nfrm的数值、FPS、实际annotation key及split manifest未提供可核reader。历史action recognition用CLIP ViT-L/14与Transformer加两个MLP heads；ICAF的visual encoder为BLIP2-OPT-2.7B，意图VLM原文明写「LLaMA 3.2-9B」，text encoder及预测LLM为LLaMA 3-8B，精确模型ID / revision仍待设置档核实。例子只从training pool取observed labels与future labels；先对视觉及文字embedding的L2距离各自min–max范式，再用α加权，距离较小为较相似。α实际值、零距离范围 / ties处理未核到。§4.4虽说7例最佳，最终结果明确采3个例子。Ego4D的243小时 / 3472 clips、117 verbs / 521 nouns以及EK-55的125 / 352与EGTEA的19 / 51词汇量皆为原作母库描述，非ICVL已核case数。
评估方式	§4.1的Ego4D：Nseg=8、Z=20、K=5，对noun / verb / action分别报minimum Damerau–Levenshtein ED。完整距离实作、范式分母、三项是否各自取min及生成错误处理未核到。Ego4D只称standard splits，Table1未明列具体版本 / 评测split ID。EK-55与EGTEA则沿EGO-TOPO设置：观测首P%=25/50/75%，预测其余部分的verbs only，于validation报multi-label mAP All/Freq/Rare；未取得串行转verb分数、频率分组与AP聚合程序。3个ICL例子、5条生成候选、8个观测segments及20步预测是不同预算，均非题数。

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

可重用observed video→辨识labels / 生成intention→ICAF→LLM的数据流、training-only例子来源、距离融合规则、3-shot例子预算与原生Ego4D ED / EK-EGTEA verb-mAP规格。没有已核ICVL模型实作或evaluator可接线。

需要转换

source保留arXiv v1及母数据集依存；domain/environment限定脱机人类视频。task分有序verb–noun forecasting与无序verb presence。case应保存观测窗口、原生labels、生成意图、visual/text表示引用、3个training example IDs与5条预测；intention标为model_generated，训练例子的future labels与test GT隔离。evaluator分开保存ED与All/Freq/Rare mAP，母库clips、frames及词汇不展开成虚构案例。

仍需补齐

官方ICVL repo / commit、精确模型型号与版本、影格 / segment reader、数据 / 类别与split IDs、example pool及去重隔离规则、prompt/输出parser、ED与verb-mAP scorer。需确认原文LLaMA 3.2-9B型号、α及frame抽样值；不能借用AntGPT、PALM或STDD的程序视为ICVL已实作。

P246 · Decision-aware uncertainty

Decision-Aware Uncertainty Evaluation of Vision-Language Model-Based Early Action Anticipation for Human-Robot Interaction

实作尚未确认 · 主来源 · 原作 · 独立页面

已核固定v2全文的抽样、三种聚合与不确定性评测公式；原作、cached search、精确arXiv-ID查找及通信作者lab页仍未指向confirmed方法repo。可创建paper-level evaluator规格，但没有reader、聚合器或scorer可宣称已核读；HRI结果是confidence gating模拟，非实体部署。

> **版本与身份**
>
> cached「decision aware uncertainty egocentric」repository query为0；一次「"2603.10061" in:readme」亦HTTP200、0笔、incomplete_results=false。arXiv v2摘要与PDF没有本篇code链接；官方Mines lab的publications列表从2022开始，未列2026本篇，不能当作完整现时code库清单。下列来源只支持尚未确认官方repo，不支持repo绝对不存在；本轮小型补查均200，未遇429或rate-limited403，未运行API模型、聚合器或robot。
>
> Decision-Aware Uncertainty Evaluation of Vision-Language Model-Based Early Action Anticipation for Human-Robot Interaction；Zhaoda Du、Michael Bowman、Qiaojie Zheng、Xiaoli Zhang。固定arXiv:2603.10061v2（2026-03-12），不是2026-03-09的v1。Mines lab首页的Xiaoli Zhang及联系地址与论文对上。PDF第8页的OpenReview DWkJCSxKU5属引用的Generating with Confidence，不能借其code作本篇实作。

领域	餐饮与烹饪
环境	EGTEA Gaze+与EPIC-KITCHENS-100脱机人类第一人称视频，包含厨房活动；没有本篇可reset的robot环境。§VI明言interaction analysis使用模拟confidence-gated decision policy，尚非real robotic deployment。母数据库约10K及逾90K action segments不是本篇已核test case清单。
任务	虽摘要反复使用short-term action recognition / temporal prefix措辞，§IV-A明确指定观测action onset之前的图像、预测紧接的next action。因此保留pre-onset anticipation标记，不将本篇径改成已开始动作的early recognition。输出是同一未来动作的Top-K候选verb–noun labels及confidence，K是候选数，不是K步未来串行。Fig.1的after 1 s为示意；实际观测时窗、提前量、采样FPS与prefix切点并未由reader固定。

题数与数据	每input以Gemini 2.5 Flash-lite black-box API及相同prompt独立抽样M=5次，temperature=0.8，每次K=10。以a[i,k]记第i次第k顺位动作、p[i,k]为该动作的verbalized confidence；这些是论文符号，非已核JSON key。Consistency逐rank多数决，c[k]为该rank支持胜出label的次数/M；Confidence-weighted逐rank以p加权，c[k]=胜出label的confidence总和 / 所有runs于该rank的confidence总和。PairRank先取跨runs唯一label集合A，由顺位生成pairwise preferences，再以Bradley–Terry MLE拟合s(a)，softmax成P(a)并选Top-K。rank-wise confidence不必形成总和1的类别分布，须保留各方法的原生尺度。单次baseline只有1次抽样；M、K及唯一label数不能计成额外case。缺prompt、label范式 / parser、实际prediction文件、model revision、test ID与split reader。
评估方式	§III-C / IV-D：Top-1 accuracy与Recall@K按每input唯一GT动作比对。Top-1 ECE及Set-ECE均用[0,1]上的10个等宽bins；Set-ECE以z=1[GT在Top-K]为target、c_bar=(Σ_k c[k])/K为set confidence，再按bin样本占比加权绝对校准差。这是作者明定的平均confidence，不能暗换成Top-K概率总和。Selective policy只对首位label采c[1]≥τ；coverage分母为全部N个inputs，selective accuracy分母为通过门槛的inputs。Entropy另先将Top-K的c除以其总和，再算−Σp log p/log K；不得把此范式后的p倒灌到原生ECE / gating。§IV-A称官方train/test与test结果，但精确case IDs、GT取得 / 提交路径、匹配规则、bin边界与空bin / 零coverage处理均未核到。Fig.5的K=5、τ=0.39只是澄清范例，不是预设整批评测设置或安全保证。

▼ **原作数字：保留论文的单位与页码**

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **5** stochastic model calls per input · 原文页 5

依这个顺序读

未确认可核读的实作；下方保留已查过的原作、项目页与检索依据。

怎么接入我们的benchmark

可重用

可保留pre-onset next-action目标、M=5 / K=10 / temperature0.8、三种aggregation公式、10-bin ECE、作者定义的Set-ECE、coverage/selective-accuracy分母及entropy诊断。尚无可直接重用的已核程序。

需要转换

source固定v2与母数据集版本关系；domain/environment记人类视频观测，HRI是评测动机。每case保留onset/observation boundary、GT verb/noun、每run每rank的raw label/confidence及聚合结果；evaluator分correctness、calibration、selective utility与confidence geometry，明记confidence构造及entropy专用范式。保留abstain / retained case集合、model/prompt与采样预算，不创建跨方法通用success score。

仍需补齐

作者可确认的repo / commit、精确观测与test manifest、API model/prompt设置、动作同义词 / label-ID parser、重复label及rank ties规则、Bradley–Terry拟合与正则化、零confidence / 零分母 / K=1 entropy边界，以及完整ECE与gating实作。实体HRI控制、clarification真值及安全验证不在本轮已取得来源内。

P247 · EgoSpanLift

Gaze Beyond the Frame: Forecasting Egocentric 3D Visual Span

文件 / 网站 · 主来源 · 原作 · 独立页面

Gaze Beyond the Frame 的方法名为 EgoSpanLift，数据名为 FoVS-Aria / FoVS-EgoExo。官方 repo 目前只有发布预告，不能把论文的 364.6K samples 说成本案已取得数据。已从原文核对四层视觉区域、两套父数据及时间窗。

> **版本与身份**
>
> 官方 README 的题名是 Gaze Beyond the Frame；EgoSpanLift 是方法别名而非另一独立 benchmark。论文、数据子集、程序预告分开。

领域	居家整理与清洁、餐饮与烹饪、医疗与手术支持、交通移动与车辆维修、休闲与运动、音乐与表演、穿戴交互与动作界面
环境	FoVS-Aria 衍生自 Aria Everyday Activities（143 recordings、7.3 小时原始数据）；FoVS-EgoExo 衍生自 EgoExo4D 的 cooking / music / health / repair / bouldering 五类活动。物理 location、recording、活动用途与 voxel grid 各自不同单位。
任务	一个 3D visual-span forecasting 任务、四个输出层：foveal 2°、central 8°、peripheral 30°、head orientation/FoV 约 55°。GT 是未来区间内看过区域的联集，不保证逐帧 gaze 次序；四层不是四批独立数据。
题数与数据	论文约 364.6K samples：FoVS-Aria 约 23.2K、FoVS-EgoExo 约 341.4K。Aria 2 秒历史→2 秒未来、stride 1 秒、16^3 grid / 3.2 m cube / 20 cm cell，test 使用 location 4；EgoExo 预设预测 4 秒。原文 rounded split numbers 仅作约数保存，不自行调整成精确整数。
评估方式	四层分别计 3D IoU / F1，另有 precision / recall 与 foveal metric distance。semi-dense SLAM 点与 gaze 产生区域，foveal 缺失不能自动当全负例；地图可见时间、空 grid、threshold、聚合分母仍需未发布 evaluator 核对。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **2,100** FoVS-Aria test windows（约数） · 原文页 7
- **37,000** FoVS-EgoExo test windows（约数） · 原文页 8

- **364,600** combined forecast windows（约数） · 原文页 1, 7, 8

依这个顺序读

1. `README.md` ↗
   GitHub · HS-YN/GazeBeyondFrame · 71e26f0b64

   官方题名与 NeurIPS 2025 身分相符；明示 Code and details will be released soon。

   L1–4

怎么接入我们的benchmark

可重用

重用论文清楚定义的 gaze cone / voxel / future union 任务与父数据关系，可纳入感知 / 预测任务目录。

需要转换

case 应保留 recording、location、observation_end、future window、SLAM map 可用范围、gaze 校正、四层角度与 voxel 原点 / 尺寸；不把 gaze prediction 当 robot navigation success。

仍需补齐

公开 repo 没有 loader、标注 manifest 或 evaluator；本次未取得产生后样本、未运行方法，故不能列为可立即评测。

P248 · HOIMotion

HOIMotion: Forecasting Human Motion During Human-Object Interactions Using Egocentric 3D Object Bounding Boxes

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

HOIMotion 以过去人体姿态和头部视角的 3D 对象框预测人体动作，重用 ADT / MoGaze。已核两套 loader、跨参与者设置与 MPJPE；对象框顶点、图节点和人物关节都不应计为任务数。

> **版本与身份**
>
> 官方来源固定 commit；ADT preprocessing 明载数据版本 1.1.0。default script 的 train→eval 不是唯读测试命令，没有在本机运行。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	Aria Digital Twin 与 MoGaze 的人类对象交互场景；ADT 原生 work / decoration / meal 三活动类，MoGaze pick / place 两类，不能把五个标签当五个新独立物理环境。
任务	单一人体 3D motion forecasting 任务，按用途与 holdout participant 分组。21 joints，10 个过去 frame→30 个未来 frame（评分假设 30 Hz）；两个 dynamic / 两个 static objects，各 bbox 八个顶点作模型输入。
题数与数据	原生 .npy 档依 sequence 提供 pose xyz、head、dynamicbbx、staticbbx；loader 各自排序后用相同 list index 配对。每个连续 40-frame 窗口可重叠，train_sample_rate=2 只抽窗口，不把视频 FPS 降半。MoGaze 测试 p1 / p2 / p4 / p5 / p6 / p7 六个 holdouts，每人可有多个 session。
评估方式	MPJPE=未来各关节 xyz 欧氏距离的平均，先 batch 平均×batch_size 累加再除总 sample；输出 mm、每未来 timestamp / joint 另列。zero-velocity baseline 重复末个观测 pose。velocity loss 仅训练用，没有加到报告 MPJPE。ADT training 将 test 目录作 validation 选 best checkpoint；MoGaze 也以 holdout participant 作 validation，完整模型选择条件应保留。

依这个顺序读

1. `README.md` ↗

   GitHub · CraneHzm/HOIMotion · d2f4322c70

   确认两个父数据集、训练后测试的 shell 工作方式与人类研究范围。

   L1–53

---

2. `adt_processing/README.md` ↗

   GitHub · CraneHzm/HOIMotion · d2f4322c70

   固定 ADT / Project Aria Tools 均为 1.1.0 的数据前处理依赖。

   L1–13

---

3. `utils/adt_dataset.py` ↗

   GitHub · CraneHzm/HOIMotion · d2f4322c70

   核对 work / decoration / meal、train/test 目录、对应数组及重叠切窗。

   L6–119

---

4. `utils/mogaze_dataset.py` ↗

   GitHub · CraneHzm/HOIMotion · d2f4322c70

   核对 pick / place、participant split、native 文件名与切窗。

   L6–113

---

5. `utils/opt.py` ↗

   GitHub · CraneHzm/HOIMotion · d2f4322c70

   固定 21 joints、10 history / 30 future、object counts 与采样率。

   L15–55

---

6. `train_adt.sh` ↗

   GitHub · CraneHzm/HOIMotion · d2f4322c70

   区分 all 与三个 action 子集；脚本先训练再评分。

   L1–9

---

7. `train_mogaze_p1.sh` ↗

   GitHub · CraneHzm/HOIMotion · d2f4322c70

   确认 p1 holdout 与 pick/place 分组不是额外独立数据。

   L1–7

---

8. `main_adt_pose_forecasting.py` ↗

   GitHub · CraneHzm/HOIMotion · d2f4322c70

   确认 test folder 用于 validation 选 checkpoint、只用过去对象信息、MPJPE 分母。

   L17–97 · L257–373

---

9. `main_mogaze_pose_forecasting.py` ↗

   GitHub · CraneHzm/HOIMotion · d2f4322c70

   查核六个 participant holdout 的组成与相同 MPJPE 汇总。

   L16–81 · L295–411

怎么接入我们的benchmark

可重用

可重用两父数据的 actor/session、动作标签、21-joint pose、3D bbox 与原生 MPJPE；用户研究 N=20 是独立感知评价，不并入样本题数。

需要转换

标准 case 以 parent sequence / window 起点识别，明定 30 Hz、21 joints / 米、过去 bbox 可见性与 split role；文件配对改用 sequence key 并验证一致。添加真正 untouched test split 时另列为扩充协定。

仍需补齐

本次未下载 ADT / MoGaze 原始素材、未运行训练。各用途的精确窗口数需由完整文件 manifest 重算；原始数据及工具授权 / 版本各自保留。

P249 · EgoCast

EgoCast: Forecasting Egocentric Human Pose in the Wild

内核内容已核读 · 方法 / 综述 · 原作 · 独立页面

EgoCast 的预设分支与 forecasting 分支是两个不同版本。已追到预测分支的 loader→test_fcast→report；目前 pred_input=True 路径会改写回传 gt，不能直接把这个快照视为可重现论文 ground-truth 评测。

> **版本与身份**
>
> default commit 1db0c6e 与 forecasting commit 6ba9eec7 各自锁定。README 的视频下载范例重复 annotation 命令；需依父数据工具取得真正图像。此处只报静态可查的路径差异，不声称论文结果有误。

领域	方法 / 综述参考，未另作来源用途归纳。
环境	EgoExo4D 与 Aria Digital Twin 的人体姿态预测，没有新机器人环境。已深入核读的 forecast 路径为 EgoExo4D；ADT loader 虽存在，本次未声称完整核对其 forecast evaluator。
任务	先估当前全身姿态，再由历史头部轨迹与估计姿态预测未来。论文比较 0.5 / 1 / 2 / 3 / 4 / 5 秒 horizons；default repo 的姿态估计、forecast branch 的预测与 oracle-GT pose input 必须分条件。
题数与数据	EgoExo4D take_uid、camera_pose、body annotation、17-joint skeleton、visible flags、time index、cached prediction route。forecast train config window_size=80、future_frames=15，test config 为 30；文件名与 dataroot 中的 fps 字样不足以证明实际 sampling frequency。test loader 排除 take_name 含 bouldering，且为 prediction input 使用外部 camera 档绝对路径。
评估方式	test_fcast 滑窗产生多个预测，skeletal MPJPE 乘 visibility 后除 (error!=0) 计数，真正零误差也被排除；速度沿相邻窗口轴相减并乘 10，aria 分支乘 30，不能直接视为同一 future-time 速度。外层每 take 等权平均，跳过 enumerated index 17/62。更关键的是 pred_input=True 时 skeletons_window 被 cached prediction 覆盖，且同变量作输入及回传 gt，feed_data→test_fcast 沿用；需修复 / 核实独立 GT 才能发布结果。论文的跨 horizon AUC 不在本次读到的 caller 中实作。

依这个顺序读

1. `README.md` ↗

   GitHub · BCV-Uniandes/EgoCast · 1db0c6e185

   确认父数据、current-frame estimation 与 forecasting 分支的官方指示。

   L1–137

---

2. `options/train_egocast_forecasting.json` ↗

   GitHub · BCV-Uniandes/EgoCast · 6ba9eec74f

   固定 80-frame history / 15 future 与 pred_input 设置。

   L1–98

---

3. `options/test_egocast_forecasting.json` ↗

   GitHub · BCV-Uniandes/EgoCast · 6ba9eec74f

   对照 test future_frames=30、来源路径、checkpoint 与 train 设置差异。

   L1–96

---

4. `data/dataset_egoexo.py` ↗

   GitHub · BCV-Uniandes/EgoCast · 6ba9eec74f

   确认 take 筛选、17 joints、cached prediction 加载及 gt 变量沿用。

   L361–462 · L568–662

---

5. `models/model_egocast.py` ↗

   GitHub · BCV-Uniandes/EgoCast · 6ba9eec74f

   追到 sample 的 gt、滑窗 forecast、zero-error 分母及速度轴。

   L182–198 · L406–484

---

6. `main_train_egocast.py` ↗

   GitHub · BCV-Uniandes/EgoCast · 6ba9eec74f

   核对跳过 index 17/62、每 take 等权平均、cm 输出与实际 test caller。

   L234–315

怎么接入我们的benchmark

可重用

可重用 current-estimation→forecast 的任务分解、take / frame 对照、17-joint schema；固定两个 branch commits 与父数据版本。

需要转换

以 task 记录 forecasting 目标，case 指明 estimated-pose 或 GT-pose 条件、history / horizon / sampling、visibility 和独立 GT 资产。将 default / forecast revision 分开；修订 gt、mask、velocity 或 index exclusions 时添加 evaluator version 与原生对照。

仍需补齐

未下载完整 EgoExo / ADT、cached predictions 或 checkpoint，未运行模型。当前源代码有上述评分链缺口与本机路径依赖，尚不能认为可直接重现 paper horizon curve。

P250 · EgoMAN

Flowing from Reasoning to Motion: Learning 3D Hand Trajectory Prediction from Egocentric Human Interaction Videos

内核内容已核读 · 主来源 · 原作 · 独立页面

EgoMAN 将人类 6DoF 手部轨迹和推理 QA 配对，适合加入语意→预测的共同目录；官方明确表示 processed dataset 与 model weights 不发布。已核数据创建、loader、trajectory / waypoint 评分链，不能把 repo 可读当成 219K 轨迹或 3M QA 已可下载评测。

> **版本与身份**
>
> 固定官方 commit；README 提到新 DINOv3 / Qwen3-VL 等依赖，不能假设与 paper checkpoints 完全相同。raw metrics 的 closest_pred 选 minADE，summary 则用 ADE+ROT 系数，两种 best index 必须分清；已有 processed.pkl 时会跳过重算，需用来源 / evaluator hash 隔离。

领域	居家整理与清洁、餐饮与烹饪、交通移动与车辆维修、穿戴交互与动作界面
环境	人体交互视频的 EgoExo4D / Nymeria 衍生数据，HOT3D 作 OOD。camera-relative 手腕轨迹与人体视角推理不是机器人 actuator 命令；需保留原数据 take/sequence 关系。
任务	语意 / 空间 / 时间 / 阶段 QA 与 3D 双手 6DoF trajectory prediction。approach/contact/end stage、任务文字和两种输出共用 interaction clip；不把 3M QA 与 219K 轨迹相加成独立情境。
题数与数据	README 报告 219K 轨迹 / 3M structured QA，processed dataset 及权重不公开。原生 meters、10 Hz、position+xyzw；模型以每手 position3+rotation6 的 18D 表达、past 5 frames，未来 tensor 最多 50 slots、−1000 sentinel。视频 / tracking timestamp ns/us、reference camera transform、stage annotation 及自动 QA provenance 必须同存。品质筛选要求接触 / 结束可见且非平凡动作，会影响难度分布。
评估方式	trajectory：ADE/FDE 公尺、DTW按 warping path length 范式、ROT度。GT有效 mask 为每 frame 任一座标非−1000，未逐手遮罩；空 GT 回零值且少 best_idx 栏，正式入口需拒收此情况。summary 的 best-of-K 选 ADE+0.001×ROT 最小同一条候选，再报四项，与单纯 minADE / 各指针各取最小不同。waypoint 取各方法 key 交集，>2 点以 GT 选最佳成对候选；--shift 仅对非 EgoMAN/GT 方法向 GT / 最近轨迹点移最多 0.06m，各栏忽略 NaN 后平均。这是带 oracle / 容忍补偿的协定，不能当实际物理接触成功率。

▼ 原作数字：保留论文的单位与页码

下列为既有原文审阅摘录；GitHub快照和本库取得范围另见上文，不互相代替。

- **2,844** EgoMAN-Unseen trajectory cases · 原文页 4
- **990** HOT3D-OOD trajectory cases · 原文页 4
- **3,000,000** structured QA supervision（概要约数） · 原文页 1, 2

依这个顺序读

1. `README.md` ↗
   GitHub · facebookresearch/egoman · 20f19ccf31

   核对 219K / 3M、未发布数据与权重、座标 / 频率、QA 与评分入口。

   `L1–140 · L159–244 · L319–416`

---

2. `dataset/scripts/step4_6dof_traj_process.py` ↗
   GitHub · facebookresearch/egoman · 20f19ccf31

   追踪 ns→us 最近帧、10 Hz、reference-camera 转换与输出。

   `L106–140 · L626–651 · L786–855 · L866–885`

---

3. `dataset/scripts/step6_traj_quality_filter_rules.py` ↗
   GitHub · facebookresearch/egoman · 20f19ccf31

   读 contact/end 可见性、位移 / 旋转与 grasp/pick approach 筛选规则。

   `L137–258`

---

4. `dataset/dataloaders/joint_finetune_dataset.py` ↗
   GitHub · facebookresearch/egoman · 20f19ccf31

   确认 value→past/future tensor、xyzw→rot6d、sentinel 与坏样本替换。

   `L489–566 · L638–715`

---

5. `model/tools/egomanbench_metrics.py` ↗
   GitHub · facebookresearch/egoman · 20f19ccf31

   查核 5 past frame 移除、HOT3D / unseen routing、K=1/5/10 与结果缓存。

   `L21–164`

---

6. `utils/eval_utils/metrics.py` ↗
   GitHub · facebookresearch/egoman · 20f19ccf31

   核对 ADE / FDE / DTW / ROT、frame mask、空标注与最优候选。

   L14–152 · L185–352 · L435–499

---

7. `utils/eval_utils/metrics_summary.py` ↗
   GitHub · facebookresearch/egoman · 20f19ccf31

   追踪 summary 使用 ADE+0.001×ROT 选同一候选、每 sample 平均与 K cap。

   L279–455 · L463–555 · L636–676

---

8. `model/tools/waypoint_metrics.py` ↗
   GitHub · facebookresearch/egoman · 20f19ccf31

   核对 GT-oracle candidate pair、最多 6 cm shift、method交集与有限值分母。

   L34–53 · L106–138 · L283–340 · L388–423 · L456–474

怎么接入我们的benchmark

可重用

可重用 trajectory / QA / stage 关联结构、来源追踪、创建标注的方法和四种几何误差定义；code 与 data 授权及发布范围各自保存。

需要转换

case 固定 parent clip、标注者 / 模型与生成版本、起讫与合法过去输入、meters / xyzw / rot6d、validity mask。将 raw single prediction、oracle best-of-K、shifted waypoint 分开报表；所有 expected cases 的遗漏 / 失败另报 coverage。评测 loader 禁止训练式坏样本换下一笔。

仍需补齐

未发布 processed dataset / 模型权重，所以本案未取得这 219K / 3M 样本，也未跑推论或 GPT 标注。QA correctness evaluator 与完整基线资产不在本次 trajectory 核读范围；新任务需要独立取得合法数据并完成标注 / 评分验证。