RESEARCH ATLAS

Robot-use Benchmark完整整理

先看整體數字、用途與研究分佈、共同結構及例項，再查250篇來源的資料、判分、版本與證據。

快照 2026-10-11：250/250篇已處理。183份主來源和67篇方法 / 綜述分開標明。

GitHub證據：279個倉庫、286個固定版本；另有1個外部資料庫。合計1506個已核驗檔案，其中2個來自外部資料庫。核讀限所列片段；沒有執行上游模型或機器人。

先看全庫：哪些數字已確認

用途分類 source-review-0.11；來源ID清單 2026-10-02；GitHub核讀 2026-10-11。三份快照分開標明，舊12領域與早期任務配額只作歷史資料。

專案	目前確認實數	實數範圍	本版規劃口徑
領域	**21** 已歸納用途類別	183/183份來源均有歸類；原22份已補齊。每個用途有任務 / 場景理由；同一來源可涵蓋多用途。	按任務、物件與目標歸納，再逐任務建立聯集；新用途可擴充分類。
環境	**284** 已取得命名場景條目	64個已讀來源有某種環境量；284條僅是已取ID子集，未完成跨庫幾何去重。	整理各來源scene/layout/location及重用關係後，計全庫聯集；不再先配1,000。
任務	**2,096** 已取得robot任務條目	另有7資訊題型、263人類活動。原作task/skill/instruction的差異已逐篇記錄，尚未全部正規化去重。	先取原作任務聯集，再加有差異證據的新目標 / 規則；不再先配5,000。
題數	**114,288** 已取得題目定義元資料	111,652 PARTNR train＋1,000 val＋1,636 OpenEQA；含訓練資料，素材未全齊，不是114,288道已整合測試題。	依task、split、合法輸入及判分建立case manifest後定量；原作量、已取得量、可評量分列。
評估方式	**4** 共同判分大類	183份來源均有判分方式與原文依據；具體metrics及評分器仍各自保留，尚未全數掛接。	答案、誤差、狀態 / 過程、人工 / 模型評審各報；不以4類代表4個完成的通用評分器。

這是固定250篇書目的來源查核。全庫去重後的環境、語義任務和完整可執行題數仍待建立；新增規則要有父任務、差異與判分，不能以排列數當完成量。

用途與文獻分佈

用途回答做什麼生活 / 工作；研究型別回答論文測什麼。用途可多選，文獻主類一篇一類；來源共享影片或資產時仍需去重。

用途	來源數 / 183	來源支援
居家整理與清潔	104	P001、P003、P007、P009、P010、P011、P012、P013、P016、P017、P018、P024、P026、P027、P028、P029、P030、P031、P032、P033、P038、P039、P040、P042、P062、P063、P064、P065、P066、P067、P068、P069、P070、P071、P072、P073、P074、P075、P076、P080、P081、P082、P083、P084、P087、P093、P094、P095、P096、P097、P098、P099、P100、P101、P104、P105、P106、P107、P108、P109、P111、P114、P116、P119、P123、P124、P129、P142、P143、P144、P145、P164、P165、P166、P169、P178、P180、P181、P198、P199、P201、P202、P203、P204、P205、P206、P207、P212、P214、P034、P037、P051、P054、P110、P125、P126、P127、P120、P132、P150、P222、P228、P247、P250
餐飲與烹飪	70	P003、P004、P005、P006、P008、P009、P010、P011、P012、P013、P014、P018、P021、P022、P023、P024、P026、P027、P028、P029、P030、P031、P032、P033、P039、P063、P070、P071、P072、P073、P096、P097、P098、P100、P101、P105、P106、P108、P109、P116、P141、P143、P145、P152、P164、P166、P182、P198、P202、P204、P207、P212、P214、P002、P053、P057、P060、P125、P126、P127、P132、P217、P222、P228、P229、P233、P241、P246、P247、P250
衣物與洗護	25	P045、P082、P083、P085、P086、P087、P092、P093、P100、P119、P151、P152、P167、P181、P185、P196、P088、P089、P090、P091、P127、P186、P188、P191、P120
辦公與教育	18	P018、P038、P039、P042、P072、P094、P095、P100、P101、P141、P144、P145、P202、P002、P054、P126、P120、P150
工藝與修繕	17	P003、P004、P013、P023、P028、P029、P031、P041、P063、P073、P106、P112、P141、P002、P034、P054、P150
裝配與生產作業	30	P015、P016、P023、P063、P067、P068、P069、P076、P079、P082、P083、P106、P112、P115、P119、P129、P141、P170、P171、P177、P179、P183、P184、P207、P208、P210、P211、P120、P150、P225
包裝、倉儲與物流	8	P076、P084、P086、P103、P164、P170、P200、P077

用途	來源數 / 183	來源支援
零售與購物	9	P013、P031、P100、P164、P200、P202、P204、P120、P150
實驗室操作	12	P021、P031、P072、P112、P164、P172、P173、P174、P175、P176、P192、P120
醫療與手術支援	5	P041、P113、P164、P060、P247
個人照護	8	P003、P014、P031、P087、P103、P148、P167、P002
交通移動與車輛維修	12	P003、P004、P013、P014、P031、P202、P002、P060、P150、P226、P247、P250
農業與園藝	7	P013、P023、P028、P031、P100、P002、P213
休閒與運動	16	P003、P013、P014、P019、P020、P031、P033、P041、P063、P072、P106、P202、P002、P054、P229、P247
公共場館與服務	3	P102、P103、P209
寵物照護與動物活動	4	P025、P041、P205、P002
音樂與表演	3	P014、P229、P247
社交與溝通	7	P013、P019、P020、P032、P033、P061、P168
通用物件與機動作業	31	P062、P063、P065、P067、P068、P069、P075、P076、P081、P082、P083、P084、P106、P107、P115、P123、P129、P151、P152、P169、P171、P177、P182、P212、P214、P077、P125、P128、P193、P222、P228
協助、交接與陪伴	17	P058、P061、P073、P097、P103、P113、P141、P142、P143、P145、P146、P147、P148、P168、P208、P209、P210
穿戴互動與動作介面	25	P013、P014、P018、P019、P020、P058、P119、P197、P198、P199、P051、P053、P057、P060、P216、P222、P224、P225、P226、P228、P229、P230、P233、P247、P250

研究型別	主來源	全部書目
人類影片與動作資料	32	32
理解、推理與規劃	21	25
未來動作 / 互動預測	18	48
一般操作 benchmark	31	32
布料 / 柔性物操作	21	26
導航與家務執行	11	11
穩健性、失敗與評測品質	19	19
人類觀測到機器人轉移	7	11
機器人資料與通用策略	6	16
輔助與協作	11	11
世界模型與預測表示	5	9
Survey / 評測方法	1	10

評估方式	來源數 / 183（可多選）	原生判分
標準答案比對	64	accuracy、precision / recall / F1、top-k等；各自保留分母。
數值誤差與相似度	103	距離 / 角度 / 時間誤差、ADE / FDE、IoU、生成品質等；不同量綱不混平均。
環境狀態與過程檢查	95	成功率、合規完成率、違反率、完成時間與成本；按任務保留條件。
人工或模型評審	21	rubric分數、偏好率或排名；人工與模型裁判、版本和一致性另記。

四類評估方式不是四個已完成的通用評分器，也不應把不同單位的誤差混成單一分數。

從Survey到可投稿Benchmark

本次交付完成逐篇來源核讀。論文的規模與廣度主張仍需靠共同任務聯集、真正新增的規則及同協定模型結果驗證。

1. **M1　來源閱讀與共同比較**

   本版250篇篩查、183份逐篇審閱、原文頁碼/單位/重用紀錄和五欄比較表。

   驗收：所有原143來源有記錄，補入40來源；可重算分類分佈，未知與衝突公開。

   本輪已完成，限現有書目範圍

2. **M2　逐ID整理環境與任務聯集**

   取得各來源任務清單，保留source ID、version、split、資產引用；標示equivalent/derived/unresolved。

   驗收：來源覆蓋率按183來源計；每筆任務有父來源和判分定義，不能僅比名稱。

   已有部分清單；全庫去重尚未完成

3. **M3　擴充任務與規則**

   針對已核來源新增必要過程、精度、安全、恢復、記憶與協作規則；逐條記錄相對父任務新增了什麼。

   驗收：新增語義目標與新增測例條件分開計數；每個合法變體有可解性與evaluator驗證。

   設計可據來源展開；未承諾固定題數

4. **M4　建立可執行評測與論文證據**

   分問答、預測、規劃、控制輸出報分；固定觀測/動作/時間/抽樣預算，做來源與任務群聚切分。

   驗收：公開case manifest與判分器，報subset實測及不確定性；以去重後覆蓋和新增任務證明規模優勢。

   全庫尚未完成；既有小型實驗為工程附錄

共同結構、格式與例項



箭頭表示整理與驗證流程。進共同目錄、已取得素材、已能評測各有自己的狀態；不把上一層數量直接算成下一層完成量。

結構規格草案 0.2 · 2026-10-11。0.2是介面規格版本，不是題庫發布版號。這份檔案根據逐篇核讀整理共同介面；每篇的倉庫、版本與程式證據另見 GitHub 核讀表。原生任務索引、已取得素材和可評測題目仍分項計數。

先看最簡單的結構

我們只維護三層：**原作快照 → 共同目錄 → 可評測子集**。首頁仍只回答領域、環境、任務、題數、評估方式。

層	儲存什麼	何時算完成
原作快照	論文、GitHub commit、子模組、任務 / 資料 / 判分原檔引用與hash	身份和版本可回查；下載與閱讀各有紀錄
共同目錄	來源、用途、環境、任務、題目、判分器及它們的關係	欄位、ID、引用和原生單位通過檢查；語義未決保持未決
可評測子集	完整輸入、初態、可見資訊、動作 / 輸出、預算與判分	素材、協定、判分正反例、切分及執行範圍逐項驗證

一本論文可以有多個倉庫，同一個倉庫也可以支援多篇論文。原作、倉庫、版本、原生task、case和trial各有自己的ID，不能共用一個「資料量」數字。

用兩個例子走完

步驟	CALVIN：操作機器人	OpenEQA：看環境後回答
固定原作	CALVIN主倉庫和它指定的calvin_env子模組	OpenEQA固定版本與open-eqa-v0.json
認識環境	A–D四個原生場景；D_eval沿用D的layout	episode_history是觀測歷史引用，不能直接當作可操作環境
認識任務	34個原作子任務定義，例如開抽屜	7個資訊題型，例如物件位置；不是7個機器人工作
找到一題	需繫結實際初態、指令鏈、觀測與動作協定	一個question_id連到問題、歷史輸入、答案與判分協定
真正判分	由具體goal checker與整條指令鏈的完成結果判分	依原作開放式回答評審；裁判、prompt與版本一併固定
目前可計什麼	已取得34條任務定義；不能把文中1,000條鏈當成本案已取得	已取得1,636條問題 / 答案元資料；完整歷史影像另行取得
進入共同格式	source→environment→task→case→evaluator，保留原生動作尺度	source→history resource→information task→case→evaluator，保留影像可見範圍

兩個例子共用身份、來源和評測紀錄格式，但輸入、輸出與判分各自儲存。對它們新增「指令被打斷後恢復」或「不得讀取某段歷史」時，要寫出父任務、變更規則、答案如何產生及新增的評測版本。

目錄怎麼放

以下為目標目錄結構；現有catalog importer保留其0.1版本，不以這張示意冒充全部adapter已實作。

```
benchmark/
  sources/                  每份來源一張卡：身份、版本、原作入口
  catalog/
    domains.jsonl           用途分類與定義
    environments.jsonl      有身份的場景 / layout
    tasks.jsonl             原生任務與共同規格、規則版本
    cases.jsonl             一題的輸入 / 初態 / split / 判分引用
    evaluators.jsonl        原生與共同判分契約
```

```
adapters/          按來源或資料形態讀取、轉換、驗證
protocols/         模型可見資訊、預算、輸出及切分規則
releases/          固定的catalog / evaluation發布清單
```

影片、HDF5、NPZ、3D資產與大型模型存放在資料儲存區。目錄儲存引用、內容hash和依賴關係；網站直接從同一份目錄產生表格和下載。

一篇 GitHub 怎麼讀

依這個順序走一遍，每一步留實際檔名、commit、行號和閱讀結論。

順序	讀什麼	要回答的問題
1. 身份與版本	論文 / 作者頁 → README → tag / submodule	這是否該篇的作者程式？是原作版、移植版、新版或只是網站？
2. 任務入口	registry、task class、goal DSL、題型或活動表	原作的一個task究竟是什麼？目標、引數、變體怎麼分？
3. 資料入口	manifest、dataset reader、紀錄器、split設定	一筆樣本包含什麼？時間、單位、座標、label和來源如何對齊？
4. 真正判分	執行入口 → wrapper → 具體checker / metric	程式實際如何判分？分母、失敗排除、候選預算與聚合是什麼？
5. 整理與對映	來源卡、欄位對照與驗證紀錄	哪些原樣儲存、哪些要轉換、哪些仍不足以形成合法評測？

README中的指令只是入口。要沿實際呼叫鏈讀到資料與判分。例如LIBERO的基底`_check_success`是佔位，真正goal檢查在具體problem子類；只讀基底會得到錯誤結論。

每份來源只填一張卡

欄位	最少要有什麼
來源身份	paper ID、repo及角色、官方性依據、固定版本、讀過的檔案

欄位	最少要有什麼
領域	原作任務 / 用途支援的分類；逐任務對映與來源層級標籤分開
環境	原生scene / workspace / asset或生成規則；影片觀測脈絡另存
任務	native ID、原生單位、目標 / 規則 / 必要過程、引數或變體
題數與資料	原生split、case/sample單位、輸入 / 標註引用、已取得範圍
評估方式	實際checker / metric檔案、版本、所需證據、聚合與預算
標準化結論	可復用、需要轉換、仍缺少什麼；目前是目錄或可評測

欄位不明時用null和原因。未找到官方GitHub不表示原作沒有資料；只有README或網站的倉庫，也不表示評測程式已公開。

統一哪些東西

統一身份、欄位意思、資料關係及評測介面。 原生表示保留，轉換由adapter完成。

共同專案	必須保留的原作細節
身份	source、repo、commit、native ID、split、父資料與衍生關係
時間	原片秒數、frame index、特徵時間格、控制頻率、預測截止點與horizon
空間	座標frame、世界 / 相機方向、quaternion順序、單位與變換引數
動作	embodiment、controller、位置 / 速度 / 力矩 / 增量、維數、縮放與夾爪約定
觀測與答案	資料裡有什麼，以及此評測允許模型看什麼；參考狀態 / 未來 / 答案分開
成功與誤差	原生predicate / metric、閾值、時間持續、invalid規則及分母
發布	schema / adapter / evaluator / protocol版本與全部依賴的固定清單

相同形狀的tensor可能有不同物理意思；不同形狀也可以走相同的adapter介面。控制、問答、定位、預測與世界模型保留各自輸出型別與native metric。

從已讀程式看到的具體原因

原作	已核對的程式事實	我們要怎麼處理
Meta-World現行版	基礎obs由當前18維、前一觀測18維、goal3維組成；部分說明仍寫9D	由固定程式與資料驗證schema，記下stack與goal可見性，不只抄文字說明
Meta-World vs CALVIN	Meta-World原生4維控制另乘action_scale；CALVIN有兩種7維動作，relative另有位置 / 角度縮放	儲存原生ActionSpec及轉換，不強制把所有資料視為同一個7維向量
CALVIN	主倉庫pin的calvin_env不是該倉庫的目前main；scene_obs存在資料裡但原作政策不使用	固定依賴閉合版本，並把儲存欄位和政策可見欄位分開
ManiSkill1/2/3	原作2021在Legacy，ManiSkill2在v0.5.3，現行main為ManiSkill3	不用同一個main代表三篇；版本與對映各自有證據
ManiSkill2	recorder儲存T+1個觀測與T個transition；depth以uint16並乘2^10寫入	儲存時間對齊和深度尺度；dtype本身不足以解釋資料
ManiSkill3	training loader裁去最後obs；device分支另對success/fail賦值為terminated/truncated	原始儲存和training view分開；保留原label，匯入adapter需做回讀一致性檢查
RLBench	condition可以表示關節、抓握、偵測、順序或OR；variation還會換目標部位	完成條件與必要過程一起儲存，不從任務名稱推定
CrossTask	18 primary與65 related標註資格不同；時間轉到1Hz特徵格會floor/ceil	資料子集、時間格與原始秒數分開；沒有GT的活動不自動變成可評題
LIBERO-Plus（P105）	分類檔有10,030個擾動條目，許多共用底層任務與初態	儲存base task→variant→case關係；原生level與共同難度分開

原作	已核對的程式事實	我們要怎麼處理
EgoDex（P119）	ARKit世界座標可能每episode不同；best-of-K只計指定位置點	連結episode座標與原片；儲存K、padding、所評joint及被略過的旋轉分量
WatchAct（P123）	Plan SR、完整終態一致與LIBERO物理成功不同；progress還可能扣初態	同題可建不同protocol，分別保留原metric與新增規則
Open X（P125）	示例可以把tensor形狀對齊，原action卻可能是位置、速度或增量	容器/schema和物理ActionSpec分開驗證，保留每個子資料來源
AHA（P110）	名稱為F1的Yes/No指令碼實際計算accuracy；模型裁判另有無效輸出分母	記下原名稱與真正公式，儲存invalid數與預期題目全集
ALOHA/ACT（P130）	兩個sim有具體reward規則；real介面的0 reward只是佔位	原實機評分需另有rubric或checker，不能直接沿用通用rollout日誌欄位
EggHand / EgoH4（P227 / P230）	相同父影片被切成不同視窗；target是否含當前幀、缺失關節mask與MPJPE對齊不同	父take與時間交集去重，逐協定固定歷史 / 未來與有效分母
SFHand（P228）	誤差只評匹配、IoU及手別正確的子集合；串流仍取得新影像	同時報評分覆蓋率與條件誤差，標明online observation
OCT / Diff-IP2D（P233 / P232）	檔案可相同，實際caller卻不同；OCT wrapper的名稱對調不等於Diff-IP2D主路徑也如此	必須沿入口查到真正呼叫，保留native名稱、公式和修訂版
EgoCast（P249）	預設分支與forecasting分支不同；預測輸入路徑有GT變數覆寫問題	固定兩個commit；獨立GT、視窗與判分驗證通過後才能發布成績
EgoMAN（P250）	程式已公開，但processed data與模型權重未發布；best-of-K還有特定選樣規則	分開程式可讀、素材取得與可評測；不把檔案中的219K / 3M當作已下載

這些是固定來源的靜態核讀發現，並非本次跑出的模型成績。逐篇表提供具體code/hash/行號；涉及可執行行為的問題仍需相應測試。

Adapter只做四件事

```
read_native(source_snapshot)
    讀原作，保留native欄位與來源身份

map_catalog(native_record, mapping_version)
    輸出共同目錄；未知、未決和不適用分開

build_case(record_ids, protocol)
    綁定相容環境 / 觀測、初態、輸入、預算與evaluator

evaluate(prediction_or_trajectory, case)
    保留原生指標，輸出分項證據與明確分母
```

這是共同介面規格，不是宣稱所有來源已實作這四個函式。資料來源沒有原生成功條件時，只能先收目錄與示範；新增robot task需要另寫goal、規則、可解性和判分。

每次匯入留下哪些交付物

交付物	用途	本次已有什麼
來源卡與閱讀證據	說明讀了哪個版本、哪些內容、哪些仍缺少	逐篇JSON、固定commit、行段 / JSON pointer與內容hash
欄位對照表	native欄位→共同含義→轉換→不能推定的內容	每篇「可重用 / 需要轉換 / 仍需補齊」及共同規格
原生數量紀錄	保留task、layout、sample、frame、trial原單位	原文數量摘錄、固定ID清單；全庫語義聯集尚未完成
匯入與驗證紀錄	記錄成功、失敗、缺漏、來源及schema版本	現有catalog importer 0.1；不包含所有來源的runtime adapter
發布清單	固定要比較的任務、case、資產、協定和評分器	來源審閱與目錄下載；新增可執行子集另行驗收

GitHub commit只能固定程式。Hugging Face資料revision、下載壓縮檔hash、子模組commit、影片 / 資產授權和裁判版本仍要各自記錄。原作刪除或暫停發布的內容保留處理結果；不以同名倉庫補位。

廣度、規模和難度怎麼報

要證明什麼	可用的數字	比較條件
用途更廣	有任務支援的用途數、用途交集與新增用途	同一分類表與納入範圍；來源級與任務級覆蓋分開
任務更多	去重後語義任務數、保留前作數、新增規則數	相同粒度；換初態 / 顏色不當成新的語義任務
環境更多	有版本身份的場景 / layout聯集	共用資產、別名、style組合與程式生成規則分開
題目更多	實際case manifest數量及其中可評測數	native split、素材與判分資格清楚；train不冒充test
覆蓋有效	按來源 / 用途 / 任務分組的模型結果與缺漏率	缺失預測仍留在expected-case清單，不只報成功讀到的交集
難度可量化	同協定內的baseline反應分佈與不確定性	真正跑過模型後才校準；不從文獻篇數推定難度

難度先記可觀測條件：步驟 / 依賴、容許誤差、遮擋、幹擾物、材料、歷史長度、恢復需求和資訊預算。取得模型×case結果後，再於相容的判分協定內校準成功率 / 誤差分級，依task / scene群聚估計信賴區間。IRT需要足夠的反應矩陣與擬合檢查，不能借用另一領域的100題設定就宣稱機器人難度已校準。

規則擴充要留下「父任務→差異→新判分」：例如同樣把物件放入抽屜，新增關門、指定順序、不可碰倒另一物件或中途滑脫後恢復，分別寫出是否改變語義任務，還是隻新增評測條件。每個新增規則都要有合法完成與近失敗的可核對例子；引數排列數不直接當完成題數。

限速與可續作

先讀快取，再抓必要的小型來源檔；所有程式共用請求排程。GitHub搜尋至少間隔6.5秒，一般API至少0.85秒，raw檔與各網站至少1秒。收到429或rate-limit 403時依Retry-After / reset暫緩，保留deferred狀態，不立即重試。這能降低觸發限制的機率，不能保證服務端永遠不限制。

代理同樣採一次一個短批次、完成即儲存；遇模型服務429就停止新增代理請求，繼續本機整理。來源已完成、待查核和暫緩都有獨立紀錄，續作不需要把整批重新抓取。

發布前的最小驗收

- 身份與版本：來源、task、scene、case、evaluator能回到原作；子模組 / 資產版本沒有偷換。
- 資料保留：原始紀錄與共同紀錄可以回查；時間、單位、座標、T/T+1及label不因loader而丟失。
- 合法輸入：模型看到的欄位符合protocol，參考答案 / 未來 / 特權狀態按約定管理。
- 判分正確：接受合法完成、拒絕相關近失敗，missing/invalid和聚合分母明確。
- 比較公平：native split保留；新split有血緣核對，候選數、時間 / 動作 / 適應預算固定。
- 計數可重算：論文、倉庫、task、環境、case、trial不混加；已取得與已可評分欄。

本研究的規模優勢應來自有出處的任務與環境聯集，以及清楚定義的新規則。程式倉庫數、資料檔案數或引數乘積，不能代替這些證據。

250篇逐篇索引

每篇保留原文數量、固定程式版本、實際閱讀範圍、可重用內容與缺口。下列編號可跳到正文；PDF也可搜尋來源編號。

P001 · VLOG

P002 · HowTo100M

P003 · COIN

P004 · CrossTask

P005 · YouCook2

P006 · Breakfast

P007 · Charades-Ego

P008 · EGTEA Gaze+

P009 · EPIC-KITCHENS

P010 · EPIC-KITCHENS-100

P011 · EPIC-KITCHENS VISOR

P012 · HD-EPIC

P013 · Ego4D

P014 · Ego-Exo4D

P015 · Assembly101

P016 · IKEA ASM

P017 · HOI4D

P018 · HOT3D

P019 · EgoBody

P020 · EgoHumans

P021 · Ego-ExoLearn

P022 · CaptainCook4D

P023 · EgoProceL

P024 · EPIC Fields

P025 · EgoPet

P026 · EgoHOS

P027 · EgoPCA

P028 · EgoSchema

P029 · EgoThink

P030 · EgoPlan-Bench

P031 · EgoPlan-Bench2

P032 · EgoTaskQA

P033 · EgoLife

P034 · EgoVLP

P035 · EgoVLPv2

P036 · EgoT2

P037 · EgoEnv

P038 · OpenEQA

P039 · RoboVQA

P040 · RoboBench

P041 · EgoCross

P042 · RoboSpatial

P043 · Embodied VideoAgent

P044 · HiERO

P045 · ManipBench

P046 · RULSTM

P047 · AVT

P048 · EGO-TOPO

P049 · AntGPT

P050 · PALM

P051 · USST / EgoPAT3D trajectories

P052 · StillFast

P053 · HandsOnVLM

P054 · EgoVid-5M / EgoDreamer

P055 · FUTR

P056 · Forecasting hands and objects

P057 · Motor attention and action forecasting

P058 · EgoPAT3Dv2

P059 · EMAG

P060 · Continuous 4D interaction forecasting

P061 · Interact with me

P062 · RLBench

P063 · Meta-World

P064 · LIBERO

P065 · CALVIN

P066 · ManiSkill

P067 · ManiSkill2

P068 · ManiSkill3

P069 · robosuite

P070 · RoboCasa

P071 · RoboCasa365

P072 · VLABench

P073 · RoboTwin

P074 · RoboTwin 2.0

P075 · VIMA

P076 · Ravens / Transporter Networks

P077 · CLIPort

P078 · PerAct

P079 · FMB

P080 · DexArt

P081 · ARNOLD

P082 · RoboVerse

P083 · RoboDojo

P084 · KinDER

P085 · SoftGym

P086 · DeformableRavens

P087 · GarmentLab

P088 · FlingBot

P089 · SpeedFolding

P090 · Cloth Funnels

P091 · UniFolding

P092 · ICRA cloth competition

P093 · MoDeSuite

P094 · R2R / VLN

P095 · RxR

P096 · ALFRED

P097 · TEACh

P098 · Habitat 2.0

P099 · HomeRobot

P100 · BEHAVIOR-1K

P101 · Embodied Agent Interface

P102 · NavVerse

P103 · Follow-Bench

P104 · SIMPLER

P105 · LIBERO-Plus

P106 · MetaWorld+

P107 · COLOSSEUM

P108 · RoboArena

P109 · REFLECT / RoboFail

P110 · AHA

P111 · RoboReward

P112 · EgoOops

P113 · REPAIR-Bench

P114 · RobotArena infinity

P115 · RoboMME-Interference

P116 · OopsieVerse

P117 · UMI

P118 · EgoMimic

P119 · EgoDex

P120 · EgoScale

P121 · EgoZero

P122 · EgoBridge

P123 · WatchAct

P124 · RoboReel

P125 · Open X-Embodiment

P126 · DROID

P127 · BridgeData V2

P128 · RoboNet

P129 · RH20T

P130 · ALOHA / ACT

P131 · Mobile ALOHA

P132 · RT-1

P133 · RT-2

P134 · OpenVLA

P135 · Octo

P136 · pi0

P137 · pi0.5

P138 · Diffusion Policy

P139 · R3M

P140 · VIP

P141 · HoloAssist

P142 · Habitat 3.0

P143 · PARTNR

P144 · CAP / EgoGym

P145 · NIABench

P146 · DexH2R

P147 · HRIBench

P148 · Assistax

P149 · V-JEPA 2

P150 · DreamDojo

P151 · H2R-Bench

P152 · RoboWM-Bench

P153 · EgoExo-Gen

P154 · Hand-conditioned ego predictive model

P155 · EgoExo-WM

P156 · Egocentric survey

P157 · Human-video robot learning survey

P158 · VLA benchmark survey

P159 · tinyBenchmarks

P160 · Rliable

P161 · First-person prediction survey

P162 · Egocentric hands survey

P163 · Ego-exo collaboration survey

P164 · The Imitator Game

P165 · LIBERO-Recover

P166 · SafeVLA-Bench

P167 · DexGarmentLab

P168 · HRIBench (perception, 2025)

P169 · X2Real

P170 · MotionForge

P171 · Bench2Dex

P172 · LabUtopia

P173 · LabDex

P174 · Labimus

P175 · Pipette

P176 · AutoBio

P177 · H2RBench (human transfer)

P178 · RoboRecover

P179 · REBOOT

P180 · SafeManip

P181 · RoboFolDeX

P182 · SoftVTBench

P183 · WireCraft

P184 · DLO-Lab

P185 · RGBench

P186 · BiFold

P187 · SSFold

P188 · DRAPER

P189 · GPT-Fabric

P190 · UniGarmentManip

P191 · ClothesNet

P192 · Phys-Liquid

P193 · GRIP

P194 · Cloth gripper interface

P195 · World models for unfolding

P196 · Deform360

P197 · EgoSim / MultiEgoView

P198 · TACO

P199 · OpenEgo

P200 · SABER

P201 · EgoSAT

P202 · EgoMonth

P203 · EGOSTREAM

P204 · S-EMBER

P205 · CapMem

P206 · EmbodiedMemory-Bench

P207 · EgoCoT-Bench

P208 · DYAD

P209 · HUI360

P210 · RoCo Challenge

P211 · AssemblyGrid

P212 · ARB4WM

P213 · Vision to Harvest

P214 · COIN（interactive）

P215 · World-model evaluation survey

P216 · HAP

P217 · TRS + RVG

P218 · TrajPilot

P219 · FROST-STA

P220 · VISTA（Ego4D STA）

P221 · STAformer++

P222 · Uni-Hand

P223 · INSIGHT

P224 · EMPIRE

P225 · Exo2EgoPose

P226 · EgoTraj

P227 · EggHand

P228 · SFHand / EgoHaFL

P229 · UniEgoMotion

P230 · EgoH4

P231 · MADiff

P232 · Diff-IP2D

P233 · OCT / HOI forecasting

P234 · I-CVAE

P235 · TransFusion

P236 · ActFusion

P237 · Gated Temporal Diffusion

P238 · Object-centric LTA

P239 · MVP

P240 · ANTICIPATR

P241 · AFF-ttention

P242 · NAOGAT

P243 · FactCheck（LTA）

P244 · BiAnt

P245 · ICVL

P246 · Decision-aware uncertainty

P247 · EgoSpanLift

P248 · HOIMotion

P249 · EgoCast

P250 · EgoMAN

P001 · VLOG

From Lifestyle Vlogs to Everyday Interactions

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

找到作者的 VLOGToolkit；它提供原作資料讀取和四種感知評測，並按 uploader 群聚 bootstrap，不能把影片當成互相獨立的樣本。

> **版本與身份**
>
> 固定toolkit commit；README連到Berkeley作者資料頁。這補足既有VLOG GitHub空缺，未將資料集宣稱量視為已下載量。
>
> README指向dfouhey的VLOG資料頁，eval.py署名David Fouhey；與原論文作者和資料集相符。

領域	居家整理與清潔
環境	影片的場景 / 距離類別是觀測標籤，不是可互動環境。
任務	手—物接觸、手部狀態、場景類別與proxemic分類；本倉庫沒有機器人動作任務或完整未來手軌跡評測入口。
題數與資料	manifest.txt、splitId.txt、uploaderId.txt、hand_object.npy、hand_state.txt，clip/frame路徑連回video ID；外部data_v1.1.tgz與影片尚未閉合取得。
評估方式	evaluateNBinary先排除標籤0再算逐類AP/mAP；其他分支算accuracy/top-k。bootstrap的抽樣單位為uploader。hand_state分支直接比較類別預測與標籤，不能只照過時的posterior註解傳矩陣。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **114,000** 影片 · 原文114K，約數 · 原文頁 1, 3
- **30** 物件接觸標籤 · 原文頁 5, 7
- **8** 手部 / 人物狀態類別 · 原文頁 5, 7
- **219,000** 抽樣標註影格 · 原文219K，非全部有一致標籤 · 原文頁 5

依這個順序讀

1. `Readme.md` ↗
   GitHub · dfouhey/VLOGToolkit · 69cef04828

   作者資料入口、資料路徑與評測用途。

   L1–40

---

2. `eval.py` ↗
   GitHub · dfouhey/VLOGToolkit · 69cef04828

   資料索引、有效標籤、分類/AP與uploader群聚評分。

   L1–406

怎麼接入我們的benchmark

可重用

原生video/frame/uploader ID、split、未知標籤mask與評分程式。

需要轉換

把影片 / 影格保留為context與case；原生分類分項登記，uploader用於分組切分與不確定性。

仍需補齊

外部素材、Python2 / 舊依賴移植、預測輸出型別核對與正式case驗證。

P002 · HowTo100M

HowTo100M: Learning a Text-Video Embedding by Watching Hundred Million Narrated Video Clips

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

這個倉庫提供影片—文字表徵訓練與跨資料集檢索評測；HowTo100M 是訓練資料來源，程式的主要評測入口另外讀 MSR-VTT、YouCook2 和 LSMDC。

> **版本與身份**
>
> 本輪讀取固定 commit 的公開程式；不把 README 的歷史「largest」敘述當成現時排名。

領域	餐飲與烹飪、辦公與教育、工藝與修繕、個人照護、交通移動與車輛維修、農業與園藝、休閒與運動、寵物照護與動物活動
環境	原作影片 / YouTube 來源作觀測脈絡；這個倉庫沒有可直接當成本庫互動環境的 scene registry。
任務	保留 CSV 的人類 task 標籤與影片—文字檢索題型；不能把字幕片段或人類活動直接改成機器人任務。
題數與資料	CSV video_id/task/path、caption 起訖時間、2D/3D 特徵。loader 明示兩種特徵各自的取樣頻率；完整影片與特徵由外部下載。
評估方式	eval.py 將影片與文字配對矩陣送到 metrics.py，以正確配對的排名算 R@1/5/10、median rank。README 指出 YouCook2 使用 validation 集合。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **12** WikiHow來源用途類別 · 原文頁 3, 4
- **23,611** human visual-task query labels · 原文頁 3
- **136,600,000** weak clip-caption pairs（約數） · 原文頁 4

依這個順序讀

1. `README.md` ↗
   GitHub · antoine77340/howto100m · 50af0ffb10

   先區分 HowTo100M 訓練資料與三個下游檢索評測集合。

   L1–65

---

2. `youtube_dataloader.py` ↗
   GitHub · antoine77340/howto100m · 50af0ffb10

   看影片 ID、task、字幕時間段和不同頻率特徵如何組成輸入。

   L19–52 · L144–150

---

3. `eval.py` ↗
   GitHub · antoine77340/howto100m · 50af0ffb10

   找到檢索評測入口及送入 metric 的影片—文字相似度矩陣。

   L83–94

---

4. `metrics.py` ↗
   GitHub · antoine77340/howto100m · 50af0ffb10

   核對 R@1、R@5、R@10 和 median rank 的實作。

   L9–29

怎麼接入我們的benchmark

可重用

影片 ID、字幕時段、活動標籤、下游檢索 split 與 metric 可以保留。

需要轉換

轉成 video/context 紀錄與檢索 case；分開儲存原片時間、各特徵頻率及對應關係，另記真正使用的下游資料來源。

仍需補齊

原始素材 / 特徵下載閉合、跨來源影片重複、共同用途對映與本庫 evaluator 接線。

P003 · COIN

COIN: A Large-scale Dataset for Comprehensive Instructional Video Analysis

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

COIN 將標註、下載與評測拆成不同倉庫。要先讀 annotations 的 domain/task/step 與影片 JSON，再讀 code 的時段定位 / 逐影格分割評測。 2026-10-11 補讀 annotation-tool 的實際匯出與時段生成。

> **版本與身份**
>
> 12 domains / 180 tasks 是作者的活動分類，並非本庫21類用途或180個已去重的機器人任務。 annotation-tool 為獨立固定提交，CSV 標註工作檔不能視為已發布的 database JSON；sample 的 0.5 秒間隔不能推為所有影片 fps。

領域	居家整理與清潔、餐飲與烹飪、工藝與修繕、個人照護、交通移動與車輛維修、休閒與運動
環境	影片觀測脈絡；原作生活用途不是互動場景 ID。
任務	原生 domain/task/step 分類與人類程式活動；定位、分割是資訊評測題型，不能等同機器人工作規格。
題數與資料	ActivityNet 風格 database JSON、YouTube ID、影片 URL、步驟 label/segment 及 taxonomy。README 範例的 class 與下載器的 recipe_type 欄位需對實際版本檢查。 補讀：annotation-tool 讀 URLID/URL、TagID/Tag、URLID/Frame/Time 三表，匯出 instruction_時間.txt 的 CSV 八欄 URLID,URL,TagID,Tag,Start,End,Time,State。輸出 Time 為 times（確認儲存次數），有別於 frame.txt 的抽幀秒數；Start/End 為時段秒數。影格模式依 newSpace 分開不連續區段，影片模式先以 toFixed(0) 儲存整秒文字。匯出只保留有 URLID/TagID 的 tagInfo 列，不含沒有標註的影片。
評估方式	定位結果包含 action_id、start、end、confidence、video_name；evaluate.number_label 需設為相符的原生標籤空間。分割另報逐影格 accuracy；各自保留分母。 補讀工具的 State=0/1/2 分別是未標註 / 已標註 / 刪除；checked 是另存於瀏覽器的布林值，八欄匯出沒有帶出。這些是標註流程狀態，並非 AP/F1、GT 品質或獨立複核指標。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **12** 原作活動領域 · 原文頁 3, 4
- **180** 人類程式任務 · 原文頁 3, 4

- **778** 步驟定義 · 原文頁 4
- **11,827** 影片 · 原文頁 5
- **46,354** 時間標註步驟片段 · 原文頁 5
- **2,797** test影片 · 原文頁 5

依這個順序讀

1. `README.md` ↗
   GitHub · coin-dataset/annotations · 67e31260e9

   看三層活動分類與影片、步驟時段的 JSON 結構。

   L1–65

---

2. `download_videos.py` ↗
   GitHub · coin-dataset/annotations · 67e31260e9

   看影片 ID、recipe_type 與 video_url 的實際使用方式。

   L1–26

---

3. `README.md` ↗
   GitHub · coin-dataset/code · c1e09e74aa

   區分 step localization 與 frame-wise action segmentation；確認輸出格式及所需標籤空間。

   L1–46

---

4. `evaluate.py` ↗
   GitHub · coin-dataset/code · c1e09e74aa

   核對同影片同 action 的時段重疊、F1 與 AP。

   L16–26 · L57–64 · L75–96

---

5. `README.md` ↗
   GitHub · coin-dataset/annotation-tool · b4b3d52729

   輔助標註工具的三份輸入、影格 / 影片模式及匯出入口。

   L1–29 · L35–81

---

6. `input/video.txt` ↗
   GitHub · coin-dataset/annotation-tool · b4b3d52729

   URLID 與影片檔名範例；不是直接套用公開資料的 YouTube key。

   L1–2

---

7. `input/label.txt` ↗
   GitHub · coin-dataset/annotation-tool · b4b3d52729

   工具本地 TagID / Tag 字典範例。

   L1–6

---

8. `input/frame.txt` ↗
   GitHub · coin-dataset/annotation-tool · b4b3d52729

   URLID / Frame / Time 表與範例每 0.5 秒抽幀；非全資料集 fps。

   L1–8 · L49–52

---

9. `lib/js/index.js` ↗
   GitHub · coin-dataset/annotation-tool · b4b3d52729

   實際匯出八欄 CSV 文字、列過濾與匯入欄名檢查 / localStorage。

   L26–124

---

10. `lib/js/config.js` ↗
    GitHub · coin-dataset/annotation-tool · b4b3d52729

    簡易逗號切分、按 URLID 合併及 state / checked 工作流程。

    L1–23 · L79–105 · L232–251

---

11. `lib/js/imageTag.js` ↗
    GitHub · coin-dataset/annotation-tool · b4b3d52729

    追到標註儲存及區段生成；影格間距分段、影片秒數取整、times 與 checked 的更新。

    L301–318 · L400–426 · L674–700 · L728–766 · L770–826 · L903–1011 · L1019–1034

怎麼接入我們的benchmark

可重用

活動 / 步驟 ID、影片血緣、原生時段及 AP/F1 等判分程式。 可另重用工具輸入字典、逐影片 tagInfo 與匯出欄位。

需要轉換

活動放 human_activity_definition；影片與時間標註放 context/annotation；定位與分割 case 分開建立，保留秒與影格換算。 工具 URLID/URL → 來源影片引用，TagID/Tag → 工具版本內標籤，Start/End → 原生秒區段；Time/State 放標註流程 metadata。需明確建立這些本地 ID 與已發布 COIN JSON/taxonomy 的對映。

仍需補齊

影片有效取得、完整 split 清單、欄位別名核對及本庫資訊題型的 evaluator 接線。 工具讀寫採直接逗號 / 換行切分，未處理引號包覆的逗號；仍需匯出往返、整秒精度、缺列及 checked 遺失驗證。此補讀未取得影片或執行瀏覽器工具。

P004 · CrossTask

Cross-task weakly supervised learning from instructional videos

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

CrossTask 的核心是從教學影片定位有順序的步驟。18 個 primary tasks 有時段標註；65 個 related tasks 用於跨任務學習，不能全部當成同樣有答案的評測題。

> **版本與身份**
>
> 公開程式的版本已固定；README 的外部下載與舊依賴尚未作完整可執行重現。

領域	餐飲與烹飪、工藝與修繕、交通移動與車輛維修
環境	教學影片來源；沒有互動場景清單。
任務	原生人類活動包含有序 step descriptions；primary 與 related 任務資格需保留。
題數與資料	tasks 檔、task/video/URL CSV、每影片特徵 NumPy、敘述限制 CSV 及逐步時間標註。read_assignment 對 start floor、end ceil 並使用半開時段。
評估方式	train.py 的 eval 以 DP 產生步驟指派；get_recalls 按有 GT 的步驟計匹配，再以 task 平均。這是步驟定位召回，不是整個程式的物理完成率。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **83** 全部程式 · 原文頁 2, 5, 6
- **18** 主要評測程式 · 原文頁 5, 6
- **65** 相關訓練程式 · 原文頁 5, 6
- **4,700** 影片 · 約4.7K · 原文頁 2
- **1,850** 每輪test影片 · 原文頁 6

依這個順序讀

1. `README.md` ↗
   GitHub · DmZhukov/CrossTask · 9e6fdccbce

   先分清83活動、18/65子集、外部資料包和1秒特徵時間格。

   L1–54

---

2. `data.py` ↗
   GitHub · DmZhukov/CrossTask · 9e6fdccbce

   讀 task/step 列表、影片 CSV、時間邊界轉成指派矩陣及 train/test 分割。

   L1–109

---

3. `train.py` ↗
   GitHub · DmZhukov/CrossTask · 9e6fdccbce

   找到 get_recalls 與 eval，核對可用 GT 子集及逐 task 平均方式。

   L1–85 · L144–182

---

4. `dp.pyx` ↗
   GitHub · DmZhukov/CrossTask · 9e6fdccbce

   確認順序限制與 exactly_one 的動態規劃指派，這會影響輸出與評分。

   L1–72

怎麼接入我們的benchmark

可重用

83個原生活動 ID、primary/related 資格、步驟順序、影片與時間標註、原作 recall 邏輯。

需要轉換

原始秒數與衍生時間格分欄；固定影片分割與隨機分割種子。人類活動、定位 case 和模型重跑分開計數。

仍需補齊

完整來源素材及標註包、當前依賴環境重現、本庫 split 血緣核對與 evaluator 接線。

P005 · YouCook2

Towards Automatic Learning of Procedures from Web Instructional Videos

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

作者ProcNets倉庫將YouCook2影片程式分段、Lua Torch訓練/驗證與Python proposal評分放在一起；應讀實際公式，不把所有分數都當同一種IoU。

> **版本與身份**
>
> 當前公開碼是舊Lua Torch/Python2實作；README的PyTorch未來發布敘述不代表已取得該版本。

領域	餐飲與烹飪
環境	網路烹飪影片的觀測脈絡；未提供可互動場景。
任務	程式片段提議/分段；步驟文字與時間段不是機器人控制任務。
題數與資料	database JSON的annotations/segment、影片duration/total_frame CSV與ResNet特徵；均勻取樣和temporal augmentation會改變時間到特徵索引的換算。
評估方式	Lua iou是intersection/union；名稱為jacc的函式實際除以預測片段長度。驗證對每個GT找最佳proposal，再逐影片平均。Python另按tIoU算precision/recall並限制每影片proposal數。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **89** 食譜 · 原文頁 3, 4
- **2,000** 影片 · 原文頁 3, 4
- **176** 小時 · 原文頁 3, 4

依這個順序讀

1. `README.md` ↗
   GitHub · LuoweiZhou/ProcNets-YouCook2 · 815ae582b5

   匹配作者論文、資料與評測路徑。

   L1–77

---

2. `misc/DataLoader.lua` ↗
   GitHub · LuoweiZhou/ProcNets-YouCook2 · 815ae582b5

   原始時間、均勻取樣與augmentation換算。

   L8–12 · L14–18 · L22–30 · L37–41 · L58–63 · L89–97 · L102–106 · L108–112 · L122–135 · L145–149

---

3. `train_bilstm_seq.lua` ↗
   GitHub · LuoweiZhou/ProcNets-YouCook2 · 815ae582b5

   IoU/Jacc實際公式及驗證聚合。

   L23–31 · L165–231 · L247–273 · L292–298 · L301–315 · L355–362 · L367–376 · L379–394

---

4. `script/eval_recall_precision.py` ↗
   GitHub · LuoweiZhou/ProcNets-YouCook2 · 815ae582b5

   proposal格式、split與tIoU判分。

   L1–80 · L120–186

怎麼接入我們的benchmark

可重用

原生video ID、segment、split、duration/frame資訊和兩套明確指標。

需要轉換

原始秒數與取樣索引分欄；記proposal上限、tIoU與逐影片分母，保留原生指標名及公式，不能直接改成robot success。

仍需補齊

完整素材/特徵與split閉合、Lua/Python2依賴移植，以及指標等價性驗證。

P006 · Breakfast

The Language of Actions: Recovering the Syntax and Semantics of Goal-Directed Human Activities

實作尚未確認 · 主來源 · 原作 · 獨立頁面

核對原論文資料入口與目前轉址後，尚未確認可歸屬原作的官方GitHub；後續方法的Breakfast實驗程式不能替代原作發布。

> **版本與身份**
>
> 這是本輪來源鏈尚未確認GitHub，不宣稱世界上沒有Breakfast程式。

領域	餐飲與烹飪
環境	論文中的真實廚房和同步視角是錄製脈絡，並非已取得的模擬scene。
任務	料理活動與action units分層；沉默單元、活動和影格分類不是不同機器人任務。
題數與資料	原作描述受試者、廚房、影片視角和動作標註；舊資料頁已轉到實驗室首頁，原生manifest與格式在本輪尚未取得。
評估方式	原文報unit及frame識別表現和依受試者四折評測；沒有已確認官方GitHub evaluator可作程式核讀。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **18** 真實廚房 · 原文頁 3
- **10** 料理活動 · 原文頁 3
- **48** 粗粒度動作單元 · 原文頁 3
- **11,267** 動作單元樣本（含靜默） · 原文頁 3
- **52** 參與者 · 原文頁 3

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

原文活動階層、受試者分組與資料取得入口。

需要轉換

先收source與原生活動筆記；取得檔案後保留subject/session/view/time及原生四折，視角不增加獨立活動。

仍需補齊

官方實作或資料包、原生時間格和標註欄位、完整評分重現。

P007 · Charades-Ego

Charades-Ego: A Large-Scale Dataset of Paired Third and First Person Videos

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

Charades-Ego原文引用gsig的Charades演算法；這是沿用Charades的baseline框架，不是完整ego/exo配對資料發布。程式本身明示Python mAP只是近似官方MATLAB評分。

> **版本與身份**
>
> 原文PDF第2頁明列此baseline來源；不要把其README上的原Charades結果當Charades-Ego本次實測。
>
> 原作PDF裸網址github.com/gsig/charades-algorithms及作者挑戰頁共同支援；倉庫明示自己是Charades starter code。

領域	居家整理與清潔
環境	同一人類活動的第一/第三人稱錄製為成對觀測；相機視角不能算兩套互動環境。
任務	Charades多標籤活動識別，需另保留Ego配對與跨視角設定；原倉庫157類不能當157個機器人工作。
題數與資料	CSV id/actions含class/start/end；loader以24FPS換算時間，video驗證均勻取25個影格，train/val使用不同取樣與label格式。
評估方式	map.py逐類排序算AP，無正例類別為NaN；charades_map把沒有任何GT的影片分數壓至負無限。原碼要求精確排名使用官方MATLAB指令碼，這個近似不能靜默替代。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **112** 錄製住宅 · 原文頁 1, 2
- **157** 活動類別 · 原文頁 2
- **7,860** 視角影片 · 原文頁 2
- **1,693** test視角影片 · 原文頁 2
- **68,536** 動作標註 · 原文頁 2

依這個順序讀

1. `README.md` ↗
   GitHub · gsig/charades-algorithms · 927794cd04

   確認baseline用途與原Charades引用關係。

   L1–35

---

2. `pytorch/datasets/charadesrgb.py` ↗
   GitHub · gsig/charades-algorithms · 927794cd04

   CSV schema、frame換算及video取樣。

   L1–65 · L78–188

---

3. `pytorch/utils/map.py` ↗
   GitHub · gsig/charades-algorithms · 927794cd04

   近似mAP實作與官方評分限制。

   L1–39

怎麼接入我們的benchmark

可重用

原生影片/活動ID、時間段、RGB/flow讀取和baseline預測格式。

需要轉換

補ego/exo對應與subject/session血緣，分開frame、video和跨視角評測；儲存原生取樣及評分版本。

仍需補齊

Ego配對資料/split、精確官方MATLAB evaluator及當前執行環境。

P008 · EGTEA Gaze+

In the Eye of Beholder: Joint Learning of Gaze and Actions in First Person Video

實作尚未確認 · 主來源 · 原作 · 獨立頁面

已核對EGTEA Gaze+原作與舊資料網址，但目前未確認官方GitHub。搜尋中的第三方下載器不等於原作模型或凝視評分實作。

> **版本與身份**
>
> 原文10321樣本與後續版本數字需分開；不能用第三方重打包靜默取代。

領域	餐飲與烹飪
環境	自然廚房的人類第一人稱錄影；不是本輪可互動的環境。
任務	凝視估計與動作識別分開；meal活動、action classes和clip樣本是不同粒度。
題數與資料	原文第9頁定義24Hz影片/凝視、24影格clip、首split與有效凝視；資料檔schema及素材仍待取得。
評估方式	論文凝視P/R/F1忽略未追蹤與saccade，8影格聚合；動作使用mean class accuracy且clip/video分開。尚未取得已確認官方evaluator。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **7** 料理任務 · 原文頁 9
- **106** 動作類別 · 原文頁 9
- **86** 錄製sessions · 原文頁 9
- **10,321** 動作樣本 · 原文頁 9
- **2,022** 首split test動作樣本 · 原文頁 9

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

原作時間格、凝視有效性、clip/video層次和split定義。

需要轉換

各建gaze與action case；保留原始時間、座標縮放、validity mask和類別空間，不轉成robot action。

仍需補齊

官方程式、可確認的資料發布、原生標註與評分接線。

P009 · EPIC-KITCHENS

Scaling Egocentric Vision: The EPIC-KITCHENS Dataset

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EPIC-KITCHENS 原始版的標註、讀取工具與評分庫分開發布；舊網址現已轉嚮明確的 55 版倉庫。已核讀動作 / 物件標註、GulpIO 流程與分類指標。 2026-10-11 補讀官方共用 downloader 的版本選擇；舊 download-scripts URL 的 404 保留為候選處置。

> **版本與身份**
>
> 固定提交的 annotations / starter-kit / epic-lib 舊路徑均轉向 EPIC-55。epic-lib README 警告 v1.4.0 及更早版本的 Gulp flow 可能亂序；原始 GoPro 與釋出抽幀版本的 fps / frame index 不可混用。 補讀 downloader 固定 4f11fb2b579833f360c3c7bb917bf1e24a9787b5，不宣稱是 download-scripts 的已驗證轉址。其 README 說 data/ 未追蹤，但該提交完整 tree 列有四份 CSV，且兩份 split 已實讀；以固定檔案為準。原 Snakefile 的 annotations/master 連結需替換為既有 55 固定版本，不能依今天的預設 challenge 選項推回 2018 評測。

領域	居家整理與清潔、餐飲與烹飪
環境	真實第一人稱廚房影片；participant_id、video_id 與 seen / unseen kitchen 測試條件須保留。影片、拍攝者與廚房不是同一個環境計數。
任務	動作辨識以 verb_class、noun_class 及其組合定義；物件框另有自己的標註時間軸。這些是人類影片標籤，不是可直接執行的機器人任務。
題數與資料	action CSV 含 uid、video_id、participant_id、narration、start/stop_timestamp、start/stop_frame、verb/noun_class 與 all_noun_classes。物件框使用 (top,left,height,width)；object_frame 和 action_frame 需依對照表對齊。S1/S2 測試只公開片段時間；narration 時間不可代替動作邊界。 補讀：原 55 starter-kit 的 Snakefile 由 train/test_seen/test_unseen_video_ids.csv 產生 Bristol 的逐影片 RGB / flow tar 路徑。另由官方 2022 網頁直接連結的 epic-kitchens-download-scripts 提供 epic_downloader.py：先讀 55 的 video_id/split 和 100 的 ar/da/cmr 布林 split CSV，依 video_id 後段長度辨認 extension，再以 --epic55-only 或 --extension-only 過濾；兩旗標互斥，未指定時涵蓋 100（含重用的 55）。輸出一律使用 EPIC-KITCHENS/participant/媒體型別 目錄，原始 55 遠端 train/test 路徑另由 epic_55_split 決定。

評估方式	epic-lib 計算 verb、noun、action 的 top-1/top-5；沒有 action 分數時可由 verb/noun 分數構造。precision/recall 先逐類計算，再對指定 many-shot 類別平均；與 100 版的 tail / unseen 指標不同。top-k 使用每列排名內是否包含 GT 的平均。 下載器的 --action-recognition/--train 等篩選取自 100 版 challenge 欄位；--epic55-only 只限制影片來源，不能替代原 55 的 S1/S2。需仍沿用 55 starter-kit 的 seen→s1、unseen→s2 與原標註契約。MD5 只用於判斷檔案是否可跳過下載，不是辨識指標；本次未執行下載或校驗媒體。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **32** 錄製廚房 · 原文頁 1, 3
- **3** benchmark端點 · 原文頁 11, 12, 13, 14, 15
- **125** 動詞類別 · 原文頁 10
- **331** 名詞類別 · 原文頁 10
- **39,596** 動作片段 · 原文頁 3
- **454,255** 物件框 · 原文頁 3

依這個順序讀

1. `README.md` ↗

   GitHub · epic-kitchens/epic-kitchens-55-annotations · 63fa7d78eb

   55 版欄位、框座標、原始影片與測試條件

   `L1–3 · L11–15 · L31–35 · L47–61 · L67–71 · L75–80 · L82–96 · L100–220 · L222–227 · L229–262 · L264–290 · L296–343 · L347–354 · L370–390 · L392–396 · L401–405 · L410–416`

2. `README.md` ↗

   GitHub · epic-kitchens/epic-kitchens-55-starter-kit-action-recognition · 200ba5a497

   從標註到 RGB / flow 片段與 GulpIO 的流程

   `L1–158`

3. `README.md` ↗

   GitHub · epic-kitchens/epic-lib · 7f2499aff5

   資料讀取與版本限制

   `L1–33`

4. `epic_kitchens/metrics.py` ↗
   GitHub · epic-kitchens/epic-lib · 7f2499aff5

   top-k 及 many-shot precision / recall 實作

   L12–18 · L35–41 · L75–95 · L118–124 · L129–157 · L162–184 · L188–194 · L196–202 · L221–242 · L258–267 · L274–346 · L348–356 · L369–385

---

5. `README.md` ↗
   GitHub · epic-kitchens/epic-kitchens-55-annotations · 63fa7d78eb

   補讀直接連向舊 download-scripts 的官方 55 版取得說明；404 候選另列處置。

   L352–369

---

6. `Snakefile` ↗
   GitHub · epic-kitchens/starter-kit-action-recognition · 200ba5a497

   核對原 55 資料取得的 video_id 清單、Bristol tar 路徑及 S1→seen / S2→unseen；metadata URL 仍指向 master。

   L9–48 · L53–105 · L130–147

---

7. `README.md` ↗
   GitHub · epic-kitchens/epic-kitchens-download-scripts · 4f11fb2b57

   官方另連結的 55 / 100 共用 downloader；資料型別、版本旗標與輸出目錄。

   L1–18 · L48–63 · L109–121 · L139–167 · L169–189 · L239–281

---

8. `epic_downloader.py` ↗
   GitHub · epic-kitchens/epic-kitchens-download-scripts · 4f11fb2b57

   實際 caller→split CSV→版本篩選→URL / 輸出路徑；核對預設全資料、MD5 跳過條件與 CLI。

   L30–68 · L133–161 · L174–215 · L248–320 · L328–363 · L366–486

---

9. `data/epic_55_splits.csv` ↗
   GitHub · epic-kitchens/epic-kitchens-download-scripts · 4f11fb2b57

   55 版 metadata 的 participant_id / video_id / split 欄位與樣列。

   L1–8

---

10. `data/epic_100_splits.csv` ↗

    GitHub · epic-kitchens/epic-kitchens-download-scripts · 4f11fb2b57

    100 版 challenge 布林欄位及舊 / 新增影片共表；不把資料來源 filter 當成 55 評測 split。

    L1–8 · L20–24

怎麼接入我們的benchmark

可重用

原生類別字典、片段 uid、S1/S2 切分、框座標、GulpIO 資料流程與評分函式。 可重用已釘選的取得程式、兩版 split CSV 欄位、原生 URL 與輸出路徑對映。

需要轉換

source 固定為 EPIC-55；case 保留 uid 與原始 split；segment 同時保留秒與 frame，記錄實際抽幀版本；動作 / 物件時間軸以顯式對映關聯。verb/noun/action 與 many-shot 報表分項儲存。 另記錄 acquisition_repo/commit、資料 edition、video_id、來源 split、challenge split、媒體型別與 errata/校驗表版本；55/100 重用影片共用 ancestry，但各自保留評測切分。

仍需補齊

尚未取得影片 / flow / 隱藏測試標籤，也未執行 GulpIO 或官方提交；跨來源與 EPIC-100 重用關係需由 video_id 建立。 需固定下載器實際依賴的 split/md5/errata CSV 版本，驗證完整取得與雜湊；本次 split 僅核讀欄位和列出的樣列，未宣稱逐列審核。

P010 · EPIC-KITCHENS-100

Rescaling Egocentric Vision

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EPIC-KITCHENS-100 需保留五項挑戰各自的資料與評測約定；本次核讀總標註、敘述工具及 C1 動作辨識實際指標，沒有把其他挑戰概括成已整合。

> **版本與身份**
>
> 固定提交的說明列出 P01_109、P27_103 預抽幀錯誤；原始影片與標註不受影響，資料取得時必須儲存修正版本。narrator 是工具，並非額外 benchmark。EPIC-55 many-shot P/R 不等於本版 tail 指標。

領域	居家整理與清潔、餐飲與烹飪
環境	沿用部分 EPIC-55 廚房影片並新增拍攝；PXX_YY 與 PXX_1YY 的影片來源不同，不能把兩版影片量相加當作獨立場景。
任務	包含動作辨識、弱監督辨識、動作預測、無監督領域適應、影片文字檢索。verb、noun、action 類別與檢索句子各有原生 ID，挑戰種類不等於獨立任務數。
題數與資料	train / validation / test_timestamps CSV 以 narration_id 對齊片段；narration_timestamp、start/stop_timestamp、frame 邊界各自儲存。anticipation 使用動作前 5 秒觀測並留 1 秒間隔；UDA 的 source/target 與 retrieval 的 sentence 表另列。C1 預測含 verb_output[N,97]、noun_output[N,300] 及 narration_id。
評估方式	C1 utils/metrics.py 計算全部樣本 verb / noun / action top-1/top-5，以及 unseen participants、tail verbs / nouns / actions 的對應 top-1 子集；布林遮罩決定分母。其他四項挑戰需各自取得 evaluator，不可沿用 C1 得分。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **45** 錄製環境 · 原文頁 1
- **6** challenge · 原文頁 7
- **4,053** 動作類別 · 原文頁 5
- **89,977** 動作片段 · 原文頁 5

- **700** 影片 · 原文頁 5
- **13,092** test動作片段 · 原文頁 5

依這個順序讀

1. `README.md` ↗
   GitHub · epic-kitchens/epic-kitchens-100-annotations · ea8b40457a

   五項挑戰、欄位、版本與錯誤修正

   `L1–120 · L136–193 · L375–421 · L544–579`

---

2. `README.md` ↗
   GitHub · epic-kitchens/epic-kitchens-100-narrator · d9d429819c

   narration 標註工具與時間來源

   `L1–68 · L192–229`

---

3. `README.md` ↗
   GitHub · epic-kitchens/C1-Action-Recognition · 277586f7fc

   C1 輸出維度、narration_id 與評測輸入

   `L1–99`

---

4. `utils/metrics.py` ↗
   GitHub · epic-kitchens/C1-Action-Recognition · 277586f7fc

   top-k、unseen 與 tail 子集實作

   `L7–13 · L24–30 · L35–41 · L53–65 · L90–106 · L113–129 · L143–155 · L166–175 · L179–193`

怎麼接入我們的benchmark

可重用

動作 / 敘述時間、原生 split、tail / unseen 子集、C1 分數格式與 top-k evaluator；narrator 可作為標註來源工具。

需要轉換

source 版本標 EPIC-100 並建立對 EPIC-55 的 video 重用邊；task / case 記錄 challenge、narration_id、合法觀測窗；retrieval 與 anticipation 分成不同 profile；指標保留原生子集與分母。

仍需補齊

尚未下載影片、驗證 frame 修正版、取得隱藏測試或執行提交；C2–C5 的完整 loader / evaluator 仍需另外核讀與測試。

P011 · EPIC-KITCHENS VISOR

EPIC-KITCHENS VISOR Benchmark: VIdeo Segmentations and Object Relations

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

VISOR 是 EPIC-KITCHENS 影片上的分割與物件關係標註。五個倉庫分別承擔 VOS、HOS、來源追溯、視覺化與抽幀工作，不能算成五批獨立環境。

> **版本與身份**
>
> VISOR-FrameExtraction 要求先修正插值並列出 P02_01、P03_14；新版名詞表追加左右手 / 手套，仍保留舊 hand/glove 類別。VOS 不是未修改的 DAVIS 評分：末影格被納入。

領域	居家整理與清潔、餐飲與烹飪
環境	EPIC-100 的廚房影片子集；video、subsequence、image 各是不同層級。VISOR 重新抽幀，需 frame_mapping.json 才能對回 EPIC。
任務	VOS 在給定首影格物件遮罩後追蹤分割；HOS 判斷手側、接觸與手物件組合；WDTCF 用查詢物件遮罩追溯來源物件與證據影格。這些為視覺理解，不是機器人完成操作。
題數與資料	每影片 JSON 的 video_annotations 含 image.name/video/subsequence 及 mask id/name/class_id/segments/exhaustive/in_contact_object/on_which_hand。dense type=0 為插值、type=1 為端點 GT，不可同當人工標註。VOS 轉成 DAVIS 的 JPEGImages、Annotations、ImageSets 與物件色碼對映。
評估方式	VOS 實作排除首影格但保留末影格，以逐物件 J（IoU）與 F（邊界 F-measure）評分；空 union 的 J=1。HOS 將手側 / 接觸轉類別、遮罩轉 RLE，交給 COCO evaluator。WDTCF 必須 query 類別、證據影格字串吻合，source 類別才可計分，另算 query/source mask IoU；錯類別或錯影格會歸零，非單純來源分類正確率。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **42** 錄製廚房 · 原文頁 4
- **3** challenge · 原文頁 7
- **179** 影片 · 原文頁 4
- **50,729** 人工標註影格 · 原文頁 4

- **271,584** 人工mask · 原文頁 4
- **222** WDTCF test queries · 原文頁 9

依這個順序讀

1. `README.md` ↗
   GitHub · epic-kitchens/VISOR-FrameExtraction · 095cb98a7d

   稀疏 / 插值欄位、抽幀修正與 EPIC 重用

   L1–23 · L86–151

---

2. `README.md` ↗
   GitHub · epic-kitchens/VISOR-VOS · 0707a688b9

   首影格條件與轉換流程

   L1–54 · L85–145

---

3. `dataset/visor.py` ↗
   GitHub · epic-kitchens/VISOR-VOS · 0707a688b9

   逐片段讀圖、mask 色碼與取樣

   L22–134

---

4. `evaldavis2017/davis2017/evaluation.py` ↗
   GitHub · epic-kitchens/VISOR-VOS · 0707a688b9

   評測影格範圍及逐物件統計

   L1–111

---

5. `evaldavis2017/davis2017/metrics.py` ↗
   GitHub · epic-kitchens/VISOR-VOS · 0707a688b9

   IoU 與邊界 F 實際公式

   L14–52 · L101–152

---

6. `README.md` ↗
   GitHub · epic-kitchens/VISOR-HOS · 8566507382

   HOS / active 子任務

   L1–59 · L99–151

---

7. `hos/evaluation/epick_evaluation.py` ↗
   GitHub · epic-kitchens/VISOR-HOS · 8566507382

   COCO 輸出轉換

   L28–145

---

8. `README.md` ↗
   GitHub · epic-kitchens/VISOR-WDTCF · 02829f0907

   來源追溯輸入與標籤

   L1–82

---

9. `evaluation.py` ↗
   GitHub · epic-kitchens/VISOR-WDTCF · 02829f0907

   嚴格證據影格條件與失敗歸零

   L25–184

---

10. `README.md` ↗
    GitHub · epic-kitchens/VISOR-VIS · c4865d0c53

    視覺化工具角色

    L1–31

怎麼接入我們的benchmark

可重用

原生分割多邊形、接觸 ID、首影格輸入限制、VOS evaluator、WDTCF JSON 與四項輸出。

需要轉換

保留 parent=EPIC-100、frame mapping、subsequence 和 mask ID；人工 / 插值標註分開；以 VOS / HOS / WDTCF 建立獨立 case/evaluator profile，且記錄 480p / 1080p 座標與縮放。

仍需補齊

尚未取得影格與 mask；HOS 的外部 COCO 實作和線上 C6 提交流程未完整追核；資料轉換需驗證色碼與 frame mapping，不能從視覺化結果推定可評測。

P012 · HD-EPIC

HD-EPIC: A Highly-Detailed Egocentric Video Dataset

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

HD-EPIC 的標註包含動作、物件移動、凝視、食譜 / 營養與音訊；VQA 原始 schema 支援多影片 / 片段。已追到主程式實際使用的 BaseVLM 與 LlavaVideo 評分，而非把舊單影片 Dataset 當作全部介面。

> **版本與身份**
>
> 固定提交檔案已新增 MP4 對齊的中介 calibration / pose / gaze；不得假定與原論文首發資產同版。檔案明列 mask 與 bbox 由不同團隊標註可能不一致；YouTube 版本只供觀看，不作復現輸入。
>
> vqa-eval README 自述為 HD-EPIC CVPR2025 benchmark 程式，指向官方 annotations；已核對專案名稱和實際資料路徑。

領域	居家整理與清潔、餐飲與烹飪
環境	佩戴 Aria 眼鏡的真實廚房活動及對應 digital twin / fixture。video、participant、capture、fixture、3D 場景的 ID 分開，不把多個感測流計成新環境。
任務	以每個 JSON 的 question prototype 管理五選一 VQA；動作、物件關聯、凝視 priming、食譜和聲音是標註層，各自不自動成為可執行任務。
題數與資料	敘述含 unique_narration_id、秒制 start/end_timestamp、另列 narration_timestamp、多個 verb/noun pairs 與 main_actions；assoc_info 連到 mask_info 的 0-based MP4 frame、XYZ、XYXY bbox、fixture。音訊以 48kHz sample index 標示。VQA 含 inputs/question/choices/correct_idx（0-based），保留多個 input 的 id 與時間窗。
評估方式	主程式呼叫模型 run_eval；核讀 LlavaVideo 的 answer==correct_idx，再由 run_benchmark 對結果平均。BaseVLM 取回覆第一個大寫字母轉選項索引；invalid 回 -1。analyse_output 按 prototype 字首分組，另列 invalid / failure。輸入會按模型 max_video_length_seconds 降取樣，須一併報告 input_total_seconds 與 input_subsampled_seconds。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **9** 錄製廚房與數位副本 · 原文頁 1, 5
- **69** 食譜 · 原文頁 1

- **30** VQA prototypes · 原文頁 6, 7
- **26,650** 五選一VQA題 · 原文頁 7
- **1,000** VOS序列 · 原文頁 28
- **413** 廚房fixtures · 原文頁 1, 5

依這個順序讀

1. `README.md` ↗
   GitHub · hd-epic/hd-epic-annotations · aa1f833feb

   多層標註、座標與 VQA 原生格式

   L1–186 · L218–269

---

2. `README.md` ↗
   GitHub · hd-epic/hd-epic-downloader · d3431a3a90

   資產分包與下載角色

   L1–44

---

3. `README.md` ↗
   GitHub · hd-epic/hd-epic-vqa-eval · d0c233be1f

   原作者 benchmark 程式與配置入口

   L1–45

---

4. `data/vqa_dataset.py` ↗
   GitHub · hd-epic/hd-epic-vqa-eval · d0c233be1f

   舊單影片 loader 限制

   L1–99

---

5. `utils/questions.py` ↗
   GitHub · hd-epic/hd-epic-vqa-eval · d0c233be1f

   原始 inputs 分組及時間轉換

   L1–70

---

6. `models/base_model.py` ↗

   GitHub · hd-epic/hd-epic-vqa-eval · d0c233be1f

   正式多輸入讀取、取樣與選項解析

   L8–17 · L22–30 · L35–76 · L110–118 · L122–139 · L163–203 · L207–232 · L235–254 · L256–264 · L267–275 · L282–308

---

7. `models/llavavideo.py` ↗

   GitHub · hd-epic/hd-epic-vqa-eval · d0c233be1f

   具體答案比較和輸出欄位

   L32–42 · L65–75 · L91–109 · L112–122

---

8. `run_benchmark.py` ↗

   GitHub · hd-epic/hd-epic-vqa-eval · d0c233be1f

   實際入口及跨快取結果平均

   L2–17 · L57–67 · L72–82 · L95–105 · L130–140

---

9. `scripts/analyse_output.py` ↗

   GitHub · hd-epic/hd-epic-vqa-eval · d0c233be1f

   題型統計與失敗分類

   L1–91

怎麼接入我們的benchmark

可重用

原始標註層關聯、五選一題目、時間 / 框 tag 解析、同輸入題目分組及正確率流程。

需要轉換

用原生 question ID 建 case，inputs 保留多影片與框；同一次 capture 的多感測 / 多題重用同一環境記錄。保留完整毫秒時間和原始座標，另記 native adapter 對時間取整秒、框轉 0–1000 的行為；模式 visual_text / narration 與取樣預算入 evaluator 約定。

仍需補齊

尚未下載數 TB 感測資料、校準 / digital twin 或執行模型。各模型 wrapper 的 parsing / API 版本仍需個別驗證；data/vqa_dataset.py 只支援單影片且舊欄位與正式 VQA 不同，不能直接通用。

P013 · Ego4D

Ego4D: Around the World in 3,000 Hours of Egocentric Video

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

Ego4D 是多項挑戰共用的人類第一人稱影片庫。本次核讀五類官方倉庫入口，以及 NLQ、VQ3D、狀態變化、長期預測和音訊的核心格式 / 指標；各子挑戰的完成度分開記錄。

> **版本與身份**
>
> 各倉庫固定提交仍有 2022 挑戰說明；不得自動視為所有後續版本的同一協定。episodic-memory 列出近零 NLQ 時窗問題，需固定 annotation release。PNR 無正例 batch 預設回 0，evaluate_trained 可回 None，統計時應保留。LTA 註解名稱與實際使用函式應依賴鎖定的 editdistance 版本核實。

領域	居家整理與清潔、餐飲與烹飪、工藝與修繕、零售與購物、交通移動與車輛維修、農業與園藝、休閒與運動、社交與溝通、穿戴互動與動作介面
環境	多種真實日常與工作觀測；video_uid、clip_uid 與實體環境須分層。五個挑戰倉庫不是五批互不重疊的影片或機器人環境。
任務	episodic memory 包含 NLQ、MQ、VQ2D、VQ3D；手物件包含 PNR、狀態變化分類與物件定位；其他入口涵蓋 looking/talking-to-me、說話者與轉錄、短期 / 長期動作及未來手 / 移動預測。子任務數不可當做動作類別或 case 數。
題數與資料	NLQ 原生 videos→clips→annotations→language_queries，case ID 應用 clip_uid+annotation_uid+query_idx；保留 clip/video 的起迄秒與 feature-rate 對映。測試預處理填入的 0,0 是未知答案佔位，不是 GT。音訊 CTM 使用 channel/tb/dur/word，GT STM 另含 speaker/te/txt；RTTM 用於 diarization。
評估方式	NLQ 逐預測計算時間 overlap 與 top-K 超過閾值的比例，程式只列出 evaluated/GT 數，外層必須檢查缺題與重複。PNR 僅對 GT 狀態變化為真的片段，以 16-bin 映回 frame 再換秒。LTA 使用 N×Z×K 序列、每筆取 K 個預測中最小 editdistance.eval/Z，積分字首 ED 得 AUED。VQ3D 提供 L2、角度與依兩位標註者框大小 / 差異的閾值。轉錄先 lower-case/GLM 過濾後呼叫 SCTK WER；audio-only DER 用 pyannote，另外輸出逐檔平均。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **74** 原作地理locations · 原文頁 1

- **5** benchmark families · 原文頁 6
- **110** MQ活動類別 · 原文頁 7, 30
- **3,670** 影片小時 · 原文頁 1, 24
- **19,200** NLQ queries · 原文19.2K，約數 · 原文頁 29
- **22,602** VQ queries · 原文頁 29
- **64,798** short-term anticipation樣本 · 原文頁 75
- **19,780** short-term anticipation test樣本 · 原文頁 75

依這個順序讀

1. `README.md` ↗
   GitHub · EGO4D/episodic-memory · 5275b9570a

   四項 memory 任務與已知標註問題

   L1–42

---

2. `NLQ/VSLNet/utils/prepare_ego4d_dataset.py` ↗
   GitHub · EGO4D/episodic-memory · 5275b9570a

   複合 ID、時間窗及測試佔位

   L28–78 · L95–141

---

3. `NLQ/VSLNet/utils/evaluate_ego4d_nlq.py` ↗
   GitHub · EGO4D/episodic-memory · 5275b9570a

   原生閾值、分母與輸出

   L13–119

---

4. `VQ3D/VQ3D/API/metrics.py` ↗
   GitHub · EGO4D/episodic-memory · 5275b9570a

   空間誤差與標註不確定性閾值

   L1–43

---

5. README.md ↗

   GitHub · EGO4D/hands-and-objects · 0aea0a4ed6

   狀態變化任務

   L1–32

---

6. state-change-localization-classification/i3d-resnet50/evaluation/metrics.py ↗

   GitHub · EGO4D/hands-and-objects · 0aea0a4ed6

   PNR 秒制距離與分類 accuracy

   L1–53

---

7. README.md ↗

   GitHub · EGO4D/social-interactions · 033fefb2b1

   lam / ttm 分支角色

   L1–41

---

8. README.md ↗

   GitHub · EGO4D/forecasting · 38d1931b54

   四類預測入口

   L1–64

---

9. ego4d_forecasting/evaluation/lta_metrics.py ↗

   GitHub · EGO4D/forecasting · 38d1931b54

   best-of-K ED 與 AUED

   L1–115

---

10. README.md ↗

    GitHub · EGO4D/audio-visual · da19e63569

    影音子任務

    L1–38

---

11. `transcription/eval_ai_scoring.py` ↗
    GitHub · EGO4D/audio-visual · da19e63569

    STM / CTM、GLM 與 WER 介面

    L5–28 · L32–40 · L60–73 · L107–117 · L123–132 · L136–142 · L156–162 · L165–171 · L211–218 · L240–254

---

12. `diarization/audio-only/diarization/score_pyannote.py` ↗
    GitHub · EGO4D/audio-visual · da19e63569

    RTTM 排序配對及 DER 聚合

    L1–61

怎麼接入我們的benchmark

可重用

官方子挑戰入口、NLQ 複合 ID / 時窗、PNR / LTA 指標實作，以及音訊格式轉換。

需要轉換

一個父 source 下建各 challenge 的 task/case/evaluator；精確保留輸入可見範圍、label/feature/frame/second 單位、K / Z / 閾值及 GT 有效遮罩。原生影片重用以 uid 連結，評分逐項儲存，不合成一個成功率。

仍需補齊

尚未取得影片或執行 evaluator。社交任務實作在 lam、ttm 分支，本次只讀主分支入口，不能說無程式；VQ2D、MQ、STA、未來手 / 移動與社交的完整實作仍須逐支整合。SCTK / pyannote 外部實作未執行。

P014 · Ego-Exo4D

Ego-Exo4D: Understanding Skilled Human Activity from First- and Third-Person Perspectives

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

Ego-Exo4D 的主檔案、姿態、步驟與視角關係倉庫分工明確。已核對共享步驟 ID、姿態有效關節 / 座標以及具體評分；挑戰年份與論文任務清單不能混為一談。

> **版本與身份**
>
> 已釘選檔案的 challenge 頁為 2026，但 pose 倉庫 README 仍列 2024；不能把當年開放的 2 項挑戰當整個 benchmark 覆蓋量。body loader 排除含 bouldering 名稱的 take 並依相機 / 標註可用性篩選，應儲存實際納入清單。relation README 的 translation 仍寫 Coming Soon，不能只憑此推定 tree 完全無相關程式。

領域	餐飲與烹飪、個人照護、交通移動與車輛維修、休閒與運動、音樂與表演、穿戴互動與動作介面
環境	同時拍攝第一 / 第三人稱的熟練活動，檔案舉運動、音樂、舞蹈、腳踏車維修。以 take_uid 連多相機與標註，camera 數不等於環境數，scenario 是活動分類。
任務	步驟辨識 / 程式理解、穿戴者身體 / 手部 3D pose、ego-exo 物件 correspondence 等分成子挑戰。taxonomy 的 step_id 僅 scenario 內唯一；跨 scenario 共用步驟以 step_unique_id 表示，不能逐 scenario 直接加總。
題數與資料	keystep JSON 有 annotations/taxonomy/vocabulary，含 take_uid、scenario、segments 的 start/end_time、step_id、step_unique_id、is_essential。body loader 讀 takes.json、camera_extrinsics、annotation / automatic 與可見旗標，提供 global / aria / 當前相機座標選項。hand GT 以 take_uid/frame_number/right或left_hand_3d 及 hand_valid_3d 索引。
評估方式	手姿態要求 21×3、將公尺轉毫米，僅有效關節計 MPJPE；PA-MPJPE 使用平移 / 旋轉 / 尺度對齊，逐手影格誤差再平均。offset 模式加回 GT wrist，須列成不同條件。細粒度步驟以 ego_segment_name 對齊 label_id，缺預測報錯，計 top-1。correspondence 提供邊界 F 與輪廓中心距離 / 影像對角線正規化；完整聚合入口尚未驗證。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **8** 原作技能domains · 原文頁 10
- **123** 自然錄製scene · 原文頁 4, 10

- **43** 整體活動 · 原文頁 10
- **278** 正式keystep識別標籤 · 原文頁 28, 73
- **5,035** 概述takes · 原文頁 4, 10
- **33,001** keystep test視角片段 · 原文頁 74
- **6,373** keystep test ego片段 · 原文頁 74

依這個順序讀

1. `README.md` ↗
   GitHub · EGO4D/Ego-Exo4D-docs · aa763b1cd2

   官方檔案倉庫身份

   L1–35

---

2. `docs/challenge.md` ↗
   GitHub · EGO4D/Ego-Exo4D-docs · aa763b1cd2

   年份、活動背景與挑戰入口

   L1–91

---

3. `docs/annotations/keystep.md` ↗
   GitHub · EGO4D/Ego-Exo4D-docs · aa763b1cd2

   scenario-local / global step ID 與欄位

   L1–92

---

4. `README.md` ↗
   GitHub · EGO4D/ego-exo4d-egopose · 2494c0d192

   身體 / 手部任務

   L1–20

---

5. `bodypose/data/dataset_egoexo.py` ↗
   GitHub · EGO4D/ego-exo4d-egopose · 2494c0d192

   座標、take、pseudo/manual 與資料篩選

   L27–55 · L58–100 · L108–114 · L117–142 · L145–159 · L166–172 · L182–195 · L198–204 · L206–232 · L239–246 · L250–330

---

6. `handpose/evaluation/evaluate.py` ↗
   GitHub · EGO4D/ego-exo4d-egopose · 2494c0d192

   有效關節、單位及 MPJPE / PA-MPJPE

   L1–137

---

7. `README.md` ↗
   GitHub · EGO4D/ego-exo4d-keystep · 3ceee681f5

   兩種步驟任務入口

   L1–9

---

8. `fine_grained/eval_json.py` ↗
   GitHub · EGO4D/ego-exo4d-keystep · 3ceee681f5

   segment ID 對齊與正確率

   L1–42

---

9. `README.md` ↗
   GitHub · EGO4D/ego-exo4d-relation · d6b7443fef

   關係任務與 translation 檔案狀態

   L1–14

---

10. `correspondence/evaluation/metrics.py` ↗
    GitHub · EGO4D/ego-exo4d-relation · d6b7443fef

    輪廓中心距離與 F 函式

    L4–10 · L41–47 · L65–74 · L110–139 · L191–197 · L210–216 · L231–237 · L242–258 · L264–271

怎麼接入我們的benchmark

可重用

take / 步驟全域 ID、階層 taxonomy、姿態有效性旗標和手部 evaluator。

需要轉換

環境保持實體場景 / take / 相機多層關聯；scenario→task 用原生 taxonomy，step_unique_id 保留跨 scenario 共用。姿態與視角關係以獨立 profile 記錄 frame、座標、米 / 毫米、pseudo/manual、GT wrist 條件與對齊方式。

仍需補齊

尚未取得多視角影片與校準、執行 pose / keystep evaluator，或完整核讀程式理解 / proficiency 的實作。

fine_grained/eval_json.py 使用 os.path 卻未 import os，為靜態發現的整合問題；需在 adapter 測試時修正並保留差異。

P015 · Assembly101

Assembly101: A Large-Scale Multi-View Video Dataset for Understanding Procedural Activities

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

Assembly101 的原生粗 / 細粒度和錄製 / 視角可以明確分開；六個官方倉庫分別是下載、標註、錯誤標註及三種理解 baseline。

> **版本與身份**
>
> 下載 README 已加入 2026-05 Hugging Face 與更新的 AssemblyPoses.zip；不要把新特徵 / pose 視為 2022 原始實驗。mistake 註釋指向 2023 Every Mistake Counts in Assembly，與原始三項理解評測需建立衍生關係。

領域	裝配與生產作業
環境	人類組裝 / 拆卸玩具車；recording/sequence 與 8 固定 RGB、4 頭戴單色視角分層。toy_id 是物件身份與泛化切分依據，不直接等於場景數。
任務	標註檔案列 202 coarse actions（61 物件、11 verbs）與 1,380 fine-grained actions（90 物件、24 verbs），是原生類別數。粗標註供 temporal segmentation，細標註供 recognition/anticipation；mistake/correction 是另外的程式標籤。
題數與資料	fine CSV 含 id、video、start/end_frame、action/verb/noun_id、toy_id/name、is_shared、is_RGB；coarse labels 為片段 frame 邊界與 action_cls，coarse_splits 分 assembly/disassembly。影片原始 60fps，動作標註 frame 為 30fps；手 pose 又為 60fps。mistake CSV 含 start/end、verb、this/that、label、remark。
評估方式	temporal utils.py 將連續同類影格折成片段，計正規化 edit、全影格 MoF、tIoU=.1/.25/.5 下逐 GT 至多匹配一次的 F1。anticipation 先對 action 分數 marginalize 得 verb/object，再算逐類平均 top-k recall，另列 tail/unseen；不是逐題 accuracy。TSM loader 以 start_frame+片段內取樣位置讀圖。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **101** 玩具型號 · 原文頁 1, 4
- **202** 粗動作類別 · 原文頁 4
- **1,380** 細動作類別 · 原文頁 4

- **362** 獨立拆裝sequences · 原文頁 4
- **4,321** 視角影片 · 原文頁 4
- **1,013,523** 細動作視角片段 · 原文頁 5

依這個順序讀

1. `README.md` ↗
   GitHub · assembly-101/assembly101-download-scripts · 01835b08ae

   recording / camera 與感測版本

   L1–29 · L67–103

---

2. `README.md` ↗
   GitHub · assembly-101/assembly101-annotations · 01651287ee

   兩種標註粒度與 30fps

   L1–25

---

3. `coarse-annotations/README.md` ↗
   GitHub · assembly-101/assembly101-annotations · 01651287ee

   coarse 字典、toy split 與片段格式

   L1–87

---

4. `fine-grained-annotations/README.md` ↗
   GitHub · assembly-101/assembly101-annotations · 01651287ee

   fine 字典與欄位

   L1–56

---

5. `README.md` ↗
   GitHub · assembly-101/assembly101-mistake-detection · 6f3a953267

   後續錯誤標註及其來源

   L1–81

---

6. README.md ↗
   GitHub · assembly-101/assembly101-temporal-action-segmentation · 1ef3e0abbb

   feature 與 augmentation 條件

   L1–72

---

7. utils.py ↗
   GitHub · assembly-101/assembly101-temporal-action-segmentation · 1ef3e0abbb

   MoF / edit / segment F1 實作

   L68–78 · L89–99 · L107–154 · L165–231 · L271–312 · L383–416

---

8. README.md ↗
   GitHub · assembly-101/assembly101-action-anticipation · 7ae5cf6328

   預測倉庫身份

   L1–16

---

9. tempAgg-action-anticipation/evaluate.py ↗
   GitHub · assembly-101/assembly101-action-anticipation · 7ae5cf6328

   評分維度與分數格式

   L1–105

---

10. tempAgg-action-anticipation/utils/challenge.py ↗
    GitHub · assembly-101/assembly101-action-anticipation · 7ae5cf6328

    逐類 top-k recall 與子集

    L1–17 · L35–56 · L111–128 · L145–161 · L169–187

---

11. README.md ↗
    GitHub · assembly-101/assembly101-action-recognition · 00d3c3bb3a

    recognition 倉庫身份

    L1–16

---

12. `TSM-action-recognition/ops/dataset.py` ↗

    GitHub · assembly-101/assembly101-action-recognition · 00d3c3bb3a

    片段 frame 取樣

    L14–45 · L49–99

怎麼接入我們的benchmark

可重用

原生粗 / 細字典、toy/view/sequence 身份、跨 toy 切分、錯誤原因與 temporal evaluator。

需要轉換

一個 recording 連多視角 case，分開 fine/coarse/mistake annotation schema；30fps 動作與 60fps pose 顯式對時。evaluator 儲存 label universe、背景類別、tail/unseen、augmentation 及 macro/micro 聚合，錯誤與修正另連到原程式上下文。

仍需補齊

尚未取得影片、LMDB、cleaned pose 或執行指標。mistake 倉庫 tree 無 Python，發布的是標註並指向後續論文，不能當成已提供錯誤檢測 baseline。anticipation 固定 1064 actions / 17 verbs / 90 objects，需核對其 CSV 子集，不能直接套用完整 1380 / 24 字典；缺題檢查被註解，需 adapter 外層驗證。

P016 · IKEA ASM

The IKEA ASM Dataset: Understanding People Assembling Furniture through Actions, Objects and Pose

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

IKEA ASM 的 GitHub 包含影片 / 姿態 / 零件處理工具與多項視覺 baseline。本次核讀動作資料庫、片段轉 frame 和具體評分，另確認 tracking 入口依賴 MOT evaluator。

> **版本與身份**
>
> 倉庫解析名稱為 IkeaASM/IKEA_ASM_Dataset；README 保留早期 dev wording，但已存在實際處理 / 評分程式，不能標為只有計畫。物理組裝成功不由影格辨識 accuracy 證明。

領域	居家整理與清潔、裝配與生產作業
環境	人類組裝 IKEA 傢俱的多視角 RGB/depth 影片；scan_path 與 dev1/dev2/dev3 相機分開，預設 train_cross_env/test_cross_env 是來源切分條件。
任務	原子動作辨識與時間定位、人體姿態、零件分割 / 追蹤。frame/clip/pose-based 是模型輸入方式，不是三批新任務。背景 NA 不算傢俱組裝任務。
題數與資料	SQLite videos/annotations 表以 video_id 關聯；indexing_files 的動作與動作物件關係共同排序，索引 0 插入 NA。ActivityNet 外形 JSON 的 database/annotation 或 results 內 segment 在此 loader 直接切 current_labels[start:end]，實際為 frame index，不能因格式名稱就當秒。
評估方式	動作 evaluator 對每影片先算 frame top-1/top-3 和 balanced accuracy 再平均，並呼叫 ANET detection/classification AP。tIoU 閾值為 .1,.2,.3,.4,.5,.55 至 .95；eval_utils 以真正交集 / 聯集及 interpolated P/R 積分。tracking 入口採 dev3 的 MOT 格式並呼叫 motmetrics，細部 matching 尚未完整核讀。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **5** 錄製環境 · 原文頁 4
- **4** 傢俱種類 · 原文頁 4
- **371** assembly scans · 原文頁 4
- **1,113** RGB視角影片 · 原文頁 4

- **117** test assembly scans · 原文頁 4

依這個順序讀

1. `README.md` ↗
   GitHub · IkeaASM/IKEA_ASM_Dataset · 6fc2d9ea67

   精確論文身份、多模態資產與子任務

   L1–78

---

2. `action/README.md` ↗
   GitHub · IkeaASM/IKEA_ASM_Dataset · 6fc2d9ea67

   baseline 輸入與原生 split

   L1–64

---

3. `action/IKEAActionDataset.py` ↗
   GitHub · IkeaASM/IKEA_ASM_Dataset · 6fc2d9ea67

   SQLite、字典排序、frame labels 與相機

   L22–100 · L160–226 · L310–346

---

4. `action/evaluation/evaluate.py` ↗
   GitHub · IkeaASM/IKEA_ASM_Dataset · 6fc2d9ea67

   實際指標與聚合

   L1–112

---

5. `action/evaluation/eval_utils.py` ↗
   GitHub · IkeaASM/IKEA_ASM_Dataset · 6fc2d9ea67

   top-k、tIoU 與 AP 核心公式

   L1–92

---

6. `part-tracking/eval.py` ↗
   GitHub · IkeaASM/IKEA_ASM_Dataset · 6fc2d9ea67

   MOT 子任務入口

   L1–28

怎麼接入我們的benchmark

可重用

SQLite / split 索引、動作字典、frame segment 轉換及原生動作評分流程。

需要轉換

scan→camera→frame 建來源關聯，任務字典保留排序與 NA。case 記原始 frame 邊界與相機、輸出 logits 和片段分數；每影片平均與全 frame pooled 的統計分開，pose/tracking 另建 evaluator。

仍需補齊

尚未取得 SQLite、影片、校準與標註或執行。姿態、分割與完整 MOT matching 需後續獨立 adapter。README 的 evaluate 路徑與 tree 中 evaluation 不同；入口解析 testset_filename 但建立 Dataset 時未顯式傳入，需確認實際 split 生效方式。

P017 · HOI4D

HOI4D: A 4D Egocentric Dataset for Category-Level Human-Object Interaction

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

HOI4D 有可直接利用的 room、layout、物件與任務路徑，原生任務表也已核讀；後續 semantic/action segmentation challenge 的張量與類別空間需獨立儲存。

> **版本與身份**
>
> 三倉庫均引用同一 HOI4D 論文；兩個 challenge 倉庫同時引用後續 PPTr，不表示這些程式和首版論文的所有協定完全相同。task 表的 T1–T6 是來源內編碼，與本計畫舊 T 模組無關。
>
> Instructions 的精確標題 / 作者 / 官方專案連結及兩個 challenge README 的同題引用、hoi4d.top 指向一致；保留各自 repo 角色。

領域	居家整理與清潔
環境	路徑 ZY/H/C/N/S/s/T 分別代表 camera、human、object class、object instance、room、room layout、task。S 與 s 才提供實體房間 / 佈局身份，T 不可計為新環境。
任務	task_definitions.csv 按 16 個物件類別列 T1–T6，含取放、開關、切割、倒水、收納、裝訂等；有 N/A 和相同文字重複欄位。T 編號僅在物件類別內有意義，不能把列×欄或動作 segmentation label 當通用任務總數。
題數與資料	align_rgb/depth、objpose JSON、action/color.json、raw_pc/label.pcd、相機 output.log、motion masks 與 MANO pose 各自保留。CAD 的 canonical frame 定義物件姿態；MANO 轉米時除 1000。action challenge HDF5 讀 pcd/center/label，與原始 RGB-D 資料是加工關係。
評估方式	semantic test_seg.py 去掉輸出 channel 0/1、回加 label offset=2，再聚合各類 intersection/union；跳過 0/1 與 GT 無樣本類，計 macro accuracy/mIoU。action train_p4.py 用 frame accuracy、segment edit 與 F1@.1/.25/.5，結果還依 batch 聚合。公開 challenge 輸出形狀分別 (892,300,8192) 與 (892,150)，是序列×時間×點或序列×時間，不能當任務類別數。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **610** 錄製rooms · 原文頁 1
- **800** 物件例項 · 原文頁 1

- **16** 物件類別 · 原文頁 1
- **4,000** sequences · 原文頁 1
- **376** 4D分割影片子集（含train/test） · 原文頁 8

依這個順序讀

1. `README.md` ↗
   GitHub · leolyliu/HOI4D-Instructions · 15478666c4

   資料路徑、姿態與空間資產約定

   L1–113 · L133–169

---

2. `definitions/task/task_definitions.csv` ↗
   GitHub · leolyliu/HOI4D-Instructions · 15478666c4

   逐物件原生任務表

   L1–17

---

3. `README.md` ↗
   GitHub · hoi4d/HOI4D_SemSeg · 66df3ff3f0

   challenge 身份與輸出 shape

   L1–55

---

4. `test_seg.py` ↗
   GitHub · hoi4d/HOI4D_SemSeg · 66df3ff3f0

   label offset、skip 與 mIoU

   L20–28 · L31–55 · L65–100 · L144–166

---

5. `README.md` ↗
   GitHub · hoi4d/HOI4D_ActionSeg · ca779d86ad

   action challenge 格式

   L1–54

---

6. `datasets/AS_base.py` ↗

   GitHub · hoi4d/HOI4D_ActionSeg · ca779d86ad

   HDF5 schema 與 train/test 讀取

   L1–80

---

7. `train_p4.py` ↗

   GitHub · hoi4d/HOI4D_ActionSeg · ca779d86ad

   frame accuracy / edit / F1

   L66–80 · L88–96 · L114–143 · L147–189 · L258–270

怎麼接入我們的benchmark

可重用

room/layout/task 身份、原生任務表、CAD articulation / pose 及 semantic/action 評分。

需要轉換

保留 C+T 複合 task ID 並以 parent source 追溯，N/A 不計數，重複語義僅提出待核對關係。environment 用 S/s，case 記原始序列→challenge HDF5 row 的對映、點取樣與 label mapping；3D/4D segmentation、動作分割與人體姿態分 profile。

仍需補齊

尚未取得 RGB-D、CAD、HDF5 或執行 CUDA baseline；需要 release.txt 和 challenge row-order / sampling 對映、標註時間單位與原生 challenge evaluator 版本核對。不能把具有人類取放標籤的影片當已可執行的機器人題。

P018 · HOT3D

HOT3D: Hand and Object Tracking in 3D from Egocentric Multi-View Videos

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

HOT3D 官方 toolkit 同時服務完整 VRS 序列與 HOT3D-Clips 子集；已核讀 schema、DataProvider 和 BOP 轉換，不把工具可讀取誤寫成已完成評測。 2026-10-11 補讀官方連結的 hand_tracking_toolkit 提交、GT writer 與實際指標 caller；BOP evaluator 仍未核讀。

> **版本與身份**
>
> VERSIONS.md 列 v2 修正 MANO 拇指、v3 更新 visibility，metadata.json 的 version 需隨資料保留。Clips README 對 T_world_from_object 的文字方向與欄位名不一致，已用實際 converter 確認為 model→world 再轉 camera，不直接複製文字說明。 官方專案頁區分 2024 whitepaper / ECCV 2024 hand challenge 與 CVPR 2025 完整論文；此補讀固定 hand_tracking_toolkit@bc628e9286c18444b47a0971a89d075ea6f00747，不宣稱今日 snapshot 就是 2024 伺服器提交或論文全部實驗。README 的 pose 欄名和 run_evaluation.par 與程式的 mano_theta / run_evaluation.py 不同，以已讀 caller/writer 為準；資料 v1–v3、論文 edition 與 evaluator commit 分開儲存。

領域	居家整理與清潔、餐飲與烹飪、辦公與教育、穿戴互動與動作介面
環境	Aria / Quest3 頭戴裝置記錄的手與物件互動；sequence、participant、clip、device、stream 分層。HOT3D-Clips 為同一資料的 5 秒 / 150 frame 子序列，多個 image streams 不是獨立環境。
任務	3D 手 / 物件追蹤與姿態、手形估計；BOP object pose 與手部 pose/shape challenge 使用不同 GT 可見性。動態 object onboarding 只給首影格 GT，靜態 onboarding 每影格給 GT。
題數與資料	完整資料用 VRS+CSV providers；clip tar 含 image_STREAM、cameras/hands/hand_crops/objects/info JSON，__hand_shapes 跨 frame 共享。clip_definitions 連原 sequence/device/timestamp；clip_splits 有 train、test_ht_pose、test_ht_shape，test_bop 是兩個 test 的聯集。相機有 fisheye 模型、projection_params、wxyz quaternion，時間為 ns。 2026-10-11 補讀：實際 pose JSON 使用 sequence_name、frame_id、mano_theta[15]、wrist_xform[6]、hand_side（0 左 / 1 右）；wrist 前三項送 global_orient，後三項是米制平移。shape JSON 用 mano_beta[10]，GT writer 每 clip 只存一份左右手共用 shape。HOT3D README 規定 frame_id=0,10,20…；GT writer 的 --every-n-frames 預設 1，須顯式對齊 challenge 抽樣。

評估方式	已核公開格式轉換及hand_tracking_toolkit所列pose / shape評分鏈；完整BOP評分器不在本篇列出的閱讀範圍。BOP converter 實際以 inverse(T_world_from_camera) @ T_world_from_object 得模型到相機姿態，平移乘 1000 成毫米，XYXY 轉 XYWH；visib_fract 取 modeled/predicted 可見性的最小值。不在 stream 範圍的物件以 -1 pose、空 mask、0 visibility 佔位，不能當真實姿態。 Hand tracking的實際呼叫鏈為 scripts/run_evaluation.py→evaluate→compute_overall_*→compute_pose_metrics/compute_shape_metrics。pose 用 GT mano_beta 搭配預測 pose / wrist 做 MANO FK，20 點移除 wrist 後評 19 點並乘 1000 成毫米；實際回傳 MPJPE、PCK_AUC、FINGERTIP_PCK_AUC，沒有 docstring 所列的 MPVPE。PCK 用誤差≤閾值，0–50 mm 共 101 點，曲線乘 100 後以梯形面積除 50，保留 0–100 尺度；五指尖另算。pose 依 GT landmarks 列數（手 / 影格樣本，未必是唯一影格數）加權；shape 在零 pose / 零 wrist 的左手模型算 MPVPE(mm)，再等權平均序列。未提交某 dataset 的整份結果檔會略過，不是零分。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **1** mocap lab · 原文頁 4
- **4** 情境佈置型別 · 原文頁 4
- **33** 剛體物件模型 · 原文頁 4
- **3,832** curated clips（train+test） · 原文頁 4
- **1,028** test clips · 原文頁 4

依這個順序讀

1. `README.md` ↗
   GitHub · facebookresearch/hot3d · 146b34afef

   完整序列與 clips 工具身份 / 入口

   `L1–78 · L115–162 · L207–248`

2. `hot3d/clips/README.md` ↗
   GitHub · facebookresearch/hot3d · 146b34afef

   tar schema、GT 可見性與 split 聯集

   `L1–150`

3. `hot3d/dataset_api.py` ↗
   GitHub · facebookresearch/hot3d · 146b34afef

   必需資產檢查與 providers

   L37–115 · L192–240

---

4. `hot3d/clips/bop_format_converters/hot3d_clips_to_bop_scenewise.py` ↗
   GitHub · facebookresearch/hot3d · 146b34afef

   座標 / 單位 / visibility 的實際轉換

   L104–114 · L125–154 · L183–219 · L223–244 · L246–276 · L301–311 · L320–337 · L346–369

---

5. `VERSIONS.md` ↗
   GitHub · facebookresearch/hot3d · 146b34afef

   v1–v3 標註版本

   L1–9

---

6. `README.md` ↗
   GitHub · facebookresearch/hand_tracking_toolkit · bc628e9286

   官方 hand challenge 身份、HOT3D 每十影格的提交範圍、pose / shape 分軌與本地驗證限制。

   L1–9 · L64–80 · L148–260

---

7. `scripts/run_evaluation.py` ↗
   GitHub · facebookresearch/hand_tracking_toolkit · bc628e9286

   真實命令入口呼叫 evaluation.evaluate；README 的 .par 範例與檔案 .py 不同。

   L15–48

---

8. `hand_tracking_toolkit/submissions.py` ↗
   GitHub · facebookresearch/hand_tracking_toolkit · bc628e9286

   實際 JSON writer：mano_theta 15 維、wrist_xform 6 維、mano_beta 10 維、hand_side 和 20 點 GT。

   L27–105

---

9. `scripts/write_annotations_files.py` ↗
   GitHub · facebookresearch/hand_tracking_toolkit · bc628e9286

   GT 由 UmeTrack FK 產生，按 clip_splits 選 Aria / Quest3；every-n-frames 預設 1，每序列只存一次 shape。

   L38–142

---

10. `hand_tracking_toolkit/evaluation.py` ↗
    GitHub · facebookresearch/hand_tracking_toolkit · bc628e9286

    追完整 pose / shape caller、GT shape 注入、依 GT 列數或依序列聚合，以及缺少 dataset 結果檔的跳過規則。

    L50–110 · L113–237 · L280–311

---

11. `hand_tracking_toolkit/metrics.py` ↗
    GitHub · facebookresearch/hand_tracking_toolkit · bc628e9286

    核讀實際回傳指標、19 點去腕 / 五指尖、米→毫米、0–50 mm PCK 曲線與 canonical shape MPVPE。

    L30–56 · L59–321

---

12. `hand_tracking_toolkit/hand_models/mano_hand_model.py` ↗
    GitHub · facebookresearch/hand_tracking_toolkit · bc628e9286

    MANO PCA pose、6 維 global transform 的位置 / 方向分量、21→20 點原生對映及左右手 FK。

    L52–120 · L137–174 · L233–274

怎麼接入我們的benchmark

可重用

VRS/clip schema、物件 / 手模型、同步時間、GT 可見性 split 與 BOP 轉換。 可另接手部提交 writer、原生 19 點 / 指尖 PCK 和 canonical shape MPVPE；各自保留聚合單位。

需要轉換

保留 full→clip→frame→stream ancestry，BOP scene_id 映回 clip_id 而非新增實體場景。座標轉換記明方向、米 / 毫米、相機畸變模型和 visibility 來源；測試缺 GT 依 track 顯式標 unknown，不填零。 手部 case 保留 clip/sequence_name、frame_id、hand_side、抽樣步長、GT shape 是否已知、PCA pose / wrist 向量格式及 mm/AUC 尺度；不與 BOP 物件姿態合成共同成功率。

仍需補齊

尚未取得 VRS、tar、物件 / MANO 模型、外部 BOP / 手評測套件或執行。需為外部 evaluator 另釘選提交，驗證相機畸變、時間同步和 -1 佔位規則。 更新：手 evaluator 的選定原始碼已取得並釘選，但隱藏 GT、MANO 資產、BOP 套件與執行仍未完成。caller 僅按 sequence_name 分組及 frame_id 排序後逐列相減，未顯式按 frame_id/hand_side join；接線須驗證缺列、重複影格與同影格左右手順序。本地自選 train 子集也不是官方 validation split。

P019 · EgoBody

EgoBody: Human Body Shape and Motion of Interacting People from Head-Mounted Devices

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoBody 官方倉庫主要是資料檔案與視覺化 / 座標轉換工具；它有真實來源程式，但沒有在此釘選 tree 找到公開 challenge evaluator。

> **版本與身份**
>
> README 包含 2022 全模態釋出與 2023 Motion-X 文字擴充；主程式 calibration 路徑多一層 cal_trans，需以實際下載版本核對。讀過視覺化程式不等於重現 README 的 baseline 成績。

領域	休閒與運動、社交與溝通、穿戴互動與動作介面
環境	HoloLens 與 Azure Kinect 同步拍攝室內雙人互動。檔案分 125 sequences、36 subjects、15 scenes；環境以 scene_name/mesh 追溯，EgoSet、MVSet、interactee-visible 子集不是三批新場景。
任務	第一人稱觀察互動物件 / 穿戴者的 3D 人體 pose、shape、motion。Motion-X 的後加文字描述是衍生標註，不能直接視為原版任務或機器人協作成功。
題數與資料	data_info_release.csv 含 recording_name、body_idx_fpv、start/end_frame、scene_name，data_splits.csv 定義 sequence split。PV 影像名以 timestamp_frame 連 Kinect frame；pv.txt 提供每 frame 的 fx/fy/pv2world，keypoints.npz 有 BODY_25、center、scale；valid_frame 以至少 6 個 OpenPose 關節為可見條件。SMPL/SMPL-X 引數在 master Kinect RGB 座標。
評估方式	README 列 MPJPE、PA-MPJPE、V2V、PA-V2V 原作者結果與 challenge 連結；本次沒有取得其精確 scoring 實作，因此不能由渲染器推定對齊 / 遮罩 / 單位的評分規則。核讀渲染器確認 Kinect→HoloLens world→PV 變換及 OpenCV/OpenGL Y/Z 翻轉。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **15** 室內scene · 原文頁 9
- **125** sequences · 原文頁 9
- **175,611** EgoSet-interactee影格 · 原文頁 10

- **62,155** interactee test影格 · 原文頁 10

依這個順序讀

1. `README.md` ↗
   GitHub · sanweiliti/EgoBody · e3ecbb839d

   資料身份、scene/sequence/subset、欄位與 evaluator 可見範圍

   `L1–90 · L96–185 · L209–263`

---

2. `release_renderer_fpv_gaze.py` ↗
   GitHub · sanweiliti/EgoBody · e3ecbb839d

   split 與 frame 邊界、校準、座標方向與可見性

   `L37–46 · L65–77 · L94–109 · L116–137 · L139–157 · L175–183 · L192–198 · L214–220 · L225–237 · L246–260 · L272–278 · L287–301 · L324–332`

怎麼接入我們的benchmark

可重用

場景 / recording/split 索引、時間同步、有效影格、人體引數與相機轉換流程。

需要轉換

scene_name 作 environment 關聯，recording 與人物角色分開；case 保留 timestamp/frame、相機和 body index。EgoSet_interactee 作同源 subset；範圍外 frame 依 start/end 丟棄，另記 valid 遮罩。pose shape profile 保留 SMPL 與 SMPL-X 模型版本。

仍需補齊

尚未取得註冊後資料與人體模型，亦未執行或取得 challenge evaluator。需補齊原作的關節集合、對齊、可見性與 mesh error 協定，再標可評測。

P020 · EgoHumans

EgoHumans: An Egocentric 3D Multi-Human Benchmark

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoHumans 官方倉庫提供多人體資料處理、COCO-video 轉換與追蹤評測。已沿 tracking 檔案追到內含 MMTracking 的 dataset evaluator 與 MOT matching。

> **版本與身份**
>
> 作者 TRACKING.md 說因 PyTorch 升級，公開結果與原論文有約 1% 變動；不能將當前程式當原表格的逐位重現。所核讀的 external/MMTracking 檔案是正式入口依賴，其他內嵌模型 / 資料集未據此宣稱全數讀完。

領域	休閒與運動、社交與溝通、穿戴互動與動作介面
環境	穿戴 Aria 與外部相機同步記錄多人活動，含網球、擊劍等；big_sequence/subsequence、相機與人物分層。拼接 COCO video 或增加 ego_slam/exo 視角不新增實體環境。
任務	多人偵測、2D/3D pose、mesh 和身份追蹤；主要 tracking 比較以 ego_rgb 和指定 detector 條件進行。GT bbox 與 YOLOX bbox 是不同合法輸入條件。
題數與資料	coco_video_format.py 以 parent_sequence+sequence+camera+mode 建 video_name；image 有 image_id/video_id/frame_id，annotation 保留 human_name/camera_name/camera_mode/time_stamp，instance_id 由 aria 人名解析，bbox 用 XYWH。frame_id 在可納入影像序列內重新編號；無有效人框的 frame 會被跳過。MiDaS 深度 / 3D root 是加工輸出，不是直接測量深度。
評估方式	CocoVideoDataset 按 frame_id==0 分影片並檢查 track_bboxes 長度；eval_mot 用 1-IoU 距離、預設 .5 門檻、ignore IoF 和 MOTAccumulator，輸出 IDF1/MOTA/MOTP/FP/FN/IDSw 等。MOTP 在此轉成 1-distance，方向與底層距離不同；全體累積結果與逐類平均需分開。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **6** 錄製地點 · 原文頁 6
- **7** 活動sequences / 型別 · 原文頁 6
- **47,740** test ego影像 · 原文頁 6

依這個順序讀

1. `README.md` ↗
   GitHub · rawalkhirodkar/egohumans · d7875dd4b3

   論文身份、活動及 benchmark 角色

   L1–82

---

2. `assets/TRACKING.md` ↗
   GitHub · rawalkhirodkar/egohumans · d7875dd4b3

   原作 tracking 和 GT/detector 條件

   L1–33

---

3. `assets/COCO_VIDEO.md` ↗
   GitHub · rawalkhirodkar/egohumans · d7875dd4b3

   COCO video 加工與深度來源

   L1–61

---

4. `egohumans/tools/create_benchmark/coco_video_format.py` ↗
   GitHub · rawalkhirodkar/egohumans · d7875dd4b3

   原始人物 / 影格到評測 ID 的轉換

   L35–41 · L43–77 · L84–90 · L109–141 · L145–152 · L155–178 · L188–225 · L228–241 · L263–335

---

5. `scripts/benchmarks/tracking/0_test_tracking.sh` ↗
   GitHub · rawalkhirodkar/egohumans · d7875dd4b3

   實際 MMTracking 入口與子集設定

   L1–130

---

6. `egohumans/external/mmtracking/mmtrack/datasets/coco_video_dataset.py` ↗
   GitHub · rawalkhirodkar/egohumans · d7875dd4b3

   分影片與 evaluator 呼叫

   L5–13 · L240–254 · L363–453

---

7. `egohumans/external/mmtracking/mmtrack/core/evaluation/eval_mot.py` ↗

   GitHub · rawalkhirodkar/egohumans · d7875dd4b3

   IoU matching、ignore 與 MOT 聚合

   `L2–20 · L28–82 · L87–93 · L100–139 · L147–161 · L179–185 · L188–194 · L218–227`

怎麼接入我們的benchmark

可重用

COCO-video 轉換、原人物 ID / 時間、tracking 輸入條件與內含 MOT adapter。

需要轉換

environment 留真實錄製 / subsequence，video ID 只作觀測序列；維持原 time_stamp 到重編 frame_id 的對照。case/evaluator 記 detector、GT bbox 可用性、ego_rgb/ego_slam/exo、深度來源、忽略區域與匹配閾值，跨拼接需重新命名 instance ID 並儲存原值。

仍需補齊

尚未取得影像、pose、MiDaS 加工資料 / 模型或執行；主要驗證流程需固定設定檔與 detector 輸出。2D/3D pose 和 mesh benchmark 的完整 evaluator 不包含在這次 tracking 核讀範圍。

P021 · Ego-ExoLearn

EgoExoLearn: A Dataset for Bridging Asynchronous Ego- and Exo-centric View of Procedural Activities in Real World

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoExoLearn 的核心是不同時間、不同視角的人類示範跟隨。已核讀標註、跨視角 association 的選項評分和 skill assessment 的成對排序，兩者不是同一種成功率。

> **版本與身份**
>
> annotations README 開頭仍說只有 train/val，結尾與 root 更新已提供 test GT；標準化應鎖定實際檔案，不直接採信舊段落。VQA 與 full-size videos 為後續更新，不能併稱首發版本。

領域	餐飲與烹飪、實驗室操作
環境	資料列 kitchen / lab，用於日常協助與實驗室程式；scene 是粗場景用途，video_uid 才是影片 ID。ego/exo 是非同步示範關係，不可當同步多相機標定資料。
任務	跨視角 association、動作分割 / anticipation / planning、參考示範的 skill assessment / captioning；2024-08 又加入 VQA。能力題型與程式活動類別分開。
題數與資料	fine CSV 保留 video_uid、annotation_uid、subset、view、scene、start/end_sec、人工 narration_en；hand/no-hand prompt 文字是 GPT 改寫。skill list 每列 better/worse 影片，NPZ arr_0 提供特徵，use_exo 時依 action 從 exo 檔案隨機選一參考。association loader 回 query、options、answer、q_type、uid。
評估方式	association 對 query/options 特徵相似度 argmax，按 Ego→Exo / Exo→Ego 分組 accuracy；skill train.py 的 accuracy 是 better 分數嚴格大於 worse 的配對比例，平手不算對。RankingAttentionLoss 為訓練 loss，不能拿它代替評測 accuracy。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **7** ego錄製場地（4廚房+3lab） · 原文頁 3
- **8** 程式任務 · 原文頁 3
- **747** ego+exo影片 · 原文頁 3
- **34,239** 有效skill比較對（含所有split） · 原文頁 4

- **17,300** ego anticipation test片段 · 原文17.3K，約數 · 原文頁 12

依這個順序讀

1. `README.md` ↗
   GitHub · OpenGVLab/EgoExoLearn · e1f11b1ab1

   精確論文身份、場景與發布範圍

   L1–78

---

2. `annotations/README.md` ↗
   GitHub · OpenGVLab/EgoExoLearn · e1f11b1ab1

   原生 CSV、生成文字與 test 版本

   L1–31

---

3. `association_benchmark/main.py` ↗
   GitHub · OpenGVLab/EgoExoLearn · e1f11b1ab1

   實際 association 輸入與雙向 accuracy

   L33–51 · L54–84 · L102–110 · L137–147 · L166–181 · L275–336 · L342–364

---

4. `skill_benchmark/dataset.py` ↗
   GitHub · OpenGVLab/EgoExoLearn · e1f11b1ab1

   better/worse 與隨機 exo 讀取

   L1–117

---

5. `skill_benchmark/train.py` ↗
   GitHub · OpenGVLab/EgoExoLearn · e1f11b1ab1

   validation 聚合與嚴格成對比較

   L147–166 · L230–253 · L260–281 · L298–313 · L353–361 · L381–420 · L463–476

---

6. `skill_benchmark/losses.py` ↗
   GitHub · OpenGVLab/EgoExoLearn · e1f11b1ab1

   辨別訓練 ranking loss

   L1–22

怎麼接入我們的benchmark

可重用

原生標註 / 改寫來源、跨視角配對、better/worse 排序與兩種核心評分。

需要轉換

保留 demo_reference 邊及不同 video 時間線；同一影片多問答 / 配對透過 uid 共用，不能重算成新環境。case 儲存配對順序、選項、exo reference 與抽樣 seed；人工與生成字幕 provenance 分開。

仍需補齊

尚未取得影片 / gaze / 特徵或執行。完整 segmentation/planning/captioning 與新增 VQA evaluator 尚未核讀；若比較參考示範版本，需鎖定具體 exo reference，不能每次隨機抽而不留紀錄。

P022 · CaptainCook4D

CaptainCook4D: A Dataset for Understanding Errors in Procedural Activities

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

CaptainCook4D 主倉庫是入口；已追到官方 annotations 與 error_recognition 程式，核讀原始步驟 JSON、mug cake 圖、loader 及實際 step/sub-step metrics。

> **版本與身份**
>
> Error-Dataset/annotations 轉向 CaptainCook4D/annotations；2023 初版與 2024 最終 baseline / 2025 衍生工作分開。主 repo 無 Python 不能推定整項無程式，實作在其明確連結的子倉庫。

領域	餐飲與烹飪
環境	真實廚房中遵循食譜或刻意誘發錯誤的錄製。recording、recipe、person、environment split 分別管理；同一食譜多錄製是 case，不自動增加獨立任務。
任務	error recognition、early error recognition、多步定位 / 程式學習；task_graph 的 steps/edges 可保留先後與選擇限制。loader 另有五類錯誤 one-vs-rest 標籤及 has_errors，未出現 / 負時間步驟不當作已觀察完成。
題數與資料	step_annotations 以 recording_id 連 steps 的 step_id、start/end_time、description、has_errors；error_annotations 另連多個 errors.tag。ImageBind 特徵按 2 秒索引，其他 backbone 按 1 秒；floor/ceil 後切片，同一 step 多次出現會串接。early 只取前半特徵；recording 12_6 在 ImageBind 分支因無特徵跳過。
評估方式	base.py sub-step 以 sigmoid>.5 算 accuracy/P/R/F1，ROC-AUC 用連續分數，但 PR-AUC 實際餵二值預測。step 層取每個 loader batch 的平均分數，再可選全測試集 min-max 正規化，以 threshold 判斷；GT 平均>.95 才當 error。README 報 step split=.6、recording=.4，core/evaluate.py 目前掃 .5/.6，需固定原作條件。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **10** 錄製廚房 · 原文頁 4
- **24** 食譜 · 原文頁 3
- **7** 錯誤類別 · 原文頁 4, 5

- **384** recordings · 原文頁 1

依這個順序讀

1. `README.md` ↗
   GitHub · CaptainCook4D/CaptainCook4D · 1137b884e0

   論文身份、真正的標註及 baseline 連結

   L1–75 · L112–173 · L230–320

---

2. `README.md` ↗
   GitHub · Error-Dataset/annotations · a8a920a329

   官方 annotation 倉庫與版本

   L1–131

---

3. `annotation_json/step_annotations.json` ↗
   GitHub · Error-Dataset/annotations · a8a920a329

   原生步驟 JSON 樣本

   L1–54

---

4. `task_graphs/mugcake.json` ↗
   GitHub · Error-Dataset/annotations · a8a920a329

   完整單一 recipe steps/edges 範例

   L1–1

---

5. `README.md` ↗
   GitHub · CaptainCook4D/error_recognition · 35ef284a67

   評測 split 與作者閾值

   L1–36

---

6. `dataloader/CaptainCookStepDataset.py` ↗
   GitHub · CaptainCook4D/error_recognition · 35ef284a67

   步驟 / 錯誤欄位、時間取樣與 split

   L1–4 · L8–20 · L22–32 · L34–53 · L59–145 · L149–169 · L171–376

---

7. `core/evaluate.py` ↗

   GitHub · CaptainCook4D/error_recognition · 35ef284a67

   入口、閾值掃描與 checkpoint 條件

   L1–59 · L71–138 · L148–164 · L171–179

---

8. `base.py` ↗

   GitHub · CaptainCook4D/error_recognition · 35ef284a67

   真正的 step/sub-step 聚合與 metric 輸入

   L10–20 · L75–93 · L117–130 · L179–189 · L342–400 · L406–425 · L427–437 · L440–463

怎麼接入我們的benchmark

可重用

24 份 recipe graph 的路徑清單、逐步錯誤 schema、split 型別及 error / early 的資料流程。mugcake.json 作為已逐項閱讀的 task graph 範例；其他 graph 不能據此宣稱內容全審。

需要轉換

case ID 用 recording+step+occurrence，保留完整秒數、重複片段及合併規則；source 關聯原始影片、特徵與 graph。error labels、early prefix、step/recording/person/environment split 分欄；評分儲存閾值、min-max、batch_size 和二值 PR-AUC 的原始行為。

仍需補齊

尚未取得影片 / 特徵、執行評分或核讀 zero-shot/multi_step_localization 全實作。step 切分內 phase=test/val 對應片段命名互換，應以實際索引存檔；batch 必須維持單一步驟，否則 collate 後 batch 被當 step。程式保留作者絕對路徑、手選 epoch 表和 start-end>1 條件，均需 adapter 驗證與差異記錄。

P023 · EgoProceL

My View is the Best View: Procedure Learning from Egocentric Videos

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoProceL 是程式學習資料與 CnC 方法的共同發布；它明確重用 CMU-MMAC、EGTEA、MECCANO、EPIC-Tent 並加入電腦組拆。已核讀資料來源、PC Assembly loader 和主評分呼叫。

> **版本與身份**
>
> download README 明列舊 OneDrive 過期與新 Google Drive，並說父庫只有部分影片被使用；以新程式標註清單作 subset 證據。PC_Assembly.py 開頭註解仍寫 MECCANO，但類別及配置實際為 PC_Assembly。

領域	餐飲與烹飪、工藝與修繕、裝配與生產作業、農業與園藝
環境	烹飪、玩具 / 電腦組拆、帳篷搭建等人類程式影片；parent dataset→category→video 需要保留。16 個原生 task 是程式活動，不是 16 個獨立房間或全部錄製環境。
任務	由同一程式多段影片學習 key-step 與次序，包含缺步、重複步和背景。重用父資料的影片被加上程式標註，不可和父庫相加當全新影片。
題數與資料	CSV 與原影片同名，三欄為 step 起始秒、結束秒、step 名；子集按來源 / category 分目錄。PC_Assembly loader 配對影片與標註、抽 HDF5 frames/labels；train/val/test 分支尚為 NotImplemented，真正公開路徑是 mode=all。
評估方式	procedure_learning→gen_print_results→compute_align_MoF_UoI，以 GT/pred frame overlap 做 Hungarian cluster-label assignment，再計 MoF/IoU/precision；per_keystep 模式排除無 GT 類別並平均。另有 procl_eval 函式實作補上未配對類別的 P/R/F1，但不是本主入口呼叫，二者不混用。GT 用於事後 cluster 對齊不代表模型已輸出語義標籤。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **16** 程式任務 · 原文頁 1, 5
- **62** 影片小時 · 原文頁 1, 5
- **130** 參與者 · 原文頁 1

依這個順序讀

1. `README.md` ↗
   GitHub · Sid2697/EgoProceL-egocentric-procedure-learning · bf4d9c2e7a

   精確論文身份、原生 task 與四項父資料

   L1–96 · L126–158

---

2. `EgoProceL-download-README.md` ↗
   GitHub · Sid2697/EgoProceL-egocentric-procedure-learning · bf4d9c2e7a

   逐來源取得與 CSV 單位

   L1–93

---

3. `datasets/PC_Assembly.py` ↗
   GitHub · Sid2697/EgoProceL-egocentric-procedure-learning · bf4d9c2e7a

   實際 PC 子集 loader 與 split 限制

   L1–95

---

4. `RepLearn/TCC/procedure_learning.py` ↗
   GitHub · Sid2697/EgoProceL-egocentric-procedure-learning · bf4d9c2e7a

   主流程及子集 key-step 配置

   L1–29 · L31–43 · L121–127 · L160–171

---

5. `RepLearn/TCC/utils.py` ↗
   GitHub · Sid2697/EgoProceL-egocentric-procedure-learning · bf4d9c2e7a

   主入口呼叫哪個 evaluator

   L8–26 · L143–206

---

6. `evaluate/metrics.py` ↗
   GitHub · Sid2697/EgoProceL-egocentric-procedure-learning · bf4d9c2e7a

   Hungarian assignment 與聚合差異

   L1–243

怎麼接入我們的benchmark

可重用

父資料重用清單、原生秒制 step CSV、PC 組裝新來源與聚類評分。

需要轉換

source→parent video→新 annotation 建 ancestry；task 記來源內 category，case 是指定多影片集合 / 取樣與合法 GT 使用範圍。cluster ID 儲存 Hungarian assignment 作評分證據；K、背景、per_keystep 與全體聚合明列。

仍需補齊

尚未取得影片 / 標註、產生 HDF5 或執行。需要逐子集對應原影片及相同 frame 取樣；不能自行發明 train/test split 或把 mode=all 的結果標為未見環境泛化。

P024 · EPIC Fields

EPIC Fields: Marrying 3D Geometry and Video Understanding

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EPIC Fields分成重建/讀取工具與NVS、UDOS評測；epic-fields本身只是網頁倉庫，不能當作評測程式。

> **版本與身份**
>
> 評測README明示2024-02-10標註更新，並給前版commit；原始arXiv與新版不能混用。

領域	居家整理與清潔、餐飲與烹飪
環境	相機與點雲是影片觀測幾何；video-scene與原廚房一對多，不能每影片都新增可操作環境。
任務	NVS、動態/半靜態分割、VISOR衍生VOS是不同資訊/世界模型評測端點。
題數與資料	JSON的camera採COLMAP/OpenCV內參，images為qw-first quaternion加translation的world-to-camera，points含XYZRGB。評測另需EPIC100影格、mask、split與模型cache。
評估方式	NVS先逐影片平均PSNR再跨影片平均，前景/背景僅在適用within-action列出。UDOS依有效mask畫素算AP、排除無有效標籤影格，motion型別分報。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **45** 上游錄製廚房 · 原文頁 3
- **671** 重建影片 · 原文頁 3
- **18,790,333** camera-pose影格 · 原文頁 3
- **50** D-NVS來源影片 · 原文頁 5, 6

依這個順序讀

1. `README.md` ↗
   GitHub · epic-kitchens/epic-fields · 44b9cf1660

   確認此repo只存網頁。

   L1–2

---

2. `README.md` ↗
   GitHub · epic-kitchens/epic-fields-code · e5cd4fdfbb

   資料schema、W2C與重建流程。

   L1–145

---

3. `README.md` ↗
   GitHub · dichotomies/epic-fields-nvs-udos · 4ac1d11096

   原作評測、下載依賴與標註版本變更。

   L1–79

---

4. `evaluate_nvs.py` ↗
   GitHub · dichotomies/epic-fields-nvs-udos · 4ac1d11096

   NVS輸入範圍、PSNR與聚合。

   L7–18 · L31–39 · L54–79 · L81–129 · L134–175 · L177–185

---

5. `evaluate_udos.py` ↗
   GitHub · dichotomies/epic-fields-nvs-udos · 4ac1d11096

   有效區域與motion mask的AP。

   L3–18 · L36–44 · L53–94 · L96–106 · L111–152 · L154–199 · L201–210

怎麼接入我們的benchmark

可重用

video/frame ID、相機轉換、原生NVS/UDOS split與評分。

需要轉換

明記W2C、qw順序與軸方向；轉NeRF時儲存反轉/翻軸。兩種case的可見輸入、mask與聚合分母分開。

仍需補齊

對應版本的EPIC100素材、標註與模型輸出閉合、影片重用核對和本庫evaluator。

P025 · EgoPet

EgoPet: Egomotion and Interaction Data from an Animal's Perspective

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoPet 分成動物互動 VIP、動物移動 LP，以及四足機器人資料上的 VPP。已核讀三項定義與實際評測，不能把動物影片或 latent 回歸直接算成機器人完成任務。

> **版本與身份**
>
> 主 README 的會議年份文字不可單獨作書目依據，身份由標題 / 作者 / 專案互連確認；LP 文案的 40 點 / 4 秒和命令的 num_pose_prediction=120/fps/pps 需依實際 pose_skip 對映，不能只抄旗標數字。

領域	寵物照護與動物活動
環境	VIP/LP 是動物第一人稱影片；VPP 另用四足機器人在 office/park/beach 的錄製與日夜 / 地面移轉。影片來源、robot episode 與實體地點分層。
任務	VIP 判斷是否互動與 17 種互動物件；LP 預測尺度模糊的未來相對軌跡；VPP 從影像預測 proprioception-derived latent，在 -1.5、-.8、0、.8、1.5 秒條件分項比較。
題數與資料	VIP CSV 含 animal、ds_type、video_id、segment_id、start/end_time、interacting_object、video_path；LP 另存 DPVO stride 和 TUM trajectory。LP loader 用 training_set/validation_set、cat/dog、有效檔案過濾，test 最長截到 50 秒；sample index 不等於完整來源總量。
評估方式	VIP interaction 使用 sigmoid/accuracy/BinaryAUROC；object top-1/top-3 與 macro AUROC 僅在 GT 有互動樣本算。LP 以方向正規化增量預測，重建時乘回 GT 增量尺度，再用 evo align=True/correct_scale=True 的 ATE/RPE RMSE；不是無尺度輔助的導航成功率。VPP validation 用 MSE，loader 設 drop_last=True，分散式補齊可能重複樣本；百分比形式列印的 loss 不表示 accuracy。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **6,646** 動物影片片段 · 原文頁 4
- **695** VIP test片段 · 原文頁 6
- **249** LP validation片段 · 原文頁 7

- **3** VPP機器人測試地點 · 原文頁 7

依這個順序讀

1. `README.md` ↗
   GitHub · DannyTran123/egopet · 478d62327e

   資料與預訓練 / 三項任務角色

   L1–78

---

2. `VIP.md` ↗
   GitHub · DannyTran123/egopet · 478d62327e

   互動標籤、CSV 與物件類別

   L1–91

---

3. `LP.md` ↗
   GitHub · DannyTran123/egopet · 478d62327e

   未來軌跡定義與子集

   L1–91

---

4. `VPP.md` ↗
   GitHub · DannyTran123/egopet · 478d62327e

   四足機器人來源與 horizon

   L1–56

---

5. `locomotion_prediction/locomotion_prediction_dataloader.py` ↗
   GitHub · DannyTran123/egopet · 478d62327e

   有效樣本與時間截斷

   L47–53 · L59–68 · L100–106 · L119–148 · L156–167 · L172–178 · L186–192 · L208–217 · L221–228 · L230–236

---

6. `engine_object_interaction_for_finetuning.py` ↗
   GitHub · DannyTran123/egopet · 478d62327e

   GT-positive 條件與分類指標

   L13–21 · L150–158 · L206–234 · L241–264 · L294–302

---

7. `engine_locomotion_prediction_for_finetuning.py` ↗
   GitHub · DannyTran123/egopet · 478d62327e

   逐片段評分和略過錯誤

   `L1–32 · L149–157 · L181–193 · L195–204`

---

8. `locomotion_prediction/locomotion_prediction_utils.py` ↗
   GitHub · DannyTran123/egopet · 478d62327e

   GT scale、對齊與 ATE/RPE

   `L1–5 · L20–28 · L46–74 · L80–91 · L103–130 · L162–172 · L174–183 · L188–201`

---

9. `eval_adaptation_ds.py` ↗
   GitHub · DannyTran123/egopet · 478d62327e

   robot latent 評測入口

   `L1–40 · L130–136 · L186–192 · L280–288 · L295–301 · L315–326 · L330–341 · L376–382 · L399–441`

---

10. `engine_for_finetuning.py` ↗
    GitHub · DannyTran123/egopet · 478d62327e

    VPP MSE、drop_last 與分散式條件

    `L137–151 · L159–202 · L337–351`

怎麼接入我們的benchmark

可重用

三項原生 task、CSV、軌跡處理與 VIP/LP/VPP 評分流程。

需要轉換

animal source 與 robot transfer source 分開並連 pretraining 關係；case 保留 horizon、fps/pps、DPVO stride、方向 / 尺度、有效樣本、GT scale 使用範圍與 episode split。分類、軌跡 RMSE、latent MSE 保持分項。

仍需補齊

尚未取得影片、DPVO 軌跡、CMS robot 資料或執行。LP 例外只印出後略過，需儲存實際評分 / 失敗清單；VPP 須額外取得 latent 生成版本，不能宣稱提升實體走路成功。

P026 · EgoHOS

Fine-Grained Egocentric Hand-Object Segmentation: Dataset, Model, and Applications

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoHOS 是細粒度手物件分割，第一 / 第二階互動關係和 contact mask 有明確定義。已核讀原生類別、資料配置與實際 MMSegmentation 評分路徑。

> **版本與身份**
>
> 此倉庫內含 MMSegmentation，已釘選其本地版本；不能換成最新版同名套件而不記錄差異。README 中 LaMa / FGVC / homan 等是應用依賴，不是額外 EgoHOS benchmark 來源。

領域	居家整理與清潔、餐飲與烹飪
環境	真實第一人稱影像；來源內明列 train/val/test_indomain/test_outdomain。這裡 domain 指來源分佈測試條件，不直接等於生活用途領域數。
任務	左右手、由左 / 右 / 雙手互動的第一階 / 第二階物件，以及 dense contact。9 個 label IDs 含背景，是畫素類別，不能當 9 個操作任務或物件身份。
題數與資料	資料夾 image/label/contact，EgoHOSDataset 讀 .jpg 和 .png，classes/palette 固定 0–8。handobj2 config 保留背景（reduce_zero_label=False）、padding ignore=255；test 預設 test_indomain，crop/resize 360×480。
評估方式	CustomDataset 預設 mIoU；metrics.py 先套 label map / ignore_index，再累加逐類 intersection、pred、GT、union，算 IoU/Acc，summary 以 nanmean。還支援 Dice/Fscore，但不能由支援函式推定原論文都採用。contact 二值 mask 需用其獨立配置，不與 9-class 平均混算。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **11,243** 分割標註影像 · 原文頁 1, 5, 6
- **500** OOD test影像 · 原文頁 2, 9

依這個順序讀

1. README.md ↗
   GitHub · owenzlz/EgoHOS · cd9bdf427e

   身份、label schema、四個 split 與模型流程

   L1–111 · L152–200

---

2. mmsegmentation/mmseg/datasets/egohos.py ↗
   GitHub · owenzlz/EgoHOS · cd9bdf427e

   實際類別 / palette 與副檔名

   L1–34

---

3. mmsegmentation/configs/_base_/datasets/egohos_handobj2.py ↗
   GitHub · owenzlz/EgoHOS · cd9bdf427e

   背景、ignore 與 split 配置

   L1–59

---

4. mmsegmentation/mmseg/datasets/custom.py ↗
   GitHub · owenzlz/EgoHOS · cd9bdf427e

   實際 mIoU 呼叫與 nanmean 聚合

   L85–93 · L384–392 · L419–427 · L439–447

---

5. mmsegmentation/mmseg/core/evaluation/metrics.py ↗
   GitHub · owenzlz/EgoHOS · cd9bdf427e

   畫素計數與 IoU/Dice/F 定義

   L55–103 · L348–395

怎麼接入我們的benchmark

可重用

原生 label/palette、contact 與 split、實際 dataset→metrics 呼叫。

需要轉換

case 保留來源影像 / split / raw label mask、接觸關係與第一 / 第二階；畫素座標、resize、ignore=255、背景納入和 nan 規則都進 evaluator profile。手物件分割與物理接觸 / 抓取成功不同。

仍需補齊

尚未下載影像、mask、checkpoint 或執行。需取得各 head 配置與來源影片 ID 才能避免跨 split 同源影片；contact 與分階段模型的全部依賴仍須逐配置測試。

P027 · EgoPCA

EgoPCA: A New Framework for Egocentric Hand-Object Interaction Understanding

檔案 / 網站 · 主來源 · 原作 · 獨立頁面

此公開倉庫只有README和LICENSE；README連結匹配的ICCV2023論文，並明寫程式尚待發布。不能把它標成已核讀到資料處理或評測實作。

> **版本與身份**
>
> silicx/EgoPCA固定10364626...的完整tree僅有README與LICENSE；主頁程式發布承諾不是已發布證據。
>
> README自述官方並連到匹配的ICCV論文。

領域	居家整理與清潔、餐飲與烹飪
環境	論文描述多個影片來源；公開倉庫未提供scene或觀測清單。
任務	One4All / EgoPCA的類別與子集需按論文保留；目前無原生清單程式可核。
題數與資料	未見可讀的dataset loader、標註結構或split檔；只有發布佔位檔案。
評估方式	原作accuracy與分析指標見論文；公開樹未提供evaluator，不能宣稱已接通。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **394** pretrain統一類別 · 原文頁 5, 14
- **204** test統一類別 · 原文頁 5, 14
- **10,000** 最大One4All-T子集 · 原文頁 5, 14

依這個順序讀

1. `README.md` ↗

   GitHub · silicx/EgoPCA · 10364626df

   核對論文身份和程式尚待發布的明示狀態。

   L1–5

怎麼接入我們的benchmark

可重用

論文身份、原作來源組成、分類 / 子集定義的引用。

需要轉換

先收source及paper-defined task/type筆記；待正式manifest和checker取得後再建case。

仍需補齊

公開實作、原始標註 / split / 子集清單與可重現評分。

P028 · EgoSchema

EgoSchema: A Diagnostic Benchmark for Very Long-form Video Language Understanding

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoSchema 官方倉庫含資料取得、原 Ego4D 對映和遠端提交 wrapper；完整 GT 未公開。已核讀提交程式與兩筆來源對映樣本，未把遠端介面當作本機 evaluator。

> **版本與身份**
>
> README 同時有 Kaggle 入口與舊 coming-soon 文句；這次只確認釘選檔案與 wrapper，不用舊介紹推定平臺狀態。Wasabi 簽署網址會過期，下載網址不是穩定資料 ID。

領域	居家整理與清潔、餐飲與烹飪、工藝與修繕、農業與園藝
環境	從 Ego4D 截出的第一人稱影片；q_uid 對應一個影片片段，uid_to_ego4d.json 另連 video_uid、starting_sec、ending_sec。多片段可能來自同一原影片 / 場景。
任務	零樣本長影片五選一 QA。README 的完整 5,031 題與公開答案 500 題是不同口徑，500 題為子集，不能加總；這是原作者檔案數字，非本次已整合題數。
題數與資料	影片名對 q_uid；提交 JSON 是 question_uid→0–4 整數。已讀兩筆 parent mapping，其中一例把 q_uid 對到原影片 240–420 秒；只核對欄位與例子，不宣稱全量對映已人工審查。
評估方式	validate.py 直接 POST JSON 到作者服務，返回 full/subset MCQ accuracy；程式本身沒有本機 scoring 邏輯或完整 hidden labels。未送出任何提交，也未驗證服務現時可用性。500 題離線結果不能當完整 benchmark 成績。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **5,063** 五選一QA · 原文頁 14

依這個順序讀

1. README.md ↗
   GitHub · egoschema/EgoSchema · 505c787376

   零樣本用途、native 題數、public/hidden 與提交格式

   L1–115

---

2. uid_to_ego4d.json ↗
   GitHub · egoschema/EgoSchema · 505c787376

   只讀兩筆 JSON pointer，確認原 Ego4D 與秒制來源

   JSON /001934bb-81bd-4cd8-a574-0472ef3f6678 · JSON /001d2d1b-d2f9-4c39-810e-6e2087ff9d5a

---

3. validate.py ↗
   GitHub · egoschema/EgoSchema · 505c787376

   遠端傳送程式，不是本地評分器

   L1–43

怎麼接入我們的benchmark

可重用

原生 q_uid、五選一輸出範圍、公開 subset 口徑及 Ego4D 來源時間對映。

需要轉換

case 留 q_uid 與 parent video/time window；split/label_access 明確區分 public-500、完整公開問題與 hidden answers。evaluator 分 local_subset / remote_full，記錄影片取樣預算、輸出解析和提交回執。

仍需補齊

本次未取得全量影片與 questions.json（超過本工作者小型文字取得上限），未執行模型或服務。需全量 schema / ID 唯一性與 public subset 對齊檢查後，才計已取得 / 已整合 cases。

P029 · EgoThink

EgoThink: Evaluating First-Person Perspective Thinking Capability of Vision-Language Models

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoThink 是單影像第一人稱思考問答。已核讀資料樣本、推論輸出、實際裁判 prompt 選擇與分數聚合；程式沿用 FastChat 格式，但原生分數不是其通用 1–10 分。

> **版本與身份**
>
> README 列 VidEgoThink 為另一篇後續工作；不能因同 repo 宣傳連結就把其影片題目計入 EgoThink。現行預設裁判為 gpt-4o，原論文使用的模型 / prompt 必須另依對應版本釘選。

領域	居家整理與清潔、餐飲與烹飪、工藝與修繕
環境	來自人類第一人稱影像；樣本 source_dataset=ego4d，image_path 為本地圖片。能力目錄不等於生活場域或新實體環境；原影片時間 / 地點需另外補來源對映。
任務	六類能力目錄 Activity、Forecast、Localization、Object、Planning、Reasoning，下含 12 份 annotations.json。導航 / 協助題是文字規劃問答，未要求機器人執行。
題數與資料	樣本含 source_dataset、image_path、question、answer；eval.py 用 image_path[0] 的檔名定位影像，依目錄順序重新給 question_id，輸出 question/model_answer/reference_answer JSONL。assistance/navigation token 預算300，其他30，需保留差異。
評估方式	gen_judgment.py 實際採 judges[math] 的 single-math-v2 prompt：只看問題、參考與模型文字、不看圖片，給 0/.5/1；common.py 解析 [[rating]]，最多嘗試3次，失敗=-1。show_result.py 排除 -1 後平均，去重被註解；應額外報有效率和重複題，不能將保留樣本平均當全題 accuracy。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **6** 能力類別 · 原文頁 5
- **12** 細分題型 · 原文頁 5, 14
- **700** 影像QA · 原文頁 5
- **595** 母影片 · 原文頁 5

依這個順序讀

1. `README.md` ↗
   GitHub · AdaCheng/EgoThink · fbafe8fe4e

   精確論文身份、能力與流程

   L1–117 · L152–197

---

2. `data/Activity/annotations.json` ↗
   GitHub · AdaCheng/EgoThink · fbafe8fe4e

   JSON /0 樣本欄位與 Ego4D parent

   JSON /0

---

3. `eval.py` ↗
   GitHub · AdaCheng/EgoThink · fbafe8fe4e

   單影像讀取、預算與重編 ID

   L1–145

---

4. `judge_prompts.jsonl` ↗
   GitHub · AdaCheng/EgoThink · fbafe8fe4e

   原生 reference-only 0/.5/1 prompt

   L1–9

---

5. `gen_judgment.py` ↗
   GitHub · AdaCheng/EgoThink · fbafe8fe4e

   實際選用 single-math-v2

   L19–24 · L29–33 · L71–75 · L112–116 · L142–146 · L168–175 · L178–182 · L184–199 · L201–205 · L212–225 · L234–242 · L276–296 · L310–329 · L341–349 · L352–356

---

6. `common.py` ↗
   GitHub · AdaCheng/EgoThink · fbafe8fe4e

   rating 解析 / 失敗 / 重試

   L129–137 · L152–160 · L173–196 · L343–354

---

7. `show_result.py` ↗

   GitHub · AdaCheng/EgoThink · fbafe8fe4e

   排除 -1、分組平均與未啟用去重

   L3–11 · L32–133 · L142–157 · L169–181

怎麼接入我們的benchmark

可重用

十二能力題集結構、單影像 QA schema、原參考答案與具體 0/.5/1 裁判流程。

需要轉換

case 用 source+能力目錄+原始 row/hash 建穩定 ID，儲存生成 question_id 對映；記錄圖片、token budget、reference、judge model/version/prompt、原 judgment、解析重試與缺失。各能力分項，與 physical navigation evaluator 分開。

仍需補齊

未執行模型 / 付費裁判。僅讀 Activity 第一筆資料樣本，未逐題查圖片與標籤；需確認各子集來源 video/time、去重與盲測切分。API 模型版本與裁判可靠性需另外驗證。

P030 · EgoPlan-Bench

EgoPlan-Bench: Benchmarking Multimodal Large Language Models for Human-Level Planning

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoPlan-Bench 使用 EPIC-100 / Ego4D 的人類影片做下一步四選一；已核讀 sample schema、Video-LLaMA 介面與實際比較方式。EgoPlan-IT 是另外的訓練資料。

> **版本與身份**
>
> 原 README 包含不同模型的輸入設定，必須記錄 history segmentation 是否給定。IT 的自動答案與人工核驗 Bench split 不能合併宣稱同等標註品質。

領域	居家整理與清潔、餐飲與烹飪
環境	來源為既有 EPIC-100 與 Ego4D。video_source/video_id 連原影片，目標與進度是題目上下文，不能把同影片不同目標當新實體環境。
任務	給 task_goal、進度片段與當前觀測，選最合理下一步。原檔案列 Val 3,355、Test 1,584（隱藏 GT）、IT 50K；額外 164K 通用 instruction 不屬測試題數。
題數與資料	sample_id、video_source、video_id、task_goal、choice_a–d、golden_choice_idx、answer、current_observation_frame、task_progress_metadata 的 narration/start/stop_frame。Ego4D 介面只取最近4個 action、每個8 frames，再加當前影格；不足片段以 padding+clip_mask 補齊。
評估方式	介面對四個候選計模型 loss，取 argmin 回傳候選文字；eval_multiple_choice.py 將該文字與 sample.answer 完全比較，再算 accuracy。對外 submission 則是 sample_id+label A–D，兩種表示需顯式對映。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **419** 原作觀測scenes · 原文頁 5, 7
- **3,269** 表2 task goals · 原文頁 7
- **4,939** 評測QA（val+test） · 原文頁 5, 7
- **1,584** test QA · 原文頁 7

依這個順序讀

1. README.md ↗
   GitHub · ChenYi99/EgoPlan · 1510afc12b

   原生訓練 / 評測量、欄位與父資料

   L1–176 · L205–263

---

2. src/__init__.py ↗
   GitHub · ChenYi99/EgoPlan · 1510afc12b

   模型介面入口

   L1–11

---

3. src/egoplan_video_llama_interface.py ↗
   GitHub · ChenYi99/EgoPlan · 1510afc12b

   合法影片讀取與四選項 loss

   L32–64 · L70–78 · L81–92 · L95–109 · L138–160 · L169–175

---

4. eval_multiple_choice.py ↗
   GitHub · ChenYi99/EgoPlan · 1510afc12b

   實際文字比較及入口變數問題

   L1–78

怎麼接入我們的benchmark

可重用

目標 / 進度 / 當前影格與候選 schema、兩個父庫對映、四選一 loss scoring。

需要轉換

source 分 Bench-Val / Bench-Test / IT，case ID 留原 sample_id、video_source、video_id 與 frame 範圍；記合法 action 邊界資訊、最近4片段與取樣預算。輸出同時保留候選索引 / 原字串與 choice2loss，未見 label 不補 GT。

仍需補齊

未下載影片 / IT、執行模型或提交。入口引用未定義 subset_name（列印與 predict_choice 呼叫），需修正為來源分支後驗證；短 action 可能讓 (end-start)//8=0，需記錄例外策略。不能把問答正確率當物理規劃成功。

P031 · EgoPlan-Bench2

EgoPlan-Bench2: A Benchmark for Multimodal Large Language Model Planning in Real-World Scenarios

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoPlan-Bench2 比第一版加入明確 domain/scenario 欄位並擴充人類生活用途；已核讀完整 eval.py，確認其測量仍是影片下一步四選一。

> **版本與身份**
>
> 與 P030 的 EPIC/Ego4D 雙父庫不同，本版檔案只指 Ego4D；題目集合、父影片與候選需核對後才能算淨新增量。

領域	居家整理與清潔、餐飲與烹飪、工藝與修繕、零售與購物、實驗室操作、個人照護、交通移動與車輛維修、農業與園藝、休閒與運動
環境	Ego4D v1_288p 影片，原文案 4 major domains / 24 scenarios 是生活用途分類，不是 24 個物理 layout。sample_id 的 UUID 字首連到父影片，另有 task_start_frame。
任務	依整段進度及當前觀測推下一動作。四候選與 task_goal 構成題目；CoT / GroundingDINO 是可選方法處理，不能當多一批評測任務。
題數與資料	sample_id、domain、scenario、task_goal、choice_a–d、golden_choice_idx、answer、task_start_frame、current_observation_frame、task_progress_metadata。eval 從 start 到 current 逐 frame 截影片（含末 frame），或用 linspace 抽預設8張給 image model。
評估方式	extract_characters_regex 取回覆第一個大寫 A–D，空字串算錯，再與 golden_choice_idx 比較累積 accuracy；儲存 raw model_response 與 extracted_answer。parser 的部分 prefix 字串因少逗號被相接，且非嚴格字邊界匹配，需儲存此原始版本。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **4** 原生life domains · 原文頁 1, 5
- **24** 語義scenario類別 · 原文頁 1, 5
- **1,113** 來源影片 · 原文頁 1
- **1,321** 四選一QA · 原文頁 1

依這個順序讀

1. `README.md` ↗
   GitHub · qiulu66/EgoPlan-Bench2 · 5c75ffff73

   原生用途分類、欄位及 CoT 方法範圍

   L1–161

---

2. `eval.py` ↗
   GitHub · qiulu66/EgoPlan-Bench2 · 5c75ffff73

   截片、取樣、字母解析與 accuracy

   L1–172

怎麼接入我們的benchmark

可重用

來源 domain/scenario、完整觀測區間、四候選與推論 / 解析 / 分數紀錄。

需要轉換

沿用父 Ego4D ancestry，新增 source-local domain/scenario 對映；case 留 sample_id/觀測範圍。image-8frame、video、CoT 分成 evaluator configuration，不把方法條件算成新任務；選項及字串一致性可在 intake 檢查。

仍需補齊

未取得完整 HF 題庫 / 影片或執行。需將所有來源 domain/scenario 逐項對映本計畫用途，不能只抄 4/24。輸出採 append 且每次 count 重設，重跑需 session ID 與去重；已存在的視覺快取需繫結 source/sampling hash。

P032 · EgoTaskQA

EgoTaskQA: Understanding Human Tasks in Egocentric Videos

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoTaskQA 可用於「從程式標註產生可追溯問題」的流程。已核讀 generation 說明、direct/indirect 切分、LEMMA loader，以及實際答案索引 accuracy。

> **版本與身份**
>
> 已核讀一種 baseline 的評分路徑；其他 HCRN/HGA/PSAC/VisualBERT 的輸入及聚合不據此推定完全相同。direct 名稱不表示該 split 只含 direct 問題，原程式實際對 all_qas 分配。

領域	居家整理與清潔、餐飲與烹飪、社交與溝通
環境	沿用 LEMMA 人類活動影片與世界狀態標註；interval 裡的 video_name/fpv/start/end 是觀測區間，不是新的場景資產。
任務	world state+template/program 產生 query/localize/counterfactual 等問答，再作答案分佈平衡。reasoning_type 可重複附在同一題上，各類分母不互斥。能生成更多問句不等於增加同樣數量的程式或環境。
題數與資料	raw parsed.json 與 templates 產出 direct/indirect/merged/balanced QA；maskX 表示物件遮蔽數。baseline 的 tagged QA 有 interval、question、answer_encode、reasoning_type、各詞 / 字編碼；vid_intervals 對 feature video_id，HDF5 預設取20 frames。interval=[start,end)，影像檔名為1-based，feature indices 為0-based。
評估方式	所核讀 LSTM baseline 對 logits argmax 與 answer_encode 完全比較，validate 先算各 batch accuracy 再平均；另依多個 reasoning tags 計 true/total。test loader shuffle=True/drop_last=True，故不是保證所有 test 題都進分母。direct split 依答案平衡比例 3:1:1；indirect 將 direct 題與特定 query/iterate_until 程式留 train，其餘 indirect 一分為二。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **4** QA reasoning types · 原文頁 1, 6
- **40,000** balanced QA · 原文頁 4
- **368,000** 生成候選QA（非正式題庫） · 原文頁 4

依這個順序讀

1. `README.md` ↗
   GitHub · Buzz-Beater/EgoTaskQA · 807a34d77d

   精確論文身份與生成 / 實驗入口

   L1–50

---

2. `generation/README.md` ↗
   GitHub · Buzz-Beater/EgoTaskQA · 807a34d77d

   世界狀態、program、模板與平衡

   L1–45

---

3. `baselines/README.md` ↗
   GitHub · Buzz-Beater/EgoTaskQA · 807a34d77d

   資料 / feature / vocab 格式

   L1–86 · L120–161

---

4. `baselines/preprocess/split.py` ↗
   GitHub · Buzz-Beater/EgoTaskQA · 807a34d77d

   direct/indirect 實際切分邏輯

   L7–20 · L22–30 · L33–54 · L57–110

---

5. `baselines/dataset/dataset.py` ↗
   GitHub · Buzz-Beater/EgoTaskQA · 807a34d77d

   frame 基數與 HDF5 讀取

   L1–120

---

6. `baselines/train_pure_lstm.py` ↗
   GitHub · Buzz-Beater/EgoTaskQA · 807a34d77d

   具體答案分類、batch 平均與 test 取樣

   L13–21 · L93–105 · L122–131 · L142–185 · L189–205 · L216–227 · L230–255 · L264–281

---

7. `baselines/utils/utils.py` ↗

   GitHub · Buzz-Beater/EgoTaskQA · 807a34d77d

   多標記 reasoning accuracy

   L1–41

怎麼接入我們的benchmark

可重用

可追溯 world state / program / template、答案分佈平衡、direct/indirect split 與原生 QA schema。

需要轉換

task/規則保留 program 和生成版本；case 保留父影片+fpv+半開 frame 區間、maskX、template、answer vocabulary/hash。題數按唯一 QA ID 計，影片 / 模板 / reasoning tags 另算；原 split 按問題分，不自動宣稱 video-disjoint。

仍需補齊

尚未取得世界狀態 / 影片 / 特徵或執行生成與評分。需確認穩定 ID、完整 split 檔及欄位，而非重跑未固定 seed 的 split.py；評估 all-cases adapter 與原 drop_last 結果需各自標版本。

P033 · EgoLife

EgoLife: Towards Egocentric Life Assistant

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoLife、EgoIT、EgoGPT、EgoRAG 是資料 / 訓練集 / 模型 / 方法的不同角色。已核讀 EgoRAG 的 QA schema、記憶查詢、證據與精確選項評分。

> **版本與身份**
>
> 主 README 中早期 arXiv-on-hold 等訊息仍保留，身份以實際論文標題 / arXiv ID 為準。EgoGPT 檔案對其他 EgoSchema/EgoPlan/EgoThink 的結果是外部測試，不算 EgoLife 原生題目。

領域	居家整理與清潔、餐飲與烹飪、休閒與運動、社交與溝通
環境	六位參與者一週的真實生活觀測，包含 Aria、外部相機與 mmWave；本次核心程式處理人物/日期/影片的記憶序列，不代表所有感測 modality 都已進入每道題。
任務	長期記憶、人物 / 事件 / 習慣等 QA，以 query_time 和過去證據答四選一。EgoIT-99K 是九個既有 ego 資料的 instruction tuning 混合，不是新增 99K EgoLife 測試題。
題數與資料	QA 有 ID、query_time 的 DAY/time 字串、type、need_audio/need_name、question、choice_a–d、answer、target_time、keywords、reason。caption DB 以 date/start/end/video_path/text 建記憶片段；parse_query 實際使用 keywords。時間為來源自訂8位編碼，需保留原字串再建立經核驗的時間換算。
評估方式	calculate_accuracy 只對已進 answers 的 model_option 與 metadata.answer strip 後精確比較；query_all/main 遇例外 continue，故漏題可能不進分母。get_answer 遇 API 字串 error 會隨機選 A–D；須另列失敗 fallback。主入口 extract_evidence 實際 modality=text，EgoGPT 是可換的 caption/視覺模型，不能把此設定報成每題直接看影片。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **1** EgoHouse · 原文頁 3
- **5** QA types · 原文頁 5
- **3,000** 正式QA · 原文頁 3, 5
- **500** 本文快速實驗實評QA · 原文頁 7

- **266** 保留影片小時 · 原文頁 3

依這個順序讀

1. `README.md` ↗
   GitHub · EvolvingLMMs-Lab/EgoLife · 7a97157908

   EgoLife / EgoGPT / EgoRAG 的角色

   L1–87

---

2. `EgoGPT/README.md` ↗
   GitHub · EvolvingLMMs-Lab/EgoLife · 7a97157908

   EgoIT 混合訓練與外部 lmms-eval

   L1–62 · L95–146

---

3. `EgoRAG/README.md` ↗
   GitHub · EvolvingLMMs-Lab/EgoLife · 7a97157908

   QA 與 caption DB schema

   L1–195

---

4. `EgoRAG/main.py` ↗
   GitHub · EvolvingLMMs-Lab/EgoLife · 7a97157908

   實際 query/answer/text-evidence 流程

   L1–9 · L15–21 · L33–41 · L67–112 · L115–170 · L173–183 · L218–242 · L247–256

---

5. `EgoRAG/egorag/agents/RagAgent.py` ↗
   GitHub · EvolvingLMMs-Lab/EgoLife · 7a97157908

   cutoff、keywords、證據、失敗回退及分母

   L1–117 · L125–134 · L143–157 · L159–178 · L193–199 · L203–212 · L217–223 · L227–235 · L239–245 · L257–269 · L277–372 · L380–447 · L449–481 · L483–518 · L520–543 · L549–615 · L619–625 · L627–665

怎麼接入我們的benchmark

可重用

人物 / 日期 / query time、題目與證據 schema、記憶資料庫與四選一評分。

需要轉換

case 保留本人、query timestamp、合法 past cutoff、是否提供 keywords，以及 target_time/reason 的 GT 身份。cache/DB 對應 caption model/version、影片範圍與讀取記錄；完整預定題清單與已答題清單並列，漏題、隨機回退、解析失敗分開。

仍需補齊

尚未下載完整一週影片、EgoIT、建立 DB 或呼叫模型。需核驗每層摘要 / retrieval/filter 的時間截止與 evidence 完整性，並固定 keyword 可用條件；不同人物和同時攝影不能直接計成獨立環境。

P034 · EgoVLP

Egocentric Video-Language Pretraining

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoVLP 同時提供 EgoClip 預訓練與 EgoMCQ 開發評測；本次核讀 EgoMCQ 格式、chunk loader 和實際 accuracy。其他 Ego4D / EPIC / Charades 評測保留父來源。

> **版本與身份**
>
> EgoMCQ 被用來選預訓練 checkpoint，應標 development set，不自動當獨立最後測試。EgoVLPv2 為後續方法，新聞連結不代表本 repo 已包含其新增結果與全部程式。

領域	居家整理與清潔、工藝與修繕
環境	影片來自 Ego4D；600 秒 chunk 是儲存切塊，不是物理環境。intra/inter-video 指候選來自同／異影片的難度條件，不等於生活用途。
任務	EgoMCQ 給文字查詢，從五個影片候選找正解；與從影片選文字答案的 QA 方向不同。EgoClip 數百萬 narration clips 是訓練單位，不能當 EgoMCQ 測試題或新動作任務。
題數與資料	EgoClip TSV 含 clip_idx/video_uid/narration_source/narration_ind/narration_time/clip_start/end/clip_text/tag_verb/tag_noun；MCQ JSON 有 query/choices/answer/types。loader 依 clip 秒數取可能跨兩個600秒檔案的 frames，返回 video/text/text_ops/correct/type。val 與 test 都讀同一 egomcq.json。
評估方式	egomcq_accuracy_metrics 在各 type 內 argmax 對 label 算 accuracy。重要不一致：loader 註解寫 1=inter、2=intra，但 metric 將排序後 type 配給 Intra-video、Inter-video；需對原 JSON 定義後判斷，不能直接抄標題。eval config 4frames/224px/loading=lax，失敗會以黑圖補，應另計資料讀取失敗。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **39,000** EgoMCQ development questions（約數） · 原文頁 6
- **3,850,000** EgoClip narrations（約數） · 原文頁 3
- **129** source scenario labels · 原文頁 3

依這個順序讀

1. `README.md` ↗
   GitHub · showlab/EgoVLP · 928406c2d5

   EgoClip / EgoMCQ 與父 benchmark 角色

   L1–99 · L124–201

---

2. `configs/eval/egomcq.json` ↗
   GitHub · showlab/EgoVLP · 928406c2d5

   開發評測輸入配置

   L1–78

---

3. `data_loader/EgoClip_EgoMCQ_dataset.py` ↗
   GitHub · showlab/EgoVLP · 928406c2d5

   chunk 跨界、原生 MCQ 格式與黑圖回退

   L13–95 · L128–183

---

4. `model/metric.py` ↗
   GitHub · showlab/EgoVLP · 928406c2d5

   實際 type 分組與 accuracy

   L208–241 · L341–361

怎麼接入我們的benchmark

可重用

原生五候選 query/choice metadata、來源切塊對映、pretraining 與 development 分界。

需要轉換

case 保留 EgoMCQ ID、候選順序及各父 video/time；source 分 EgoClip/EgoMCQ/下游父 benchmark，tag 字典作原生訓練詞彙。evaluator 儲存 type 數值與已核定名稱、4frame 預算、缺檔回退，不能把同 JSON 的 val/test 加成兩套題。

仍需補齊

尚未取得 egoclip/egomcq 全量 metadata、影片或執行。需解決 type 名稱矛盾、有效樣本清單與跨來源影片去重；下游 NLQ/MQ/PNR/OSCC 完整 adapters 仍另按父協定驗證。

P035 · EgoVLPv2

EgoVLPv2: Egocentric Video-Language Pre-training with Fusion in the Backbone

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

EgoVLPv2 是跨模態預訓練方法與既有 benchmark 的適配實作，保持 related_reference 身份；沒有把其下載特徵和下游結果當作新環境或新題庫。

> **版本與身份**
>
> root README 指明基於 EgoVLP 的特定提交，不能與 P034 的當前固定快照視為完全相同程式。EgoTaskQA 的資料仍屬 P032/LEMMA 衍生範圍。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	沿用 EgoClip/Ego4D、EPIC-100、Charades-Ego、EgoTaskQA、QFVS 等父來源；此方法不獨立定義一組新生活場景。
任務	預訓練與 video-text fusion，於 EgoMCQ、retrieval、動作、NLQ/MQ、QA / summarization 進行遷移。任務清單引用原 benchmark，模型比較本身不增加 canonical tasks。
題數與資料	EgoTaskQA 子目錄明確沿原作者預處理，formatted_*_qas_encode.json 的 interval 加 .mp4 定位加工影片，question/answer_encode 和 reasoning_type 保留；tokenizer 以30 token 為上限截斷，frame 預算由配置定義。NLQ 保留 clip_uid/annotation_uid/query_idx/predicted_times。
評估方式	核讀 NLQ 原生時間 overlap/top-K 閾值 recall，分母為傳入預測且只列 evaluated/GT。QA validate 在分散式 allgather 後 argmax 對 answer 索引，另計 reasoning tag 正確率；直接 all_acc 公式寫成 correct/B*world_size，需檢查分母與 tag 報表的一致性，不直接採用此摘要作新結果。

依這個順序讀

1. `README.md` ↗
   GitHub · facebookresearch/EgoVLPv2 · 550c0596b8

   方法身份、來源與子目錄角色

   L1–73

---

2. `EgoTaskQA/README.md` ↗
   GitHub · facebookresearch/EgoVLPv2 · 550c0596b8

   原 EgoTaskQA 資料與 direct/indirect 協定

   L1–43

---

3. `EgoTaskQA/EgoTaskQA_dataset.py` ↗
   GitHub · facebookresearch/EgoVLPv2 · 550c0596b8

   加工影片、question/answer 與輸入截斷

   L14–103

---

4. `EgoTaskQA/main_end2end.py` ↗
   GitHub · facebookresearch/EgoVLPv2 · 550c0596b8

   分散式評分、tag 報表與模型選取路徑

   L100–106 · L111–117 · L122–128 · L184–202 · L218–224 · L227–233 · L246–254 · L258–277 · L310–318 · L349–360 · L364–370 · L383–406

---

5. `EgoNLQ/utils/evaluate_ego4d_nlq.py` ↗
   GitHub · facebookresearch/EgoVLPv2 · 550c0596b8

   NLQ 時窗、閾值與分母

   L13–117

怎麼接入我們的benchmark

可重用

父 benchmark adapters、固定特徵 / 模型版本、EgoTaskQA 的原生 ID 和 NLQ evaluator。

需要轉換

用 method→evaluated_on/source 與 derived_feature 邊連父資料，不新建一份重複環境 / 任務數。case 在原 benchmark namespace 下儲存，另記模型、16frame/224px、30token、分散式取樣與 adapter 提交版本。

仍需補齊

未下載權重 / features 或執行。需核驗 DistributedSampler padding 的去重、QA pooled 分母及 checkpoint 選擇 split；本次讀 EgoTaskQA/NLQ 核心，不能代替其他下游完整 adapter 審核。

P036 · EgoT2

Egocentric Video Task Translation

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

EgoT2 將七個 Ego4D 任務互相遷移，屬方法參考；已核讀資料來源與 OSCC/PNR 的實際輸入和評分，並辨識 eval_lta.py 的名字與當前輸出不同。

> **版本與身份**
>
> 論文表的 ED@20、repo 某個 eval_lta.py 及 challenge submission 屬不同路徑，須固定可重現入口後比較。父資料版本仍依 Ego4D 原來源，related_reference 不加到183份 benchmark/data 來源量。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	共用 Ego4D 影片，分人與人互動 HHI、人與物 HOI。任務融合不等於跨資料集新增七套環境。
任務	LAM、TTM、ASD、PNR、OSCC、AR、LTA；各有原生條件。faces localized/tracked 是 HHI 的前置輸入，PNR/OSCC 用狀態變化片段，LTA 與 AR 共用 verb/noun vocabulary。
題數與資料	docs 分別連官方 social-interactions 的 lam/ttm 分支、ASD、hands-and-objects、forecasting。HOI batch 含 orig 的 frames/labels/state_change/fps/info，另有 recognition 或 pnr 輔助視覺輸入。提交以 unique_id+state_change bool 或 clip-relative pnr_frame 識別。
評估方式	OSCC 逐例 argmax 後全樣本正確率；PNR 僅 GT 有變化時計16-bin到frame的距離，再除各自 fps成秒。eval_pnr.py 平均 batch 平均，無正例預設0需保留。通用輸出 metric 在合法 token 子集再取 argmax，另列 out-of-task token 比率。當前 eval_lta.py 只評 forecast_labels 第一動作的 verb/noun accuracy，不是 README 的 ED@20。

依這個順序讀

1. `README.md` ↗

   GitHub · facebookresearch/EgoT2 · 1e261806ca

   七項原生任務、方法及報告指標

   L1–87 · L158–229

2. `docs/PREPARE_HOI.md` ↗
   GitHub · facebookresearch/EgoT2 · 1e261806ca

   HOI 父資料與片段

   L1–48

3. `docs/PREPARE_HHI.md` ↗
   GitHub · facebookresearch/EgoT2 · 1e261806ca

   HHI 分支與原作者依賴

   L1–53

4. `HOI/submission/eval_oscc.py` ↗
   GitHub · facebookresearch/EgoT2 · 1e261806ca

   auxiliary input、bool 提交與 accuracy

   L1–89

5. `HOI/submission/eval_pnr.py` ↗
   GitHub · facebookresearch/EgoT2 · 1e261806ca

   PNR 相對 frame 與 batch 聚合

   L1–95

6. `HOI/evaluation/pnr/metrics.py` ↗
   GitHub · facebookresearch/EgoT2 · 1e261806ca

   有效樣本、秒誤差、token 錯誤與重複計數

   L1–257

7. `HOI/submission/eval_lta.py` ↗
   GitHub · facebookresearch/EgoT2 · 1e261806ca

   實際只計第一預測動作的 accuracy

   L19–61

怎麼接入我們的benchmark

可重用

七項父任務關係、auxiliary inputs、輸出 token 子集與 OSCC/PNR adapters。

需要轉換

保持 source=P013 的 benchmark/case 身份，另記 translation method、可用輔助模型與輸入。evaluator 對 PNR 秒誤差、OSCC accuracy、LTA ED 各自留協定，不能依檔名將第一動作 accuracy 改叫長期 ED。

仍需補齊

未執行訓練 / 推論。完整 HHI mAP 和 LTA ED 提交流程仍需追核；PNR/OSCC 通用 metric 的重複 unique_id 只列印、continue 被註解，需全量去重與分母檢查。不得由融合模型結果估算新的任務數。

P037 · EgoEnv

EgoEnv: Human-centric environment representations from egocentric video

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoEnv 同時有 HM3D 模擬 walkthrough 與真實影片理解用途；已核讀 episode/scene ID、四方位狀態標註與具體評測，不能把128維特徵當任務。

> **版本與身份**
>
> 檔案釘選 Habitat-sim0.2.2 與 Habitat-lab 特定提交；同樣 HM3D 名稱不等於其他 benchmark 的相同 split/episode。程式庫書目年份文字需仍以論文來源核對，不據README單行覆寫主書目。

領域	居家整理與清潔
環境	模擬 scene_id 屬 HM3D，episode_id 是初態與訪問目標形成的導航歷程。下游另用 HouseTours / Ego4D 真實影片；RoomPred instance 可區分同類多房間，屬來源內 metadata，不是全球唯一環境 ID。
任務	區域性物件存在 / 距離與相對 pose 學習，遷移到 RoomPred/NLQ。四方位、23 object classes、512 timestep 是張量軸；不代表 4×23×512 個獨立任務。
題數與資料	episode_list.pth 連 state/{type}/{scene_id}_{episode_id}.pth；labels/dists 為 T×4×object，distance=-1 表示未出現。val walkthrough 均勻預選4 query，train 隨機 query / memory window。下游特徵每秒一筆 T×128；HouseTours 原 YouTube clip 與 Ego4D video/clip/time 必須保留父來源。
評估方式	CardinalObjectStateTask 在每方向對多物件算 average_precision_score，再平均方向；distance argmax accuracy 僅 dists!=-1 的位置。訓練 BCE+masked CE 是 loss，不是實體導航成功；RoomPred/NLQ 的完整下游 metrics 不由這個 local-state evaluator 取代。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **900** HM3D pretraining scenes · 原文頁 7
- **886** 選用HouseTours houses · 原文頁 7
- **2** environment understanding endpoints · 原文頁 6
- **146** MP3D video walkthroughs · 原文頁 7

依這個順序讀

1. README.md ↗
   GitHub · facebookresearch/ego-env · 6f06c5888b

   模擬生成、版本、metadata 與下游角色

   L1–92 · L104–145

---

2. DATASETS.md ↗
   GitHub · facebookresearch/ego-env · 6f06c5888b

   HouseTours/Ego4D 來源、時間與 room instance

   L1–48

---

3. state_prediction/data/dataset.py ↗
   GitHub · facebookresearch/ego-env · 6f06c5888b

   scene/episode、query 抽樣與 label mask

   L16–24 · L28–34 · L46–58 · L64–94 · L97–103 · L108–114 · L117–131 · L137–149 · L178–184 · L196–202 · L210–234

---

4. state_prediction/task.py ↗
   GitHub · facebookresearch/ego-env · 6f06c5888b

   方向 AP、距離 accuracy 與訓練 loss

   L9–17 · L21–29 · L45–57 · L97–105 · L118–126 · L132–140 · L158–177 · L179–203 · L208–216 · L218–242

怎麼接入我們的benchmark

可重用

真實 scene/episode 分離、四方位物件 / 距離 schema、RoomPred 的 room instance 和 AP/masked accuracy。

需要轉換

HM3D source→scene→episode→query 建關聯，HouseTours/Ego4D 新標註另連 parent video/time；case 留 query/memory indices、可用歷史、pose/angle、missing-distance。128維 feature 作加工 artifact，不計為新題。

仍需補齊

尚未取得 HM3D、導航軌跡、真實影片或執行。README 只提供50條 sample metadata，完整訓練需生成；需核驗 SCENE_SPLITS、room-instance 身份和下游評分，才能報可用環境 / cases。

P038 · OpenEQA

OpenEQA: Embodied Question Answering in the Era of Foundation Models

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

OpenEQA 的 question/answer/history 格式和文字裁判已可具體追溯；本次核讀一筆原始 QA、歷史取得方式、兩種 prompt 與完整評分指令碼。

> **版本與身份**
>
> data README prose 寫 simulator2.5，但實際安裝命令是 habitat-sim0.2.5；以明確套件版本和歷史版本為準。RGB直接下載被作者標為第三方hosting，官方來源身份與實際分發者需分欄。

領域	居家整理與清潔、辦公與教育
環境	episode histories 來自 HM3D 與 ScanNet；HM3D 用 Habitat 重播 agent states，ScanNet 從原掃描資料抽取。episode_history 路徑連回 scene/source；RGB、depth、pose 是同歷史不同觀測，不新增場景。
任務	開放詞彙環境問答，可討論 episodic memory 和 active exploration；此核讀 evaluator 判文字答案，沒有證明某 agent 已完成探索或操作。
題數與資料	open-eqa-v0.json 例含 question_id、question、answer、category、episode_history，可另有 extra_answers。HM3D 版本為 hm3d-v0/場景路徑，資料檔案提供 RGB-only 或 RGB-D+intrinsics+pose；原 scan/agent state 與 extraction 版本要隨 case 儲存。
評估方式	llm_match 預設 gpt-4-1106-preview/seed1234/temperature.2/max_tokens32，以原參考與可選 extra_answers 判1–5；parse Your mark 後整數。evaluate-predictions 先核 ID/數量、截掉最後句點後的尾文、逐題快取，再將clip(score,1,5)線性映成0–100平均。prediction=None 回0後映為0；force 只對提供的 result 遍歷，dry-run 只取前5，均不能報全量分數。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **187** 蒐集候選scenes / scans · 原文頁 4
- **7** 問答類別 · 原文頁 3, 4
- **1,636** EM-EQA題 · 原文頁 3, 4
- **557** 重用於A-EQA的題子集 · 原文頁 3

依這個順序讀

1. `README.md` ↗
   GitHub · facebookresearch/open-eqa · cfa3fce459

   原生 Q/A/history 及兩種應用情境

   L1–72

---

2. `data/README.md` ↗
   GitHub · facebookresearch/open-eqa · cfa3fce459

   HM3D/ScanNet、感測與 extraction 版本

   L1–101 · L127–168

---

3. `data/open-eqa-v0.json` ↗
   GitHub · facebookresearch/open-eqa · cfa3fce459

   JSON /0 原始 QA 範例

   JSON /0

---

4. `prompts/mmbench.txt` ↗
   GitHub · facebookresearch/open-eqa · cfa3fce459

   1–5文字匹配裁判

   L1–27

---

5. `prompts/mmbench-extra.txt` ↗
   GitHub · facebookresearch/open-eqa · cfa3fce459

   替代答案裁判

   L1–31

---

6. `openeqa/evaluation/llm_match.py` ↗
   GitHub · facebookresearch/open-eqa · cfa3fce459

   裁判引數、空回答與解析

   L1–82

---

7. `evaluate-predictions.py` ↗

   GitHub · facebookresearch/open-eqa · cfa3fce459

   ID、force/dry-run、快取和0–100對映

   L1–122

怎麼接入我們的benchmark

可重用

穩定 question_id、scene/history 路徑、參考答案與替代答案、原始 judge prompt / 正規化。

需要轉換

environment 儲存父 HM3D/ScanNet scene 和 extraction release；case 綁 question_id/history/modalities/觀測 budget。evaluator 固定裁判版本、prompt hash、預處理、cached score 來源；完整資料 / 結果 ID 一對一，force/dry-run 和缺題另標。

仍需補齊

尚未取得 histories、執行 simulator / baseline / 付費裁判。只讀 QA /0 schema 範例，未逐題驗證全庫；若更換模型或 prediction，舊 metrics 快取需按輸入hash區分，並另外驗證裁判與人工一致性。

P039 · RoboVQA

RoboVQA: Multimodal Long-Horizon Reasoning for Robotics

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

RoboVQA 公開 GitHub 是資料讀取與示範評分 notebook，並非完整實機控制評測平臺。已讀所有 notebook source cells，包含 SequenceExample schema、任務tag解析和 mock eval。

> **版本與身份**
>
> 公開 notebook 的 mock 範例與論文的真實機器人 / 人工介入實驗不同。程式授權與其餘資料授權在 README 分開列示，後續來源表應各自儲存。

領域	居家整理與清潔、餐飲與烹飪、辦公與教育
環境	已核原論文第1頁：資料來自3棟辦公大樓，含機器人、人、人持抓取工具的多 embodiment。公開 notebook 本身只讀 images/texts，未提供可直接重設的場景或 robot dynamics。
任務	長程 / 中程指令與高階 VQA，例如成功、affordance、離散進度及文字推理。<task:...> 是問題 / 標註型別，同一影片可帶多個 QA；29,520 unique instructions 與829,502 video-text pairs 是原論文報告的不同單位，不是本次取得或可執行題數。
題數與資料	Google Storage train/val TFRecord 裡是 tf.train.SequenceExample，feature_lists 的 images 為 JPEG bytes，texts[0] 為包含多個 task/pred/speaker tags 的UTF-8字串。Tasks 分成 tag→文字，再用 A: 分離輸入 / 答案；隨機抽 task 與 split 需儲存實際選到的內容。
評估方式	run_eval 只取 validation 第一筆 SequenceExample，對其中 QA 呼叫 mock_call_model 並示範 sentence_bleu，無全量平均或實機 intervention 統計。程式呼叫為 sentence_bleu(answer,pred_answer)，需按鎖定 SacreBLEU 核對候選 / 參考順序及型別，不能直接把示範印出的數字當正式 benchmark 成績。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **3** 辦公樓 · 原文頁 1, 2
- **2,722** unique長程指令字串 · 原文頁 2
- **26,798** unique中程指令字串 · 原文頁 2
- **5,246** 長程episodes · 原文頁 2

- **100** 離線planning episodes · 原文頁 4
- **854** 離線planning steps · 原文頁 4

依這個順序讀

1. `README.md` ↗
   GitHub · google-deepmind/robovqa · 93f183129a

   官方 example-code 身份與精確論文

   L1–45

---

2. `data_loading_and_eval.ipynb` ↗
   GitHub · google-deepmind/robovqa · 93f183129a

   所有 source cells；未執行、不把 notebook outputs 當驗證

   L8–22 · L29–46 · L53–55 · L65–88 · L98–375 · L384–389 · L399–403 · L412–428 · L435–437 · L447–452 · L461–492 · L501–503 · L512–514

怎麼接入我們的benchmark

可重用

原生多tag語料、TFRecord images/texts schema 與 task/source-target parser。

需要轉換

source 記 embodiment / episode / building 若來源metadata可取得；case 用record ID+task tag+該tag內QA序號，frame sequence 只儲存一次。raw text/tag 與去tag的prompt/answer同存；VQA字串評分與實機 intervention evaluator 分別建檔。

仍需補齊

尚未下載 TFRecords、執行 notebook 或機器人試驗。需要全量 ID/split/embodiment metadata、正式 BLEU 協定與 intervention 原始軌跡；get_splits 的 binary/discrete 路由引用未定義常數，使用時需修正並測試，A:範例不受該路由影響。

P040 · RoboBench

Robobench: A Comprehensive Evaluation Benchmark for Multimodal Large Language Models as Embodied Brain

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

RoboBench 的釘選版本已分 MCQ 與 Planning，並提供原生粒度表。本次核讀 loader、MCQ、Q1–Q3 planning 的核心規則，以及 point/IoU 輔助 evaluator；不把模型裁判等同物理執行。

> **版本與身份**
>
> README已是ECCV2026 release，不能無版本註記地替換2025 arXiv表。IoU檔案開頭提mAP，但實際回傳平均IoU / pass rates，沒有AP排序積分；點 / IoU工具存在也不代表32 manifest全都使用它們。

領域	居家整理與清潔
環境	影像 / 影片中的機器人或人類操作觀測；unique_id 中的 images 路徑定位樣本。cross-embodiment/object/view/attribute 是泛化條件，5 dimensions 是能力分類，不是5種生活用途。
任務	2026 release README 列5 dimensions、14 groups、25 tasks、32 subtask manifests、6,092 QA，MCQ=1,895、Planning=4,197；這是版本化原作者規模，非本次資料整合實數。Q1 多步計畫、Q2 下一步、Q3 狀態估計會共用同一來源影像。
題數與資料	system_prompt.json 和 dimension/subtask/questions.json；question 有 unique_id、task_type、image_urls、robotic_type、question/options，轉 request_id/prompt。Q1–Q3 suffix 在找圖時去除；Q1另讀 dag.json 的 id→gt_dag，navigation 無同樣 DAG。human 在 prompt 被轉成 single-arm，原始 embodiment 不能因此覆寫。
評估方式	MCQ 取 answer tag / 清除 think 後比A–D集合，不明確輸出可用另設裁判正規化。Q1模型看首圖、GT nodes/DAG、預測計畫，給 node correctness與task completion各0–10後平均映0–100；空 critical-state集合依prompt直接Completion=10。Q2 skill/object/parameter三項平均，前兩任一0則parameter=0；Q3 yes/no精確比。Q1/Q2解析失敗排除均分但overall按原count加權；point/IoU亦只用有效解析作分母，需附valid率。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **25** 認知評測端點 · 原文頁 2, 8
- **6,092** questions · 原文頁 8

- **4,336** unique items · 原文頁 8

依這個順序讀

1. README.md ↗
   GitHub · yulin-luo/RoboBench · 08314edc65

   2026 release原生粒度、兩種設定與程式結構

   L1–94 · L161–225 · L279–330

---

2. src/robobench/data/dataset.py ↗
   GitHub · yulin-luo/RoboBench · 08314edc65

   manifest、request ID、Q suffix與prompt

   L1–149

---

3. src/robobench/evaluation/multi_choice.py ↗
   GitHub · yulin-luo/RoboBench · 08314edc65

   MCQ解析、可選裁判和分母

   L1–130

---

4. src/robobench/evaluation/planning.py ↗
   GitHub · yulin-luo/RoboBench · 08314edc65

   Q1 prompt、DAG、Q2/Q3與聚合

   L26–104 · L244–270 · L305–321 · L372–415 · L595–631 · L713–774

---

5. src/robobench/evaluation/point.py ↗
   GitHub · yulin-luo/RoboBench · 08314edc65

   點距離與valid-only分母

   L1–105

---

6. src/robobench/evaluation/iou.py ↗
   GitHub · yulin-luo/RoboBench · 08314edc65

   bbox IoU、門檻通過率與invalid處理

   L1–123

怎麼接入我們的benchmark

可重用

原生32 manifest層級、題目/skill/DAG/prompt格式與逐項判分證據。

需要轉換

source 固定 release+commit，task 保留原25/32對映，不把 Q1/Q2/Q3 或新視角當新環境；case 保留 raw_question/來源圖/embodiment/DAG及觀測預算。evaluator 分MCQ、Q1/Q2/Q3和point/IoU等可選工具，native分數、parse_failures與分母同存。

仍需補齊

未取得完整HF資料 / DAG或執行模型裁判。需查 empty-goal cases、裁判一致性、skill語義與可用資產；MLLM imagined rollout 不能宣稱物理穩定性 / 真實任務成功。trajectory evaluator 未在本次核讀範圍。

P041 · EgoCross

EgoCross: Benchmarking Multimodal Large Language Models for Cross-Domain Egocentric Video Question Answering

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoCross 的原作者工具庫另指官方 EgoCrossCodes；已補釘選兩者，核對開 / 閉集評分和官方testbed。兩份核心eval檔案的SHA256相同，README / 資料發布內容則不同。

> **版本與身份**
>
> 官方固定README說2026-05挑戰結束後釋出answers，故不再把它寫成永久隱藏GT；本次僅取得questions-only metadata。官方指令碼與原作者檔案相同不表示兩個repository或957題可重複計數。

領域	工藝與修繕、醫療與手術支援、休閒與運動、寵物照護與動物活動
環境	官方957題testbed JSON實際含CholecTrack20、ENIGMA、EgoPet、EgoSurgery、ExtrameSportFPV五個原生dataset標記。這是父資料來源，不是5個實體環境；primary_category/question_type另為能力分類。
任務	閉集四選一與開集文字問答，保留多種活動 / 視角來源。官方檔案區分source-limited/open-source challenge條件；不從benchmark名稱推定統一robot action space。
題數與資料	實際解析questions-only檔有957列、957唯一id，0列含correct_option_letter，0列含question_id；欄位包括dataset、primary_category、question_type、question_text、options、original_video_fps、video_path列表。官方README說另可取得957題answers檔，新增correct_option_letter/answer_text/detailed_answer及global question_id，未在本次取得。
評估方式	閉集從JSON prediction解析並小寫後完全比correct_option_letter，模型例外記success=False。開集先以參考字串 / 數字子字串包含規則直接給5，否則文字裁判給0–5，score>=4才算success再平均；不是單純平均0–5分。來源通常.5fps，部分手術影格條件為1fps，original_video_fps和實際觀測取樣不同。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **4** 原作domains · 原文頁 3, 4
- **15** 細分QA型別 · 原文頁 3, 4

- **957** QA · 原文頁 4
- **798** clips · 原文頁 4

依這個順序讀

1. README.md ↗
   GitHub · MyUniverse0726/EgoCross · f81f41d29d

   原作者工具與官方challenge repo互連

   L1–79

---

2. eval_os_closedset.py ↗
   GitHub · MyUniverse0726/EgoCross · f81f41d29d

   讀取、取樣、JSON解析、失敗記錄

   L60–66 · L111–117 · L191–197 · L350–501 · L503–524

---

3. eval_gpt_openset.py ↗
   GitHub · MyUniverse0726/EgoCross · f81f41d29d

   開集shortcut與0–5裁判

   L12–18 · L22–58 · L68–78 · L80–117 · L127–137 · L139–145 · L166–172 · L186–202 · L215–221 · L228–237 · L243–249 · L253–260 · L268–280

---

4. README.md ↗
   GitHub · EgoCross-Benchmark/EgoCrossCodes · 6737720c12

   957題questions/answers版本及取得方式

   L1–92

---

5. datasets/egocross_testbed_imgs.json ↗
   GitHub · EgoCross-Benchmark/EgoCrossCodes · 6737720c12

   JSON /0逐項閱讀；另對全檔做row/ID/欄位數量統計

   JSON /0

---

6. `eval_os_closedset.py` ↗

   GitHub · EgoCross-Benchmark/EgoCrossCodes · 6737720c12

   確認官方閉集核心與必要欄位

   L322–377 · L403–424 · L482–508

---

7. `eval_gpt_openset.py` ↗

   GitHub · EgoCross-Benchmark/EgoCrossCodes · 6737720c12

   確認官方開集核心與>=4成功閾值

   L25–35 · L83–139 · L230–246 · L270–280

怎麼接入我們的benchmark

可重用

957題唯讀metadata、來源標記、原題與四選項、原作者 / 官方core evaluators和答案發布說明。

需要轉換

source保留原作者repo與challenge repo roles；case以官方id加source version，answers檔以id一對一join，global question_id未取得則不杜撰。video_path序列儲存原fps/取樣率和父影片對映；closed exact-match、open substring shortcut / judge / >=4規則各自版本化。

仍需補齊

尚未取得影格與需另取得的answers檔，也未執行 / 提交。questions-only不具eval指令碼必需的answer和question_id欄位，不能直接以README早期命令宣稱能評分。開集substring捷徑需保留原作口徑並另分析誤判；裁判/API程式仍有外部依賴。

P042 · RoboSpatial

RoboSpatial: Teaching Spatial Understanding to 2D and 3D Vision-Language Models for Robotics

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

RoboSpatial 必須分生成工具NVlabs/RoboSpatial與benchmark評測RoboSpatial-Eval；兩個repo互相連結，身份已確認。已核讀範例loader、生成入口與新版Context評分。

> **版本與身份**
>
> 固定Eval README要求5/13以前fork更新Context邏輯，屬2026 challenge版本。應和CVPR2025原論文結果分版本比較；預測點數由1改2也會改變成功機會。已讀生成派發，未宣稱完整spatial_analysis幾何演算法逐行審完。

領域	居家整理與清潔、辦公與教育
環境	生成工具沿用EmbodiedScan整理的ScanNet/3RScan/Matterport3D/ARKitScenes等掃描；dataset/scene_name/image_name分層。RoboSpatial-Home是另外發布的評測集合，不能與生成資料總量直接相加。
任務	grounding、context（空間指點）、configuration（關係）、compatibility（能否容納）；Home評測用後三類。BOP/GraspNet統一loader在固定README仍為待辦，不能報已支援全部資產。
題數與資料	ExampleLoader要求dataset/scene_name/image_name/objects/camera_annotations，含intrinsic/extrinsic、Name與bbox_3d[0]的9DOF；重複類別生成區域性chair_0等名稱。generator按unique/all-visible pair模式、grid/threshold/buffer/sample數產生unary/pairwise與grounding JSON。Home例欄位img/category/question/answer，Context另需mask。
評估方式	新版Context解析最多前2點（可設1），正規化xy乘width-1/height-1、round後clamp，任一點落非零mask畫素算對；不再用GT點的距離。binary答案用yes/no開頭判斷。即時評分分母為原json_data數；pregenerated按(question,img)匹配，unmatched跳過分母，需額外報matching coverage。README總分按三類平均，VQA avg只平均configuration/compatibility。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **4,916** train indoor scans · 原文頁 5
- **190** train tabletop scenes · 原文頁 5
- **6,000** RoboSpatial-Val QA · 原文頁 5

- **350** RoboSpatial-Home QA · 原文頁 6

依這個順序讀

1. `README.md` ↗
   GitHub · NVlabs/RoboSpatial · 7a1b901cd8

   生成與評測角色、待辦支援及來源身份

   L1–81 · L110–164 · L180–208

---

2. `data/README.md` ↗
   GitHub · NVlabs/RoboSpatial · 7a1b901cd8

   掃描 / EmbodiedScan父來源

   L1–46

---

3. `robospatial/data_loader/example_loader.py` ↗
   GitHub · NVlabs/RoboSpatial · 7a1b901cd8

   中介欄位、區域性物件ID與可見物件限制

   L20–28 · L55–75 · L102–109 · L111–118 · L122–134 · L139–163 · L170–178 · L182–238 · L240–247 · L249–259 · L261–280 · L294–303

---

4. `robospatial/annotation_generator.py` ↗
   GitHub · NVlabs/RoboSpatial · 7a1b901cd8

   生成型別、派發與引數

   L11–24 · L34–41 · L44–70 · L120–131 · L139–171 · L176–185 · L229–248 · L250–258 · L277–284 · L297–306

---

5. `README.md` ↗
   GitHub · chanhee-luke/RoboSpatial-Eval · c0095be6ca

   Home三類、聚合、point budget及版本修正

   L1–100 · L141–196

---

6. `evaluation.py` ↗

   GitHub · chanhee-luke/RoboSpatial-Eval · c0095be6ca

   真實mask/yes-no判分與兩種分母

   `L12–54 · L60–121 · L123–137 · L140–146 · L156–174 · L190–216 · L222–263 · L265–271 · L281–287 · L294–300 · L302–308 · L316–344 · L349–374 · L382–398 · L410–416 · L419–434 · L436–442 · L446–474 · L478–494`

怎麼接入我們的benchmark

可重用

掃描來源/scene ID、相機/9DOF box中介格式、生成引數，以及二值/point-in-mask評測。

需要轉換

保留生成資料與Home benchmark的source/subset區別；case以原question+img並附穩定hash，mask/座標縮放/影像尺寸版本化。區域性物件索引映回來源instance，不當跨圖全球ID；evaluator記num_points_to_match、clamp、mask版本、matched/total與分項聚合。

仍需補齊

未下載Home影像 / mask與全掃描或執行生成。需核驗Home對train來源的重用關係、各loader座標約定及full-scene occupancy；範例loader只含當前圖可見 / 標註物件，不能假定所有未見空間都為空。生成幾何關係不等於具體機器人能抓取或放置成功。

P043 · Embodied VideoAgent

Embodied VideoAgent: Persistent Memory from Egocentric Videos and Embodied Sensors Enables Dynamic Scene Understanding

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

Embodied VideoAgent 是可呼叫導航 / 操作工具的持續記憶agent，保留related_reference角色。本次確認程式實際用Habitat/HSSD場景與兩agent流程，不能推定為ALFRED或TEACh移植。

> **版本與身份**
>
> 此repo明確標ICCV2025 Embodied VideoAgent；README中VideoAgent為2024前作，不能將兩者資料/評測混計。生成10 layouts不等於10種新任務，更不代表全套測例已建立。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	Habitat-sim0.3.0 withbullet，generate_episodes 指向home-robot-remake/HSSD場景；scene_config與layout_i、agent_position、island_index分層。預設for迴圈生成同場景10個layout只是範例設定，不是已發布benchmark規模。
任務	另一LLM生成使用者要求，agent用CHAT/GOTO/OPEN/CLOSE/PICK/PLACE/SEARCH及appearance/environment檢索處理。object memory接受timestamp/RGB/depth/depth_mask/camera pose/FOV，物件記憶與工具技能不是固定題庫。
題數與資料	episode JSON含scene、agent_position、island_index、objects；需另有pickable/unpickable/receptacle資產檔。記憶相機座標定義為右x、下y、入畫面z。生成器用物件 / 容器box提議位置與contact_test後穩定step；重新隨機layout必須儲存具體初態。
評估方式	two_agent_pipeline 限max_iterations=100，輸出tool_cnt與action_cnt，核讀入口未提供獨立goal-success evaluator。PICK檢查距離<=2及可見性後將物件移到y-10000並設STATIC；PLACE直接設translation/DYNAMIC後step，OPEN/CLOSE直接改joint velocities。這是抽象工具執行條件，不是末端效應器接觸控制benchmark。

依這個順序讀

1. `README.md` ↗
   GitHub · Embodied-VideoAgent/embodied-videoagent · 342c06f727

   精確論文、Habitat環境與sensor座標

   L1–90

---

2. `generate_episodes.py` ↗
   GitHub · Embodied-VideoAgent/embodied-videoagent · 342c06f727

   HSSD父場景、隨機layout與初態輸出

   L1–101 · L136–178

---

3. `env/actions.py` ↗
   GitHub · Embodied-VideoAgent/embodied-videoagent · 342c06f727

   額外no-op/backward actions

   L1–22

---

4. `env/executor.py` ↗
   GitHub · Embodied-VideoAgent/embodied-videoagent · 342c06f727

   工具語義、距離/可見性條件及狀態修改

   L4–10 · L12–19 · L42–53 · L58–70 · L101–107 · L146–176 · L193–207 · L225–254 · L263–279 · L286–293 · L295–307 · L314–321 · L323–373 · L383–400

---

5. `two_agent_pipeline.py` ↗
   GitHub · Embodied-VideoAgent/embodied-videoagent · 342c06f727

   LLM任務生成、工具集、預算與輸出

   L64–70 · L153–159 · L171–177 · L190–204 · L231–244 · L246–270

怎麼接入我們的benchmark

可重用

RGB-D/pose記憶介面、工具回饋、scene/layout初態與部分物理狀態處理。

需要轉換

method連父Habitat/HSSD/資產版本；environment分scene與layout，case需先固定user task生成結果、初始episode及合法sensor/tool約定。工具呼叫、sim actions、dialogue與終態證據分別記錄，另加獨立goal判定後才可列可評測。

仍需補齊

未下載場景 / 模型、執行agent或對外服務。尚缺固定任務清單、task生成seed、獨立success checker與完整初態重播驗證；executor回覆success字串不能單獨當benchmark通過。真實機器人動作轉移需新的控制與驗證。

P044 · HiERO

HiERO: understanding the hierarchy of human behavior enhances reasoning on egocentric videos

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

HiERO是影片表徵與階層活動推理方法；重用Ego4D、EgoClip/EgoMCQ與EgoProceL，不能將下游資料重新計為新任務庫。

> **版本與身份**
>
> README提到2026 HiERO-StepG；本筆核讀固定commit的2025方法倉庫，不合併擴充套件成績。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	影片與clip觀測脈絡、活動圖，不是可互動場景。
任務	影片文字對齊、自然語言或步驟時間定位、程式分割；保持各下游任務身份。
題數與資料	Ego4D原生annotation與特徵；NLQ以clip_uid、annotation_uid、query_idx定位題目，GT為clip_start_sec/clip_end_sec。
評估方式	GoalStep程式計算時間窗IoU與top-K閾值recall；EgoProceL另算MoF、IoU、precision及coverage，各自保留平均方法。

依這個順序讀

1. `README.md` ↗

   GitHub · sapeirone/HiERO · 1b56b0d31f

   確認精確論文、下游資料與後續HiERO-StepG擴充套件。

   L1–92

2. `ego4d_goalstep/utils/evaluate.py` ↗

   GitHub · sapeirone/HiERO · 1b56b0d31f

   核對NLQ資料鍵及IoU/recall。

   L1–81

3. `egoprocel/evaluate.py` ↗

   GitHub · sapeirone/HiERO · 1b56b0d31f

   核對程式評測指標、分母及coverage。

   `L7–17 · L30–40 · L58–68 · L98–108 · L126–139 · L144–180 · L182–186`

怎麼接入我們的benchmark

可重用

原生題目身份、時間窗、父資料引用與評測程式。

需要轉換

以context、資訊題型及時間標註入庫；分開EgoMCQ、NLQ和程式分割case，活動圖不計作物理環境。

仍需補齊

原片與特徵閉合、原生split及共同切分核對、各任務evaluator接線。

P045 · ManipBench

ManipBench: Benchmarking Vision-Language Models for Low-Level Robot Manipulation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

ManipBench將真實機器人影像、布料及模擬影像問答拆成三個倉庫；問答正確率與另行執行機器人的成功率須分開。 2026-10-11 補讀官方直接連結的 robot-side 實作；倉庫有實際執行程式，物理成功由人工輸入紀錄。

> **版本與身份**
>
> Fabric README保留main_old.py為論文版。真實Q1列印len(episodes)分母與回傳有效total_count不同；Q2額外點數註明不是論文指標。 robot-side 固定 e25872ebd357559d5675daa07d05268afd5bd0b8；官方 question README 第25行證明其角色。readme.md 列的 moka_real_world_image_preprocess.py / moka_real_world.py 是伺服器指令且不在此 robot repo 完整 tree；實際本地入口由 run.sh 和 pipeline main 確認。這是已取得的實作與尚待配對的環境 / 伺服器契約，不是空白 README 或整庫 unavailable。

領域	衣物與洗護
環境	題目使用真實或模擬場景影像；圖片不等於相應可互動環境已取得。 補讀 MOKA robot-side 路徑使用 RealSense RGB / depth、已校準的相機到機器人 base 矩陣及預設右臂 / 夾爪；這是需現場設定的物理實驗入口。
任務	真實資料含抓點與路徑選擇、抓點和落點雙問；布料含狀態、空間、時序和反事實題型。
題數與資料	question/options/answer/image或多圖JSON；真實資料用correct_answer.json、wrong_answers_v批次、格點及隨機候選順序；完整圖片外部提供。 補讀：run.sh 指向 moka_real_world_pipeline.py，工作目錄按 tasks/task_name/model_Vversion 建立。info.json 傳 model_info、version、影像與 task_description 路徑、點 / 格數；伺服器 log.json 提供 plan_success、picking_point、points、end_point 和可選 height。相機存 color_image.png、顯示用 depth_image.png 與原始 raw_depth_image.npy；程式用 depth[y,x]/1000 反投影，Z 再加 0.005，經固定 4×4 校準矩陣轉 base。
評估方式	真實Q1解析選項後比對correct標記，Q2分抓點與落點；布料main.py比對答案；模擬指令碼以檔名編碼GT選項。解析失敗、缺檔及分母規則要保留。 補讀：plan_success 只決定是否有抓放點可執行，不能當物理任務成功。generate_exp_seq.py 對模型次序 random.shuffle，執行後人工輸入 y/n，其他輸入記 false，將 {task_name_version: bool} 加入 vlm_list.json 的 task_tested，最後才寫回。已讀路徑沒有由感測器自動判定物理成功；其人工紀錄、執行中止與問答 checker 的分母需分開。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **5** 操作類別 · 原文頁 4
- **7** 額外真機驗證任務 · 原文頁 6
- **12,617** MCQ · 原文頁 3, 4
- **2,662** 布料MCQ子集 · 原文頁 5

依這個順序讀

1. README.md ↗

   GitHub · slurm-lab-usc/ManipBench-Real-Robot-question · 39b4a3c1bd

   區分原作總量、真實問答子集及robot-side倉庫。

   L1–118

---

2. manipbench_question_pipeline.py ↗

   GitHub · slurm-lab-usc/ManipBench-Real-Robot-question · 39b4a3c1bd

   核對候選隨機化、解析及Q1/Q2判分。

   L17–23 · L26–92 · L96–108 · L111–117 · L121–121 · L172–245 · L364–409

---

3. README.md ↗

   GitHub · slurm-lab-usc/ManipBench-Fabric-Manipulation-Code · 7a24890b0e

   確認題型、圖片缺口及新版與main_old差異。

   L1–59

---

4. main.py ↗

   GitHub · slurm-lab-usc/ManipBench-Fabric-Manipulation-Code · 7a24890b0e

   核對題目欄位與答案比較。

   L40–46 · L50–66 · L68–89 · L92–101 · L105–114 · L118–127 · L130–139 · L143–195

---

5. README.md ↗

   GitHub · slurm-lab-usc/ManipBench-Sim-Robot-question · 6d39a15f8a

   確認模擬影像問答範圍。

   L1–46

---

6. `evaluation_scripts/pick_and_place/PutCarrotOnPlate/evaluate_random.py` ↗

   GitHub · slurm-lab-usc/ManipBench-Sim-Robot-question · 6d39a15f8a

   確認GT選項編碼與計分單位。

   L1–140

---

7. `readme.md` ↗

   GitHub · Enyu-Zhao/ManipBench-Real-World · e25872ebd3

   robot-side 真實實驗說明；區分伺服器端指令、相機與機器人操作。

   L1–44

---

8. `run.sh` ↗

   GitHub · Enyu-Zhao/ManipBench-Real-World · e25872ebd3

   倉庫內實際入口是 moka_real_world_pipeline.py，含 task/version/model 與高度引數。

   L1–1

---

9. `image_capture.py` ↗

   GitHub · Enyu-Zhao/ManipBench-Real-World · e25872ebd3

   RealSense z16 / BGR 串流、raw_depth_image.npy、顯示深度圖與回傳的 depth intrinsics。

   L49–133

---

10. `moka_real_world_pipeline.py` ↗

    GitHub · Enyu-Zhao/ManipBench-Real-World · e25872ebd3

    讀 info/log JSON 接線、深度→相機→robot-base、人工逐步執行與抓放 / translate / gripper 呼叫。

    L26–49 · L51–107 · L119–171 · L192–261 · L265–340 · L344–408 · L412–462

---

11. `generate_exp_seq.py` ↗

    GitHub · Enyu-Zhao/ManipBench-Real-World · e25872ebd3

    實驗順序打亂、呼叫機器人 pipeline、人工 y/n 成功判定及寫回 task_tested；不是自動 success checker。

    L20–83

怎麼接入我們的benchmark

可重用

三子集的題目格式、GT、候選生成及答案檢查。 可另重用 robot-side 的 info/log 契約、逐次模型 / 任務版本紀錄及人工成功欄位，作為獨立物理 trial profile。

需要轉換

case保留父episode、題型、候選批次與順序、影像及答案引用；固定抽樣seed，不將候選變換算成新的語義任務。 物理 trial 另保留 task_name、version、model、相機 intrinsics、raw depth 尺度、crop、calibration、抓放點 / 高度、人工判定來源與中止原因；原 VQA profile 不因此改成 robot episode。

仍需補齊

完整圖片、版本一致題目集、統一解析與分母契約；物理操作另需robot-side實驗程式。 更新：robot-side 選定原始碼已補讀；仍需配對伺服器指令碼 / task_description、現場相機 / 機器人設定、可重播試驗清單、人工判定規則與 seed。capture 路徑未記錄 depth_scale 或顯式 RGB-depth 對齊；height_required 分支的 log.height 註解為 mm 卻未作 /1000，需先驗證單位，不能直接執行為標準 case。

P046 · RULSTM

What Would You Expect? Anticipating Egocentric Actions with Rolling-Unrolling LSTMs and Modality Attention

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

RULSTM同一倉庫含2019方法、PAMI擴充套件及EK55/EK100版本；動作前時間窗、資料身份與原生取樣設定須保留。

> **版本與身份**
>
> 現行repo含EK100等後續版本；P046原作EK55設定及後續基線不可合成新資料來源。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	第一人稱影片和特徵LMDB；程式中的env是LMDB讀取環境，不是機器人場景。
任務	動作預測及early recognition；同一標註在多個提前量報分，不等於多個新活動任務。
題數與資料	CSV含標註ID、video、start/end frame與verb/noun/action；LMDB特徵按frame索引。SequenceDataset設定time_step、fps、sequence_length及action_samples，不足歷史者列入discarded_ids。
評估方式	utils.py實作top-k accuracy、逐類平均top-k recall與多時間點結果；TTA使用原生2.0至0.25秒格。EK55/EK100 label space、split及官方JSON需分開。

依這個順序讀

1. `README.md` ↗
   GitHub · fpv-iplab/rulstm · e648c7ee40

   核對論文及兩代資料與CSV。

   L15–94 · L180–229

2. RULSTM/dataset.py ↗

   GitHub · fpv-iplab/rulstm · e648c7ee40

   核對過去和動作內特徵、時間設定與discarded IDs。

   L23–64 · L110–158 · L184–209

---

3. RULSTM/utils.py ↗

   GitHub · fpv-iplab/rulstm · e648c7ee40

   核對top-k、macro recall、TTA和官方輸出。

   L43–96 · L108–155

怎麼接入我們的benchmark

可重用

原生CSV/LMDB欄位、動作對映、時間取樣、排除清單及metrics。

需要轉換

儲存context截止點、提前量、frame到時間換算及label空間；action_features只在合法協定中暴露。

仍需補齊

特徵素材閉合、排除樣本分母、父EPIC資料重複及訓練汙染核對。

P047 · AVT

Anticipative Video Transformer

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

AVT是重用EK55/EK100、EGTEA及50Salads的預測方法；README還固定了外部RULSTM commit，必須把模型repo與父資料 / 評測來源分開。

> **版本與身份**
>
> 原作外部RULSTM固定57842b27d6264318be2cb0beb9e2f8c2819ad9bc；不能預設使用其他commit的評測。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	影片或預取特徵的觀測脈絡，無互動場景定義。
任務	依tau_a提前量及tau_o觀測長度做動作預測，另有未來特徵學習；辨識與預測模式不能混用。
題數與資料	base_video_dataset儲存orig_start/orig_end，轉換出過去視窗和future_i視窗並另記discarded樣本；不同資料根目錄與特徵頻率保留。
評估方式	BasicLossAccuracy對各target型別計cross-entropy、top1/top5；common.utils.accuracy會展平時間維。正式EPIC評測另依README固定的RULSTM介面。

依這個順序讀

1. `README.md` ↗

   GitHub · facebookresearch/AVT · b082c99a6b

   確認精確論文、父資料和指定外部commit。

   L13–55 · L71–142

2. `docs/DATASETS.md` ↗

   GitHub · facebookresearch/AVT · b082c99a6b

   核對其他資料集標註來源。

   L1–20

3. `datasets/base_video_dataset.py` ↗
   GitHub · facebookresearch/AVT · b082c99a6b

   讀時間視窗、future與discard規則。

   L23–32 · L38–71 · L73–79 · L82–100 · L106–112 · L116–138

---

4. `func/train_eval_ops.py` ↗
   GitHub · facebookresearch/AVT · b082c99a6b

   讀target/logits與分類指標。

   L10–37 · L51–102 · L113–121 · L129–159

---

5. `common/utils.py` ↗
   GitHub · facebookresearch/AVT · b082c99a6b

   核對accuracy分母和多維輸出處理。

   L17–44

怎麼接入我們的benchmark

可重用

時間窗轉換、target字典、標籤空間及原生metric。

需要轉換

case分開context、未來reference、tau_a/tau_o和資料版本；future欄位作訓練目標或評分證據，不能自動全部給推論端。

仍需補齊

素材閉合、外部RULSTM指定版本、discarded分母與共同split核對。

P048 · EGO-TOPO

EGO-TOPO: Environment Affordances from Egocentric Video

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

EGO-TOPO把影片中的活動區域建成圖，再用於動作預測；圖節點不是已重建且可操作的房屋場景。

> **版本與身份**
>
> EPIC/EGTEA資料與其後AntGPT等工作重用，不能將圖或模型論文各自的資料量相加。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	EPIC55與EGTEA影片、推斷的活動區域及訪問圖；儲存video來源與時間關係。
任務	拓撲活動圖與長期動作預測，是既有資料上的方法 / 表示，不新增獨立資料集。
題數與資料	每影片graph.pth、locnet特徵與配對分數；epic_utils用video、start/end frame、labels及圖歷史選出指定frame的圖。
評估方式	metrics.py提供top-k accuracy、逐類平均top-k recall與TTA；圖建構品質和動作預測分數需分項。

依這個順序讀

1. `README.md` ↗

   GitHub · facebookresearch/ego-topo · 81b5396e2a

   確認論文身份、父資料與建圖/預測流程。

   L1–95

2. `build_graph/README.md` ↗

   GitHub · facebookresearch/ego-topo · 81b5396e2a

   確認graph及pairwise score產物。

   L1–51

3. `anticipation/anticipation/datasets/epic_utils.py` ↗

   GitHub · facebookresearch/ego-topo · 81b5396e2a

   核對frame範圍、訪問標籤與歷史圖選擇。

   L13–19 · L23–33 · L35–53 · L68–74 · L95–101 · L105–115 · L117–154 · L165–169

---

4. `anticipation/anticipation/utils/metrics.py` ↗

   GitHub · facebookresearch/ego-topo · 81b5396e2a

   核對accuracy、macro recall和TTA。

   L1–55

怎麼接入我們的benchmark

可重用

父影片ID、圖 / visit時間、特徵引用與動作評測。

需要轉換

圖存context衍生資源，保留產生器和source hash；用觀測截止點取圖歷史，不把完整未來圖自動暴露給模型。

仍需補齊

原片與預計算特徵、建圖視窗/切分核對及evaluator接線。

P049 · AntGPT

AntGPT: Can Large Language Models Help Long-term Action Anticipation from Videos?

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

AntGPT用LLM產生未來動作序列；Ego4D v1/v2、EPIC55及EGTEA仍是父資料，文字解析及序列修補是評測契約的重要部分。

> **版本與身份**
>
> 此核讀針對指定GPT ICL指令碼；不能把其他GPT/Llama/Transformer指令碼的配置及成績當同一協定。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	影片、caption / 動作上下文和既有資料切分，非互動模擬環境。
任務	長期verb/noun/action序列預測；候選序列及不同語言模型不增加獨立任務。
題數與資料	taxonomy/dicts.json、上下文與未來動作文字、LLM回應及相似度檢索池；指令碼將序列截斷或補齊為20動作，並做詞彙對映。
評估方式	eval_icl.py逐樣本取K候選最小正規化editdistance.eval。短/空答案有補齊策略，未知詞有模糊匹配和預設類別；action ED在此指令碼使用verb/noun索引相加，需與官方定義核對。

依這個順序讀

1. `README.md` ↗

   GitHub · brown-palm/AntGPT · 2dbc211ae8

   確認原作和多個父資料版本。

   L15–114

2. `GPT_models/ICL_COT/eval_icl.py` ↗

   GitHub · brown-palm/AntGPT · 2dbc211ae8

   讀序列修補、詞彙fallback、K候選評分與輸出。

   L3–15 · L17–25 · L36–112 · L142–150 · L162–170 · L193–201 · L203–229

怎麼接入我們的benchmark

可重用

父資料血緣、候選輸出、vocab對映與原作解析 / 評分程式。

需要轉換

case儲存上下文模式、候選K、20個動作的horizon、prompt/檢索池版本及修補規則；不得把20動作當20秒或20道新題。

仍需補齊

原始素材及split閉合、解析失敗處理、action度量對照官方evaluator及本庫協定。

P050 · PALM

PALM: Predicting Actions through Language Models

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

已找到作者名下的PALM程式，README明列動作辨識、影像描述與語言模型預測三個模組；不能把論文引用的VideoBLIP倉庫當成PALM。

> **版本與身份**
>
> 固定commit為7d4e6cd6426a51857214cdd3ec818568624ab320。metric註解提到Damerau，但實作呼叫editdistance.eval；移植時應保持函式及套件版本，不能只照註解更換公式。annotation_utils也有作者本機絕對路徑，需改成版本化資料引用。
>
> GitHub精確名稱搜尋找到kim-sanghwan/PALM；README自述為ECCV2024 PALM官方實作，論文標題與作者Sanghwan Kim相符。原PDF只列VideoBLIP等引用，已分開處理。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	Ego4D影片與clip觀測脈絡；annotation_utils將clip_uid映到video_uid和影片scenario，這些不是機器人可互動場景。
任務	先取得辨識動作與影像caption，再預測未來verb/noun序列；本篇是重用既有長期動作預測資料的方法，不新增獨立機器人工作庫。
題數與資料	README指定recognized-action JSON與caption JSON進入預測模組；annotation_utils保留clip/video關係，並將原生verbs/nouns詞彙及同義字映成taxonomy索引。
評估方式	eval_utils對形狀N×Z×K的候選序列計正規化editdistance.eval，逐樣本取K候選最小值再平均；AUED對不同字首長度的ED做梯形積分。K、Z和文字到標籤解析都影響分數。

依這個順序讀

1. `README.md` ↗

   GitHub · kim-sanghwan/PALM · 7d4e6cd642

   核對精確論文身份及三階段輸入輸出。

   L1–9

2. `action_anticipation_module/EGO4D-prediction/utils/annotation_utils.py` ↗

   GitHub · kim-sanghwan/PALM · 7d4e6cd642

   核對clip/video關係和原生verb/noun對映。

   L1–100

---

3. `action_anticipation_module/EGO4D-prediction/utils/eval_utils.py` ↗

   GitHub · kim-sanghwan/PALM · 7d4e6cd642

   核對候選最小ED、字首AUED與實際呼叫。

   L1–59

怎麼接入我們的benchmark

可重用

三段模型輸入路徑、clip/video血緣、詞彙對映、候選序列與ED/AUED程式。

需要轉換

建立以原生clip與觀測截止點為鍵的forecast case；分開模型可見的辨識動作、caption、未來GT及候選預算，保留taxonomy和解析規則版本。

仍需補齊

原始影片、辨識/caption中間檔與split閉合；需核對原作配置的預測長度、候選數及依賴版本，並接回正式Ego4D評測。

P051 · USST / EgoPAT3D trajectories

Uncertainty-aware State Space Transformer for Egocentric 3D Hand Trajectory Forecasting

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

USST的實作包含EgoPAT3D-DT / H2O-PT重標註資料流程；未來手軌跡須連同觀測比例、相機座標與seen / unseen切分儲存。

> **版本與身份**
>
> 已核讀EgoPAT3D主要資料與評分路徑；不將H2O分支或外部EgoPAT3D新版本視為已同等驗證。

領域	居家整理與清潔、穿戴互動與動作介面
環境	第一人稱影片中的既有拍攝場景；EgoPAT3D loader明列scene與record切分，不是新增可操作模擬場景。
任務	由過去影像 / 位置預測未來2D或3D手部軌跡；global與local版本是不同座標 / 輸入設定。
題數與資料	EgoPAT3D的pkl含traj2d、traj3d及num_preserve；mp4和T×4×4 odometry以scene/record/clip對齊。loader儲存有效長度、正規化引數並裁切或補零。
評估方式	utils先反正規化，再依觀測比例計逐軌跡平均歐氏距離ADE、最後一點FDE及各軸絕對誤差；3D、2D畫素、norm2d不可混報。test.py分開seen與unseen。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **14** EgoPAT3D-DT scenes · 原文頁 6
- **3,715** H2O-PT test windows · 原文頁 6
- **1,605** EgoPAT3D-DT seen-test windows · 原文頁 6
- **2,334** EgoPAT3D-DT unseen-test windows · 原文頁 6

依這個順序讀

1. README.md ↗
   GitHub · oppo-us-research/USST · beebdb963a

   確認論文身份、EgoPAT3D-DT / H2O-PT及模型設定。

   L1–110

---

2. src/EgoPAT3DLoader.py ↗
   GitHub · oppo-us-research/USST · beebdb963a

   讀scene split、軌跡欄位、odometry與有效長度。

   L28–36 · L38–87 · L90–137 · L146–190 · L194–205 · L208–231 · L233–308

---

3. src/utils.py ↗
   GitHub · oppo-us-research/USST · beebdb963a

   讀反正規化、觀測比例及實際ADE/FDE。

   L57–205

---

4. test.py ↗
   GitHub · oppo-us-research/USST · beebdb963a

   確認seen / unseen及eval_space分項。

   L52–74 · L76–88

怎麼接入我們的benchmark

可重用

父資料ID、場景切分、軌跡 / odometry欄位與原生距離函式。

需要轉換

case保留scene/record/clip、有效影格、觀測比例與座標系；camera pose是觀測或轉換證據，不能當作robot action。

仍需補齊

原始影片與重標註資產閉合、H2O專用loader / 評分分支細讀及可執行adapter驗證。

P052 · StillFast

StillFast: An End-to-End Approach for Short-Term Object Interaction Anticipation

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

StillFast在Ego4D STA上預測下一個互動物件、動作與接觸時間；官方測試提交和本機validation必須分開記錄。

> **版本與身份**
>
> 本機Overall mAP有更多診斷組合，不等於官方只報的STA欄位；靜態核讀還發現add的空字典分支有不可達的內層len(preds)>0條件，整合前須核對空輸出對分母的影響。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	Ego4D影片的觀測影格及短歷史片段，無互動模擬環境。
任務	共同預測box、noun、verb、time_to_contact；四種STA指標組合不是四份獨立素材。
題數與資料	annotation以uid、video_id、frame和objects索引；objects含box / noun_category_id / verb_category_id / time_to_contact。訓練標籤有noun+1與依ROI版本決定的verb offset，輸出JSON再還原。
評估方式	實際validation呼叫OverallMeanAveragePrecision(top_k=5)：IoU嚴格大於0.5、TTC誤差不超過0.25；依GT數折免(K−1)×GT個高分false positives。正式成績依README指定的Ego4D evaluator / 隱藏test。

依這個順序讀

1. `README.md` ↗

   GitHub · fpv-iplab/stillfast · 199ba4902b

   確認Ego4D v1/v2、資料與官方評分入口。

   L1–102

2. `stillfast/datasets/ego4d_sta_still.py` ↗
   GitHub · fpv-iplab/stillfast · 199ba4902b

   讀UID、影格、objects和類別offset。

   L17–23 · L34–41 · L48–54 · L56–67 · L78–84 · L93–136 · L144–154

---

3. `stillfast/tasks/sta.py` ↗
   GitHub · fpv-iplab/stillfast · 199ba4902b

   追到validation metric與提交JSON的類別還原。

   L1–178

---

4. `stillfast/evaluation/sta_metrics.py` ↗
   GitHub · fpv-iplab/stillfast · 199ba4902b

   讀匹配、K個false-positive折免及STA具體條件。

   L2–6 · L15–19 · L32–40 · L61–203 · L205–217 · L233–237 · L266–270 · L288–292 · L294–298 · L308–312 · L359–363 · L368–378 · L380–388 · L398–402 · L407–411 · L414–420 · L428–439 · L463–467 · L487–491 · L496–500 · L523–529 · L532–543 · L551–555 · L566–592

怎麼接入我們的benchmark

可重用

STA annotation、uid結果格式、類別offset還原及原生匹配規則。

需要轉換

case保留版本、frame / 歷史視窗、物件GT與TTC單位；box數與影片題數分開，evaluator儲存top_k、IoU/TTC及類別平均規則。

仍需補齊

影片 / LMDB與split閉合、官方evaluator版本對照及空預測 / 標籤offset邊界案例核對。

P053 · HandsOnVLM

HandsOnVLM: Vision-Language Models for Hand-Object Interaction Prediction

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

HandsOnVLM公開了EPIC手軌跡與reasoning資料介面；核讀發現評分變數命名和實際函式不一致，必須保留程式版本並先校核。

> **版本與身份**
>
> 靜態核讀另見inference正常回傳3項而evaluate_epic_kitchen_traj以2項接收；尚未執行，不能宣稱此commit可直接跑通或原文數值有相同問題。

領域	餐飲與烹飪、穿戴互動與動作介面
環境	EPIC-KITCHENS第一人稱影片與人類手軌跡；reasoning子集由有對應提問的影格篩選。
任務	一般或文字條件的雙手未來2D軌跡預測；預設評估入口是ek100 validation，非所有父資料的統一測試。
題數與資料	dataset提供future_hands[2,5,2]、future_valid[2]、contact_point、image_abs_paths及prompt；評分移除首點後用雙手×4個未來點。reasoning用valid_index篩子集，影像張量的重複不增加題數。
評估方式	traj_eval含ADE/FDE與四步加權WDE、位置及手的有效遮罩；但evaluate_traj_stochastic把compute_fde存為ade、compute_ade存為fde，最後回傳均值而非已算出的min。推論包裝還跳過無效生成，需另報覆蓋率。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **2** hand-prediction task formulations · 原文頁 5
- **8,000** Ego4D zero-shot generated query pairs（約數） · 原文頁 6
- **7,500** EPIC generated query pairs（約數） · 原文頁 6

依這個順序讀

1. `README.md` ↗

   GitHub · Kami-code/HandsOnVLM-release · 1163d45a7b

   確認精確論文、資料及評估入口。

   L1–110

---

2. `docs/prepare_data.md` ↗

   GitHub · Kami-code/HandsOnVLM-release · 1163d45a7b

   確認EPIC、Drive資產與LITA依賴。

   L1–6

---

3. `handsonvlm/dataset/epic_dataset.py` ↗

   GitHub · Kami-code/HandsOnVLM-release · 1163d45a7b

   讀future欄位、影像與reasoning子集。

   L11–46 · L48–72 · L77–102 · L111–118 · L122–155 · L158–158

---

4. `handsonvlm/evaluation/evaluate.py` ↗

   GitHub · Kami-code/HandsOnVLM-release · 1163d45a7b

   確認實際ek100 validation入口。

   L1–26

---

5. `handsonvlm/evaluation/handsonvlm_inference.py` ↗

   GitHub · Kami-code/HandsOnVLM-release · 1163d45a7b

   讀輸出有效性、四步擷取及metric接線。

   L7–64 · L109–138 · L142–151 · L155–177 · L214–224

---

6. `hoi_forecast/evaluation/traj_eval.py` ↗

   GitHub · Kami-code/HandsOnVLM-release · 1163d45a7b

   讀實際遮罩、ADE/FDE呼叫與WDE計算。

   L2–254

怎麼接入我們的benchmark

可重用

EPIC來源鏈、prompt / 軌跡欄位、reasoning篩選和有效遮罩。

需要轉換

case保留提問、原始影格ID、2D正規化座標、4步時間點與valid masks；metric儲存實際函式、候選數及失敗輸出處理，不直接信任列印名稱。

仍需補齊

外部資產及原始EPIC影片、時間步長核對、評分命名 / 均值修正對照與完整推論接線。

P054 · EgoVid-5M / EgoDreamer

EgoVid-5M: A Large-Scale Video-Action Dataset for Egocentric Video Generation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoVid的公開repo主要是Ego4D衍生影片標註與清洗工具；相機運動控制標註不能直接視為可執行機器人控制。

> **版本與身份**
>
> 本筆覆蓋公開資料處理路徑；不宣稱EgoDreamer模型或所有外部清洗依賴已核讀。

領域	居家整理與清潔、辦公與教育、工藝與修繕、休閒與運動
環境	Ego4D v1/v2來源影片及clip視窗；來源影片須另行取得。
任務	文字 / 相機運動條件的第一人稱影片資料；本次固定tree見標註、pose及品質計算工具，未取得完整EgoDreamer生成 / 評測實作。
題數與資料	CSV的video_id=來源影片_起始影格_終止影格，含fps、frame_num、noun/verb、llava_cap、name和各項品質分數；pose資產含3×3 intrinsics及逐影格4×4相機外參。README提醒raw IMU已知問題。
評估方式	光流清洗程式每8影格取樣，將flow按平均影像尺寸縮放到512基準，再存均值 / 分箱比例；這是素材品質證據，不是操作成功率。flow_0_4程式實為>0且≤5，與欄名 / README有差異。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **5,000,000** EgoVid clips（名義約數） · 原文頁 4
- **1,200** EgoVid-val samples（約數） · 原文頁 7
- **65,000** kinematic-annotated subset（約數） · 原文頁 7

依這個順序讀

1. README.md ↗
   GitHub · JeffWang987/EgoVid · 45c59d0df9

   確認來源素材、CSV、pose欄位與精確論文。

   L1–120

---

2. processor/egovid-metadata/Optical-flow/optical-flow-score.py ↗
   GitHub · JeffWang987/EgoVid · 45c59d0df9

   核對frame步長、尺寸正規化及分箱實作。

   L1–30 · L45–138

怎麼接入我們的benchmark

可重用

父影片ID、精確clip範圍、文字 / pose標註和清洗provenance。

需要轉換

source記Ego4D重用關係；case保留frame/fps、caption來源、pose座標與quality filter版本。5M名稱不能直接算成本庫已取得評測題數。

仍需補齊

完整CSV與影片 / pose資產閉合、實際clip去重、生成模型與正式evaluator，以及清洗欄名 / 實作差異校核。

P055 · FUTR

Future Transformer for Long-term Action Anticipation

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

FUTR重用Breakfast與50Salads，預測動作類別及持續比例；觀測 / 預測百分比和frame級MoC是原生協定的一部分。

> **版本與身份**
>
> FUTR是方法repo，父資料與EGO-TOPO / 其他預測方法可能重用；樣本視窗與原片不能重複相加。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	既有長影片及預計算視覺特徵，無新可操作場景。
任務	從過去影片預測後續動作分段；一支影片的多個觀測比例是不同評測設定，不是不同語義任務。
題數與資料	groundTruth逐影格標籤、features/*.npy及mapping.txt；dataset返回features、past_label、trans_future_target、trans_future_dur，保留sample_rate、NONE、pad_idx及n_query截斷。
評估方式	predict.py將預測類別 / duration展開到未來影格，再按觀測與預測比例擷取；eval_file累積每類正誤影格，最後對有GT的類別平均得到MoC，非全影格micro accuracy。

依這個順序讀

1. README.md ↗
   GitHub · gongda0e/FUTR · a3440100ef

   確認精確論文、父資料與split / 觀測比例。

   L1–97

2. `data/basedataset.py` ↗
   GitHub · gongda0e/FUTR · a3440100ef

   讀特徵 / GT視窗、duration與padding規則。

   L1–162

---

3. `predict.py` ↗
   GitHub · gongda0e/FUTR · a3440100ef

   讀duration展開、擷取視窗和MoC類別平均。

   L8–14 · L42–48 · L69–111

---

4. `utils.py` ↗
   GitHub · gongda0e/FUTR · a3440100ef

   核對每類影格正誤與duration正規化入口。

   L7–20 · L23–31 · L39–60

怎麼接入我們的benchmark

可重用

來源影片 / split、逐影格GT、類別字典與MoC計算。

需要轉換

case保留來源影片長度、obs_fraction、pred_fraction、特徵步長及label mapping；duration比例要連同影片長度儲存，不改寫成固定秒數。

仍需補齊

影片 / 特徵閉合、Breakfast四split / 50Salads五split核對及共同輸出adapter。

P056 · Forecasting hands and objects

Forecasting Hands and Objects in Future Frames

實作尚未確認 · 方法 / 綜述 · 原作 · 獨立頁面

已核對論文前四頁與現有GitHub搜尋紀錄；本輪未找到可確認的作者實作，不能把同名時間序列或較新物件預測repo當原作。

> **版本與身份**
>
> 核對的是1705.07328v3論文及本輪搜尋範圍；未找到不等於全網證明不存在。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	論文的第一人稱與街景影片觀測；未取得對應的互動環境或程式資料契約。
任務	從當前影格預測未來手 / 物件是否出現及其bounding boxes，包含當前不可見物件；不是機器人動作執行。
題數與資料	論文顯示當前影像 / 光流、未來時間與框標註的研究設定；公開資料檔、欄位和原生split仍未確認。
評估方式	論文討論未來物件presence/location及AP；原作評分指令碼未取得，本筆不宣稱程式或數值已重現。

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

可保留來源、預測目標與時間視野的定義參考。

需要轉換

先作方法參考登記；取得影片、future boxes、標籤與split後，才可建立完整forecast cases。

仍需補齊

作者倉庫、資料manifest、確切欄位和可執行evaluator。

P057 · Motor attention and action forecasting

Forecasting Human-Object Interaction: Joint Prediction of Motor Attention and Actions in First Person Video

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

作者實作可讀出 EGTEA / EPIC 的動作、手部與接觸點資料格式；分類評分可追到實作，但手部 / hotspot 測試入口停留在視覺化版本，不能宣稱完整重現論文評測。

> **版本與身份**
>
> 固定 77675f97143202b0a8e4555a3f30334ebe3c219f（2019-11-22），早於已讀的 2020 v2 論文。設定引用作者本機路徑；本輪未下載資料 / 權重，未將被註解的實驗碼當成有效評分器。
>
> 論文為 Liu、Tang、Li、Rehg 的 Forecasting Human-Object Interaction: Joint Prediction of Motor Attention and Actions in First Person Video（arXiv:1911.10967；本地 PDF 為 v2 / ECCV 2020）。論文連至作者頁，作者頁同列本 repo、相同 arXiv ID、四位作者及額外標註；頁面標題的 Egocentric Activity 是同一作品的標題差異。Repo 是方法與既有 EGTEA / EPIC 資料的轉接實作，不是另一套獨立機器人任務庫。

領域	餐飲與烹飪、穿戴互動與動作介面
環境	既有 EGTEA Gaze+ / EPIC-Kitchens 的人類第一視角廚房影片。論文 §4.1 將 EGTEA 轉為 320×256、24 fps，EPIC 為 512×288、30 fps；手部與接觸位置投影在最後可觀測影格，沒有可執行機器人環境。
任務	聯合預測未來 verb/noun/action、motor attention 與 interaction hotspot。EGTEA 用 split1、提前 0.5 秒；EPIC 用指定 train/val 做消融、提前 1 秒，challenge seen/unseen 另列。106 / 2513 是各設定的 action 類數；論文補充的 7381 / 14951 是額外標註樣本數，不是新任務數。
題數與資料	根層 video_list 與 verb_dict/noun_dict/action_dict；每筆 filename、video_info.{width,height,fps,num_frames}、label=[verb,noun,action]、target。EPIC target=[hotspot_xy,fingertip_xy]，整數代表缺失；以 12 點直線插值產生手部熱圖。EGTEA target=[hand,hotspot_xy]，hand 有 12 筆 [x1,y1,x2,y2,num_hand]；num_hand=0 或 hotspot=(0,0) 改用均勻先驗。座標是各自影像畫素，缺失標記不能轉成真實原點；通用 convert_dataset.py 的產物並不足以供 joint loader 使用。

評估方式	eval_joint.py 對原圖 / 水平翻轉分類輸出取平均，計 top-1/top-5（%）與 mean class accuracy；後者對所有設定類別取平均，零支援類別依 epsilon 得零。論文 §4.3 另報 hotspot F1/KLD 與手部平均 / 最終位移（空間 / 時間下取樣後正規化；手部結果僅 EGTEA）。但 test_joint.py 的 compare_hotspot 忽略輸入預測，改造三張 8×8 中心先驗；compare_hand 用 GT 最大值>0.01 的切片、argmax 點歐氏距離，末項取扁平化後最後有效切片，函式本身沒有論文正規化。這些評分呼叫與彙總均被註解；不能將函式名稱視為已接通的論文評測。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **3** joint forecasting endpoints · 原文頁 11

依這個順序讀

1. `README.md` ↗

   GitHub · 2020aptx4869lm/Forecasting-Human-Object-Interaction-in-FPV · 77675f9714

   核對訓練 / 測試入口與外部資料、權重依賴。

   L1–23

2. `exp_configs/egtea-o/egteao-action_split1_i3d_res50v1_vae.json` ↗

   GitHub · 2020aptx4869lm/Forecasting-Human-Object-Interaction-in-FPV · 77675f9714

   確認 106 類、split1 設定、32 幀步長 2 與私人資料路徑。

   L1–28

3. `exp_configs/epic-kitchens/epic-kitchens-action_trainval_i3d_csn152_vae.json` ↗

   GitHub · 2020aptx4869lm/Forecasting-Human-Object-Interaction-in-FPV · 77675f9714

   確認 EPIC train/val 的 2513 action 類及獨立設定。

   L1–30

4. `libs/datasets/custom_dataset_joint.py` ↗

   GitHub · 2020aptx4869lm/Forecasting-Human-Object-Interaction-in-FPV · 77675f9714

   讀實際 JSON keys、兩資料集相反的 target 順序、12 時片熱圖與缺失標註處理。

   L22–56 · L223–253 · L256–369 · L382–509 · L522–590

5. `tools/convert_dataset.py` ↗

   GitHub · 2020aptx4869lm/Forecasting-Human-Object-Interaction-in-FPV · 77675f9714

   README 的通用轉換器只寫 label_dict/video_list，並未產生 joint loader 必要欄位或 EPIC 分支。

   L68–70 · L74–147

---

6. `eval_joint.py` ↗

   GitHub · 2020aptx4869lm/Forecasting-Human-Object-Interaction-in-FPV · 77675f9714

   核對推論翻轉平均及實際只計分類 top-1/top-5、mean class accuracy。

   L59–64 · L97–108 · L127–216

---

7. `libs/utils/metrics.py` ↗

   GitHub · 2020aptx4869lm/Forecasting-Human-Object-Interaction-in-FPV · 77675f9714

   確認按樣本加權的 top-k 百分比與 confusion matrix 各列召回的平均。

   L21–86

---

8. `test_joint.py` ↗

   GitHub · 2020aptx4869lm/Forecasting-Human-Object-Interaction-in-FPV · 77675f9714

   核對 hotspot 中心先驗覆寫、有效手部切片的位移演算法與被註解的評分 / 輸出。

   L78–215 · L298–407 · L440–461 · L486–554

怎麼接入我們的benchmark

可重用

保留父資料集 / split 身分、類別字典、clip 引用、原生熱圖建置及分類指標實作。

需要轉換

case 以父資料集+split+filename 定位，task 分為分類、接觸點與手部預測；按資料集解開 target，附影像大小、提前時間、畫素 / 熱圖座標和真實 / 插值 / 均勻先驗標記。evaluator 分別保留分類、F1/KLD、位移單位。

仍需補齊

需取得作者額外 joint JSON、標註與可觀測 clip 邊界，重建相符類別字典；修復 / 驗證 hotspot 與手部評分入口、正規化及有效切片彙整，再做執行驗證。

P058 · EgoPAT3Dv2

EgoPAT3Dv2: Predicting 3D Action Target from 2D Egocentric Vision for Human-Robot Interaction

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoPAT3Dv2 的作者 repo 同時保留原版與擴充版讀取器；可追到逐幀 3D 目標誤差與進度分箱，但 HDF5 版本、手部特徵錯寫及評分彙整差異須先處理。

> **版本與身份**
>
> 固定 a24b3a5a2453931de69a17dfc7116057dc849136（2024-03-19）。configs/README.md 在 manifest 中是空檔；README 測試命令未帶程式所需 model_epoch/checkpoint。test_DDP 後處理固定 4K 內參，v>=2160 分支錯改 u，且 x1/y1 使用前輪 z；重現前須確認保留原行為或另列修正版。論文 §IV-A 說擴充分配 9+2 新場景，§V-B 又說新增12場景，不能以文字自行決定總場景數。
>
> README 的完整標題、十一位作者與論文 arXiv:2403.05046v1 一致；論文指定的 ai4ce 專案頁直接連本 repo 與 Hugging Face 資料。這是 ICRA 2024 EgoPAT3Dv2 的實作及 EgoPAT3D 擴充資料入口，原版 D1 與擴充版 D2 有重用關係，不能加總當作兩份互斥資料集。

領域	協助、交接與陪伴、穿戴互動與動作介面
環境	頭盔安裝 Azure Kinect 的人類物件操作影片。論文 §VI 的 UR10e 避讓 / 朝預測點移動是另行展示；已讀 repo 提供預測資料與模型測試，沒有該展示的機器人任務成功評分器。
任務	線上以 X1:t 預測同一段操作最終 3D 手部目標；目標必須轉到當前影格相機座標，並非未來全身動作或機器人控制。T1/T2 指原版 / 擴充訓練來源，D1/D2 指測試資料版本，seen/unseen 指場景是否在訓練出現。論文報告可用 clips 由 4129 增為 9579；本輪未下載資產核算此數。
題數與資料	原版 HDF5 用 /{annotrain|annovalidate|annotest}/{scene}/{video} 與 /sequences/{scene}/{video}/{color,transformation/odometry}；擴充版將 /color/{scene}/{video}/{frame} 與 annotation、/transformation/{scene}/{video}/{frame} 分置兩檔。annotation 每列前三值為三個邊界，3:6 / 6:9 為兩段目標 xyz；原版要求 z>0.1，擴充版 z>0。長度=end-start、RGB 讀 start+1...end，累乘 odometry 後以逆矩陣轉換目標，單位公尺。RGB resize 224×224；training 直接排除長度>25 的 clips，測試以最長段補零並回傳真實長度。handLM 為 21×2、hand 為 landmark 5 的 x/y；兩 RGB 讀取器的 handLM 奇數欄實際也寫 lm.x，不能當成正確的 x/y 特徵。

評估方式	test_DDP.py 依模型 / epoch、scene、video 輸出 start-end.txt（逗號分隔 xyz）與 start-end_gt.txt。eval.py 算每幀 ‖pred-gt‖2，以 i/(L-1) 落入十個寬 0.1、兩端皆包含的區間；先在 clip 內平均，再平均同 recording 的 clips，最後等權平均 recordings，×100 得 cm；Overall 使用 linspace(2,1,10) 加權。邊界影格可能進入相鄰兩箱，短 clips 可出現空箱。論文 §IV-B 寫按影格等分十階段、餘數給較早階段，並報三個 seed 平均；目前入口不自動做三 seed 彙整。eval.py 的 --mode 是 store_true，僅用於輸出命名，真正 split 由 test_DDP 的設定決定。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **22** 原版＋新增scenes · 5+6+9+2推算 · 原文頁 4

依這個順序讀

1. `README.md` ↗

   GitHub · ai4ce/EgoPAT3Dv2 · a24b3a5a24

   確認作者 / 論文、外接 HDF5 資料及 test_DDP→eval.py 流程。

   L1–45

2. `configs/cfg_defaults.py` ↗

   GitHub · ai4ce/EgoPAT3Dv2 · a24b3a5a24

   確認原版 / 擴充版、seen/unseen、單筆測試 batch 及預設路徑。

   L15–35 · L42–75

3. `configs/cn_t_post_hand_newloss_1_d1_seen.yaml` ↗

   GitHub · ai4ce/EgoPAT3Dv2 · a24b3a5a24

   實際 D1 seen RGB 設定與作者 HPC 路徑。

   L1–21

4. `data_utils/Dataset_RGBD.py` ↗

   GitHub · ai4ce/EgoPAT3Dv2 · a24b3a5a24

   原版 annotation、color/odometry、有效深度門檻及逐幀轉換。

   L10–114

5. `data_utils/Dataset_RGBD_enhanced.py` ↗
   GitHub · ai4ce/EgoPAT3Dv2 · a24b3a5a24

   擴充版兩個 HDF5 的群組、clip 篩選、影格偏移與手部輸出。

   L13–120 · L136–140

---

6. `data_utils/testDataset.py` ↗
   GitHub · ai4ce/EgoPAT3Dv2 · a24b3a5a24

   區分舊 pointcloud/IMU 基線所需欄位，避免誤列為 RGB 方法必要輸入。

   L9–34 · L42–100

---

7. `test_DDP.py` ↗
   GitHub · ai4ce/EgoPAT3Dv2 · a24b3a5a24

   追 seen/unseen 讀取器分派、真值 / 預測輸出及固定內參後處理。

   L19–38 · L58–87 · L160–237 · L256–261

---

8. `eval.py` ↗
   GitHub · ai4ce/EgoPAT3Dv2 · a24b3a5a24

   核對歐氏誤差、公分單位、含雙端點的十箱及 recording 層級平均。

   L45–61 · L92–104 · L248–282 · L284–345 · L397–409

怎麼接入我們的benchmark

可重用

scene/video/clip 邊界、逐幀目標與 odometry 引用、D1/D2 及 seen/unseen 分派、歐氏誤差實作。

需要轉換

case 儲存 dataset_version+split+scene+video+start/end，附實際影格索引、公尺相機座標、有效長度與手部缺失遮罩；evaluator 明列進度分箱、recording 平均、Overall 時間權重與 seed。原版 / 擴充版以來源重用關係相連。

仍需補齊

需取得並固定 Hugging Face HDF5 版本 / 場景清單，核對修正版標註與影格取樣時間；修正或隔離 handLM 的 x/x 特徵、補足 checkpoint/model_epoch 引數與私人路徑，再驗證評分分箱及後處理。

P059 · EMAG

EMAG: Ego-motion Aware and Generalizable 2D Hand Forecasting from Egocentric Videos

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

EMAG 是重用 Ego4D / EPIC-Kitchens-55 的雙手位置預測方法。已讀資料與 ADE/FDE 計算程式，但公開設定、讀取器與 trainer 的欄位 / 時間維度不一致；不可標成可直接執行的跨資料集評測。

> **版本與身份**
>
> 固定 0386bd9de2bd2ec3504e5b645a095c46e9a565ca（2025-03-25），與 2024 論文區分。loader 傳 ego_feat，trainer 卻讀 egos_input；loader 保留五時點且沒有裁切，test_step reshape 明定四時點；兩份設定皆未定義 trainer 初始化所讀的 model_config.loss。論文稱 homography，檔案路徑 / 變數稱 fundamental/fmat，未取得矩陣資產前不能宣稱兩者等價。非截斷 tree 未列 EPIC 專用 loader 或前處理釋出。
>
> README 自稱 ECCVW 2024 官方實作，列 Hatano、Hachiuma、Saito，與 arXiv:2405.20030 論文及其指定作者頁一致；作者頁 Code 連至 masashi-hatano/EMAG。論文也引用 SORT、hoi-forecast、EGO4D/forecasting 作為相關工具 / 比較方法，不能把它們替代成本論文的實作。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	論文在 EPIC-Kitchens-55 廚房影片及 Ego4D 多種人類活動上做同資料集 / 跨資料集預測；資料屬人類第一視角影像，沒有機器人可執行動作介面。已讀程式入口使用 Ego4D schema，EPIC 另有設定但沒有獨立 loader / 轉換指令碼。
任務	論文 §4.2 用八張 4 FPS 觀測，預測未來一秒四時點的左右手 2D 位置，並以未來 ego-motion 為輔助訓練目標。跨資料集的方向（EPIC→Ego4D 或反向）及 train/val 必須各自保留；活動類別分析不是新增機器人任務。
題數與資料	讀 annotations/fho_hands_{mode}.json 的 /clips/*/{video_uid,clip_uid,frames}，由 frames/*/{pre_45,pre_30,pre_15,pre_frame,contact_frame}/boxes 的 left_hand/right_hand 建立 [2,5,2] 座標與 [2,5] mask；以來源 w/h 正規化。排除設定 delete 清單、pre_45.clip_frame≤interval×8 或全零 mask。輸入 image_frame/{clip_uid}/{frame:06d}.png、optical_flow/{clip_uid}/npy/*.npy、fundamental/{clip_uid}/*.npy，另讀 hand-objects/interval={interval}/{clip_uid}/{pre45}.pkl 的 bboxes_obj/bboxes_hand/attention_mask。回傳 frames、flows、bboxes、ego_feat、future_hands、future_egos、hands_mask、egos_mask 與影格 h/w；八個觀測索引終於 pre45-interval。影格步長不能直接當秒；pickle 與影像均未下載 / 反序列化。

評估方式	論文 §4.3 定義影像高度256 px尺度的 ADE（所有未來時點、左右手）與 FDE（末時點、左右手）。實作 test_step 固定四時點、套 hands_mask，scaling_original 按 meta 中的來源 w/h 還原畫素；calculate_L2_loss 排除 GT=(0,0)，分別累積左右手所有有效時點與第四時點的 L2 距離，test_epoch_end 只輸出四個分手平均。沒有此處的左右手合併報表，也沒有保證來源 PNG 高度為256的轉換步驟；原始解析度不同會改變分數。

依這個順序讀

1. `README.md` ↗

   GitHub · masashi-hatano/EMAG · 0386bd9de2

   確認完整作品 / 作者及公開訓練、評測入口。

   `L4–20 · L32–52`

2. `configs/config_ego4d.yaml` ↗

   GitHub · masashi-hatano/EMAG · 0386bd9de2

   核對預設 val split、八幀輸入 / 四步輸出、間隔、外部路徑及排除影片。

   `L1–96`

3. `configs/config_epic.yaml` ↗

   GitHub · masashi-hatano/EMAG · 0386bd9de2

   確認 EPIC 間隔16與另一套 normalization，不把兩資料設定視為等價。

   `L1–15 · L42–90`

4. `datamodule/ego4d_dataset.py` ↗

   GitHub · masashi-hatano/EMAG · 0386bd9de2

   追 JSON 標註、五時點遮罩、RGB/flow/3×3矩陣與 pickle bounding boxes 的實際欄位。

   `L35–62 · L77–171 · L179–239 · L241–290`

5. `datamodule/lit_ego4d_data_module.py` ↗

   GitHub · masashi-hatano/EMAG · 0386bd9de2

   確認 test_type=val 且只例項化 Ego4D 讀取器。

   `L33–51 · L53–110 · L128–134`

6. `lit_main.py` ↗

   GitHub · masashi-hatano/EMAG · 0386bd9de2

   核對實際預設設定、checkpoint 與 test 呼叫。

   L12–38 · L63–76

---

7. `models/lit_EMAGTrainer.py` ↗

   GitHub · masashi-hatano/EMAG · 0386bd9de2

   核對輸入契約、四時點 reshape、遮罩及每隻手平均 / 最終歐氏距離。

   L15–31 · L74–98 · L243–316 · L334–359

---

8. `utils/util.py` ↗

   GitHub · masashi-hatano/EMAG · 0386bd9de2

   確認從正規化座標回復到來源影格 h/w，並未自行縮到高256。

   L4–28

怎麼接入我們的benchmark

可重用

原生 clip_uid、觀測錨點、標註時點與有效性 mask，左右手 / 物件框引用及分手位移演算法。

需要轉換

case 以父資料集版本+split+clip_uid+錨點定位；保留 2D x/y、來源影格尺寸與秒 / 幀對照，明列四步 horizon、兩手缺失規則與影像高度256的評分尺度。跨資料集保留訓練來源與評測來源，不合併其原生 case。

仍需補齊

須補齊影像、flow、手物框與 ego-motion 前處理來源 / 版本及 EPIC 格式轉換；修復 ego_feat/egos_input key、五標註時點對四輸出時點的契約與缺少的 model_config.loss 設定，確認兩手合併、解析度及遮罩後才可執行驗證。

P060 · Continuous 4D interaction forecasting

From Where to How: Continuous 4D Interaction Forecasting from Egocentric Video

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

此來源不只是專案頁：有 Coherent4D 的事件分段、共同座標及 SMPL 附加程式。正式預測指標只能讀到論文定義，尚無公開評分器可直接沿用。

> **版本與身份**
>
> 固定67386704bf335af977232594d0f86428d0623c8e（2026-09-14）。非截斷tree有網站、統計與process程式，沒有釋出完整訓練 / 評分實作。SMPL指南指定外部 FIction-WHAM b520bc8f1d755be658c4d2bafdffe5081d09cfe2；本輪只讀該依賴宣告，未讀取 / 執行外部模型。chunk指令碼不建立split，須承接來源take分割，不能把每個chunk隨機切分。
>
> README 的完整標題、六位作者及 arXiv:2609.08636 與本地 v1 論文一致，論文作者頁直接連 CorrineQiu/from-where-to-how。Coherent4D 是在 Ego-Exo4D 上建置的配對位置 / 姿態資料；HIGFlow 是方法名稱。FIction、Detic、Llama 與 WHAM 是來源 / 依賴，不能替代本論文版本。
>
> **分類覆核：**既有Coverage已將本作納入資料 / 評測主來源；本次維持此判定。原文定義Coherent4D資料、固定split、聯合預測目標和具體指標，應同時承認資料、評測與方法貢獻。早期書目M / no標記屬初篩快照，不能用來否定此後原文審閱結果。公開倉庫未釋出預測scorer是另一項可得性缺口。

領域	餐飲與烹飪、醫療與手術支援、交通移動與車輛維修、穿戴互動與動作介面
環境	Ego-Exo4D 的 Aria 第一視角程式影片；Cooking、Health、Bike Repair 三個 domain。第三視角用於離線標註 / SMPL 重建，不是預測輸入。787 unique takes 是來源錄製單位，不能當成787個獨立機器人環境。
任務	共同預測有序3D互動位置與同時間的全身 SMPL 狀態。原生21個程式任務由 CSV 按 domain 指定；Cooking/Health/Bike Repair 分別預測10/5/4個事件，並非秒數。公開統計為233828 samples（train193598、val20484、test19746）、1594186個非padding未來 targets、跨domain去重535個物件標籤；這些均為來源統計，未以完整資產重算。

題數與資料	build_chunks 讀 pickle 根層 dataset，按 interactions.time 排序並以 chunk_size 不重疊切分，產生 id={take_name}_{datum_idx}_{chunk_idx}。每筆含 observation_start/end_time_s、history_interactions、target_interactions、target_mask、source_meta 及可選 env_objects；事件有 time_s、time_rel_s、location_norm、object。首個未來事件是時間零，history 嚴格在前30秒（起點截於0）；尾段以 None 加 mask=0。F0 取自 source_meta.source_observation_end_time_s，不隨 chunk 時間原點重新設定；位置用 clip(R0.T@(p-t0)/5,-1,1)。SMPL 附加 history/target_pose_mask、*_pose_frame、*_pose_time_delta_s、*_root_orient6d_f0、*_root_trans_f0_m、*_body_pose_local6d（23×6）、*_joints_f0_m（19×3）。pose位置保留公尺，6D旋轉為3×3矩陣前兩欄按列展平；不能套用不同6D排列。
評估方式	固定 tree 沒有 HIGFlow 預測 / benchmark 評分器。已讀論文 §III-C：位置先反縮放至度量空間，ADE 先平均每樣本有效事件再跨樣本平均，ADE90 是每樣本 ADE 的90百分位，FDE 取最後有效事件；姿態用19關節 MPJPE、每姿態相似變換對齊的 PA-MPJPE、Root Trans. 及23個非root關節 Body Geo.，位置報mm、旋轉報度。Single 用第一候選；Best-5 以各樣本有效步的關節誤差選一條候選，再用同一候選算所有pose指標。資料建置的最近影格檢查採 floor(time_s×fps)，預設fps30、誤差上限0.49秒；它只是標註有效性檢查，不能充作預測評分。配對有效性須用 target_mask & target_pose_mask。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **3** source procedural domains · 原文頁 5
- **19,746** test forecast samples · 原文頁 5
- **233,828** all forecast samples · 原文頁 5

依這個順序讀

1. `README.md` ↗

   GitHub · CorrineQiu/from-where-to-how · 67386704bf

   辨認論文、Coherent4D/HIGFlow 角色、資料規模及 Ego-Exo4D 重用。

   L1–57

2. `data/README.md` ↗

   GitHub · CorrineQiu/from-where-to-how · 67386704bf

   確認事件步數、有效 target 與跨 domain 物件標籤去重單位。

   L1–13

3. `data/dataset_statistics.csv` ↗

   GitHub · CorrineQiu/from-where-to-how · 67386704bf

   核對各 domain、split、takes、samples、targets 與 object labels。

   L1–5

---

4. `data/dataset_task_sunburst_stats.csv` ↗

   GitHub · CorrineQiu/from-where-to-how · 67386704bf

   讀21個原生程式任務及其 domain / 樣本統計。

   L1–22

---

5. `process/README.md` ↗

   GitHub · CorrineQiu/from-where-to-how · 67386704bf

   釐清五階段建置、外接資產與 pose 附加順序。

   L1–39

---

6. `process/02_shared_coordinate_construction/README.md` ↗

   GitHub · CorrineQiu/from-where-to-how · 67386704bf

   確認 F0 空間參照、5公尺縮放、pose 公尺欄位與 chunk 繼承關係。

   L1–40

---

7. `process/05_forecast_sample_generation/README.md` ↗

   GitHub · CorrineQiu/from-where-to-how · 67386704bf

   核對事件 horizon、30秒觀測、history 壓縮及 split 前提。

   L1–48

---

8. `process/05_forecast_sample_generation/build_chunks.py` ↗

   GitHub · CorrineQiu/from-where-to-how · 67386704bf

   讀實際 pickle schema、非重疊事件分段、時間原點、history、padding mask 與輸出 metadata。

   L31–36 · L106–137 · L151–225 · L227–261 · L267–463 · L517–533 · L571–629

---

9. `process/04_smpl_state_attachment/README.md` ↗
   GitHub · CorrineQiu/from-where-to-how · 67386704bf

   確認外部 WHAM/SMPL、19關節、配對遮罩、時間容差與姿態單位。

   L1–29 · L59–110

---

10. `process/04_smpl_state_attachment/attach_smpl.py` ↗
    GitHub · CorrineQiu/from-where-to-how · 67386704bf

    核對最近影格實作、F0 復用、旋轉6D排列、米制姿態欄位與逐 token 成功遮罩。

    L101–116 · L158–174 · L210–226 · L521–535 · L883–977 · L1054–1079 · L1194–1249 · L1264–1302 · L1309–1377

怎麼接入我們的benchmark

可重用

原生 domain/task_name 統計、take/datum/chunk 身分、事件時間、F0 metadata、位置 / pose 分離遮罩與實際建置函式。

需要轉換

source 記 Ego-Exo4D 派生與外部重建版本；task 保留 CSV domain/task_name，case 用 take+datum+chunk，儲存30秒觀測引用、事件horizon、絕對 / 相對秒與空間參照。位置正規化 / 裁切、公尺pose及毫米 / 角度評分分開記；不可由裁切座標還原超界真值。

仍需補齊

需取得原始takes、確定的take-level split清單、建置後位置 / pose caches、SMPL/19關節regressor與模型依賴；補公開預測/evaluator及30張觀測影格抽取對照。再驗證mask、資料規模、共同座標與論文報表一致性。

P061 · Interact with me

Interact with me: Joint Egocentric Forecasting of Intent to Interact, Attitude and Social Actions

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

SocialEgoNet 是 JPL-Social 的官方分類實作；已追到人物 JSON、133點姿態圖與 weighted F1/accuracy。attitude 只評有互動真值的人物，且訓練程式把 test 目錄兼作 validation，整合不能忽略這兩個協定限制。

> **版本與身份**
>
> 固定d81ad122080ca734a866dfcf3c4bd4db60078390（2026-02-26）。train.py 的validation與test都讀test/，每epoch評一次同一目錄，結束後儲存最後模型；不能宣稱獨立validation或由此推斷論文實驗的split。config資料路徑是../JPL_Social/，與README「放於專案內」須對齊工作目錄。僅讀程式 / 論文，未下載Google Drive資料或載入repo內權重。
>
> 本地 arXiv:2412.16698v3（2025-05-08）第1頁直接連 biantongfei/SocialEgoNet。README 列 ICME2025、同一 arXiv ID 與五位作者；上方連結標題使用 joint prediction/self-centred 字樣，正式引用仍是 Joint Egocentric Forecasting of Intent to Interact, Attitude and Social Actions，屬同一作品。JPL-Social 是既有 JPL-Interaction 的人物層級擴充標註，不是新拍攝的獨立影片庫。

領域	社交與溝通、協助、交接與陪伴
環境	JPL-Interaction 的人形觀察者 / 機器人第一視角社交影片，背景與照明有變化。論文 §III 報告200段影片、16位受試者、6種場景設定、320×240與30FPS；JPL-Social 對可見人物建立290條person tracks。影片、人物tracks、姿態影格和場景數不能互換。
任務	預測 intent、attitude、action。constants 的 intent=[Interacting,Interested,Not_Interested]；attitude=[Positive,Negative,Not_Interacting]，前兩者是論文的兩種有效態度，2是非互動狀態；action=[Handshake,Hug,Pet,Wave,Punch,Throw,Point,Gaze,Leave,No_Response]。論文新增Gaze/No_Response並以人物為標註單位，並非十種機器人可執行指令。
題數與資料	一個人物JSON描述 video_name/person_id、frame_size=[w,h]、偵測 / 互動起訖、三項class與frames；實際reader取 frames[*].{frame_id,keypoints}，keypoints=[133,3]為畫素x/y及confidence。x/y轉為2*(xy/[w,h]-0.5)，score保留；輸出固定[30,133,3]。以frames[0].frame_id作起點，時間缺口及不足30幀以最近姿態補齊，不套confidence門檻，也不回傳補幀mask。walk_frame、interact_start_frame、gaze、box與contact_class沒有被此reader用作模型輸入。README誤寫key points，實際必須是keypoints；檔案 / 人物來源ID須另行保留以免只剩feature張量。

評估方式	scripts/test.py 對每項logits做softmax/argmax，彙總所有test樣本後計 sklearn f1_score(average="weighted")×100 與accuracy×100。attitude先依真值!=2排除非互動人物，仍保留3個輸出logits；誤預測Not_Interacting仍會計錯，不能依預測intent過濾。論文表II的83.15%是三項accuracy的算術平均，其分母並不相同，也不是三項同時正確率。公開測試程式沒有計算latency或三項平均；論文latency另外區分姿態抽取成本。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **200** 母影片 · 原文頁 3
- **290** person tracks（全部split） · 原文頁 3
- **10** 互動動作類別 · 原文頁 3

依這個順序讀

1. `README.md` ↗
   GitHub · biantongfei/SocialEgoNet · d81ad12208

   確認 exact paper、父資料 / 下載入口、metadata 與命令。

   L1–21 · L28–82 · L85–111

2. `scripts/constants.py` ↗
   GitHub · biantongfei/SocialEgoNet · d81ad12208

   核對三組類別順序、133點與30FPS及各身體區域圖邊。

   L22–54

3. `scripts/data.py` ↗
   GitHub · biantongfei/SocialEgoNet · d81ad12208

   讀人物JSON、首次偵測錨點、補幀、座標公式及attitude真值過濾。

   L11–66

4. `scripts/DataLoader.py` ↗
   GitHub · biantongfei/SocialEgoNet · d81ad12208

   確認23身體 / 68臉 / 42手部點分圖，x/y/score三個node特徵。

   L5–55

5. `config/test.yaml` ↗
   GitHub · biantongfei/SocialEgoNet · d81ad12208

   確認30幀、測試batch128及相對資料路徑。

   L1–14

---

6. `config/train.yaml` ↗
   GitHub · biantongfei/SocialEgoNet · d81ad12208

   確認訓練40epochs與相同人物序列設定。

   L1–17

---

7. `scripts/Models.py` ↗
   GitHub · biantongfei/SocialEgoNet · d81ad12208

   核對attitude仍有3個logits與chain輸出，避免誤當純二分類模型。

   L6–35 · L75–95

---

8. `scripts/test.py` ↗
   GitHub · biantongfei/SocialEgoNet · d81ad12208

   核對weighted F1 / accuracy百分比、依真值排除attitude=2及完整test目錄彙整。

   L19–43 · L46–69

---

9. `scripts/train.py` ↗
   GitHub · biantongfei/SocialEgoNet · d81ad12208

   核對validation/test共用目錄、訓練保留第三attitude類及最後權重輸出。

   L28–42 · L58–91 · L107–128

怎麼接入我們的benchmark

可重用

人物JSON與video/person識別、三組label字典、姿態圖邊、分身體部位特徵及具體weighted F1 / accuracy演算法。

需要轉換

case以父影片+person_id+觀測錨點定位，task分開intent/attitude/action，保留attitude=2的訓練類與評分排除規則；儲存畫素原值、正規化公式、confidence及補幀來源。evaluation記錄每項有效樣本數，合併指標明列算術平均。

仍需補齊

需取得並固定外部人物JSON及train/test清單，核對同影片 / 受試者是否跨split及augmentation來源；建立真正獨立validation協定、確認首次偵測錨點與論文觀測視窗一致，再做執行驗證。

P062 · RLBench

RLBench: The Robot Learning Benchmark & Learning Environment

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

RLBench 以 Python Task、CoppeliaSim 場景 / 模型和 condition 物件組成任務。應沿 task 的成功條件讀到 backend，而不是隻看任務名稱或示範檔。

> **版本與身份**
>
> README 明示action mode曾有破壞性變更；本輪固定公開commit，不能混用其他版本的動作約定。

領域	居家整理與清潔、通用物件與機動作業
環境	CoppeliaSim/PyRep 任務場景與模型；任務 class 數、variation 數和獨立環境數不能直接等同。
任務	Task class 繫結場景物件與 condition。open_drawer 包含 top/middle/bottom 三個 variation，並以 JointCondition 門檻0.15檢查絕對關節位移。
題數與資料	示範將多視角 RGB、depth、mask 分檔，並把影像從 observation 移除後儲存低維資料；載入時需閉合影像與狀態引用。
評估方式	各 task 註冊具體 condition。ConditionSet 可累積有序條件或做同時 AND；OrConditions 做 OR。這些狀態 / 過程語義要一起保留。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **1** 共用桌面scene · 原文頁 4
- **100** 原版task definitions · 原文頁 1
- **10** 原版meta-test tasks · 100的10% · 原文頁 6

依這個順序讀

1. `README.md` ↗
   GitHub · stepjam/RLBench · 02720bba4c

   辨認套件、action API 版本與任務 / 示範入口。

   L1–55

---

2. `rlbench/tasks/open_drawer.py` ↗
   GitHub · stepjam/RLBench · 02720bba4c

   看任務變體、語言描述、關節選擇及成功條件註冊。

   L1–33

---

3. `rlbench/backend/conditions.py` ↗
   GitHub · stepjam/RLBench · 02720bba4c

   核對關節位移、偵測、抓握，以及有序 / 無序 condition 組合的真實邏輯。

   L1–194

---

4. `rlbench/dataset_generator.py` ↗
   GitHub · stepjam/RLBench · 02720bba4c

   看每個視角的 RGB / depth / mask 與低維 observation 如何分檔儲存。

   L26–66 · L104–144

怎麼接入我們的benchmark

可重用

task ID、variation、場景模型、語言描述、示範與 condition 程式。

需要轉換

task、variation、初態、感測及 action mode 分開存；evaluator 指向具體條件程式。原生variation可作繫結變化，不自動當新增共同任務。

仍需補齊

完整模型 / 示範資產閉合、跨來源語義對齊及統一協定下的執行驗證。

P063 · Meta-World

Meta-World: A Benchmark and Evaluation for Multi-Task and Meta Reinforcement Learning

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

原作倉庫已轉到Farama的現行Meta-World。當前程式碼可以核讀任務、動作和評測介面，但README已引用MetaWorld+，必須保留與2019原作協議的版本差異。

> **版本與身份**
>
> 發現現行state_space.md仍寫9D且表格列18維，但程式_get_obs明確組成39維；欄位標準化以固定程式與測試查核，不能只抄說明頁。
>
> 舊入口rlworkgroup/metaworld的已儲存GitHub metadata回應指向Farama-Foundation/Metaworld，按倉庫別名保留，不另外算成未讀的第二個倉庫。

領域	居家整理與清潔、餐飲與烹飪、工藝與修繕、裝配與生產作業、休閒與運動、通用物件與機動作業
環境	Sawyer/MuJoCo任務環境；source task/env ID不等於獨立家居場景。
任務	MT與ML清單保留原生任務和train/test成員；現行v3任務與2019版不可僅刪掉版本字尾就宣稱等價。
題數與資料	四維動作是xyz增量控制加gripper；set_xyz_action另乘action_scale。基礎觀測為當前18維、前一觀測18維與目標3維，goal可被遮蔽；benchmark還可加task ID。
評估方式	evaluation.py在成功時終止episode，用info.success按任務計成功率，再對任務平均。meta評測另外包含適應步數、適應episode和evaluation episode預算。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **50** 操作task types · 原文頁 1, 4
- **2,500** MT50訓練引數化instances · 原文頁 6
- **5** ML10 / ML45保留test任務 · 原文頁 7

依這個順序讀

1. README.md ↗
   GitHub · Farama-Foundation/Metaworld · c0dafaf155

   核對現行論文連結、Gymnasium API及MT/ML任務分割。

   L1–55

---

2. metaworld/env_dict.py ↗
   GitHub · Farama-Foundation/Metaworld · c0dafaf155

   任務名稱如何映到class及train/test清單。

   L80–110

---

3. metaworld/sawyer_xyz_env.py ↗
   GitHub · Farama-Foundation/Metaworld · c0dafaf155

   以程式確認動作縮放、frame stack與39維基礎觀測。

   L320–336 · L475–527

---

4. metaworld/envs/sawyer_drawer_open_v3.py ↗
   GitHub · Farama-Foundation/Metaworld · c0dafaf155

   核對info.success與不同reward版本，避免用reward替代成功。

   L66–88 · L115–188

---

5. metaworld/evaluation.py ↗
   GitHub · Farama-Foundation/Metaworld · c0dafaf155

   核對每任務episode數、成功終止、平均方式及meta適應預算。

   L48–103 · L106–169

怎麼接入我們的benchmark

可重用

版本化task IDs、train/test清單、reset引數、info.success與正式evaluation流程。

需要轉換

記下v3、reward版本、goal可見性、action_scale、觀測stack和適應預算；共同ActionSpec保留原生4維與轉換規則，不強塞成7維。

仍需補齊

2019原作相符release的獨立重現、跨來源task/scene對齊及統一case清單。

P064 · LIBERO

LIBERO: Benchmarking Knowledge Transfer for Lifelong Robot Learning

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

LIBERO最清楚的入口是benchmark登錄檔：每個Task把語言、BDDL、init-state檔與示範路徑連起來。成功判定要沿wrapper找到實際problem子類；base class的False是佔位。

> **版本與身份**
>
> 不能只讀bddl_base_domain._check_success就斷言沒有判分器；必須追TASK_MAPPING到實際problem子類。

領域	居家整理與清潔
環境	problem型別、MuJoCo場景與物件資產由BDDL和wrapper連線；suite或task數不能直接當layout數。
任務	Task含name/language/problem/problem_folder/bddl_file/init_states_file。原作100-task集合拆成90/10；程式有五個suite清單但不可重算同一組任務。
題數與資料	HDF5示範含多視角RGB/可選depth、proprioception、action/state/reward/done；另存模型XML和初態。評測需固定.pruned_init等來源。
評估方式	具體problem子類以parsed goal predicates合取檢查成功；evaluation指令碼固定步數和checkpoint，儲存loss與success_rate兩種不同指標。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **130** task definitions · 原文頁 1, 2, 5
- **4** task suites · 原文頁 5
- **90** LIBERO100內pretraining tasks · 原文頁 5
- **10** LIBERO100內long tasks · 原文頁 5

依這個順序讀

1. `README.md` ↗

   GitHub · Lifelong-Robot-Learning/LIBERO · 8f1084e313

   核對130任務、suite劃分與原始用途。

   L15–55

---

2. `libero/libero/benchmark/__init__.py` ↗

   GitHub · Lifelong-Robot-Learning/LIBERO · 8f1084e313

   找Task欄位、BDDL、示範和初態引用；90/10不重複加成。

   L35–77 · L108–160

---

3. `libero/libero/envs/env_wrapper.py` ↗

   GitHub · Lifelong-Robot-Learning/LIBERO · 8f1084e313

   看控制/相機約定、TASK_MAPPING和初態恢復。

   L25–104 · L118–145

---

4. `libero/libero/envs/problems/libero_tabletop_manipulation.py` ↗

   GitHub · Lifelong-Robot-Learning/LIBERO · 8f1084e313

   以具體problem確認goal_state經predicate逐一判定。

   L135–143

---

5. `scripts/create_dataset.py` ↗

   GitHub · Lifelong-Robot-Learning/LIBERO · 8f1084e313

   核對HDF5的感測、actions、states、rewards、dones和init_state。

   L20–60 · L238–278

---

6. `libero/lifelong/evaluate.py` ↗

   GitHub · Lifelong-Robot-Learning/LIBERO · 8f1084e313

   固定task/checkpoint/seed，區分行為模仿loss與rollout success。

   L72–114 · L261–301

怎麼接入我們的benchmark

可重用

Task註冊、BDDL及init states、HDF5示範和具體problem evaluator。

需要轉換

保持task、scene/assets、initial state、case protocol分離；將原生goal program與predicate實作一起引用，HDF5映到typed episode資料。

仍需補齊

跨來源等價判定、素材閉合、controller/相機一致性與本庫case驗證。

P065 · CALVIN

CALVIN: A Benchmark for Language-Conditioned Policy Learning for Long-Horizon Robot Manipulation Tasks

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

CALVIN 要一起固定 benchmark 主倉庫與 calvin_env 子模組。資料是按時間步儲存的多感測器 / 動作 / 狀態，評測則是連續指令鏈；不能把訓練視窗當成正式評測題。

> **版本與身份**
>
> mees/calvin在fa03f01...的Git tree明確pin calvin_env到1431a46...，與calvin_env目前main 797142c...不同。要重現CALVIN就使用gitlink，不直接替換成依賴倉庫的最新main。

領域	居家整理與清潔、通用物件與機動作業
環境	A–D場景與機體 / 感測配置由calvin_env提供；D_eval是評測設定，不能直接另算獨立layout。
任務	task函式以start_info/end_info變化定義；語言可對應相同原生task。正式long-horizon評測是從同一初態連續執行指令，失敗就停止prefix。
題數與資料	每步NumPy字典包含rgb/depth/tactile、actions、rel_actions、robot_obs、scene_obs；語言檔另外儲存ann/task/embedding及起訖索引。scene_obs是評分/狀態資料，README明示原作不供政策使用。
評估方式	rollout用原作task oracle比對起終info；evaluate_sequence保持環境狀態延續，子任務失敗即回傳成功prefix長度。count_success計至少完成1至5項的比例。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **4** 桌面配置 · 原文頁 3
- **34** 原子tasks · 原文頁 3, 5
- **1,000** 5步instruction chains · 原文頁 5
- **340** 單步評測rollouts / 一設定 · 34×10 · 原文頁 5

依這個順序讀

1. `README.md` ↗

   GitHub · mees/calvin · fa03f01f19

   核對原作、資料分割、相機 / 觸覺和相對 / 絕對動作配置。

   L1–75

---

2. `dataset/README.md` ↗

   GitHub · mees/calvin · fa03f01f19

   讀取具體NPZ欄位、動作縮放、狀態可見範圍和語言索引。

   L1–134

---

3. `calvin_models/calvin_agent/datasets/disk_dataset.py` ↗

   GitHub · mees/calvin · fa03f01f19

   確認連續時間步、語言片段和訓練視窗的組成。

   L71–130

---

4. `calvin_models/calvin_agent/evaluation/evaluate_policy.py` ↗

   GitHub · mees/calvin · fa03f01f19

   確認固定初態、連續子任務、失敗中止及原作task oracle。

   L79–179

---

5. `calvin_models/calvin_agent/evaluation/utils.py` ↗

   GitHub · mees/calvin · fa03f01f19

   確認至少連續成功1至5項的prefix成功率。

   L77–84

---

6. `calvin_env/envs/tasks.py` ↗

   GitHub · mees/calvin_env · 1431a46bd3

   以主倉庫實際pin的子模組核對起終狀態條件和抽屜位移判定。

   L10–33 · L245–255

怎麼接入我們的benchmark

可重用

NPZ欄位、語言片段、場景定義、固定序列 / 初態和task oracle。

需要轉換

保留7維absolute與relative兩種動作的區別、世界座標和50/20縮放；訓練視窗、指令鏈case、子任務執行各自識別。依協定分開政策輸入和評分狀態。

仍需補齊

完整素材閉合、共同跨來源任務對齊及本庫協定下的執行驗證。

P066 · ManiSkill

ManiSkill: Generalizable Manipulation Skill Benchmark with Large-Scale Demonstrations

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

2021原作應讀haosulab/ManiSkill-Legacy，不能用現在ManiSkill3的main代替。其四種基本任務會依PartNet模型與目標link產生更多環境ID，這些不是全部新的工作種類。

> **版本與身份**
>
> 來源版本固定為Legacy commit58964d08...；與ManiSkill2 v0.5.3和ManiSkill3分別儲存，不混用數量及API。

領域	居家整理與清潔
環境	SAPIEN場景繫結PartNet-Mobility模型；model/link ID與level控制資產及初態變化。
任務	OpenCabinetDoor、OpenCabinetDrawer、PushChair、MoveBucket四種原生基本任務，再衍生模型 / link設定。
題數與資料	觀測可為點雲 / RGBD / 狀態；示範及資產外部取得，模型分割與初態在YAML / level設定。讀取時需保留觀測模式和模型身份。
評估方式	具體task先產生條件旗標，base_env要求連續保持0.5秒；Evaluator依episode終止時eval_info計比例，不能以某一幀接近目標替代。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **4** skills · 原文頁 4, 5
- **162** 按4類相加的資產條目 · 52+35+36+39，非跨類去重 · 原文頁 4
- **36,000** 成功demo trajectories · 約數 · 原文頁 6

依這個順序讀

1. `README.md` ↗

   GitHub · haosulab/ManiSkill-Legacy · 58964d08b4

   確認2021身份、4種任務、162模型及原生系統。

   L1–75

---

2. `mani_skill/env/__init__.py` ↗

   GitHub · haosulab/ManiSkill-Legacy · 58964d08b4

   區分基本任務ID、model繫結及target-link繫結。

   L1–118

---

3. `mani_skill/env/push_chair.py` ↗

   GitHub · haosulab/ManiSkill-Legacy · 58964d08b4

   看具體成功條件：接近目標、姿態站立和靜止。

   L267–277

---

4. `mani_skill/env/base_env.py` ↗

   GitHub · haosulab/ManiSkill-Legacy · 58964d08b4

   確認條件持續0.5秒才算通過，以及成功 / 時間上限終止的差別。

   L178–181 · L524–571

---

5. `mani_skill/eval/evaluator.py` ↗

   GitHub · haosulab/ManiSkill-Legacy · 58964d08b4

   按指定level執行，收集最終eval_info並以episode數平均。

   L1–59

---

6. `mani_skill/assets/config_files/chair_models_custom_split_example.yml` ↗

   GitHub · haosulab/ManiSkill-Legacy · 58964d08b4

   模型ID、位姿和初始關節設定如何構成具體初態。

   L1–28

怎麼接入我們的benchmark

可重用

四種任務定義、model/link registry、level、初態和持續條件evaluator。

需要轉換

基本task、模型繫結、目標link和level分層存；保留成功持續時間、觀測模式和native done/time-limit約定。

仍需補齊

全部資產 / 示範閉合、跨世代移植差異和共同case協定驗證。

P067 · ManiSkill2

ManiSkill2: A Unified Benchmark for Generalizable Manipulation Skills

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

原ManiSkill2網址目前只是搬家說明；實作應固定mani-skill/ManiSkill的v0.5.3。它把episode設定、HDF5軌跡、JSON資訊和原生success評測分開儲存。 2026-10-11 另補讀 ManiSkill2-Learn 的 BC 資料與單程式評測入口，與主 benchmark 的 v0.5.3 契約分開記錄。

> **版本與身份**
>
> v0.5.3解析到commit493be361...；最新main是ManiSkill3，因此每個來源連結都帶ref/commit。 Learn 固定 e9860aff595da3ad34829d62c923be0b50001427，與主 benchmark v0.5.3 的提交分開；其 README 指明 0.5.0 起改 Gymnasium，較舊環境用 ms2_gym 分支（本次未核讀該分支）。README 另說早期 checkpoint / 環境 0.3、0.4 的 RGBD camera order 不同，須保留實際 wrapper / 觀測版本，不把 Learn、ManiSkill2022 challenge 或 ManiSkill3 當成同一版主 benchmark。

領域	居家整理與清潔、裝配與生產作業、通用物件與機動作業
環境	SAPIEN任務依env_id、asset模型、reset_kwargs和control_mode建立；柔體另外依賴原作Warp版本。
任務	註冊的env/task與原作家族保留其單位；不是每個asset模型、隨機seed都增加一個基礎任務。
題數與資料	HDF5 traj_id配合JSON episodes/env_info；reset初態使觀測 / env_states比actions多一筆。depth以uint16儲存，原作寫入前乘2^10，必須儲存這個尺度。 補讀 Learn：tools/convert_state.py 依 HDF5 traj 字尾尋找 JSON episodes 的 episode_id/reset_kwargs，逐 state 重建剛體觀測，或由 env_init_state 重播動作取得柔體觀測；控制模式須先在主 ManiSkill2 轉好。輸出為 T 筆 obs/actions/rewards，dones 直接來自原 success，episode_dones 僅尾筆為真，next_obs 要加 --with-next。輸出 traj_{cnt} 重新編號，須另存原 episode 對映。BC 的 buffer_filenames 範例仍是 SOME_DEMO_FILE；ReplayMemory→FileCacheWorker 實際讀 HDF5 groups，num_samples 限制每檔前幾條排序軌跡，-1 才是全部，不能稱為隨機 split。

評估方式	Evaluator按episode_cfg的reset_kwargs重建，終止時讀info.success等scalar；PickCube示例要求物件放到目標且robot靜止。reward、terminated、truncated不互相替代。 補讀 Learn 的獨立路徑：run_rl.py --evaluation / --resume-from→build_evaluation→Evaluation.run；單程式策略預設 mode=eval，BC 範例 num=10、num_procs=1 只是設定值。live step_dict 把 terminated 命名為 dones，以 terminated OR truncated 判 episode_dones；Evaluation 在終止那一步把 dones 記為 finish，statistics.csv 存 length/reward/finish，顯示的是 mean(finish) 的「Success or Early Stop Rate」。此 caller 並未直接取 info.success；只有繫結環境的終止契約相符時才能解作成功率。only_save_success_traj 篩存檔、不縮減 statistics 的所有已評 trial 分母；與前述主 benchmark Evaluator 的 info.success 分開。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **20** task families · 原文頁 1, 3, 4
- **6** soft-body families · 原文頁 3
- **2,000** object models · 超過 · 原文頁 1
- **4,000,000** demonstration frames · 超過 · 原文頁 1

依這個順序讀

1. `README.md` ↗

   GitHub · haosulab/ManiSkill2 · 63e0e7db63

   確認搬家與原作指定的v0.5.3版本。

   L1–6

2. `README.md` ↗

   GitHub · mani-skill/ManiSkill · 493be36121

   確認ManiSkill2、原生任務家族、剛體 / 柔體資產與控制模式。

   L1–85

3. `mani_skill2/envs/pick_and_place/pick_cube.py` ↗

   GitHub · mani-skill/ManiSkill · 493be36121

   看觀測模式差異和放置 / robot-static合成success。

   L54–83 · L141–150

4. `mani_skill2/utils/wrappers/record.py` ↗

   GitHub · mani-skill/ManiSkill · 493be36121

   讀episode identity/reset/control、T+1觀測、T動作與深度編碼。

   L146–186 · L222–325

---

5. `mani_skill2/evaluation/evaluator.py` ↗

   GitHub · mani-skill/ManiSkill · 493be36121

   按episode_cfg/reset_kwargs執行，檢查episode ID唯一性與success輸出。

   L45–91

---

6. `README.md` ↗

   GitHub · haosulab/ManiSkill2-Learn · e9860aff59

   baseline 身份、Gymnasium / camera-order 版本差異、控制模式先轉換與示範 / 評測入口。

   L1–23 · L174–195 · L246–268 · L292–324 · L336–363

---

7. `configs/brl/bc/pointnet.py` ↗

   GitHub · haosulab/ManiSkill2-Learn · e9860aff59

   BC 示例的 replay 欄位 / 佔位資料路徑與 num=10、單程式評測；不是 benchmark 固定 trial 數。

   L1–60

---

8. `tools/convert_state.py` ↗

   GitHub · haosulab/ManiSkill2-Learn · e9860aff59

   HDF5+JSON reset 契約、剛體 state / 柔體 action 路徑、輸出 dones / episode_dones、可選 next_obs 與軌跡重編號。

   L39–142 · L149–185 · L196–248

---

9. `maniskill2_learn/env/replay_buffer.py` ↗

   GitHub · haosulab/ManiSkill2-Learn · e9860aff59

   由 buffer_filenames 建構 ReplayMemory/FileCache；容量與 num_samples 如何控制讀取。

   L30–145

---

10. `maniskill2_learn/utils/file/cache_utils.py` ↗

    GitHub · haosulab/ManiSkill2-Learn · e9860aff59

    追到實際 HDF5 group reader、逐檔限制 / 鍵排序，以及布林欄位和 episode_dones 的讀取處理。

    L77–128 · L156–181 · L215–256 · L289–385 · L447–480

---

11. `maniskill2_learn/apis/run_rl.py` ↗

    GitHub · haosulab/ManiSkill2-Learn · e9860aff59

    checkpoint / evaluation CLI 到 evaluator.run、結果輸出與 evaluation env_cfg / seed。

    L35–79 · L265–268 · L293–315 · L351–395

---

12. `maniskill2_learn/env/builder.py` ↗

    GitHub · haosulab/ManiSkill2-Learn · e9860aff59

    Evaluation 的建構；num_procs>1 會選 BatchEvaluation，與本次單程式示例分清。

    L18–27

---

13. `maniskill2_learn/env/env_utils.py` ↗

    GitHub · haosulab/ManiSkill2-Learn · e9860aff59

    實際 gym.make、觀測 wrapper、時間上限和 obs_frame 預設值。

    L96–186

---

14. `maniskill2_learn/env/wrappers.py` ↗

    GitHub · haosulab/ManiSkill2-Learn · e9860aff59

    Gymnasium terminated/truncated 原樣傳遞及 ignore_dones 可抑制 terminated；不自行改寫為 info.success。

    L61–107 · L190–239 · L683–695

---

15. `maniskill2_learn/env/vec_env.py` ↗

    GitHub · haosulab/ManiSkill2-Learn · e9860aff59

    live step_dict 的 dones=terminated、episode_dones=terminated OR truncated。

    L149–166

---

16. `maniskill2_learn/env/evaluation.py` ↗

    GitHub · haosulab/ManiSkill2-Learn · e9860aff59

    單程式實際評測迴圈、策略取樣模式、最後一步 finish、level 數限制和 statistics.csv 分母。

    `L34–46 · L252–300 · L328–483`

怎麼接入我們的benchmark

可重用

env/task IDs、episode ID、reset kwargs、control mode、HDF5/JSON及原生success。 可另重用 baseline 的 HDF5 視覺轉換、ReplayMemory 輸入及 length/reward/finish 原生報表。

需要轉換

原始T+1觀測與T個transition保留對齊；深度尺度、obs mode、state、success、時間上限分欄，不用共通dtype猜單位。 另儲存 Learn commit、checkpoint、實際 env_cfg、seed、num/eval_levels、sample_mode 與輸入 / 輸出 trajectory ID 對映；原 success、示範 dones、live terminated/truncated/finish 分欄。FileCache 的 purify_items 可補 worker_indices、把 dones 轉 bool，並將讀取片段末項 episode_dones 設真，不能依訓練 buffer 片段另增物理 episode。

仍需補齊

完整資產 / 示範閉合、共同split血緣與本庫eval adapter驗證。 Learn 的示範 / checkpoint / 資產未取得或執行；需替換示例佔位路徑、儲存完整 reset / split 血緣，驗證控制模式、觀測處理與主 benchmark 的 success / 終止關係。converter 的 obs_frame 預設 base，而 make_gym_env 預設 world，資料生成 / 訓練 / 評測都需顯式對齊。

P068 · ManiSkill3

ManiSkill3: GPU Parallelized Robotics Simulation and Rendering for Generalizable Embodied AI

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

ManiSkill3的核心是向量化場景 / 任務API，資料以HDF5+JSON連結episode、env kwargs和觀測。讀取訓練loader時還要檢查它是否刪掉最終觀測或改寫label。

> **版本與身份**
>
> 固定commit62ff3a58...。發現trajectory/dataset.py的device分支把success指定成terminated、fail指定成truncated；本庫匯入應保留原始label並針對此分支驗證，不能盲用loader輸出。本輪為靜態核讀，未執行重現此問題。

領域	居家整理與清潔、裝配與生產作業、通用物件與機動作業
環境	SAPIEN向量化環境可變機體、scene與物件；環境ID、asset場景與並行env數不是同一個數量。
任務	具體task子類提供evaluate，基底scene evaluate可能是空字典。PickCube成功為物件到位且機器人靜止；is_grasped則另列。
題數與資料	JSON記episodes/env_info/env_id/env_kwargs；HDF5儲存traj_ID和多模態obs/actions/terminated/truncated，reward/success/fail可選。訓練Dataset會裁掉最後一筆obs，不適合作為原始儲存格式。
評估方式	BaseEnv將success/fail合成terminated，time limit另由外層處理。baseline可輸出回報、成功和失敗；必須保留各自定義及向量化episode邊界。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **12** 技術task categories · 原文頁 3
- **20** robot models · 超過 · 原文頁 6
- **4** SIMPLER轉接環境 · 原文頁 4

依這個順序讀

1. `README.md` ↗
   GitHub · mani-skill/ManiSkill · 62ff3a5896

   核對RSS2025論文、版本、機體與執行平臺範圍。

   L1–94

---

2. `mani_skill/envs/tasks/tabletop/pick_cube.py` ↗
   GitHub · mani-skill/ManiSkill · 62ff3a5896

   讀實際extra observation與success組合。

   L132–159

---

3. `mani_skill/envs/sapien_env.py` ↗
   GitHub · mani-skill/ManiSkill · 62ff3a5896

   追get_info/evaluate及success/fail/terminated的關係。

   L1050–1079 · L1155–1165

---

4. `mani_skill/trajectory/dataset.py` ↗
   GitHub · mani-skill/ManiSkill · 62ff3a5896

   核對HDF5/JSON、動作與觀測長度、label及device分支。

   L13–20 · L36–154

---

5. `examples/baselines/tdmpc2/evaluate.py` ↗
   GitHub · mani-skill/ManiSkill · 62ff3a5896

   核對實際baseline的checkpoint、eval episode和成功 / 失敗 / 回報輸出。

   L21–61 · L82–122

怎麼接入我們的benchmark

可重用

Task/evaluate、JSON episode metadata、HDF5資料與原生控制 / 觀測模式。

需要轉換

以原始檔建立可逆episode view，再提供訓練 / 評測檢視；保留T+1末態、資訊白名單、control mode、機體與逐episode指標。

仍需補齊

完整素材、跨版本任務對齊、GPU/CPU實測與adapter回讀一致性驗證。

P069 · robosuite

robosuite: A Modular Simulation Framework and Benchmark for Robot Learning

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

robosuite 提供可配置任務與狀態判定；論文的 SAC 圖表來自另一個 v1.0 benchmark 倉庫。已核讀 Lift、示範序列化及 return 統計鏈，不能把現行 v1.5 環境直接當原實驗版本。

> **版本與身份**
>
> 主程式固定5ce6643f3092639d08f7b0f90ed1c6a84f50552c；SAC固定b229f7442f3590dd0e0cad21dc6ae52f410a34bc，依賴rlkit b7f97b2463df1c5a1ecd2d293cfcc7a4971dd0ab。SAC requirements 只寫robosuite>=1.0.1，卻使用mujoco-py/Gym舊API。notebook第89–100行把Wipe與Door都寫成NutAssemblyRound；Door示例variant為2000 epochs，論文 / 檔案為500。載入variant後，亂數初始化仍取CLI args.seed，不能只相信JSON seed。
>
> 對應 arXiv:2009.12293v3（2025-01-18），題名與作者以固定論文首頁為準；雖收錄年份為2020，本 PDF 明述 v1.5。PDF 第15頁直接連到 robosuite-benchmark；主倉庫 README 指回同一論文。

領域	居家整理與清潔、裝配與生產作業、通用物件與機動作業
環境	MuJoCo 的 robot＋arena＋objects 組合。已讀 Lift 使用0.8×0.8公尺桌面，桌高0.8公尺；cube 的 xy 初態在桌面原點附近各±0.03公尺抽樣。模型數、任務數與初始化 case 數分開。
任務	論文九個標準環境；實驗細化到 PickPlaceCan、NutAssemblyRound 等子型，雙臂設定另存。Lift 的具體 checker 只要求 cube 中心 z 大於桌面 z＋0.04公尺；不額外要求持續抓握或停留。其餘八個 checker 未逐一核讀。
題數與資料	原生 observation 是具名感測 dict；Lift 有 cube_pos、公尺制相對位置與 xyzw cube_quat，感測率跟 control_freq。HDF5 data/demo_N 存 states、actions 與 model_file XML；data attrs 存 env、env_info、repository_version、date/time。寫入前刪掉最後一筆 state 以對齊 actions，只收成功示範；此格式本身不含 RGB。20 Hz 是已讀基線設定，動作維度 / 縮放須保留各 controller 設定。
評估方式	基線鏈為 train→experiment→MdpPathCollector→CustomBatchRLAlgorithm._log_stats→get_custom_generic_path_information→eval_util。Returns 是每回合 reward 總和，ExplReturns 截至 exploration horizon；統計函式的 reward_scale 引數沒有執行除法，縮放在環境端。例示 run 每epoch收2500步、每回合500步，通常為5回合；論文另對5個訓練 seeds 報均值與標準差。現行 base.done 是 horizon 條件且 info 為空，不能當 task success。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **9** 標準benchmark環境 · 原文頁 13, 14, 15, 16
- **10** robot models · 原文頁 7

依這個順序讀

1. `README.md` ↗

   GitHub · ARISE-Initiative/robosuite · 5ce6643f30

   確認 v1.5 與論文連結。

   L5–22

---

2. `docs/algorithms/benchmarking.md` ↗

   GitHub · ARISE-Initiative/robosuite · 5ce6643f30

   辨識基線仍標為 v1.0，報500步 return 與5個訓練 seeds。

   L5–13

---

3. `README.md` ↗

   GitHub · ARISE-Initiative/robosuite-benchmark · b229f7442f

   確認 SAC 倉庫角色及 rlkit 固定依賴。

   L1–5 · L23–29

---

4. `requirements.txt` ↗

   GitHub · ARISE-Initiative/robosuite-benchmark · b229f7442f

   核對舊 mujoco-py / Gym 與未鎖上限的 robosuite。

   L1–6

---

5. `notebooks/create_benchmark_environments.ipynb` ↗

   GitHub · ARISE-Initiative/robosuite-benchmark · b229f7442f

   九任務實驗子型、共同設定及兩處錯誤 env_name。

   L7–19 · L36–50 · L75–125

---

6. `robosuite/environments/manipulation/lift.py` ↗

   GitHub · ARISE-Initiative/robosuite · 5ce6643f30

   實際初態、物件感測、reward 與物件中心高於桌面4公分的判定。

   L145–193 · L224–273 · L275–344 · L356–415 · L433–444

---

7. `robosuite/environments/base.py` ↗

   GitHub · ARISE-Initiative/robosuite · 5ce6643f30

   step→reward→task checker；done 僅反映 horizon。

   L429–465 · L467–548

---

8. `robosuite/scripts/collect_human_demonstrations.py` ↗

   GitHub · ARISE-Initiative/robosuite · 5ce6643f30

   HDF5 寫入欄位、僅儲存成功軌跡及 state/action 對齊。

   L148–207

---

9. `robosuite/scripts/playback_demonstrations_from_hdf5.py` ↗

   GitHub · ARISE-Initiative/robosuite · 5ce6643f30

   以 env_info、模型 XML、states/actions 還原；分開狀態重播與動作重播。

   L41–108

---

10. `scripts/train.py` ↗

    GitHub · ARISE-Initiative/robosuite-benchmark · b229f7442f

    variant 載入與實際亂數 seed 來源。

    L51–104 · L107–113

---

11. `util/rlkit_utils.py` ↗

    GitHub · ARISE-Initiative/robosuite-benchmark · b229f7442f

    建環境、確定性 SAC policy、collector 與統計入口。

    L31–62 · L90–106 · L139–163

---

12. `util/rlkit_custom.py` ↗

    GitHub · ARISE-Initiative/robosuite-benchmark · b229f7442f

    取樣預算及 Returns / ExplReturns 的具體加總。

    L199–217 · L275–290 · L312–374

---

13. `rlkit/samplers/data_collector/path_collector.py` ↗

    GitHub · rail-berkeley/rlkit · b7f97b2463

    檢查依步數收集完整 episode 的邏輯。

    L29–59

---

14. `rlkit/core/eval_util.py` ↗

    GitHub · rail-berkeley/rlkit · b7f97b2463

    return 平均、標準差與極值的真正實作。

    L65–113

---

15. `runs/Door-Panda-OSC-POSE-SEED17/Door_Panda_OSC_POSE_SEED17_2020_09_13_00_26_44_0000--s-0/variant.json` ↗

    GitHub · ARISE-Initiative/robosuite-benchmark · b229f7442f

    具體 run 的2000 epochs、2500 eval steps、20 Hz與seed17。

    L1–35 · L49–61

怎麼接入我們的benchmark

可重用

任務 class、版本化 controller/env 設定、初態抽樣、HDF5 模型 / 狀態與具體 checker，以及原生 return 統計。

需要轉換

source 儲存論文v3與兩倉庫commit；environment 儲存robot/arena；task 儲存子型；case 儲存seed、初態、horizon/control_freq；evaluator 分列二元checker、shaped reward、episode return。模型XML與資產引用需閉合。

仍需補齊

原實驗所用 robosuite 精確commit仍未鎖定；尚需其餘任務checker、控制器動作約定及資產 / 重播驗證，不能宣稱已重現原圖。

P070 · RoboCasa

RoboCasa: Large-Scale Simulation of Everyday Tasks for Generalist Robots

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

2024 RoboCasa 的資料介面可由官方 v0.2 tag 核讀：25項 single-stage 資料註冊、5項 multi-stage 資料註冊、HDF5 重播與具體幾何 checker。這些資料入口不是論文100項任務的完整清單；現行 main 已轉為 RoboCasa365。

> **版本與身份**
>
> v0.2固定756598a5be52e052339bb2d957426e39015c2afb；目前main固定456174f62b89b8fca99eaaf33949c29fec9cfc2a，屬P071。不可把v0.2的0-based layout/style、PnPCounterToCab、HDF5 env_args與365的1-based ID、PickPlaceCounterToCabinet、LeRobot格式按名稱直接合併。舊版仍要求robosuite master並留有舊controller入口，需要額外鎖定相容版本。
>
> 對應 arXiv:2406.02523v1（2024-06-04）及八位作者的 RSS 2024 論文。v0.2 README 直接列此題名 / 作者並連原論文；v0.2 是同一作品的後續維護版，未宣稱其commit就是投稿時程式。

領域	居家整理與清潔、餐飲與烹飪
環境	原論文10個floor plans×12個styles＝120種廚房組合；v0.2 scene_registry 的layout ID為0–9、style為0–11，分別解到YAML。fixtures包括櫃子、檯面、家電；一個layout的材質變化不另算平面配置。
任務	論文100項＝25 atomic＋75 composite。已讀PnPCounterToCab把物件從檯面放入櫃內；get_ep_meta.lang插入抽樣物件名稱，_get_obj_cfgs給name/obj_groups/graspable/placement及兩個幹擾物。資料registry的5個composite入口只涵蓋ArrangeVegetables、MicrowaveThawing、RestockPantry、PreSoakPan、PrepareCoffee，不能據此說其餘任務不存在。
題數與資料	registry以human_path、mg_path、horizon及download_links連線v0.1資料；human_raw讀demo.hdf5，human_im / mg_im分別挑選帶影像 / 生成材質的檔案，NavigateKitchen沒有mg_path。HDF5 data.attrs.env_args提供env_name/type/env_kwargs；data/demo_N內含states、actions或actions_abs、obs/<camera>_image，attrs含model_file與ep_meta。ep_meta、XML、資產與初態需一起還原，frame index、控制頻率與影片抽幀分開記。

評估方式	已閉合run_random_rollouts→PnPCounterToCab._check_success→obj_inside_of AND gripper_obj_far。前者檢查物件8個bbox角點對fixture內部3軸的投影，後者要求eef與物件中心距離>0.25公尺。obj_inside_of的0.05加在未正規化軸向量的內積上，不能直接標為5公分容許誤差。create_eval_env固定(1,1)/(2,2)/(4,4)/(6,9)/(7,10)，obj_instance_split=B。論文每task50 trials；這裡main只是3回合×100步隨機動作示例，不是正式BC-Transformer評測預算。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **10** floor plans · 原文頁 4
- **120** layout-style scenes · 原文頁 4
- **100** tasks · 原文頁 5
- **75** composite tasks · 原文頁 5
- **100,000** generated trajectories · 原文頁 6

依這個順序讀

1. `README.md` ↗

   GitHub · robocasa/robocasa · 756598a5be

   確認2024作品與後續v0.2 / robosuite v1.5依賴。

   L1–29 · L90–98

---

2. `robocasa/models/scenes/scene_registry.py` ↗

   GitHub · robocasa/robocasa · 756598a5be

   10種layout、12種style各有獨立ID與YAML引用。

   L7–62 · L65–118

---

3. `robocasa/utils/dataset_registry.py` ↗

   GitHub · robocasa/robocasa · 756598a5be

   逐項核讀25＋5資料入口、horizon、v0.1資料路徑、raw/image/MimicGen選擇。

   L1–354

---

4. `robocasa/environments/kitchen/single_stage/kitchen_pnp.py` ↗
   GitHub · robocasa/robocasa · 756598a5be

   PnPCounterToCab的指令、fixtures、目標 / 幹擾物、初始開門及成功條件。

   L24–139

---

5. `robocasa/utils/object_utils.py` ↗
   GitHub · robocasa/robocasa · 756598a5be

   從checker追到bounding-box投影與gripper距離閾值。

   L12–60 · L349–356

---

6. `robocasa/scripts/playback_dataset.py` ↗
   GitHub · robocasa/robocasa · 756598a5be

   HDF5 reader與模型、ep_meta、states、actions還原。

   L133–191 · L214–272 · L378–395

---

7. `robocasa/utils/eval_utils.py` ↗
   GitHub · robocasa/robocasa · 756598a5be

   五個固定場景組合、B物件split與成功時計數的參考loop。

   L16–59 · L62–103

---

8. `README.md` ↗
   GitHub · robocasa/robocasa · 456174f62b

   確認目前main承載365版，避免把新版本規模回填2024論文。

   L5–22 · L142–150

怎麼接入我們的benchmark

可重用

layout/style YAML引用、原生task class、物件抽樣與語言模板、v0.1 HDF5資料來源、task checker。

需要轉換

source固定論文v1與程式v0.2；environment分layout/style/asset；task保留PnP等原生ID；case記物件split、場景pair、初態與控制設定；evaluator分開bool成功、step horizon及trial數。raw、rendered、MimicGen資料保留派生關係。

仍需補齊

完整75 composite與已公開資料入口的逐項對應、原始2024程式 / robosuite精確版本、正式policy runner設定與50 trials seed清單，以及HDF5 / 資產閉合驗證。

P071 · RoboCasa365

RoboCasa365: A Large-Scale Simulation Framework for Training and Benchmarking Generalist Robots

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

RoboCasa365 應從 TASK_SET_REGISTRY、split 建環境、LeRobot extras 和具體 task checker 讀起。現行程式的 all_tasks 來自資料registry而非365項完整任務名冊；論文與後續檔案的trial數、horizon也已不同。

> **版本與身份**
>
> 主倉庫同時殘留舊eval_utils的PandaMobile/B split；365應沿env_utils＋Gym讀取。Gym預設split="test"，create_env只接受None/all/pretrain/target，因此呼叫時需明設split。LeRobot playback拒絕filter_key；--use_abs_actions沒有進入use_actions分支，而底層get_episode_actions(abs_actions=True)也明確未實作。README要求robosuite master，LeRobot與policy runner版本尚未固定；本次沒有宣稱執行相容。
>
> 對應 arXiv:2603.04356v1（2026-03-04 / ICLR 2026），四位作者及題名與README的RoboCasa365引用一致。與P070共用官方倉庫，但這份筆記固定365時代main：456174f62b89b8fca99eaaf33949c29fec9cfc2a。

領域	居家整理與清潔、餐飲與烹飪
環境	pretrain由layout 11–60與style 11–60交叉組成2500組；target只用(1,1)…(10,10)十組，不是10×10。create_env同時切換obj_instance_split。Kitchen會再排除任務不支援的layout/style；2500不能保證每task都有2500個有效場景。
任務	論文365＝65 atomic＋300 composite；target50明列18 atomic-seen、16 composite-seen、16 composite-unseen。固定registry經AST計數為65 atomic＋252 composite＝317個key，all_tasks直接串接這兩表；pretrain300與target50聯集316，另外一個key是PlaceOnDishRack。這是資料 / 評測入口的覆蓋差異，不以317覆蓋論文365，也不推論未列者沒有環境實作。
題數與資料	get_ds_meta輸出path/horizon/filter_key/task/split/source；human預設pretrain100、target500 demos，MimicGen一般10000但OpenCabinet特例5000。缺folder回None，soup會略過。LeRobot讀data/*/episode_NNNNNN.parquet的action，按meta/modality.json重排；重播另需extras/dataset_meta.json的env_args，及每episode的states.npz、model.xml.gz、ep_meta.json。ep_meta保留layout_id/style_id/object_cfgs/fixture_refs/cam_configs/lang及底盤初態。action原始順序為eef平移3、旋轉3、gripper1、base/torso4、mode1；Gym提供三個video.*視角、state.*與annotation.human.task_description，不能直接按LeRobot欄位字典順序拼接。

評估方式	Gym.step→Kitchen.reward / 具體_check_success；PickPlaceCounterToCabinet要求bbox位於某一櫃內區域且eef離物件>0.25公尺。obj_inside_of仍在未正規化軸投影使用0.05，非固定5公分容差。Gym將checker轉為reward 0/1與info.success；ignore_done=True且truncated固定False，registry的horizon必須由policy runner另行取用。論文§G.2每task30 trials、期限內曾成功即算成功、跨task平均；現行檔案改50 rollouts且v1.0.1把horizon增至1.5倍。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **50** 新pretrain floor layouts · 原文頁 4
- **2,500** pretrain layout-style scenes · 原文頁 4
- **10** target scenes · 原文頁 4
- **365** tasks · 原文頁 5
- **50** target eval tasks · 原文頁 6
- **600,000** synthetic pretrain demos · 60×10K · 原文頁 6

依這個順序讀

1. `README.md` ↗

   GitHub · robocasa/robocasa · 456174f62b

   辨認2024/365兩篇論文及v1.0.1 horizon、2026-07標註更新。

   L5–22 · L129–150

2. `docs/benchmarking/benchmarking_overview.md` ↗

   GitHub · robocasa/robocasa · 456174f62b

   當前檔案的50 rollouts與1.5倍horizon，對照論文30 trials。

   L16–33

3. `docs/datasets/datasets_overview.md` ↗

   GitHub · robocasa/robocasa · 456174f62b

   300 pretrain、50 target與18/16/16三組資料。

   L3–71

4. `robocasa/utils/dataset_registry.py` ↗

   GitHub · robocasa/robocasa · 456174f62b

   task資料條目、target清單與all_tasks實際組成。

   L1–40 · L2130–2170 · L2802–2860 · L2931–2962

---

5. `robocasa/utils/dataset_registry_utils.py` ↗

   GitHub · robocasa/robocasa · 456174f62b

   資料路徑、demo_fraction/filter_key、缺資料時略過及task horizon取得。

   L11–89 · L121–169 · L240–253

---

6. `robocasa/models/scenes/scene_registry.py` ↗

   GitHub · robocasa/robocasa · 456174f62b

   1–10 target與11–60 pretrain的layout/style群組。

   L14–92 · L162–199

---

7. `robocasa/utils/env_utils.py` ↗

   GitHub · robocasa/robocasa · 456174f62b

   split到場景 / 物件的對映、12維action切片與成功時計數的參考loop。

   L57–154 · L157–193

---

8. `robocasa/wrappers/gym_wrapper.py` ↗

   GitHub · robocasa/robocasa · 456174f62b

   typed observation/action、預設split、success、done與未註冊TimeLimit的行為。

   L33–140 · L143–177 · L303–328 · L342–385 · L400–424

---

9. `robocasa/environments/kitchen/atomic/kitchen_pick_place.py` ↗

   GitHub · robocasa/robocasa · 456174f62b

   具體PickPlaceCounterToCabinet的物件配置、指令與checker。

   L24–137

---

10. `robocasa/utils/object_utils.py` ↗

    GitHub · robocasa/robocasa · 456174f62b

    完整追到fixture內部幾何投影及eef距離。

    L14–64 · L645–652

---

11. `robocasa/environments/kitchen/kitchen.py` ↗

    GitHub · robocasa/robocasa · 456174f62b

    20 Hz、場景組合排除、ep_meta及reward委派。

    L376–396 · L424–445 · L1167–1214 · L1530–1540

---

12. `robocasa/scripts/dataset_scripts/playback_dataset.py` ↗

    GitHub · robocasa/robocasa · 456174f62b

    LeRobot重播的真實reader呼叫與filter/absolute-action限制。

    L254–304 · L315–345

---

13. `robocasa/utils/lerobot_utils.py` ↗

    GitHub · robocasa/robocasa · 456174f62b

    Parquet action排序、meta/modality.json與必需extras實體欄位。

    L63–79 · L123–165 · L199–346

---

14. `robocasa/utils/eval_utils.py` ↗

    GitHub · robocasa/robocasa · 456174f62b

    核對main殘留的PandaMobile、B物件split與五場景舊介面，避免誤用於365評測。

    L14–57

怎麼接入我們的benchmark

可重用

有版本的task sets、pretrain/target分割、LeRobot modality及extras、場景 / 物件生成設定與具體bool checker。

需要轉換

source記論文v1及commit；task全集、資料覆蓋、target集合分欄。case記split、layout/style pair、物件分割、seed、控制頻率及實際horizon；evaluator儲存trial數、期限內成功與跨task平均，禁止和P070或不同horizon結果直接合併。

仍需補齊

365任務與317個資料key的完整對照、正式policy runner依賴commit / seed清單、per-frame subtask標註的實際檔案schema，以及LeRobot影片 / extras / 資產的閉合驗證。

P072 · VLABench

VLABench: A Large-Scale Benchmark for Language-Conditioned Robotics Manipulation with Long-Horizon Reasoning Tasks

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

VLABench 有互動VLA評測與離線VLM技能序列評測兩條不同鏈。已追到select_fruit的容器幾何、progress實作、HDF5 writer/reader及DSL匹配；metric.py的pass不代表全庫沒有評分器，但現行總分與CLI確有靜態缺陷。

> **版本與身份**
>
> VLM get_final_score雖宣告0.4/0.4/0.1/0.1，實際total_score只加前兩項，因此完美匹配上限80；get_final_score_dict呼叫get_result_save_path時漏eval_dim。evaluate_vlm.py引用未宣告的task_list_json/save_dir。互動Evaluator捕捉episode例外後不加入task_infos，均值分母會縮小；必須另列請求、完成、失敗及錯誤數。README的舊CLI拼字/引數也不等於現行parser。這些是靜態檢查結果，未執行上游。
>
> 固定論文為arXiv:2412.18194v1（2024-12-24），README引用相同題名與11位作者。固定程式cf588fe60c0c7282174fe979f5913170cfe69017（2025-11-11）已有2025評測軌道與資料更新，不能視作2024預覽版的原封快照。

領域	居家整理與清潔、餐飲與烹飪、辦公與教育、實驗室操作、休閒與運動
環境	MuJoCo/dm_control依scene、components、robot及MJCF資產組裝；select_fruit_series具體使用studyroom_0與table。觀測依模型的ncam迭代，不能把樣例四視角當所有任務固定相機數。物理步、NUM_SUBSTEPS=100與policy步數分開；影片10 fps不是通用控制頻率。
任務	論文100項（60 primitive＋40 composite）；原生task、config_manager與condition以註冊名連線。select_fruit的seen類別為apple/banana/orange/pear，unseen為peach/lemon/kiwi/mango；contain檢查物件worldbody位置點落在Plate的平面範圍及預設0–0.1公尺上方，不檢查整個物件bbox或穩定接觸。PourCondition只比較top/bottom site高度，是姿態代理，不代表液體流動。
題數與資料	HDF5為data/<時間名>/observation、meta_info、trajectory、instruction；observation可含rgb uint8、depth/q_state/q_velocity/q_acceleration/ee_state及點雲float32。meta_info儲存entities、target_entity、episode_config字串；writer略過segmentation、instrinsic、extrinsic等欄位，點雲補零且未另存有效點數。trajectory為8維xyz/Euler/兩指gripper；指令碼只從xyz減robot_position，不能宣稱已做含旋轉的完整座標轉換。VLM題目則是task/exampleN/input的input.png/input_mask.png/instruction.txt與output/operation_sequence.json，GT為skill_sequence[{name,params}]。

評估方式	互動鏈：Evaluator→load_env→dm_control終止→ConditionSet→ContainCondition→Plate/FlatContainer.contain；success取timestep.last。未提供episode_config時用42+i seeds；預設最多200個policy步，可由task_config覆蓋。當前API分別平均success、intention、progress；intention是歷史最小eef距離<0.1公尺，primitive progress將當前已滿足condition與曾抓握target計數合併，沒有實作論文0.2/0.8加權PS。離線VLM鏈用技能/引數多重集合recall、技能引數聯合recall及DAG節點匹配百分比；這些0–100分數不能轉稱物理成功率。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **100** task categories · 原文頁 4
- **60** primitive tasks · 原文頁 4
- **40** composite tasks · 原文頁 4
- **2,164** 資產items · 原文頁 6

依這個順序讀

1. `README.md` ↗
   GitHub · OpenMOSS/VLABench · cf588fe60c

   核對作品、2025資料發布與VLA/VLM分流。

   `L1–39 · L139–184 · L193–204`

2. `VLABench/configs/task_config.json` ↗
   GitHub · OpenMOSS/VLABench · cf588fe60c

   引擎設定、studyroom、水果類別與容器split。

   `L1–18 · L92–119`

3. `VLABench/tasks/config_manager.py` ↗
   GitHub · OpenMOSS/VLABench · cf588fe60c

   seen/unseen抽樣及原生entity→class/XML對映。

   `L40–114 · L122–150`

4. VLABench/tasks/hierarchical_tasks/primitive/select_fruit_series.py ↗
   GitHub · OpenMOSS/VLABench · cf588fe60c

   指令、contain條件與pick/place expert序列。

   L8–30 · L87–97

---

5. VLABench/envs/__init__.py ↗
   GitHub · OpenMOSS/VLABench · cf588fe60c

   episode_config與task註冊的載入入口。

   L15–55

---

6. VLABench/tasks/dm_task.py ↗
   GitHub · OpenMOSS/VLABench · cf588fe60c

   狀態重建、condition例項化、終止checker與episode儲存。

   L25–76 · L124–152 · L165–222 · L298–303 · L442–460

---

7. VLABench/tasks/condition.py ↗
   GitHub · OpenMOSS/VLABench · cf588fe60c

   Contain、同時AND、累積條件及Pour姿態代理。

   L43–64 · L178–199 · L299–355

---

8. VLABench/configs/constant.py ↗
   GitHub · OpenMOSS/VLABench · cf588fe60c

   plate_seen/unseen皆實際映到Plate class。

   L153–157

---

9. VLABench/tasks/components/specific_entities/common_containers.py ↗
   GitHub · OpenMOSS/VLABench · cf588fe60c

   Plate繼承FlatContainer，閉合contain dispatch。

   L102–105

---

10. `VLABench/tasks/components/container.py` ↗

    GitHub · OpenMOSS/VLABench · cf588fe60c

    容器軸對齊bounds、平面半徑及高度判定，非抽象stub。

    L34–102

---

11. `VLABench/envs/dm_env.py` ↗

    GitHub · OpenMOSS/VLABench · cf588fe60c

    480×480多視角觀測、原生拼字instrinsic與進度委派。

    L7–41 · L118–150 · L213–235

---

12. `VLABench/utils/skill_lib.py` ↗

    GitHub · OpenMOSS/VLABench · cf588fe60c

    8維waypoint為xyz＋Euler＋兩指gripper；成功末步可能不記入示範。

    L18–66

---

13. `scripts/trajectory_generation.py` ↗

    GitHub · OpenMOSS/VLABench · cf588fe60c

    成功篩選、只減底座平移的trajectory轉換與meta_info來源。

    L47–110

---

14. `VLABench/utils/data_utils.py` ↗

    GitHub · OpenMOSS/VLABench · cf588fe60c

    HDF5群組、dtypes、丟棄欄位及點雲補零。

    L12–87

---

15. `tutorials/3.process_dataset.ipynb` ↗

    GitHub · OpenMOSS/VLABench · cf588fe60c

    實際HDF5 reader與作者儲存的樣例欄位形狀；未執行notebook。

    L39–52 · L86–118 · L156–160

---

16. VLABench/tasks/hierarchical_tasks/primitive/base.py ↗
    GitHub · OpenMOSS/VLABench · cf588fe60c

    最近接近距離、曾抓握與當前條件比例的真正進度。

    L4–60

17. VLABench/evaluation/metric.py ↗
    GitHub · OpenMOSS/VLABench · cf588fe60c

    確認僅為未實作函式，不能當正式metric入口。

    L4–23

18. scripts/evaluate_policy.py ↗
    GitHub · OpenMOSS/VLABench · cf588fe60c

    CLI預算、track JSON載入與metric選擇。

    L11–47

19. VLABench/evaluation/evaluator/base.py ↗
    GitHub · OpenMOSS/VLABench · cf588fe60c

    seed/episode來源、exception分母、IK動作、last成功與三個獨立均值。

    L39–109 · L122–205

20. VLABench/evaluation/evaluator/vlm.py ↗
    GitHub · OpenMOSS/VLABench · cf588fe60c

    圖片/指令/GT序列格式、離線計分與輸出路徑錯配。

    L54–110 · L233–279 · L300–325

21. VLABench/evaluation/utils.py ↗
    GitHub · OpenMOSS/VLABench · cf588fe60c

    技能pattern→DAG、recall/exact比例及漏加權重的總分。

    L7–98 · L148–339

22. `scripts/evaluate_vlm.py` ↗

    GitHub · OpenMOSS/VLABench · cf588fe60c

    未定義CLI屬性及few-shot/CoT輸出設定。

    L14–64

怎麼接入我們的benchmark

可重用

原生task/config/condition、確定性episode_config、HDF5與DSL case結構、分開的物理checker及圖匹配metric。

需要轉換

同一source保留互動與離線兩種case/evaluator；對映name/params/target_entity_name/target_container_name時儲存圖依賴模式、few-shot、CoT及資訊可見性。保留8維Euler waypoint、9維joint＋gripper控制與觀測四元數各自語義，不依維度誤併。

仍需補齊

大型track JSON與外部vlm_evaluation_v1.0的完整case清單尚未取得，不能填全庫episode數；仍需修正CLI/metric、固定model與dm_control版本、資產閉合，以及逐task驗證進度支援。

P073 · RoboTwin

RoboTwin: Dual-Arm Robot Benchmark with Generative Digital Twins (early version)

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

P073 應綁官方early_version分支。已核讀早期DP3的PKL→Zarr→reader→rollout→錘擊checker與公開seed檔；真實17項資料任務、論文6項實驗、後續分支任務表必須分開。

> **版本與身份**
>
> 本體固定early_version f14a315ac4c9c72bfea05b523874f787080dfcf2，非main ea8b21121ebb3cd201ff5b3fe361944ac94eda3f。早期README明記2024-10-01改get_obs及實驗結果，真實資料仍標Coming Soon。TopK摘要寫出各項suc/(topk×test_num)，沒有求和成單一平均，不能直接把文字輸出當總平均。
>
> 對應arXiv:2409.02920v3（2025-04-16），題名帶early version、九位作者。早期與現行README都直接引用該arXiv；CVPR 2025的RoboTwin為2504.13059，不能替代P073。

領域	居家整理與清潔、餐飲與烹飪、工藝與修繕、協助、交接與陪伴
環境	早期SAPIEN雙臂桌面，physics timestep預設1/250秒。錘擊配置有頭部、前方與兩腕相機，320×240、1024個世界座標xyzRGB點；conbine=False只取頭部點雲。論文真實Cobot Magic資料另為30 Hz、三個640×480 RGB-D視角及主 / 從臂記錄，不能與模擬schema混用。
任務	論文評測6項；真實資料設計17項各30條軌跡，標籤可重疊。分支README列15個名稱，但完整tree只有14個具體env檔，block_sweep未在該commit提供。已讀block_hammer_beat的play_once為pass，不能稱expert產生器已公開。checker要求工具target_pose轉到世界後，xy與方塊各差<0.02公尺且0.78<z<0.81；沒有接觸、衝量或敲擊次數檢查。
題數與資料	PKL儲存observation/<camera>的rgb/depth、intrinsic_cv/extrinsic_cv/cam2world_gl，以及pointcloud/joint_action/endpose。depth乘1000存float64，單位毫米；點雲xyz為世界公尺、RGB限0–1。joint_action是左右各6關節get_drive_target加gripper，共14維，並非實測qpos；endpose為左右xyz/RPY/gripper。轉檔將joint_action同時寫成Zarr data/state與data/action，endpose寫tcp_action，meta/episode_ends為累積排他端點。DP3 reader讀state/action/point_cloud，以episode mask和padding建立時間窗。
評估方式	eval_policy_dp3→test_policy→setup_demo→apply_dp3→check_success。指定checkpoint測100個seed；checkpoint=-1掃描300...3000十個checkpoint，各取前20 seeds再選Top5。錘擊seed檔100筆，範圍100000–100102，略過100025/100029/100040。step_lim=400按預測chunk長度累計，TOPP再展為250 Hz動作；get_obs本身也會scene.step，因此400不能當400個physics frames。每episode成功只累加一次suc。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **17** 資料收集任務 · 原文頁 8
- **6** DP3評測任務 · 原文頁 7, 8
- **510** 真實demo trajectories · 17×30推算 · 原文頁 8

依這個順序讀

1. `README.md` ↗

   GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

   區分early、CVPR 1.0與2.0，找到官方legacy分支。

   L8–31 · L281–288

---

2. `README.md` ↗

   GitHub · RoboTwin-Platform/RoboTwin · f14a315ac4

   50示範發布、模態、較新任務表及尚未發布的真實資料。

   L5–8 · L21–49 · L83–123 · L137–167

---

3. `task_config/block_hammer_beat.yml` ↗

   GitHub · RoboTwin-Platform/RoboTwin · f14a315ac4

   相機、1024點、雙臂及PKL資料選項。

   L1–25

---

4. `envs/block_hammer_beat.py` ↗

   GitHub · RoboTwin-Platform/RoboTwin · f14a315ac4

   初態、400步上限、play_once佔位及工具參考點成功條件。

   L6–64

---

5. `envs/base_task.py` ↗

   GitHub · RoboTwin-Platform/RoboTwin · f14a315ac4

   深度/座標、drive targets、PKL欄位、DP3 chunk控制與checker。

   L48–84 · L97–122 · L694–738 · L746–773 · L889–908 · L1035–1069 · L1099–1109 · L1111–1220 · L1222–1311 · L1320–1387

---

6. `script/pkl2zarr_dp3.py` ↗

   GitHub · RoboTwin-Platform/RoboTwin · f14a315ac4

   state/action都來自joint_action；episode_ends累積邊界。

   L17–58 · L66–95

---

7. `policy/3D-Diffusion-Policy/3D-Diffusion-Policy/diffusion_policy_3d/dataset/robot_dataset.py` ↗

   GitHub · RoboTwin-Platform/RoboTwin · f14a315ac4

   Zarr reader、episode mask與時間窗sample。

   L13–58 · L73–90

---

8. `policy/3D-Diffusion-Policy/3D-Diffusion-Policy/dp3_policy.py` ↗

   GitHub · RoboTwin-Platform/RoboTwin · f14a315ac4

   policy/runner與apply_dp3的接點。

   L31–45

---

9. `script/eval_policy_dp3.py` ↗

   GitHub · RoboTwin-Platform/RoboTwin · f14a315ac4

   checkpoint選擇、20/100 trials、seed與成功率分母。

   L42–99 · L105–134

---

10. `task_config/eval_seeds/block_hammer_beat.txt` ↗

    GitHub · RoboTwin-Platform/RoboTwin · f14a315ac4

    100個不連續eval seeds，不能用連續range代替。

    L1–1

怎麼接入我們的benchmark

可重用

early_version任務class、checker、eval seeds、相機 / 點雲設定、PKL/Zarr轉換及DP3評測。

需要轉換

source分early/1.0/2.0，task保留論文子集關係；case存seed、checkpoint選擇方式及chunk預算。state標為command target，另記depth的mm→m轉換、world/OpenGL/OpenCV、RPY與episode邊界。

仍需補齊

block_sweep程式、其他論文任務逐一checker覆核、17項真實資料manifest、可執行expert產生器、資產target_pose與相容SAPIEN/DP3依賴鎖定。

P074 · RoboTwin 2.0

RoboTwin 2.0: A Scalable Data Generator and Benchmark with Strong Domain Randomization for Robust Bimanual Robotic Manipulation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

RoboTwin 2.0 的50項任務清單與逐task步數上限可直接核對；現行main已有XPolicyLab評測及新版HDF5。已閉合Lift Pot的幾何checker、seed篩選、action計數、資料時間對齊與影像解碼，須與2025論文版區分。

> **版本與身份**
>
> XPolicyLab實際gitlink為fa431ecd893ee706883e64fe5fe1464ec8cd928d；.gitmodules的branch=main不是版本pin。本次只讀RoboTwin端整合與本地codec。具體schema風險：save_freq用作每N個控制步抽幀，卻原值寫入frequency；還另插入端點幀，不能據此重建固定Hz時間軸。extrinsics_matrix優先寫cam2world_gl，缺少時才寫extrinsic_cv，座標方向不由欄位名保證。JPEG有legacy色序與XPL-RGB1兩制，不能無條件再交換RGB/BGR。
>
> 對應arXiv:2506.18088v2（2025-08-27），題名 / 作者以固定PDF為準。官方README連同一arXiv，並記錄2025-08論文更新；本次main commit ea8b21121ebb3cd201ff5b3fe361944ac94eda3f則是2026-09-24的後續整合版。

領域	居家整理與清潔
環境	SAPIEN桌面雙臂，論文正式設定為Aloha AgileX。現行clean與randomized不是兩個生活場域；randomized包含clutter、背景、光照，table_z_bias實際抽[-0.03,0]公尺，並改用unseen語言。兩份YAML都將depth/pointcloud關閉，不能把論文DP3使用的完美點雲當所有方法共同輸入。
任務	all_tasks與step-limit檔各列50個原生task；左右 / 數量變體按原清單保留。Lift Pot從兩個060_kitchenpot模型抽樣；成功需世界z>0.82公尺、兩TCP各距指定contact point<0.03公尺，以及pot區域性z軸與世界z軸內積>0.8。此check不另測雙臂接觸力或持續時間。
題數與資料	原生PKL仍是observation/joint_action/endpose字典；關節讀值來自drive targets，非real_jointState。現行轉檔輸出HDF5 data_format_version="v1.0"、instructions JSON字串、additional_info/frequency、state/action與vision；state=values[:-1]、action=values[1:]，只保留N−1組。joint欄位用left/right_arm_joint_states及left/right_ee_joint_states，pose用left/right_ee_poses；vision含cam_head/cam_left_wrist/cam_right_wrist的colors定長JPEG bytes、shape、可選depths與矩陣。線上adapter用單數joint_state鍵，且EE/TCP有不同原點。

評估方式	main→eval_remote_policy→take_action→lift_pot.check_success→eval_success；逐task成功數除以test_num（預設100）。從100000×(1+seed)往後找候選；expert_check預設開啟，先play_once且要求plan_success與checker通過，再重置同seed評policy。unstable、setup錯誤及首個action前的rollout錯誤會被略過；因此100是有效試驗數，不是連續100個初態。期限按take_action_cnt而非physics frames；每次action內部再規劃 / 插值，達條件即鎖定成功。論文50 clean示範訓練、Easy/Hard各自100rollouts的結果不由本輪執行重現。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **50** simulation benchmark tasks · 原文頁 11
- **731** RoboTwin-OD物件 · 原文頁 6
- **4** 真實驗證tasks · 原文頁 10
- **100** 每task設定的rollouts · 原文頁 11

依這個順序讀

1. `README.md` ↗

   GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

   核對2.0作品、legacy分支、DP3修正與2026 XPolicyLab整合。

   L8–31 · L35–49 · L59–78 · L249–256

2. `.gitmodules` ↗

   GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

   子模組repo與追蹤分支；實際pin另以git tree為準。

   L1–4

3. `env_cfg/eval/all_tasks.yml` ↗

   GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

   實讀50個評測task IDs。

   L9–59

4. `env_cfg/task_config/_eval_step_limit.yml` ↗
   GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

   50個task各自的action上限，lift_pot為400。

   L1–50

---

5. `env_cfg/task_config/demo_clean.yml` ↗
   GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

   clean條件、50 demonstrations、語言與模態設定。

   L3–38

---

6. `env_cfg/task_config/demo_randomized.yml` ↗
   GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

   randomized改背景 / clutter / 高度 / 光照，並切unseen指令。

   L3–38

---

7. `envs/lift_pot.py` ↗
   GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

   實際兩種pot資產、雙臂expert及高度 / TCP距離 / 方向checker。

   L7–58

---

8. `envs/utils/actor_utils.py` ↗
   GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

   contact point由資產區域性matrix與scale轉成世界點，含articulation覆寫。

   L16–62 · L100–144

---

9. `envs/utils/transforms.py` ↗
   GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

   pot方向分數的實際旋轉與內積。

   L523–530

---

10. `envs/robot/robot.py` ↗
    GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

    jointState是drive targets；EE與TCP原點有0.12公尺差異。

    L494–506 · L557–603

---

11. `envs/_base_task.py` ↗
    GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

    隨機化、obs、儲存間隔、action計數與成功鎖定。

    L55–153 · L201–224 · L438–501 · L608–624 · L1480–1550 · L1552–1640 · L1704–1740

---

12. `envs/utils/pkl2hdf5.py` ↗
    GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

    t/t+1成對欄位、版本、指令、相機matrix與JPEG欄位。

    L79–168 · L171–220

---

13. `envs/utils/parse_hdf5.py` ↗
    GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

    HDF5 reader到decode_image_bit。

    L11–53

---

14. `data/decode_image_bit.py` ↗
    GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

    legacy與XPL-RGB1 JPEG的不同色彩解碼規則。

    L14–46 · L164–223 · L272–299 · L423–442

---

15. `scripts/eval_policy_xpolicylab.py` ↗
    GitHub · RoboTwin-Platform/RoboTwin · ea8b21121e

    種子 / expert篩選、實際success統計與XPolicyLab觀測動作對映。

    L270–332 · L774–851 · L877–999 · L1041–1064 · L1093–1168 · L1214–1245

怎麼接入我們的benchmark

可重用

50 task IDs、逐task步數、clean/randomized設定、物件contact-point資料模型、具體checker與seed篩選loop。

需要轉換

source固定主repo及XPolicyLab gitlink；case存embodiment、語言分割、隨機化、被接受 / 略過seed、action計數與checkpoint。分開PKL命令、HDF5 t/t+1配對、線上單數鍵，保留EE/TCP、pose/quaternion與JPEG marker約定。

仍需補齊

2025論文對應的程式 / asset版本閉合、所有50 checker逐項覆核、XPolicyLab與policy模型依賴取得、正式accepted-seed manifest及時間 / 座標schema驗證。

P075 · VIMA

VIMA: General Robot Manipulation with Multimodal Prompts

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

VIMA-Bench提供任務、資料與成功判定，VIMA倉庫提供模型與互動範例。已核讀多模態prompt、四級partition、T+1/T資料對齊，以及visual_manipulation與without_touching的具體checker；primitive步數不能當低階控制步數。

> **版本與身份**
>
> train與L1 YAML整檔相同（SHA256 bf577e269939b6b9850f1d4fe1deb4e532b1badae6711cb4c74b9f438c611322）；泛化須靠不同初始化，不能把相同YAML當已固定test cases。VIMA example.py一直重設seed42，reset失敗才加seed；顯示範例設hide_arm_rgb=False，README benchmark預設True。其TimeLimit是oracle_max_steps+2，並非完成全級評測的統計指令碼。
>
> 對應arXiv:2210.03094v2（2023-05-28 / ICML 2023），收錄年份2022是首版年。兩個官方倉庫都連同一arXiv；VIMABench固定97e0af11e126fd477c9d81eeabfb6c739021c680，VIMA固定8449837aa453f8ec9ba229cb956e3bbef5c796ea。

領域	居家整理與清潔、通用物件與機動作業
環境	PyBullet / UR5桌面，前方與俯視RGB＋segmentation；基礎physics為240 Hz。位置bounds為x=[0.25,0.75]、y=[−0.5,0.5]公尺。吸盤pick-place或spatula push是完整primitive，一次env.step內含多個移動、接觸與settle步。
任務	全庫17個模板；train/L1/L2各13、L3為12、L4為4個模板，不能直接算17×4套獨立任務。L4是sweep_without_touching、novel_adj_and_noun、follow_motion、same_texture。visual_manipulation的goal含objects/matches/target poses/metric/params/max_progress；影像placeholder與語言由generate_prompt共同生成，不能把prompt_assets丟掉後稱為同一任務。
題數與資料	發布說明為650K成功訓練軌跡，非測試case總量且本輪未重新清點資產。每trajectory含rgb_front/<t>.jpg、rgb_top/<t>.jpg、obs.pkl（segm/ee）、action.pkl、trajectory.pkl（prompt/prompt_assets/steps/success/failure及seed、物件對映、action_bounds等meta）。writer明確儲存T個actions與T+1個observations；loader將JPEG HWC轉CHW。action為pose0/pose1各2D位置＋xyzw四元數，模型範例另執行位置反正規化與quaternion範圍轉換。

評估方式	env.step→task.update_goals→具體check_success→info.success/failure；reward固定0，done也可能來自失敗或primitive timeout。visual_manipulation設定pos_eps=0.1公尺，is_match只比xy距離，忽略z與旋轉；完成的goal逐一移除，誤把distractor當目標 / 物件亦失敗。without_touching每50個physics steps檢查物件點集與禁止區域重疊，一次違規即鎖定failure，最後還需完成精確目標數；不是逐接觸事件的檢查。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **17** task templates · 原文頁 2, 3
- **6** 非互斥prompt/task型別 · 原文頁 3
- **600,000** expert training trajectories · 超過 · 原文頁 1

依這個順序讀

1. `README.md` ↗

   GitHub · vimalabs/VIMABench · 97e0af11e1

   17模板、4級泛化、650K訓練軌跡及原生媒體 / action。

   L1–19 · L46–158

2. `vima_bench/tasks/__init__.py` ↗

   GitHub · vimalabs/VIMABench · 97e0af11e1

   task class註冊、YAML插值解析及過濾輔助key。

   L11–94

3. `vima_bench/tasks/partition_files/train.yaml` ↗

   GitHub · vimalabs/VIMABench · 97e0af11e1

   13個訓練模板與物件 / 材質集合。

   L1–200

4. `vima_bench/tasks/partition_files/placement_generalization.yaml` ↗

   GitHub · vimalabs/VIMABench · 97e0af11e1

   L1沿用訓練物件和材質；整檔bytes與train相同。

   L103–125

5. `vima_bench/tasks/partition_files/combinatorial_generalization.yaml` ↗
   GitHub · vimalabs/VIMABench · 97e0af11e1

   L2交換材質集合的角色，保留13模板設定。

   L1–204

---

6. `vima_bench/tasks/partition_files/novel_object_generalization.yaml` ↗
   GitHub · vimalabs/VIMABench · 97e0af11e1

   L3的12個模板及新形狀 / 容器。

   L1–69

---

7. `vima_bench/tasks/partition_files/novel_task_generalization.yaml` ↗
   GitHub · vimalabs/VIMABench · 97e0af11e1

   L4四個未見模板，空值不等於零案例。

   L1–11

---

8. `vima_bench/tasks/task_suite/instruction_following/simple_manipulation.py` ↗
   GitHub · vimalabs/VIMABench · 97e0af11e1

   影像placeholder、goal tuple與10公分平面匹配；rotation被忽略。

   L22–76 · L205–233 · L302–353 · L484–536

---

9. `vima_bench/tasks/task_suite/base.py` ↗
   GitHub · vimalabs/VIMABench · 97e0af11e1

   goal移除、distractor失敗條件、prompt資產與xy/yaw匹配實作。

   L72–96 · L313–430 · L448–498

---

10. `vima_bench/tasks/task_suite/constraint_satisfaction/without_touching.py` ↗
    GitHub · vimalabs/VIMABench · 97e0af11e1

    語言約束與需追蹤的禁止區域 / 物件點集。

    L25–66 · L352–369

---

11. `vima_bench/tasks/task_suite/constraint_satisfaction/base.py` ↗

    GitHub · vimalabs/VIMABench · 97e0af11e1

    每50個simulation steps檢查點集入區，鎖定違規及精確物件數。

    L130–143 · L155–369

---

12. `vima_bench/env/base.py` ↗

    GitHub · vimalabs/VIMABench · 97e0af11e1

    兩pose API、meta_info、zero reward、success/failure與constraint呼叫鏈。

    L28–57 · L159–199 · L320–389 · L391–455 · L581–591 · L660–682

---

13. `vima_bench/tasks/components/action_primitives.py` ↗

    GitHub · vimalabs/VIMABench · 97e0af11e1

    PickPlace如何將2D位置補z並透過接觸下降 / 吸盤執行。

    L177–241

---

14. `scripts/data_generation/run.py` ↗

    GitHub · vimalabs/VIMABench · 97e0af11e1

    成功篩選、T+1觀測/T動作與三個pickle＋JPEG的儲存。

    L39–145

---

15. `scripts/data_loading.py` ↗

    GitHub · vimalabs/VIMABench · 97e0af11e1

    真正的分檔reader、CHW RGB與prompt_assets復原。

    L10–48

---

16. `README.md` ↗

    GitHub · vimalabs/VIMA · 8449837aa4

    確認另一倉庫的角色是模型與示範。

    L1–24

---

17. `scripts/example.py` ↗

    GitHub · vimalabs/VIMA · 8449837aa4

    模型action反正規化、固定seed範例、reset重試與oracle_max_steps+2限制。

    L79–106 · L200–240 · L476–496

怎麼接入我們的benchmark

可重用

模板class、版本化partition/YAML參照、prompt_assets、obs/action時序、seed與具體幾何 / 過程checker。

需要轉換

case ID需含template、partition、seed、物件/材質及prompt媒體；保留T+1/T對齊、2D雙pose primitive、oracle-only goals、違規記憶與50-frame檢查頻率。任務模板、軌跡量及rollout數分欄。

仍需補齊

正式eval seed/case manifest及跨task聚合設定、其餘checker逐一覆核、全部示範 / prompt媒體閉合，以及policy checkpoint與視覺資訊條件驗證。

P076 · Ravens / Transporter Networks

Transporter Networks: Rearranging the Visual World for Robotic Manipulation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

Ravens的具體評測鏈是task goal→delta reward→test累積return→plot平均，包含部分分數。已核讀插入、清掃及資料writer/reader；done不是統一成功旗標，圖表的百分比標籤也不能直接當原生分數單位。

> **版本與身份**
>
> 固定manifest顯示倉庫已封存。具體問題：plot.py把0–1 mean/std直接印成%且ylabel寫Task Success，沒有×100，也掩蓋partial credit；6DOF插入子類設sixdof與pos_eps=0.02，仍繼承只看xy/yaw的is_match，未增加z/roll/pitch判定。test預設task=hanoi但registry為towers-of-hanoi，應明設task。Dataset.sample是先等機率選episode再選非末步，不是全庫frame均勻抽樣。
>
> 對應Transporter Networks: Rearranging the Visual World for Robotic Manipulation，arXiv:2010.14406v3（2022-01-05；CoRL 2020作品）。README明稱此論文的reference repository；正式作者清單以固定PDF為準。固定程式4752ffab487ebd387781ad7890aa540ae2780970為2024-03-14快照，非2020原始版本。

領域	居家整理與清潔、裝配與生產作業、包裝、倉儲與物流、通用物件與機動作業
環境	PyBullet / UR5桌面，工作區0.5×1公尺；三個RealSenseD415模擬視角、640×480 RGB-D。環境預設240 Hz，demos/test指令碼明設480 Hz；這是physics頻率，不是示範frame或policy primitive頻率。相機引數在固定cameras.py，沒有逐episode嵌入color/depth檔。
任務	論文十項桌面任務；當前registry有15個ID，包含五個額外子型，不能回填成15項原始benchmark。BlockInsertion的goal是object/match-matrix/target-pose與pose metric，最多3次動作；SweepingPiles配置50個小方塊，最多20次push，以zone內物件取樣點比例給部分分數。
題數與資料	Dataset分color/depth/action/reward/info五個資料夾，用相同NNNNNN-seed.pkl連線；color uint8、depth float32公尺。每個episode是(obs,act,reward,info)序列，最後一筆act=None。demos先儲存當前obs/action與既有reward，才env.step，因此第t筆reward對應前一動作；匯出transition時應將action[t]對上reward[t+1]。info儲存GT物件position/quaternion/dimensions；test還會將末筆goal傳給agent，資訊可見性須按policy另記。action含pose0/pose1，各為xyz公尺＋xyzw四元數，並非VIMA的2D位置介面。

評估方式	Environment.step→task.primitive→Task.reward/done；pose metric用xy距離<0.01公尺及對稱修正後yaw差<15°。zone metric將每物件區域性取樣點轉入zone，算合法點比例；點集由visual-shape尺寸以0.02公尺網格建立，並非精確mesh體積。reward是累積進度差值；test加總成completion return，goal完結或_rewards>0.99才由Task.done回True，primitive timeout也可使env.done=True。論文每task100 unseen runs；程式實際遍歷test Dataset.n_episodes。test資料只收oracle return>0.99的奇數seed，訓練為偶數seed。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **10** simulation tasks · 原文頁 6
- **100** 每task unseen test runs · 原文頁 6
- **2** real驗證tasks · 原文頁 8

依這個順序讀

1. `README.md` ↗

   GitHub · google-research/ravens · 4752ffab48

   十項原始任務、論文關係及data/train/test/plot流程。

   L1–28 · L76–103

2. `ravens/tasks/__init__.py` ↗

   GitHub · google-research/ravens · 4752ffab48

   原生ID與額外easy/translation/sixdof等變體。

   L18–51

3. `ravens/tasks/block_insertion.py` ↗

   GitHub · google-research/ravens · 4752ffab48

   L形物件 / fixture、goal tuple、3次primitive上限及6DOF子類。

   L25–64 · L82–106

4. `ravens/tasks/sweeping_piles.py` ↗

   GitHub · google-research/ravens · 4752ffab48

   50小物件、0.12×0.12公尺目標區與zone評分。

   L25–63

5. `ravens/tasks/task.py` ↗
   GitHub · google-research/ravens · 4752ffab48

   完整pose/zone reward、goal消耗、done與取樣點定義。

   L39–75 · L211–320 · L341–364 · L396–404

---

6. `ravens/environments/environment.py` ↗
   GitHub · google-research/ravens · 4752ffab48

   觀測 / action schema、primitive dispatch、timeout與公尺深度重建。

   L45–103 · L179–255 · L270–341 · L398–406

---

7. `ravens/tasks/primitives.py` ↗
   GitHub · google-research/ravens · 4752ffab48

   實際吸盤pick-place與spatula push，區分高階動作與physics步。

   L22–128

---

8. `ravens/tasks/cameras.py` ↗
   GitHub · google-research/ravens · 4752ffab48

   三個640×480 RGB-D視角及固定intrinsics/extrinsics。

   L22–62

---

9. `ravens/demos.py` ↗
   GitHub · google-research/ravens · 4752ffab48

   even/odd seed、oracle成功篩選與末筆None action。

   L43–92

---

10. `ravens/dataset.py` ↗
    GitHub · google-research/ravens · 4752ffab48

    五類PKL分檔、seed解析、tuple還原及episode/step抽樣。

    L26–90 · L96–169

---

11. `ravens/test.py` ↗

    GitHub · google-research/ravens · 4752ffab48

    逐test dataset episode還原seed、執行task.max_steps及累積return。

    L30–40 · L61–115

---

12. `ravens/plot.py` ↗

    GitHub · google-research/ravens · 4752ffab48

    真正的mean/std與未乘100的百分比顯示。

    L36–67

怎麼接入我們的benchmark

可重用

十項原始task與變體對映、goal tuple、pose/zone evaluator、seed編碼、RGB-D與原生pick-place/push。

需要轉換

source分論文v3與2024commit；case記task變體、seed、goal、primitive步數與physics頻率。保留terminal None action及reward後移配對；evaluator分開二元goal完成、delta reward、0–1累積完成度和展示用×100比例，不能全叫success rate。

仍需補齊

原論文checkpoint選擇及完整100-case資料manifest、其餘任務checker逐一覆核、相機 / 資產 / seed閉合；6DOF及continuous變體需獨立評測協定。

P077 · CLIPort

CLIPort: What and Where Pathways for Robotic Manipulation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

CLIPort已追到Ravens/PyBullet的bowl / rope任務、示範讀寫與Task.reward/is_match。mean_reward可含部分分數；bowl文字目標與checker有一對一配對落差，且eval沒有按episode seed重設Python random，不能保證完全重建示範語義變體。

> **版本與身份**
>
> 本輪固定cliport/cliport@2be5c47b5bb9bb7040ad90693288b87b1e18e7ad（2023-05-22），晚於2021v1；未取得論文實驗的逐項commit對照。README承認部分seen/unseen train相同、多工Google物件訓練集較小及旋轉augmentation與方向語句衝突。記錄的是所列選讀區段；不聲稱全倉庫 / 完整資料 / 實機實驗已驗證。
>
> 固定論文為 Shridhar、Manuelli、Fox 的 CLIPort: What and Where Pathways for Robotic Manipulation，arXiv:2109.12098v1 / CoRL 2021。PDF 的 code-availability 指向 cliport.github.io；倉庫 README 1–9 同時吻合題名、三位作者、arXiv 與專案網址，足以確認 cliport/cliport 為本論文官方程式。openai/CLIP 與 Ravens 是重用依賴，不能另算 CLIPort benchmark。

領域	包裝、倉儲與物流、通用物件與機動作業
環境	PyBullet 桌面 UR5 / 預設吸盤；agent有三個480×640無噪RGB-D視角，oracle另有俯視影像與segmentation。示範與評測入口將physics設為480Hz，但每筆資料是完成pick/place primitive並等待物體靜止後的決策步，不能當480fps影片。工作區x=[0.25,0.75]、y=[-0.5,0.5]公尺；Task bounds的z上限0.3，dataset/action bounds為0.28，需按用途保留。實機Franka結果不等於此UR5環境可直接重播。
任務	任務檔案的10個goal-conditioned家族需與seen/unseen/full屬性子集及seq流程分開。已讀PutBlockInBowl：隨機1–3個碗、1至碗數個block、6個distractor，語言指定兩種顏色；goal=(objects,matches,target_poses,replace,rotations,metric,params,max_reward)，步數重設為blocks+1。seen與unseen類別在train均取TRAIN_COLORS，unseen只在非train改EVAL_COLORS。AlignRope是20節繩 / 四種邊方向、可正反向匹配；節數、語句變化與生成seed均不能當新增任務數。

題數與資料	RavensDataset把同一episode寫成color/depth/action/reward/info五個目錄下的{episode_id:06d}-{seed}.pkl；color為uint8、depth為float32公尺。序列元素為(obs,act,reward,info)，最後一筆act=None；reward是到達該obs的前一步回饋。act.pose0/pose1各是(position_xyz公尺,quaternion_xyzw)；info含lang_goal及object_id→(pos,rot,dimensions)特權狀態。讀入後以3.125mm/pixel融合成320×160×6 RGB+重複三次height，p0_theta固定0、p1_theta為相對負yaw（弧度）。seq以i+1為goal，其他任務用末幀。train seed從0每次+2，val從1、test從10001每次+2；只儲存oracle總reward>0.99，實際case數須列舉落地檔案，不能用要求生成的n或README估計值替代。
評估方式	callchain：eval.main→ds.load(i)/seed→env.reset（Python random非逐case重設）→最多task.max_steps次env.step→Task.reward→is_match或zone點覆蓋。pose逐object在可配對target中找到任一匹配即加max_reward/objects；is_match只看XY距離與對稱性處理的z-yaw，不看高度，bowl容差0.05m、rope0.02m。zone算區域性座標點落入矩形範圍且低於z上限的比例。reward為累計完成度差值，完成當前goal後彈出相應語言；done是goals空或_rewards>0.99，primitive timeout也會直接done=True且reward=0。結果JSON儲存episodes=(total_reward,last_info)與mean_reward；預設n_demos=100、n_repeats=1，test_best依val mean_reward選模型（未找到則last.ckpt）。因此不得把done、mean_reward與二元success混用。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **10** language-conditioned Ravens task types · 原文頁 6
- **100** evaluation runs per setting · 原文頁 6

依這個順序讀

1. `README.md` ↗

   GitHub · cliport/cliport · 2be5c47b5b

   身份、四階段 train/val/test 流程、重複訓練集與 SE(2) augmentation 限制。

   `L1–18 · L121–148 · L273–284 · L319–331`

2. `cliport/tasks/README.md` ↗

   GitHub · cliport/cliport · 2be5c47b5b

   10 個 goal-conditioned 原生任務家族與 seen/unseen/full/seq 標籤、Ravens 重用及修改 COM 的資產。

   `L1–58 · L60–66`

3. `cliport/tasks/put_block_in_bowl.py` ↗

   GitHub · cliport/cliport · 2be5c47b5b

   具體語言、物件數、goal tuple、5cm XY 容差、步數和顏色切分。

   L11–99

---

4. `cliport/tasks/align_rope.py` ↗

   GitHub · cliport/cliport · 2be5c47b5b

   20 節繩、四個方向描述、可反向 match matrix 與20步上限；不是20個獨立case。

   L14–104

---

5. `cliport/tasks/cameras.py` ↗

   GitHub · cliport/cliport · 2be5c47b5b

   三個480×640 RGB-D視角與只供oracle使用的俯視相機。

   L7–58

---

6. `cliport/environments/environment.py` ↗

   GitHub · cliport/cliport · 2be5c47b5b

   pose0/pose1執行、settle後計分、timeout終止、depth還原與特權info。

   L20–84 · L149–151 · L198–233 · L250–301 · L305–323

---

7. `cliport/demos.py` ↗

   GitHub · cliport/cliport · 2be5c47b5b

   偶 / 奇seed與test偏移、macro-action步記錄、只儲存總reward>0.99的示範。

   L15–89

---

8. `cliport/dataset.py` ↗

   GitHub · cliport/cliport · 2be5c47b5b

   五個pickle欄位、seed命名、heightmap/角度標籤、sequential goal選擇與多工切分。

   L24–208 · L243–263 · L395–449

---

9. `cliport/tasks/task.py` ↗
   GitHub · cliport/cliport · 2be5c47b5b

   pose與zone的真正checker、delta reward、goal推進及done語義。

   L19–54 · L165–227 · L229–270 · L316–323

---

10. `cliport/eval.py` ↗
    GitHub · cliport/cliport · 2be5c47b5b

    依示範seed重建case、累積reward平均與val最佳checkpoint挑選。

    L16–49 · L83–165 · L168–215

---

11. `cliport/cfg/eval.yaml` ↗
    GitHub · cliport/cliport · 2be5c47b5b

    預設100個val instances、一次repeat與路徑依賴。

    L10–38

---

12. `cliport/utils/utils.py` ↗
    GitHub · cliport/cliport · 2be5c47b5b

    確認Python random只隨train_run初始化；eval每case的env.seed只改區域性NumPy RNG。

    L773–780

怎麼接入我們的benchmark

可重用

重用task class與原生屬性切分、goal tuple、語言順序、episode seed、相機與pose-action欄位、具體reward/checker。

需要轉換

source綁paper edition+commit；environment綁資產 / 相機 / 物理設定；task保留家族及seen/unseen/full/seq；case以task+mode+seed+示範檔案識別並儲存五檔引用；evaluator分列delta_reward、total_reward、done及終止原因。把世界座標、公尺、xyzw、heightmap投影和特權info可見性寫入profile；同一train資料的seen/unseen別名記reuse關係。

仍需補齊

尚未閉合Google Scanned Objects修改COM後資產、所有case檔與實機採集格式。PutBlockInBowl註解要求每block放不同碗，goal也設replace=False，但reward丟棄replace並逐物件獨立匹配，不消耗target；加上只驗XY，需協調者明列原生checker限制，不能宣稱嚴格一對一裝碗或3D落碗驗證。val_best只取目錄第一個匹配results-val檔，且n_repeats共用同checkpoint / case seed，需固定檔案與replicate定義才能可比較。另有seed再現性缺口：demos.py同時以episode seed重設np.random與Python random；eval.py只在repeat開始用train_run呼叫utils.set_seed，逐case僅重設np.random及env.seed，而env.seed只建立self._random。PutBlockInBowl等任務的random.sample顏色未按case重設，因此存下seed不等於已驗證同一示範場景 / 語句；需儲存或修訂完整RNG協定。

P078 · PerAct

Perceiver-Actor: A Multi-Task Transformer for Robotic Manipulation

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

PerAct 是使用 RLBench 的方法參考，不另建18任務 / 249 variations的新任務庫。已讀replay與keypoint定義，並沿作者peract分支的reader、open_drawer condition、YARR rollout及accumulator閉合一條具體評測路徑；test可為每個task載入不同的val最佳checkpoint。

> **版本與身份**
>
> 主倉庫02fb87681c5a47be9dbf20141bedb836ee2d3ef9（2024-05-09），README明說論文DataParallel改為公開版DDP。補讀依賴固定RLBench ad991951bc53e4f3b73b803a75cf4b7d55295cf7與YARR 8d0f2e228b97efa207eeccedfc6dac9334342ba3。P077 PyBullet、P062較新RLBench與本版資料 / checker各有版本邊界；本輪只審所列區段。
>
> 論文為Shridhar、Manuelli、Fox的Perceiver-Actor: A Multi-Task Transformer for Robotic Manipulation，arXiv:2209.05451v2（2022-11-11）。README題名、作者、arXiv與peract.github.io相符；84–109明指MohitShridhar/RLBench及MohitShridhar/YARR的peract分支，不是P062的stepjam/RLBench現行快照。兩fork是執行 / 計分依賴。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	作者fork的RLBench/CoppeliaSim 4.1 / PyRep桌面操作，EndEffectorPoseViaPlanning後接Discrete gripper。policy取front/left_shoulder/right_shoulder/wrist四個128×128 RGB與世界點雲；配置不直接輸出depth/mask，loader仍讀depth產生點雲。場景界限[-0.3,-0.5,0.6,0.7,0.5,1.6]為公尺，100^3 voxel在此配置每格1cm。Franka真實實驗的teleop ZIP及Drive資料是外部附件，未取得 / 未驗證。
任務	18個task是README 232–249手選RLBench subset；249是論文v2的variations，不是task或trial數。已讀open_drawer的bottom/middle/top三variation，成功條件為指定joint相對初態位移>0.15m。task、variation_number、語句、demo初態各自存放；其餘17個checker未逐一選讀。

題數與資料	路徑為{split_root}/{task}/all_variations/episodes/episodeN，包含low_dim_obs.pkl、variation_number.pkl、variation_descriptions.pkl與camera/%d.png。24-bit depth除DEPTH_SCALE後以near+depth*(far-near)還原公尺，結合intrinsics/extrinsics產生點雲。reader即使僅啟用四視角，仍檢查全部五相機RGB/depth影格數與low_dim_obs一致。fill_replay按自然序讀demo、取第一句description；keypoint為gripper_open改變、末幀或joint_velocities在0.1容差內停止，stopped_buffer=4。action為xyz公尺+xyzw+gripper共8D；保留拼法trans_action_indicies / rot_grip_action_indicies，rotation是xyz Euler+180後5度bin。replay另含ignore_collisions、rgb/point_cloud/矩陣、task、lang_goal、1024D sentence embedding、77×512 token embedding及demo。low_dim_state是gripper_open、兩指位置及[-1,1]決策進度。末keypoint的100 reward為合成訓練標籤；增廣replay條目數不能當demo/case數。
評估方式	eval→IndependentEnvRunner→_run_eval_independent→RolloutGenerator→CustomMultiTaskRLBenchEnv→RLBench TaskEnvironment.step→Task.success→open_drawer JointCondition。demo index=eval_from_eps_number+ep，variation與初態自檔案恢復。範例checker成功時RLBench回1並terminal，PerAct乘100；reward<1歸零，IK / path / invalid-action錯誤直接失敗終止；預設25決策後timeout。SimpleAccumulator對episode累積reward取mean，稀疏0/100協定的eval_envs/return/{task}數值等於百分比成功率，但保留return名稱及scale，不泛推到有reward shaping的task。預設每task25 episodes；method seed另記。best模式每task依val CSV獨立選現存checkpoint、平手取最後，因此test不保證同一權重。YARR依weight是否dict決定test_data.csv檔名，仍需另核對demo_path實際split。

依這個順序讀

1. `README.md` ↗
   GitHub · peract/peract · 02fb87681c

   身份、作者fork、18 task清單、val/test流程與實機附件。

   L1–13 · L42–55 · L84–109 · L214–263 · L309–347 · L413–423 · L448–462

2. `conf/config.yaml` ↗
   GitHub · peract/peract · 02fb87681c

   100 demos/task、四相機、場景界限與task-uniform replay。

   L6–24

3. `conf/method/PERACT_BC.yaml` ↗
   GitHub · peract/peract · 02fb87681c

   100^3 voxel、5度rotation bin與每10原始步重取起點。

   L5–9 · L37–42 · L48–63

4. `rlbench/backend/const.py` ↗

   GitHub · MohitShridhar/RLBench · ad991951bc

   實際目錄 / pickle / PNG命名與24-bit depth scale。

   L1–29

---

5. `rlbench/utils.py` ↗

   GitHub · MohitShridhar/RLBench · ad991951bc

   自然序episode、variation/description、五相機完整性檢查與depth還原。

   L41–147 · L209–236 · L254–308

---

6. `helpers/demo_loading_utils.py` ↗

   GitHub · peract/peract · 02fb87681c

   夾爪切換、最後幀與低關節速度停止點。

   L8–42

---

7. `agents/peract_bc/launch_utils.py` ↗

   GitHub · peract/peract · 02fb87681c

   replay schema、pose標籤、合成訓練reward與示範增廣。

   L32–209 · L212–274

---

8. `helpers/utils.py` ↗

   GitHub · peract/peract · 02fb87681c

   四元數 / Euler bin、policy observation及相機矩陣。

   L43–59 · L72–82 · L322–418

---

9. `helpers/custom_rlbench_env.py` ↗

   GitHub · peract/peract · 02fb87681c

   demo reset、100倍reward及IK/path/action錯誤終止。

   L20–91 · L134–198 · L314–391

---

10. `rlbench/tasks/open_drawer.py` ↗
    GitHub · MohitShridhar/RLBench · ad991951bc

    三種drawer variation、語句與JointCondition(0.15)。

    L9–33

---

11. `rlbench/backend/conditions.py` ↗
    GitHub · MohitShridhar/RLBench · ad991951bc

    prismatic joint相對初態的絕對位移嚴格大於0.15m。

    L30–40

---

12. `rlbench/backend/task.py` ↗
    GitHub · MohitShridhar/RLBench · ad991951bc

    reward預設None、fail優先 / success AND與TTM引用。

    L118–120 · L180–187 · L287–311

---

13. `rlbench/task_environment.py` ↗
    GitHub · MohitShridhar/RLBench · ad991951bc

    action後由success給0/1 reward、從Demo恢復初態。

    L94–126 · L159–161

---

14. `eval.py` ↗
    GitHub · peract/peract · 02fb87681c

    planner與每task獨立選最佳val checkpoint。

    L14–31 · L83–105 · L124–152 · L220–272

---

15. `conf/eval.yaml` ↗
    GitHub · peract/peract · 02fb87681c

    每task25 episodes與每episode25決策是不同預算。

    L1–28

---

16. `yarr/runners/independent_env_runner.py` ↗
    GitHub · MohitShridhar/YARR · 8d0f2e228b

    建立自訂env後進入真正的runner。

    L74–126

---

17. `yarr/runners/_independent_env_runner.py` ↗
    GitHub · MohitShridhar/YARR · 8d0f2e228b

    逐task換權重、demo index範圍、accumulator寫CSV。

    L112–139 · L154–200 · L230–283

---

18. `yarr/utils/rollout_generator.py` ↗
    GitHub · MohitShridhar/YARR · 8d0f2e228b

    demo reset、deterministic action、timeout與終止。

    L17–89

---

19. `yarr/utils/stat_accumulator.py` ↗
    GitHub · MohitShridhar/YARR · 8d0f2e228b

    episode return平均；pop至少需兩個完成episode。

    L24–56 · L81–119 · L129–151

怎麼接入我們的benchmark

可重用

作者fork reader / demo reset、18-task subset、variation/description、keypoint生成、planner與具體condition、YARR return aggregation。

需要轉換

source記P078方法與P062 RLBench重用關係並儲存三個commit；case以split+task+episode+variation+Demo初態hash識別。raw sensor、policy observation、連續pose與voxel/Euler標籤分層；保留原始frame到keypoint的對映、augmentation起點與碰撞旗標。evaluator另存task→checkpoint、decision/trial budget、return scale、error/timeout。

仍需補齊

README只鎖peract分支，補pin不能證明是論文實驗版本。尚需五相機影像 / TTM / Demo資產閉合、其餘17 checker核對與實機附件版本。不能套用P062現行RLBench reader。YARR pop只在>1個完成episode時輸出，單case試讀不保證有CSV指標。

P079 · FMB

FMB: a Functional Manipulation Benchmark for Generalizable Robotic Learning

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

FMB有真實Franka資料轉RLDS與策略rollout，但環境step固定回reward=0、done=False；成功需依官方實物評測程式另行記錄。已追到combined / insert-only builder、ResNet reader與robot action，發現state/peg_id欄位不相容、負ID轉uint8、primitive過濾後episode邊界未重算等具體整合問題。

> **版本與身份**
>
> 固定rail-berkeley/fmb@d4da6ce044a9806f41e58bf7423b5a3c05289925（2024-05-28），早於論文v3（2024-09-03）；不能認定涵蓋v3所有實驗。官方procedure是以SHA256固定的網站文字快照，無與paper/commit同版的證明。combined、single、multi、insert-only TFDS builders是不同schema / subset，不能僅因均1.0.0合併；本輪選讀combined與insert-only。
>
> 固定論文為Luo、Xu等人的FMB: a Functional Manipulation Benchmark for Generalizable Robotic Learning，arXiv:2401.08553v3（2024-09-03）。PDF及README均指functional-manipulation-benchmark.github.io，README 136–140列相同作者與arXiv；繫結中的專案Code連結指rail-berkeley/fmb。此repo是控制器 / 資料builder / baseline，CAD與資料壓縮包另行發布。

領域	裝配與生產作業
環境	真實Franka Panda、兩個側面與兩個腕部RGB-D相機、抓取區、reorientation fixture及插入板。論文單物體位置隨機於20×20cm、板於35×35cm；多物體抓取區20×30cm，板固定。控制器預設10Hz；gripper切換會另等待，影片以20fps寫出，均不能用來推定原始資料有精確等間隔timestamp。形狀 / 顏色 / 長短 / 大小是物件屬性，板號或相機數不等於environment/case數。
任務	原生任務含single_object_manipulation及三種multi_object assembly；combined builder的primitive有grasp、place_on_fixture、regrasp、rotate、move_up、go_to_board、insert。論文Table 1的六種分段標籤與程式中的過渡primitive不強制一對一合併。22,550為論文統計的分段軌跡（single 15,350、multi 7,200），不等於完整任務episodes：論文另列2,700個single全流程、4,050個額外insert及每assembly150個multi全流程。本輪未下載檔案，無實際落地case計數。

題數與資料	combined builder 1.0.0讀.npy dictionary：actions(T,7)、primitive[T]、obs/{side_1,side_2,wrist_1,wrist_2及_depth,q,dq,tcp_pose,tcp_vel,tcp_force,tcp_torque,gripper_pose}，single另有object_info。RLDS steps.observation為256×256 JPEG RGB、float32 depth、joint_pos/vel(7)、eef_pose(7)、eef_vel(6)、eef_force/torque(3)、state_gripper_pose及object/shape/color/size/length；episode_metadata保留file_path、episode_task與生成語句，USE embedding為512D。depth僅astype，未提供raw depth到公尺的scale；size/length為類別字串。action是base-frame xyz增量（m）、左乘的xyz Euler增量（rad）及gripper 0=open/1=close；env裁剪前六維至±0.06m / ±0.25rad。builder只有train，ResNet reader預設train[:95%]/train[95%:]，不是物件held-out benchmark split。reward在原始最後步硬設1、discount全1，不能作量測成功標籤。
評估方式	callchain：ResNet simulate_policy→rollout→FrankaFMB.step；env固定回(obs,0,False,{})，rollout亦丟棄reward/done、可按Esc停止，只存observation/action與影片。N=100是程式呼叫引數，不是官方protocol；grasp/regrasp 60步、insert/place_on_fixture 100步、rotate 200步、long_horizon 300步，action chunk可能跨越外層上限。官方procedure另定grasp/rotate/place/regrasp各50 trials（5 seen+5 unseen物件各5次）、insert 45（9 shapes各5次）、single multi-stage 10、每multi-object assembly 10（5初態各2次）。成功依牢固抓持、fixture上斜放、rotate ±15度、底面完全插入正確孔等實物條件；multi-object需全部插入。未找到此路徑的機器自動量測或success JSON，必須保留人工 / 外部判讀地位。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **66** 原生物件 · 原文頁 4
- **5** 額外未見測試物件 · 原文頁 4
- **3** multi-object assemblies · 原文頁 8
- **22,550** primitive demonstration trajectories · 原文頁 7

依這個順序讀

1. `README.md` ↗
   GitHub · rail-berkeley/fmb · d4da6ce044

   身份、builder與checkpoint設定、force/torque座標框架更動、實物評測入口。

   `L1–16 · L30–66 · L95–140`

2. `ResNet/README.md` ↗

   GitHub · rail-berkeley/fmb · d4da6ce044

   dataset版本、primitive/object篩選、tcp_frame及action chunk選項。

   L28–46 · L49–62

---

3. `fmb_dataset_builder/fmb_dataset/fmb_dataset_dataset_builder.py` ↗

   GitHub · rail-berkeley/fmb · d4da6ce044

   實際raw keys→RLDS欄位、語言生成、terminal reward、ID dtype與train-only split。

   L36–97 · L135–280 · L285–469

---

4. `fmb_dataset_builder/fmb_single_object_insert_dataset/fmb_single_object_insert_dataset_dataset_builder.py` ↗

   GitHub · rail-berkeley/fmb · d4da6ce044

   只保留insert步卻沿用原始i計算is_first/is_last，以及其實際schema。

   L166–215 · L241–397

---

5. `ResNet/src/rlds/rlds_dataset.py` ↗

   GitHub · rail-berkeley/fmb · d4da6ce044

   95/5切分、primitive/peg filter、decoder必讀state、eef→tcp rename及chunk padding。

   L16–181 · L229–260

---

6. `robot_infra/envs/franka_fmb_env.py` ↗

   GitHub · rail-berkeley/fmb · d4da6ce044

   10Hz、7D delta action、四相機觀測、實機HTTP狀態及無成功checker。

   L36–82 · L133–149 · L197–221 · L225–270

---

7. `ResNet/src/rollout_main.py` ↗

   GitHub · rail-berkeley/fmb · d4da6ce044

   人工reset/object ID、policy縮放、rollout忽略reward/done、影片儲存及每primitive預算。

   L24–42 · L106–179 · L216–270 · L348–384

怎麼接入我們的benchmark

可重用

raw→RLDS欄位、primitive語句與object屬性、父軌跡file_path、控制器delta-action定義、官方逐skill初態 / trial / 成功準則。

需要轉換

source同時綁paper v3、repo commit與TFDS dataset名稱/1.0.0；task區分完整assembly與primitive；case保留父episode、原始frame index、board/object ID、切分後segment及protocol trial。物件泛化split需另存held-out清單，不沿用95/5切片。把raw depth scale、force/torque frame、gripper及action正規化作profile欄位；evaluator單列合成demo reward與實物成功判讀。

仍需補齊

combined及insert-only builder均無observation.state/peg_id，但ResNet decoder 137–140無條件讀state，peg filter/shape_vec又用peg_id；需版本化adapter，不能宣稱可直接串接。combined把-1 ID sentinel轉uint8後成255，schema文字卻仍說-1。insert-only過濾後仍用原始i標is_first/is_last，可能沒有first或terminal步。README說舊checkpoint force/torque在base frame、新dataset預期eef frame，不能只按同名欄位合併。尚缺深度尺度、物理資產 / 相機校正、protocol附圖座標、實際trial結果與觀察者判讀記錄。

P080 · DexArt

DexArt: Benchmarking Generalizable Dexterous Manipulation with Articulated Objects

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

DexArt已追到四個具體RL task的state / success、底層contact、物件annotation reader與paper評測入口。原生success是episode內曾達is_eval_done的比例；bucket的成功比early_done寬鬆，laptop reset又隨機抽物件，不能將eval_per_instance名稱當每個物件精確等量試驗的證據。

> **版本與身份**
>
> 固定d6ab75e1a0b81384d1ac918cbfd4d97b1f230149（2026-05-11），晚於2023v1；README的2023-11checkpoint發布也晚於論文。所讀門檻只代表此commit；無論文精確experiment lock或assets版本對照，不宣稱重現paper表格。未執行PPO、感知預訓練或SAPIEN。
>
> 固定論文為Bao、Xu、Qin、Wang的DexArt: Benchmarking Generalizable Dexterous Manipulation with Articulated Objects，arXiv:2305.05706v1 / CVPR 2023。README 1–13和171–176吻合完整題名、作者及arXiv，確認Kami-code/dexart-release為官方模擬環境 / 訓練程式；不是同名搜尋命中即視為官方。DexPoint及vendored Stable-Baselines3是重用實作。

領域	居家整理與清潔
環境	SAPIEN articulated objects與xArm6腕接Allegro手；create_env預設frame_skip=10，已讀laptop scene timestep=0.004s，即該配置每control step為0.04s。policy相機64×64，另外1000×1000的viz_only相機不算policy觀測。四task各有point-cloud裁切bound和rand_pos/rand_degree；例如laptop位置擾動為每軸[0,0.1)m、yaw±60度，不是對稱±0.1m。基底pose、物件scale、摩擦、handle與joint annotation都是case重建依賴。
任務	四個原生task labels是faucet、bucket、laptop、toilet；TRAIN_CONFIG的seen/unseen ID數分別11/7、11/8、11/6、17/11（共82個配置中的物件ID），不是82個task或實測episodes。*_half只是訓練物件子集。laptop reader讀assets/sapien/{id}/mobility.urdf與mobility_v2.json的joint欄位，結合annotation/laptop_scale.json、laptop_joint_annotation.json中left/middle及robot-relative position。外部asset包未下載，僅核對程式期待的欄位，未聲稱這些JSON內容已讀。

題數與資料	BaseRLEnv.step依序控制、update_cached_state、更新robot imagination、讀觀測、算reward與done。action為[-1,1]的robot.dof向量：前六維還原Cartesian速度，Jacobian IK得arm速度並裁至±π，再積分成joint target；後段對映到hand joint位置limits，不能當全向量都是joint velocity。obs含state/oracle_state（所讀laptop為joint qpos+palm線/角速度+位置+step/horizon）、instance_1-point_cloud(512,3)、instance_1-seg_gt(512,4)及imagination_robot。點雲由camera轉robot座標後裁切，少點時重複第一點，空雲補零；四mask順序handle/instance_body/hand/arm。pretrain生成器把512個感知點及96個robot imagination點組成(608,7)樣本，儲存{task}/{train|val|test}_{id}.npy，再np.load合併；seen同時產生train與val，unseen產生test。其內容是random-action / random-joint-state感知樣本，不是成功操作軌跡或固定時間同步action標籤。
評估方式	入口 examples/evaluate_policy.py→create_env→BaseRLEnv.step→task.update_cached_state→sim contact checker。contact以scene contact的sum(abs(impulse))>=1e-2認定。laptop：progress=1-|q-middle|/(|left-middle|-init_open_rad)，需>0.95且palm距handle<=0.2m、至少兩指及palm接觸；toilet相似progress>0.95，但距離<=0.1m、兩指接觸即可。faucet需|hinge qpos|>1.5rad，距離<=0.2m及兩指+palm接觸。bucket eval需progress>0.7且base-link升高>0.25m；early_done則>0.9、state=3及>0.3m，且is_done實際只看250步horizon。四個task的horizon均250；faucet、laptop、toilet在各自成功條件成立時提早結束。主迴圈只要任一步is_eval_done為真就鎖定episode成功，即使bucket之後落下仍記成功。最終印mean(success_list)，shaped reward另累加但不作該成功率。通用SB3 evaluate_policy回mean/std reward，不能替代此入口。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **4** 操作tasks · 原文頁 3
- **82** articulated objects · 表1四類相加 · 原文頁 3
- **32** unseen test objects · 表1分量相加 · 原文頁 3

依這個順序讀

1. `README.md` ↗

   GitHub · Kami-code/dexart-release · d6ab75e1a0

   精確作者 / arXiv、外部assets、paper評測入口與DexPoint重用。

   `L1–19 · L35–48 · L110–118 · L165–182`

2. `dexart/env/task_setting.py` ↗

   GitHub · Kami-code/dexart-release · d6ab75e1a0

   四task的seen/unseen/half物件ID、相機、點雲與初態隨機化。

   L8–13 · L20–89 · L116–152

---

3. `dexart/env/create_env.py` ↗

   GitHub · Kami-code/dexart-release · d6ab75e1a0

   xArm6+Allegro、task dispatch、frame_skip、pc_seg/noise與robot imagination。

   L13–62

---

4. `dexart/env/sim_env/laptop_env.py` ↗

   GitHub · Kami-code/dexart-release · d6ab75e1a0

   實際mobility/annotation讀取、hinge辨識、scale、0.004s物理步與隨機object reset。

   L13–141

---

5. `dexart/env/rl_env/base.py` ↗

   GitHub · Kami-code/dexart-release · d6ab75e1a0

   控制與觀測callchain、camera→robot點雲、seg_gt、history及TimeLimit標記。

   L99–139 · L153–176 · L198–229 · L465–482 · L484–544 · L565–595 · L598–646

---

6. `dexart/env/rl_env/pc_processing.py` ↗

   GitHub · Kami-code/dexart-release · d6ab75e1a0

   過濾 / 抽樣 / padding / noise與xyz+四類mask的真實順序。

   L21–73

---

7. `dexart/env/sim_env/base.py` ↗

   GitHub · Kami-code/dexart-release · d6ab75e1a0

   env seed範圍與接觸impulse門檻，而非只用幾何接近。

   L67–72 · L110–132

---

8. `dexart/env/rl_env/laptop_env.py` ↗
   GitHub · Kami-code/dexart-release · d6ab75e1a0

   progress公式、兩指加palm接觸、成功 / reward / annotation及250步上限。

   L38–148

---

9. `dexart/env/rl_env/faucet_env.py` ↗
   GitHub · Kami-code/dexart-release · d6ab75e1a0

   絕對joint角度>1.5rad且接觸，與shaped reward分離。

   L37–141

---

10. `dexart/env/rl_env/bucket_env.py` ↗
    GitHub · Kami-code/dexart-release · d6ab75e1a0

    eval與early_done門檻不同、lift高度、reward及僅horizon終止。

    L54–100 · L123–174 · L194–199

---

11. `dexart/env/rl_env/toilet_env.py` ↗
    GitHub · Kami-code/dexart-release · d6ab75e1a0

    95% annotation progress與兩指接觸、0.1m近距離判定。

    L56–144 · L164–169

---

12. `examples/evaluate_policy.py` ↗
    GitHub · Kami-code/dexart-release · d6ab75e1a0

    總trial迴圈、deterministic PPO、episode任一步成功及最終mean。

    L14–81

---

13. `examples/pretrain/generate_dataset.py` ↗
    GitHub · Kami-code/dexart-release · d6ab75e1a0

    random-state點雲樣本與.npy merge reader；不是專家action示範。

    L10–45 · L49–103

---

14. `stable_baselines3/common/evaluation.py` ↗

    GitHub · Kami-code/dexart-release · d6ab75e1a0

    通用mean_reward evaluator與paper的success入口不同。

    L11–35 · L72–131

怎麼接入我們的benchmark

可重用

四task checker、contact門檻、native object ID/split、物件annotation loader、robot/point-cloud觀測profile與episode-any-success聚合。

需要轉換

task記動作目標；environment綁SAPIEN、robot、資產/annotation版本；case記task+object ID+split+初態+seed，不以渲染幀或pretrain樣本數當case。evaluator分開is_eval_done、early_done、reward、done、any_step_success及horizon；保留每task不同的角度 / progress / 接觸與高度門檻。點雲、seg_gt、imagination及可選previous觀測需標示來源與policy可見性。

仍需補齊

外部assets的URDF、scale、joint left/middle及relative-position JSON尚未閉合或驗證，須固定asset版本 / hash。eval_per_instance預設10、README示例100，總數為該值×instance_list長度；但已讀laptop reset用random.randint抽ID，沒有逐ID均衡控制或per-ID結果儲存，需記實際抽樣頻數。程式stdout只有總成功率，缺trial明細與失敗 / 落下後狀態。BaseRLEnv在horizon處因task.is_done已為True而寫TimeLimit.truncated=False，需協調者分離超時與成功，不能把done當成功。

P081 · ARNOLD

ARNOLD: A Benchmark for Language-Grounded Task Learning With Continuous States in Realistic 3D Scenes

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

ARNOLD已追到NPZ重建、兩階段策略、具體joint / pickup / orientation / water checker及score聚合。水量實作是cup world-AABB內粒子比例，成功還需連續穩定；normalized訓練state不可直接當checker原生target。checkpoint選擇有list.argmax靜態錯誤，且GT輔助結果必須獨立儲存。

> **版本與身份**
>
> 固定arnold-benchmark/arnold@40ad6861f45b676bf538b7a0e180d81c8d454823（2024-04-01），晚於論文v2，README另含CVPR 2024 Challenge公告；不能混用Challenge與ICCV paper的case/split。P077/P078方法在此的軸、單位、keypoint及checker均已改寫，需標為重用方法的另一實驗版本。未執行Isaac Sim、policy、Cython或上游shell。
>
> 固定論文為Gong、Huang等人的ARNOLD: A Benchmark for Language-Grounded Task Learning With Continuous States in Realistic 3D Scenes，arXiv:2304.04321v2（2023-09-11）。PDF第7頁直接指arnold-benchmark/arnold，README作者、題名與arXiv相符。此repo含benchmark與改寫的PerAct/6D-CLIPort基線；它們是P077/P078方法的重用，不是原倉庫資料或同一評測協定。

領域	居家整理與清潔、通用物件與機動作業
環境	Isaac Sim / USD、Franka與五相機front/base/left/wrist_bottom/wrist（配置128×128）。load_task將stage設為y-up、1單位=0.01m、gravity=(0,-1,0)且magnitude=981；physics設120Hz。場景 / 機器人 / 物件 / material USD依NPZ info重建，路徑改寫假設原始路徑含VRKitchen2.0或指定materials字串。README的20 scenes / 40 objects / 10k demos是來源宣告，未以本地asset / NPZ列舉驗證。
任務	8個原生task為pickup_object、reorient_object、open/close_drawer、open/close_cabinet、pour_water、transfer_water。訓練樣本分act1抓取 / act2操作，sample_weights=0.2/0.8；一般四keyframes（初態、預抓、抓住、終態），water六幀並混合frame3位置與frame4姿態作第二動作。二次policy決策不等於3或6個planner stages。7個split需保留train/val/test/novel_object/novel_scene/novel_state/any_state；預設eval只跑後五者。

題數與資料	每case是.npz，gt為keyframe物件序列，info包含scene_parameters、robot_parameters、objects_parameters及robot_shift。gt使用instruction、robot_base、position_rotation_world、gripper_joint_positions、images；每camera有rgb、semanticSegmentation、depthLinear、camera內參 / pose。Reader把position/finger由cm除100成m、wxyz轉xyzw，以機器人前方0.5m為中心；PerAct點雲維持y-up，CLIPort heightmap換軸成z-up。depthLinear先clip到[0,10]，Cython反投影乘100到cm、世界變換後再除100；不能把raw depth直接當cm。target_points註解寫[6]，實際concat xyz+xyzw是7D（rot=None才3D）。parse_state從檔名取標籤：pickup目標/40、reorient角度/180、pour為(100-p)/100、transfer為p/100，其他直接取浮點；runtime CheckerParameters.target_state另取info中的cm / 度 / 比例 / 百分點原生單位。尚未讀任何示範NPZ內容，欄位證據來自reader。
評估方式	eval→load_task→OpenDrawer或PourWater/TransferWater.step→120Hz physics callback→具體Checker.start_checking→BaseChecker。joint把位置按lower/upper化為0–100%，必要時翻轉target，要求比例差<0.1且每physics-step百分點差<0.05；pickup要求相對初始y高度誤差<5cm且每step y位移<0.1原生單位；orientation要求物件y軸相對世界y的角度誤差<20度，穩定性檢查同樣是y位移，不是角速度。water用所有粒子落在cupShape世界AABB的比例，誤差<10百分點、受約束杯偏離直立<30度，transfer另需兩杯外spill<10%；pour只看原杯殘餘量。各條件需連續success_steps>steps_per_second*2，失敗清零；末planner stage完成後最多再step 300次讀success，callback已從reset啟動，並未在末階段重新開始2秒計時。horizon=2400是planner主迴圈tick預算，額外gripper等待及success period另計。eval寫stats[fname]=1/0/-1、score=correct/total（0–1），-1包含timeout及捕捉到的例外並留在分母；console另乘100。0gt/1gt/2gt與use_gt旗標必須區分。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **20** 3D scenes · 原文頁 4
- **40** objects · 原文頁 4
- **8** task types · 原文頁 5
- **10,080** 全部split的valid demonstrations · 原文頁 5
- **773** IID test instances · 原文頁 5

依這個順序讀

1. `README.md` ↗

   GitHub · arnold-benchmark/arnold · 40ad6861f4

   精確身份、8-task/7-split宣告、外部資料及尚待發布的demonstration generator。

   `L1–22 · L32–60`

2. `configs/default.yaml` ↗

   GitHub · arnold-benchmark/arnold · 40ad6861f4

   GT介入、五個eval splits、相機、兩階段策略與planner預算。

   L23–40 · L75–108

---

3. `dataset.py` ↗

   GitHub · arnold-benchmark/arnold · 40ad6861f4

   npz gt、四 / 六關鍵幀、cm/wxyz轉換、act1/act2與normalized state。

   L19–37 · L40–76 · L78–206 · L228–279 · L282–325

---

4. `utils/env.py` ↗

   GitHub · arnold-benchmark/arnold · 40ad6861f4

   五視角的固定順序。

   L1–7

---

5. `utils/transforms.py` ↗

   GitHub · arnold-benchmark/arnold · 40ad6861f4

   camera內參 / pose與點雲座標轉換。

   L145–165

---

6. `utils/compute_points.pyx` ↗

   GitHub · arnold-benchmark/arnold · 40ad6861f4

   depth乘100進cm camera frame；未編譯此Cython程式。

   L7–28

---

7. `tasks/__init__.py` ↗

   GitHub · arnold-benchmark/arnold · 40ad6861f4

   npz info重建USD資產、物理與fluid欄位、checker dispatch及y-up/cm stage。

   L39–109 · L111–210

---

8. `environment/parameters.py` ↗
   GitHub · arnold-benchmark/arnold · 40ad6861f4

   Object/Scene/Robot與CheckerParameters的實際schema。

   L16–44 · L55–87

---

9. `tasks/base_task.py` ↗
   GitHub · arnold-benchmark/arnold · 40ad6861f4

   120Hz、RMPFlow與Franka / sensor setup。

   L122–179 · L332–374

---

10. `tasks/open_drawer.py` ↗
    GitHub · arnold-benchmark/arnold · 40ad6861f4

    兩次policy step、三planner stages、2400 tick timeout與末階段checker讀取。

    L104–227

---

11. `tasks/pour_water.py` ↗
    GitHub · arnold-benchmark/arnold · 40ad6861f4

    pour檢查原容器殘餘水量；六stage動作完成後才讀success。

    L66–94 · L123–125 · L145–194 · L265–295

---

12. `tasks/transfer_water.py` ↗
    GitHub · arnold-benchmark/arnold · 40ad6861f4

    transfer檢查接收杯、原杯upright及spill；不是pour同一目標。

    L41–100

---

13. `tasks/checkers/base_checker.py` ↗
    GitHub · arnold-benchmark/arnold · 40ad6861f4

    physics callback與連續超過2秒保持條件，失敗即清零。

    L14–39 · L44–93

---

14. `tasks/checkers/joint_checker.py` ↗
    GitHub · arnold-benchmark/arnold · 40ad6861f4

    關節範圍比例、方向翻轉、±0.1與每step變化門檻。

    L36–84 · L87–153

15. `tasks/checkers/pickup_checker.py` ↗
    GitHub · arnold-benchmark/arnold · 40ad6861f4

    y高度目標、5cm容差與每physics-step位移。

    L7–74

16. `tasks/checkers/orient_checker.py` ↗
    GitHub · arnold-benchmark/arnold · 40ad6861f4

    物件y軸相對世界y的角度、20度容差；穩定度仍取y位置。

    L8–69

17. `tasks/checkers/water_checker.py` ↗
    GitHub · arnold-benchmark/arnold · 40ad6861f4

    AABB粒子比例、±10百分點、upright<30度與spill<10%。

    L13–30 · L55–82 · L100–112 · L126–207

18. `ckpt_selection.py` ↗
    GitHub · arnold-benchmark/arnold · 40ad6861f4

    val成功率及跨task平均選模型；list.argmax靜態缺陷。

    L84–110 · L133–214

19. `eval.py` ↗
    GitHub · arnold-benchmark/arnold · 40ad6861f4

    GT模式、NPZ case讀取、-1錯誤、分母與逐task/split輸出JSON。

    L29–49 · L82–111 · L113–229

20. `eval_pipeline.sh` ↗

    GitHub · arnold-benchmark/arnold · 40ad6861f4

    官方串接checkpoint選擇與0gt/1gt分開評測。

    L1–34

怎麼接入我們的benchmark

可重用

NPZ欄位 / USD物理設定、語言與native continuous target、四類checker、兩階段policy / 多stage planner、task/split/case成功記錄。

需要轉換

source綁v2+commit；case保留NPZ檔名、object/scene/state split、raw info和asset引用。建立cm↔m、wxyz↔xyzw、y-up↔z-up的明確轉換，normalized learning goal與runtime target分欄。evaluator儲存每步穩定性單位、hold ticks、planner耗時、GT介入、checkpoint及-1原因，水量保留particle-AABB proxy名稱。

仍需補齊

ckpt_selection.py 204產生Python list、205直接.argmax()，在此靜態路徑不能完成best checkpoint挑選，需協調者處理且保留修補版本；本輪未執行確認。缺USD/material/fluid資產及實際NPZ manifest、其餘具體task stage覆寫的逐項核對。water AABB不是精確杯內幾何或真實體積，須保留限制。GT log名稱對任意use_gt組合未全區分；bare except把不同錯誤壓成-1且已有score會跳過整個split，需追加設定hash / 錯誤分類。README尚列demonstration generator為TODO。

P082 · RoboVerse

RoboVerse: Towards a Unified Platform, Dataset and Benchmark for Scalable and Generalizable Robot Learning

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

RoboVerse官方repo已確認，但2026固定commit的MetaSim、trajectory reader與generalization level均有版本變化。已閉合maniskill.pick_cube config-port的初態→PositionShiftChecker→IL SuccessOnce聚合，另讀Zarr產生 / 載入鏈。發現NaN可令整批checker成功、L2/L3與paper定義錯位，以及trial尾批 / normalizer切分問題。

> **版本與身份**
>
> 固定RoboVerseOrg/RoboVerse@5f3ec0185d2d3bcb59d53b0bd1f5b0f8a6f2ce14（2026-09-08），對應paper 2504.18904v1（2025-04-26）的官方延續repo，而非paper原始實驗pin。README如今把MetaSim與RoboVerse分成同tag發行的兩套package；trajectory v2/v3、native/config ports與generalization protocol各自記版本。舊usage的RandomizationCfg不可直接作現行DRConfig schema；本輪只選讀所列task / data / evaluator。
>
> 固定paper為Geng等人的RoboVerse: Towards a Unified Platform, Dataset and Benchmark for Scalable and Generalizable Robot Learning，arXiv:2504.18904v1（2025-04-26）。PDF指roboverseorg.github.io，README 134–141題名、作者與arXiv一致，確認RoboVerseOrg/RoboVerse為官方平臺。本文不等於較早同名RoboVerse環境，也不把整合的RLBench、ManiSkill、LIBERO、ARNOLD等資料算成新獨立來源。

領域	居家整理與清潔、衣物與洗護、裝配與生產作業、通用物件與機動作業
環境	平臺把task/robot/scene內容放roboverse_pack，模擬核心在packages/metasim/metasim。已讀範例是Franka提起4cm紅cube，ScenarioCfg與runtime backend共同決定物理 / 相機 / 控制時間；不能賦予全平臺單一FPS。eval建立camera0的256×256 RGB/depth並依task選pose。此maniskill.pick_cube是跨simulator config port，該基類檔案明分它與*_native/SAPIEN3 official-demo port；未獨立驗證任何跨引擎parity。
任務	pick_cube alias與maniskill.pick_cube共用一個task，目標cube比reset初態沿z移動>=0.1m，最大250原生步；不要求抓持或放置。traj_filepath指roboverse_data/trajs/maniskill/pick_cube/v2/franka_v2.pkl.gz，下載helper在constructor被呼叫，本輪未執行。全平臺registry條目、object variants、來源task、demo與benchmark trial必須分開；本輪未聲稱現行registry總數等於paper task數。

題數與資料	legacy v2內容為{robot_name:[{init_state,actions,states?},...]}，init/state是entity→pos/rot/dof_pos；actions支援dof_pos_target/dof_vel_target/dof_effort_target。v3轉換只是把state分objects/robots、action包上robot名稱；缺states仍可回初態+actions，但不能做state-anchored replay。現行get_traj按內容辨識、拒v1，遇roboverse.episode會要求load_episode另一API，不能只改副檔名。TensorState儲存objects/robots/cameras；root/body state為[pos,quat,lin_vel,ang_vel]13維，joint資料與body_names需繫結，部分backend欄位可None。另一路data2zarr讀demo_NNNN/metadata.json及各camera.mp4（head_camera可退到rgb.mp4），用joint_qpos、joint_qpos_target或robot_root_state/robot_ee_state(_target)生成state/action；EE為robot-local xyz+wxyz+兩指共9D，delta_ee另有相對quat。輸出data/{camera,state,action}與meta/episode_ends，保留downsample/padding/action-space設定。RobotImageDataset從Zarr抽episode內sequence、相機值除255。未取得外部traj、MP4或Zarr，case數應依實際episode_ends / 檔案manifest，而非metadata要求處理的num_episodes。
評估方式	DefaultRunner.evaluate→get_task_class→ManiskillBaseTask→get_traj(v2→v3)→env.reset/checker.reset→BaseTaskEnv.step→handler.set_dof_targets/simulate/get_states→_terminated→PositionShiftChecker.check→util.get_pos。正常checker以reset差值z>=0.1m且總位移<=100m回bool，base reward仍為0，timeout另回。runner每個outer step執行joint action一次、EE action兩次，僅讀最後一次success；SuccessOnce是outer steps上的OR，SuccessEnd是末步，TimeOut只累積不停止個別env；全batch曾成功或max_step耗盡才退出。final_stats為SuccessOnce成功數/總完成數，並儲存demo索引、DR level/mode/seed。選取demo靠task_id_range_low/high及max_demo，並沒有自動套用paper90/10索引。現行DRManager確為L1 scene+material、L2加light、L3加camera，與paper / 舊usage檔案的L2 camera、L3 light/reflection不能同名比較。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **90** navigation Matterport3D scenes · 原文頁 8
- **276** 已遷移操作task categories · 原文頁 7, 8
- **510,500** 操作trajectories · 原文510.5K · 原文頁 8
- **6** 主IL實驗代表tasks · 原文頁 10

依這個順序讀

1. `README.md` ↗

   GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

   身份、MetaSim新目錄與多來源重用，不把整個平臺清單當paper實驗集。

   `L8–13 · L23–55 · L65–101 · L131–143`

2. `docs/source/dataset_benchmark/benchmark/overview.md` ↗
   GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

   benchmark範圍與randomization wrapper宣告。

   L1–12

---

3. `docs/source/dataset_benchmark/benchmark/usage.md` ↗
   GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

   仍使用舊RandomizationCfg / L2相機、L3光照的檔案版本。

   L3–55

---

4. `roboverse_pack/tasks/maniskill/pick_cube.py` ↗
   GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

   具體4cm cube、Franka、v2軌跡、250步及z位移checker。

   L12–37

---

5. `roboverse_pack/tasks/maniskill/maniskill_base.py` ↗
   GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

   config port與native port不同；初態reader、checker reset及terminated掛接。

   L12–39 · L53–106

---

6. `packages/metasim/metasim/types.py` ↗
   GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

   action/state/camera資料結構、預設可空欄位及camera wxyz慣例。

   L29–87 · L133–198 · L237–273 · L336–347

---

7. `packages/metasim/metasim/utils/demo_util/loader.py` ↗
   GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

   pickle/gzip/JSON/YAML實際讀取，不執行其中內容。

   L9–43

---

8. `packages/metasim/metasim/utils/demo_util/demo_util.py` ↗
   GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

   依內容辨識v2、明拒v1與roboverse.episode的獨立reader要求。

   L17–118

---

9. `packages/metasim/metasim/utils/demo_util/demo_util_v2.py` ↗
   GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

   robot→demo[]、init_state/actions/states及flat entity namespace。

   L15–108

---

10. `packages/metasim/metasim/utils/demo_util/demo_util_v3.py` ↗
    GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

    v3只改in-memory state/action namespace，並非新磁碟trajectory格式。

    L1–67

---

11. `roboverse_learn/il/data2zarr_dp.py` ↗
    GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

    metadata+MP4→Zarr、joint/EE/delta模式及episode_ends。

    L21–77 · L147–265 · L273–318 · L329–347

---

12. `roboverse_learn/il/datasets/robot_image_dataset.py` ↗
    GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

    真正Zarr reader、episode mask、normalizer範圍、相機鍵與postprocess。

    L33–174

---

13. `packages/metasim/metasim/task/base.py` ↗
    GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

    action→handler→terminated/timeout的原生step contract。

    L143–171 · L225–330

---

14. `packages/metasim/metasim/example/example_pack/tasks/checkers/util.py` ↗
    GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

    handler tensor root_state的前三維位置讀取。

    L8–40

---

15. `packages/metasim/metasim/example/example_pack/tasks/checkers/checkers.py` ↗
    GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

    PositionShiftChecker真正門檻與NaN回傳全True的例外路徑。

    L189–230

---

16. `packages/metasim/metasim/randomization/dr_manager.py` ↗
    GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

    現行L1環境/材質、L2光照、L3相機的具體dispatch。

    L1–41 · L78–90 · L155–203 · L432–474 · L510–516

---

17. `roboverse_learn/il/utils/eval_args.py` ↗
    GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

    eval的demo範圍、250決策及level/seed預設。

    L9–49

---

18. `roboverse_learn/il/runners/default_runner.py` ↗
    GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

    真正評測的init-state selection、DR、SuccessOnce/End與分母。

    L18–30 · L280–309 · L346–546

---

19. `roboverse_learn/il/runners/default_eval_runner.py` ↗
    GitHub · RoboVerseOrg/RoboVerse · 5f3ec0185d

    checkpoint/EMA、obs/action chunk配置與policy輸出。

    L17–45 · L71–95

怎麼接入我們的benchmark

可重用

官方native task ID / aliases、ScenarioCfg、typed state/action、v2 parser和v3轉換、metadata→Zarr鏈、具體checker及SuccessOnce/End結果。

需要轉換

source保留paper v1與2026 code snapshot；task標config_port或native_port並連回ManiSkill等上游。case儲存robot、task、原demo index、asset/初態hash、backend、控制步長及DR實際factor，不只存level數字。明分v2磁碟trajectory、v3記憶體state、roboverse.episode與IL Zarr四種介面；保留joint名稱 / 單位、wxyz、camera座標及EE local/delta語義。

仍需補齊

PositionShiftChecker 219–221只要cur_pos任何元素NaN就回整批True，沿此task鏈會被SuccessOnce計成功，需先修補並標版本。尾批demo_end_idx只截到num_demos、不截到要求的low+max_demos，SuccessOnce分母固定num_envs，需核對超額或不滿批處理。RobotImageDataset normalizer.fit吃全buffer而非train mask；get_validation_dataset取downsample後train_mask的補集，可能把未選訓練episodes納入val，需固定真正paper split。尚缺2025實驗commit/資產/90-10 case清單及舊L2/L3到現行factor對照；v1資料已明示不支援。

P083 · RoboDojo

RoboDojo: A Unified Sim-and-Real Benchmark for Comprehensive Evaluation of Generalist Robot Manipulation Policies

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

RoboDojo與XPolicyLab分別提供sim任務 / 計分與policy / data adapter。已閉合stack_bowls、push_T的checker、RewardManager、EvalEnv及summary，並讀HDF5→RGB→LeRobot reader。success_rate與partial score不同；unstable/abandoned layout不在相同分母，summary還有embodiment鍵遺失與layout排序問題。

> **版本與身份**
>
> RoboDojo固定cb2a37d58dbbeb2777b0c2b30e97ecb8ab91095c（2026-10-08），不同於舊inventory 726e9aabfaa642203722eb126f5eaf0f37f3e1ad；XPolicyLab固定de9b445e4e46388542c412e406c73d359a5802fd（2026-10-10）。RoboDojo README記9月16–17日get_obs單幀與RGB修正、HF資料更新及swap_T assets修正，要求XPolicyLab bb9a0b5f5136a74503b679af830bfd0a3a837d5c或後續；未獨立驗證本兩pin的完整runtime相容性。7月paper、9月資料修訂、10月程式與8月XPolicyLab paper須分開建版本，不把政策數當benchmark task數。未啟動server、sim、policy或遠端評測。
>
> 固定RoboDojo論文為Chen等人的完整sim-and-real benchmark，arXiv:2607.04434v3（2026-07-08）。PDF第1頁直接連兩repo，主README題名/arXiv吻合。XPolicyLab現行README另引用2608.09892（2026年8月的獨立工具論文）；本P083只審其RoboDojo adapter角色，不把那篇的政策數或新功能倒算成7月RoboDojo benchmark。

領域	居家整理與清潔、衣物與洗護、裝配與生產作業、通用物件與機動作業
環境	Isaac Sim / Isaac Lab配置化場景，TaskEnv由sim/scene/robot/camera/task YAML建立，可有target雙臂與support arm。選讀stack_bowls從8個bowl asset ID中選3個同類物件，xlim[-0.45,0.45]、ylim[-0.25,0.07]相對Table；評測改讀已存Eval_Layout。主README此版為sim eval-only，真實ARX X5/Piper/Piper X的18 tasks使用RoboDojo-RealEval另行部署；本輪未取得真實trial影片、三人評分或隱藏驗證layout。

任務	summary DIMENSIONS確列42個base tasks：Generalization12、Precision8、Long-Horizon8、Memory6、Open8；12個*_random是對應base task的泛化設定，不另算42以外新canonical任務。stack_bowls完整成功需三碗軸向<45度、最低碗<7度、相鄰中心XY距離<=0.04m且高度差>=0.005m、target robot回原位（每座標差<=0.15m、旋轉<=20度）。此stack checker不驗接觸且未設最大垂直間隔。process score為兩碗階段15、三碗階段100，要求gripper開度>=0.8；transition每action最多推進一階，100仍須完整成功gate。push_T以quat差<7度、XY距離<0.007m及robot回原位成功；is_lift相對初態>0.01m的query允許次數0，觸發即失敗；不是IoU評測。
題數與資料	case來源為Assets/Eval_Layout/RoboDojo/{config_name}/{eval_seed}/{task}_N.json。SeedManager按N排序後重新以0..len-1編ordinal，該ordinal才是程式layout_id；未取得外部layout JSON，不能用檔名suffix直接替代。runtime obs含data_format_version='v1.0'、instruction、additional_info.frequency、vision/state/action及env_idx；RGB為HWC，float depth保持距離，approximate_depth=clip(raw*1000,0,65535).uint16。實際ObsManager寫extrinsic_matrix，與XPolicyLab README宣稱runtime extrinsics_matrix不同。XPolicyLab load(RoboDojo,v1.0)遞迴讀HDF5、解析instruction/subtasks JSON，colors經decode_image_bit；pose為xyz+qwqxqyqz。legacy JPEG及有XPL-RGB1 COM marker的新JPEG可共存，decoder只對有marker者做BGR→RGB。LeRobot v2.1 converter取state/action下left_arm_joint_states、left_ee_joint_states、right_arm_joint_states、right_ee_joint_states依序串接；三相機映到cam_high/left_wrist/right_wrist，缺相機補黑，各arm補到共同最大維度。paper的3500 trajectories=34訓練tasks各100+100 DLC輔助（Open無task-specific訓練），1859602 frames及25Hz是paper統計，未下載重新點算。
評估方式	policy deploy→update_obs/get_action→EvalEnv.take_action→robot control→RewardManager.step→Func_Parser→is_episode_end。check按列表順序移除已完成stage，巢狀list交替OR/AND，query計事件次數；完整reward只回0/1。stack_bowls上限800個take_action，push_T600，非physics ticks；capture frequency另由dt與collect_freq決定。EvalEnv完整成功記episode score=1，失敗若有process score則/100；_result.json含details{record_index:{layout_id,success,score}}、success_rate（0–1）、score（0–100平均）、eval_time（已計數episodes，不是秒）。無效、unstable及部分PhysX broken layouts被排除 / 補樣，abandoned另存resume manifest；要求50不能當50次嘗試。summary採每task/policy/embodiment/seed最新timestamp結果；獨立task前50筆，Generalization合base25+random25，三seed0/1/2共126個完整cell。先平均每維tasks，再五維等權平均，seed標準差為population std；未完成cell留空，overview可顯示已完成部分平均。真實paper協定每task10 trials、三位評分者分別打成功與substeps後平均，不能以sim RewardManager替代。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **42** simulation tasks · 原文頁 7
- **18** real tasks · 原文頁 7, 8
- **2,100** simulation eval episodes · 原文頁 7

- **180** real eval trials / policy · 18×10 · 原文頁 9

依這個順序讀

1. `README.md` ↗
   GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

   paper身份、September資料 / RGB修正、sim eval-only與XPolicyLab責任界線。

   L5–7 · L13–37 · L54–107

---

2. `task/RoboDojo/task_registry.py` ↗
   GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

   按task名載入class與YAML，不將檔案數當canonical task數。

   L1–21

---

3. `task/RoboDojo/config/_task.yml` ↗
   GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

   共同設定、teleop/datagen、每task trial覆寫及support robot。

   L1–145

---

4. `task/RoboDojo/config/stack_bowls.yml` ↗
   GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

   三個同類bowl、asset候選及桌面初態取值範圍。

   L1–17

---

5. `task/RoboDojo/tasks/stack_bowls.py` ↗
   GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

   800步、三碗完整成功與15/100 transition process score。

   L5–99

---

6. `task/RoboDojo/tasks/push_T.py` ↗
   GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

   600步、7度 / 7mm位置對齊及禁止lift。

   L5–37

---

7. `env/environment/task_env.py` ↗
   GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

   runtime robot/scene/camera/physics及控制呼叫。

   L10–100

---

8. `env/seed_manager/seed_manager.py` ↗
   GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

   Eval_Layout JSON排序、layout ordinal、resume排除及實際檔案reader。

   L27–100

---

9. `env/observation_manager/obs_manager.py` ↗
   GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

   感測同步、frequency、depth/approximate_depth與真實runtime欄位。

   L16–66 · L81–220

---

10. `env/reward_manager/reward_manager.py` ↗
    GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

    函式descriptor、巢狀AND/OR、query事件計數、transition及滿分成功gate。

    L28–69 · L78–161 · L236–297 · L315–405 · L527–664 · L792–803 · L829–831

---

11. `env/reward_manager/func_parser.py` ↗
    GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

    實際object pose幾何、gripper與robot回原位條件。

    L61–74 · L996–1019 · L1126–1157 · L1523–1536 · L1631–1645 · L1672–1741 · L1978–2001

---

12. `src/eval_client/main.py` ↗
    GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

    合併configs、eval budget、seed排程、PhysX / unstable中斷及補樣。

    L254–346 · L347–378 · L378–442

---

13. `src/eval_client/eval_env.py` ↗

    GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

    policy client、控制步計數、任務結束、partial score與_result.json分母。

    L43–194 · L208–285 · L337–389 · L410–465 · L638–652 · L771–867

---

14. `scripts/internal/summarize_result.py` ↗

    GitHub · RoboDojo-Benchmark/RoboDojo · cb2a37d58d

    42-task taxonomy、25+25 / 50、三seed、五維等權平均及缺漏cell語義。

    L1–95 · L96–116 · L247–322 · L339–412 · L427–482 · L511–551

---

15. `README.md` ↗

    GitHub · XPolicyLab/XPolicyLab · de9b445e4e

    獨立XPolicyLab paper、trajectory v1.0、pose、RGB byte版本與LeRobot profile。

    L7–28 · L323–429 · L448–489

---

16. `policy/demo_policy/deploy.py` ↗

    GitHub · XPolicyLab/XPolicyLab · de9b445e4e

    reset/update_obs/get_action到TASK_ENV.take_action的單例與batch契約。

    L1–42

---

17. `utils/data_loader.py` ↗

    GitHub · XPolicyLab/XPolicyLab · de9b445e4e

    converter真正reader：RoboDojo/xspark v1.0 HDF5遞迴、JSON語句與RGB decoder。

    L1–58

---

18. `utils/process_data.py` ↗

    GitHub · XPolicyLab/XPolicyLab · de9b445e4e

    JPEG COM標記XPL-RGB1、legacy / standard byte的RGB解碼分支。

    L291–305 · L345–396 · L423–526

---

19. `scripts/transform_lerobot_v21_format.py` ↗

    GitHub · XPolicyLab/XPolicyLab · de9b445e4e

    bimanual state/action欄位、padding / 缺相機、原幀逐一轉存及max_fps。

    `L25–51 · L154–159 · L200–274 · L376–425 · L484–604 · L639–702`

怎麼接入我們的benchmark

可重用

42-task capability mapping、base/random關係、layout replay與seed排程、具體幾何 / 事件 / 階段checker、逐trial success/score及HDF5 / JPEG reader。

需要轉換

source同時鎖RoboDojo與XPolicyLab commit；case鍵包含paper/code版、task、base/random、embodiment、config、eval_seed、layout ordinal和實際檔案hash，record_index另存。evaluator區分success、process score、末階段gate、unstable/abandoned與實際分母；按五維聚合而非所有task混平均。資料profile保留v1.0容器、JPEG marker、pose wxyz、觀測 / 動作對齊、相機缺失與padding mask、原頻率及LeRobot版本。

仍需補齊

尚缺固定layout/robot/object資產包、原始HDF5樣本、真實評分資料與hidden-layout驗證。summary load_entries其實按details字典record key排序而非payload.layout_id；main又將(policy,embodiment,seed)寫入data[policy][task][seed]，多embodiment同名結果可能互相覆蓋。latest timestamp還會跨不同checkpoint/action_type選最後結果，須額外綁run配置。LeRobot轉換合併多頻率來源時以max_fps建立dataset，convert_one逐原幀寫入無resampling，需儲存原時間軸或分流。geometry-only stack條件、runtime extrinsic鍵差異、score gate與unstable排除均需協調者在schema / protocol層明示。

P084 · KinDER

KinDER: A Physical Reasoning Benchmark for Robot Learning and Planning

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

KinDER將程式化環境與baselines分兩repo；已讀ClutteredRetrieval2D / Motion2D的具體幾何成功、5D動作與vector schema，再追到demo儲存 / IL reader及MPC評測CSV。非成功demo可被手動儲存卻未被reader篩除；MPC steps漏算成功那一步，execution_time也不是環境執行時間。

> **版本與身份**
>
> 主repo固定5b2dbac482142b879b48449b3fa2af63f641aed3（2026-09-11，pyproject 0.2.5），baselines固定f763946435c9ed8ab0f89e645f1014b07c1a1e8a（2026-09-15），均晚於paper v2。env ID的-v0不表示reset/碰撞實作從未變更；registry還會因backend匯入失敗而跳過整組環境，本機可用ID數不能作全庫case/env數。paper的25/13與現行README新增專案分開保留；本輪未安裝、run CI、重播、訓練或執行planner。
>
> 固定paper為Huang、Li、Saxena等人的KinDER: A Physical Reasoning Benchmark for Robot Learning and Planning，arXiv:2604.25788v2（2026-05-04）。PDF首頁指prpl-group.com/kinder-site；已讀該專案頁快照中精確title、arXiv、kindergarden主repo及kinder-baselines companion連結，避免只靠作者頁上的其他研究連結。主repo提供KinDERGarden/Gym，companion提供KinDERBench方法，不是兩份獨立benchmark。

領域	居家整理與清潔、包裝、倉儲與物流、通用物件與機動作業
環境	paper v2宣告25個程式化環境 / 13 baselines，跨Kinematic2D、Dynamic2D、Kinematic3D、Dynamic3D；現行0.2.5另列kinematic3d_v2/Vega等內容，須依paper版本選子集。已讀兩個Kinematic2D環境的world=[0,2.5]²，原點左下、x向右、y向上；使用2D原生長度座標與theta弧度，不把render DPI當物理尺度。CRV robot是圓形底座、伸縮臂與吸盤；kinematic轉移沒有速度積分。觀測排除固定牆面等initial_constant_state，planner可透過專用state API取得；allow_state_access是方法可見資訊條件。
任務	ClutteredRetrieval2D需把target_block完整放入target_region；o1/o10/o25代表阻擋物數，registry儲存同一class的variant_ids，並非固定case數。最初robot必須在最大free-space連通分量，目標不得已與region重疊；這是初態有效性檢查，不等於已證明全域性可解。Motion2D-p0-v0是MPC預設task，成功只要求robot的(x,y)參考位置在target rectangle內；與完整block包含判定不同。每步reward均-1，包含成功那一步，不能當正向成功獎勵。

題數與資料	ConstantObjectKinDEREnv由exemplar與type_features產生可逆vectorize/devectorize；ClutteredRetrieval-o1文件具體39維：robot9維，target_block/target_region/obstruction各10維（x,y,theta,static,color_rgb,z_order,width,height）。名稱及feature順序需保留，不能按任意字典排序重新編號。action=[dx,dy,dtheta,darm,vac]：位移±0.05、角度±π/16、臂長增量±0.1、vac∈[0,1]；吸附物件按前一步gripper相對變換搬移，碰撞則整個候選state不採用。demo寫{sanitized_env_id}/{seed}/{timestamp}.p（dill），有env_id/timestamp/seed/observations/actions/rewards/terminated/truncated，T actions通常配T+1 observations；timestamp是儲存時間，不是逐frame時間。GUI render_fps=20不能證明每action間隔固定。IL reader依數字seed目錄排序、每目錄取glob第一個.p，zip(observations[:-1],actions)生成observation.state/action/episode_index/frame_index；預設無images，render_images=True才以同seed和actions重播產生影像，本輪未執行。
評估方式	ClutteredRetrieval chain為vector wrapper.step→ObjectCentricKinematic2DRobotEnv.step→_get_reward_and_done→is_inside，逐一檢查target rectangle頂點是否在goal rectangle；base回truncated=False、無原生maximum horizon。MPC另一條完整路徑：run_experiment依Motion2D-p0配置建立eval env及allow_state_access=True的獨立sim env→TrajOptAgent/PredictiveSampling→KinderTrajOptProblem.get_transition→Motion2D.contains_point，實際eval success直接取env.step的terminated。預設每cfg seed50 episodes、max_eval_steps=200；planning horizon=100、num_rollouts=10、replan_interval=3是規劃預算，不是trial數。results.csv記success、steps、planning_time、execution_time、reward及正常episode的eval_episode；例外直接插入失敗 / 零數值列。evaluate_stats讀config.env.env_id、seed與CSV success，先取每job成功率，再對收集到的job rates平均與sample std(ddof=1)。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **25** procedural task-environments · 原文頁 4, 5
- **8** 主實驗環境 · 原文頁 6
- **50** 每環境每seed eval episodes · 原文頁 7

依這個順序讀

1. `README.md` ↗

   GitHub · Princeton-Robot-Planning-and-Learning/kindergarden · 5b2dbac482

   官方主環境、object-centric/vector API、backend版本與外部assets / demos。

   `L7–16 · L26–57 · L79–99 · L124–147 · L149–194`

2. README.md ↗

   GitHub · Princeton-Robot-Planning-and-Learning/kinder-baselines · f763946435

   companion baselines與model/skill套件角色。

   L1–31

---

3. pyproject.toml ↗

   GitHub · Princeton-Robot-Planning-and-Learning/kindergarden · 5b2dbac482

   package 0.2.5、Pymunk/MuJoCo與未鎖精確版次的幾何依賴。

   L5–43

---

4. src/kinder/__init__.py ↗

   GitHub · Princeton-Robot-Planning-and-Learning/kindergarden · 5b2dbac482

   按backend註冊、o1/o10/o25 variants及metadata，不從本機註冊結果推全庫數量。

   L34–96 · L119–136 · L560–592 · L647–654

---

5. src/kinder/core.py ↗

   GitHub · Princeton-Robot-Planning-and-Learning/kindergarden · 5b2dbac482

   vector/object對映、state-access許可權與planner內部transition。

   L124–199 · L215–267 · L300–318 · L344–350 · L376–407

---

6. src/kinder/envs/kinematic2d/clutteredretrieval2d.py ↗

   GitHub · Princeton-Robot-Planning-and-Learning/kindergarden · 5b2dbac482

   原生2D座標、物件初態、碰撞取樣、完整包含checker與固定feature順序。

   L36–86 · L137–248 · L306–438

---

7. src/kinder/envs/kinematic2d/base_env.py ↗

   GitHub · Princeton-Robot-Planning-and-Learning/kindergarden · 5b2dbac482

   5D action、上一時刻吸附物件轉換、碰撞回退、reward/termination與無預設horizon。

   L99–199 · L206–249

---

8. `src/kinder/envs/kinematic2d/utils.py` ↗

   GitHub · Princeton-Robot-Planning-and-Learning/kindergarden · 5b2dbac482

   真正包含判定：inner rectangle的每個頂點皆在outer rectangle內。

   L422–437

---

9. `src/kinder/envs/kinematic2d/motion2d.py` ↗

   GitHub · Princeton-Robot-Planning-and-Learning/kindergarden · 5b2dbac482

   MPC預設Motion2D的實際goal：robot參考位置落入region。

   L34–55 · L117–145 · L261–297

---

10. `docs/envs/ClutteredRetrieval2D.md` ↗

    GitHub · Princeton-Robot-Planning-and-Learning/kindergarden · 5b2dbac482

    task/variant及action欄位說明；25-step random-action展示不是評測預算。

    L7–43

---

11. `docs/envs/variants/ClutteredRetrieval2D/ClutteredRetrieval2D-o1.md` ↗

    GitHub · Princeton-Robot-Planning-and-Learning/kindergarden · 5b2dbac482

    o1版本的39維feature索引。

    L24–66

---

12. `scripts/collect_demos.py` ↗

    GitHub · Princeton-Robot-Planning-and-Learning/kindergarden · 5b2dbac482

    dill .p欄位、T+1觀測、手動儲存非成功軌跡與20fps GUI。

    L1–10 · L95–119 · L152–195 · L233–260 · L348–372

---

13. `kinder-imitation-learning/src/kinder_imitation_learning/dataset.py` ↗

    GitHub · Princeton-Robot-Planning-and-Learning/kinder-baselines · f763946435

    實際.p reader、首檔選擇、obs/action對齊、可選重播影像與丟棄flags。

    L18–174

---

14. `kinder-trajopt/experiments/conf/config.yaml` ↗
    GitHub · Princeton-Robot-Planning-and-Learning/kinder-baselines · f763946435

    50評測episodes、100步planning horizon、10候選rollouts。

    L17–28

15. `kinder-trajopt/experiments/conf/env/motion2d-p0.yaml` ↗
    GitHub · Princeton-Robot-Planning-and-Learning/kinder-baselines · f763946435

    Motion2D-p0-v0、200執行步、每3步replan及不用world-model checkpoint。

    L1–5

16. `kinder-trajopt/src/kinder_trajopt/agent.py` ↗
    GitHub · Princeton-Robot-Planning-and-Learning/kinder-baselines · f763946435

    PredictiveSampling/MPC設定、觀測到action與可選world-model。

    L26–80

17. `kinder-trajopt/src/kinder_trajopt/trajopt_problem.py` ↗
    GitHub · Princeton-Robot-Planning-and-Learning/kinder-baselines · f763946435

    simulated candidate成本為到termination前的負累積reward；可選world-model仍用env reward。

    L18–44 · L68–108

18. `kinder-trajopt/experiments/run_experiment.py` ↗
    GitHub · Princeton-Robot-Planning-and-Learning/kinder-baselines · f763946435

    實際eval loop、seed、success CSV、exception fallback及時間 / 步數指標範圍。

    L33–107 · L110–146

19. `kinder-trajopt/scripts/evaluate_stats.py` ↗
    GitHub · Princeton-Robot-Planning-and-Learning/kinder-baselines · f763946435

    每job success平均與job間ddof=1標準差；不是獨立重評審。

    L17–67

怎麼接入我們的benchmark

可重用

環境class/variant registry、程式化reset、object/feature對映、action bounds、幾何checker、.p軌跡schema及具體MPC success CSV。

需要轉換

source鎖paper v2與兩repo commit，environment再綁backend/package版本與完整config；task家族、variant物件數、reset seed/case和method trial分開。case儲存初態vector+feature manifest及父demo檔案hash，保留T/T+1關係。evaluator儲存terminated/truncated、execution步數、planning rollout預算、state-access / world-model設定；rendered images標為重播衍生資料，連回原seed與code版本。

仍需補齊

collector手動G鍵可儲存terminated=False，但IL loader不檢查terminated/truncated，並任選同seed第一個.p、未驗證各episode env_id一致；需明確挑檔及成功標籤。重播影像只依seed、未比對stored observations，環境修訂後不能宣稱畫面仍對齊。MPC steps在done前break而少算成功步；execution_time只包agent.update，不含env.step；抽到的實際episode seed未寫CSV，例外列又缺eval_episode。summarizer不依seed去重，重複job可冒充更多獨立seed。需補paper環境 / baseline清單、外部3D資產及prpl_utils/relational_structs/tomsgeoms2d精確版本；未驗證其餘dynamic tasks或真實mobile-manipulator實驗。

P085 · SoftGym

SoftGym: Benchmarking Deep Reinforcement Learning for Deformable Object Manipulation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

已核讀 SoftGym 的環境 / 狀態介面、10 個論文任務對應的具體計分及 picker 動作。它提供 FleX 柔性物與流體互動環境；normalized_performance 是任務專屬連續量，不能當共同成功率。此 commit 的 ClothFoldCrumpled reward 與 performance 存在公式差異。

> **版本與身份**
>
> 固定 2022-01-14 commit；README 含 2021 年新增 depth rendering，不能視為原論文提交時完整快照。核心核讀限所列 Python 段落，未執行 FleX、基線或載入 pickle。 已補固定SoftAgent db2fbb5d的CEM / DrQ / 初態生成核心段落；未執行baseline，也未把這個後續版本當成論文完整再現。
>
> README 的完整題名、四位作者及 CoRL 2020 引用對應 arXiv:2011.07215；不是論文引用的 CURL、DrQ 或 rlpyt 基線倉庫。

領域	衣物與洗護
環境	NVIDIA FleX / PyFlex，布料、繩索、流體以粒子及 shape states 表示。預設以抽象 picker 或杯子直接控制；程式含 sawyer / franka 分支，但本次未驗證 Robotics 版 PyFlex，不能據此宣稱完整手臂環境可執行。布料位置為原生 xyz、y 為高度、面積投影到 xz；camera 設定使用弧度值。
任務	README 列 6 Medium＋4 Hard 任務。SOFTGYM_ENVS 有 12 個註冊名稱：ClothFlattenPPP / ClothFoldPPP 是同 class 的控制變體；env_arg_dict 另外有未註冊專案，不能全部算任務。RopeConfiguration 的 S/O/M/C/U 為 goal 變體。num_variations=1000 是預設生成預算，未讀取實際初態資產，不能當已驗證 case 數。

題數與資料	初態 pickle 儲存 (cached_configs, cached_init_states)，以 config_id 關聯；Flex 狀態有 particle_pos(N×4，xyz＋inverse mass)、particle_vel(N×3)、shape_pos(N×14)、phase、camera_params。液體子類改用 glass_x / glass_y / glass_rotation、glass_states、poured_glass_states、glass_params 等欄位，不能硬套同一狀態 schema。布料 config 含 ClothPos / ClothSize / ClothStiff / camera_params / flip_mesh。觀測可為 cam_rgb、key_point 或補零粒子 point_cloud；RopeConfiguration RGB 與 goal RGB 沿通道拼成 6 通道。未指定 config_id 時，訓練從前 80% 初態抽取，eval_flag 從後 20% 抽取；1000 配置因而對應 800/200 索引，非 rollout 次數。 補核SoftAgent：generate_cached_states設定num_variations=1000，但main覆寫env_names為僅ClothFold；DrQ預設num_variations=1，README要求另設1000才對應原論文條件。CEM輸出initial_states / action_trajs / configs，不能把100萬train steps或候選rollouts計為題數。
評估方式	FlexEnv.step 在 action_repeat 次物理步後計算 reward / info，到 horizon 才 done，沒有通用成功門檻。ClothFlatten：100×100 xz 佔格面積；ClothFold：−平均對應粒子距離−1.2×固定半側偏移；ClothDrop：−平均粒子至 target_pos 距離；ClothFoldDrop 沿用 ClothFold。ClothFoldCrumpled 的 reward 以 flat_pos 與 norm(mean(...,axis=1)) 算固定項，info 卻以 init_pos 與 mean(norm(...)) 計算，兩者不能互換。RopeFlatten：−|端點距離−繩長|，以 −繩長 與 0 正規化；RopeConfiguration 預設對下取樣點做 Hungarian 最小配對距離。PassWater：−10×杯外粒子比例−|terminal_x−glass_x|；PourWater：目標杯內且控制杯外的粒子比例；PourWaterAmount：−|int(N×target_amount)−目標杯有效粒子數|/N。多數 info 用初態與上界正規化、未裁切；PourWaterAmount 延用父類 reward_max=1，與其負誤差理論上界 0 不同。補核SoftAgent實際baseline：CEM取得完整env state，在副本環境set_state後逐candidate累加reward作成本；是可查詢真實模擬動力學的oracle規劃條件。預算由timestep_per_decision / max_iters / plan_horizon決定。DrQ使用sample=False推論，報每episode回報的平均，以及info的episode×time平均與末幀平均；這些不等同任務成功率。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **10** Medium+Hard tasks · 原文頁 3, 4
- **6** 有廣泛baseline的Medium tasks · 原文頁 3
- **200** 每task評測variations · 原文頁 7

依這個順序讀

1. `README.md` ↗

   GitHub · Xingyu-Lin/softgym · bb383f64cd

   確認論文身分、Medium / Hard 任務與 SoftAgent 關係。

   `L1–70`

2. `softgym/registered_env.py` ↗
   GitHub · Xingyu-Lin/softgym · bb383f64cd

   區分引數字典、真正註冊名稱、PPP 別名與各自 horizon / action_repeat。

   L14–196

---

3. `softgym/envs/flex_env.py` ↗
   GitHub · Xingyu-Lin/softgym · bb383f64cd

   核對 pickle 狀態對、80/20 索引分割、Gym step 與影像翻轉。

   L17–118 · L153–197 · L217–230

---

4. `softgym/envs/cloth_env.py` ↗
   GitHub · Xingyu-Lin/softgym · bb383f64cd

   核對 ClothSize / ClothStiff、粒子與四角觀測、camera 及 scene 建立。

   L10–166

---

5. `softgym/action_space/action_space.py` ↗
   GitHub · Xingyu-Lin/softgym · bb383f64cd

   讀取 picker 增量、抓取門檻與 PPP 絕對位置及內部步數。

   L22–60 · L117–179 · L185–224

---

6. `softgym/envs/cloth_flatten.py` ↗
   GitHub · Xingyu-Lin/softgym · bb383f64cd

   面積網格與相對初態的展布計分。

   L10–33 · L110–159 · L176–202

---

7. `softgym/envs/cloth_fold.py` ↗
   GitHub · Xingyu-Lin/softgym · bb383f64cd

   粒子映象配對、固定半側位移與 1.2 權重。

   L85–169

---

8. `softgym/envs/cloth_drop.py` ↗
   GitHub · Xingyu-Lin/softgym · bb383f64cd

   落布目標粒子位置的平均距離與正規化。

   L147–188

---

9. `softgym/envs/cloth_fold_crumpled.py` ↗
   GitHub · Xingyu-Lin/softgym · bb383f64cd

   核對 hard 變體覆寫後 reward / info 的不同基準及聚合。

   L1–14 · L77–139

---

10. `softgym/envs/cloth_fold_drop.py` ↗
    GitHub · Xingyu-Lin/softgym · bb383f64cd

    空中初態與沿用 ClothFoldEnv evaluator 的關係。

    L1–18 · L91–150

---

11. `softgym/envs/rope_flatten.py` ↗
    GitHub · Xingyu-Lin/softgym · bb383f64cd

    端點距離、繩長及 reward_min 正規化。

    L47–99

---

12. `softgym/envs/rope_configuration.py` ↗
    GitHub · Xingyu-Lin/softgym · bb383f64cd

    字形 goal、六通道觀測與預設 Hungarian 配對誤差。

    L14–51 · L160–238

---

13. `softgym/envs/pass_water.py` ↗
    GitHub · Xingyu-Lin/softgym · bb383f64cd

    杯子狀態、軸向包圍盒內水量、溢水懲罰及位移。

    L13–41 · L183–216 · L365–399 · L553–576

---

14. `softgym/envs/pour_water.py` ↗
    GitHub · Xingyu-Lin/softgym · bb383f64cd

    目標杯獨佔粒子比例、狀態列位與 reward_max。

    L53–62 · L161–199 · L377–411 · L602–623

---

15. `softgym/envs/pour_water_amount.py` ↗
    GitHub · Xingyu-Lin/softgym · bb383f64cd

    目標水量量化、負誤差與繼承正規化分母。

    L12–65 · L148–190

---

16. `README.md` ↗
    GitHub · Xingyu-Lin/softagent · db2fbb5dc3

    補核SoftGym官方基線庫、依賴與預設variation數。

    L1–62

---

17. `experiments/generate_cached_states.py` ↗
    GitHub · Xingyu-Lin/softagent · db2fbb5dc3

    確認生成1000個初態但main只保留ClothFold；不是一次生成全部任務。

    L36–53

---

18. `experiments/run_cem.py` ↗
    GitHub · Xingyu-Lin/softagent · db2fbb5dc3

    核對任務horizon、規劃預算、真實軌跡與info統計。

    L29–54 · L70–124 · L130–151

---

19. `cem/cem.py` ↗
    GitHub · Xingyu-Lin/softagent · db2fbb5dc3

    追CEM取完整state、規劃並恢復環境的oracle資訊許可權。

    L35–59 · L62–81 · L98–116

---

20. `cem/parallel_worker.py` ↗

    GitHub · Xingyu-Lin/softagent · db2fbb5dc3

    確認真正在副本模擬器重設state、累加reward並取負成本。

    L8–45

---

21. `experiments/run_drq.py` ↗

    GitHub · Xingyu-Lin/softagent · db2fbb5dc3

    核對reward scaling、預設1個variation、train step與episode數分離。

    L9–25 · L40–83

---

22. `drq/train.py` ↗

    GitHub · Xingyu-Lin/softagent · db2fbb5dc3

    確認deterministic policy inference與原生reward/info mean/final分母。

    L44–67 · L124–173

怎麼接入我們的benchmark

可重用

任務 class、原生 task 名稱、具體 metric、可重設的 config/state、camera 與 action_mode 設定。

需要轉換

source→固定 commit；environment→FleX 場景與物理設定；task→論文目標並保留註冊別名；case→config_id＋狀態雜湊＋split；evaluator→各 class 公式。保留 raw reward、performance、normalized_performance 三欄及 oracle/RGB 許可權。picker 每支為 [dx,dy,dz,pick]，位移範圍 ±0.01、pick>0.5；PPP 為 [x,y,z,pick]、內部步長 0.01，最多 300 步，不把 horizon 當秒或影格。

仍需補齊

初態 / rope goal 資產與生成 seed 的清單；SoftAgent其餘演算法及paper checkpoint / 跨seed聚合的完整閉合；ClothFoldCrumpled 與 PourWaterAmount 的 evaluator 差異決策；PyFlex 執行及分母為零的驗證。

P086 · DeformableRavens

Learning to Rearrange Deformable Cables, Fabrics, and Bags with Goal-Conditioned Transporter Networks

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

已核讀模擬主倉庫與實體 cable 實驗補充倉庫。12 個新增柔性物任務共用 Task.reward 分支，但 cloth coverage、袋口凸包、袋子搬運與真機 mask IoU 是不同指標；bag-items 的 task.done 只要求正分，不能直接當論文完整成功。

> **版本與身份**
>
> 兩倉庫均固定 2023-06-11 commit；模擬 README 的 metric 概述仍只寫 pose/zone，實際新增分支更多。原生狀態 / 示範及 PyBullet、Franka 控制均未執行。
>
> 模擬 README 明示 ICRA 2021 完整題名及作者、繼承 google-research/ravens，並直接連結 gctn_physical；後者 README 反向指向模擬倉庫。論文 arXiv:2012.03385v4 含後加真機章節，不能把 2023 真機程式視為 2020 初稿內容。

領域	衣物與洗護、包裝、倉儲與物流
環境	模擬為 PyBullet UR5 桌面與三臺 RGB-D camera，z 軸向上；柔性 cloth/bag 需 deformable world，environment 註解要求至少 480 Hz，CLI 預設卻是 240，必須保留實驗命令設定。真機另為 Franka Panda＋手部 Azure Kinect、foam 工作面及校正轉換。
任務	新增 5 cable、3 cloth、4 bag，共 12；全 registry 另含原 Ravens 任務與 insertion-goal。cloth-flat 等程式名稱對應論文 fabric-*；bag-items-easy/hard 對應 bag-items-1/2。cable-ring-notarget 只是無可見標線，load.py 未將它列為 goal-image conditioned 任務。bag-items 以開啟、插入、搬運三 stage 及各 stage primitive 引數組成。
題數與資料	Dataset 將 color/depth/action/info 存成各目錄相同的 {episode:06d}-{length}.pkl；RGB uint8 為 T×3×480×640×3，depth float32 為 T×3×480×640。最後一筆另存 last_color/last_depth/last_info，不在 action 長度內；goal 預設取同回合最後狀態，也可抽未來時間。action 有 camera_config、primitive、params.pose0/pose1；info 儲存 object_id→(position,rotation,dimensions) 及 extras。真機 trial_info 的 img_dict/eval_metrics 應比 act_dict/gctn_dict 多一筆，舊 trial 有缺尾；depth 原始毫米、mask 160×320，需保留 crop 與相機外參。人類示範取像不是 robot rollout。

評估方式	模擬 reward 回傳當步 delta，extras.total_rewards 保留當前值。cable-target 檢查每珠到任一目標 XY 距離 <3.5×radius、全數合格才 done；ring 面積除 πr² 達0.75，bag-alone-open 達0.70。cloth-flat 以目標交集/目標面積達0.85，另記 IoU；cloth-cover 要 cube 在 segmentation 不可見且距四角中心≤0.25。bag-items 在 stage3 以物體入 zone 比例與袋口珠入 zone 比例各佔0.5，done 只要求 total_rewards>0；訓練 main.py 另過濾不完整示範，測試 load.py 僅排除 t=0 或 exit_gracefully，不能沿用示範過濾作 test success。bag-color-goal 以目標物可見畫素位於目標袋口凸包的比例≥0.95，先要求可見袋口珠比例>0.33；不是完整3D containment。load.py 每2000 iteration 評測一次，共10 snapshots，各20個有效回合，seed 從10000開始，保留重抽計數與 final_info；論文第5頁對3訓練runs的60個指標先平均再取10 snapshots最大值，bag-color-goal僅1 run。真機 evaluate_masks 算交集/聯集，另有交集/min(mask面積)；論文成功為10動作內 IoU>0.25，程式只存連續值、README 使用手動退出，尚無完整自動成功彙總。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **12** deformable tasks · 原文頁 4, 5
- **12,000** scripted成功demo · 12×1,000 · 原文頁 5
- **20** 每checkpoint每run eval episodes · 原文頁 5

依這個順序讀

1. `README.md` ↗

   GitHub · DanielTakeshi/deformable-ravens · 73982748bd

   核對論文、Ravens 衍生關係、資料與真機補充來源。

   L1–18 · L51–138 · L147–163

2. `Tasks.md` ↗

   GitHub · DanielTakeshi/deformable-ravens · 73982748bd

   確認該檔案主要記錄前代 Transporter 任務，不把舊 cable 算成新套件。

   L1–12 · L72–91

3. `ravens/tasks/__init__.py` ↗

   GitHub · DanielTakeshi/deformable-ravens · 73982748bd

   分開 12 新增柔性物名稱與繼承 registry。

   L1–55

4. `ravens/dataset.py` ↗

   GitHub · DanielTakeshi/deformable-ravens · 73982748bd

   核對 episode/time 索引、三視角 RGB-D、動作及 last_* goal。

   L68–226

---

5. `ravens/environment.py` ↗

   GitHub · DanielTakeshi/deformable-ravens · 73982748bd

   讀實際 UR5 場景、空觀測初始化、終止失敗與 task.done 的分離。

   L20–76 · L135–180 · L247–325

---

6. `ravens/tasks/defs_cables.py` ↗

   GitHub · DanielTakeshi/deformable-ravens · 73982748bd

   確認 cable 目標 / ring 子類、珠粒引數、goal 和 0.75 門檻。

   L396–408 · L449–481 · L555–576 · L600–632 · L637–677 · L721–731

---

7. `ravens/tasks/defs_cloth.py` ↗

   GitHub · DanielTakeshi/deformable-ravens · 73982748bd

   讀 pixel IoU / goal coverage、遮擋 checker 與具體 cloth 任務。

   L190–235 · L313–316 · L354–391 · L433–483

---

8. `ravens/tasks/defs_bags.py` ↗

   GitHub · DanielTakeshi/deformable-ravens · 73982748bd

   讀袋子 task、stage、0.70 面積門檻及可見袋口凸包內物體比例。

   L44–84 · L251–258 · L402–428 · L476–520 · L660–705 · L899–949 · L1098–1192

---

9. `ravens/tasks/task.py` ↗

   GitHub · DanielTakeshi/deformable-ravens · 73982748bd

   追到底層 reward 與所有新增 metric 的 done 條件。

   L726–750 · L845–1106 · L1108–1164

---

10. `main.py` ↗

    GitHub · DanielTakeshi/deformable-ravens · 73982748bd

    區分成功 demo 過濾、1000 生成預算與多次訓練。

    L47–81 · L163–194 · L234–274

---

11. `load.py` ↗

    GitHub · DanielTakeshi/deformable-ravens · 73982748bd

    核對具體測試 goal、L2/SSIM、10 snapshots、20 accepted episodes 與 seed 起點。

    L17–79 · L157–212 · L224–244 · L249–265 · L282–290 · L339–376

---

12. `README.md` ↗

    GitHub · DanielTakeshi/gctn_physical · ac002ece13

    確認真機參考實作的機器相依與手動退出慣例。

    L1–75

---

13. `get_demo_data.py` ↗

    GitHub · DanielTakeshi/gctn_physical · ac002ece13

    核對人類擺放後取像資料；不將取像當機器人 action。

    L66–103

---

14. `main.py` ↗

    GitHub · DanielTakeshi/gctn_physical · ac002ece13

    核對真機 trial_info、毫米 depth、逐步 metric 與預設 10 動作。

    L104–192 · L376–399

---

15. `daniel_utils.py` ↗

    GitHub · DanielTakeshi/gctn_physical · ac002ece13

    具體 160×320 binary mask IoU 與另兩個 pixel 指標。

    L562–601

---

16. `inspect_results.py` ↗

    GitHub · DanielTakeshi/gctn_physical · ac002ece13

    驗證歷史 rollout 缺值及重新計算 IoU 的 reader。

    L43–66 · L100–123

怎麼接入我們的benchmark

可重用

新增 task subclasses、metric 分支、RGB-D / goal 配對、seed 與 snapshot 的結果 pickle，以及真機 mask evaluator。

需要轉換

source 分兩個 commit；environment 分 UR5 模擬與 Panda 真機；task 儲存 paper_name↔code_name 與 Ravens 繼承；case 綁 seed / goal episode / 初態；evaluator 分 delta、raw score、task.done、termination_reason 及 paper-success。t=0 為取像而非操作，所以 max_steps=21/11/3 等不能直接作動作數；有效 cable 通常20、cloth-flat10、cloth-cover2次，bag依子類8或9次。

仍需補齊

資料 / goal 資產清單與每次重抽 seed；論文 bag-items 完整成功的結果彙總對接；10-snapshot 選擇與獨立測試分割；真機10-goal清單、手動停止紀錄、完整校正和缺尾 trial 處理。

P087 · GarmentLab

GarmentLab: A Unified Simulation and Benchmark for Garment Manipulation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

已核讀 Isaac Sim 場景、Fold / Hang / Bimanual 範例、點雲資料管線及 RL fold 的具體 evaluator。公開程式可作來源與部分任務參考，但所讀路徑未實現論文整套20任務及持續5秒成功驗收；多處資料鍵、split 與計分接線尚未閉合。

> **版本與身份**
>
> 固定 2025-03-02 commit，晚於2024論文；READMEs與論文宣稱不代表此公開版本已實現所有協定。本次未啟動 SimulationApp、未下載 USD/模型，亦未將 template 或檔案數當核讀完整性。
>
> README 直接連結 arXiv:2411.01200、官方 GarmentLab 頁面與同名倉庫，BibTeX 題名及作者對應 NeurIPS 2024 論文。LearningBaseline/unigarmentmanip 是本倉庫中的基線實作，不另外算新 benchmark。

領域	居家整理與清潔、衣物與洗護、個人照護
環境	Isaac Sim 4.0.0 / PhysX；BaseEnv 匯入 USD 房間與地面、啟用 GPU dynamics / CCD；GarmentConfig 儲存 USD、pos、ori、scale、stretch/bend/shear stiffness、friction 和 collision offsets。FoldEnv 使用 Franka、頂視 Recording_Camera 的 depth / point-cloud / segmentation；BimanualEnv 配兩支 Franka。原生 Euler / quaternion 與 USD scale 混用，不能直接假定所有輸入角度或資產尺寸相同。
任務	README 宣稱20任務、5互動群、11衣物類別、20場景及9000+資產，均為不同單位且非本次驗證的可執行 case 數。本輪追查 Fold、Hang、雙臂展布及 RL fold 子路徑；demo 是固定資產 / 抓點序列。RL fold/config 實際 task_name 為 hang，須由協調者核對任務名稱與實驗配置，不能僅依資料夾分類。
題數與資料	collector 把 pcd_points / mesh_points 寫入 {garment}/p_{index}.npz、另存 rgb_{index}.png；loader 還要求 keypoints_visible_mask、pcd_keypoints_id、visible_mesh_indices，需補前處理來源。loader 回傳兩份點雲與 correspondence 索引，交替產生同衣物跨變形及跨衣物配對，不是 robot episode。get_deformation_paths 先按衣物目錄數字排序再切 split；config.train_ratio=1 會把所有衣物給 train、val 為空，不能套用論文 split。BaseEnv 的 .npy record/replay 是 callback 框架，base callback 為 pass，未提供統一有效軌跡 schema。

評估方式	HangEnv.get_reward 讀 garment_mesh.get_world_pose() 的 z>門檻（預設0.3，demo傳0.5），未檢查掛架接觸或5秒穩定。FoldEnv 與 FoldDemo 沒有 fold success checker。BimanualEnv 以 trial/reference coverage>0.75，但 evaluator 會停止 / 重設衣物姿態且面積 min/span 使用xy、pos2d卻使用xz，必須標為原生疑點。RL fold 的 eval_policy 平均30次 SimEnv.step(...,True) 布林值；SimEnv 計算抓點到指定粒子的誤差，兩個 reward_action>0 才成功，誤差恰為0.1經非線性分支後仍為正。雖計算0.8×reward_action＋0.2×reward_result，非eval實際回傳 reward_action，eval也未用結果形狀誤差。FoldTask.calculate_metrics 是 Cartpole 範本，不是主 fold evaluator。點雲 simple_val 以歸一化特徵 argmax 找 correspondence，報平均歐氏距離與 distance<threshold 比例；val_score.py 卻讀 points/keypoints_id、取 train 的0.8子集，而且呼叫 cal_distance_accuracy 時少了必填 distance_threshold。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **20** scene資產 · 原文頁 2
- **20** tasks · 原文頁 6
- **5** 物理互動groups · 原文頁 6
- **11** garment categories · 原文頁 2, 17

依這個順序讀

1. `README.md` ↗

   GitHub · GarmentLab/GarmentLab · 6ee0620fdd

   識別論文、20任務宣稱、Isaac Sim 4.0.0 與外部資產。

   `L1–49 · L51–65 · L82–118 · L120–128`

2. `Env/Config/GarmentConfig.py` ↗

   GitHub · GarmentLab/GarmentLab · 6ee0620fdd

   USD、位姿、scale、彈簧 / 碰撞材料引數。

   `L1–35`

3. `Env/env/BaseEnv.py` ↗

   GitHub · GarmentLab/GarmentLab · 6ee0620fdd

   場景匯入、GPU 物理、record/replay callback 與無成功條件的 step。

   `L37–133`

4. demo/FoldDemo.py ↗
   GitHub · GarmentLab/GarmentLab · 6ee0620fdd

   固定衣物 / 抓點的示範流程，不是完整測試 case manifest。

   L1–40

---

5. Env/env/FoldEnv.py ↗
   GitHub · GarmentLab/GarmentLab · 6ee0620fdd

   確認場景與相機實作，以及沒有 fold success checker。

   L1–87

---

6. demo/HangDemo.py ↗
   GitHub · GarmentLab/GarmentLab · 6ee0620fdd

   實際呼叫 get_reward(pick_threshold=0.5)。

   L8–35

---

7. Env/env/HangEnv.py ↗
   GitHub · GarmentLab/GarmentLab · 6ee0620fdd

   高度判斷的具體成功函式。

   L29–59

---

8. Env/env/BimanualEnv.py ↗
   GitHub · GarmentLab/GarmentLab · 6ee0620fdd

   狀態改寫的 coverage ratio 與面積座標軸混用。

   L29–134

---

9. LearningBaseline/unigarmentmanip/collect/collect_cd/collect_front_open_deformation.py ↗
   GitHub · GarmentLab/GarmentLab · 6ee0620fdd

   原始 npz 與 RGB 寫入鍵值、garment/frame 命名。

   L229–303 · L312–365

---

10. `LearningBaseline/unigarmentmanip/train/dataloader/dataloader.py` ↗
    GitHub · GarmentLab/GarmentLab · 6ee0620fdd

    點雲 correspondence 欄位、跨變形 / 跨物件配對與補樣。

    L15–146

---

11. `LearningBaseline/unigarmentmanip/train/dataloader/utils.py` ↗
    GitHub · GarmentLab/GarmentLab · 6ee0620fdd

    以衣物目錄做 split 與配對，不把 pair 數當衣物數。

    L5–40 · L46–65 · L88–115

---

12. `LearningBaseline/unigarmentmanip/train/base/config.py` ↗
    GitHub · GarmentLab/GarmentLab · 6ee0620fdd

    train_ratio=1 與 correspondence threshold 的實際預設。

    L1–46

---

13. `LearningBaseline/unigarmentmanip/utils/val_score.py` ↗
    GitHub · GarmentLab/GarmentLab · 6ee0620fdd

    驗證入口讀取 train 子集、舊 npz 鍵以及遺漏引數。

    L38–110

---

14. `LearningBaseline/unigarmentmanip/train/val/simple_val.py` ↗
    GitHub · GarmentLab/GarmentLab · 6ee0620fdd

    cosine correspondence 配對、歐氏誤差與門檻 accuracy。

    L27–89

---

15. `LearningBaseline/rl_fold/rl_fold.py` ↗
    GitHub · GarmentLab/GarmentLab · 6ee0620fdd

    確認實際 eval 入口與30次 rollout 呼叫。

    L44–100

---

16. `LearningBaseline/rl_fold/config/config.yaml` ↗

    GitHub · GarmentLab/GarmentLab · 6ee0620fdd

    具體 garment、demo_point / target_point 及 task_name=hang。

    L1–38

---

17. `LearningBaseline/rl_fold/rl_utils/task_defne.py` ↗

    GitHub · GarmentLab/GarmentLab · 6ee0620fdd

    辨識 FoldTask 裡的 Cartpole 範本殘留，不能當 fold checker。

    L14–60 · L111–135

---

18. `LearningBaseline/rl_fold/rl_utils/rl_env.py` ↗

    GitHub · GarmentLab/GarmentLab · 6ee0620fdd

    task 在此提供 action/observation space，避免將範本 checker 誤當主 evaluator。

    L111–130

---

19. `LearningBaseline/rl_fold/rl_utils/ppo.py` ↗

    GitHub · GarmentLab/GarmentLab · 6ee0620fdd

    eval_policy 真正呼叫 SimEnv.step(...,True) 並平均布林回傳。

    L160–216

---

20. `LearningBaseline/rl_fold/rl_utils/simulation_env.py` ↗

    GitHub · GarmentLab/GarmentLab · 6ee0620fdd

    讀取抓點誤差、unused 混合 reward、每回合 reset 與實際成功旗標。

    L31–149

怎麼接入我們的benchmark

可重用

USD / 材料設定、場景與感測配置、固定任務指令碼、點雲配對結構及已查明的原生 checker。

需要轉換

source 綁 commit；environment 綁資產與物理引數；task 對應實際指令碼 / 配置及論文標籤；case 需另建 garment_id＋初態＋示範 / seed；evaluator 分 geometry matching、抓點成功、掛衣高度、論文持續成功。資料配對數、render frames、衣物物件與30次RL評測不可混算。

仍需補齊

完整20任務 case/split manifest；fold IoU / 持續5秒的可執行 checker；原始npz→標註npz→val_score的欄位橋接與threshold修正；coverage軸向與state mutation決策；資產、真機benchmark檔案及校正尚未納入可執行接線。

P088 · FlingBot

FlingBot: The Unreasonable Effectiveness of Dynamic Manipulation for Cloth Unfolding

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

已核讀 FlingBot 的模擬 / 真機 task 與 replay HDF5、coverage checker、evaluation 入口及彙總。原生 task 是衣物形狀 / 材質 / 初態的一筆配置，目標仍是展布；模擬與真機 coverage 的原始單位不同。另確認非重複 loader 的末筆等待問題及彙總過濾會影響分母。

> **版本與身份**
>
> 固定2021-10-13 commit，原論文PDF快取為後續2021-10-18版；保留版本差異。environment/Memory.py是symlink文字，實作讀到learning/Memory.py。未執行任何模擬、GPU模型、機器人控制或下載衣物HDF5。
>
> 論文 arXiv:2105.03655 與 README 作者 Huy Ha / Shuran Song 對應。binding 的 columbia-robovision/flingbot 在快取 GitHub metadata 解析為 real-stanford/flingbot；保留 requested_repo 與 resolved_repo，不能當兩個獨立來源。論文亦使用 columbia-ai-robotics 舊網址。 舊入口columbia-robovision/flingbot的已儲存GitHub metadata回應指向real-stanford/flingbot，按倉庫別名保留，不另外算成未讀的第二個倉庫。

領域	衣物與洗護
環境	模擬為修改 SoftGym/PyFlex 的 CUDA 粒子布料環境，抽象雙picker配合UR5可達性邊界；使用Blender或OpenGL，論文設定為Blender。真機為兩支UR5、RG2 / WSG50、頂視Azure Kinect及前視RealSense；setup.py 只留一件衣物參考與裝置位置引數，未提供完整論文實體資產清單。
任務	展布 / 最大覆蓋面積是一個目標族；Normal Rect、Large Rect、Shirt 是形狀 / 尺寸泛化設定。fling、stretchdrag、drag、place 是 action primitives，不是四個新的生活任務。TaskLoader 的 task_name 是 HDF5 配置ID；生成group key是對當時記錄數字取SHA1，不是狀態內容雜湊。論文600模擬測試配置＝三類各200，真機三類各10次；2000訓練配置及150真機調適回合另列，未下載HDF5驗證實際記錄數。

題數與資料	task HDF5 以group儲存 particle_pos、particle_vel、shape_pos、phase、cloth_size、cloth_stiff、mesh_verts / faces / stretch/bend/shear edges；flatten_area、initial_coverage、cloth_mass、task_difficulty為attribute。方布尺寸為粒子數，預設半徑0.00625m；mesh尺寸用[-1,-1]、flatten_area取trimesh面積/2。replay每個{episode:09d}_step{step:02d}（尾步加_last）為一筆action；含observations、actions單畫素mask、rewards、is_terminal、next_observations及rotation/scale/action_primitive/task_name/preaction_coverage/postaction_coverage/max_coverage。RGB/255＋depth為4×H×W、策略預設僅用RGB與64×64輸入；action需連同影像旋轉縮放與可達性轉換解碼。
評估方式	模擬coverage是100×100 xz佔格的面積（原生m²）；step reward為A_after−A_before，學習label預設再除flatten_area。方布reference來自展平網格，mesh取表面面積/2。真機coverage是HSV背景分割後最大連通區畫素佔全影像比例，再除同相機的flatten_area參考；不能把此原始值當m²。10 primitive actions內可提前終止：模擬最大粒子位移<0.05，真機前後mask IoU>0.9，均代表停滯而非成功。collect_stats報normalized final/best/delta coverage，未裁至[0,1]；跳過failed_grasp/cloth_stuck/timed_out、缺max_coverage及postcoverage/reference<0.05的記錄。其episode_length直接讀零起始尾步索引，真正動作數需+1。run_sim預設統計最近128個step groups；visualize.summarize用1e7上限讀全buffer，不可把線上平均當全測試分數。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **1** cloth-unfolding goal family · 原文頁 6
- **600** simulation test initializations · 原文頁 7
- **30** real test cases，3types×10 · 原文頁 7

依這個順序讀

1. `README.md` ↗

   GitHub · real-stanford/flingbot · c5f35c785c

   確認論文、SoftGym/PyFlex 衍生、三種測試衣物設定與真機裝置。

   `L1–46 · L79–87 · L123–215 · L217–280`

2. `environment/tasks.py` ↗

   GitHub · real-stanford/flingbot · c5f35c785c

   核對任務生成、mesh / 粒子狀態、HDF5 格式及 nonrepeat loader。

   `L105–219 · L261–421 · L436–479`

3. `environment/simEnv.py` ↗

   GitHub · real-stanford/flingbot · c5f35c785c

   action primitive、逐步記錄、coverage delta 與終止機制。

   L33–117 · L431–516 · L663–689 · L782–807

---

4. `environment/flex_utils.py` ↗

   GitHub · real-stanford/flingbot · c5f35c785c

   實際 xz 網格面積與方布 flatten reference。

   L358–415

---

5. `environment/Memory.py` ↗

   GitHub · real-stanford/flingbot · c5f35c785c

   確認該檔是指向 learning/Memory.py 的連結內容。

   L1–1

---

6. `learning/Memory.py` ↗

   GitHub · real-stanford/flingbot · c5f35c785c

   episode-step HDF5 的 attribute/dataset、最後步與巢狀資料。

   L9–23 · L55–80 · L106–165

---

7. `learning/utils.py` ↗

   GitHub · real-stanford/flingbot · c5f35c785c

   讀取 replay 的 observation/action mask 及 normalized coverage label。

   L12–44 · L76–100

---

8. `environment/utils.py` ↗

   GitHub · real-stanford/flingbot · c5f35c785c

   RGB/255 與原生 depth 組成 CHW，以及真機 segmentation 後處理。

   L579–602

---

9. `run_sim.py` ↗

   GitHub · real-stanford/flingbot · c5f35c785c

   確認 eval / 訓練入口與定期 collect_stats。

   L37–109

---

10. `utils.py` ↗

    GitHub · real-stanford/flingbot · c5f35c785c

    eval 停止更新、loader 接線、raw/final/delta 統計、排除規則與零起始步索引。

    L17–88 · L100–157 · L186–336 · L337–376

---

11. `visualize.py` ↗

    GitHub · real-stanford/flingbot · c5f35c785c

    離線 summary 使用全buffer上限，與訓練128步視窗分開。

    L1–43

---

12. `real_world/setup.py` ↗

    GitHub · real-stanford/flingbot · c5f35c785c

    真機衣物 reference、workspace crop 與空白裝置配置。

    L7–52

---

13. `real_world/realWorldEnv.py` ↗

    GitHub · real-stanford/flingbot · c5f35c785c

    真機同名 task 與原生 IoU 停滯、失敗旗標、感測縮放。

    L1–63 · L96–163 · L367–394

---

14. `real_world/utils.py` ↗

    GitHub · real-stanford/flingbot · c5f35c785c

    真機 mask coverage 是影像畫素比例，並核對畫素至機器人座標轉換。

    L22–69

怎麼接入我們的benchmark

可重用

Task狀態重設、HDF5 reader/writer、action transformation欄位、raw與normalized coverage及failure flags。

需要轉換

source儲存舊repo別名及resolved commit；environment分模擬 / 真機與renderer；task儲存展布目標及primitive；case用dataset雜湊＋task_name＋形狀設定；rollout另存episode/step/action_count；evaluator明列面積或畫素比例、reference方法及過濾後分母。

仍需補齊

三測試HDF5 / 訓練HDF5的雜湊與mesh split；nonrepeat loader末筆問題修正或保留原版行為；未排除失敗的系統評測分母；真機衣物完整表、校正與背景設定；native step index轉操作次數驗證。

P089 · SpeedFolding

SpeedFolding: Learning Efficient Bimanual Folding of Garments

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

已核讀 SpeedFolding 的真機流程、SQLite/PNG 格式、BiMaMa 資料 reader、摺線指令與具體 coverage reward。evaluation.py 只記錄事件 / 時間，folded 事件也不是獨立成功判定；論文摺衣成功須保留三位人類評閱者多數決。公開版本另有 reader / writer 介面不一致。

> **版本與身份**
>
> 固定2023-12-11 commit，晚於2022論文；README已明示硬體相依參考程式。未連線資料庫、相機或YuMi，未下載15.2GB資料集或執行模型。
>
> README直接連結 arXiv:2208.10552 與 pantor 官方專案頁，明示 IROS 2022 / ABB YuMi＋PhoXi 的硬體相依參考實作。

領域	衣物與洗護
環境	實體ABB YuMi雙臂平行夾爪、海綿工作面、PhoXi頂視灰階 / 深度，以及額外webcam coverage。軟體包含OMPL與PhoXi C++ wrappers，README明示不易直接執行。pixel_to_transform從校正point cloud取xyz、以theta設定gripper姿態；影像位姿不能直接當已校正機器人動作。
任務	流程是先平整衣物，再依使用者摺線 / 2-second heuristic / fling-to-fold完成摺衣。shirt.json有兩種順序、每種三條摺線，屬同一目標的候選程式，不是6個任務。loader的fling、fling-to-fold、pick-and-hold、drag、done為訓練primitive類別。論文每組實驗15 trials，4300訓練action records含1500複製重標；不能把records、物理操作、完整摺衣trial及任務名稱混算。
題數與資料	SQLite actions(id,episode_id,action_id,data JSON)與 images(episode_id,action_id,scene,camera,hash)；PNG路徑為 collection/episode_id/{action_id}-{scene}-{camera}.png，scene含before/after，camera可為color/depth/ortho-color/ortho-depth。JSON儲存type、poses[{x,y,theta}]、reward、needs_annotation、is_human_annotated、is_self_supervised。Saver把0.85–1.25m深度反向線性對映0–255並裁切，0深度先改1.25m，不能把PNG值當公尺。BiFoldingDataset讀灰階與量化深度兩通道，按1032×772來源尺寸crop後resize到256×192、theta為弧度及20個離散方向。預設以episode_id的SHA256低16bit閾值做約80/20 train/test，非衣物物件切分；run.py每個action新建Episode，因此該ID未必代表整個物理trial。

評估方式	reward.segment以灰階閾值90、形態學與最大輪廓產生mask；calculate_reward為tanh(64×A_before×(A_after−A_before))，A為mask畫素佔比。另一個coverage＋confidence reward函式存在，但run.py呼叫前者。Experiment.take_coverage用校正webcam、閾值130並回傳輪廓面積/影像面積。done是模型分類的Sufficiently Smoothed停止決策；執行摺線後直接記folded事件，不代表成品合格。Evaluation記相對啟動秒數及profile duration，未實作三人投票或完整FPH。論文成功要求10動作內且三位評閱者多數通過，排除motion-planning早退；表I duration只平均成功trial，cycle time/FPH包含成功與失敗。程式CLI horizon預設3，README實驗設10；run.py horizon限制平整迴圈，後續摺線及move另外執行，須明訂共同action budget。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **4,300** training action records，含重標 · 原文頁 6
- **15** trials per experiment · 原文頁 6, 7

依這個順序讀

1. `README.md` ↗

   GitHub · pantor/speedfolding · db06519a2f

   確認論文身分、硬體限制、來源結構與測試命令。

   L29–87

2. `learning/database.py` ↗

   GitHub · pantor/speedfolding · db06519a2f

   SQLite schema、JSON action、影像引用及episode_id雜湊分割。

   L13–109 · L121–126

3. `manipulation/saver.py` ↗

   GitHub · pantor/speedfolding · db06519a2f

   實際writer簽名、每次新ID與depth壓至PNG的尺度。

   L11–78

4. `learning/bimama/dataset.py` ↗

   GitHub · pantor/speedfolding · db06519a2f

   觀測灰階＋深度、五個primitive classes、heatmaps、標註權重及split。

   L20–103 · L109–175

---

5. `data/instructions/shirt.json` ↗

   GitHub · pantor/speedfolding · db06519a2f

   兩個摺線順序候選、三條摺線與兩個grasp-points。

   L1–27

---

6. `manipulation/heuristics/matching.py` ↗

   GitHub · pantor/speedfolding · db06519a2f

   讀取template與instructions，pixel equality配準後選候選。

   L13–28 · L54–106

---

7. `manipulation/heuristics/folding.py` ↗

   GitHub · pantor/speedfolding · db06519a2f

   摺線畫素化、輪廓抓點及映象放置。

   L9–98

---

8. `manipulation/experiment.py` ↗

   GitHub · pantor/speedfolding · db06519a2f

   畫素→3D pose、webcam coverage及摺線執行，沒有成品裁判。

   L77–92 · L210–244 · L1033–1087

---

9. `learning/inference.py` ↗

   GitHub · pantor/speedfolding · db06519a2f

   done由模型primitive分類選出，非摺衣成功checker。

   L181–229 · L272–286

---

10. `learning/reward.py` ↗

    GitHub · pantor/speedfolding · db06519a2f

    灰階分割、area fraction及實際tanh reward；辨別備用confidence reward。

    L5–64

---

11. `manipulation/evaluation.py` ↗

    GitHub · pantor/speedfolding · db06519a2f

    具體event elapsed time / profile duration，而非成功率計算器。

    L1–47

---

12. `manipulation/run.py` ↗

    GitHub · pantor/speedfolding · db06519a2f

    horizon、folded事件、每action新Episode、失敗排除及實際writer呼叫。

    L17–29 · L69–129 · L143–209

怎麼接入我們的benchmark

可重用

摺線JSON＋template、影像 / action DB索引、primitive執行脈絡、coverage reward及事件計時。

需要轉換

source綁commit；environment綁YuMi工作站與相機校正；task綁衣物與摺執行緒序；case新增完整trial_id、garment_id與初態，連到多個action record；evaluator分smoothing confidence、grasp failure、coverage、成品人評與duration/cycle/FPH，明列排除及分母。重標記錄保留來源action關係，量化depth需用尺度 / 缺測mask解碼。

仍需補齊

人評票決與完整trial成品影像 / 耗時表；去除重標後的資料lineage及物理trial切分；公開reader/writer相容性修正；硬體 / template / weights資產與校正接線。

P090 · Cloth Funnels

Cloth Funnels: Canonicalized-Alignment for Multi-Purpose Garment Manipulation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

已核讀 Cloth Funnels 模擬的 task HDF5、mesh split、replay reader/writer、剛體 / 變形距離及實際 eval_buffer。生成指令碼規劃每類400個eval配置，但公開eval鏈只選hard子集；彙總固定取每回合最大IoU步，並非函式引數宣稱的第n步或最終步。

> **版本與身份**
>
> 固定2025-08-23 commit，晚於2022 arXiv；README標ICRA2023但BibTeX仍填2022，保留原論文與公開程式版本。只核讀所列模擬來源段落，未執行GPU、下載task/weights或宣稱真機全流程可用。
>
> README 題名、七位作者與 arXiv:2210.09347 對應本篇；binding舊網址 columbia-ai-robotics/cloth-funnels 解析為 real-stanford/cloth-funnels。保留原始別名、canonical repo與同一commit，避免重複來源。 舊入口columbia-ai-robotics/cloth-funnels的已儲存GitHub metadata回應指向real-stanford/cloth-funnels，按倉庫別名保留，不另外算成未讀的第二個倉庫。

領域	衣物與洗護
環境	修改版FleX/PyFlex粒子衣物與抽象雙picker，可達性與table引數另存；本輪核讀README主張的模擬評測鏈。原生xyz中y為高度，canonicalized-alignment要求指定平面姿態與衣物形狀；高coverage不能代替對齊。真機檔案雖在tree，本輪未聲稱真機 / 熨燙評測已完整核讀。
任務	主要目標為canonicalized-alignment，place/fling為預設primitive；longsleeve/pants/dress/jumpsuit/skirt為五衣物類別。生成指令碼每類目標配額2000 train＝1500 hard＋500 easy、400 eval＝200 hard＋200 easy；第二次命令的num_tasks是累積配額，不再相加。實際eval loader只取hard，因此README的200與整份400有子集差異；未下載HDF5確認實際完成配額。fold_finish為下游shirt heuristic，不另當完成驗證的benchmark。
題數與資料	類別JSON以train/test清單選mesh，生成器按args.eval抽對應衣物ID；不能用同檔未被呼叫的is_eval字首helper替代。task HDF5包含particle_pos（擾動後起始狀態）、init_particle_pos（canonical目標）、particle_vel、shape_pos、phase、mesh_verts/faces/edges/nocs、cloth_instance、pkl_path、init_rgb/task_rgb、cloth_height/width與keypoint groups。flatten_area為mesh表面面積/2，get_config.cloth_area卻是cloth_height×cloth_width；距離正規化用後者。replay為episode_stepXX[_last]，有觀測、單畫素action mask、旋轉 / scale / primitive、pre/postaction_verts / masks、各metric與deformable_weight。writer丟掉task_name及cloth_instance，但保留task_pkl_path與init_verts；sum(init_verts)僅是既有查詢慣例，不是可靠唯一ID。

評估方式	SimEnv.deformable_reward→learning.utils.deformable_distance：goal/current先將y設0，保留相同mesh頂點對應；以SVD及5次距離子集配準取得變形殘差，逆向配準取得剛體偏移，允許x映象取較小距離。原生l2_distance是變形項、icp_distance是剛體項、pointwise_distance是未配準點距；各除sqrt(cloth_height×cloth_width)，weighted_distance預設0.65×變形＋0.35×剛體。mask為RGB通道和>0；IoU=交集/聯集，coverage=當前mask畫素/目標mask畫素。init mask失敗時退用當前mask，應保留異常。SimEnv儲存rewards=0，學習reader才從pre–post metric重建reward並用0.072等尺度標準化，不能直接平均rewards欄。eval_buffer先hard-only，再每個episode固定選postaction_iou最大步，無視evaluate(mode,n)，10輪迴圈實際重複相同選擇，報mean與std/sqrt(N)。fold_finish在最後一步以三段shirt heuristic替代policy primitive，沒有獨立摺衣成品checker；應分開canonicalization與downstream成功。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **5** garment categories · 原文頁 5
- **400** unseen-mesh test settings per category · 原文頁 5

依這個順序讀

1. `README.md` ↗

   GitHub · real-stanford/cloth-funnels · 3b355304a6

   確認論文、200個crumpled eval敘述、五衣物類及FlingBot/SoftGym來源。

   `L1–46 · L81–85 · L125–155 · L162–249`

2. `cloth_funnels/conf/config.yaml` ↗

   GitHub · real-stanford/cloth-funnels · 3b355304a6

   核對訓練8步 / eval覆寫10步、primitive、觀測與0.65權重。

   `L1–20 · L29–49 · L57–114`

3. `cloth_funnels/cloth_data/cloth3d_pickle/longsleeve.json` ↗

   GitHub · real-stanford/cloth-funnels · 3b355304a6

   實際train/test mesh ID列表，非由檔名字首猜split。

   `L1–1`

4. `cloth_funnels/tasks/generate_tasks_script.py` ↗
   GitHub · real-stanford/cloth-funnels · 3b355304a6

   2000訓練與400測試生成配額、hard/easy的不同擾動。

   L1–41

---

5. `cloth_funnels/tasks/generate_tasks.py` ↗
   GitHub · real-stanford/cloth-funnels · 3b355304a6

   確認canonical goal / 擾動初態、HDF5欄位、cloth_area與hard-only loader。

   L54–173 · L255–293 · L330–367 · L374–424 · L457–505 · L532–596

---

6. `cloth_funnels/environment/Memory.py` ↗
   GitHub · real-stanford/cloth-funnels · 3b355304a6

   讀到symlink目標，避免把連結文字當writer。

   L1–1

---

7. `cloth_funnels/learning/Memory.py` ↗
   GitHub · real-stanford/cloth-funnels · 3b355304a6

   episode-step序列化及被刻意省略的task_name/cloth_instance欄位。

   L109–178

---

8. `cloth_funnels/learning/utils.py` ↗
   GitHub · real-stanford/cloth-funnels · 3b355304a6

   追到SVD配準與正規化距離、reward重建及HDF5 reader。

   L32–199 · L270–343

---

9. `cloth_funnels/environment/simEnv.py` ↗
   GitHub · real-stanford/cloth-funnels · 3b355304a6

   實際呼叫metric、mask計分、zero reward欄位、失敗reset、fold_finish與canonical reference。

   L6–41 · L696–779 · L782–832 · L855–873 · L876–922 · L945–1024 · L1330–1404 · L1430–1450

---

10. `cloth_funnels/environment/flex_utils.py` ↗
    GitHub · real-stanford/cloth-funnels · 3b355304a6

    實際匯入版本的粒子覆蓋面積函式。

    L269–300

---

11. `cloth_funnels/utils/env_utils.py` ↗
    GitHub · real-stanford/cloth-funnels · 3b355304a6

    六點幾何匯出三段下游摺衣動作，不是成功裁判。

    L890–936

---

12. `cloth_funnels/utils/utils.py` ↗
    GitHub · real-stanford/cloth-funnels · 3b355304a6

    eval_tasks / TaskLoader與SimEnv接線，另讀到sum(init_verts)重建查詢。

    L100–148

---

13. `cloth_funnels/run_sim.py` ↗
    GitHub · real-stanford/cloth-funnels · 3b355304a6

    eval不更新模型、max_steps為buffer大小限制而非唯一case數。

    L106–120 · L134–170 · L184–193

---

14. `cloth_funnels/scripts/eval_buffer.py` ↗
    GitHub · real-stanford/cloth-funnels · 3b355304a6

    完整閱讀hard過濾、legacy metric名稱與固定max_iou步選擇。

    L8–38 · L41–160

怎麼接入我們的benchmark

可重用

mesh split與task目標 / 初態、固定對應頂點、分解距離 / mask metric、HDF5狀態與primitive資料。

需要轉換

source綁canonical repo及commit；environment保留FleX/renderer/座標系；task儲存對齊目標、衣物類及fold_finish協定；case用task來源雜湊＋原group ID＋mesh ID＋擾動；evaluator把legacy名稱映到deformable/rigid/pointwise並儲存正規化面積、映象規則與step-selection。保留hard子集分母及policy-step與heuristic動作數，禁止自動轉成共同success。

仍需補齊

實際task HDF5清單與case/replay穩定對照；非重複loader末筆等待修正；最大IoU / nth / last選步協定；失敗reset未落檔的分母；下游fold / 真機與熨燙成功規則及資產校正。

P091 · UniFolding

UniFolding: Towards Sample-efficient, Scalable, and Generalizable Robotic Garment Folding

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

已核讀 UniFolding 的 VR HDFStore、runtime YAML/NPZ/PLY、動作與標註格式、模擬幾何計分及真機狀態機。真機 SUCCESS 是流程狀態：fold1/fold2 條件以最後 action 型別推定，並無成品幾何驗收；原始論文10步內按摺法完成的成功率需另保留評閱證據。

> **版本與身份**
>
> 固定2024-10-18 commit，晚於2023論文。核讀限Python資料 / task / metric與控制流程，未核讀所有電機控制 / Unity外掛底層，未執行上游程式、連線標註資料庫 / 通知或下載模型與大型資產。 已補讀VR-Garment c9014f62的收集與回放資料契約；它本是GarmentTracking工具，UniFolding引用作Stage0上游。未使用VR硬體或執行Unity。
>
> README 明示官方 CoRL 2023 程式，完整題名、六位作者與 arXiv:2311.01267 相符。RFUniverse、CLOTH3D、VR-Garment 與 ClothFunnels 各有重用角色，不把框架 / 母資料集當成本篇新benchmark。

領域	衣物與洗護
環境	模擬是Unity 2022.3 LTS上的RFUniverse，README要求另取得Cloth Dynamics 2.0.9 beta；CLOTH3D衣物依category meta與instance filter載入。真機是雙Flexiv Rizon 4、AG-95與Photoneo MotionCam3D＋MindVision RGB。Unity左手系先轉Open3D右手系，再轉virtual/world/左右robot frames；virtual以z為高度，配置另有particle_scale=100與time_scale=4，不能直接沿用FleX的y-up或將步數當秒。
任務	兩種衣物tshirt_long / tshirt_short的展開→fold1→fold2流程；附錄C先同時摺兩袖，再對半摺本體，精確抓放點由VR人類示範生成。ActionTypeDef包含FLING/DRAG/FOLD_1/FOLD_2/PICK_AND_PLACE/DONE及恢復 / HOME等，是動作enum而非同數量任務。ExperimentVirtual.execute_action只實作FLING，random_fold用於初態，不能宣稱runtime模擬提供完整摺衣動作集。論文60件真衣物以2:1分割，20件held-out各10trials＝200次測試；2432是訓練sample、每sample16次人類偏好比較，不是測試cases。

題數與資料	VR data.h5 的Pandas df以instance_id/video_id/sample_id標識，讀pcd_path_frame1→NumPy Nx6 xyz/rgb、nocs_path_frame1、coverage_frame1/2、左右gripper_point/theta_frame1/2、action_type、folding_step、is_smoothed/is_smoothing。raw fold依folding_step映為fold1/fold2；pose內部順序為左pick、左place、右pick、右place，角度wrap至±π。VR依instance_id打亂切分，所讀stage1 config為8/1/1；runtime real/virtual卻依sample打亂，不能等同論文物件held-out split。runtime metadata按namespace記pcd.processed.begin、processed_nocs.begin、pose_virtual、reward.begin/end及episode_idx/trial_idx/action_step；NPZ鍵為points/nocs，real另接受PLY。annotation.action_poses原順序左pick、右pick、左place、右place，reader重排後將角度全設0；虛擬fling place亦用0佔位，應儲存validity而非當有效目標。偏好0/1/2/3分別為左對優 / 右對優 / 相等 / 不可比較，經label smoothing後監督分數模型。 VR-Garment補查：PoseData包含dualHandPoses（position / Euler / 手勢）、localParticles（solver renderable positions / normals）、左右grasp solver indices、solver / actor local-to-world矩陣和Time.time。Record名義每0.04秒呼叫，應保留實際timestamp而非假設等間隔。JSON錄製再回放輸出AnimationData及color/depth/mask影像引用的BSON；四個隨機相機視角共用同一段示範。
評估方式	虛擬get_deformable_reward以canonical初態粒子覆蓋面積作max_coverage，在virtual XY平面用100×100粒子網格；IoU另外把兩組XY點共同縮放至0–99並畫半徑2圓，以點陣交集/聯集計算，不是RGB影像mask IoU。reward.py沿用ClothFunnels分解形式，但此版把z歸零、同頂點SVD配準5次、映象取min，距離除sqrt(初態粒子覆蓋面積)，stage2權重0.7；與P090用長×寬正規化不同。runtime學習用begin–end的l2/icp改善量；VR則用同instance的coverage_frame1最大值正規化、stage1以max(tanh(2Δcoverage+coverage_after),0)給fling標籤，fold等固定0.8、done為0，均非實測成功率。真機state machine把fold成功設為最後action_type==FOLD_1/FOLD_2，garment_fling_drag_success固定True且有TODO；operable只看mask面積上限、reachable看mask橫向均值，沒有成品摺法驗收。step_idx>max_num_steps非全域強制終止，部分轉移還要求不可操作，lift與fold前drag迴圈不按每個物理動作累加。論文要求10動作內按規則完成，這與狀態機SUCCESS需分欄。 VR收集工具的開始 / 清除 / 儲存由手勢或按鍵觸發，超過maxFrameCount僅提示；錄完不表示通過摺疊成功判分。ClothImitation2 / AnimationImitation2是錄製與回放場景，不能加成兩個新任務；四視角不加成四段獨立示範。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **20** held-out real garments · 原文頁 6
- **200** real trials，20garments×10 · 原文頁 6
- **2,793** VR manipulation videos · 原文頁 5

依這個順序讀

1. `README.md` ↗

   GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

   確認論文、資料 / 硬體、VR收集與四階段流程。

   L1–9 · L48–70 · L109–146 · L154–166

---

2. `RFUniverse/README.md` ↗

   GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

   Unity/RFUniverse與需另取得的Cloth Dynamics版本，非完整自含模擬器。

   L1–38 · L66–76

---

3. `common/datamodels.py` ↗

   GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

   動作enum、兩支手臂pick/place、觀測與四類偏好標註。

   L13–135 · L182–210 · L236–276

---

4. `learning/datasets/vr_dataset.py` ↗

   GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

   HDFStore df、frame pair / fold_step對映、虛擬示範reward與instance split。

   L25–60 · L134–137 · L146–227 · L252–314 · L357–422

---

5. `config/virtual_experiment_stage1/train_virtual_base.yaml` ↗

   GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

   確認8/1/1 split、點雲抽樣、voxel與tanh reward設定。

   L1–31 · L63–86

---

6. `learning/components/obj_data_loader.py` ↗

   GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

   CLOTH3D instance filter、category meta與worker分塊，勿當資料split。

   L9–85

---

7. `learning/datasets/runtime_dataset_virtual.py` ↗
   GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

   虛擬log的NOCS / points、抓點零值佔位、metric delta及sample切分。

   L210–231 · L246–302 · L316–359

---

8. `learning/datasets/runtime_dataset_real.py` ↗
   GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

   metadata與annotation讀取、pose重排、偏好label及sample切分。

   L131–187 · L216–308 · L323–365

---

9. `learning/components/cloth_dynamics_env.py` ↗
   GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

   讀Unity訊息解碼、左右手座標、depth前景及NOCS對應。

   L126–158 · L189–208 · L309–330 · L359–375

---

10. `manipulation/experiment_virtual.py` ↗
    GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

    虛擬座標轉換、只支援FLING的runtime執行與具體reward呼叫。

    L39–113 · L274–355

---

11. `common/metric_utils.py` ↗
    GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

    XY粒子面積與100×100點陣IoU的真正公式。

    L1–70

---

12. `common/geometry_util.py` ↗
    GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

    面積grid輔助函式與SVD剛體配準。

    L90–142

---

13. `learning/components/reward.py` ↗

GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

投影、映象、分解距離及面積正規化的具體實作。

L1–101

---

14. `config/virtual_experiment_stage2/experiment_virtual_base.yaml` ↗

GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

runtime粒子縮放 / 時間尺度、5步收集及0.7 reward權重。

L19–78 · L127–140

---

15. `run_virtual.py` ↗

GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

一筆action的begin/end觀測、metric及episode/garment/trial/step脈絡。

L64–113 · L132–155

---

16. `Makefile` ↗

GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

兩類衣物測試target覆寫每件10trials並關閉探索。

L81–98

---

17. `config/real_experiment/experiment_real_base.yaml` ↗

GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

真機校正、mask門檻、10步與barrier / runtime training設定。

L5–79

---

18. `config/real_experiment/experiment_real_tshirt_long.yaml` ↗

GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

長袖test使用的base繼承與衣物設定。

L1–19

---

19. `config/real_experiment/experiment_real_tshirt_short.yaml` ↗

GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

短袖test使用的base繼承與衣物設定。

L1–19

---

20. `run_real.py` ↗

GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

依garment與trial執行狀態機，及測試target仍可能進入訓練路徑。

L82–117 · L143–228

---

21. `manipulation/statemachine_garment.py` ↗

GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

核對SUCCESS條件、TODO布林、非全域步數上限與錯誤處理。

L19–138 · L249–306 · L325–348 · L395–459

---

22. `manipulation/experiment_real.py` ↗

GitHub · xiaoxiaoxh/UniFolding · cbd0b374f1

mask / point cloud感測、可操作 / 可達判斷及實體fold動作dispatch。

L493–570 · L635–665 · L742–767

---

23. `README.md` ↗

GitHub · xiaoxiaoxh/VR-Garment · c9014f626e

核對VR硬體、Unity2021.3、record/replay兩場景及資料角色。

L1–71

---

24. `Assets/Scripts/Imitation2/ObiSceneManagerImitation2.cs` ↗

GitHub · xiaoxiaoxh/VR-Garment · c9014f626e

讀PoseData欄位、名義25Hz / Time.time、手姿及抓取粒子、JSON儲存。

L62–124 · L160–168 · L457–575

---

25. `Assets/Scripts/Imitation2/AnimateImitation2.cs` ↗

    GitHub · xiaoxiaoxh/VR-Garment · c9014f626e

    讀四視角影像 / 相機矩陣、mesh/hand資料與BSON回放輸出。

    `L83–129 · L250–324 · L452–476 · L484–541`

怎麼接入我們的benchmark

可重用

原生動作 / 觀測 / annotation dataclasses、frame pairs與偏好、instance與sample索引、模擬幾何metric及真機流程狀態。

需要轉換

source固定commit並標記VR-Garment/CLOTH3D/ClothFunnels重用；environment儲存Unity/Open3D/virtual/world/robot座標鏈；task儲存衣物類與兩段摺法；case保留完整garment/trial/step、checkpoint、split粒度；evaluator分模擬距離、VR訓練reward、preference target、真機流程狀態及獨立成品成功。保留特權粒子/NOCS，勿當真機可觀測量；人類VR示範須經primitive與校正adapter才能成為robot命令。 VR原生Unity / solver座標、Euler順序、BSON/JSON與視角 / timestamp對應須保留並校驗；不得直接視為米制robot命令。

仍需補齊

VR→UniFolding前處理與data.h5/NPZ/annotation/instance清單閉合；物件held-out真機200trials的逐次成品評閱；嚴格10物理action budget；pure evaluation入口與網路 / barrier相依隔離；Unity付費外掛 / CLOTH3D / 硬體校正取得與執行驗證。

P092 · ICRA cloth competition

A Dataset and Benchmark for Robotic Cloth Unfolding Grasp Selection: The ICRA 2024 Cloth Competition

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

競賽倉庫公開雙臂布料觀測格式與半自動面積量測；coverage 原始面積與正規化競賽得分需要分開。

> **版本與身份**
>
> 釘選2024競賽倉庫；README的未來式文字不能否定已存在的evaluation-service。已讀核心章節，未重現比賽。

領域	衣物與洗護
環境	真實雙UR5e / Robotiq工作站及雙目深度相機；Drake場景供運動規劃，布料點雲凸包焊接為障礙，不代表完整柔性物理模擬。
任務	布料攤展競賽中的抓取與展開結果；每次sample/scene及衣物初態不是新的任務語義。
題數與資料	CompetitionObservation含左右RGB、與左圖對齊depth_map、confidence_map、世界座標point_cloud、相機 / 左右臂 / TCP世界姿態與關節；檔案為PNG/TIFF/PLY/JSON，讀寫程式明確處理RGB/BGR。README指向83GB外部資料，未下載。
評估方式	組織者選框 / 正負點→SAM遮罩→按平均深度±outlierThreshold過濾→每畫素投影面積加總。server.py把此原始面積寫為coverage；README所述相對最大可展面積之比例仍需衣物基準面積，不能直接把輸出值當0–1成功率。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **1** 核心unfold grasp-selection任務 · 原文頁 6, 7
- **34** cloth items · 原文頁 8
- **679** recorded unfolding episodes · 原文頁 8
- **176** 11方法競賽trials · 原文頁 8, 11

依這個順序讀

1. README.md ↗
   GitHub · Victorlouisdg/cloth-competition · 34dcac88c9

   確認競賽、資料與程式角色

   L1–24

---

2. cloth-tools/cloth_tools/dataset/format.py ↗
   GitHub · Victorlouisdg/cloth-competition · 34dcac88c9

   原生雙目 / 深度 / 世界座標 / 雙臂觀測儲存及讀取

   L29–75 · L78–222

---

3. cloth-tools/cloth_tools/drake/scenes.py ↗
   GitHub · Victorlouisdg/cloth-competition · 34dcac88c9

   雙UR5e工作站與布料碰撞近似

   L31–91

---

4. evaluation-service/README.md ↗
   GitHub · Victorlouisdg/cloth-competition · 34dcac88c9

   人工選區與競賽coverage定義

   L1–19

---

5. evaluation-service/backend/server.py ↗
   GitHub · Victorlouisdg/cloth-competition · 34dcac88c9

   SAM遮罩、深度離群值、相機投影面積與輸出

   L42–82 · L81–178

怎麼接入我們的benchmark

可重用

原生觀測欄位、相機標定 / 機體座標、選區與面積量測紀錄。

需要轉換

environment記工作站與標定版本，case連sample及衣物初態；evaluator保留原面積單位、最大面積分母、人工框點、SAM版本、過濾引數與複核。

仍需補齊

資料資產、衣物最大面積基準、合法介入規則與一致性評估、可重設初態及整體競賽分數聚合尚需接入。

P093 · MoDeSuite

MoDeSuite: Robot Learning Task Suite for Benchmarking Mobile Manipulation with Deformable Objects

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

MoDeSuite有8種移動柔性物任務；具體Spot-Place程式可追到9維控制、觀測組合與on_table判定，但結束訊號及README命令需要核對。

> **版本與身份**
>
> README連2507.21796，倉庫2026發布。README寫scripts/，實際程式在script/；安裝 / 授權需讀正式檔案，不僅靠MIT徽章。本筆以Spot-Place為具體程式抽讀，不宣稱8類所有程式都逐行核讀。

領域	居家整理與清潔、衣物與洗護
環境	Isaac Sim 4.2 / Isaac Lab，Spot帶臂與輪式Franka；含桿、帶、布等及桌面、走廊、障礙。Spot-Place使用USD桌與桿，num_envs=4是平行複本，不是4種不同環境。
任務	README列Place/Bend/Transport/Drag/Lift/Uncover/Cover/Curtain共8種，分5彈性 / 3塑性；Gym的機體與PPO/SAC註冊不能當新語義任務。Cover文字誤重複Uncover描述，需以各具體程式與論文釐清。
題數與資料	Spot-Place配置9維動作=3基座+6手臂，sim.dt=1/200、decimation=2；policy觀測拼桿節點位置、機體位置 / 四元數、桌中心、關節位置 / 速度。play記action/obs/reward/timestep至pickle；不可把58維配置宣告當已驗證實際tensor形狀。
評估方式	on_table要求桿端落在桌中心x±0.38、y±0.54、z至z+0.08內且桿中點高於桌面；reward另外含距離、成功bonus及失衡罰分。_get_dones返回(time_out, on_table或失衡)，對DirectRLEnv介面的terminated/truncated及wrapper需專門驗證，不能直接把done當成功。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **8** mobile deformable tasks · 原文頁 1, 3, 4, 5
- **5** 新增elastic tasks · 原文頁 3
- **20** 評測trials / 設定 · 原文頁 6

依這個順序讀

1. `README.md` ↗
   GitHub · carolzyy/MoDeSuite · 470681a7ff

   核對精確論文、8種任務、兩種機體及外部資料

   L1–150

---

2. `task/Drag/__init__.py` ↗
   GitHub · carolzyy/MoDeSuite · 470681a7ff

   同一任務因機體 / 演算法出現不同Gym ID

   L1–49

---

3. `task/Place/spot_place_env.py` ↗
   GitHub · carolzyy/MoDeSuite · 470681a7ff

   資產、步頻、控制 / 觀測、原生成功條件與done順序

   L25–98 · L171–204 · L249–365

---

4. `script/play.py` ↗
   GitHub · carolzyy/MoDeSuite · 470681a7ff

   rollout記錄與輸出格式；不是已驗證總表評分器

   L168–218

怎麼接入我們的benchmark

可重用

8種原生任務標籤、機體 / USD配置、各task class、控制與成功predicate。

需要轉換

task連原生class，environment拆資產/初態/機體；case記seed、步頻、控制約定及資訊預算；evaluator獨立保留success、失衡、timeout與reward。

仍需補齊

USD / 示範資料閉合、Isaac Lab精確版本、各8類具體predicate逐項接線、done順序與實際obs維度執行驗證；本機未執行。

P094 · R2R / VLN

Vision-and-Language Navigation: Interpreting visually-grounded navigation instructions in real environments

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

R2R的基本身份是scan→path_id→instruction_id；同一路徑的3份語言說明是不同題目，共用環境與路徑。評分逐條檢查軌跡連通性與終點距離。

> **版本與身份**
>
> 主README說2019API由單筆改為batched並有v0.1舊版。釘選現有commit的R2R實作，未宣稱重現2018所有設定；RxR共享父環境需去重。

領域	居家整理與清潔、辦公與教育
環境	Matterport3D真實室內RGB-D全景與離散導航圖。README的90個原始環境是父資產規模，不能當R2R每個split的已取得環境數。
任務	自然語言引導導航；scan是環境、path_id是一條來源路徑、instr_id=path_id_說明序號是一道語言條件題。每路徑3句的假設寫在原evaluator，擴充語言數時不能原樣沿用。
題數與資料	原生item含scan/path/heading/instructions；R2RBatch拆instructions成多筆，reset由首viewpoint和heading開始。觀測字典有feature、navigableLocations和teacher最短路徑；teacher屬監督訊號，不能預設作測試輸入。
評估方式	輸出instr_id與(viewpoint,heading,elevation)序列。程式要求完整ID集合、正確起點與合法圖邊；navigation error / oracle error用圖上最短距離。成功為誤差<3m，SPL=成功×最短路長/max(實走長,最短路長)，按指令題平均。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **90** building scenes · 原文頁 2, 6
- **7,189** navigation paths · 原文頁 5
- **21,567** instruction instances（全部split） · 原文頁 5
- **4,173** test instructions · 原文頁 6

依這個順序讀

1. `README.md` ↗
   GitHub · peteanderson80/Matterport3DSimulator · 589d091b11

   原始論文身份、Matterport資產及版本變更

   L1–50 · L77–84

---

2. `tasks/R2R/env.py` ↗
   GitHub · peteanderson80/Matterport3DSimulator · 589d091b11

   路徑 / 多說明拆題、初態、teacher與合法觀測

   L104–152 · L157–211 · L215–222

---

3. `tasks/R2R/eval.py` ↗
   GitHub · peteanderson80/Matterport3DSimulator · 589d091b11

   預期題目ID、3公尺嚴格閾值、軌跡有效性和SPL

   L1–106

怎麼接入我們的benchmark

可重用

scan / viewpoint / path / instruction身份、導航圖、語言和原生evaluator。

需要轉換

environment鍵連Matterport父資產；task存導航目標語義；case保留instr_id與語言、split、起點 / 朝向、感測 / 步數預算；teacher隔離為reference。

仍需補齊

Matterport資產存取、圖與影像版本閉合、split防洩漏、動作 / 停止規則和模擬器API匹配。

P095 · RxR

Room-Across-Room: Multilingual Vision-and-Language Navigation with Dense Spatiotemporal Grounding

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

RxR公開多語指令、跟隨示範、視角軌跡與讀取程式；同一Matterport場景、語言改寫、示範和後加合成指令應分開計數。

> **版本與身份**
>
> README含2021修正7個pose檔和2022新增landmarks / 100萬合成指令；不可將現有完整下載內容當2020論文原始資料量。倉庫已封存不等於外部資料不可用。

領域	居家整理與清潔、辦公與教育
環境	重用Matterport3D scan / 全景viewpoint和導航連通圖；與R2R同父資產，不可跨來源直接相加。
任務	英語、印地語、泰盧固語導航與細粒度語言 / 視覺對齊。guide instruction是題目條件，follower demonstration是人類執行示範；二者非兩套獨立環境。
題數與資料	gzip JSONL guide含split/instruction_id/annotator_id/language/path_id/scan/path/heading/timed_instruction；少數word無時間欄位。follower有demonstration_id及父instruction_id。NPZ包含pano/time/audio_time、展平16數相機矩陣和mask/features；time為秒，heading為弧度且零朝+y、z向上。
評估方式	README定義NE、<3m SR、SPL、DTW/nDTW/sDTW；follower資料已有metrics。已讀倉庫的具體程式是載入 / 視覺化，不是完整競賽evaluator；RxR與RxR-Habitat兩種執行 / 提交協定需分別接線，不能以預存人類分數代模型評測。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **90** Matterport3D scenes · 原文頁 3
- **16,522** paths · 原文頁 4, 5
- **126,069** instructions（全部split） · 原文頁 5
- **2,684** test paths · 原文頁 4

依這個順序讀

1. `README.md` ↗
   GitHub · google-research-datasets/RxR · d22df5940a

   原始資料schema、時空對齊、標準指標和後加資料版本

   L1–131 · L133–300 · L315–357

---

2. `visualizations/setup.py` ↗
   GitHub · google-research-datasets/RxR · d22df5940a

   讀取JSONL/NPZ與導航圖、scan到mesh連結

   L42–92

---

3. `marky-mT5/render_landmarks.py` ↗
   GitHub · google-research-datasets/RxR · d22df5940a

   後加landmark資料讀取與MatterSim相機設定

   L24–46

怎麼接入我們的benchmark

可重用

多語ID、source scan、path、guide-follower關係、秒制詞語 / 視角對齊與原native metrics。

需要轉換

case鍵保留instruction_id；示範另連demonstration_id。environment沿Matterport資產鍵去重；pose/語音時間基準分開。後加marky合成指令與原人類資料另標來源版本。

仍需補齊

競賽scorer與stop/action預算核對、全量資料 / 資產取得、時間缺值處理、機器產生指令與原split隔離。

P096 · ALFRED

ALFRED: A Benchmark for Interpreting Grounded Instructions for Everyday Tasks

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

ALFRED把家務型別、具體場景 / 物件 / 軌跡和語言repeat分開；成功取決於終態條件，與每步API成功、reward和示範長度加權分數不同。

> **版本與身份**
>
> 主程式同時保留原論文與後續model links；不把所有外部model repo當新benchmark。ALFWorld是同系環境的不同介面，需顯式重用關係。

領域	居家整理與清潔、餐飲與烹飪
環境	AI2-THOR室內場景與物件狀態；原生目錄tuple包含scene_num，具體軌跡還需原始初態與版本。現行README仍指THOR2.1.0資料 / 檔案。
任務	評測器分7種家務型別：直接放置、清潔後放置、加熱後放置、冷卻後放置、放兩物、持物照燈、透過可移容器放置。物件 / 場景 / 語言repeat是下層條件，不與7種直接混算。
題數與資料	traj task_id/task_type、pddl_params、plan.high_pddl/low_actions、turk_annotations.anns[repeat_idx].task_desc；模型輸出離散action與互動mask。原生trial名稱不等於本庫policy重跑trial。
評估方式	EvalTask從視覺和語言rollout，STOP / max_steps / max_fails可終止，再取get_goal_satisfied與條件滿足數。例：照燈要求持有目標且燈可見並開啟。GC全域性累加條件分母，PLW按原示範low_actions長度加權，非導航圖最短距離SPL。t=0的除法及被exception跳過的題需adapter明確處理。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **120** rooms · 原文頁 3
- **7** task types · 原文頁 3
- **2,685** task parameter combinations · 原文頁 3
- **8,055** expert demonstration episodes · 原文頁 3

- **25,743** 概述language directives · 原文頁 3
- **1,529** 表2 test-unseen directives · 原文頁 4

依這個順序讀

1. `README.md` ↗
   GitHub · askforalfred/alfred · f91f4c0c96

   原始論文、資料版本與環境依賴

   L1–53

---

2. `models/eval/eval_task.py` ↗
   GitHub · askforalfred/alfred · f91f4c0c96

   完整具體rollout評測、task/repeat身份、停止與分母

   L1–206

---

3. `env/tasks.py` ↗
   GitHub · askforalfred/alfred · f91f4c0c96

   reward與成功分離，拿物照燈的具體條件

   L75–124 · L126–155 · L237–272

---

4. `gen/utils/dataset_management_util.py` ↗
   GitHub · askforalfred/alfred · f91f4c0c96

   goal/物件/容器/scene與多trial目錄身份

   L5–51

怎麼接入我們的benchmark

可重用

7種native task類別、PDDL引數、初態 / 低層操作與終態條件、language repeats。

需要轉換

原task_id/scene/repeat_idx拆為source instance與case鍵，留示範 / 語言父子關係；原生SR/GC/PLW分開記錄，失敗和未產出題也入分母清單。

仍需補齊

完整THOR初態重播、資產版本、split與合法模型資訊、missing/error題處理和原生/共同協定對照。

P097 · TEACh

TEACh: Task-driven Embodied Agents that Chat

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

TEACh需要保留game→EDH/TfD instance的關係；兩種題目檢查不同目標。現有CLI有靜態可見的漏題 / 變數問題，不能下載後直接宣稱可評測。

> **版本與身份**
>
> 2022-12修訂只保留有助主任務的EDH狀態變化，刪無相關變化instances與2個valid_unseen game；不能混用早期paper數字與當前檔案。軟體 / 影像 / 其他資料授權分開。

領域	居家整理與清潔、餐飲與烹飪、協助、交接與陪伴
環境	AI2-THOR家務場景，Commander與Driver/Follower不同視角和角色；game可派生多個EDH或TfD片段，不能各自算新屋子。
任務	EDH依對話 / 操作歷史完成後續指定狀態改變，TfD依完整任務引數檢查終態。task definition有components、數量determiner及relations；Toast要求BreadSliced且isCooked=1。
題數與資料	game_id、instance_id、driver_actions_future、state_changes、expected_init_goal_conditions_*，輸出game含初 / 終態objects及custom_object_metadata。dialog acts是後加da_metadata；答案狀態不能當一般模型輸入。
評估方式	EDH從state_changes建checker；TfD取原task_id並套task_params。check_episode_progress合成component/relation的成功與條件數。GC分母扣除初態已滿足部分；PLW依future動作長度。cli/eval.py有未定義edh_instance_files紀錄行，且缺輸出題建立error紀錄後未加入traj_stats；需修正並保留原版差異，否則可能阻斷 / 漏計分母。這是靜態閱讀發現，未執行重現。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **109** 表2收集池rooms · 原文頁 5
- **12** task types · 原文頁 3, 5
- **438** 收集池parameter variants · 原文頁 5
- **11,176** 表3 EDH instances（全部split） · 分量相加 · 原文頁 5

- **2,270** test-unseen EDH instances · 原文頁 5

依這個順序讀

1. `README.md` ↗
   GitHub · alexa/teach · 903191e256

   精確論文、授權分件與2022資料修訂

   L1–95

---

2. `src/teach/meta_data_files/task_definitions/101__toast.json` ↗
   GitHub · alexa/teach · 903191e256

   原生component與可機器檢查的吐司條件

   L1–23

---

3. `src/teach/dataset/task_THOR.py` ↗
   GitHub · alexa/teach · 903191e256

   任務component/relation與遞迴成功聚合

   L22–48 · L1057–1197

---

4. `src/teach/eval/compute_metrics.py` ↗
   GitHub · alexa/teach · 903191e256

   EDH/TfD差異、初態未滿足條件與PLW/SR聚合

   L1–202

---

5. `src/teach/cli/eval.py` ↗
   GitHub · alexa/teach · 903191e256

   預期instance集合、步數/API失敗限制、漏題處理問題

   L23–130

怎麼接入我們的benchmark

可重用

game/instance/task引數、角色視角、歷史、state-change和task checker。

需要轉換

EDH/TfD各自protocol，case連game父來源與歷史截止；state/reference隔離；evaluator儲存初 / 終條件數、完整預期ID、失敗原因和step/API預算。

仍需補齊

資料修訂版閉合、原始重播與instance有效性、CLI修正驗證、缺輸出 / 零分母政策、原生對照跑通。

P098 · Habitat 2.0

Habitat 2.0: Training Home Assistants to Rearrange their Habitat

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

Habitat-Lab負責episode / 任務 / 評分，Habitat-Sim負責感測與物理。二者共同支援多代論文；目前HEAD不能直接代表2021的Habitat2.0原設定。

> **版本與身份**
>
> 現有README同時引用Habitat1/2/3。這次核讀指定現有commit中的具體介面，歷史2.0重現版本仍需另定；未將新增3.0能力歸給2021論文。

領域	居家整理與清潔、餐飲與烹飪
環境	Habitat2.0研究使用家居可互動重排環境；現行Sim另外支援多種掃描場景、CAD、機器人URDF與RGB-D。引擎支援的資料集列表不等於已取得或可對比的環境全集。
任務	物件重排及導航 / 抓放等子任務；具體task config和measure才決定條件。Lab的benchmark速度指令碼與模型任務成功率不可混為同一評估。
題數與資料	RearrangeEpisode包含ao_states、rigid_objs(handle,transform)、targets、markers、target/goal_receptacles與name_to_receptacle。現行from_json把episode_id重設為列序號，標準庫須保留原source檔案與record index避免ID碰撞。
評估方式	具體RearrangePickSuccess檢查持有正確物件、未違反hold constraint，且末端到rest位置距離低於配置閾值；-1可關閉rest檢查。成功定義依配置改變，不能只存measure名稱；reward、渲染FPS及task success分開。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **111** ReplicaCAD layouts · 原文頁 2
- **3** HAB long-range families · 原文頁 10, 11
- **500** Pick unseen-layout eval episodes · 原文頁 9

依這個順序讀

1. README.md ↗
   GitHub · facebookresearch/habitat-lab · 0fb6f43ffe

   原論文身份與Lab/Sim角色依賴

   L14–78

---

2. README.md ↗
   GitHub · facebookresearch/habitat-sim · 57ee4941dc

   引擎、資產與機體支援；非新增獨立任務庫

   L14–27 · L47–70

---

3. habitat-lab/habitat/datasets/rearrange/rearrange_dataset.py ↗
   GitHub · facebookresearch/habitat-lab · 0fb6f43ffe

   具體rearrangement episode欄位與讀取時ID重設

   L23–76

---

4. habitat-lab/habitat/tasks/rearrange/sub_tasks/pick_sensors.py ↗
   GitHub · facebookresearch/habitat-lab · 0fb6f43ffe

   具體pick成功條件及配置閾值

   L205–249

---

5. src_python/habitat_sim/utils/datasets_download.py ↗
   GitHub · facebookresearch/habitat-sim · 57ee4941dc

   資料UID、版本、LFS與實體資產取得狀態

   L527–539 · L727–767 · L785–825

怎麼接入我們的benchmark

可重用

episode schema、資產UID / 版本、任務配置與原生measure。

需要轉換

source拆論文/程式/資產角色，environment存scene及物件初態；case ID以來源版本＋原檔＋原索引生成；evaluator釘選實作與閾值。

仍需補齊

2021論文匹配的Lab/Sim/資產版本及完整任務配置、LFS實體資產、原生重播與共同協定接線。

P099 · HomeRobot

HomeRobot: Open-Vocabulary Mobile Manipulation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

HomeRobot的OVMM流程分找物、抓物、找容器、放置；真正overall成功還要求零robot-scene碰撞。已沿官方submodule讀到實際放置與穩定性checker。

> **版本與身份**
>
> home-robot tree把Habitat-Lab釘在b727ca9f7123101aaedb737ca9ccc1b153525dd9；本次直接讀此版checker，沒有用現行HabitatHEAD代替。README另指定home-robot-ovmm-challenge-2024 tag，與本main快照分開。

領域	居家整理與清潔
環境	真實Stretch與Habitat模擬分開；模擬依賴HSSD ovmm資產、物件、Stretch模型和episode配置。相同HSSD屋子被多工重用需按父資產鍵去重。
任務	將指定類別物件從起始容器搬到目標容器；四階段是同一長程任務進度，不自動算4道獨立題。原生episode允許多個candidate物件 / 容器。
題數與資料	OVMMEpisode記object_category/start_recep_category/goal_recep_category及candidate goal集合。wrapper讀head_rgb/depth、GPS/compass/joint及task goal；depth由[0,1]對映min/max並特判邊值；相機座標模式與GT semantic開關必須記入protocol。
評估方式	原子放置量測檢查物件與合法容器接觸、排除地板與過深穿透，父checker再檢查放開、末端回rest距離及可選的穩定步數。階段success具有歷史累積性；metrics_utils的overall_success=END.ovmm_place_success且robot_scene_colls==0，partial=(找物+抓物+找容器+overall)/4。缺失欄位在聚合時被略過，須額外儲存完整預期episode與缺值數。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **60** 實際benchmark HSSD scenes · 原文頁 5
- **10** test scenes · 原文頁 5
- **1** OVMM task family · 原文頁 5, 7
- **2,535** objects · 原文頁 5

- **20** real experiments / baseline · 原文頁 6

依這個順序讀

1. `README.md` ↗
   GitHub · facebookresearch/home-robot · ede6a67a2d

   OVMM任務與2024挑戰tag

   L10–48

---

2. `projects/habitat_ovmm/README.md` ↗
   GitHub · facebookresearch/home-robot · ede6a67a2d

   HSSD資產、episode與GT/Detic評測條件

   L10–67 · L130–163

---

3. `.gitmodules` ↗
   GitHub · facebookresearch/home-robot · ede6a67a2d

   官方依賴Habitat-Lab；tree另固定submodule commit

   L1–6

---

4. `src/home_robot_sim/home_robot_sim/env/habitat_ovmm_env/habitat_ovmm_env.py` ↗
   GitHub · facebookresearch/home-robot · ede6a67a2d

   觀測 / 深度 / 相機座標與動作轉換

   L114–181 · L220–241 · L290–398

---

5. `projects/habitat_ovmm/evaluator.py` ↗
   GitHub · facebookresearch/home-robot · ede6a67a2d

   scene_episode鍵、階段/END指標與分母

   L194–224 · L255–324

---

6. `projects/habitat_ovmm/utils/metrics_utils.py` ↗
   GitHub · facebookresearch/home-robot · ede6a67a2d

   零碰撞overall成功與四項partial平均

   L1–113

---

7. habitat-lab/habitat/datasets/ovmm/ovmm_dataset.py ↗
   GitHub · facebookresearch/habitat-lab · b727ca9f71

   OVMM categories/candidate goal與episode subset

   L27–41 · L153–204

---

8. habitat-lab/habitat/tasks/ovmm/ovmm_sensors.py ↗
   GitHub · facebookresearch/habitat-lab · b727ca9f71

   階段成功保留歷史且依賴前一階段

   L453–585

---

9. habitat-lab/habitat/tasks/ovmm/sub_tasks/place_sensors.py ↗
   GitHub · facebookresearch/habitat-lab · b727ca9f71

   接觸目標容器、穿透限制與排除地板

   L83–144

---

10. habitat-lab/habitat/tasks/rearrange/sub_tasks/place_sensors.py ↗
    GitHub · facebookresearch/habitat-lab · b727ca9f71

    放置穩定性與具體PlaceSuccess條件

    L206–347

怎麼接入我們的benchmark

可重用

物件 / 容器category、候選集合、場景episode身份、觀測/動作轉換、原子與階段checker。

需要轉換

case固定資料版本、scene_episode、機體、GT或感知模式、步數與控制比例；native放置、overall零碰撞及partial三項分開存。依賴源釘選b727ca9而非目前Habitat main。

仍需補齊

HSSD/機體/episode資產閉合、感測配置與相機內參檢查、原生感知 / 控制執行驗證、論文與2024挑戰版本對照。

P100 · BEHAVIOR-1K

BEHAVIOR-1K: A Human-Centered, Embodied AI Benchmark with 1,000 Everyday Activities and Realistic Simulation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

BEHAVIOR-1K的activity、definition、instance已在原程式分開；1,000種活動不等於1,000個已載入case。Q-score與全條件成功也有不同分母。

> **版本與身份**
>
> 本次HEAD為2026-10快照，內含新BDDL3及向量化eval；README引用2024論文。此前庫存用4b0f43d版本，兩次快照不混算已取得任務與cases。

領域	居家整理與清潔、餐飲與烹飪、衣物與洗護、辦公與教育、零售與購物、農業與園藝
環境	OmniGibson場景、物件 / 材料 / 系統、機器人與預取樣狀態；scene_model和activity_instance_id共同定位初態，不按並行num_envs增算場景種類。
任務	原生activity_name是活動，activity_definition_id選同一活動不同完成規格，activity_instance_id選預配置狀態。新增definition可能改規則；重跑rollout_id只改試驗，不增加活動數。
題數與資料	cached filename含scene_model/activity/definition/instance；evaluator逐例項寫task、instance_id、rollout_id、steps、success及metrics。可選online sampling、robot pose、asset whitelist/blacklist及task highlighting，均影響合法題目配置。
評估方式	PredicateGoal委派compiled BDDL目標檢查，各env用獨立object scope。成功Q=1；未成功時對每一備選goal，計初態不滿足而現在滿足的predicate數÷該option全部predicate數，再取最大。此分母不是初態未滿足數。timeout可依人類示範長度乘係數或明定max_steps；時間標準化需保留human stats版本。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **50** scenes · 原文頁 1, 4
- **373** rooms（包含於50scene） · 原文頁 4
- **8** 原作scene types · 原文頁 4

- **1,000** BDDL activities · 原文頁 3
- **3** 原文baseline活動 · 原文頁 6, 7

依這個順序讀

1. `README.md` ↗
   GitHub · StanfordVL/BEHAVIOR-1K · cd484e0477

   精確論文、1,000活動為作者宣告

   L1–24

---

2. `OmniGibson/omnigibson/tasks/behavior_task.py` ↗
   GitHub · StanfordVL/BEHAVIOR-1K · cd484e0477

   活動/定義/例項身份、各並行環境的predicate scope

   L65–99 · L166–181 · L201–250

---

3. `OmniGibson/omnigibson/termination_conditions/predicate_goal.py` ↗
   GitHub · StanfordVL/BEHAVIOR-1K · cd484e0477

   BDDL目標判斷與成功終止

   L1–53

---

4. `OmniGibson/omnigibson/metrics/task_metric.py` ↗
   GitHub · StanfordVL/BEHAVIOR-1K · cd484e0477

   Q-score確切分子 / 分母、時間與初態

   L1–81

---

5. `OmniGibson/omnigibson/eval/evaluator.py` ↗
   GitHub · StanfordVL/BEHAVIOR-1K · cd484e0477

   相機/超時設定、instance和rollout輸出

   L265–295 · L636–697

怎麼接入我們的benchmark

可重用

活動/definition/instance、BDDL目標、預取樣場景與細項metrics。

需要轉換

來源活動與本庫語義任務分開，environment接scene+assets，case保留definition/instance/機體/感測/初態；Q-score及success分欄並儲存初始predicate mask和備選goal。

仍需補齊

資產 / 知識庫 / BDDL / 模擬器版本閉合、全部活動定義及可執行子集清單、物理有效性與原生重播。

P101 · Embodied Agent Interface

Embodied Agent Interface: Benchmarking LLMs for Embodied Decision Making

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EAI統一四種決策模組，但BEHAVIOR與VirtualHome各有具體評分程式。目標理解的JSON錯誤處理不同，不能只因同名F1就合併成一個分數。

> **版本與身份**
>
> 原embodied-agent-eval repo現轉址embodied-agent-interface/embodied-agent-interface，屬同一倉庫身份。這次深入核對goal interpretation，其他模組僅確認介面與來源角色，未宣稱全codebase或所有模組已跑通。

領域	居家整理與清潔、餐飲與烹飪、辦公與教育
環境	重用BEHAVIOR/iGibson與VirtualHome環境 / 狀態圖。形式goal、PDDL problem或語言題不自動新增物理場景。
任務	goal interpretation、subgoal decomposition、action sequencing、transition modeling四種資訊 / 決策評測；同一底層家務任務可接受不同資訊及要求，應建立不同case protocol。
題數與資料	BEHAVIOR以demo identifier連goal conditions、objects、instruction與LLM輸出；VirtualHome以scene_id、script/file_id連狀態 / 動作目標。保留node goals/edge goals/action goals與原形式語法，不能直接flatten丟掉順序 / 備選完成方式。
評估方式	已核讀goal interpretation：BEHAVIOR精確比對conditions，對備選目標取命中最多option，累計TP/FP/FN；解析失敗代空預測。VirtualHome JSON解析失敗直接continue並記format error，幻覺物件另記錄；跨環境F1分母與失敗規則需分開。transition env.step呼叫抽象control，不能宣稱真實機器人成功。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **4** 能力modules · 原文頁 4, 5, 6
- **26** VirtualHome表2task names · 原文頁 7
- **100** BEHAVIOR100 tasks · 原文頁 7, 89
- **438** instruction instances · 338+100 · 原文頁 7

依這個順序讀

1. README.md ↗
   GitHub · embodied-agent-interface/embodied-agent-interface · 531c62f8df

   精確論文、4模組、父環境與程式改名

   L1–69 · L92–105

---

2. docs/source/modules/goal_interpretation.md ↗
   GitHub · embodied-agent-interface/embodied-agent-interface · 531c62f8df

   初態與語言到形式目標的評測約定

   L1–70

---

3. src/behavior_eval/evaluation/goal_interpretation/scripts/evaluate_results.py ↗
   GitHub · embodied-agent-interface/embodied-agent-interface · 531c62f8df

   條件精確比對、備選goal、解析錯誤與global計數

   L133–162 · L362–449 · L451–490 · L529–579

---

4. src/virtualhome_eval/evaluation/goal_interpretation/scripts/evaluate_results.py ↗
   GitHub · embodied-agent-interface/embodied-agent-interface · 531c62f8df

   VirtualHome schema、不同錯誤處理與node/edge/action分數

   L15–59 · L95–147 · L153–217 · L275–310

---

5. src/behavior_eval/transition_model/eval_env.py ↗
   GitHub · embodied-agent-interface/embodied-agent-interface · 531c62f8df

   符號 / 抽象action效果介面不等於逐步物理操作

   L133–142 · L155–157

怎麼接入我們的benchmark

可重用

原goal/schema、scene/demo/script身份、模組介面、細粒度錯誤與evaluator。

需要轉換

同一父task連多protocol case；state/可見物件名/語言與reference答案分開；保留環境特定parser、備選goal及micro計數，不扁平為通用accuracy。

仍需補齊

其餘3模組各具體checker逐一接線、原始資產、判分分母完整性、形式規劃器與物理執行的比較界線。

P102 · NavVerse

NavVerse: Benchmarking Indoor-to-Outdoor Embodied Navigation in Continuous Robot Simulation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

NavVerse提供室內、室外與連線場景的連續導航；原程式的成功距離是參考路徑近似值，collision指標是卡住代理量，不等同接觸感測。

> **版本與身份**
>
> 原PDF p1連umich-curly.github.io/NavVerse-Benchmark，與此同名組織庫和題名相符；本次固定2026-09後更新之commit，非宣稱逐項重現7月版本。

領域	公共場館與服務
環境	作者報100室內＋50室外＋50連線場景，來源USD/navmesh/scene_scale/collider設定另存。這是作者release宣告，尚非本庫已取得200個資產。
任務	ObjNav/VLN/PlaceNav三種條件導航；原episode_target_type分obj/place，instruction_type分target/vln，避免把同一終點的兩種指令視為新場景。
題數與資料	VLNEpisode含scene_id/scene_type/episode_id/path/scale/navmesh_preset、goals(instance/type/location/radius/reference_path)、start_position/start_rotation；episode_label=scene_id+episode_id。JSON讀取錯誤會continue，匯入應另列遺漏。
評估方式	距離取當前點到各reference_path點的直距＋後續路徑長，再扣目標半徑；成功需STOP且距離<1.6。SPL由該初始距離與實走長計。collision以有移動指令但pose變化<0.015判斷，collision_rate平均此代理訊號，非直接物理碰撞次數；保留原名與操作定義。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **200** 含組合的scene entries · 原文頁 3, 12
- **3** navigation task types · 原文頁 5
- **10,000** 生成episodes（全benchmark） · 4027+2973+3000 · 原文頁 5

依這個順序讀

1. `README.md` ↗
   GitHub · UMich-CURLY/NavVerse-Benchmark · 8b89bfee4f

   原作範圍、版本化場景包與episode檔分離

   L1–17 · L48–81 · L130–155

---

2. `navverse/episode.py` ↗
   GitHub · UMich-CURLY/NavVerse-Benchmark · 8b89bfee4f

   scene/episode/goal與兩種instruction schema

   L23–142

---

3. `navverse/measures.py` ↗
   GitHub · UMich-CURLY/NavVerse-Benchmark · 8b89bfee4f

   success/SPL/碰撞率的實際公式

   L1–12 · L194–265 · L291–350 · L430–462 · L546–642

---

4. `baselines/eval_navverse.py` ↗
   GitHub · UMich-CURLY/NavVerse-Benchmark · 8b89bfee4f

   split manifest驗證與隔離episode目錄

   L1400–1420

怎麼接入我們的benchmark

可重用

場景與episode schema、split manifests、語言/目標條件和native measures。

需要轉換

environment固定場景包hash+navmesh/collider；case存scene_episode+目標/指令/機體/控制模式；metric存實際距離近似、STOP及卡住判定而非僅縮寫。

仍需補齊

10,000作者報episode的全量取得 / ID完整性、各機體控制與場景有效性、物理contact及近似指標對照。

P103 · Follow-Bench

Follow-Bench: A Unified Motion Planning Benchmark for Socially-Aware Robot Person Following

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

正確的Follow-Bench是MedlarTea的機器人跟隨規劃庫；社交距離、搜尋、無碰撞分開記錄，不能混同另一個LLM指令遵循同名benchmark。

> **版本與身份**
>
> 原2025paper有2026-05v4；此repo5月建立，site仍有舊6planner與paper8planner敘述差異。ir-sim/RDA-planner為上游元件，不能當獨立新benchmark。
>
> 官方project頁的Benchmark Code按鈕仍為空href；另以完整題名、來源owner自述Hanjing YE（原第一作者）與mobile navigation/person-following身分核對MedlarTea/follow-bench。

領域	協助、交接與陪伴、個人照護、公共場館與服務、包裝、倉儲與物流
環境	內含ir-sim模擬器與socialRPF規劃器；走廊、交叉口、門口、雜物場地及動態人群。人數、寬度、障礙、跟隨距離和隨機初態是場景設定。
任務	跟隨特定人的後方或側方、失去視線後搜尋；README每設定100 seeds是原規劃，不表示本次已有100次新結果。seed改人物 / 佈局時是新instance，policy-only重跑另計trial。
題數與資料	env_basic_info.json存step_time、robot/target半徑；object_info.json實際按JSONL逐行讀count、target_visible、robot/target/obstacles/humans。robot位置為索引1:3，速度4:6，碰撞旗標6，需保留schema與單位。
評估方式	無碰撞與搜尋成功分開；連續失蹤>max_search_steps才search失敗。可見率分母max_steps，路徑按差分，zone時間按step_time累加。avg_velocity直接mean速度分量，並非速度模長；private-zone計算扣target_radius，與人群半徑異質情況須核對。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **16** scenario types · 原文頁 6
- **1** person-following family · 原文頁 6
- **100** 每configuration trials · 原文頁 7, 8

依這個順序讀

1. `README.md` ↗
   GitHub · MedlarTea/follow-bench · 202d164501

   場景、人數/寬度/跟隨條件、計量單位與上游元件

   L1–105 · L171–208

---

2. `socialRPF/example/robot_person_following/evaluate_scripts/evaluate_iso.py` ↗
   GitHub · MedlarTea/follow-bench · 202d164501

   逐步log schema、碰撞/可見率/搜尋/舒適度確切計算

   L1–162

怎麼接入我們的benchmark

可重用

佈局/人群/目標軌跡配置、原log與多項距離/舒適度/搜尋metrics。

需要轉換

case記target identity、follow位置/距離、seed、max_steps與step_time；evaluator保留碰撞與搜尋各分母，不把單一無碰撞當完成全部任務。

仍需補齊

完整場景包 / log對齊、速度與社交區域計量修訂審核、真實ROS部署repo認領、各planner同預算驗證。

P104 · SIMPLER

Evaluating Real-World Robot Manipulation Policies in Simulation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

SIMPLER是實機設定的模擬評測，不是新的實機大資料集；兩種配置為視覺匹配與變體平均。已核對子模組中的done=success及抓取歷史成功規則。

> **版本與身份**
>
> SimplerEnv main基於CPU ManiSkill2；README另連maniskill3分支。此tree的ManiSkill2_real2sim釘在ef7a4d4；不得替換為最新ManiSkill3後仍稱同設定。

領域	居家整理與清潔
環境	Google Robot與WidowX+Bridge的SAPIEN/ManiSkill2實轉模擬設定；背景overlay、紋理、光照、幹擾物等變體是設定，不自動新增語義任務。
任務	抓取、移近、抽屜開關 / 放物，以及WidowX放置 / 堆疊等；ENVIRONMENT_MAP把不同罐姿態對映同class＋引數，需保留variant關係。
題數與資料	reset options指定robot xy/quat和object xy或episode_id；模型輸出world_vector、rot_axangle、gripper、terminate_episode。控制頻率、sim_freq、相機、overlay與subtask推進全部是case協定。
評估方式	此釘選子庫get_done=info.success；外層直到模型停止或truncated，儲存最後done。抓取可按提起>1cm且無有效外部接觸，或連握5步；開啟episode_stats時曾顯著提起>2cm達5步亦可成功。另以Pearson/MMRV比較模型sim-real表現排序，不是單題完成率。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **2** real robot setups · 原文頁 6
- **8** 圖6–7主要task groups · 4+4，drawer開/關合組 · 原文頁 7, 8

依這個順序讀

1. `README.md` ↗
   GitHub · simpler-env/SimplerEnv · eddb569074

   兩種實轉模擬協定與ManiSkill2/3版本

   L1–64 · L78–100

---

2. `simpler_env/__init__.py` ↗
   GitHub · simpler-env/SimplerEnv · eddb569074

   task alias至環境/引數對映，變體不能按名稱全加

   L1–88

---

3. `simpler_env/evaluation/maniskill2_evaluator.py` ↗
   GitHub · simpler-env/SimplerEnv · eddb569074

   初態掃描、模型/控制輸出、終止與最後成功判定

   L15–219

---

4. `simpler_env/utils/metrics.py` ↗
   GitHub · simpler-env/SimplerEnv · eddb569074

   sim-real Pearson及MMRV的模型排序分母

   L134–163

---

5. `mani_skill2_real2sim/envs/sapien_env.py` ↗
   GitHub · simpler-env/ManiSkill2_real2sim · ef7a4d4fdf

   此版本terminated直接取info.success

   L547–582

---

6. `mani_skill2_real2sim/envs/custom_scenes/grasp_single_in_scene.py` ↗
   GitHub · simpler-env/ManiSkill2_real2sim · ef7a4d4fdf

   提起高度、接觸與歷史5步成功條件

   L401–461

怎麼接入我們的benchmark

可重用

真實setup對應、task alias/config、初態掃描及原生task metrics。

需要轉換

case保留視覺匹配/變體平均、variant權重、時間/動作約定；evaluator存瞬間/歷史成功旗標、subtask及固定子庫版本。sim-real correlation另為模型層聚合。

仍需補齊

完整資產、真實結果配對與不確定性、每變體分母/權重、各task具體checker接線、原生模型執行。

P105 · LIBERO-Plus

LIBERO-Plus: In-depth Robustness Analysis of Vision-Language-Action Models

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

LIBERO-Plus的10,030是擾動任務條目；實際分類JSON確有10,030筆，但大量條目共享原LIBERO任務和初態。原difficulty level保留為來源標籤。

> **版本與身份**
>
> fork替代LIBERO套件使用方式不代表資料獨立；RLDS/LeRobot連結是訓練資料表示，不能各自重複計數。當前分類筆數為檔案結構核對，未執行全部變體。

領域	居家整理與清潔、餐飲與烹飪
環境	重用LIBERO桌面，擴充物件、紋理、相機、光照、機器人初態及noise。多擾動名稱不代表不同房屋或獨立原始資料。
任務	7擾動維度；分類檔結構計數：spatial2,402、object2,518、goal2,591、libero_10為2,519，合10,030。這是native variant entries，不是本庫10,030去重語義目標。
題數與資料	Task保留name/language/problem_folder/bddl_file/init_states_file；getter依_language_/_view_/_table_/_light_等字樣回取共同或專屬初態。分類JSON的id基準與API task index需明確對映。
評估方式	具體_check_success逐一AND goal_state predicate；rollout在max_steps內累積done成功。README要求num_trials_per_task由50改1，是該擾動協定，不等同所有來源都一試可充分估計成功率。difficulty_level為作者擾動級別，尚非跨benchmark校準難度。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **10,030** 擾動task settings · 原文頁 8
- **7** 擾動factors · 原文頁 2, 8
- **21** 擾動components · 原文頁 8

依這個順序讀

1. `README.md` ↗
   GitHub · sylvestf/LIBERO-plus · 4976dc3002

   精確來源、7擾動維度、外部資產與每變體1trial建議

   L1–43 · L67–91

---

2. `libero/libero/benchmark/task_classification.json` ↗
   GitHub · sylvestf/LIBERO-plus · 4976dc3002

   抽讀id/name/category/difficulty_level；全量筆數僅結構計數，不宣稱每筆人工語義核對

   JSON /libero_spatial/0 · JSON /libero_spatial/1

---

3. `libero/libero/benchmark/__init__.py` ↗
   GitHub · sylvestf/LIBERO-plus · 4976dc3002

   Task欄位、語言重寫與變體如何共用init-state

   L37–96 · L154–245

---

4. `libero/libero/envs/problems/libero_tabletop_manipulation.py` ↗
   GitHub · sylvestf/LIBERO-plus · 4976dc3002

   具體成功為全部goal predicate合取

   L253–273

---

5. `libero/lifelong/evaluate.py` ↗
   GitHub · sylvestf/LIBERO-plus · 4976dc3002

   done成功累積與預算 / 分母

   L261–288

怎麼接入我們的benchmark

可重用

10,030原生分類條目、7維度與level、BDDL/語言和init-state來源。

需要轉換

保留base-task→perturbation variant→case關係，normalization不丟variant；level存native_difficulty，原假設 / 配置 / seed與規則差異可追。

仍需補齊

10,030條目逐筆asset/init-state閉合、語言/variant語義等價審核、外部training資料取得與分母 / CI。

P106 · MetaWorld+

Meta-World+: An Improved, Standardized, RL Benchmark

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

現行Meta-World README直接引用2505.11289，與MetaWorld+相符。重點是固定觀測、動作、成功終止和meta適應預算，而不是把新實驗版本計成另一份獨立任務庫。

> **版本與身份**
>
> 部分舊state-space說明與現行程式不一致；不得以9D舊描述生成本版schema。

領域	居家整理與清潔、餐飲與烹飪、工藝與修繕、裝配與生產作業、休閒與運動、通用物件與機動作業
環境	與Meta-World來源共用Sawyer/MuJoCo任務體系；保留版本重用關係。
任務	50個任務可組成MT1/10/50與ML1/10/45。train任務、test任務與goal variations需要各自保留單位。
題數與資料	實際程式使用39維基礎觀測與4維控制；多工觀測可附task ID，目標是否可見取決於約定。
評估方式	成功率依完成的episode和info.success統計；meta適應資料與最終評測episode分開，預算是可比較性的必要條件。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **50** 沿用的task types · 原文頁 4
- **25** 新增中型suite訓練task量 · 原文頁 7, 16
- **50** MT每task eval episodes · 原文頁 5

依這個順序讀

1. `README.md` ↗
   GitHub · Farama-Foundation/Metaworld · c0dafaf155

   確認論文身份、MT/ML用途與現行API。

   L1–55

---

2. `metaworld/sawyer_xyz_env.py` ↗
   GitHub · Farama-Foundation/Metaworld · c0dafaf155

   核對動作縮放、觀測stack與遮蔽goal。

   L320–336 · L475–527

---

3. `metaworld/envs/sawyer_drawer_open_v3.py` ↗
   GitHub · Farama-Foundation/Metaworld · c0dafaf155

   對照獨立success訊號與reward版本。

   L66–88 · L115–188

---

4. `metaworld/evaluation.py` ↗
   GitHub · Farama-Foundation/Metaworld · c0dafaf155

   看正式計分、task平均和meta適應/測試分離。

   L48–103 · L106–169

怎麼接入我們的benchmark

可重用

原生evaluation.py、task清單、versioned reset和success判定。

需要轉換

與P063記為同一程式來源的版本關係；task identity、goal instance及trial分開，保留動作縮放與可見資訊。

仍需補齊

共同跨來源語義去重、素材閉合與新benchmark協定下的baseline。

P107 · COLOSSEUM

THE COLOSSEUM: A Benchmark for Evaluating Generalization for Robotic Manipulation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

Colosseum在20個RLBench任務上加入擾動；變體產生、示範seed及RVT評測在不同檔案 / 倉庫。RVT所稱success rate來自100倍縮放的成功reward。

> **版本與身份**
>
> scene程式用函式引數數量相容upstream/PerAct RLBench；安裝可成功不代表兩版本物理 / 評分完全一致。RVT repo沿用RVT README，身份由Colosseum官方README明確連結確認。

領域	居家整理與清潔、通用物件與機動作業
環境	RLBench/PyRep/CoppeliaSim TTM場景；scene載入自定義TTM並在episode / step套變體。原README20任務×14因素不可直接當280獨立場景 / 新語義任務。
任務	源任務＋物件/桌面/背景/相機/光照/物理引數等擾動。例CloseBox只有1原生task variation、4句說明，成功登記JointCondition(box_joint,2.6)，依固定RLBench版本判。
題數與資料	factor含variation/name/enabled/targets及引數；demo儲存NumPy random state，可依指定demo index恢復。正式示範在外部tar，未取得，例項必須帶variant配置與資產版本。
評估方式	官方連結RVT runner以指定demo初態評測，例預設25episodes和25控制步，使用規劃式末端姿態＋離散gripper。wrapper將原task reward>=1的成功縮放100；IK/path/invalid-action錯誤給0並終止。CSV success rate取eval_envs/return，需保留0–100尺度與實際完成 / 缺題數。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **20** base tasks · 原文頁 4
- **14** perturbation factors · 原文頁 4
- **20,371** 生成task instances · 原文頁 4
- **5,875** 主protocol eval episodes · 235×25 · 原文頁 7

依這個順序讀

1. `README.md` ↗
   GitHub · robot-colosseum/robot-colosseum · 098a910ae1

   原論文、20任務/14變化因子、原生RVT評測repo

   L1–54

---

2. `colosseum/rlbench/tasks/close_box.py` ↗
   GitHub · robot-colosseum/robot-colosseum · 098a910ae1

   具體JointCondition成功predicate和語言變體

   L1–32

---

3. `colosseum/variations/manager.py` ↗
   GitHub · robot-colosseum/robot-colosseum · 098a910ae1

   factor enable/targets及reset/step時套用

   L29–104

---

4. `colosseum/rlbench/extensions/scene.py` ↗
   GitHub · robot-colosseum/robot-colosseum · 098a910ae1

   TTM資產與變體生命週期、RLBench fork相容性

   L66–120

---

5. `colosseum/rlbench/extensions/task_environment.py` ↗
   GitHub · robot-colosseum/robot-colosseum · 098a910ae1

   demo NumPy狀態儲存與重設

   L59–85

---

6. `rvt/eval.py` ↗
   GitHub · robot-colosseum/rvt_colosseum · 3cd92a3f01

   25episodes/25step預設、示範初態及CSV聚合

   L194–218 · L295–362

---

7. `rvt/utils/custom_rlbench_env.py` ↗

   GitHub · robot-colosseum/rvt_colosseum · 3cd92a3f01

   reward_scale=100、動作錯誤處理、demo reset與variation

   `L219–219 · L328–350 · L377–406`

怎麼接入我們的benchmark

可重用

20task定義、factor schema、TTM/示範seed、原生成功條件與RVT評測入口。

需要轉換

task連RLBench父任務，case固定factor值/啟用時間/初態/控制預算；evaluator儲存成功布林、100倍報分和錯誤分母，重複來源不增語義任務。

仍需補齊

RLBench/PyRep/fork精確依賴閉合、所有factor資產與demo取得、YARR聚合環節和同預算原生跑通。

P108 · RoboArena

RoboArena: Distributed Real-World Evaluation of Generalist Robot Policies

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

RoboArena主庫是遠端policy介面，志工client收集實機A/B偏好與部分成功。它是跨站實機評測流程，不是固定題庫自動判分器。

> **版本與身份**
>
> 主庫與志工client分開固定commit；後者owner名與原第一作者Pranav Atreya相符且明示RoboArena志工用途。未執行其服務登入、上傳或機器人指令。

領域	居家整理與清潔、餐飲與烹飪
環境	DROID真實機器人各站點、相機和桌面設定；evaluation session記錄現場任務及A/B兩次rollout。自願站點數、機體、任務及試驗各是不同單位。
任務	現場人員先輸入任務，再分配A/B policies；人工重設同一初態，兩者是成對試驗，不是兩種任務。另連sim-evals是提交前模擬檢查。
題數與資料	policy obs有wrist/exterior RGB、7joint/6cartesian/1gripper state與prompt；actions為N×8或N×7且整chunk執行。client存逐步state/action NPZ、3視角影片、session/command、partial/binary success及valid標記；控頻約15Hz但影片編碼10fps，媒體時間需對齊。
評估方式	人員給0–100部分分數後除100，只有==1才binary成功；另給A/B/tie偏好、長文字和session有效性。主庫沒有本機全域性排名scorer，中央服務未訪問；須保留人評protocol和成對初態 / 有效性，不能以主觀partial當物理predicate。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **7** 參與機構（非scene） · 原文頁 1
- **4,284** 跨7policies的實測rollouts · 原文頁 8

依這個順序讀

1. README.md ↗
   GitHub · robo-arena/roboarena · a07f93db00

   原benchmark、policy服務與DROID/模擬測試角色

   L1–72

---

2. roboarena/policy.py ↗
   GitHub · robo-arena/roboarena · a07f93db00

   觀測欄位、action chunk和session reset

   L7–30

---

3. roboarena/policy_server.py ↗
   GitHub · robo-arena/roboarena · a07f93db00

   相機需求、控制space及服務schema

   L12–48

---

4. README.md ↗
   GitHub · pranavatreya/roboarena_evaluator · 5992b26f91

   志工client的A/B偏好 / 部分分數 / 有效session流程

   L1–9 · L60–75

---

5. evaluation_client/main.py ↗
   GitHub · pranavatreya/roboarena_evaluator · 5992b26f91

   15Hz控制、部分分數轉binary、媒體 / NPZ回傳及人工reset

   L385–465 · L474–552 · L552–586

怎麼接入我們的benchmark

可重用

policy介面、感測 / action chunk需求、A/B session設計、人評與逐步證據schema。

需要轉換

environment記站點/配置，case記任務與reset證據；trial按session×policy獨立存，pairwise preference作比較記錄。去識別人員資訊，公開報表保留站點分組與有效性。

仍需補齊

中央排名演算法與完整資料存取、人工rubric一致性、各站機體/時間校準、實體任務初態對等及完整分母。

P109 · REFLECT / RoboFail

REFLECT: Summarizing Robot Experiences for Failure Explanation and Correction

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

REFLECT/RoboFail公開失敗設定、歷史摘要與修正執行流程；LLM對子目標的Yes判斷和修正後的模擬狀態成功是兩種不同證據。

> **版本與身份**
>
> 原columbia-ai-robotics/reflect已轉址real-stanford/reflect，屬同一來源。README含舊commit示例連結；本筆固定c2f9db9，未執行LLM或模擬器。

領域	居家整理與清潔、餐飲與烹飪
環境	AI2-THOR FloorPlan場景和另附真實感測資料；RGB-D、聲音、robot state形成scene graph，GT detection與感知模型模式需區分。
任務	失敗原因 / 時刻辨識、執行錯誤與規劃錯誤、生成恢復計畫及執行檢查。tasks.json的scenario會共用task_idx，但failure設定 / 原計畫不同。
題數與資料	name/task_idx/scene/actions/success_condition、chosen_failure/params、gt_failure_reason/step；GT時間可能字串或list，轉換需原video_fps。events/step_i.pickle與nav_actions/interact_actions及L1/L2摘要有共同時間關係。
評估方式	run_reasoning以ans.split(", ")[0]=="Yes"解析子目標，輸出prediction和GT並列於reasoning.json，GT不可迴流模型。修正後另用check_task_success讀THOR物件狀態；例如task_idx=5檢查乾淨mug裝有coffee，未檢查countertop位置。原checker並非完整自然語言目標所有條件，自建規則須另版，不覆寫原分數。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **10** simulation task types · 原文頁 5
- **11** real task types · 原文頁 5
- **100** simulation failure cases · 原文頁 5
- **30** real failure demonstrations · 原文頁 5

依這個順序讀

1. `README.md` ↗

   GitHub · real-stanford/reflect · c2f9db993e

   原論文、sim/real資料與模組角色

   L1–51

---

2. `main/tasks.json` ↗

   GitHub · real-stanford/reflect · c2f9db993e

   兩個具體task/scene/失敗注入/GT時間與目標schema

   L1–61

---

3. `main/data.py` ↗

   GitHub · real-stanford/reflect · c2f9db993e

   逐事件pickle與nav/interact動作索引

   L1–35

---

4. `main/exp.py` ↗

   GitHub · real-stanford/reflect · c2f9db993e

   子目標/計畫失敗推理、輸出解析及修正計畫生成

   L238–347 · L350–395

---

5. `main/execute_replan.py` ↗

   GitHub · real-stanford/reflect · c2f9db993e

   執行修正動作後實際呼叫task checker

   L13–29 · L194–200

---

6. `main/utils.py` ↗

   GitHub · real-stanford/reflect · c2f9db993e

   時間字串轉換、10個task index的具體終態檢查

   L269–355

怎麼接入我們的benchmark

可重用

scenario/parent task、失敗注入、感測時間鏈、原子actions及實體狀態checker。

需要轉換

同一case分診斷/恢復protocol，隔離GT原因與時間；保留parser、LLM版本、history截止、預算及原checker範圍，新加目標條件以derived-rule標記。

仍需補齊

全量感測資產與物件對映、GT/感知模式公平性、文字診斷一致性、任務自然語言與程式predicate差異審核。

P110 · AHA

AHA: A Vision-Language-Model for Detecting and Reasoning Over Failures in Robotic Manipulation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

AHA公開failure生成及失敗問答評測；Yes/No指令碼把正確率稱為F1，LLM fuzzy評分則會略過無有效裁判輸出的題。共同報表需要保留實際公式與分母。

> **版本與身份**
>
> 固定ICLR2025公開碼；README依賴PerAct RLBench並含fork更新，不將其視為與所有RLBench版本相同。只核對生成來源及評分核心，未生成資料或呼叫裁判。

領域	居家整理與清潔
環境	RLBench/FailGen產生的機器人失敗片段，另重用REFLECT等test來源；示例是時間格狀拼圖，不是額外可操控場景。
任務	判斷子任務成功與解釋失敗原因；下游恢復應用另有執行protocol，問答分數本身不等於恢復成功。
題數與資料	GT JSON含字串id、image和human/gpt conversations；Yes/No預測為JSONL整數question_id與text。樣本格圖包含時間順序與未來空白格說明；source video/frame範圍需追回父資料。
評估方式	Yes/No程式取逗點前小寫答案，(yes正確+no正確)/indx_num為accuracy而非標準F1；預設indx_num不能當全資料實數。fuzzy用claude-3-haiku-20240307，解析correct/partially/incorrect→1/.5/0，按列序配對且只對有效裁判分數平均；須儲存ID、invalid count和裁判回執。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **7** failure modes · 原文頁 5
- **11,000** held-out RLBench failure QA（約數） · 原文頁 8
- **130** ManiSkill-Fail pairs · 原文頁 8
- **49,000** failure training pairs（約數） · 原文頁 5

依這個順序讀

1. README.md ↗
   GitHub · NVlabs/AHA · 0d39c05915

   精確論文與RLBench/FailGen來源

   L1–75

---

2. aha/evaluation/REFLECT_test.json ↗
   GitHub · NVlabs/AHA · 0d39c05915

   選讀一筆id/image/conversations與failure問答樣本

   JSON /0

---

3. aha/evaluation/eval_metrics/check_answer_Yes_No.py ↗
   GitHub · NVlabs/AHA · 0d39c05915

   字串ID對整數question_id、逗點前答案及實際accuracy公式

   L20–55 · L89–123

---

4. aha/evaluation/eval_metrics/LLM_fuzzy.py ↗
   GitHub · NVlabs/AHA · 0d39c05915

   模型裁判提示 / 版本、0/0.5/1解析與有效樣本平均

   L27–76 · L78–112

怎麼接入我們的benchmark

可重用

問答schema、父benchmark標記、二元 / 文字理由分開評測、原parser。

需要轉換

case以父影片+子任務+時間窗+prompt建鍵；GT/預測用ID對齊，不僅等長zip。evaluator儲存原稱F1與實際accuracy別名、fuzzy模型/提示/解析和完整分母。

仍需補齊

全量影像和time-window對映、FailGen設定/資料split閉合、裁判一致性與invalid處理、下游物理恢復證據。

P111 · RoboReward

RoboReward: General-Purpose Vision-Language Reward Models for Robotics

檔案 / 網站 · 主來源 · 原作 · 獨立頁面

已找到並核讀HELM中的RoboReward官方入口，以及其連出的資料卡；目前確認的是排行榜網站與資料格式，未確認專用訓練 / 評測後端實作。

> **版本與身份**
>
> HELM main的固定commit可查到對應2601.00675前端；未將整個HELM通用後端宣稱為RoboReward專用評測程式。資料卡引用v0.0.1排行榜，latest與固定版本要分開。

領域	居家整理與清潔
環境	OXE和RoboArena的真實機器人rollout影片；源自多機體 / 場景，獎勵配對不能當新增物理軌跡或環境。
任務	看task instruction＋rollout video預測1–5結束進度；反事實指令和時間截短產生不同評分題，但保留同一父影片關係。
題數與資料	官方資料卡列video/task/reward/gpt5_mini_check；train45,072、val6,232、test2,831，合54,135配對（作者資料卡數字，未全量下載）。自動檢查輸出是標籤審核證據，不能作模型輸入；test另由人驗證。
評估方式	原文主指標為progress MAE並按來源群組聚合。HELM前端只渲染MiniLeaderboard與連結，不能當本地scorer；資料卡指出五級rubric，但本次未取得完整原生評分後端 / 輸出解析和group aggregation程式。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **2,831** 人工驗證RoboRewardBench test pairs · 原文頁 3, 27
- **45,072** train episode-reward pairs · 原文頁 8
- **6,232** validation pairs · 原文頁 8
- **54,135** 全部split pairs · 原文頁 22

依這個順序讀

1. `helm-frontend/src/components/Landing/RoboRewardLanding.tsx` ↗

   GitHub · stanford-crfm/helm · 63754d05db

   精確arXiv、HF資料/模型與排行榜連結；此檔是前端展示

   L1–101

怎麼接入我們的benchmark

可重用

官方資料卡schema、五級分數、train/val/test口徑、OXE/RoboArena來源鏈。

需要轉換

case以video＋instruction＋截短視窗識別；同一父episode的反事實 / 截短放在同split lineage群。reward/reference和審核訊號隔離；evaluator維持MAE與群組分母。

仍需補齊

全量影片 / 原始episode ID對映、官方scorer實作、模型輸出解析、生成 / 人工審核紀錄和語義去重。

P112 · EgoOops

EgoOops: A Dataset for Mistake Action Detection from Egocentric Videos referring to Procedural Texts

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoOops官方庫公開程式 / 影片 / 錯誤標註；檔案5種task key對應論文4類活動。實際instruction有-1特殊值，不能照README的零基索引直接取句子。

> **版本與身份**
>
> 官方README明示資料task名稱與paper不同；annotations快照和外部影片ZIP版本需雙重固定。

領域	工藝與修繕、裝配與生產作業、實驗室操作
環境	第一人稱程式活動影片，包括化學演示、紙板製作、電路和積木；task key/QR物件不是可執行機器人場景。
任務	程式文字對齊與錯誤動作偵測/解釋。blacklight與ion都對映論文IR活動；6個mistake labels包括修正動作，不能一律當物理失敗。
題數與資料	已取得metadata結構計數50video紀錄、538segments、5個procedure key。segment有秒制startTime/endTime、instruction、labels/caption；[]和空caption表示正確步。實際有instruction=-1，應保留特殊值而非Python負索引。全量只結構掃描，未逐段人工驗證。
評估方式	此倉庫是annotations/metadata，未包含官方模型scorer或可用split定義；原文評分需另接入。538標註片段不是538道已驗證測試題，影片資產與合法觀測尚未閉合。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **5** 程式tasks · 原文頁 3
- **6** 錯誤taxonomy型別 · 原文頁 3
- **50** videos · 原文頁 4
- **538** segments · 原文頁 4
- **95** 標註execution mistakes（全庫） · 原文頁 4

依這個順序讀

1. `README.md` ↗
   GitHub · Y-Haneji/EgoOops-annotations · ec0746d4dd

   標註schema、影片來源與資料/論文名稱對映

   L1–72

---

2. `meta/metadata.json` ↗
   GitHub · Y-Haneji/EgoOops-annotations · ec0746d4dd

   完整首例與一筆-1錯誤片段、程式文本；全量只做結構計數

   `L1–80 · JSON /videos/1/segments/4 · JSON /instructions/cardboard/0`

---

3. `meta/mistake_classes.json` ↗
   GitHub · Y-Haneji/EgoOops-annotations · ec0746d4dd

   6個原生mistake label類別

   L1–8

---

4. `meta/microqr/blacklight.json` ↗
   GitHub · Y-Haneji/EgoOops-annotations · ec0746d4dd

   同一程式內QR物件編號對映

   L1–16

怎麼接入我們的benchmark

可重用

影片/task/segment身份、秒制時間、程式文本、multi-label與QR物件對映。

需要轉換

保留原5task keys並連論文4活動名稱；case連video/time/instruction，-1轉明確特殊狀態而不丟原值；錯誤/修正/正確和字幕各保留。

仍需補齊

影片取得、participant/split清單、-1語義正式確認、原文scorer與原生評測再現。

P113 · REPAIR-Bench

REPAIR-Bench: A Benchmark for Robot Error Perception And Interaction Recovery

實作尚未確認 · 主來源 · 原作 · 獨立頁面

已核對REPAIR-Bench原作與有界GitHub搜尋；目前未確認此篇的官方程式庫。同名軟體修復benchmarks不屬於這篇HRI研究。

> **版本與身份**
>
> 固定2606.29937v1 PDF與既有原文閱讀紀錄。搜尋未確認不代表作者永遠沒有code；不把GitHub軟體RepairBench套上這篇。

領域	醫療與手術支援、協助、交接與陪伴
環境	原文是實驗室 / 醫院的crash-cart取物引導互動，重用RFM-HRI人類反應資料；不是可操作整套醫院任務的模擬環境。
任務	三種端點：失敗時刻定位、失敗型別分類、使用者偏好的恢復策略；人類偏好預測不同於機器人實際恢復成功。
題數與資料	原作來源214互動/41人；排除後分析184互動/38人，含面部AU、頭姿、語音 / 文字與問卷。native code schema未核實，不能把論文欄位描述當可直接匯入的檔案規格。
評估方式	原文有時序定位誤差 / tIoU F1、分類F1及恢復Hit/precision/recall/F1@k。視覺與文字端點split不同；濾波等前處理敘述尚需程式釐清。未執行scorer。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **3** 評測端點 · 原文頁 1, 2
- **214** 來源interaction trials · 原文頁 2
- **184** 過濾後usable trials（含各split） · 原文頁 3, 4

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

原文三種端點、排除規則、participant/session來源鏈與人類偏好標籤設計。

需要轉換

資料取得後以participant→interaction→temporal case編號；各端點保留資訊 / 時間截止及split，恢復偏好標明human label而非physical success。

仍需補齊

官方實作 / 資料檔schema、184筆分析subset清單、前處理及端點split、GT時間與偏好對映。

P114 · RobotArena infinity

RobotArena ∞: Scalable Robot Benchmarking via Real-to-Sim Translation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

RobotArena∞公開Genesis測試與GVL裁判流程，但自動場景生成仍列未發布。實際GVL入口使用影像加NPZ特權狀態，不是單純影片問答。

> **版本與身份**
>
> 固定預設branch fix/stable_version_genesis；README的Preview措辭與bash實際gemini-2.5-pro引數不同，需以執行manifest為準。未呼叫Gemini。

領域	居家整理與清潔
環境	真實畫面轉成Genesis Robot Arenas；預設 / 生成scene及背景、相機、物件位置擾動。∞指生成擴充套件能力，不是無限個已取得環境；README自動生成碼未勾選發布。
任務	指定語言的操作目標在多擾動設定下評測。支援多個policy server是方法介面，不能按policy數擴大任務量。
題數與資料	預設測試65步含5步預熱，存5fps MP4和同名NPZ；world/base是末端pos/quat/gripper，物件是13維pos/quat/linear/angular velocity。可加入weld抓持約束，須記assistance模式。
評估方式	GVL入口以Gemini影像＋NPZ狀態評0–100進度，可做no_object/no_robot/none ablation；接觸文字由5cm距離啟發式推估。分數regex抓整數後clip，解析/API失敗可漏frame。聚合對repeat取逐frame median，再取最高30%等；avg_last_10實際取最後num_top幀，不固定10。需固定frame身份與完整分母。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **70** BridgeSim環境 · 原文頁 9, 25
- **8,749** BridgeSim人類pairwise comparisons · 原文頁 8, 25

依這個順序讀

1. README.md ↗
   GitHub · offjangir/RobotArena · 31ae600006

   精確來源、擾動與原生發行範圍

   L1–40 · L400–465 · L557–585 · L605–617

---

2. bash_scripts/GVL.bash ↗
   GitHub · offjangir/RobotArena · 31ae600006

   真實入口GVL_multithreaded和模型/重複設定

   L6–8 · L10–16

---

3. src/pipeline/default_test.py ↗
   GitHub · offjangir/RobotArena · 31ae600006

   動作與場景軌跡儲存、預熱及焊接輔助

   L417–450 · L497–516

---

4. src/pipeline/GVL_multithreaded.py ↗
   GitHub · offjangir/RobotArena · 31ae600006

   裁判輸入、狀態/接觸近似、取樣/解析與缺值

   L27–88 · L465–548 · L623–755

---

5. src/pipeline/GVL_metrics.py ↗
   GitHub · offjangir/RobotArena · 31ae600006

   跨裁判repeat中位數、top30%與尾段聚合

   L1–122

怎麼接入我們的benchmark

可重用

scene/variant配置、成對MP4/NPZ、policy介面、明確裁判提示與聚合碼。

需要轉換

case固定原真實來源、生成版本、scene/擾動/輔助抓持；judge輸入與policy輸入分開，記模型版本/ablation/取樣/每frame回執和native聚合公式。

仍需補齊

自動場景生成release、全部資產與原生匹配、實體成功checker對照、裁判一致性/漏frame處理及完整可重跑protocol。

P115 · RoboMME-Interference

RoboMME-Interference: Benchmarking Robot Memory Under Interference

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

RoboMME-Interference在既有RoboMME任務上新增跨session幹擾規則；已取得並結構核對25,200列發布結果，這些是多方法rollouts，不是25,200種任務。

> **版本與身份**
>
> 此repo主要提供cross-session分析與檢索擴充，README重現指令能重算發布CSV圖表，不代表重新跑25,200個機器人試驗。

領域	通用物件與機動作業、裝配與生產作業
環境	重用RoboMME場景與任務；lesson session、k個幹擾session、query是歷史條件，不是增加k個新的場景種類。
任務	9native任務家族，no-history/k0/k1/k3/k7；同一query跨memory系統重跑屬trial比較。原作者easy/medium/hard另為來源標籤。
題數與資料	CSV已結構計數25,200rows，含variant/family/split/episode/seed/difficulty/condition/success/status、buffer構成與latency欄位；前2例latency等欄位為空。取得結果CSV不等於取得每次影像 / 狀態或獨立驗證執行。
評估方式	analysis以字串true轉success_bool，按variant/condition及family分組計分母與Wilson CI。視覺gate利用lesson_span/filler真實邊界校準閾值，再以query相似度選segment；校準集合須和最終test分開，purity/coverage是檢索品質，不是物理成功。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **9** 適用的原task families · 原文頁 2, 3
- **450** 基底test episodes · 9×50 · 原文頁 4
- **25,200** 核心grid policy rollouts · 450×(11×5+1)，由協定推算 · 原文頁 3, 4

依這個順序讀

1. `README.md` ↗
   GitHub · SoumilRathi/robomme-interference · 3536f63bbd

   父benchmark、9家族/5條件/方法網格及重現範圍

   L1–24 · L58–90

---

2. `results/canonical_rollouts.csv` ↗
   GitHub · SoumilRathi/robomme-interference · 3536f63bbd

   只讀表頭與前2列；全量25,200列做結構計數

   L1–3

---

3. `scripts/analyze_cross_session_results.py` ↗
   GitHub · SoumilRathi/robomme-interference · 3536f63bbd

   success字串處理、groupby分母與Wilson區間

   L98–128 · L147–192

---

4. `retrieval/robomme_visual_gate.py` ↗
   GitHub · SoumilRathi/robomme-interference · 3536f63bbd

   檢索分段、threshold校準與purity/coverage gate

   L1–96

怎麼接入我們的benchmark

可重用

query/lesson/distractor protocol、發布結果表與原生聚合、檢索選框證據。

需要轉換

case固定query父episode、歷史session有序列表、memory budget與k；trial才連variant/result。原task來源仍是RoboMME，不重算為獨立新任務庫。

仍需補齊

底層RoboMME環境/政策版本與可執行資產、歷史影像/embedding、校準split證據、相同query配對不確定性及完整執行回執。

P116 · OopsieVerse

OopsieVerse: A Safety Benchmark with Damage-Aware Simulation for Robot Manipulation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

OopsieVerse把機體 / 物件損傷追蹤加到既有模擬器；任務成功和健康值是兩條評分線。已核對thermal公式、health累積及觀測 / HDF5對映。

> **版本與身份**
>
> 固定2026-10公開碼；本次深入熱損傷及共同health流程，未宣稱所有損傷機制、全部任務或真實安全效能已驗證。

領域	居家整理與清潔、餐飲與烹飪
環境	BEHAVIOR-1K/OmniGibson及RoboCasa/RoboSuite父環境＋damageable物件 / 機體部件；損傷模型擴充不自動產生新的生活場域。
任務	完成原操作目標並控制損傷；需要記錄允許的damage條件、閾值及破壞後能力改變。各任務具體completion function仍由其配置提供。
題數與資料	obs.health為float32部件向量；info.damage_info分object/part/evaluator，HDF5 attr health_list_link_names固定向量對映，另存task_completion/reward。health是真實可見感測或僅sim特權訊號需在protocol宣告。
評估方式	各part由100開始，每次update扣各evaluator damage並下界0，object health取最小part。thermal超出閾值按scale×溫差且cap100；OG取Temperature，讀取失敗回0。step有init_skip_steps和可覆寫reward_fn；計量必須固定步頻/暖機/scale，損傷分數是模擬模型輸出。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **21** unique task designs · 原文頁 5
- **32** 跨simulator task instantiations · 原文頁 5
- **90** 5task demos · 原文頁 5
- **30** IL每task評測rollouts · 原文頁 7

依這個順序讀

1. `README.md` ↗
   GitHub · UT-Austin-RobIn/oopsieverse · a739f99e94

   精確論文與BEHAVIOR/RoboCasa/RoboSuite父來源

   L9–38

---

2. `damagesim/core/damageable_env.py` ↗
   GitHub · UT-Austin-RobIn/oopsieverse · a739f99e94

   damage啟用/鎖定、health觀測欄位

   L43–77 · L240–269

---

3. `damagesim/core/damageable_mixin.py` ↗
   GitHub · UT-Austin-RobIn/oopsieverse · a739f99e94

   初始100、各part累積扣損與最小part健康

   L69–99 · L129–174

---

4. `damagesim/core/evaluators/thermal.py` ↗
   GitHub · UT-Austin-RobIn/oopsieverse · a739f99e94

   過熱/過冷損傷確切公式

   L24–75

---

5. `damagesim/omnigibson/evaluators/thermal.py` ↗
   GitHub · UT-Austin-RobIn/oopsieverse · a739f99e94

   具體OG Temperature讀取及缺值行為

   L1–60

---

6. `damagesim/omnigibson/damageable_env.py` ↗
   GitHub · UT-Austin-RobIn/oopsieverse · a739f99e94

   step與damage更新、task completion、序列化健康部件索引

   L233–290 · L437–472 · L1087–1125

怎麼接入我們的benchmark

可重用

父task＋damage配置、各part健康與細項診斷、HDF5部件字典。

需要轉換

case固定機體/材料/損傷引數/步頻/初始health與合法觀測；evaluator分task completion、damage trajectory、約束違反，原先無損傷與擴充協定分版。

仍需補齊

全任務completion predicates與assets對齊、機械/電氣子模型逐項接線、步頻與真實損傷校準、回放T/T+1及狀態閉合驗證。

P117 · UMI

Universal Manipulation Interface: In-The-Wild Robot Teaching Without In-The-Wild Robots

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

UMI是示範蒐集與跨機體部署介面。需要分開原始影片/SLAM、重播buffer、訓練pose表達和實際控制；README的SLAM可用比例不是任務成功率。

> **版本與身份**
>
> 固定d095ba9；code另重用Diffusion Policy與ORB_SLAM3，不把內含的其他task示例當新UMI獨立資料。只核讀核心轉換與控制修正，未執行硬體。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	野外手持gripper/相機蒐集與實機部署兩種場景；有左右gripper及非gripper相機，frame serial/場景和episode需保留關係。
任務	UMI可蒐集多種操作示範並訓練Diffusion Policy；示範source與下游robot task不同層，SLAM成功不能替代物理任務成功判斷。
題數與資料	dataset_plan.pkl含grippers/tcp_pose/gripper_width/demo_start/end_pose及cameras/video_path/video_start_end。轉成Zarr robotN_eef_pos/rot_axis_angle/width。訓練把原每手7D轉成pos3+rot6+gripper1；mat_to_pose10d本身是9D，不能從函式名猜10D。
評估方式	已讀部署端有桌面高度與雙臂球碰撞姿態修正，屬控制輔助；未核得通用跨任務自動成功checker。資料讀取保留每key的horizon/latency_steps/down_sample；當前action轉換實際用obs_pose_repr，即使另有action_pose_repr設定也需驗證。

依這個順序讀

1. `README.md` ↗

   GitHub · real-stanford/universal_manipulation_interface · d095ba9590

   原始論文、SLAM與資料轉換鏈

   L1–24 · L47–87

2. `scripts_slam_pipeline/07_generate_replay_buffer.py` ↗
   GitHub · real-stanford/universal_manipulation_interface · d095ba9590

   dataset_plan、每gripper姿態與多相機frame對齊

   L75–145

---

3. `diffusion_policy/dataset/umi_dataset.py` ↗
   GitHub · real-stanford/universal_manipulation_interface · d095ba9590

   各觀測/動作的horizon/latency/downsample與座標表示

   L30–44 · L91–125 · L334–372

---

4. `umi/common/pose_util.py` ↗
   GitHub · real-stanford/universal_manipulation_interface · d095ba9590

   rotvec、旋轉6D以及pose10d函式實際輸出

   L17–44 · L86–115

---

5. `eval_real.py` ↗
   GitHub · real-stanford/universal_manipulation_interface · d095ba9590

   部署端桌面和雙臂碰撞修正屬於控制介入

   L64–106

怎麼接入我們的benchmark

可重用

影片→SLAM→dataset_plan→Zarr的來源鏈、gripper/相機身份與時間/座標轉換。

需要轉換

human-held demonstration與robot trial分開；case固定座標anchor、原7D/訓練10D/部署格式、延遲補償及控制修正；處理品質和task success另列。

仍需補齊

原影片/SLAM資產與校準、全部示範有效性、下游task rubric、時間/pose轉換與跨機體執行驗證。

P118 · EgoMimic

EgoMimic: Scaling Imitation Learning via Egocentric Video

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

EgoMimic把Aria人類資料與Eve機器人資料轉成相似HDF5結構，但人類future palm位置和機器人關節動作仍是不同動作語義。

> **版本與身份**
>
> 主README仍連舊Eve名稱；已讀EgoMimic-Eve README明確回指本作。兩repo commit各固定；不把hardware程式碼等同資料已取得。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	Aria Glasses的人類觀測與Eve/ViperX單臂或雙臂桌面平臺；實際camera extrinsics/arm側及人機資料來源要分開。
任務	人機共同模仿學習，示例包括groceries、laundry、小物放碗；mask/插值與同一demo多chunk是表示 / 樣本擴充，不是新增語義任務。
題數與資料	人類future palm經future camera→world→目前camera變換，單手3D / 雙手6D，actions_xyz再插值成100步actions_xyz_act；每300frame另存demo。robot原HDF5為qpos/qvel/effort/action14D，影像可JPEG padded且compress_len另存。type欄明記human/robot。
評估方式	eval_real輸出actions_joints_act，可temporal aggregate，按query_frequency送到實機；此選讀程式是rollout，不提供統一任務成功判分。資料篩掉出界/跳動frame，case需儲存原時間對映；offline action loss與physical success分開。

依這個順序讀

1. `README.md` ↗

   GitHub · SimarKareer/EgoMimic · 6d63e9a3cd

   原作、三組樣本資料與獨立人/機器人normalization

   L1–18 · L37–54 · L82–92

2. `data_processing.md` ↗
   GitHub · SimarKareer/EgoMimic · 6d63e9a3cd

   手眼標定與人類/機器人轉換入口

   L19–77

---

3. `egomimic/scripts/aria_process/aria_to_robomimic.py` ↗
   GitHub · SimarKareer/EgoMimic · 6d63e9a3cd

   future palm到目前camera frame、篩樣、HDF5 chunk與插值

   L181–258 · L299–330 · L468–519

---

4. `egomimic/utils/dataset.py` ↗
   GitHub · SimarKareer/EgoMimic · 6d63e9a3cd

   時序padding/goal取樣及robot=0/hand=1標記

   L122–196

---

5. `egomimic/scripts/evaluation/eval_real.py` ↗
   GitHub · SimarKareer/EgoMimic · 6d63e9a3cd

   joint-action rollout/temporal aggregation而非任務判分

   L225–240 · L279–303

---

6. `README.md` ↗
   GitHub · SimarKareer/EgoMimic-Eve · b0e45c3f75

   硬體repo與主論文的相互認領

   L1–31

---

7. `scripts/record_episodes.py` ↗
   GitHub · SimarKareer/EgoMimic-Eve · b0e45c3f75

   原robot14D關節/動作、JPEG壓縮長度與HDF5格式

   L302–338

怎麼接入我們的benchmark

可重用

人機兩域、轉換矩陣、原HDF5/處理後chunk關係、type與action keys。

需要轉換

source保留raw VRS/MPS與Eve session；case分domain/action語義/arm/camera/normalization，300frame chunk共享parent demo避免split洩漏，插值點不當獨立觀測。

仍需補齊

原始資產與校準版本、前處理保留索引、robot/human action對齊驗證、下游人工/物理判分協定與全量split。

P119 · EgoDex

EgoDex: Learning Dexterous Manipulation from Large-Scale Egocentric Video

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoDex官方庫提供HDF5/MP4 loader及best-of-K軌跡誤差。829小時包含split凍結後追加資料；每frame樣本量不能當不同任務或episode數。

> **版本與身份**
>
> apple/ml-egodex已轉址apple-aiml-research/ml-egodex，屬同一源。README分約725h train/7h test/97h extra；不可將追加部分混進原凍結test。

領域	居家整理與清潔、衣物與洗護、裝配與生產作業、穿戴互動與動作介面
環境	Vision Pro/ARKit第一人稱桌面人類操作；每episode的ARKit origin由裝置初始化，不保證跨episode一致，不能把相同world坐標當同一場所。
任務	作者報194種人類操作task，829小時資料；test/robot部署是不同用途。loader __len__回總frame數，不是194任務的題數。
題數與資料	同索引MP4/HDF5，30Hz對齊；camera intrinsic3×3、各joint transforms N×4×4、可選confidence；reversible語言用llm_description/description2及which_llm_description。loader比較字串"1"，需驗證實際attr型別。
評估方式	evaluate_distance採B×T×48 GT與K×B×T×48 prediction，排除任何padding的chunk，選出12個位置點而略過6D旋轉；平均距離與終點距離各自best-of-K，可能選不同候選。這是人類軌跡預測誤差，非機器人完成率。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **194** 人類操作tasks · 原文頁 2, 4, 6
- **2** 軌跡benchmark端點 · 原文頁 6
- **338,000** human episodes · 原文頁 2, 4
- **829** 影片小時 · 原文頁 4

依這個順序讀

1. `README.md` ↗
   GitHub · apple-aiml-research/ml-egodex · 718d9ebd8e

   原作、split/extra與SE3/語言/置信度schema

   L1–9 · L37–87

---

2. `simple_dataset.py` ↗
   GitHub · apple-aiml-research/ml-egodex · 718d9ebd8e

   frame到episode定位、座標與reversible指令 / 置信度取值

   L15–75

---

3. `compute_metrics.py` ↗
   GitHub · apple-aiml-research/ml-egodex · 718d9ebd8e

   48D動作中只評位置、padding排除、各K獨立最小化

   L11–50

怎麼接入我們的benchmark

可重用

episode/media配對、ARKit座標、joint confidence、語言方向及best-of-K metrics。

需要轉換

case固定episode/frame/history/horizon/K及query joints；raw SE3和prediction action表達分開，split凍結後extra另版，confidence缺失和padding明確標記。

仍需補齊

大型媒體取得、194task完整manifest、語言方向標籤確認、joint/action對映與全test一致聚合；robot retargeting需另協定。

P120 · EgoScale

EgoScale: Scaling Dexterous Manipulation with Diverse Egocentric Human Data

實作尚未確認 · 主來源 · 原作 · 獨立頁面

NVIDIA官方EgoScale頁目前提供論文與方法 / 影片介紹，未提供可確認的GitHub實作；相似名稱搜尋結果不可直接當官方benchmark程式。

> **版本與身份**
>
> 以2602.16710與NVIDIA研究頁核對身份；Exoscale雲端SDK、EgoScaler不同論文及unofficial候選不視為本作官方實作。已補看dipfocus候選README（論文整理 / 骨架）及paragonLab候選（實為Fast-WAM）；wingAGI候選README介面404，未據此斷言repo不存在。

領域	居家整理與清潔、衣物與洗護、辦公與教育、裝配與生產作業、零售與購物、實驗室操作
環境	原文的人類pretraining scene labels與實機桌面評測場地不同層次；EgoDex和in-house來源保留來源鏈，未取得完整場景manifest。
任務	原文6,015人類訓練標籤、344對齊midtraining任務與5個主實機目標需分開；本次沒有將訓練標籤當已可執行robot task。
題數與資料	官方頁述20k+小時action-labelled egocentric video與少量人機對齊資料；原文細量與6D手 / 機體轉換須原始資料 / 實作確認，未取得完整欄位規格。
評估方式	原文whole-task成功與細項完成度；當前頁未給可執行scorer、全量reset banks或逐次rollout紀錄，不能由影片展示推算整體成績。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **9,869** 作者報告human scene labels · 原文頁 3
- **6,015** human pretraining task labels · 原文頁 3
- **344** aligned midtraining tabletop tasks · 原文頁 4
- **5** real-robot evaluation tasks · 原文頁 6, 7
- **20,854** human pretraining hours · 原文頁 3

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

訓練來源/中間對齊/下游評測三層設計、原作reported規模及機體差異。

需要轉換

source保留EgoDex/in-house父來源，task分training labels與下游目標，case待manifest後固定觀測/hand→robot action轉換與審核規則。

仍需補齊

官方實作認領、可存取資料與schema、實機protocol和trial集合、與同源大corpus的重疊對映。

P121 · EgoZero

EgoZero: Robot Learning from Smart Glasses

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

EgoZero公開Aria示範前處理和Franka點軌跡控制；提供的Franka底層done固定False，不能直接把現有success日誌當自動任務成功評測。

> **版本與身份**
>
> 固定51dc1c6；公開code偏資料處理/實機部署，硬體另依Franka-Teach。未向MPS提交資料或執行機器人。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	人類Aria錄影與Franka/iPhone RGB-D實機部署，需ArUco/相機/robotframe的標定；手持示範場景不等於已可重播機器人環境。
任務	由人類點 / 手部軌跡學習操作；原README按指定手消失來分demo，用另一手reset，這是蒐集協定而非任務語義。
題數與資料	每demo儲存original.mp4、palm/wrist/index/thumb/grasp/pose.npy、fingers_keypoints及first_frame_g2w；人工標記物件點 / triangulation另存。Frankafeatures為pos3+quat4+gripper1；底層宣告action_dim=7卻按pos/quat/gripper切片，須核對wrapper實際編碼。
評估方式	eval.sh選eval_point_track、10queries/10history與temporal_agg；日誌平均goal_achieved。所讀Franka step總回done=False，wrapper把done設為goal_achieved，因此此路徑未提供task-specific自動成功checker。實機操作展示與論文實驗評分需另保留人工 / 任務規則。

依這個順序讀

1. `README.md` ↗

   GitHub · vliu15/egozero · 51dc1c622b

   原作、手部缺席分段、人工點選與資料/部署流程

   `L6–16 · L50–87`

2. `preprocess.py` ↗
   GitHub · vliu15/egozero · 51dc1c622b

   每demo儲存的影片、手部與姿態/對映欄位

   L485–521

---

3. `scripts/eval.sh` ↗
   GitHub · vliu15/egozero · 51dc1c622b

   真正部署入口為eval_point_track及歷史/查詢預算

   L31–45

---

4. `franka-env/franka_env/envs/franka_env.py` ↗
   GitHub · vliu15/egozero · 51dc1c622b

   底層action切片、RGB-D觀測、reward/done返回

   L98–113 · L143–204

---

5. `point_policy/suite/point_policy.py` ↗
   GitHub · vliu15/egozero · 51dc1c622b

   點動作轉實機指令與goal_achieved沿用done

   L219–231 · L277–292 · L435–451

---

6. `point_policy/eval_point_track.py` ↗
   GitHub · vliu15/egozero · 51dc1c622b

   末步goal_achieved平均的限制

   L532–566

怎麼接入我們的benchmark

可重用

示範切分規則、物件點 / 手軌跡、pose標定、部署query/history約定。

需要轉換

人類demo連原VRS/MPS與分段時間，policy action保留幾何/關節/夾爪轉換；case需加具體任務goal與判分器，不能直接沿用placeholder done。

仍需補齊

全量資料/權重、原始校準與取樣紀錄、action形狀驗證、每task成功rubric及可重現測試初態。

P122 · EgoBridge

EgoBridge: Domain Adaptation for Generalizable Imitation from Egocentric Human Data

實作尚未確認 · 方法 / 綜述 · 原作 · 獨立頁面

EgoBridge原作專案頁的Code Release連結實際是#佔位符；未確認官方程式庫，不能將受其啟發的機器翻譯repo當機器人實作。

> **版本與身份**
>
> 以2509.19626和EgoBridge完整題名核對，專案頁code href=#。搜尋的AttentionBridge/AB-2是NMT衍生研究。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	原文/專案頁的人類egocentric與robot觀測兩域，含模擬及三項真實單臂 / 雙臂操作；研究方法重用源資料，不是獨立通用環境包。
任務	Optimal Transport對齊人機策略latent並聯合模仿學習；比較in-domain及新物件/場景/人類示範行為的轉移。
題數與資料	方法需human/robot observation-action序列、動作距離與域標籤；未確認公開loader、精確tensor/座標或資料發行schema。
評估方式	原文實機成功率和generalization設定可供參考；專案頁成果影片與方法圖不提供可執行的benchmark checker或已可匯入case清單。

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

人機父來源區分、視覺/感測/運動學差異、OT/DTW對齊與generalization設計。

需要轉換

方法列related reference；human demo與robot episode保留各自embodiment/action約定，另記對齊關係，不把latent樣本算新實體任務。

仍需補齊

正式code release、來源資料schema、對齊 / 切分manifest、下游成功判定和原生重現。

P123 · WatchAct

WatchAct: A Benchmark for Behavior-Grounded Robot Manipulation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

WatchAct有14種行為理解題型，規劃用符號狀態評分，LIBERO另跑物理執行；Plan Success、完整終態一致和實體成功不能合併成同一數值。

> **版本與身份**
>
> 本次固定97d8873；先前原作索引使用7036927快照，不能直接當同版本。未呼叫VLM、translator或policy server，也未執行LIBERO。

領域	居家整理與清潔、通用物件與機動作業
環境	觀察人類影片後在LIBERO桌面執行；影片camera_perspective/spatial_reference與模擬相機 / 世界坐標要分開。符號場景圖不等於新的物理場景。
任務	14native題型如Imitation/Reversal/Temporal_Sort、Count/Moment、Implicit Intent與Episodic等，屬行為條件與推理方式；具體robot goal / 物件 / 初態另定，不把14題型當14生活用途。
題數與資料	row有id/original_id、language_instruction、video、camera_perspective、spatial_reference；按original_id群組抽樣。規劃輸出action_plan_json，翻譯/符號推演產initial/final/goal_state；執行端是BDDL、init_state、prompt切換與policy action chunk。
評估方式	Plan SR對需變化的interest objects全對即成功，可能忽略side effects；all_success才要求完整終態相等。Imitation/Reversal可改用序列匹配SR。LIBERO物理成功從done取，progress另記max(0,final-initial)，Right/Horizontal檢查幾何且物件已釋放、接觸桌面。彙總依evaluated_count加權，error_count與缺題需另保留。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **14** task scenarios · 原文頁 4
- **4** 認知capability groups · 原文頁 4
- **3,000** paired video-simulator instances · 原文頁 1, 4
- **10** policy每task評測trials · 原文頁 6

依這個順序讀

1. `README.md` ↗
   GitHub · Baiqi-Li/WatchAct · 97d8873e41

   14題型/4能力與規劃、翻譯、物理執行分離

   L1–19 · L38–49 · L66–100

---

2. `video_planning/scripts/run_vlm_evaluation.py` ↗
   GitHub · Baiqi-Li/WatchAct · 97d8873e41

   輸入欄位、影片取樣及original_id群組抽樣

   L542–608 · L712–732

---

3. `video_planning/scripts/run_action_plan_simulation.py` ↗
   GitHub · Baiqi-Li/WatchAct · 97d8873e41

   planning simulation是符號狀態更新

   L205–272 · L476–482

---

4. `video_planning/scripts/run_action_plan_scoring.py` ↗
   GitHub · Baiqi-Li/WatchAct · 97d8873e41

   目標變化、完整狀態、sequence覆寫與分母

   L370–468 · L586–621 · L708–736

---

5. `action_execution/run_libero_execution.py` ↗
   GitHub · Baiqi-Li/WatchAct · 97d8873e41

   物理執行done、原始/初始/net completion與trial聚合

   L123–140 · L185–215 · L246–269 · L460–498

---

6. `action_execution/custom_predicates.py` ↗
   GitHub · Baiqi-Li/WatchAct · 97d8873e41

   Right/Horizontal必須resting及幾何條件

   L122–199

怎麼接入我們的benchmark

可重用

影片/語言/視角條件、原題型、original_id lineage、planning與physical兩種checker。

需要轉換

同一來源題分planning case與execution case，各固定translator/模型資訊/預算；存PlanSR/all_success/physical_success、原始及net progress不同metric。新加無副作用規則另版。

仍需補齊

全影片與BDDL/init-state資產對齊、翻譯前後語義驗證、底層LIBERO版本、初態已達標剔除與完整missing/error分母協定。

P124 · RoboReel

Monkey See, Can Monkey Do? A Benchmark for Evaluating Robot Skill Learning by Observation

檔案 / 網站 · 主來源 · 原作 · 獨立頁面

RoboReel已有官方GitHub網站倉庫；固定index.html的Code與Data仍為disabled Soon按鈕，動畫 / 展示指令碼不是benchmark執行碼。

> **版本與身份**
>
> 固定2609.08209v2及網站a3589a9快照。網站source含動畫生成工具和展示影片，不宣稱robot benchmark程式 / 全資料已公開。

領域	居家整理與清潔
環境	原文是實拍桌面人類影片與ManiSkill3/SAPIEN對應場景；多相機影片不是多個獨立物理環境。
任務	10個操作task、4個evaluation suites；任務條件 / 幹擾和同一task的多視角保留關係，不乘為40種語義任務。
題數與資料	原文正文2,000人類示範，附錄含PD共3,000＝12,000視角影片，另2,000robot trajectories。這些是原文reported量；GitHub展示mp4不能替代正式資料release。
評估方式	原文用模擬predicate、固定初態bank及3runs×20rollouts之每cell設定；抽屜 / toaster等閾值需保留。固定網站沒有原生checker / bank清單，未跑評測。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **10** task types · 原文頁 4, 5
- **4** evaluation suites · 原文頁 4
- **3,000** 含ND/WD/PD的human demos · 原文頁 24, 25
- **2,000** paired robot trajectories · 原文頁 24, 25
- **60** 每model/task/setting結果cell rollouts · 原文頁 29

依這個順序讀

1. `README.md` ↗
   GitHub · RoboReel/roboreel.github.io · a3589a9c08

   網站倉庫名稱

   L1–1

---

2. `index.html` ↗
   GitHub · RoboReel/roboreel.github.io · a3589a9c08

   Code/Data發布狀態與精確論文 / 作者身份

   L100–104 · L771–775

怎麼接入我們的benchmark

可重用

10task/4suites設計、paired人機來源關係、原文成功閾值與多視角區分。

需要轉換

human demo為parent，多view作同一示範媒體；robot episode別存，case固定suite/初態bank/合法觀測與原文predicate版本。

仍需補齊

正式code/data發布、配對及split manifest、初態bank數量矛盾釐清、每任務checker與資產取得。

P125 · Open X-Embodiment

Open X-Embodiment: Robotic Learning Datasets and RT-X Models

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

Open X-Embodiment提供共用RLDS容器與資料讀取示例；相同tensor形狀並不自動統一不同機體動作的物理意義，父資料集也不能重複計數。

> **版本與身份**
>
> 固定9eeb68b；README的3Hz/單workspace RGB是RT-1-X模型介面，不代表所有OXE資料的原取樣率和可見模態。Notebook source cells與輸出分開核讀。

領域	居家整理與清潔、餐飲與烹飪、通用物件與機動作業
環境	聚合多來源、多機體的robot episodes，包括Bridge、RoboNet等；每個子資料原有場景和授權/版本，OXE不是額外一份完全獨立的環境資料。
任務	主要是跨機體訓練資料與RT-X方法；不能把資料集數、機體數、skill labels和實際評測題數互換。
題數與資料	RLDS episode含steps，notebook以TFDS builder從固定dataset/version讀取。Kuka示例拼world_vector/rotation_delta/gripper_closedness_action，Mutex直接取action；影像resize128。另一例保留is_first/is_last/is_terminal且只對齊影像，並未對齊所有action語義。
評估方式	倉庫讀取 / 混合示例和RT-1-X inference不是覆蓋全部子資料的通用成功checker。README指出7個控制變數可能是absolute/delta/velocity；相等TensorSpec只是形狀檢查。tf.data.repeat重複取樣不增加獨立資料；train[:10]也是示例subset。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **60** pooled source datasets（本PDF版本） · 原文頁 3
- **22** robot embodiments · 原文頁 3
- **527** 作者報告skills · 原文頁 6
- **160,266** 作者報告tasks，語言語義去重待核 · 原文頁 6

依這個順序讀

1. `README.md` ↗

   GitHub · google-deepmind/open_x_embodiment · 9eeb68b989

   資料聚合角色、RLDS、RT-1-X輸入與native action差異

   `L1–37 · L45–61`

---

2. `colabs/Open_X_Embodiment_Datasets.ipynb` ↗

   GitHub · google-deepmind/open_x_embodiment · 9eeb68b989

   只讀列出的code cells：資料版本、Kuka/Mutex讀取與軌跡容器；未讀大型嵌入輸出或執行notebook

   `JSON /cells/5/source · JSON /cells/7/source · JSON /cells/13/source · JSON /cells/16/source · JSON /cells/17/source · JSON /cells/26/source · JSON /cells/34/source · JSON /cells/35/source`

怎麼接入我們的benchmark

可重用

RLDS episode/step結構、子資料dataset/version引用與來源引用規則。

需要轉換

source維持OXE→子dataset→原episode lineage，case保留子來源ID與split；另補ActionSpec的座標/單位/absolute-delta-velocity/夾爪約定及task-specific evaluator。

仍需補齊

全子資料素材與精確manifest、跨來源重複episode、任務語義對齊、共同測試split與各機體可執行成功判定。

P126 · DROID

DROID: A Large-Scale In-The-Wild Robot Manipulation Dataset

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

DROID有原始蒐集平臺與policy-learning兩個官方倉庫；raw/RLDS、更新語言與相機標定是同一來源的不同發行物。實機成功由人員標記。

> **版本與身份**
>
> 2024-12新增75k成功episodes的多語言、2025-04更新36k標定為作者公佈更新，不新增獨立資料集。policy loader依賴Octo85b83fc，不能自動換成目前HEAD。

領域	居家整理與清潔、餐飲與烹飪、辦公與教育
環境	多站點DROID robot及相機配置；schema有lab/building/scene_id/robot_serial與外參，不用平臺數代替環境數。scene_id=-1表示未提供值，須保留未知而非新場景。
任務	language/goal條件物件操作；示範、失敗、下游自選任務和eval trials不同集合。三句語言描述對同episode不增加實體軌跡。
題數與資料	raw為trajectory.h5、metadata與多視角MP4/SVO；RLDS有episode_metadata和steps含3圖、state、action_dict、多語言與episode flags。training transform用cartesian_position轉pos3+rot6+gripper1，另移除第一action；預設只取success路徑及有語言資料。
評估方式	實機GUI由人員按鍵儲存success/failure，metadata未提供success時為None。RobotEnv的step返回action_info，不能當task success。檔案flat action7D註解提6joint velocities，但RobotEnv區分cartesian7/joint8，使用時應以明確action_dict及converter核對語義。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **564** unique robot workspaces · 原文頁 3
- **52** buildings · 原文頁 3
- **86** verb-based task labels · 原文頁 3
- **6** downstream evaluation tasks · 原文頁 7
- **76,000** robot demonstration trajectories（約數） · 原文頁 3

依這個順序讀

1. `README.md` ↗
   GitHub · droid-dataset/droid · 33ae6a6727

   平臺、論文與官方policy-learning連結

   L1–22

---

2. `README.md` ↗
   GitHub · droid-dataset/droid_policy_learning · 9a29c832b4

   語言/標定更新、RLDS與Octo固定依賴

   L1–43 · L46–74

---

3. `docs/the-droid-dataset.md` ↗
   GitHub · droid-dataset/droid · 33ae6a6727

   RLDS與原HDF5/MP4/SVO層級

   L44–82 · L84–103

---

4. `droid/postprocessing/schema.py` ↗
   GitHub · droid-dataset/droid · 33ae6a6727

   UUID/lab/scene、success未知值、版本與相機標定

   L12–89

---

5. `droid/robot_env.py` ↗
   GitHub · droid-dataset/droid · 33ae6a6727

   cartesian7D/joint8D、15Hz與velocity範圍

   L16–33 · L49–63

---

6. `examples/droid_dataloader.py` ↗
   GitHub · droid-dataset/droid_policy_learning · 9a29c832b4

   過濾/視角/視窗/normalization的訓練view

   L14–79

---

7. `robomimic/utils/rlds_utils.py` ↗

   GitHub · droid-dataset/droid_policy_learning · 9a29c832b4

   success路徑篩選、絕對10D動作與action時間擷取

   L1–65

---

8. `droid/user_interface/eval_gui.py` ↗

   GitHub · droid-dataset/droid · 33ae6a6727

   A/B按鍵標記成功/失敗與實機eval來源

   L552–578 · L611–625

怎麼接入我們的benchmark

可重用

UUID/lab/scene/version、原始與RLDS對映、相機標定、action_dict、人評標籤。

需要轉換

一個parent episode連raw/RLDS/語言更新/標定版本；case固定模型可見相機、座標/control mode、初態與人評rubric；training選樣不得當完整benchmark分母。

仍需補齊

大型素材、UUID至更新標定/語言的全量join、原成功標籤和case集合、原生評分者一致性、實機或匹配模擬執行。

P127 · BridgeData V2

BridgeData V2: A Dataset for Robot Learning at Scale

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

BridgeData V2提供raw/自訂TFRecord/RLDS多種表示。預設訓練action會被改寫成到達狀態差分，gripper還會使用後續狀態重新標記，不能只改檔案副檔名。

> **版本與身份**
>
> 固定bc60a35，README清楚區分raw demos與scripted zip及多種表示。此repo是訓練/部署方法實作，不能把其所有分支範例當Bridge新增benchmark。

領域	居家整理與清潔、餐飲與烹飪、衣物與洗護
環境	WidowX在多種桌面/廚房環境的蒐集與部署；raw示範和scripted資料、經轉換的TFRecord/RLDS共用來源episode。
任務	goal-image或language條件的操作；各演算法/目標重標與視角不是新的物理任務。CALVIN/SuSIE子目錄為其他實驗來源，需另標parent。
題數與資料	自訂TFRecord每example一trajectory，含observations與next_observations的image/state、actions、terminals/truncates和可選language。relabel_actions用next_proprio[:6]-current_proprio[:6]，gripper閾值>.95/<.05再回填中間值；chunk補首obs/末action，goal與language另取樣。
評估方式	部署從checkpoint還原action_mean/std；取樣後可加noise、sticky-gripper狀態機與遮蔽部分姿態自由度，再送WidowX。這些是控制協定。所讀eval程式提供rollout，沒有通用任務成功predicate；原作實機成功標記需另建protocol。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **24** source environments · 原文頁 5
- **13** skills · 原文頁 5
- **60,096** expert+scripted trajectories · 原文頁 5
- **10** real trials per method/task · 原文頁 6

依這個順序讀

1. `README.md` ↗
   GitHub · rail-berkeley/bridge_data_v2 · bc60a35b70

   原作、表示與方法角色、真實controller來源

   L1–27 · L41–74

---

2. `jaxrl_m/data/bridge_dataset.py` ↗
   GitHub · rail-berkeley/bridge_data_v2 · bc60a35b70

   TFRecord schema、action重標、chunk padding與goal relabeling

   L41–81 · L257–312 · L349–397

---

3. `experiments/eval.py` ↗
   GitHub · rail-berkeley/bridge_data_v2 · bc60a35b70

   checkpoint action反正規化、sticky gripper與DOF限制

   L82–150 · L325–369

怎麼接入我們的benchmark

可重用

父episode、多格式對映、原生7D action/重標規則、goal和語言條件。

需要轉換

儲存raw_action與training_action的轉換/normalization版本；補值mask、來源時間、goal取樣一起記入case；評測固定action execution horizon及gripper/DOF後處理。

仍需補齊

raw→NumPy→TFRecord/RLDS全量ID對映、相機/場景metadata、測試split與成功rubric、與OXE子資料去重、原生部署驗證。

P128 · RoboNet

RoboNet: Large-Scale Multi-Robot Learning

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

RoboNet原生loader會檢查資料hash，統一T個影像/狀態與T−1個action；不同機體維度可補零、截短或推估autograsp，必須保留轉換來源。

> **版本與身份**
>
> 固定d83eee2的2019來源實作；RoboNet另被OXE重發為RLDS，需保留同一父episode關係。未執行TF模型或原資料loader。

領域	通用物件與機動作業
環境	多機器人HDF5 interaction sequences，metadata帶robot/ncam/維度/長度/檔案hash。任務環境或物件配置不能由機體名與record數推定。
任務	動作條件影片預測、逆動態 / 視覺控制及標註點預測；frame、subsequence、同episode多camera皆不是新增語義任務。
題數與資料	env/state、policy/actions、camera影像及可選bbox_annotations；loader以min(state_T,img_T,action_T+1)決定可用T，action取T−1。Mismatch模式可PAD_ZERO/CLEAVE，autograsp根據後一state及邊界推估新增控制維。
評估方式	標註variant預設拆non-annotated train/val/test並另列annotated robots；指定train_ex_per_source時另走分支，須固定split規則。metrics提供分佈畫素距離和normalize到1的PSNR/MSE等，值受resize/camera/horizon影響，不是物理task完成率。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **4** lab environments · 原文頁 5
- **113** camera configurations · 原文頁 5
- **15,000,000** video frames（約數） · 原文頁 1

依這個順序讀

1. `README.md` ↗
   GitHub · SudeepDasari/RoboNet · d83eee20f3

   原作、資料與inverse/video prediction方法角色

   L1–20

---

2. `robonet/datasets/util/hdf5_loader.py` ↗
   GitHub · SudeepDasari/RoboNet · d83eee20f3

   state/action維度、autograsp推估、標註縮放與T對齊

   L78–174

---

3. `robonet/datasets/variants/annotation_benchmark_dataset.py` ↗
   GitHub · SudeepDasari/RoboNet · d83eee20f3

   有/無標註與robot-specific評測模式

   L1–54

---

4. `robonet/video_prediction/metrics.py` ↗
   GitHub · SudeepDasari/RoboNet · d83eee20f3

   畫素距離與MSE/PSNR的實際計量公式

   L13–88

怎麼接入我們的benchmark

可重用

內容hash、原robot/相機/維度、T/T−1對齊、標註模式與視覺metrics。

需要轉換

case記parent HDF5、選取camera/起始frame/context/horizon、原維度和補零/截斷/autograsp推估；畫素誤差附影像解析度，原標註缺失與零placeholder分開。

仍需補齊

資料資產與完整metadata、場景/語義目標對映、原train/test與annotated子集隔離、視覺控制真實成功協定及跨來源去重。

P129 · RH20T

RH20T: A Comprehensive Robotic Dataset for Learning Diverse Skills in One-Shot

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

RH20T API能按時間對齊多相機、TCP和力矩，但不同機體有不同前處理；tactile原始資料可載入，按時間查詢介面仍是佔位。

> **版本與身份**
>
> 固定aa31244 API版；README列出的介面和實作範圍分開。未下載大資料或進行online機器人投影執行。

領域	居家整理與清潔、裝配與生產作業、通用物件與機動作業
環境	多機器人配置與相機序列的實拍操作場景；scene folder是資料record脈絡，機體/攝影機數不能當獨立環境數。
任務	多樣操作示範與多模態學習資料；此庫主要提供loader/visualizer/online preprocessor，任務目標與評測協定需連原文 / 來源metadata。
題數與資料	時間查詢以毫秒，影像選最近low-frequency timestamp，TCP/FT/關節/夾爪值另線性插值。TCP7D四元數、FT6D；Kuka位置除1000，Franka/UR5姿態及不同gripper各有processor；標定和raw/zeroed FT不能混用。
評估方式	沒有從此資料API取得通用task成功scorer。get_tactile(timestamp)與detect_outlier仍NotImplemented，高頻gripper getter也未實作；不能由tactile.npy存在推定整套評測介面可用。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **147** task definitions · 原文頁 3
- **42** skill verbs · 原文頁 3
- **110,000** robot sequences · 超過；另等量human sequences · 原文頁 2, 3
- **20** 主實驗每configuration trials · 原文頁 5

依這個順序讀

1. README.md ↗
   GitHub · rh20t/rh20t_api · aa31244347

   資料API、相機/TCP/FT與毫秒查詢入口

   L1–60

---

2. rh20t_api/configurations.py ↗
   GitHub · rh20t/rh20t_api · aa31244347

   機體單位/姿態/夾爪轉換及標定矩陣

   L1–83

---

3. rh20t_api/scene.py ↗
   GitHub · rh20t/rh20t_api · aa31244347

   最近影格、連續值插值、原始tactile與未實作介面

   L38–75 · L114–115 · L467–489 · L528–550 · L563–592 · L617–639

---

4. rh20t_api/online.py ↗
   GitHub · rh20t/rh20t_api · aa31244347

   機體base到相機的TCP/FT投影

   L127–155

怎麼接入我們的benchmark

可重用

配置ID、相機serial、raw/aligned資料、毫秒時間與機體/相機轉換引數。

需要轉換

source/native scene與實際workspace分開；case儲存各模態原始時間/插值方式/資料缺失、TCP encoding、FT零偏和gripper單位；sensor trace不是直接可執行action。

仍需補齊

全量metadata/素材、任務goal及split、四元數插值有效性、tactile/高頻gripper接線與原生評測判分。

P130 · ALOHA / ACT

Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

ALOHA提供雙臂蒐集，ACT提供訓練及兩個模擬任務。sim的成功從最高reward判定；真真實模式的reward佔位不能當原文實機成功率。

> **版本與身份**
>
> ALOHA/ACT各固定commit；真實環境中的0 reward是軟體介面佔位，不能推論原論文實機研究使用此欄自動評分。未執行硬體或sim。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	真實雙臂ALOHA與MuJoCo/DM-Control兩個模擬場景分開；資料中的四相機 / 四個主從臂不算四種任務環境。
任務	ACT repo兩個sim任務為Transfer Cube/Bimanual Insertion；joint-control和EE-control是執行表示，scripted/human是示範來源，不能各算新的語義task。
題數與資料	HDF5 obs qpos/qvel/effort與action均14D，RGB相機分key。蒐集T次action產T+1 timesteps，但儲存配對只取前T。ACT real資料從start_ts−1取action，sim從start_ts取，padding與mean/std要儲存。
評估方式	sim Transfer reward4為左gripper接觸且方塊不接觸桌；Insertion reward4為peg碰到pin。eval用全episode最高reward==max_reward作成功，非最後穩定狀態。real_env.get_reward固定0，eval real分支max_reward也0，此自動數值不能代替實機任務審核。

依這個順序讀

1. `README.md` ↗
   GitHub · tonyzhaozh/aloha · 06369f03cd

   硬體/蒐集與ACT的角色分工

   L1–12

2. `README.md` ↗
   GitHub · tonyzhaozh/act · 742c753c0d

   兩個原生sim環境與示範/方法入口

   L1–25 · L55–68

---

3. `aloha_scripts/record_episodes.py` ↗
   GitHub · tonyzhaozh/aloha · 06369f03cd

   T+1觀測蒐集後存T、14D雙臂HDF5

   L88–101 · L127–165

---

4. `aloha_scripts/real_env.py` ↗
   GitHub · tonyzhaozh/aloha · 06369f03cd

   真實reward佔位與每臂6關節+gripper

   L111–112 · L142–151

---

5. `utils.py` ↗
   GitHub · tonyzhaozh/act · 742c753c0d

   sim/real不同action時間偏移、padding與normalization

   L23–76

---

6. `sim_env.py` ↗
   GitHub · tonyzhaozh/act · 742c753c0d

   Transfer/Insertion具體接觸式分階reward

   L143–169 · L192–229

---

7. `imitate_episodes.py` ↗
   GitHub · tonyzhaozh/act · 742c753c0d

   最高reward成功聚合及real模式限制

   L179–194 · L280–313

怎麼接入我們的benchmark

可重用

HDF5原結構、兩個sim checker、機體/相機配置、action/padding與示範來源。

需要轉換

real/sim分protocol；case固定初態與目標、joint或EE動作、資料時間偏移、temporal aggregation及原最高reward指標。新加穩定性規則另版。

仍需補齊

原實機任務rubric、全量素材 / split、終端觀測與T對齊、sim/real重播與獨立成功判定。

P131 · Mobile ALOHA

Mobile ALOHA: Learning Bimanual Mobile Manipulation with Low-Cost Whole-Body Teleoperation

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

Mobile ALOHA擴充雙臂示範為14D手臂＋2D底盤；共訓練的靜態資料會補零底盤，部署還有13步對齊，不能與原ALOHA時間 / 動作表達混用。

> **版本與身份**
>
> mobile-aloha和act-plus-plus各自固定版本，README稱兩個sim為LEGACY。未跑VINN/ACT/diffusion或機器人。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	Mobile ALOHA真實底盤/雙臂與沿用ACT的兩個桌面模擬場景；不能把legacy sim當已提供全部移動任務的模擬版。
任務	全身雙臂移動操作與靜態資料共訓練；原sim transfer/insertion是父來源重用。新物理任務應追到實機活動/場景與具體目標。
題數與資料	HDF5原action14D、base_action2D；有JPEG壓縮長度。loader串為16D，沒有base_action時補2維零，並5步卷積平滑base。缺少底盤標註和真的靜止需要metadata區分。
評估方式	real部署將手臂chunk[:-13]與底盤chunk[13:]拼接，query頻率同步調整；temporal_agg還改取樣方式。最高reward評估沿用ACT，real reward與max_reward均0，不能直接作實機任務成功。實際移動任務評分仍需原文 / 人評協定。

依這個順序讀

1. `README.md` ↗

   GitHub · MarkFzp/mobile-aloha · 0e403249c7

   原作、ALOHA父庫與ACT++官方連結

   L1–13

2. README.md ↗
   GitHub · MarkFzp/act-plus-plus · 26bab0789d

   共訓練與沿用的兩個legacy模擬任務

   L1–23 · L55–67

---

3. aloha_scripts/record_episodes.py ↗
   GitHub · MarkFzp/mobile-aloha · 0e403249c7

   控制時間、14D action＋2D base與JPEG metadata

   L90–107 · L203–229

---

4. utils.py ↗
   GitHub · MarkFzp/act-plus-plus · 26bab0789d

   缺底盤補零、平滑、real action時間偏移與padding

   L48–98 · L282–291

---

5. imitate_episodes.py ↗
   GitHub · MarkFzp/act-plus-plus · 26bab0789d

   13步base/arm對齊、temporal aggregation與real reward限制

   L294–321 · L395–421 · L442–462 · L498–509

---

6. aloha_scripts/real_env.py ↗
   GitHub · MarkFzp/mobile-aloha · 0e403249c7

   真實reward固定0的介面

   L170–171

怎麼接入我們的benchmark

可重用

機體/動作分量、示範來源、壓縮schema、base smoothing與延遲對齊。

需要轉換

case儲存原14+2與模型16D表示、base有效mask、時間偏移/控制頻率、靜態/移動父資料及實機判分來源；重用legacy tasks不增聯集。

仍需補齊

原移動任務初態/goal/rubric、素材與校準、13步時序假設及temporal_agg互作用驗證、對應可執行sim資產。

P132 · RT-1

RT-1: Robotics Transformer for Real-World Control at Scale

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

RT-1官方庫主要公開策略網路、action tokenizer和checkpoint。700-task是其中模型的訓練標籤說明，並非可直接下載的700題評測清單。

> **版本與身份**
>
> 固定4569641封存快照，README明示初期元件發行；RT-1-X/OXE是相關但不同版本與資料發行，不能合併成同一份獨立benchmark。

領域	居家整理與清潔、餐飲與烹飪
環境	原研究Google robot實機工作脈絡；庫中三個checkpoint分主模型、多機體、sim-real資料訓練，checkpoint數不是環境數。
任務	語言條件robot控制方法；每個原生任務 / held-out評測case需另接原資料與實驗協定，不能從README700-task標籤推定可執行task registry。
題數與資料	動作TensorSpec指定順序、shape、dtype、min/max。int32 one-hot轉一token，float每維clip/normalize後離散分桶；detokenize按相同順序還原，部分越界離散token預設0。token值本身不代表物理單位。
評估方式	此選讀庫提供模型與tokenizer測試，未由公開元件取得通用task成功checker、完整reset/split清單。checkpoint/API可載入不等於原作實機評測可重現。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **3** evaluation environments · 原文頁 8
- **744** language instructions · 原文頁 7
- **21** held-out novel instructions · 原文頁 8
- **15** long-horizon instructions · 原文頁 9
- **3,000** 全研究real trials（>3000） · 原文頁 8

依這個順序讀

1. README.md ↗

   GitHub · google-research/robotics_transformer · 4569641b81

   方法元件、checkpoint角色與發行範圍

   L1–14 · L37–54

---

2. tokenizers/action_tokenizer.py ↗

   GitHub · google-research/robotics_transformer · 4569641b81

   action_order/各field範圍、one-hot/浮點tokenization及反轉

   L42–89 · L103–157

怎麼接入我們的benchmark

可重用

官方模型介面、action spec/order/量化與checkpoint來源。

需要轉換

列為策略/訓練參考，case另連來源dataset/robot/goal；儲存token↔action轉換的vocab_size、bounds、dtype及控制模式，不硬寫統一7D。

仍需補齊

逐任務資料/資產、原實機成功rubric與split、感測/時間/動作物理語義以及匹配模型部署驗證。

P133 · RT-2

RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control

實作尚未確認 · 方法 / 綜述 · 原作 · 獨立頁面

RT-2原作專案頁提供論文與實機示例；本次未確認Google/原作者釋出的RT-2 GitHub實作，第三方同名實作不作原生benchmark來源。

> **版本與身份**
>
> 固定原作PDF與官方專案頁查核範圍；未找到官方repo不是宣稱世界上不存在任何實作。搜尋kyegomez/RT-2不當原作者發行。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	原作實機移動操作平臺與語言/視覺條件；專案頁示例沒有提供可重設的完整場景與資產manifest。
任務	將web視覺語言知識轉到robot action tokens的策略方法；語義泛化/推理示例可補研究分類，但不是公開固定題庫。
題數與資料	原文描述動作離散token化與VLM共同訓練；本次未確認原資料loader、checkpoint、完整action spec及訓練/評測episode ID清單。
評估方式	原文實機試驗和泛化結果屬作者報告；沒有確認可直接沿用的原作task checker或逐trial判分實作。示範影片不當新增自動評測資料。

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

原作方法、語義泛化設定及輸入/動作共同表示的設計參考。

需要轉換

列為方法參考；若補資料，case需另連可公開的dataset/robot/goal/protocol，保留原作與第三方重現的身份差異。

仍需補齊

可確認的官方實作、模型/資料版本、action解碼、原生測試任務/初態/分母與實機成功審核。

P134 · OpenVLA

OpenVLA: An Open-Source Vision-Language-Action Model

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

OpenVLA是VLA方法，重用OXE/Bridge/LIBERO資料與任務。模型action解碼依dataset專屬q01/q99，LIBERO部署再改gripper範圍與方向。

> **版本與身份**
>
> 固定c8f03f4；README後加OFT/FAST並非vanilla OpenVLA同版本。此庫是Prismatic fork且由原作者頁認領，fork屬性不代表非官方。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	BridgeData V2真實WidowX和LIBERO模擬設定；新增模型 / 微調不新建獨立benchmark環境。
任務	語言條件操作策略與既有task-suite評測。原作訓練資料量和LIBERO任務數應追到父來源，不累加成新的任務聯集。
題數與資料	predict_action以dataset專屬unnorm_key解碼action tokens，依mask使用q01/q99還原。維度由stats的q01長度決定；雖範例7D，不能忽略dataset/controller。LIBERO observation字典含state，但程式註明OpenVLA不使用proprio作輸入。
評估方式	LIBERO使用固定initial_states[episode_idx]，suite預算220/280/300/520/400步，另有暖機；gripper[0,1]→[-1,+1]且OpenVLA再反號。成功取原env.done，原goals沿LIBERO。需記下成功/例外和整體分母。

依這個順序讀

1. `README.md` ↗

   GitHub · openvla/openvla · c8f03f48af

   原作、後續OFT/FAST、資料重用及模型介面

   L1–37 · L65–83

2. `prismatic/models/vlas/openvla.py` ↗

   GitHub · openvla/openvla · c8f03f48af

   依unnorm_key取stats、mask與action維度

   L90–131

---

3. `experiments/robot/libero/run_libero_eval.py` ↗

   GitHub · openvla/openvla · c8f03f48af

   原生init-state、各suite步數、合法輸入與gripper變換

   L150–235

怎麼接入我們的benchmark

可重用

模型與原dataset/suite對應、action解碼統計、各task評測指令碼。

需要轉換

method與source task/case分離；case固定預算/初態/影像前處理，policy adapter儲存unnorm_key/mask/gripper方向。原native分數與我們新增規則各有版本。

仍需補齊

完整checkpoint/資料/資產、各來源訓練重疊與holdout、normalize與實機controller對照、原生執行再現。

P135 · Octo

Octo: An Open-Source Generalist Robot Policy

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

Octo提供可組合的多相機/語言/goal介面及OXE loader；其80萬軌跡是訓練混合，模型task字典與benchmark語義任務不是同一計數單位。

> **版本與身份**
>
> 固定241fb35；DROID另釘較早Octo85b83fc，不可互相套用。README連1.5 checkpoint，模型版本、程式版本與資料版本分開儲存。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	重用多來源robot資料及既有ALOHA/WidowX執行環境；模型支援的機體/相機種類不等於獨立benchmark環境。
任務	多工goal-image或language條件policy；create_tasks組裝的是一次條件輸入，並不定義全庫獨立task。
題數與資料	task含goal/text及pad_mask_dict；缺模態填零但mask=False。observations為B×window×...，timestep_pad_mask區分padding。output為sample_shape×B×action_horizon×action_dim；以mean/std或p01/p99和mask反正規化並裁到機體維度。
評估方式	例子在aloha-sim-cube-v0用history=1、exec_horizon=50，跑3次400step上限並記episode return。它是示例protocol，不能作全部Octo/所有機體的統一成功判定；底層checker仍屬原環境。

依這個順序讀

1. `README.md` ↗

   GitHub · octo-models/octo · 241fb3514b

   原方法、訓練混合與evaluation/loader入口

   `L1–28 · L65–90`

2. `octo/model/octo_model.py` ↗

   GitHub · octo-models/octo · 241fb3514b

   task/missing-modality mask、候選維度和反正規化

   L76–134 · L174–253

---

3. `examples/03_eval_finetuned.py` ↗

   GitHub · octo-models/octo · 241fb3514b

   既有ALOHA sim wrapper、history與exec-horizon及回報方式

   L43–110

怎麼接入我們的benchmark

可重用

task/obs/action模組介面、missing/timestep masks、資料來源stat與normalization。

需要轉換

保留OXE子來源/episode與method分離；case固定language或goal、可見相機/歷史、sample_shape與exec horizon，數值表示和缺失mask不可丟。

仍需補齊

完整pretraining mixture與來源去重、模型版本/目標機體stat、各原benchmark正式protocol、素材與原生執行驗證。

P136 · pi0

$π_0$: A Vision-Language-Action Flow Model for General Robot Control

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

π0的openpi介面保留機體與模型兩種表示；模型預設輸出50步、32維，ALOHA adapter再轉成14維控制。

> **版本與身份**
>
> 固定215abfb現行openpi同時含π0/FAST/π0.5；此筆以π0介面為主，不能把後續π0.5功能與成績歸到最初π0版本。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	原π0研究機體與openpi公開ALOHA/DROID示例應分開；checkpoint場景標籤與原私有訓練資料不是公開環境manifest。
任務	通用VLA與任務微調，含towel等示例；訓練10k+小時和各checkpoint不當新獨立benchmark task/case量。
題數與資料	模型預設action_horizon50/action_dim32；ALOHA外部state/action14D，input轉換關節sign/gripper angular，缺wrist圖片填零且image_maskFalse；output只回前14維。DeltaActions/AbsoluteActions依mask和當前state轉換。
評估方式	policy.infer返回action和infer_ms；timer只包模型sample_actions，不含input/output轉換或網路。此policy介面不是task成功checker；各示例要承接原環境或實機rubric，不能以推論成功當任務完成。

依這個順序讀

1. `README.md` ↗

   GitHub · Physical-Intelligence/openpi · 215abfb217

   原π0與FAST/π0.5、base與task checkpoints分開

   L1–19 · L59–84

2. `src/openpi/models/pi0_config.py` ↗
   GitHub · Physical-Intelligence/openpi · 215abfb217

   action維度/長度及π0/π0.5旗標

   L18–55

---

3. `src/openpi/policies/aloha_policy.py` ↗
   GitHub · Physical-Intelligence/openpi · 215abfb217

   相機缺失mask、關節/夾爪轉換與14D輸出

   L25–102 · L181–202

---

4. `src/openpi/transforms.py` ↗
   GitHub · Physical-Intelligence/openpi · 215abfb217

   依state與mask做delta/absolute及padding

   L204–242 · L328–337

---

5. `src/openpi/policies/policy.py` ↗
   GitHub · Physical-Intelligence/openpi · 215abfb217

   input→model→output轉換與infer_ms範圍

   L67–106

怎麼接入我們的benchmark

可重用

機體adapter、相機mask、state/action表示、checkpoint/config與normalization鏈。

需要轉換

method與task/case分開；保留原生維度、padding、關節/夾爪對映、delta mask、history/horizon和全流程預算，模型輸出容器不拿來計環境或任務量。

仍需補齊

原π0訓練資料/正式測試清單、各機體scorer、完整素材/校準/模型與control spec對照、原生基線執行。

P137 · pi0.5

$π_{0.5}$: a Vision-Language-Action Model with Open-World Generalization

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

π0.5與π0共用openpi，但state離散token、prompt預算和模型旗標不同。公開LIBERO示例還固定了雙相機、5步action chunk與原suite預算。

> **版本與身份**
>
> README明示此repo目前只支援π0.5 flow matching head；不能宣稱公開碼已覆蓋原作所有head和私有資料。與P136共用repo/commit但分開記錄方法配置。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	π0.5原研究開放環境泛化與公開LIBERO/DROID示例不是同一環境集合；公開示例重用父benchmark資產。
任務	升級的VLA方法和跨環境泛化；不因π0.5/model-head或checkpoint新名字重計底層LIBERO任務。
題數與資料	pi05旗標預設離散state輸入，prompt max_token_len200（π0預設48）；TokenizePrompt需state與prompt。LIBERO範例傳agentview/wrist RGB各旋轉180度、EEF pose/gripper state及task文字，資料可見性和只RGB baseline不同。
評估方式	公開LIBERO預設50trials/task、10步暖機、每次執行action chunk前5步；suite上限220/280/300/520/400，按原env.done計成功，seed與預存初態都要固定。這些是公開示例協定，不等於原文全部open-world評測。

依這個順序讀

1. `README.md` ↗
   GitHub · Physical-Intelligence/openpi · 215abfb217

   π0.5與公開flow-head/下游checkpoints的範圍

   L1–19 · L73–81

2. `src/openpi/models/pi0_config.py` ↗
   GitHub · Physical-Intelligence/openpi · 215abfb217

   pi05/discrete_state_input與48/200 prompt長度

   L18–55

---

3. `src/openpi/transforms.py` ↗
   GitHub · Physical-Intelligence/openpi · 215abfb217

   state進prompt token的真實轉換

   L247–267

---

4. `examples/libero/main.py` ↗
   GitHub · Physical-Intelligence/openpi · 215abfb217

   原benchmark物件初態、相機方向、chunk與成功

   L25–40 · L57–71 · L89–156 · L189–197

怎麼接入我們的benchmark

可重用

π0.5專屬配置/transform、公開LIBERO runner與原native成功來源。

需要轉換

method_version區分π0/0.5；case固定state可見性、prompt/token預算、雙相機方向、replan/暖機/suite步數，父benchmark與資料重用關係獨立儲存。

仍需補齊

原文泛化場景與trial manifest、完整訓練 / 測試素材、模型head/資料切分對照、公平資訊預算與原生結果再現。

P138 · Diffusion Policy

Diffusion Policy: Visuomotor Policy Learning via Action Diffusion

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

Diffusion Policy跨既有benchmark比較；Push-T的mean_score是每次rollout最高部分reward的平均，且checkpoint聚合有max與低loss選樣兩種口徑。

> **版本與身份**
>
> 固定5ba07ac；README/runner已公開說明原作與修正聚合範圍。未執行原模型，未假定目前main可逐數字重現原paper。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	Push-T、robomimic、Kitchen等父環境以及實機評測分開；方法repo包含多套實驗，不代表這些全是新的獨立環境資料。
任務	Diffusion Policy學習動作序列；每個task仍追到父benchmark。Push-T是將T形物推到目標pose，影像/lowdim兩種觀測不增語義任務。
題數與資料	Push-T Zarr含img/state/action，SequenceSampler按episode mask、horizon與padding出樣本。模型觀測image與agent_pos，action是2D推動控制目標；訓練state還含物體pose但不是全數模型可見。
評估方式	coverage=物體與目標交集/目標面積；reward=clip(coverage/.95,0,1)，done在coverage>.95。runner取每episode最高reward平均為mean_score，仍可有部分分數。multirun的max與k_min_train_loss依不同epoch選樣，需分開報；runner註記原作只聚合前n_envs的歷史差異。

依這個順序讀

1. `README.md` ↗

   GitHub · real-stanford/diffusion_policy · 5ba07ac666

   原作、三seed實驗紀錄與paper聚合鍵

   `L1–20 · L28–59`

2. `diffusion_policy/dataset/pusht_image_dataset.py` ↗
   GitHub · real-stanford/diffusion_policy · 5ba07ac666

   Zarr episode/sequence、模型觀測與2D action

   L15–65 · L74–90

---

3. `diffusion_policy/env/pusht/pusht_env.py` ↗
   GitHub · real-stanford/diffusion_policy · 5ba07ac666

   幾何coverage、reward尺度與done閾值

   L109–138 · L311–317

---

4. `diffusion_policy/env_runner/pusht_image_runner.py` ↗
   GitHub · real-stanford/diffusion_policy · 5ba07ac666

   每rollout最大reward、seed分母與已記錄原作差異

   L222–251

---

5. `multirun_metrics.py` ↗
   GitHub · real-stanford/diffusion_policy · 5ba07ac666

   跨epoch max與低train/val-loss選樣

   L30–97

怎麼接入我們的benchmark

可重用

父task/資料source、Zarr/序列視窗、具體Push-T grader與experiment config/log。

需要轉換

case保留觀測可見性、episode/seed、horizon/控制與影像前處理；metric儲存coverage、scaled reward、binary done和checkpoint選擇規則，不把mean_score全稱成功率。

仍需補齊

各其他父benchmark版本/資產與checker接線、原作vs修正seed集合、固定checkpoint/held-out再現和全套baseline。

P139 · R3M

R3M: A Universal Visual Representation for Robot Manipulation

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

R3M主庫提供Ego4D表徵訓練，BC評測在eval分支。已分開固定兩個commit；不能只看其中一份README的coming-soon文句判斷code可得性。

> **版本與身份**
>
> 主庫b2334e7與eval分支600d866分開。eval分支root README仍說coming soon，但evaluation目錄已有程式；main README明確連此分支。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	下游重用MetaWorld fork、Franka Kitchen、Adroit/RoboHive；人類Ego4D訓練影片和robot環境是不同資料層。
任務	學習通用視覺表示，再用少量示範BC；表徵模型是方法，並未新定義所有下游操作task。
題數與資料	Ego4D預處理為224×224編號JPG＋manifest.csv（clip路徑、長度、語言配對）。BC讀multiview demo pickle並取前num_demos；encoder接收0–255影像，wrapper選擇是否拼接proprio，需保留資訊預算。
評估方式	Adroit/Kitchen呼叫原env.evaluate_success；MetaWorld fallback取每trajectory最後env_infos.success平均×100；每次eval seed含epoch偏移，另追蹤max_success。最後步成功、跨epoch最佳、原環境成功函式都不能混為單一通用指標。

依這個順序讀

1. `README.md` ↗

   GitHub · facebookresearch/r3m · b2334e7268

   原作、資料格式與明確eval分支入口

   L1–38

2. `r3m/utils/data_loaders.py` ↗
   GitHub · facebookresearch/r3m · b2334e7268

   預先抽frame的Ego4D與manifest讀取

   L30–61

---

3. `evaluation/README.md` ↗
   GitHub · facebookresearch/r3m · 600d866675

   BC評測來源與MetaWorld/RoboHive指定版本

   L1–25

---

4. `evaluation/r3meval/core/train_loop.py` ↗
   GitHub · facebookresearch/r3m · 600d866675

   demo擷取、env-specific成功與跨epochmax

   L97–115 · L141–180

---

5. `evaluation/r3meval/utils/obs_wrappers.py` ↗
   GitHub · facebookresearch/r3m · 600d866675

   影像量程與可選proprio拼接

   L120–159

---

6. `r3m/models/models_r3m.py` ↗
   GitHub · facebookresearch/r3m · 600d866675

   表徵輸入0–255、相似度與learned reward介面

   L78–107

怎麼接入我們的benchmark

可重用

Ego4D父來源、表示介面、BC demo/相機/機體資料與eval分支。

需要轉換

method與task/case分離；case固定相機/proprio、demo數、encoder輸入量程、seed與checkpoint規則；原benchmark versions另列。

仍需補齊

Ego4D與downstream素材、MetaWorld fork/RoboHive v0.0.5依賴閉合、固定eval initial states和完整重現。

P140 · VIP

VIP: Towards Universal Visual Reward and Representation via Value-Implicit Pre-Training

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

VIP學習的是視覺reward/表示；embedding距離和環境任務成功是不同評估。程式的success門檻是episode累積solved次數，並非連續穩定時間。

> **版本與身份**
>
> 固定81b0520；前述sum門檻屬目前公開env基底，具體task可能另override，整合每task時仍需沿具體class核對。未跑MPPI。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	Ego4D人類訓練影片、實機示例和MuJoCo系下游環境；原場景與資料仍屬各父來源。
任務	以goal-image/embedding引導robot任務與reward learning；fold_towel等展示是應用例子，不能由曲線距離直接認定任務語義正確。
題數與資料	自訂影片依video資料夾存frames；model依影像shape resize/crop224和normalization，max>2時除255。sim=-L2(embedding1,embedding2)，此單位是特徵距離而非幾何公尺。
評估方式	MPPI讀goal_embedding並用H/paths_per_cpu/num_cpu/kappa配置最佳化；env.evaluate_success預設判sum(solved)>5再按paths算百分比，未要求連續。embedding reward、原生solved與工程時間分開儲存。

依這個順序讀

1. `README.md` ↗
   GitHub · facebookresearch/vip · 81b0520145

   原作、Ego4D/自訂影片與reward用途

   L1–9 · L24–38 · L68–82

2. `vip/models/model_vip.py` ↗
   GitHub · facebookresearch/vip · 81b0520145

   影像預處理及負Euclidean embedding距離

   L68–91

---

3. `evaluation/trajopt/trajopt/run_mppi.py` ↗
   GitHub · facebookresearch/vip · 81b0520145

   目標embedding、MPPI取樣預算與trajectory儲存

   L27–67 · L94–103 · L126–134

---

4. `evaluation/mj_envs/mj_envs/envs/env_base.py` ↗
   GitHub · facebookresearch/vip · 81b0520145

   原environment success百分比及solved數門檻

   L260–282

怎麼接入我們的benchmark

可重用

表示/goal資料介面、原reward數學定義、MPPI配置與環境成功引用。

需要轉換

evaluator標明learned reward或ground-truth環境條件；case固定goal frame、相機、normalization、planner預算和solved門檻，避免將reward作通用正解。

仍需補齊

各task實際solved predicate、原素材/goal設定、planner與環境版本、reward與任務正確性的反例校準。

P141 · HoloAssist

HoloAssist: an Egocentric Human Interaction Dataset for Interactive AI Assistants in the Real World

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

HoloAssist提供多感測程式互動資料和多種任務；PyHoloAssist另提供投影工具。recognition、anticipation、hand forecasting各用不同觀測視窗與分母。

> **版本與身份**
>
> 主release與PyHoloAssist各固定commit；後者是作者工具，不替代完整benchmark。UTF16 README行號指解碼文字，外部連結定位到檔案，不捏造GitHub逐行fragment。

領域	餐飲與烹飪、辦公與教育、工藝與修繕、裝配與生產作業、協助、交接與陪伴
環境	人類HoloLens工作session與指導者互動，RGB/depth/眼動/手/頭/IMU/音訊同步到RGB；session/裝置/活動不是可直接執行的robot environment。
任務	細/粗動作識別與anticipation、錯誤與介入偵測/預測、手部forecast；原Narration/Conversation/細/粗行為是標註種類，與生活用途/robot task不同層。
題數與資料	session中*_synced資料按RGB時鐘排列，原annotation有id/start/end（秒）及attributes。anticipation取[0,t_start-time_range]並篩長度，hand forecast只取correct action，用過去3秒預測起始後1.5秒；不能把全量mistake資料當hand test分母。
評估方式	分類top1/top5與precision/recall依class平均設定；hand分支ks=15/30/45是字首frame數，不是候選數，且輸出名稱*_acc實際為masked 3D Euclidean距離。NUM_CLASSES<=10分支優先，配置要固定。投影工具nearest-neighbor假設時間順序。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **20** 程式tasks · 原文頁 3
- **414** coarse action classes · 原文頁 5
- **2,221** sessions · 原文頁 4, 7
- **463** test sessions · 原文頁 7

依這個順序讀

1. README.md ↗
   GitHub · Ember-HoloAssist/holoassist-release · f53ad2b5c3

   主論文、同步模態、四種原始標註與正誤行為

   L1–10 · L30–88 · L139–181

---

2. README.md ↗
   GitHub · taeinkwon/PyHoloAssist · 9d0dfe238f

   原檔UTF16，已正確解碼；投影用途和PSI/校準資料依賴

   utf-16 解碼文字行號 · L1–17

---

3. hand_eye_project.py ↗
   GitHub · taeinkwon/PyHoloAssist · 9d0dfe238f

   逐時間前進的nearest-neighbor同步方式

   L17–34

---

4. src/data_loader/raw_loader.py ↗
   GitHub · Ember-HoloAssist/holoassist-release · f53ad2b5c3

   原事件ID、識別/預測視窗、正確動作hand子集

   L54–64 · L193–250 · L296–322

---

5. src/test_net.py ↗
   GitHub · Ember-HoloAssist/holoassist-release · f53ad2b5c3

   top-k分類、手部prefix15/30/45及masked距離

   L114–126 · L394–424 · L483–550 · L719–726

怎麼接入我們的benchmark

可重用

session/事件/模態同步、label字典、各任務視窗和有效mask、投影校準。

需要轉換

case固定benchmark kind、觀測截止/預測horizon、原事件/participant/split；相同session多題連父來源，手部距離/分類百分比/介入標籤分開。

仍需補齊

全量素材與同步校準、手部座標/單位核對、每任務split/排除清單、不同感測缺失處理和全部端點重現。

P142 · Habitat 3.0

Habitat 3.0: A Co-Habitat for Humans, Avatars and Robots

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

Habitat3.0把人類avatar和機器人互動加入同一平臺；已深入核對social navigation配置與成功判定，其他協作場景仍需各自的task配置。

> **版本與身份**
>
> 本次讀現有Lab0fb6f43/Sim57ee494固定快照，不能當2023原文全部實驗的精確重現；HSSD Spot範例明確採kinematic模式。

領域	居家整理與清潔、協助、交接與陪伴
環境	HSSD等父資產中的Spot和human avatar，含互動/協作設定；Habitat3是平臺版本，不新增整份與Habitat2不重疊的房屋資料。
任務	social navigation、人機共同場景與協作重排；本筆以social navigation深入讀code，不能由平臺支援列表計所有可評task。
題數與資料	YAML固定agent0 Spot/agent1 human，分別有velocity/停止/oracle等actions，區域性定位、另一agent資訊、humanoid detection與RGB-D/深度等配置。所列sensor與policy實際obs_keys要分別儲存。
評估方式	SocialNavSeekSuccess在安全距離區間且朝向條件成立時累加following_step，未在離開區間時歸零；達門檻後可再要求當前角度。不是連續跟隨時長；use_geo_distance、min/max距離、face/look配置及機體索引均影響判定。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **59** 實驗HSSD scenes · 原文頁 7, 26
- **2** social task families · 原文頁 6
- **150** 基底test episodes · 10scene×15 · 原文頁 26

依這個順序讀

1. README.md ↗
   GitHub · facebookresearch/habitat-lab · 0fb6f43ffe

   三代Habitat同庫、HITL與multi-agent角色

   L14–78

---

2. README.md ↗
   GitHub · facebookresearch/habitat-sim · 57ee4941dc

   模擬器 / 資產角色和三代引用

   L14–27 · L47–70

---

3. habitat-lab/habitat/config/benchmark/multi_agent/hssd_spot_human_social_nav.yaml ↗
   GitHub · facebookresearch/habitat-lab · 0fb6f43ffe

   Spot+human、HSSD、actions/sensors與kinematic模式

   L1–66

---

4. habitat-lab/habitat/tasks/rearrange/social_nav/social_nav_sensors.py ↗
   GitHub · facebookresearch/habitat-lab · 0fb6f43ffe

   距離/朝向/累積跟隨步數的具體成功條件

   L469–551

怎麼接入我們的benchmark

可重用

agent/機體/資產配置、互動action/sensor契約、具體social success與細項measure。

需要轉換

environment連HSSD父來源，case固定各agent可見資訊、控制/模擬模式及人類行為來源；metric存累積步數/距離/朝向與時間單位。

仍需補齊

原Habitat3論文版本的全episode/asset組合、其他協作task predicates、真實human traces與共同protocol、原生執行驗證。

P143 · PARTNR

PARTNR: A Benchmark for Planning and Reasoning in Embodied Multi-agent Tasks

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

PARTNR的題目已包含命題、依賴與過程限制。判分追蹤何時完成，並用約束取消不合法的命題，不能只比對最後物件位置。

> **版本與身份**
>
> 固定ddfff19；先前已取得111652train+1000val題目metadata是不同階段的庫存，不因本次code核讀再加一次。Habitat-Sim0.3.3及HSSD partnr版本需要與本paper繫結。

領域	居家整理與清潔、餐飲與烹飪、協助、交接與陪伴
環境	Habitat中的人/機器人協作與HSSD partnr資產；房屋與episode分開，val_mini/train_2k是原split子集而非新獨立資料。
任務	自然語言規劃/協作、具體物件目標與前後順序/同物件等約束；Agent使用Tool/Skill和WorldGraph，因此可支援多模態工具流程的來源設計。
題數與資料	CollaborationEpisode繼承scene/初態，再存instruction、evaluation_propositions、proposition_dependencies、evaluation_constraints、object_states。quantity可unroll成多命題，需保留原/展開ID；真值條件和planner可見world graph不同。
評估方式	先按依賴決定哪些proposition能評，記首次滿足時間；TemporalConstraint要求前置嚴格更早，TerminalSatisfaction要求指定命題在最後仍成立。percent_complete是已滿足且未被任一constraint取消的命題比例，空命題回0；success需比例==1。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **60** 論文house scenes · 原文頁 5, 7
- **4** task characteristic types · 原文頁 4, 7
- **100,000** 論文train scene-goal episodes · 原文頁 7
- **1,000** 論文test episodes · 原文頁 7

依這個順序讀

1. `README.md` ↗
   GitHub · facebookresearch/partnr-planner · ddfff19f4b

   原作、agent/planner/tool/skill、集中/分散與資訊流

   L1–36 · L46–79

---

2. `INSTALLATION.md` ↗
   GitHub · facebookresearch/partnr-planner · ddfff19f4b

   Habitat0.3.3、HSSD partnr和原episodes依賴

   L14–26 · L32–62

---

3. `habitat_llm/agent/env/dataset.py` ↗
   GitHub · facebookresearch/partnr-planner · ddfff19f4b

   CollaborationEpisode欄位與constraint類別解析

   L30–54 · L101–129

---

4. `habitat_llm/agent/env/measures.py` ↗
   GitHub · facebookresearch/partnr-planner · ddfff19f4b

   數量展開、首次滿足時間、constraint與success鏈

   L84–154 · L182–196 · L219–259

---

5. `habitat_llm/agent/env/evaluation/evaluation_functions.py` ↗
   GitHub · facebookresearch/partnr-planner · ddfff19f4b

   時序DAG、終態持續條件與percent-complete分母

   L354–381 · L421–450 · L453–525 · L601–677

怎麼接入我們的benchmark

可重用

原生episode、命題/依賴/DAG/終態規則、agent/tool資訊契約與評分軌跡。

需要轉換

case儲存原命題及展開對映、agent許可權/觀測/工具/步數預算；evaluator保留首次時間和完整state sequence，不能扁平化為一組終態AND。

仍需補齊

全部scene/asset/skill版本閉合、原始split和環境去重、模態/工具預算公平性、原生與共同grader對照執行。

P144 · CAP / EgoGym

Contact-Anchored Policies: Contact Conditioning Creates Strong Robot Utility Models

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

CAP/EgoGym來源有公開policy和real2sim抓取路徑；此路徑的稀疏成功是提升高度，且包含重力補償輔助，不能由此推定完整EgoGym實驗全部已可重現。

> **版本與身份**
>
> 固定8ab1117；目前深入的是公開real2sim pick流程，未宣稱每個CAP應用、全部人類資料與實機checker皆公開或已執行。

領域	居家整理與清潔、辦公與教育
環境	MuJoCo real2sim scene.xml和可替換物件/幹擾物，另有實機/人類gripper資料；物件asset、機體與scene設定應各自有ID。
任務	接觸條件化policy；已核對的RUM-Pick-v0是具體抓取測試，不等於原文所有utility/EgoGym任務。
題數與資料	loader按同一trajectory slice取RGB、可選depth及action；sim observation含RGB和object_2d/3d_position。評測可明確使用這些位置作conditioning，屬資訊預算差異；2D投影引數480×360與obs宣告256需核對。
評估方式	default sparse以物件升高>carry_threshold(.02)給1，terminated=bool(reward)。dense模式reward一般非零，不能沿用此termination當成功。step含600次physics控制、首次grasp另gravcomp=1和2000步，應保留輔助/成本設定；總成功按指定episode數聚合。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **424** 資料收集environments · 原文頁 4
- **3** utility task families · 原文頁 2, 7, 8
- **20,365** demonstrations · 原文頁 4
- **250** real Pick trials · 原文頁 8

依這個順序讀

1. `README.md` ↗
   GitHub · jeffacce/cap-policy · 8ab11176ec

   精確論文與發布/硬體指南

   `L1–20`

---

2. `imitation-in-homes/dataloaders/decord_dataset.py` ↗
   GitHub · jeffacce/cap-policy · 8ab11176ec

   video/action/depth共享切片索引和資料格式

   `L237–251` · `L285–292` · `L326–351`

---

3. `imitation-in-homes/real2sim/tasks/pick.py` ↗
   GitHub · jeffacce/cap-policy · 8ab11176ec

   原生action、目標觀測、carry threshold與輔助physics

   `L22–61` · `L99–189`

---

4. `imitation-in-homes/real2sim/evaluate.py` ↗
   GitHub · jeffacce/cap-policy · 8ab11176ec

   object/seed排程、2D/3D/無條件與分母

   `L16–51` · `L140–188` · `L190–213`

怎麼接入我們的benchmark

可重用

原物件/場景配置、資料切片、目標條件與稀疏lift checker。

需要轉換

case區分2D/3D/無條件與合法觀測，儲存位置單位/解析度、7D增量/Euler與gripper閾值、physics substeps及重力輔助。

仍需補齊

完整EgoGym原生manifest/接觸標註、所有utility task規則、素材/模型與校準、dense/sparse判分分離及原文對照。

P145 · NIABench

Assistance Without Interruption: A Benchmark and LLM-based Framework for Non-Intrusive Human-Robot Assistance

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

NIABench有候選動作詞庫、何時/做什麼的ranker與AI2-THOR示例，但詞庫不等於評測題。所讀simulation示例是固定人機階段，尚需完整benchmark閉環。

> **版本與身份**
>
> 固定45065e5；README保留舊renytek13 clone路徑，當前官方組織庫與精確題名一致。未執行模擬或模型。

領域	居家整理與清潔、餐飲與烹飪、辦公與教育、協助、交接與陪伴
環境	AI2-THOR多agent場景；公開7個simulation指令碼是示例，沒有據此推算完整benchmark環境數。
任務	在不打斷人類多步活動的前提下選協助時刻及robot action；candidate primitive、human step、完整episode是不同層級。
題數與資料	InterventionDataset期待human_task_seq、robot_vocab與oracle_labels(best_robot_action/human_step_idx)，每個oracle label成一訓練example；缺失action會落到index0/unknown no_op，匯入應另外檢查。公開robot_instructions為類別詞庫，訓練episode/權重另待取得。
評估方式	reason.py對B×S×C logits joint argmax選step/action；simulation示例固定human→robot→human，不直接呼叫ranker結果。utils把total_step_count印為Human、人類實做數印Human Saved，需回讀真實分子/分母；影片每frame重複兩次也不能當實際時長。完整非幹擾/省力metric仍需閉合。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **4** room categories · 原文頁 3
- **7** held-out代表tasks/episodes · 原文頁 3, 5
- **2,000** scripted corpus episodes · 原文頁 3

依這個順序讀

1. `readme.md` ↗
   GitHub · Cognition2Action-Lab/NIABench · 45065e59df

   原作、model/模擬入口與AI2-THOR來源

   L1–11 · L59–86

---

2. `datasets/robot_instructions.json` ↗
   GitHub · Cognition2Action-Lab/NIABench · 45065e59df

   候選primitive動作片段，不是完整case

   L1–80

---

3. `model.py` ↗
   GitHub · Cognition2Action-Lab/NIABench · 45065e59df

   human_task_seq/robot_vocab/oracle_labels轉訓練example

   L114–158

---

4. `reason.py` ↗
   GitHub · Cognition2Action-Lab/NIABench · 45065e59df

   step×candidate joint argmax與未知詞/預設路徑

   L46–164

---

5. `simulation/cut_tomato.py` ↗
   GitHub · Cognition2Action-Lab/NIABench · 45065e59df

   FloorPlan28兩agent固定示例流程

   L1–47 · L103–115

---

6. `simulation/utils.py` ↗
   GitHub · Cognition2Action-Lab/NIABench · 45065e59df

   原生步數計數、影片重複frame與輸出標籤

   L1–43 · L190–214

怎麼接入我們的benchmark

可重用

人類計畫/候選動作/oracle schema、joint決策介面、示例scene與步數紀錄。

需要轉換

case固定人類主計畫、合法協助時機與候選集合；原primitive詞庫對映task而非當題庫；evaluator另明定幹擾、助益、任務完成與計算分母。

仍需補齊

完整benchmark episodes/split/權重、ranker到simulation接線、真正省力/非幹擾scorer、原始評估結果與實機協定。

P146 · DexH2R

DexH2R: A Benchmark for Dynamic Dexterous Grasping in Human-to-Robot Handover

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

DexH2R提供人到機器人的動態交接資料與抓取/接近策略。所讀DP評測將進入最終抓取插值記為成功，不能直接解讀為真實物件已穩定交接。

> **版本與身份**
>
> 固定43c5e5c；README仍用wang-youzhuo舊owner和空DiffusionPolicy連結，所讀為4DVLab當前固定版。只核讀列出的DP核心片段，未宣稱CVAE/MotionNet全部核讀。

領域	協助、交接與陪伴
環境	真實多視角人類交接，Kinect/RealSense/ZCam合計18視角；人類MANO與Shadow Hand qpos、物件mesh/point cloud及逐時刻物件pose。相機數不當作環境數。
任務	動態靈巧抓取、人到機器人的接近與交接；subject/object/sequence形成資料階層，grasp pose preparation和approaching motion是方法/子流程。
題數與資料	原資料按subject zip；sequence含calibration、mano、obj_pose、qpos和real_obj_pcd。depth原始int16需按檔案轉uint16；DP loader又將image/depth除255，需區分原始物理深度與模型輸入。Zarr包含agent_pos/action/final_grasp/traj_index等；先建隨機val_mask後被索引區間覆寫，應儲存實際mask_start/end。
評估方式	compute_pose_distance最後只回傳平移距離×100(cm)，算出的旋轉差未加入。接近門檻、非零物件變化與最少frame觸發ls_interpolate，dp_success_rate取此旗標。安全率扣除GT穿透基線後判斷是否零穿透；名為max_pener_depth的量在累加後除總frame，不能直接稱最大深度。這是靜態程式判讀，未跑策略。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **1** dynamic handover family · 原文頁 3, 6
- **56** objects · 原文頁 3
- **4,282** handover trials · 原文頁 3
- **803** test trajectories · 原文頁 7

- **79,911** successful grasp poses · 原文頁 3, 7

依這個順序讀

1. `README.md` ↗
   GitHub · 4DVLab/DexH2R · 43c5e5c948

   論文身分、18視角、subject/object/sequence及相機標定

   L1–85

---

2. `DiffusionPolicy/DP/diffusion_policy/dataset/eval_dp_dataset.py` ↗
   GitHub · 4DVLab/DexH2R · 43c5e5c948

   Zarr欄位、明確episode切片與RGB/depth預處理

   L14–58 · L86–121

---

3. `DiffusionPolicy/DP/diffusion_policy/workspace/eval_dp_baseline_workspace.py` ↗
   GitHub · 4DVLab/DexH2R · 43c5e5c948

   平移距離、插值觸發、穿透修正與輸出metrics

   L123–129 · L349–377 · L401–423 · L575–607

怎麼接入我們的benchmark

可重用

多相機標定、原生split、物件與手姿態、DP輸入及指標公式。

需要轉換

environment繫結拍攝/標定與robot；task描述交接條件；case保留subject/object/sequence與完整初態；將接近、抓取穩定、交接完成分別定義evaluator。

仍需補齊

資料/mesh資產取得、depth尺度驗證、穿透函式及最末trajectory匯總完整查核、實際穩定抓取/交接checker與重現。

P147 · HRIBench

HRIBench: Benchmarking Interaction-Centric Human-Robot Collaboration

實作尚未確認 · 主來源 · 原作 · 獨立頁面

此篇2026 HRIBench研究互動型人機協作，與2025年的同名感知benchmark不同；目前核對的原文與搜尋未確認其官方程式庫。

> **版本與身份**
>
> 核對2607.13056v1及cached exact-title/HRIBench搜尋；命中interaction-lab/HRIBench對應另一篇2025感知工作，未作此篇實作。no_confirmed_code_repository是本次有界查核結果。
>
> P147是Interaction-Centric Human-Robot Collaboration；P168是2025 robot perception，兩者保留不同source ID。

領域	協助、交接與陪伴
環境	論文設計動態人類、物件與robot共處的模擬互動場景；可變layout/人類動作/時序/視角，尚無取得的scene asset或instance manifest。
任務	論文p4分Instructor、Collaborator、Intruder三角色，13個task，每task超過50trajectory variants，合計超過650episode；數量屬論文宣告。
題數與資料	論文scenario script將每個act寫為(role,goal,temporal/causal constraints,human-motion distribution,reward/success)。生成經指令碼、場景、motion synthesis與simulation filtering；尚未取得序列/標註與可解析schema。
評估方式	論文p5列Effectiveness(CSR/CT/IR)、Coordination(TSync/Rsp/OC)、Safety/robustness(CFR/HCS/CIR/DSR)；未取得對應實作，因此只作原作協定記錄，不宣稱已跑或可直接整合。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **13** role-conditioned tasks · 原文頁 4
- **786** 驗證trajectory pool · 原文頁 6
- **650** adaptation trajectories · 13×50 · 原文頁 6
- **130** 主held-out eval trajectories · 13×10 · 原文頁 6

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

角色/互動指令碼分解、13任務與650+episode的原作規模及多維評估構想。

需要轉換

task儲存人類角色/目標/允許介入，case固定motion/timing seed；每個指標指向其原文公式和未來scorer；不可合併P168同名HRIBench。

仍需補齊

官方repo/資料入口、13task清單與case manifest、成功/安全/恢復checker、生成資產與執行重現。

P148 · Assistax

Assistax: A Multi-Agent Hardware-Accelerated Reinforcement Learning Benchmark for Assistive Robotics

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

Assistax有明確的JAX/Brax/MJX環境、雙agent觀測/動作與獎勵介面；feeding原始done固定0，累積回報不能當成餵食完成率。

> **版本與身份**
>
> 固定a7d94f4；目前registry多於README頂部5張照護示意圖，應以註冊清單標明當前版本。未執行JAX、訓練或臨床評估。

領域	個人照護、協助、交接與陪伴
環境	目前registry有scratchitch、bedbathing、armmanipulation、pushcoop、handover、feeding、teethbrushing共7個環境類別；這是程式註冊名稱數，非房間/layout數。
任務	生活照護與協作控制；不同task指定human/robot或robot1/robot2。disability、preference及sparse reward是可選協定設定，不自行增加語義任務。
題數與資料	功能式reset/step使用JAX key和state，按agent分obs/action/reward/done。feeding機器人7 actuator、人類頭部2 actuator；觀測含pose、force與joint angle，屬state-based而非預設RGB視覺題。episode_length預設1000、action_repeat預設1。
評估方式	feeding混合距離、姿態、速度、口部接觸力與控制成本；原始done=0，結束依外層episode wrapper。MASAC回報mask在首次done後截斷；__all__在heterogeneous模式取agent reward平均。使用者偏好/身體受限設定改變score，必須隨case記錄。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **5** assistive tasks · 原文頁 5
- **630** 每task partner policies · 原文頁 7
- **625** 每task unseen partners（非episodes） · 原文頁 9
- **64** MARL每次評測episodes · 原文頁 8

依這個順序讀

1. `README.md` ↗
   GitHub · assistive-autonomy/assistax · a7d94f4e20

   官方題名、套件用途及multi-agent介面

   L1–85

---

2. `assistax/envs/__init__.py` ↗
   GitHub · assistive-autonomy/assistax · a7d94f4e20

   7個registry名稱及episode/auto-reset/preference wrapper順序

   L28–97

---

3. `assistax/envs/base_env.py` ↗
   GitHub · assistive-autonomy/assistax · a7d94f4e20

   agent actuator索引、全域狀態分流與shared/heterogeneous reward

   L20–69 · L104–121 · L215–241

---

4. `assistax/envs/feeding.py` ↗
   GitHub · assistive-autonomy/assistax · a7d94f4e20

   feeding觀測、距離/速度/力等獎勵及done=0

   L175–204 · L245–310

---

5. `assistax/baselines/MASAC/eval_masac.py` ↗
   GitHub · assistive-autonomy/assistax · a7d94f4e20

   只累計第一次episode結束以前的未折扣回報

   L69–80

怎麼接入我們的benchmark

可重用

registry、actuator/observation對映、wrapper引數、具體獎勵與return聚合。

需要轉換

source固定commit；environment儲存task類別/MJX資產與控制設定；case儲存人類policy、preference、disability、seed與時限；evaluator分原生return和另定的任務完成條件。

仍需補齊

其餘6環境完整checker、資產/控制介面實測、統一測例清單、各方法在相同人類策略/偏好下的基線。

P149 · V-JEPA 2

V-JEPA 2: Self-Supervised Video Models Enable Understanding, Prediction and Planning

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

V-JEPA 2同庫包含2、2-AC及較新2.1。可復用EPIC動作預測評測與DROID reader，但既有資料集和新模型結果不能另算一套獨立任務庫。

> **版本與身份**
>
> 固定204698b；當前README已加入2.1，本條文獻仍為2506.09985的V-JEPA 2，不把2.1新增內容當作原版論文成果。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	自然影片理解/預測與DROID真實機器人軌跡；原資料的廚房、場景和相機沿用父來源，不因V-JEPA checkpoint新增環境。
任務	影片理解、下一動作anticipation、action-conditioned latent預測與影像目標規劃是不同評估用途；本次程式核讀重點為EK100與DROID，不據此列出完整機器人測例。
題數與資料	EK100使用start_frame/stop_frame、verb_class/noun_class；32frame、8fps及1秒時間設定需保留。實作取af=sf×ap+(1−ap)×ef−at×fps，val預設ap=0，應核定該stop-frame基準與目標協定；不足歷史以首frame補。DROID從trajectory.h5載入cartesian_position/gripper_position及相機外參，降取樣後算平移/相對旋轉/夾爪變化量；失敗樣本會隨機換另一樣本。
評估方式	ClassMeanRecall預設top5，recall對有出現的類別平均，accuracy對樣本平均，均乘100。validation對多個probe分別取accuracy/recall最大值，可能不是同一probe；不能當單一固定模型完整結果。機器人任務成功checker未在本次所讀路徑確認。

依這個順序讀

1. `README.md` ↗

   GitHub · facebookresearch/vjepa2 · 204698b45b

   論文身分與2/2-AC/2.1版本範圍

   L1–75

2. `configs/eval/vitl/ek100.yaml` ↗
   GitHub · facebookresearch/vjepa2 · 204698b45b

   EK100 split、32frame/8fps與預測時間設定

   L1–38

3. `evals/action_anticipation_frozen/dataloader.py` ↗
   GitHub · facebookresearch/vjepa2 · 204698b45b

   實際導向EK100 reader

   L15–81

4. `evals/action_anticipation_frozen/epickitchens.py` ↗
   GitHub · facebookresearch/vjepa2 · 204698b45b

   標註frame到合法觀測區間的實際公式

   L99–154

5. `evals/action_anticipation_frozen/eval.py` ↗
   GitHub · facebookresearch/vjepa2 · 204698b45b

   val時間點預設及多probe分項max聚合

   L90–101 · L230–277 · L640–710

6. `evals/action_anticipation_frozen/metrics.py` ↗
   GitHub · facebookresearch/vjepa2 · 204698b45b

   class-mean recall和sample accuracy不同分母

   L1–58

7. `app/vjepa_droid/droid.py` ↗
   GitHub · facebookresearch/vjepa2 · 204698b45b

   DROID影片/HDF5對齊、相機座標與相鄰狀態差分action

   L87–229

怎麼接入我們的benchmark

可重用

EK100評估公式與split介面、DROID姿態/外參/視角的資料流程。

需要轉換

來源關聯指向EPIC/DROID；case顯式儲存觀測截止、target frame、補幀與樣本替代策略；action儲存delta與camera_frame選項；evaluator保留topk、分母和probe選擇規則。

仍需補齊

觀測時間基準核驗、完整robot planning/evaluation協定、資產/權重取得、固定case而非重抽樣及原生重現。

P150 · DreamDojo

DreamDojo: A Generalist Robot World Model from Large-Scale Human Videos

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

DreamDojo具有動作條件影片生成的真實評估入口；核心輸出為PSNR/SSIM/LPIPS。預訓練影片時數、評估樣本與機器人可執行任務需分開。

> **版本與身份**
>
> 固定02f119b；從docs/EVAL追到cosmos_predict2/action_conditioned.py，不誤把套件內一般VQA metrics當作本論文主scorer。沒有下載44k小時資料或權重。

領域	居家整理與清潔、辦公與教育、工藝與修繕、裝配與生產作業、零售與購物、交通移動與車輛維修
環境	GR-1實驗室機器人影片、EgoDex與DreamDojo-HV評估素材；人類影片庫是預訓練來源。README宣稱44k小時不表示本次已取得或等量可評測。
任務	由首影格和動作序列預測後續影片；檔案In-lab清單含10個原生dataset路徑，另有EgoDex/HV兩組來源。路徑、100個抽樣與49frame是不同單位。
題數與資料	統一reader輸出 video/lam_video/action/fps/num_frames/__key__/padding_mask/image_size/ai_caption；根據path字串選MANO、一般影片或LeRobot。LeRobot schema保留state/action的start/end、rotation_type、absolute。restrict_len可以指定100，不等於底層獨立episode總量；檔案定義train前95%、test後5%，full全量，須落實固定抽樣清單。
評估方式	生成片與GT先轉[0,1]逐frame算PIQ PSNR/SSIM/LPIPS，再對樣本平均；這段沒有排除首個條件影格。恢復篩選查詢*_psnr.json但輸出為*_metrics.json，可能重算；plot指令碼只接受恰501個檔的資料夾。以上是程式限制，尚未執行驗證，也不是robot物理成功率。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **43,827** DreamDojo-HV video hours · 原文頁 5
- **44,711** three-source mixture hours · 原文頁 5
- **6,015** GPT-estimated skill/task labels · 原文頁 5

- **25** samples per edited-background eval set · 原文頁 10

依這個順序讀

1. `README.md` ↗
   GitHub · NVIDIA/DreamDojo · 02f119b759

   官方論文、資料/模型與公開範圍

   L1–56

---

2. `docs/EVAL.md` ↗
   GitHub · NVIDIA/DreamDojo · 02f119b759

   三類評估集及49frame/100sample抽樣設定

   L1–47

---

3. `eval.sh` ↗
   GitHub · NVIDIA/DreamDojo · 02f119b759

   實際入口與本機路徑/連續checkpoint輪詢設定

   L1–16

---

4. `groot_dreams/data/schema.py` ↗
   GitHub · NVIDIA/DreamDojo · 02f119b759

   LeRobot state/action切片、absolute與rotation metadata

   L28–105

---

5. `groot_dreams/dataloader.py` ↗
   GitHub · NVIDIA/DreamDojo · 02f119b759

   資料型別dispatch、欄位、抽樣和restrict_len語義

   L1–168 · L193–227

---

6. `cosmos_predict2/action_conditioned.py` ↗
   GitHub · NVIDIA/DreamDojo · 02f119b759

   case選取、生成/GT比較及metric聚合

   L278–304 · L366–407

---

7. `scripts/plot_psnr.py` ↗

   GitHub · NVIDIA/DreamDojo · 02f119b759

   繪圖依固定輸出檔案數篩選的限制

   L15–40

怎麼接入我們的benchmark

可重用

評估集分組、LeRobot modality metadata、可追到metric實作的生成入口。

需要轉換

以原生clip/episode ID和實際取樣frame作case；儲存action representation、完整GT影片及不可見未來、scorer前處理；預測影片與物理環境分列，父EgoDex重用關係明確。

仍需補齊

固定抽樣及ID清單、checkpoint/套件版本、條件影格是否計分與斷點恢復修正、原生跑分和物理行為有效性checker。

P151 · H2R-Bench

H2R-Bench: Benchmarking Human-to-Robot Manipulation Video Generation in World Models

檔案 / 網站 · 主來源 · 原作 · 獨立頁面

H2R-Bench的官方GitHub目前主要是展示網站。README明列240個影片轉換case與5維加權指標，但評估程式與標註尚未放在此庫。

> **版本與身份**
>
> 固定6549ae1，README L73明說evaluation code與benchmark annotations尚不在庫內；本次處置為website_only。

領域	衣物與洗護、通用物件與機動作業
環境	EgoDex test來源的人類第一人稱操作片，轉成平行夾爪或靈巧手的影片；兩個target embodiment不自動等於兩種實體場景。
任務	將同一人類示範轉成指定robot embodiment影片；README記錄6個操作家族，120source clips×2embodiments=240transfer cases；11是模型數。
題數與資料	公開庫的主要內容在docs/專案網站，評估標註與可直接載入的case manifest未提供；因此240為原作宣告，不記為本次已整合題量。EgoDex為父來源。
評估方式	H2RCore=100×(0.15目標狀態+0.15事件完成+0.30功能接觸轉移+0.30機體正確+0.10影片品質)。所讀README提供定義/榜單，未提供足以重現的scorer或標註，影片高分不代表真實robot完成。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **6** manipulation families · 原文頁 4
- **120** source clips · 原文頁 4
- **240** video-transfer cases · 原文頁 4, 5

依這個順序讀

1. README.md ↗

   GitHub · Rongdingyi/H2R-Bench · 6549ae11bb

   論文作者/ID、案例組成、H2RCore公式與未公開宣告

   L1–75

怎麼接入我們的benchmark

可重用

來源120clip×2embodiment的case設計、5項指標權重與公開榜單作比較參考。

需要轉換

先建source/task/evaluator規格記錄；取得EgoDex子集ID後建立lineage與240case清單；各分項與總分一起保留。

仍需補齊

case標註、來源clip ID、生成條件、評審rubric/程式與評分一致性驗證。

P152 · RoboWM-Bench

RoboWM-Bench: A Benchmark for Evaluating World Models in Robotic Manipulation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

RoboWM-Bench把生成影片經IDM/手部軌跡抽取後放入Isaac Lab評估，能連到真實task checker；其成功定義仍須逐題保留，不能只比較影片品質。

> **版本與身份**
>
> 固定0a8b0ea；README的Code badge實際連HF權重，核讀本GitHub內實作。未安裝Isaac或執行任何世界模型。

領域	餐飲與烹飪、衣物與洗護、通用物件與機動作業
環境	IsaacSim5.1與庫內IsaacLab_5_1、LeHome式操作場景；robot track列7個Gym名稱，其中pull_and_push共享名稱。human track列12個原生task目錄；不能加上隨附IsaacLab全部任務當RoboWM規模。
任務	robot影片經IDM解碼為Franka動作；human影片經Phantom抽手軌跡再執行。pick/擺盤/丟垃圾/抽屜/按鈕/推拉及human track柔性、倒水等，各有獨立判分。
題數與資料	World-model輸入為初始RGB和prompt；robot軌跡檔名.json實為每行一個action，pose.jsonl依episode檔名索引。parquet轉檔按episode尾3位排序後重編0..N，須儲存對映避免pose錯配。Franka為7arm+2gripper joint targets，夾爪有額外閾值與關節裁切。
評估方式	回放先30step穩定，再取軌跡中曾成功；例外回False列入attempts。pick用abs(z−ori_z)>0.05，未限制向上；擺盤成功只看XY各≤0.15；倒水預設至少1%粒子落在XY±0.02、Z±0.5的對稱盒內。step_interval計數跨呼叫，部分成功條件不檢查穩定、容器內部或釋放；需保留原版並另定嚴格擴充。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **8** 主表human-hand task條件 · 原文頁 7
- **8** 主表robot task條件 · 原文頁 7
- **6** 附錄sim-native task條件 · 原文頁 14
- **10** 每task共享initial configurations · 原文頁 6

依這個順序讀

1. `README.md` ↗
   GitHub · fffstrong/RoboWM-Bench · 0a8b0eab3e

   世界模型→動作→模擬流程、環境版本和兩種track

   L1–125 · L149–218

---

2. `tools/parquet_actions_to_json.py` ↗
   GitHub · fffstrong/RoboWM-Bench · 0a8b0eab3e

   parquet action逐行輸出及重新編號/pose配對

   L24–43 · L70–95

---

3. `scripts/robot/eval_franka.py` ↗
   GitHub · fffstrong/RoboWM-Bench · 0a8b0eab3e

   動作裁切、30step穩定、any-time success與分母

   L123–138 · L207–241 · L285–355 · L419–439 · L481–505

---

4. `source/lehome/lehome/tasks/franka_task/Task00_Pick/pick.py` ↗
   GitHub · fffstrong/RoboWM-Bench · 0a8b0eab3e

   joint target與pick checker實際呼叫

   L125–156 · L291–300

---

5. `source/lehome/lehome/tasks/franka_task/Task01_Put_on_plate/tableware.py` ↗
   GitHub · fffstrong/RoboWM-Bench · 0a8b0eab3e

   分階段contact/lift/place

   L328–372

---

6. `source/lehome/lehome/utils/success_checker.py` ↗
   GitHub · fffstrong/RoboWM-Bench · 0a8b0eab3e

   間隔檢查、絕對高度差、XY對齊和水粒子近似

   L1–26 · L63–90 · L115–141 · L197–208 · L430–467

---

7. `source/lehome/lehome/tasks/human_task/Task07_Franka_Tableware_Pour_Water/tableware.py` ↗

   GitHub · fffstrong/RoboWM-Bench · 0a8b0eab3e

   human track倒水實際呼叫預設checker

   L364–373

怎麼接入我們的benchmark

可重用

兩條video-to-action管線、原始初圖/prompt、具體success與stage score。

需要轉換

case固定原影片ID、解碼器/軌跡/pose對映及sim資產；將影片生成、動作解碼、物理回放結果分別儲存；新增規則用新evaluator版本，不覆寫原作score。

仍需補齊

完整初態/資產取得、原生case清單、各task checker全覆蓋、時間/間隔計數核驗、IDM/Phantom抽取誤差與GPU執行基線。

P153 · EgoExo-Gen

EgoExo-Gen: Ego-centric Video Prediction by Watching Exo-centric Videos

實作尚未確認 · 方法 / 綜述 · 原作 · 獨立頁面

EgoExo-Gen先預測跨視角手物mask再生成第一人稱影片；原作實驗是Ego-Exo4D子集及H2O轉移，目前未確認其官方實作repo。

> **版本與身份**
>
> 核對2504.11732 ICLR2025原文p5–6與cached題名/EgoExo-Gen搜尋。搜尋的awesome lists只保留為線索，沒有當作本篇官方code。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	Ego-Exo4D cooking來源涵蓋60location、564小時的原生子集描述；H2O作外部分佈測試，不新增物理robot環境。
任務	Exo影片及HOI mask+Ego首影格→未來Ego mask/影片；cross-view mask prediction與video generation是兩個評估輸出。
題數與資料	原文p6列33,448訓練clip、平均1秒；validation抽1000clip，其中500標HOI mask；H2O val122clip。16frame模型輸入、mask480²與影片256²；選4個exo視角中手mask比例最高者，需保留view selection。此為原文數量，未下載case。
評估方式	Mask用IoU、對齊質心後的Contour Accuracy、正規化質心Location Error；影片用SSIM/PSNR/LPIPS/FVD。不同mask/影片子集及source split不可混同；缺官方scorer和明確clip ID。

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

Ego/Exo同步父來源、兩階段HOI建構、原生指標與子集設計。

需要轉換

source關聯Ego-Exo4D/H2O；case儲存take/clip/view/narration、可見exo完整影片和ego首影格；GT mask不可直接視為所有方法合法輸入。

仍需補齊

官方實作、clip ID/annotation release、mask生成版本與data leakage檢查、相同前處理的評估指令碼。

P154 · Hand-conditioned ego predictive model

Ego-centric Predictive Model Conditioned on Hand Trajectories

實作尚未確認 · 方法 / 綜述 · 原作 · 獨立頁面

Ego-PM論文明確連到showlab/Ego-PM，但本次API取得回404；已記下原文的兩階段預測/評測設計，不把失效入口當作已核讀程式。

> **版本與身份**
>
> 2508.19852v2 p1提供明確URL；2026-10-10T07:46:30Z API回404。404僅證明該次無法取得，不推定作者從未公開或不存在。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	Ego4D人類第一人稱影片、BridgeData及RLBench下游測試；p1圖另標Meta-World，需要實作/資產版本才能釐清完整場景範圍。
任務	先預測hand trajectory，再以其為條件逐frame預測視覺結果；原文p5列RLBench9task。single-step和consecutive prediction是協定設定，不自動增加語義任務。
題數與資料	輸入為歷史視覺、語言與action history；輸出hand action與future frame。未取得loader、split manifest、座標/時間尺度或BridgeData實體完成標註。
評估方式	人類資料以hand mask IoU衡量action prediction；影片用EgoVLP/CLIP/FID/SSIM/PSNR/LPIPS等；robot章節報Success Rate。沒有code時不能把手mask IoU當robot success，也無法核驗物理checker。

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

論文的觀測→手軌跡→視覺未來結構、跨資料集評估專案。

需要轉換

先登入source與proposed task/evaluator；待repo可取再建立case及native fields；保持Ego4D/Bridge/RLBench lineage。

仍需補齊

可取得的官方repo、原始case/split、軌跡格式、評估前處理及物理完成checker。

P155 · EgoExo-WM

EgoExo-WM: Unlocking Exo Video for Ego World Models

檔案 / 網站 · 方法 / 綜述 · 原作 · 獨立頁面

EgoExo-WM原作頁面仍將Code標為Coming Soon；可整理其人類全身動作世界模型協定，尚無取得的官方loader/scorer。

> **版本與身份**
>
> 2605.15477v2與2026-10-10已取得的UT Austin官方頁相符，Code仍Coming Soon。原文p7說未發布的是比較方法EgoControl，不誤當本篇可用性證據。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	Nymeria訓練資料及HOMAGE、LEMMA、Ego-Exo4D Bike/Cooking測試影片；將HowTo100M/CrossTask/100DOH的exo片轉ego作訓練。生成視角沿用原拍攝事件lineage。
任務	全身動作條件下的2秒未來視覺預測，另用世界模型替候選人體動作排序；這是人類motion planning評估，不是新增robot物理任務庫。
題數與資料	原文固定200小時訓練預算：190h Nymeria+10h轉換exo；測試描述HOMAGE/LEMMA取150clip、Bike/Cooking各125clip，前兩者150是各組或合計仍待manifest核定，未先加總。2秒=4Hz×8frame；不同來源motion估計器/標註需分開。
評估方式	視覺用DINOv3-L latent L2，動作一致性用wrist PCK@20；pixel與latent方法採不同wrist predictor需保留。planning每case產生4個horizon8候選，以最末latent距goal排序，再評whole-body/wrist MPJPE，5次run均值/標準差；不是取4個GT最小error當部署成功。

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

原生來源lineage、統一2秒/4Hz條件、預測與候選動作排序的分項度量。

需要轉換

source記human-motion schema與frame clock；case分合法goal/obs、候選動作及未來GT；將conversion比例和take/clip重用關係保留。

仍需補齊

官方code/weights與測試clip IDs、150clip範圍、wrist評估器差異、底層actor motion到robot動作的可執行轉換。

P156 · Egocentric survey

Challenges and Trends in Egocentric Vision: A Survey

實作尚未確認 · 方法 / 綜述 · 原作 · 獨立頁面

這篇Ego綜述以subject/object/environment/hybrid四類整理視覺研究，適合補充文獻分類；目前未確認作者提供獨立程式/資料庫。

> **版本與身份**
>
> 已讀2503.15275v4 p2–5；原文後段的EPIC/Ego4D/HOI4D連結是被引用資料源，不當作本survey的implementation。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	文獻中的環境是穿戴相機所見的生活空間、背景結構與互動上下文；綜述本身不產生可執行scene。
任務	四類為主體理解(視線/姿態/動作)、物件理解(社交/人類身分/物體)、環境理解(建模/定位)、混合理解(摘要/多視角/VQA)。屬研究輸出分類，非四個生活用途domain。
題數與資料	原文另按datasets的基礎特性、標註與適用task彙整；圖3指出同影片中action/object/location有不同時間粒度。不可把subject、物體和場景的segment數相加當題數。
評估方式	綜述不提供統一evaluator；各理解/預測任務需回原作保留自己的GT及度量。

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

四類taxonomy、視角動態/遮擋/多粒度挑戰及dataset線索。

需要轉換

研究分類保留source metadata；用途domain由實際活動推導；case限定時間視窗、感測與可見資訊，來源書目和資料量分開。

仍需補齊

作者配套repo確認、被引sources逐一原作查核及實際case/metric取得。

P157 · Human-video robot learning survey

Robot Learning from Human Videos: A Survey

檔案 / 網站 · 方法 / 綜述 · 原作 · 獨立頁面

這是Human-video robot learning綜述的官方閱讀清單，可補分類與來源線索，沒有自己的可執行benchmark或case庫。

> **版本與身份**
>
> 固定6d3c7c7，對應2604.27621；README為持續更新的survey companion，本次選讀所列分類/資料區段。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	分類覆蓋第一/第三人稱資料及真實robot研究；清單不提供自身環境資產。
任務	Information Transfer分task-oriented、observation-oriented、action-oriented；learning formulation另列WAM、VLA、ICL/VCL且明說可重疊。這些是文獻分類，不是新增生活用途或任務數。
題數與資料	每篇列paper/code/project、年份、方法標記；dataset表有viewpoint、組織、原作入口。🌟 表示作者列為有code、🤖 表示有real robot實驗，仍須回原作核驗。
評估方式	沒有自有scorer、split或benchmark leaderboard；方法效能應回各被引用benchmark。

依這個順序讀

1. `README.md` ↗
   GitHub · IRMVLab/awesome-robot-learning-from-human-videos · 6d3c7c7073

   綜述身分、task/observation/action轉移分類與dataset列例

   `L1–32` · `L44–82` · `L136–141` · `L198–211` · `L288–305` · `L450–482`

怎麼接入我們的benchmark

可重用

三類資訊轉移定義、影片資料表、相似工作檢索線索。

需要轉換

每個被引paper解析到source並與既有ID去重；保留survey分類為source metadata，對task的用途另按原作判定；星號不直接提升integration status。

仍需補齊

被引新來源的獨立原文/code核讀、版本和資產授權；清單本身不能生成robot case。

P158 · VLA benchmark survey

Vision-Language-Action in Robotics: A Survey of Datasets, Benchmarks, and Data Engines

檔案 / 網站 · 方法 / 綜述 · 原作 · 獨立頁面

VLA綜述的GitHub清單將資料、benchmark和data engine分開，適合設計對照表；其中預留分類與空code連結不能視為來源不存在。

> **版本與身份**
>
> 固定24b5e02，當前清單有年份/venue格式不一致，正式書目以主庫已核驗原作為準。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	以tabletop/multi-scene描述benchmark場景範圍；不提供自己的環境asset或scene ID。
任務	benchmark採桌面/多場景×短/長序列的四格分類，Multi-Scene+Simple格明列Reserved。dataset另有real/synthetic/mixed；engine有video2data/hardware/generative。
題數與資料	列出論文、網站/code與delta/absolute、EEF/DoF、image/3D/video等標記；同一來源可同時是dataset和engine。來源鏈結仍需原作確認，空連結不代表沒有實作。
評估方式	列出binary/graded success、reset、OOD split、embodiment shift、seeds/task counts/CI的比較要素；未包含可執行統一scorer。

依這個順序讀

1. `README.md` ↗
   GitHub · ziyaow1010/vla-datasets-benchmarks · 24b5e028b7

   資料/benchmark/engine角色、場景×時序分類、比較協定

   L1–95 · L155–199 · L332–346

怎麼接入我們的benchmark

可重用

角色拆分、原生action/觀測標記與比較報告欄位。

需要轉換

清單列只增加source關聯；資料與engine共用同source而非重計；將技術標記保留profile內，公開表仍用領域/環境/任務/題數/評估方式。

仍需補齊

回到各原作補case manifest、scorer、版本與原生計量；不以四格預留內容推斷領域沒有研究。

P159 · tinyBenchmarks

tinyBenchmarks: evaluating LLMs with fewer examples

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

tinyBenchmarks提供用少量anchor題推估原benchmark分數的IRT工具；對本計畫是抽樣與難度校準參考，100題不是所有robot領域適用的固定答案。

> **版本與身份**
>
> 工具固定e9a8b10，原實驗庫c9df154；package缺pickle時連mutable main下載，正式adapter需把數值資產另行固定hash。未執行模型/IRT或pickle。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	原研究為LLM評估題庫，沒有robot物理環境；MMLU、AlpacaEval等是父benchmark。
任務	評估任務是以少數已跑題估計完整benchmark/model表現。100為每個tiny dataset的anchor數，非100個新語義task；模型family外推與題目抽樣需分開切分。
題數與資料	package讀seen_examples、examples_weights、A/B、optimal_lambdas與scenario/subscenario positions；y_input為按anchor順序的response向量。原實驗data包含models與各benchmark結果矩陣，以model row拆IID/non-IID。未下載或反序列化pickle。
評估方式	以sigmoid(sum(a×theta−b))擬合能力，IRT加權anchor、pIRT混合觀測與未測預測、gpIRT再混合；不是補出真正執行結果。README說公開小集從5seed選test平均最佳版本，因此新robot設計應另留獨立validation/test model families，不能直接保證相同誤差。

依這個順序讀

1. `README.md` ↗

   GitHub · felipemaiapolo/tinyBenchmarks · e9a8b1031b

   100anchor設計、資料角色與seed選擇說明

   L1–85

2. `tinyBenchmarks/__init__.py` ↗

   GitHub · felipemaiapolo/tinyBenchmarks · e9a8b1031b

   IRT sigmoid、theta擬合、scenario權重及三種估計式

   L1–105

---

3. `README.md` ↗

   GitHub · felipemaiapolo/efficbench · c9df1547a4

   原論文實驗庫與工具庫區分

   L1–14

---

4. `run_experiment.py` ↗

   GitHub · felipemaiapolo/efficbench · c9df1547a4

   model-level IID/non-IID split及sampling/latent dimension設定

   L1–93 · L155–196

怎麼接入我們的benchmark

可重用

anchor/index/權重、模型response矩陣、IRT估計流程與分佈外評估概念。

需要轉換

先取得本benchmark多policy×case的實測response，再按來源/場域/任務分層；calibration、anchor selection與最終model test分開，預估分數明標estimate並附誤差。

仍需補齊

robot response矩陣、跨policy/embodiment外推驗證、難度引數穩定性與估計CI；不能用目前metadata假造IRT難度。

P160 · Rliable

Deep Reinforcement Learning at the Edge of the Statistical Precipice

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

rliable可為已有的多run、多task結果加上分佈與不確定性；它不定義robot任務，也不能讓不同原生metric自動變可比。

> **版本與身份**
>
> 固定3ccd9f4；API標示archived。這是來源實作核讀，未安裝套件或宣稱CI已計算。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	方法評估庫，不新增環境；原展示使用Atari/ALE/DM Control/Procgen。robot使用時仍保留原environment/source lineage。
任務	對既有task結果作聚合、bootstrap與performance profile，不是新增task registry或case dataset。
題數與資料	輸入每個algorithm的num_runs×num_tasks(×其他維度)矩陣，需固定同一task列順序、metric尺度與missing值策略。不能把不同分佈的未知/不適用填0。
評估方式	mean先按task平均再總平均；median是task均值的中位數；IQM將所有run×task分數flatten後trim25%；optimality gap=gamma−mean(min(score,gamma))。bootstrap預設只重抽run，task_bootstrap才同時抽task；機率提升按task算Mann–Whitney再平均。不同方法同case配對與共享source的相依性需另設計。

依這個順序讀

1. `README.md` ↗
   GitHub · google-research/rliable · 3ccd9f4dea

   原論文身分與run×task矩陣使用方法

   L1–38 · L62–83

2. `rliable/metrics.py` ↗

   GitHub · google-research/rliable · 3ccd9f4dea

   mean/median/IQM/optimality gap/提升機率的具體公式

   `L20–95`

---

3. `rliable/library.py` ↗

   GitHub · google-research/rliable · 3ccd9f4dea

   stratified resampling、固定task或task-bootstrap、CI與profile介面

   `L26–49 · L71–122 · L211–283 · L301–323`

怎麼接入我們的benchmark

可重用

原生公式、CI與performance profiles、固定task集合/未知task母體兩種推論區分。

需要轉換

先對同協定同單位結果建立可比score矩陣；儲存run/case/scene群組與分層權重，再報per-domain及整體CI。公式不直接混合SR、距離與LPIPS。

仍需補齊

真實policy結果矩陣、不同來源群聚重抽樣策略、缺失結果規則、正規化依據；所讀update_indices使用全域np.random，重現時需驗證RNG設定。

P161 · First-person prediction survey

Predicting the Future from First Person (Egocentric) Vision: A Survey

實作尚未確認 · 方法 / 綜述 · 原作 · 獨立頁面

第一人稱未來預測綜述把問題拆為Action、Region、Trajectory三組九種challenge，並明確區分預測與已發生動作辨識。未確認獨立survey實作repo。

> **版本與身份**
>
> 已讀2107.13411 p5/7/14；原文p12的GitHub是個別被引方法，非綜述自行發布的benchmark。論文當時「缺長期共同benchmark」不能當作2026現況。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	原文彙整20份dataset與17項屬性，包括native vs lab環境、場景數、攝影者、scripted與否、audio/hand/object annotations。這些是綜述時點統計，非新獨立資料。
任務	Action含短/長期anticipation與future caption；Region含next active object、hotspot、gaze；Trajectory含wearer、他人/物件、手。另列recognition/segmentation為相關但非future prediction。
題數與資料	短期預測觀測視窗為[action_start−segment_length−anticipation_time, action_start−anticipation_time]。原文分時數、frame、影片、segment、class、environment、subject，正好作計數格式依據。
評估方式	原文p14說明best-of-many、topk/mean recall、ADE/FDE、IoU/mAP不同度量；需固定候選K與預測horizon才可比較，seen/unseen kitchen split也分開。

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

三組九題型、嚴格觀測截止定義、20dataset×17屬性的歷史比較方法。

需要轉換

每個future case記observation_end、target_start、horizon、candidate_budget與parent source；不同模型引用同資料只新增result/relationship。

仍需補齊

各被引方法的版本與case清單、統一時間基準、部署型安全/任務完成評測。

P162 · Egocentric hands survey

Analysis of the hands in egocentric vision: A survey

實作尚未確認 · 方法 / 綜述 · 原作 · 獨立頁面

Hands in egocentric vision綜述使用Localization、Interpretation、Application三層，有助分清手部標註與機器人任務。未確認作者配套GitHub。

> **版本與身份**
>
> 已讀1912.10867 p2/15；其歷史dataset表保留論文年代，不冒稱目前已完整涵蓋所有手部資料。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	頭戴/胸前/肩上攝影位置、RGB/depth感測、原生資料拍攝場景；相機位置不等於三種工作用途domain。
任務	Localization含segmentation/detection/tracking/left-right identification/pose；Interpretation含grasp/gesture/action-interaction/activity；Application使用這些結果作HCI/HRI等。activity可由多個action構成，不能當等粒度task相加。
題數與資料	原文表1按dataset/year/modality/device/camera location/frames/videos/duration/subjects/resolution/annotation列對照，明確區分全部frame和已標註frame；兩個同名EgoGesture也需要年份/作者識別。
評估方式	各定位/姿態/辨識來源有各自label和metric；綜述不是可執行的共同scorer，手部資訊詳細程度也不是經驗證的robot task difficulty。

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

定位→解釋→應用分工、感測/標註/時數/數量欄位與歷史dataset列表。

需要轉換

依原作ID匯入source，手部GT按mask/bbox/joint/gesture等profile儲存；只有指定合法輸入、目標及scorer的片段才升為case。

仍需補齊

所有原生資料與scorer的當前入口、重複來源去重、可轉移到robot action的標定/對應。

P163 · Ego-exo collaboration survey

Bridging Perspectives: A Survey on Cross-view Collaborative Intelligence with Egocentric-Exocentric Vision

檔案 / 網站 · 方法 / 綜述 · 原作 · 獨立頁面

Ego–Exo綜述配套清單可沿跨視角資訊方向整理研究與資料，沒有新增一套獨立機器人評測。

> **版本與身份**
>
> 固定a2f15a0，README連2506.06253、標示最後更新2025-11-14；本次不聲稱清單含其後所有研究。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	第一人稱、第三人稱及同步/多視角資料；原場景仍屬Charades-Ego、Assembly101、Ego-Exo4D等父來源。
任務	以Ego→Exo、Exo→Ego、Joint Learning分研究，內分生成、理解、affordance、檢索、追蹤、操作等；視角方向不是生活用途domain。
題數與資料	表列title/venue/year/code與dataset/paper/project，部分GitHub欄實際是組織頁/網站；需解析到真正reader/evaluator庫。
評估方式	綜述未提供統一scorer；跨視角辨識、生成品質與robot操作成功分開比較。

依這個順序讀

1. `README.md` ↗
   GitHub · ayiyayi/Awesome-Egocentric-and-Exocentric-Vision · a2f15a07fa

   survey身分、三種跨視角方向、操作/資料例子

   `L1–65 · L81–107 · L192–238`

怎麼接入我們的benchmark

可重用

跨視角轉移方向、dataset與code入口作來源追蹤。

需要轉換

將survey→被引source存relation；同一同步拍攝事件的不同視角共用episode lineage，不能當獨立場景或任務倍增。

仍需補齊

每個候選repo的官方身分/版本確認、同步與攝影標定、原生split/scorer和可用case。

P164 · The Imitator Game

The Imitator Game: Benchmarking Robot Imitative Ability Beyond Action Prediction

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

The Imitator Game提供人類影片→robot模仿的配對資料、分級場景與模擬評估。任務完成、軌跡相似及盲測偏好是三種不同證據。

> **版本與身份**
>
> 固定d6d16ec；README對應2608.22301。所讀為共用DP評測鏈與兩個具體task版本，未宣稱整個ManiSkill內含任務或全部基線已驗證。

領域	居家整理與清潔、餐飲與烹飪、包裝、倉儲與物流、零售與購物、實驗室操作、醫療與手術支援
環境	ManiSkill/SAPIEN雙Panda imitator scene，人類demonstrator另有影片。pinned tree中L0/L1/L2/L3各50個config，合計200個task-level設定；不能未去重就宣稱200個獨立語義任務。
任務	以示範模仿操作，可用video-only、language-only或兩者。task透過human/robot/sim ID mapping關聯，L-level與input mode保留case設定；盲測arena另有human preference協定。
題數與資料	LeRobot metadata/parquet/video對齊timestamp秒與episode；MANO姿態是同episode特徵，不是另一資料集。is_right=-1表示缺偵測、數值補0需mask。評測按task隨機抽human episode與video frame；原始action範例雙臂8+8=16D，應固定reference IDs與normalizer。
評估方式	例子成功為兩物件幾何中心在各籃XY bounds及Z上界，is_robot_static另外輸出但未加入success。TSS=1/(1+DTW/path_length)，直接對action向量L2，尺度/單位會影響分數；success軌跡截到首次成功，fail截GT長度；ss<2走fail分支需核驗。eval status=success代表流程完成，物理完成另看success_once/at_end。GT seed=None且batch任一truncated就重置群組，需要固定抽樣/同步假設。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **6** 用途domains · 原文頁 5
- **53** 按domain分量推算base tasks · 原作概述50+，表2約50 · 原文頁 5
- **10** 主評測task types · 原文頁 7, 8

- **11,720** real paired episodes · 原文頁 5
- **10,000** sim paired episodes · 原文頁 5

依這個順序讀

1. `README.md` ↗
   GitHub · imitator-game/The-Imitator-Game · d6d16ec511

   原作、場景/資料/基線與human A/B評測定位

   L1–100

---

2. `examples/baselines/lerobot_dataset/README.md` ↗
   GitHub · imitator-game/The-Imitator-Game · d6d16ec511

   LeRobot時間/episode、同row MANO與原影片關係

   L1–115

---

3. `examples/baselines/_template/eval_template_imitator.py` ↗
   GitHub · imitator-game/The-Imitator-Game · d6d16ec511

   共用eval呼叫與status欄位語義

   L113–160

---

4. `examples/baselines/lerobot_dataset/evaluate_processor.py` ↗
   GitHub · imitator-game/The-Imitator-Game · d6d16ec511

   human↔sim task mapping及reference episode抽樣

   L217–262 · L293–326

---

5. `examples/baselines/diffusion_policy/eval_dp_imitator.py` ↗
   GitHub · imitator-game/The-Imitator-Game · d6d16ec511

   分級設定、video/language輸入、雙臂action與batch/truncation/TSS流程

   L97–139 · L178–276 · L314–409

---

6. `examples/baselines/lerobot_dataset/trajectory_metrics.py` ↗
   GitHub · imitator-game/The-Imitator-Game · d6d16ec511

   DTW/TSS公式與隨機GT trajectory

   L1–21 · L47–103 · L130–175 · L273–302

---

7. `mani_skill/envs/tasks/tabletop/dual_tasks/_008_pick_apple_banana_baskets.py` ↗
   GitHub · imitator-game/The-Imitator-Game · d6d16ec511

   具體雙物件入籃checker

   L337–415

---

8. `mani_skill/envs/tasks/tabletop/dual_tasks_l3/_008_pick_apple_banana_baskets_l3.py` ↗
   GitHub · imitator-game/The-Imitator-Game · d6d16ec511

   L3對應checker與相同goal關係

   L283–346

怎麼接入我們的benchmark

可重用

人類/robot/sim mapping、native level configs、LeRobot schema、完成與TSS的獨立指標。

需要轉換

case固定human示範及frame IDs、sim資產/初態、level/input mode、雙臂action spec；reference trajectory與方法輸出分隔，success/TSS/human preference分欄報告。

仍需補齊

所有task checker覆蓋、完整IG10K資產取得、case固定種子、action尺度/TSS可比性、同步batch條件與盲測評審一致性。

P165 · LIBERO-Recover

LIBERO-RECOVER: Beyond Task Success Towards Failure Recovery in Robotic Manipulation Models

實作尚未確認 · 主來源 · 原作 · 獨立頁面

已核讀同名網站與同owner的LIBERO-Recovery評估庫，但目前程式的人工XY擾動協定與論文「自然執行失敗」不同；不能直接當作論文完整release。

> **版本與身份**
>
> 網站c8cdf8d仍匿名且Paper/Code/Data皆Soon；code7584d1b README計畫2026-10-20釋出，該日期尚未到。2609.05178v3 p4明說不人工擾動，與此版做法不同，故處置identity_or_version_unresolved。
>
> 網站題名與論文相符、候選eval庫同owner；未把匿名網站與當前custom-scene code的關係直接認定為完整論文版本。

領域	居家整理與清潔
環境	沿用LIBERO/MuJoCo；程式scene定義為.bddl+_sim_state.npy pair。這是任務設定/物理初態組合，非必然獨立房屋。網站列2178recovery scenarios，未取得對應完整資產manifest。
任務	論文L1重試/L2調適/L3物件狀態恢復/L4環境恢復；程式目前主要對custom state加±2cm自由物件XY擾動，5closed+5open起始試驗。語義任務、failure scenario和10次trial不能相加。
題數與資料	原文2000+自然失敗情境；網站另列3184恢復示範、625731frame、110task types，單位不同。程式frame記雙相機、EEF/axis-angle/gripper狀態，模型example只送image+lang；manifest存scene/trial/gripper_init/obj_deltas/success等。缺完整failure trajectory/原始goal與recover標註的連結。
評估方式	最多520step，done取原LIBERO goal conjunction；close/open分報。outer reset宣稱12次重試，但內層env_wrapper.reset會吞RandomizationError並持續重試，須驗證失敗行為；建構/重置失敗被跳過會影響分母。flat_state擾動索引還需確認time/qpos佈局。沒有據此重現論文四層恢復結果。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **130** 上游tasks · 原文頁 4, 5
- **4** recovery levels · 原文頁 3, 4
- **2,178** recovery scenarios · 原文頁 5

- **3,184** recovery training trajectories · 原文頁 5

依這個順序讀

1. `README.md` ↗
   GitHub · liulin815/libero-recover · c8cdf8d1b3

   舊庫僅一行README

   L1–1

---

2. `index.html` ↗
   GitHub · liulin815/libero-recover · c8cdf8d1b3

   同名匿名網站、Coming Soon與原生數量單位

   L20–41 · L63–97 · L580–595

---

3. `README.md` ↗
   GitHub · liulin815/LIBERO-Recovery · 7584d1baf3

   10/20未來釋出計畫及當前custom scene協定

   L1–100

---

4. `examples/LIBERO/eval_files/eval_libero_custom_scene.py` ↗
   GitHub · liulin815/LIBERO-Recovery · 7584d1baf3

   擾動、重置、雙gripper split、模型輸入及case/結果manifest

   L79–151 · L166–204 · L212–244 · L310–371 · L386–451 · L501–543

---

5. `LIBERO/libero/libero/envs/env_wrapper.py` ↗
   GitHub · liulin815/LIBERO-Recovery · 7584d1baf3

   step轉接與內層reset重試

   L87–105

---

6. `LIBERO/libero/libero/envs/bddl_base_domain.py` ↗
   GitHub · liulin815/LIBERO-Recovery · 7584d1baf3

   done實際由_check_success覆寫

   L779–809

---

7. `LIBERO/libero/libero/envs/problems/libero_tabletop_manipulation.py` ↗

   GitHub · liulin815/LIBERO-Recovery · 7584d1baf3

   具體子類以goal predicate AND判成功

   L135–162

怎麼接入我們的benchmark

可重用

已讀custom state replay、gripper設定、擾動/輸入/原生success及manifest介面。

需要轉換

保留論文source、候選website與code各自版本；case要連到自然失敗τ_fail/s_f及目標，人工擾動另列衍生協定；記seed/實際state hash、gripper settle、無效reset與分母。

仍需補齊

原作到code的明確完整release對應、全部場景/資料、論文四層標註與規則；修正或確認flat_state/重置/分母後再執行。

P166 · SafeVLA-Bench

SafeVLA-Bench: A Benchmark for the Success-Safety Gap in Vision-Language-Action Models

檔案 / 網站 · 主來源 · 原作 · 獨立頁面

已確認SafeVLA-Bench的作者網站庫與原論文相符；榜單提供task-aware安全評估定義，但新找到的SafeVLA-Bench-release入口取得回404，尚未讀到其STL scorer。

> **版本與身份**
>
> 網站固定3178c93並直接引用2606.00773；leaderboard L160連JFan5/SafeVLA-Bench-release，但本次API404。Jatshi同名庫是另一研究，未混入。

領域	居家整理與清潔、餐飲與烹飪
環境	沿用LIBERO四suite及RoboCasa-365 atomic-seen，所加的是事後trajectory instrumentation與安全規則；不自動增加獨立scene或task。
任務	論文p5記58個既有task，使用7種機制template組合和物件tag選適用條款。8個安全family分scene interaction、object handling、execution三組；規則條款數不是task數。
題數與資料	作者榜單宣稱24policy、27policy–benchmark entries、22,500 scored rollouts；LIBERO每row每suite10task×20episode=200，RoboCasa18family×50=900。這些是已報run數，不能直接當獨立評測case量；兩組RoboCasa seed互不配對。
評估方式	SR沿用父benchmark；Safety=滿足所有適用條款的episode比例；SBU=成功且違規佔全部episode，SBU/SR才是成功中違規比例；VSI為每episode最嚴重違規的正規化深度。signal不可用是N/A。9月版本由per-step force重新算RoboCasa，舊action-log數字不能混報。閾值屬文中模擬proxy，不是實體安全認證。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **58** host task types · 原文頁 5, 6
- **8** scored safety clause families · 原文頁 4, 5
- **200** LIBERO每policy-suite episodes · 原文頁 6
- **50** RC每policy-task episodes · 原文頁 6

依這個順序讀

1. `README.md` ↗

   GitHub · JFan5/safevla.org · 3178c93fc6

   網站用途、safevla.org與展示內容

   L1–30

---

2. `index.html` ↗

   GitHub · JFan5/safevla.org · 3178c93fc6

   精確論文ID、榜單規模、8spec與N/A語義

   L13–16 · L43–86 · L343–373

---

3. `leaderboard.html` ↗

   GitHub · JFan5/safevla.org · 3178c93fc6

   每suite rollout分母、種子群組、release入口與9月重計版本

   L128–177

怎麼接入我們的benchmark

可重用

適用條款registry概念、原生success與附加規則分離、四種度量的分母及結果版本註記。

需要轉換

task保留原LIBERO/RoboCasa ID，evaluator另版本化STL/threshold/tags；case保留相同input/action/budget，新增per-step raw signal evidence與N/A，而非把安全規則乘成新task數。

仍需補齊

release repo可存取、compute_stl_robustness.py實作、per-episode verdict/force logs、clauses與template明細及重現。

P167 · DexGarmentLab

DexGarmentLab: Dexterous Garment Manipulation Environment with Generalizable Policy

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

DexGarmentLab的15個衣物任務場景與2500+衣物資產可擴充柔性物覆蓋；所讀Fold Tops驗收主要看終態點雲的XY範圍比例，尚不能單獨證明指定摺法。

> **版本與身份**
>
> 固定e4e298e；論文2505.11032v3。只核讀Fold Tops實際判分鏈和共用reader；公開15任務不表示本次已逐場執行，未下載大資產或權重。

領域	衣物與洗護、個人照護
環境	IsaacSim4.5.0、雙UR10e/靈巧手、衣物與衣架/人體/收納等資產。README的15 task scenes、8衣物類別、2500+garments屬不同計量，不能相乘作已測環境量。
任務	6種衣物自身任務(fling/fold×tops/dress/trousers)與9種衣物–環境互動(hang/wear/store)。衣物位置/形狀、材質與環境資產設定是case條件。
題數與資料	Zarr原生keys為 state/action/object_point_cloud/garment_point_cloud/environment_point_cloud/points_affordance_feature；SequenceSampler有horizon/padding/episode mask。Fold Tops控制以action前30維/後30維分雙手joint position，每個action執行5physics步；HALO含指令碼接近/離開和分stage策略，不能只截神經網路輸出當完整policy。
評估方式	Fold Tops依預測操作點定義XY boundary，終態分割點雲至少88%在該範圍即通過；不看Z/層拓撲/邊緣對應。指令碼中還有暫時gravity_scale=10再還原，需納入protocol。隨機位置/asset取time.time種子，未固定測例不能只靠run次數重現。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **15** task definitions · 原文頁 5
- **14** 主simulation eval tasks · 原文頁 8
- **2,500** garment models · 超過 · 原文頁 5
- **50** 每task評測episodes / seed設定 · 原文頁 8

- **15** real每task trials · 原文頁 10

依這個順序讀

1. `README.md` ↗
   GitHub · wayrise/DexGarmentLab · e4e298e696

   原作、IsaacSim版本、15task與衣物/環境互動分組

   L1–114

---

2. `Validation_Core.md` ↗
   GitHub · wayrise/DexGarmentLab · e4e298e696

   HALO/DP3/DP不同觀測介面

   L1–72

---

3. `Model_HALO/SADP/structure_aware_diffusion_policy/dataset/robot_dataset.py` ↗
   GitHub · wayrise/DexGarmentLab · e4e298e696

   Zarr state/action/點雲/affordance、序列取樣與normalizer

   L1–109

---

4. `Env_Validation/Fold_Tops_HALO.py` ↗
   GitHub · wayrise/DexGarmentLab · e4e298e696

   雙手各30joint目標、物理子步/重力、最後驗收及時間seed

   L207–261 · L384–443

---

5. `Env_Config/Utils_Project/Position_Judge.py` ↗
   GitHub · wayrise/DexGarmentLab · e4e298e696

   RGB yellow比例與點雲XY box比例checker，實際選用後者

   L1–75

怎麼接入我們的benchmark

可重用

15任務原生列表、Zarr特徵、分stage控制、現有點雲/影像判分規則。

需要轉換

environment儲存衣物mesh/材料/接觸與robot關節規格；case明定asset/seed/實際初態及全部scripted stage；evaluator保留原88%區域標準，另版本化指定摺法/拓撲/穩定檢查。

仍需補齊

資產和測試衣物split取得、固定seed/metadata、全部task checker、joint單位/物理時間、真實摺疊正確性標註與原生基線。

P168 · HRIBench (perception, 2025)

HRIBench: Benchmarking Vision-Language Models for Real-Time Human Perception in Human-Robot Interaction

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

2025 HRIBench是人類感知VQA，不是2026同名協作模擬。官方README明列1000題但只公開4/5類；GitHub存模型輸出logs，未包含完整影像題庫與grader。

> **版本與身份**
>
> 固定b993469，README指2506.20566及Shi等2025作者；與P147的2607.13056保持不同source，不能靠HRIBench名稱合併。
>
> P168: Real-Time Human Perception in HRI (ISER2025)；P147: Interaction-Centric Human-Robot Collaboration (2026)。

領域	社交與溝通、協助、交接與陪伴
環境	真實HRI影像與其他公開dataset場景；五類是感知評估領域，不是五個獨立物理場景。
任務	Non_Verbal、Ins_Follow、HROI、Social_Nav、Id_Rec各200VQA，共1000為原作宣告；README只宣佈前4類可下載，Id_Rec仍未公開，因此宣佈可取範圍為800題，本次未下載影像題庫。
題數與資料	每case應有driod.txt(prompt/options)、correct_answer.json、wrong_answers.json與processed_frame.png。GitHub結果按demo_ID儲存choices/correct_answer/response/time_taken，另有summary；所讀HROI結果檔201頂層key中200是demo、1是summary，不能算201題。demo_0的choice標籤有重複，匯入須驗證選項順序/唯一性。
評估方式	此結果summary預存17/200=0.085 accuracy與0.478秒average time，僅作已公佈log例子，非本次跑分；沒有從response解析到correct的grader實作。各模型latency需要硬體/API/計時範圍一致才可比。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **5** 感知domains · 原文頁 1
- **1,000** VQA · 原文頁 1, 2

- **800** overall表格對應四domain題範圍 · 4×200，identification排除 · 原文頁 5

依這個順序讀

1. README.md ↗
   GitHub · interaction-lab/HRIBench · b993469d3c

   精確2506.20566身分、5×200題及公開限制

   L1–40

---

2. HROI/answers_of_InternVL2_5-1B.json ↗
   GitHub · interaction-lab/HRIBench · b993469d3c

   原始結果中3個demo及summary；未逐條人工核讀整份結果

   JSON /demo_0 · JSON /demo_1 · JSON /demo_199 · JSON /summary

---

怎麼接入我們的benchmark

可重用

5種題型、原生資料目錄約定、帶time_taken的模型輸出schema。

需要轉換

case_id由source+native category+demo_ID組成；原影像/合法person-reference/options與GT分開；result的200demo和模型trial不倍增任務；保留800公開/1000宣告/本次取得影像0三種口徑。

仍需補齊

Google Drive題庫實際取得、缺第五類、README重複圖片路徑說明釐清、選項ID驗證、response grader與latency協定。

P169 · X2Real

X2Real: an eXtensive simulation benchmark for real-world generalist policies

實作尚未確認 · 主來源 · 原作 · 獨立頁面

X2Real論文提出44個階層式長序列task與Policy Space統一介面，但本次官方GitHub及專案頁均回404；只能先登入原文規模與介面設計。

> **版本與身份**
>
> 2609.27449v1 p1明列X-Square-Robot/x2real；2026-10-10T07:46:54Z GitHub API回404，原作專案頁亦404。保留明確入口與取得紀錄，未以第三方名稱相似庫替代。

領域	居家整理與清潔、通用物件與機動作業
環境	論文以Isaac Lab-Arena/Mana設計單臂、雙臂、移動操作及可換gripper；多軸appearance/task setting/embodiment隨機化，不以其笛卡兒積宣稱已驗證環境數。
任務	原文摘要44個階層長序列task、10項能力維度；後文分reasoning4項、manipulation5項與挑戰任務，能力taxonomy不是生活用途domain。每task以subtask DAG描述。
題數與資料	論文近300h標註模擬軌跡；桌面task每個300條demo、移動每個1000條，3個challenge超20,000條。這些是training/demo量，不能當評測題數；未取得case/split/asset manifest。
評估方式	原文DAG節點有rule checker、episode有進度與success；Policy Space處理觀測對映、action適配、歷史與episode lifecycle。需要實作才能核驗same task/observation/budget與ID/OOD分離；未重現其0.84 sim-real相關性。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **44** simulation tasks · 原文頁 3
- **10** 能力維度 · 原文頁 3
- **3** mobile tasks · 原文頁 29
- **40** mobile每task每condition episodes · 原文頁 29

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

44task的原作比較規模、DAG子任務、與policy-specific前處理解耦的介面概念。

需要轉換

source固定2609.27449版本，先整理task/spec並保留planned/imported區別；case日後繫結相同DAG、asset/seed、randomization和evaluator；demo與trial獨立計數。

仍需補齊

可取得的code與專案頁、44task對應原始規格、全部case及asset、Policy Space adapter與實際評測重現。

P170 · MotionForge

MotionForge: A Data Generation Pipeline and Large-Scale Benchmark for Long-Horizon Manipulation of Dynamic Objects with Domain Shifts

實作尚未確認 · 主來源 · 原作 · 獨立頁面

MotionForge原文定義動態操作與延遲感知評測；已排除同名Blender動畫工具倉庫，精確paper-ID與robot關鍵字搜尋仍未確認本篇官方code。

> **版本與身份**
>
> 原文2609.25689v1；同名mayalhc/motionforge是Blender動畫工具，與作者/任務不同。2026-10-11兩個精確GitHub查詢均無結果；只宣稱本次未確認，不宣稱程式永久不存在。

領域	裝配與生產作業、包裝、倉儲與物流
環境	原文分Factory Conveyor、Circular Motion、Home Tabletop、Embodied Interaction四個scene family，各10task；families代表場景/動態配置，非四個完全獨立生活用途。
任務	40個semantic task families中17個long-horizon，11種primary motion pattern；只改速度的variants在原文計數協定合併，這點可直接用來對齊我們的task granularity。
題數與資料	生成約20kepisodes，訓練每task只取50successful demo、共2000；每scene family訓練一個model，所以每policy方法有4個family-specific模型。80k訓練steps×batch32不是獨立資料題量。
評估方式	每task每方法50個固定seed，對40task macro-average；R1環境120Hz獨立於推論前進，action execution horizon預設16，latency按方法原生pipeline量測。ID/OOD只改指定因素，測例需要儲存連續時間/延遲規則，不可換同步step後沿用原作分數。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **4** scene families · 原文頁 3
- **40** semantic task families · 原文頁 3
- **17** long-horizon families · 原文頁 4
- **50** 每task每condition eval episodes · 原文頁 6

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

原文40task/17long/11motion分類、速度variant去重口徑與R1時間協定。

需要轉換

task以語義family去重，case另含動態因果/速度/物件/外觀與seed；result保留latency、policy-family training scope與真即時間控制規則。

仍需補齊

官方repo、task與motion生成器、固定case/scene/asset manifest、R1 scheduler/scorer及來源實測。

P171 · Bench2Dex

Bench2Dex: Benchmarking Visuo-Tactile Bimanual Dexterous Manipulation Across Dexterous Hands

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

Bench2Dex有可追溯的YAML任務、視觸覺HDF5 reader與具體success engine。26任務、12機體、8模態和1300示範各有不同單位；雙手/多模態不直接倍增任務。

> **版本與身份**
>
> 固定fd90dcc；success語義依metric_schema_version與evaluation_protocol而變，不能拿不同版本同名success_rate直接合併。只核讀所列實際片段，未跑Isaac或policy。

領域	裝配與生產作業、通用物件與機動作業
環境	IsaacSim5.1/IsaacLab2.3.2；26個task YAML包含桌面、資產路徑、物理屬性、佈局與generalization flags，跨12種robot embodiment。相同場景的雙手與多感測不算獨立環境。
任務	原生26task從放置/分類、清潔、工具使用、拼圖到盛湯/琴鍵等；YAML stages可有depends_on。task_manifest先選scenes_final再scenes；其中task.md只有3欄但parser要求6欄，可能退回Unknown，需我們的匯入器自行正確對映原表。
題數與資料	HDF5 robot/qpos、action/commanded、cameras/*/rgb、robot/tactile/tacmap/*與site_names。同一start_ts取所有模態；缺commanded會改用qpos作action，必須記來源。tactile為uint8影像且順序跨episode嚴格一致；activeDOF/padding/NaN mask儲存，尾chunk mask長度仍需測試。1300demo為原作宣告，未取得payload。
評估方式	core-v1.8：reach_and_stop以terminal條件持續dwell(預設0.5秒)為成功，fixed_horizon改看budget末態；instant/at_end/stable分開。Soup Serving以湯杓進鍋→到碗上方兩次，再歸杓/擺碗/碗直立判分，沒有直接量測流體體積。安全成功另排drop/high-speed；joint limits預設diagnostic。空結果回0在本庫應標N/A；robust ratio需baseline和perturbed兩組才定義。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **26** task-embodiment settings · 原文頁 8
- **12** dexterous-hand morphologies · 原文頁 2, 5
- **20,800** 跨4policy的evaluation rollouts · 原文頁 8

- **50** 每policy/task/channel rollouts · 原文頁 8

依這個順序讀

1. `README.md` ↗
   GitHub · Bench2Dex/Bench2Dex · fd90dcc625

   原作ID、規模宣告與Isaac版本

   L1–88

---

2. `scenes/task.md` ↗
   GitHub · Bench2Dex/Bench2Dex · fd90dcc625

   26個release task ID與YAML入口

   L1–39

---

3. `collector/task_manifest.py` ↗
   GitHub · Bench2Dex/Bench2Dex · fd90dcc625

   scene優先序、metadata parser與缺值fallback

   L12–105

---

4. `scenes/76_soup_serving.yaml` ↗
   GitHub · Bench2Dex/Bench2Dex · fd90dcc625

   例項資產/初態/custom checker/stage DAG/dwell與safety設定

   L1–137

---

5. `success/engine.py` ↗
   GitHub · Bench2Dex/Bench2Dex · fd90dcc625

   all/any/sequence/hold_duration/custom語義

   L1–86

---

6. `success/custom/task_76_soup_serving.py` ↗
   GitHub · Bench2Dex/Bench2Dex · fd90dcc625

   兩次舀取狀態機與實際末態條件

   L1–44 · L54–152

---

7. `policy/ACT-Tactile/act_tactile_dataset.py` ↗

   GitHub · Bench2Dex/Bench2Dex · fd90dcc625

   tactile site順序、同步sampling、command/qpos fallback與padding

   L20–36 · L47–169

---

8. `benchmark/metrics.py` ↗

   GitHub · Bench2Dex/Bench2Dex · fd90dcc625

   success protocol、空結果/有效結果分母與OOD比例

   L1–70 · L413–491 · L498–515 · L549–575 · L817–874

怎麼接入我們的benchmark

可重用

26task目錄、YAML stage/terminal規格、視觸覺schema、成功/安全/魯棒聚合公式。

需要轉換

task對映原ID及領域用途，保留scene版本；case固定control/physics/query時計與embodiment/activeDOF；evaluator原樣報stable/instant/safety，新增實際舀取量規則另版本化。

仍需補齊

完整assets/HDF5取得、12機體適配、所有task checker/時鐘實測、manifest欄位修復、NaN/padding與空結果處理、感測單位/校準。

P172 · LabUtopia

LabUtopia: High-Fidelity Simulation and Hierarchical Benchmark for Scientific Embodied Agents

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

LabUtopia把場景/觀測放在task、完成檢查放在controller；只讀task類別會漏掉真正判分。此版同時存在不同HDF5欄位格式，匯入時需要分開對接。

> **版本與身份**
>
> 固定8df7278，README已指IsaacSim5.1；論文為2505.22634，不能把現在的軟體依賴版本直接當成2025原論文設定。未執行Isaac或遠端policy。

領域	實驗室操作
環境	實驗室USD場景和Franka/移動機器人等配置；所讀level1_pick指定lab_001、3相機與物件初態range。多個YAML/相機不直接當獨立物理環境。
任務	以基礎、組合、泛化和長序列四層組織實驗室操作；配置task_type/controller_type決定行為，scene/物件組合構成具體case。此輪核讀pick，不將每個config別名視為新語義task。
題數與資料	NavDataset使用joint_positions/robot_position/cam_01_rgb/cam_02_rgb/hand_cam_rgb，action取joint_positions序列；其validation只copy同一資料與sequence表，非獨立holdout。新converter期待agent_pose/actions與相機欄位，缺shape預設7、缺FPS預設60；source<=target FPS時保留所有frame，須確認輸出timebase。
評估方式	pick controller要求物體Z比初始高0.1且連續60次check；reset時計success_count。task.done只是reset_needed，base timeout還調on_task_complete(True)，不能用task.done替代controller成功。50個inference episodes只是README範例；正式case/budget須按發布協定固定。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **100** 基礎lab scene assets · 約數 · 原文頁 5
- **30** 摘要聲稱distinct tasks · 與§4 >50不一致，未定為全庫唯一值 · 原文頁 1, 3
- **5** benchmark levels · 原文頁 7, 8

依這個順序讀

1. `README.md` ↗
   GitHub · Rui-li023/LabUtopia · 8df7278426

   當前Isaac版本、task/controller分工與60Hz資料約定

   L1–95 · L274–313 · L328–373

---

2. `config/level1_pick.yaml` ↗
   GitHub · Rui-li023/LabUtopia · 8df7278426

   具體場景、物件range、3相機、robot和budget

   L1–69

---

3. `tasks/base_task.py` ↗
   GitHub · Rui-li023/LabUtopia · 8df7278426

   觀測state與reset/timeout訊號

   L286–356

---

4. `controllers/base_controller.py` ↗
   GitHub · Rui-li023/LabUtopia · 8df7278426

   60次持續成功及episode計數

   L19–41 · L122–150

---

5. `controllers/pick_controller.py` ↗
   GitHub · Rui-li023/LabUtopia · 8df7278426

   pick抬高0.1m的具體連續判定

   L20–25 · L50–78 · L129–154

---

6. `policy/dataset/nav_dataset.py` ↗
   GitHub · Rui-li023/LabUtopia · 8df7278426

   HDF5舊schema、state/action視窗及validation副本

   L1–41 · L81–121

---

7. `scripts/convert_labsim_data_to_lerobot.py` ↗

   GitHub · Rui-li023/LabUtopia · 8df7278426

   新schema、FPS偵測/降取樣及LeRobot欄位轉換

   L55–84 · L109–162 · L183–244

怎麼接入我們的benchmark

可重用

YAML場景/感測/初態、task/controller分工、具體pick evaluator與HDF5→LeRobot路徑。

需要轉換

先辨識HDF5 schema版本和action是否command/state；建立episode級split；case記physics/control/check頻率、連續成功時間與timeout獨立結果；原文規模和當前config取樣分開。

仍需補齊

全部task完成checker、原文到當前版本對照、獨立validation、舊/新資料schema轉接、FPS/shape fallback驗證與場景資產/基線重現。

P173 · LabDex

LabDex: A Hierarchical Benchmark for Dexterous Manipulation in Laboratories

檔案 / 網站 · 主來源 · 原作 · 獨立頁面

LabDex的GitHub目前是展示網站，Code標Coming Soon；作者連結的HF dataset card已核對，但還沒有可核驗的task evaluator實作。

> **版本與身份**
>
> 固定3d1c43b網站與2608.18618一致；2026-10-11已讀serandt/LabDex公開card。Code仍Coming Soon，未把網站或8000+宣告當已整合case。

領域	實驗室操作
環境	實體與模擬共用Franka Research3+XHand，三個相機視角、20+laboratory assets；同場景多視角不增加環境數。
任務	原文概觀為30+Atomic、10+Compositional、1Long-Horizon workflow；實驗表實際比較26atomic instances、7種操作類別。整體collection、已報評估subset及family是不同層次。
題數與資料	HF card宣告8000+demo和1M+trajectory steps，包含同步多視角RGB、proprio、action、hierarchical annotations；card未給詳細鍵名/檔案佈局，本次沒有下載demo。50為每task評估trial數，非demo總量。
評估方式	原文成功要求末stage後狀態在目標容差內連續2秒；atomic報SR，composite/workflow另報各atomic成功及每rollout平均完成數。必須取得容差、stage/時間checker才可執行。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **7** atomic operation categories · 原文頁 4, 5
- **26** 實驗atomic task instances · 原文頁 5, 11
- **10** 附錄列出compositional definitions · 依完整清單列舉 · 原文頁 12, 13
- **1** long workflow · 原文頁 13
- **50** 每task每model eval trials · 原文頁 5

依這個順序讀

1. `docs/index.html` ↗

   GitHub · Zhipeng-Tang/LabDex · 3d1c43b63f

   原作ID、資料入口、Code Coming Soon及三層技能

   `L35–91 · L279–307`

怎麼接入我們的benchmark

可重用

三層task結構、原生demo/trajectory量、2秒穩定成功協定與作者dataset入口。

需要轉換

environment保留robot/相機/asset版本；task建立atomic→composite→workflow關係，不重加共享subtask；case記phase/容差/穩定時間和split。

仍需補齊

正式code、可解析episode manifest、確切action/clock schema、容差與每task成功規則、真實/模擬資料分割。

P174 · Labimus

Labimus: A Simulation and Benchmark for Humanoid Dexterous Manipulation in Chemical Laboratory

檔案 / 網站 · 主來源 · 原作 · 獨立頁面

Labimus的官方網站可核對6種原子操作和1條七步秤重流程；目前這個GitHub只有展示內容，尚未取得模擬與精度checker。

> **版本與身份**
>
> 網站固定caea61f，原作2606.31037；所讀GitHub tree展示index.html與媒體，沒有benchmark Python實作，不據此宣稱pipeline已復現。

領域	實驗室操作
環境	Isaac Sim化學工作站、Tianyi humanoid、30+功能資產，包含可動儀器、粉末粒子與數位秤量測；網站影片不是可執行USD資產包。
任務	6atomic operations加1個7-step workflow。三種評估層(task completion/precision/step progress)×四個appearance條件形成12格評測設計；不能稱12個新語義任務。
題數與資料	原文/網站描述procedural layout及Standard/Lighting/Textures/Combined；仍未取得具ID的scene、episode、示範和控制資料，未能算本次可用case數。
評估方式	同一物理動作分報binary completion、protocol precision和長流程stage進度；網站秤重例以原文±0.001g作模擬量測容差，另有位置容差。這些是原作任務標準，需相應物理量/儀器讀值及校準，不只看物件是否放到秤上。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **6** atomic definitions · 原文頁 9
- **1** 7-step workflow definition · 原文頁 9
- **150** 每task-condition實驗trials · 原文頁 12

依這個順序讀

1. `index.html` ↗

   GitHub · labimus/labimus.github.io · caea61fd73

   精確原作/作者、任務列、三種評測層與四種條件

   `L188–214 · L250–280 · L363–382 · L449–468`

怎麼接入我們的benchmark

可重用

6+1任務粒度、動作完成與量測有效性分離、四種環境條件。

需要轉換

case保留儀器狀態/粒子質量、單位、stage順序和容差；evaluator同時輸出完成/精度/進度；新增精度規則另有版本與支援證據。

仍需補齊

可公開取得的simulation code、asset與episode清單、instrument/particle校準、精度與stage scorer、各條件實際基線。

P175 · Pipette

Pipette: An Embodied Simulation Platform, Benchmark, and Data-Efficient Augmentation Framework for Wet-Lab Robotics

實作尚未確認 · 主來源 · 原作 · 獨立頁面

Pipette原文明確提供GitHub，但本次取得回404。已整理12個wet-lab任務的共通格式與成功驗證augmentation設計，實作仍待取得。

> **版本與身份**
>
> 同一2606.12936的v3題名已改為Success-Verified Simulation Augmentation，書目舊題名Data-Efficient保留版本註記。官方hbhuiyou/Pipette取得404，只作當次不可用判定。
>
> 精確arXiv ID相同；論文版本改題名，不建立成另一份獨立benchmark。

領域	實驗室操作
環境	Isaac Sim/Isaac Lab、100+互動USD/消耗品資產；主要Franka Panda，部分task使用AgileX。三個RGB視角是感測配置，非三環境。
任務	12個sample handling、instrument/lid interaction、placement/alignment等wet-lab任務；NL parser輔助產生場景/任務設定，原文仍要求人工和模擬驗證。
題數與資料	原文HDF5逐步記top/main/wrist RGB、proprio、sim state、action、language；成功驗證後轉LeRobot、去stale frame、對齊並降到10Hz，影像400²、robot-command8D。raw與augmented episode分別存，關聯同一原示範；資料增強不是新增語義task。
評估方式	原文依物件pose、actuator state或幾何關係與registered threshold判success；每episode JSON應記成功/失敗理由/runtime/policy及control頻率/gripper threshold。code及文中另提的technical supplement未取得，尚無法驗證12task具體判分。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **12** wet-lab tasks · 原文頁 5, 7
- **1,200** 每policy每資料設定eval episodes · 12×100 · 原文頁 17
- **360** raw human training trajectories · 12×30 · 原文頁 17

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

task entry(scene/robot/sensor/instruction/target/constraints/criterion)與HDF5→LeRobot對齊流程。

需要轉換

建立原demo→augmentation lineage和各自render/action；case固定scene/初態/clock/8D命令語義，evaluator保留task-specific threshold與有效性。

仍需補齊

可取GitHub、12task/資產/episode清單、technical supplement、實際converter/evaluator與simulation重現。

P176 · AutoBio

AutoBio: A Simulation and Benchmark for Robotic Automation in Digital Biology Laboratory

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

AutoBio初步版有真實task/evaluator程式與LeRobot資料；MuJoCo和Blender是同任務的兩種渲染版本。必須保留render lineage與各task具體量測，不能只拿生成影片數當題數。

> **版本與身份**
>
> 固定0850421，README明列Preliminary Version。未安裝MuJoCo/Blender或執行policy；未將renderer份數當新任務或獨立示範。

領域	實驗室操作
環境	MuJoCo生物實驗室資產與Blender Cycles外觀渲染；pipette例為雙UR5e和靈巧手/夾爪。physics scene、相機和render edition分別記錄，Blender不另增物理環境。
任務	當前factory接受13個原生task名稱，README列9種dataset各有MuJoCo/Blender版本；這兩個範圍不是同一清單。原子操作與完整儀器任務需要按原作版本對照；pickup匯入模組未在固定tree找到。
題數與資料	LeRobot v2.0每episode parquet與videos，meta包含episodes/info/stats/tasks；README影片224²@50fps。runtime使用observation/state、影像與prompt，task_info指定state_indices/action_indices/camera_mapping。RDT資料用fps建立action/history timestamps並儲存缺影像mask；不可將補0當真實sensor。
評估方式	每action保持10個MuJoCo physics步，chunk外檢查time_limit/early_stop，可能超出名義budget到chunk末；不健康模擬回False。pipette checker追蹤tip入液麵、拇指命令變化與最後抬離液麵，未直接對抽取體積作容差檢查。history deque追加qpos未明確copy，也需驗證歷史狀態是否別名。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **16** task definitions · 原文頁 6
- **9** 實驗task子集 · 3levels×3tasks · 原文頁 7
- **900** train demonstrations · 9×100 · 原文頁 7

- **100** 每task eval episodes / run · 原文頁 8

依這個順序讀

1. `README.md` ↗
   GitHub · autobio-bench/AutoBio · 0850421335

   preliminary身分、9類資料的兩種render與LeRobot2.0

   L1–80

---

2. `autobio/task.py` ↗
   GitHub · autobio-bench/AutoBio · 0850421335

   task factory原生名稱、state/step/serializer介面

   L16–83 · L90–146

---

3. `autobio/evaluate.py` ↗
   GitHub · autobio-bench/AutoBio · 0850421335

   master seed生成每episode seed、結果bool列表

   L18–21 · L43–100

---

4. `autobio/evaluator.py` ↗
   GitHub · autobio-bench/AutoBio · 0850421335

   合法觀測、10physics步/action、健康/時間/成功條件

   L174–266

---

5. `autobio/mani_pipette.py` ↗
   GitHub · autobio-bench/AutoBio · 0850421335

   雙UR5e task_info、初態、液麵/操作條件的具體checker

   L132–239

---

6. `RoboticsDiffusionTransformer/data/lerobot_vla_dataset.py` ↗
   GitHub · autobio-bench/AutoBio · 0850421335

   FPS相對timestamp、影像history/padding、state/action正規化

   L12–45 · L181–240

怎麼接入我們的benchmark

可重用

明確task/serializer/factory、LeRobot結構、paired renderer來源、具體task checker與seed協定。

需要轉換

source+task+episode為底層ID，render variant作observation版本；case固定physics/action時間、joint順序、初態及scorer；量化體積/精度可作新增規則，保持原版可比。

仍需補齊

preliminary版本缺件、13factory與原作task清單對齊、完整資產/資料、command/state normalizer、history/budget驗證與全部task重現。

P177 · H2RBench（human transfer）

H2RBench: A Real-to-Sim Benchmark for Evaluating Human-to-Robot Transfer

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

H2RBench提供基於PolaRiS的6個Gym場景註冊與human-to-robot transfer評測。此版rubric按曾完成的子條件累積，與末態全部同時完成有差異。

> **版本與身份**
>
> 固定5082e75。README arXiv仍TODO且clone示例為舊DavidZ2851/polaris；官方h2rbench.github.io連此庫並列精確2609.24778，身分相符。與P151影片生成H2R-Bench保持不同source。

領域	裝配與生產作業、通用物件與機動作業
環境	Isaac Lab與PolaRiS真實場景重建/3D Gaussian splat；固定registry6個Gym ID為放紅杯、疊積木、套環、掛杯、玩具入盒、疊碗。authoring scene.json與runtime scene.usda/渲染資產不是同一種環境描述。
任務	6個原生task setup有Rubric前置依賴；新case須儲存human/robot資料轉移的訓練條件與實際goal，不能把完整PolaRiS父資產庫當本篇全部已評任務。
題數與資料	initial_conditions.json含instruction/poses；task_config.yaml有object_randomization/waypoints。當前randomize以poses[0]為底再取range，未逐條使用所有原始pose；旋轉入參xyzw、輸出wxyz。policy推論入口送obs+language，human示範訓練/配對資料另需manifest，不能從此eval入口推定已有video prompting。
評估方式	每criterion曾達成即latched，progress=ever_reached/total，成功為全數曾達成；空criteria會success=True但progress0，應拒作合法case。放置看XY投影覆蓋與finger條件；插入有速度穩定/XY/Z檢查，其closure計數須確認跨episode重置。續跑先生成ic後快轉RNG，第一個恢復episode仍用舊ic，需修正或儲存實際初態。影片固定15fps不是控制clock證據。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **4** manipulation task families · 原文頁 5
- **340** 固定robot demonstration預算 · 40+100+100+100 · 原文頁 5
- **1,000** human demonstration上限預算 · 100+300+300+300 · 原文頁 5

- **90** 每method/task eval rollouts · 原文頁 6

依這個順序讀

1. `README.md` ↗
   GitHub · xiaochy/H2RBench · 5082e75c4c

   作者/原作專案與PolaRiS來源關係

   L1–80

---

2. `src/polaris/environments/__init__.py` ↗
   GitHub · xiaochy/H2RBench · 5082e75c4c

   6個具體環境與reach/lift/place/insert依賴條件

   L1–128

---

3. `PolaRiS-Hub/put_red_cup_no_curtain/scene.json` ↗
   GitHub · xiaochy/H2RBench · 5082e75c4c

   authoring scene的asset/path/pose/scale

   L1–47

---

4. `src/polaris/utils.py` ↗
   GitHub · xiaochy/H2RBench · 5082e75c4c

   instruction/poses與task randomization設定

   L18–59

---

5. `src/polaris/utils_/eval_utils.py` ↗
   GitHub · xiaochy/H2RBench · 5082e75c4c

   seed、僅取第一個基準pose、xyzw→wxyz轉換

   L6–64

---

6. `scripts/eval_policy.py` ↗
   GitHub · xiaochy/H2RBench · 5082e75c4c

   case抽樣/續跑、model介面、rubric結果和budget

   L20–153

---

7. `src/polaris/environments/manager_based_rl_splat_environment.py` ↗
   GitHub · xiaochy/H2RBench · 5082e75c4c

   reset/step均評rubric，缺rule不計正常progress

   L42–96 · L179–198

---

8. `src/polaris/environments/rubrics/base.py` ↗
   GitHub · xiaochy/H2RBench · 5082e75c4c

   max-ever criteria、依賴和progress/empty-rule

   L1–77

---

9. `src/polaris/environments/rubrics/checkers.py` ↗
   GitHub · xiaochy/H2RBench · 5082e75c4c

   具體XY覆蓋和穩定插入checker

   L8–91 · L222–261

怎麼接入我們的benchmark

可重用

6環境註冊、scene/initial_conditions/task_config介面、可追溯predicate與依賴進度。

需要轉換

case繫結source episode、重建/碰撞/渲染資產版本與座標系；記實際初態、human訓練子集和固定budget；保持ever-success與同時末態成功分項。

仍需補齊

human/robot完整配對資料、資產和training split、續跑初態一致性、stateful predicate reset、非空rubric/全部終態有效性及跨機體基線。

P178 · RoboRecover

RoboRecover: Benchmarking Robot Policy Recovery under Execution Deviations

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

公開程式是 LIBERO / RoboTwin 的恢復起點、固定 split 與回放後推論 overlay。已核讀 JSON reader、回放 / 新推論預算、LIBERO 成功傳遞與 RoboTwin 入櫃任務的具體 checker；完整2,000個 scenario JSON 的託管仍待發布，兩個 example 並非完整資料集。

> **版本與身份**
>
> 固定 RoboRecover 089b942；LIBERO 延伸核讀恰為 lock 指定8f1084e。lock 所有 historical_revision_verified 均為 false；README 指 LIBERO MuJoCo3.3.2 / robosuite1.4.x、RoboTwin SAPIEN3.0.0b1，不可用 upstream 最新版代換。RoboTwin FastWAM / LingBot-VA recovery adapters 仍 pending；論文六政策結果不等於倉庫六個可用 adapter。
>
> 收錄論文為 arXiv:2609.28952v1，PDF 第1頁直接連至 RUCKBReasoning/RoboRecover；README 的雙平臺、action-prefix recovery 與論文一致。README 第78行仍使用 CuteClaire/RoboRecover 複製網址，保留為別名待確認，不另算來源。

領域	居家整理與清潔
環境	LIBERO 的 MuJoCo 桌面任務與 RoboTwin 2.0 的 SAPIEN 雙臂場景各自重用原 benchmark。LIBERO 依 suite/task_id 找 BDDL、episode_idx 找原生 init state；RoboTwin 依 task_name/task_config/seed、embodiment 與 camera YAML 初始化。scenario 是同一任務執行偏離後的起點，不另計為新的 environment 或 task。
任務	論文定義 Recovery Stage=Approach/Contact/Move/Place，Deviation Type=Wrong Target/Wrong Pose/Stage Rollback/Scene Change；實際兩個 test CSV 都有9種 stage–type 組合，不是4×4皆存在。靜態解析各200個不重複 test sample_id，LIBERO 含38個 task_name、RoboTwin 含34個；論文另述 train 涵蓋40 / 42個任務。2,000是恢復 scenarios，兩平臺各800 train / 200 test，不是2,000項技能。

題數與資料	split CSV 欄位為 sample_id/path/sha256/original_sha256/actions/replay_prefix_steps/task_name/s_stage/d_stage；兩個 example 的實際 SHA256 各匹配該平臺 test 第一列。LIBERO JSON 包含 task_suite_name/task_id/episode_idx/seed、initial_state.xyz/quat/rpy/gripper、actions；RoboTwin 包含 task_name/task_config/instruction、initial_state.joint_vector/left_endpose/right_endpose/left_gripper/right_gripper 及 annotation_meta.frame_index/video_fps。驗證器接受 LIBERO 7D、RoboTwin 14或16D action，qpos / ee 應另存 action_type；不可把 gripper 或正規化 action 一律當公尺。reader 只在長於 annotated_step+1 時擷取，不補短 prefix。LIBERO 模型輸入是兩視角 RGB、末端位置 / axis-angle / gripper state；annotation video_fps=10 的 example 不代表所有控制頻率。
評估方式	先以原 reset 重建，再回放 prefix、清空推論歷史並給新的 S 步預算；正式設定 post-replay wait=0，prefix 不扣推論額度。LIBERO suite 預設預算 spatial/object/goal/10/90 分別 220/280/300/520/400；RoboTwin 以原 task.step_lim 和可選 max_infer_steps 取較小值。LIBERO native done 來自 goal predicates；RoboTwin Base_Task 將具體 check_success 鎖存至 eval_success，所讀入櫃 checker 要求 |dx|、|dy|各<0.05，物件比初高0.007至0.12且對應夾爪張開（原生模擬長度單位）。論文 Overall RSR 是每 scenario 成功數 / 排定 trials 後等權平均；Macro-9 再對9個 stage–type group 等權平均。程式 build_summary 按 task/error_type 直接累加 trial 並使用 eval_success_at_end，可能包含 replay_already_done；不能原封當成論文 RSR。LIBERO _to_summary 主要輸出 status_counts，effective_failure 只加 timeout_failure/env_crash，亦不等於完整失敗分母。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **2,000** recovery scenarios（含train） · 原文頁 3, 4
- **400** held-out recovery scenarios · 原文頁 4
- **9** 測試集有資料的stage-type groups · 原文頁 5, 6

依這個順序讀

1. `README.md` ↗

   GitHub · RUCKBReasoning/RoboRecover · 089b9420e8

   核對雙平臺身分、資料未完整託管與 scenario 等權評分協定。

   `L1–19 · L55–71 · L105–153`

2. `dependencies.lock.json` ↗

   GitHub · RUCKBReasoning/RoboRecover · 089b9420e8

   保留 upstream commit 與 historical_revision_verified=false，不能宣稱重現了論文原始環境。

   L1–52

---

3. `tools/prepare_data.py` ↗

   GitHub · RUCKBReasoning/RoboRecover · 089b9420e8

   split membership、SHA256、action shape 與數值檢查。

   L10–37

---

4. `examples/libero.json` ↗

   GitHub · RUCKBReasoning/RoboRecover · 089b9420e8

   LIBERO task/reset、stage/type 與第一個 action 的實際欄位。

   `JSON /task_suite_name · JSON /task_id · JSON /episode_idx · JSON /seed · JSON /initial_state · JSON /s_stage · JSON /d_stage · JSON /annotated_step · JSON /actions/0`

---

5. `examples/robotwin.json` ↗

   GitHub · RUCKBReasoning/RoboRecover · 089b9420e8

   RoboTwin config、instruction、關節 / 末端初態與 annotation frame 約定。

   `JSON /task_name · JSON /task_config · JSON /instruction · JSON /initial_state · JSON /annotation_meta · JSON /actions/0`

---

6. `overlays/RoboTwin/script/robotwin_trace_utils.py` ↗

   GitHub · RUCKBReasoning/RoboRecover · 089b9420e8

   JSON 必要欄位、annotated_step 擷取與動態 task class 解析。

   `L21–29 · L84–101 · L123–175`

---

7. `overlays/RoboTwin/script/eval_ood_replay_then_infer.py` ↗

   GitHub · RUCKBReasoning/RoboRecover · 089b9420e8

   回放與推論分段、異常狀態、具體 summary 的 trial 分母。

   `L348–442 · L480–556 · L596–643`

---

8. `overlays/RoboTwin/envs/_base_task.py` ↗
   GitHub · RUCKBReasoning/RoboRecover · 089b9420e8

   每次物理 step 的 check_success 如何設定 eval_success。

   L1707–1715

---

9. `overlays/RoboTwin/envs/put_object_cabinet.py` ↗
   GitHub · RUCKBReasoning/RoboRecover · 089b9420e8

   入櫃 task 的高度 / 平面距離 / 張開夾爪聯合條件。

   L67–81 · L119–130

---

10. `overlays/openpi/examples/libero/eval_filtered_repro.py` ↗
    GitHub · RUCKBReasoning/RoboRecover · 089b9420e8

    LIBERO reset、7D prefix、done 解讀、suite 預算與狀態統計。

    L104–110 · L245–302 · L428–470 · L703–741 · L770–802 · L918–937 · L1244–1271

---

11. `libero/libero/envs/env_wrapper.py` ↗
    GitHub · Lifelong-Robot-Learning/LIBERO · 8f1084e313

    在 dependencies.lock 指定版本追 TASK_MAPPING 到 task。

    L43–88 · L103–104

---

12. `libero/libero/envs/bddl_base_domain.py` ↗
    GitHub · Lifelong-Robot-Learning/LIBERO · 8f1084e313

    step 的 done 直接覆寫為具體 task 的 _check_success。

    L801–809

---

13. `libero/libero/envs/problems/libero_tabletop_manipulation.py` ↗
    GitHub · Lifelong-Robot-Learning/LIBERO · 8f1084e313

    goal_state 的逐項 predicate 合取；不是 base class 的佔位 False。

    L135–154

怎麼接入我們的benchmark

可重用

固定 split / 逐檔雜湊、JSON schema、upstream task/reset 關係、stage–type 標籤、replay/infer 分段與具體成功 checker。

需要轉換

source 保留兩層 commit；environment 指向原生模擬器 / 資產；task 仍用平臺與 native task key；case 用平臺 +split+sample_id，儲存 reset 引用、prefix、原指令及偏離來源；evaluator 另記 step budget、repeat、scheduled/invalid/status。domain 只按任務內容對映。從 results.jsonl 重算 scenario 等權 RSR、Macro-9，將回放已完成與 state mismatch 保留為獨立有效性狀態。

仍需補齊

完整 scenario archive / 資料授權及 simulator assets；各 adapter 完整環境驗證；原論文歷史 upstream revision 證實；正式排定 trial 名冊及 replay_already_done 的統一處置；各 task checker 全覆蓋。本輪只核讀代表性核心路徑，未跑模型或模擬。

P179 · REBOOT

REBOOT: From Failure to Recovery - A Dataset and Benchmark for Precision Assembly

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

已核讀 REBOOT 的 depth reader、frame / video 對齊、phase.json 裁切讀取與通用 evaluator。原生18任務及人工五階段判定主要定義於論文；所查固定版本未提供 REBOOT 專用自動 phase scorer。另實查官方 RCA recovery 資料 metadata，確認僅30 episodes、train split 且沒有 meta/phase.json，不能直接把論文2,160段視為已閉合的公開資料。

> **版本與身份**
>
> 固定 depth 分支269d539，不以 upstream LeRobot 最新版替代；HF實查固定fb4e5c5。README 的『2,160 bimanual』與論文83段實際協作需分開解讀；論文1-based phase公式、範例tau_0=0及程式0-based slice 也要保留來源差異。未下載 parquet/video，未安裝或執行上游程式。
>
> arXiv:2609.22591v1 第16頁及作者 nanayawoa 的專案頁均連至此 fork；README 自稱 LeRobot (REBOOT fork)，承接 Trossen fork、LeRobot v0.4.3 與 depth PR2604。這是資料錄製 / 讀取支援倉庫，不是18項組裝任務的完整模擬器。

領域	裝配與生產作業
環境	實體 NIST Assembly Task Board #1，Trossen WidowX AI 兩支6關節 follower 與 leader teleoperation；四臺 RGB-D 視角為 high、low、left_wrist、right_wrist。論文物件初位在名義位置周圍3–6 cm 變動，目標板固定。雙臂硬體 / 14D state 不等於每段雙臂協作：論文第10頁只有83 / 2,160段屬雙臂，且主要為 recovery_install。
任務	依第23頁表10保留9種物件各 install/remove，共18項：M12、USB-A、USB-C、RJ45、NEMA 1-15P、HAN10E、RCA、16mm bar/cylinder。每 task 保留 C1/C2/continuous symmetry、clearance（mm）、precision tier。共同五階段是 Align(pick)、Engage(pick)、Transport、Align(place)、Engage(place)，不是90個獨立任務。論文每 task 有60 expert+60 recovery，總2,160；第7頁『10 types』與具體9列 inventory 不一致，採表10列舉並標記差異。

題數與資料	論文 action/state 為兩臂各6 joint+1 gripper 的14D絕對目標 / 狀態，30 Hz；保留關節及夾爪原生尺度，不推定全部維度為角度。實查 REBOOT26/rca_recovery_install@fb4e5c5：info.codebase_version=v3.0、30 episodes、26,939 frames、1 task、splits.train='0:30'；action/observation.state 為 float32[14]，RGB 為480×640×3 video、四個 *_depth 為 480×640×1 depth。data/chunk-*/file-*.parquet 與 videos/{video_key}/chunk-*/file-*.mp4 透過 episode metadata 的 chunk/file/from_timestamp 連線；reader 裁定 delta_indices 不跨 episode，另輸出 *_is_pad。相機程式以 z16 讀 uint16，docstring 稱 mm，但資料 info 未提供 depth scale，仍需校準資訊。論文 phase schema 含 repo_id/task_id/episode_index、phase_boundaries.tau_0…tau_5、failure.originating_phase/failure_mode/t_f/t_r/t_s；trim reader 則要求外層 episodes[]，按 failure.<cut-key>（預設t_r）取 [start,stop)。抽查的 RCA dataset file inventory 未含 meta/phase.json；其他38個 API 列出專案未逐一查資料，不能斷言全部缺標註。
評估方式	論文以人工標記的 last-completed phase / first failure phase 形成每階段分佈及最終成功率，不能由 clearance 單欄推導自動成功。正文第7頁寫20 rollouts/task/policy，第8頁與附錄A.5寫15，後者18×3×15=810；須釐清實際使用名冊。公開 lerobot_eval.py 讀 info.final_info.is_success 或 info.is_success，缺值用False，沿 episode 合併為 any(success)，再平均成 pc_success（百分比），同時計 reward；它不判斷 connector engagement 或 phase 邊界，不能代替 REBOOT grader。失敗詞彙也有版本差：第6頁四類，附錄與第7頁另含 slip。裁切器會移除 dtype=depth / 名稱結尾_depth 的 feature，重新產生 index/timestamp，未重對映 phase/failure 時間，不能直接把其輸出當原版完整 recovery case。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **18** assembly/disassembly tasks · 原文頁 5
- **2,160** expert+recovery demonstration episodes · 原文頁 5, 6
- **810** 主分析總evaluation rollouts · 15×18×3；與protocol 20次不一致 · 原文頁 8

依這個順序讀

1. `README.md` ↗

   GitHub · anon-robo-account/REBOOT · 269d53958c

   確認 fork 角色、LeRobot v3/depth 與 REBOOT26 官方資料來源。

   L11–27 · L47–67

2. `src/lerobot/datasets/lerobot_dataset.py` ↗
   GitHub · anon-robo-account/REBOOT · 269d53958c

   從 metadata 到 parquet / MP4 reader、episode 邊界 padding、timestamp offset 與 depth 分流。

   `L161–217 · L233–260 · L934–1060 · L1117–1160 · L1321–1338`

---

3. `src/lerobot/cameras/realsense/camera_realsense.py` ↗
   GitHub · anon-robo-account/REBOOT · 269d53958c

   RealSense z16、uint16 depth 與相機後處理，避免當 RGB 正規化。

   `L280–291 · L327–365 · L420–461`

---

4. `dtset-trim/dataset_episode_trim.py` ↗
   GitHub · anon-robo-account/REBOOT · 269d53958c

   實際 phase.json schema、failure.t_r、半開 frame slice，以及刪除 depth / 重建索引的行為。

   `L1–18 · L74–157 · L191–259 · L269–279`

---

5. `src/lerobot/scripts/lerobot_eval.py` ↗
   GitHub · anon-robo-account/REBOOT · 269d53958c

   具體程式只彙總環境 is_success 與 reward，沒有 REBOOT 五階段的物理 / 視覺判定。

   `L198–231 · L366–381 · L438–463`

怎麼接入我們的benchmark

可重用

14D通道名稱、四相機 / depth schema、LeRobot v3 episode 索引讀取、原生 task inventory、人工 phase/failure 表達及裁切窗解析。

需要轉換

source 分別保留程式 commit 與每個 HF dataset revision；environment 記硬體 / board；task 用 object+install/remove；case 用 dataset revision+episode_index，另存 expert/recovery 與雙臂旗標；frame/time 用30 Hz與原 offset 連線。保留 source_frame_index 與 trim offset，重新對映 phase/t_f/t_r/t_s，避免刪 depth；evaluator 獨立儲存人工階段判定與通用 rollout success，不合併。

仍需補齊

36個理論 task×episode-type 分組與官方實際38個資料 repo / 分片的對照及去重；完整 episode 與 phase annotation 名冊；RCA 本次固定版本僅30段及缺phase的原因；15/20 rollout 協定釐清；原生 joint/gripper/depth 校準尺度；公開 REBOOT 專用 grader 或人工評分流程。

P180 · SafeManip

SafeManip: A Property-Driven Benchmark for Temporal Safety Evaluation in Robotic Manipulation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

已追到 privileged HDF5/JSON reader、simulator contact grounding、LTLf DFA、可恢復的 repeated-violation 狀態機與實際聚合器。公開 code 有20個 enforced specifications / 8類，但所讀 analysis/monitor_metrics/RQ1 的分母與論文v3 per-trigger pooled metrics 不一致；id.csv 也有9個當前公式無法匹配。

> **版本與身份**
>
> AST / CSV靜態比對發現9 / 20個當前公式不能由id.csv文字join到ID；例如collision已改sustained、grasp拆成兩spec、release改用object_dropped。id.csv也將釋放公式列為GraspStability、舊抓握公式列為ReleaseStability，與ApplicableProperty不同。不要用舊P1...ID自行覆寫native property_name。README明示working forks被gitignore，但monitor/sim公開extension確實存在，不能把整個來源誤標為無程式。
>
> 收錄 arXiv:2605.12386v3（2026-09-28），第6頁列此 GitHub；README 題名一致但仍匿名。程式固定2026-09-26 commit，早於該 PDF 修訂，尤其評分與ID對映不可假定完全同步。

領域	居家整理與清潔
環境	沿用 RoboCasa365 廚房與 LIBERO 桌面模擬，主體是可取得 privileged simulator state 的安全監測層。論文50個RoboCasa tasks、4×10個LIBERO tasks是重用範圍，不另當90個新環境。固定scene實驗依seed鎖定layout / 初態，應與一般scene variation分開。gitlink 的 LIBERO=8f1084e、LIBERO_openpi=f78abd6、RoboCasa=4f8a298。
任務	8類：碰撞 / 接觸、抓握穩定、釋放穩定、交叉汙染、action onset、mechanism、containment、enclosure/access。論文表2的10個template與表4 / 程式20個enforced spec不同單位；靜態AST逐一抽出20個name/ltl，抓握拆同步與掉落合法性，action onset有8種skill。task applicability 必須取原生場景 / 物件及ApplicableProperty表；LIBERO無某些語義觸發不能當免費安全分數。monitor目前每property每episode使用binding={}，未列舉全物件組合。

題數與資料	LIBERO reader 讀 data/demo_*/states、可選actions及init_state attr、data.attrs.bddl_file_name；直接set_state_from_flattened後forward，另設timestep=t+1防止監測狀態每frame重置。若actions數等於states數，嘗試最後action補一個terminal frame，故監測長度可能T+1；其replay_summary仍硬編split='train'，即使fallback可讀eval rollout。輸出privileged_static_info、privileged_dynamic_info[{step,data}]、replay_summary；dynamic含task.timestep/success、robot.end_effector_pose、scene物件 / fixture pose與predicates。env_ext quaternion由body_xquat輸出wxyz。monitor輸出property_name/ltl/binding、num_frames、violations/satisfied、original/repeated、repaired_traces、accepting_by_property/recovery_accepting_by_property；raw per-frame repeated trace預設移除。frame index、原生step、call_stride與秒數須分開，不從monitor行數推定物理時間。
評估方式	具體collision grounding先排除合法robot/object/fixture/receiver/source-support/tool接觸，剩餘geom pair累加forbidden_contact_age，>20 frames才令forbidden_contact_sustained=True，enforced公式為G(!forbidden_contact_sustained)。SETTLE_TIMEOUT_FRAMES=100、SKILL_ONSET_FRAMES=10是本commit幀閾值。DFA逐frame轉移；repeated monitor進reject後凍結main並推進recovery DFA，recovery接受才結束unsafe episode及重新啟動，保留次數與duration。論文v3定義聚合後Vφ/Nφ及Uφ/Nφ，aggregate先pool counts，task success獨立。實際monitor_metrics卻算violated_instances/evaluated_instances及exposure_frames/monitored_frames；analysis.metrics的violations_per_skill_onset以evidence裡所有skill_*_onset_candidate_count的最大快照作分母，RQ1再平均各列ratio，不是每property trigger總數。因此這些現成CSV / 圖不能直接標成v3正式per-trigger結果。timeout未觸發而影片已結束時run_monitor把該property歸satisfied，必須儲存截斷 / 未觀測完成的限制。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **90** 兩來源host task entries · 原文頁 6
- **10** 安全規則templates · 原文頁 4, 5
- **50** 每policy/task evaluation episodes · 原文頁 6

依這個順序讀

1. `README.md` ↗

   GitHub · chengyuehuang511/SafeManip · cb9ca772c5

   確認 safety layer 角色、gitignored working forks 與固定 / 變動場景流程。

   `L13–69 · L83–92 · L309–353`

2. `.gitmodules` ↗

   GitHub · chengyuehuang511/SafeManip · cb9ca772c5

   模擬器 / 模型是獨立 gitlink，不能把 parent tree 當完整上游程式。

   L1–41

---

3. `SafeManip/analysis/ApplicableProperty.csv` ↗

   GitHub · chengyuehuang511/SafeManip · cb9ca772c5

   以50個task欄位對應property applicability，不將所有安全類別套到每task。

   L1–15

---

4. `SafeManip/monitor/extract_privileged_from_dataset_libero.py` ↗

   GitHub · chengyuehuang511/SafeManip · cb9ca772c5

   HDF5 states/actions/BDDL reader、逐frame還原與末端frame補回。

   L107–219 · L267–305

---

5. `SafeManip/monitor/sim/libero/env_ext.py` ↗

   GitHub · chengyuehuang511/SafeManip · cb9ca772c5

   實際輸出 task/scene/robot/predicates 與 wxyz quaternion。

   L50–131

---

6. `SafeManip/monitor/sim/robocasa/predicates.py` ↗

   GitHub · chengyuehuang511/SafeManip · cb9ca772c5

   allowed contact class 排除後，連續 forbidden contact 超過20 frames 才觸發 sustained。

   L436–456 · L4140–4273

---

7. `SafeManip/monitor/specs.py` ↗

   GitHub · chengyuehuang511/SafeManip · cb9ca772c5

   具體 collision invariant 與 grasp weak-until，和文章template分層儲存。

   L443–460 · L527–531

---

8. `SafeManip/monitor/predicates.py` ↗
   GitHub · chengyuehuang511/SafeManip · cb9ca772c5

   predicate wrapper 只查已grounded值，必須往 sim implementation 追。

   L119–163

---

9. `SafeManip/monitor/monitor.py` ↗
   GitHub · chengyuehuang511/SafeManip · cb9ca772c5

   每property使用單一空binding，逐frame餵入已grounded atom。

   L72–93 · L225–276

---

10. `SafeManip/monitor/LTLfDFA.py` ↗
    GitHub · chengyuehuang511/SafeManip · cb9ca772c5

    實際 MONA/DFA 建立、唯一轉移與終止 / trap 判定。

    L161–246 · L267–287

---

11. `SafeManip/monitor/repeated_violation_monitor.py` ↗
    GitHub · chengyuehuang511/SafeManip · cb9ca772c5

    違反後凍結main、啟動recovery、恢復時reset，以及collision具體recovery公式。

    L105–245 · L248–319 · L1408–1437

---

12. `SafeManip/monitor/run_monitor_on_privileged.py` ↗
    GitHub · chengyuehuang511/SafeManip · cb9ca772c5

    reader→predicate修補→monitor→輸出；截斷timeout會被列為satisfied的實際語義。

    L103–133 · L1238–1324 · L1328–1409 · L1524–1569 · L1640–1681

---

13. `SafeManip/monitor/monitor_metrics.py` ↗
    GitHub · chengyuehuang511/SafeManip · cb9ca772c5

    instance分母的violation_rate與frame exposure，不是per-trigger。

    L77–125 · L137–230

---

14. `SafeManip/analysis/metrics.py` ↗

    GitHub · chengyuehuang511/SafeManip · cb9ca772c5

    onset候選計數、零分母空值、task/safety/safe-success的分離。

    L72–85 · L266–397

---

15. `SafeManip/analysis/id.csv` ↗

    GitHub · chengyuehuang511/SafeManip · cb9ca772c5

    舊公式 / 類別對映與當前spec不一致。

    L1–20

---

16. `SafeManip/analysis/RQ1.py` ↗

    GitHub · chengyuehuang511/SafeManip · cb9ca772c5

    圖表以ratio列取平均，未依論文先pool trigger與violation數。

    L743–766 · L1846–1864

怎麼接入我們的benchmark

可重用

原生property_name、enforced LTLf、recovery LTLf、predicate grounding / 幀閾值、靜態scene角色、逐frame trace與unsafe episode區間。

需要轉換

source保留PDF版 / parent commit / simulator gitlink；environment與task指向原生RoboCasa/LIBERO；case=原生task+policy+seed+scene/split+episode；evaluator拆task success、whole-rollout satisfaction、repeated counts、unsafe frames、per-property trigger counts。保留template→enforced-spec→category對映與NA applicability。零分母記NA，禁止把空類別回傳0當成已證安全；從trace另建有版本的trigger registry後才算v3 pooled metrics。

仍需補齊

v3 per-trigger Nφ 的完整程式 / 可核對輸出；當前20個公式與id.csv / ApplicableProperty的版本對齊；被gitignore的working policy/simulator fork與公開extension的接線；末端補frame及硬編train provenance驗證；全部grounding與機制的獨立有效性檢查。本輪未跑MONA、模型或模擬。

P181 · RoboFolDeX

RoboFolDeX: A Physical-World Benchmark for Long-Horizon Robotic Manipulation of Deformable Objects

實作尚未確認 · 主來源 · 原作 · 獨立頁面

完成 pinned PDF、GitHub 搜尋快取與官方 challenge 頁的限量身分查詢，仍未確認作者授權的公開程式倉庫或資料 reader。保留長時程實體折衣任務、人工品質評分與 FoldScore 的論文規格；不以其他 cloth benchmark 或通用VLA程式替代。

> **版本與身份**
>
> 以2026-09-18 v2 PDF為準；第3頁仍稱review期間省略access links，與首頁已列Midea網址並存，不能據此補猜程式網址。無repo commit可記；各PDF/搜尋/HTML/HTTP receipt均記本地SHA256及read範圍。未執行JS、提交policy、聯絡作者或下載模型 / 資料。
>
> RoboFolDeX 指 Chenhuan Liu、Yi Xu 等的 arXiv:2609.10243v2，機構為 Fudan / Midea / CMU。PDF第1頁給出的第一方平臺為 ai.midea.com/#/fold-challenge。FoldChallenge 是這篇的實體評測平臺名稱，不是可據以自動推定的 GitHub owner/repo。

領域	居家整理與清潔、衣物與洗護
環境	真實雙臂長時程衣物整理，從籃中取衣、桌面翻轉 / 攤平、多次折疊到最後放置 / 堆疊。資料涵蓋桌面 / 家庭場景與照明、背景、layout變化；論文列Aloha、YAM、Piper、Astribot、Franka、UR5、自研移動雙臂、AgiBot G2等，10+是宣稱的embodiment規模，未取得完整registry。
任務	主題是衣物折疊，參考實驗分Shirt、Skirt、Pants、Towel；完整資料另外含其他deformable及少量rigid任務。20+是論文來源層task宣稱，不是已列舉的可執行task數。四個track為recovery-data utilization、cross-task、cross-scene、cross-embodiment；它們是訓練 / 轉移協定，不另計為四項操作技能。
題數與資料	論文宣稱2,000+小時真實robot trajectories。觀測為兩腕相機+外部workspace相機RGB、自然語言指令、proprioception；action為未來end-effector pose trajectory。論文描述共用metadata語義：task、object category/instance、scene、embodiment、operator、data source、completion及failure/termination reason；本輪未取得實際檔名 / keys、action維度與座標系、時間頻率或split名冊，因此不能將這些概念冒寫成已驗證JSON schema。hours、tasks、robot embodiments與episode/case數分開，case總數保持未知。

評估方式	論文標準完整episode需無人工介入且無不可恢復失敗，通常每衣物類別30次獨立實體trials、初態隨機化；品質由至少兩名相同評審跨方法獨立評定，達成一致才記錄。neatness等級0–5檢視形狀、緊密、平整、穩定與邊緣；FoldScore=35×平均正規化品質Q̄+35×完整success rate R+30×max(0,1–t/Tmax)，t只在成功trials平均，無成功時時間項為0。PDF稱quality mapping及細rubric在Appendix，但固定版本共9頁、第8–9頁為references，未附該表；Tmax也未給數值。故不能自行用neatness/5或任意時限做『官方scorer』。π0.5的pre-flattened短流程baseline與basket-to-stack完整流程須分開。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **2,000** real-robot data hours · 下限 / 2,000+ · 原文頁 1, 4
- **20** 資料task種類 · 20+，非全數主評測 · 原文頁 4
- **30** 每衣物類別物理trials · 原文頁 5, 6

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

已明確的實體任務流程、四track設計、observations/action的語義、0–5品質尺度及FoldScore公式。

需要轉換

source記PDF v2與FoldChallenge第一方平臺；environment儲存實體硬體 / 相機 / 場景；task儲存衣物類別與完整或區域性流程；case待原生trial/garment instance/init metadata公開後建立。evaluator先標人工評分及paper_specified_formula，品質 / success / 成功trial時間三項分存，資料重用track保留訓練來源與target embodiment。

仍需補齊

作者確認的程式repo、可檢驗reader/schema、公開資料manifest / 授權 / split、完整品質rubric及Q對映、Tmax、submission/execution介面與實體trial結果。SPA大型JS及可能需互動的頁面內容本輪未展開，平臺『operational』僅依論文宣告。

P182 · SoftVTBench

SoftVTBench: A Deformation-Aware Visuo-Tactile Dataset and Benchmark for Deformable-Object Manipulation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

核讀的是舊v0.1的四suite task/config、HDF5 reader、具體goal checker、FEM Kabsch變形計算、per-object calibration及正式softvtbench_metrics。它與收錄論文的資料規模、asset清單及90th-percentile門檻不同，且runtime停用了drop termination；本筆是有版本限制的程式核讀，不代表已重現4,000示範版DSR。

> **版本與身份**
>
> 固定58056111f（2026-07-22）。repo身分由PDF明鏈與相同作者確認，但README的2607.04234、1,628/33、pi05-only、半最大值calibration都屬舊版；PDF為2608.18701、4,000/50+、Diffusion/π0.5/FastWAM、90th-percentile。另有README NoDrop敘述與正式code不一致，以及deprecated global-threshold scorer，全部分開記錄。未執行任何模擬或上游模型。
>
> arXiv:2608.18701v1 第1頁直接連至此repo，作者與README的Bowen Jing、Mingxin Wang等一致，故為第一方來源。但2026-07-22固定commit的README / 專案頁仍連2607.04234並使用Safety-Aware舊題名；不能據此改寫收錄PDF身分或當作新paper版本已完整發布。

領域	通用物件與機動作業、餐飲與烹飪
環境	Isaac Sim / Isaac Lab，Franka Panda及雙指GelSight Mini，FEM deformable物件、剛性對照與tactile proxy；與Tabero / LIBERO有重用關係。task JSON分fixtures、objects、regions、robot_base_pos / wxyz orientation、obj_of_interest與tactile_targets，soft / rigid twin及場景variation要各自保留，不將舊LIBERO BDDL檔名當作當前soft task身分。
任務	Object-Soft、Spatial-Soft、Object-Rigid、Spatial-Rigid是2×2 matched suites，核心為pick-and-place。收錄論文每suite10 tasks / 1,000 demos，另500 ID evaluation episodes / suite（50/task），soft suites各9種單因子OOD條件、每suite/config合計900 OOD trials。程式的generic softvtbench_tasks.json另列libero_10/spatial/object/goal各0–9，不能直接當四個soft/rigid suite mapping。實查object_soft config有10 tasks；task0為取white swirled soft pastry放basket，其asset soft_pastry001與舊alphabet_soup BDDL並存。

題數與資料	PDF宣稱4,000 demonstrations、50+ assets；README舊v0.1是1,628 demonstrations（500/500/421/207）與33 assets，均非本輪實際下載數。20 Hz同步第三人稱 / 腕部RGB、左右tactile RGB/marker motion、proprioception、language及binary/continuous gripper；FEM為evaluator-only。所讀HDF5使用data/demo_*、actions、obs/eef_pose（xyz+wxyz）、obs/gripper_pos、states/deformable_object/<asset>/nodal_pos_w與soft_extras。assembly保留original_demo_id並按(task_id,demo_id)去重；缺success attr預設True，匯入需額外驗證。7D converter以xyz+axis-angle+單指gripper為state，接受7D或legacy8D action，13D force-in-action需另一converter；較短影片路徑有隨機drop state/action再切video的分支，不能宣稱與PDF『無重取樣』完全一致。模型7D、legacy8D、13D及server padded32D不可混為一種action space。
評估方式	goal checker逐個goals合取xy距離與(|Δz|−height_diff)<height_threshold；IN/ON尚共用此公式，force條件只在enable_force_threshold='True'且sensor存在時啟用。task0閾值xy=0.2、height=0.2、force=0.05（原生模擬尺度），soft asset建置會跳過該rigid contact sensor。client預設30次推論×10動作、8連續success steps；但正式JSONL scorer取最後success_now，須核對其與experiment_success一致，且成功 / terminated會在debug記錄前break。FEM正式metric_id=fem_rms_rigid_aligned_bbox_pct_v1，以首個節點狀態作reference，proper Kabsch禁止reflection，D(t)=100×RMS位移 / reference bbox diagonal，D_peak=max_t D(t)。程式SafeSuccess=GoalSuccess且D_peak≤tau，未另檢NoDrop，harness也停用*_dropped；不能宣稱符合PDF的drop即停。舊calibrator用0.5×max stable peak；例如soft_pastry001 tau=0.44692%，PDF表9的90th-percentile tau為7.6%，差異不是單純改名。正式scorer重算HDF5 nodes、檢JSONL metric ID；goal rate分母是已知goal episodes，safe rate分母是全部episodes，未知safety保留n_safe_unknown且不算safe。strict通過且分母一致前，goal_safe_gap不具有PDF TSR−DSR的精確語義。rigid診斷可令safe=goal，公表仍應保留N/A / 適用性。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **40** object/spatial ×soft/rigid task settings · 原文頁 5, 6
- **4,000** expert demonstrations · 原文頁 6
- **2,000** ID evaluation episodes · 原文頁 7
- **1,800** OOD evaluation episodes / configuration · 原文頁 8, 9

依這個順序讀

1. `README.md` ↗

   GitHub · TuojingAI/SoftVTBench · 58056111f0

   第一方作者身分、舊資料規模、v0.1模型範圍與50次/task預算。

   `L3–33 · L47–105 · L229–238 · L375–407`

---

2. `configs/benchmark_protocol_v1.json` ↗

   GitHub · TuojingAI/SoftVTBench · 58056111f0

   正式程式protocol與README文字差異。

   `JSON root`

---

3. `configs/object_soft/libero_object.json` ↗

   GitHub · TuojingAI/SoftVTBench · 58056111f0

   task_id、language、native BDDL來源、goals、assets / regions與robot pose。

   `JSON /task_suite_name · JSON /total_tasks · JSON /tasks/0`

---

4. `SoftVTBench/source/tac_manip/tac_manip/tasks/manipulation/libero/config/franka/franka_libero_env_cfg.py` ↗

   GitHub · TuojingAI/SoftVTBench · 58056111f0

   JSON task reader、success term註冊，soft物件跳過rigid contact sensor建置。

   `L90–126 · L388–401 · L829–835`

---

5. `SoftVTBench/source/tac_manip/tac_manip/tasks/manipulation/libero/mdp/terminations.py` ↗

   GitHub · TuojingAI/SoftVTBench · 58056111f0

   實際位置 / 高度 / 可用時contact-force合取；IN與ON共用位置近似。

   `L103–169`

---

6. `SoftVTBench/benchmarks/common/closedloop_policy_inference.py` ↗

   GitHub · TuojingAI/SoftVTBench · 58056111f0

   取出success後由client檢查；runtime停用timeout與object_dropped。

   `L43–66 · L89–104`

---

7. `SoftVTBench/benchmarks/openpi/openpi_inference_client.py` ↗
   GitHub · TuojingAI/SoftVTBench · 58056111f0

   action模式、30×10預算、8連續成功step與debug success_now欄位。

   L555–594 · L726–789 · L2053–2069 · L2178–2186

---

8. `experiments/object_soft/replay_format/assemble_object_soft_replay_format.py` ↗
   GitHub · TuojingAI/SoftVTBench · 58056111f0

   native示範metadata、FEM summaries、success篩選及task/demo去重。

   L29–52 · L66–83 · L168–180 · L243–257

---

9. `SoftVTBench/benchmarks/common/convert_all_libero_to_lerobot_openpi.py` ↗
   GitHub · TuojingAI/SoftVTBench · 58056111f0

   7D / legacy8D轉換、wxyz到axis-angle、影片對齊與13D拒絕條件。

   L122–176 · L257–348

---

10. `experiments/common/deformation.py` ↗
    GitHub · TuojingAI/SoftVTBench · 58056111f0

    metric ID、proper Kabsch去平移 / 旋轉後的RMS與bbox百分比。

    L6–53

---

11. `experiments/common/calibrate_safety_thresholds.py` ↗
    GitHub · TuojingAI/SoftVTBench · 58056111f0

    舊版tau=0.5×最大stable compression peak，並非PDF的90th percentile。

    L1–10 · L36–89

---

12. `configs/safety_thresholds.json` ↗
    GitHub · TuojingAI/SoftVTBench · 58056111f0

    每asset的tau、d_ref、kappa、stable trial數及calibration版本。

    JSON root

---

13. `experiments/common/softvtbench_metrics.py` ↗
    GitHub · TuojingAI/SoftVTBench · 58056111f0

    正式HDF5/JSONL scorer、missing-evidence語義、百分比與不同分母。

    L55–98 · L109–225 · L233–274 · L302–331

---

14. `experiments/spatial_soft/evaluation/spatial_soft_safety_metrics.py` ↗
    GitHub · TuojingAI/SoftVTBench · 58056111f0

    此global-threshold舊檔已deprecated，不能作正式scorer。

    L1–14

---

15. `SoftVTBench/benchmarks/common/metrics.py` ↗
    GitHub · TuojingAI/SoftVTBench · 58056111f0

    附加force診斷的local-frame定義及max其實為Top5%均值。

    L121–189 · L261–300

怎麼接入我們的benchmark

可重用

具體task/config、native HDF5與影片索引、policy/evaluator通道分離、Kabsch FEM公式、per-asset門檻及explicit metric ID。

需要轉換

source綁PDF v1與程式v0.1兩個版本；environment記solver / scene / tactile assets；task以suite+native task_id+asset identity建立；case分demo、ID trial、OOD trial並儲存paired seed / initial state。evaluator保留TSR/DSR與程式Goal/Safe label的版本關係，另記tau生成方法、reference nodes、百分比尺度、成功horizon及drop規則。domain依實際pick/place用途對映。附加force的squeeze=2min(|fLz|,|fRz|)，applied-force z扣除成對squeeze，*_max是非零Top5%均值，不映成物理peak。

仍需補齊

對應2608.18701的4,000版release / split manifest、90th-percentile calibration與rescorer、soft_stw_cuboid_hq等新版asset對照；drop termination及300-step協定閉合；terminal debug / sustained goal的對齊；資料與USD / Tabero tactile runtime資產取得驗證；原生HDF5 success型別、跨root重複JSONL/HDF5及影片時間對齊。

P183 · WireCraft

WireCraft: A Simulation Benchmark for Industrial DLO Manipulation

檔案 / 網站 · 主來源 · 原作 · 獨立頁面

限量primary discovery找到作者身分支援的WireManip/WireCraft，固定tree不截斷且只含223 bytes / 4行README。README宣告程式預計2026年11月初發布；當日2026-10-11尚無task、reader或scorer可核讀，因此本篇處置為公開README佔位，不再泛稱沒有候選，也不採用同名第三方專案。

> **版本與身份**
>
> pinned PDF June2026寫upon acceptance；9月新建README改成2026年11月初釋出計畫，當日仍在未來。這是作者公告，非程式已公開或會準時發布的保證。本輪只抓小型metadata / README與兩個作者頁，未下載資產或執行上游。
>
> 收錄arXiv:2606.18097v1，第一作者Chongyu Zhu、University of Toronto。既有精化搜尋找到WireManip/WireCraft；本輪固定commit作者為GitHub ChongyuZhu，其公開profile同名且company=University of Toronto，README完整題名相符。共同作者Zachary Tang的第一方頁也確認原論文與本人參與，但該頁未直接連repo。作者身分證據足以提出高可信來源繫結候選，仍將繫結修改交協調者。

領域	裝配與生產作業
環境	以下為論文規格，尚無repo實作可驗證：Isaac Lab2.2.1 / Isaac Sim4.5，另聲稱驗證5.1。DLO有PhysX D6剛性segment chain及FEM deformable兩種表示，對齊task / connector介面而非聲稱材料引數等價。模擬支援UR5、Franka、Trossen Stationary AI；實體validation用UR5+Robotiq2F-85、腕部與側視RGB、3D列印Ethernet接頭 / task board。實體腕部force/torque sensor讀值未用於policy，只需在sim匹配其幾何offset。
任務	三個family為connector insertion、clip routing、channel seating。論文註冊五種connector geometry，其中cylinder/cuboid/Ethernet/DisplayPort進入所報實驗，USB-A為額外asset；不能把五個connector全當已評測tasks。clip difficulty最多3個clips；channel由5 segments組成，可為直線或每joint最多±20°彎曲。family、variant、fixture數、reset variation與episode均不同單位，無公開registry可確認精確全部task count。
題數與資料	論文稱scripted、RL rollout、sim teleoperation、real UR5四種來源共用LeRobot-compatible schema。UR5 state/action各7D（6 joint+gripper），雙RGB與instruction同步；這是論文語義，未取得實際feature keys、parquet/video path、dataset revision或reader。IL/VLA比較使用同一1,000條scripted insertion trajectories，非全benchmark總case數。RL另用42D privileged observation與Cartesian delta pose+gripper action，clip到[-1,1]再乘0.01；不與joint-space dataset action直接合併。原生physics dt=1/120 s、decimation=2、control=60 Hz，其他實體資料時間約定需待公開。

評估方式	只有paper-defined protocol：insertion分SRreach（夾持plug進入socket周邊2 cm）及SRinsert（tip就座），不得以reach代替insert；3 mm是Ethernet測試clearance，不是插入成功閾值。clip需seated於clips；channel需超過80%線長在channel內，尚無公開離散化 / checker細節。RL報3 seeds的mean±std，8秒horizon；IL/VLA附錄F用4 seeds×16 rollouts=64/checkpoint、800 simulator steps，不可與8秒 / 60 Hz budget預設等同。checkpoint以相同evaluation rollouts的reach success取前三，並非held-out validation選模；insert來自同checkpoint、未另最佳化。公開tree無可執行scorer，不能聲稱已核對這些條件的程式實作。

▼ **原作數字：保留論文的單位與頁碼**

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **3** industrial DLO task families · 原文頁 3, 4
- **10** real Ethernet每metric/setting rollouts · 原文頁 23, 25

依這個順序讀

1. `README.md` ↗

   GitHub · WireManip/WireCraft · 9acbc318c1

   完整題名及未來程式release計畫；完整tree確證此commit僅README。

   L1–4

怎麼接入我們的benchmark

可重用

可重用論文的task families / 變化軸、兩種DLO表示、資料來源分類及reach/insert/channel的不同度量；README作release追蹤。

需要轉換

source保留paper v1及placeholder commit；environment按simulation model / robot / physical setup分開；task按family+fixture/connector geometry；case在公開reset seed / episode manifest後建立。evaluator先標paper_specified、runtime_unavailable，儲存native units、budget、policy可見資訊及checkpoint選擇協定。各data-source mixing實驗保留R/S/P組成，不做語義等價合併。

仍需補齊

11月release是否履行、真正task registry / reader / concrete scorer、dataset與3D assets manifest / 授權、精確insert/clip判定、8秒vs800步預算對齊、各實驗checkpoint / split closure。

P184 · DLO-Lab

DLO-Lab: Benchmarking Deformable Linear Object Manipulations with Differentiable Physics

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

已核讀8-task registry、原生RL/DiffRL action與時間約定、coiling/lifting/wrapping的具體reward、trajectory aggregation，以及LeRobot匯出 / 讀取。原生episodic return、存活到horizon的diagnostic success及論文影片人工success三者不同；生成示範的過濾也只排除absorbing，不證明任務完成。

> **版本與身份**
>
> 固定2026-10-08的4af05620，晚於June2026 PDF，包含新的LeRobot輸出及registry整理；未宣稱與論文原始程式完全一致。envs/README稱reward非負 / loss近似負reward是設計指南，具體lifting/wrapping程式有penalty與不同loss，標準化以實作為準。README的SharePoint資產與Mushroom-RL fork未下載；未執行模擬 / policy。
>
> arXiv:2606.04206v1 → dlo-lab-26.github.io第一方[Code] → UMass-Embodied-AGI/DLO-Lab；README列相同六位作者與2606.04206。專案頁另一個zzyunzhi/template只是網頁模板，不納入benchmark source。

領域	裝配與生產作業
環境	Genesis衍生的Taichi differentiable rod simulator，ROD material可設E/G、segment radius/mass、接觸friction與塑性；場景配Franka、cones/posts、rings等。coiling具體為60個rod vertices、間距0.02 m、radius0.01 m與固定cone，control_idx=[1]在reset直接attached_to_gripper，不能視為已包含自由抓取成功。scene dt=0.001 s、substeps=5；一次policy action跨steps_interval個scene steps，須另保留此數與split，不以影片fps推控制頻率。
任務	registry正好8個固定horizon任務：coiling、gathering、lifting、separation、slingshot、unknotting、wiring_post、wrapping。論文第6頁另列Letter Art與Wiring-ring，屬DLO agent的長時程分解實驗，未在此8-task registry中，分開建task來源 / 協定。grasp候選、rod nodes、posts、robot arms與rollout次數都不是task數；未取得固定case manifest，案例總數不填虛構值。

題數與資料	RL privileged observation按(rope vertices+additional objects)×6+grasp points×14，包含位置 / 速度、末端pose及arm joints；RL action每control point 6D，先乘_act_magnitude、clip、L2限制，再拆xyz / rotation，Pink controller預設translation=m、rotation=degrees。DiffRL只有每point3D translation並從rope vertex反傳，不能共享同一action schema。資料匯出另統一為observation.state float32[16]、action[12]、action.joint[18]，單臂左側zero padding；action排列[right_xyz,left_xyz,right_rot,left_rot]。相機front/wrist_right/wrist_left，單臂wrist_left為黑圖，不是第三個真實視角。timestamp=step_idx×scene.dt×n_substeps_per_step；初frame有zero action，之後capture在step之後，末frame action/action.joint又複製前frame，必須保留原對齊。匯出data/chunk-000/file-000.parquet、meta/info.json/stats.json/tasks.parquet、meta/episodes/...與videos/chunk-*/observation.images.<cam>/episode_*.mp4，split只宣告train。filter reader只讀consolidated file-000；需保持其前置條件。
評估方式	coiling reward=exp(−0.1Σv‖v−(0,0,0.15)‖)，是距離proxy而非繞圈成功。lifting reward=5×兩環高度和+rope相對抬高項−0.5×rope到兩環最近距離−100×末端距環小於0.08 m的penalty；loss_criterion另外含stretch loss，不能當相同分數。wrapping以xy-plane角度和 / 2π的絕對winding、與1圈的平方誤差及到三柱最近距離超出0.015 m的penalty計reward。coiling eval_traj累加substep reward，另回final_reward及forward_time，NaN/failed final用survival_ratio−100；CMA可選cum或final做最佳化。PPO儲存undiscounted return及末reward，diagnostic success_rate=(episode_length==n_outer_steps)，只是未提前失效。論文主表報固定budget內最大episodic return、3 seeds；附錄影片人工success用每RL方法15條、GD1條、CMA最佳checkpoint的top15條。這些不是同一個自動success metric。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **10** DLO task definitions · 原文頁 3, 4
- **8** 主固定horizon評測tasks · 原文頁 5, 6
- **15** 附錄RL每task evaluation trajectories · 原文頁 18, 19

依這個順序讀

1. `README.md` ↗

   GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

   確認論文、外部assets、八task與本版新增資料匯出流程。

   L3–39 · L68–81 · L154–209

2. `experiments/envs/registry.py` ↗
   GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

   實際唯一task→Train_Env subclass清單。

   L16–50

---

3. `experiments/envs/base.py` ↗
   GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

   scene dt / substeps、RL觀測/action sizing、DiffRL的3D vertex控制。

   L30–108 · L298–353 · L418–439

---

4. `experiments/envs/env_coiling.py` ↗
   GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

   60節點scene、指定grasp vertex、exp-distance reward、NaN failure、sum/final return與observation。

   L42–80 · L111–134 · L149–204 · L326–351 · L353–469

---

5. `experiments/envs/env_lifting.py` ↗
   GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

   兩環高度 / rope距離與gripper近距離penalty；differentiable loss不等於負reward。

   L188–272

---

6. `experiments/envs/env_wrapping.py` ↗
   GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

   封閉rope winding number、15mm柱半徑距離penalty及不同最佳化loss。

   L211–262 · L341–414

---

7. `experiments/utils/controller.py` ↗
   GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

   Pink IK的translation公尺、rotation預設degrees與world target更新。

   L501–580

---

8. `experiments/trajopt/cmaes.py` ↗
   GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

   由eval_traj取得cum/final reward，依use_last_state_reward選CMA最佳軌跡。

   L90–123 · L292–334

---

9. `experiments/rl/rudinppo.py` ↗
   GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

   PPO使用undiscounted return；success_rate欄其實只是episode_length==horizon。

   L299–358

---

10. `experiments/datagen/config.py` ↗
    GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

    16D state / 12D action / 18D joints及單臂padding、相機欄位。

    L10–30 · L100–153

---

11. `experiments/datagen/generate_dataset.py` ↗
    GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

    run_config reader、post-step資料擷取、failed filter、T+1紀錄與action時序。

    L77–126 · L135–211 · L335–417 · L570–608

---

12. `experiments/datagen/export.py` ↗
    GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

    實際parquet schema、影片template、v3 metadata與train-only split。

    L54–132 · L388–440 · L610–630

---

13. `experiments/datagen/filter_dataset.py` ↗
    GitHub · UMass-Embodied-AGI/DLO-Lab · 4af05620a9

    單一consolidated parquet reader與episode/frame/video重編號。

    L40–73 · L197–255

怎麼接入我們的benchmark

可重用

8-task registry、具體reward/loss、scene / material / control-point引數、macro/micro-step約定、LeRobot欄位與frame/video reader。

需要轉換

source儲存此Genesis衍生commit及外部dependency / asset來源；environment按DLO拓樸、材料、fixture、robot/grasp attachment建立；task儲存原goal文字與reward program。case儲存seed、randomization、grasp indices、horizon、algorithm、sampling budget及checkpoint；evaluator分cum_return/final_reward、simulation-survival及人工task success。資料另記arm_present / camera_present mask、原raw action及縮放後物理action、前後state/action對齊，task名稱去重不靠生成episode數。

仍需補齊

assets與Mushroom-RL/Pink等依賴的完整pin / 驗證；論文影片success rubric / 標註及top15選擇名冊；完整task checker覆蓋；LeRobot產生資料的action-time與SHAC格式驗證；data generation僅依absorbing過濾且在n_envs>1時用obs0選action後tile給各env，不能直接視為獨立閉迴路成功示範。

P185 · RGBench

Real Garment Benchmark (RGBench): A Comprehensive Benchmark for Robotic Garment Manipulation featuring a High-Fidelity Scalable Simulator

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

這是服裝模擬fidelity評測，不是學習policy的task-success榜。已核讀98-capture registry、processed CSV / PCD reader、PyBullet fixed-point回放、具體Chamfer / stability計算與兩階段聚合；GarmentDynamics本體仍只有外部import插槽及已發布baseline數字。

> **版本與身份**
>
> 固定2026-07-30的5cc3d072。公開來源是evaluation harness加asset子集，不能將paper『Ours / mujoco_style3d』baseline當成此repo可跑的普通MuJoCo。比較指令碼掃描所有timestamp run且aggregate時丟robot、按garment/action/simulator/mode平均，重複sample會被重複加權。n_samples亦非處處3。現有cloth params依GarmentDynamics擬合，跨sim使用須保留校準協定。未下載6.7GB資料、checkpoint或執行sim。
>
> arXiv:2511.06434v2（2025-11-12）首頁 → rgbench.github.io → hwk0809/RGBench；README的AAAI2026題名與作者相符。網站模板eliahuhorwitz/Academic-project-page-template與Nerfies不算benchmark來源。

領域	衣物與洗護
環境	真實雙臂衣物操弄capture與同一動作的cloth simulator配對。公開資料檔案列Piper / RealSense D455，固定PDF則描述Piper或JAKA K1 / RealSense L515，應儲存各版本capture硬體證據。fixed_point以錄製末端位置驅動mesh anchors；robot mode包含robot tracking/contact。所讀PyBullet wrapper在grasp/fold讀取position並把grabber orientation固定identity，不能直接宣稱完整6DoF姿態精確重放。普通MuJoCo僅fixed_point；GarmentDynamics不等於普通MuJoCo wrapper。
任務	Grasp、Fling、Fold三種原生動作；native case key=(garment,action,robot,sample_id)。靜態解析完整experiment_library得到9 garment keys、98 entries、98個不重複data_subfolder。baseline CSV有105行：fixed_point三動作各21行，robot的fold/grasp各21行，缺robot-fling的21個cells；runner也明示fling只支援fixed_point。baseline只有7件衣物，grey_sunwear / khaki_blazer的資料仍有但未入baseline。PDF6k+ mesh assets=4k+自有工業assets+2k+ ClothesNet來源，不是6,000個task或capture；mesh解析度variants亦不增加衣物數。

題數與資料	每capture含calibration/world_to_camera_transform.json、兩臂 joints/*joint_states_and_end_pose.csv、 segment_pcds/pointcloud_<absolute_timestamp>_segmented.pcd；mesh另由HF來源供應。實際load_processed_data要求time、pos_1...pos_gripper，或pos_x/y/z、orn_w/x/y/z；檔案列header.stamp.secs/nsecs及JSON position/name是另一層ROS輸入約定，不可直接餵此reader。pose輸出quaternion=wxyz，base_rotation_quat輸入給SciPy用xyzw，位置以R_base_to_world.apply(local)+translation組合。PCD由 camera_to_world=inv(world_to_camera)轉世界座標，timestamp減master_start_time。main逐一遍歷PCD，再用target_time+camera_delay+fling_prepare_time+fling_wait_time推進sim；不是重取樣成共同FPS。保留原seconds、delay、sim step大小、record/calculation windows與point/vertex數。
評估方式	compute_cost輸出單向Chamfer L1 sim→real及real→sim、L2 sim→real、雙方向one-sided Hausdorff、sim_stability_score及兩點雲平均z差絕對值。Chamfer L1是每source point找Manhattan nearest distance後平均；L2用Euclidean距離而非平方距離，單位維持m。CPU/GPU對Nx3路徑同義，但batch輸入CPU只取[0]、GPU平均batch，不能未驗證就擴成batched evaluator。stability實際將同一frame vertices[1:-1]與相鄰vertex-index三點均值作L2偏差，再除總vertex數N，並非跨時間穩定性。HD委派point-cloud-utils且未傳norm，PDF公式卻寫L1；pyproject只限>=0.30，本輪未鎖定/核讀該依賴版本的HD實作，norm一致性列為缺件。record window決定計算哪些frame，calculation window再按sim_time取mean/std；benchmark primary fidelity metric為cd_l1_r2s。空sim mesh frame會跳過，低於z門檻的vertices函式只警告仍原樣返回。這些誤差不能轉成操作success率。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **6,000** garment assets · 6,000+ · 原文頁 1, 3
- **3** manipulation primitives · 原文頁 4, 5
- **9** real comparison garment types · 原文頁 5, 13

依這個順序讀

1. `README.md` ↗

   GitHub · hwk0809/RGBench · 5cc3d07209

   公開範圍、兩種actuation mode、asset / capture授權與論文身分。

   `L15–38 · L143–154 · L327–354 · L423–449`

2. `configs/experiment_library.yaml` ↗

   GitHub · hwk0809/RGBench · 5cc3d07209

   原生(garment,action,robot,sample) key、capture路徑、camera delay及兩個時間窗。

   L1–45

---

3. `configs/main.yaml` ↗

   GitHub · hwk0809/RGBench · 5cc3d07209

   Hydra registry binding、資料 / calibration path與實際mode / delay設定。

   L8–44 · L47–98 · L116–124

---

4. `configs/cloth_params/green_tshirt.yaml` ↗

   GitHub · hwk0809/RGBench · 5cc3d07209

   mesh resolution、物理引數與shoulder vertex ID；不能混用其他mesh的index。

   L1–22

---

5. `rgbench/csv_data.py` ↗

   GitHub · hwk0809/RGBench · 5cc3d07209

   真實reader要time/pos_* / orn_*處理後欄位，並做base transform與起點裁切。

   L24–78 · L465–558

---

6. `rgbench/transforms.py` ↗

   GitHub · hwk0809/RGBench · 5cc3d07209

   相機外參的反矩陣、手眼refinement與缺檔時identity fallback。

   L79–123

---

7. `rgbench/envs/__init__.py` ↗

   GitHub · hwk0809/RGBench · 5cc3d07209

   選擇具體PyBullet/IsaacSim/MuJoCo wrapper，GarmentDynamics屬外部closed-source dependency。

   L6–55

---

8. `rgbench/envs/pybullet/cloth_pybullet_fixed_point_env.py` ↗

   GitHub · hwk0809/RGBench · 5cc3d07209

   以CSV pose驅動固定vertex anchor、time stepping及世界座標mesh讀取。

   L41–78 · L115–123 · L184–249 · L336–376 · L429–482

---

9. `scripts/run_benchmark.py` ↗

   GitHub · hwk0809/RGBench · 5cc3d07209

   依每個真實PCD timestamp推進sim、計算方向性cost，再依calculation window彙總。

   L45–86 · L165–244 · L259–286 · L302–376

---

10. `rgbench/metrics.py` ↗

    GitHub · hwk0809/RGBench · 5cc3d07209

    Chamfer L1/L2具體nearest-neighbor與單幀vertex-index stability。

    L17–39 · L59–88 · L91–122 · L125–176

---

11. `rgbench/visualization.py` ↗

    GitHub · hwk0809/RGBench · 5cc3d07209

    以sim_time過濾calculation window，再對frame等權mean/std。

    L252–295

---

12. `rgbench/output.py` ↗

    GitHub · hwk0809/RGBench · 5cc3d07209

    metrics.csv尾端mean/std列與index=False的輸出約定。

    L110–124

---

13. `scripts/compare_to_paper.py` ↗

    GitHub · hwk0809/RGBench · 5cc3d07209

    取iloc[-2]後依cell平均、baseline join與rank；重跑sample未去重。

    L49–127

---

14. `results/paper_baselines.csv` ↗

    GitHub · hwk0809/RGBench · 5cc3d07209

    baseline長表keys與實際n_samples可為2，不能一律假設3。

    L1–6

---

15. `results/README.md` ↗

    GitHub · hwk0809/RGBench · 5cc3d07209

    7件baseline garments、105/126涵蓋與GarmentDynamics不可由此repo重現。

    L13–36 · L61–93

怎麼接入我們的benchmark

可重用

98個capture registry / 每case時間窗、world calibration、CSV pose與PCD reader、BaseEnvWrapper到具體sim stepping、方向性Chamfer與result schema。

需要轉換

source分capture dataset、工業asset subset、ClothesNet重用與code commit；environment儲存sim engine/version/mode、robot / sensor、mesh/material；task記動作primitive；case用capture key，simulator/mode/mesh resolution是trial條件。evaluator分direction/norm/unit、raw frame errors、window mean/std及跨sample mean。儲存case frame coverage、camera delay與calibration SHA；不要把105列baseline或不同sim run倍增case。raw ROS→processed CSV明示轉換，保持wxyz/xyzw與base-transform方向。

仍需補齊

HF capture / mesh與校準檔的實際revision及完整性驗證；GarmentDynamics本體、完整工業library與不同component條款；HD norm / 依賴pin；spatial vertex-order stability的指標命名或實作釐清；資料檔案與processed CSV / capture硬體版本對齊；重跑sample去重、mean/std尾列存在性與跳過frame的coverage檢查。

P186 · BiFold

BiFold: Bimanual Cloth Folding with Language Guidance

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

BiFold同庫含ICRA原作和加入時間上下文的workshop版本；可復用語言/雙手pick-place標註與SoftGym評估，但畫素預測分數和物理摺疊結果要分開。

> **版本與身份**
>
> 固定0b763d1，README同時連2501.16458和2505.07600；只有列出片段經核讀，未把workshop額外設定併為原作新task。

領域	衣物與洗護
環境	客製SoftGym/PyFlex，載入CLOTH3D衣物；VR folding為父雙手資料，真實影像另一路徑。重貼texture/render與順序版衍生資料不當成獨立物理場景。
任務	單手/雙手語言摺疊，包含逐步與rollout評測；左右pick/place是動作欄位，不是4種獨立任務。原作與temporal extension各自保留合法history設定。
題數與資料	vr_folding_dataset.zarr配actions/<partition>.csv，含left/right_grip_from/to、end_idx與text；3D vertex經相機矩陣投到pixel、depth依depth_scale還原。frame_start/frame_end是case對齊基礎，未來end位置只作GT label，不能自動暴露給policy。
評估方式	同初態先跑oracle、再跑model；成功為平均對應particle距離<2×particle_radius，另報mask IoU及50/80/90門檻，task分組後macro平均。KeypointMSE實作是最近點L2距離且另除valid數量，不能直接當一般MSE；真實影像預測分數亦不是實體摺疊成功。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **7,000** parsed bimanual folding actions（約數） · 原文頁 3
- **1,000** unique prompts（>1K） · 原文頁 3

依這個順序讀

1. `README.md` ↗
   GitHub · Barbany/bifold · 0b763d16ef

   兩篇版本、SoftGym/CLOTH3D、VR folding和真實影像來源

   L1–25 · L56–63 · L99–167

---

2. `bifold/data/bimanual_dataset.py` ↗
   GitHub · Barbany/bifold · 0b763d16ef

   Zarr+CSV、camera矩陣、左右手vertex→pixel及start/end frame

   L19–52 · L117–206

---

3. `bifold/env/softgym_evaluator.py` ↗
   GitHub · Barbany/bifold · 0b763d16ef

   具體雙手物理評測、oracle目標與粒子/IoU門檻

   L27–49 · L78–87 · L103–128 · L423–469 · L527–624

---

4. `bifold/metrics/utils.py` ↗
   GitHub · Barbany/bifold · 0b763d16ef

   模擬mask IoU是0–100

   L1–7

---

5. `bifold/metrics/__init__.py` ↗
   GitHub · Barbany/bifold · 0b763d16ef

   影像IoU與名稱KeypointMSE的實際公式

   L76–125

怎麼接入我們的benchmark

可重用

Zarr/CSV/相機投影、原生partition、oracle相同初態比較與各metric公式。

需要轉換

case固定cloth asset/config/state、文字、history與相機；分開標註預測/物理粒子誤差/視覺IoU；VR與CLOTH3D lineage保留，衍生render與順序資料去重。

仍需補齊

資產/原生split取得、temporal版本切分、GT多解/粒子對應有效性、KeypointMSE分母確認、真實成品與simulation重現。

P187 · SSFold

SSFold: Learning to Fold Arbitrary Crumpled Cloth Using Graph Dynamics from Human Demonstration

檔案 / 網站 · 方法 / 綜述 · 原作 · 獨立頁面

已找到SSFold的網站原始碼，確認同作者與同篇研究；真正Code仍指向取得404的SSFold-main，不能把網站repo當作graph-dynamics訓練/評測實作。

> **版本與身份**
>
> 網站213f5e9；Code連結zcswdt/SSFold-main於本次回404。網站arXiv按鈕連作者GitHub profile，正式paper URL沿用已核對2411.02608，不採錯連結。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	真實UR5摺布，從皺褶初態開始；網站表示跨顏色/形狀/剛度測試，但未提供可解析scene/物理初態清單。
任務	合併攤平與摺疊、sequential pick/place及partial point-cloud connectivity；原作網站主要報4種folding tasks。示範影片與generalization展示不直接當額外獨立task數。
題數與資料	作者Data連結為Google Drive，網站媒體及圖示已可讀；未取得完整human demonstrations/graph/action schema、split/episode ID與坐標尺度。
評估方式	網站報4種折法的原作成功率，缺公開grader與trial明細時無法重算或判斷分母。graph預測誤差、terminal摺法與real success須分別規格化。

依這個順序讀

1. `README.md` ↗

   GitHub · zcswdt/SSFold · 213f5e9841

   明示SeqSpatialFold Website

   L1–1

2. `index.html` ↗

   GitHub · zcswdt/SSFold · 213f5e9841

   精確題名/作者、資料與失效code入口、4種UR5折法

   L68–84 · L143–178 · L184–222

怎麼接入我們的benchmark

可重用

四種主task與皺褶→成品設計、partial-observation graph概念、作者原始資料入口。

需要轉換

先登入source/task規格，case需cloth/初態/示範/目標折法/動作預算和物理checker；可見connectivity與隱藏真實mesh分隔。

仍需補齊

SSFold-main可取得實作、Drive資料manifest、graph/action/標定格式、成功/攤平及折法判定規則與測試split。

P188 · DRAPER

DRAPER: Towards a Robust Robot Deployment and Reliable Evaluation for Quasi-Static Pick-and-Place Cloth-Shaping Neural Controllers

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

DRAPER的來源分散在SoftGym擴充、Agent-Arena和real-robot介面；兩個倉庫已有改名。需固定三者版本、資料模式與task config，不能把同一布料環境的fork視為獨立benchmark。

> **版本與身份**
>
> softgym-deepcloth解析到halid1020/softgym(8a21966)，agent-arena-v0解析到actoris_harena(4d9c9c9)，硬體庫405d4c2；目前generic框架不等於原論文固定實驗release。

領域	衣物與洗護
環境	共用SoftGym布料整形與realadapt towel場景；realadapt config宣告1000variation，但eval tier只取30、val取3。Franka/UR3e是另一硬體介面層，未執行。
任務	主要布料攤平/整形及跨sim-real適應；domain字串如rainbow-rectangular-fabrics是布料分佈設定，不是生活用途domain。多論文共享initial_states需建立reuse關係。
題數與資料	TrajectoryDataset以observation/action/goal/trajectory_lengths存資料，T+1觀測對T個action並附terminal補0；whole/cross-trajectory模式與goal索引需驗證。實機介面RGB由BGR轉換，v1/v2 depth作單frame min-max並將背景置1，已非metric depth；action為4個[-1,1]pick-place座標另帶orientation。
評估方式	Towel flattening成功需要keypoints全可見且normalized coverage≥0.99，canonical模式另加IoU。記錄coverage/improvement/形狀距離與首次成功步；perform_single可因environment done、agent terminate/success、arena success或max_steps終止，因此done不等於完成。當前towel.step呼叫reward引數數目與定義不同，正式adapter需修正/驗證。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **3** fold pattern definitions · 原文頁 5, 6
- **10** UR3e ablation trials per setting · 原文頁 6

依這個順序讀

1. `README.md` ↗
   GitHub · halid1020/softgym · 8a2196648c

   DRAPER/其他論文共用擴充與初態資料

   L1–7 · L32–46

---

2. `README.md` ↗
   GitHub · halid1020/actoris_harena · 4d9c9c9273

   Agent-Arena與共用SoftGym關係

   L1–19 · L41–45

---

3. `agent_arena/api.py` ↗
   GitHub · halid1020/actoris_harena · 4d9c9c9273

   eval configs與checkpoint、已存在結果跳過

   L80–127

---

4. `agent_arena/arena/softgym/builder.py` ↗
   GitHub · halid1020/actoris_harena · 4d9c9c9273

   domain/task/action/picker設定解析

   L7–62

---

5. `agent_arena/arena/softgym/builders/fabric_domain_builder.py` ↗
   GitHub · halid1020/actoris_harena · 4d9c9c9273

   flattening接線與1000variation中30eval/3val

   L99–112 · L298–318

---

6. `agent_arena/arena/softgym/tasks/rect_fabric/towel_flattening.py` ↗
   GitHub · halid1020/actoris_harena · 4d9c9c9273

   可見性/coverage成功與多種progress metrics

   L18–55 · L93–162

---

7. `agent_arena/utilities/perform_single.py` ↗
   GitHub · halid1020/actoris_harena · 4d9c9c9273

   終止、成功、動作耗時與逐步評估

   L7–126

---

8. `agent_arena/utilities/trajectory_dataset.py` ↗
   GitHub · halid1020/actoris_harena · 4d9c9c9273

   T+1觀測/terminal action補0與不同window模式

   L224–269 · L325–374

---

9. `README.md` ↗
   GitHub · halid1020/robot_control_cloth · 405d4c2ae4

   DRAPER的ROS硬體介面角色

   L1–7

---

10. `interface/agent_arena_interface.py` ↗
    GitHub · halid1020/robot_control_cloth · 405d4c2ae4

    normalized pixel action及real-depth轉換

    L96–125 · L140–186

怎麼接入我們的benchmark

可重用

明確arena配置、eval/val初態索引、source改名關係、T+1 trajectory和real-depth/action轉換。

需要轉換

source分方法/框架/模擬/硬體repo角色；case固定init-state hash、觀測尺度、畫素順序、policy checkpoint與停止條件；保留整形metric各自分母。

仍需補齊

原DRAPER paper-era configuration/checkpoint對照、repo版本相容、reward/trajectory mode介面驗證、初態資產與全部pipeline重現。

P189 · GPT-Fabric

GPT-Fabric: Smoothing and Folding Fabric by Leveraging Pre-Trained Foundation Models

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

GPT-Fabric的folding、smoothing與physical分三庫。Folding比較多種合法expert終態，smoothing衡量覆蓋；這些不能合併成同一成功率。

> **版本與身份**
>
> folding102f4ce、smoothing06d9592、physical e0e6195；README提舊model版本變動只是歷史資訊，本次未呼叫LLM API或執行robot。實機庫本輪只核對README入口，核心核讀限兩個模擬分支。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	SoftGym/PyFlex方形/矩形布料，沿用Foldsformer初態與demonstration sub-goals；相同config與expert reference保持父來源關聯。實機庫另有平臺專用程式。
任務	4種原生folding樣式及smoothing；每個fold可有多個合法終態。smoothing的trails引數是pick-place步數，並非多次獨立episode或題數。
題數與資料	cached配置、expert info-*.pkl、model info.pkl、示範子目標與query訊息構成評測資料；每種reference fold只是同題多解。smoothing輸出message_step.jsonl和[coverage,improvement] CSV，3位小數為輸出格式；GIF跳frame倍速不代表控制時間。
評估方式	fold每次run對8/9/16個expert粒子終態取最小平均距離，再對run和config平均，輸出乘1000為mm；不取最低run當主結果。smoothing分(A−A0)/(Amax−A0)與A/Amax，前者Amax=A0需處理。naive loop傳last_step_info=None，即使回傳history也不能假設每模式有上一動作提示；LLM model/prompt/API失敗處理須固定。

依這個順序讀

1. `README.md` ↗

   GitHub · slurm-lab-usc/GPT-fabric-folding · 102f4cec4f

   論文身分、Foldsformer父初態/子目標、多合法expert結果

   L1–10 · L43–71

2. `slurm_utils.py` ↗
   GitHub · slurm-lab-usc/GPT-fabric-folding · 102f4cec4f

   8/9/16種expert終態的最小粒子誤差

   L71–117

---

3. `eval.py` ↗
   GitHub · slurm-lab-usc/GPT-fabric-folding · 102f4cec4f

   run×config結果與最終mean非best-of-run

   L234–279

---

4. `README.md` ↗
   GitHub · slurm-lab-usc/GPT-Fabric-Smoothing · 06d9592abf

   smoothing入口、trails是動作數、GIF速度

   L1–10 · L39–75

---

5. `softgym/envs/cloth_flatten.py` ↗
   GitHub · slurm-lab-usc/GPT-Fabric-Smoothing · 06d9592abf

   面積/正規化改善/相對最大面積的三種度量

   L180–214

---

6. `RGBD_manipulation.py` ↗
   GitHub · slurm-lab-usc/GPT-Fabric-Smoothing · 06d9592abf

   primitive執行、歷史/輸出、coverage CSV及GIF抽frame

   L1432–1459 · L1658–1687 · L1699–1713

---

7. `README.md` ↗
   GitHub · slurm-lab-usc/gpt-fabric-physical-experiments · e0e6195604

   實機專用入口，非可直接移植到別人的平臺

   L1–6

怎麼接入我們的benchmark

可重用

多合法目標、原生粒子/coverage metrics、VLM訊息與幾何primitive的接線範例。

需要轉換

case固定init/config、合法示範/提示、expert目標集合、動作與query預算；來源渲染/示範去重；物理結果、VLM格式有效性、延遲/查詢次數分開報。

仍需補齊

完整資料取得、歷史模型/提示版本、API失敗分母、coverage零分母、實機成品scorer/平臺標定與重現。

P190 · UniGarmentManip

UniGarmentManip: A Unified Framework for Category-Level Garment Manipulation via Dense Visual Correspondence

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

UniGarmentManip透過衣物dense correspondence把示範動作轉到新衣物。程式提供3類衣物/3種代表任務的研究框架，但資料配對樣本與實際操控episode須分開。

> **版本與身份**
>
> 固定fe15994，CVPR2024原作；本次核讀雙手fold鏈與共用correspondence reader，未聲稱所有支線及實機實驗已重現。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	GarmentGym/PyFlex衣物模擬；3種衣物類別、單/雙臂、flat/messy與多步設定屬不同變化維度，不以笛卡兒積當全部已驗證場景。
任務	主要unfolding/fling、folding、hanging；訓練dense correspondence是支援方法，兩point cloud或20對correspondence不是20個robot任務。
題數與資料	HDF5有points/colors/vertices/visible_vertices/visible_indices、camera_intrisics/camera_extrisics、rgb/depth/faces。reader按mesh與deform層配對，__getitem__交替cross-shape/cross-deform，從visible vertices找20對correspondence。converter將.pkl換成h5漏了點，但reader只找.h5，需核對/修正檔名契約。
評估方式	動作從demo點的normalized feature相似度argmax對映到新point cloud，再投影回world控制；fold checker先等穩定，按final/init coverage比例與肩/袖/角點距離判定，各fold type門檻不同。此為幾何啟發式，不直接驗證層拓撲；GT mesh indices只供訓練/判分不能直接作policy觀測。

依這個順序讀

1. README.md ↗
   GitHub · luhr2003/UniGarmentManip · fe15994326

   原作、3類/3任務及資料/環境/示範模組

   L1–43

---

2. train/dataloader/preprocess/pickle2h5.py ↗
   GitHub · luhr2003/UniGarmentManip · fe15994326

   原始record→HDF5欄位與輸出檔名

   L15–42

---

3. train/dataloader/dataloader.py ↗
   GitHub · luhr2003/UniGarmentManip · fe15994326

   mesh/deformation配對、可見性GT與對應點取樣

   L81–109 · L234–255 · L338–366 · L403–407

---

4. task/fold/double_from_flat.py ↗
   GitHub · luhr2003/UniGarmentManip · fe15994326

   示範/mesh固定、特徵相似點→world pick/place與環境checker

   L101–152 · L198–232

---

5. garmentgym/garmentgym/env/bimanual_fold.py ↗
   GitHub · luhr2003/UniGarmentManip · fe15994326

   具體funnel/simple摺法的area與語義keypoint距離規則

   L608–727

怎麼接入我們的benchmark

可重用

mesh/deformation/visibility配對結構、示範到控制的幾何轉換、已讀兩種fold成功條件。

需要轉換

source按garmentUID與deformationID分層，case儲存示範序列/目標fold/相機/mesh尺度；將point-correspondence訓練example與robot rollout分別計數。

仍需補齊

衣物/示範split、檔名和schema一致性、完整hanging/fling與其他fold checker、坐標單位/動作預算與跨衣物重現。

P191 · ClothesNet

ClothesNet: An Information-Rich 3D Garment Model Repository with Simulated Clothes Environment

實作尚未確認 · 主來源 · 原作 · 獨立頁面

ClothesNet官方頁面可核對3D衣物及標註格式，下載須走作者表單；目前沒有確認其官方GitHub，Google Sites依賴和同名舊研究已排除。

> **版本與身份**
>
> 官方Google Sites頁與2023原作題名/作者相符；google/safevalues是網站依賴，lixiangbao/ClothesNet_PyTorch自述為另一篇2018人體衣著生成實作，皆未當作本篇code。

領域	衣物與洗護
環境	約4400個3D garment models、11衣物類別，作模擬場景的資產來源；garment model不是robot環境或完整評測episode。
任務	衣物感知：分類、boundary segmentation、keypoint detection；robot互動方向：rearranging/folding/hanging/dressing。用途方向與11衣物類別不相乘當已定義task數。
題數與資料	每衣物folder含mesh OBJ/MTL/texture、邊界OBJ/MTL、10個keypoint的PCD與2048個sampled mesh points。官網約4400是原作量，未下載資產，沒有據此生成4400case。官方資料條款限非商業科學研究且禁止轉發/分發。
評估方式	官網說明感知及robot互動基準，但未確認可取的完整evaluator/code；需原作split、keypoint語義對應、成功predicate及物理引數才可接入完整robot評測。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **4,400** garment meshes（約數） · 原文頁 4
- **3,051** ClothesNetM meshes · 原文頁 4
- **496** 3D classification test meshes · 原文頁 6
- **3** clothes-understanding endpoints · 原文頁 6

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

原始衣物UID、類別/邊界/關鍵點等標註結構與可引用的原作下載入口。

需要轉換

以source+garment ID登入asset並關聯environment/task；metadata與我們的規格獨立發布，原始衣物資料包保留官方下載方式與條款，未獲允許前不納入再分發包。

仍需補齊

作者資料取得、確切檔案manifest/單位/標註順序/物理引數、split/evaluator、原始資料再分發授權。

P192 · Phys-Liquid

Phys-Liquid: A Physics-Informed Dataset for Estimating 3D Geometry and Volume of Transparent Deformable Liquids

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

Phys-Liquid提供液體幾何/尺度估計reader及F-score/voxel IoU程式，但README的總量仍是N佔位、完整下載入口TBD；不能把樣本庫視為完整benchmark已取得。

> **版本與身份**
>
> 固定2d4e3c8，AAAI26 source/sample repo；split_data.py只是指定結果資料夾複製工具，沒有據此宣稱已取得完整train/test。

領域	實驗室操作
環境	模擬實驗室透明液體/容器，顏色、照明、場景與旋轉設定；六張生成/重建視角屬同一樣本的觀測，不增加六個環境。
任務	透明液體segmentation、多視角mask、3D reconstruction及metric scale/volume估計；屬於感知/量測任務，不直接驗證robot倒水或吸液完成。
題數與資料	sample/frame目錄有multiview_images.png、volumes.json、real_volume.json；拼圖切成6×256²。pseudo volume乘1e-6、width乘1e-2；label_mode可為體積比、三軸比、算術/幾何平均，需記模式與單位。缺檔/GT會跳過，README沒有可用總量數字。
評估方式	F-score先各自質心對齊，隨機採10000surface points，以距離門檻(預設0.02)算precision/recall；不測絕對位置誤差。frame缺pred/GT/載入錯誤被略過，再sample內均值→sample間均值。voxel IoU以各網格grid_index相交，shared origin/voxel尺度需驗證；這些都不是task成功率。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **5** lab scenes · 原文頁 3, 4
- **100** simulation configuration sequences · 原文頁 3, 4
- **10** held-out sequences · 原文頁 4
- **97,200** RGB與mask image files合計 · 原文頁 3, 4

依這個順序讀

1. `README.md` ↗
   GitHub · dualtransparency/Phys-Liquid-AAAI · 2d4e3c8770

   原作、四階段重建與sample/full release狀態

   L1–36

---

2. `volume_estimate/dataset.py` ↗
   GitHub · dualtransparency/Phys-Liquid-AAAI · 2d4e3c8770

   sample/frame結構、6視角拼圖、體積/尺度ratio標籤

   L9–108 · L113–140

---

3. `metrics/F-Score.py` ↗
   GitHub · dualtransparency/Phys-Liquid-AAAI · 2d4e3c8770

   質心對齊、點取樣、距離門檻與跳過/聚合分母

   L10–94 · L112–189

---

4. `metrics/volume_iou.py` ↗
   GitHub · dualtransparency/Phys-Liquid-AAAI · 2d4e3c8770

   mesh體素化與grid-index IoU

   L20–50

---

5. `split_data.py` ↗
   GitHub · dualtransparency/Phys-Liquid-AAAI · 2d4e3c8770

   手列13個結果目錄複製，非完整split生成協定

   L1–60

怎麼接入我們的benchmark

可重用

具體label生成、前處理與原生幾何metrics，可作universal benchmark的量測能力來源。

需要轉換

case_id連到物理sample/frame與view；儲存原始/重建mesh、座標/單位/scale mode，GT只給scorer；報attempted/valid/skipped與metric seed，避免有效子集分母混淆。

仍需補齊

完整公開資料/精確數量、正式split manifest、物理單位、voxel共同grid、sample間相依性與task級液體操作驗收。

P193 · GRIP

GRIP: A General Robotic Incremental Potential Contact Simulation Dataset for Unified Deformable-Rigid Coupled Grasping

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

GRIP有柔性/剛性抓取HDF5結構和Finray視覺化程式；整體10萬姿態與8子集是不同於目前公開Finray範圍的宣告。完整生成/評分pipeline尚未發布。

> **版本與身份**
>
> 固定56a4520；README計畫僅勾Finray，其他子集/生成pipeline未勾，雖寫完整dataset連結仍需依實際發布manifest核對。未把100frames或renderer輸出當獨立case。

領域	通用物件與機動作業
環境	IPC柔性–剛性耦合抓取，手型與material分子集；overview記1200objects/100000poses。finray_soft_837與finray_rigid_710可能共用object ID，不直接相加當獨立物件或環境。
任務	抓取及stress-field等下游學習來源；每個pose/手型/材質形成具體抓取設定。雙手/單手子集與物件變體不直接增加語義task。
題數與資料	HDF5分object_config(密度、Young模數、Poisson比、摩擦)和trajectories(關節/SE3/mesh/contact)。Finray檔案稱每H5有20個成功trajectory、每條100frame，前40抓取、後60作重力驗證；是已篩成功的資料，不可從此推未篩候選的成功率。未下載大archive。
評估方式	本庫沒有完整生成/失敗判定程式，不能重現10萬候選的過濾率。visualizer有soft分支rajectories/object_points拼字，object_type在README稱類別但程式用rigid判material；contacts檔案語義與viewer向量相加用法仍需核定。record_fps24只決定輸出影片，不是simulation timebase。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **1,200** unique selected objects，800+800–400 · 原文頁 1, 4
- **100,000** grasp poses（概要數） · 原文頁 1
- **4** stressprediction held-out objects · 原文頁 6

依這個順序讀

1. README.md ↗
   GitHub · BeLl0o/GRIP_Dataset · 56a4520167

   原作、公開計畫、object/hand/material階層與成功過濾軌跡

   L1–35 · L61–100 · L107–188

---

2. scripts/finray_h5_visualizer.py ↗
   GitHub · BeLl0o/GRIP_Dataset · 56a4520167

   真實HDF5路徑、pose/time索引、剛/柔分支與渲染clock

   L143–227

怎麼接入我們的benchmark

可重用

object/material引數、pose/time結構、mesh及contact紀錄，作柔性物task/資產來源。

需要轉換

用objectUID+hand/material+poseID形成instance，frame作其軌跡；記successful-only選擇條件、未篩樣本來源和力/位置/時間單位；修正或版本化reader而不更改原始bytes。

仍需補齊

完整/已公開子集manifest、生成/驗收器、失敗資料、HDF5型別/單位實測、viewer路徑和object_type對應。

P194 · Cloth gripper interface

A Simple Gripper Interface for Simulator-Agnostic Cloth Manipulation

實作尚未確認 · 方法 / 綜述 · 原作 · 獨立頁面

這篇提供模擬器無關的cloth gripper概念介面，適合參考action contract；原文未提供可確認的GitHub，不能當成已取得的跨模擬器adapter。

> **版本與身份**
>
> 已讀2609.29340v2 p3–4；原文Drive連結為示例素材，cached精確gripper-interface搜尋未確認GitHub。只登入方法/介面參考，沒有假造code路徑。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	原文在constraint-based不可伸長四邊形cloth mesh模擬；說明如何接position/force/constraint三類solver，並非已驗證所有backend等價。
任務	兩種grasping volume：box pinch與square-pyramid point grasp；屬抓持模型選項，沒有因此新增兩種完整摺布task或case庫。
題數與資料	指令由gripper位置/四元數/jaw state組成；在open→closed時用local-volume內的節點、面中心和邊中心挑grasp support，儲存local座標直到open清除；squeeze按數個simulation steps插值。尚無可取原生程式、trajectory schema或split。
評估方式	原文比較抓持策略/可控性與計算成本；抓持用移動位置約束，沒有計算夾爪壓力、摩擦或完整區域性變形。此模型的穩定抓持不等於真實摩擦/滑脫測試通過。

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

清楚的pose/jaw/grasp-region契約與solver適配概念。

需要轉換

environment必存grasp_model、mesh解析度、抓持集合與squeeze時間；action記local/world pose及jaw edge；不同backend分別驗證，不將相同函式名稱當物理等價。

仍需補齊

作者實作、solver介面、原生評測資料與可重現案例；壓力/摩擦/滑脫/恢復能力另需支援的物理模型。

P195 · World models for unfolding

Learning to unfold cloth: Scaling up world models to deformable object manipulation

檔案 / 網站 · 方法 / 綜述 · 原作 · 獨立頁面

已找到與論文題名、三位作者相符的專案網站repo；其方法/結果區仍是模板文字，未包含Unity/Obi/DreamerV2實作。

> **版本與身份**
>
> 網站a7b0550為2024版本，論文2602.16675於2026收錄；題名/作者相符但網站不能證明2026實驗程式已公開。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	論文Unity/RFUniverse Gym介面與ObiCloth，固定一個cloth corner、Franka在空中展開；與桌面flattening有不同物理設定和目標。
任務	主目標為in-air unfolding，5種garment types×4種agent設定=20個trained agents，不能稱20種新任務。
題數與資料	原文每step兩張64×64×3影像，加EEF xyz/gripper width/張力boolean；action為4維[-1,1]位移與jaw控制。RGB/normal image及replay-buffer版本分開；每agent1M訓練step不是1M評測case，完整資料/episodes未取得。
評估方式	原文用4×4網格估計unfold面積proxy、除最大值並加時間penalty；失敗/近成功/成功按episode內最高unfold量分類，與末態/持續成功不同。沒有scorer程式就無法核驗門檻與投影/面積實作。

依這個順序讀

1. `README.md` ↗

   GitHub · jrome5/Learning-to-unfold-cloth.github.io · a7b0550ec3

   網站repo題名

   L1–2

2. `docs/index.html` ↗

   GitHub · jrome5/Learning-to-unfold-cloth.github.io · a7b0550ec3

   作者/abstract相符，主要內容仍為placeholder

   L7–30 · L33–68

怎麼接入我們的benchmark

可重用

原文action/observation介面、固定角約束、5garment×4agent對照與最高進度評估。

需要轉換

case固定pinned corner/cloth parameters、輸入RGB或normals、張力資訊來源與budget；儲存maximum progress和final state分項，標明privileged observation。

仍需補齊

真正方法repo、Unity/Obi資產/介面、demo/replay與split、成功界線/scorer、原生重現與跨backend可比性。

P196 · Deform360

Deform360: A Massive Multi-view Visuotactile Dataset for Deformable World Models

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

Deform360有明確多視角/觸覺對齊與annotation contract，可直接作資料層參考；README明示world-model訓練、baseline和checkpoint未公開。

> **版本與身份**
>
> 固定d8522a4；所讀公開庫定位access/preprocessing/annotation/alignment，未把能生成annotation推論為已發布world-model baseline。

領域	衣物與洗護
環境	BRICS capture dome真實柔性物互動；原作198物件/13類、1980互動，41同步RGB相機及4組16×32觸覺sensor。13物件類別不是13生活domain，41views不是41episodes。
任務	柔性物世界模型/多視觸覺研究資料；dataset utility提供對齊和annotations，不等同機器人物理任務registry或已釋出的world-model benchmark runner。
題數與資料	原作215.7h、約23.3Mframes須保留其跨視角統計口徑。episode/<camera>/undistorted.mp4與K/c2w、aligned timestamps、provenance hash；預設檢查相機frame/timeline一致。H5鍵data：mask bool/uint8二值、depth uint16毫米且0無效、velocity m/s；不可像RGB除255。
評估方式	這些檢查驗證資料形狀/時間/校準一致性，不是world-model或robot成功分數。觸覺nearest配對保留match/accepted/duplicate資訊，未接受格補0須連valid mask使用；用於預測task時另外限制query以前的可見資料。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **198** deformable objects · 原文頁 5, 6
- **1,980** physical interaction episodes · 原文頁 6
- **74,850** 同步/品質filter後view videos · 原文頁 6
- **215.7** 累加多視角video hours · 單視角行為20,483秒約5.69h，非215.7h獨立行為 · 原文頁 6

依這個順序讀

1. `README.md` ↗
   GitHub · lhy0807/deform360 · d8522a4403

   198objects/1980interactions/41camera與release scope

   L1–85

---

2. `deform360/dataset.py` ↗
   GitHub · lhy0807/deform360 · d8522a4403

   相機K/c2w校驗、frame數/輸出provenance與timestamp_us

   L130–269 · L421–478

---

3. `deform360/tactile.py` ↗
   GitHub · lhy0807/deform360 · d8522a4403

   nearest時間對齊、accepted mask與共同camera timeline

   L304–353 · L408–449

---

4. `deform360/annotations.py` ↗
   GitHub · lhy0807/deform360 · d8522a4403

   HDF5 data陣列、mask/depth/velocity單位與encode/decode

   L1–83 · L175–206

怎麼接入我們的benchmark

可重用

明確影像/姿態/深度/速度/觸覺契約、common timeline與output hash校驗，可復用到標準化來源層。

需要轉換

source/episode是主lineage，camera/frame/sensor作子記錄；儲存微秒時間、c2w方向、單位、invalid值與alignment政策，case另繫結真正預測目標和scorer。

仍需補齊

完整資料/annotations取得、interaction/物件split、world-model評測協定/程式與checkpoint、從感知資料建立物理可執行task的驗證。

P197 · EgoSim / MultiEgoView

EgoSim: An Egocentric Multi-view Simulator and Real Dataset for Body-worn Cameras during Motion and Activity

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoSim提供真正的身體穿戴相機模擬擴充，核心在SIPCharacter C++，不是AirSim通用的image benchmarker。它產生多相機/IMU/骨架資料，並非robot任務成功評測器。

> **版本與身份**
>
> 固定e48780e；NeurIPS2024作品於2502.18373存檔。只核讀實際EgoSim擴充，未把整個AirSim所有功能當成本文評測範圍。

領域	穿戴互動與動作介面
環境	Unreal Engine/AirSim的SIPCharacter avatar，可接FBX/SMPL系列動畫與多socket身體攝影機；6camera sockets是同avatar的感測位置，非6個獨立場景。MultiEgoView實拍資料另有下載來源。
任務	身體相機視角、運動/活動資料生成及下游感知研究。avatar動畫和camera placement本身不構成已帶robot goal/scorer的操作task。
題數與資料	record有VehicleName、相對建立時間TimeStampMs、TimeStampAnimationS、6組相機position/quaternion(xyzw)、IMU acc/velocity及bone世界pose。settings採NED轉換，record直接寫Unreal Actor/Bone位置；位置/加速度單位需驗證，不能看到註解convert to meters就假定已換算。
評估方式	本次未確認完整語義下游benchmark scorer，capture FPS不是活動理解成功率。tick依clock_speed和record_interval取樣；camera2角速度噪聲用dist_vel1，camera3所讀角速度噪聲被註解，與六份std設定未完全對稱，需逐sensor記實際生成條件。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **4** virtual scenes · 原文頁 5
- **24** locations within scenes · 原文頁 5
- **35** real human activity types · 原文頁 6

- **119.4** synthetic motion hours（6views） · 原文頁 5

依這個順序讀

1. `README.md` ↗
   GitHub · eth-siplab/EgoSim · e48780e6c8

   原作、MultiEgoView、最多6socket與IMU/相機設定

   L1–85

---

2. `Unreal/Plugins/AirSim/Source/Vehicles/SIPCharacter/SimModeSIPCharacter.cpp` ↗
   GitHub · eth-siplab/EgoSim · e48780e6c8

   settings NED→Unreal spawn變換與avatar建立

   L117–154

---

3. `Unreal/Plugins/AirSim/Source/Vehicles/SIPCharacter/SIPCharacterPawn.cpp` ↗
   GitHub · eth-siplab/EgoSim · e48780e6c8

   camera lag、IMU噪聲配置與實際tick推導

   L148–162 · L185–205 · L427–492 · L503–520 · L533–550

---

4. `Unreal/Plugins/AirSim/Source/Vehicles/SIPCharacter/SIPCharacterPawnSimApi.cpp` ↗
   GitHub · eth-siplab/EgoSim · e48780e6c8

   record欄位、雙時計、6相機/IMU及所有bone world pose

   L18–105

怎麼接入我們的benchmark

可重用

SIPCharacter生成器、sensor mount/lag設定、完整record欄位與雙時計。

需要轉換

environment儲存UE場景/avatar/animation/外掛版本；case儲存socket視角、noise與時序/座標轉換，body poses作label時不得作隱式policy輸入；觀測生成與下游任務/判分分層。

仍需補齊

MultiEgoView原生reader與split、UE資產/animation權利及取得、坐標/時間/IMU統計實測、下游task/scorer與部署驗證。

P198 · TACO

TACO: Benchmarking Generalizable Bimanual Tool-ACtion-Object Understanding

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

TACO的公開庫主要是人體手–工具–物件資料載入和投影工具。pre-release與V1的序列、triplet和視角數不同，必須分版計數。

> **版本與身份**
>
> 固定b385ac1；CVPR2024原作2401.08399，README後續更新到V1與額外工具。未將視覺化成功當作理解或機器人操作成功。 已補核TLabel be7121d0的檔案、schema與quality入口，限後加工具角色；未執行adapter / export或宣稱TACO數量因此增加。

領域	餐飲與烹飪、居家整理與清潔、穿戴互動與動作介面
環境	真實雙手工具操作，多視角RGB與ego RGB-D。pre-release為8個allocentric views，V1為12個，且共用206object models；不同view或release不當成獨立物理場景。
任務	〈tool,action,object〉triplet理解與generalization：pre-release244sequences/137triplets，V1 2317sequences/151triplets。triplet是原生語義組合，sequence是觀測樣本，不自行當151種可執行robot目標。
題數與資料	按triplet/sequence組織RGB-D、Hand_Poses、Object_Poses及Camera_Parameters；MANO48Dpose+10Dshape+translation，輸出778vertices/21joints。hand模型結果除1000、object_cm.obj乘0.01後進同m座標；camera extrinsics明示world_to_camera。缺shape helper會補0beta，需標missing/default。 額外工具TLabel的固定README / schema已補讀：它另有schema_version、sensor_info、capabilities、episodes，以及14個觸覺語義欄位；這不表示原TACO已有這些觸覺訊號。TLabel的L1–L4描述資訊完整程度，非本benchmark的任務難度。
評估方式	所讀是loader與視覺化，不是完整原作benchmark grader；frame數與pose數不符會跳過。需要原作task split/metric才可做辨識/軌跡/互動評測。後加TLabel workflow只是工具支援，不能據此把原作RGB-D清單宣稱新增實測觸覺模態。 TLabel的QualityScorer以一致性30%、平滑25%、完整性25%、覆蓋20%合成資料品質分數；不是對GT量測準確率、機器人成功率或校準後的難度。data_quality另可使用者自述；schema預設confidence=1.0也不能當已驗證的可信度。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **3** benchmark endpoints · 原文頁 6, 7, 8
- **131** tool-category/action/target-category triplets · 原文頁 5
- **15** action labels · 原文頁 4
- **2,500** motion sequences · 約2.5K · 原文頁 4

依這個順序讀

1. `README.md` ↗
   GitHub · leolyliu/TACO-Instructions · b385ac1e89

   原作、244/2317版本差異及後加annotation工具

   L1–85 · L198–223

---

2. `dataset_utils/hand_pose_loader.py` ↗
   GitHub · leolyliu/TACO-Instructions · b385ac1e89

   MANO shape/pose/translation與mm→m

   L10–76

---

3. `dataset_utils/video_utils.py` ↗
   GitHub · leolyliu/TACO-Instructions · b385ac1e89

   影片順序、BGR/RGB與frame cap

   L16–49

---

4. `dataset_utils/project_pose_to_egocentric_view.py` ↗
   GitHub · leolyliu/TACO-Instructions · b385ac1e89

   cm物件mesh→m、世界pose、逐frame world-to-camera與資料完整性

   L20–120

---

5. `README.md` ↗
   GitHub · liesliy/tlabel · be7121d011

   確認是後加的跨感測觸覺annotation工具，不是原TACO資料。

   L1–99

---

6. `docs/tlabel-format.md` ↗

   GitHub · liesliy/tlabel · be7121d011

   核對schema版本、capabilities、sensor_info與episode引用，保留物理單位。

   L1–112

---

7. `tlabel/core/schema.py` ↗

   GitHub · liesliy/tlabel · be7121d011

   確認14個語義欄位、預設confidence及使用者自述data_quality。

   L21–102

---

8. `tlabel/quality/scorer.py` ↗

   GitHub · liesliy/tlabel · be7121d011

   區分資料完整性 / 平滑 / 一致性加權分數與robot任務成功。

   L39–89

怎麼接入我們的benchmark

可重用

版本化triplet/sequence ID、MANO/物件pose/camera校準、單位明確的投影流程。

需要轉換

source保留pre-release→V1 relation；case以triplet+sequence+時間/視角定位；camera/object/hand座標及units統一但保留原始值，缺frame/shape單列invalid/default狀態。

仍需補齊

完整data/asset與官方split、原benchmark scorer與基線、object/contact物理化以轉robot任務、default shape與時間同步驗證。

P199 · OpenEgo

OpenEgo: A Large-Scale Multimodal Egocentric Dataset for Dexterous Manipulation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

已確認OpenEgo官方對應repo，提供六來源的統一資料API與LeRobot轉檔。其290 tasks是原作來源表加總，與本庫跨來源去重任務聯集不同。

> **版本與身份**
>
> 固定51f704a，README明確連2509.05513及原作網站；有MIT code不代表六份底層資料享有同一授權。未下載完整1107h或執行轉檔。

領域	居家整理與清潔、穿戴互動與動作介面
環境	彙整CaptainCook4D、HOI4D、HoloAssist、EgoDex、HOT3D、HO-Cap；原作1107h/119.6Mframes/344.5krecordings/600+environments沿用父來源，並非重新拍攝的獨立環境池。
任務	意圖對齊action primitives與dexterous hand trajectory學習。原表24+16+20+194+33+3=290個原生task labels；各父來源粒度可能不同，須保留來源再歸併。
題數與資料	API按mp4列demo，讀joints.hdf5、annotation.json、metadata.hdf5；Action.start/end是秒，round(timestamp×fps)並採end-exclusive slice。EgoDex joint slice與annotation getter仍NotImplemented；按parent目錄建name索引會讓同目錄多影片互相覆寫查詢。EgoDex直接取transform平移，需核驗與camera-frame宣告的對齊。
評估方式	此repo主要是資料API/轉檔，不含可核驗的手軌跡baseline evaluator。LeRobot action實際存下一frame雙手21×3×2=126D座標，末frame重複，非robot actuator command。缺visibility會補全1、缺annotation會空列表、不同FPS僅warning並截各模態最短長度，正式case不得預設這些都有效。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **290** 六來源task labels合計 · 原文頁 3
- **1,107** 來源video hours合計 · 原文頁 3
- **344,500** source recordings · 344.5K約數 · 原文頁 3

依這個順序讀

1. `README.md` ↗
   GitHub · ahadjawaid/openego · 51f704ae36

   精確原作ID、六父來源、原生加總與API宣告

   L1–95

---

2. `openego/data/openego.py` ↗
   GitHub · ahadjawaid/openego · 51f704ae36

   實際影片索引、source辨識、EgoDex特殊載入與未實作分支

   L1–137

---

3. `openego/data/annotations.py` ↗
   GitHub · ahadjawaid/openego · 51f704ae36

   action timestamps/actors/objects、frame界線及visibility

   L9–105

---

4. `port_openego_to_lerobot.py` ↗
   GitHub · ahadjawaid/openego · 51f704ae36

   126D人手狀態/next-frame target、終態與不同FPS/缺標註處理

   L32–77 · L84–122 · L173–226

怎麼接入我們的benchmark

可重用

原source ID、Action時間/物件/actor、統一reader與顯式next-pose轉檔schema。

需要轉換

用父source+完整video相對路徑+segment界線建ID；保留measured/estimated/converted pose與座標單位、visibility unknown、原FPS；126D next-pose prediction與robot執行action分開profile。

仍需補齊

EgoDex未實作分支、六來源坐標/units/hand-order轉換驗證、case級去重與split、parent資料權利、真正預測scorer和robot retarget驗證。

P200 · SABER

SABER: A Scalable Action-Based Embodied Dataset for Real-World VLA Adaptation

實作尚未確認 · 主來源 · 原作 · 獨立頁面

SABER的公司research頁確認論文及HF資料入口，但本次公開取得HF card回401，沒有找到GitHub。可先整理retail用途及三種action representation，不能宣稱素材或scorer已取得。

> **版本與身份**
>
> 2026-10-11原專案路徑轉向DreamVu首頁；research頁仍列精確2605.09613與DreamVu/SABER-10K，但公開HF raw請求401。401只表示本次未取得，未推定資源不存在或嘗試繞過存取限制。

領域	包裝、倉儲與物流、零售與購物
環境	多個真實grocery store；頭戴GoPro配固定ALIA360°六個同步視角，拍攝時沒有robot。相機數/視角數不能當商店或環境數。
任務	零售補貨、取放商品、貨架不同高度、籃車/冷藏櫃與走道活動；原文主張domain-specific VLA adaptation，尚無已取得的固定任務/評測case清單。
題數與資料	原文約100小時雙流拍攝；Stream1為25K約10秒ego episodes的LAPA latent tokens，Stream2為18.6K ego episodes的人類21點hand pose/修正後retarget，Stream3由exo SMPL轉UnitreeG1。三stream來自相同拍攝，不相加當獨立物理episodes；手動修正的human pose與retarget不是原生robot控制紀錄。
評估方式	原文包含VLA適配實驗及人工annotation QC；尚無取得的評估code/episode verdict，不能重現其提升倍數，也不能把人工QC比例當任務成功率。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **44,800** 三supervision streams samples · 約數；不是unique physical episodes · 原文頁 10
- **10** RoboBenchMart downstream tasks · 原文頁 13
- **100** 每task evaluation rollouts · 原文頁 13

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

retail用途與雙流感測、latent/hand/body三層action來源分工。

需要轉換

source記拍攝session及三stream lineage；case分清human估計/人工修正/retarget/robot命令，儲存相機同步與合法輸入；SABER-10K名稱不代替實際case manifest。

仍需補齊

可用資料/card與code入口、stream schema/單位、店面/session/split ID、retarget校準與VLA評估協定/基線。

P201 · EgoSAT

EgoSAT: A Comprehensive Benchmark of Egocentric Streaming Interaction Understanding

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoSAT已有streaming runner、query helper與正式main-table scorer；標準化時必須保留完整native JSON和effective queryset，單純壓成答案JSONL會丟掉判分資訊。

> **版本與身份**
>
> 固定7f65bbb；原作2606.24422。examples/evaluation_fixtures是合成格式例，不記為本庫新增真實評測題或原作模型跑分。本輪未執行模型/API/scorer。

領域	居家整理與清潔
環境	Ego4D的1997段第一人稱影片、約165h/56場景型別；場景型別不是已取得的56個simulator環境。原始Ego4D影片不在此repo重新分發。
任務	回顧、當下、預測三模式，約4800QA；另有answerability/branchiness/surprise與state-switch probes。group、step、兩probe配對及QA數分開，不從56×3推算task/case量。
題數與資料	原生GT含video_uid、video_metadata.interval_start/end、samples；helper產effective queryset保留idx/t_eval/t_eval_rel/window/horizon/options/memory。runner只裁整個interval，真正每query可見prefix需由adapter依window執行；共通格式須儲存原JSON、token probabilities、queryset references與model flavor。
評估方式	MCQ對有效queryset中有GT的題計full denominator，缺/無效回答為錯；缺GT略過。scorer先掃現有prediction檔案，所以整份缺失的GT仍需外部expected-case manifest檢查。confidence是有效cand_conf值均值，不能當accuracy或完整校準分數。state-switch需前後兩probe均對，主值用valid pairs，另有total/missing/invalid計數及僅成功pair的after-confidence。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **56** Ego4D scenario labels · 原文頁 9
- **1,997** video sessions · 原文頁 9, 10
- **4,800** QA pairs · 約數 · 原文頁 10
- **6** QA task types · 原文頁 11

依這個順序讀

1. `README.md` ↗
   GitHub · leiyj23/EgoSAT · 7f65bbb201

   原作、Ego4D父來源、1997影片/約4800QA與三種時間推理

   L1–85

---

2. `evaluation/README.md` ↗
   GitHub · leiyj23/EgoSAT · 7f65bbb201

   正式輸入、不同prediction flavor與各metric分母

   L1–124

---

3. `benchmark_val/runner.py` ↗
   GitHub · leiyj23/EgoSAT · 7f65bbb201

   interval影片裁切、空GT紀錄與source/query身份

   L196–225 · L520–599

---

4. `benchmark_val/helper.py` ↗
   GitHub · leiyj23/EgoSAT · 7f65bbb201

   retrospective/prospective query時間與合法window

   L1992–2018 · L2385–2410

---

5. `docs/model_guide.md` ↗
   GitHub · leiyj23/EgoSAT · 7f65bbb201

   model adapter契約、time_offset/相對時間與因果取frame模板

   L58–82 · L143–211

---

6. `evaluation/metrics.py` ↗
   GitHub · leiyj23/EgoSAT · 7f65bbb201

   零分母None與基本度量

   L1–61

---

7. `evaluation/evaluate_main_table.py` ↗

   GitHub · leiyj23/EgoSAT · 7f65bbb201

   完整queryset MCQ、valid-only confidence與state-switch成對分母

   `L351–388 · L463–597 · L600–722`

怎麼接入我們的benchmark

可重用

真正runner/helper/scorer、合法時間視窗、prediction flavor與透明分子/分母。

需要轉換

case儲存source/video/interval/query idx與精確clock、options順序和pair ID；central input loader限定可見frame，GT獨立；score保留total/valid/missing和conditional confidence，不丟native payload。

仍需補齊

完整Ego4D/QA資產與release split、每model相同expected queryset、adapter實際prefix稽核、全檔案缺失計分及confidence欄位可用性驗證。

P202 · EgoMonth

EgoMonth: A Month-Level Egocentric Video Benchmark for Long-Term Spatiotemporal Memory

檔案 / 網站 · 主來源 · 原作 · 獨立頁面

susu801/EgoMonth 的 README 與網站對應同名論文的 301 小時 / 738 clips / 1,443 QA / 14 題型，但 pinned 完整 tree 只有靜態頁面與圖片。檔案聲稱存在的 scripts/ 與評測程式均不在此 commit；尚不能視為已公開可執行 benchmark。

> **版本與身份**
>
> 程式來源固定 81143141d98b4511ff1adcae9a5ccf3a9f0f9606（2026-09-22），PDF 為 2608.13113v1。非截斷 tree 的 15 個 entries 中沒有 scripts/、.py 或資料 JSON；README/index.html 的存在宣告與此版本實物不一致。未嘗試用別人的同名倉庫填補。
>
> 核對 arXiv:2608.13113v1 首頁題名、作者及正文。候選倉庫完整題名、統計與題型一致，足以確認內容所指論文；但 pinned PDF 未連到該倉庫，README/index.html 僅署名 EgoMonth Team，未提供作者名單或 arXiv 反向連結，因此 susu801 的作者官方身分仍未獨立證實。

領域	居家整理與清潔、餐飲與烹飪、辦公與教育、零售與購物、交通移動與車輛維修、休閒與運動
環境	人類日常第一人稱錄影，20 名參與者各跨 20–120 天、室內外與不同裝置；論文有學習工作、交通、飲食、購物、休閒、家務六種活動分類，沒有可執行 scene registry 或實體場所去重總數。
任務	保留 Table 1 的 14 QA 型別：Habit Inference、Personality Inference；Detail Retrieval、Spatial Relation、Self-localization、Temporal Ordering、Event Time、Object Location；Procedure Planning、Event Counting、Object Counting、Route Reasoning、Cross-view Spatial Reasoning、Direction Judgement。三組分別是 Schema Consolidation、Episodic Indexing、Cascading Reasoning；它們是影片記憶 / 推理題型，非機器人動作任務。
題數與資料	已讀到的 schema 僅是 README 檔案示例：JSON list，每筆 video_path 為一至多個相對影片路徑，question、四個 options、correct_options 字母與 task_type；檔案稱以 CONFIG["video_root"] 接路徑，但沒有可核對的 loader。論文報 738 clips、18,072 分鐘與 1,443 人工四選一題；這些是論文統計，未取得 QA manifest，不能宣稱已清點實際 release。跨日參與者 / session ID、時間戳格式、每類實際題數與 split 檔均未見。

評估方式	論文 §4.1 與 README 定義 micro Acc = 全部答對題數 / 全部題數（完整論文集合 N=1,443），macro Avg = 14 個題型各自 accuracy 的等權平均；直接比對正解，無 LLM judge。各模型觀測預算不同，例如 16 / 64 / 256 / 512 frames 或 1 fps，需保留。固定 tree 未含 README 所稱的 Qwen 等指令碼，因此無法核對答案字母 parser、多影片拼接 / 抽幀、錯誤 / 空回答如何入分母，也沒有可追的 concrete scorer。

▼ **原作數字：保留論文的單位與頁碼**

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **14** memory QA types · 原文頁 5
- **6** 作者activity categories · 原文頁 6
- **1,443** human-authored MCQs · 原文頁 6, 7
- **738** video clips · 原文頁 6

依這個順序讀

1. `README.md` ↗

   GitHub · susu801/EgoMonth · 81143141d9

   確認論文對應、檔案宣告的資料鍵、macro/micro 及缺失 scripts 宣告。

   L1–9 · L35–99

2. `index.html` ↗

   GitHub · susu801/EgoMonth · 81143141d9

   核對網站題型、Code 按鈕與所列評測命令；Code 僅回到同一倉庫。

   L27–73 · L86–112 · L181–218

怎麼接入我們的benchmark

可重用

可重用有來源的 14 題型、三認知層級、論文統計、檔案示例 schema，以及 macro / micro 的分開定義；倉庫先列檔案來源。

需要轉換

source 保留 paper v1 與候選 repo commit / 身分狀態；environment 用參與者與生活錄影脈絡；task 保留原生 task_type。release 到位後，case 以原始 QA ID 關聯有序 video_path[]、question/options/correct_options，另儲存 participant/day/session、媒體時間及觀測預算；單片與跨片同屬一題，不能按片重複計數。evaluator 分列 micro 與每類及 macro 分母。

仍需補齊

作者官方連結、QA / split / 影片 manifest、可讀 loader、實際答案解析與 scorer、跨日時間對齊、抽幀及例外處理。現階段不能產生已驗證可執行 case 清單。

P203 · EGOSTREAM

EGOSTREAM: A Diagnostic Benchmark for Streaming Episodic Memory in Egocentric Vision

檔案 / 網站 · 主來源 · 原作 · 獨立頁面

已確認 saroo25/Egostream 是論文官方網站的靜態原始碼。首頁明示 data 尚未公開且 GitHub coming soon；唯一 Python 檔 server.py 只是 HTTP 靜態伺服器，沒有資料 reader、memory manager 或評測 scorer。

> **版本與身份**
>
> pinned paper 是 2605.31557v2（2026-06-01）；website repo main 固定 8cb0dab06659a56a7de75b88770f31eecec17944。完整非截斷 tree 已核，public release 狀態與論文「匿名倉庫已分享」敘述不一致。這是 website-only / release 未找到，不是 GitHub 404 或 rate-limit deferred。
>
> arXiv:2605.31557v2 首頁連到 saroo25.github.io/Egostream；網站題名、Rosario Forte / Giuseppe Lando / Antonino Furnari 與 Catania 單位一致，並反連同一 arXiv。網站 cache 與 pinned index.html SHA256 相同，可確認此 repo 的網站角色。論文 p.3 所稱匿名 GitHub release，未在 pinned PDF 連結或公開網站找到可解析的 release 位址。

領域	居家整理與清潔
環境	重用 Ego4D Episodic Memory VQA、EgoLife、EgoTempo、Multi-Hop EgoQA 與 HD-EPIC 的人類第一人稱影片；沒有新增可執行機器人環境。父來源、影片、參與者與重寫 QA 關係必須保留。
任務	7 個 primary memory dimensions：detail、spatial、temporal、event、social、causal、prospective；每題另可有 secondary tags。7 個 recall regimes 是同題的時間條件：0 秒、0–5 秒、5–30 秒、30–180 秒、180–1,800 秒、1,800–28,800 秒、超過 28,800 秒，不應計成額外語義 task。
題數與資料	論文流程 2,634 candidates → 2,335 人工核對 → 2,250 final base questions，再依 AVW 展成 8,528 question–recall evaluations。每題概念上關聯來源影片、四選一題 / 正解、evidence moment、primary / secondary labels、AVW 與 recall timestamp；目前沒有公開 annotation 檔可驗證這些概念的實際 JSON keys、時間原點、split 或 loader。Appendix A.6 以秒為 delay 單位，Instant=0，其餘依 regime 擷取高斯分佈取樣，只接受落在該題 AVW 的時間，ultra-long 用 TTL；不是每題固定乘 7。

評估方式	論文 §3.4 定義四選一 accuracy = 正確推論數 / 適用 question–recall 推論數，完整實驗分母 8,528；語義類別與 recall regime 用各自子集分母，不能用 2,250 代替。串流只准使用 recall time 前畫面，建記憶時不可先知 query，亦不可無限儲存原影格再重讀；需記 memory budget 與平均每 frame 處理時間。Appendix A.7 描述 ingestion / QA 分離並要求回覆選項 index；實際 parser、skip / error 計數、記憶限制與 timing scorer 未公開，論文協定不可記成程式已核。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **7** primary memory dimensions · 原文頁 4, 5
- **2,250** base validated questions · 原文頁 5
- **8,528** question × applicable recall evaluations · 原文頁 6

依這個順序讀

1. `README.md` ↗

   GitHub · saroo25/Egostream · 8cb0dab066

   確認倉庫自述為靜態 landing page。

   L1–3

2. `index.html` ↗

   GitHub · saroo25/Egostream · 8cb0dab066

   核對作者、paper link、未公開公告、AVW 與串流協定。

   L34–111 · L113–211

3. `server.py` ↗

   GitHub · saroo25/Egostream · 8cb0dab066

   核對 Python 入口只提供靜態網站，不能冒稱 benchmark runner。

   L1–62

4. `script.js` ↗

   GitHub · saroo25/Egostream · 8cb0dab066

   核對 JavaScript 只有選單、捲動與顯示動畫，沒有隱藏資料 / scorer 呼叫。

   L1–38

怎麼接入我們的benchmark

可重用

可保留官方網站 / paper 的題型、AVW 定義、因果觀測限制、原生統計及子題擴充關係；網站程式僅作 discovery 證據。

需要轉換

source 記 v2、website repo commit 與五父來源；task 記 primary dimension、secondary tags；case 分成 base QA 與帶 recall timestamp / AVW / regime 的條件化評測紀錄，保留群聚 parent ID。evaluator 分開記整體 / 類別 / regime accuracy、實際有效推論分母、memory / frame budget 及時間成本。

仍需補齊

公開 annotations / split / source manifest、AVW 與 recall 抽樣清單 / seed、資料 reader、串流 memory manager、答案解析與 concrete scorer。尚無可核實的 executable release；不能把網站部署程式當評測。

P204 · S-EMBER

S-EMBER: A Large-Scale Benchmark for Streaming Egocentric Memory Retrieval

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

官方 S-EMBER 已有具體 JSONL reader、五選一 scorer、temporal IoU 與 optional Gemini judge；核讀專用 sember task 及兩條模型 / API 路徑。此 commit 預設只回報 MCQ accuracy 或 mIoU，尚未實作 paper v2 的完整 clean / overall / hallucination / R@1 / GQ 協定；另有缺片降為純文字與 judge 非同步錯配等整合問題。

> **版本與身份**
>
> 固定 code 18db1323a60c86f50d9cf91df2083237a9895c50（2026-07-08）早於 paper 2607.02689v2（2026-08-26）。pyproject 標 lmms_eval 0.7.1、task metadata 0.2；Qwen runner 預設 uniform_nframes=768、fixed_frame_pixels=786432，而 paper v2 主表是 open models 128 frames。此讀取範圍不是整個繼承 framework 或所有外部 decoder 已核。
>
> pinned arXiv:2607.02689v2 首頁直接指定 facebookresearch/S-EMBER 與 facebook/S-EMBER dataset；README 題名、作者及 arXiv 對應一致。倉庫包含 lmms-eval 的其他 task，但本篇只追 lmms_eval/tasks/sember 與其直接呼叫；沒有把 FALCONBench 等繼承 task 當成本篇資料。

領域	居家整理與清潔、餐飲與烹飪、零售與購物
環境	613 名使用者以 Ray-Ban Meta 錄下日常人類第一人稱、visual-only 觀測。論文的 2,090 fine-grained scenario labels 合併為 33 activity categories，均非可執行場景資產或去重實體場所數。
任務	原生八類為 location_trace、sequential_action、counting_objects_events、visual_detail_recall、temporal_ordering_recognition、time_duration、object_comparison、spatial_aware_reasoning。兩個 task entry 是 sember_mcq（五選一）與 sember_grounding（答案＋證據時間段）；同題三種 verbosity 參考答案及 MCQ 變體不產生三倍獨立 case。

題數與資料	兩個 YAML 以 datasets.load_dataset(path="json", data_files={test: data/sember_*.jsonl}) 載入 test split。程式按 SEMBER_VIDEO_DIR/<video_id>.mp4 取影片，忽略 HF 的 video 路徑欄；doc_to_visual 產生 {video_path, video_end: question_time}。MCQ 使用 question_id、question、options、correct_letter（scorer 可 fallback correct_index）、question_category；grounding 使用 answer、answers[].answer_text、answer_start_time / answer_end_time，並保留 memory_recency、answer_range、duration、video_category。question_time、證據區間及 duration 以原片秒為單位；未做跨影片共用時間軸。論文 / README 報 9,448 QA、3,141 videos、388 小時，本輪未下載 HF JSONL / 影片，未把這些數字宣稱為本地驗算。
評估方式	MCQ parser 優先接受單一 A–E，否則取第一個獨立字母；空白 / 不可解析為錯。aggregate = 100×答對數 / 所有傳入結果，另印每類 accuracy / parsed 數，並非八類 macro。grounding 只解析 Answer: 與 Time:[非負數,非負數]；IoU = max(0,min(end)−max(start)) / (max(end)−min(start))，缺 GT、無法解析或 union≤0 均為 0。mIoU = 100×IoU 總和 / 所有結果，未解析仍在分母，未裁到 question_time / duration。API summary 同樣把 FAILURE 留在分母；--max-samples 限制後只對該子集計分。optional judge 收集 answer 與 answers[].answer_text，以任一可接受答案匹配；CORRECT / WRONG / UNPARSED / ERROR 均入 total，僅 CORRECT 入分子。paper v2 的 Acccl、Accov、hallucination union-check、R@1≥τ 及 GQ@τ 並未在上述專用公開 scorer 實作；其論文主表以原始 IoU 0–1 報告，而程式回傳 0–100。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **2,090** fine-grained scenario labels · 原文頁 6
- **8** question categories · 原文頁 5
- **9,448** QA pairs · 原文頁 1, 4
- **3,141** unique video clips · 原文頁 4, 5

依這個順序讀

1. `README.md` ↗

   GitHub · facebookresearch/S-EMBER · 18db1323a6

   確認 paper / repo / dataset 身分及 grounding 預設與 optional judge 的差別。

   `L1–63 · L124–168 · L191–213`

2. `data/README.md` ↗

   GitHub · facebookresearch/S-EMBER · 18db1323a6

   核對八類、JSONL 欄位與以秒計的 query / evidence 時間。

   L75–174

---

3. `lmms_eval/tasks/sember/sember_mcq.yaml` ↗

   GitHub · facebookresearch/S-EMBER · 18db1323a6

   定位 test JSONL、doc_to_visual、結果處理與自訂 aggregator。

   L1–31

---

4. `lmms_eval/tasks/sember/sember_grounding.yaml` ↗

   GitHub · facebookresearch/S-EMBER · 18db1323a6

   確認 grounding 的公開 metric 只有 temporal IoU。

   L1–35

---

5. `lmms_eval/api/task.py` ↗

   GitHub · facebookresearch/S-EMBER · 18db1323a6

   追到 datasets.load_dataset 與實際 test split / task callback。

   L1138–1174 · L1206–1208 · L1571–1582

---

6. `lmms_eval/tasks/sember/utils.py` ↗

   GitHub · facebookresearch/S-EMBER · 18db1323a6

   核對影片解析、MCQ parser、IoU 公式、失敗與聚合分母。

   L17–163 · L171–289

---

7. `lmms_eval/models/simple/internvl3.py` ↗

   GitHub · facebookresearch/S-EMBER · 18db1323a6

   追秒→frame index、None 過濾、缺片空回答與 video bounds。

   L154–218 · L363–405 · L455–506

---

8. `lmms_eval/models/simple/qwen3_vl.py` ↗
   GitHub · facebookresearch/S-EMBER · 18db1323a6

   追 video_end 傳遞、frame budget、metadata 及缺片仍生成文字回答的路徑。

   L182–244 · L285–366 · L378–447

---

9. `scripts/data/filter_jsonl_by_videos.py` ↗
   GitHub · facebookresearch/S-EMBER · 18db1323a6

   核對本地影片過濾如何改變被評題目與印出的錯誤混合單位。

   L28–100

---

10. `scripts/mcq/run_qwen3vl.sh` ↗
    GitHub · facebookresearch/S-EMBER · 18db1323a6

    確認提供的 Qwen runner 預設 768 frames，與 paper v2 主表不同。

    L51–87

---

11. `tools/api_baseline.py` ↗
    GitHub · facebookresearch/S-EMBER · 18db1323a6

    追 API 的裁片 / 抽幀、JSONL reader、失敗保留與實際 scorer。

    L110–188 · L249–281 · L464–658 · L666–720

---

12. `tools/judge_grounding.py` ↗
    GitHub · facebookresearch/S-EMBER · 18db1323a6

    核對 gold-answer union、verdict parser、非同步順序與逐題 / 分類分母。

    L53–119 · L122–174 · L177–224

怎麼接入我們的benchmark

可重用

可重用原生八類、兩個 task YAML、JSONL loader、per-question logs、五選一 parser / deterministic IoU 作待修正的原生 evaluator；保留完整 / 缺片子集與 API / local 路徑。

需要轉換

source 記 paper v2、repo commit、HF 另行固定的資料版本及 lmms-eval 衍生關係；domain / environment 從 video_category_broad / video_category 分層，不能將 2,090 labels 當 scene assets。case 以 question_id 關聯 video_id、question_time、options / answer variants 與多 reference intervals，MCQ / grounding 共用 parent QA。evaluator 各自儲存 score unit、全分母、parsed / failed / 缺片數、可見 prefix、frame/pixel budget；追加 paper v2 的各分項與同題 joint GQ，保留和舊版 scorer 的差別。

仍需補齊

HF 原生題目 / 影片 manifest 及資料 revision、有效題數驗算、缺片一致處置、strict schema / timestamp validation、judge ID 對齊與 parser 修正、完整 paper v2 metrics 接線。Qwen 的實際解碼委派 qwen-vl-utils>=0.0.14，未固定精確版本；需另驗證取樣時間 / 外部 reader 的 cutoff，不宣稱已完成 runtime 重現。

P205 · CapMem

CapMem: A Benchmark for Caption-Based Episodic Memory in Egocentric Video

實作尚未確認 · 主來源 · 原作 · 獨立頁面

CapMem 的 pinned paper 有完整標註、單一 evaluation split、caption / frame 協定與 retrieve-and-verify 規則，Appendix G 亦宣稱發布程式；但已收錄 PDF / project / 搜尋來源未提供可確認的本篇 GitHub release。未把同名記憶遊戲或 CapMemUtils 當成實作，也未假造 loader / scorer 檔案。

> **版本與身份**
>
> 全篇依 pinned 2609.17688v1 與既有 2026-10-10 搜尋 / project cache；沒有已確認 repo commit 可記。論文 p.24 的 release 宣告不能替代可讀原始碼。沒有新批次搜尋、模型執行或資產下載。
>
> 核對 arXiv:2609.17688v1（2026-09-15），Dingli Liang、Yiqiao Xie 等九位作者。project_candidates 的本篇沒有 project 或 repo；既有 CapMem egocentric 搜尋為 0，廣義 CapMem 搜尋的前 8 / 10 個結果未建立作者或論文對應。因此狀態是尚未確認程式倉庫，不是證明全網無 code 或 repository 404。

領域	居家整理與清潔、寵物照護與動物活動
環境	75 段既有公共人類第一人稱影片，共 33.7 小時，來源為 Ego4D、EgoLife、EgoPet、EPIC-KITCHENS、HoloAssist、ENIGMA-51、CASTLE2024。四用途是 Daily Life & Domestic、Outdoor & Mobility、Work & Procedural、Pet Related；16 scenario labels 不等於 16 個已去重可執行世界。
任務	主題是 Episodic Memory Video Caption QA；CleanQA（僅問題 / 選項）、Direct VideoQA（抽樣影格）、CaptionQA（時間化文字記憶）是同題三種資訊條件。Ego / Exo × Who / What / Where / When / How 為問題分類，50 templates 是出題樣板；Object、Attribute、Spatial、Action 為可重疊標記，不是額外物理任務。
題數與資料	論文 Appendix E 的 2,109 人工 candidates 經雙 reviewer 留 1,276，文字捷徑 filter 刪 352 後剩 924，再復核恢復 76，得到 1,000 題。Appendix G 指定每題包含 question identifier、父資料 / 影片 ID、四選項與正解、evidence timestamps、domain / scenario、Ego / Exo、4W1H、evidence-location、多視覺 tags；此為論文所述內容，沒有實際檔案可驗證 JSON key 名稱或 loader。單一 1,000-question evaluation split，無獨立 dev；來源影音 / 原庫標註不重發。影格 cache 是 1 fps，full-coverage caption 用連續 30 / 60 秒窗；caption 完成後以文字回答同影片各題。

評估方式	論文用四選一 QA accuracy（正確題 / 實際評測題）及每題 token 成本；主設定 N=1,000，Gemini 3 Flash Direct VideoQA 僅 N=786，相關配對比較須對齊這 786 題。duration 子集 208 / 792 題，evidence-location 子集 348 / 507 / 145 題；multi-label tags 的分母重疊。CleanQA 15%–35% 是 model 進入主評測的 gate，不是 case 成功門檻。Direct 的 InternVL / Qwen frame caps 為 128 / 768；full-caption 無 video-level cap，六 Qwen 的 frame-aligned control 才用與 direct 相同的 frames。Appendix D 的 retrieve-and-verify 最多三 seed、neighbor=1、NMS 45 秒，最多三段各四個影格驗證；僅 strong 視覺支援、合法字母且無 clock-time cue 才覆蓋原 CaptionQA。該 override policy 在全 benchmark 錯誤分析後選定，作者明示屬 post-hoc proof of concept。未取得 concrete scorer，答案 parser、無效輸出、例外 / 遺漏題入分母方式及實際 filter 實作均未核實。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **4** 作者application domains · 原文頁 3, 4
- **16** scenario labels · 原文頁 3, 18
- **1,000** final MCQs · 原文頁 4, 18
- **786** Gemini DirectVideoQA已評子集 · 原文頁 5

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

可重用原生用途 / 題型 / 多標籤、單一 evaluation split 的論文統計、公開 prompt 文字、input-budget 對照與 post-hoc 限制。

需要轉換

source 綁 paper v1 並保留七個父媒體來源；domain / environment 保留四用途與 scenario labels。case 用 CapMem QA ID 關聯 parent video / evidence 與選項，三種資訊條件及 30 / 60 秒 caption 版本作同題條件；evaluator 儲存 matched question IDs、完整或 786 子集、frame IDs / captioner / QA model、caption 一次性成本與逐題攤提成本。retrieve-and-verify 另記 override / wrong→correct / correct→wrong，不能與無視覺 CaptionQA 混記。

仍需補齊

作者可驗證 release URL、官方 annotations / question IDs / split manifest、JSON schema、reader、caption cache 索引、各協定實際 scorer 與可追溯排除清單；還需獨立 dev / held-out policy 驗證。未取得的 LICENSE-DATA / LICENSE-CODE 僅是論文宣告，不列成已讀檔案。

P206 · EmbodiedMemory-Bench

EmbodiedMemory-Bench: Benchmarking Embodied Memory for Long-Horizon Embodied Tasks

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

循官方 project 搬移頁確認 ZJU-OmniAI/Embodied-Omni 的 embodied_memory/ 為本篇公開程式，已追 manifest loader、history sanitization、simulator runner、四家族具體 success / ERR 與 macro 分母。HF 有 frozen release，但公開 loader 與發布路徑不一致；code 亦將任一 ERR 視為不能成功，與 paper 的可恢復終態 SR 有實質差異。

> **版本與身份**
>
> code 固定 f0409a8ecd858acd1f53c69f6424e0c4af83737b，只核 embodied_memory 子專案。HF 固定 3b45bd3f3a67a23b09b78d27c3ab563a700e832a；README 說公開 episode-level 名稱 / 描述 / probe instructions 已英文化並更新 hash，原語言 revision 為 28694bf83b78049ac96ba01c9ffb13aeac7eaef9，不能混用。HF canonical manifest SHA256=6c69644b9fc4755065830e4884a12898e3ed0db32c1825dbecf623c37b9b1bc2 是發布者 metadata 宣告，本輪未下載 full2554 逐例重播驗算。
>
> pinned arXiv:2609.28236v1 題名及 Lizhou Liang 等作者與 embodied_memory/README 一致。PDF 原始 ZJU-OmniAI project 轉址到 Embodied-Omni/EmbodiedMemoryBench，新頁直接連官方 monorepo 與 lzLiang/EmbodiedMemoryBench；不將參考文獻的 OpenBMB/MiniCPM-V 當成 benchmark。只核本篇 embodied_memory 子樹，未擴讀同 monorepo 的 reasoner / navigator。

領域	居家整理與清潔
環境	AI2-THOR 單房間組合的多房間脈絡與 ProcTHOR 場景；論文 Table 9 報 1,118 個 globally unique source scene IDs、四 room types，不能加總各家族重疊 scene counts。當前 env 以 probe.scene reset，使用 500×500 RGB、visible_objects、agent_state、available_actions 與高階離散目標動作。原生 x/y/z、objectId、rotation_y（0–360）及相機角度須保留；不把 Navigate / PickUp 等介面當連續機器人關節控制。
任務	manifest 四家族 l2_passive、l2_dynamic、l2_interaction、l3_owner_habit 分別對應 Passive Observation、Dynamic Tracking、Interaction Failure、Experience Generalization。probe_retrieve / probe_track_location 要到記憶位置並拾取目標；probe_avoid_failure 要選非已知鎖定容器存放物品；owner_habit 以先前 correction 對新物件選擇合規 receptacle。construction schema 的 L0–L3 enums 不等於四個發布家族。

題數與資料	data.load_manifest 讀 JSONL 的 id、family、source.episode_path、source.episode_sha256；拒絕重複 id，先依 family / per_family 選擇，再檢查 episode 檔與可選 SHA256。run 另以 source.probe_id 精確配對一個 probe。episode JSON loader 是 json.load；schema 含 episode_id/name/difficulty、sessions[].context_trajectory.steps[] 的 step_id/image_path/visible_objects/agent_state/action/feedback、micro_probe 或 macro_probe，以及 hidden_rules / memory_cues / expected_actions / evaluation_hooks。時間原生單位是有序 session / step，非影片秒。paper 與 HF metadata / audit report 同報 2,554=1,036+1,052+263+203、split=all；本輪僅機械清點小型 experience_generalization manifest 的 203 個唯一 id，未重新驗證全部 2,554 episodes。
評估方式	實際鏈為 CLI evaluate→load_manifest→run.evaluate→env.step→EpisodeEvaluator.evaluate_probe。env 為每次 action 嘗試記 success / feedback，無效動作及 Done / Stop 也計入 actual_steps；預設 8-step budget 覆蓋 schema 的 30 / 60 預設。success 讀 simulator world_state 的持物 / parent / 狀態並核對成功執行的導航或放置；L2 可接受原生指定的同類且同記憶容器物件，owner_habit 保留 executable receptacle alias。ERR 只比對成功動作的 frozen triggers，L2 是先去不同 receptacle type、interaction 是重複已知錯誤 action–target、owner_habit 是違規放置；每 subtask ERR=min(1,觸發數/max(1,required_memory_integration 數))，probe 對 subtasks 平均。run.summarize 以每家族 task_completed 布林值 / 已記錄 rows 計 SR，再對實際出現家族等權 macro；ERR 同樣先家族平均。不能將 smoke 選樣或中止前 summary 當 Full-2554。InvalidPhaseOutput 保留作該例失敗，infra exception 寫錯誤並中止，不產生新的完整 summary。RAR/AES/MAE 是附帶 diagnostics，不等於 paper 主 metric。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **1,118** benchmark source scenes · 原文頁 6
- **4** memory task families · 原文頁 5
- **2,554** validated executable episodes · 原文頁 6
- **800** history介入paired base episodes · 原文頁 27

依這個順序讀

1. `embodied_memory/README.md` ↗

   GitHub · ZJU-OmniAI/Embodied-Omni · f0409a8ecd

   確認 paper / project / data 身分及 compact public evaluation 入口。

   `L10–31 · L49–77 · L127–196`

2. `embodied_memory/src/emem_bench/data.py` ↗
   GitHub · ZJU-OmniAI/Embodied-Omni · f0409a8ecd

   核 manifest id / family / source path、hash 檢查與 history 圖片解析。

   L8–58 · L61–112

---

3. `embodied_memory/src/emem_bench/construction/schema.py` ↗
   GitHub · ZJU-OmniAI/Embodied-Omni · f0409a8ecd

   核對 actions / feedback、sessions、micro / macro probes 及 evaluator-only annotations。

   L153–225 · L243–344

---

4. `embodied_memory/src/emem_bench/cli.py` ↗
   GitHub · ZJU-OmniAI/Embodied-Omni · f0409a8ecd

   確認預設每家族 1 例、8 steps、evaluate / offline score 不同路徑。

   L20–28 · L132–157 · L182–217

---

5. `embodied_memory/src/emem_bench/evaluation/run.py` ↗
   GitHub · ZJU-OmniAI/Embodied-Omni · f0409a8ecd

   追實際 simulator 執行、單一 manifest probe 配對、infra failure 與分母。

   L18–38 · L58–175

---

6. `embodied_memory/src/emem_bench/evaluation/env.py` ↗
   GitHub · ZJU-OmniAI/Embodied-Omni · f0409a8ecd

   看場景 reset、動作嘗試、終止、世界狀態及當前 action ID。

   L135–193 · L209–374 · L711–748 · L845–977

---

7. `embodied_memory/src/emem_bench/evaluation/evaluator.py` ↗
   GitHub · ZJU-OmniAI/Embodied-Omni · f0409a8ecd

   追四家族可執行終態判定、同類 receptacle alias、ERR 觸發與聚合；不是採用 ordered-subsequence stub。

   L202–357 · L377–424 · L518–562 · L717–866 · L1073–1152 · L1154–1288 · L1405–1438

---

8. `embodied_memory/src/emem_bench/evaluation/planner.py` ↗
   GitHub · ZJU-OmniAI/Embodied-Omni · f0409a8ecd

   核對 full_context 真正給模型的欄位及每 session 80-step 上限。

   L409–461 · L740–806

---

9. `embodied_memory/src/emem_bench/evaluation/protocol.py` ↗
   GitHub · ZJU-OmniAI/Embodied-Omni · f0409a8ecd

   核對 emem ingestion 可見資料、序列動作重新繫結與 simulator fail 處理。

   L902–971 · L1017–1161

---

10. `embodied_memory/src/emem_bench/evaluation/tool_agent.py` ↗
    GitHub · ZJU-OmniAI/Embodied-Omni · f0409a8ecd

    核對先 ingest 歷史再接 target，僅從可見 feedback 作後續 memory writes。

    L160–290

---

11. `embodied_memory/src/emem_bench/evaluation/grounding.py` ↗
    GitHub · ZJU-OmniAI/Embodied-Omni · f0409a8ecd

    確認依當前 available_actions 修復 / 繫結模型預測並儲存修復紀錄。

    L98–269 · L272–459

怎麼接入我們的benchmark

可重用

官方 frozen manifest 身分 / family / hash、episode schema、session-step 脈絡、模型可見欄位過濾、動態 action registry、trace 與具體 state / ERR evaluator 可重用；case、probe、action attempts 需分開。

需要轉換

source 同時記 paper v1、GitHub commit 與 HF revision；domain / environment 保留 room type、host simulator、scene provenance 與重用關係。task 維持四家族 / probe 規則；case key 用 manifest id 及 episode_id+probe_id，另以 organized_view 建可攜 execution_path，不覆寫原研究路徑或 lineage。history/action/feedback、model-visible context 與 evaluator-only rules 分開對映；evaluator 儲存 terminal-state SR 與此版 ERR-veto SR 差異、逐類分母、8-step / 80-per-session budget、grounding repair 與實際 world-state。

仍需補齊

修正 published manifest→loader 路徑橋接、核對 ERR-veto 與論文 scorer、全 release hashes / 素材 / scene reset 閉合、完整 runtime 及同一預算重現。單一 nested episode 嘗試超過本輪 512 KiB 小文字上限，已停止且保留 receipt；不把該檔視為已讀或不存在，亦未下載 RGB / 模型 / simulator。

P207 · EgoCoT-Bench

EgoCoT-Bench: Benchmarking Grounded and Verifiable Operation-Centric Chain of Thought Reasoning for MLLMs

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

GitHub DStardust/EgoCoT 是本篇官方補充網站，HF 另有公開 dev / test 標註、媒體重建 manifest 與實際 reconstruction reader。已核程式只有媒體處理與網站示例，未找到正式 Acc / R / SCR scorer 或 test 正解；不能把網站題目點選函式當成 benchmark evaluator。

> **版本與身份**
>
> GitHub 71e6114c155c7a593fa39e2af801b51e836b53ca 是網站；HF 31c4aa4adc88632c6efe984cf8c5399cc75f6fc3 是 clean public release，只重發自錄媒體，不能將其與較早含第三方處理片的版本混用。raw README / CSV / reconstruction script 均固定 HF revision。viewer/rows endpoint 未回傳 dataset revision，本輪只儲存帶時間與 SHA256 的一列 dev / test 與 features 作輔助欄位核對，不聲稱已核 pinned Parquet 全體內容；未下載影片或執行 reconstruction。
>
> pinned arXiv:2605.19559v1 連到 dstardust.github.io/EgoCoT，固定 repo index.html 與既有 website cache 的 SHA256 相同；其 Dataset 按鈕連 DStardust/EgoCoT-Bench，dataset card 反連同一 paper / project。PDF 作者有 Yang Dai、Dian Jiao、Tianwei Lin、Wenqiao Zhang；網站頁首隻列前三人，文獻作者以 PDF 為準。搜尋的 EmbodiedGPT/EgoCOT_Dataset 是 2023 年另一候選，未將同名視為本篇；頁尾 Academic Project Page Template 亦非 benchmark。

領域	居家整理與清潔、餐飲與烹飪、裝配與生產作業
環境	五個公共人類第一人稱父來源 Ego4D、EPIC-KITCHENS、Charades-Ego、MECCANO、HD-EPIC 加自錄影片，涵蓋生活、廚房及組裝操作；沒有可互動的機器人環境。pinned reconstruction CSV 清點為 351 個 (source_dataset,source_video_id)，但有 352 個 processed_clip_id / output paths；MECCANO 0001_part1 有 416×234 與 588×331 兩版，必須保留版本關係。
任務	4 groups / 12 subtasks：Egocentric Grounding & Perception＝Active Object Grounding、Hand-Object Association、Manipulation State Perception；Spatio-Temporal Retrospection＝State Retrospection、Location/Visibility Retrospection、Hand-Object Temporal Retrospection；Predictive & Causal Inference＝Next State Anticipation、Next Action Anticipation、Local Cause-Outcome Inference；High-level Grounded Reasoning＝Progress Reasoning、Hand-Object Grounded CoT、Goal-Oriented Object Tracking。均是四選一影片理解及公開解釋 / 證據品質，不是可執行操作技能。

題數與資料	HF pinned tree 的實際資料檔為 data/dev-00000-of-00001.parquet 與 data/test-00000-of-00001.parquet；card 指定 load_dataset 後取 dev / test，300 / 2,872 題。小型官方 viewer 回應各抽一列：qid、question、choices[{label,text}]、answer、cot[{step,text}]、media_id、source、big_category_en、sub_category_en、type；dev 有答案與解釋，test 範例 answer=""、cot=[]。兩份 viewer 的 features 沒有獨立 evidence / bbox 欄，不能依 card 的 may include 自造結構化證據。pinned CSV 實際 3,172 個唯一 qid；columns 含 processed_clip_id、source_dataset/video_id、source_start_sec/end_sec、target_width/height、resize_mode、fps、preprocess_version、expected_local_output_path、coordinate_system。所有 start/end 為空、resize_mode=stretch、座標系 processed_clip；2,859 QA 引用 4 fps、313 QA 引用 8 fps，這是題目列數而非影格數。63 個自錄輸出與第三方待重建媒體分開。
評估方式	paper §3.2.4 的 Acc 為四選一 exact match / 全部評測題；R 是 Qwen-Max 對公開生成解釋與參考解釋的 0–5 分；SCR = 答對且 R≤2 的題數 / 所有答對題數×100，分母不是全題數，零答對的處置未由公開程式核實。paper 的 3,172 題結果不可當作 public hidden-test 2,872 題分數；card 的 dev 193 個 video、test 351 個 video 與總 351 個來源顯示不能假定 video-disjoint。paper 另以 2,800 responses 核對 judge，人類一致性樣本不是額外 benchmark cases。GitHub handleAnswer 只對四個寫死示例比字母，leaderboard 只排序 HTML；HF scripts tree 唯一程式 reconstruct_media.py 沒有模型推論、judge、R / SCR 聚合或提交驗證。正式 test scorer / labels 在本輪已核來源中未公開。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **12** reasoning subtasks · 原文頁 3, 4
- **3,172** QA pairs · 原文頁 3
- **351** video clips · 原文頁 3

依這個順序讀

1. `index.html` ↗

   GitHub · DStardust/EgoCoT · 71e6114c15

   核對作者、官方 dataset 連結、dev/test 可見資訊及提交欄位。

   `L510–585 · L865–905 · L2580–2599`

2. `index.html` ↗
   GitHub · DStardust/EgoCoT · 71e6114c15

   追真正 JavaScript：只排序已寫好的分數並比對四個示例題，沒有模型結果的 benchmark 聚合。

   L229–298 · L302–465

---

3. `static/js/index.js` ↗
   GitHub · DStardust/EgoCoT · 71e6114c15

   核對其餘 JS 是網站互動與影片輪播。

   L1–142

---

4. `scripts/reconstruct_media.py` ↗
   Hugging Face · DStardust/EgoCoT-Bench · 31c4aa4adc

   追 CSV reader、來源影片定位、fps / resize / 逐影格處理與重複輸出去重；不執行程式。

   L18–103 · L106–147

---

5. `manifests/media_reconstruction.csv` ↗
   Hugging Face · DStardust/EgoCoT-Bench · 31c4aa4adc

   核 qid / 來源 / 處理版本 / 座標欄及同來源兩個不同解析度輸出。

   L1–4 · L109–109 · L2472–2472 · L3171–3173

怎麼接入我們的benchmark

可重用

可重用 qid、group / subtask / type、選項及 public dev 解釋、來源 / processed clip 對映、重建 CSV 與實際 reader；paper 的 Acc / R / SCR 保留各自定義。

需要轉換

source 同時記 paper v1、website commit、HF revision 與五父資料來源；task 按四群十二類，case 按 qid 保留 dev/test、media_id、options，將 cot 記公開參考解釋而非模型私有思考。environment 記 human-egocentric context；媒體引用需帶來源 ID、processed resolution / fps / coordinate_system，351 sources 與 352 processed variants 分開。evaluator 分別記 Acc 的 N、R 的判讀數及 SCR 的答對分母；test 空正解標為 withheld，不能轉成錯誤標籤或零分。

仍需補齊

正式 evaluator / submission runner、hidden test labels、judge prompt與精確版本 / 解析 / 失敗處置、完整結構化時空 evidence、父素材取得與重建驗證。reconstruction script 用整段 source_video_id 影片，未使用 start/end / resize_mode 欄；CSV 的 start/end 全空，對含切段字尾的 source_video_id 仍須外部定位到正確已裁素材。讀影格失敗時 continue 而不補位，可能改變輸出時間軸；需校核處理後 timestamps / bbox。

P208 · DYAD

DYAD: A Multimodal Dataset of Co-Located Human Assistance

實作尚未確認 · 主來源 · 原作 · 獨立頁面

DYAD pinned paper 將資料與 benchmark code 列為規劃中的 controlled-access research release；已收錄 PDF / project / GitHub 搜尋沒有可確認的本篇倉庫。已核三個 endpoint 的標註與分母，但沒有公開 reader 或 concrete scorer 可讀，不能把同名 app builder / 其他 dyadic dataset 當成來源。

> **版本與身份**
>
> 來源固定為 2609.09023v1 與既有 2026-10-10 discovery/search caches；未確認 repo 就不造 commit 或 source path。851 assistance events、528 step intervals、611 requests、829 mode cases、256 response test pairs、感測影格均為不同單位；數字來自已核 paper，沒有本地 release 逐列驗算。
>
> 核對 arXiv:2609.09023v1（2026-09-08），Akhil Ajikumar、Mahya Qorbani、Sakib Reza、Sean Andrist、Mohsen Moghaddam。paper p.3 Table II 明示 planned release，正文說 will provide annotations/manifests/benchmark code under controlled access；未附本篇 release URL。既有 DYAD co-located assistance 搜尋成功回傳 0；DYAD 廣義搜尋前 8 / 1,197 結果不足以證明全網無倉庫。

領域	裝配與生產作業、協助、交接與陪伴
環境	單一 gearbox 組裝工作站的同地人類 performer–helper 協作；20 名 HoloLens 2 佩戴者各一 session，同一受訓 helper 遵循先言語引導、等待自我修正、必要時實體幫助的規則。六 pilot 不計正式 20 sessions / 5 小時 58 分鐘。人類示範不是已執行機器人協作。
任務	三個分開評測的 reference endpoints：因果組裝步驟辨識、已知將有介入時的 verbal / physical mode anticipation、給 oracle 脈絡的 helper response generation。八個 step labels 是 Gear on shaft、Bearing in holder、Second holder、First holder、Part search、Shaft assembly in post、Attach crank、Verify rotation。九 trigger labels 是 out of reach、cannot find part、cannot decide next step、wrong part、ordering violation、wrong orientation、wrong screwdriver、stabilization needed、missed screw；null trigger 表示分類外需要，不能當沒有介入的負例。

題數與資料	論文 Table II 的觀測為 ego RGB 24–30 Hz / 896×504、depth 5 Hz / 320×288 16-bit、gaze 30 Hz 3D origin/direction、hands 20 Hz 每手 26 joints / 4×4 poses、head 30 Hz 4×4 transform、Kinect RGB-D 15 Hz（RGB 1280×720 JPEG）。音訊不在規劃釋出範圍，使用去識別逐字稿。三層標註各有 task step（step/objects/tool）、request（utterance/confidence）、assistance（onset/offset、mode、initiation、hard stop、trigger、objects、helper utterance、outcome）。全部轉 session-relative clock 並儲存 null；兩場原始絕對式 hour 欄需保留各自 origin，不能當 elapsed hours。這些是論文 principal fields / 單位，尚未核到實際 JSON keys、檔案佈局、reader 或同步轉換程式。
評估方式	mode 的論文清點是 export 852→刪一重複 851→有 mode label 850→完整 pre-onset RGB window 829（610 verbal / 219 physical）；window=[onset−3.5s,onset−0.5s]。五 fold 各 12/4/4 performers，合併 829 個唯一 OOF events 算 binary macro-F1、physical-class AUPRC，四 seeds 為 0/1/2/42，2,000 participant bootstrap replicates 不能算新 cases。當次 trigger / initiation / outcome / speech / step label 等不得作輸入。step track 是 5 validation / 15 test sessions，1 Hz 因果 RGB、四 frame lookback；segment F1@IoU0.1、collapsed-sequence edit、temporal mAP@0.1、frame mAP 與 MoF 分別保留，528 intervals 中一筆 null 不能擅自丟成零標籤。response 將 request end 前5秒至後15秒內最近的 verbal assistance 配對，376 pairs=120 dev+256 held-out test；oracle 提供先前步驟、10輪真實對話、10次介入及 CAD 圖，當次 trigger 不提供。每 query 一次生成、100-token cap；Claude Opus 4.5 依正確性、完整性、脈絡相關性、可行動清晰度、簡潔度與整體各評0–5，另 BERTScore P/R/F1。以上均為 paper protocol；segment matcher、judge prompt / parser、null / 例外處理、aggregation 程式未找到，沒有宣稱本輪算過成績。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **3** reference endpoints · 原文頁 4, 6
- **829** eligible pre-onset mode events · 原文頁 4, 5
- **256** held-out response pairs · 原文頁 6
- **851** valid assistance records · 原文頁 4, 5

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

可重用三層事件結構、八步驟 / 九 trigger 原生詞表、單 helper policy、三 endpoint 的資訊邊界與原生分母；規劃 release 與實際可用素材分開記。

需要轉換

source 儲存 v1 與 controlled-access-planned 狀態；domain 記組裝 / 協作，environment 記 workstation、performer、helper policy。case 將 session、step interval、request、assistance event 與各 endpoint 的 eligible sample 建關聯，保留原始時鐘 / session origin / 同步率 / nullable 欄。evaluator 分開 mode OOF、step sequence / frame 與 response pair，各自保留 split、seed、可見資訊及分母，三 endpoint 沒有共同成功分數。

仍需補齊

官方 release / access 流程及程式 URL、native annotation / manifest、同步 clock reader、829 OOF IDs、step null-policy、response 配對與評分實作。沒有 non-intervention negatives，不能接成 assistance-need detector；827 個有 outcome 標籤的事件中 812 個為 effective，這種高度偏態是作者不設 outcome prediction 的原因，不能以所有 851 events 當此 endpoint 分母。

P209 · HUI360

HUI360: A 360{\deg} Egocentric Dataset and Baselines for Human-Robot Interaction Anticipation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

HUI360 已核官方 baseline 與 Interact360 標註 / CSV 管線。論文結果必須對應 baseline legacy 分支與固定 HF dataset revision；新版 main 的 32-frame / 16-frame cutoff、資料 main 及最佳 F1 threshold 搜尋不能直接當論文 30 / 15 協定。已追到實際 track reader、視窗標籤、AUROC / F1 / AP scorer，未執行模型或下載大型資料。

> **版本與身份**
>
> 主核論文baseline legacy=32a90eb716e503ef8a0daabc052ce7c34ba36a95，README / config 指定 dataset rlorlou/HUI360@3c8a342548534b6b92d32b0099e266962facdf45，30-frame輸入、15-frame兩cutoff、25epochs。另讀 main=a6bd61c8539061242cbf756a18847c0900a8707c（2026-08-29）新版核心設定 / reader入口 / scorer，預設32frames / 16cutoff / 75epochs及hf_dataset_revision: main，不能混用數字。Interact360=d11ec02d666965968293813b9c17501cf1568cf6（2026-05-06），其README的CSV教學雖TBD，實際export程式已存在且已核。以上是選定核心區段，不是全基線架構 / 整個標註模型codebase已審完。
>
> arXiv:2608.11051v1 的官方 project 明確分開 Code (Baselines)=hucebot/HUI360-Baselines 與 Code (Pipeline)=RaphaelLorenzo/Interact360；前者 README 直接連同一 arXiv 並要求論文使用 legacy，後者雖仍有 arXiv TDB placeholder，但官方 project、HAL 與題名均指向本篇。SSUP-HRI 是重用父資料，不另當 HUI360 新收集來源。

領域	公共場館與服務、協助、交接與陪伴
環境	robot-egocentric 360° equirectangular 觀測。paper 的新 HUI360 有 9 真實場所、30 robot setups、68 recordings；71.3 小時原始資料裁成 1,937 episodes / 11.3 小時（15 fps）。4,310 person tracks 中 375 有物理互動；另 SSUP-A 是 SSUP-HRI 兩個 field sessions 的重標註，27,698 tracks / 419 interactions，不可當獨立新捕捉資料。本輪沒有可互動 robot policy 環境，評的是離線 anticipation。
任務	預測人是否即將與平臺發生物理 interaction；positive onset 依投放、拿取等實際事件與人工修訂，並非對 gaze / 社交意圖的通用判定。RF / MLP / LSTM 是模型，T_ADV horizons 5/10/15/20/30 frames（15 Hz 下約0.33/0.67/1/1.33/2秒）與輸入降取樣是同一 task 的條件。論文 HUI locations1–7 train、8–9 test，SSUP 第一 / 二場次 train/test；實際程式依 checkpoint 的 include_recordings_val 等清單選樣，變數 val 不能擅自解讀成另有第三份驗證集。

題數與資料	Interact360 讀 episodes/<id>/annotations_360.json 的 image_file/image_shape/detections；track_id 可由 associated_track_id 合併，含 validity、bbox、mask_rle、mask_size、engagement_level、17點 ViTPose 與308點 Sapiens。bbox / pose 是原全景畫素，x 可跨影像寬度邊界，不能直接裁成普通2D box。detect_interactions 的相交面積>min_pixels_intersection（預設10,000）給 level3，否則0，之後允許人工修訂。export 只收 checked/valid 類 flags，依validity與quality連續段篩選，寫 data-<recording>-<index>-of-<total>.csv；unique_track_identifier=recording_episode_track。timestamp 由檔名 %Y_%m_%d_%H_%M_%S_%f 解析；另存 timestamp_sec、相對track秒、time_to_first_interaction秒，無互動用99999.0 sentinel。缺 Sapiens 資料可填0，需視作缺失而非真座標。baseline CSV reader 把 engagement / 時間 / ID 列列為 metadata，指定LSTM features為 mask area+bbox+17×(x,y,score)，即56維 / frame；keypoints先box-normalize再用固定HUI mean/std。
評估方式	legacy get_track_input_possible_indices 將 image_index 連續存在、validity、至少9個 ViTPose score≥0.5與mask_size篩選做AND，再找連續段。第一個 engagement>0 定義 onset；interaction_cutoff / positive_cutoff 以frame計。非互動 track 可截到最大mask面積（近距離proxy），並依設定把視窗對齊該處。force_positive_samples 會排除互動track的早期負窗。__len__ 是合格track數，__getitem__ 為各track固定或隨機選一個候選視窗；固定索引清單與subsample必須儲存。legacy infer 對每個視窗得到 sigmoid(logit) 或 RF predict_proba[:,1]，用>0.5算 binary P/R/F1，整個pass的分數送 roc_auc_score；training.evaluate 另算 average_precision_score。其 N 是實際送入的合格track視窗，AUROC比較正負樣本排序，F1分母為2TP+FP+FN，不是4,310 raw tracks、375 interactions或百萬 detections。new main 可用 stride 展開多視窗，需重記樣本數；main infer 直接算 AUROC/AP，並在同一集合用100個threshold搜尋最佳F1。未下載實際CSV，因此不宣稱驗算任何eligible test case數。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **9** real locations · 原文頁 3, 4
- **30** robot setups within locations · 原文頁 4
- **1,937** HUI360 extracted episodes · 原文頁 4
- **4,310** HUI360 person tracks · 原文頁 4

依這個順序讀

1. README.md ↗

   GitHub · hucebot/HUI360-Baselines · a6bd61c853

   確認本篇身分及 legacy 才對應論文結果。

   L1–18

---

2. README.md ↗

   GitHub · hucebot/HUI360-Baselines · 32a90eb716

   確認 legacy 與論文使用的固定 HF 資料版。

   L1–3 · L47–52

---

3. process/detect_interactions.py ↗

   GitHub · RaphaelLorenzo/Interact360 · d11ec02d66

   核實 mask intersection 的 level 3 標註與預設 pixel 門檻。

   L23–52 · L81–105 · L148–157

---

4. export/export_utils.py ↗

   GitHub · RaphaelLorenzo/Interact360 · d11ec02d66

   核日期字串、人工檢查 flags、associated track 合併及 invalid 標記。

   L9–36 · L78–126

---

5. export/export_to_dataset_plain_csv.py ↗

   GitHub · RaphaelLorenzo/Interact360 · d11ec02d66

   追逐 detection→track/frame CSV、onset、時間單位、quality 篩選與輸出檔名。

   L128–295 · L298–394 · L396–445 · L595–624

---

6. experiments/configs/expe_classifier/lstm_config.yaml ↗

   GitHub · hucebot/HUI360-Baselines · 32a90eb716

   核資料 revision、30-frame 輸入、15-frame cutoffs、recording split 及固定取樣。

   L1–29 · L65–156

---

7. `datasets/HUIDataset.py` ↗

   GitHub · hucebot/HUI360-Baselines · 32a90eb716

   追 CSV reader、連續有效影格、正 / 負例視窗、normalize、每 track 一個樣本的分母。

   L130–217 · L248–451 · L486–574 · L612–701 · L759–896

---

8. `infer.py` ↗

   GitHub · hucebot/HUI360-Baselines · 32a90eb716

   核 checkpoint 協定、實際 inference、AUROC / binary F1 與全同硬分類分支。

   L396–443 · L530–637 · L670–700 · L771–804

---

9. `training.py` ↗

   GitHub · hucebot/HUI360-Baselines · 32a90eb716

   核 validation AP、threshold sweep 及全同預測時未初始化回傳值。

   L55–68 · L131–185

---

10. `experiments/configs/in_hui/lstm_base.yaml` ↗

    GitHub · hucebot/HUI360-Baselines · a6bd61c853

    分開記新版 32 / 16、stride 與可變動 HF main。

    L36–46 · L82–113 · L260–267

---

11. `infer.py` ↗

    GitHub · hucebot/HUI360-Baselines · a6bd61c853

    核新版 per-input metric、同集合最佳 threshold 與 checkpoint 版本限制。

    L61–83 · L152–177 · L188–227 · L339–359

---

12. `utils/eval_utils.py` ↗

    GitHub · hucebot/HUI360-Baselines · a6bd61c853

    確認新版以100個threshold求同一label集合的最高binary F1。

    L10–34

怎麼接入我們的benchmark

可重用

可重用兩倉庫原生track/frame結構、人工curation flags、mask-intersection標籤、legacy reader / window selector / score path及固定normalization；SSUP重用關係獨立記錄。

需要轉換

source 必須同存 paper v1、baseline legacy或main commit、dataset revision、Interact360 commit。environment 區分 location / setup / recording；task 儲存物理interaction定義與horizon。case 用dataset+recording+episode+track+window起訖 / sample index，另保留raw track與條件化window父子關係；frame index、檔名時間、relative seconds、panorama seam / pose confidence / 缺失標記分開。evaluator 儲存正負樣本N、filters、取樣seed / stride、threshold來源、AUROC/AP/F1及normalization版本，不能轉成機器人完成工作成功率。

仍需補齊

固定revision的完整CSV / track manifest與checkpoint protocol對齊、eligible windows實際清點、SSUP跨全景邊界與missing-pose處理驗證、legacy邊界分支修正、獨立threshold選擇、原始影像 / curation與標註版本閉合。只做靜態核讀；snapshot_download、大型骨架 / 影像、模型、GUI與模擬均未執行。

P210 · RoCo Challenge

RoCo Challenge at AAAI 2026: Benchmarking Robotic Collaborative Manipulation for Assembly Towards Industrial Automation

實作尚未確認 · 主來源 · 原作 · 獨立頁面

收錄論文是AAAI2026第一屆RoCo齒輪箱組裝；目前找到的兩個devkit是IROS2026第二屆Task Board/Brick，不能當作同版原作實驗。已核讀其新介面作延伸來源並明列版本缺口。

> **版本與身份**
>
> TaskBoard45dd6ad、Brick8e7ad4d均明示2nd IROS2026且建立於原文3月之後。原文RoCo2026網站/同名repo取404，org首頁轉向IROS2026。原作到實作版本未閉合，故identity_or_version_unresolved。
>
> 組織相同但edition/task/scoring不同；這是版本差異，不把兩個新repo錯標成AAAI2026齒輪箱程式。

領域	裝配與生產作業、協助、交接與陪伴
環境	原文為Isaac Sim Galaxea R1及onsite R1Lite齒輪箱；新TaskBoard/Brick devkit是另一edition的場景/機體配置，不合併為同一環境版本。
任務	AAAI原文3情境：從零組裝、接手partial state、錯誤檢測/恢復。新TaskBoard的9個parts是單一板件任務的計分部件；Brick有2種起始/目標結構格式。上述數字不可加總作原文task數。
題數與資料	新TaskBoard API有physics step、joint rad/metre、wxyz EE pose、RGB/depth(m)/intrinsics及snap_fired；Brick用23Djoint array與structure_start/goal或structure.json。原文第一屆case/資產/資料版本尚未完整取得對應。
評估方式	AAAI原文S_sim=(4S1+2S2+4S3)/10；新TaskBoard按part pass/total，snap parts看觸發，open parts看mesh/AABB位置距goal<0.01m且不檢朝向。新Brick main只到Policy.is_done，完整grader需另接。原文重現不能套用第二屆這套分母/吸附機制。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **3** assembly scenarios per track · 原文頁 3, 4, 5
- **300** sim demonstrations · >300 · 原文頁 5
- **300** real demonstrations · >300；不同資料 · 原文頁 5

依這個順序讀

1. `README.md` ↗
   GitHub · rocochallenge/RoCo_TaskBoardAssembly · 45dd6ad6e0

   明示2nd IROS2026、9parts及active/unused資產

   L1–90

---

2. `task/policy_api.py` ↗
   GitHub · rocochallenge/RoCo_TaskBoardAssembly · 45dd6ad6e0

   當前step/關節/EE/camera/snap訊號約定

   L130–175

---

3. `task/run_pick_place.py` ↗
   GitHub · rocochallenge/RoCo_TaskBoardAssembly · 45dd6ad6e0

   當前TaskBoard具體位置/snap判分與per-part輸出

   L493–515 · L552–653

---

4. `README.md` ↗
   GitHub · rocochallenge/RoCo_BrickAssembly · 8e7ad4dae6

   第二屆brick場景、23D控制及禁止runtime privileged訊號

   L1–90

---

5. `src/rocobrick/task_config/Task.py` ↗
   GitHub · rocochallenge/RoCo_BrickAssembly · 8e7ad4dae6

   type1/type2結構/初態與topology解析

   L21–83

---

6. `run/main.py` ↗
   GitHub · rocochallenge/RoCo_BrickAssembly · 8e7ad4dae6

   執行到policy完成；完整grading未在此入口彙總

   L1–29

怎麼接入我們的benchmark

可重用

原文3種assembly/recovery情境，以及新devkit清楚的observation/action/part-target契約作延伸參考。

需要轉換

source明確分AAAI2026與IROS2026 editions；task/instance/scorer各綁版本，原作weighted score保持原協定；新9part和brick規則只在對應來源比較。

仍需補齊

第一屆有效code/data入口、原作初態/GT/evaluator；新Brick完整評分接線與privileged input隔離；各edition獨立baseline與真實物理驗證。

P211 · AssemblyGrid

AssemblyGrid v1: A Benchmark for Multi-Robot Production with Temporary Coalitions, Local Information, and Geometric Constraints

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

AssemblyGrid提供明確的問題/instance/schema與KPI，可借鏡標準化設計；其canonical環境是無量綱任務層幾何，不能直接當接觸式robot物理操作。

> **版本與身份**
>
> 固定3bb72dd；easy/medium/hard只在同family內排序。doc規則與core的legacy同名欄位須選canonical口徑，未執行training或simulation。

領域	裝配與生產作業
環境	official abstract-v1 geometry，tick無量綱；固定robot base/reach/payload及操作位置，沒有joint、grasp/contact或collision-free軌跡保證。UR10派生驗證是另一非canonical profile。
任務	Flow、Coalition、Concurrency各easy/medium/hard，共9官方scenario；recipe規定材料/先後/XOR選項/coalition角色。歷史Geometry及AG-*擴充tracks不直接加進官方9。
題數與資料	instance_definition儲存grid/topology、robot population、recipe、資源、demand、時間、合作、local資訊及generation_seed；演算法/執行seed另存。local proposal_support是聚合支援比例，不是free-form message或global可行性oracle。
評估方式	completion=delivered/spawned，throughput=delivered/ticks；delivered-only mean flow需連unfinished count看。restricted flow把未完成者截尾到目前t；batch_makespan只在batch全部完成時有效，generic makespan仍可回區域性值，不能混用。coalition成功分母committed+expired；utilization只對exact-capacity且有機會的狀態平均，approx upper bounds分開。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **3** workload families · 原文頁 12, 13
- **9** official scenarios · 原文頁 14
- **50** 每scenario held-out instances · 原文頁 20

- **270** MARL training runs · 原文頁 20

依這個順序讀

1. `README.md` ↗
   GitHub · Fouad-Bahrpeyma/AssemblyGrid_v1 · 3bb72ddc2f

   9個官方scenario與3family×3level

   L1–90

---

2. `docs/BENCHMARK_SPEC.md` ↗
   GitHub · Fouad-Bahrpeyma/AssemblyGrid_v1 · 3bb72ddc2f

   normative範圍、recipe有效性、local資訊、regime、KPI與統計單位

   L1–199

---

3. `Experiments/env/benchmark.py` ↗
   GitHub · Fouad-Bahrpeyma/AssemblyGrid_v1 · 3bb72ddc2f

   擴充tracks與instance hash欄位、canonical/legacy metric字典

   L74–112 · L149–204 · L264–310

---

4. `Experiments/env/core.py` ↗
   GitHub · Fouad-Bahrpeyma/AssemblyGrid_v1 · 3bb72ddc2f

   實際completion/flow/makespan、terminal/truncation及conditional KPI

   L925–955 · L995–1005 · L1465–1474 · L1797–1838 · L2310–2416

怎麼接入我們的benchmark

可重用

規範recipe/schema/semantic/realizability三層驗證、instance hash、訓練seed與execution seed分離、canonical KPI明確化。

需要轉換

source固定v1/abstract profile；task按recipe目標，environment按grid與geometry配置，case加generation/execution seeds與資訊契約；維持tick及抽象reach單位，實體秒/碰撞另驗證。

仍需補齊

官方instance全量manifest取得、neural candidate-slot/identity alias上限測試、與物理robot的適配/抽象誤差驗證、同seed範圍的基線。

P212 · ARB4WM

ARB4WM: An Adversarial Robustness Benchmark for World Models in Continuous Control

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

ARB4WM在既有DMC與Meta-World上加視覺攻擊/防禦評測；要儲存攻擊強度、時間視窗與底層task版本，不能把攻擊條件當成新物理任務。

> **版本與身份**
>
> 固定66ebc33；read-only核對，不執行對抗演算法或policy。MetaWorld-v3及conditional metric介面是此版具體行為，不等同所有Dreamer/MetaWorld標準協定。

領域	通用物件與機動作業、居家整理與清潔、餐飲與烹飪
環境	DeepMind Control Suite vision與Meta-World visual manipulation，MetaWorld wrapper使用MT1(name-v3)及train_tasks[0]。source/backend/seed需保留，不把同底層task的五種attack objective當新環境。
任務	4種Dreamer-family模型、policy/value/latent/RSSM等目標與temporal/full/partial攻擊是評估條件。動作任務仍來自父benchmark。
題數與資料	sweep記epsilon/alpha/attack steps、optimizer、defense/adaptive模式、seed、task/model與run_tag；大型logs/checkpoints未包含。world-model image介面與attack前處理需一起固定，0–1/0–255尺度不能共用同數值epsilon。
評估方式	DMC主值為累積return，MetaWorld sweep明確取success rate；同名returns容器仍需標metric。影像SSIM/PSNR按data_range255且在defense前計算。SES用SR×(1–平均首次成功步/該batch觀察到的max steps)，不是固定budget正規化。clean Tester用eval_envs，attack建構收到train_envs，需核對paired seeds/環境；success_once與影像統計對已結束env的遮罩也需驗證。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **20** existing host control tasks · 原文頁 8
- **5** adversarial loss objectives · 原文頁 8
- **20** 每setting evaluation runs · 原文頁 8

依這個順序讀

1. README.md ↗
   GitHub · zaoanguai/ARB4WM · 66ebc330e6

   Dreamer系列、借用benchmark與release範圍

   L1–37

---

2. envs/metaworld.py ↗
   GitHub · zaoanguai/ARB4WM · 66ebc330e6

   MT1-v3/固定train task、reward/success/terminated與repeat

   L9–26 · L50–84

---

3. test_robustness.py ↗
   GitHub · zaoanguai/ARB4WM · 66ebc330e6

   clean/attack環境物件、epsilon sweep與MetaWorld/DMC分開取值

   L61–158

---

4. tester.py ↗
   GitHub · zaoanguai/ARB4WM · 66ebc330e6

   首episode masked return、success累積及conditional回傳

   L36–105 · L117–136

---

5. Attack/attacker.py ↗
   GitHub · zaoanguai/ARB4WM · 66ebc330e6

   攻擊後評估、image-quality metrics、success_once/步數與SES

   L15–48 · L76–191 · L200–248 · L345–362

怎麼接入我們的benchmark

可重用

父env wrapper、可重現attack配置/命名、原生return/SR/SES及影像差異分項。

需要轉換

case先繫結同父task/初態/seed，再加威脅模型/合法擾動budget；保留clean/attacked pairs、時間作用範圍、defense前後metrics及不同episode分母。

仍需補齊

checkpoint/原始campaign、clean-attack環境與seed對齊、active-episode masking、固定budget效率指標與完整攻擊規範重現。

P213 · Vision to Harvest

From Vision to Harvest: Benchmarking Vision-Language Models for Multi-Arm Robotic Fruit Harvesting

實作尚未確認 · 主來源 · 原作 · 獨立頁面

Vision to Harvest評估從果園影像生成多臂採收計畫；原文的harvested ratio與collision ratio是計畫幾何指標，不能當作實際採摘完成與碰撞感測結果。未確認官方GitHub。

> **版本與身份**
>
> 已讀2609.13606v1 p3/5與現有repository discovery；未確認source code或將相關harvesting/MIP工具當作本篇完整實作。

領域	農業與園藝
環境	兩份真實orchard RGB-D來源：Fuji apple與citrus；citrus父資料432張影像，論文再取heldout場景，未提供本次可取得的benchmark場景ID manifest。
任務	從初始canopy觀測分配水果及生成各Cartesian arm的順序/waypoints。作者明說online perception/replanning留待future work，因此屬觀測後計畫評測，不是完整閉環採果。
題數與資料	oracle採GroundingDINO/SAM2→depth投3D→DBSCAN→MIP分配/規劃；VLM用原始影像及workspace/robot constraints，輸出每臂JSON順序/waypoints，未提供定時軌跡。沒有公開reader/標註子集入口可核驗。
評估方式	五類原生指標為detection ratio、距離門檻內waypoint的harvested ratio、含x軸arm-order violation的scene比例、總路徑距離、tokens/scene。Verifier不修復計畫；碰撞定義是順序可行性proxy，沒有實際觸碰或水果detach驗收。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **2** crop types，非兩種生活domain · 原文頁 5

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

農業用途、原圖→多臂計畫的任務定義、原生空間可行性與效率指標。

需要轉換

case綁crop/scene/image-depth標定、arm配置/工作空間、固定prompt與距離門檻；將計畫品質和可執行物理採收分層，保留oracle與VLM合法輸入差異。

仍需補齊

官方code、heldout scene/GT清單、JSON parser/一對一水果匹配/ verifier與完整控制、動態feedback及真正採果驗收。

P214 · COIN（interactive）

Chain Of Interaction Benchmark (COIN): When Reasoning meets Embodied Interaction

實作尚未確認 · 主來源 · 原作 · 獨立頁面

此COIN是2026 Chain of Interaction，與P003的2019影片COIN不同。論文定義90個互動推理task及6類指標，但目前未確認官方GitHub。

> **版本與身份**
>
> 2604.16886v1；原文引用ERQA、MuJoCoAR等他作repo不是此COIN code。原作名稱同P003但題名/ID/資料皆不同，維持獨立source。
>
> P214=Chain Of Interaction (2026)；P003=COIN instructional video dataset (2019)。

領域	居家整理與清潔、餐飲與烹飪、通用物件與機動作業
環境	ManiSkill3/Panda桌面操作，PartNet-Mobility與其他物件資產；5個camera views與depth/segmentation/proprio是觀測設定，不是5環境。
任務	COIN-Primitive20、COIN-Composition20、COIN-50共50，合計90task。原作三種reasoning domains是物件中心、robot理解、組合推理，不直接當生活用途。VQA probes和子任務序列另有層級。
題數與資料	原文20primitive各50teleop demos共1000，不能當全90task都各50demo。兩action space：VLA delta EEF+gripper；CodeAsPolicy7joint absolute+gripper。完整case/split、teleop原檔及scorer尚未取得。
評估方式	原文SR、CSR、VQA score、trajectory stability(TS)、gripper stability(GS)、GCS=SRcomposition/SRprimitive；TS使用速度/加速度/jerk變異係數的指數分項，GS有預期切換次數等依賴。缺code時不能核對零分母、取樣頻率與穩定性實作，也不能把TS/GS當物理安全。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **90** task definitions across three suites · 原文頁 4
- **1,000** Primitive demonstrations · 原文頁 5
- **10** SR evaluation trials · 原文頁 7

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

90task三層設計、部分可觀測互動、兩種policy動作介面與6類原作指標。

需要轉換

task維持原生20/20/50集合；case分清操控、subtask planning與VQA，固定camera/segmentation是否合法、action轉換和score版本；新規則另列衍生關係。

仍需補齊

官方repo/全部task與示範/合法split、動作轉換、TS/GS/GCS精確grader與原生baseline。

P215 · World-model evaluation survey

Do World Models Make Better Robots? A Survey of Evaluation Benchmarks for Predictive Embodied Intelligence

實作尚未確認 · 方法 / 綜述 · 原作 · 獨立頁面

這篇綜述以160個評測artifact建立四類evaluation lane，適合補方法論與查漏；它排除純資料/模型，因此不能直接和我們183份含資料來源的總庫比篇數。未確認配套GitHub。

> **版本與身份**
>
> 已讀2609.29669v1 p4/5/7；以上比例是該survey報告的分佈，未冒稱本輪已重建/驗證全部160項分類。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	跨policy、embodied-agent、world-model evaluation與prediction-to-action bridge；這些是研究評估分類，非4種應用環境或生活domain。
任務	作者160benchmark中選86代表項進主taxonomy；lane數為37policy、85embodied、34world-model、4bridge。這是該survey自訂單位/範圍的統計，不新增160組我們已取得的task。
題數與資料	其criterion包含有scoring protocol的dataset或有task distribution的interactive environment，排除純datasets/models/simulators；名單及reference不代表作者下載了所有資產或跑過所有模型。
評估方式	作者按open-loop43、closed-loop113、bridge4分類；另有VLA-vs-world-model對照explicit11、partial11、agnostic138，是不同軸。11不是bridge數。可借鑑同一budget/task/observation下比較直接policy和world-model policy，而非用影片品質推論控制增益。

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

明確inclusion/exclusion、paper-ID去重、原作計數單位與預測→控制證據分層。

需要轉換

將其160項作後續查漏線索並與本庫source ID對映；沿用本庫183來源/67參考口徑。文獻taxonomy和任務/環境ontology分開，未審查的新線索不算完成收錄。

仍需補齊

配套machine-readable catalogue/code確認、對160項逐條原作交叉核驗、真正matched-policy實驗與來源case資料。

P216 · HAP

HAP: A Hand-Driven Active Perception Framework for Egocentric Head Motion Prediction

檔案 / 網站 · 主來源 · 原作 · 獨立頁面

HAP官方GitHub目前只有接受後公開的承諾。原文可提供hand-driven head-motion prediction的格式與評估參考，但沒有可核讀的模型/資料處理實作。

> **版本與身份**
>
> 固定525d603 README6行；原作2609.18548明說code will be released。未因repo存在就計為核心程式已公開。

領域	穿戴互動與動作介面
環境	EgoPAT3Dv2與新增Bottle的ego RGB-D；Bottle382clips來自12sessions，10train/1val/1test。session不是直接可執行robot environment。
任務	以觀測手部motion、target intention與occlusion context預測未來6-DoF頭部運動；不是已完成robot active-camera control或grasping benchmark。
題數與資料	原文用camera motion作head proxy，DA3估計/平滑、另以ORB-SLAM3對照；9D輸出含translation與rotation representation。Bottle手/物件由視覺模型和depth處理，需保留estimated標記、split與觀測視窗。
評估方式	四指標tADE/tFDE(毫米)、rADE/rFDE(SO3 geodesic角度)。不同pose-estimation backend、平滑/觀測長度/預測horizon必須固定；沒有code時不能確認causal preprocessing或masked未來步的計分。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **382** Bottle clips · 原文頁 5
- **12** recording sessions · 原文頁 5
- **1** held-out test session · 原文頁 5

依這個順序讀

1. `README.md` ↗

   GitHub · HAP-ego/HAP · 525d603983

   目前只承諾paper接受後發布程式/重現資料

   L1–6

怎麼接入我們的benchmark

可重用

Bottle session split、6DoF/9D表示、角度/位置分項誤差與遮擋條件。

需要轉換

case儲存camera/head proxy來源、hand/object annotation方法、observed prefix/horizon/有效未來mask；head motion prediction與控制攝影機效益另分evaluator。

仍需補齊

公開implementation、Bottle clip IDs/annotations、表示/尺度/clock與scorer、causal feature處理及基線重現。

P217 · TRS + RVG

Reliable Egocentric Action Anticipation via Temporal Reliability Suppression and Compositional Graph Decoding

實作尚未確認 · 主來源 · 原作 · 獨立頁面

TRS+RVG在既有EGTEA/EPIC feature pipeline上研究缺幀/噪聲魯棒預測；原文特別說明其EPIC標籤和split與官方榜單不同。未確認官方code。

> **版本與身份**
>
> 已讀2609.13293v1 p6–7；本文processed EPIC index space與官方taxonomy不同，不把其125/352當EPIC官方類別數。cachedTRS/RVG題名搜尋未確認code。

領域	餐飲與烹飪
環境	既有EGTEA Gaze+、EPIC-KITCHENS影片/預抽TSN features；新增的是feature corruption與解碼協定，不產生新物理場景。
任務	下一verb–noun joint action預測；TRS處理temporal可靠度、RVG用training-label compatibility graph重排組合。19×51=969候選scores不是969種實際觀測task。
題數與資料	原文EGTEA19verbs/51nouns/106actions、processed split1共10321clips；EPIC pipeline125verb/352noun indexes且public-train videos再90/10 video-disjoint分割，明說不能與official97/300榜單直接比較。input為10個1024D TSN tokens，非直接對raw pixels加噪。
評估方式	joint top1要求verb與noun同對；AvgC跨corruption平均、RR=100×AvgC/clean accuracy應連同絕對accuracy看。PMI graph只用training labels，weight由EGTEAval校準後移到EPIC；高強度mask/drop等作用於6/10tokens，缺code還需核定具體indices與seed。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **6** main temporal corruption conditions · 原文頁 7

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

原文corruption定義、training-only graph、native feature label space及group metrics。

需要轉換

source關聯原EPIC/EGTEA；case固定feature提取器/hash、clip/observed timestamps、corruption mask/seed與label vocabulary；official和within-pipeline兩種結果分表。

仍需補齊

官方repo/features/split ID與graph資料、精確corruptor/scorer、missing/zero-denominator處理與同協定基線。

P218 · TrajPilot

How You Move Tells What You'll Do: Trajectory-Conditioned Egocentric Prediction

檔案 / 網站 · 方法 / 綜述 · 原作 · 獨立頁面

已核對 arXiv:2605.20388v1、作者專案頁及同實驗室 TrajPilot 候選庫；固定版本的完整檔案樹只有一行 README，沒有 data reader、模型或 metric 實作。以下任務與協定來自論文，不能視為已完成程式評測整合。

> **版本與身份**
>
> 固定 repo commit 85afac4ae7a800fc104a4499c349b09979c34941 的完整樹只有 README.md；未將作者網頁算成模型程式。論文附錄稱 atomic/Keystep 等使用 validation takes，但結果表稱 test split，需保留原文標示差異並取得 manifest 才能對齊。Aria pose 與 RGB估計 PI3 的 oracle 條件也不可混同。
>
> 論文題名 How You Move Tells What You'll Do: Trajectory-Conditioned Egocentric Prediction，作者 Sejoon Jun、Hai Nguyen-Truong、Luigi Seminara、Lorenzo Torresani。PDF 連到 farsightlab.github.io/TrajPilot，頁面題名、作者與 arXiv ID 一致；farsightlab/TrajPilot 與該專案共用名稱空間，但公開 README 只有名稱，專案頁未提供可核驗的方法程式連結。排除搜尋中的 mimozing3003/TrajPilot-AI-Autonomous-Driving-Research-Platform：它描述自動駕駛，與本篇論文不符。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	離線人類第一人稱影片：Ego-Exo4D atomic / Keystep、Ego4D GoalStep、EgoPER，另做 EPIC-KITCHENS-100 anticipation 與 Ego-Exo4D 籃球投籃結果分類。相機運動是觀測 / 條件訊號，並非可直接執行的機器人控制。
任務	分開記錄提供 start+goal 的程式規劃、移除 goal 的未來動作預測，以及 made / missed 二分類。規劃 horizon H=3–8 是動作序列長度；8,472 個 atomic 文字標籤、1,165 類 closed collapse、375 個 Keystep 標籤、310 個 GoalStep 標籤和57個 EgoPER 標籤均為各自詞彙表，不能加總成任務數。Scorer 使用訓練集候選未來軌跡，Oracle 使用實際未來軌跡，兩者資訊條件分開。
題數與資料	論文附錄 A.1：atomic 為 take-disjoint 的140,413 train segments / 2,237 takes 與11,425 validation segments / 312 takes；連續 segment 形成 H=3–8 windows，但未提供公開 window manifests。每段16張 RGB，384×384，V-JEPA 池化為1664維特徵；atomic 區間以相鄰時間戳中點決定，其餘以標註區間中點與邊界取樣。Aria 或 PI3 相機姿態對齊影片時間並轉成相對 [Δx,Δy,Δz,Δrx,Δry,Δrz]，旋轉為 rotation vector；實際 tensor schema、尺度 / 單位與插值實作未公開。籃球子集294 train / 74 test events、42 / 10 takes，test 為37 made+37 missed；模型僅看平均1秒的出手前片段，16張取樣自30 fps來源影片。

評估方式	沒有具體 metric/scorer 程式可讀。論文區分 middle-step R@1/5 與 full-sequence R@1/5，MSeq/FSeq 為整段全對比例；Full 包含觀測端點，Future 不含 observed Start。Closed-vocabulary 另報 Mid/Full mAcc、exact-sequence SR、mIoU、Levenshtein，實際 macro/micro、重複標籤與跨 horizon 權重須等程式確認。EK100 的 verb/noun/action 為 mean-class Recall@5，另列 instance accuracy；籃球 accuracy 分母為74個事件，balanced accuracy 為兩類 recall 平均，各類 recall 分母37。模型內部 Scorer 的候選排序 / fallback 不是 benchmark 成功判定，不能取代 evaluator。

依這個順序讀

1. `README.md` ↗
   GitHub · farsightlab/TrajPilot · 85afac4ae7

   確認公開 pinned repo 只有名稱，沒有 data / task / metric 程式。

   L1–1

怎麼接入我們的benchmark

可重用

重用論文所界定的來源資料集、take 層級 split、原生動作詞彙與規劃 / anticipation / outcome 任務分類；repo 僅可重用身份與版本證據。

需要轉換

source 連回各母資料集；case 以 take_id+segment/window+H+split+詞彙版本識別，儲存 start/goal 可見性與 No-Traj / Scorer / Oracle。camera_pose 另存來源 Aria/PI3、時間軸與相對6DoF格式；evaluation 分列 step retrieval、sequence exact match、class recall、event accuracy及其分母。

仍需補齊

公開 reader、window / label-bank manifests、軌跡取樣與單位、實際 scorer/gating 和全部 metric 實作；尚不能核驗論文指標或形成可執行套件。

P219 · FROST-STA

FROST-STA: Frozen Dense Features for the Ego4D Short-Term Object Interaction Anticipation

實作尚未確認 · 方法 / 綜述 · 原作 · 獨立頁面

核讀 FROST-STA 五頁 primary PDF 與既有 discovery/search 後，受限的精確 repo 查詢仍未確認作者程式庫。可記錄 EgoVis 2026 的 Ego4D STA 方法與論文協定，沒有 pinned reader、decoder 或 evaluator 可以冒稱已核讀。

> **版本與身份**
>
> 本次bounded discovery：cached「FROST STA」有145筆候選、快取前8筆均非本篇；新增GitHub「"FROST-STA" in:name,description,readme」有49筆，只核對返回前5筆，皆不相關；「"2606.00694" in:readme」為0筆。另一次限定GitHub與作者名的網頁查詢未返回結果。這表示本輪未確認公開庫，不能推論所有49筆均核讀或repo絕對不存在；本輪補查HTTP均200，沒有將429/defer當成不存在。
>
> 精確論文為 FROST-STA: Frozen Dense Features for the Ego4D Short-Term Object Interaction Anticipation，Chaoyang Wang、Lexuan Xu，Beihang University，arXiv:2606.00694v1（2026-05-30）。sun0710 是論文中的挑戰賽參賽名稱，並未提供可驗證的 GitHub 身份。V-JEPA 2.1、StillFast、AFF-ttention 與 VISTA 是引用 / 基礎方法，不能代替 FROST-STA 官方庫。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	Ego4D 未裁切人類第一人稱影片；query 時刻之前的短片及最後觀測影格。下一 active object 定義包含手直接接觸或透過手持工具接觸的物件；不提供機器人互動環境。
任務	每個 query 輸出排序的 (active-object box, noun, verb, time-to-contact, confidence) 假設。這是同一 Ego4D STA benchmark 上的方法參考，非新增獨立資料庫或一組可執行操作技能。
題數與資料	論文 §2.1：取 query 前0.5秒內8張影格，影片分支resize為384 pixels；最後觀測影格resize為1080 pixels，為框定位參照。TTC 使用秒。§3.1 使用官方 train 加挑戰賽允許的 validation annotations 訓練25 epochs，並未另報獨立 validation benchmark；八個 heads 及epoch15–25 checkpoint合併。實際 annotation鍵名、frame index邊界、resize逆對映、去重、split ID與樣本數沒有 reader / manifest 可核。
評估方式	僅論文 §3.2：Top-5 mAP，框匹配寫為 IoU>0.5；Noun檢查noun，Noun+Verb加入verb，Noun+TTC加入|TTC誤差|<0.25秒，Overall同時要求全部條件。論文報告的5.13是官方test server返回的Overall Top-5 mAP，非本輪執行結果。具體AP插值、Top-5對每query/GT的預算、每類GT分母、空GT / 遺漏query處理、邊界採>或≥及macro平均均無本篇實作可查；不能借用其他STA repo便宣稱它們一致。

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

重用已核對的論文身份、Ego4D依存關係、五元組輸出及論文明列的輸入視窗、train+permitted-val條件與指標名稱。

需要轉換

以source→Ego4D STA方法關係建檔；每query為case，保留box座標參照、noun/verb taxonomy版本、TTC秒、confidence排序與head/checkpoint預算。論文結果單列paper_reported_test_server，將訓練使用的validation與可獨立評測split分開。

仍需補齊

可由作者primary source確認的repo及40位revision、annotation / split reader、模型輸出序列化、合併程式與完整metric實作；在取得前維持paper-only整合狀態。

P220 · VISTA（Ego4D STA）

VISTA: Technical Report for the Ego4D Short-Term Object Interaction Anticipation at EgoVis 2026

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

已核讀精確VISTA repo的STA reader、split設定、submission序列化與具體Top-5 mAP程式。公開train設定使用train+大部分val，僅24個holdout且每次只跑1個batch的proxy；最終ensemble預設version 2.0，庫內scorer卻只接受1.0，整合時須顯式處理。

> **版本與身份**
>
> 讀取commit 62e39d137426e12f30fe4efd12122f8c188b4b33。初始prediction writer回傳version 1.0；dynamic_metric_head_ensemble與包裝shell預設最終version 2.0，而本地validate_results_json拒絕非1.0。ensemble/proxy使用無+1的連續IoU，scorer使用+1畫素IoU；ensemble的IoU匹配可含0.5，scorer嚴格>0.5；論文寫TTC<0.25，程式為≤。README的scaffold稱呼不代表只有README，亦不代表已完整重現官方submission。
>
> arXiv:2605.20901v1，Qiaohui Chu等人的 VISTA: Technical Report for the Ego4D Short-Term Object Interaction Anticipation at EgoVis 2026，PDF第1頁直接指向CorrineQiu/VISTA；README與8張2FPS影片、Faster R-CNN still branch、四prediction heads相符。不是其他同名VISTA專案，也不是FROST-STA。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	Ego4D v2人類第一人稱影片之STA query；資料被預先拆成train / val / test_unannotated sample directories，每例含短片歷史影格與最後高解析影格。沒有robot rollout或simulation場景。
任務	預測每個query下一互動的active-object box、noun、verb、TTC及score；一例可有多個GT物件。類別不是固定新任務清單：build_label_maps_from_roots掃train+val中有效noun/verb ID，排序重編成連續index，輸出時再還原；須保留mapping與母資料taxonomy版本。
題數與資料	reader掃排序後的label.json，讀uid、split、video_uid、frame、observation.history_frames[*].file與last_history_frame_highres_file；GT優先future_prediction_target.objects，fallback raw_annotation.objects，讀box_xyxy/box/bbox、noun_category_id/noun_id、verb_category_id/verb_id、time_to_contact/ttc。train/val排除空標註與所有框無效的樣本；test仍需label.json但不要求GT。history_frames保留既有順序，超過8取最後8，不足8以前端第一張補齊，並不在reader內由fps重建時間戳。論文/設定為8張2FPS、影片384×384；still short-side train640–800、eval800，max1333。框隨影像縮放，dump依orig_size還原xyxy畫素，TTC秒不縮放；可改讀split/uid.pt的1664維JEPA cache。train_include_val=true時以有效樣本排序後前24個作holdout，其餘val併train，並非take-disjoint的新split。

評估方式	run_official_metric_only.py是真正本地scorer：以uid對齊，CLI要求所有GT uid都有results（可空list）；無GT物件的query不入評分。IoU面積使用(x2-x1+1)(y2-y1+1)，框須IoU>0.5，TTC條件為絕對誤差≤0.25秒。每query按score貪婪一對一匹配各metric的GT；Top-5不是截前5，而是每個metric忽略排序前4×該query GT數的FP。Noun / Noun+Verb / Noun+TTC / Overall皆按noun類別分組：recall分母是全評測集中該noun的GT物件數，AP以precision envelope對recall積分乘100，再只對出現GT的noun做macro平均。compute_proxy_hits則只查score前5，只要任一GT匹配就給該query一個hit，分母為batch中有GT的query；eval.py以batch size加權再跨rank平均，與mAP不同。預設train max_val_batches=1、run_official=false、best_metric_source=proxy；test設定只產生每head最多100個hypotheses，四headensemble再保留100。論文5.40為test server結果，本輪未重跑或證明本地Lite實作與server完全等價。

依這個順序讀

1. `README.md` ↗
   GitHub · CorrineQiu/VISTA · 62e39d1374

   核對精確EgoVis 2026 STA方法、資料依存與公開評測入口。

   L1–22 · L69–77 · L95–103 · L158–188 · L197–223

2. `configs/vista_train.yaml` ↗
   GitHub · CorrineQiu/VISTA · 62e39d1374

   固定train+val、24個holdout、8-frame輸入、proxy驗證與四prediction-head設定。

   L19–40 · L58–110

3. `configs/vista_test.yaml` ↗
   GitHub · CorrineQiu/VISTA · 62e39d1374

   test_unannotated、完整推論dump及top100輸出預算。

   L19–40 · L58–106

4. `evals/vista_sta/dataloader.py` ↗
   GitHub · CorrineQiu/VISTA · 62e39d1374

   實讀label-map來源、validation前24個holdout、其餘併入train及DataLoader分母。

   L15–114 · L139–182

5. `evals/vista_sta/ego4d_sta.py` ↗
   GitHub · CorrineQiu/VISTA · 62e39d1374

   追到label.json欄位、歷史影格pad、類別重編碼、過濾與box/image座標。

   L84–148 · L171–203 · L258–335 · L436–496 · L512–625 · L664–776

---

6. `evals/vista_sta/losses.py` ↗
   GitHub · CorrineQiu/VISTA · 62e39d1374

   區分top5樣本hit proxy與AP；核對原始畫素框逆縮放及submission序列化。

   L10–20 · L68–150

---

7. `evals/vista_sta/eval.py` ↗
   GitHub · CorrineQiu/VISTA · 62e39d1374

   追到batch proxy彙總、head選擇、scorer呼叫與test停用本地GT評分。

   L637–640 · L704–718 · L772–843 · L854–875 · L1321–1346

---

8. `evals/vista_sta/utils.py` ↗
   GitHub · CorrineQiu/VISTA · 62e39d1374

   確定run_official_evaluator只是subprocess包裝，需另讀具體計分程式。

   L230–258

---

9. `evals/vista_sta/run_official_metric_only.py` ↗
   GitHub · CorrineQiu/VISTA · 62e39d1374

   核對+1畫素IoU、TTC邊界、greedy匹配、4×GT之FP額度、noun-class AP分母與version檢查。

   L11–15 · L71–144 · L190–345 · L376–428

---

10. `evals/vista_sta/dynamic_metric_head_ensemble.py` ↗
    GitHub · CorrineQiu/VISTA · 62e39d1374

    核對noun/verb/IoU/TTC合併、head權重與輸出version 2.0，不將ensemble當metric。

    L23–150 · L153–362

---

11. `scripts/ensemble_vista.sh` ↗

    GitHub · CorrineQiu/VISTA · 62e39d1374

    最終四head包裝命令未覆寫ensemble的version 2.0預設。

    L1–22

怎麼接入我們的benchmark

可重用

重用STASampleDirItem及label.json reader、noun/verb雙向map、UID submission schema、具體STAMeanAveragePrecisionLite與head ensemble引數，保留其來源commit。

需要轉換

case鍵為Ego4D版本+split+uid，video_uid/frame另存；框保留原影像畫素xyxy、orig_size與resize比例，時間以TTC秒與實際history-frame序列描述。evaluator分開記proxy query-hit與noun-macro Top-5 mAP，儲存FP-budget=4×GT、IoU+1、比較邊界與head/top100預算。

仍需補齊

原始影片至sample label.json的可驗證製作流程、實際manifest/hash與frame時間戳仍需補齊；未取得資料、features、weights，無法報有效case總數。需固定24個holdout身份並按完整benchmark split評分；須對齊ensemble version 2.0與scorer要求1.0、以邊界例核驗本地scorer/server差異，不能只改字串便宣稱等價。

P221 · STAformer++

Integrating Affordances and Attention models for Short-Term Object Interaction Anticipation

實作尚未確認 · 方法 / 綜述 · 原作 · 獨立頁面

P221精確論文連到作者AFFttention庫，但pinned版本停在2024年；已實讀舊版STA reader與metric，尚無法把它核定為2026 STAformer++的完整實作。入口雖引用DETR，但必要模組不在完整樹中，且新版Swin-T/EgoVideo/DETR配置未對上。

> **版本與身份**
>
> 固定commit 1a1253fa2bde09ef1de4894f3bf872c1fbf270de，日期2024-07-15；2026論文§4是明確架構延伸。完整tree未truncated，因此缺失的DETR/hand模組不是快取挑檔漏抓。README要求依StillFast配置，程式仍import stillfast但目錄叫stillfast_code，另有硬編碼本機/省略號路徑；只能主張已讀具體舊版程式段，不能主張新版可重現。
>
> 論文為 Integrating Affordances and Attention models for Short-Term Object Interaction Anticipation，Lorenzo Mur-Labadia等，arXiv:2602.14837v1；P221-discovery保留PDF第1、9頁指向Imur98/AFFttention的超連結。這是2024 AFF-ttention的延伸，作者與repo關聯已確認；未確認的是2026新版方法與公開程式版本的一致性。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	離線Ego4D STA v1/v2及由EPIC-KITCHENS active-object tracks/action segments衍生的STA影片標註。environment affordance為歷史影片相似場域的noun/verb先驗，並非互動模擬器或新機器人場景。
任務	每query輸出(box,noun,verb,TTC,score)，另利用environment affordance及interaction hotspot調整預測。論文新增STAformer++的Swin-T、EgoVideo、DETR與learned affordance integration，不能只因同一repo有字樣就視為已公開可執行；舊版配置是Dino2D_with_EgoVLP、ROI_HEADS.VERSION=aff。論文EPIC-STA的33,804 train / 7,055 val是衍生標註instances，104 noun / 51 verb是taxonomy，不是新增robot tasks。

題數與資料	Ego4D reader依TRAIN/VAL/TEST_LISTS讀info.video_metadata及annotations；每例uid、video_id、frame、objects[*].box/noun_category_id/verb_category_id/time_to_contact。v2配置指向v2資料，但活躍讀取仍用video_id、video_uid行被註解，需明確版本適配。fast clip以frame-arange(N×stride)[::-1]取歷史，負索引夾到0；配置N=16、stride=1，不能未讀metadata就假設FPS。noun+1，非v1 ROI verb+1；writer再減回。AFF檔以v_id/frame尋找AFF_N_top3、AFF_V_top3，找不到用全1先驗。EPIC pkl為eid、video_id、timestamp、objects內平行arrays；合併noun群組、剔除含others的整例及指定verb後重編ID。EPIC框被乘(1920,1080,1920,1080)，影格int(timestamp×30+1)，16張含當前影格、最低1；AFF卻以round(timestamp×30)+2查詢，兩個frame convention不可混同。test分支直接讀val_annotations.pkl，不能列成獨立test split。
評估方式	STATask.validation_epoch_end先以uid建dict（重複UID會覆寫），再呼叫OverallMeanAveragePrecision(top_k=5)，輸出8個class-agnostic AP及4個按noun平均的mAP。匹配為+1像素面積IoU>0.5、TTC誤差≤0.25秒及各項noun/verb條件，按score貪婪一對一配GT；每query、每metric忽略前4×GT物件數個FP。recall分母是已加入GT中的相應類別物件數；AP為VOC precision-envelope積分×100，mAP預設僅平均有GT的noun，不按noun-verb joint class平均。需保留程式缺陷：add的空preds={}分支再次判斷len(preds)>0，因而不加入GT；空array字典與真正空字典行為不同，不能宣稱未檢測案例分母已安全處理。Ego4D _load_annotations對無objects例還會造出[0,0,100,100]及零標籤dummy target，不能拿test-unannotated當validation真值。

依這個順序讀

1. `README.md` ↗
   GitHub · lmur98/AFFttention · 1a1253fa2b

   確認公開庫仍介紹2024 AFF-ttention / STAformer、外部affordance資產及StillFast依存。

   `L3–14` · `L25–51` · `L55–78`

2. `stillfast_code/models/stillfast.py` ↗
   GitHub · lmur98/AFFttention · 1a1253fa2b

   核對實際FasterRCNN入口、DETR未完成分支及匯入但不在pinned tree的模組。

   `L1–30` · `L73–128`

3. `stillfast_code/test_dir/Aff_ttention_v2/config.yaml` ↗
   GitHub · lmur98/AFFttention · 1a1253fa2b

   確認16影格stride1、v2 taxonomy、ROI aff head與split配置。

   `L13–35` · `L39–76` · `L114–120` · `L142–162`

4. `stillfast_code/datasets/ego4d_sta_still.py` ↗
   GitHub · Imur98/AFFttention · 1a1253fa2b

   讀annotations/videos結構、train清理、video_id/v2差異、dummy GT與類別offset。

   L22–82 · L102–153 · L232–258

---

5. `stillfast_code/datasets/ego4d_sta_still_video.py` ↗
   GitHub · Imur98/AFFttention · 1a1253fa2b

   固定歷史frame索引、AFF_N/V_top3 sidecar及輸出targets。

   L9–17 · L72–110 · L168–226

---

6. `stillfast_code/datasets/ek_55_sta_dataset.py` ↗
   GitHub · Imur98/AFFttention · 1a1253fa2b

   核對EPIC分類合併/剔除、pkl split、30FPS、框乘1920×1080與affordance時間偏移。

   L79–116 · L138–213 · L224–256 · L260–405

---

7. `stillfast_code/models/faster_rcnn_AFF_sta.py` ↗
   GitHub · Imur98/AFFttention · 1a1253fa2b

   確定已公開的affordance是sidecar prior乘softmax後正規化，並非完整新版learned memory實作。

   L209–243 · L364–405 · L423–489

---

8. `stillfast_code/tasks/sta.py` ↗
   GitHub · Imur98/AFFttention · 1a1253fa2b

   核對UID聚合去重、OverallMeanAveragePrecision(top_k=5)及submission offset逆對映。

   L44–90 · L94–193

---

9. `stillfast_code/evaluation/sta_metrics.py` ↗
   GitHub · Imur98/AFFttention · 1a1253fa2b

   讀具體matching、FP容忍預算、AP分母、macro noun averaging及空預測處理缺陷。

   L1–205 · L215–266 · L268–359 · L416–524

怎麼接入我們的benchmark

可重用

可重用已核讀的舊版Ego4D/EPIC reader規格、noun/verb offset、affordance sidecar schema與原生AP/mAP定義，標成AFF-ttention 2024 lineage；論文2026方法另存版本關係。

需要轉換

保留source→Ego4D/EPIC衍生標註關係；case使用版本+split+uid/eid，區分原annotation、清理後有效case與taxonomy。顯式對映EPIC normalized xyxy→1920×1080畫素、timestamp→影格及獨立AFF lookup frame；保留noun合併/剔除表、background offset、FP-budget及AP vs noun-macro mAP。

仍需補齊

新版STAformer++正確revision與Swin-T/EgoVideo/DETR/learned-affordance完整實作；pinned tree缺少入口匯入的detr_criterion.py、detr_backbone.py、detr_transformer.py、detr_matcher.py及ego4d_sta_hands_still_video.py，DETR_head也未在入口定義。另缺正式annotation/sidecar資產與portable路徑、v1/v2欄位適配、EPIC雙frame偏移核驗及空預測/無GT的計分測例。

P222 · Uni-Hand

Uni-Hand: Universal Hand Motion Forecasting in Egocentric Views

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

已核讀Uni-Hand human-video demo與作者指向的MMTwin/EgoPAT3D reader及具體ADE/FDE。主庫現行流程只以首影格條件預測右手腕與接觸轉換；不能將論文全部2D/3D、多關節、head-motion及robot結果視為同一套已公開評測。

> **版本與身份**
>
> 主庫commit 7f3edd5955fcb786b78b343510d7b2297694393b；MMTwin commit bd0faf148ae574accd5a4c1e7cd173f6416a52e6。README稱toy有100段影片，而本版split roster是100 train+5 test，保留此粒度/版本差異。主庫unseen_envs已標deprecated且兩個test loader讀同檔；MMTwin的test_novel才是實際不同scene split。論文表1的USST修正引用不能視為本輪已核讀或新版metric等價證明。
>
> arXiv:2511.12878v4（2026-05-11），Junyi Ma等，精確題名Uni-Hand: Universal Hand Motion Forecasting in Egocentric Views。PDF連作者專案頁，頁面Code指IRMVLab/UniHand、Data指IRMVLab/MMTwin；MMTwin README反向指Uni-Hand為extended version，本身論文為2504.07375。專案頁footer的nerfies是網頁模板，論文USST erratum是baseline依存，均非本篇模型庫。

領域	穿戴互動與動作介面、通用物件與機動作業、居家整理與清潔、餐飲與烹飪
環境	主庫為RealSense L515人類示範的pick-and-place / open-door場景，首RGBD影格產生固定相機座標點雲；MMTwin用EgoPAT3D-DT移動頭戴視角，以odometry將軌跡表成首camera參照。CABH的cup/apple/box與HAT robot-transfer屬論文/前身不同子集，不可和主庫toy split混成獨立robot environment registry。
任務	Uni-Hand論文涵蓋手部2D/3D中心與指定關節、head motion及contact/separation；本次主庫實際epoch loop取joint0，註明TODO multi-finger，preprocess只讀right_keypoints；motion_feat為全零，視覺使用第一張feature，觀測mask只保留第0個手腕點。輸出是未來腕點與兩個接觸/分離峰，非完整21關節姿態，也不是可直接執行的末端action。

題數與資料	主庫以date folder讀traj3d_in_cam_dict_refine.pkl、date.npy視覺特徵、rgb數字檔名與date_folders.csv。所謂traj3d原始值實為21×(u畫素,v畫素,depth-mm)；reader對depth除1000、u/w與v/h、z/max_depth後各減0.5，保留有效frame IDs，截/零補至40。CSV兩個原始frame ID映到有效序列的0-based index；沒有FPS/秒換算。config為1280×720、max_depth=1、50^3 voxel、0.02公尺格、origin[-0.5,-0.5,0]。split檔有100 train與5 test唯一ID且無交集；它們是清單筆數，未下載素材核驗有效case。val/test/test_novel全部走同一test_split.txt。MMTwin則有明列scene/record train/val/test；novel scenes13/14/15，pkl讀traj2d/traj3d/num_preserve，最多40點，3D以odometry連乘轉首camera，再以(u/w,v/h,z/3)-0.5編碼，非train的未來motion/odometry先以最後觀測值替代。
評估方式	主庫實際scorer在epoch_feat.py：單次diffusion sample，gap=1、3點moving-average平滑；加回0.5並以內參反投影XYZ，z使用預設max_depth=1，單位公尺。future slice=[1,nframes)，ADE先對該case所有有效未來點的Euclidean error取平均，FDE只取最後有效點，最後對case平均，非全資料逐frame加權。CE將future contact曲線Gaussian平滑、取最高兩個區域性峰並排序，兩個峰的絕對index誤差平均後再跨case平均；缺峰用-1補而未剔除。存在明確索引疑點：pred峰是future slice相對index，GT是完整valid序列index，scorer未加start_=1或減GT offset，CE不是可直接當秒的MAE。MMTwin actual loop用固定ratio（預設0.6），floor(nframes×ratio)作觀測長度，單次sample；相同逐case ADE/FDE，test_space=3d為公尺，其他值走投影、clip/floor畫素再除影像尺寸的2D距離，並非best-of-K。論文robot SR為每task 10次trial的報告；已讀repo沒有該robot成功checker。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **3** CABH interaction tasks · 原文頁 9
- **5** HAT robot tasks · 原文頁 10
- **1,200** CABH videos · 原文頁 9
- **50** HAT physical trials，5×10 · 原文頁 10

依這個順序讀

1. `README.md` ↗

   GitHub · IRMVLab/UniHand · 7f3edd5955

   確認Uni-Hand主庫的human-video demo範圍、MMTwin前身關係與heuristic grasp。

   `L1–27 · L116–140 · L193–199 · L236–261 · L279–326`

2. README.md ↗

   GitHub · IRMVLab/MMTwin · bd0faf148a

   確認MMTwin/EgoPAT3D/CABH資料角色，CABH專用模型程式仍標示待發布。

   L5–35 · L161–184 · L194–216

---

3. unihand/configs/traineval.yaml ↗

   GitHub · IRMVLab/UniHand · 7f3edd5955

   固定相機內參、depth尺度、40影格、split、gap與平滑預算。

   L1–63

---

4. unihand/data_utils/train_split.txt ↗

   GitHub · IRMVLab/UniHand · 7f3edd5955

   實讀100個唯一train roster ID，與test比較無交集。

   L1–100

---

5. unihand/data_utils/test_split.txt ↗

   GitHub · IRMVLab/UniHand · 7f3edd5955

   實讀5個唯一test roster ID；這不是5個task。

   L1–5

---

6. unihand/data_utils/date_folders.csv ↗

   GitHub · IRMVLab/UniHand · 7f3edd5955

   確認CSV實際只有date與兩個整數frame標記，非秒制contact timestamp。

   L1–6

---

7. preprocess_human_video/generate_hand_trajs.py ↗

   GitHub · IRMVLab/UniHand · 7f3edd5955

   確認right-hand 21點是u/v/depth-mm，只有000000影格寫入點雲。

   L37–59 · L76–96 · L124–154 · L157–179

---

8. `unihand/data_utils/HumanDataLoader.py` ↗

   GitHub · IRMVLab/UniHand · 7f3edd5955

   追到有效frame對齊、pixel/depth正規化、padding、voxel與contact index，三個非train split共用清單。

   L31–168 · L194–213 · L245–315 · L330–374

---

9. `unihand/traineval.py` ↗

   GitHub · IRMVLab/UniHand · 7f3edd5955

   確認demo入口選用TrainEvalLoop與test/test_novel loader。

   L23–31 · L85–107 · L119–149

---

10. `unihand/netscripts/epoch_feat.py` ↗

    GitHub · IRMVLab/UniHand · 7f3edd5955

    核對實際單腕/首frame/單次sample評測、ADE/FDE公尺分母、CE兩峰與索引偏移。

    L34–114 · L201–221 · L300–322 · L573–746 · L778–786

---

11. `unihand/viz_predicted_trajs.py` ↗

    GitHub · IRMVLab/UniHand · 7f3edd5955

    確認相機座標中的固定grasp_offset，沒有機器人controller/success checker。

    L21–25 · L85–119

---

12. `options/expopts.py` ↗

    GitHub · IRMVLab/MMTwin · bd0faf148a

    固定EgoPAT3D的seen/unseen、ratio0.6、40frame與diffusion預算。

    L1–37 · L40–74

---

13. `data_utils/EgoPAT3DLoader.py` ↗

    GitHub · IRMVLab/MMTwin · bd0faf148a

    核對scene/record split、traj2d/traj3d/num_preserve、首camera投影及非train未來motion遮蔽。

    L38–133 · L147–173 · L220–343 · L437–456

---

14. `traineval.py` ↗

    GitHub · IRMVLab/MMTwin · bd0faf148a

    追到test_novel選擇、seed與實際metric loop引數。

    L23–46 · L126–136 · L149–185

---

15. `netscripts/epoch_feat.py` ↗

    GitHub · IRMVLab/MMTwin · bd0faf148a

    確認真正執行的ratio mask、單次sample與逐case ADE/FDE，2D為影像尺寸正規化。

    L27–84 · L451–587 · L613–620

怎麼接入我們的benchmark

可重用

重用兩庫各自split與reader、有效frame index、內參/voxel設定、逐case ADE/FDE與contact峰值定義；保留MMTwin為前身與母資料轉接來源。

需要轉換

case以repo版本+dataset+scene/date/clip+觀測長度識別；把u/v/depth-mm、正規化latent及XYZ-m分開儲存，記錄camera參照與有效frame至原frame對映。evaluator分開ADE、FDE、CE、paper-reported robot SR，儲存每case未來點數、sample數、smoothing/gap與ratio。grasp_offset屬另行校準的camera-frame幾何轉換。

仍需補齊

RGBD、refined trajectories、特徵、點雲與weights未取得，roster不等於可執行case數；需修正/核驗CE offset、缺峰策略、改max_depth時的反正規化一致性。需補獨立validation/novel split、論文其餘資料集/多target/robot協定，以及相機到robot基座外參、運動控制與成功判定。MMTwin不能充當Uni-Hand所有新版結果的實作證據。

P223 · INSIGHT

Intention-Guided Cognitive Reasoning for Egocentric Long-Term Action Anticipation

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

精確INSIGHT舊網址已轉址至iLearn-Lab/AAAI26-INSIGHT；已讀feature reader、stage1分類、具體序列ED與GRPO reward。ED只平均有GT對應的prediction records、沒有強制五候選或20步；另有reader語法錯誤及reward/plugin命名缺口，尚不能直接執行完整流程。

> **版本與身份**
>
> commit ab9495968b80ccae7a905ecb663a9d101873cf75（canonical iLearn-Lab/AAAI26-INSIGHT）。read-only靜態解析沒有匯入/執行上游程式；全部模型、ms-swift與MiniLM均未執行。README稱完整兩階段，但本輪只核讀所列來源段，未認定論文分數可重現。
>
> 論文為 Intention-Guided Cognitive Reasoning for Egocentric Long-Term Action Anticipation，Qiaohui Chu、Haoyu Zhang、Meng Liu、Yisen Feng、Haoxiang Shi、Liqiang Nie；cached PDF為arXiv:2508.01742v2（2025-11-15），第1頁直接指向CorrineQiu/INSIGHT。GitHub metadata依repository ID轉址後full_name為iLearn-Lab/AAAI26-INSIGHT，README題名/作者與AAAI26引用一致；這是搬移別名，不是另一篇同名專案。 舊入口CorrineQiu/INSIGHT的已儲存GitHub metadata回應指向iLearn-Lab/AAAI26-INSIGHT，按倉庫別名保留，不另外算成未讀的第二個倉庫。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	離線人類第一人稱影片，Ego4D-v2 LTA及EPIC-Kitchens-55 / EGTEA Gaze+；stage1讀full-frame與hand-object區域的預抽特徵。不存在可供policy rollout的互動環境。
任務	stage1是verb/noun action recognition，stage2產生think/intention/answer文字與未來verb-noun序列。Ego4D論文協定觀測8個action segments、預測5條各20個action的序列；8不是8張frame。EK55/EGTEA則預測影片前25/50/75%之後會出現的verb集合，報All/Freq/Rare mAP，不是同一ED題型。
題數與資料	ActionDataset按train.json / val.json / fho_lta_test_unannotated.json的clips分組clip_uid，再依action_idx排序；長clip切window_size=8、stride=1重疊視窗，短clip逐action成例。每action讀split/<clip_uid>_<action_idx>.pt兩路特徵，標籤verb_label/noun_label；缺feature會使不完整視窗被捨棄。main配置input_dim=1408、117 verb / 521 noun，collate再攤平視窗，因此同action可能重複計數。reader未提供原影格時間/fps/feature取樣manifest；test就算is_test=True仍會在getitem讀mask feature。stage2依外部ms-swift chat JSONL，messages assistant含<answer>與<intention>，images提供路徑；cal_ED把images[0]父目錄當clip_uid，GT同ID會覆寫。pred JSONL用clip_uid、res_list；沒有公開的完整stage1→chat/prediction轉換與split資產。

評估方式	stage1 train/validate是分類正確action occurrences除以flattened有效標籤數×100；main的co-occurrence validation在各top5 verb/noun組閤中挑raw_cooccurrence>0且機率乘積最大的pair。prior缺檔時只由train建立，但重疊視窗會重複action。cal_ED以逗號分動作、第一個詞為verb，其餘為noun；保留大小寫，不做taxonomy ID校驗。具體DP允許插入/刪除/替換及相鄰交換（受限交換遞迴，未證明與官方Damerau實作等價）。對每條res_list候選截至GT長度L，分別取最小action/verb/noun距離，三項可來自不同候選，再各除L、最後按處理到的prediction records平均。候選數不強制5、L不強制20；缺GT的prediction被跳過，完全缺prediction的GT不進分母，重複prediction ID可重複計數，L=0給0，空res_list會使min失敗。reward不是此ED：只接受兩個英文字token的pair並lowercase，至少20對才開gate，內容分數分母固定20；intention為MiniLM cosine經β=0.8、γ=40 sigmoid對映，R=gate×(0.85內容+0.05意圖+0.05語言+0.05格式)，shell再以0.9此R+0.1外部soft_overlong組合。意圖reward不是意圖分類accuracy；EK55/EGTEA的All/Freq/Rare mAP scorer未在此版本公開。

依這個順序讀

1. `README.md` ↗
   GitHub · iLearn-Lab/AAAI26-INSIGHT · ab9495968b

   核對精確論文身份、兩階段範圍與外部特徵依存。

   `L1–36 · L123–140 · L146–172 · L204–223`

2. `HandObject/README.md` ↗
   GitHub · iLearn-Lab/AAAI26-INSIGHT · ab9495968b

   確認feature與annotation檔案命名、stage1輸出用途。

   `L1–31 · L43–70`

3. `HandObject/dataset.py` ↗
   GitHub · iLearn-Lab/AAAI26-INSIGHT · ab9495968b

   讀clip/action_idx視窗、資料過濾與實際feature載入；第25行語法錯誤已靜態確認。

   `L10–134`

4. `HandObject/main.py` ↗
   GitHub · iLearn-Lab/AAAI26-INSIGHT · ab9495968b

   追到flattened action分母、co-occurrence重排、train-only prior與val/test設定。

   `L30–113 · L126–213 · L350–427`

5. `HandObject/train.py` ↗
   GitHub · iLearn-Lab/AAAI26-INSIGHT · ab9495968b

   區分stage1分類accuracy與長期序列評測。

   L14–105

---

6. `CognitiveReasoning/README.md` ↗
   GitHub · iLearn-Lab/AAAI26-INSIGHT · ab9495968b

   確認chat標籤schema及GRPO reward與離線ED分工。

   L1–43 · L65–70

---

7. `CognitiveReasoning/cal_ED.py` ↗
   GitHub · iLearn-Lab/AAAI26-INSIGHT · ab9495968b

   核對實際字串parser、相鄰交換DP、best候選、GT長度分母與缺失case處理。

   L8–159

---

8. `CognitiveReasoning/my_rewards_intention.py` ↗
   GitHub · iLearn-Lab/AAAI26-INSIGHT · ab9495968b

   具體reward：20-pair gate、ED/20、MiniLM intention sigmoid、格式與語言項。

   L2–15 · L22–105 · L149–217 · L220–318

---

9. `CognitiveReasoning/plugin_in_log_intention.py` ↗
   GitHub · iLearn-Lab/AAAI26-INSIGHT · ab9495968b

   核對reward registry及與實際檔名不同的my_rewards_new_intention匯入。

   L1–20 · L665–677

---

10. `CognitiveReasoning/run_external_reward_func_7B_qwen_intention.sh` ↗
    GitHub · iLearn-Lab/AAAI26-INSIGHT · ab9495968b

    確認GRPO五個generation、0.9/0.1權重與尚未具體化的data/plugin路徑。

    L6–42

怎麼接入我們的benchmark

可重用

保留clip/action身份、兩路feature schema、stage1 taxonomy與train-only co-occurrence規格、離線ED的實際parser/DP，以及reward各分量。公開來源以canonical repo記錄並保留舊alias。

需要轉換

分開source、action-occurrence、8-action context window、20-action forecast case與多候選輸出；case鍵應包含clip_uid+最後觀測action_idx，不能只用image父目錄。evaluator分列stage1 accuracy、各自best-of-K normalized ED、intention相似度reward及論文mAP；保留實際K、L、分母、缺失/重複UID與大小寫/多詞noun策略。

仍需補齊

完整annotation/features與chat生成/預測指令碼、8→20對齊及五候選驗證；需對所有GT補齊失敗case並核驗官方ED一致性。靜態ast.parse確認HandObject/dataset.py第25行assert末尾逗號造成SyntaxError；plugin匯入my_rewards_new_intention但樹只有my_rewards_intention.py，shell指plugin_new_in_log_intention.py但樹只有plugin_in_log_intention.py；reward使用nullcontext卻未匯入。需修正這些執行缺口及補EK55/EGTEA mAP實作。

P224 · EMPIRE

EMPIRE: Explicit Manipulation Planning as a Learnable Intermediate Representation for Egocentric Hand-Motion Forecasting

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

已追完EMPIRE的index/episode reader、30→12FPS取樣、混合MANO動作表示及best-of-8 joint scorer。公開庫有核心程式，但EMPIRE-651K資料與前處理明示尚未發布；650,910訓練視窗與111活動標籤為論文數字，未由實際dataset逐筆驗證。

> **版本與身份**
>
> 固定commit bea74bb146baa750b02f291754cafd5ed6cd0bfe。標準StageII配置與predicted_plan ablation使用預測plan；ground_truth_plan另列。直接執行eval_mse的預設K=5、COT_GENERATE_THEN_CONDITION=0，可能使用GT plan suffix；正式shell才設定K=8與online生成，因此兩入口不可混同。online分支重讀raw image/coarse instruction而不用GT suffix，但資料載入仍依賴reference-plan存在；不能宣稱是完全無標註部署封裝。所有內容僅靜態核讀，未執行資料前處理、模型、MANO或評測。
>
> arXiv:2608.22449v1，Wen Wang、Ruibing Hou、Hong Chang、Shiguang Shan、Xilin Chen，EMPIRE: Explicit Manipulation Planning as a Learnable Intermediate Representation for Egocentric Hand-Motion Forecasting。PDF第1頁直接連wangwen-banban/EMPIRE，README題名/arXiv一致。VITRA為程式與資料格式基礎，EgoDex為母資料，Being-H0為比較baseline，三者不能另算本篇新資料。

領域	穿戴互動與動作介面
環境	EgoDex/Apple Vision Pro的人類桌面操作第一人稱影片，RGB、相機內外參、雙手追蹤骨架轉MANO、task caption與per-hand plan。reader在query frame的camera座標表示整段未來姿態；公開FrameDataset只支援human，不提供robot互動環境。
任務	從current RGB、初始雙手狀態與caption生成操作plan，再預測雙手未來motion；plan描述不是可執行robot技能。論文650,910個5秒train windows、6,836個test windows、111個活動標籤需分開計數。Part1 ablation另以訓練任務重疊定義26 seen tasks/1,247 windows與85 unseen tasks/5,589 windows；並非全五partition訓練的預設unseen切分。task summary從episode名稱或obj_class/video_name解析label，再對指定training annotation snapshot比對，沒有封閉111-task registry。

題數與資料	preferred layout為dataset/episode_frame_index.npz（index_frame_pair[N,2]=episode_index/frame_index、index_to_episode_id[E]）、episodic_annotations/id.npy及statistics.json；legacy .npy字典/processed_episodes_vitra_format也可讀。episode含video_name、video_decode_frame、intrinsics、extrinsics及left/right的beta、kept_frames、global_orient_worldspace、transl_worldspace、hand_pose、joints_worldspace、text/anno_type；caption→instruction、plan→cot只是alias。標準設定source_fps=30、target_fps=12，step=2.5，以np.rint取整，並可依此過濾index rows；future=59建立含current的60個window位置，再取next-state而產生60個未來action。OOB雖clip索引，但被mask剔除，60個slots不保證60個有效影格。text範圍採[start,end)，plan匹配卻允許end且取最近範圍。每hand51維為逐步腕平移m、腕旋轉xyz Euler-radians及下一步絕對15×3手指Euler；use_rel=false仍保留腕部relative分量。兩手102維action補到288；原state122維含betas，padding移除betas後補到296。predicted plan ABI為schema_version=1.0、plans[episode_id:frame_index]，主StageII配置明確讀該sidecar。
評估方式	run_full_eval預設REPEAT_TIMES=8、ONLINE_PLAN=1、save_repeated_samples；model config為flow matching 4步。eval_mse先依mask選正規化動作MSE最小者，分母為有效action scalar數，這不是論文MPJPE。compute_egodex_metrics優先讀sampled_actions[N,K,T,D]，逐候選反正規化並recon_traj：累加腕平移、左乘腕旋轉、手指使用絕對角，再以MANO重建21關節；beta固定0、左手套軸修正，剔除初始state，只評未來。mask為hand/frame有效性，非獨立joint可見性。每window MPJPE=全部有效hand-frame之21-joint Euclidean均值；等價分母21×有效hand-frame數。選該MPJPE最小的同一候選來算wrist joint0與finger-relative（扣wrist後只取其餘20關節），不可各指標另挑best。FDE為每個有GT手最後有效frame的joint均值，再對手平均。最終對非NaN windows的metric等權nanmean，再m×1000轉mm；num_samples仍包含無有效手而為NaN的records，須另報有效分母。若NPZ沒有sampled_actions，scorer把pred_actions當K=1，無法恢復best-of-8。shard merge按sample_positions排序並檢查連續性；task summary再分組，並不將總分改成task-macro平均。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **111** retained source task labels · 原文頁 4
- **650,910** training windows · 原文頁 4
- **6,836** held-out test windows · 原文頁 4, 6

依這個順序讀

1. `README.md` ↗

   GitHub · wangwen-banban/EMPIRE · bea74bb146

   確認精確論文、dataset coming soon、VITRA依存與正式eval鏈。

   L1–22 · L35–50 · L84–117

---

2. `docs/DATA_SCHEMA.md` ↗

   GitHub · wangwen-banban/EMPIRE · bea74bb146

   核對index/episode/plan ABI，明確區分runtime格式與未發布dataset/preprocessing。

   L1–85

---

3. `empire/datasets/schema.py` ↗

   GitHub · wangwen-banban/EMPIRE · bea74bb146

   讀preferred/legacy resolver、index形狀、caption/plan別名、canonical sample ID與sidecar驗證。

   L25–158 · L164–195 · L198–264

---

4. `empire/configs/train_stage2_actor.json` ↗

   GitHub · wangwen-banban/EMPIRE · bea74bb146

   固定predicted-plan條件、60步、30→12FPS、8次sample及4-step flow matching設定。

   L1–110

---

5. `empire/configs/ablations/ground_truth_plan.json` ↗

   GitHub · wangwen-banban/EMPIRE · bea74bb146

   核對GT-plan ablation與預設sidecar條件的差別。

   L1–108

---

6. `empire/configs/ablations/predicted_plan.json` ↗

   GitHub · wangwen-banban/EMPIRE · bea74bb146

   核對明確的predicted plan來源與sidecar路徑。

   L1–110

---

7. `empire/datasets/data_mixture.py` ↗

   GitHub · wangwen-banban/EMPIRE · bea74bb146

   empire_train只是一個具名dataset mixture，沒有111個task registry。

   L1–7

---

8. `empire/datasets/dataset.py` ↗

   GitHub · wangwen-banban/EMPIRE · bea74bb146

   追到EpisodicDatasetCore/EvalDataset、plan選擇、suffix資料及model tensor欄位。

   L30–219 · L219–259 · L268–340

---

9. `empire/datasets/human_dataset.py` ↗

   GitHub · wangwen-banban/EMPIRE · bea74bb146

   核讀FPS推斷/取樣、anchor-camera轉換、有效mask、相對腕/絕對finger混合表示、padding及evaluation同約定。

   L48–123 · L169–283 · L345–439 · L536–597 · L639–661 · L731–787 · L791–842 · L873–947 · L1040–1202 · L1283–1406 · L1430–1558 · L1596–1686 · L1681–1750 · L1850–1899

---

10. `empire/utils/data_utils.py` ↗

    GitHub · wangwen-banban/EMPIRE · bea74bb146

    追到mean/std正規化及實際step-wise wrist/pose重建，不能把latent MSE當MPJPE。

    L268–408 · L462–539

---

11. `scripts/run_full_eval.sh` ↗

    GitHub · wangwen-banban/EMPIRE · bea74bb146

    正式入口預設K=8、online plan、保留全部sample、merge→joint metric→task summary。

    L1–106

---

12. `scripts/eval_mse.py` ↗

    GitHub · wangwen-banban/EMPIRE · bea74bb146

    核對K預算、GT-plan/online分支、MSE預選與sampled_actions/UID/FPS輸出。

    L21–116 · L152–190 · L192–274 · L275–391 · L379–444 · L450–583

---

13. `scripts/merge_eval_shards.py` ↗

    GitHub · wangwen-banban/EMPIRE · bea74bb146

    確認按sample_positions排序及連續性檢查；欄位只取各shard交集。

    L1–56

---

14. `scripts/egodex_eval_utils.py` ↗

    GitHub · wangwen-banban/EMPIRE · bea74bb146

    重建左右手21關節、beta=0、左手chirality、初始frame剔除及mask。

    L19–74 · L157–190 · L192–289 · L291–307

---

15. `empire/models/mano.py` ↗

    GitHub · wangwen-banban/EMPIRE · bea74bb146

    確認SMPL-X MANO補五個指尖並轉OpenPose 21-joint順序。

    L1–57

---

16. `scripts/compute_egodex_metrics.py` ↗

    GitHub · wangwen-banban/EMPIRE · bea74bb146

    完整核讀具體joint scorer：per-hand有效frame、best MPJPE、wrist/finger-relative/FDE、NaN與window平均。

    L1–406

---

17. `scripts/summarize_egodex_all_tasks.py` ↗

    GitHub · wangwen-banban/EMPIRE · bea74bb146

    核對task解析、training snapshot定義seen/unseen及episode/raw-file/window各自計數。

    L1–98 · L157–238

怎麼接入我們的benchmark

可重用

重用versioned schema/resolver、canonical sample ID、plan sidecar、FPS/mask邏輯、MANO adapter、step重建、best-of-K MPJPE與task provenance摘要；保留EgoDex/VITRA lineage。

需要轉換

分開source/domain/environment/task/window/evaluator；case鍵為dataset revision+episode_id+frame_index，儲存source/video/target FPS及np.rint後實際indices。將51維混合action、102有效維、288/296 padding及mean/std明確分層；保留anchor-camera與xyz-radians、公尺/mm轉換。evaluator儲存K、4步設定、全部sampled_actions、選中best_k、21/20 joint定義、每window有效hand-frame及NaN分母。

仍需補齊

未發布的index/episodes、骨架→MANO擬合與caption/plan前處理、資料/統計/sidecar/weights/MANO資產尚未閉合；不能驗證650,910/6,836筆或真正split無洩漏。需核對eval dataset statistics.json與scorer STATISTICS_PATH均使用對應training normalization，避免反正規化版本不同。須鎖定ONLINE_PLAN、各shard皆保留sampled_actions、真正K與完整case coverage；資料格式稱HF-compatible不代表已確認HF dataset repo/revision。

P225 · Exo2EgoPose

Exo2EgoPose: Leveraging Exocentric Demonstrations for Vision-Language guided Egocentric 3D Hand Pose Forecasting

檔案 / 網站 · 主來源 · 原作 · 獨立頁面

已確認精確Exo2EgoPose論文與作者repo；固定版本完整樹只有四行README，明示source code與benchmark仍在準備。可核讀論文任務/資料/指標定義，沒有pinned data reader、MPJPE/MPJVE或CALVIN成功checker可檢查。

> **版本與身份**
>
> repo固定commit 17c1d8c09e357045aadcdad13708ce48b30cff2e（2026-09-22），tree未truncated且只有README.md。論文摘要寫code available，而此快照README仍為will be released soon；依實際程式狀態列public_readme_only。論文未提供真正benchmark檔案，未以同名repo或母資料現行版本補成已發布。
>
> Zhaofeng Shi、Heqian Qiu、Lanxiao Wang、Xiang Li、Hongliang Li，Exo2EgoPose: Leveraging Exocentric Demonstrations for Vision-Language guided Egocentric 3D Hand Pose Forecasting，cached PDF為arXiv:2607.15890v2（2026-08-05）。PDF第1頁直接指向ZhaofengSHI/Exo2EgoPose，README精確題名一致；因此是已確認作者庫的placeholder，不是repo找不到或無關同名庫。

領域	裝配與生產作業、穿戴互動與動作介面
環境	離線AssemblyHands/Assembly101玩具組裝、Ego-Exo4D活動與EgoMe正確模仿配對影片；AssemblyHands/Ego-Exo4D有同步多視角，EgoMe-pose的Ego/Exo配對可能不同步。CALVIN ABC→D是另行teacher-to-policy蒸餾的robot下游實驗。
任務	VL-EHPF在t時刻輸入1–10步Ego影格、語言instruction與同段手姿，輸出t+1至t+10的42×3座標（兩手各21點）及42點validity。論文DERM把涵蓋觀測與未來的配對Exo影片當訓練監督，從Ego輸入重建Exo表徵，再交GLMM；推論公式只含Ego/語言/pose，不能把實際未來Exo影格加入test條件。它預測人體pose，不直接輸出robot動作。

題數與資料	論文報AssemblyHands衍生episode train/val/test=6,120/355/355，Ego-Exo4D=10,869/1,540/1,540，EgoMe-pose=6,067/1,344/2,648；這是episode數，不是10-frame forecast windows、joint數或實際可下載case數。AssemblyHands/EgoMe-pose為15FPS、Ego-Exo4D為30FPS，RGB resize224×224，10步預測因此有不同時間長度。AssemblyHands保留每手>10個valid joints且root有效的frame，world→Ego camera並依共用frame ID連Assembly101文字；隨機Exo view配對，從原val隨機切50%作test。Ego-Exo4D須Aria去畸變、world→camera及joint-order對映，文字window為atomic timestamp前0.5秒至後1秒且每frame pose有效，也將原val隨機半分作test。EgoMe-pose以InterHand相對姿態+RootNet root-depth轉絕對座標，剔除false imitation、hand confidence<0.6或有效frame比例≤95%的episode；非同步Exo以片段相對位置線性對齊。上述隨機seed、episode/frame清單、joint permutation、標註檔schema均無公開reader可核。
評估方式	僅論文§4.1.2：MPJPE比較root-aligned predicted/GT關節的Euclidean距離；MPJVE比較關節位移，論文單位寫mm，沒有可核程式證明另除Δt，不能改記mm/s。這與EMPIRE的absolute-camera MPJPE不同。雖模型預測validity，實際scorer使用GT或pred mask、兩手/root是否計入、分母是有效joint-frame或先逐episode平均、位移是否包含最後觀測點及缺失鄰接frame處理均待程式確認，不能用10×42固定分母填空。CALVIN表列連續完成1–5任務比例、Avg.L.與Avg.R.，採ABC訓練→D測試及Exo2EgoPose teacher蒸餾GR-1類student；本版無robot action adapter、trial manifest或具體success checker可讀，不能把手姿誤差換成robot成功率。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **355** AssemblyHands test episodes · 原文頁 5
- **1,540** EgoExo4D test episodes · 原文頁 5
- **2,648** EgoMe-pose test episodes · 原文頁 6

依這個順序讀

1. `README.md` ↗

   GitHub · ZhaofengSHI/Exo2EgoPose · 17c1d8c09e

   精確題名與source code/benchmark尚在準備的公開狀態。

   L1–4

怎麼接入我們的benchmark

可重用

重用已確認paper/repo身份、三個衍生資料集的母來源、42點/10步/validity任務契約及論文明列的split/取樣條件；repo僅提供發布狀態證據。

需要轉換

case以母資料版本+衍生episode+query frame+split+FPS識別；儲存world/camera/root-aligned三層座標、兩手joint-order與validity。另記train-only Exo監督、同步/相對時間線性對齊、原val→新val/test關係；CALVIN蒸餾獨立為下游reuse關係，metric保留pose與robot兩類原生單位。

仍需補齊

程式與EgoMe-pose benchmark尚未發布；缺前處理、reader、精確split/seed、有效case manifest、MPJPE/MPJVE具體分母與root/mask約定、weights及CALVIN蒸餾/執行成功判定。不能執行或聲稱本輪重現論文分數。

P226 · EgoTraj

EgoTraj: Real-World Egocentric Human Trajectory Dataset for Multimodal Prediction

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoTraj提供戶外行人頭部/視線/影片資料與EgoViz reader；公開檔案可支援資料對齊，但不是完整trajectory預測baseline實作。四元數順序在README與reader註解不一致，需核驗。

> **版本與身份**
>
> 固定902c354、原作2605.19004；README結果是原作報告，本輪只核讀資料/視覺化介面，未重跑預測模型。

領域	交通移動與車輛維修、穿戴互動與動作介面
環境	真實都市步行、7個預設waypoints間自行選路，MetaQuestPro錄制；75participants不是75個不同物理環境，位置為session-relative、Y向上、地平面x-z，沒有地理坐標。
任務	行人trajectory forecasting與AR導航研究，原文/README採1.5秒觀測→3.5秒預測；不同participant/waypoint/unfamiliar splits另列。不是robot實際導航任務完成benchmark。
題數與資料	HDF5按session含pose position/rotation/velocity/angular_velocity/timestamp、gaze origin/direction、video segment/frame/has_video；scene annotations為1fps，用pose_idx回連30Hz資料。README稱quaternion wxyz，reader按xyzw解讀；原始資料必須核定。未匹配影片frame以NaN標示。
評估方式	README列ADE/FDE(m)、L1_head與bootstrap結果，但repo主要EgoViz，未確認完整baseline/scorer。影片在拍攝時已疊紅色gaze dot，RGB-only是否允許這個線索需在case條件明示；1fps VLM scene descriptions也需有獨立可見性/生成版本。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **75** participants and recording sessions · 原文頁 4, 5
- **10.7** recording hours · 原文頁 5
- **7** navigation landmarks · 原文頁 4

依這個順序讀

1. `README.md` ↗
   GitHub · yehiahmad/EgoTraj · 902c354d17

   原作、75participants、sensor clock、預測/split與資料契約

   `L1–60 · L61–79 · L124–167 · L222–248`

---

2. `ego_viz.py` ↗
   GitHub · yehiahmad/EgoTraj · 902c354d17

   30Hz近鄰重取樣及HDF5/annotation/video join讀取

   `L1079–1120 · L1235–1275`

怎麼接入我們的benchmark

可重用

session/pose_idx跨模態join、原生視線與local坐標、資料reader和source split設計。

需要轉換

case固定participant/session/觀測截止與預測視窗；統一quaternion及clock、保留has_video mask、原始/疊點影像與VLM annotation來源；模態消融先界定合法可見線索。

仍需補齊

全部資料/split manifest、quaternion查核、baseline/scorer與姿態metric定義、含gaze-dot版本的公平輸入設計。

P227 · EggHand

EggHand: A Multimodal Foundation Model for Egocentric Hand Pose Forecasting

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

EggHand 是在 EgoH4 / EgoExo4D 手部軌跡上評測的預測方法；「action」在這裡是未來 42 個人體關節座標，不能直接當成機器人控制命令。已逐段核對取樣、相機對齊與六項誤差的有效樣本口徑。

> **版本與身份**
>
> 已讀 revision 的 implementation note 明載 warmup 為 1% 而非論文 5%；推論 BF16 / 四步 denoising 與訓練精度分開。閱讀範圍是列出的來源段落，未聲稱重現論文分數。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	EgoExo4D 衍生的 EgoH4 人體影片 / 手部軌跡，非新建模擬場景。相機外參為 world→camera 3×4；以最早可見幀（offset −19，含邊界補幀）的相機位置與前向建立座標系。
任務	一個 3D 雙手預測設定：42 關節 × xyz。state offsets −19…0，4 個影像 offsets −18 / −12 / −6 / 0，target offsets 0…9；target 包含當前 timestep，不能稱為 10 個純未來幀。
題數與資料	README 列 train 555 episodes / 41,314 samples、val 109 episodes / 8,830 samples，10 Hz，LeRobot v2.1。episode、重疊時間窗和關節數分開記；與 EgoH4 / EgoExo4D 保留父資料關係。原始 126D 關節與 12D 外參經模型投影，32D latent action 不是原生 actuator 維度。
評估方式	以公尺計算 wrist ADE / FDE、絕對 MPJPE / MPJPE-F、wrist-relative R-MPJPE / R-MPJPE-F。論文的 MPJPE 欄對應後兩項相對誤差。GT 三軸全零才排除關節；relative 額外要求 wrist 有效，包含對齊後零誤差的 wrist。ADE 先手腕→幀→sample 平均，MPJPE 池化有效 joint×time；不共用分母。全無效 sample 不計，異常直接停止並報 sample index。

依這個順序讀

1. `README.md` ↗

   GitHub · JYOUN9/EggHand_Code · 72d9b8f58c

   核對官方身分、資料 split / 頻率、訓練與推論設定、論文欄位對照。

   L1–104

2. `docs/IMPLEMENTATION.md` ↗
   GitHub · JYOUN9/EggHand_Code · 72d9b8f58c

   確認原生依賴版本、時間索引、補邊、mask 和 paper / code 指標差異。

   L1–35

---

3. `inference/evaluate.py` ↗
   GitHub · JYOUN9/EggHand_Code · 72d9b8f58c

   追蹤資料欄位、逐座標訓練 mask、GT 有效關節、分母與錯誤處理。

   L86–123 · L176–193 · L275–297 · L357–395 · L487–490 · L535–643

---

4. `gr00t/model/transforms.py` ↗
   GitHub · JYOUN9/EggHand_Code · 72d9b8f58c

   檢查 world-to-camera 外參、首個歷史相機的 canonical frame、零座標關節與 raw tensors。

   L356–450

怎麼接入我們的benchmark

可重用

重用原生 joint keys、episode / frame 對照、相機對齊與原生 evaluator。；保留同一評測的 absolute / relative 六欄，不把不同 alignment 的 MPJPE 合成一欄。

需要轉換

case 固定 source episode、base timestep、完整 observation / target offsets、padding mask、m 單位與 camera reference。；訓練 per-coordinate 非零 mask 和評測 per-joint mask 各自儲存；新增缺失值策略必須另立協定。；資料 split 沿用父 take / episode，防止重疊視窗跨 train / test。

仍需補齊

本次未下載影片 / 模型、未執行基線；資料與 checkpoint revision 仍需固定。；目前原生對齊會把全零缺失關節當點平移；不能事後把它誤認為觀測到的手。

P228 · SFHand / EgoHaFL

SFHand: Learning Embodied Manipulation by Streaming Egocentric 3D Hand Forecasting

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

SFHand / EgoHaFL 有可讀取的手部串流預測資料與 evaluator；目前 README 仍把 Franka Kitchen 評測與 3D 標註產生程式列為 Coming soon。已沿 loader→stream→模型輸入→matching→metric 查核，將人體預測與機器人實作分開。

> **版本與身份**
>
> 閱讀版本為 pinned GitHub commit；DATA / MODEL 外部儲存庫另需固定 revision。論文尺度與程式 clip 子取樣各自登記，不把新觀測幀或四種輸出當新任務。

領域	穿戴互動與動作介面、居家整理與清潔、餐飲與烹飪、通用物件與機動作業
環境	Ego4D v1 真實活動短片 / 自動 MANO 標註；EgoHaFL 為衍生 annotations，不是 247K 個模擬環境。Franka Kitchen 下游環境須追到父 benchmark，公開原始碼尚未完整涵蓋。
任務	串流、語言引導的 hand type / 2D box / 3D pose / 3D trajectory 四類輸出，共用同一 clip。每步餵入截至當下的新影像，hand state 由前次預測接續；不是一次只看首幀的全盲長期預測。
題數與資料	論文報告約 247K 個 3 秒 clips（242K train / 5K test）、每 clip 16 個 annotated frames，約 3.95M 標註幀；不是 3.95M 獨立問題。eval config clip_length=8、max_hand=10、camera depth 0<z<2.5。loader 保留前 10 個有效 hand，LMDB uid / video_id / start/end / caption 與 native split 一起儲存。
評估方式	Hungarian matching 後，以 IoU>−1 / 0.5 及手別正確篩選，再計 camera translation ADE / 最後一步 FDE、wrist-aligned MPJPE / PA-MPJPE，輸出 cm。precision=matched 中達 IoU 且手別正確 / matched 中達 IoU；recall 分母也是 matched pairs 數，未匹配額外預測不在該分母。誤差是條件於匹配及分類正確的子集合，不能當完整 detection precision/recall 或所有手的平均誤差。err_data 未看到跨 rank gather，正式分散式評測需核對匯總。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **247,000** 3-second clips（約數） · 原文頁 5
- **5,000** test clips（約數） · 原文頁 5

- **3,950,000** hand annotations（約數）· 原文頁 5

依這個順序讀

1. `README.md` ↗
   GitHub · ut-vision/SFHand · 86e3e34e57

   確認原生資料來自 Ego4D v1，發布範圍與未發布元件。

   L1–92

---

2. `configs/config/clip_base_eval.yml` ↗
   GitHub · ut-vision/SFHand · 86e3e34e57

   固定 test CSV、clip 長度、max_hand 與深度有效範圍。

   L1–42

---

3. `dataset/egodataset.py` ↗
   GitHub · ut-vision/SFHand · 86e3e34e57

   讀取 clip / caption / LMDB、16-frame 子取樣、深度篩選與最多 10 手的截斷。

   L20–194

---

4. `engine_pretrain.py` ↗
   GitHub · ut-vision/SFHand · 86e3e34e57

   追蹤每步新增影像、autoregressive hand state、matching-only 分母與誤差。

   L90–288

---

5. `model/matcher.py` ↗
   GitHub · ut-vision/SFHand · 86e3e34e57

   確認 Hungarian 一對一匹配只保留 min(predictions,targets) 對。

   L21–92

---

6. `model/clip.py` ↗
   GitHub · ut-vision/SFHand · 86e3e34e57

   核對名為 future 的引數在這個 forward 中沒有被使用，避免憑變數名誤判。

   L274–317

---

7. `main.py` ↗

   GitHub · ut-vision/SFHand · 86e3e34e57

   查核 distributed 包裝、eval 儲存的原生統計。

   L135–164

怎麼接入我們的benchmark

可重用

重用 EgoHaFL CSV / LMDB uid、原始 clip 時間窗、有效手數與原生匹配 evaluator。；保留 4 類預測輸出及 IoU 門檻，同列呈現 coverage / 條件誤差。

需要轉換

標準 case 寫明 rolling RGB observation、autoregressive hand input、文字來源、clip horizon / frame stride、深度過濾與 hand cap。；保留原始 metrics；若要完整 detection precision / recall，另建版本並將所有未匹配預測 / GT 納入分母。；跨 Ego4D 衍生資料以 video / 時間交集去重，不將標註幀數乘成新增題數。

仍需補齊

本次未下載 Ego4D 影片 / MANO 權重，未執行模型或確認論文分數。；embodied evaluation 與 annotation pipeline 尚未公開於本次 revision；matching error 空集合與多 rank 匯總需要 adapter 驗證。

P229 · UniEgoMotion

UniEgoMotion: A Unified Model for Egocentric Motion Reconstruction, Forecasting, and Generation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

UniEgoMotion 把重建、生成和預測放在同一人體動作框架；它的 EE4D-Motion 是 EgoExo4D 的處理版本。已核對切窗 / split、可見資訊 mask、3D 評分與地面接觸代理量，不能把三種設定當成三批獨立原始資料。

> **版本與身份**
>
> 本次固定官方 commit，三種 task 共用 EE4D-Motion。論文 / README 的資料量為來源報告量，不是本案已取得題數；時間視窗和 eval 抽樣不可省略。

領域	餐飲與烹飪、休閒與運動、音樂與表演、穿戴互動與動作介面
環境	EgoExo4D 多用途人類活動的 Aria 影片、軌跡與擬合 SMPL-X 身體；沒有新增可執行機器人環境。EE4D-Motion 使用父資料 take / train-val 關係。
任務	原生三種 model task：recon 全觀測重建；gen 僅第一影格可見；fore 可見 window 前 1/4（典型 20/80 幀）。這些是觀測協定差異，不能直接增加三倍獨立情境。
題數與資料	DATASET.md：原始 4,792 takes、約 208 小時，篩選為 train 2,032 / val 560 takes、約 110 小時。segment key 的 start/end 使用 30 Hz 原始 index、含末端；motion 為 10 Hz。dataset 每 20 motion frames 建窗，正式 evaluation 再用每第十個 validation sample。SMPL-X 是擬合結果，需保留失敗 / 遮蔽篩選及父 take ID。
評估方式	評分含全身 / body 前 22 joints / hand 25:55 的 MPJPE 與 PA-MPJPE、head / trajectory 誤差、足滑、穿地、騰空與接地距離。rotation error 是 R差的 Frobenius norm，非角度。接觸指標各有 4 cm / 8 cm 等閾值；足滑按序列長度歸一且乘 1000，不是成功率。compute_3d_metrics 遍歷 GT key，評整段和每 20 幀；pred trajectory=None 時以 GT trajectory 替代，此條件下 trajectory 誤差不能證明模型預測能力。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **3** motion endpoints · 原文頁 3
- **143,000** training clips（約數） · 原文頁 5

- **4,400** validation clips · 原文頁 5

依這個順序讀

1. `README.md` ↗
   GitHub · chaitanya100100/UniEgoMotion · 580c92c6d7

   確認方法、官方 repo 與資料依賴。

   L1–60

---

2. `DATASET.md` ↗
   GitHub · chaitanya100100/UniEgoMotion · 580c92c6d7

   核對父 take、資料篩選、原生 30 Hz index 與 10 Hz motion、validation 抽樣。

   L1–56

---

3. `dataset/ee4d_motion_dataset.py` ↗
   GitHub · chaitanya100100/UniEgoMotion · 580c92c6d7

   檢查訓練統計來源、20-frame stride、reconstruction / generation / forecast mask。

   L36–91 · L230–250

---

4. `eval/compute_3d_metrics.py` ↗
   GitHub · chaitanya100100/UniEgoMotion · 580c92c6d7

   追蹤 GT key 分母、whole-clip / 20-frame segment、缺失 trajectory 的替代。

   L15–109 · L113–124

---

5. `eval/metrics.py` ↗
   GitHub · chaitanya100100/UniEgoMotion · 580c92c6d7

   確認 rotation norm、body / hand joint subsets、PA 與 foot / floor 指標的真正計算。

   L9–127 · L192–275

怎麼接入我們的benchmark

可重用

重用 take lineage、SMPL-X / Aria 對照、明確 mask 與 evaluator 各原生欄位。；保留 reconstruction / generation / forecast 的條件差異，不混合 rank。

需要轉換

canonical case 固定 take、start/end、30→10 Hz 對照、valid frames、觀測 mask 和 train-only normalization revision。；把 supplied-GT trajectory 與 predicted trajectory 設為不同 evaluation condition；報分時明示。；全段與分段 metrics 分開；若另評純未來區間，新增 evaluator 版本並保留原生成績。

仍需補齊

未下載受原始資料 / SMPL-X 授權約束的完整資產，未跑模型。；語義生成評分與模型內部 diffusion 未在本次列出的 3D reader 範圍內完整審核。

P230 · EgoH4

The Invisible EgoHand: 3D Hand Forecasting through EgoBody Pose Estimation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoH4 評測由頭部 / 影像與可見 2D 手位置推估及預測 3D 手部，特別區分視野內外。已核對資料模組、20+10 幀切分與 metric 實作；這是 EgoExo4D 上的新評測任務，不是新採集的一批影片。

> **版本與身份**
>
> 固定目前官方 commit；trainer 註解有 17-joint 遺留文字，但實際使用 57 joints。future condition 於 decoder 被排除，不能因 sample 接收 GT-shaped tensor 就直接判定資料洩漏。

領域	穿戴互動與動作介面
環境	EgoExo4D 的 Aria 頭部相機、相機姿態及人體 / 手部標註。機器人控制與物理成功不在本來源評測範圍內；場景應沿用父 take。
任務	3D 手軌跡及手姿態 forecasting，並可分離觀測段 reconstruction；native 30 幀中前 20 幀觀測、後 10 幀未來，按可見 / 視野外比例分組。全身 57 joints 是移除重複 wrist 後的輸出維度，不是 57 個任務。
題數與資料	論文報告約 156K train / 34K test sequences；公開 config 的 test.split=val，並 concatenate manual body dataset 與 manual hand+auto body dataset。視窗 size=30、slice=1、frame interval=3，需儲存 take_uid / start_frame 和標註型別，避免把交疊片段或不同標註視為獨立原片。
評估方式	原生 evaluator 分 body / wrist / hand / full，計 obs/fut ADE、末幀 FDE、10 個未來 timestep 和 in-/out-of-view 子群；不以單一 success 評分。calc_jpe 先乘 visibility，再以 jpe!=0 篩選，會連真正零誤差也排除。該固定版本以絕對座標 L2 計手部誤差，沒有在所讀 test_step 執行 wrist-relative 對齊；比較論文相對 MPJPE 欄時必須核對。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **156,000** hand-side training sequences（約數） · 原文頁 5
- **34,000** hand-side test sequences（約數） · 原文頁 5

依這個順序讀

1. `README.md` ↗

   GitHub · masashi-hatano/EgoH4 · baa8ae87ce

   確認官方論文、執行入口與 checkpoint 來源。

   L1–46

---

2. `config/data_module/egoexo.yaml` ↗

   GitHub · masashi-hatano/EgoH4 · baa8ae87ce

   核對原生 split、30-frame window、interval=3 與正規化界限。

   L1–47

---

3. `config/trainer/egoh4.yaml` ↗

   GitHub · masashi-hatano/EgoH4 · baa8ae87ce

   查核模型維度及 30 timestep 設定；註解與實際維度不可混讀。

   L1–39

---

4. `datamodule/lit_egoexo4d_data_module.py` ↗

   GitHub · masashi-hatano/EgoH4 · baa8ae87ce

   確認測試實際用 EgoExo4D val、body / hand loader concatenation。

   L14–44

---

5. `datamodule/dataset/egoexo4d_hand_body_pose_dataset.py` ↗

   GitHub · masashi-hatano/EgoH4 · baa8ae87ce

   追蹤 take、連續視窗、out-of-view 分組、17+42 關節、mask 與只載前 20 幀影像。

   L15–127 · L296–383

---

6. `models/lit_EgoH4Trainer.py` ↗

   GitHub · masashi-hatano/EgoH4 · baa8ae87ce

   檢查 57 關節、觀測 / 未來分開、per-timestep 誤差及零誤差過濾。

   L273–436

---

7. `models/transformer_cond_diffusion_model.py` ↗

   GitHub · masashi-hatano/EgoH4 · baa8ae87ce

   確認 sample 只用 x_start.shape 建噪聲，不把 GT 座標直接當預測。

   L314–345

---

8. `models/transformer_module.py` ↗

   GitHub · masashi-hatano/EgoH4 · baa8ae87ce

   確認 future token 只讀 noisy pose channels、沒有讀 future condition。

   L236–283

怎麼接入我們的benchmark

可重用

重用 parent take / sequence indexing、可見性標註、原生 20+10 與分組 evaluator。；以各分項原生誤差作基準；0...1 視野外比例是 case 屬性，不直接標成難度分數。

需要轉換

canonical case 固定 observation boundary、camera / pose 座標、joint order、3D / 2D masks 及 annotation provenance。；保留 native evaluator；修正零誤差 mask 或新增 wrist-relative metric 時另建協定與相同 fixture 對照。；test dataset 所稱 test 對應父資料 val，標準格式同時保留兩個 split 名稱。

仍需補齊

本次只查核列出的公開來源段落，未取得完整資料或執行 diffusion。；body / hand concatenation 之重疊 take 與實際數量需要用下載後的 annotation manifest 核對。

P231 · MADiff

MADiff: Motion-Aware Mamba Diffusion Models for Hand Trajectory Prediction on Egocentric Videos

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

MADiff 是重用多個既有 Ego 資料集的手軌跡方法。已讀到的官方版本提供 H2O / EgoPAT3D 兩個 backend，並附 ACT 條件輸入教學；論文五個資料集的覆蓋、目前程式入口與新增機器人教學分開登記。

> **版本與身份**
>
> 目前 README 為 T-PAMI 2025、引用同一 arXiv；版本新增 H2O / EgoPAT3D backend 與 ACT 教學。已讀原生程式與論文範圍不相同，必須按版本列出。 補查MMTwin README：它對應2504.07375，CABH列三種人類操作任務，CABH專用模型仍待發布；EgoPAT3D配套程式已在P222核讀。這是相關延伸，不改寫MADiff本篇的任務或可執行範圍。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	父資料 EK55、EK100、EGTEA Gaze+、EgoPAT3D-DT、H2O-PT；目前公開入口主要為後兩個。EgoPAT3D loader 有 11 個已見 scene IDs 與 novel 13 / 14 / 15；ID 是父資料場景，不能當 MADiff 新建環境。
任務	同一手部軌跡 forecasting 方法在不同資料與觀測配置測試。現行兩個 backend 設定 target=2d、observation ratio=0.6；H2O max_frames=64，EgoPAT3D=40。ACT 教學將 forecast 作額外 token，沒有提供一套新的正式 robot benchmark 題單 / 判分器。
題數與資料	原生資料與權重需外部下載，來源依賴 USST 預處理。讀取 native filename、scene/recording split、有效幀數、trajectory / GLIP / motion features；論文五資料集的 train/test 樣本表不能算為五批全新原始影片。
評估方式	實際 H2O / EgoPAT3D eval loop 對純未來區間逐序列計 normalized-image ADE 與末點 FDE，並非檔內未用 helper 的 weighted error。H2O 每題 1 次抽樣、gap=999；EgoPAT3D gap=333。test_novel 雖有 loader，traineval 對 tuple 取 [0]，預設入口只評 test。H2O rank 檔只彙整 ADE、檔名需隔離執行以免讀到舊檔。

依這個順序讀

1. `README.md` ↗

   GitHub · IRMVLab/MADiff · 9f13e5a703

   核對官方論文、目前兩個 backend、USST 資料和 ACT 延伸。

   L1–121

---

2. `traineval.py` ↗

   GitHub · IRMVLab/MADiff · 9f13e5a703

   查核 backend dispatch、test tuple 只取第一個 loader、原生種子與推論入口。

   L17–141

---

3. `configs/h2o.yml` ↗

   GitHub · IRMVLab/MADiff · 9f13e5a703

   固定 H2O 2D 64-frame 設定。

   L1–16

---

4. `configs/egopat3d.yml` ↗

   GitHub · IRMVLab/MADiff · 9f13e5a703

   固定 EgoPAT3D 2D 40-frame 設定。

   L1–15

---

5. `src/H2OLoader.py` ↗

   GitHub · IRMVLab/MADiff · 9f13e5a703

   追蹤 split、2D / 3D normalization、未來 motion feature 的觀測值延用與 padding。

   L28–89 · L93–137 · L294–375

---

6. `src/EgoPAT3DLoader.py` ↗

   GitHub · IRMVLab/MADiff · 9f13e5a703

   辨識 scene/recording split、novel scene test、有效長度與輸出。

   L41–99 · L273–350

---

7. `netscripts/epoch_feat_h2o.py` ↗
   GitHub · IRMVLab/MADiff · 9f13e5a703

   核對固定 60% 觀測、single sample、純未來 ADE / FDE、跨 rank 儲存。

   L1–31 · L426–523 · L543–576

---

8. `netscripts/epoch_feat_egopat.py` ↗
   GitHub · IRMVLab/MADiff · 9f13e5a703

   核對 EgoPAT3D 的噪聲填入、333 gap 與誤差路徑。

   L1–33 · L419–489

---

9. `docs/MADiff_for_Robotics.md` ↗
   GitHub · IRMVLab/MADiff · 9f13e5a703

   區分人體預測、固定 forecast token 與 ACT 實體操作教學。

   L1–70

---

10. `README.md` ↗
    GitHub · IRMVLab/MMTwin · bd0faf148a

    補讀MADiff官方連結的3D延伸身分及CABH資料角色；它有不同arXiv，完整配套程式核讀另見P222。

    L1–38 · L161–216

怎麼接入我們的benchmark

可重用

重用父資料 split、scene IDs、有效長度、座標轉換與實際呼叫的 ADE / FDE。；ACT forecast-token 教學可作 human-to-robot 介面參考，與正式測題清單分開。

需要轉換

case 包含 dataset revision、backend、filename、60% boundary、max_frames、normalization 與 feature revision。；novel test 建獨立入口和完整 expected-case manifest；抽樣次數、diffusion gap 各自固定。；把論文五資料集與目前兩 backend / MMTwin 3D 延伸保留版本關係，不合併報為新環境。

仍需補齊

未跑模型、未取得特徵 / checkpoint；沒有重現論文數字。；機器人教學缺可下載任務 / 示範 / evaluator；MMTwin本次僅補讀 README；其EgoPAT3D程式核讀見P222，不把CABH待發布模型當成已可用。

P232 · Diff-IP2D

Diff-IP2D: Diffusion-Based Hand-Object Interaction Prediction on Egocentric Videos

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

Diff-IP2D 重用 OCT / EPIC 的軌跡與接觸標註，但實際軌跡入口評的是 WDE / FDE。逐段追到 runtime caller 後，已把它和 repo 內沿用但未在該路徑呼叫的 OCT evaluator 分開；不能只看檔名就判斷評估方式。

> **版本與身份**
>
> 原生程式 import 了 evaluate_traj_stochastic，但所讀實際軌跡路徑使用 compute_wde / compute_fde；OCT wrapper 的名稱對調不能直接套到此主結果。固定版本的來源差異均保留。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	來源影片與人工評測 labels 重用 EPIC-KITCHENS / OCT；論文也包含其他 Ego 資料實驗，README 的當前完整部署僅 EK100，EK55 / EG 發布仍列待補。
任務	未來 2D 雙手 waypoint 與 object affordance/contact hotspot；典型 10 個過去 token→4 future 點。改 diffusion 架構不是新增語義任務，沿用 label 要連回 OCT 父來源。
題數與資料	features / bbox / 有效性、uid / raw frame 與 homography 均有原生欄位。training loader 會加 future features，evaluation loader 不加；manual-merged annotations 不等同 OCT 原始 annotation folder。各外部檔案與 checkpoint 要固定 hash / split，不能只記 repo commit。
評估方式	主迴圈將預測轉 numpy 後呼叫 compute_wde：4 未來點權重 0.25 / 0.5 / 0.75 / 1.0，求和未除以權重總和；FDE 為末點，normalized image 單位。tensor 分支反而為普通平均，但不是此路徑。輸出先按 batch 的有效手平均，再跨抽樣 / batch / rank 平均，與全資料有效手池化不同。heatmap SIM/AUC-J/NSS 沿用 OCT，仍需按 uid 配對、NaN 分母明示；原始 metrics rank equal-average 也要保留。

依這個順序讀

1. `README.md` ↗

   GitHub · IRMVLab/Diff-IP2D · 733ae0150f

   確認 EK100 發布範圍、OCT 資料沿用、自製 training features 與各外部檔。

   L1–163

---

2. `datasets/datasetopts.py` ↗

   GitHub · IRMVLab/Diff-IP2D · 733ae0150f

   確認 4 Hz、2.5+1 s 與 split 約定。

   L5–65

---

3. `datasets/ho_utils.py` ↗

   GitHub · IRMVLab/Diff-IP2D · 733ae0150f

   與 OCT 逐行比較 normalized hand labels / missing mask，新增 homography 子取樣。

   L12–103

---

4. `datasets/holoaders.py` ↗

   GitHub · IRMVLab/Diff-IP2D · 733ae0150f

   查核 future features 限 train、observation homographies、uid / label 對齊。

   L87–124 · L193–258 · L303–366

---

5. `options/expopts.py` ↗

   GitHub · IRMVLab/Diff-IP2D · 733ae0150f

   固定 10 observation / 4 future、sample_times=10、fast_test。

   L1–28

---

6. `netscripts/epoch_feat.py` ↗

   GitHub · IRMVLab/Diff-IP2D · 733ae0150f

   追蹤 numpy WDE 與 FDE 真正路徑、batch / rank 平均與 affordance caller。

   L44–100 · L103–140 · L460–567 · L626–676

---

7. `evaluation/traj_eval.py` ↗

   GitHub · IRMVLab/Diff-IP2D · 733ae0150f

   逐行比較 OCT 檔案：除註解外相同；此 wrapper 不是所讀主迴圈的 WDE caller。

   L5–122

---

8. `evaluation/affordance_eval.py` ↗

   GitHub · IRMVLab/Diff-IP2D · 733ae0150f

   與 OCT 對照 heatmap / score 原生公式及省略 logging 的差別。

   L8–32 · L46–160 · L163–206

怎麼接入我們的benchmark

可重用

重用 OCT lineage、native labels / split、真正在主迴圈呼叫的 WDE / FDE 與熱圖 evaluator。；保留 full / fast diffusion 與 sample_times，不能將 10 次抽樣當 10 道題。

需要轉換

source 同時記 paper version、code commit、data archive hash；canonical case 禁止 training-only future features 出現在評測輸入。；原生 WDE、FDE、heatmap 各列公式和有效分母；若改為 sample-weighted global mean，需新增 evaluator 版本。；以父 participant/video/time 去重；EPIC55/100、OCT / Diff-IP2D 保留 overlap 關係。

仍需補齊

未下載 weights / features 或執行，README checkpoint links 與其他資料部署仍需逐一取得。；已有函式不等於已有完整測試任務，case metadata 與 raw video 許可權尚未整合。

P233 · OCT / HOI forecasting

Joint Hand Motion and Interaction Hotspots Prediction from Egocentric Videos

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

OCT / HOI-Forecast 以既有廚房 Ego 影片自動建立訓練 labels，另外人工標註評測軌跡與接觸熱區。已核對 labels、時間窗及實際評分入口，並記下目前程式的 ADE / FDE 命名對調與熱圖配對條件，供標準化時保留原始口徑。

> **版本與身份**
>
> 本次核對的是固定官方 commit。文中指出可直接驗讀的程式語義；不將未執行的靜態差異擴張成對論文分數的判定。

領域	餐飲與烹飪、穿戴互動與動作介面
環境	EPIC-KITCHENS-55 / 100 與 EGTEA Gaze+ 的人類廚房影片；EK100 延伸 EK55，與 Diff-IP2D 等工作共享影片或 labels。不是新增模擬場景。
任務	兩個相關輸出：未來左右手 2D 軌跡與 next-active object 接觸熱區。典型 4 Hz、2.5 秒歷史 / 1 秒未來；label 有邊界點+4 future 點，epoch eval 去掉第一點。任務輸出維度與多次生成 samples 不計為新情境。
題數與資料	訓練 labels 自動產生，評測 hand trajectory / hotspot 人工標註；uid、participant / video、frame indices、RULSTM split 必須一起保留。README 600 MB 是含 feature / partition / labels 的檔案大小，不是題數。未取得完整 labels，不能從目錄片段宣稱已整合全量。
評估方式	原生 compute_ade / compute_fde 正確區分平均 / 末點，但 evaluate_traj_stochastic 把 compute_fde 放入 ade_list、compute_ade 放入 fde_list，造成輸出名稱對調；實際 epoch 確實呼叫這個 wrapper。invalid GT 座標誤差乘零、時間長度分母仍保留。hotspot 在 32×32 Gaussian heatmap 計 SIM / AUC-J / NSS，NaN 個別剔除；zip 兩個 dict values 依 insertion order 配對，未按 uid join。另列的 F1 選當次資料最優 threshold，不是固定閾值分數。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **1,894** EK55 evaluation hand trajectories · 原文頁 5
- **3,513** EK100 evaluation hand trajectories · 原文頁 5
- **442** EGTEA evaluation hand trajectories · 原文頁 5

- **69** EGTEA evaluation hotspots · 原文頁 5

依這個順序讀

1. `README.md` ↗
   GitHub · stevenlsw/hoi-forecast · fbc85a17cd

   分離 automatic training labels / manual evaluation、父資料與兩種評測命令。

   L1–142

---

2. `datasets/datasetopts.py` ↗
   GitHub · stevenlsw/hoi-forecast · fbc85a17cd

   固定 4 Hz、2.5 s history、1 s future、RULSTM splits。

   L5–66

---

3. `datasets/ho_utils.py` ↗
   GitHub · stevenlsw/hoi-forecast · fbc85a17cd

   查核 normalized 2D、首個邊界點、缺失手 sentinel 與有效 mask。

   L12–86

---

4. `datasets/holoaders.py` ↗
   GitHub · stevenlsw/hoi-forecast · fbc85a17cd

   核對 uid / native split、label type 與 history/future frame alignment assertion。

   L189–251

---

5. `traineval.py` ↗
   GitHub · stevenlsw/hoi-forecast · fbc85a17cd

   區分 traj validation 與 affordance eval loader。

   L19–109

---

6. `netscripts/epoch_feat.py` ↗
   GitHub · stevenlsw/hoi-forecast · fbc85a17cd

   追蹤去掉首 GT 點、多次抽樣、dict 與 evaluator 的實際呼叫。

   L72–133

---

7. `evaluation/traj_eval.py` ↗

   GitHub · stevenlsw/hoi-forecast · fbc85a17cd

   核對 ADE / FDE 函式、stochastic wrapper 的對調與有效座標分母。

   L5–121

---

8. `evaluation/affordance_eval.py` ↗

   GitHub · stevenlsw/hoi-forecast · fbc85a17cd

   核對 Gaussian heatmap、SIM/AUC-J/NSS、key 對齊、NaN 與最佳 threshold。

   L8–32 · L46–76 · L79–227

怎麼接入我們的benchmark

可重用

重用人工 eval uid / labels、native splits、可追溯自動標註來源。；保留原生 wrapper 輸出及其實際定義，將任何更正以新 evaluator version 登記。

需要轉換

先以 uid join 預測和 GT，再檢查 expected-case coverage、順序、shape、有效手及 frame boundary。；canonical metric 明列公式、單位、mask 分母、sampling 次數和熱圖 kernel；原 native 名稱附別名對映，不靜默改名後混報。；兩個任務共享 clip/case lineage，多次 stochastic sample 僅增加 trial，不新增獨立資料。

仍需補齊

本次未執行上游模型或重現 README 分數。；完整資料獲取、生成標註程式的全流程及 licensed raw video 尚未整合；runtime adapter 需用小型有答案 fixture 查驗原生 / 更正版差異。

P234 · I-CVAE

Intention-Conditioned Long-Term Human Egocentric Action Forecasting

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

已沿 Ego4D clips→視窗 / 意圖→ICVAE generate→本地 ED/AUED 核讀核心程式。這是重用 Ego4D 的方法來源；52 個 scenario-derived intention、20 個未來位置與 K=5 候選是不同單位。串接預測、GT 條件消融及 challenge 分數必須分開。

> **版本與身份**
>
> 固定作者 repo commit 5b95d85e0bec6bd94851c867054c535c1afc6248；此程式快照早於 arXiv v4，沒有宣稱逐版結果一致。README 的已提供完整 code 不是本次核讀完整碼庫的證據；本次僅核以上核心區段與 taxonomy 結構。未取得權重、完整資料或重跑模型。
>
> 清單題名為 Intention-Conditioned Long-Term Human Egocentric Action Forecasting（2022 初稿）；已核快取為 arXiv:2207.12080v4（2024-04-08），題名改為 Intention-Conditioned Long-Term Human Egocentric Action Anticipation。作者均為 Esteve Valls Mascaró、Hyemin Ahn、Dongheui Lee。repo README 保留 Forecasting 標題，但連結並引用 WACV 2023 的 Anticipation，且具名第一作者維護，可確認為同一方法的作者程式，而非同名第三方。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	離線人類第一人稱 Ego4D 日常活動；物理場景資訊來自 ego4d.json 的 scenarios，程式將單一 scenario 視為高層 intention。沒有 robot reset、control 或可執行成功條件；scenario 數不代表場景 layout 或機器人任務數。
任務	H3M 由過去片段辨識 verb、noun、intention；I-CVAE 預測 Z=20 個未來 verb–noun 標籤，通常產生 K=5 序列。固定 taxonomy 為 115 verbs、478 nouns、52 intentions；論文 p.6 的 53 scenarios 是另一統計口徑。設定檔 N=8，論文端到端表格包含 N=2/4/6/8，最佳結果用 N=6，不能一律寫 N=4。

題數與資料	外部 fho_lta_{train,val,test_unannotated}.json 根為 clips；使用 video_uid、clip_uid、action_idx、verb_label、noun_label、action_clip_start_sec/end_sec，預處理另讀 action_clip_start_frame/end_frame。按 clip_uid 分組、action_idx 排序；case key 為最後觀測的 clip_uid_action_idx。input_clips / forecast_clips 各為 N / Z 筆，標籤 tensor 次序 [verb,noun]，forecast_times.label_clip_times 保留秒；缺 test label 補 -1，不能當有效類別。意圖 mapper 僅納入恰一個且在 52 類 taxonomy 中的 scenario，未提供多 scenario 的明確處置。SlowFast 特徵存 clip_uid_action_idx.pt；frame_to_feat 實際 int(frame/16)，W 引數未用；slice [start_feat:end_feat]，預設左補至 15 格。論文描述 2304 維特徵，不能把 feature index 當秒或控制步。完整標註 / features / ego4d.json 未隨本次取得，沒有聲稱完整 case 數。原生每 clip 視窗數為 max(0,L-N-Z)，迴圈缺 +1，最後一個完整視窗未取。
評估方式	ICVAE_Task.validation_step 分別評 verbs、nouns；pred [B,K,Z]→[B,Z,K]。lta_metrics.edit_distance 對每 case 取 min_k(editdistance.eval(pred_seq,gt_seq)/prefix_length)，再對 case 平均；AUED 對長度 1..Z 的 ED 做 trapz/(Z-1)，ED_19 是 Z=20 的末點，非第 19 個未來動作。validation_epoch_end 再不加權平均各 batch 指標；非 test 的 test_epoch_end 先依 clip key 合併去重後評分，兩者分母流程不同。論文稱 Damerau–Levenshtein 並報 action ED；此檔實際 import editdistance、呼叫 eval，未見 transposition 專用實作，也未在這條 Task 鏈計 action-pair ED，不能直接宣稱重現 challenge scorer。單模組 validation 使用 GT observed_labels 與 GT intention；create_prediction 才設 FROM_PREDICTION 串接 H3M。test GT 未公開，submission 每 case 含 verb / noun 的 K×Z 整數陣列。

依這個順序讀

1. `README.md` ↗

   GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

   題名、WACV 2023 引文與第一作者維護身分。

   `L1–5 · L10–40`

2. `Quickstart.MD` ↗

   GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

   Ego4D 外部特徵 / 標註依賴及單模組、串接測試的區別。

   `L11–44`

3. `ego4d/datasets/ptv_dataset_helper_features.py` ↗

   GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

   原生 clips JSON、秒欄位改名、按 action_idx 排序及實際視窗數。

   `L108–170 · L371–457`

4. `ego4d/datasets/LTA_features.py` ↗
   GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

   split、scenario→intention、verb/noun 次序、case key 及預測缺失時的回退。

   L197–263 · L296–313 · L336–402 · L405–499

---

5. `preprocess_dataset.py` ↗
   GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

   影格到特徵索引、左側補零與預處理入口限制。

   L6–56 · L66–142

---

6. `data/config/config_ICVAE.yaml` ↗
   GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

   此設定的 8 observed / 20 future、115 verbs / 478 nouns / 52 intentions。

   L1–18 · L28–82

---

7. `ego4d/config/defaults.py` ↗
   GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

   實際 K 預設為 5；不能把未覆寫的預設 horizon 當論文設定。

   L666–687

---

8. `ego4d/models/lta_models.py` ↗
   GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

   ICVAE 繼承 CAE，定位實際 generate 實作。

   L15–58

---

9. `ego4d/models/architectures/cae.py` ↗
   GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

   從觀測與意圖取樣 K 個 latent，只經 decoder / head 生成未來類別。

   L72–131

---

10. `ego4d/tasks/ICVAE_Task.py` ↗
    GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

    GT 條件 validation、batch 平均、去重輸出與本地計分呼叫鏈。

    L122–246

---

11. `ego4d/evaluation/lta_metrics.py` ↗
    GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

    best-of-K ED、prefix 正規化、AUED 梯形積分與函式註解差異。

    L6–14 · L71–115

---

12. `create_prediction.py` ↗
    GitHub · Evm7/ego4dlta-icvae · 5b95d85e0b

    H3M action / intention 預測合併與 FROM_PREDICTION 串接。

    L140–165 · L172–212

怎麼接入我們的benchmark

可重用

固定 taxonomy、clips 欄位及排序、case key、原生 ED/AUED 實作與 H3M→ICVAE 預測介面。

需要轉換

source 記 paper version+repo commit 並指回 Ego4D；domain 記人類活動，environment 記 video/scenario provenance；task 分 H3M recognition 與 LTA forecasting；case 用 dataset revision+split+clip_uid+最後 observed action_idx+N/Z；保留觀測秒 / 影格與特徵索引三種座標、GT/predicted intention 來源及不可見未來 label。evaluator 保留 verb/noun、best-of-K、prefix normalization、AUED 與 batch/global 聚合差別；不轉成機器人 success。

仍需補齊

須固定 Ego4D v1 標註 / feature revision 與 split manifest；核對 52 類 intention 排除的影片與 case 分母、末視窗少取及 batch 平均；比對正式 Damerau/action scorer。FROM_PREDICTION 缺 clip 時會借用隨機其他 clip 的 intention 並填 -1，接軌須改成可追蹤缺件。preprocess_dataset.py 的 Namespace 以字典取用且未定義 dir_annotations 引數，Quickstart 的 test_model.py 也不在固定 tree；這些都須在允許執行前修復 / 指定正確入口。

P235 · TransFusion

Summarize the Past to Predict the Future: Natural Language Descriptions of Context Boost Multimodal Object Interaction Anticipation

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

作者頁直接連 algvr/transfusion，已核 Ego4D v1/v2 reader、語言摘要輸入及實際 Top-5 STA mAP。此來源是離線下一次人類物件互動預測；外部摘要、SlowFast TTC 替換與跨 GPU 合併都是結果協定的一部分。論文 EK100 路徑在現行入口尚未閉合。

> **版本與身份**
>
> 固定 55d3a4eca3325dc65f5f0391cc27105ba110c00f。論文方法、作者專頁 CVPR 2024 release、Ego4D v1/v2 與 EK100 pseudo-label 實驗各留版本關係；同名 LiDAR TransFusion 不屬本篇。僅核上述核心來源，未執行上游、下載完整影片 / 模型 / 摘要套件。
>
> 精確題名與 Pasca、Gavryushin 等八位作者相符；清單 2023 是 arXiv 初稿，快取為 arXiv:2301.09209v4（2024-03-10）。PDF p.1 連作者專頁，專頁 HTML 52–117 行顯示相同題名、作者、CVPR 2024 與 Code→algvr/transfusion。專頁 / 現行 repo 支援兩版 Ego4D，不能把這個版本直接當 v4 文中全部 EK100 實驗的完整 release。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	Ego4D 人類第一人稱日常場景，包含廚房、園藝、維修等；論文另以 EPIC-KITCHENS-100 廚房影片驗證。輸入是 prediction frame 與其過去的語言化情境，沒有 robot state/action 或 simulator。
任務	每個 prediction uid 可有多個將互動的物件，預測 box、noun、verb、time_to_contact、score。v1 固定 mapping 有 87 nouns / 74 verbs，v2 為 128 / 81；這些是詞彙類別，不是新增任務數。Noun、Noun-Verb、Noun-TTC、Overall 為不同匹配限制的指標，另有 noun-only / verb-only 消融。

題數與資料	fho_sta_{train,val,test_unannotated}.json 以 annotations、noun_categories、verb_categories、info.video_metadata 組成；每筆 uid、video_id(v1)/video_uid(v2)、frame、clip_id、clip_uid、clip_frame、objects[{box,verb_category_id,noun_category_id,time_to_contact}]。框為原影像 xyxy 畫素，TTC 為秒；det_sec=frame/fps，fps 讀各影片 metadata，不能一律硬設 30。reader 轉 Bboxes/all_nouns/all_verbs/det_diff，objects_to_entries 只留最後物件 TTC，再對所有物件複製，接軌應保留原始每物件 TTC 並驗證此假設。LMDB 模式可縮至高 480，jpg 模式不先縮框。noun ID 0 移至末類以讓 0 作背景，輸出再還原；v1/v2 對 nut/tape 等字串處理不同。設定 subset=0 實際使用原始 orig_split；另排除 5 個 UID、有框過濾與讀圖失敗跳下一筆，故完整 case 分母須由版本化可讀 uid manifest 計算，不能直接沿用論文的 64,798 統計。test 中 ball/take 與固定框為 loader placeholder，不能當 GT。語言 JSON 用 prediction uid 索引，v1 將 object_lang/action_lang 直接串接，v2 加分號；目前 current 策略消費預先生成摘要。
評估方式	EgoNAOTrainer 的 train/val 均建 STAMeanAveragePrecision(top_k=5)，先將預測與 GT 框轉整數。每圖按 confidence 遞減、以最大有效 IoU 一對一配對；IoU 使用畫素端點 +1 面積，實作 boxes>0.5，abs(TTC error)<=0.25 秒。論文 p.5 寫 IoU>=0.5、TTC<0.25，邊界不可混寫。Top-5 實作對每種配對條件豁免該圖最高分的 (5-1)×GT物件數個 FP；不是隻計五類。剩餘預測依 class/confidence 合併，recall=累積TP/該類GT物件數，precision=TP/(TP+FP)，取單調 precision envelope 的 VOC 積分；count_all_classes=False，對有 GT 的類別作宏平均×100，joint 指標按 noun 平均。trainer 輸出 results[uid]=至多5個 {box,noun_category_id,verb_category_id,time_to_contact,score}，所以線上 raw-pred 指標與匯出檔重評有額外截斷差異。DDP 本地 AP 後同步不等於合併資料再計 AP；README 要合併 JSON 用 EGO4D/forecasting 正式指令碼。TTC loss 在兩設定均為 0，README 指論文結果使用外部 SlowFast TTC；這次沒有把本地 scorer 充當已核正式 server 結果。

依這個順序讀

1. `README.md` ↗

   GitHub · algvr/transfusion · 55d3a4eca3

   作者方法、資料版本、官方評分依賴與 TTC 後處理。

   L1–6 · L19–37 · L43–91

2. `data_preprocessing/utils/annotations_df_utils.py` ↗

   GitHub · algvr/transfusion · 55d3a4eca3

   STA annotations→DataFrame、原始 category/frame/TTC、split 與排除條件。

   L74–124 · L127–274

3. `data_preprocessing/utils/path_utils.py` ↗
   GitHub · algvr/transfusion · 55d3a4eca3

   uid-keyed 外部語言摘要替換；現行入口接受的資料來源。

   L62–125

---

4. `data_preprocessing/datasets/base_nao_dataset.py` ↗
   GitHub · algvr/transfusion · 55d3a4eca3

   video_id/video_uid、框縮放與 label mapping。

   L40–147

---

5. `data_preprocessing/utils/dataset_utils.py` ↗
   GitHub · algvr/transfusion · 55d3a4eca3

   noun 0 移至末類以保留背景；非單純全類別 +1。

   L82–143

---

6. `data_preprocessing/datasets/egonao_datasets.py` ↗
   GitHub · algvr/transfusion · 55d3a4eca3

   image/bboxes/labels/verb/ttc/id/orig_shape 及讀圖失敗時跳下一筆。

   L90–103 · L131–183

---

7. `runner/nao/configs/ego_nao_res50_ego4d.yml` ↗
   GitHub · algvr/transfusion · 55d3a4eca3

   v1 原生 split、外部摘要、current 策略與 TTC loss 關閉。

   L11–79 · L129–145

---

8. `runner/nao/configs/ego_nao_res50_ego4dv2.yml` ↗
   GitHub · algvr/transfusion · 55d3a4eca3

   v2 mapping / 摘要資產與多 GPU 設定。

   L11–79 · L122–152

---

9. `data_preprocessing/train_test_splits/utils.py` ↗

   GitHub · algvr/transfusion · 55d3a4eca3

   subset=0 實際沿用 orig_split，不執行名稱所示的新分層切分。

   L97–144

---

10. `runner/nao/snao_data.py` ↗

    GitHub · algvr/transfusion · 55d3a4eca3

    split 套用、空 test 回退與語言 wrapper 連線。

    L84–152 · L155–175 · L207–224

---

11. `modeling/narration_embeds/collate_wrapper_utils.py` ↗

    GitHub · algvr/transfusion · 55d3a4eca3

    current / previous wrapper 的實際選擇。

    L13–45

---

12. `modeling/narration_embeds/datasets/current_embeddings_dsets.py` ↗

    GitHub · algvr/transfusion · 55d3a4eca3

    current word wrapper 按 prediction uid 取得摘要；無生成時間稽核。

    L63–101

---

13. `runner/nao/ego_nao_data.py` ↗

    GitHub · algvr/transfusion · 55d3a4eca3

    EgoNaoDataset 接外部摘要 wrapper 的實際路徑。

    L53–79

---

14. `runner/nao/ego_nao_trainer.py` ↗

    GitHub · algvr/transfusion · 55d3a4eca3

    模型預測→本地 scorer、整數框、每圖僅輸出前 5 筆及輸出欄位。

    L15–31 · L107–158 · L195–250 · L400–438 · L500–501

---

15. `runner/metrics_losses/ego_metrics.py` ↗

    GitHub · algvr/transfusion · 55d3a4eca3

    實際 IoU/TTC 配對、FP 豁免、每類 GT 分母與 AP 積分。

    L4–59 · L123–205 · L207–288 · L302–364 · L468–561

---

16. `runner/utils/adapt_ttc_values.py` ↗

    GitHub · algvr/transfusion · 55d3a4eca3

    依 score 配對替換 TTC 及未閉合的 CLI / test_keys。

    L7–46

怎麼接入我們的benchmark

可重用

版本化 category mapping、原始 annotation→case 欄位、語言 uid lookup、STA 配對與 AP 聚合，以及 submission JSON 外形。

需要轉換

source 記 paper/repo/Ego4D revision；domain/environment 指人類影片及該筆場景；task 保留下一次互動預測；case key=(dataset_version,split,uid)，frame 與 clip_frame 各留參照系，boxes 記 xyxy/原圖尺寸，objects 與 TTC 逐筆保留。label 同時存原 category ID 與背景重編號；context 記生成模型、輸入最大 frame/time、摘要資產 SHA、GT / 預測模式。evaluator 區分本地 / 匯出 / 正式 server、Top-5 FP 預算、noun macro AP、TTC來源及 DDP 合併策略。

仍需補齊

需固定外部 context、Ego4D 標註與 SlowFast TTC revision；目前 loader 只按 uid 取字串，無法證明摘要只使用過去影格，w_leak=False 也不是此證明。核對多物件 TTC 被壓成一值、5 筆輸出截斷與實際可讀 case 分母。adapt_ttc_values.py 使用 argparse 的 description 引數、連字號 positional 名稱卻以底線取值，且 test_keys 未定義，不能視為可直接執行的 TTC 整合器；README 所述 evaluate_wandb_jsons.py 不在固定 tree。EK100 論文採 UniDet 產生 pseudo boxes 並依影片分割，現行 get_annotations_df 只接受 Ego4D，須找對應 release / 處理過的 manifest 才能宣稱重現。

P236 · ActFusion

ActFusion: a Unified Diffusion Model for Action Segmentation and Anticipation

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

已核 ActFusion 的 feature/label loader、full_len 遮罩推論、TAS scorer 與 LTA MoC。固定 release 的預設 LTA 仍使用完整影片長度；不可標成論文 ActFusion⁺ 的未知未來長度協定。訓練亦用 test split 分數選 best checkpoint，需保留模型選擇條件。

> **版本與身份**
>
> 固定 00ba6c1df0ac30cfcb90110278dd3616a589ced4。release 的 50 Salads epochs=7001、n_mask=10，Breakfast batch_size=16、feature layers=[7,8,9]；論文表 S5 / §5.2 有 5000 epochs、50 Salads mask=25、Breakfast batch_size=4 等差異，不能把公開 JSON 稱作逐項相同的論文設定。README 的 default_configs.py 實際位於 src/default_configs.py。本次未執行任何上游模型或訓練。
>
> arXiv:2412.04353v1（2024-12-05），Dayoung Gong、Suha Kwak、Minsu Cho，NeurIPS 2024。官方作者帳號 gongda0e 的 README 明列相同 arXiv、題名、作者與會議；搜尋中更早同名 magrogovich/ActFusion 不採用。PDF 提及 FUTR 和 DiffAct 是比較方法 / 重用程式，不能拿它們當 ActFusion release。此 repo 建立及固定 commit 為 2025-07-08，晚於論文。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	離執行緒序活動影片；Breakfast 與 50 Salads 是第三人稱烹飪來源，GTEA 是第一人稱烹飪來源，不能全部標 Ego 或機器人環境。程式以預先提取 I3D 特徵為輸入，不提供物理控制或 robot success。
任務	同一模型做 temporal action segmentation（TAS，完整觀測）及 dense long-term anticipation（LTA，部分觀測）；論文 TAS 用 50 Salads/Breakfast/GTEA，LTA 用前兩者。原生 action 數從外部 mapping.txt 的列數取得，event_list 的行序編碼與 read_mapping_dict 的首欄數字必須一致；這次未取得該資料包，未冒稱固定程式類別數。論文 50 Salads 的 50 videos/17 fine-grained labels、Breakfast 的 1712 videos/48 labels、GTEA 的 28 videos/11 labels是原作統計，不能直接當本次載入的有效 case 數。

題數與資料	datasets/{dataset}/features/{video}.npy、groundTruth/{video}.txt（一行一個 frame label）、mapping.txt（ID 名稱）、splits/{train,test}.split{split}.bundle。reader 接受二 / 三維 features，swapaxes 後為 augmentation×T×F，assert T 與 GT/boundary 長度一致；未知 label=-100。事件邊界在 label 改變點及前一格置1，再可 Gaussian smoothing。sample_rate=8（50 Salads）或1（Breakfast），temporal_aug 對各 offset::rate 建樣本，但 dataset 長度仍是 video 數；回復用 nearest interpolation 與首末值填充。時間原生為 annotation frame index，無可靠 fps/秒轉換資產隨 repo；2048 是輸入 feature 維度。paper 指 5/4/4 folds，程式每次只讀指定 --split，沒有自動跨 fold 聚合；完整資料包及有效長度未下載。
評估方式	預設 decoder-agg：LTA α=0.2/0.3，full_len=feature[0]時間長度，observed_len=round(α×full_len)，切掉未來視覺特徵後仍把 full_len 傳給 ddim_sample 追加 mask tokens；這是已知全長設定。各 temporal offset 機率平均，median filter（50 Salads=30、Breakfast=15 個取樣位置）、argmax，回復至 GT 全長。LTA 對 β=0.1/0.2/0.3/0.5，以 [int(αT):int((α+β)T)] 的原始 frame 範圍計各 GT 類別 n_T/n_F，先跨 videos 累加，再對有 GT frame 的類平均 n_T/(n_T+n_F)×100；不是 frame micro accuracy，也不是 best-of-K。TAS Acc=所有評測 frame 正確數/總 frame；Edit=每影片壓縮連續同標籤後的 (1-Levenshtein/max(segment_count))×100 再影片平均；F1@10/25/50 以同類 segment IoU 門檻一對一配對，跨影片累積 TP/FP/FN 後計 F1。只排除字面 background，不能預設所有 SIL/action_start 類被排除。LTA 同時回傳的 Acc/Edit/F1 是 observed prefix 上的分段分數，不能標成 future MoC。sampling seed=video_idx，25 sampling steps / 1000 diffusion steps；offset 不是新增試驗數。

依這個順序讀

1. `README.md` ↗

   GitHub · gongda0e/ActFusion · 00ba6c1df0

   精確論文與作者、自稱官方 release、MS-TCN 資料 / DiffAct 重用。

   `L1–9 · L31–64 · L84–109`

2. `main.py` ↗

   GitHub · gongda0e/ActFusion · 00ba6c1df0

   mapping、bundle split、單模型 TAS/LTA 入口與 α 設定。

   `L29–46 · L62–109 · L115–145`

3. `src/dataset.py` ↗
   GitHub · gongda0e/ActFusion · 00ba6c1df0

   feature/GT 對齊、未知標籤、時間降取樣、boundary 與回復全長。

   L11–107 · L110–126 · L129–189

---

4. `src/model/actfusion.py` ↗
   GitHub · gongda0e/ActFusion · 00ba6c1df0

   訓練遮罩與推論 full_len mask-token、DDIM步數 / seed。

   L192–248 · L342–429

---

5. `src/trainer.py` ↗
   GitHub · gongda0e/ActFusion · 00ba6c1df0

   各 offset 聚合 / median、MoC 呼叫及 test 指標選 checkpoint。

   L150–186 · L278–381 · L384–481 · L519–547

---

6. `src/utils.py` ↗
   GitHub · gongda0e/ActFusion · 00ba6c1df0

   具體 frame Acc、segment Edit/F1、MoC 的計數與分母。

   L71–200 · L239–264

---

7. `src/default_configs.py` ↗
   GitHub · gongda0e/ActFusion · 00ba6c1df0

   只產生兩資料集設定；核對 release 與論文超引數差異。

   L5–73 · L75–167

怎麼接入我們的benchmark

可重用

bundle/video key、mapping、逐格 labels/features 對齊、TAS 具體 Edit/F1 與 LTA class-count scorer。

需要轉換

source 儲存 paper version/commit 及 MS-TCN feature來源；domain/environment 依資料集視角分開；task 分 TAS 和 LTA，case=(dataset revision,fold,video,α,β,length_protocol)，frames/segments/augmentation 不互相加總。另記 F、feature_stride、offset、original_frame_index、round/int 邊界、median 窗、seed、DDIM budget；evaluator 區分 frame micro、video-mean Edit、pooled segment F1、class macro MoC。

仍需補齊

需固定完整 mapping/split/feature bytes與原始 fps，檢驗 mapping 行序=數字 ID、未知 -100、背景與末 segment end 的邊界（實作最終 end=i，非 i+1）。論文 §5.4 的 ActFusion† 用 r=4×observed length，此 release 的 CLI/config/已核 sampler 未提供該協定；須新增明確 adapter/取得對應作者版本。train 在 test_test_dataset 上計 TAS 五項平均與八格 LTA MoC 平均選 best / combined 模型，須改為獨立 validation 或如實標註。TAS及不同 α 共寫同一 prediction/{video}.txt，匯入須另用 protocol key 防覆寫。GTEA 無隨附設定與資料；不能只憑 main.py 的分支宣稱已接通。

P237 · Gated Temporal Diffusion

Gated Temporal Diffusion for Stochastic Long-Term Dense Anticipation

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

已核 GTDA 的 Breakfast/50Salads 與 Assembly101 loader、DDIM inference 及 Mean/Max MoC / Frame Diversity。三個指標有不同分母：candidate-pooled class accuracy、逐 case/β oracle 選樣後 class accuracy，以及候選兩兩 frame disagreement；不可折成共同 success 或把 Top-1 當部署模型選出的最佳預測。

> **版本與身份**
>
> 固定 010bad63c802e1666f64943dd098f3ac7be13118（2025-05-29），晚於ECCV 2024。readme所稱 precomputed_<dataset> 命名與實際 predict_precomp_bf_prob.sh 不同。論文對Breakfast/Assembly用50 DDIM steps，50Salads用10；不能把兩個已讀指令碼的50套全資料集。paper p.14 明指ANTICIPATR協定不同，不應與P240數值直接合併。僅讀核心區段及小型split/label來源，未跑模型或載入pickle / 大資產。
>
> arXiv:2407.11954v1（2024-07-16），Olga Zatsarynna、Emad Bahrami、Yazan Abu Farha、Gianpiero Francesca、Juergen Gall；PDF p.1 直接給 olga-zats/GTDA，README 引同一 ECCV 2024 論文。GTD 是 stochastic diffusion、GTAN 是其 deterministic backbone；同 repo 兩個模式不增加獨立來源數。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	離線烹飪（Breakfast、50 Salads）及玩具車組裝 / 拆解（Assembly101）。Assembly CSV 含固定 RGB 相機與頭戴 HMC view，程式按存在的 numpy feature 過濾，沒有隻選 Ego view 的條件；視角欄位必須留在 case，不能把所有來源標第一人稱。
任務	以 α=0.2/0.3 的觀測預測 β=0.1/0.2/0.3/0.5 的逐格動作標籤。Breakfast mapping=48類含 SIL；50Salads mapping=19類（17動作+action_start/action_end）；Assembly 使用 coarse action_cls/action_id，附帶 actions.csv 有202類，不是全部細粒度 action 組合。每訓練 video/view 衍生 α=.2/.3/.5 的3個 observation case，另有40%機率改為 .15+.25U；這些不是3支新增影片。

題數與資料	Breakfast/50s 為 D×T 的 .npy、逐行 label .txt、mapping.txt、split bundle。sample 回傳 features、classes、classes_all、classes_one_hot、mask_past、mask_future、vid_len、file_name；feature 只取 [:int(αT)] 並 [::sample_rate]，collate 在未來 / padding補零，label padding=C+1。--part_obs 將 prediction span設為全影片的 .5，所需長度仍源自完整 GT T。Assembly CSV 為 video_id,view,action_type,video_start_frame,video_end_frame；coarse_labels/{action_type}_{video_id}.txt 每行 tab 分隔 start,end,label（尾空欄依實作），依 end-start 展開，程式註明 @30fps；TSM_features/{video_id}/{view}/features.npy 用 [start:end] 裁切。feature缺檔、空segment或無長度會跳過，lmdb分支未實作。固定 split4 bundle 1136 train / 576 test unique video keys，無交集；這是名單數。Assembly train/val CSV 4684/1424列、204/61個 video_id，各16種view；尚非有效執行case數。儲存預測 pickle 以 action_type_video_id_view 或 Breakfast file_name 為key，值為K組復原逐格預測，gt_ 字首是全長GT。
評估方式	線上 validate 強制 batch_size=1，stochastic 用 EMA 產生 K=25 候選；Breakfast示例 sample_rate=3，Assembly=6，預測每個取樣位置重複該倍數回原格。對 [int(αT):int((α+β)T)] 計 n_T/n_F。Mean MoC 先把所有影片、全部K候選的每GT類別正誤格數相加，再對有GT的類別平均 T/(T+F)，輸出0..1；不是每影片MoC的平均。Max/Top-1 MoC 對每影片及每β依GT挑該範圍MoC最高的一個候選，累積其類別計數後再宏平均，同影片不同β可選不同候選。precomputed Frame Diversity 對每case取 K(K-1)/2 配對的 [1-相同frame數/該future窗長] 平均，再等權平均case。完整K=25對應300配對；test_num_samples 預設1會除零，不能沿用其預設。eval_file 另算 normalized segment Levenshtein error，但目前 MoC caller 丟棄該回傳，不能當正式主指標。程式把 x_0 GT傳到 predict，但底層只用 zeros_like取得形狀，生成值起於高斯噪聲；仍依賴GT長度，與GT action值洩漏需分辨。

依這個順序讀

1. `README.md` ↗

   GitHub · olga-zats/GTDA · 010bad63c8

   正式題名、作者與 Breakfast/Assembly features / annotation 外部依賴。

   L1–25 · L34–94

2. `src/main.py` ↗

   GitHub · olga-zats/GTDA · 010bad63c8

   資料分支、真實 action dict、α 與 evaluation 入口。

   L148–224

3. `src/batch_gen.py` ↗

   GitHub · olga-zats/GTDA · 010bad63c8

   bundle、3 個訓練 observation case、部分未來長度、零補 features 與 masks。

   L34–136 · L159–216

---

4. `src/batch_gen_assembly.py` ↗

   GitHub · olga-zats/GTDA · 010bad63c8

   view/action_type identity、coarse segment/end-exclusive 展開與缺 feature 排除。

   L18–20 · L78–179 · L182–255 · L278–332

---

5. `src/trainers.py` ↗

   GitHub · olga-zats/GTDA · 010bad63c8

   EMA sampling、原 frame 回復、Mean/Max MoC、輸出 pickle 與無效 stochastic Acc。

   L22–55 · L283–341 · L345–456 · L459–569

---

6. `src/bit_diffusion.py` ↗

   GitHub · olga-zats/GTDA · 010bad63c8

   確認 x_0 僅供形狀；self-condition 是先前預測，輸入 features 按觀測 mask。

   L305–352 · L380–471

---

7. `src/evaluation.py` ↗

   GitHub · olga-zats/GTDA · 010bad63c8

   實際 class TP/FN 計數、frame mismatch、segment edit 距離。

   L12–87

---

8. `src/diff_evaluate.py` ↗

   GitHub · olga-zats/GTDA · 010bad63c8

   預存候選選擇、best-per-case-and-horizon、成對 Frame Diversity 與聚合分母。

   L14–150

---

9. `src/main_diff_evaluate.py` ↗

   GitHub · olga-zats/GTDA · 010bad63c8

   precomputed 評測缺 mapping 的入口與 Assembly 空 dict 問題。

   L16–29 · L43–83

---

10. `scripts/prob/predict_bf_prob.sh` ↗

    GitHub · olga-zats/GTDA · 010bad63c8

    Breakfast split4、K=25、sample_rate=3、50/1000步與 epoch85。

    L1–33

---

11. `scripts/prob/predict_assembly_prob.sh` ↗

    GitHub · olga-zats/GTDA · 010bad63c8

    Assembly val、K=25、sample_rate=6與部分觀測。

    L1–30

---

12. `scripts/determ/predict_bf_determ.sh` ↗

    GitHub · olga-zats/GTDA · 010bad63c8

    GTAN 無 diffusion，且示例用不同 split1。

    L2–29

---

13. `scripts/prob/predict_precomp_bf_prob.sh` ↗

    GitHub · olga-zats/GTDA · 010bad63c8

    K=25 的 precomputed 示例未傳 --mapping_file。

    L1–19

---

14. `datasets/50salads/mapping.txt` ↗

    GitHub · olga-zats/GTDA · 010bad63c8

    17 動作外另含 action_start/action_end，原生19類。

    L1–19

---

15. `datasets/breakfast/mapping.txt` ↗
    GitHub · olga-zats/GTDA · 010bad63c8

    48類含 SIL，保留原始ID。

    L1–48

16. `datasets/assembly101/actions.csv` ↗
    GitHub · olga-zats/GTDA · 010bad63c8

    coarse action_id/verb_id/noun_id/action_cls 欄位與邊界 ID；不等於 fine labels。

    L1–16 · L195–203

17. `datasets/assembly101/train.csv` ↗
    GitHub · olga-zats/GTDA · 010bad63c8

    原生訓練 CSV 的 video、view、action_type、起訖影格樣例。

    L1–12

18. `datasets/assembly101/val.csv` ↗
    GitHub · olga-zats/GTDA · 010bad63c8

    原生 validation CSV 與多視角身份。

    L1–12

19. `datasets/breakfast/splits/train.split4.bundle` ↗
    GitHub · olga-zats/GTDA · 010bad63c8

    固定 split4 訓練名單樣例；另以全列 key scan 檢驗計數。

    L1–8

20. `datasets/breakfast/splits/test.split4.bundle` ↗
    GitHub · olga-zats/GTDA · 010bad63c8

    固定 split4 評測名單樣例；另以全列 key scan 檢驗計數。

    L1–8

怎麼接入我們的benchmark

可重用

原生 mapping、split與view身份、coarse-to-frame規則、TP/FN累積、候選pickle結構及Frame Diversity程式。

需要轉換

source 記paper/repo/data-feature revision，domain/environment依烹飪或組裝與view分類；task區分deterministic GTAN / stochastic GTD；case=(dataset revision,fold或train/val,video,action_type,view,α,β)，candidate_index屬case內試樣。保留annotation frame reference、sample_rate、GT-length protocol、K、EMA/checkpoint、diffusion T/D；evaluator標明Mean MoC / oracle Top-1 MoC / pairwise diversity各自分母與0..1尺度，不能直接對齊P236的百分比或P240的mAP。

仍需補齊

固定TSM/I3D及Assembly coarse annotation版本、實際feature存在清單，驗證start/end與view長度裁切。線上stochastic分支沒有累加frame error/num_frames卻仍輸出Acc，會得到0/0，應列為無效欄位。precomputed讀取硬編碼/home/user/diff_results/final，與writer的 ./diff_results 不同；predict_precomp_bf_prob.sh未傳mapping_file；Assembly的main_diff_evaluate把actions_dict設空，eval_file會以零長類別陣列索引，須修復後才能重評。固定test_num_samples>=2並檢查候選數 / 長度、有效GT窗；原程式min(pred_len,GT_len)可能縮短評測分母。尚未閉合50Salads的示例指令碼 / checkpoints與完整跨fold聚合。

P238 · Object-centric LTA

Object-centric Video Representation for Long-term Action Anticipation

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

已核 ObjectPrompt 的 Ego4D clips→視覺 / 物件features→K序列→ED/AUED 與submission核心。現行release有README維度及fps矛盾，物件特徵 / prompt生成資產未閉合；論文的50Salads MoC和EGTEA next-action實驗不能因共用論文而視為已核可執行。

> **版本與身份**
>
> 固定 a826b3d0317f03ee2636c200fb6255ac36f305ba；README、YAML、論文附錄的影片取樣與特徵維度須逐項核合，不能以下載到README/feature說明代替核心碼核讀。paper最終test報action ED但本地Task只評兩head。source tree中的ego4dv2僅見範例註解，不能當實際存在的v2設定。未載入模型、PT資產或重跑任何結果。
>
> arXiv:2311.00180v1（2023-10-31），Ce Zhang、Changcheng Fu、Shijie Wang、Nakul Agarwal、Kwonjoon Lee、Chiho Choi、Chen Sun。PDF p.1直接連brown-palm/ObjectPrompt，README對應同名WACV2024論文。清單2023是初稿年；程式固定2023-12-31 commit。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	人類離線影片。Ego4D與EGTEA Gaze+為第一人稱；50Salads為第三人稱烹飪。物件box及attention token是觀測表徵，不是robot pose、抓取目標或可執行動作。
任務	公開設定做Ego4D LTA：N=3個已標註過去segment、Z=20個未來verb–noun、K=5序列，115 verbs / 478 nouns。ObjectPrompt detector的81類embedding槽、每frame 10 detections與action taxonomy不同。論文另有EGTEA Gaze+ next-action top1/class-mean accuracy，以及50Salads α/β dense MoC；本repo tree只有Ego4D配置與clips reader，後兩者的資料 / scorer未閉合。

題數與資料	fho_lta_{train,val,test_unannotated}.json根clips，以相鄰clip_uid分組再按action_idx排序；用action_clip_start_sec/end_sec切.mp4，forecast_labels_idx為[Z,2]且次序verb,noun，last_observed_id=clip_uid_最後observed action_idx。設定input_segments=[-3,0)、output=[0,20)，mask預設false，名義上L個連續segments提供max(0,L-3-20+1)個完整視窗，仍須檢驗排序、短segment及資產可讀性。test label填-1。image/object檔為各clip_uid.pt；object每token先D維特徵，尾6欄是xyxy四值、class_id、confidence；依模型切片及配置，GLIP是256+6=262，CLIP是768+6=774；image維度分別256 / 768。bbox原始座標單位 / 縮放未由讀取器驗證。每segment選4個frame，每frame10物件，image token另存，可對應論文把整張frame算第11個object的敘述。README寫1FPS及GLIP232、CLIP image256，與配置image/object.fps=30和實際維度不符。索引由int(t*fps)取用，strict只把最後觀測segment末端扣半個feature frame；validation/test仍random抽interval frame，不能聲稱固定center sampling。
評估方式	ClassificationModule.generate的naive方法先把head logits clamp(min=0)，各verb/noun head獨立Categorical抽K序列；k=1才argmax。Task用[B,Z,K]逐head呼叫distributed_AUED：每case/prefix取min_k(editdistance.eval/該prefix長度)，再case平均；prefix 1..20積分trapz/(20-1)，ED_19即ED@20，AUED_mean只是verb/noun兩head平均。epoch再不按batch size加權平均；DDP all_gather後仍須檢查sampler重複和最後batch分母。這條鏈沒有joint action-pair ED；論文稱Damerau–Levenshtein，本地實際用editdistance.eval，正式server一致性未驗證。top1/top5為每position正確case/該batch case，對時間位置與head再平均，並非EGTEA所需class-mean。AUED在Z=1硬回1.0，不可拿來評next-action。test單GPU、無本地GT scorer，submission是{last_observed_id:{verb:K×Z,noun:K×Z}}。

依這個順序讀

1. `README.md` ↗

   GitHub · brown-palm/ObjectPrompt · a826b3d031

   精確論文、Ego4D v1、外部 features 說明與維度 / fps歧義。

   `L1–3 · L34–71 · L95–110`

2. `configs/ego4d/sf_video_image_object_glip.yaml` ↗

   GitHub · brown-palm/ObjectPrompt · a826b3d031

   N=3/Z=20、30fps、10物件、GLIP256維及checkpoint指標。

   `L1–57`

3. `configs/ego4d/sf_video_image_object_clip.yaml` ↗
   GitHub · brown-palm/ObjectPrompt · a826b3d031

   同協定的CLIP768維對照。

   L1–57

---

4. `src/defaults.py` ↗
   GitHub · brown-palm/ObjectPrompt · a826b3d031

   K=5、naive sampling、strict、mask與輸入來源預設。

   L104–113 · L169–210 · L232–296

---

5. `src/datasets/base_dataset.py` ↗
   GitHub · brown-palm/ObjectPrompt · a826b3d031

   原生clips / case建立、秒→feature索引、multi-modal tensor、split和reader。

   L34–48 · L84–174 · L239–336 · L338–472 · L474–522 · L528–649

---

6. `src/datasets/clip_samplers.py` ↗
   GitHub · brown-palm/ObjectPrompt · a826b3d031

   random / last / uniform clip取樣與短片段回傳差異。

   L11–44

---

7. `src/models/model.py` ↗
   GitHub · brown-palm/ObjectPrompt · a826b3d031

   物件尾6欄的實際切片、confidence處理及K序列生成。

   L147–199 · L340–352 · L406–482

---

8. `src/tasks/video_classification_task.py` ↗
   GitHub · brown-palm/ObjectPrompt · a826b3d031

   GT label只供loss/scorer，逐head/step分數、epoch聚合與test submission。

   L16–52 · L107–214

---

9. `src/utils/eval_util.py` ↗

   GitHub · brown-palm/ObjectPrompt · a826b3d031

   top-k分母、best-of-K ED/AUED與不等價的submission缺件檢查。

   `L9–13 · L34–50 · L52–152 · L154–168`

---

10. `scripts/run.py` ↗

    GitHub · brown-palm/ObjectPrompt · a826b3d031

    validation checkpoint選擇、固定seed、test限定單GPU。

    `L23–98 · L136–151`

怎麼接入我們的benchmark

可重用

Ego4D原始case key / label欄位、multimodal feature尾欄解析、confidence閾值及ED/AUED原生邏輯。

需要轉換

source儲存paper/repo/Ego4D版本與GLIP/CLIP prompt / features來源；domain/environment按資料集視角分離；task區分Ego4D sequence、EGTEA next-action、50Salads dense timeline。case=(dataset revision,split,clip_uid,last_observed_action_idx,N,Z)，時間保留原video秒、feature fps及index；box另記座標系，object_class_id與action noun分開。evaluator保留K、clamped-logit sampling、prefix normalization、head mean、batch aggregation與正式server角色；不產生共通success。

仍需補齊

取得並固定外部object/image features、prompt詞表（most-common/kmeans/coco）與其只由training資料建立的證據；先解決30vs1FPS、GLIP262vs232與CLIP image768vs256，再驗證shape與索引邊界。reader只load特徵、模型只信任尾欄，不能由README認定完整feature extraction已核。RandomClipSampler在短segment時回[a,b]，fill_video卻期待[[a,b]]，要修復或給出可追蹤排除規則。若任一啟用modality缺anno，convert仍可能以至少一modality收案，getitem卻要求全部啟用key，須檢查case完整性。submission checker硬從i=7起查且用位置i組key，與N=3的actual action_idx reader不同；不能當全case覆蓋驗證。50Salads/EGTEA仍需對應release與各自scorer。

P239 · MVP

Multiscale Video Pretraining for Long-Term Activity Forecasting

實作尚未確認 · 方法 / 綜述 · 原作 · 獨立頁面

已核精確MVP論文與第一作者官方頁；作者頁該篇的Code/Project連結是空href，兩筆GitHub查詢均零結果，作者公開repo名單也無可確認MVP實作。未發現已能固定版本並核讀的官方方法repo；保留paper-level資料 / 評測規格，不借用同名MVP或其他方法程式。

> **版本與身份**
>
> 無confirmed method-code commit可提供；已固定的1210bac9afe61febf68d5a205a31285254ee1141只屬第一作者網站index.html，不計為方法repo。查詢範圍限下列PDF、官方頁、兩筆GitHub repository search與第一作者14個公開repo metadata，結論是尚未確認，不是聲稱全球不存在程式。補查均HTTP200，沒有429 / 403 rate limit或deferred；未重試、未下載模型 / 資料資產。
>
> Multiscale Video Pretraining for Long-Term Activity Forecasting，Reuben Tan、Matthias De Lange、Michael Iuzzolino、Bryan A. Plummer、Kate Saenko、Karl Ridgeway、Lorenzo Torresani。快取PDF為arXiv:2307.12854v1（2023-07-24）；作者頁同名專案列Submission, 2023，未提供足以確認後續會議版的連結。MVP指Multiscale Video Pretraining，不是任何同縮寫的機器人預訓練或重建repo。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	論文研究離線人類第一人稱影片：Ego4D多種日常活動及EPIC-KITCHENS-55/100廚房活動。不是可reset的機器人環境；未取得作者實際reader，沒有把母資料集全庫時數當MVP有效樣本數。
任務	方法是self-supervised multiscale video pretraining，轉移到三種分開的任務：order-agnostic未來verb/noun集合、order-specific未來verb–noun序列、video-summary forecasting。最後一種是從候選文字摘要檢索正確摘要，不是生成文字摘要。訓練用future clip representation作target，不能當測試時可見未來影格。
題數與資料	已核論文§3.1及附錄B.1：video以10FPS抽樣，每clip8frames（約0.8秒），observed/future clip序列以N_O/N_F表示，K是兩序列的時間offset、S是timescale stride、N_P=N_F/S是預測尺度數。保留上述clip/time單位，K不能誤當Ego4D常見的5候選。order-agnostic label是N_verb與N_noun兩個multi-hot向量；order-specific是每預測位置的verb/noun ID；summary task是observed clip序列與整段摘要文字配對。附錄A說Ego4D沿用官方train/validation，test為held-out challenge，且各split出現的類別不一致；EK55/100是不同版本，沒有提供足以固定case清單的檔案。原生序列化key、annotation檔名、category ID對照、觀測百分比清單、summary候選集合與split manifest均未公開可核。正文泛定義預測剩餘影片，而§4.2.1實驗提next8 timesteps，不能未加分辨地套Ego4D Z=20。

評估方式	只有paper-level規格，未核到作者scorer。order-agnostic按verb與noun類別報mAP（presence within future span，非box IoU AP）；零positive類別是否納入、AP積分 / tie及樣本權重規則未能核實。order-specific報verb/noun/action edit distance，action為verb–noun組合；精確distance實作、正規化分母、候選數及選樣規則沒有code可確認，不能直接移植P234/P238的best-of-5。summary forecasting以R@1/5/10評估：分子是正確摘要進topK的video query數，分母是被評query數；完整候選池大小、同影片多摘要及重複處理未能核實。預訓練contrastive region accuracy是另一個訓練診斷，不是下游action成功率。附錄B.2稱下游凍結video model、訓練linear probes，應保留這一轉移設定。

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

可重用論文定義的pretraining→downstream關係、三種task區分、8frame/10FPS clip與時間尺度概念，以及各評測名稱；沒有可直接重用的已核reader/scorer。

需要轉換

source記arXiv v1、PDF SHA及author-page固定commit，作者網站明確標為publication evidence；domain/environment儲存人類Ego4D與EK版本；task分unordered multi-label、ordered sequence、summary retrieval。case/evaluator先儲存描述性規格與未解析欄位，不虛建案例、秒座標或通用success。未來若取得實作，須另建observed/future視窗、label vocabulary、summary candidate-set與training-only target可見性。

仍需補齊

需要有作者或primary paper明確連回的官方repo與40位commit、small example annotations/loader、split/category manifest，以及三種實際scorer及分母。另需釐清order-agnostic實驗的8步與剩餘全片定義、ordered ED的正規化/候選預算、summary retrieval候選集合。不能用Ego4D/EPIC資料本身或rxtan2的網站模板repo補成MVP實作。

P240 · ANTICIPATR

Rethinking Learning Approaches for Long-Term Action Anticipation

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

已沿ANTICIPATR的TSV/feature reader→instance-set預測→timeline / 集合前處理→evaluator核讀。其future比例以剩餘影片為基準，與P236/P237的全影片比例不同；公開commit的scorer鏈還有會阻止合法計分的變數、shape與case鍵錯誤，不能宣稱直接重現論文結果。

> **版本與身份**
>
> 固定 a7f0af215f50680e6b784df195a17884cb520bbf（2023-04-06）。論文§4與附錄A.1.3定義remaining-length protocol及dense重建，與其引用的全長比例benchmark需分項對待。主評測應保留模型提出的instance集合；loss配對不是scorer，loss_segment/loss_siou以跨rank平均target instance數（至少1）正規化，不是case成功率。僅核核心source區段與小型原生文字資料，未安裝、載入pickle / checkpoint或跑上游模型。
>
> Rethinking Learning Approaches for Long-Term Action Anticipation，Megha Nawhal、Akash Abdu Jyothi、Greg Mori，ECCV 2022；快取arXiv:2210.11566v1（2022-10-20）。PDF p.3直接連Nmegha2601/anticipatr，README列同題名作者。原生方法是兩階段Anticipation Transformer；不是固定20個verb–noun的Ego4D LTA。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	離線人類活動：Breakfast/50Salads第三人稱烹飪；EK55/EGTEA Gaze+第一人稱廚房。此release的stage2 build_dataset只註冊bf與ek，50Salads/EGTEA雖有pretraining名單及論文結果，不能視為stage2已接通。
任務	預測未來action instance集合，每instance是(label,start,end)，query數是最多預測槽數，不是任務數。stage1 snippet anticipation、stage2以凍結snippet encoder配合video encoder/decoder是論文方法關係，本次核心核讀以stage2資料 / 計分為主。Breakfast時間條件dense timeline評測；EK55時間無關future-label presence評測。固定Breakfast詞表48類含SIL；EK示例容量125 verbs/352 nouns/3806 actions，many-shot檔實際26 verbs/71 nouns，不能照ek.py的舊註解32 nouns。

題數與資料	名為.csv的split實際無header、tab分隔：video_path,start_frame,end_frame,verb_id[,noun_id]；另*_nframes.csv是video_path與全長frame數。DatasetSegmentRecord.num_frames=end-start+1。外部feature pickle是video→frame_index→2048維向量，reader不載RGB；目前切取range(start-31,end+31)中存在的key，會涵蓋觀測終點之後至+30的feature index，須驗證提特徵的時間支援域。區域性fps=1只是idx模數，不能解讀為1Hz；CLI fps預設60。target含video_id、labels_onehot、instance labels、label_mask、segments、duration、prediction_duration、observation_duration、ratio_idx、prediction_idx、observation_positions、fps；segments=(native_start/end-observation_duration)/prediction_duration，duration以秒存，observation/prediction_duration仍是frame數，單位混用不能抹平。EK action ID依各自CSV中的verb/noun頻率另建int_to_idx，可能造成train/val ID漂移。
評估方式	實際入案：只取end<=t的完整past與start>t的future，且各至少3個action；Breakfast future另需end<=pred_t，跨邊界action被排除。EK α=.25/.5/.75預測全部remaining；Breakfast α=.2/.3、β=.1/.2/.3/.4/.5，pred_t=t+int(β*(T-t))，論文表只報β=.1/.2/.3/.5。以固定val_S1文字檔依相同條件作結構重算（未載features）：Breakfast252影片/1548segments只產生12個視窗、5個video keys；EK67影片/7742segments產生172視窗、60個video keys。這是入案邏輯統計，非成功跑分。模型輸出pred_logits[B,Q,C+1]及pred_segments[B,Q,2]；後者實作ReLU+0.1，並未保證<=1或end>=start。get_unrolled_timeline將segment乘prediction_duration，重疊處逐類取最大softmax，去no-action後argmax；卻把整個future multi-hot label複製到所有時間位置當GT，未重建instance的逐格GT。get_mAP再把timeline presence加總clip至0/1，外層預定呼叫sklearn average_precision_score macro/micro；get_accuracy預定用1-hamming_loss按class平均×100，不能等同論文的class-normalized逐格MoC。snapshot的get_accuracy寫acc[k]但k未定義，get_AP_perclass未初始化preds[k_ap]/targets[k_ap]便append，get_accuracy_perclass對1D陣列argmax(axis=1)；所以沒有可認定正確的實際評測分母 / 合法輸出。engine更以video name為唯一key覆寫不同α/β視窗；單process下前述12/172視窗最多隻留5/60筆。

依這個順序讀

1. `README.md` ↗

   GitHub · Nmegha2601/anticipatr · a7f0af215f

   精確論文與兩階段方法 / 外部資料來源。

   `L1–3 · L15–38 · L42–50`

2. `src/datasets/__init__.py` ↗

   GitHub · Nmegha2601/anticipatr · a7f0af215f

   此release實際註冊只有ek與bf。

   `L1–12`

3. `src/datasets/bf.py` ↗

   GitHub · Nmegha2601/anticipatr · a7f0af215f

   Breakfast feature/split路徑與α=.2/.3。

   L13–43

---

4. `src/datasets/ek.py` ↗

   GitHub · Nmegha2601/anticipatr · a7f0af215f

   EK55 feature/split與α=.25/.5/.75。

   L14–44

---

5. `src/datasets/baseds_longfuture.py` ↗

   GitHub · Nmegha2601/anticipatr · a7f0af215f

   原生TSV、instance/set target、入案條件、相對remaining視窗與features時間界線。

   L21–53 · L75–180 · L183–277 · L295–372

---

6. `src/datasets/ds_utils.py` ↗

   GitHub · Nmegha2601/anticipatr · a7f0af215f

   video_id編碼 / 反解，以及engine只按影片建立鍵。

   L19–67

---

7. `src/main.py` ↗

   GitHub · Nmegha2601/anticipatr · a7f0af215f

   類別容量、matcher/query/fps預設與loader。

   L19–86 · L117–131

---

8. `run_scripts/run_anticipatr.sh` ↗

   GitHub · Nmegha2601/anticipatr · a7f0af215f

   實際EK示例125 verbs/352 nouns/3806 actions、900 queries。

   L1–3

---

9. `src/models/antr.py` ↗

   GitHub · Nmegha2601/anticipatr · a7f0af215f

   pred_logits / pred_segments、timeline生成、loss分母與scorer前處理錯誤。

   L29–95 · L135–190 · L206–229 · L241–324

---

10. `src/models/matcher.py` ↗

    GitHub · Nmegha2601/anticipatr · a7f0af215f

    實際greedy matching；import Hungarian不等於執行Hungarian。

    L21–80

---

11. `src/utils/segment_utils.py` ↗

    GitHub · Nmegha2601/anticipatr · a7f0af215f

    所稱generalized_segment_iou實際是普通一維IoU。

    L4–31

---

12. `src/engine.py` ↗

    GitHub · Nmegha2601/anticipatr · a7f0af215f

    criterion→每例metric→video-key字典覆寫→all_gather→evaluator。

    L73–123

---

13. `src/metrics/longfuture_metrics.py` ↗

    GitHub · Nmegha2601/anticipatr · a7f0af215f

    具體AP / accuracy實作、預期macro/micro與靜態可見失效點。

    L12–96

---

14. `data/bf/longfuture/annotations/bf_verbs.csv` ↗

    GitHub · Nmegha2601/anticipatr · a7f0af215f

    48類含SIL。

    L1–49

---

15. `data/bf/longfuture/split/val_S1.csv` ↗

    GitHub · Nmegha2601/anticipatr · a7f0af215f

    無header的TSV segment樣例與單一verb欄。

    L1–12

16. `data/bf/longfuture/split/val_S1_nframes.csv` ↗

    GitHub · Nmegha2601/anticipatr · a7f0af215f

    原生影片長度表。

    L1–12

17. `data/ek/longfuture/split/val_S1.csv` ↗

    GitHub · Nmegha2601/anticipatr · a7f0af215f

    含重疊instance的TSV、verb/noun尾欄。

    L1–12

18. `data/ek/longfuture/split/val_S1_nframes.csv` ↗

    GitHub · Nmegha2601/anticipatr · a7f0af215f

    EK影片長度表與path身份。

    L1–12

19. `data/ek/longfuture/annotations/EPIC_many_shot_nouns.csv` ↗

    GitHub · Nmegha2601/anticipatr · a7f0af215f

    實際71個many-shot noun ID。

    L1–72

20. `data/ek/longfuture/annotations/EPIC_many_shot_verbs.csv` ↗

    GitHub · Nmegha2601/anticipatr · a7f0af215f

    實際26個many-shot verb ID。

    L1–27

怎麼接入我們的benchmark

可重用

版本化TSV與length table、dataset-specific video_id、instance(label,start,end)、觀測 / future比例及原生query輸出介面；普通temporal IoU函式可作原生定義參照。

需要轉換

source記paper/commit及EgoTopo/MS-TCN feature來源；domain/environment保留view與dataset；task分instance-set模型、dense timeline與future-label set評測；case鍵必須包含dataset/split/video/α/β與有效視窗，而不只video。frame、秒、normalized-future座標分欄，native inclusive標註與rasterizer [start,end)保留差異；global action mapping與many-shot mask另版本化。evaluator必須重建合法GT timeline與每類正確/總GT格數，或儲存per-case presence及score以計AP；β剩餘長度協定不可直接換算成P236/P237表格同一格。

仍需補齊

優先修復criterion/evaluator未定義變數、mask形狀、GT timeline與engine視窗覆寫，再確認macro/micro / 空類 / frequent/rare的分母。須固定global action ID，noun分支instance["nouns"]與建立時"noun"也不一致。確認末端+30 feature索引是否越界可見、實際feature pickle及stage1 checkpoint版本、min-three入案排除，並取得50Salads/EGTEA的stage2 reader/scorer。build_matcher永遠回GreedyMatcher，CLI hungarian未接；generalized_segment_iou只算普通IoU；greedy將targets依長度排序後未還原原索引，需對照label配對。以上靜態疑點尚未執行驗證，不可把程式已下載當可重現。

P241 · AFF-ttention

AFF-ttention! Affordances and Attention models for Short-Term Object Interaction Anticipation

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

已核STA reader→預測affordance prior→AFF ROI head→OverallMeanAveragePrecision，以及新增EPIC STA pickle的讀取格式。固定release的v2設定仍遇v1欄位硬編碼及未隨repo提供的import；AFF、hotspots和完整執行環境尚未閉合，不能以README結果或外部權重連結宣稱可重現整篇。

> **版本與身份**
>
> 固定 1a1253fa2bde09ef1de4894f3bf872c1fbf270de（2024-07-15）。已核propagate_AFF_from_node.py用top1/3/5 visual及cross-modal鄰居、1.5×最近距離篩選、softmax(2×similarity)加權後逐類max、max-normalize再softmax；論文式(3)是加權sum後exp，不能混成同一prior配方。該指令碼np.save被註解，不能直接認定會產出reader所需檔；其diagnostic n_samples從1起算、最後分母多1，也不是STA mAP。generate_AFF_labels.py是另一cluster頻率版本，root標TRAIN但輸出名含VAL，需要provenance而非靠檔名判split。README連的weights與config checkpoint亦不同。只核以上核心source / 小型詞表，未跑模型、simulator或下載大資產。
>
> AFF-ttention! Affordances and Attention models for Short-Term Object Interaction Anticipation，Lorenzo Mur-Labadia、Ruben Martinez-Cantin、Jose J. Guerrero、Giovanni Maria Farinella、Antonino Furnari；Guerrero在清單/README也寫Josechu。快取arXiv:2406.01194v2（2024-06-05），README對應ECCV 2024，PDF hyperlink discovery直接指lmur98/AFFttention。README另連2407.04369 challenge report，不能混為本篇PDF版本或後續STAformer++。

領域	餐飲與烹飪
環境	Ego4D v1/v2日常活動與作者整理的EPIC-Kitchens STA第一人稱影片。affordance node/zone是影片中視覺相似的活動區域及其已觀察互動，不是3D場景layout或機器人可執行技能；hotspot是影像中的人手互動機率。
任務	下一次物件互動的box、noun、verb、TTC與confidence。v1 taxonomy87 nouns/74 verbs，v2 128/81；類別、prediction frame、GT object、zone/visit與policy trial各為不同單位。P241有新的curated EPIC STA標註貢獻，不能與P235的EK100 pseudo-box實驗或母EK action資料直接合併計數。

題數與資料	Ego4D JSON讀info.video_metadata與annotations；每ann含uid、video_id(v1)/video_uid(v2)、frame、objects[{box,noun_category_id,verb_category_id,time_to_contact}]。still圖為video_id_七位frame.jpg；fast LMDB以video_id為父目錄、video_id_十位frame為key，值是JPEG；sampler取frame-15..frame共16格、早於0補0，沒有取未來影格。frame索引與TTC秒保留各自單位。target是boxes/noun_labels/verb_labels/ttc_targets；noun固定+1，verb在ROI_HEADS.VERSION不含v1時+1，因此兩個aff設定都+1，與資料集v1/v2名稱無關。train移除退化框 / 無物件ann；test無objects時loader製造假框與0 label，不能作GT。AFF檔是list[dict]的numpy物件容器，key為v_id、frame、AFF_N_top3、AFF_V_top3等；reader把它們命名AFF_N_GT/AFF_V_GT，實際來源是predicted_AFF檔，缺項填全1 prior。EPIC pickle則是[{eid,video_id,timestamp,objects:{noun_category_id[],verb_category_id[],boxes[],time_to_contact[]}}]；框被當normalized xyxy乘(1920,1080,1920,1080)。影像frame=int(timestamp*30+1)，AFF lookup卻round(timestamp*30)+2；timestamp秒與這兩個索引不可混用。EPIC noun合群/排除others、verb刪除稀用詞都會改case分母；test分支實際重用val_annotations.pkl。未取得完整標註資產，未宣稱有效case總數。
評估方式	STATask.validation_epoch_end先list_gather所有rank、以uid建立pred/GT dict去重，再OverallMeanAveragePrecision(top_k=5)。每圖依score排序，針對各配對條件對尚未匹配的GT選最大IoU；IoU用xyxy畫素端點+1面積，門檻>0.5，TTC abs(error)<=0.25秒。Top-5對每圖每條件豁免(5-1)×GT物件數個最高分FP；餘下按confidence建立precision=TP/(TP+FP)、recall=TP/該類GT物件數，取單調precision envelope的VOC積分。12個輸出中前8個是合併類別的AP，後4個map_box_noun、map_box_noun_verb、map_box_noun_ttc、map_box_noun_verb_ttc才按有GT的noun類別宏平均×100；checkpoint用最後一項，不能把global AP混入主表mAP。AFF head將預測prior×各head softmax後重新正規化，去背景、每proposal保留verb_topk=1、noun×verb分數>0.002（不是config的0.05），per verb–noun NMS後最多100 detections；此預測budget與scorer的Top-5 FP豁免不同。export把noun減1、verb減相應offset，輸出results[uid]的box/score/noun_category_id/verb_category_id/time_to_contact。test僅匯出，無公開GT scorer結果。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **1** STA joint prediction formulation · 原文頁 10

依這個順序讀

1. README.md ↗

   GitHub · Imur98/AFFttention · 1a1253fa2b

   精確論文、STAformer/AFF/hotspot角色、Ego4D版本及新增EPIC STA標註。

   L3–14 · L25–51 · L55–76

---

2. stillfast_code/test_dir/Aff_ttention_v1/config.yaml ↗

   GitHub · Imur98/AFFttention · 1a1253fa2b

   v1類別、16-frame輸入、aff head、split與輸出開關。

   L13–35 · L39–76 · L114–162

---

3. stillfast_code/test_dir/Aff_ttention_v2/config.yaml ↗

   GitHub · Imur98/AFFttention · 1a1253fa2b

   v2類別與資料路徑；不能用folder名稱代替reader版本核對。

   L11–35 · L39–76 · L115–162

---

4. stillfast_code/datasets/ego4d_sta_still.py ↗

   GitHub · Imur98/AFFttention · 1a1253fa2b

   原始STA schema、train清理、硬編碼v1 key與label offsets。

   L22–38 · L40–82 · L102–153 · L180–203 · L232–258

---

5. stillfast_code/datasets/ego4d_sta_still_video.py ↗

   GitHub · Imur98/AFFttention · 1a1253fa2b

   past-frame sampler、預測AFF載入 / lookup、缺件均勻prior與batch欄位。

   L9–17 · L72–110 · L168–226

---

6. stillfast_code/datasets/sta_hlmdb.py ↗

   GitHub · Imur98/AFFttention · 1a1253fa2b

   LMDB父目錄 / 10位frame key與JPEG bytes。

   L8–21 · L36–56

---

7. `stillfast_code/models/stillfast.py` ↗
   GitHub · Imur98/AFFttention · 1a1253fa2b

   Dino/EgoVLP及aff head實際分派、外部StillFast依賴與缺import。

   L1–25 · L73–128

8. `stillfast_code/models/faster_rcnn.py` ↗
   GitHub · Imur98/AFFttention · 1a1253fa2b

   noun_labels改名labels並把AFF附加target送入head。

   L120–154

9. `stillfast_code/models/faster_rcnn_AFF_sta.py` ↗
   GitHub · Imur98/AFFttention · 1a1253fa2b

   Bayes乘prior再正規化、verb_topk、score/NMS與最終預測。

   L190–260 · L287–391 · L396–441 · L443–584

10. `stillfast_code/tasks/sta.py` ↗
    GitHub · Imur98/AFFttention · 1a1253fa2b

    跨rank收集後uid去重、去AFF target、實際Overall mAP及提交ID還原。

    L36–92 · L94–193

11. `stillfast_code/evaluation/sta_metrics.py` ↗
    GitHub · Imur98/AFFttention · 1a1253fa2b

    具體GT配對、FP預算、VOC積分與global AP/noun-macro mAP分母。

    L4–59 · L121–205 · L207–359 · L416–523

12. `code_extract_affordances/generate_AFF_labels.py` ↗
    GitHub · Imur98/AFFttention · 1a1253fa2b

    cluster/node/visit/STA→每zone標籤分佈與資料檔格式。

    L1–26 · L28–61 · L83–91

13. `propagate_affordances/propagate_AFF_dataset.py` ↗
    GitHub · Imur98/AFFttention · 1a1253fa2b

    v2 validation query v_id/frame/STA targets；標籤供diagnostics。

    L8–30 · L80–96

---

14. `propagate_affordances/propagate_AFF_from_node.py` ↗
    GitHub · Imur98/AFFttention · 1a1253fa2b

    train-node descriptors、query visual matching、weighted-max priors、診斷分母與輸出未寫檔。

    L24–50 · L61–122 · L124–165 · L281–391 · L396–412

---

15. `stillfast_code/datasets/ek_55_sta_dataset.py` ↗
    GitHub · Imur98/AFFttention · 1a1253fa2b

    EPIC專用pickle/eid/timestamp、class merge/filter、normalized框與frame偏移。

    L79–120 · L138–213 · L224–256 · L260–405

怎麼接入我們的benchmark

可重用

Ego4D v1/v2 taxonomy、STA JSON與EPIC pickle reader的原生欄位、predicted-prior lookup / Bayes fusion、具體mAP與submission adapter。

需要轉換

source記paper/commit、Ego4D或curated EPIC annotation revision、StillFast base與prior/hotspot資產；domain/environment為人類影片和zone provenance。task保持STA；case用dataset+split+uid/eid，另存video/frame/timestamp、原框座標、class_remap/背景offset。zone/visit/node及其training STA/narration是source附屬資料，不增加case。evaluator固定score生成、verb_topk/NMS/100候選、Top-5豁免、TTC門檻、noun macro AP與uid去重；跨source不等價為robot success。

仍需補齊

優先修復Ego4D reader的video_id硬編碼與v2 video_uid；固定StillFast base commit / 安裝佈局，補缺的ego4d_sta_hands_still_video、faster_rcnn_HANDS_sta、faster_rcnn_prior_HANDS_sta、detr_criterion等被無條件import的模組。移除...及作者絕對路徑，固定完整split/annotation與predicted_AFF/hotspot SHA。AFF資料庫生成 / descriptor取樣仍需train-only及時間可見性核驗；當前code以train_nodes匹配visual query，不能因GT欄名就指為oracle，也不能因檔名train就視為已證明無洩漏。EPIC需要固定class_names、實際class remap及兩套frame偏移，且test=val不能當獨立test。hotspot讀入有外部placeholder，當前Ego4D __getitem__的contact-point呼叫與heatmap target被註解，selected aff鏈未核到完整hotspot重權重執行路徑。

P242 · NAOGAT

Leveraging Next-Active Objects for Context-Aware Anticipation in Egocentric Videos

實作尚未確認 · 方法 / 綜述 · 原作 · 獨立頁面

已核NAOGAT原作、WACV刊載頁及作者現行project：GitHub仍標示Soon，EK-100新增NAO框標註須向作者索取。可收錄論文層級的STA方法與標註衍生關係，尚無可固定commit並核讀的官方reader / evaluator。

> **版本與身份**
>
> 2023年arXiv摘要承諾接受後提供code；2026-10-11讀到同篇project仍為GitHub(Soon)，有Code標題但沒有方法連結。project文末誤標WACV 2023，刊載年份以CVF 2024為準；本筆技術內容僅按已固定arXiv v3核讀，未聲稱和會議PDF逐段一致。探索用/wacv24短網址返回404，其後由作者about找到可用現行project；這不是GitHub repo不可用或全球無code的證明。本輪小型HTML讀取除該404外均200，未遇429 / rate-limited403；未聯絡作者或讀取內嵌影片。
>
> 精確題名為Leveraging Next-Active Objects for Context-Aware Anticipation in Egocentric Videos；Sanket Thakur、Cigdem Beyan、Pietro Morerio、Vittorio Murino、Alessio Del Bue。核讀快取arXiv:2308.08303v3（2023-10-05）；CVF確認WACV 2024、pp.8657–8666。作者about以略不同的Short-Term題名連回同一arXiv及本project。ANACTO、GANOv2是另篇方法；網站模板richzhang/webpage-template亦非NAOGAT程式。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	Ego4D人類第一人稱日常活動及EPIC-KITCHENS-100廚房影片，皆為離線觀測。STA假設下一互動物件在最後觀測影格可見；EK-100原有action anticipation並不保證此條件。未提供可reset的robot場景或動作控制介面。
任務	輸入截至T的RGB序列，預測下一active object的noun類別n、最後觀測影格中的bounding box b、未來動作verb v及距接觸的δ秒。NAO定位與動作 / TTC聯合預測屬一個STA問題的不同輸出，不是四套機器人任務。EK-100實驗仍須和Ego4D STA分開記錄。
題數與資料	§3–4.2：16影格、4 FPS；訓練resize高度248–280 pixels並crop224。Faster R-CNN偵測輸入為每物件4個框座標加confidence，固定Q筆不足時padding；Q/Nq的實際值、座標順序 / 正規化與序列化key未能由reader核實。Ego4D forecasting部分稱逾1000影片、STA標註30 FPS；EK-100母庫97 verbs / 300 nouns / 約90K action segments皆非本篇有效case數。附錄§7的EK-100框由GT noun匹配偵測器結果產生，失敗再用hand-object ROI及top-3 noun候選；noun仍沿用EK標籤，不是新人工重標整庫。12.5% training、6% Unseen及約22% Tail的NAO缺失分別有不同分母；附錄另把22%稱validation中的「Test Set」，需原始ID核對。現行project只提供索取標註的聯絡方式，沒有已取得的annotation檔、split manifest或loader。

評估方式	僅核到paper protocol：§4.3以noun / verb top-1判對、box IoU≥0.5及|TTC誤差|≤0.25秒；聯合條件須全部滿足。Table1列8種b/n/v/δ組合的AP，但正文概述稱4組，應保留各欄位而非併成單一成功率。候選預算、AP積分 / macro平均、confidence合成及漏標樣本處理沒有scorer可核，不能逕套另一篇Ego4D的Top-5實作。EK-100 Table2分Unseen/Tail/Overall及action/verb/noun；§4.3僅援引先前方法的metric，未在本版明列其Top-k / 類別平均細節。§4.4剔除無NAO的tail clips後所得分數屬另一次過濾評測，不能覆蓋原validation分母。

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

可重用原作身份、Ego4D STA / EK-100衍生框標註關係、四項預測輸出、16frame/4FPS輸入及論文明列的IoU與TTC門檻；尚無已核可執行reader或scorer。

需要轉換

source保留arXiv v3及WACV 2024關係；domain/environment限定人類影片脈絡，task以STA定義建檔。未來case須帶video/segment身份、最後觀測影格、原生box參照、noun/verb taxonomy、δ秒及缺失NAO原因；Ego4D、EK原split及過濾子集分開。evaluator儲存各AP組合與尚待核實的EK metric，不把母庫frames/segments或模型queries當case數。

仍需補齊

作者可確認的官方方法repo / commit、EK衍生框檔案及授權、精確split與NAO缺失ID、座標 / 時間轉換reader、分類與AP evaluator。需釐清附錄Test Set / 正文Tail Set及EK metric細節；ANACTO或GANOv2程式不可代填。

P243 · FactCheck（LTA）

FactCheck: Feasibility-aware Long-term Action Anticipation with Multi-agent Collaboration

實作尚未確認 · 方法 / 綜述 · 原作 · 獨立頁面

已核FactCheck原作的Observe–Plan–Verify流程、資料與mAP設定，並找到通訊作者列出的同篇IET Software論文；該條目僅連Paper，尚無confirmed官方方法repo。本文的Verifier是LLM推理模組，報告的mAP是未來類別集合評測，不能當成實體可行性驗證或機器人成功率。

> **版本與身份**
>
> cached repository query「FactCheck action anticipation」為0筆；arXiv摘要及PDF連結抽取沒有method code連結，Qwen/Grok連結屬模型引用。通訊作者同篇publication條目只列期刊Paper。一次依該連結讀取Wiley得到HTTP403 Forbidden，共享network.py沒有標成rate_limited，未重試；期刊版code/data availability仍未核到，另列為待查來源，不能把403當repo不存在。技術結論限固定arXiv v1；未確認全球不存在程式。
>
> FactCheck: Feasibility-aware Long-term Action Anticipation with Multi-agent Collaboration；Rui Cao、Jiannong Cao、Bo Yuan、Zhiyuan Wen、Mingjin Zhang。固定核讀arXiv:2606.14778v1（2026-06-10）；首頁的Journal 2023與DOI xxx/xxxx是模板內容。通訊作者Zhiyuan Wen的publications頁列同五位作者及IET Software 2026、DOI 10.1049/sfw2/7118691。此FactCheck是動作預測方法，非同名新聞 / 文字事實查核專案。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	離線EPIC-KITCHENS-55與EGTEA Gaze+人類第一人稱廚房活動。Observer由已觀測片段的辨識結果重建物件狀態，並非從robot simulator取得真實狀態。§5.4的長程操作及人機協作屬未來應用構想，沒有本篇實體robot評測環境。
任務	§3以M個action segments構成影片、N=floor(αM)個歷史片段預測Z=floor(βM)個未來verb–noun動作；α為25/50/75%，β≤1−α。Observer產生歷史動作、意圖 / 環境摘要及圖；Planner生成有序草稿；Verifier依Object Availability、Affordance Validity、State Consistency修正。三個agent是推理角色，不是三臺robot，也不是三個獨立benchmark。§5.1.1實際評測取剩餘影片中的動作類別集合，須保留「序列生成、集合計分」差異。

題數與資料	§4.1與§5.1.3：每action segment均勻抽4影格，以凍結CLIP-ViT-L/14-336px加訓練分類head辨識verb/noun；抽樣是每片段4張，非4 FPS。History Action Abstract是一句生成文字。圖的noun node儲存Attr(n)=(v,t_start,t_end)，edge weight計歷史轉移頻率；時間單位未明列。Table3提供示意JSON的nodes[].id/state/history及edges[].src/tgt/w；§5.1.3另稱圖序列化為JSONL，未取得真正檔案或parser，不能將示例當已驗證schema。Planner用Qwen2.5-3B/7B-Instruct與QLoRA；摘要及Verifier用grok-4-1-fast-reasoning，Verifier prompt含3個人工few-shot範例。母庫的EK-55 39.6K segments / 125 verbs / 352 nouns及EGTEA 86 videos / 10,325 action instances / 19 verbs / 53 nouns，不是本篇測試case數。精確split ID、完整提示與範例、生成輸出及資料reader均缺。
評估方式	§5.1.1按α=25/50/75%的觀測比例，對剩餘(1–α)部分的未來類別做mAP-All / mAP-Freq / mAP-Rare；Freq/Rare沿EGO-TOPO分組，這裡未提供類別表或頻率門檻。未核到實際sequence→class score轉換、重複動作處理、AP積分 / 空positive類別及各α平均方式。沒有獨立的物理可行性真值、constraint violation rate或robot rollout；Table3是定性修正案例，不能作scorer。§5.1.1稱沿用train/test split，§5.2.1卻將EK-55結果稱validation；§3的floor與79動作案例「50%=40個observed」亦不一致，須以原始case生成器釐清。

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

可重用三角色流程、歷史資訊可見性、三種feasibility約束、圖示意欄位、每segment4影格與多觀測比例，以及mAP-All/Freq/Rare的原生名稱。未取得作者可執行checker或dataset reader。

需要轉換

source保留arXiv v1及作者頁所列journal關係；domain/environment歸人類影片預測。task同時儲存有序生成目標與無序集合計分。case應保留video/segment、α/β、observed recognized labels、生成摘要 / 圖、draft與refined outputs，並與GT分離；evaluator記類別與頻率分組、提示 / 模型版本及取樣預算。圖中的狀態為推斷記憶，不升格成已確認的實體世界狀態。

仍需補齊

官方method repo與commit、完整graph schema / 讀寫器、觀測切點及split manifest、sequence-to-score與mAP實作、三個few-shot範例及API設定。需釐清noun node與文中action edge的連結語義、JSONL和表中JSON示例的對應、floor邊界及test/validation稱法；若要評機器人可行性，還缺獨立狀態真值與執行判準。

P244 · BiAnt

Bidirectional Action Sequence Learning for Long-term Action Anticipation with Large Language Models

實作尚未確認 · 方法 / 綜述 · 原作 · 獨立頁面

BiAnt的固定論文、Panasonic作者頁與精確arXiv-ID查詢均未提供可確認的方法repo。已核明forward為8段觀測→20段預測，backward為訓練時16→12；測試只做forward，以5組候選的最低edit distance評測。

> **版本與身份**
>
> 快取「BiAnt」repository search共有74筆但只返回8筆，這8筆為無關帳號 / 專案，未聲稱已排除全部74筆。新增精確查詢「"2508.00374" in:readme」HTTP200、total_count=0、incomplete_results=false。Panasonic作者頁同篇條目只有arXiv link；arXiv頁無method repo連結。結論為限定查證範圍內尚未確認code，不是不存在證明；本輪小型讀取 / 查詢均200，未遇rate limit。
>
> Bidirectional Action Sequence Learning for Long-term Action Anticipation with Large Language Models；Yuji Sato（Panasonic Connect）、Yasunori Ishii（Panasonic Holdings）、Takayoshi Yamashita（Chubu University）。固定arXiv:2508.00374v1（2025-08-01）；arXiv comments及Panasonic的Ishii作者頁均列MVA2025 / Best Poster Award。同頁其他Panasonic code links、AntGPT基線及名稱相似BiAnt搜尋結果不代表本篇實作。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	Ego4D v2離線人類第一人稱日常活動，例子包含桌面紙板處理與洗衣。沒有可互動的robot環境；automated driving / robotics為動機，不是新增已測試場景。
任務	以過去action segments中的辨識noun / verb標籤預測未來verb–noun序列。訓練同時用[forward]和[backward]提示；原來8個observed加20個future action形成28段視窗，反向訓練取倒序16段作context、餘12段作target。推論只輸入8段已觀測動作作forward預測，backward所用未來標籤屬訓練資料，不能放進測試可見context。
題數與資料	§3–4將動作形式記為a=(n,v)，Fig.2的實際prompt文字則用verb noun；轉換時須以欄位身份而非tuple位置硬套。母庫詞彙為117 verbs / 521 nouns；每segment約240 frames是論文概述，不是固定片長，沒有已核FPS / 時間邊界或序列化key。visual encoder與action recognition在本方法LLM訓練時凍結，具體骨幹與reader未能核實，不以AntGPT目前程式補填。LLM為Llama2-7B、引數有效微調、8-bit量化；forward/backward loss權重均1。Table1是Ego4D v2 test；§4另明示task-token ablation使用官方validation中的160樣本，未提供這160筆ID或完整test case數。附錄S1的16是backward context長度，不是推論觀測長度。

評估方式	§4報noun / verb / action三種ED，越低越好；K=5生成候選中選最低ED，Z=20為每條預測的action位置數，不是20秒。未核到距離演算法的操作集合 / 正規化分母、三種指標是否各自挑不同候選、未知標籤 / 長短輸出處理、候選取樣引數與scorer。Table1的test分數與160-sample validation ablation及附錄S1數字需分開，不能將160當整個benchmark題數，亦不能將best-of-5 ED改叫單次成功率。

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

可保留Ego4D v2依存關係、117/521詞彙規模、8→20 forward / 16→12 backward設定、方向提示與K=5 ED協定，以及test和160樣本ablation的區分。沒有可直接重用的已核BiAnt loader或evaluator。

需要轉換

source固定arXiv v1並記MVA2025；domain/environment歸人類影片。task將training direction和inference direction分開；case須保留video/clip/segment ID、stopping boundary、verb/noun taxonomy、observed window、20步GT與5條候選。backward pairs僅連train split；evaluator儲存ED種類及候選預算，native action index不任意轉成秒或robot控制命令。

仍需補齊

官方BiAnt repo及commit、28段視窗與反向樣本產生器、GT / 辨識label來源和split隔離、prompt/output parser、精確label-ID表、160筆ablation manifest與ED實作。AntGPT是文中採用的baseline，未確認其任何固定commit包含BiAnt改動。

P245 · ICVL

Vision and Intention Boost Large Language Model in Long-Term Action Anticipation

實作尚未確認 · 方法 / 綜述 · 原作 · 獨立頁面

已核ICVL的原作方法、訓練例子選擇與兩套評測協定；快取查詢及精確arXiv-ID查詢均無repo，另查的候選作者帳號只有其他題名的專案。尚未確認官方ICVL實作；院校作者頁的412存取限制另列，不能當成沒有code的證明。

> **版本與身份**
>
> 核讀範圍為固定arXiv v1方法與實驗，未建立新的會議 / 期刊版本假設。cached「ICVL egocentric」為0筆；一次「"2505.01713" in:readme」亦HTTP200、0筆、incomplete_results=false。另核Mia-YatingYu候選帳號返回的3筆公開repo metadata，題名均不匹配ICVL；帳號候選不構成作者為本篇公開code的證明。Congqi Cao院校頁一次返回HTTP412 Precondition Failed，未讀到正文且未重試；此為author-page access limitation，非rate limit或repository unavailable。結論限已查證來源，非宣稱全球沒有code。
>
> Vision and Intention Boost Large Language Model in Long-Term Action Anticipation；Congqi Cao、Lanshu Hu、Yating Yu、Yanning Zhang，Northwestern Polytechnical University。固定arXiv:2505.01713v1（2025-05-03）；ICVL在本篇指Intention-Conditioned Vision-Language，不是同縮寫的其他資料庫或實驗室。AntGPT、PALM及候選帳號的STDD / Open-MeDe / Cue-R1均非本篇code。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	Ego4D人類第一人稱日常環境，及EPIC-KITCHENS-55 / EGTEA Gaze+的廚房活動影片；都是離線影片預測。意圖是VLM從已觀測影格推斷的文字，並非新增人工意圖真值集，也沒有robot場景 / 控制介面。
任務	ICVL先辨識歷史verb–noun labels，再從按時間順序抽取的觀測影格逐步推斷intention；每次VLM輸入包含先前生成的intention context，以最後結果作最終意圖。ICAF以意圖embedding為query、視覺embedding為key/value，再與文字prompt合併預測未來序列。Ego4D目標是noun / verb / action序列；EK-55與EGTEA明定為剩餘影片中會出現的verb集合，不能把兩者共用一個sequence evaluator。

題數與資料	§3：segment Si對應Ai=(vi,ni)；每段均勻取k影格形成visual embeddings，總數T=Nseg×k，意圖另取Nfrm影格；k/Nfrm的數值、FPS、實際annotation key及split manifest未提供可核reader。歷史action recognition用CLIP ViT-L/14與Transformer加兩個MLP heads；ICAF的visual encoder為BLIP2-OPT-2.7B，意圖VLM原文明寫「LLaMA 3.2-9B」，text encoder及預測LLM為LLaMA 3-8B，精確模型ID / revision仍待設定檔核實。例子只從training pool取observed labels與future labels；先對視覺及文字embedding的L2距離各自min–max正規化，再用α加權，距離較小為較相似。α實際值、零距離範圍 / ties處理未核到。§4.4雖說7例最佳，最終結果明確採3個例子。Ego4D的243小時 / 3472 clips、117 verbs / 521 nouns以及EK-55的125 / 352與EGTEA的19 / 51詞彙量皆為原作母庫描述，非ICVL已核case數。
評估方式	§4.1的Ego4D：Nseg=8、Z=20、K=5，對noun / verb / action分別報minimum Damerau–Levenshtein ED。完整距離實作、正規化分母、三項是否各自取min及生成錯誤處理未核到。Ego4D只稱standard splits，Table1未明列具體版本 / 評測split ID。EK-55與EGTEA則沿EGO-TOPO設定：觀測首P%=25/50/75%，預測其餘部分的verbs only，於validation報multi-label mAP All/Freq/Rare；未取得序列轉verb分數、頻率分組與AP聚合程式。3個ICL例子、5條生成候選、8個觀測segments及20步預測是不同預算，均非題數。

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

可重用observed video→辨識labels / 生成intention→ICAF→LLM的資料流、training-only例子來源、距離融合規則、3-shot例子預算與原生Ego4D ED / EK-EGTEA verb-mAP規格。沒有已核ICVL模型實作或evaluator可接線。

需要轉換

source保留arXiv v1及母資料集依存；domain/environment限定離線人類影片。task分有序verb–noun forecasting與無序verb presence。case應儲存觀測視窗、原生labels、生成意圖、visual/text表示引用、3個training example IDs與5條預測；intention標為model_generated，訓練例子的future labels與test GT隔離。evaluator分開儲存ED與All/Freq/Rare mAP，母庫clips、frames及詞彙不展開成虛構案例。

仍需補齊

官方ICVL repo / commit、精確模型型號與版本、影格 / segment reader、資料 / 類別與split IDs、example pool及去重隔離規則、prompt/輸出parser、ED與verb-mAP scorer。需確認原文LLaMA 3.2-9B型號、α及frame抽樣值；不能借用AntGPT、PALM或STDD的程式視為ICVL已實作。

P246 · Decision-aware uncertainty

Decision-Aware Uncertainty Evaluation of Vision-Language Model-Based Early Action Anticipation for Human-Robot Interaction

實作尚未確認 · 主來源 · 原作 · 獨立頁面

已核固定v2全文的抽樣、三種聚合與不確定性評測公式；原作、cached search、精確arXiv-ID查詢及通訊作者lab頁仍未指向confirmed方法repo。可建立paper-level evaluator規格，但沒有reader、聚合器或scorer可宣稱已核讀；HRI結果是confidence gating模擬，非實體部署。

> **版本與身份**
>
> cached「decision aware uncertainty egocentric」repository query為0；一次「"2603.10061" in:readme」亦HTTP200、0筆、incomplete_results=false。arXiv v2摘要與PDF沒有本篇code連結；官方Mines lab的publications列表從2022開始，未列2026本篇，不能當作完整現時code庫清單。下列來源只支援尚未確認官方repo，不支援repo絕對不存在；本輪小型補查均200，未遇429或rate-limited403，未執行API模型、聚合器或robot。
>
> Decision-Aware Uncertainty Evaluation of Vision-Language Model-Based Early Action Anticipation for Human-Robot Interaction；Zhaoda Du、Michael Bowman、Qiaojie Zheng、Xiaoli Zhang。固定arXiv:2603.10061v2（2026-03-12），不是2026-03-09的v1。Mines lab首頁的Xiaoli Zhang及聯絡地址與論文對上。PDF第8頁的OpenReview DWkJCSxKU5屬引用的Generating with Confidence，不能借其code作本篇實作。

領域	餐飲與烹飪
環境	EGTEA Gaze+與EPIC-KITCHENS-100離線人類第一人稱影片，包含廚房活動；沒有本篇可reset的robot環境。§VI明言interaction analysis使用模擬confidence-gated decision policy，尚非real robotic deployment。母資料庫約10K及逾90K action segments不是本篇已核test case清單。
任務	雖摘要反覆使用short-term action recognition / temporal prefix措辭，§IV-A明確指定觀測action onset之前的影像、預測緊接的next action。因此保留pre-onset anticipation標記，不將本篇逕改成已開始動作的early recognition。輸出是同一未來動作的Top-K候選verb–noun labels及confidence，K是候選數，不是K步未來序列。Fig.1的after 1 s為示意；實際觀測時窗、提前量、取樣FPS與prefix切點並未由reader固定。

題數與資料	每input以Gemini 2.5 Flash-lite black-box API及相同prompt獨立抽樣M=5次，temperature=0.8，每次K=10。以a[i,k]記第i次第k順位動作、p[i,k]為該動作的verbalized confidence；這些是論文符號，非已核JSON key。Consistency逐rank多數決，c[k]為該rank支援勝出label的次數/M；Confidence-weighted逐rank以p加權，c[k]=勝出label的confidence總和 / 所有runs於該rank的confidence總和。PairRank先取跨runs唯一label集合A，由順位生成pairwise preferences，再以Bradley–Terry MLE擬合s(a)，softmax成P(a)並選Top-K。rank-wise confidence不必形成總和1的類別分佈，須保留各方法的原生尺度。單次baseline只有1次抽樣；M、K及唯一label數不能計成額外case。缺prompt、label正規化 / parser、實際prediction檔案、model revision、test ID與split reader。
評估方式	§III-C / IV-D：Top-1 accuracy與Recall@K按每input唯一GT動作比對。Top-1 ECE及Set-ECE均用[0,1]上的10個等寬bins；Set-ECE以z=1[GT在Top-K]為target、c_bar=(Σ_k c[k])/K為set confidence，再按bin樣本佔比加權絕對校準差。這是作者明定的平均confidence，不能暗換成Top-K機率總和。Selective policy只對首位label採c[1]≥τ；coverage分母為全部N個inputs，selective accuracy分母為通過門檻的inputs。Entropy另先將Top-K的c除以其總和，再算−Σp log p/log K；不得把此正規化後的p倒灌到原生ECE / gating。§IV-A稱官方train/test與test結果，但精確case IDs、GT取得 / 提交路徑、匹配規則、bin邊界與空bin / 零coverage處理均未核到。Fig.5的K=5、τ=0.39只是澄清範例，不是預設整批評測設定或安全保證。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **5** stochastic model calls per input · 原文頁 5

依這個順序讀

未確認可核讀的實作；下方保留已查過的原作、專案頁與檢索依據。

怎麼接入我們的benchmark

可重用

可保留pre-onset next-action目標、M=5 / K=10 / temperature0.8、三種aggregation公式、10-bin ECE、作者定義的Set-ECE、coverage/selective-accuracy分母及entropy診斷。尚無可直接重用的已核程式。

需要轉換

source固定v2與母資料集版本關係；domain/environment記人類影片觀測，HRI是評測動機。每case保留onset/observation boundary、GT verb/noun、每run每rank的raw label/confidence及聚合結果；evaluator分correctness、calibration、selective utility與confidence geometry，明記confidence構造及entropy專用正規化。保留abstain / retained case集合、model/prompt與取樣預算，不建立跨方法通用success score。

仍需補齊

作者可確認的repo / commit、精確觀測與test manifest、API model/prompt設定、動作同義詞 / label-ID parser、重複label及rank ties規則、Bradley–Terry擬合與正則化、零confidence / 零分母 / K=1 entropy邊界，以及完整ECE與gating實作。實體HRI控制、clarification真值及安全驗證不在本輪已取得來源內。

P247 · EgoSpanLift

Gaze Beyond the Frame: Forecasting Egocentric 3D Visual Span

檔案 / 網站 · 主來源 · 原作 · 獨立頁面

Gaze Beyond the Frame 的方法名為 EgoSpanLift，資料名為 FoVS-Aria / FoVS-EgoExo。官方 repo 目前只有發布預告，不能把論文的 364.6K samples 說成本案已取得資料。已從原文核對四層視覺區域、兩套父資料及時間窗。

> **版本與身份**
>
> 官方 README 的題名是 Gaze Beyond the Frame；EgoSpanLift 是方法別名而非另一獨立 benchmark。論文、資料子集、程式預告分開。

領域	居家整理與清潔、餐飲與烹飪、醫療與手術支援、交通移動與車輛維修、休閒與運動、音樂與表演、穿戴互動與動作介面
環境	FoVS-Aria 衍生自 Aria Everyday Activities（143 recordings、7.3 小時原始資料）；FoVS-EgoExo 衍生自 EgoExo4D 的 cooking / music / health / repair / bouldering 五類活動。物理 location、recording、活動用途與 voxel grid 各自不同單位。
任務	一個 3D visual-span forecasting 任務、四個輸出層：foveal 2°、central 8°、peripheral 30°、head orientation/FoV 約 55°。GT 是未來區間內看過區域的聯集，不保證逐幀 gaze 次序；四層不是四批獨立資料。
題數與資料	論文約 364.6K samples：FoVS-Aria 約 23.2K、FoVS-EgoExo 約 341.4K。Aria 2 秒歷史→2 秒未來、stride 1 秒、16^3 grid / 3.2 m cube / 20 cm cell，test 使用 location 4；EgoExo 預設預測 4 秒。原文 rounded split numbers 僅作約數儲存，不自行調整成精確整數。
評估方式	四層分別計 3D IoU / F1，另有 precision / recall 與 foveal metric distance。semi-dense SLAM 點與 gaze 產生區域，foveal 缺失不能自動當全負例；地圖可見時間、空 grid、threshold、聚合分母仍需未發布 evaluator 核對。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **2,100** FoVS-Aria test windows（約數） · 原文頁 7
- **37,000** FoVS-EgoExo test windows（約數） · 原文頁 8

- **364,600** combined forecast windows（約數） · 原文頁 1, 7, 8

依這個順序讀

1. README.md ↗
   GitHub · HS-YN/GazeBeyondFrame · 71e26f0b64

   官方題名與 NeurIPS 2025 身分相符；明示 Code and details will be released soon。

   L1–4

怎麼接入我們的benchmark

可重用

重用論文清楚定義的 gaze cone / voxel / future union 任務與父資料關係，可納入感知 / 預測任務目錄。

需要轉換

case 應保留 recording、location、observation_end、future window、SLAM map 可用範圍、gaze 校正、四層角度與 voxel 原點 / 尺寸；不把 gaze prediction 當 robot navigation success。

仍需補齊

公開 repo 沒有 loader、標註 manifest 或 evaluator；本次未取得產生後樣本、未執行方法，故不能列為可立即評測。

P248 · HOIMotion

HOIMotion: Forecasting Human Motion During Human-Object Interactions Using Egocentric 3D Object Bounding Boxes

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

HOIMotion 以過去人體姿態和頭部視角的 3D 物件框預測人體動作，重用 ADT / MoGaze。已核兩套 loader、跨參與者設定與 MPJPE；物件框頂點、圖節點和人物關節都不應計為任務數。

> **版本與身份**
>
> 官方來源固定 commit；ADT preprocessing 明載資料版本 1.1.0。default script 的 train→eval 不是唯讀測試命令，沒有在本機執行。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	Aria Digital Twin 與 MoGaze 的人類物件互動場景；ADT 原生 work / decoration / meal 三活動類，MoGaze pick / place 兩類，不能把五個標籤當五個新獨立物理環境。
任務	單一人體 3D motion forecasting 任務，按用途與 holdout participant 分組。21 joints，10 個過去 frame→30 個未來 frame（評分假設 30 Hz）；兩個 dynamic / 兩個 static objects，各 bbox 八個頂點作模型輸入。
題數與資料	原生 .npy 檔依 sequence 提供 pose xyz、head、dynamicbbx、staticbbx；loader 各自排序後用相同 list index 配對。每個連續 40-frame 視窗可重疊，train_sample_rate=2 只抽視窗，不把影片 FPS 降半。MoGaze 測試 p1 / p2 / p4 / p5 / p6 / p7 六個 holdouts，每人可有多個 session。
評估方式	MPJPE=未來各關節 xyz 歐氏距離的平均，先 batch 平均×batch_size 累加再除總 sample；輸出 mm、每未來 timestamp / joint 另列。zero-velocity baseline 重複末個觀測 pose。velocity loss 僅訓練用，沒有加到報告 MPJPE。ADT training 將 test 目錄作 validation 選 best checkpoint；MoGaze 也以 holdout participant 作 validation，完整模型選擇條件應保留。

依這個順序讀

1. `README.md` ↗

   GitHub · CraneHzm/HOIMotion · d2f4322c70

   確認兩個父資料集、訓練後測試的 shell 工作方式與人類研究範圍。

   L1–53

---

2. `adt_processing/README.md` ↗

   GitHub · CraneHzm/HOIMotion · d2f4322c70

   固定 ADT / Project Aria Tools 均為 1.1.0 的資料前處理依賴。

   L1–13

---

3. `utils/adt_dataset.py` ↗

   GitHub · CraneHzm/HOIMotion · d2f4322c70

   核對 work / decoration / meal、train/test 目錄、對應陣列及重疊切窗。

   L6–119

---

4. `utils/mogaze_dataset.py` ↗

   GitHub · CraneHzm/HOIMotion · d2f4322c70

   核對 pick / place、participant split、native 檔名與切窗。

   L6–113

---

5. `utils/opt.py` ↗

   GitHub · CraneHzm/HOIMotion · d2f4322c70

   固定 21 joints、10 history / 30 future、object counts 與取樣率。

   L15–55

---

6. `train_adt.sh` ↗

   GitHub · CraneHzm/HOIMotion · d2f4322c70

   區分 all 與三個 action 子集；指令碼先訓練再評分。

   L1–9

---

7. `train_mogaze_p1.sh` ↗
   GitHub · CraneHzm/HOIMotion · d2f4322c70

   確認 p1 holdout 與 pick/place 分組不是額外獨立資料。

   L1–7

---

8. `main_adt_pose_forecasting.py` ↗
   GitHub · CraneHzm/HOIMotion · d2f4322c70

   確認 test folder 用於 validation 選 checkpoint、只用過去物件資訊、MPJPE 分母。

   L17–97 · L257–373

---

9. `main_mogaze_pose_forecasting.py` ↗
   GitHub · CraneHzm/HOIMotion · d2f4322c70

   查核六個 participant holdout 的組成與相同 MPJPE 匯總。

   L16–81 · L295–411

怎麼接入我們的benchmark

可重用

可重用兩父資料的 actor/session、動作標籤、21-joint pose、3D bbox 與原生 MPJPE；使用者研究 N=20 是獨立感知評價，不併入樣本題數。

需要轉換

標準 case 以 parent sequence / window 起點識別，明定 30 Hz、21 joints / 米、過去 bbox 可見性與 split role；檔案配對改用 sequence key 並驗證一致。新增真正 untouched test split 時另列為擴充協定。

仍需補齊

本次未下載 ADT / MoGaze 原始素材、未執行訓練。各用途的精確視窗數需由完整檔案 manifest 重算；原始資料及工具授權 / 版本各自保留。

P249 · EgoCast

EgoCast: Forecasting Egocentric Human Pose in the Wild

核心內容已核讀 · 方法 / 綜述 · 原作 · 獨立頁面

EgoCast 的預設分支與 forecasting 分支是兩個不同版本。已追到預測分支的 loader→test_fcast→report；目前 pred_input=True 路徑會改寫回傳 gt，不能直接把這個快照視為可重現論文 ground-truth 評測。

> **版本與身份**
>
> default commit 1db0c6e 與 forecasting commit 6ba9eec7 各自鎖定。README 的影片下載範例重複 annotation 命令；需依父資料工具取得真正影像。此處只報靜態可查的路徑差異，不聲稱論文結果有誤。

領域	方法 / 綜述參考，未另作來源用途歸納。
環境	EgoExo4D 與 Aria Digital Twin 的人體姿態預測，沒有新機器人環境。已深入核讀的 forecast 路徑為 EgoExo4D；ADT loader 雖存在，本次未聲稱完整核對其 forecast evaluator。
任務	先估當前全身姿態，再由歷史頭部軌跡與估計姿態預測未來。論文比較 0.5 / 1 / 2 / 3 / 4 / 5 秒 horizons；default repo 的姿態估計、forecast branch 的預測與 oracle-GT pose input 必須分條件。
題數與資料	EgoExo4D take_uid、camera_pose、body annotation、17-joint skeleton、visible flags、time index、cached prediction route。forecast train config window_size=80、future_frames=15，test config 為 30；檔名與 dataroot 中的 fps 字樣不足以證明實際 sampling frequency。test loader 排除 take_name 含 bouldering，且為 prediction input 使用外部 camera 檔絕對路徑。
評估方式	test_fcast 滑窗產生多個預測，skeletal MPJPE 乘 visibility 後除 (error!=0) 計數，真正零誤差也被排除；速度沿相鄰視窗軸相減並乘 10，aria 分支乘 30，不能直接視為同一 future-time 速度。外層每 take 等權平均，跳過 enumerated index 17/62。更關鍵的是 pred_input=True 時 skeletons_window 被 cached prediction 覆蓋，且同變數作輸入及回傳 gt，feed_data→test_fcast 沿用；需修復 / 核實獨立 GT 才能發布結果。論文的跨 horizon AUC 不在本次讀到的 caller 中實作。

依這個順序讀

1. `README.md` ↗

   GitHub · BCV-Uniandes/EgoCast · 1db0c6e185

   確認父資料、current-frame estimation 與 forecasting 分支的官方指示。

   L1–137

---

2. `options/train_egocast_forecasting.json` ↗

   GitHub · BCV-Uniandes/EgoCast · 6ba9eec74f

   固定 80-frame history / 15 future 與 pred_input 設定。

   L1–98

---

3. `options/test_egocast_forecasting.json` ↗

   GitHub · BCV-Uniandes/EgoCast · 6ba9eec74f

   對照 test future_frames=30、來源路徑、checkpoint 與 train 設定差異。

   L1–96

---

4. `data/dataset_egoexo.py` ↗

   GitHub · BCV-Uniandes/EgoCast · 6ba9eec74f

   確認 take 篩選、17 joints、cached prediction 載入及 gt 變數沿用。

   L361–462 · L568–662

---

5. `models/model_egocast.py` ↗

   GitHub · BCV-Uniandes/EgoCast · 6ba9eec74f

   追到 sample 的 gt、滑窗 forecast、zero-error 分母及速度軸。

   L182–198 · L406–484

---

6. `main_train_egocast.py` ↗

   GitHub · BCV-Uniandes/EgoCast · 6ba9eec74f

   核對跳過 index 17/62、每 take 等權平均、cm 輸出與實際 test caller。

   L234–315

怎麼接入我們的benchmark

可重用

可重用 current-estimation→forecast 的任務分解、take / frame 對照、17-joint schema；固定兩個 branch commits 與父資料版本。

需要轉換

以 task 記錄 forecasting 目標，case 指明 estimated-pose 或 GT-pose 條件、history / horizon / sampling、visibility 和獨立 GT 資產。將 default / forecast revision 分開；修訂 gt、mask、velocity 或 index exclusions 時新增 evaluator version 與原生對照。

仍需補齊

未下載完整 EgoExo / ADT、cached predictions 或 checkpoint，未執行模型。當前原始碼有上述評分鏈缺口與本機路徑依賴，尚不能認為可直接重現 paper horizon curve。

P250 · EgoMAN

Flowing from Reasoning to Motion: Learning 3D Hand Trajectory Prediction from Egocentric Human Interaction Videos

核心內容已核讀 · 主來源 · 原作 · 獨立頁面

EgoMAN 將人類 6DoF 手部軌跡和推理 QA 配對，適合加入語意→預測的共同目錄；官方明確表示 processed dataset 與 model weights 不發布。已核資料建立、loader、trajectory / waypoint 評分鏈，不能把 repo 可讀當成 219K 軌跡或 3M QA 已可下載評測。

> **版本與身份**
>
> 固定官方 commit；README 提到新 DINOv3 / Qwen3-VL 等依賴，不能假設與 paper checkpoints 完全相同。raw metrics 的 closest_pred 選 minADE，summary 則用 ADE+ROT 係數，兩種 best index 必須分清；已有 processed.pkl 時會跳過重算，需用來源 / evaluator hash 隔離。

領域	居家整理與清潔、餐飲與烹飪、交通移動與車輛維修、穿戴互動與動作介面
環境	人體互動影片的 EgoExo4D / Nymeria 衍生資料，HOT3D 作 OOD。camera-relative 手腕軌跡與人體視角推理不是機器人 actuator 命令；需保留原資料 take/sequence 關係。
任務	語意 / 空間 / 時間 / 階段 QA 與 3D 雙手 6DoF trajectory prediction。approach/contact/end stage、任務文字和兩種輸出共用 interaction clip；不把 3M QA 與 219K 軌跡相加成獨立情境。
題數與資料	README 報告 219K 軌跡 / 3M structured QA，processed dataset 及權重不公開。原生 meters、10 Hz、position+xyzw；模型以每手 position3+rotation6 的 18D 表達、past 5 frames，未來 tensor 最多 50 slots、−1000 sentinel。影片 / tracking timestamp ns/us、reference camera transform、stage annotation 及自動 QA provenance 必須同存。品質篩選要求接觸 / 結束可見且非平凡動作，會影響難度分佈。
評估方式	trajectory：ADE/FDE 公尺、DTW按 warping path length 正規化、ROT度。GT有效 mask 為每 frame 任一座標非−1000，未逐手遮罩；空 GT 回零值且少 best_idx 欄，正式入口需拒收此情況。summary 的 best-of-K 選 ADE+0.001×ROT 最小同一條候選，再報四項，與單純 minADE / 各指標各取最小不同。waypoint 取各方法 key 交集，>2 點以 GT 選最佳成對候選；--shift 僅對非 EgoMAN/GT 方法向 GT / 最近軌跡點移最多 0.06m，各欄忽略 NaN 後平均。這是帶 oracle / 容忍補償的協定，不能當實際物理接觸成功率。

▼ 原作數字：保留論文的單位與頁碼

下列為既有原文審閱摘錄；GitHub快照和本庫取得範圍另見上文，不互相代替。

- **2,844** EgoMAN-Unseen trajectory cases · 原文頁 4
- **990** HOT3D-OOD trajectory cases · 原文頁 4
- **3,000,000** structured QA supervision（概要約數） · 原文頁 1, 2

依這個順序讀

1. `README.md` ↗
   GitHub · facebookresearch/egoman · 20f19ccf31

   核對 219K / 3M、未發布資料與權重、座標 / 頻率、QA 與評分入口。

   `L1–140 · L159–244 · L319–416`

---

2. `dataset/scripts/step4_6dof_traj_process.py` ↗
   GitHub · facebookresearch/egoman · 20f19ccf31

   追蹤 ns→us 最近幀、10 Hz、reference-camera 轉換與輸出。

   `L106–140 · L626–651 · L786–855 · L866–885`

---

3. `dataset/scripts/step6_traj_quality_filter_rules.py` ↗
   GitHub · facebookresearch/egoman · 20f19ccf31

   讀 contact/end 可見性、位移 / 旋轉與 grasp/pick approach 篩選規則。

   `L137–258`

---

4. `dataset/dataloaders/joint_finetune_dataset.py` ↗
   GitHub · facebookresearch/egoman · 20f19ccf31

   確認 value→past/future tensor、xyzw→rot6d、sentinel 與壞樣本替換。

   `L489–566 · L638–715`

---

5. `model/tools/egomanbench_metrics.py` ↗
   GitHub · facebookresearch/egoman · 20f19ccf31

   查核 5 past frame 移除、HOT3D / unseen routing、K=1/5/10 與結果快取。

   `L21–164`

---

6. `utils/eval_utils/metrics.py` ↗
   GitHub · facebookresearch/egoman · 20f19ccf31

   核對 ADE / FDE / DTW / ROT、frame mask、空標註與最優候選。

   L14–152 · L185–352 · L435–499

---

7. `utils/eval_utils/metrics_summary.py` ↗
   GitHub · facebookresearch/egoman · 20f19ccf31

   追蹤 summary 使用 ADE+0.001×ROT 選同一候選、每 sample 平均與 K cap。

   L279–455 · L463–555 · L636–676

---

8. `model/tools/waypoint_metrics.py` ↗
   GitHub · facebookresearch/egoman · 20f19ccf31

   核對 GT-oracle candidate pair、最多 6 cm shift、method交集與有限值分母。

   L34–53 · L106–138 · L283–340 · L388–423 · L456–474

怎麼接入我們的benchmark

可重用

可重用 trajectory / QA / stage 關聯結構、來源追蹤、建立標註的方法和四種幾何誤差定義；code 與 data 授權及發布範圍各自儲存。

需要轉換

case 固定 parent clip、標註者 / 模型與生成版本、起訖與合法過去輸入、meters / xyzw / rot6d、validity mask。將 raw single prediction、oracle best-of-K、shifted waypoint 分開報表；所有 expected cases 的遺漏 / 失敗另報 coverage。評測 loader 禁止訓練式壞樣本換下一筆。

仍需補齊

未發布 processed dataset / 模型權重，所以本案未取得這 219K / 3M 樣本，也未跑推論或 GPT 標註。QA correctness evaluator 與完整基線資產不在本次 trajectory 核讀範圍；新任務需要獨立取得合法資料並完成標註 / 評分驗證。